TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - Nguyễn Gia Kiệt

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

TP. HỒ CHÍ MINH, THÁNG 08/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - 22127390
Nguyễn Gia Kiệt - 22127221

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

GIẢNG VIÊN HƯỚNG DẪN
PGS.TS. Lý Quốc Ngọc
ThS. Đỗ Thị Thanh Hà

TP. HỒ CHÍ MINH, THÁNG 08/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc lập – Tự do – Hạnh phúc

BẢN THUYẾT MINH CHỈNH SỬA BÁO CÁO ĐỀ TÀI KHÓA LUẬN TỐT NGHIỆP

Tên đề tài: Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức

Sinh viên thực hiện:

- Nguyễn Gia Kiệt - MSSV: 22127221
- Nguyễn Văn Lê Bá Thành - MSSV: 22127390

Hội đồng bảo vệ: Thị Giác Máy Tính
Ngày bảo vệ: 28/08/2026

(Chúng) tôi đã hoàn chỉnh khóa luận tốt nghiệp theo góp ý của Hội đồng và nhận xét của Giảng viên phản biện. Nội dung đã hiệu chỉnh như sau:

Tên đề tài đã điều chỉnh: (nếu có)

Tiếng Việt : Không thay đổi
Tiếng Anh : Không thay đổi

Điều chỉnh nội dung báo cáo: (Ghi rõ nội dung, chỉ rõ vị trí chỉnh sửa: trang/chương…)

1. **BỔ SUNG CÁC DANH MỤC TỪ VIẾT TẮT VÀ DANH MỤC THUẬT NGỮ**
   - **Vị trí cũ:** Chưa có danh mục từ viết tắt và danh mục thuật ngữ.
   - **Vị trí mới:** Trang xii và xiii.
   - **Nội dung hiệu chỉnh:** Bổ sung Danh mục từ viết tắt (trang xii) định nghĩa rõ ràng 15 từ viết tắt cốt lõi xuất hiện nhiều lần (AI, Acc, BAcc, BERT, BTXRD, CLIP, CNN, CTCH, FN, FP, TN, TP, TPR, ViT, VLM). Bổ sung Danh mục thuật ngữ Anh-Việt (trang xiii) định nghĩa các khái niệm chuyên ngành (như Ablation study, AUROC-OOD, Baseline, Bidirectional cross-attention, Bootstrap, v.v.).

2. CHƯƠNG 1: GỘP MỤC VÀ TÁI CẤU TRÚC NỘI DUNG

- **Vị trí cũ:** Tách rời Mục 1.1 'Bối cảnh và lý do chọn đề tài' (trang 1) và Mục 1.2 'Động lực nghiên cứu' (trang 3). Đóng góp chính nằm ở mục 1.8 (trang 11) còn lan man và chưa nổi bật đóng góp chính.
- **Vị trí mới:** Mục 1.1 (trang 1-4), mục 1.1.1 (trang 3-4), mục 1.2 (trang 5), mục 1.7 (trang 12).
- **Nội dung hiệu chỉnh:** Gộp mục 1.1 and 1.2 thành một mục duy nhất '1.1 Bối cảnh, động lực và nhu cầu nghiên cứu' (trang 1-4) để tăng tính chặt chẽ, loại bỏ các diễn giải trùng lặp và làm rõ động lực phát triển hệ thống đa phương thức.

+ Bổ sung tiểu mục 1.1.1 'Vị trí hệ thống trong quy trình khám chữa bệnh lý xương' (trang 3-4) và sơ đồ tích hợp hệ thống hỗ trợ chẩn đoán XBone-Net vào luồng lâm sàng thực tế (Hình 1.2, trang 4) để làm nổi bật ứng dụng thực tiễn.

+ Viết lại mục Đóng góp chính (mục 1.7 mới, trang 12) cô đọng hơn, loại bỏ các câu chữ rườm rà và làm nổi bật 3 đóng góp khsoa học lớn của nhóm: (1) Quy trình thích nghi XBone-Net từ BiomedCLIP bằng LoRA, quy trình huấn luyện hai pha và chú ý chéo hai chiều; (2) Đánh giá thực nghiệm có hệ thống về hiệu năng và chi phí tính toán (bổ sung kịch bản thực nghiệm đối chứng lớn "Chỉ ảnh" để làm nổi bật vai trò của bệnh sử lâm sàng); (3) Đánh giá độ tin cậy thông qua cảnh báo dữ liệu ngoài phân phối (OOD) hậu xử lý từ không gian biểu diễn k-NN đa phương thức và truy vết nguồn phụ thuộc dự đoán bằng tích phân gradient (Integrated Gradients) kết hợp can thiệp đầu vào.

Trích dẫn minh chứng từ mục 1.7 mới: *"Đóng góp cốt lõi của khóa luận là xây dựng và đánh giá XBone-Net, một mô hình đa phương thức thích nghi từ BiomedCLIP bằng LoRA, quy trình huấn luyện hai pha và..."*

3. CHƯƠNG 2: ĐỒNG BỘ KÍ HIỆU, BỎ TỪ TIẾNG ANH

- **Vị trí cũ:** Bắt đầu từ trang 14.
- **Vị trí mới:** Bắt đầu từ trang 14.
- **Nội dung hiệu chỉnh:** Đồng bộ hóa, giảm triệt để các thuật ngữ học thuật bằng tiếng anh và các ký hiệu toán học tương thích với Danh mục thuật ngữ Anh-Việt và Danh mục ký hiệu.

4. CHƯƠNG 3: GIẢM THIỂU TỪ NGỮ CHUYÊN NGÀNH, GIẢI THÍCH CƠ CHẾ GIẢM DƯƠNG SAI, ÂM SAI

- **Vị trí cũ:** Mục 3.3 (trang 33) và 3.4 (trang 34). Từ chuyên ngành được sử dụng một cách tối nghĩa như "Phân tách từ tố". Chưa giải thích rõ thành phần nào giải quyết âm sai và dương sai.
- **Vị trí mới:** Mục 3.3 (trang 34) và mục 3.4 (trang 36-38).
- **Nội dung hiệu chỉnh:**

+ Bỏ thuật ngữ 'phân tách từ tố', ghi dễ hiểu hơn "Tách văn bản thành các đơn vị mã hóa" kèm giải thích (trang 34)

+ LoRA (Mục 3.4, trang 36-38): Đổi tên mục thành 'Thích nghi hạng thấp bộ mã hóa bằng LoRA'.

+ Đồng bộ hóa ký hiệu toán học: Đồng bộ các ký hiệu, biến số toán học trong toàn bộ Chương 3 khớp với Danh mục ký hiệu ở trang xv.

+ Phân tích cơ chế giảm dương sai (FP) và âm sai (FN): Đề cập đến việc sử dụng hàm khớp mất mát ngữ nghĩa để giảm âm sai tại phần 3.6.1 (trang 42), giảm dương sai bằng việc sử dụng làm trơn nhãn trong hàm mất mát phân loại cross-entropy ở phần 3.6.2 (trang 45)

5. CHƯƠNG 4: SO SÁNH ĐỐI CHỨNG VÀ ĐỒNG BỘ SỐ LIỆU

- **Vị trí cũ:** Mục 4.2.3 (trang 64) chưa có cấu hình đối chứng 'chỉ ảnh'. Mục 4.3 (trang 68-71) nghiên cứu loại bỏ thành phần (Ablation Study) còn sơ khai. Số liệu không đồng nhất giữa Tóm tắt, Chương chính và Phụ lục.
- **Vị trí mới:** Mục 4.2.3 (trang 65-71), Bảng 4.9 (trang 65), Bảng 4.14 (trang 73), Bảng 4.15 (trang 76), Bảng 4.16 (trang 78), Mục 4.3 (trang 72-74).
- **Nội dung hiệu chỉnh:** Đồng bộ hóa số liệu thực nghiệm thực tế: Số lượng tham số cập nhật LoRA là 8.44 triệu (chiếm 4.13% tổng số tham số). Chi phí tính toán đạt 82.318 GFLOPs (tăng 1.6% do mô-đun dung hợp). Điểm số Macro-F1 trên BTXRD là 0.6240 và CTCH là 0.5727.

+ Đánh giá vai trò của bệnh sử lâm sàng: Huấn luyện thêm cấu hình 'XBone-Net (chỉ ảnh)' làm đối chứng theo nguồn đầu vào. Bổ sung Bảng 4.9 so sánh trực tiếp kết quả phân lớp CTCH giữa cấu hình chỉ ảnh so với đầy đủ phương thức: Accuracy tăng từ 0.4439 lên 0.6183 (+0.1744); Balanced Accuracy tăng từ 0.4843 lên 0.5935 (+0.1092); Macro-F1 tăng từ 0.3813 lên 0.5727 (+0.1914). Bổ sung đối chứng chỉ ảnh vào Bảng 4.15 giúp AUROC-OOD tăng từ 0.5598 lên 0.7598 (+0.2000). Bổ

sung đối chứng chỉ ảnh vào Bảng 4.16 chứng minh mô hình đa phương thức phân bổ sự phụ thuộc cân bằng lên cả ảnh (0.3187) và bệnh sử (0.2725) thay vì chỉ tập trung vào kênh thị giác.

+ Hoàn thiện nghiên cứu loại bỏ thành phần (Ablation Study): Xây dựng thêm 2 cấu hình đối chứng tại Mục 4.3 và Bảng 4.14: Biến thể 'Chỉ pha 2' (loại bỏ pha khớp ngữ nghĩa) và Biến thể 'Nối đặc trưng' (thay thế bộ dung hợp bằng chú ý chéo hai chiều bằng phép nối đặc trưng đơn giản). Nhóm tiến hành kiểm định ghép cặp hoán vị (hiệu chỉnh đa so sánh Holm) trên 10.000 lần bootstrap và trình bày kết quả tại Bảng 4.14: dù XBone-Net đạt điểm số quan sát cao nhất (Acc 0.6183, F1 0.5727), chênh lệch chưa đạt ý nghĩa thống kê (p_Holm >= 0.05), từ đó đưa ra giả thuyết khoa học và định hướng kiểm định sâu rộng hơn.

6. CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN (MỞ RỘNG ĐỊNH HƯỚNG NGHIÊN CỨU)

- **Vị trí cũ:** Chương 5 (trang 77-84) trình bày còn quá dài và lặp nội dung giữa các hướng phát triển.
- **Vị trí mới:** Chương 5 (trang 81-84).
- **Nội dung hiệu chỉnh:** Nhóm đã cô đọng và cụ thể hóa còn 5 định hướng nghiên cứu lớn trong tương lai để giải quyết các hạn chế học thuật hiện tại: (1) Mở rộng kiểm định và làm rõ đóng góp thành phần; (2) Cải thiện phân loại tổn thương nhỏ và lớp hiếm; (3) Cải thiện cảnh báo OOD và xử lý đầu vào thiếu hoặc nhiễu; (4) Kiểm chứng độ ổn định và ý nghĩa của lời giải thích; (5) Giảm chi phí và đánh giá khả năng hỗ trợ thực tế.

7. PHỤ LỤC A: KIỂM TRA RÒ RỈ NHÃN GIÁN TIẾP

- **Vị trí cũ:** Mục A.1.2 (trang 94-99) chưa có phần đánh giá định lượng rủi ro rò rỉ nhãn từ quy trình sinh văn bản tổng hợp.
- **Vị trí mới:** Phụ lục A.1.2 (trang 94-99) & Bảng A.5.
- **Nội dung hiệu chỉnh:** Nhóm đã bổ sung nghiên cứu định lượng độc lập để loại trừ triệt để rủi ro rò rỉ nhãn gián tiếp/shortcut trong văn bản BTXRD được sinh từ các cờ nhóm bệnh:

+ Tiến hành rà soát tự động 3.746 văn bản, không phát hiện trường hợp tên bệnh đích xuất hiện trực tiếp.

+ Sử dụng bộ mã hóa BiomedCLIP để tính Cosine margin trung bình giữa

embedding văn bản của mẫu và câu nhắc đúng nhãn so với nhãn khác gần nhất.

+ Kết quả Cosine margin trung bình đạt -0.0400 (giá trị âm), chứng minh một cách khoa học rằng tên bệnh đích không bị rò rỉ trực tiếp hoặc gián tiếp, triệt tiêu nguy cơ học tủ (shortcut learning) từ văn bản tổng hợp.

8. PHỤ LỤC B & C: BỔ SUNG ĐỐI CHỨNG

- **Vị trí cũ:** Phụ lục B (trang 106) và Phụ lục C (trang 111) thiếu cấu hình đối chứng chỉ ảnh và các thông số cài đặt tương ứng.
- **Vị trí mới:** Phụ lục B (trang 106) và Phụ lục C (trang 111).
- **Nội dung hiệu chỉnh:** Tại Phụ lục B: Bổ sung cấu hình siêu tham số chi tiết của mô hình đối chứng 'XBone-Net (chỉ ảnh)', bao gồm kích thước batch, tốc độ học, cấu hình LoRA cụ thể và chi tiết cài đặt hàm mất mát Weighted Cross-Entropy kết hợp làm trơn nhãn (Bảng B.5, trang 117).

+ Tại Phụ lục C: Bổ sung bảng thống kê kết quả thực nghiệm chi tiết theo từng hạt giống (seed) chạy ngẫu nhiên cho cả mô hình XBone-Net đầy đủ và mô hình đối chứng chỉ ảnh, đảm bảo tính minh bạch, khả năng tái lặp (reproducibility) cao của nghiên cứu khoa học.

Tp. Hồ Chí Minh, ngày 9 tháng 9 năm 2026

Xác nhận của Giảng viên hướng dẫn
(Ký tên, ghi rõ họ tên)

Lý Quốc Ngọc

Đỗ Thị Thanh Hải

(Nhóm) Sinh viên
(Ký tên, ghi rõ họ tên)

Nguyễn Gia Kiệt

Nguyễn Văn Lê Bá Thành

Xác nhận của Giảng viên phản biện
(Ký tên, ghi rõ họ tên)

Phạm Minh Hoàng

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc lập – Tự do – Hạnh phúc

BẢN NHẬN XÉT KHÓA LUẬN TỐT NGHIỆP

(HƯỚNG NGHIÊN CỨU)

Tên đề tài: PHÁT TRIỂN HỆ THỐNG PHÂN LỚP ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO HỌC SÂU ĐA PHƯƠNG THỨC

Sinh viên thực hiện: Nguyễn Văn Lê Bá Thành – 22127390

Nguyễn Gia Kiệt – 22127221

Giảng viên hướng dẫn: PGS.TS. Lý Quốc Ngọc; ThS. Đỗ Thị Thanh Hà

1. Chủ đề và ý tưởng nghiên cứu:

Đề tài xây dựng XBone-Net cho phân lớp bệnh lý xương trên ảnh X-quang, kết hợp ảnh và bệnh sử lâm sàng; đồng thời khảo sát cảnh báo mẫu ngoài phân bố đã học và giải thích dự đoán.

Hướng nghiên cứu có tính thực tiễn và phù hợp xu hướng AI đa phương thức trong y tế.

2. Phương pháp nghiên cứu:

Mô hình kế thừa BiomedCLIP, thích nghi bằng LoRA theo hai giai đoạn, dung hợp ảnh–văn bản bằng chú ý chéo; thực nghiệm trên BTXRD và CTCH, có đối sánh và khảo sát loại trừ.

Hạn chế chính: mô tả cấu hình XBone-Net chưa nhất quán; văn bản BTXRD sinh từ metadata/cờ nhóm bệnh có nguy cơ shortcut và rò rỉ nhãn gián tiếp; ablation chưa tách đầy đủ vai trò từng thành phần.

3. Đóng góp Khoa học và thực tiễn:

Điểm mới của khóa luận nằm ở việc xây dựng một qui trình thích nghi BioMedCLIP chuyên biệt cho phân lớp X-quang xương đa phương thức, kết hợp LoRA hai giai đoạn, semantic alignment và bidirectional cross-attention, cùng một quy trình đánh giá OOD và explainability; tính mới ở mức tích hợp hệ thống và thực nghiệm, chưa phải mới về phương pháp.

Khóa luận đề xuất cách tích hợp Semantic Matching kế thừa từ MedCLIP với BioMedCLIP–LoRA trong pha thích nghi, sau đó dùng bidirectional cross-attention để dung hợp ảnh X-quang và bệnh sử trong pha phân lớp.

Khóa luận xây dựng được quy trình thích nghi đa phương thức với số tham số cập nhật thấp, đồng thời đánh giá hiệu năng–chi phí, OOD và truy vết nguồn dự đoán.

Kết quả cho thấy mô hình cạnh tranh về Macro-F1 nhưng chưa vượt trội nhất quán; OOD hiện mới phù hợp làm cảnh báo bổ trợ.

Điểm giá trị về thực tiễn là khóa luận đã thử nghiệm trên bộ dữ liệu từ bệnh viện Chấn thương chỉnh hình gồm cả dữ liệu lâm sàng và cận lâm sàng.

Bốn thách thức trung tâm nhất mà phương pháp XBone-Net thực sự nhắm trực tiếp tới là: **dữ liệu ít/mất cân bằng, thích ứng miền dữ liệu, kết hợp đa phương thức và phát hiện ngoài phân bố**. Phần giữ độ phân giải cao và tính khả diễn có xét đến, nhưng bằng chứng thực nghiệm cho hai phần này chưa mạnh bằng các phần còn lại

4. Quá trình thực hiện và quản lý dự án:

Khóa luận hoàn thành các nội dung chính: xây dựng phương pháp, chuẩn bị dữ liệu, thực nghiệm nhiều hạt giống và phân tích thành phần. Cần đồng bộ lại phiên bản mô hình và số liệu giữa tóm tắt, chương chính và phụ lục trước khi bảo vệ.

5. Báo cáo viết:

Bố cục tương đối đầy đủ, có câu hỏi nghiên cứu, thiết kế thực nghiệm, độ đo và phụ lục.

Cần sửa các mâu thuẫn về classifier, tiền xử lý ảnh, phương pháp OOD, kích thước biểu diễn và các số liệu GFLOPs, tham số, Macro-F1/AUROC; đồng thời thống nhất thuật ngữ và ký hiệu.

Cần đánh giá vai trò của dữ liệu lâm sàng trong phân lớp ảnh đối với các thách thức: dữ liệu ít/mất cân bằng, thích ứng miền dữ liệu, phát hiện ngoài phân bố. Lập bảng thống kê kết quả phân lớp có dùng và không dùng dữ liệu lâm sàng.

Cần nêu rõ các kỹ thuật nào đã dùng trong khóa luận có tác dụng nhằm giảm kết quả dương sai (FP), âm sai (FN).

6. Trình bày trước hội đồng:

Trình bày các nội dung và đóng góp chính của khóa luận. Trả lời đáp ứng yêu cầu của hội đồng.

7. **Công bố khoa học/ ứng dụng thực tế:**

Khóa luận hướng đến hệ thống hỗ trợ phân loại X-quang xương. Báo cáo chưa nêu công bố khoa học đã được chấp nhận/xuất bản; kết quả cần được kiểm định thêm trên dữ liệu đa trung tâm trước khi xem xét ứng dụng thực tế.

Đánh giá xếp loại: xuất sắc

TP.HCM, ngày 28 tháng 08 năm 2026

Giảng viên hướng dẫn

PGS.TS. Lý Quốc Ngọc; ThS. Đỗ Thị Thanh Hà

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc lập – Tự do – Hạnh phúc

BẢN NHẬN XÉT KHÓA LUẬN TỐT NGHIỆP

(HƯỚNG NGHIÊN CỨU)

Tên đề tài :Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức

Sinh viên thực hiện : 22127390 –Nguyễn Văn Lê Bá Thành

22127221 –Nguyễn Gia Kiệt

Giảng viên phản biện: ThS Phạm Minh Hoàng.....

1. **Chủ đề và ý tưởng nghiên cứu:**

Ảnh X-quang là dữ liệu chẩn đoán hình ảnh phổ biến, chi phí thấp, hỗ trợ bác sĩ trong quá trình chuẩn đoán bệnh lý về xương và phát hiện tổn thương. Tuy nhiên, việc đọc phim truyền thống gặp khó khăn khi tổn thương nhỏ, ảnh có độ tương phản thấp hoặc khối lượng ca đọc lớn, khiến kết quả phụ thuộc nhiều vào kinh nghiệm và sự tập trung của bác sĩ. Các mô hình học sâu hiện có thường chỉ khai thác thông tin hình ảnh mà bỏ qua dữ liệu lâm sàng đi kèm (triệu chứng, tiền sử, cơ chế chấn thương), trong khi thực tế bác sĩ luôn kết hợp cả hai nguồn thông tin khi ra quyết định. Khóa luận đề xuất một hệ thống khai thác đồng thời ảnh X-quang và dữ liệu văn bản lâm sàng để dự đoán lớp bệnh lý, nhằm mô phỏng sát hơn quy trình chẩn đoán thực tế.

2. **Phương pháp nghiên cứu:**

Khóa luận khảo sát các công trình liên quan, từ mô hình kết hợp ngôn ngữ – hình ảnh đến mô hình ngôn ngữ trực quan y khoa, và lựa chọn BiomedCLIP làm mô hình nền; đồng thời khảo sát các phương pháp tinh chỉnh tham số hiệu quả (dùng câu nhắc, bộ điều hợp, tinh chỉnh thích nghi) và các phương pháp phát hiện mẫu ngoài phân phối.

Trên cơ sở đó, khóa luận đề xuất mô hình XBoneNet kết hợp đặc trưng hình ảnh và văn bản, tinh chỉnh bằng LoRA, và thực nghiệm trên hai tập dữ liệu BTXRD, CTCH với các độ đo accuracy, macro-F1, macro-AUROC, macro-AUPRC, so sánh với các phương pháp baseline để đánh giá hiệu quả.

3. **Đóng góp Khoa học và thực tiễn:**

Đề xuất quy trình XBoneNet tinh chỉnh BiomedCLIP bằng LoRA cho bài toán phân lớp X-quang xương, huấn luyện hai pha kết hợp cơ chế chú ý chéo hai chiều nhằm giảm số tham số huấn luyện.

Thiết kế bộ dung hợp đa phương thức dựa trên chú ý chéo hai chiều để kết hợp đặc trưng hình ảnh và văn bản.

Thiết kế bộ phân loại tuyến tính để ra kết quả phân loại cuối cùng

4. Báo cáo viết:

Báo cáo viết gồm 5 chương, đúng bố cục quy định của khóa luận tốt nghiệp. Một số điểm cần chỉnh sửa:

- Bổ sung danh mục từ viết tắt và danh mục thuật ngữ tiếng Anh.
- Gộp mục 1.1 và 1.2 thành một mục, nêu rõ động lực và nhu cầu giải quyết bài toán.
- Viết lại mục 1.8 (đóng góp chính) ngắn gọn, làm nổi bật đóng góp cốt lõi của khóa luận.
- Giải thích các thuật ngữ chuyên ngành còn dùng chưa rõ nghĩa, ví dụ "phân tách từ tố" (trang 33, mục 3.3), "thích nghi tham số hiệu quả bằng LoRA" (mục 3.4).

5. Trình bày trước hội đồng:

Trình bày còn lan man, dài dòng, chưa tập trung vào các đóng góp chính

6. Công bố khoa học/ ứng dụng thực tế:

Không có công bố khoa học

Đánh giá xếp loại: Đạt yêu cầu khóa luận, với điều kiện chỉnh sửa báo cáo viết theo các góp ý nêu trên.

TP.HCM, ngày 28 tháng 08 năm 2026

Giảng viên phản biện

(*Ký và ghi rõ họ tên*)

Phạm Minh Hoàng

Lời cam đoan

Nhóm xin cam đoan đây là công trình nghiên cứu của riêng nhóm. Dữ liệu và kết quả nghiên cứu trong khóa luận này là trung thực và không trùng lặp với bất kỳ chủ đề nào khác. Nhóm cam đoan toàn bộ nội dung khóa luận này không đạo văn hoặc sao chép từ các công trình nghiên cứu khác. Ngoài ra, trong quá trình nghiên cứu và viết khóa luận, nhóm tuân thủ nghiêm ngặt các quy định về bảo mật do các tập dữ liệu nhóm sử dụng trong nghiên cứu của mình cung cấp. Hơn nữa, nhóm luôn tuân thủ mọi nguyên tắc đạo đức trong suốt quá trình nghiên cứu. Nhóm đảm bảo rằng tất cả các nguồn và tài liệu tham khảo đều được trích dẫn đúng cách và nhóm duy trì tính chính trực học thuật trong mọi khía cạnh công việc của mình.

Lời cảm ơn

Nhóm xin chân thành cảm ơn PGS.TS Lý Quốc Ngọc và ThS. Đỗ Thị Thanh Hà đã dành rất nhiều thời gian, tâm huyết để định hướng, tận tình hướng dẫn và đưa ra những lời khuyên quý báu cho nhóm trong suốt quá trình nghiên cứu và thực hiện khóa luận tốt nghiệp với đề tài "Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức".

Xin trân trọng gửi lời cảm ơn sâu sắc đến Ban Chủ nhiệm cùng toàn thể quý thầy cô Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG-HCM. Những kiến thức nền tảng vững chắc mà các thầy cô đã truyền đạt trong bốn năm học vừa qua và môi trường thí nghiệm tuyệt vời chính là hành trang quan trọng nhất giúp nhóm có thể hoàn thành tốt hướng nghiên cứu này.

Nhóm cũng xin gửi lời cảm ơn đến các y bác sĩ tại Bệnh viện Chấn thương Chỉnh hình TP.HCM, thầy Đỗ Phúc Thịnh và thầy Võ Thế Hào đã hỗ trợ chia sẻ nguồn dữ liệu ảnh X-quang cũng như tư vấn các kiến thức chuyên môn về y khoa, giúp mô hình nghiên cứu bám sát với quy trình chẩn đoán thực tế.

Mặc dù đã có nhiều cố gắng trong quá trình thực hiện, nhưng do hạn chế về mặt thời gian và kinh nghiệm nghiên cứu, khóa luận chắc chắn không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô và hội đồng đánh giá để đề tài được hoàn thiện hơn.

Xin chân thành cảm ơn!

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO HỌC SÂU ĐA PHƯƠNG THỨC

(Developing a bone X-ray image classification system based on multimodal deep learning)

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm Sinh viên thực hiện:

1. Nguyễn Văn Lê Bá Thành (MSSV: 22127390)
2. Nguyễn Gia Kiệt (MSSV: 22127221)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ *02/2026* đến *08/2026*

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn đầu. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, các nghiên cứu hiện nay đã ứng dụng các mô hình học sâu vào để giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ để đưa vào ứng dụng thực tế. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để bổ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác. Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống.

Khác với các mô hình đơn phương thức chỉ xử lý trên một phương thức như ảnh hay văn bản duy nhất, các mô hình đa phương thức có thể sử dụng nhiều phương thức và tìm ra sự tương quan giữa các phương thức nhằm tạo nên biểu diễn có ý nghĩa hơn từ đó nâng cao hiệu năng của hệ thống. Với thực tế lâm sàng hiện nay, các mô hình nghiên cứu tập trung

vào kết hợp ngôn ngữ và hình ảnh hay còn được gọi là mô hình ngôn ngữ trực quan đang là các mô hình đang nhận được nhiều sự chú ý.

2.2 Định nghĩa các khái niệm

Thông tin lâm sàng

Thông tin lâm sàng là những dữ liệu thu thập trực tiếp qua quá trình bác sĩ thăm khám người bệnh, bao gồm việc khai thác bệnh sử và khám thực thể (nhìn, sờ, gõ, nghe) [5]. Dữ liệu này mang tính chất định hướng ban đầu, giúp bác sĩ khoanh vùng tổn thương và đưa ra các quyết định chỉ định thăm khám chuyên sâu tiếp theo [2].

Thông tin cận lâm sàng

Thông tin cận lâm sàng là các dữ liệu khách quan thu được từ việc áp dụng các trang thiết bị và kỹ thuật y khoa hiện đại (như hình ảnh X-quang, cắt lớp, hay xét nghiệm sinh hóa) [5]. Nếu lâm sàng dùng để định hướng, thì cận lâm sàng cung cấp bằng chứng xác thực từ bên trong cơ thể để chẩn đoán chính xác bệnh lý.

2.3 Phát biểu bài toán

Đầu vào (Input)

Hệ thống nhận vào các nguồn dữ liệu sau:

- Thông tin lâm sàng bao gồm báo cáo cận lâm sàng, khám xét toàn thân, lý do vào viện của bệnh nhân.
- Ảnh X-quang xương của bệnh nhân tương ứng.
- Tập nhãn được định nghĩa trước.

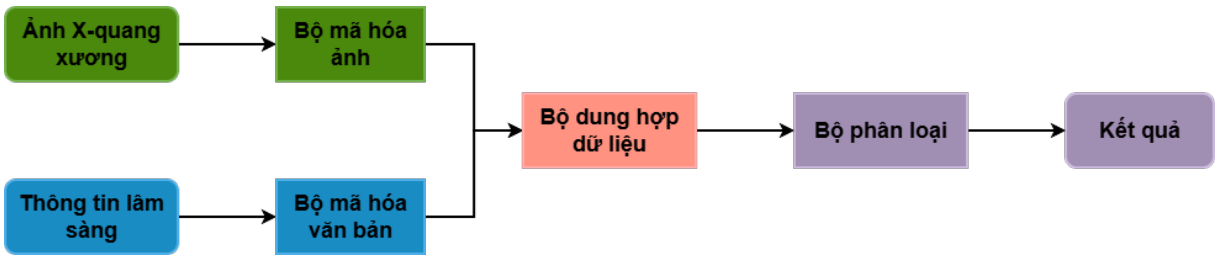
Đầu ra (Output)

Hệ thống sẽ sinh ra các nhãn sau:

- Tỉ lệ mà ảnh và thông tin lâm sàng tương ứng thuộc vào các lớp được định nghĩa trước.
- Ảnh trực quan hóa giải thích cho kết quả.

Kiến trúc tổng quan

Với bài toán này, kiến trúc tổng quan của một mô hình học sâu đa phương thức được sử dụng bao gồm bốn thành phần chính: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại như được thể hiện ở Hình 1.



Hình 1: Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức

Trong đó, bộ mã hóa ảnh có chức năng rút trích đặc trưng từ ảnh đầu vào, bộ mã hóa văn bản có chức năng rút trích đặc trưng từ văn bản đầu vào, bộ dung hợp dữ liệu có chức năng dung hợp hay căn chỉnh các đặc trưng được rút trích từ hai phương thức dữ liệu trên để tạo ra một biểu diễn có ý nghĩa và có đầy đủ tính chất của phương thức đầu vào, đây cũng là mô-đun quan trọng nhất đối với một mô hình học sâu đa phương thức, cuối cùng là bộ phân loại, nhận biểu diễn đặc trưng chung của các phương thức đầu vào để phân loại và đưa ra kết quả cuối cùng.

2.4 Mục tiêu đề tài

Trong bối cảnh già hóa dân số và các tác nhân gây bệnh từ ô nhiễm và lối sống thiếu lành mạnh trong đời sống hiện đại, các bệnh lý về xương và chấn thương có thể ảnh hưởng trực tiếp đến đời sống và tính mạng dẫn đến việc chẩn đoán và tiên lượng để đưa ra hướng điều trị phù hợp đang trở thành gánh nặng cho các y bác sĩ, các hệ thống học sau đa phương

thức tuy đã phát triển nhưng lại thiếu khả năng giải thích. Đề tài hướng đến phát triển một hệ thống phân loại ảnh X-quang có khả năng:

- Đạt được độ chính xác cao trên các bộ dữ liệu nội bộ và quốc tế.
- Có khả năng giải thích được kết quả.
- Tích hợp kết quả để trợ giúp y bác sĩ trong quá trình chẩn đoán.

2.5 Phạm vi của đề tài

Nội dung nghiên cứu của đề tài tập trung vào việc khảo sát các mô hình nền tảng và thiết kế, huấn luyện, tinh chỉnh, đánh giá kiến trúc được đề xuất trên ảnh X-quang xương và các bộ dữ liệu quốc tế để so sánh, đánh giá với các kiến trúc trước.

Đối tượng nghiên cứu xoay quanh các thành phần bên trong một mạng học sâu đa phương thức bao gồm: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại, tập trung vào các phương pháp dung hợp dữ liệu hình ảnh và văn bản cùng với các phương pháp tinh chỉnh tham số cho các bộ mã hóa đã được huấn luyện trước nhằm tận dụng lại các tri thức đã có và nâng cao hiệu năng trên các tác vụ đích.

Đề tài chủ yếu sử dụng các bộ dữ liệu cặp ảnh - văn bản, không có trường hợp thiếu đã được công bố và bộ dữ liệu nội bộ được thu thập và cung cấp bởi giảng viên có hợp tác với bệnh viện ở khu vực Thành phố Hồ Chí Minh, một số thông tin cơ bản về các bộ dữ liệu được thể hiện ở Bảng 1. Nhóm sử dụng các bộ dữ liệu này nhằm đánh giá hiệu năng của kiến trúc đề xuất thông qua các độ đo phổ biến và tiến hành so sánh với các phương pháp trước đó nhằm chứng minh sự hiệu quả của phương pháp đề xuất.

2.6 Cách tiếp cận dự kiến

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ cung cấp tổng quan tình hình nghiên cứu

Bộ dữ liệu	Nguồn	Loại dữ liệu	Số lượng mẫu	Số lượng lớp
RSNA Pneumonia (2018)	Radiological Society of North America	Ảnh X-quang ngực metadata/tags	30,000	3
CheXpert (2019)	Standford ML Group - Stanford Hospital	Ảnh X-quang ngực Báo cáo đọc ảnh	224,316	14
MIMIC-CXR v2 (2019)	Beth Israel Deaconess Medical Center	Ảnh X-quang ngực Báo cáo đọc ảnh	227,835	14
SARCOMA-CTCH (2025)	Bệnh viện Chấn Thương Chỉnh Hình - TPHCM	Ảnh X-quang xương Báo cáo đọc ảnh Báo cao lâm sàng	Đang cập nhật	Đang cập nhật

Bảng 1: Tổng hợp các bộ dữ liệu dự kiến được sử dụng để thí nghiệm

từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

Các mô hình xây dựng từ đầu là các mô hình đơn giản, khởi điểm trong bài toán học sâu đa phương thức, thiết kế và huấn luyện một hệ thống mới từ đầu, điểm chung của các phương pháp này là chúng tập trung vào việc thiết kế các cơ chế để "trộn" (fusion) đặc trưng từ các bộ mã hóa (encoder) chuyên biệt ở các cấp độ khác nhau để tối ưu hóa hiệu suất cho các tác vụ cụ thể, sử dụng những bộ mã hóa hình ảnh đơn giản như CNN.

Khởi điểm vào 2020, X. Mei [16] và đồng nghiệp đã đề xuất lấy đặc trưng được tạo ra từ các lớp cuối của mô hình CNN (véc-tơ 512 chiều) và các đặc trưng từ dữ liệu lâm sàng rồi nối lại. Véc-tơ kết hợp này được đưa vào một mạng MLP cuối cùng để đưa ra dự đoán.

Clinical-BERT [25] và TGANet [21] tìm cách học biểu diễn đa phương thức bằng cách thúc đẩy mô hình hiểu và liên kết (align) các đặc trưng giữa các vùng trong ảnh và các từ khóa trong văn bản báo cáo thông qua các nhiệm vụ tự giám sát (self-supervised objectives), cho phép mô hình học được các biểu diễn ngữ nghĩa chung. Hay LViT [13] đề xuất một kiến trúc hybrid CNN-Transformer "Double-U", cấu trúc CNN-Transformer kết hợp mô-đun Pixel-Level Attention Module để giữ lại các đặc trưng cục bộ của ảnh giúp mô hình giữ được khả năng trích xuất đặc trưng cục bộ mạnh mẽ của CNN, đồng thời tận dụng khả năng mô hình hóa ngữ cảnh toàn cục của Transformer.

Việc chỉ nối các đặc trưng có điểm yếu về sự khác biệt về giá trị hoặc sự ngữ nghĩa lớn giữa các phương thức dữ liệu, IRENE [34] đã đưa tất

cả dữ liệu gốc về dạng token chung và học biểu diễn tổng thể (holistic representation) ngay từ đầu, sử dụng một mô hình Transformer duy nhất học các biểu diễn toàn diện cho cả hai phương thức. IRENE còn sử dụng cơ chế chú ý hai chiều ở cấp độ token để nắm bắt "các kết nối cục bộ".

Nghiên cứu của Dai và cộng sự [4] đề xuất mô hình TransMed, giải quyết bài toán kết hợp đa phương thức bằng cách tích hợp CNN và Transformer. Bằng việc chuyển đổi đặc trưng ảnh từ CNN thành dạng chuỗi để Transformer xử lý, mô hình này tối ưu hóa việc nắm bắt các đặc điểm toàn cục của hình ảnh y khoa. Cách tiếp cận này mang lại hiệu quả cao hơn các kỹ thuật fusion thông thường nhờ khả năng biểu diễn dữ liệu đa phương thức một cách toàn diện và chính xác.

Những nghiên cứu này đã khai phá và chứng minh về tác động tích cực của các phương thức dữ liệu khác như văn bản đến kết quả của việc chẩn đoán hình ảnh, tuy nhiên độ chính xác của các phương thức này còn chưa quá cao bởi các bộ mã hóa và phương pháp dung hợp dữ liệu còn đơn giản.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Kiến trúc mô hình			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	**X. Mei** [16]	Full Fine-Tuning	Pretrain với Cross-Entropy loss	Inception-ResNet-v2	ResNet-18	Decision-level	N/a
2	**Clinical-BERT** [25]	Full Fine-Tuning	Cross-modal Repr. Learning	DenseNet121	Uncased BERT-base	Early fusion	N/a
3	**LViT** [13]	Full Fine-Tuning	Semi-supervised (Pseudo-label)	Hybrid U-shape (CNN + ViT)	BERT_12_768_12	Intermediate	N/a
4	**TGANet** [21]	Train from scratch	Exponential Pseudo-label Iteration	ResNet50	Không có	Intermediate	N/a
5	**IRENE** [34]	Train from scratch	BCE Loss & AdamW optimizer	Convolution layer	Pretrained BERT	Simultaneous	Upsampling, FEM, CBAM Attention
6	**TransMed** [4]	Full Fine-Tuning	Supervised (SGD, 100 epochs)	2D CNN (ResNet18 đến 152)	N/a	Attention fusion	Lớp kết nối đầy đủ (FC Layer)

Bảng 2: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tinh chỉnh của các mô hình kết hợp ngôn ngữ - ảnh

Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu (thường cố gắng dung hợp dữ liệu thô thành một khối thống nhất), Med-VLMs chú trọng vào việc đối chiếu và liên kết chặt chẽ ngữ nghĩa giữa hình ảnh và ngôn ngữ tự nhiên. Cụ thể, kiến trúc của chúng thường kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này khớp với

nhau. Lúc này, bộ phân loại không gán nhãn theo cách truyền thống mà đóng vai trò là một cơ chế đo lường mức độ tương đồng. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Để đạt được khả năng trên, các nghiên cứu tiền huấn luyện Med-VLMs hiện nay đang phát triển chủ yếu theo ba hướng: học tương phản, học có che giấu và tích hợp tri thức y khoa (chi tiết tổng hợp được trình bày tại các Bảng 3, 4, 5).

Thứ nhất, **học tương phản (Contrastive Learning)** là chiến lược được ứng dụng rộng rãi nhất, tiêu biểu với các mô hình như ConVIRT [30], GLoRIA [8], MedCLIP [23] và BiomedCLIP [28]. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau ở mức độ cục bộ lẫn toàn cục. Phương pháp này đem lại hiệu năng ấn tượng; ví dụ, BiomedCLIP [28] (huấn luyện trên 15 triệu cặp dữ liệu) đạt độ chính xác phân loại 83%, trong khi ConVIRT [30] đạt 90,3% trên bộ dữ liệu COVIDx. Mặc dù có ưu điểm vượt trội là khả năng học biểu diễn không cần gán nhãn thủ công, học tương phản vẫn bộc lộ hạn chế về việc tiêu tốn tài nguyên tính toán lớn và rủi ro xảy ra hiện tượng âm tính giả (đẩy xa các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý).

Thứ hai, **học có che giấu (Masked Learning)** là hướng đi tập trung vào mục tiêu tái tạo dữ liệu, với các đại diện nổi bật như MRM [35] và MedViLL [17]. Bằng cách ẩn ngẫu nhiên các vùng ảnh hoặc từ ngữ trong báo cáo y khoa, kiến trúc này buộc mô hình phải dự đoán và khôi phục phần thông tin bị khuyết. Hướng tiếp cận này thể hiện ưu thế rõ rệt trong các môi trường khan hiếm dữ liệu; điển hình là MRM [35] đạt mức 92,7% AUC chỉ với 10% dữ liệu từ tập RSNA. Tuy nhiên, rào cản chính của phương pháp này nằm ở việc phụ thuộc vào nguồn dữ liệu đã được ghép cặp sẵn từ trước, cộng với độ phức tạp tính toán cao của quá trình khôi phục điểm ảnh/token.

Thứ ba, **tích hợp tri thức y khoa (Knowledge Integration)** ra đời nhằm giải quyết những đặc thù phức tạp của ngôn ngữ lâm sàng. Các

mô hình như MedKLIP [24], BioViL [3], BioViL-T [1] và KAD [29] tận dụng đồ thị tri thức (như RadGraph) hoặc dữ liệu chuỗi thời gian để cung cấp tín hiệu giám sát chi tiết về cả loại và vị trí bệnh lý. Cách tiếp cận này giúp giải quyết triệt để sự mơ hồ của các từ vựng diễn tả tiến triển bệnh (ví dụ: "cải thiện", "xấu đi"). Về mặt hiệu năng, KAD [29] đạt 0.966 AUC trên tập PadChest ở thiết lập không mẫu (zero-shot), còn BioViL-T [1] đạt độ chính xác 67,4% trong bài toán phân loại tiến triển bệnh. Dù vậy, các phương pháp này chưa loại bỏ hoàn toàn được hiện tượng âm tính giả và rất dễ gặp sai số nếu nhãn chẩn đoán thực tế nằm ngoài cơ sở tri thức đồ thị gốc.

Dựa trên sự phân tích các ưu và nhược điểm từ những khảo sát trên, hướng tiếp cận đề xuất trong nghiên cứu này được thiết kế có chọn lọc nhằm tối ưu hóa hiệu năng và chi phí:

- **Kế thừa BiomedCLIP [28]:** Tận dụng sức mạnh của các bộ mã hóa đã được huấn luyện với chất lượng cao.
- **Không áp dụng học tương phản & học có che giấu:** Khó khắc phục rào cản về tài nguyên tính toán lớn và giảm thiểu rủi ro gặp phải hiện tượng âm tính giả.
- **Tích hợp tri thức từ UMLS (tương tự MedKLIP [24]):** Sử dụng để làm giàu thêm tri thức trong các báo cáo lâm sàng.

Mặc dù các phương pháp tiền huấn luyện Med-VLMs giúp xây dựng nền tảng tri thức đa phương thức khổng lồ, việc áp dụng trực tiếp vào lâm sàng lại vấp phải rào cản lớn về chi phí tính toán và sự khan hiếm dữ liệu y tế ghép cặp. Để giải quyết vấn đề này, các nghiên cứu thường chuyển hướng sang tinh chỉnh mô hình. Tuy nhiên, nếu tinh chỉnh toàn phần trên một tập dữ liệu nhỏ, sự chênh lệch phân phối sẽ dễ dẫn đến hiện tượng chuyển giao tiêu cực hoặc "quên thảm khốc", làm đánh mất tri thức gốc. Do đó, giới nghiên cứu đang tập trung vào các chiến lược tinh chỉnh hiệu quả tham số (PEFT) nhằm đảm bảo tính linh hoạt, tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các nghiên cứu gần đây được chia thành ba hướng tiếp cận chính:

STT	Tên phương pháp	Phân loại	Nguyên lý
1	**ConVIRT (2022)**	Học tương phản	Tối ưu bộ mã hoá ảnh và văn bản bằng cách kéo các cặp đặc trưng ảnh-văn bản giống nhau lại gần nhau và đẩy các cặp đặc trưng ảnh-văn bản khác nhau ra xa
2	**GLoRIA (2021)**	Học tương phản	Dùng hai hàm mất mát global contrastive để kéo các cặp đặc trưng ảnh-văn bản, trong khi đó hàm mát mát local contrastive học cách căn chỉnh chi tiết của các vùng trong ảnh và các từ trong câu
3	**MedCLIP (2022)**	Học tương phản	Đề xuất cơ chế tách cặp và trích xuất tri thức, và đề xuất hàm mất mát Semantic Matching nhằm giải quyết vấn đề false negative
4	**BiomedCLIP (2025)**	Học tương phản	Có cơ chế tương tự như CLIP nhưng được tiền huấn luyện với bộ dữ liệu PMC-15M
5	**MRM (2023)**	Học có che giấu	Ẩn ngẫu nhiên các thông tin trong văn bản và các vùng trong ảnh để cho mô hình dự đoán lại ảnh và văn bản hoàn chỉnh.
6	**MedViLL (2022)**	Học có che giấu	Đề xuất một kiến trúc dựa trên BERT kết hợp với một mặt nạ chú ý mới được đề xuất (BAR) cho phép ảnh tương tác tự do với văn bản trong các tác vụ hiểu, đồng thời đảm bảo tính tự hồi quy cho các token trong văn bản trong các tác vụ sinh
7	**BioViL (2022)**	Tích hợp kiến thức y khoa	Đề xuất một bộ mã hoá văn bản CXR-BERT được tối ưu cho ảnh X-quang, duy trì hàm mất mát MLM để giúp mô mình giữ lại được các kiến thức văn bản trong quá trình căn chỉnh với ảnh
8	**BioViL-T (2023)**	Tích hợp kiến thức y khoa	Sử dụng các ảnh X-quang từ trước kết hợp với ảnh hiện tại để học được các đặc trưng không gian, thời gian từ đó giải thích cho các từ vựng như "cải thiện" giúp giảm đi sự mơ hồ trong báo cáo
9	**MedKLIP (2023)**	Tích hợp kiến thức y khoa	Đề xuất một mô-đun trích xuất bộ ba và cơ chế mã hoá tăng cường tri thức, từ đó tạo ra biểu diễn tốt hơn cho văn bản
10	**KAD (2023)**	Tích hợp kiến thức y khoa	Tích hợp kiến thức y khoa vào quá trình tiền huấn luyện để giúp mô hình học các biểu diễn có ý nghĩa hơn

Bảng 3: Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Mục tiêu tiền huấn luyện	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	**ConVIRT (2022)**	CL	GCL	ResNet50	BERT	Contrastive Alignment	N/a
2	**GLoRIA (2021)**	CL	LCL, GCL	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	**MedCLIP (2022)**	CL	GCL	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	**BiomedCLIP (2025)**	CL	GCL	ViT-Base	PubMedBERT	Contrastive Alignment	N/a
5	**MRM (2023)**	MP	MIM, MLM	Kiến trúc giống ViT	WordPiece	Global Context Injection	Văn bản: Transformer; Hình ảnh: Fully Connected
6	**MedViLL (2022)**	HA	MLM, ITM	ResNet50	BERT	Cross-modal Self-Attention	Multi-Layer Perceptron
7	**BioViL (2022)**	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
8	**BioViL-T (2023)**	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
9	**MedKLIP (2023)**	CL	LCL	ResNet50	ClinicalBERT	Knowledge-enhanced Alignment	Constrative head, Cross-Entroy head
10	**KAD (2023)**	HA	CL, Disease Diagnosis Prediction	ResNet50, ViT-Base	PubMedBERT	Contrastive Alignment	Disease Query Network

Bảng 4: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;

STT	Tên phương pháp	Bộ dữ liệu tiền huấn luyện	Hiệu năng			
			Tác vụ	Bộ dữ liệu đánh giá	Độ đo	Kết quả
1	**ConVIRT (2022)**	MIMIC-CXR, Private Bone image	- Phân loại ảnh - Phân loại ít mẫu	RSNA Pneumonia, CheXpert, COVIDx, MURA	AUC, Accuracy	- Phân loại ít mẫu: RSNA (1%): 88.8% AUC, (10%): 91.5% AUC; CheXpert (1%): 87.0% AUC, (10%): 88.1% AUC; MURA (1%): 81.3% AUC, (10%): 86.5% AUC - Phân loại ảnh: RSNA: 92.7% AUC, CheXpert: 88.1% AUC, MURA: 89.0% AUC; COVIDx 90.3% ACC
2	**GLoRIA (2021)**	CheXpert	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	CheXpert, RSNA Pneumonia	AUROC	- Phân loại không mẫu: CheXpert 5x200: 0.61 ACC, 0.67 F1; RSNA: 0.70 ACC, 0.58 F1; - Phân loại ít mẫu: CheXpert (1%): 86.6 AUC, (10%): 87.8 AUC, RSNA (1%): 86.1 AUC, (10%) 88.0 AUC - Phân loại ảnh: CheXpert: 88.1 AUC, RSNA: 88.6 AUC
3	**MedCLIP (2022)**	MIMIC-CXR, CheXpert	- Phân loại ảnh - Phân loại không mẫu	MIMIC-5x200, COVID, RSNA Pneumonia	Mean Accuracy	- Phân loại không mẫu: CheXpert-5x200: 0.5942 ACC; MIMIC-5x200: 0.5430 ACC; COVID: 0.8472 ACC; RSNA: 0.7682 ACC - Phân loại ảnh: CheXpert-5x200: 0.5960 ACC; MIMIC-5x200: 0.5650 ACC; COVID: 0.7890 ACC; RSNA: 0.8075 ACC
4	**BiomedCLIP (2025)**	PMC-15M	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PCam, LC25000 (Lung, Colon), TCGA-TIL, RSNA Pneumonia	AUC, Accuracy	- Phân loại không mẫu: PCam: 73.41% ACC; LC25000 Lung 65.23% ACC; LC25000 Colon 92.98%; RSNA 78.95%; TCGA-TIL: 67.04% - Phân loại ít mẫu: PCam (1%): 82% ACC, (10%): 83%; RSNA (1%): 77% ACC, (10%): 82% ACC - Phân loại ảnh: PCam: 83% ACC, RSNA: 83% ACC
5	**MRM (2023)**	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu	CheXpert, NIH ChestX-ray, RSNA Pneumonia, COVID-19 Image Data Collection	AUC, Accuracy	- Phân loại ít mẫu: CheXpert (1%): 88.5 AUC, (10%): 88.5 AUC; RSNA (1%): 91.3 AUC, (10%): 92.7 AUC; NIH ChestX-ray (1%): 79.4 AUC, (10%): 84.0 AUC - Phân loại ảnh: CheXpert: 88.7 AUC, RSNA 93.3, NIH ChestX-ray: 85.9, COVID-19: 85.8
6	**MedViLL (2022)**	MIMIC-CXR	- Phân loại chẩn đoán	MIMIC-CXR, Open-I	Micro-averaged AUROC, Micro-averaged F1 score	- Phân loại ảnh: MIMIC-CXR: 0.980 avg AUROC, 0.839 F1; Open-I: 0.892 avg AUROC, 0.407 F1
7	**BioViL (2022)**	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	RSNA Pneumonia	Accuracy, F1-score, AUROC, Sensitivity Specificity.	- Phân loại không mẫu: RSNA: 0.732 ACC, 0.831 AUC; ChestX-ray14: 0.6912 AUC - Phân loại ít mẫu: RSNA (1%): 0.805 ACC, 0.881 AUC; (10%): 0.812 ACC, 0.884 AUC - Phân loại ảnh: RSNA: 0.822 ACC, 0.891 AUC
8	**BioViL-T (2023)**	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu - Phân loại ảnh tiến triển	MS-CXR-T, RSNA Penumonia, Chest ImaGenome	Macro-Accuracy, Accuracy, F1, AUROC.	- Phân loại Tiến triển: MS-CXR-T: 67.4% Acc - Phân loại không mẫu: RSNA: 0.805 ACC, 0.871 AUC - Phân loại ít mẫu: RSNA (1%): 0.814 ACC, 0.890 AUC
9	**MedKLIP (2023)**	MIMIC-CXR	- Phân loại ảnh - Phân loại không mẫu	ChestX-ray14, RSNA Pneumonia, SIIM-ACR Pneumothorax, COVIDx CXR-2, COVID Rural, Edema Severity	AUC, F1-score, Accuracy.	- Phân loại không mẫu: RSNA: 0.8694 AUC, 0.6342 F1; SIIM-ACR: 0.8924 AUC, 0.6833 F1; ChestX-ray14: 0.7676 AUC, 0.2525 F1; COVID-19: 0.7396 AUC, 0.7670 F1 - Phân loại ít mẫu: ChestX-ray14 (1%): 0.7721 AUC, (10%): 0.7894; RSNA (1%): 0.8731 AUC, (10%): 0.8799 AUC - Phân loại mẫu: ChestX-ray14: 0.8323 AUC, RSNA 0.8931
10	**KAD (2023)**	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PadChest, NIH ChestXray14, CheXpert, ChestX-Det	AUC, F1-Score, MCC	- Phân loại không mẫu: PadChest: 0.966 AUC; CheXpert: 0.905 AUC, 0.647 F1, 0.589 MCC - Phân loại ít mẫu: ChestXray-14 (1%): 0.78 AUC, 0.31 F1; (10%): 0.80 AUC, 0.33 F1 - Phân loại ảnh: ChestXray-14: 0.82 AUC, 0.34 F1

Bảng 5: Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

Tinh chỉnh sử dụng câu nhắc (Prompt Tuning): Hướng này chèn thêm các tham số có thể học được vào không gian đầu vào của mô hình. Các phương pháp như CITE [31], FPT [9] hay DiCoP + DPL [27] khai thác đặc trưng thị giác kết hợp với tri thức lâm sàng, cho thấy hiệu quả vượt trội ngay cả khi thiếu hụt dữ liệu (ví dụ: DiCoP + DPL thích nghi mô hình PLIP đạt AUC trung bình 0,896 qua 10 lần chạy với 5% dữ liệu huấn luyện PanNuke). Nhằm giải quyết khó khăn khi thiết kế thủ công, MedPrompt [32] và UniDCP [26] tự động sinh câu nhắc động dựa trên ngữ cảnh ảnh để xử lý đa tác vụ. Gần đây hơn, việc tích hợp Mô hình ngôn ngữ Lớn (LLM) qua ViP [7], CILMP [6] và BiomedCoOp [10] giúp tạo sinh các câu nhắc ngữ nghĩa sâu sắc, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản, mang lại hiệu năng cao trong các kịch bản ít mẫu hoặc không mẫu.

Tinh chỉnh bộ điều hợp (Adapter Tuning): Thay vì can thiệp ở đầu vào, phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ giữa các lớp của kiến trúc gốc. Điển hình, CLIPath [11] sử dụng kết nối thặng dư để giảm khoảng cách miền trên dữ liệu nhỏ; FTB [19] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chắt lọc thông tin đa phương thức. Ở hướng bán giám sát, mô hình MedUnA [20] dùng LLM tạo nhãn giả và tinh chỉnh không giám sát bộ điều hợp trên ảnh chưa gán nhãn, giúp mô hình thích ứng tốt mà không thay đổi trọng số.

Tinh chỉnh chọn lọc (Selective Tuning): Hướng đi này tối ưu hóa kiến trúc bằng cách chỉ cập nhật một lượng nhỏ các trọng số quyết định hiệu năng. TransMed [33] kết hợp LLM để chuyển đổi nhãn bệnh thành mô tả chi tiết, trong khi SH-PEFT [15] chỉ tìm và cập nhật các trọng số quan trọng nhất trên bộ mã hóa thị giác nhằm khai thác tính thưa thớt của mạng. Tương tự, LCBB [14] áp dụng kỹ thuật LoRA để tinh chỉnh tham số hiệu quả cho Med-VLMs, giúp bám sát hiệu năng của tinh chỉnh toàn phần (đạt 93.1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn) nhưng giảm thiểu tối đa chi phí tính toán.

Tóm lại, các phương pháp tinh chỉnh hiệu quả tham số (PEFT) thể hiện ưu điểm vượt trội trong việc tiết kiệm tài nguyên tính toán, ngăn chặn hiện tượng quên tri thức và giúp mô hình thích ứng tốt ngay cả khi đối mặt với các bộ dữ liệu y tế khan hiếm. Tuy nhiên, hướng tiếp cận này

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	**CITE (2023)**	Parameter-efficient fine tuning	Visual prompt tuning	CLIP ViT-Base, ImageNet-21k ViT-Base, INTERN ViT-Base	BioLinkBERT-large, BioBERT-large , Kế thừa CLIP	Contrastive Alignment	N/a
2	**UniDCP (2023)**	Parameter-efficient fine tuning	Visual-Textual prompt tuning	CLIP ViT	RoBERTa	Cross Attention, Contrastive Alignment	N/a
3	**ViP (2024)**	Parameter-efficient fine tuning	Textual prompt tuning	ViT-Base	Kế thừa CLIP	Cross Attention, Contrastive Alignment	N/a
4	**DiCoP + DPL (2024)**	Parameter-efficient fine tuning	Visual prompt tuning, Efficient Selective tuning	ViT-Base	Kế thừa CLIP	Concatnate	N/a
5	**FPT (2024)**	Parameter-efficient fine tuning	Visual prompt tuning	ViT-Base	N/a	Cross Attention	N/a
6	**MedPrompt (2024)**	Parameter-efficient fine tuning	Textual prompt tuning	Swin Transformer, ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
7	**CILMP (2025)**	Parameter-efficient fine tuning	Visual-Textual prompt tuning	ViT-Base	Kế thừa CLIP	Hadamard Product, Concatnate	N/a
8	**BiomedCoOp (2025)**	Parameter-efficient fine tuning	Visual-Textual prompt tuning	Kế thừa BiomedCLIP	Kế thừa BiomedCLIP	Contrastive Alignment	N/a
9	**CLIPath (2023)**	Parameter-efficient fine tuning	Adapter tuning	ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
10	**FTB (2024)**	Parameter-efficient fine tuning	Adapter tuning	ResNet autoencoder, DINOv2-small, DINOv2-base	BERT, BioBERT, ClinicalBERT, CXR-BERT, PubMedBERT	Cross Attention	N/a
11	**MedUnA (2024)**	Parameter-efficient fine tuning	Adapter tuning	ViT-Base, MedCLIP-Swin	Kế thừa CLIP, MedCLIP	No Fusion	N/a
12	**TransMed (2023)**	Parameter-efficient fine tuning	Direct Selective tuning	Swin Transformer, ViT-Base	BERT, LLM/GPT-4	Contrastive Alignment	N/a
13	**SH-PEFT (2024)**	Parameter-efficient fine tuning	Direct Selective tuning	ViT-Base	Kế thừa CLIP	No Fusion	N/a
14	**LCBB (2024)**	Parameter-efficient fine tuning	Efficient Selective tuning	Kế thừa MAE, MRM	Kế thừa MAE, MRM	Kế thừa MAE, MRM	N/a

Bảng 6: Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan

vẫn tồn tại một số hạn chế nhất định. Hiệu năng cuối cùng của hệ thống phụ thuộc rất lớn vào chất lượng của mô hình tiền huấn luyện gốc. Đồng thời, quá trình thiết kế câu nhắc mang đậm tính chuyên môn hay xác định vị trí tối ưu để chèn bộ điều hợp thường phức tạp và đòi hỏi nhiều thử nghiệm. Ngoài ra, việc bổ sung các thành phần này ít nhiều làm tăng tính "hộp đen" của mô hình, gây ra những thách thức về tính minh bạch khi cần giải thích các quyết định dự đoán cho bác sĩ trên thực tế lâm sàng.

Các mô hình ngôn ngữ lớn y khoa đa phương thức

Trong thời gian gần đây, với sự phát triển của các mô hình ngôn ngữ lớn được huấn luyện trên những tập dữ liệu rất lớn phục vụ cho rất nhiều tác vụ khác nhau, các mô hình này đang thể hiện sự ảnh hưởng và đa dụng trong lĩnh vực y tế với độ chính xác rất tốt khi chỉ học ít mẫu hoặc không mẫu.

Med-Flamingo [18] là mô hình đầu tiên có khả năng học ít mẫu chuyên dụng cho y tế, thông qua hội thoại tự nhiên để hỗ trợ chẩn đoán. Theo sau đó, LLaVA-Med [12] là mô hình chuyển đổi khả năng thực hiện theo chỉ

dẫn (instruction-following) từ miền tổng quát sang lĩnh vực y sinh bằng cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn với 600.000 cặp, với dữ liệu hội thoại tạo ra từ chú thích ảnh y khoa được tạo ra bằng cách sử dụng GPT-4. Phương pháp này đã đề xuất quy trình huấn luyện 2 bước: (1) Căn chỉnh khái niệm; (2) Tinh chỉnh chỉ dẫn đầy đủ; 2 bước này tương ứng với giai đoạn học và suy luận. Kết quả thể hiện khả năng suy luận vượt trội trên dữ liệu chưa từng thấy.

Med-Palm M [22] là mô hình của Google, đánh dấu bước tiến từ các mô hình đơn nhiệm sang đa nhiệm quy mô lớn, có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì sử dụng các mô hình chuyên biệt cho từng tác vụ. Gần đây hơn, SkinGPT-4 [36] là hệ thống chẩn đoán da liễu tương tác đầu tiên sử dụng LLM quy mô lớn với độ chính xác cao, đã kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM), tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Dù đưa đến các phương pháp có độ chính xác cao đến rất cao trong nhiều tác vụ cùng việc hỗ trợ trong việc giao tiếp với mô hình, kích cỡ và chi phí huấn luyện (Med-Flamingo có đến 9 tỷ thông số) để vận hành các mô hình ngôn ngữ lớn đa phương thức là một vấn đề lớn, đi kèm với vấn đề ảo giác có thể gặp phải khi đối mặt với dữ liệu mới hoặc những câu hỏi phức tạp. Ngoài ra nếu yêu cầu một độ chính xác cao - một yêu cầu quan trọng trong lĩnh vực y tế trong một tác vụ cụ thể thì đây không phải một cách tiếp cận tốt cho bài toán này.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Cấu trúc phương pháp			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	**Med-Flamingo [18]**	PEFT	Parameter-efficient + Domain adaptation	Frozen CLIP ViT	LLaMA-7B	Intermediate fusion	LLaMA Decoder
2	**LLaVA-Med [12]**	Full FT	Visual Instruction Tuning (GPT-4 data)	CLIP ViT-L/14	LLaMA	Projection Matrix	LLM (Vicuna)
3	**Med-PaLM M [22]**	Full FT	Instruction Fine-tuning	ViT (4B - 22B)	PaLM	Multimodal embedding	PaLM
4	**SkinGPT-4 [36]**	PEFT	LoRA	Vision Transformer	GPT-4	Linear alignment	LLaMA-2-13B

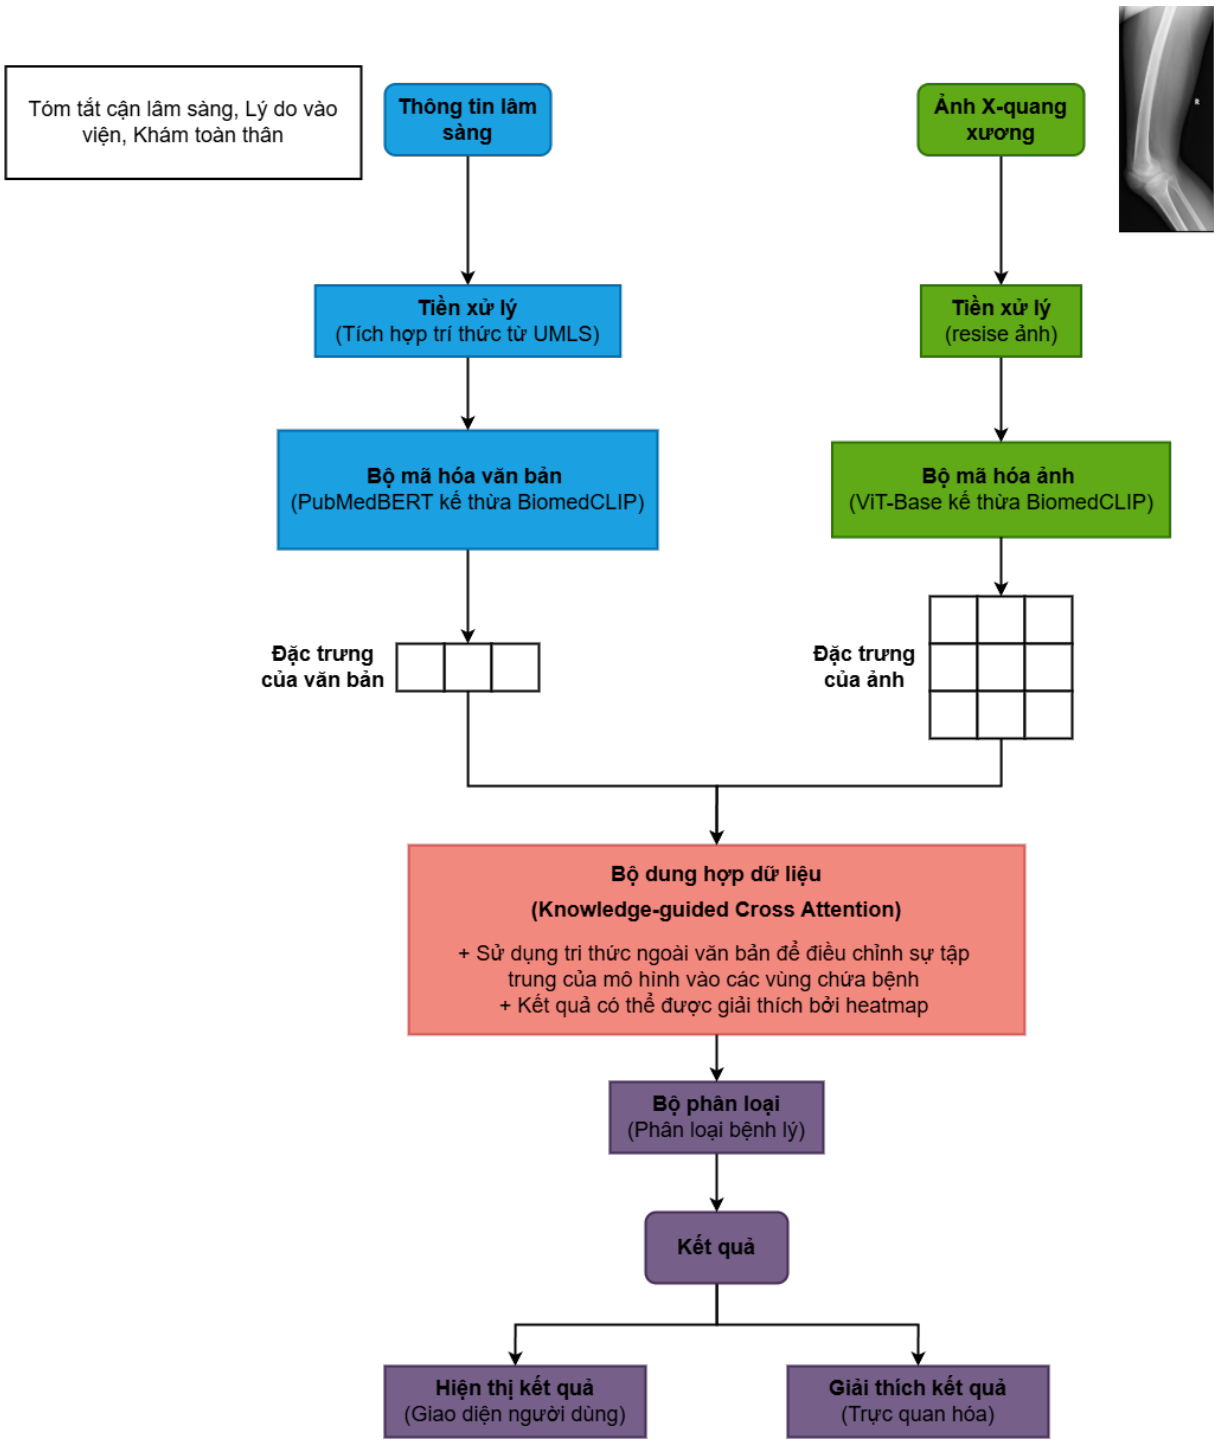
Bảng 7: Tổng hợp chiến lược và cấu trúc các mô hình ngôn ngữ lớn đa phương thức

Phương pháp đề xuất: Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng

thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế theo hướng tích hợp tri thức y khoa nhằm nâng cao khả năng giải thích của mô hình được minh họa ở Hình 2. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Bộ mã hóa ảnh:** Kế thừa lại mô hình ViT-Base của phương pháp BiomedCLIP [28]
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [28]
- **Bộ dung hợp dữ liệu:** Nhóm hướng đến sử dụng cơ chế ***Knowledge-guided Cross-Attention*** - Các khái niệm y học được trích xuất và liên kết từ văn bản lâm sàng sẽ được sử dụng để tạo thiên lệch trong quá trình tính toán cross attention. Cơ chế này giúp điều hướng mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Nhờ đó, mô hình không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.
- **Bộ phân loại:** Sử dụng một mạng phân loại (Multi-Layer Perceptron) để dự đoán nhãn bệnh lý.

Đồng thời, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán.



Hình 2: Kiến trúc tổng thể của hệ thống đề xuất

2.7 Kết quả dự kiến của đề tài

- **Số liệu định lượng:** Độ chính xác, điểm F1, AUC-ROC đạt kết quả cạnh tranh trên các bộ dữ liệu đã nêu.
- **Sản phẩm đầu ra:**

  - Hệ thống demo phân loại ảnh X-quang xương với khả năng nhận ảnh và văn bản và trả ra các lớp thuộc bộ dữ liệu Sarcoma-CTCH.
  - Giao diện đơn giản để hiển thị kết quả phân loại.
  - Cho phép trực quan hóa sau khi hiện kết quả phân loại.

- **Báo cáo khoa học:** hoàn thiện phương pháp và hệ thống để hướng tới công bố trên các hội nghị và tạp chí uy tín trong lĩnh vực Trí tuệ nhân tạo và Y sinh, như MICCAI, CVPR hoặc các tạp chí được công nhận.

- **Hướng phát triển:**
  - Mở rộng ra cho các bệnh lý khác.
  - Cải thiện độ chính xác và hiệu suất của hệ thống.

2.8 Kế hoạch thực hiện

Mục tiêu	Thời gian	Phân công	Nội dung
Khoá luận tốt nghiệp	**01 tháng**	**Giai đoạn 1**	
		Bá Thành	Khảo sát tổng quan về bài toán phân loại ảnh X-quang về xương
		Gia Kiệt	Khảo sát các mô hình tiền huấn luyện trên dữ liệu y khoa
		Bá Thành	Khảo sát các phương pháp học chuyển giao và các mô hình liên quan
	02 tháng	**Giai đoạn 2**	
		Cả nhóm	Phát triển mô hình học sâu đa phương thức áp dụng phương pháp học chuyển giao
		Gia Kiệt	Cài đặt môi trường, thu thập các bộ dữ liệu liên quan
		Bá Thành	Thực hiện thí nghiệm trên mô hình đề xuất
	02 tháng	**Giai đoạn 3**	
		Bá Thành	Phân tích so sánh kết quả thực nghiệm.
		Gia Kiệt	Xây dựng nguyên mẫu cho hệ thống phân loại
	0.5 tháng	**Giai đoạn 4**	
		Cả nhóm	Viết 01 bài báo khoa học cho hội nghị - tạp chí chuyên ngành trong nước hoặc ngoài nước
	0.5 tháng	**Giai đoạn 5**	
		Bá Thành	Viết báo cáo khoá luận tốt nghiệp.
		Gia Kiệt	Thiết kế slide cho lễ bảo vệ đề tài tốt nghiệp

Bảng 8: Kế hoạch bố trí thời gian nghiên cứu

Tài liệu tham khảo

[1] Shruthi Bannur et al. "Learning to exploit temporal structure for biomedical vision-language processing". In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2023, pp. 15016–15027. DOI: 10.1109/cvpr52729.2023.01442.

[2] Lynn S. Bickley, Peter G. Szilagyi, and Richard M. Hoffman. *Bates' Guide to Physical Examination and History Taking*. 13th ed. Lippincott Williams & Wilkins, 2020.

[3] Benedikt Boecking et al. "Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing". In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5. DOI: 10.1007/978-3-031-20059-5_1.

[4] Yin Dai, Yifan Gao, and Fayu Liu. "TransMed: Transformers Advance Multi-modal Medical Image Classification". In: *Diagnostics* 11.8, 1384 (2021). DOI: 10.3390/diagnostics11081384.

[5] Dorland. *Dorland's Illustrated Medical Dictionary*. 32nd ed. Elsevier Health Sciences, 2011. ISBN: 978-1-4160-6257-8.

[6] Ye Du, Nanxi Yu, and Shujun Wang. "Medical Knowledge Intervention Prompt Tuning for Medical Image Classification". In: *IEEE Transactions on Medical Imaging* 44.12 (2025), pp. 4945–4959. DOI: 10.1109/TMI.2025.3584841.

[7] Xiao Fang et al. "Aligning Medical Images with General Knowledge from Large Language Models". In: *International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Vol. 15010. Lecture Notes in Computer Science. Springer Nature Switzerland, 2024, pp. 57–67. DOI: 10.1007/978-3-031-72117-5_6. URL: https://papers.miccai.org/miccai-2024/062-Paper1358.html.

[8] Shih-Cheng Huang et al. "GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition". In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.

[9] Yijin Huang et al. "Fine-Grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-Resolution Medical Image Classification". In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Cham: Springer Nature Switzerland, 2024, pp. 120–130. ISBN: 978-3-031-72390-2. DOI: 10.1007/978-3-031-72390-2_12.

[10] Taha Koleilat et al. "BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2025, pp. 14766–14776. DOI: 10.1109/CVPR52734.2025.01376.

[11] Zhengfeng Lai et al. "CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts". In: *Proceedings of the IEEE/CVF International*

Conference on Computer Vision Workshops (ICCVW). IEEE, 2023, pp. 2366–2372. DOI: 10.1109/iccvw60793.2023.00251.

[12] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: https://arxiv.org/abs/2306.00890.

[13] Zihan Li et al. "LViT: Language Meets Vision Transformer in Medical Image Segmentation". In: *IEEE Transactions on Medical Imaging* 43.1 (Jan. 2024), pp. 96–107. DOI: 10.1109/TMI.2023.3291719. (Visited on 02/19/2024).

[14] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: https://arxiv.org/abs/2401.12215.

[15] Mingyuan Liu et al. "Sparsity- and Hybridity-Inspired Visual Parameter-Efficient Fine-Tuning for Medical Diagnosis". In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. 15005. Lecture Notes in Computer Science. Springer, 2024, pp. 627–637. DOI: 10.1007/978-3-031-72086-4_59.

[16] Xueyan Mei et al. "Artificial intelligence–enabled rapid diagnosis of patients with COVID-19". In: *Nature Medicine* 26 (Aug. 2020), pp. 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: https://www.nature.com/articles/s41591-020-0931-3.

[17] Jong Hak Moon et al. "Multi-Modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training". In: *IEEE Journal of Biomedical and Health Informatics* 26.12 (2022), pp. 6070–6080. DOI: 10.1109/JBHI.2022.3207502.

[18] Michael Moor et al. "Med-Flamingo: a Multimodal Medical Few-shot Learner". In: *Proceedings of the 3rd Machine Learning for Health Symposium*. Vol. 225. Proceedings of Machine Learning Research. PMLR, 2023, pp. 353–367. URL: https://proceedings.mlr.press/v225/moor23a.html.

[19] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.

[20] Umaima Rahman et al. “Can language-guided unsupervised adaptation improve medical image classification using unpaired images and texts?” In: *2025 IEEE 22nd International Symposium on Biomedical Imaging (ISBI)*. IEEE. 2025, pp. 1–5. DOI: 10.1109/isbi60581.2025.10981057.

[21] Nikhil Kumar Tomar et al. “TGANet: Text-Guided Attention for Improved Polyp Segmentation”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2022*. Springer Nature Switzerland, Jan. 2022, pp. 151–160. DOI: 10.1007/978-3-031-16437-8_15. (Visited on 09/04/2024).

[22] Tao Tu et al. “Towards Generalist Biomedical AI”. In: *NEJM AI* 1.3, AIoa2300138 (2024). DOI: 10.1056/AIoa2300138.

[23] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: https://aclanthology.org/2022.emnlp-main.256/.

[24] Chaoyi Wu et al. “MedKLIP: Medical Knowledge Enhanced Language-Image Pre-Training for X-ray Diagnosis”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023, pp. 21315–21326. DOI: 10.1109/iccv51070.2023.01954.

[25] Bin Yan and Mingtao Pei. “Clinical-BERT: Vision-Language Pre-training for Radiograph Diagnosis and Reports Generation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 36.

3. June 2022, pp. 2982–2990. DOI: 10.1609/aaai.v36i3.20204. (Visited on 07/08/2022).

[26] Chenlu Zhan et al. "UniDCP: Unifying Multiple Medical Vision-Language Tasks via Dynamic Cross-Modal Learnable Prompts". In: *IEEE Transactions on Multimedia* 26 (2024), pp. 9736–9748. DOI: 10.1109/TMM.2024.3397191.

[27] Jiajin Zhang et al. "Disease-Informed Adaptation of Vision-Language Models". In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. 15011. Lecture Notes in Computer Science. Springer Nature Switzerland, 2024, pp. 232–242. DOI: 10.1007/978-3-031-72120-5_22.

[28] Sheng Zhang et al. "A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs". In: *NEJM AI* 2.1, AIoa2400640 (2025). DOI: 10.1056/AIoa2400640.

[29] Xiaoman Zhang et al. "Knowledge-enhanced visual-language pre-training on chest radiology images". In: *Nature Communications* 14.1, 4542 (July 2023). DOI: 10.1038/s41467-023-40260-7.

[30] Yuhao Zhang et al. "Contrastive Learning of Medical Visual Representations from Paired Images and Text". In: *Proceedings of the 7th Machine Learning for Healthcare Conference*. Vol. 182. Proceedings of Machine Learning Research. PMLR, 2022, pp. 2–25. URL: https://proceedings.mlr.press/v182/zhang22a.html.

[31] Yunkun Zhang et al. "Text-Guided Foundation Model Adaptation for Pathological Image Classification". In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*. Ed. by Hayit Greenspan et al. Cham: Springer Nature Switzerland, 2023, pp. 272–282. ISBN: 978-3-031-43904-9. DOI: 10.1007/978-3-031-43904-9_27.

[32] Fudan Zheng et al. "Exploring low-resource medical image classification with weakly supervised prompt learning". In: *Pattern Recognition* 149 (2024), p. 110250. ISSN: 0031-3203. DOI: 10.1016/j.patco

g.2024.110250. URL: https://www.sciencedirect.com/science/article/pii/S0031320324000013.

[33] Kaipeng Zheng, Weiran Huang, and Lichao Sun. "TransMed: Large Language Models Enhance Vision Transformer for Biomedical Image Classification". In: *arXiv preprint arXiv:2312.07125* (2023).

[34] Hong-Yu Zhou et al. "A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics". In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).

[35] Hong-Yu Zhou et al. "Advancing Radiograph Representation Learning with Masked Record Modeling". In: *The Eleventh International Conference on Learning Representations*. 2023. URL: https://openreview.net/forum?id=w-x7U26GM7j.

[36] Juexiao Zhou et al. "Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4". In: *Nature Communications* 15.1, 5649 (July 2024). DOI: 10.1038/s41467-024-50043-3.

XÁC NHẬN	*TP. Hồ Chí Minh, ngày 05 tháng 04 năm 2026*
CỦA NGƯỜI HƯỚNG DẪN	**NHÓM SINH VIÊN THỰC HIỆN**
(Ký và ghi rõ họ tên)	*(Ký và ghi rõ họ tên)*

Mục lục

Lời cam đoan **i**

Lời cảm ơn **ii**

Đề cương chi tiết

Mục lục **iii**

Danh sách hình **vii**

Danh sách bảng **ix**

Danh mục từ viết tắt **xii**

Danh mục thuật ngữ Anh–Việt **xiii**

Danh mục ký hiệu **xv**

Tóm tắt **xvi**

1 Giới thiệu **1**

1.1 Bối cảnh, động lực và nhu cầu nghiên cứu 1

1.1.1 Vị trí hệ thống trong quy trình khám chữa bệnh lý xương 3

1.2 Giới thiệu bài toán 5

1.2.1 Đầu vào 5

1.2.2 Đầu ra 6

1.2.3 Các thách thức trong bài toán 7

1.3 Mục tiêu nghiên cứu 8

1.4 Đối tượng nghiên cứu 9
1.5 Phạm vi nghiên cứu 10
1.6 Câu hỏi nghiên cứu 11
1.7 Đóng góp chính của đề tài 12
1.8 Bố cục khóa luận 13

2 Các công trình nghiên cứu liên quan 14
2.1 Các hướng tiếp cận chính và các mô hình nền tảng 15
2.1.1 Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu 15
2.1.2 Mô hình ngôn ngữ trực quan y khoa 16
2.2 Các kỹ thuật tinh chỉnh hiệu quả tham số 19
2.2.1 Tinh chỉnh sử dụng câu nhắc 20
2.2.2 Tinh chỉnh bộ điều hợp 20
2.2.3 Tinh chỉnh thích nghi hạng thấp 21
2.3 Các phương pháp phát hiện dữ liệu ngoài phân phối 22
2.3.1 Các phương pháp hậu xử lý dựa trên đầu ra của mô hình 22
2.3.2 Các phương pháp dựa trên khoảng cách 23
2.3.3 Học biểu diễn phục vụ phát hiện dữ liệu ngoài phân phối 24
2.4 Các phương pháp giải thích và đánh giá độ trung thực . . 26
2.5 Bàn luận 27
2.5.1 Hạn chế của các nghiên cứu hiện nay 27
2.5.2 Cơ sở lựa chọn và định hướng phương pháp đề xuất 28

3 Phương pháp đề xuất 31
3.1 Tổng quan phương pháp đề xuất 31
3.2 Nhánh mã hóa hình ảnh 33
3.3 Nhánh biểu diễn văn bản 34
3.4 Thích nghi hạng thấp bộ mã hóa bằng LoRA 36
3.5 Mô-đun dung hợp đa phương thức với chú ý chéo hai chiều 38
3.6 Huấn luyện hai giai đoạn trong quá trình ngoại tuyến . . . 41
3.6.1 Giai đoạn 1: Thích nghi miền bằng khớp ngữ nghĩa 41
3.6.2 Giai đoạn 2: học dung hợp và phân lớp 44

3.7 Phát hiện dữ liệu lệch phân phối bằng thuật toán k-NN đa phương thức 47
3.8 Suy luận trong quá trình trực tuyến 49

4 Thực nghiệm và kết quả **53**
4.1 Thiết kế thực nghiệm 53
4.1.1 Chuẩn bị dữ liệu 53
4.1.2 Cấu hình thí nghiệm 59
4.1.3 Các độ đo 60
4.2 Kiểm tra hiệu năng phân lớp và đánh đổi chi phí 64
4.2.1 Mục đích 64
4.2.2 Nội dung 65
4.2.3 Kết quả 65
4.2.4 Kết luận 71
4.3 Khảo sát ảnh hưởng của các thành phần 72
4.3.1 Mục đích 72
4.3.2 Nội dung 72
4.3.3 Kết quả 72
4.3.4 Kết luận 74
4.4 Khảo sát khả năng cảnh báo dữ liệu ngoài phân phối . . . 75
4.4.1 Mục đích 75
4.4.2 Nội dung 75
4.4.3 Kết quả 75
4.4.4 Kết luận 76
4.5 Khảo sát mức phụ thuộc của dự đoán vào ảnh và văn bản 77
4.5.1 Mục đích 77
4.5.2 Nội dung 77
4.5.3 Kết quả 78
4.5.4 Kết luận 80

5 Kết luận và hướng phát triển **81**
5.1 Tổng kết 81
5.2 Trả lời các câu hỏi nghiên cứu 82
5.3 Hạn chế và hướng phát triển 83

Tài liệu tham khảo **85**

A Chi tiết về bộ dữ liệu **93**
A.1 Bộ dữ liệu BTXRD 93
A.1.1 Cấu trúc lưu trữ và đặc điểm kỹ thuật 93
A.1.2 Phương pháp tạo dữ liệu giả lâm sàng 94
A.2 Bộ dữ liệu CTCH 100
A.2.1 Cấu trúc dữ liệu và đặc điểm kỹ thuật 101

B Cấu hình chi tiết của XBone-Net **106**
B.1 Mô hình nền tảng và chuẩn hóa đầu vào 106
B.2 Kích thước biểu diễn qua các thành phần 107
B.3 Cấu hình thích nghi hạng thấp 108
B.4 Dung hợp và đầu phân lớp 109
B.5 Cấu hình huấn luyện 110

C Kết quả chi tiết theo từng hạt giống **111**
C.1 Phạm vi trình bày 111
C.2 Phân loại khi sử dụng toàn bộ dữ liệu huấn luyện 112
C.3 Nghiên cứu loại bỏ từng thành phần 114
C.4 Chi tiết kiểm định thống kê và khoảng tin cậy ghép cặp . . 114
C.5 Kết quả đánh giá dữ liệu ngoài phân phối 116

Danh sách hình

1.1 Sơ đồ quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam) 2

1.2 Sơ đồ tích hợp hệ thống XBone-Net hỗ trợ phân tích (các khối tím) vào quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả dữ liệu thu được ở từng bước (các khối cam) 4

3.1 Sơ đồ tổng quan phương pháp XBone-Net đề xuất 31

3.2 Phân rã hạng r với ma trận cập nhật trọng số ΔW 36

3.3 Mô-đun dung hợp bằng chú ý chéo hai chiều 39

3.4 Giai đoạn thích nghi miền bằng khớp ngữ nghĩa ảnh-văn bản 41

3.5 Giai đoạn học dung hợp và phân lớp 45

3.6 Quy trình suy luận trực tuyến và phát hiện mẫu ngoài phân phối 49

4.1 Phân bố độ tuổi và giới tính của các bệnh nhân được quan sát trong bộ dữ liệu BTXRD 55

4.2 Ví dụ định tính về trường hợp cấu hình chỉ ảnh dự đoán sai nhưng cấu hình đầy đủ phương thức dự đoán đúng trên CTCH 66

4.3 Biểu đồ chênh lệch ghép cặp của ba độ đo phân loại trên BTXRD 68

4.4 Biểu đồ chênh lệch ghép cặp của ba độ đo phân loại trên CTCH 69

4.5 Biểu đồ chênh lệch ghép cặp giữa XBone-Net và hai biến thể trên CTCH 73

4.6 Tích phân gradient trên ảnh X-quang và văn bản lâm sàng của mẫu 3563. Màu nóng trên ảnh biểu thị độ lớn đóng góp. Trong văn bản, màu cam và màu xanh lần lượt biểu thị ủng hộ và phản đối lớp dự đoán. 79

A.1 Quá trình tạo văn bản minh họa cho mẫu `IMG000001.jpeg` 99

A.2 Quy trình sàng lọc hồ sơ cho bộ dữ liệu CTCH 100

Danh sách bảng

2.1 Tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản 16
2.2 Tổng hợp các phương pháp tinh chỉnh hiệu quả tham số cho các mô hình ngôn ngữ trực quan y khoa nổi bật 21

3.1 Các ma trận được gắn LoRA trong hai bộ mã hóa của XBone-Net 38

4.1 Phân bổ mẫu theo các tập chia trong BTXRD 55
4.2 Phân bổ các lớp đơn nhãn sau chuẩn hóa trong bộ dữ liệu BTXRD 55
4.3 Ví dụ ảnh, nhãn và văn bản tổng hợp được sinh của bộ dữ liệu BTXRD 56
4.4 Phân bổ mẫu trong phân phối của CTCH theo tập dữ liệu 58
4.5 Phân bố 22 lớp của CTCH trong ba tập dữ liệu 58
4.6 Các ví dụ ảnh, nhãn và văn bản lâm sàng của bộ dữ liệu CTCH 59
4.7 Môi trường thực nghiệm 59
4.8 Cấu hình chính của các thực nghiệm 60
4.9 So sánh kết quả phân lớp CTCH giữa XBone-Net chỉ ảnh và XBone-Net đầy đủ phương thức 65
4.10 Kết quả phân loại trên BTXRD và CTCH khi sử dụng toàn bộ tập huấn luyện 67
4.11 Số lượng tham số khi sử dụng toàn bộ dữ liệu 70

4.12 Chi phí huấn luyện, trình bày dưới dạng trung bình ± độ lệch chuẩn qua ba hạt giống. Các phép đo dùng cùng GPU NVIDIA GeForce RTX 5060 Ti, độ chính xác số học bf16 và kích thước lô 16. Giờ GPU chỉ tính thời gian thực thi các pha huấn luyện. 70
4.13 Chi phí tính toán và tốc độ suy luận khi sử dụng toàn bộ dữ liệu 70
4.14 Nghiên cứu loại bỏ từng thành phần của XBone-Net trên CTCH. Các độ đo được tính từ cùng tệp dự đoán dùng cho kiểm định ghép cặp 73
4.15 Đánh giá cảnh báo OOD hậu xử lý trên CTCH với cấu hình có và không sử dụng bệnh sử lâm sàng 76
4.16 Đánh giá tích phân gradient và can thiệp nguồn trên toàn bộ 669 mẫu kiểm thử CTCH ở hạt giống 42 78

A.1 Cấu trúc lưu trữ của bộ dữ liệu BTXRD trong nghiên cứu 94
A.2 Đặc điểm kỹ thuật của các tệp ảnh BTXRD 94
A.3 Các mẫu câu đại diện trong ngân hàng văn bản giả lâm sàng BTXRD 96
A.4 Kết quả kiểm chứng tính toàn vẹn của dữ liệu BTXRD . . 97
A.5 Kiểm tra nguy cơ rò rỉ nhãn trực tiếp và gián tiếp trong văn bản BTXRD 98
A.6 Cấu trúc lưu trữ của bộ dữ liệu CTCH trong nghiên cứu . 101
A.7 Đặc điểm kỹ thuật của các tệp ảnh CTCH 101
A.8 Dòng dữ liệu qua các bước sàng lọc CTCH 102
A.9 Vai trò của các trường bệnh án CTCH và nguyên tắc loại thông tin có nguy cơ rò rỉ nhãn 103
A.10 Độ tương đồng ngữ nghĩa giữa bệnh sử tiếng Việt và bản dịch tiếng Anh của CTCH 104
A.11 Kết quả kiểm chứng tính toàn vẹn của quần thể CTCH được sử dụng 105

B.1 Cấu hình đầu vào và mô hình nền tảng của XBone-Net . . 107
B.2 Kích thước các biểu diễn tại những bước chính của XBone-Net 108
B.3 Các mô-đun tuyến tính được thích nghi bằng LoRA 109

B.4 Cấu hình mô-đun dung hợp và đầu phân lớp 109
B.5 Cấu hình và tiêu chí lựa chọn trạng thái trong hai pha huấn luyện 110

C.1 Kết quả phân loại của từng hạt giống trên BTXRD 112
C.2 Kết quả phân loại của từng hạt giống trên CTCH 112
C.3 Kết quả phân loại của từng hạt giống trong nghiên cứu loại bỏ thành phần trên CTCH 114
C.4 Khoảng tin cậy 95% của chênh lệch ghép cặp giữa XBone-Net và các mô hình đối chứng đối với các độ đo phân loại qua ba hạt giống. Chênh lệch được tính bằng XBone-Net trừ mô hình đối chứng. Giá trị trong ngoặc vuông được ước lượng từ 10.000 lần bootstrap ghép cặp chéo bệnh nhân và hạt giống. 115
C.5 Giá trị kiểm định ghép cặp giữa XBone-Net và các biến thể. Chênh lệch được tính bằng XBone-Net trừ biến thể. 116
C.6 Khoảng tin cậy 95% của chênh lệch ghép cặp trên 669 mẫu kiểm thử CTCH qua các hạt giống 42, 123 và 456. Chênh lệch được tính bằng XBone-Net trừ biến thể, thống nhất với bảng kiểm định và hình ở chương chính. Khoảng tin cậy được ước lượng từ 10.000 lần bootstrap ghép cặp chéo bệnh nhân và hạt giống. 116
C.7 Kết quả cảnh báo OOD của từng hạt giống trên CTCH. Cấu hình chỉ ảnh dùng điểm thị giác; các cấu hình còn lại tổ hợp điểm ảnh và văn bản. 117

Danh mục từ viết tắt

Viết tắt	Tên tiếng Anh	Nghĩa tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo.
Acc	Accuracy	Độ chính xác phân lớp.
BAcc	Balanced Accuracy	Độ chính xác cân bằng giữa các lớp.
BERT	Bidirectional Encoder Representations from Transformers	Mô hình biểu diễn mã hóa hai chiều dựa trên Transformer.
BTXRD	Bone Tumor X-Ray Dataset	Bộ dữ liệu X-quang u xương.
CLIP	Contrastive Language-Image Pre-training	Tiền huấn luyện tương phản ngôn ngữ–hình ảnh.
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập.
CTCH	–	Chấn thương Chỉnh hình; tên viết tắt bộ dữ liệu bệnh viện trong khóa luận.
FLOPs	Floating-Point Operations	Số phép toán dấu phẩy động.
GFLOPs	Giga Floating-Point Operations	Đơn vị tỷ phép toán dấu phẩy động.
FN	False Negative	Âm sai trong phân lớp một lớp so với phần còn lại.
FP	False Positive	Dương sai trong phân lớp một lớp so với phần còn lại.
FPR	False Positive Rate	Tỷ lệ dương sai; cách chọn lớp dương phụ thuộc tác vụ đánh giá.
GPU	Graphics Processing Unit	Bộ xử lý đồ họa.
ID	In-Distribution	Dữ liệu trong phân phối.
IG	Integrated Gradients	Tích phân gradient.
k-NN	k-Nearest Neighbors	Phương pháp k láng giềng gần nhất.
LoRA	Low-Rank Adaptation	Thích nghi hạng thấp.
MLP	Multilayer Perceptron	Mạng truyền thẳng nhiều lớp.
OOD	Out-of-Distribution	Dữ liệu ngoài phân phối.
PEFT	Parameter-Efficient Fine-Tuning	Tinh chỉnh hiệu quả tham số.
SML	Semantic Matching Loss	Hàm mất mát khớp ngữ nghĩa.
TN	True Negative	Âm đúng.
TP	True Positive	Dương đúng.
TPR	True Positive Rate	Tỷ lệ dương đúng.
ViT	Vision Transformer	Mô hình Transformer cho dữ liệu hình ảnh.
VLM	Vision-Language Model	Mô hình ngôn ngữ–thị giác.

Danh mục thuật ngữ Anh–Việt

Thuật ngữ tiếng Anh	Nghĩa và cách dùng trong khóa luận
Ablation study	Nghiên cứu loại bỏ hoặc thay thế thành phần để khảo sát ảnh hưởng của lựa chọn thiết kế.
AUROC-OOD	Diện tích dưới đường cong ROC dùng để đánh giá khả năng xếp hạng mẫu ID và OOD.
AUPR-Out	Diện tích dưới đường cong độ chính xác–độ nhạy khi xem mẫu OOD là lớp dương.
Backbone	Mạng nền dùng để trích xuất biểu diễn đầu vào.
Baseline model	Mô hình đối chứng dùng để so sánh kết quả thực nghiệm.
Baseline input	Đầu vào tham chiếu của phép giải thích hoặc can thiệp; khác với mô hình đối chứng.
Bidirectional cross-attention	Chú ý chéo hai chiều: ảnh truy vấn văn bản và văn bản truy vấn ảnh.
Bootstrap	Lấy mẫu lại có hoàn lại để ước lượng độ bất định của một đại lượng thống kê.
Center crop	Cắt vùng trung tâm của ảnh sau bước thay đổi kích thước.
Class imbalance	Mất cân bằng lớp: số lượng quan sát chênh lệch giữa các lớp.
Clinical history	Bệnh sử lâm sàng; trên CTCH gồm lý do vào viện, diễn tiến bệnh và tiền sử.
Domain adaptation	Thích ứng miền dữ liệu; trong khóa luận là điều chỉnh biểu diễn tiền huấn luyện cho dữ liệu đích.
Domain shift	Dịch chuyển miền: thay đổi phân phối do cơ sở y tế, thiết bị, quần thể hoặc điều kiện thu nhận.
Embedding	Vector nhúng biểu diễn đầu vào trong không gian đặc trưng.
False-negative pair	Cặp âm giả trong học tương phản: cặp khác mẫu nhưng có quan hệ ngữ nghĩa bị xem là âm; không đồng nhất với FN phân lớp.
FPR@95%TPR	Tỷ lệ chấp nhận nhầm mẫu OOD tại ngưỡng giữ lại ít nhất 95% mẫu ID trong giao thức của khóa luận.

Danh mục thuật ngữ Anh–Việt (tiếp theo)

Thuật ngữ tiếng Anh	**Nghĩa và cách dùng trong khóa luận**
Full fine-tuning	Tinh chỉnh toàn bộ tham số mô hình.
Image-only	Cấu hình chỉ sử dụng ảnh, không nhận văn bản trong pha phân lớp.
Label smoothing	Làm trơn nhãn: phân bổ một phần xác suất đích cho các lớp khác nhằm hạn chế dự đoán quá tự tin.
Logit	Điểm đầu ra của mô hình trước phép Softmax.
Macro-F1	Trung bình không trọng số của điểm F1 trên từng lớp.
Metadata	Siêu dữ liệu mô tả mẫu, như tuổi, giới tính, vị trí giải phẫu hoặc cờ nhóm bệnh.
Modality	Phương thức dữ liệu; khóa luận xét ảnh và văn bản.
Padding	Đệm chuỗi hoặc ảnh; đệm token văn bản không đồng nghĩa với đệm viền ảnh.
Patch token	Đơn vị biểu diễn của một mảnh ảnh trong ViT.
Semantic matching	Khớp ngữ nghĩa giữa biểu diễn ảnh và văn bản.
Shortcut learning	Học dựa vào dấu hiệu phụ tương quan với nhãn thay vì đặc trưng cần thiết cho tác vụ.
Token / subword	Đơn vị mã hóa văn bản / mảnh từ; token có thể là từ, mảnh từ, dấu câu hoặc ký hiệu đặc biệt.
Weighted cross-entropy	Entropy chéo có trọng số lớp, làm thay đổi chi phí của lỗi giữa các lớp.

Danh mục ký hiệu

Ký hiệu	Mô tả	Trang
x^{img}	Ảnh X-quang đầu vào của hệ thống.	5
H, W, C	Chiều cao, chiều rộng và số kênh của ảnh.	5
x^{txt}	Chuỗi văn bản lâm sàng đầu vào.	5
w_t, T	Đơn vị từ ngữ tại vị trí t và tổng số đơn vị từ ngữ.	5
$\mathcal{Y}$, y_k, K	Tập nhãn trong phân phối, lớp thứ k và tổng số lớp.	5
$\widehat{y}$	Nhãn dự đoán cuối cùng.	5
ω_{OOD}	Chỉ báo cảnh báo, bằng 1 khi điểm bất thường vượt ngưỡng.	49
$s_{\text{OOD}}(\cdot)$	Điểm bất thường đa phương thức, giá trị lớn hơn biểu thị mẫu khác biệt hơn so với dữ liệu tham chiếu.	48
$p(y_k \mid x^{\text{img}}, x^{\text{txt}})$	Xác suất dự đoán lớp y_k.	5
$E(x)$	Điểm năng lượng của mẫu x.	23
$f_i(x)$	Logit phân loại của lớp i.	23
$d_E(z, c_k)$	Khoảng cách Euclid giữa đặc trưng z và tâm lớp c_k.	23
$d_M(z, \mu_k)$	Khoảng cách Mahalanobis giữa đặc trưng z và trung bình μ_k.	23
Σ, I	Ma trận hiệp phương sai và ma trận đơn vị.	23
λ_{cov}	Hệ số điều chuẩn ma trận hiệp phương sai trong khoảng cách Mahalanobis.	23
S_k, f_θ, c_k	Tập hỗ trợ, hàm đặc trưng và tâm đại diện của lớp k.	25
$\mathcal{D}_{\text{train}}$, N	Tập dữ liệu và tổng số mẫu huấn luyện.	32
x_i^{img}, x_i^{txt}, y_i	Ảnh X-quang, bệnh sử và nhãn của mẫu thứ i.	32
q_{ic}	Xác suất đích đã làm trơn của lớp c đối với mẫu i.	45
ε_{ls}	Hệ số làm trơn nhãn, bằng 0,1 trong cấu hình XBone-Net.	45
$\mathcal{L}_{\text{WLSCE}}$	Hàm mất mát entropy chéo có trọng số lớp và làm trơn nhãn.	46
$Z_{\mathcal{B}}$	Tổng trọng số của các nhãn đúng trong một lô.	46
ε_{num}	Hằng số nhỏ bảo đảm ổn định số khi chuẩn hóa khoảng cách.	48
TP_c, FP_c, TN_c, FN_c	Các trường hợp dương/âm tính thật/giả của lớp c.	60
TPR_c, FPR_c	Tỷ lệ dương tính thật và dương tính giả.	60
$\mathcal{D}_{\text{ID}}$, $\mathcal{D}_{\text{OOD}}$	Tập dữ liệu trong phân phối và ngoài phân phối.	60
τ_{alert}	Ngưỡng cảnh báo được hiệu chỉnh trên tập xác thực trong phân phối.	48
τ_{95}^{test}	Ngưỡng đánh giá FPR@95%TPR được xác định trên tập kiểm thử.	63
$\text{Precision}_{\text{OOD}}$, $\text{Recall}_{\text{OOD}}$	Độ chính xác dự đoán và độ nhạy khi xem dữ liệu ngoài phân phối là lớp dương.	62

Tóm tắt

Phân lớp bệnh lý xương trên ảnh X-quang gặp khó khăn do tổn thương tương đồng và mất cân bằng lớp, đặc biệt ở các lớp ít mẫu. Bệnh sử lâm sàng cung cấp ngữ cảnh bổ sung nhưng vai trò này cần được đánh giá thực nghiệm. Đề tài phát triển XBone-Net nhằm kết hợp ảnh và văn bản cho phân lớp bệnh lý xương với chi phí cập nhật tham số thấp. Mô hình kế thừa BiomedCLIP, sử dụng thích nghi hạng thấp LoRA, huấn luyện hai pha và chú ý chéo hai chiều để trao đổi đặc trưng ảnh–văn bản. Thực nghiệm thực hiện trên BTXRD và CTCH với phân hoạch cố định, ba hạt giống ngẫu nhiên; văn bản BTXRD được sinh từ siêu dữ liệu, còn CTCH sử dụng bệnh sử trong bệnh án. Đánh giá gồm so sánh phân lớp và chi phí, đối chứng chỉ ảnh, nghiên cứu loại bỏ thành phần, phát hiện ngoài phân phối và giải thích bằng tích phân gradient. XBone-Net đạt Macro-F1 trung bình 0,6240 trên BTXRD và 0,5727 trên CTCH; cấu hình chỉ ảnh trên CTCH đạt 0,3813. Mô hình chỉ cập nhật khoảng 4,13% tham số và giảm 60,3–61,9% bộ nhớ GPU huấn luyện so với BiomedCLIP tinh chỉnh toàn bộ, nhưng chưa giảm thời gian huấn luyện hay chi phí suy luận. Kết quả cho thấy tiềm năng của thích nghi đa phương thức hiệu quả về tham số trong điều kiện dữ liệu mất cân bằng. Tuy nhiên, cảnh báo ngoài phân phối còn hạn chế và chưa có kiểm định ngoài độc lập; vì vậy, kết quả chỉ có ý nghĩa trong phạm vi thực nghiệm, chưa đủ cơ sở xác nhận khả năng ứng dụng lâm sàng.

Chương 1

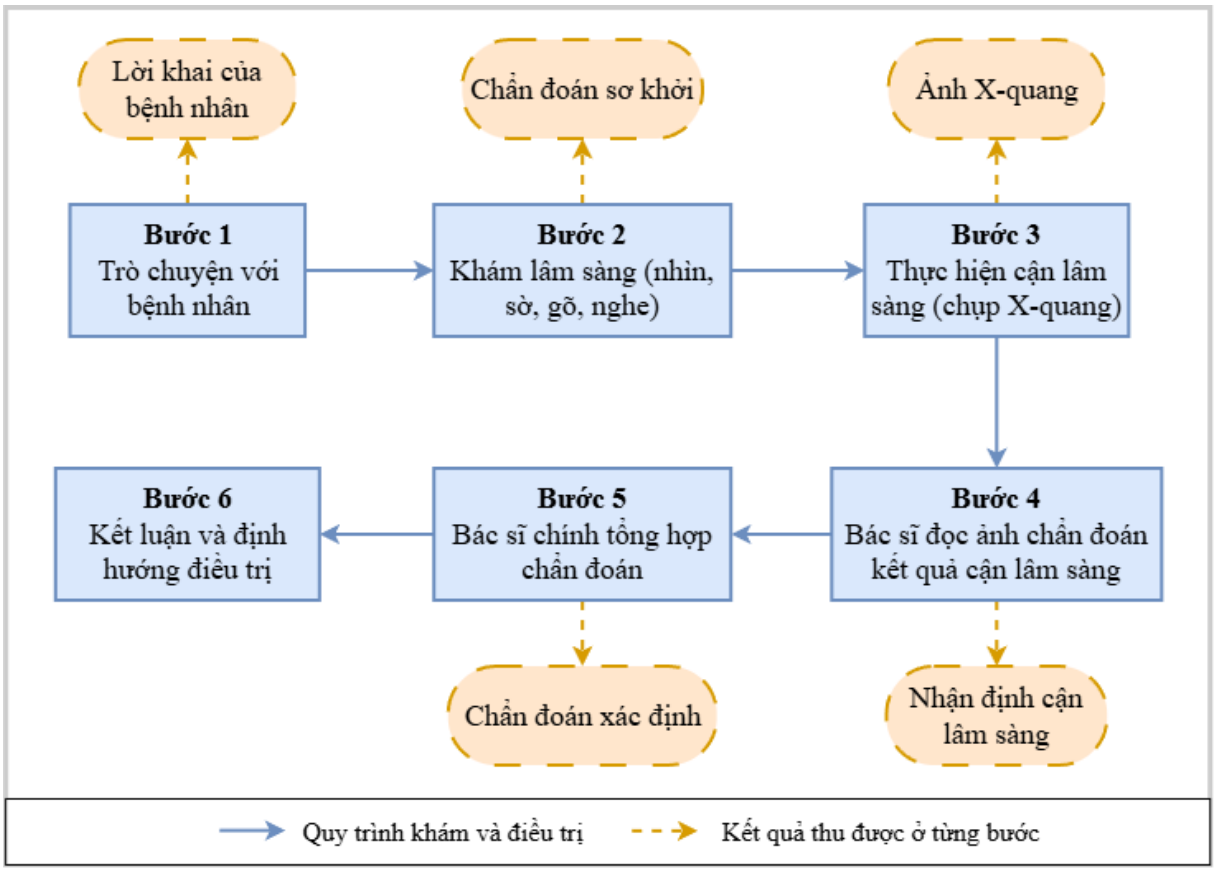
Giới thiệu

Chương này trình bày bối cảnh, vấn đề nghiên cứu và phạm vi của bài toán phân lớp ảnh X-quang xương bằng học sâu đa phương thức. Trọng tâm của khóa luận là khai thác đồng thời ảnh X-quang và nguồn văn bản đi kèm. Khóa luận áp dụng hai kịch bản dữ liệu gồm nguồn văn bản chính là văn bản lâm sàng có sẵn trong bệnh án và văn bản lâm sàng được sinh ngoại tuyến từ siêu dữ liệu do bộ dữ liệu không cung cấp bệnh sử tương ứng với từng ảnh. Hai nguồn này được phân tích riêng vì không có mức độ xác thực lâm sàng và quan hệ với nhãn giống nhau. Chương cũng xác định các thách thức liên quan đến độ phân giải ảnh, mất cân bằng lớp, dữ liệu ngoài phân phối và khả năng giải thích để từ đó đặt ra mục tiêu, giới hạn bài toán, câu hỏi nghiên cứu và các đóng góp của khóa luận.

1.1 Bối cảnh, động lực và nhu cầu nghiên cứu

Hệ xương đóng vai trò quan trọng trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Vì vậy, các chấn thương và bệnh lý về xương cần được phát hiện và đánh giá kịp thời để hỗ trợ lựa chọn hướng xử trí phù hợp. Trong thực hành lâm sàng, X-quang là một phương tiện chẩn đoán hình ảnh phổ biến, có chi phí tương đối thấp và cho phép bác sĩ khảo sát cấu trúc xương, nhận diện tổn thương và các bất thường hình thái.

Tuy nhiên, việc đọc ảnh X-quang có thể gặp khó khăn khi tổn thương nhỏ, độ tương phản thấp hoặc số lượng ca cần xử lý lớn; khi đó kết quả phụ thuộc đáng kể vào kinh nghiệm và sự tập trung của bác sĩ. Với sự phát triển của trí tuệ nhân tạo, đặc biệt ở lĩnh vực thị giác máy tính, nhiều mô hình học sâu đã được phát triển để hỗ trợ phân tích và phân lớp ảnh X-quang. Dù vậy, các mô hình chỉ sử dụng hình ảnh mới khai thác một phần thông tin của ca bệnh, trong khi quá trình ra quyết định thực tế còn dựa trên các thông tin lâm sàng như triệu chứng, tiền sử và cơ chế chấn thương. Hai nguồn thông tin này mang tính bổ sung: ảnh X-quang phản ánh đặc điểm hình thái của tổn thương, còn bệnh sử cung cấp ngữ cảnh giúp diễn giải các dấu hiệu hình ảnh trong từng trường hợp cụ thể. Quy trình chẩn đoán bệnh lý xương cùng dữ liệu thu thập qua từng bước thường tuân theo Hình 1.1



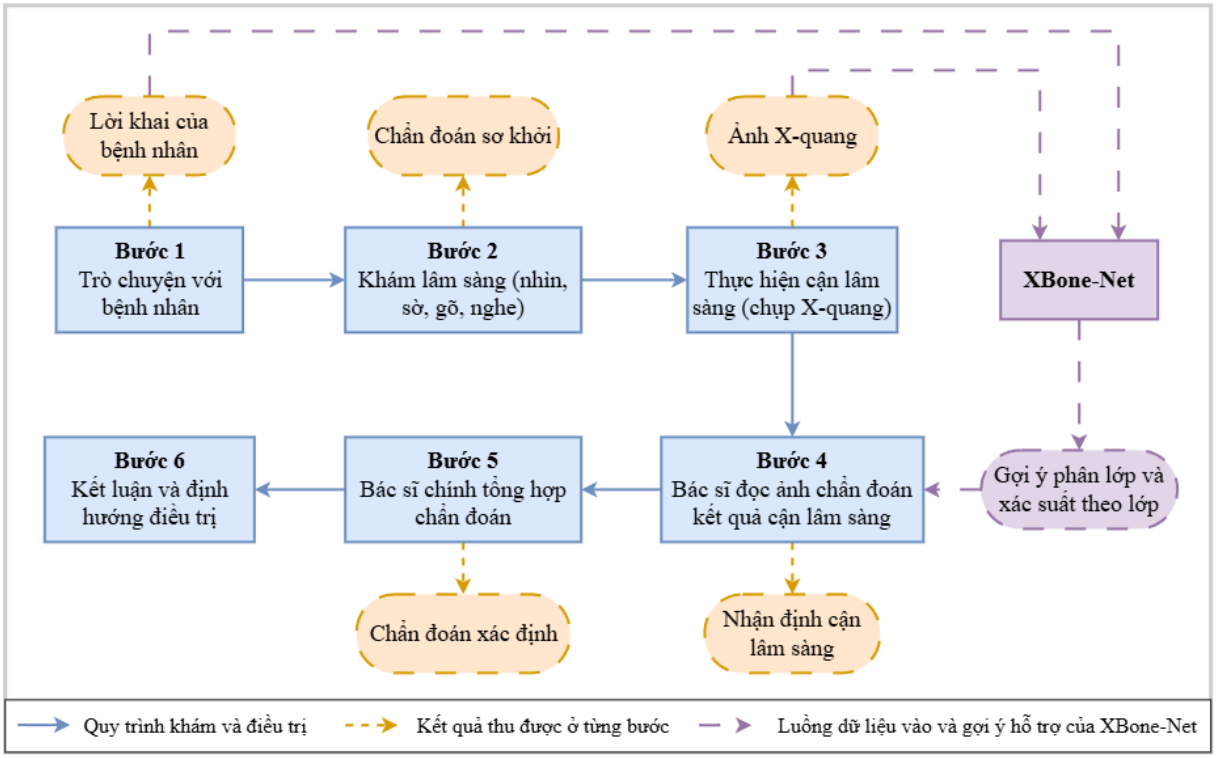
Hình 1.1: Sơ đồ quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam)

Thực tiễn dữ liệu thu thập được từ thực tế phục vụ cho việc huấn luyện các mô hình còn đưa ra một số hạn chế cần được xử lý liên quan đến mất cân bằng dữ liệu giữa các lớp và việc mô hình cần được xem xét thêm về chi phí thích nghi, hay trường hợp ca bệnh mới chưa từng xuất hiện và khả năng truy vết nguồn thông tin ảnh hưởng đến dự đoán phục vụ cho việc giải thích kết quả hệ thống.

Từ các vấn đề trên, khóa luận đặt ra nhu cầu xây dựng một hệ thống phân lớp X-quang xương đa phương thức có khả năng tận dụng hai nguồn thông tin hình ảnh và văn bản tương tác trực tiếp trước khi phân lớp. Bên cạnh hiệu năng dự đoán, hệ thống cần được đánh giá về sự đánh đổi tài nguyên, khả năng cảnh báo dữ liệu ngoài phân phối và mức độ phụ thuộc của dự đoán vào từng nguồn thông tin. Đây là động lực chính dẫn đến việc đề xuất hệ thống được đặt tên XBone-Net trong khóa luận.

1.1.1 Vị trí hệ thống trong quy trình khám chữa bệnh lý xương

Hệ thống được đề xuất trong khóa luận được thiết kế để hỗ trợ bước phân tích ảnh trong quá trình khám bệnh bằng cách khai thác đồng thời ảnh X-quang và dữ liệu văn bản đi kèm để dự đoán lớp bệnh lý, như thể hiện ở Hình 1.2. Trên bộ dữ liệu CTCH, văn bản đầu vào là bệnh sử có sẵn trong bệnh án; trong khi đó, BTXRD không cung cấp bệnh sử tự do nên sử dụng văn bản lâm sàng được sinh ngoại tuyến từ siêu dữ liệu. Hai kịch bản được phân tích riêng vì không có mức độ xác thực lâm sàng và mối quan hệ với nhãn tương đương nhau; do đó, kết quả với văn bản tổng hợp không được diễn giải như bằng chứng tương đương với bệnh sử tự nhiên.



Hình 1.2: Sơ đồ tích hợp hệ thống XBone-Net hỗ trợ phân tích (các khối tím) vào quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả dữ liệu thu được ở từng bước (các khối cam)

Trong phạm vi khóa luận, hệ thống trí tuệ nhân tạo được định hướng như một công cụ hỗ trợ phân tích, thay vì thay thế bác sĩ hoặc trực tiếp đưa ra quyết định chẩn đoán. Bên cạnh kết quả phân lớp, nghiên cứu còn xem xét các tín hiệu nhận diện dữ liệu ngoài phân phối và bản đồ đóng góp nhằm cung cấp thêm thông tin về mức độ tin cậy cũng như cơ sở hình thành dự đoán của mô hình. Các đầu ra này chủ yếu phục vụ mục đích phân tích, kiểm tra và truy vết hành vi của hệ thống, do đó không được xem là cơ chế bảo đảm an toàn tuyệt đối hay bằng chứng xác nhận vị trí tổn thương có giá trị lâm sàng.

1.2 Giới thiệu bài toán

Bài toán được nghiên cứu trong đề tài là bài toán phân lớp đa lớp ảnh X-quang sử dụng học sâu đa phương thức. Mục tiêu của hệ thống là dự đoán các loại bệnh hoặc tổn thương dựa đồng thời vào ảnh X-quang và văn bản đi kèm.

1.2.1 Đầu vào

Hệ thống nhận vào các nguồn dữ liệu sau:

- **Ảnh X-quang của bệnh nhân:**

$$x^{\text{img}} \in \mathbb{R}^{H \times W \times C}$$

  Với H, W là chiều cao và chiều rộng ảnh, C là số kênh màu của ảnh.

- **Văn bản đi kèm:** văn bản lâm sàng hoặc văn bản lâm sàng được sinh từ siêu dữ liệu.

$$x^{\text{txt}} = (w_1, w_2, \ldots, w_T)$$

  Với w_t là đơn vị từ ngữ tại vị trí thứ t trong văn bản, T là số lượng đơn vị từ ngữ trong văn bản.

- **Tập nhãn được định nghĩa trước:**

$$\mathcal{Y} = \{y_1, y_2, \ldots, y_K\}$$

  với K là số lớp bệnh cần phân lớp.

1.2.2 Đầu ra

Hệ thống sinh ra ba đầu ra chính:

- **Cảnh báo dữ liệu ngoài phân phối:**

$$\omega_{\mathrm{OOD}} = \begin{cases} 1, & \text{nếu } s_{\mathrm{OOD}}\left(x^{\mathrm{img}}, x^{\mathrm{txt}}\right) > \tau_{\mathrm{alert}}, \\ 0, & \text{ngược lại,} \end{cases}$$

  Với $s_{\mathrm{OOD}}\left(x^{\mathrm{img}}, x^{\mathrm{txt}}\right)$ là điểm bất thường đa phương thức của mẫu đầu vào, τ_{alert} là ngưỡng cảnh báo được hiệu chỉnh trước trên tập xác thực và $\omega_{\mathrm{OOD}} = 1$ biểu thị rằng hệ thống phát cảnh báo. Cảnh báo này không tự khẳng định mẫu chắc chắn nằm ngoài phân phối.

- **Nhãn dự đoán cuối cùng:**

$$\hat{y} = \arg\max_{y_k \in \mathcal{Y}} p\left(y_k \mid x^{\mathrm{img}}, x^{\mathrm{txt}}\right),$$

  Với $p\left(y_k \mid x^{\mathrm{img}}, x^{\mathrm{txt}}\right)$ là xác suất dự đoán của lớp y_k.

- **Thông tin hỗ trợ giải thích:** Hệ thống sinh ra các bản đồ nhiệt đóng góp cho ảnh và văn bản đi kèm nhằm khảo sát mức độ liên hệ của từng nguồn thông tin với dự đoán của mô hình.

1.2.3 Các thách thức trong bài toán

Mặc dù các mô hình học sâu đa phương thức đã đạt được nhiều kết quả tích cực, bài toán vẫn tồn tại nhiều thách thức cần được giải quyết:

- **Sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu đầu vào thực tế:** Tồn tại sự chênh lệch giữa các bộ dữ liệu đa phương thức hiện có, thường là cặp ảnh X-quang và báo cáo đọc ảnh, so với dữ liệu đầu vào được khảo sát trong khóa luận gồm ảnh X-quang kết hợp với bệnh sử hoặc thông tin lâm sàng ban đầu. Sự khác biệt này có thể hạn chế khả năng chuyển giao trực tiếp của mô hình.

- **Sự khác biệt về không gian và ngữ nghĩa giữa dữ liệu hình ảnh và dữ liệu văn bản:** Sự khác biệt này gây khó khăn cho quá trình học biểu diễn chung, yêu cầu một cơ chế dung hợp hiệu quả.

- **Độ phân giải ảnh cao:** Ảnh X-quang xương thường có độ phân giải cao, trong khi nhiều mô hình hiện tại được huấn luyện trên dữ liệu với độ phân giải thấp hơn. Điều này có thể làm mất thông tin chi tiết quan trọng, ảnh hưởng đến hiệu năng phân lớp.

- **Mất cân bằng dữ liệu và các lớp ít mẫu:** Dữ liệu y tế thường có phân bố không đồng đều giữa các loại bệnh, trong đó một số lớp chỉ có số lượng mẫu hạn chế. Điều này đặt ra yêu cầu về thiết kế mô hình và tiêu chí đánh giá có xét đồng đều đến các lớp, nhằm hạn chế việc kết quả tổng thể bị chi phối bởi các lớp nhiều mẫu.

- **Khả năng giải thích của mô hình:** Khả năng giải thích của các mô hình vẫn còn hạn chế khiến độ tin cậy của người dùng vào các dự đoán của hệ thống là không cao, gây khó khăn cho việc triển khai trong thực tế lâm sàng.

- **Dữ liệu ngoài phân phối:** Các bộ phân lớp chưa được thiết kế để xử lý các trường hợp dữ liệu ngoài phân phối, dẫn đến nguy cơ đưa ra dự đoán không chính xác với độ tin cậy cao đối với những ca bệnh mới chưa từng xuất hiện trong dữ liệu huấn luyện, đặt ra yêu cầu về khả năng tổng quát hóa và thích ứng của mô hình.

1.3 Mục tiêu nghiên cứu

Đề tài hướng đến xây dựng và đánh giá một hệ thống học sâu đa phương thức phục vụ phân lớp bệnh lý trên ảnh X-quang xương bằng cách kết hợp thông tin hình ảnh và văn bản lâm sàng. Hệ thống được nghiên cứu trong điều kiện dữ liệu mất cân bằng, đồng thời được đánh giá về hiệu năng phân lớp, chi phí tính toán, khả năng cảnh báo dữ liệu ngoài phân phối và mức độ giải thích của dự đoán. Để làm rõ vai trò quan sát được của dữ liệu lâm sàng, cấu hình XBone-Net đầy đủ phương thức được đối chiếu trực tiếp với cấu hình XBone-Net chỉ sử dụng ảnh trên bộ dữ liệu CTCH.

Các mục tiêu cụ thể của đề tài bao gồm:

1. Xây dựng XBone-Net bằng cách thích nghi BiomedCLIP với LoRA, quy trình huấn luyện hai giai đoạn và mô-đun dung hợp ảnh-văn bản cho bài toán phân lớp X-quang xương.

2. Đánh giá hiệu năng phân lớp của XBone-Net so với các mô hình đối chứng trong thiết lập toàn bộ dữ liệu; trên CTCH, so sánh cấu hình đầy đủ với cấu hình chỉ ảnh để đánh giá vai trò quan sát được của văn bản lâm sàng trong điều kiện mất cân bằng với các lớp ít mẫu; đồng thời định lượng sự đánh đổi giữa số tham số cập nhật, chi phí huấn luyện và chi phí suy luận. So sánh này cũng được dùng để thảo luận khả năng thích nghi với dữ liệu đích, nhưng không thay thế kiểm định ngoài trên dữ liệu từ miền độc lập.

3. Thực hiện các thí nghiệm loại bỏ và thay thế thành phần để xác định ảnh hưởng của quy trình huấn luyện và cơ chế dung hợp đến hiệu năng phân loại.

4. Đánh giá hai đầu ra hỗ trợ của hệ thống gồm cảnh báo dữ liệu ngoài phân phối bằng các điểm bất thường hậu xử lý và truy vết nguồn phụ thuộc của dự đoán bằng tích phân gradient kết hợp can thiệp đầu vào; trong đó cấu hình chỉ ảnh được sử dụng làm đối chứng để khảo sát tín hiệu bổ sung từ văn bản lâm sàng.

1.4 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học sâu đa phương thức trong bài toán phân lớp bệnh lý trên ảnh X-quang xương, sử dụng đồng thời thông tin hình ảnh và văn bản lâm sàng. Nghiên cứu tập trung vào các nhóm mô hình và thành phần kỹ thuật sau:

- Các mô hình ngôn ngữ trực quan được tiền huấn luyện trên dữ liệu tổng quát hoặc dữ liệu y khoa, đóng vai trò bộ mã hóa đặc trưng hình ảnh và văn bản.
- Các phương pháp biểu diễn ảnh X-quang bằng đơn vị toàn cục và chuỗi đơn vị cục bộ từ các biểu diễn mảnh ảnh từ bộ mã hóa thị giác tiền huấn luyện.
- Các chiến lược dung hợp đa phương thức, bao gồm phép nối đặc trưng và cơ chế chú ý chéo, để kết hợp biểu diễn hình ảnh với thông tin văn bản lâm sàng.
- Cấu hình XBone-Net chỉ sử dụng ảnh, đóng vai trò đối chứng theo nguồn đầu vào khi đánh giá vai trò của văn bản lâm sàng trong phân lớp, cảnh báo dữ liệu ngoài phân phối và phân tích mức phụ thuộc của dự đoán.
- Các phương pháp tinh chỉnh hiệu quả tham số cho mô hình tiền huấn luyện quy mô lớn, tập trung vào việc giới hạn số tham số cần cập nhật trong quá trình huấn luyện.
- Đầu phân lớp tuyến tính kết hợp hàm mất mát có trọng số để xử lý bài toán phân lớp đa lớp trên dữ liệu mất cân bằng.
- Các phương pháp phát hiện dữ liệu ngoài phân phối và trực quan hóa bản đồ tích phân gradient nhằm hỗ trợ đánh giá độ tin cậy và khả năng giải thích của mô hình.

1.5 Phạm vi nghiên cứu

Đề tài tập trung vào bài toán phân lớp đa lớp bệnh lý xương trên ảnh X-quang, kết hợp với văn bản lâm sàng. Phạm vi cụ thể bao gồm:

- **Dữ liệu:** Sử dụng bộ dữ liệu BTXRD [49] gồm 10 lớp bệnh lý xương và bộ dữ liệu CTCH gồm 22 lớp chấn thương xương thu thập từ Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.

- **Dữ liệu văn bản:** Bộ dữ liệu CTCH sử dụng bệnh sử có sẵn trong bệnh án, gồm lý do vào viện, diễn tiến bệnh và tiền sử. Bộ dữ liệu BTXRD không có bệnh sử tự do nên sử dụng văn bản lâm sàng được sinh ngoại tuyến từ siêu dữ liệu. Vì mẫu câu tổng hợp có phụ thuộc vào các cờ nhóm bệnh, kết quả BTXRD chỉ phản ánh thiết lập văn bản tổng hợp và không được xem là bằng chứng tương đương với văn bản lâm sàng tự nhiên.

- **Đối chứng theo phương thức:** Việc so sánh XBone-Net chỉ ảnh với XBone-Net đầy đủ phương thức được thực hiện trên CTCH, nơi bệnh sử tự nhiên đi kèm từng ca được sử dụng làm nguồn văn bản. Cấu hình chỉ ảnh không nhận văn bản và không thực hiện pha khớp ngữ nghĩa ảnh-văn bản; vì vậy, chênh lệch giữa hai cấu hình phản ánh đồng thời nguồn đầu vào và quy trình huấn luyện tương ứng, không phải ước lượng nhân quả riêng của bệnh sử.

- **Dữ liệu mất cân bằng:** Cụm từ "lớp ít mẫu" trong khóa luận chỉ các lớp có số lượng quan sát thấp trong phân bố mất cân bằng của bộ dữ liệu hiện có. Đề tài không xây dựng một thiết lập riêng bằng cách giảm tỷ lệ toàn bộ dữ liệu huấn luyện để đánh giá bài toán học ít dữ liệu.

- **Vai trò hệ thống:** Hệ thống được thiết kế làm công cụ hỗ trợ phân tích, không thay thế vai trò của bác sĩ trong quá trình ra quyết định.

- **Giới hạn:** Đề tài không tập trung vào các bài toán phát hiện đối tượng, phân đoạn ảnh hay sinh báo cáo y khoa tự động.

1.6 Câu hỏi nghiên cứu

Để đạt được các mục tiêu đã đề ra, nghiên cứu tập trung trả lời các câu hỏi sau:

- **Câu hỏi nghiên cứu 1:**

  Trong tác vụ phân loại, XBone-Net đạt mức hiệu năng nào so với các mô hình đối chứng; trên CTCH, kết quả thay đổi như thế nào khi bổ sung văn bản lâm sàng và quy trình huấn luyện đa phương thức tương ứng so với cấu hình chỉ ảnh trong điều kiện dữ liệu mất cân bằng với các lớp ít mẫu; đồng thời mô hình đánh đổi như thế nào giữa số tham số cần cập nhật, chi phí huấn luyện và chi phí suy luận?

- **Câu hỏi nghiên cứu 2:**

  Các thành phần do khóa luận lựa chọn cho XBone-Net, gồm quy trình huấn luyện hai pha và cơ chế dung hợp, ảnh hưởng như thế nào đến hiệu năng phân loại của mô hình?

- **Câu hỏi nghiên cứu 3:**

  Điểm cảnh báo hậu xử lý được xây dựng từ không gian biểu diễn của từng mô hình có thể phân biệt dữ liệu CTCH trong phân phối với các bệnh lý gần miền nằm ngoài không gian nhãn ở mức nào, và việc bổ sung bệnh sử tạo ra khác biệt quan sát được ra sao giữa XBone-Net chỉ ảnh, XBone-Net đầy đủ phương thức, hai biến thể cùng BiomedCLIP tinh chỉnh toàn bộ?

- **Câu hỏi nghiên cứu 4:**

  Tích phân gradient kết hợp với can thiệp đầu vào phản ánh mức phụ thuộc của dự đoán vào thông tin hình ảnh và văn bản như thế nào, và kết quả khác nhau ra sao giữa XBone-Net chỉ ảnh, XBone-Net đầy đủ phương thức và các cấu hình đối chứng?

1.7 Đóng góp chính của đề tài

Đóng góp cốt lõi của khóa luận là xây dựng và đánh giá XBone-Net, một phương pháp thích nghi BiomedCLIP và tối ưu hóa đặc trưng dữ liệu phục vụ cho bài toán phân lớp X-quang xương đa phương thức. Các đóng góp chính gồm:

1. **Đề xuất quy trình tối ưu biểu diễn dữ liệu cho phân loại:** kết hợp LoRA trên hai bộ mã hóa của BiomedCLIP, huấn luyện hai pha và cơ chế chú ý chéo hai chiều để vừa thích nghi biểu diễn với miền X-quang xương, vừa khai thác bổ sung ngữ nghĩa giữa đặc trưng hình ảnh và văn bản trước khi phân lớp. Điều này cũng tạo tiền đề cho hiệu năng phát hiện dữ liệu ngoài phân phối và khả năng giải thích dự đoán.

2. **Đánh giá có hệ thống hiệu năng và sự đánh đổi tài nguyên:** thực nghiệm với các mô hình đối chứng, cấu hình XBone-Net chỉ ảnh và các cấu hình loại bỏ thành phần cho thấy XBone-Net đạt hiệu năng cạnh tranh với các mô hình ngôn ngữ-thị giác tinh chỉnh toàn bộ, đồng thời ghi nhận lợi ích của bệnh sử cùng quy trình huấn luyện đa phương thức trên CTCH trong điều kiện mất cân bằng với các lớp ít mẫu. Mô hình chỉ cập nhật khoảng 4,13% tổng số tham số và giảm hơn 60% bộ nhớ GPU cực đại trong huấn luyện; đổi lại, khóa luận chỉ ra chi phí tăng về thời gian huấn luyện và suy luận.

3. **Bổ sung đánh giá độ tin cậy và khả năng truy vết dự đoán:** xây dựng điểm cảnh báo dữ liệu ngoài phân phối từ không gian biểu diễn và sử dụng tích phân gradient kết hợp can thiệp đầu vào để khảo sát mức phụ thuộc của dự đoán vào ảnh và văn bản, trong đó cấu hình chỉ ảnh được đặt làm đối chứng trước cấu hình đầy đủ phương thức. Hai thành phần này được xem là công cụ hỗ trợ phân tích mô hình, không phải cơ chế bảo đảm an toàn hoặc bằng chứng nhân quả về quyết định lâm sàng.

1.8 Bố cục khóa luận

Khóa luận được tổ chức thành năm chương như sau:

Chương 1: Giới thiệu. Chương này trình bày bối cảnh nghiên cứu, vấn đề đặt ra, mục tiêu, đối tượng, câu hỏi nghiên cứu và các đóng góp chính của đề tài. Nội dung chương đóng vai trò định hướng cho toàn bộ khóa luận.

Chương 2: Các công trình nghiên cứu liên quan. Chương này tổng quan các nghiên cứu về mô hình ngôn ngữ trực quan, phân lớp ảnh X-quang xương, xử lý ảnh độ phân giải cao, dung hợp đa phương thức, tinh chỉnh hiệu quả tham số, phát hiện dữ liệu ngoài phân phối và khả năng giải thích mô hình. Trên cơ sở đó, chương xác định khoảng trống nghiên cứu và định vị phương pháp đề xuất so với các công trình trước.

Chương 3: Phương pháp đề xuất. Chương này mô tả kiến trúc XBone-Net, quy trình xử lý ảnh và văn bản, cơ chế dung hợp hai chiều, đầu phân lớp tuyến tính, các hàm mất mát và chiến lược huấn luyện hai giai đoạn với LoRA. Quy trình phát hiện dữ liệu ngoài phân phối và giải thích dự đoán cũng được trình bày trong chương này.

Chương 4: Thực nghiệm và kết quả. Chương này giới thiệu các bộ dữ liệu, thiết lập thực nghiệm, mô hình đối sánh và các độ đo đánh giá. Các kết quả toàn bộ mẫu, nghiên cứu loại bỏ thành phần, đánh giá hiệu quả tính toán, phát hiện dữ liệu ngoài phân phối và giải thích mô hình được phân tích nhằm làm rõ ưu điểm, hạn chế và sự đánh đổi của phương pháp đề xuất.

Chương 5: Kết luận và hướng phát triển. Chương cuối tổng kết các kết quả đạt được, trả lời các câu hỏi nghiên cứu, chỉ ra những hạn chế còn tồn tại và đề xuất các hướng cải tiến, mở rộng trong tương lai.

Chương 2

Các công trình nghiên cứu liên quan

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Nhằm xác lập cơ sở cho việc thiết kế hệ thống phân lớp, phần này sẽ mô tả tổng quan các nghiên cứu về các mô hình nền tảng của các cách tiếp cận khác nhau cho bài toán phân lớp ảnh y khoa, đặc biệt là cách kết hợp ngữ cảnh toàn cục với đặc trưng cục bộ, các kỹ thuật tinh chỉnh hiệu quả tham số và phương pháp phát hiện dữ liệu ngoài phân phối. Trên cơ sở đó, đối chiếu ưu điểm, hạn chế và mức độ phù hợp của các hướng tiếp cận hiện có đối với dữ liệu thực tế, chương xác định khoảng trống nghiên cứu và làm rõ cơ sở lựa chọn các thành phần trong phương pháp được đề xuất ở Chương 3.

2.1 Các hướng tiếp cận chính và các mô hình nền tảng

2.1.1 Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu

Sự kết hợp giữa dữ liệu cận lâm sàng và báo cáo lâm sàng, lịch sử bệnh lý đã tạo ra những bước tiến lớn trong việc cải thiện độ chính xác của các mô hình chẩn đoán, đặc biệt là thông qua việc sử dụng văn bản để bù đắp những thiếu sót thông tin mà hình ảnh đơn thuần không thể cung cấp, hoặc giúp mô hình tập trung vào những vùng trên ảnh được xác định bởi thông tin từ nguồn văn bản. Nghiên cứu của X. Mei [30] trong việc chẩn đoán COVID-19 là một minh chứng rõ nét: khi ảnh chụp CT ngực ở giai đoạn sớm có thể chưa biểu hiện bất thường, việc tích hợp thông tin lâm sàng thông qua mạng MLP với đặc trưng ảnh từ CNN đã giúp mô hình nhận diện chính xác 68% số bệnh nhân dương tính mà các bác sĩ X-quang đã bỏ sót. Mô hình TieNet [45] đã mã hóa các báo cáo y tế và tích hợp các cơ chế chú ý đa cấp để gióng hàng các từ mang ý nghĩa quan trọng với các vùng ảnh tương ứng, cải thiện trung bình 6% chỉ số AUC so với các mô hình chỉ dùng ảnh. Gần đây, IRENE [53] đưa tất cả dữ liệu về một dạng đơn vị biểu diễn chung và sử dụng một mô hình Transformer duy nhất, cho phép văn bản trực tiếp tương tác và giải thích các đơn vị biểu diễn của ảnh ở cấp độ cục bộ.

Nhìn chung, những nghiên cứu này minh chứng rằng sự đóng góp của nhiều nguồn dữ liệu, đặc biệt là văn bản đã đi từ việc chỉ là một véc-tơ thông tin ghép nối thêm, trở thành một thành phần cốt lõi có khả năng gióng hàng ngữ nghĩa và định hướng trong cơ chế chú ý. Tuy nhiên, các mô hình xây dựng từ đầu thường đòi hỏi dữ liệu ghép cặp quy mô lớn và chi phí huấn luyện cao, tạo tiền đề cho sự xuất hiện của các mô hình ngôn ngữ trực quan y khoa.

2.1.2 Mô hình ngôn ngữ trực quan y khoa

Các mô hình ngôn ngữ trực quan đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu, các mô hình ngôn ngữ trực quan nói chung và các mô hình ngôn ngữ trực quan y khoa nói riêng tập trung vào hai nguồn dữ liệu đầu vào chính là ảnh và văn bản. Các mô hình ngôn ngữ trực quan y khoa kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet [12] hoặc ViT [7] cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, các mô hình ngôn ngữ trực quan y khoa tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Chiến lược học tương phản là hướng tiếp cận được ứng dụng rộng rãi nhất. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh-văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau. Bảng 2.1 tổng hợp các mô hình ngôn ngữ trực quan y khoa tiêu biểu sử dụng học tương phản.

STT	**Tên phương pháp**	**Chiến lược tiền huấn luyện**	**Phương pháp**			
			Bộ mã hoá thị giác	**Bộ mã hoá văn bản**	**Chiến lược kết hợp**	**Bộ giải mã**
1	**ConVIRT [52] (2020)**	Học tương phản	ResNet50	BERT	Căn chỉnh tương phản	N/a
2	**GLoRIA [19] (2021)**	Học tương phản	ResNet50	BioClinicalBERT	Căn chỉnh tương phản Toàn cục - Cục bộ	N/a
3	**MedCLIP [46] (2022)**	Học tương phản	Swin Transformer, ResNet50	BioClinicalBERT	Căn chỉnh tăng cường Tri thức	N/a
4	**BiomedCLIP [51] (2023)**	Học tương phản	ViT-Base	PubMedBERT	Căn chỉnh tương phản	N/a

Bảng 2.1: Tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản

ConVIRT [52] là nghiên cứu tiên phong áp dụng học tương phản cho dữ liệu y khoa, sử dụng ResNet50 và BERT để tối ưu bộ mã hóa ảnh và văn bản, đạt độ chính xác 90,3% trên bộ dữ liệu COVIDx. GLoRIA [19] mở rộng hướng tiếp cận này bằng cách kết hợp hai hàm mất mát toàn cục

và cục bộ, cho phép căn chỉnh chi tiết giữa các vùng trong ảnh và các từ trong câu. MedCLIP [46] đề xuất cơ chế tách cặp và trích xuất tri thức cùng hàm mất mát khớp ngữ nghĩa nhằm giải quyết vấn đề âm tính giả khi các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý. BiomedCLIP [51] kế thừa kiến trúc CLIP [36] với bộ mã hóa ViT-Base và PubMedBERT, được tiền huấn luyện trên 15 triệu cặp dữ liệu từ tập PMC-15M, đạt độ chính xác phân lớp không mẫu rất cao, chứng minh mô hình có độ phủ và khả năng tổng quát tốt với nhiều nguồn dữ liệu và tác vụ y khoa.

Ngoài học tương phản, các hướng tiếp cận khác bao gồm học có che giấu và tích hợp tri thức y khoa. Tuy nhiên, các phương pháp này thường phụ thuộc vào nguồn dữ liệu ghép cặp sẵn hoặc đồ thị tri thức chuyên biệt, hạn chế khả năng ứng dụng trên các bài toán không có sẵn nguồn tri thức ngoài. Song song với các mô hình ngôn ngữ trực quan y khoa, sự phát triển của các mô hình ngôn ngữ lớn đa phương thức như Med-Flamingo [31], LLaVA-Med [25] hay Med-PaLM M [43] đã cho thấy tiềm năng trong các tác vụ hội thoại và hỗ trợ ra quyết định y khoa. Tuy nhiên, các mô hình này thường có quy mô rất lớn, chi phí huấn luyện và suy luận cao, đồng thời vẫn tồn tại nguy cơ tạo ra thông tin không chính xác. Do đó, đối với các bài toán phân lớp chuyên biệt như phân lớp ảnh X-quang xương, việc sử dụng các mô hình ngôn ngữ - thị giác chuyên dụng kết hợp tinh chỉnh hiệu quả tham số thường phù hợp và hiệu quả hơn.

Lựa chọn BiomedCLIP làm mô hình nền tảng

Trong số các mô hình ngôn ngữ trực quan y khoa được khảo sát, khóa luận lựa chọn BiomedCLIP [51] làm mô hình nền tảng dựa trên mức độ phù hợp với bài toán, thay vì chỉ dựa trên kết quả của một bộ dữ liệu riêng lẻ. Thứ nhất, BiomedCLIP được tiền huấn luyện trên PMC-15M, gồm khoảng 15 triệu cặp ảnh-văn bản thu thập từ nhiều loại dữ liệu y sinh, trong khi một số mô hình trước đó chủ yếu được xây dựng và đánh giá trên ảnh X-quang ngực. Phạm vi tiền huấn luyện rộng hơn tạo cơ sở phù hợp cho việc chuyển giao sang ảnh X-quang xương, vốn có sự đa dạng lớn về vùng giải phẫu, tư thế chụp và loại tổn thương.

Thứ hai, mô hình sử dụng kiến trúc hai bộ mã hóa độc lập gồm Vision Transformer cho ảnh và PubMedBERT cho văn bản, phù hợp với thiết kế hai nhánh của hệ thống và cho phép kế thừa trực tiếp biểu diễn của cả hai phương thức. Thứ ba, kiến trúc CLIP của mô hình hỗ trợ đánh giá không mẫu thông qua độ tương đồng ảnh-văn bản, đồng thời có thể được mở rộng bằng các kỹ thuật tinh chỉnh hiệu quả tham số và mô-đun dung hợp cho bài toán đích. Vì vậy, BiomedCLIP được sử dụng làm mô hình nền tảng khởi tạo, trong khi các ý tưởng phù hợp từ những nghiên cứu khác, chẳng hạn hàm mất mát khớp ngữ nghĩa của MedCLIP, được kế thừa để cải thiện quá trình thích nghi trên dữ liệu X-quang xương.

Cơ chế phân lớp không mẫu của BiomedCLIP

BiomedCLIP có thể thực hiện phân lớp trong thiết lập *không mẫu* mà không cần huấn luyện một đầu phân lớp riêng trên dữ liệu đích. Thay vào đó, mô hình biểu diễn ảnh đầu vào và các câu nhắc mô tả lớp trong cùng một không gian đặc trưng, sau đó xác định lớp dựa trên mức độ tương đồng giữa hai phương thức.

Ảnh đầu vào x trước hết được tiền xử lý theo cấu hình của BiomedCLIP, bao gồm thay đổi kích thước, cắt vùng trung tâm và chuẩn hóa, để thu được tensor ảnh có kích thước 224×224. Ảnh sau đó được chia thành các mảnh ảnh có kích thước 16×16 và đưa qua bộ mã hóa thị giác ViT-B/16 để tạo biểu diễn ảnh.

Với mỗi lớp k, tên lớp được đưa vào một mẫu câu nhắc thống nhất, chẳng hạn `A radiograph showing [tên lớp].` Câu nhắc được mã hóa bởi bộ mã hóa văn bản PubMedBERT để thu được biểu diễn văn bản t_k. Điểm số của lớp k được tính bằng độ tương đồng cosine:

$$s_k = \frac{v^\top t_k}{\|v\|_2 \|t_k\|_2}. \tag{2.1}$$

Các điểm tương đồng được chuẩn hóa bằng hàm Softmax để tạo phân phối xác suất trên tập lớp:

$$p(y = k \mid x) = \frac{\exp(s_k/\tau)}{\sum_{j=1}^{K} \exp(s_j/\tau)}, \tag{2.2}$$

trong đó τ là hệ số nhiệt độ. Lớp có xác suất lớn nhất được chọn làm kết quả dự đoán. Cơ chế này cho phép BiomedCLIP chuyển giao tri thức đã học sang các tập nhãn mới mà không cần cập nhật tham số. Tuy nhiên, hiệu quả phụ thuộc đáng kể vào mức độ tương đồng giữa dữ liệu tiền huấn luyện và dữ liệu đích, cách xây dựng câu nhắc, cũng như khả năng biểu diễn các dấu hiệu bệnh lý chuyên biệt của bộ mã hóa.

2.2 Các kỹ thuật tinh chỉnh hiệu quả tham số

Sự xuất hiện của các mô hình nền tảng nói chung và mô hình ngôn ngữ-thị giác y sinh nói riêng đã mang lại một nền tảng tri thức đa phương thức khổng lồ. Tuy nhiên, để triển khai hiệu quả các mô hình này vào các bài toán lâm sàng đặc thù, quá trình chuyển giao tri thức là bắt buộc.

Trước đây, hai chiến lược phổ biến nhất là tinh chỉnh toàn phần và dò tuyến tính. Tinh chỉnh toàn phần cập nhật lại toàn bộ tham số của mô hình gốc, mang lại khả năng thích ứng cao nhưng đòi hỏi chi phí tính toán, bộ nhớ khổng lồ, yêu cầu dữ liệu huấn luyện lớn đến rất lớn, dẫn đến hiện tượng quên biểu diễn trên các tập dữ liệu y tế nhỏ. Ngược lại, dò tuyến tính đóng băng toàn bộ mạng nơ-ron gốc và chỉ huấn luyện một lớp phân lớp duy nhất ở cuối, tiết kiệm tài nguyên nhưng hạn chế khả năng thích ứng khi sự chênh lệch phân phối giữa dữ liệu gốc và dữ liệu y tế là quá lớn.

Để giải quyết bài toán đánh đổi giữa hiệu năng và chi phí tính toán, tinh chỉnh hiệu quả tham số đã nổi lên như một giải pháp thay thế. Kỹ thuật này chỉ cập nhật hoặc thêm mới một lượng rất nhỏ tham số, giúp tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các phương pháp tinh chỉnh hiệu quả tham số được chia thành ba hướng tiếp cận chính:

2.2.1 Tinh chỉnh sử dụng câu nhắc

Hướng tiếp cận này chèn thêm các tham số (vectơ) có thể học được vào không gian đầu vào của mô hình mà không thay đổi cấu trúc mạng bên trong [24].

- **Điểm mạnh:** Tiết kiệm tham số tối đa, bảo toàn nguyên vẹn tri thức của mô hình gốc, đặc biệt hiệu quả trong các kịch bản học ít mẫu hoặc không mẫu.
- **Điểm yếu:** Tối ưu hóa khó khăn do không gian biểu diễn bị giới hạn ở đầu vào, nhạy cảm với cách khởi tạo, và chiếm dụng một phần độ dài của chuỗi đầu vào.

Trong lĩnh vực y tế, PLIP [50] kết hợp đặc trưng thị giác với câu nhắc hiệu quả, đạt 0,896 AUC chỉ với 5% dữ liệu PanNuke. BiomedCoOp [21] tích hợp mô hình ngôn ngữ lớn để tự động sinh các câu nhắc ngữ nghĩa, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản.

2.2.2 Tinh chỉnh bộ điều hợp

Phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ, còn được gọi là bộ điều hợp vào giữa các lớp kiến trúc của mạng học sâu [16].

- **Điểm mạnh:** Tính mô-đun hóa cao, dễ dàng thêm/bớt các bộ điều hợp cho các tác vụ khác nhau mà không can thiệp vào tham số gốc.
- **Điểm yếu:** Việc chèn thêm các lớp mạng vật lý làm tăng độ trễ suy luận, hạn chế khả năng triển khai trên các hệ thống đòi hỏi thời gian thực.

Điển hình, CLIPath [22] sử dụng kết nối thặng dư để giảm khoảng cách miền trên dữ liệu nhỏ. FTB [35] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chắt lọc thông tin đa phương thức.

2.2.3 Tinh chỉnh thích nghi hạng thấp

Tinh chỉnh thích nghi hạng thấp LoRA [17] giữ cố định trọng số nền và bổ sung các ma trận hạng thấp có thể huấn luyện để tham số hóa phần cập nhật trọng số. Cách tiếp cận này sử dụng một lượng nhỏ tham số huấn luyện nhưng đem lại hiệu quả gần như tương đương với tinh chỉnh toàn phần.

- **Điểm mạnh:** Giảm đáng kể số tham số cần cập nhật và bộ nhớ tối ưu hóa với hiệu suất gần như tương đương với tinh chỉnh toàn phần. Ngoài ra, các ma trận cập nhật có thể được hợp nhất vào trọng số nền khi cách triển khai hỗ trợ.

- **Điểm yếu:** Hiệu quả phụ thuộc vào vị trí chèn, hạng của ma trận và cấu hình tối ưu. Tuy nhiên, việc giảm tham số huấn luyện không đồng nghĩa với giảm chi phí lan truyền tiến của toàn bộ kiến trúc.

Bảng 2.2 tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Nguyên lý	Kết quả nổi bật
1	**PLIP (2024) [50]**	Tinh chỉnh sử dụng câu nhắc	Kết hợp câu nhắc thị giác với tinh chỉnh chọn lọc, tận dụng đặc trưng hình ảnh để tinh chỉnh hiệu quả	0,896 AUC 5% PanNuke
2	**CLIPath (2023) [22]**	Tinh chỉnh sử dụng bộ điều hợp	Sử dụng kết nối thặng dư để giảm khoảng cách miền trên dữ liệu mô bệnh học	Cải thiện so với CLIP trên dữ liệu nhỏ
3	**LCBB (2024) [26]**	Thích nghi hạng thấp bằng LoRA	Bổ sung ma trận hạng thấp vào bộ mã hóa thị giác, giữ cố định trọng số nền	93,1% AUROC RSNA, 10%
4	**FTB (2024) [35]**	Tinh chỉnh sử dụng bộ điều hợp	Mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản, chắt lọc thông tin đa phương thức	Cải thiện trên CheXpert, RSNA

Bảng 2.2: Tổng hợp các phương pháp tinh chỉnh hiệu quả tham số cho các mô hình ngôn ngữ trực quan y khoa nổi bật

2.3 Các phương pháp phát hiện dữ liệu ngoài phân phối

Phát hiện dữ liệu ngoài phân phối - OOD nhằm nhận diện các mẫu có đặc trưng khác biệt đáng kể so với phân phối dữ liệu mà mô hình đã quan sát trong quá trình huấn luyện. Trong phân tích ảnh y khoa, OOD có thể đóng vai trò như một tín hiệu cảnh báo bổ trợ khi mô hình tiếp nhận các trường hợp chưa quen thuộc hoặc khác biệt so với dữ liệu huấn luyện. Tuy nhiên, tín hiệu này không đồng nghĩa với việc bảo đảm an toàn cho hệ thống và cũng không thể thay thế quy trình đánh giá lâm sàng của bác sĩ. Xét theo nguyên lý và cách thức xác định mức độ bất thường của mẫu đầu vào, các phương pháp phát hiện OOD hiện nay có thể được phân thành một số nhóm chính như sau.

2.3.1 Các phương pháp hậu xử lý dựa trên đầu ra của mô hình

Nhóm phương pháp này không can thiệp vào quá trình huấn luyện mà tận dụng trực tiếp đầu ra (thường là các logit hoặc xác suất) của một bộ phân lớp đã được huấn luyện.

- **Xác suất softmax cực đại [14]:** Sử dụng giá trị cực đại của hàm softmax làm độ tin cậy. Dữ liệu có xác suất cực đại thấp sẽ bị đánh dấu là ngoài phân phối. Tuy nhiên, điểm yếu chí mạng của xác suất softmax cực đại là các mạng nơ-ron sâu thường mắc lỗi "tự tin thái quá", dẫn đến việc gán xác suất rất cao cho cả những mẫu ngoài phân phối hoàn toàn không liên quan.
- **ODIN [27]:** Cải thiện xác suất softmax cực đại bằng cách sử dụng hiệu chỉnh nhiệt độ và thêm nhiễu đầu vào để gia tăng sự chênh lệch logit giữa dữ liệu trong phân phối và dữ liệu ngoài phân phối.

- **Điểm năng lượng [28]:** Chuyển đổi vectơ logit thành hàm năng lượng thay vì xác suất softmax:

$$E(x) = -T \log \sum_i \exp\left(\frac{f_i(x)}{T}\right) \tag{2.3}$$

trong đó $f_i(x)$ là logit của lớp thứ i và T là hệ số nhiệt độ. Mặc dù điểm năng lượng khai thác độ lớn tuyệt đối của các logit và thường khắc phục một phần hiện tượng quá tự tin của hàm softmax, các phương pháp hậu xử lý dựa trên đầu ra vẫn phụ thuộc mạnh vào biểu diễn và biên quyết định của bộ phân lớp đã huấn luyện. Do mô hình phân lớp đóng buộc mọi đầu vào vào một trong các lớp đã biết, các mẫu ngoài phân phối nằm xa dữ liệu huấn luyện vẫn có thể nhận điểm tin cậy cao.

2.3.2 Các phương pháp dựa trên khoảng cách đặc trưng

Nhận thấy những hạn chế của không gian logit, các nghiên cứu gần đây chuyển hướng sang thực hiện phát hiện dữ liệu ngoài phân phối trực tiếp trên không gian đặc trưng. Việc đánh giá bằng khoảng cách giúp giới hạn không gian rủi ro mở.

- **Khoảng cách euclid và cosine:** Khoảng cách euclid đo độ lệch hình học tuyệt đối $d_E(z, c_k) = \|z - c_k\|_2$ và phù hợp với hình học đẳng hướng khi các chiều có cùng thang đo. Khoảng cách cosine loại bỏ ảnh hưởng của độ lớn vectơ và chỉ so sánh hướng, nhưng không mô hình hóa mức phân tán khác nhau theo từng chiều.

- **Khoảng cách Mahalanobis [23]:** Khoảng cách Mahalanobis bổ sung thông tin hiệp phương sai để chuẩn hóa độ lệch theo cấu trúc phân tán của không gian đặc trưng:

$$d_M(z, \mu_k) = \sqrt{(z - \mu_k)^\top (\Sigma + \lambda_{\text{cov}} I)^{-1} (z - \mu_k)} \tag{2.4}$$

Trong đó, z là vectơ biểu diễn của mẫu kiểm thử, μ_k là trung bình đặc trưng của lớp k, Σ là ma trận hiệp phương sai, I là ma trận đơn vị và λ_{cov} là hệ số điều chuẩn hiệp phương sai. Ký hiệu λ_{cov} chỉ được dùng cho phép điều chuẩn này, khác với ngưỡng cảnh báo dữ liệu ngoài phân phối τ_{alert} ở Chương 3. Độ tin cậy của phép đo phụ thuộc vào chất lượng ước lượng hiệp phương sai và mức phù hợp của giả định phân phối.

- **Khoảng cách láng giềng gần nhất kNN [41]:** Thay vì mô hình hóa không gian đặc trưng bằng một dạng phân phối tham số, phương pháp kNN đánh giá mẫu kiểm thử dựa trên quan hệ lân cận trực tiếp với các biểu diễn của dữ liệu trong phân phối đã quan sát. Với tập tham chiếu $\mathcal{Z}_{\text{ID}} = \{z_i\}_{i=1}^{N}$, tập k láng giềng gần nhất của biểu diễn kiểm thử z được xác định bởi:

$$\mathcal{N}_k(z) = \text{kNN}(z, \mathcal{Z}_{\text{ID}}). \tag{2.5}$$

  Điểm ngoài phân phối có thể được xây dựng từ khoảng cách đến láng giềng gần thứ k hoặc từ thống kê khoảng cách trên tập $\mathcal{N}_k(z)$. Khi mẫu kiểm thử nằm xa vùng lân cận của các biểu diễn trong phân phối, điểm bất thường có xu hướng tăng. Cách tiếp cận phi tham số này không yêu cầu ước lượng trước dạng phân phối của không gian đặc trưng, nhưng phụ thuộc trực tiếp vào chất lượng biểu diễn, kích thước tập tham chiếu, giá trị k và độ đo khoảng cách được sử dụng.

2.3.3 Học biểu diễn phục vụ phát hiện dữ liệu ngoài phân phối

Sự thành công của các phương pháp dựa trên khoảng cách phụ thuộc rất lớn vào chất lượng của không gian đặc trưng. Nếu mô hình được huấn luyện bằng hàm entropy chéo thông thường, dữ liệu của các lớp không được tối ưu để co cụm lại, làm giảm hiệu quả của các phép đo khoảng cách. Để giải quyết vấn đề này, các kỹ thuật học biểu diễn được áp dụng.

- **Học tương phản:** Học biểu diễn bằng cách kéo gần các mẫu tương đồng và đẩy xa các mẫu khác lớp trong không gian đặc trưng [3, 13].

- **Mất mát tâm lớp [47]:** Giảm phương sai nội lớp bằng cách học một tâm biểu diễn cho mỗi lớp và ép các đặc trưng tiến gần tâm tương ứng.

- **Mạng nguyên mẫu [40]:** Phương pháp học theo hệ đo này biểu diễn mỗi lớp bằng một nguyên mẫu c_k:

$$c_k = \frac{1}{|S_k|} \sum_{x_i \in S_k} f_\theta(x_i) \tag{2.6}$$

  Trong quá trình huấn luyện, mạng được tối ưu hóa để cực tiểu hóa khoảng cách giữa đặc trưng của dữ liệu và nguyên mẫu tương ứng của nó.

Đối với các phương pháp dựa trên khoảng cách, chất lượng của không gian biểu diễn đặc biệt quan trọng vì điểm ngoài phân phối được suy ra trực tiếp từ cấu trúc lân cận của các đặc trưng. Một không gian đặc trưng duy trì tốt quan hệ tương đồng giữa các mẫu trong phân phối sẽ tạo cơ sở phù hợp hơn cho việc đánh giá mức độ xa lạ của mẫu mới bằng khoảng cách láng giềng.

2.4 Các phương pháp giải thích và đánh giá độ trung thực

Các phương pháp quy đóng gán mức ảnh hưởng cho từng thành phần đầu vào đối với một đầu ra cụ thể. Tích phân gradient [42] tích lũy gradient dọc theo đường nội suy từ một mốc tham chiếu đến đầu vào, nhờ đó có thể áp dụng cho vùng ảnh, đơn vị biểu diễn cục bộ và từ ngữ. Kết quả phản ánh mức phụ thuộc của đầu ra đối với mốc tham chiếu và lớp đích đã chọn, không mặc nhiên biểu thị quan hệ nhân quả hoặc vị trí tổn thương.

Độ trung thực của lời giải thích thường được kiểm tra bằng can thiệp đầu vào với phép loại bỏ hoặc phép khôi phục [34]. Trong phép loại bỏ, các thành phần được xếp hạng cao được thay dần bằng mốc tham chiếu. Khi đó, xác suất lớp đích giảm nhanh hơn so với thứ tự ngẫu nhiên cung cấp bằng chứng thuận lợi hơn cho thứ tự quy đóng. Phép khôi phục thực hiện theo chiều ngược lại. Kết quả phụ thuộc vào mốc thay thế, tỷ lệ can thiệp và không gian biểu diễn, do đó cần báo cáo giao thức cùng đối chứng ngẫu nhiên thay vì chỉ dựa vào bản đồ nhiệt.

Trọng số chú ý mô tả cách mô-đun phân bổ tương tác trong một lần truyền thuận nhưng không mặc nhiên là lời giải thích trung thực cho quyết định. Mối quan hệ giữa chú ý và giải thích vẫn phụ thuộc vào định nghĩa, mô hình và giao thức đánh giá cụ thể [20, 48]. Ngoài độ trung thực, đánh giá trong y khoa còn cần phân biệt độ ổn định của bản đồ, mức phù hợp với chú thích tổn thương và nhận định của chuyên gia. Khóa luận vì vậy sử dụng tích phân gradient và can thiệp đầu vào để khảo sát nguồn thông tin liên hệ với dự đoán, đồng thời không diễn giải bản đồ quy đóng như bằng chứng định vị hoặc xác nhận lâm sàng.

2.5 Bàn luận

2.5.1 Hạn chế của các nghiên cứu hiện nay

Mặc dù đạt được nhiều kết quả tích cực, các nghiên cứu hiện có vẫn chưa giải quyết đồng thời các yêu cầu của bài toán phân lớp ảnh X-quang xương đa phương thức, các vấn đề chính được tổng hợp như sau:

Thứ nhất, phần lớn mô hình y khoa đa phương thức được phát triển trên X-quang ngực hoặc các bộ dữ liệu lớn với X-quang chiếm phần không lớn. Ảnh X-quang xương có phạm vi giải phẫu, tư thế chụp và kiểu tổn thương đa dạng, trong khi số lượng mẫu giữa các lớp thường mất cân bằng đáng kể. Vì vậy, hiệu quả trên các miền dữ liệu khác chưa thể được chuyển trực tiếp sang bài toán này.

Thứ hai, nhiều nghiên cứu sử dụng báo cáo đọc ảnh hoặc kết luận chẩn đoán làm đầu vào văn bản. Tuy nhiên, các báo cáo này thường được hình thành sau khi bác sĩ hoặc bác sĩ chẩn đoán hình ảnh đã quan sát phim và có thể mô tả trực tiếp vị trí, hình thái hoặc mức độ tổn thương, chẳng hạn đường gãy, di lệch hay bất thường xương. Việc sử dụng các nguồn văn bản này trong giai đoạn suy luận có thể gây rò rỉ nhãn, khiến mô hình chủ yếu học cách ánh xạ một mô tả gần với kết luận chẩn đoán sang nhãn tương ứng. Trong bối cảnh triển khai thực tế, để tạo được báo cáo chi tiết, bác sĩ đã phải nhận diện tổn thương trước, do đó mô hình không còn đóng vai trò hỗ trợ phát hiện mà chủ yếu lặp lại thông tin đã được xác định. Ngược lại, các thông tin lâm sàng có sẵn trước chẩn đoán cuối cùng, như triệu chứng, tiền sử bệnh, vị trí đau hoặc cơ chế chấn thương, vẫn chưa được khai thác đầy đủ, mặc dù đây là những nguồn thông tin quan trọng giúp định hướng quá trình chẩn đoán. Bên cạnh đó, nhiều phương pháp chỉ nối hai vectơ đặc trưng toàn cục, nên chưa mô hình hóa được quan hệ cụ thể giữa các vùng ảnh và nội dung lâm sàng liên quan.

Thứ ba, mặc dù các mô hình nền tảng đạt hiệu quả cao, nhiều nghiên cứu vẫn lựa chọn tinh chỉnh toàn bộ tham số của mô hình. Cách tiếp cận này đòi hỏi chi phí tính toán lớn, đồng thời làm tăng nguy cơ quên tri thức đã được học trong giai đoạn tiền huấn luyện.

Cuối cùng, hầu hết các nghiên cứu chỉ tập trung tối ưu hiệu năng phân lớp mà chưa quan tâm đầy đủ đến khả năng phát hiện dữ liệu ngoài phân phối. Trong môi trường lâm sàng, mô hình có thể gặp các trường hợp bệnh lý hiếm, dữ liệu có chất lượng thấp hoặc các bất thường chưa xuất hiện trong tập huấn luyện. Nếu không có cơ chế phát hiện dữ liệu ngoài phân phối, mô hình vẫn có thể đưa ra dự đoán với độ tin cậy cao mặc dù kết quả không chính xác.

2.5.2 Cơ sở lựa chọn và định hướng phương pháp đề xuất

Từ những hạn chế trên, khóa luận lựa chọn xây dựng hệ thống dựa trên việc kế thừa mô hình BiomedCLIP [51] kết hợp với thông tin lâm sàng để khai thác đồng thời đặc trưng hình ảnh và văn bản. Các lựa chọn thiết kế cụ thể được đưa ra dựa trên phân tích sau:

Về thích nghi mô hình nền tảng: LoRA [17] được sử dụng để thích nghi hai bộ mã hóa của BiomedCLIP với miền ảnh X-quang xương mà không cần cập nhật toàn bộ tham số nền. Lựa chọn này giảm số tham số cần cập nhật và hướng đến tiết kiệm bộ nhớ huấn luyện. Việc giữ cố định tham số nền cũng nhằm hạn chế thay đổi quá mức biểu diễn tiền huấn luyện khi một số lớp có ít mẫu; hiệu quả phân lớp và chi phí thực tế được đánh giá ở Chương 4.

Bên cạnh đó, trong hàm mất mát tương phản InfoNCE nguyên bản [32] được BiomedCLIP sử dụng, các mẫu khác nhau trong cùng lô được xem là các cặp âm, kể cả khi chúng thuộc cùng một lớp hoặc có nội dung lâm sàng tương đồng, gây ra hiện tượng âm tính giả. Do đó, khóa luận sử dụng hàm mất mát khớp ngữ nghĩa kế thừa từ MedCLIP [46] và xây dựng phân phối đích mềm theo nhãn lớp. Mục tiêu này vẫn ưu tiên sự tương hợp của cặp ảnh-văn bản tương ứng, đồng thời giảm ảnh hưởng của các cặp âm tính giả giữa những mẫu có quan hệ ngữ nghĩa gần nhau.

Về khai thác và dung hợp thông tin lâm sàng: Thiết lập phân lớp không mẫu của BiomedCLIP chỉ đối sánh ảnh với các câu nhắc đại diện cho lớp và không sử dụng thông tin riêng của từng người bệnh. Phương pháp đề xuất bổ sung nhánh văn bản để mã hóa những thông tin lâm sàng có sẵn trước kết luận chẩn đoán, chẳng hạn lý do vào viện, triệu chứng và bệnh sử. Báo cáo đọc ảnh, chẩn đoán xác định và nhãn phân lớp không được đưa trực tiếp vào đầu vào nhằm hạn chế rò rỉ nhãn.

Hai bộ mã hóa của BiomedCLIP tạo biểu diễn riêng cho ảnh và văn bản, chưa trực tiếp thực hiện dung hợp ở cấp độ cục bộ. Trong ứng dụng Hỏi-Đáp thị giác y tế (VQA), nhóm tác giả tích hợp BiomedCLIP vào khung METER để trao đổi thông tin giữa hai phương thức. Dựa vào đó, khóa luận đề xuất tích hợp một cơ chế dung hợp. Thay vì chỉ ghép nối hai biểu diễn toàn cục, khóa luận lựa chọn cơ chế chú ý chéo hai chiều, có nguyên lý trao đổi thông tin giữa hai luồng ảnh-văn bản tương tự ViLBERT [29], để đặc trưng ảnh lựa chọn các thông tin lâm sàng liên quan, đồng thời đặc trưng văn bản định hướng mô hình đến các vùng ảnh phù hợp. Thiết kế này cho phép mô hình hóa quan hệ cụ thể giữa dấu hiệu X-quang và ngữ cảnh lâm sàng.

Về phân lớp đa lớp và mất cân bằng dữ liệu: Phương pháp sử dụng hàm mất mát entropy chéo có trọng số nhằm giảm ảnh hưởng của sự chênh lệch số lượng mẫu giữa các lớp.

Về phát hiện dữ liệu ngoài phân phối: Ngoài nhiệm vụ chính, khóa luận bổ sung cơ chế phát hiện dữ liệu ngoài phân phối ở giai đoạn hậu xử lý mà không cần mẫu OOD khi huấn luyện. Phương pháp sử dụng kNN trực tiếp trên đặc trưng ảnh và văn bản từ hai bộ mã hóa BiomedCLIP, với hai ngân hàng tham chiếu $\mathcal{B}I$ và $\mathcal{B}T$ được xây dựng từ tập huấn luyện. Với mẫu mới, hai đặc trưng được đối sánh riêng với ngân hàng tương ứng để tạo tín hiệu khoảng cách lân cận và cảnh báo OOD theo ngưỡng hiệu chỉnh trên tập xác thực; chi tiết cách tính và kết hợp hai tín hiệu được trình bày trong Chương 3.

Về quy trình huấn luyện: Từ các lựa chọn trên, hệ thống được tổ chức thành hai giai đoạn ngoại tuyến:

- **Giai đoạn 1 - Thích nghi và căn chỉnh biểu diễn:** hai bộ mã hóa của BiomedCLIP được thích nghi thông qua LoRA bằng hàm mất mát khớp ngữ nghĩa. Mô-đun dung hợp và đầu phân lớp chưa được tối ưu trong giai đoạn này.
- **Giai đoạn 2 - Dung hợp và phân lớp:** các bộ mã hóa tiếp tục được thích nghi thông qua LoRA, đồng thời mô-đun xử lý đặc trưng cục bộ và cơ chế chú ý chéo hai chiều được tối ưu cho nhiệm vụ phân lớp. Sau khi quá trình thích nghi hoàn tất, đặc trưng ảnh và đặc trưng văn bản của tập huấn luyện được trích xuất từ hai bộ mã hóa để xây dựng hai ngân hàng tham chiếu phục vụ kNN trong giai đoạn suy luận.

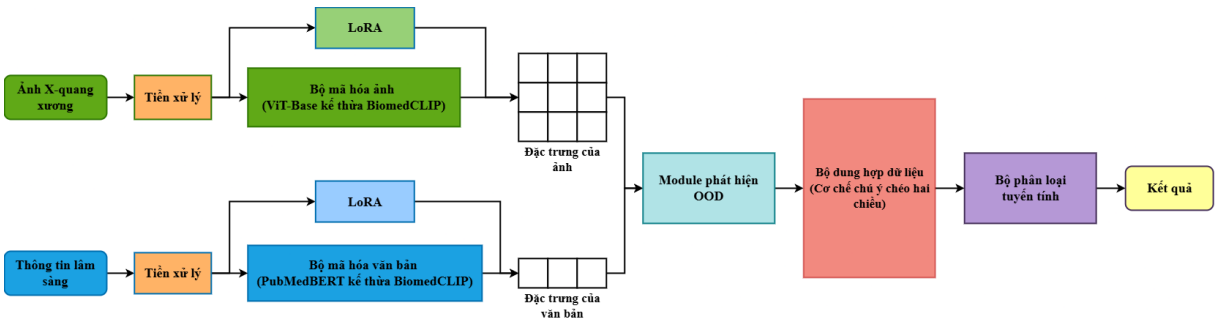
Các định hướng trên được hiện thực hóa trong phương pháp XBone-Net. Kiến trúc chi tiết, quy trình huấn luyện và cơ chế suy luận được trình bày trong Chương 3.

Chương 3

Phương pháp đề xuất

3.1 Tổng quan phương pháp đề xuất

Nhóm nghiên cứu đề xuất XBone-Net cho bài toán phân loại đa lớp ảnh X-quang xương có kết hợp thông tin lâm sàng. Hệ thống được xây dựng theo kiến trúc hai nhánh. Nhánh ảnh khai thác đồng thời cấu trúc giải phẫu toàn cục và các vùng cục bộ giàu chi tiết, trong khi nhánh văn bản biểu diễn bệnh sử và lý do vào viện. Hai nguồn thông tin được ánh xạ vào cùng một không gian đặc trưng, trao đổi ngữ cảnh bằng cơ chế chú ý chéo hai chiều, sau đó được phân lớp.



Hình 3.1: Sơ đồ tổng quan phương pháp XBone-Net đề xuất

Như minh họa trong Hình 3.1, XBone-Net kế thừa bộ mã hóa thị giác và bộ mã hóa văn bản của BiomedCLIP [51]. Các tham số nền được giữ cố định để bảo toàn tri thức y sinh đã học trước, trong khi các ma trận thích nghi hạng thấp LoRA [17] được huấn luyện để thích nghi trên dữ liệu đích. Sau bước mã hóa, mô-đun dung hợp kết hợp đặc trưng toàn cục và cục bộ

của hai phương thức. Biểu diễn tổng hợp cuối cùng được đưa vào mô-đun phân loại. Định danh mô hình nền tảng, kích thước biểu diễn, vị trí chèn LoRA và cấu hình tái lập đầy đủ được trình bày tại Phụ lục B.

Trong khóa luận, biểu diễn toàn cục là một vectơ duy nhất tóm tắt toàn bộ ảnh hoặc toàn bộ chuỗi văn bản; biểu diễn cục bộ là các vectơ tương ứng với từng mảnh ảnh hoặc từng vị trí token, giữ lại thông tin chi tiết theo không gian hoặc ngữ cảnh.

Mỗi mẫu dữ liệu được ký hiệu bởi bộ ba gồm ảnh X-quang, thông tin lâm sàng và nhãn lớp. Tập huấn luyện có dạng:

$$\mathcal{D}_{\text{train}} = \left\{ \left(x_i^{\text{img}}, x_i^{\text{txt}}, y_i \right) \right\}_{i=1}^{N}, \qquad y_i \in \mathcal{Y}. \tag{3.1}$$

Trong đó, $x_i^{\text{img}} \in \mathbb{R}^{H_i \times W_i \times C_{\text{in}}}$ là ảnh X-quang của mẫu thứ i. Các ký hiệu H_i, W_i và C_{in} lần lượt là chiều cao, chiều rộng và số kênh ảnh. Thông tin lâm sàng được ký hiệu $x_i^{\text{txt}} = (w_{i,1}, \ldots, w_{i,L_i})$, với L_i là số đơn vị biểu diễn trước khi cắt hoặc đệm. Nhãn y_i thuộc tập nhãn $\mathcal{Y} = \{y_1, y_2, \ldots, y_K\}$, còn N là số mẫu huấn luyện.

Quá trình xây dựng mô hình được chia thành hai giai đoạn ngoại tuyến. Giai đoạn thứ nhất thích nghi hai nhánh mã hóa và căn chỉnh không gian ảnh-văn bản bằng hàm mất mát khớp ngữ nghĩa. Giai đoạn thứ hai học cơ chế dung hợp và phân loại. Khi suy luận trực tuyến, toàn bộ tham số được cố định, mô hình chỉ thực hiện tính toán truyền thuận cho một ca mới.

Để làm rõ cách hệ thống chuyển đổi từng nguồn dữ liệu thành biểu diễn có thể sử dụng cho quá trình dung hợp, các phần tiếp theo lần lượt trình bày nhánh biểu diễn ảnh, nhánh biểu diễn văn bản và cơ chế thích nghi hai bộ mã hóa trước khi đi đến mô-đun dung hợp và phân lớp.

Với ký hiệu $D_{\text{enc}} = 768$ là chiều ẩn bên trong hai Transformer của BiomedCLIP, còn $D = 512$ là chiều biểu diễn chung sau các lớp chiếu của BiomedCLIP. Mọi đặc trưng được truyền vào mô-đun dung hợp, bộ phân lớp và bộ phát hiện OOD đều nằm trong không gian $D = 512$ chiều.

3.2 Nhánh mã hóa hình ảnh

Mô hình kế thừa bộ mã hóa của BiomedCLIP [51], được xây dựng theo kiến trúc Vision Transformer [7] ViT-B/16. Hình ảnh y tế đầu vào v ban đầu được chuẩn hóa về độ phân giải tiêu chuẩn 224×224 điểm ảnh với 3 kênh màu RGB. Quá trình biến đổi dữ liệu để trích xuất đặc trưng qua bộ mã hóa Vision Transformer ViT-B/16 diễn ra tuần tự như sau:

1. **Phân mảnh ảnh:** Hình ảnh $v \in \mathbb{R}^{224\times224\times3}$ được phân rã thành chuỗi N mảnh ảnh nhỏ không chồng lấn có kích thước cố định là 16×16 điểm ảnh. Số lượng mảnh ảnh thu được, đồng thời là độ dài chuỗi đầu vào của mạng Transformer, được xác định bằng công thức:

$$N = \frac{224 \times 224}{16^2} = 196 \tag{3.2}$$

2. **Nhúng tuyến tính và chèn token** $[CLS]$**:** Các mảnh ảnh được trải phẳng và chiếu tuyến tính qua ma trận trọng số $E \in \mathbb{R}^{(16^2\cdot3)\times D_{\text{enc}}}$ vào không gian ẩn $D_{\text{enc}} = 768$ chiều để tạo thành các vector nhúng. Để tổng hợp thông tin ngữ nghĩa toàn cục của bức ảnh, một token phân loại học được đặc biệt - ký hiệu là $v_{\text{CLS}} \in \mathbb{R}^{1\times D_{\text{enc}}}$ - được chèn vào ngay đầu chuỗi đặc trưng. Đồng thời, một ma trận nhúng vị trí một chiều học được $E_{\text{pos}} \in \mathbb{R}^{(N+1)\times D_{\text{enc}}}$ được cộng trực tiếp vào chuỗi nhằm bảo toàn thông tin cấu trúc không gian:

$$z_0 = [v_{\text{CLS}}; v_p^1 E; v_p^2 E; \ldots; v_p^N E] + E_{\text{pos}} \tag{3.3}$$

3. **Xử lý qua Transformer Encoder:** Chuỗi biểu diễn tích hợp z_0 được truyền qua chồng gồm $L = 12$ tầng Transformer Encoder. Tại mỗi tầng, cơ chế tự chú ý đa đầu và mạng truyền thẳng liên tục cập nhật trạng thái của toàn bộ chuỗi thông qua chuẩn hóa trước và kết nối thặng dư, cộng trực tiếp đầu vào của một khối với đầu ra sau biến đổi, giúp bảo toàn thông tin ban đầu và hỗ trợ quá trình tối ưu trong mạng sâu.

4. **Trích xuất và chiếu chuỗi đặc trưng:** Tại tầng mã hóa cuối cùng ($L = 12$), toàn bộ chuỗi được chuẩn hóa và chiếu từ $D_{\text{enc}} = 768$ xuống không gian chung $D = 512$ chiều bằng ma trận $W_v^{\text{proj}} \in \mathbb{R}^{D_{\text{enc}} \times D}$:

$$y_v = \text{LN}(z_L) W_v^{\text{proj}} \in \mathbb{R}^{(N+1) \times D}. \tag{3.4}$$

Dòng đầu $y_v^0 \in \mathbb{R}^D$ là biểu diễn ảnh toàn cục tại vị trí $[CLS]$, còn $y_v^{1:} \in \mathbb{R}^{N \times D}$ gồm $N = 196$ biểu diễn mảnh ảnh cục bộ. Hai phần này đều được giữ lại cho mô-đun dung hợp.

3.3 Nhánh biểu diễn văn bản

Bổ sung cho các bằng chứng hình thái được trích xuất từ ảnh X-quang, nhánh biểu diễn văn bản có nhiệm vụ mã hóa thông tin lâm sàng t thành các đặc trưng ngữ cảnh theo từng đơn vị biểu diễn và một vectơ đại diện cho toàn bộ chuỗi. Trong khóa luận, nhánh này được kế thừa từ bộ mã hóa văn bản của BiomedCLIP [51], với thành phần chính là PubMedBERT [11]. Khác với các mô hình ngôn ngữ được tiền huấn luyện trên văn bản tổng quát, PubMedBERT được tiền huấn luyện từ đầu trên kho ngữ liệu y sinh và sử dụng bộ từ vựng được xây dựng trực tiếp từ miền dữ liệu này. Nhờ đó, mô hình phù hợp hơn với các thuật ngữ chuyên ngành xuất hiện trong thông tin lâm sàng. Chuỗi văn bản mô tả y khoa đầu vào t được chuyển đổi thành vector biểu diễn ngữ nghĩa thông qua các bước biến đổi tuần tự như sau:

1. **Tách văn bản thành các đơn vị mã hóa (token):** Bộ tách từ của PubMedBERT chuyển văn bản thô t thành chuỗi token. Một token có thể là một từ, một mảnh từ (subword), dấu câu hoặc ký hiệu đặc biệt; vì vậy số token không đồng nhất với số từ trong câu. Các thuật ngữ "từ tố" và "đơn vị biểu diễn văn bản" dưới đây chỉ các token này. Tổng độ dài chuỗi sau khi thêm token đặc biệt, cắt và đệm được cố định ở $T = 256$ vị trí.

2. **Khởi tạo chuỗi và chèn các token đặc biệt** $[CLS]$ **và** $[SEP]$**:** Để cấu trúc hóa chuỗi đầu vào theo chuẩn BERT, một token phân loại đặc biệt ký hiệu là t_{CLS} được chèn vào đầu chuỗi, và một token phân tách đặc biệt ký hiệu là t_{SEP} được bổ sung ở cuối chuỗi để phân định ranh giới ngữ cảnh:

$$t_{\text{seq}} = [t_{\text{CLS}}, t_1, t_2, \ldots, t_\ell, t_{\text{SEP}}, t_{\text{PAD}}, \ldots], \qquad T = 256, \tag{3.5}$$

trong đó ℓ là số từ tố nội dung còn lại sau khi cắt.

Vector nhúng ban đầu g_0 sau đó được thiết lập bằng cách cộng theo từng phần tử giữa các vector nhúng từ tố, nhúng phân đoạn và nhúng vị trí trong không gian ẩn $D_{\text{enc}} = 768$ chiều:

$$g_0 = \text{Embedding}(t_{\text{seq}}) \tag{3.6}$$

3. **Xử lý qua Transformer Encoder:** Chuỗi biểu diễn tích hợp g_0 được truyền qua chồng gồm $L = 12$ tầng Transformer Encoder hai chiều. Tại mỗi tầng, cơ chế tự chú ý đa đầu và mạng truyền thẳng liên tục cập nhật trạng thái ngữ cảnh của toàn bộ chuỗi thông qua chuẩn hóa trước và kết nối thặng dư.

4. **Trích xuất và chiếu chuỗi đặc trưng:** Tại tầng mã hóa cuối cùng ($L = 12$), toàn bộ chuỗi được chiếu từ $D_{\text{enc}} = 768$ xuống không gian chung $D = 512$ chiều bằng ma trận $W_t^{\text{proj}} \in \mathbb{R}^{D_{\text{enc}} \times D}$:

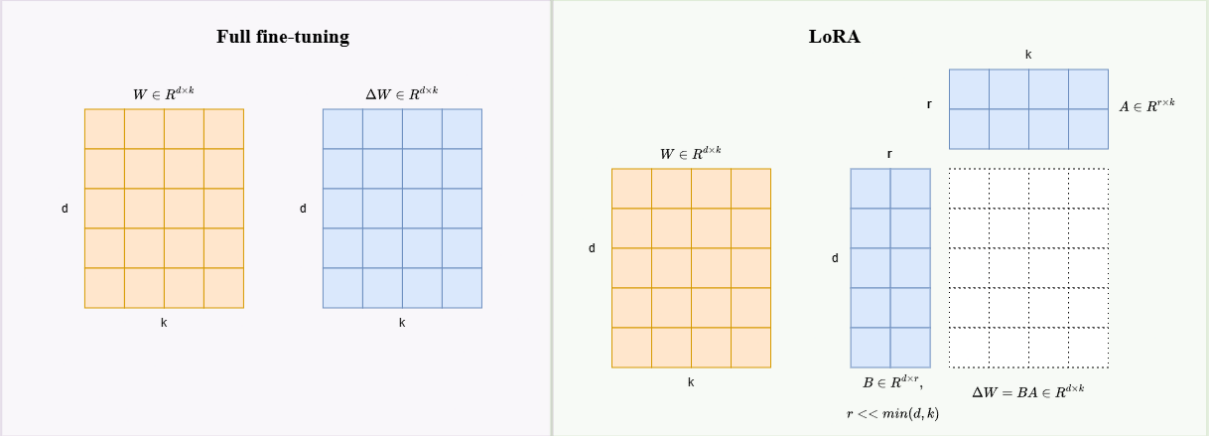
$$y_t = g_L W_t^{\text{proj}} \in \mathbb{R}^{T \times D}. \tag{3.7}$$

Dòng đầu $y_t^0 \in \mathbb{R}^D$ là biểu diễn văn bản toàn cục tại vị trí $[CLS]$. Các dòng còn lại tạo ngữ cảnh cục bộ theo từng vị trí từ tố.

Kết thúc hai nhánh mã hóa, mỗi mẫu được biểu diễn bởi chuỗi đặc trưng ảnh $\boldsymbol{V}_i$, ma trận đặc trưng văn bản $\boldsymbol{H}_i^T$ và các vectơ toàn cục tương ứng. Mặc dù các biểu diễn này kế thừa tri thức y sinh từ BiomedCLIP, sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu X-quang xương đích vẫn đòi hỏi hai bộ mã hóa được thích nghi trước khi thực hiện dung hợp.

3.4 Thích nghi hạng thấp bộ mã hóa bằng LoRA

Trong quá trình thích nghi các mô hình lớn như PubMedBERT hay ViT trong BiomedCLIP cho các tác vụ y sinh hạ nguồn, phương pháp tinh chỉnh toàn bộ tham số đòi hỏi chi phí tính toán và bộ nhớ lưu trữ cực kỳ lớn. Để giải quyết rào cản này, phương pháp thích nghi hạng thấp LoRA [17] được áp dụng. Phương pháp này hoạt động dựa trên giả thuyết rằng sự thay đổi trọng số của các lớp liên kết dày đặc trong quá trình học thực chất nằm trong một không gian có "hạng nội tại" rất thấp.



Hình 3.2: Phân rã hạng r với ma trận cập nhật trọng số ΔW

Quy trình toán học và dòng chảy dữ liệu của cơ chế LoRA được mô tả cụ thể qua các bước sau:

1. **Đóng băng trọng số nền và thiết lập nhánh song song:** Gọi $W_0 \in \mathbb{R}^{d \times k}$ là ma trận trọng số tiền huấn luyện của một lớp tuyến tính bất kỳ trong mạng Transformer. Trong suốt quá trình huấn luyện thích nghi, ma trận W_0 này hoàn toàn bị đóng băng và không nhận bất kỳ cập nhật gradient nào. Sự thay đổi trọng số tích lũy ΔW được biểu diễn gián tiếp thông qua tích của hai ma trận phân rã hạng thấp được đặt song song với lớp gốc:

$$W = W_0 + \Delta W = W_0 + BA \tag{3.8}$$

Trong đó, $B \in \mathbb{R}^{d \times r}$ và $A \in \mathbb{R}^{r \times k}$ là hai ma trận chứa các tham số học được, với hạng $r \ll \min(d, k)$ là một siêu tham số đại diện cho hạng của LoRA.

2. **Khởi tạo tham số ban đầu:** Để đảm bảo ma trận cập nhật ΔW bằng 0 tại thời điểm bắt đầu huấn luyện và tránh gây nhiễu cho tri thức tiền huấn luyện gốc, các ma trận phân rã được khởi tạo như sau:

   - Ma trận A được khởi tạo ngẫu nhiên theo phân phối Gaussian: $A \sim \mathcal{N}(0, \sigma^2)$.
   - Ma trận B được khởi tạo bằng 0.

   Phép nhân ma trận ban đầu mang lại $\Delta W = B \cdot A = 0$, giúp bảo toàn nguyên vẹn đầu ra của mô hình gốc ở vạch xuất phát.

3. **Lan truyền tiến tích hợp tham số tỷ lệ:** Với một vector đầu vào x, phép toán lan truyền tiến qua lớp tuyến tính được điều chỉnh bởi LoRA sẽ cộng trực tiếp kết quả của hai nhánh:

$$h = W_0 x + \frac{\alpha}{r} BAx \tag{3.9}$$

   Trong đó, α là một hằng số tỷ lệ cố định, hạn chế sự thay dổi quá mạnh của nhánh thích nghi khi thay đổi giá trị của hạng r.

4. **Tích hợp vào bộ mã hóa:** Trong cấu hình XBone-Net, LoRA không chỉ được gắn vào các phép chiếu Query, Key và Value mà còn được gắn vào phép chiếu đầu ra chú ý và hai lớp tuyến tính của MLP trong mỗi khối Transformer. ViT-B/16 cài đặt ba phép chiếu Query-Key-Value bằng một ma trận gộp W_{QKV}, trong khi PubMedBERT sử dụng ba ma trận riêng W_Q, W_K và W_V. Bảng 3.1 liệt kê đầy đủ các ma trận đích theo đúng cấu hình mã nguồn.

   Trong cơ chế chú ý, Query biểu diễn thông tin cần truy vấn, Key biểu diễn thông tin dùng để tính mức liên quan, còn Value chứa nội dung được tổng hợp theo các trọng số chú ý.

Bộ mã hóa	Mô-đun trong mã nguồn	Ma trận được gắn LoRA	Vai trò
ViT-B/16	`attn.qkv`	$W_{QKV}^{(v)} \in \mathbb{R}^{3D_{\text{enc}} \times D_{\text{enc}}}$	Chiếu đồng thời Query, Key và Value.
ViT-B/16	`attn.proj`	$W_{O}^{(v)} \in \mathbb{R}^{D_{\text{enc}} \times D_{\text{enc}}}$	Chiếu đầu ra của chú ý đa đầu.
ViT-B/16	`mlp.fc1`, `mlp.fc2`	$W_{1}^{(v)} \in \mathbb{R}^{4D_{\text{enc}} \times D_{\text{enc}}}$, $W_{2}^{(v)} \in \mathbb{R}^{D_{\text{enc}} \times 4D_{\text{enc}}}$	Mở rộng rồi thu hẹp chiều trong MLP.
PubMedBERT	`query`, `key`, `value`	$W_{Q}^{(t)}, W_{K}^{(t)}, W_{V}^{(t)} \in \mathbb{R}^{D_{\text{enc}} \times D_{\text{enc}}}$	Ba phép chiếu Query, Key và Value riêng biệt.
PubMedBERT	`attention.output.dense`	$W_{O}^{(t)} \in \mathbb{R}^{D_{\text{enc}} \times D_{\text{enc}}}$	Chiếu đầu ra của chú ý đa đầu.
PubMedBERT	`intermediate.dense`, `output.dense`	$W_{1}^{(t)} \in \mathbb{R}^{4D_{\text{enc}} \times D_{\text{enc}}}$, $W_{2}^{(t)} \in \mathbb{R}^{D_{\text{enc}} \times 4D_{\text{enc}}}$	Mở rộng rồi thu hẹp chiều trong mạng truyền thẳng.

Bảng 3.1: Các ma trận được gắn LoRA trong hai bộ mã hóa của XBone-Net

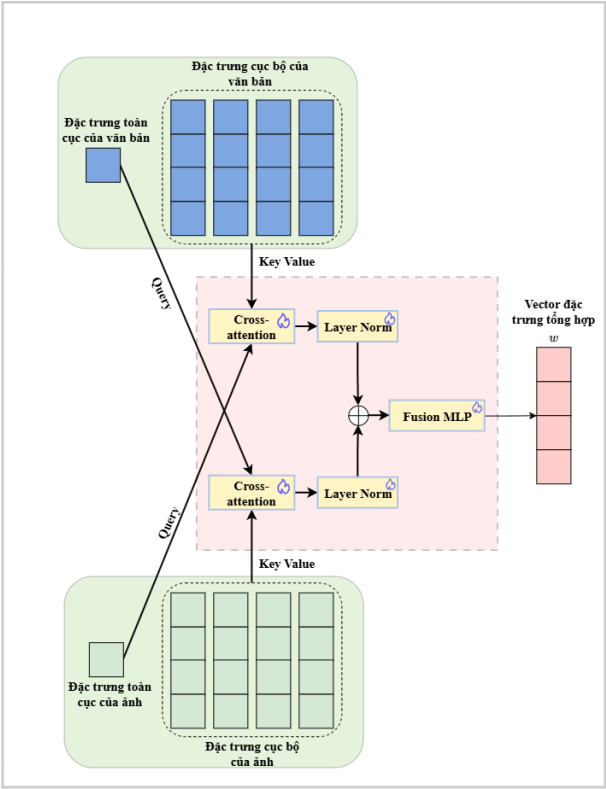
3.5 Mô-đun dung hợp đa phương thức với chú ý chéo hai chiều

Sau khi đi qua các bộ mã hóa chuyên biệt, ta thu được các ma trận biểu diễn đặc trưng đầy đủ chứa cả thông tin toàn cục lẫn cục bộ của hai nhánh:

- Ma trận đặc trưng hình ảnh $y_v \in \mathbb{R}^{197 \times D}$, trong đó dòng đầu tiên $y_v^0 \in \mathbb{R}^D$ đại diện cho token phân loại $[CLS]$, và phần còn lại $y_v^{1:} \in \mathbb{R}^{196 \times D}$ đại diện cho đặc trưng cục bộ của 196 mảnh ảnh.

- Ma trận đặc trưng văn bản $y_t \in \mathbb{R}^{T \times D}$ với $T = 256$, trong đó dòng đầu tiên $y_t^0 \in \mathbb{R}^D$ đại diện cho token đặc biệt $[CLS]$, còn $y_t^{1:} \in \mathbb{R}^{(T-1) \times D}$ chứa các vị trí ngữ cảnh còn lại; mặt nạ chú ý loại các vị trí đệm. Trong cả hai nhánh, $D = 512$.

Quy trình dung hợp thông tin sử dụng cơ chế chú ý chéo hai chiều, được xây dựng trên phép chú ý [44] và cơ chế trao đổi thông tin hai chiều giữa hai luồng ảnh-văn bản tương tự ViLBERT [29]. Quy trình này được trực quan hóa ở hình 3.3 và thực hiện tuần tự như sau:



Hình 3.3: Mô-đun dung hợp bằng chú ý chéo hai chiều

1. **Chú ý chéo từ hình ảnh sang văn bản:** Dùng đặc trưng hình ảnh toàn cục y_v^0 làm truy vấn để tìm kiếm và trích xuất ngữ cảnh liên quan từ đặc trưng văn bản cục bộ $y_t^{1:}$ đóng vai trò là khóa và giá trị:

$$Q_v = y_v^0 W_q^{(v)}, \quad K_t = y_t^{1:} W_k^{(t)}, \quad V_t = y_t^{1:} W_v^{(t)} \tag{3.10}$$

$$A_{v\to t} = \text{softmax}\left(\frac{Q_v (K_t)^T}{\sqrt{d_k}}\right) \tag{3.11}$$

$$f_{v\to t} = A_{v\to t} V_t \in \mathbb{R}^D \tag{3.12}$$

Trong đó, $W_q^{(v)}, W_k^{(t)}, W_v^{(t)} \in \mathbb{R}^{D\times d_k}$ là các ma trận chiếu tuyến tính học được, và d_k là số chiều của không gian chú ý. $A_{v\to t}$ là biểu thị phân phối trọng số thể hiện mức độ tương quan ngữ nghĩa giữa truy vấn thị giác toàn cục của bức ảnh và từng từ tố mô tả bệnh lý cục bộ đóng vai trò khóa. Giá trị của từng phần tử chỉ ra mức độ đóng góp ngữ nghĩa của từ tố tương ứng vào việc giải thích hoặc bổ nghĩa cho thực thể trực quan xuất hiện trong ảnh y tế. Vector $f_{v\to t}$ là biểu diễn văn bản đã được căn chỉnh theo ngữ cảnh hình ảnh.

2. **Chú ý chéo từ văn bản sang hình ảnh:** Tương tự, đặc trưng văn bản toàn cục y_t^0 được sử dụng làm Query để rà quét và tập trung vào các vùng đặc trưng không gian trên chuỗi mảnh ảnh cục bộ $y_v^{1:}$:

$$Q_t = y_t^0 W_q^{(t)}, \quad K_v = y_v^{1:} W_k^{(v)}, \quad V_v = y_v^{1:} W_v^{(v)} \tag{3.13}$$

$$A_{t \to v} = \text{softmax}\left(\frac{Q_t (K_v)^T}{\sqrt{d_k}}\right) \tag{3.14}$$

$$f_{t \to v} = A_{t \to v} V_v \in \mathbb{R}^D \tag{3.15}$$

Vector $f_{t \to v}$ đại diện cho đặc trưng hình ảnh đã được căn chỉnh theo ngữ cảnh của câu mô tả.

3. **Chuẩn hóa và ghép nối đặc trưng:** Hai đặc trưng sau khi chú ý chéo được tích hợp lại với các vector toàn cục gốc tương ứng bằng kết nối thặng dư, đi qua lớp chuẩn hóa tầng ký hiệu LN rồi tiến hành ghép nối để tạo thành vector dung hợp sơ bộ:

$$h_v = \text{LN}(f_{v \to t} + y_v^0) \in \mathbb{R}^D \tag{3.16}$$

$$h_t = \text{LN}(f_{t \to v} + y_t^0) \in \mathbb{R}^D \tag{3.17}$$

$$h_{\text{concat}} = [h_v; h_t] \in \mathbb{R}^{2D} \tag{3.18}$$

4. **Dung hợp phi tuyến qua MLP để tạo vector tổng hợp cuối cùng:** Cuối cùng, vector ghép nối h_{concat} được đưa qua mạng truyền thẳng MLP để thực hiện tương tác phi tuyến tính sâu giữa hai miền dữ liệu, ánh xạ đầu ra về một vector đặc trưng dung hợp tổng hợp duy nhất y_{fusion} phục vụ tác vụ hạ nguồn:

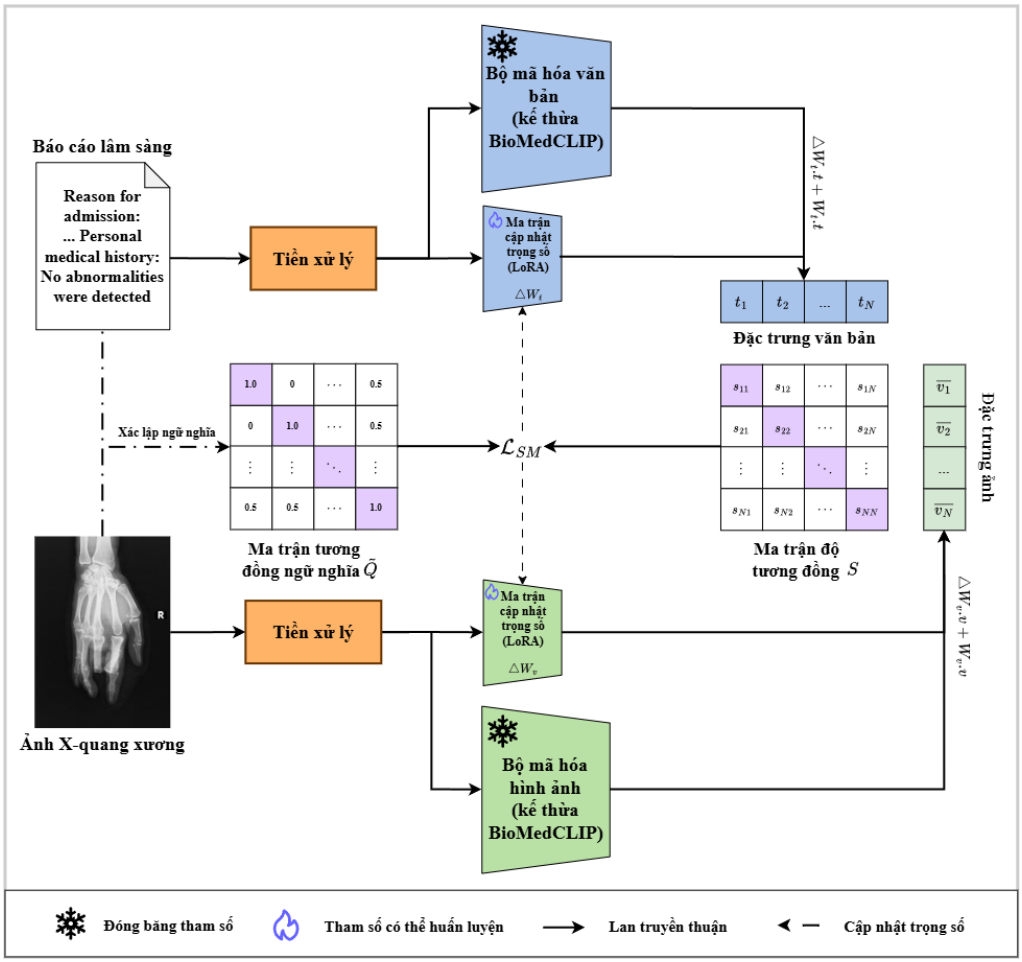
$$y_{\text{fusion}} = \text{MLP}(h_{\text{concat}}) \in \mathbb{R}^D \tag{3.19}$$

Kết quả của quá trình trên là vectơ đa phương thức $\boldsymbol{y_{fusion}}$, chứa đặc trưng ảnh và văn bản tổng hợp trong cùng một biểu diễn. Vectơ này là đầu vào trực tiếp của bộ phân lớp, do đó quyết định cuối cùng không còn dựa trên từng phương thức riêng lẻ mà dựa trên quan hệ giữa chúng.

3.6 Huấn luyện hai giai đoạn trong quá trình ngoại tuyến

Quy trình ngoại tuyến lần lượt giải quyết hai yêu cầu của hệ thống. Giai đoạn thứ nhất điều chỉnh các bộ mã hóa để ảnh X-quang và thông tin lâm sàng tương ứng được biểu diễn phù hợp hơn trong miền dữ liệu đích. Trên nền không gian đã thích nghi, giai đoạn thứ hai học tương tác liên phương thức và tối ưu quyết định phân lớp có xét đến sự mất cân bằng giữa các lớp.

3.6.1 Giai đoạn 1: Thích nghi miền bằng khớp ngữ nghĩa



Hình 3.4: Giai đoạn thích nghi miền bằng khớp ngữ nghĩa ảnh-văn bản

Giai đoạn thứ nhất được minh họa trong Hình 3.4. Trong giai đoạn này, mô hình thực hiện quá trình thích nghi miền nhằm chuyển đổi không gian biểu diễn tổng quát của bộ mã hóa tiền huấn luyện sang miền dữ liệu y khoa chuyên biệt. Để tối ưu hóa hiệu quả và bảo toàn tri thức nền tảng, các tham số gốc của bộ mã hóa hình ảnh và bộ mã hóa văn bản đều được đóng băng, và quá trình huấn luyện thích nghi được thực hiện thông qua cơ chế thích nghi hạng thấp LoRA.

Trọng tâm của giai đoạn này là hạn chế cặp âm giả trong học tương phản, xảy ra khi ảnh và văn bản của các mẫu khác nhau nhưng cùng lớp bệnh bị xem là cặp âm hoàn toàn. Giai đoạn này sử dụng hàm mất mát khớp ngữ nghĩa ký hiệu SML, kế thừa ý tưởng giám sát tương phản bằng nhãn từ MedCLIP [46], kết hợp với ma trận đích mềm được thiết kế cho XBone-Net để dẫn đường cho mô hình.

Ma trận đích mềm là ma trận $B \times B$, trong đó mỗi phần tử biểu diễn mức độ tương đồng ngữ nghĩa mục tiêu giữa ảnh của mẫu i và văn bản của mẫu j. Khác với nhãn nhị phân chỉ phân biệt cặp đúng/sai, giá trị mềm cho phép biểu diễn các mức tương đồng trung gian giữa các mẫu có quan hệ bệnh lý hoặc lâm sàng gần nhau.

Quy trình trong một lô huấn luyện kích thước B được mô tả như sau:

1. **Xây dựng ma trận đích mềm:** Với mỗi cặp thực thể i (hình ảnh) và j (văn bản) trong lô, xây dựng một ma trận đích tương đồng mềm $P \in \mathbb{R}^{B \times B}$. Giá trị phân phối mục tiêu P_{ij} đại diện cho mối tương quan y khoa giữa hai mẫu, được định nghĩa theo quy tắc sau:

$$P_{ij} = \begin{cases} 1, & \text{nếu } i = j \quad \text{(cặp khớp)} \\ 0{,}5, & \text{nếu class}(i) = \text{class}(j) \text{ và } i \neq j \quad \text{(cùng lớp khác mẫu)} \\ 0, & \text{nếu class}(i) \neq \text{class}(j) \quad \text{(khác lớp bệnh lý)} \end{cases} \tag{3.20}$$

   Trọng số 0,5 áp dụng cho hai mẫu khác nhau có cùng nhãn lớp, còn cặp ảnh-văn bản của chính một mẫu có trọng số 1. Cấu hình không kiểm tra trực tiếp cơ chế tổn thương hoặc độ tương đồng bệnh sử để gán trọng số. Như vậy, đích mềm ưu tiên cặp khớp, đồng thời vẫn phân bổ khối lượng xác suất cho các cặp cùng lớp khác mẫu.

2. **Chuẩn hóa phân phối mục tiêu:** Để biến đổi ma trận trọng số P thành phân phối xác suất hợp lệ, ta chia mỗi phần tử cho tổng trọng số của dòng hoặc cột tương ứng, không áp dụng Softmax lên đích mềm:

$$y_{ij}^{v \to t} = \frac{P_{ij}}{\sum_{k=1}^{B} P_{ik}} \tag{3.21}$$

$$y_{ji}^{t \to v} = \frac{P_{ij}}{\sum_{k=1}^{B} P_{kj}} \tag{3.22}$$

Mã thực thi chuẩn hóa các dòng của P trước, sau đó chuyển vị và chuẩn hóa lại các dòng cho chiều ngược. Với ma trận đối xứng được xây dựng từ nhãn lớp ở trên, các dòng thuộc cùng một lớp có tổng trọng số bằng nhau, nên thao tác này tương đương công thức chuẩn hóa cột đã nêu. Các phần tử bằng 0 vẫn giữ xác suất đích bằng 0.

3. **Tính toán tương đồng dự đoán:** Gọi I_i và T_j lần lượt là các vector nhúng chuẩn hóa L_2 của hình ảnh thứ i và văn bản thứ j trong không gian chung. Lượng logits tương đồng dự đoán $\hat{s}_{ij}$ được tính toán bằng:

$$\hat{s}_{ij} = \frac{I_i \cdot T_j}{\tau} \tag{3.23}$$

Trong đó, τ là tham số nhiệt độ học được. Phân phối xác suất dự đoán tương ứng được xác định bởi:

$$\hat{y}_{ij}^{v \to t} = \frac{\exp(\hat{s}_{ij})}{\sum_{k=1}^{B} \exp(\hat{s}_{ik})}, \quad \hat{y}_{ji}^{t \to v} = \frac{\exp(\hat{s}_{ij})}{\sum_{k=1}^{B} \exp(\hat{s}_{kj})} \tag{3.24}$$

4. **Hàm mất mát khớp ngữ nghĩa:** Hàm mất mát SML được định nghĩa là trung bình cộng của sai số entropy chéo hai chiều đối xứng giữa phân phối đích mềm và phân phối dự đoán của mô hình thích nghi LoRA:

$$\mathcal{L}_{\text{SML}} = \frac{\mathcal{L}_{v \to t} + \mathcal{L}_{t \to v}}{2} \tag{3.25}$$

Trong đó:

$$\mathcal{L}_{v \to t} = -\frac{1}{B} \sum_{i=1}^{B} \sum_{j=1}^{B} y_{ij}^{v \to t} \log \hat{y}_{ij}^{v \to t} \tag{3.26}$$

$$\mathcal{L}_{t\to v} = -\frac{1}{B}\sum_{j=1}^{B}\sum_{i=1}^{B} y_{ji}^{t\to v} \log \hat{y}_{ji}^{t\to v} \tag{3.27}$$

Sau giai đoạn này, hai bộ mã hóa đã được điều chỉnh để tạo ra không gian ảnh-văn bản phù hợp hơn với dữ liệu X-quang xương. Tuy nhiên, các đặc trưng của cặp ảnh-văn bản mới chỉ được căn chỉnh gần nhau hơn ở mức biểu diễn trong không gian nhúng và chưa được tối ưu trực tiếp cho quyết định phân lớp đa lớp. Vì vậy, giai đoạn thứ hai tiếp tục sử dụng các bộ mã hóa đã thích nghi, đồng thời đưa mô-đun dung hợp và mô-đun phân loại vào quá trình huấn luyện có giám sát.

3.6.2 Giai đoạn 2: học dung hợp và phân lớp

Hình 3.5 minh họa quy trình học dung hợp và phân lớp trong giai đoạn này. Trong giai đoạn thứ hai, mục tiêu cốt lõi của mạng là tiến hành dung hợp sâu sắc các thông tin đa phương thức từ hai nhánh ảnh-chữ, sau đó đưa qua một bộ phân loại tuyến tính đơn giản để dự đoán trực tiếp các lớp bệnh lý hạ nguồn.

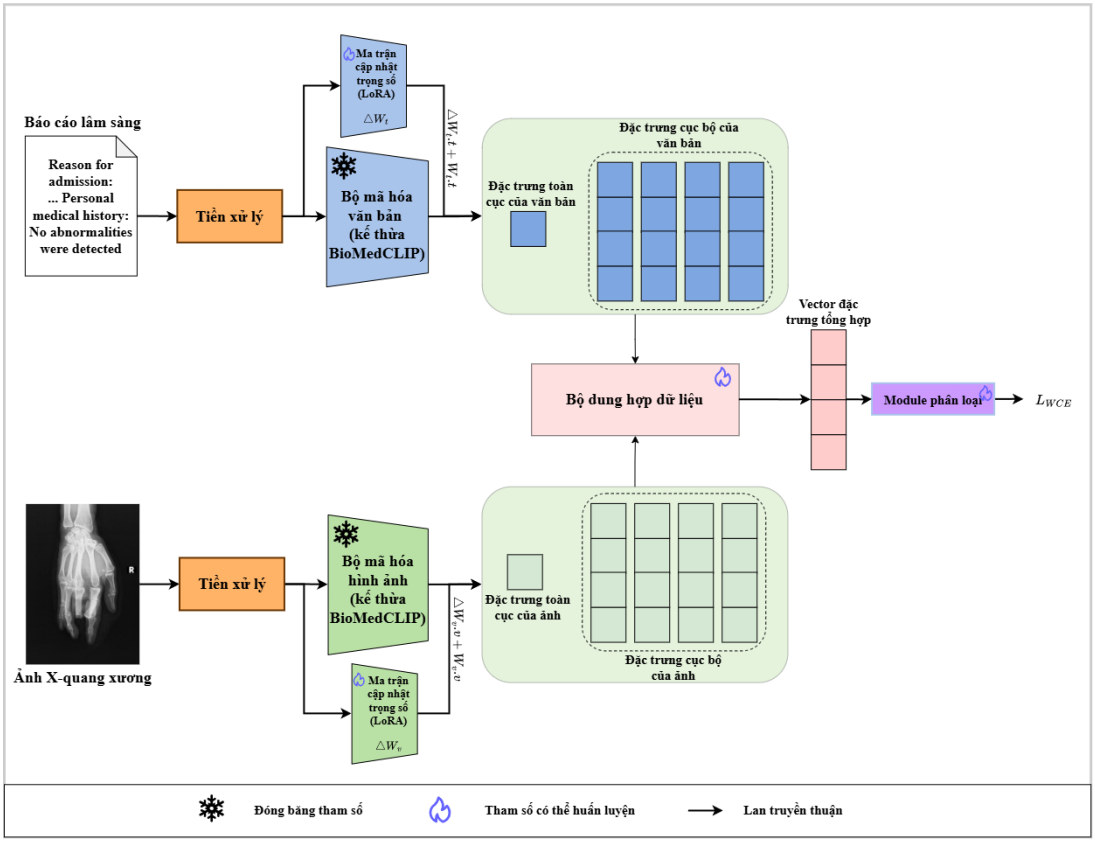
Quy trình lan truyền tiến, tính toán hàm mất mát và cập nhật trọng số trong giai đoạn này được thực hiện tuần tự theo các bước sau:

1. **Khởi tạo đầu vào bộ phân loại:** Gọi $\mathbf{z} = y_{\text{fusion}} \in \mathbb{R}^D$ là vector đặc trưng dung hợp tổng hợp thu được từ đầu ra của mô-đun chú ý chéo hai chiều, với $D = 512$. Bộ phân loại hạ nguồn được thiết lập để dự đoán C lớp bệnh lý y khoa mục tiêu.

2. **Phép chiếu tuyến tính và tính xác suất dự đoán:** Vector đặc trưng dung hợp $\mathbf{z}$ được đưa trực tiếp qua một lớp tuyến tính đơn giản để tính toán ma trận logits điểm số $\mathbf{s} \in \mathbb{R}^C$:

$$\mathbf{s} = W_{\text{clf}}\mathbf{z} + b_{\text{clf}} \tag{3.28}$$

   Trong đó, $W_{\text{clf}} \in \mathbb{R}^{C\times D}$ là ma trận trọng số huấn luyện được của bộ phân loại, và $b_{\text{clf}} \in \mathbb{R}^C$ là vector độ chệch.



Hình 3.5: Giai đoạn học dung hợp và phân lớp

Điểm logit s_c của từng lớp $c \in \{1, \ldots, C\}$ sau đó được đưa qua hàm Softmax để tạo xác suất dự đoán $\hat{p}_c \in [0, 1]$:

$$\hat{p}_c = \text{Softmax}(s_c) = \frac{\exp(s_c)}{\sum_{j=1}^{C} \exp(s_j)} \tag{3.29}$$

3. **Hàm mất mát entropy chéo có trọng số và làm trơn nhãn:** Cấu hình XBone-Net sử dụng đồng thời trọng số lớp và làm trơn nhãn. Với lô có B mẫu, nhãn lớp của mẫu i là y_i, hệ số làm trơn nhãn là ε_{ls} và $\mathbf{1}[\cdot]$ là hàm chỉ báo, phân phối đích được xác định bởi:

$$q_{ic} = (1 - \varepsilon_{\text{ls}})\, \mathbf{1}[c = y_i] + \frac{\varepsilon_{\text{ls}}}{C}. \tag{3.30}$$

Như vậy, xác suất đích không tập trung hoàn toàn vào lớp đúng mà được trộn với phân phối đều trên C lớp.

Gọi $\mathcal{C}$ là tập tất cả các lớp và n_c là tổng số mẫu thuộc lớp c trong toàn bộ tập huấn luyện. Trọng số lớp được xác định từ số lượng mẫu hiệu dụng theo ba bước:

$$E_c = \frac{1-\beta^{n_c}}{1-\beta}, \qquad u_c = \frac{1}{E_c} = \frac{1-\beta}{1-\beta^{n_c}}, \qquad c \in \mathcal{C}, \tag{3.31}$$

$$\bar{w}_c = \frac{|\mathcal{C}| u_c}{\sum_{j \in \mathcal{C}} u_j}, \qquad w_c = \min(\bar{w}_c, w_{\max})\,. \tag{3.32}$$

Trong đó, E_c là số lượng mẫu hiệu dụng, u_c là trọng số thô, $\bar{w}_c$ là trọng số sau khi chuẩn hóa để có giá trị trung bình bằng 1 trên toàn bộ các lớp, còn $w_{\max}$ giới hạn ảnh hưởng của các lớp quá hiếm. Lớp có ít mẫu nhận trọng số lớn hơn, nhưng mức tăng dần bão hòa theo n_c thay vì tỷ lệ nghịch trực tiếp với tần suất.

Số lượng mẫu hiệu dụng mô hình hóa việc các mẫu bổ sung trong cùng một lớp mang lượng thông tin mới giảm dần khi số mẫu tăng, nhờ đó trọng số lớp không tăng quá cực đoan đối với các lớp hiếm như khi dùng nghịch đảo tần suất trực tiếp.

Hàm mất mát thực tế của pha 2 là:

$$\mathcal{L}_{\text{WLSCE}} = -\frac{1}{Z_{\mathcal{B}}} \sum_{i=1}^{B} \sum_{c=1}^{C} w_c q_{ic} \log(\hat{p}_{ic})\,, \qquad Z_{\mathcal{B}} = \sum_{i=1}^{B} w_{y_i}. \tag{3.33}$$

Cấu hình XBone-Net sử dụng $\beta = 0{,}999$ theo phương pháp số lượng mẫu hiệu dụng [4], $w_{\max} = 5{,}0$ và $\varepsilon_{\text{ls}} = 0{,}1$ trên cả CTCH và BTXRD. Công thức 3.33 phản ánh trực tiếp phép tính `CrossEntropyLoss` có trọng số lớp, làm trơn nhãn và phép lấy trung bình mặc định trong mã huấn luyện.

3.7 Phát hiện dữ liệu lệch phân phối bằng thuật toán k-NN đa phương thức

Sau hai giai đoạn huấn luyện, hệ thống sử dụng các biểu diễn đơn phương thức để xây dựng điểm bất thường đa phương thức s_{OOD} theo phương pháp hậu xử lý dựa trên k-NN [41]. Với cặp đầu vào (v, t) đã được định nghĩa ở các phần trên, $y_v^0 \in \mathbb{R}^D$ và $y_t^0 \in \mathbb{R}^D$ lần lượt là các vectơ toàn cục ở vị trí [CLS] của nhánh ảnh và nhánh văn bản. Bộ phát hiện OOD không cập nhật tham số của XBone-Net và không sử dụng mẫu OOD để xây dựng ngân hàng tham chiếu hoặc chọn ngưỡng.

Việc dùng hai biểu diễn đơn phương thức thay cho vectơ dung hợp y_{fusion} cho phép đo độ lệch riêng trên từng nguồn dữ liệu. Đây là một lựa chọn thiết kế cần được đánh giá thực nghiệm; không giả định rằng phép dung hợp luôn làm mất thông tin cần thiết cho phát hiện OOD.

Trước tiên, hai vectơ toàn cục được chuẩn hóa theo chuẩn L_2:

$$\widetilde{y}_v = \frac{y_v^0}{\|y_v^0\|_2}, \qquad \widetilde{y}_t = \frac{y_t^0}{\|y_t^0\|_2}. \tag{3.34}$$

Với các vectơ đơn vị, thứ tự theo khoảng cách Euclid tương ứng với thứ tự theo độ tương đồng cosine vì $\|a - b\|_2^2 = 2 - 2a^\top b$ khi $\|a\|_2 = \|b\|_2 = 1$.

Từ N_{train} mẫu huấn luyện trong phân phối, hai ngân hàng tham chiếu đã chuẩn hóa được xây dựng độc lập:

$$\mathcal{D}_v = \{z_{v,1}, z_{v,2}, \ldots, z_{v,N_{\text{train}}}\}, \qquad \mathcal{D}_t = \{z_{t,1}, z_{t,2}, \ldots, z_{t,N_{\text{train}}}\}. \tag{3.35}$$

Mỗi $z_{v,i}$ hoặc $z_{t,i}$ là vectơ toàn cục đã được chuẩn hóa của mẫu huấn luyện thứ i trong không gian biểu diễn tương ứng.

Với một mẫu cần đánh giá, gọi $z_v^{(k)} \in \mathcal{D}_v$ và $z_t^{(k)} \in \mathcal{D}_t$ là láng giềng gần thứ k trong từng không gian. Hai khoảng cách k-NN đơn phương thức được xác định bởi

$$d_v(\widetilde{y}_v) = \left\| \widetilde{y}_v - z_v^{(k)} \right\|_2, \qquad d_t(\widetilde{y}_t) = \left\| \widetilde{y}_t - z_t^{(k)} \right\|_2. \tag{3.36}$$

Mặc dù đầu vào đã được chuẩn hóa L_2, phân phối của d_v và d_t vẫn có thể khác nhau. Vì vậy, trước khi hợp nhất, trung bình và độ lệch chuẩn của từng khoảng cách được ước lượng trên tập xác thực ID $\mathcal{V}_{\text{ID}}$. Ký hiệu các thống kê này là $\mu_v^{\text{val}}, \sigma_v^{\text{val}}$ và $\mu_t^{\text{val}}, \sigma_t^{\text{val}}$; hai khoảng cách sau chuẩn hóa Z-score là

$$\widetilde{d}_v = \frac{d_v - \mu_v^{\text{val}}}{\sigma_v^{\text{val}} + \varepsilon_{\text{num}}}, \qquad \widetilde{d}_t = \frac{d_t - \mu_t^{\text{val}}}{\sigma_t^{\text{val}} + \varepsilon_{\text{num}}}, \tag{3.37}$$

trong đó $\varepsilon_{\text{num}} > 0$ là hằng số nhỏ dùng để bảo đảm ổn định số. Phép biến đổi này đưa hai khoảng cách về cùng thang đo không thứ nguyên, nhưng không hàm ý rằng chúng tuân theo phân phối Gauss.

Điểm bất thường đa phương thức được hợp nhất bằng toán tử cực đại:

$$s_{\text{OOD}}(\widetilde{y}_v, \widetilde{y}_t) = \max\left\{ \widetilde{d}_v, \widetilde{d}_t \right\}. \tag{3.38}$$

Quy tắc này làm điểm tổng hợp tăng khi ít nhất một phương thức khác biệt so với dữ liệu tham chiếu. Tuy nhiên, giá trị lớn chỉ tạo tín hiệu cảnh báo, không tự thân chứng minh rằng mẫu chắc chắn là OOD.

Ngưỡng τ_{alert} được hiệu chỉnh trên cùng tập xác thực ID tại mức cảnh báo nhầm mục tiêu $\alpha = 0{,}05$:

$$\tau_{\text{alert}} = Q^+_{1-\alpha}(\{ s_{\text{OOD}}(\widetilde{y}_{v,i}, \widetilde{y}_{t,i}) \mid (v_i, t_i) \in \mathcal{V}_{\text{ID}} \}), \qquad \alpha = 0{,}05, \tag{3.39}$$

trong đó Q^+_q là phân vị thực nghiệm phía trên ở mức q. Với tập mẫu hữu hạn, cách chọn này nhằm giữ lại ít nhất khoảng 95% mẫu xác thực ID theo quy ước phân vị; nó không đồng nhất với chỉ số FPR@95%TPR dùng để đánh giá trên tập kiểm thử.

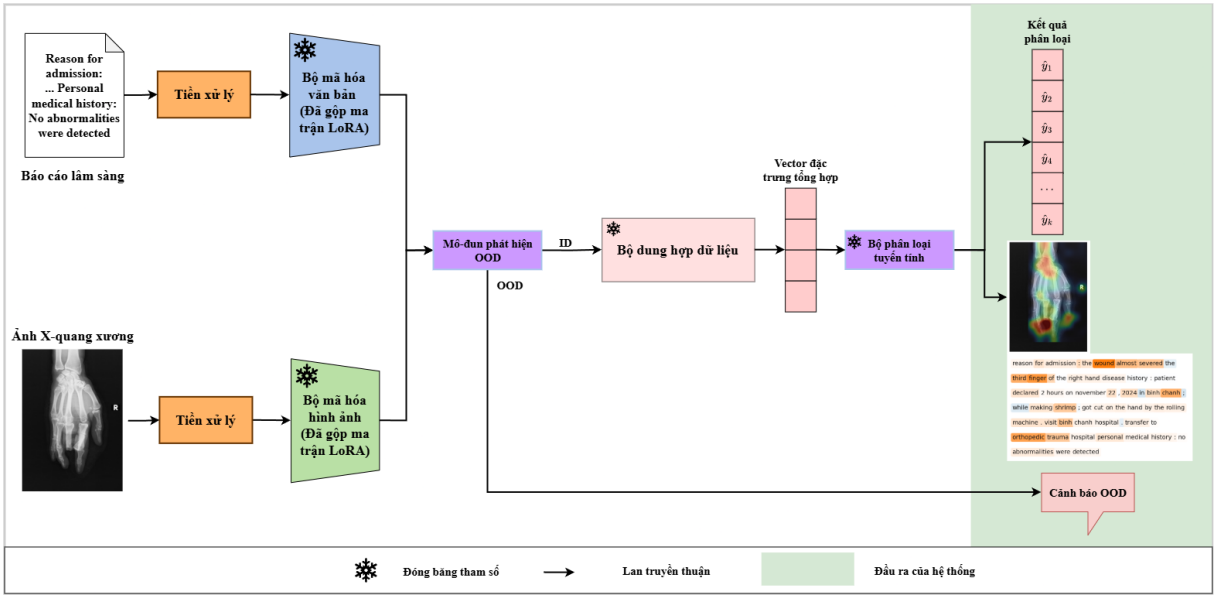
Quy tắc cảnh báo:

$$\omega_{\mathrm{OOD}} = \begin{cases} 1, & \text{nếu } s_{\mathrm{OOD}}(\widetilde{y}_v, \widetilde{y}_t) > \tau_{\mathrm{alert}}, \\ 0, & \text{ngược lại.} \end{cases} \tag{3.40}$$

Trong đó, $\omega_{\mathrm{OOD}} = 1$ có nghĩa hệ thống phát cảnh báo, còn $\omega_{\mathrm{OOD}} = 0$ có nghĩa điểm số không vượt ngưỡng. Cả hai trạng thái đều chỉ bổ trợ cho dự đoán phân lớp, không phải bằng chứng bảo đảm mẫu nằm ngoài hoặc trong phân phối và không được diễn giải như một cơ chế tự động từ chối chẩn đoán.

3.8 Suy luận trong quá trình trực tuyến

Hình 3.6 minh họa quy trình suy luận trực tuyến. Hệ thống nhận một ảnh X-quang v cùng văn bản lâm sàng t, vector đặc trưng từ hai bộ mã hóa được đưa vào mô-đun phát hiện dữ liệu ngoài phân phối, hệ thống sẽ dừng và đưa cảnh báo OOD nếu ca được đánh giá ngoài phân phối, ngược lại, đặc trưng tiếp tục được dung hợp và phân loại để đưa ra dự đoán bệnh lý kèm thông tin giải thích. Toàn bộ tham số được giữ cố định.



Hình 3.6: Quy trình suy luận trực tuyến và phát hiện mẫu ngoài phân phối

Trước khi triển khai, các ma trận LoRA đã học được hợp nhất vào trọng số nền của các lớp tuyến tính tương ứng trong bộ mã hóa ảnh và văn bản [17]:

$$W_{\text{inference}} = W_0 + \frac{\alpha}{r} BA \tag{3.41}$$

Phép hợp nhất loại các nhánh LoRA khỏi đồ thị suy luận và giữ lại trọng số đã thích nghi. Tuy nhiên, XBone-Net vẫn có mô-đun dung hợp và đầu phân lớp riêng, do đó tổng số tham số cùng chi phí suy luận không được xem là tương đương mạng nền ban đầu.

Cặp đầu vào (v, t) được đưa qua hai bộ mã hóa của BiomedCLIP. Bộ mã hóa ảnh tạo chuỗi $y_v \in \mathbb{R}^{197\times D}$ gồm đặc trưng toàn cục $y_v^0 \in \mathbb{R}^D$ và 196 đặc trưng mảnh ảnh $y_v^{1:} \in \mathbb{R}^{196\times D}$. Bộ mã hóa văn bản tạo chuỗi $y_t \in \mathbb{R}^{T\times D}$ với $T = 256$, trong đó y_t^0 là đặc trưng toàn cục và $y_t^{1:}$ chứa ngữ cảnh cục bộ.

Hai đặc trưng toàn cục đồng thời được chuyển đến bộ cảnh báo dữ liệu ngoài phân phối ở Mục 3.7. Sau khi chuẩn hóa theo chuẩn L_2, hệ thống tính khoảng cách tới láng giềng thứ k trong ngân hàng tham chiếu của ảnh và văn bản, chuẩn hóa hai khoảng cách bằng thống kê trên tập xác thực trong phân phối rồi lấy giá trị lớn hơn làm điểm cảnh báo:

$$s_{\text{OOD}} = \max\left\{\widetilde{d}_v, \widetilde{d}_t\right\}. \tag{3.42}$$

Khi $s_{\text{OOD}} > \tau_{\text{alert}}$, giao diện trả về cảnh báo và không công bố nhãn hoặc độ tin cậy cho ca đó. Đây là cơ chế thận trọng ở tầng trình bày kết quả, không phải bằng chứng rằng mẫu chắc chắn nằm ngoài phân phối. Ngược lại, trường hợp không vượt ngưỡng cũng không xác nhận mẫu an toàn hoặc thuộc phân phối huấn luyện.

Song song với việc tạo điểm cảnh báo, các chuỗi đặc trưng được đưa qua chú ý chéo hai chiều để tạo biểu diễn dùng cho phân lớp. Nhánh ảnh sang văn bản dùng y_v^0 làm truy vấn trên $y_t^{1:}$ và tạo $f_{v\to t}$. Nhánh văn bản sang ảnh dùng y_t^0 làm truy vấn trên $y_v^{1:}$ và tạo $f_{t\to v}$. Hai đầu ra được kết hợp với đặc trưng toàn cục tương ứng bằng kết nối thặng dư và chuẩn hóa lớp:

$$h_v = \mathrm{LN}\big(f_{v\to t} + y_v^0\big), \qquad h_t = \mathrm{LN}\big(f_{t\to v} + y_t^0\big). \tag{3.43}$$

Sau đó, hai biểu diễn được nối theo chiều đặc trưng và đưa qua mạng truyền thẳng để thu được biểu diễn dung hợp cuối cùng:

$$h_{\text{concat}} = [h_v, h_t] \in \mathbb{R}^{2D}, \qquad \boldsymbol{z} = \text{MLP}(h_{\text{concat}}) \in \mathbb{R}^{D}. \tag{3.44}$$

Biểu diễn $\boldsymbol{z} \in \mathbb{R}^{512}$ được đưa vào đầu phân lớp tuyến tính để tạo logit cho K lớp. Với bộ dữ liệu CTCH, $K = 22$:

$$\boldsymbol{s} = W_{\text{clf}}\boldsymbol{z} + b_{\text{clf}} \in \mathbb{R}^{K}, \qquad \widehat{p}_k = \frac{\exp(s_k)}{\sum_{j=1}^{K} \exp(s_j)}. \tag{3.45}$$

Nhãn dự đoán được xác định từ phân phối xác suất gốc:

$$\widehat{y} = \arg\max_{y_k \in \mathcal{Y}} \widehat{p}_k. \tag{3.46}$$

Hệ thống cũng truy vấn các ảnh huấn luyện gần nhất theo độ tương tự cosin của đặc trưng ảnh toàn cục để cung cấp thông tin tham khảo. Nhãn và độ tin cậy chỉ được trình bày khi điểm cảnh báo không vượt ngưỡng đã hiệu chỉnh, còn các ảnh gần nhất chỉ đóng vai trò tham khảo và không xác nhận tính đúng của dự đoán.

Đối với mẫu không tạo cảnh báo, hệ thống có thể tính thêm tích phân gradient [42] để truy vết những thành phần đầu vào làm thay đổi logit của nhãn dự đoán. Lớp có xác suất lớn nhất trên cặp đầu vào đầy đủ được cố định làm lớp đích. Khi giải thích ảnh, bệnh sử được giữ nguyên, còn khi giải thích văn bản, ảnh X-quang được giữ nguyên. Với đầu vào cần giải thích $\boldsymbol{u}$, mốc tham chiếu $\boldsymbol{u}^0$ và logit lớp đích $F_{\widehat{k}}$, mức đóng góp của thành phần thứ j được xác định bởi

$$\text{IG}_j\big(\boldsymbol{u}, \boldsymbol{u}^0\big) = \big(u_j - u_j^0\big) \int_0^1 \frac{\partial F_{\widehat{k}}\big(\boldsymbol{u}^0 + \beta\,\big(\boldsymbol{u} - \boldsymbol{u}^0\big)\big)}{\partial u_j}\,\mathrm{d}\beta. \tag{3.47}$$

Trong đó, $\beta \in [0, 1]$ xác định đường nội suy từ mốc tham chiếu đến đầu vào thật. Mốc ảnh là tensor bằng 0 trong không gian ảnh sau chuẩn hóa, không phải ảnh RGB màu đen; khi đảo phép chuẩn hóa, mốc này tương ứng với giá trị trung bình của từng kênh. Mốc văn bản thay embedding

của các token nội dung bằng embedding của token đệm $[PAD]$, giữ nguyên token đặc biệt và mặt nạ chú ý.

Kết quả ảnh được biểu diễn bằng bản đồ nhiệt, trong đó màu nóng cho biết các vị trí có độ lớn đóng góp cao. Kết quả văn bản dùng màu cam cho tác động ủng hộ và màu xanh cho tác động phản đối lớp dự đoán. Khi được yêu cầu, hệ thống có thể tính thêm các đường loại bỏ và khôi phục cùng mức giảm xác suất khi thay toàn bộ ảnh hoặc văn bản bằng mốc tham chiếu. Các phép đo này đánh giá mức phụ thuộc của dự đoán vào từng nguồn thông tin và được trình bày chi tiết ở Chương 4.

Tích phân gradient và các phép can thiệp chỉ mô tả phản ứng của mô hình đối với lớp đích, đầu vào và mốc tham chiếu đã chọn. Vì vậy, kết quả không chứng minh quan hệ nhân quả, không xác nhận vị trí tổn thương, không bảo đảm tính đúng lâm sàng và không thay thế đánh giá của chuyên gia.

Chương này đã trình bày các thành phần của XBone-Net, quy trình huấn luyện hai pha và hai công cụ hỗ trợ phân tích dự đoán là cảnh báo OOD và tích phân gradient. Trên cơ sở đó, Chương 4 đánh giá hiệu năng và chi phí, đối chiếu cấu hình chỉ ảnh với cấu hình đầy đủ để khảo sát vai trò của bệnh sử, đồng thời kiểm tra ảnh hưởng của các thành phần và giới hạn của hai công cụ hỗ trợ.

Chương 4

Thực nghiệm và kết quả

Chương này trình bày thiết kế thực nghiệm và kết quả theo bốn câu hỏi nghiên cứu đã nêu ở Chương 1. Câu hỏi thứ nhất xem xét hiệu năng phân lớp, vai trò quan sát được của bệnh sử qua đối chứng XBone-Net chỉ ảnh trên CTCH trong điều kiện mất cân bằng với các lớp ít mẫu, cùng sự đánh đổi chi phí. Câu hỏi thứ hai đánh giá ảnh hưởng của các thành phần. Câu hỏi thứ ba xác định khả năng và giới hạn của cảnh báo dữ liệu ngoài phân phối hậu xử lý. Câu hỏi thứ tư khảo sát mức phụ thuộc của dự đoán vào ảnh và văn bản qua tích phân gradient kết hợp can thiệp đầu vào. Các cấu hình có huấn luyện được đánh giá trên ba hạt giống 42, 123 và 456, sau đó giá trị tổng hợp được báo cáo dưới dạng trung bình ± độ lệch chuẩn. Riêng phân tích tích phân gradient sử dụng hạt giống 42 trên toàn bộ 669 mẫu kiểm thử CTCH. Kết quả theo từng hạt giống và các phân tích bổ sung được trình bày tại Phụ lục C.

4.1 Thiết kế thực nghiệm

4.1.1 Chuẩn bị dữ liệu

Nghiên cứu sử dụng bộ dữ liệu BTXRD [49] được công bố và bộ dữ liệu CTCH được thu thập tại Bệnh viện CTCH Thành phố Hồ Chí Minh do giảng viên cung cấp. Các phần dưới đây mô tả nguồn gốc, cách thức thu thập và những số liệu thống kê liên quan đến từng bộ dữ liệu. Ngoài

ra, cấu trúc thư mục và các bước tiền xử lý sẽ được mô tả ở Phụ lục A.

Bộ dữ liệu BTXRD

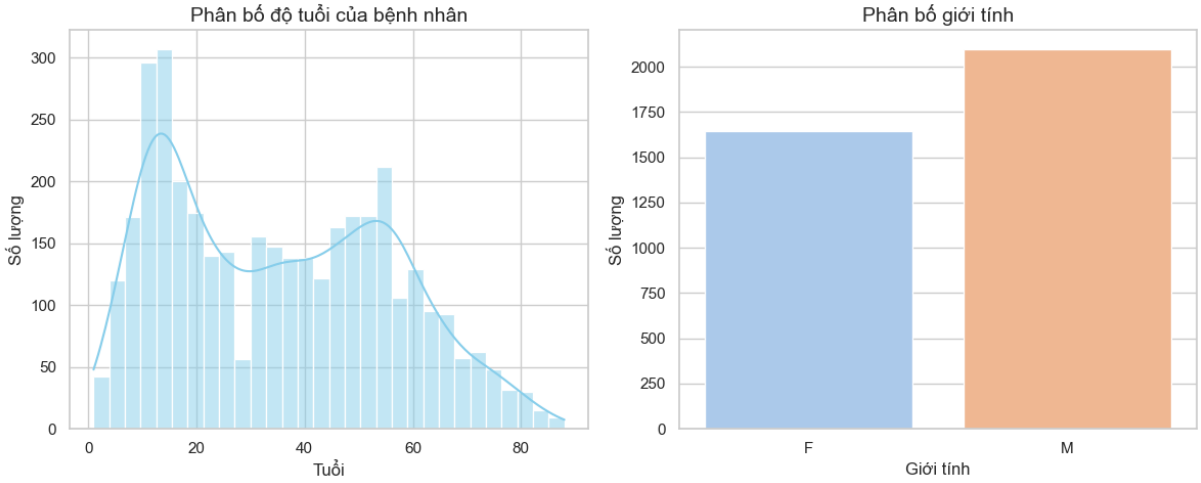
BTXRD là bộ dữ liệu ảnh X-quang được xây dựng cho các bài toán phân lớp, định vị và phân vùng u xương nguyên phát. Phiên bản được sử dụng trong nghiên cứu gồm 3.746 ảnh, siêu dữ liệu về tuổi, giới tính, vị trí giải phẫu và tư thế chụp, cùng các chỉ báo về sự hiện diện, tính lành tính hoặc ác tính và phân nhóm tổn thương. Đối với 1.867 ảnh có u, bộ dữ liệu còn cung cấp tệp chú thích chứa thông tin vùng tổn thương.

Theo mô tả của bộ dữ liệu công bố, dữ liệu được tổng hợp từ ba bệnh viện tại Trung Quốc, Radiopaedia và MedPix. Dữ liệu bệnh viện được thu thập trong giai đoạn từ tháng 7 năm 2013 đến tháng 7 năm 2023, các chẩn đoán được xác nhận bằng mô bệnh học hoặc được hai bác sĩ X-quang thống nhất. Đối với hai nguồn trực tuyến, các ảnh liên quan đến u xương được hai chuyên gia tuyển chọn, đồng thời yêu cầu có thông tin tuổi và giới tính. Những vùng giải phẫu có ít mẫu hoặc nhiều nhiễu như đầu, cổ, ngực và bụng được loại bỏ, do đó phạm vi còn lại tập trung vào chi trên, chi dưới và xương chậu.

Quy trình chú thích được thực hiện bằng Labelme [39]: một bác sĩ chuyên khoa u xương có 10 năm kinh nghiệm xác định vùng tổn thương, sau đó kết quả được một chuyên gia có 20 năm kinh nghiệm kiểm tra.

Đặc điểm dữ liệu và bài toán phân lớp Trong 3.746 mẫu, có 1.879 ảnh bình thường, 1.525 ảnh thuộc nhóm u lành tính và 342 ảnh thuộc nhóm u ác tính. Tuổi dao động từ 1 đến 88, gồm 2.098 mẫu nam và 1.648 mẫu nữ như được thể hiện trong Hình 4.1.

Nhãn được thiết lập dưới dạng phân lớp đơn nhãn với 10 lớp. Nhãn bình thường được suy ra khi cờ chỉ báo u bằng 0, chín lớp còn lại được lấy từ các chỉ báo bệnh lý trong siêu dữ liệu. Bảng 4.1 trình bày số lượng mẫu theo tập chia, trong khi Bảng 4.2 trình bày phân bố lớp ở các tập chia.



Hình 4.1: Phân bố độ tuổi và giới tính của các bệnh nhân được quan sát trong bộ dữ liệu BTXRD

Tập chia	**Số lượng hình ảnh**	**Tỷ lệ (%)**
Huấn luyện	2.621	70
Xác thực	375	10
Kiểm thử	750	20
Tổng cộng	**3.746**	**100,00**

Bảng 4.1: Phân bổ mẫu theo các tập chia trong BTXRD

Nhãn bệnh lý	**Huấn luyện**	**Xác thực**	**Kiểm thử**	**Tổng**	**Tỷ lệ**
Bình thường	1.322	191	366	1.879	50,16%
U xương sụn	538	70	145	753	20,10%
Sarcoma xương	200	32	65	297	7,93%
Đa u xương sụn	189	29	45	263	7,02%
Nang xương đơn thuần	149	17	40	206	5,50%
U lành tính khác	83	8	24	115	3,07%
U tế bào khổng lồ	54	8	31	93	2,48%
U sụn màng hoạt dịch	35	7	9	51	1,36%
U ác tính khác	27	5	13	45	1,20%
U xơ xương	24	8	12	44	1,17%
Tổng	**2.621**	**375**	**750**	**3.746**	**100,00%**

Bảng 4.2: Phân bổ các lớp đơn nhãn sau chuẩn hóa trong bộ dữ liệu BTXRD

Bộ dữ liệu được chia ngẫu nhiên ở mức ảnh với hạt giống 42 và tỷ lệ 70/10/20 cho các tập huấn luyện, xác thực và kiểm thử. Tệp siêu dữ liệu không cung cấp mã người bệnh ổn định để nhóm các ảnh của cùng một ca trước khi chia. Vì vậy, kết quả BTXRD chỉ được diễn giải trong phạm vi phép chia ở mức ảnh.

Bộ dữ liệu BTXRD không cung cấp văn bản lâm sàng tương ứng với từng bệnh nhân. Do đó, để bổ sung nguồn văn bản đi kèm, nghiên cứu sử dụng quy trình sinh văn bản lâm sàng bằng siêu dữ liệu có sẵn được mô tả ở Phụ lục A.1 và kết quả được minh họa như Bảng 4.3.

Ảnh	**Nhãn**	**Văn bản tổng hợp được sinh**
	*other mt*	Patient: 48-year-old female. Reason for admission: Pain and swelling of the hip bone. Disease history: Pain in the hip bone for 1 month; associated with decreased appetite. Physical examination: Palpable mass; tenderness on palpation; mild swelling. Personal medical history: No prior bone disease or fracture. No relevant surgical or medical history. Radiographic evaluation: AP view of the hip bone was obtained.
	*multiple osteo-chondro-mas*	Patient: 64-year-old male. Reason for admission: Progressive pain in the humerus. Disease history: The patient reports worsening pain in the humerus for 1 month. Physical examination: Palpable mass with local tenderness; no lymphadenopathy detected. Personal medical history: No prior bone disease or fracture. History of age-related degenerative changes; no prior bone lesions. Radiographic evaluation: AP view of the humerus was obtained.

Bảng 4.3: Ví dụ ảnh, nhãn và văn bản tổng hợp được sinh của bộ dữ liệu BTXRD

Trong thiết kế thực nghiệm, BTXRD được sử dụng để khảo sát khả năng chuyển giao sang bài toán u xương, ảnh hưởng của mất cân bằng lớp và hành vi của mô hình trong thiết lập văn bản tổng hợp. Do văn bản lâm sàng được sinh từ siêu dữ liệu và chịu ảnh hưởng của các cờ nhóm bệnh, kết quả trên bộ dữ liệu này không được diễn giải tương đương với kết quả thu được từ văn bản lâm sàng thực tế.

Bộ dữ liệu CTCH

CTCH là bộ dữ liệu X-quang xương được thu thập tại Bệnh viện CTCH Thành phố Hồ Chí Minh và được giảng viên Võ Thế Hào cùng giảng viên Đỗ Phúc Thịnh cung cấp cho nghiên cứu. Dữ liệu nguồn gồm ảnh được lựa chọn từ từng ca khám và các trường bệnh án tiếng Việt liên quan đến lý do vào viện, diễn tiến bệnh, tiền sử, kết quả khảo sát hình ảnh và chẩn đoán chuyên môn. Văn bản đầu vào chỉ sử dụng lý do vào viện, diễn tiến bệnh và tiền sử. Kết quả khảo sát hình ảnh, chẩn đoán chuyên môn và nhãn không được đưa vào chuỗi văn bản. Phạm vi thực nghiệm chỉ sử dụng ảnh X-quang đại diện cho vị trí bệnh lý. Ảnh từ phương thức tạo ảnh khác hoặc không đại diện cho vị trí bệnh lý không được đưa vào tập phân lớp. Quy trình lựa chọn trường và kiểm soát rò rỉ nhãn được trình bày tại Phụ lục A.2.

Đạo đức nghiên cứu, quyền riêng tư và tính sẵn có của dữ liệu Bộ dữ liệu được sử dụng theo thỏa thuận bảo mật đã ký kết và chỉ phục vụ mục đích nghiên cứu. Trước khi xử lý, các thông tin có khả năng định danh trực tiếp người bệnh đã được loại bỏ và các mã hồ sơ chỉ được dùng để liên kết dữ liệu, kiểm soát việc phân chia tập và không được công bố trong kết quả nghiên cứu.

Do chứa thông tin y tế nhạy cảm, bộ dữ liệu gốc không được công khai và khóa luận chỉ trình bày số liệu thống kê cùng kết quả tổng hợp. Mọi hoạt động kiểm định hoặc triển khai trong môi trường lâm sàng về sau cần tuân thủ quy định bảo vệ dữ liệu và được cơ quan có thẩm quyền phê duyệt.

Đặc điểm dữ liệu và bài toán phân lớp Việc chia dữ liệu được thực hiện theo người bệnh với hạt giống ngẫu nhiên 42 và tỷ lệ mục tiêu 70/10/20. Người bệnh được nhóm theo lớp chính trước khi phân bổ để duy trì sự hiện diện của các lớp ít mẫu ở cả ba tập khi số lượng cho phép. Kết quả như được thể hiện ở Bảng 4.4 gồm 2.265 mẫu huấn luyện, 315 mẫu xác thực và 669 mẫu kiểm thử và Bảng 4.5 thể hiện chi tiết số lượng mẫu trong từng lớp trong các tập chia.

Tập dữ liệu	Số lượng ảnh	Tỷ lệ
Huấn luyện	2.265	69,71%
Xác thực	315	9,70%
Kiểm thử	669	20,59%
Tổng cộng	**3.249**	**100,00%**

Bảng 4.4: Phân bổ mẫu trong phân phối của CTCH theo tập dữ liệu

Lớp	Huấn luyện	Xác thực	Kiểm thử	Tổng	Tỷ lệ
Bình thường	760	108	218	1.086	33,43%
Gãy xương quay	209	29	61	299	9,20%
Gãy xương cánh tay	147	21	42	210	6,46%
Gãy xương đùi	106	15	31	152	4,68%
Gãy xương ngón tay	102	14	31	147	4,52%
Gãy xương chày	99	14	29	142	4,37%
Gãy xương cẳng tay	99	14	29	142	4,37%
Gãy xương cổ chân	87	12	26	125	3,85%
Gãy xương cẳng chân	85	12	25	122	3,76%
Gãy xương vùng vai	70	10	21	101	3,11%
Gãy xương bàn chân	68	9	21	98	3,02%
Gãy cột sống thắt lưng	53	7	16	76	2,34%
Gãy xương bàn tay	53	7	16	76	2,34%
Gãy xương ngón chân	52	7	16	75	2,31%
Viêm khớp	47	6	15	68	2,09%
Gãy xương trụ	46	6	14	66	2,03%
Cắt cụt ngón tay	42	6	13	61	1,88%
Gãy xương bánh chè	41	5	13	59	1,82%
Gãy xương gót	36	5	11	52	1,60%
Gãy cột sống ngực	28	4	8	40	1,23%
Gãy xương thuyền	19	2	7	28	0,86%
Gãy xương vùng chậu	16	2	6	24	0,74%
Tổng cộng	**2.265**	**315**	**669**	**3.249**	**100,00%**

Bảng 4.5: Phân bố 22 lớp của CTCH trong ba tập dữ liệu

Mỗi hồ sơ được liên kết với một ảnh X-quang duy nhất. Trong quần thể phân lớp hiện tại, 3.249 ảnh tương ứng với 3.249 mã bệnh nhân và quần thể ngoài phân phối gồm 18 ảnh từ 18 mã khác, không giao với quần thể phân lớp. Bảng 4.6 minh họa một số mẫu sau tiền xử lý. Quy trình sàng lọc, lựa chọn trường văn bản và kiểm tra toàn vẹn được mô tả tại Phụ lục A.2.

Các mẫu ngoài phân phối không được đưa vào huấn luyện, xác thực hoặc kiểm thử bộ phân lớp 22 lớp. Nhóm này gồm các bệnh lý ngoại vi nằm ngoài không gian nhãn đích và chỉ được sử dụng trong kịch bản đánh giá dữ liệu ngoài phân phối được trình bày ở phần thực nghiệm.

Ảnh	Nhãn	văn bản lâm sàng
	*Lower leg fracture*	Reason for admission: Right lower leg pain. Disease history: The patient fell from the roof at 3:00 p.m. on October 17, 2024 in Tien Giang; no first aid. to the Orthopedic Trauma Hospital. Personal medical history: Nasopharynx is being treated
	*Finger phalanx fracture*	Reason for admission: Right hand wound. Disease history: The patient had his right hand cut by a saw at 2:00 p.m. on October 17, 2024 in Dong Nai; Go to the local medical station for first aid. to the Orthopedic Trauma Hospital. Personal medical history: Right hand third metatarsal fusion surgery 9 years ago

Bảng 4.6: Các ví dụ ảnh, nhãn và văn bản lâm sàng của bộ dữ liệu CTCH

CTCH là nguồn bằng chứng chính của khóa luận vì mỗi ảnh được liên kết với văn bản lâm sàng có sẵn và phép chia được thực hiện theo người bệnh. Bộ dữ liệu này đồng thời cung cấp quần thể ngoài không gian nhãn để khảo sát cảnh báo dữ liệu ngoài phân phối. Phân tích nguồn thông tin sử dụng toàn bộ 669 mẫu kiểm thử

4.1.2 Cấu hình thí nghiệm

Mỗi cấu hình có huấn luyện được chạy với ba hạt giống 42, 123 và 456 trên cùng phân chia dữ liệu và môi trường ở Bảng 4.7. Bảng 4.8 trình bày các siêu tham số chính dùng trong thực nghiệm.

Thành phần	Cấu hình
Phần cứng	RTX 5060 Ti 16 GB, Intel Core Ultra 7 265KF và 32 GB RAM
Phần mềm	Python 3.11.15, Torch 2.11.0+cu128 và CUDA 12.8
Độ chính xác số học	bfloat16

Bảng 4.7: Môi trường thực nghiệm

Thành phần	Cấu hình
Đầu vào ảnh	1 ảnh kích thước 224x224
Bộ tối ưu và kích thước lô	AdamW, 16
Hệ số suy giảm trọng số	10^{-4}
Lịch tốc độ học	cosine
Tỷ lệ khởi động	0,1
Độ chính xác số học	bfloat16
Cấu hình LoRA	Hạng 16, hệ số 32 và tỷ lệ bỏ học 0,1
Huấn luyện pha 1	Tốc độ học 5×10^{-5}, tối đa 30 vòng lặp và dừng sớm sau 3 vòng
Huấn luyện pha 2	Tốc độ học 10^{-4}, tối đa 50 vòng lặp và dừng sớm sau 5 vòng
Xử lý mất cân bằng lớp	Hệ số số lượng hiệu dụng 0,999 và giới hạn trọng số lớp 5,0

Bảng 4.8: Cấu hình chính của các thực nghiệm

4.1.3 Các độ đo

Hai bộ dữ liệu BTXRD (10 lớp) và CTCH (22 lớp) được đánh giá theo bài toán phân lớp đa lớp qua bốn nhóm độ đo: phân lớp, phát hiện dữ liệu ngoài phân phối (OOD), giải thích tích phân gradient, và hiệu quả tham số cùng chi phí huấn luyện-suy luận.

Độ đo phân lớp

Gọi N là số mẫu, C là số lớp; TP_c, FP_c, FN_c lần lượt là số dương đúng, dương sai và âm sai khi xét lớp c là lớp dương.

Độ chính xác (Accuracy): Tỷ lệ mẫu được dự đoán đúng trên toàn bộ tập dữ liệu:

$$\text{Accuracy} = \frac{\sum_{c=1}^{C} TP_c}{N}. \tag{4.1}$$

Độ chính xác cân bằng (Balanced Accuracy): Trung bình độ nhạy giữa các lớp nhằm giảm thiểu ảnh hưởng của mất cân bằng dữ liệu [1]:

$$\text{Balanced Accuracy} = \frac{1}{C} \sum_{c=1}^{C} \frac{TP_c}{TP_c + FN_c}. \tag{4.2}$$

Độ chính xác dự đoán và độ nhạy theo lớp: Đánh giá mức dương sai (Precision_c) và mức bỏ sót (Recall_c) của từng lớp:

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c}, \tag{4.3}$$

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c}. \tag{4.4}$$

Macro-F1: Trung bình cộng điểm F1 trên toàn bộ các lớp, là độ đo phân lớp chính của nghiên cứu:

$$\text{Macro-F1} = \frac{1}{C} \sum_{c=1}^{C} \frac{2TP_c}{2TP_c + FP_c + FN_c}. \tag{4.5}$$

Các kết luận về hiệu năng phân loại được xây dựng từ Accuracy, Balanced Accuracy và Macro-F1, trong đó Macro-F1 là độ đo chính. Ba độ đo này được sử dụng nhất quán trong bảng kết quả, kiểm định ghép cặp và phần trả lời các câu hỏi nghiên cứu.

Đánh giá thống kê ghép cặp: Gọi X là XBone-Net, B_k là mô hình đối chứng thứ k, $S = 3$ là số hạt giống và $\mathcal{M}$ là độ đo đánh giá. Chênh lệch quan sát trung bình được xác định bởi:

$$\widehat{\Delta}_k = \frac{1}{S} \sum_{s=1}^{S} \left[\mathcal{M}(\mathbf{y}, \widehat{\mathbf{p}}_{X,s}) - \mathcal{M}(\mathbf{y}, \widehat{\mathbf{p}}_{B_k,s}) \right]. \tag{4.6}$$

Trong đó $\widehat{\Delta}_k > 0$ biểu thị XBone-Net có kết quả cao hơn đối chứng.

- **Bootstrap ghép cặp:** Lấy mẫu có hoàn lại đồng thời theo bệnh nhân $\mathcal{I}_b$ trong từng lớp và dãy hạt giống $s_1^{(b)}, \ldots, s_S^{(b)}$ cho cả hai mô hình qua $N_{\text{boot}} = 10.000$ lần lặp [8]:

$$\widehat{\Delta}_k^{*(b)} = \frac{1}{S} \sum_{j=1}^{S} \left[\mathcal{M}\left(\mathbf{y}_{\mathcal{I}_b}, \widehat{\mathbf{p}}_{X,s_j^{(b)},\mathcal{I}_b}\right) - \mathcal{M}\left(\mathbf{y}_{\mathcal{I}_b}, \widehat{\mathbf{p}}_{B_k,s_j^{(b)},\mathcal{I}_b}\right) \right]. \tag{4.7}$$

  Khoảng tin cậy 95% là phân vị 2,5% và 97,5% của phân phối $\{\widehat{\Delta}_k^{*(b)}\}_{b=1}^{N_{\text{boot}}}$.

- **Kiểm định hoán vị ghép cặp:** Hoán đổi ngẫu nhiên dự đoán của hai mô hình theo từng bệnh nhân với xác suất 0,5 qua $N_{\text{perm}} = 10.000$ lần lặp [10]. Giá trị p hai phía được tính theo:

$$p_k = \frac{1 + \sum_{r=1}^{N_{\text{perm}}} \mathbb{I}\left(\left|\widehat{\Delta}_k^{\pi(r)}\right| \geq \left|\widehat{\Delta}_k\right|\right)}{N_{\text{perm}} + 1}. \tag{4.8}$$

  Các giá trị p được hiệu chỉnh đa so sánh theo phương pháp Holm [15]. Khác biệt được kết luận có ý nghĩa thống kê khi $p_{\text{Holm}} < 0{,}05$.

Độ đo phát hiện dữ liệu ngoài phân phối

Gọi $\mathcal{D}_{\text{ID}}$ và $\mathcal{D}_{\text{OOD}}$ lần lượt là tập dữ liệu trong và ngoài phân phối ($N_{\text{OOD}} = |\mathcal{D}_{\text{OOD}}|$), còn $s_{\text{OOD}}(x)$ là điểm bất thường đa phương thức (Công thức 3.38).

AUROC-OOD: Xác suất điểm bất thường của mẫu OOD cao hơn mẫu ID trên toàn bộ dải ngưỡng [14]:

$$\begin{aligned} \text{AUROC}_{\text{OOD}} = \Pr(s_{\text{OOD}}(x_{\text{OOD}}) > s_{\text{OOD}}(x_{\text{ID}})) \\ + \frac{1}{2}\Pr(s_{\text{OOD}}(x_{\text{OOD}}) = s_{\text{OOD}}(x_{\text{ID}}))\,. \end{aligned} \tag{4.9}$$

AUPR-Out: Diện tích dưới đường cong độ chính xác-độ nhạy khi coi dữ liệu OOD là lớp dương [14, 27]:

$$\text{AUPR-Out} = \sum_{k=1}^{K} \left(R_k^{\text{OOD}} - R_{k-1}^{\text{OOD}}\right) P_k^{\text{OOD}}. \tag{4.10}$$

FPR@95%TPR: Tỷ lệ chấp nhận nhầm mẫu OOD tại ngưỡng τ_{95}^{test} giữ lại ít nhất 95% mẫu ID trên tập kiểm thử [27, 28] (giá trị càng thấp càng tốt):

$$\begin{aligned} \text{FPR@95\%TPR} &= \frac{1}{N_{\text{OOD}}} \sum_{x \in \mathcal{D}_{\text{OOD}}} \mathbb{1}\big[s_{\text{OOD}}(x) \le \tau_{95}^{\text{test}}\big], \\ \text{với} \quad & \Pr_{x \sim \mathcal{D}_{\text{ID}}^{\text{test}}}\big[s_{\text{OOD}}(x) \le \tau_{95}^{\text{test}}\big] \ge 0{,}95. \end{aligned} \tag{4.11}$$

Độ đo đánh giá tích phân gradient

Gọi $F_t(\boldsymbol{u})$ là logit của lớp dự đoán t từ biểu diễn đầu vào $\boldsymbol{u}$, $\boldsymbol{u}'$ là mốc tham chiếu và $p_t(\cdot)$ là xác suất Softmax tương ứng.

Tích phân gradient (Integrated Gradients): Xác định mức đóng góp của thành phần j [42], được xấp xỉ bằng quy tắc hình thang 24 điểm:

$$\text{IG}_j(\boldsymbol{u}) = (u_j - u'_j) \int_0^1 \frac{\partial F_t(\boldsymbol{u}' + \alpha(\boldsymbol{u} - \boldsymbol{u}'))}{\partial u_j} \, \mathrm{d}\alpha. \tag{4.12}$$

Độ trung thực qua phép loại bỏ (AUC_{del}) và khôi phục (AUC_{ins}): Đánh giá sự biến thiên xác suất p_t khi tuần tự thay thế (loại bỏ) hoặc khôi phục tỷ lệ q các đơn vị quan trọng nhất theo thứ tự đóng góp [34]:

$$\text{AUC}_{\text{del}} = \int_0^1 p_t\big(\boldsymbol{u}^{\text{del}}(q)\big) \, \mathrm{d}q, \tag{4.13}$$

$$\text{AUC}_{\text{ins}} = \int_0^1 p_t\big(\boldsymbol{u}^{\text{ins}}(q)\big) \, \mathrm{d}q. \tag{4.14}$$

AUC_{del} càng thấp và AUC_{ins} càng cao phản ánh giải thích có độ trung thực càng cao.

Mức giảm xác suất khi che nguồn (Δp_m): Đánh giá mức phụ thuộc vào từng phương thức $m \in \{\text{img}, \text{txt}\}$ [6]:

$$\Delta p_m = p_t(x) - p_t(x_{\setminus m}). \tag{4.15}$$

Độ đo hiệu quả tham số và suy luận

Gọi Θ_{pre} là tập tham số trước khi hợp nhất LoRA và Θ_{train} là tập tham số huấn luyện. Tổng tham số P_{total}, số tham số huấn luyện P_{train} và tỷ lệ cập nhật r_{train} được tính bởi:

$$P_{\text{total}} = \sum_{\theta \in \Theta_{\text{pre}}} |\theta|, \qquad P_{\text{train}} = \sum_{\theta \in \Theta_{\text{train}}} |\theta|, \qquad r_{\text{train}} = 100 \frac{P_{\text{train}}}{P_{\text{total}}}. \tag{4.16}$$

Chi phí suy luận được đánh giá qua số phép toán dấu phẩy động trên mỗi mẫu (FLOPs), thông lượng, độ trễ trung bình và bộ nhớ GPU cực đại [2, 37]. Các phép đo thực hiện với kích thước lô 1 trên 20 lô kiểm thử; mỗi lô có 10 lượt khởi động và 10 lượt đo, tạo tổng cộng 200 quan sát thời gian lan truyền tiến. Đồ thị suy luận đã hợp nhất LoRA vào mạng nền. Thời gian chỉ tính bước lan truyền tiến, không gồm đọc dữ liệu và chuyển dữ liệu lên GPU. GFLOPs tính các phép toán được bộ đếm hỗ trợ, với một phép nhân-cộng được tính là hai FLOPs.

4.2 Kiểm tra hiệu năng phân lớp và đánh đổi chi phí

4.2.1 Mục đích

Thực nghiệm này đánh giá hiệu năng phân loại của XBone-Net so với các mô hình đối chứng trên BTXRD và CTCH, đồng thời phân tích sự đánh đổi về số tham số cập nhật, chi phí huấn luyện và chi phí suy luận so với BiomedCLIP tinh chỉnh toàn bộ. Riêng trên CTCH, thực nghiệm đối chiếu XBone-Net chỉ ảnh với cấu hình đầy đủ để khảo sát vai trò quan sát được của văn bản lâm sàng cùng quy trình huấn luyện tương ứng trong điều kiện mất cân bằng với các lớp ít mẫu. Kết quả BTXRD được diễn giải trong phạm vi văn bản tổng hợp từ siêu dữ liệu. Một trường hợp kiểm thử ghép cặp được trình bày để minh họa cách thông tin lâm sàng có thể bổ sung cho ảnh trong một quyết định cụ thể.

4.2.2 Nội dung

Thực nghiệm sử dụng hai nhóm đối chứng được tinh chỉnh toàn bộ. Nhóm chỉ dùng ảnh X-quang gồm ResNet-50 [12] và DenseNet-121 [18], đều khởi tạo từ ImageNet. Nhóm nhận cặp ảnh-văn bản gồm CLIP [36], MedCLIP [46], PubMedCLIP [9] và BiomedCLIP [51], khởi tạo từ các trọng số tiền huấn luyện tương ứng. Tất cả mô hình được đánh giá trên cùng phân hoạch dữ liệu của BTXRD và CTCH qua ba hạt giống 42, 123 và 456.

Để khảo sát theo phương thức trên CTCH, cấu hình XBone-Net chỉ ảnh nhận ảnh X-quang và không thực hiện pha khớp ngữ nghĩa ảnh-văn bản, trong khi cấu hình đầy đủ nhận cả ảnh và văn bản lâm sàng theo quy trình hai pha. Hai cấu hình được so sánh trên cùng 669 mẫu kiểm thử bằng Accuracy, Balanced Accuracy và Macro-F1. Phân tích định tính sử dụng các dự đoán ghép cặp ở hạt giống 42 để tìm trường hợp cấu hình chỉ ảnh dự đoán sai nhưng cấu hình đầy đủ dự đoán đúng. Chi phí huấn luyện được đo lường so sánh với BiomedCLIP trên cùng phần cứng và số lượng tham số và chi phí suy luận được đo trên hạt giống 42 trong cùng điều kiện môi trường.

4.2.3 Kết quả

Kết quả phân lớp theo phương thức

Bảng 4.9 so sánh trực tiếp XBone-Net chỉ ảnh với XBone-Net đầy đủ phương thức trên CTCH.

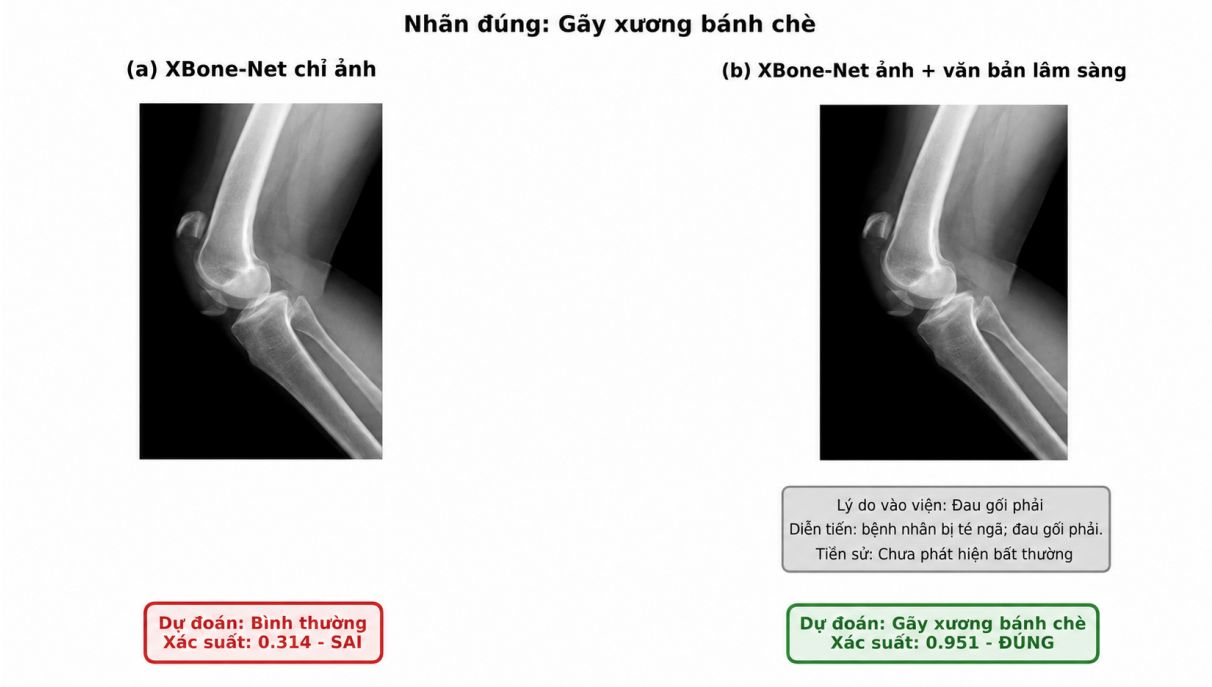
Cấu hình	**Acc ↑**	**BAcc ↑**	**Macro-F1 ↑**
XBone-Net (chỉ ảnh)	$0{,}4439 \pm 0{,}0689$	$0{,}4843 \pm 0{,}0136$	$0{,}3813 \pm 0{,}0551$
XBone-Net (đầy đủ)	$\mathbf{0{,}6183 \pm 0{,}0203}$	$\mathbf{0{,}5935 \pm 0{,}0134}$	$\mathbf{0{,}5727 \pm 0{,}0193}$

Bảng 4.9: So sánh kết quả phân lớp CTCH giữa XBone-Net chỉ ảnh và XBone-Net đầy đủ phương thức

Trên trung bình ba hạt giống, cấu hình chỉ ảnh đạt Accuracy 0,4439, Balanced Accuracy 0,4843 và Macro-F1 0,3813. Cấu hình đầy đủ đạt các giá trị tương ứng 0,6183, 0,5935 và 0,5727, tức tăng lần lượt 0,1744, 0,1092 và 0,1914. Mức tăng của Balanced Accuracy và Macro-F1 cho thấy lợi ích quan sát được không chỉ đến từ lớp chiếm đa số, mà còn xuất hiện khi các lớp được cho trọng số tương đương trong phép tính.

Đối với thách thức dữ liệu mất cân bằng với các lớp có số lượng mẫu ít, cả hai cấu hình đều sử dụng entropy chéo có trọng số theo số lượng mẫu hiệu dụng, với trọng số lớp được giới hạn ở mức 5,0, nhằm tăng chi phí của lỗi trên lớp ít mẫu và hướng đến hạn chế âm sai ở các lớp này. Label smoothing ở mức 0,1 được dùng để hạn chế dự đoán quá tự tin, qua đó hướng đến hạn chế các dự đoán dương sai có độ tin cậy cao. Việc Balanced Accuracy và Macro-F1 cùng tăng khi bổ sung bệnh sử cho thấy kết quả được cải thiện khi các lớp được xem xét đồng đều hơn.

Hình 4.2 minh họa một trường hợp kiểm thử trong 669 mẫu, cấu hình đầy đủ sửa đúng 133 trường hợp mà cấu hình chỉ ảnh dự đoán sai.



Hình 4.2: Ví dụ định tính về trường hợp cấu hình chỉ ảnh dự đoán sai nhưng cấu hình đầy đủ phương thức dự đoán đúng trên CTCH

Ở trường hợp này, nhãn thật là gãy xương bánh chè. Cấu hình chỉ ảnh dự đoán Bình thường với xác suất 0,314 và chỉ gán xác suất 0,094 cho lớp

đúng. Khi kết hợp bệnh sử mô tả đau gối phải sau té ngã, cấu hình đầy đủ dự đoán đúng gãy xương bánh chè với xác suất 0,951. Ví dụ cho thấy thông tin về vị trí đau và cơ chế chấn thương có thể bổ sung ngữ cảnh khi dấu hiệu trên ảnh chưa đủ rõ đối với mô hình chỉ ảnh. Tuy nhiên, đây chỉ là minh họa định tính được chọn theo tiêu chí đã nêu, không chứng minh bệnh sử luôn sửa đúng dự đoán hoặc xác lập quan hệ nhân quả.

Đối với thích ứng miền dữ liệu, LoRA và pha khớp ngữ nghĩa ảnh-văn bản được thiết kế để điều chỉnh biểu diễn BiomedCLIP cho dữ liệu đích với ít tham số cập nhật. Kết quả trên CTCH cho thấy cấu hình đa phương thức đạt hiệu năng phân lớp cao hơn cấu hình chỉ ảnh trên dữ liệu đích trong giao thức hiện tại. Tuy nhiên, cấu hình chỉ ảnh đồng thời không thực hiện pha khớp ngữ nghĩa vì pha này cần cặp đầu vào đa phương thức; chênh lệch vì vậy phản ánh cả bệnh sử và quy trình huấn luyện tương ứng, không phải ước lượng nhân quả riêng của văn bản. CTCH chưa có tập kiểm định độc lập từ bệnh viện, thiết bị chụp hoặc quần thể khác, nên khả năng thích ứng trước dịch chuyển miền vẫn chưa được kiểm chứng.

Kết quả phân lớp trên toàn bộ dữ liệu

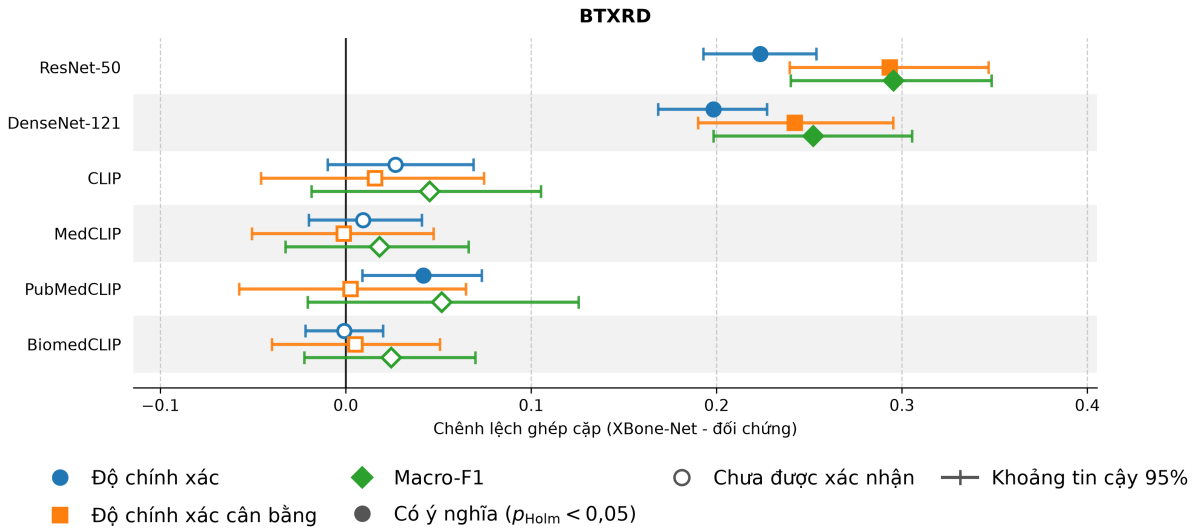
Bảng 4.10 trình bày kết quả trên tập kiểm thử khi các mô hình được huấn luyện bằng toàn bộ dữ liệu huấn luyện.

Dữ liệu	**Mô hình**	**Acc ↑**	**BAcc ↑**	**Macro-F1 ↑**
BTXRD	ResNet-50	0,6067 ± 0,0133	0,3180 ± 0,0131	0,3285 ± 0,0096
	DenseNet-121	0,6320 ± 0,0013	0,3694 ± 0,0150	0,3718 ± 0,0173
	CLIP	0,8036 ± 0,0273	0,5957 ± 0,0160	0,5787 ± 0,0252
	MedCLIP	0,8209 ± 0,0147	**0,6127 ± 0,0238**	0,6057 ± 0,0153
	PubMedCLIP	0,7884 ± 0,0285	0,6089 ± 0,0342	0,5723 ± 0,0577
	BiomedCLIP	**0,8311 ± 0,0028**	0,6062 ± 0,0254	0,5994 ± 0,0124
	XBone-Net	0,8302 ± 0,0098	0,6115 ± 0,0140	**0,6240 ± 0,0118**
CTCH	ResNet-50	0,4983 ± 0,0077	0,4180 ± 0,0046	0,4154 ± 0,0020
	DenseNet-121	0,4818 ± 0,0038	0,4920 ± 0,0465	0,4360 ± 0,0242
	CLIP	0,5874 ± 0,0209	**0,6217 ± 0,0359**	0,5633 ± 0,0090
	MedCLIP	0,5600 ± 0,0396	0,5723 ± 0,0177	0,5161 ± 0,0224
	PubMedCLIP	0,5521 ± 0,0234	0,5589 ± 0,0614	0,5203 ± 0,0264
	BiomedCLIP	0,5969 ± 0,0253	0,6023 ± 0,0234	0,5540 ± 0,0080
	XBone-Net	**0,6183 ± 0,0203**	0,5935 ± 0,0134	**0,5727 ± 0,0193**

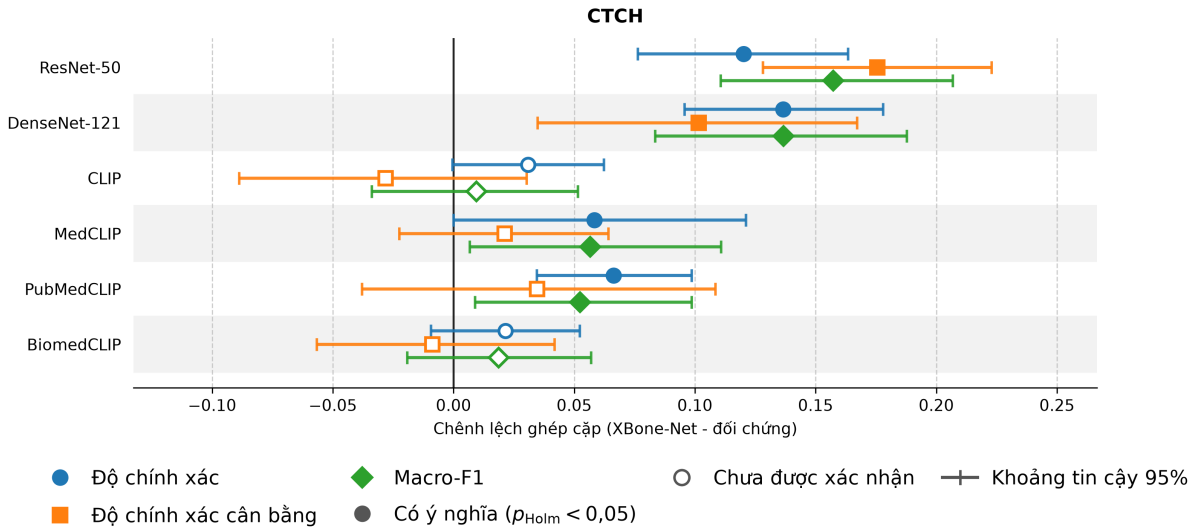
Bảng 4.10: Kết quả phân loại trên BTXRD và CTCH khi sử dụng toàn bộ tập huấn luyện

Về kết quả quan sát, XBone-Net đạt độ chính xác 0,8302 và điểm F1 vĩ mô 0,6240 trên bộ dữ liệu BTXRD; các giá trị tương ứng trên bộ dữ liệu CTCH là 0,6183 và 0,5727. Mô hình vượt trội rõ rệt so với hai đối chứng chỉ dùng ảnh theo kiến trúc tích chập là ResNet-50 và DenseNet-121. So với nhóm mô hình ngôn ngữ-thị giác tinh chỉnh toàn bộ tham số, XBone-Net đạt điểm F1 vĩ mô trung bình cao nhất trên cả hai bộ dữ liệu, đạt độ chính xác cao nhất trên CTCH và tương đương BiomedCLIP trên BTXRD (0,8302 so với 0,8311), trong khi độ chính xác cân bằng duy trì ở mức cạnh tranh.

Để đánh giá ý nghĩa thống kê của các chênh lệch, Hình 4.3 và Hình 4.4 biểu diễn biểu đồ chênh lệch ghép cặp của ba độ đo phân loại. Trục hoành thể hiện mức chênh lệch Δ = XBone-Net − mô hình đối chứng. Thanh ngang biểu diễn khoảng tin cậy 95% ước lượng qua 10.000 lần lấy mẫu lại có hoàn lại theo bệnh nhân và hạt giống. Các điểm đặc biểu thị khác biệt có ý nghĩa thống kê sau hiệu chỉnh đa so sánh ($p_{\text{Holm}} < 0{,}05$), còn điểm rỗng biểu thị khác biệt chưa đủ bằng chứng xác nhận ($p_{\text{Holm}} \geq 0{,}05$). Kết quả kiểm định ghép cặp trên hai biểu đồ cho thấy rõ hai xu hướng chính:



Hình 4.3: Biểu đồ chênh lệch ghép cặp của ba độ đo phân loại trên BTXRD



Hình 4.4: Biểu đồ chênh lệch ghép cặp của ba độ đo phân loại trên CTCH

Đối với nhóm mô hình chỉ dùng ảnh (ResNet-50 và DenseNet-121), XBone-Net vượt trội có ý nghĩa thống kê trên cả ba độ đo ở cả hai bộ dữ liệu ($p_{\text{Holm}} < 0{,}001$, khoảng tin cậy 95% hoàn toàn nằm bên phải mốc 0). Mức tăng điểm F1 vĩ mô đạt từ +0,2522 đến +0,2955 trên BTXRD và từ +0,1367 đến +0,1573 trên CTCH. Chênh lệch này cho thấy toàn bộ cấu hình XBone-Net đạt hiệu năng cao hơn hai đối chứng chỉ dùng ảnh trong giao thức hiện tại. Do các mô hình đồng thời khác nhau về nguồn đầu vào và kiến trúc, phép so sánh này không tách riêng đóng góp của văn bản, vùng ảnh cục bộ hoặc từng thành phần huấn luyện.

Đối với nhóm mô hình ngôn ngữ-thị giác tinh chỉnh toàn bộ, trên bộ dữ liệu CTCH, XBone-Net vượt trội có ý nghĩa thống kê trước MedCLIP và PubMedCLIP ở cả độ chính xác (Δ từ +0,0583 đến +0,0663) và điểm F1 vĩ mô (Δ từ +0,0524 đến +0,0566, $p_{\text{Holm}} < 0{,}05$), đồng thời chưa ghi nhận khác biệt có ý nghĩa thống kê so với CLIP và BiomedCLIP ($p_{\text{Holm}} \geq 0{,}150$). Trên bộ dữ liệu BTXRD, mô hình vượt trội có ý nghĩa về độ chính xác trước PubMedCLIP ($\Delta = +0{,}0418$, $p_{\text{Holm}} = 0{,}002$) và CLIP ($\Delta = +0{,}0267$, $p_{\text{Holm}} = 0{,}046$), trong khi chênh lệch điểm F1 vĩ mô và độ chính xác cân bằng chưa đạt mức ý nghĩa sau hiệu chỉnh ($p_{\text{Holm}} \geq 0{,}276$).

Nhìn chung, XBone-Net đạt hiệu năng phân loại cạnh tranh với các mô hình ngôn ngữ-thị giác tinh chỉnh toàn bộ trong khi chỉ cập nhật một phần nhỏ tham số. Tuy nhiên, phép so sánh đối chứng này không tự xác nhận vai trò riêng của quy trình hai pha hoặc chú ý chéo hai chiều; ảnh

hưởng của các thành phần được đánh giá riêng trong nghiên cứu loại bỏ thành phần.

Kết luận phân lớp trong báo cáo được giới hạn ở Accuracy, Balanced Accuracy và Macro-F1; không suy rộng thành ưu thế trên mọi độ đo hoặc mọi mô hình đối chứng.

Hiệu quả tham số, chi phí huấn luyện và suy luận

Số lượng tham số, chi phí huấn luyện và chi phí suy luận của XBone-Net so với BiomedCLIP tinh chỉnh toàn bộ được trình bày lần lượt tại Bảng 4.11, Bảng 4.12 và Bảng 4.13.

Dữ liệu	Mô hình	Tổng tham số	Tham số huấn luyện	Tỷ lệ (%)
BTXRD	BiomedCLIP tinh chỉnh toàn bộ	196.433.675	196.433.675	100,00%
	XBone-Net	204.342.539	8.439.818	4,13%
CTCH	BiomedCLIP tinh chỉnh toàn bộ	196.439.831	196.439.831	100,00%
	XBone-Net	204.348.695	8.445.974	4,13%

Bảng 4.11: Số lượng tham số khi sử dụng toàn bộ dữ liệu

Dữ liệu	Mô hình	Pha 1 (giờ GPU)	Pha 2 (giờ GPU)	Tổng (giờ GPU)	Bộ nhớ cực đại (MiB)
BTXRD	BiomedCLIP tinh chỉnh toàn bộ	–	$0{,}4647 \pm 0{,}1293$	$0{,}4647 \pm 0{,}1293$	$3.816{,}7 \pm 0{,}0$
	XBone-Net	$0{,}4080 \pm 0{,}0621$	$0{,}5194 \pm 0{,}1012$	$0{,}9274 \pm 0{,}0518$	$1.515{,}5 \pm 2{,}3$
CTCH	BiomedCLIP tinh chỉnh toàn bộ	–	$0{,}3411 \pm 0{,}0800$	$0{,}3411 \pm 0{,}0800$	$3.816{,}8 \pm 0{,}0$
	XBone-Net	$0{,}3318 \pm 0{,}0591$	$0{,}5224 \pm 0{,}0845$	$0{,}8542 \pm 0{,}0925$	$1.455{,}0 \pm 43{,}0$

Bảng 4.12: Chi phí huấn luyện, trình bày dưới dạng trung bình ± độ lệch chuẩn qua ba hạt giống. Các phép đo dùng cùng GPU NVIDIA GeForce RTX 5060 Ti, độ chính xác số học bf16 và kích thước lô 16. Giờ GPU chỉ tính thời gian thực thi các pha huấn luyện.

Dữ liệu	Mô hình	GFLOPs	Thông lượng (mẫu/giây)	Độ trễ (ms)	Bộ nhớ GPU (MiB)
BTXRD	BiomedCLIP tinh chỉnh toàn bộ	81,032	64,7	15,48	770,7
	XBone-Net	82,318	68,2	15,26	782,4
CTCH	BiomedCLIP tinh chỉnh toàn bộ	81,032	75,6	13,77	770,7
	XBone-Net	82,318	64,1	16,17	782,5

Bảng 4.13: Chi phí tính toán và tốc độ suy luận khi sử dụng toàn bộ dữ liệu

Trong huấn luyện, XBone-Net chỉ cần cập nhật khoảng 8,44 triệu tham số (chiếm khoảng 4,13% tổng số tham số), giảm 95,70% so với BiomedCLIP tinh chỉnh toàn bộ. Sau khi hợp nhất các trọng số của bộ điều hợp hạng thấp vào mạng nền, tổng số tham số khi suy luận là khoảng 199,33 triệu, chỉ cao hơn mô hình đối chứng 1,47% do giữ lại mô-đun dung hợp và đầu phân lớp.

Về tài nguyên huấn luyện, XBone-Net giảm từ 60,3% đến 61,9% bộ nhớ đồ họa cực đại (chỉ sử dụng khoảng 1.515,5 MiB trên BTXRD và 1.455,0 MiB trên CTCH). Tuy nhiên, tổng thời gian huấn luyện của mô hình cao hơn đối chứng (0,9274 giờ trên BTXRD và 0,8542 giờ trên CTCH) do thực hiện thêm pha thích nghi biểu diễn trước khi phân lớp.

Khi suy luận, XBone-Net cần khoảng 82,318 tỷ phép tính dấu phẩy động cho mỗi mẫu (tăng 1,6%) và bộ nhớ đồ họa tăng thêm khoảng 11,8 MiB. Kết quả cho thấy ưu thế của mô hình nằm ở khả năng thích nghi hiệu quả với ít tham số và bộ nhớ huấn luyện, thay vì giảm tài nguyên tính toán khi triển khai suy luận.

4.2.4 Kết luận

Thực nghiệm cho thấy XBone-Net đạt hiệu năng cao hơn các đối chứng chỉ dùng ảnh và có kết quả cạnh tranh với nhóm mô hình ngôn ngữ-thị giác tinh chỉnh toàn bộ. So sánh trực tiếp trên CTCH ghi nhận lợi ích của bệnh sử cùng quy trình huấn luyện đa phương thức trên Accuracy, Balanced Accuracy và Macro-F1, qua đó cung cấp bằng chứng định lượng liên quan đến dữ liệu mất cân bằng. Entropy chéo có trọng số hướng đến hạn chế FN ở lớp ít mẫu, còn label smoothing hướng đến hạn chế dự đoán quá tự tin, nhưng thực nghiệm hiện tại chưa chứng minh FP hoặc FN giảm ở mọi lớp. Lợi ích tài nguyên tập trung ở số tham số cần cập nhật và bộ nhớ GPU trong huấn luyện; đổi lại, mô hình cần thời gian huấn luyện dài hơn và không làm giảm chi phí suy luận. Khả năng thích ứng trước dịch chuyển miền ngoài vẫn chưa được kiểm chứng trực tiếp.

4.3 Khảo sát ảnh hưởng của các thành phần

4.3.1 Mục đích

Thực nghiệm này kiểm tra xem quy trình huấn luyện hai pha và cơ chế dung hợp bằng chú ý chéo hai chiều ảnh hưởng như thế nào đến quyết định lớp của XBone-Net. Mục tiêu là xác định ảnh hưởng quan sát được của từng lựa chọn kiến trúc trong cùng điều kiện đánh giá.

4.3.2 Nội dung

Thực nghiệm được thực hiện trên bộ dữ liệu CTCH với hai biến thể của XBone-Net, Chỉ pha 2 và Nối đặc trưng. Biến thể Chỉ pha 2 bỏ lần huấn luyện pha 1 và khởi tạo trực tiếp cho pha phân lớp. Biến thể Nối đặc trưng giữ nguyên pha 1 nhưng thay thiết lập dung hợp ở pha 2 bằng phép nối. Ngoài yếu tố được thay đổi, các cấu hình dùng chung được giữ nguyên.

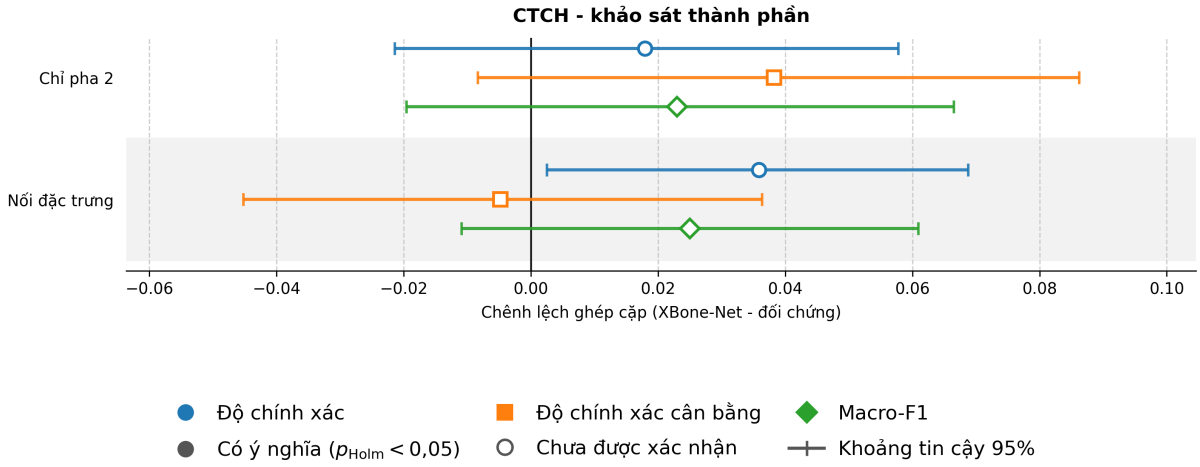
4.3.3 Kết quả

Bảng 4.14 so sánh XBone-Net với hai biến thể qua ba hạt giống trên bộ dữ liệu CTCH bằng ba độ đo quyết định lớp. XBone-Net đạt độ chính xác 0,6183 và macro-F1 0,5727, cao hơn lần lượt 0,6004 và 0,5497 của biến thể Chỉ pha 2, đồng thời cao hơn 0,5825 và 0,5477 của biến thể Nối đặc trưng. Tuy nhiên, biến thể Nối đặc trưng đạt độ chính xác cân bằng 0,5983, cao hơn mức 0,5935 của XBone-Net. Như vậy, cấu hình đầy đủ có lợi thế quan sát được về độ chính xác và macro-F1, nhưng không dẫn đầu đồng thời cả ba độ đo.

Thành phần hoặc độ đo	XBone-Net	Chỉ pha 2	Nối đặc trưng
Huấn luyện pha 1	✓		✓
Chú ý chéo hai chiều	✓	✓	
Accuracy ↑	**0,6183 ± 0,0203**	0,6004 ± 0,0085	0,5825 ± 0,0038
Balanced Accuracy ↑	0,5935 ± 0,0134	0,5552 ± 0,0341	**0,5983 ± 0,0268**
Macro-F1 ↑	**0,5727 ± 0,0193**	0,5497 ± 0,0184	0,5477 ± 0,0162

Bảng 4.14: Nghiên cứu loại bỏ từng thành phần của XBone-Net trên CTCH. Các độ đo được tính từ cùng tệp dự đoán dùng cho kiểm định ghép cặp

Để đánh giá liệu các chênh lệch này có ổn định trên cùng các mẫu kiểm thử hay không, Hình 4.5 trình bày đồng thời ba độ đo quyết định lớp trong kiểm định ghép cặp giữa từng biến thể và XBone-Net. Giá trị xác suất được tính bằng phép kiểm định hoán vị ghép cặp, sau đó được hiệu chỉnh theo phương pháp Holm trong từng độ đo cho hai phép so sánh. Để thống nhất cách đọc với hai hình trước, chênh lệch được biểu diễn bằng kết quả của XBone-Net trừ kết quả của biến thể. Điểm ở bên phải mốc 0 có lợi cho XBone-Net, còn điểm ở bên trái có lợi cho biến thể. Thanh ngang biểu diễn khoảng tin cậy 95% của từng chênh lệch, trong khi điểm đặc biểu thị khác biệt có ý nghĩa sau hiệu chỉnh Holm. Các giá trị chi tiết được trình bày tại Bảng C.5, còn các khoảng tin cậy 95% được trình bày riêng trong Bảng C.6 ở phụ lục.



Hình 4.5: Biểu đồ chênh lệch ghép cặp giữa XBone-Net và hai biến thể trên CTCH

Đối với biến thể Chỉ pha 2, kiểm định không xác nhận khác biệt có ý nghĩa thống kê ở cả ba độ đo vì các giá trị xác suất sau hiệu chỉnh Holm đều không nhỏ hơn 0,119. Vì vậy, dù XBone-Net có giá trị quan sát cao hơn ở ba độ đo trong bảng được dùng cho kiểm định, kết quả hiện tại chưa đủ bằng chứng để khẳng định pha khớp ngữ nghĩa tạo ra cải thiện ổn định trên tập kiểm thử cố định này.

Đối với biến thể Nối đặc trưng, độ chính xác quan sát được của XBone-Net cao hơn 0,0359, nhưng giá trị xác suất sau hiệu chỉnh Holm bằng 0,052 nên chưa đạt ngưỡng ý nghĩa 0,05. Chênh lệch độ chính xác cân bằng và macro-F1 cũng chưa được xác nhận, với các giá trị xác suất sau hiệu chỉnh lần lượt bằng 0,783 và 0,292.

XBone-Net đạt giá trị quan sát cao hơn về độ chính xác và macro-F1, trong khi phép nối đặc trưng đạt độ chính xác cân bằng cao hơn. Kết quả này cho thấy chú ý chéo hai chiều có thể ưu tiên quyết định lớp tổng thể, còn phép nối có thể duy trì kết quả đồng đều hơn giữa các lớp. Tuy nhiên, không chênh lệch nào trong ba độ đo được xác nhận sau hiệu chỉnh Holm, nên diễn giải về cơ chế chỉ là giả thuyết dựa trên thiết kế kiến trúc và chưa chứng minh được quan hệ nhân quả.

4.3.4 Kết luận

Thực nghiệm này cho thấy XBone-Net đạt độ chính xác và macro-F1 quan sát được cao hơn hai biến thể, nhưng kiểm định ghép cặp chưa xác nhận lợi thế này sau hiệu chỉnh đa so sánh. Việc loại bỏ pha khớp ngữ nghĩa hoặc thay chú ý chéo hai chiều bằng phép nối đặc trưng đều chưa tạo ra khác biệt có ý nghĩa thống kê trên ba độ đo quyết định lớp. Nhận định nổi bật là chưa có đủ bằng chứng để xem riêng từng thành phần là nguyên nhân trực tiếp làm tăng hiệu năng phân lớp trên phân hoạch hiện tại.

4.4 Khảo sát khả năng cảnh báo dữ liệu ngoài phân phối

4.4.1 Mục đích

Thực nghiệm này đánh giá khả năng bộ phát hiện hậu xử lý xây dựng từ không gian biểu diễn của từng mô hình phân biệt dữ liệu CTCH trong phân phối với các bệnh lý nằm ngoài không gian nhãn của CTCH.

4.4.2 Nội dung

Năm cấu hình được đánh giá gồm XBone-Net chỉ ảnh, XBone-Net, Chỉ pha 2, Nối đặc trưng và BiomedCLIP tinh chỉnh toàn bộ. Dữ liệu huấn luyện CTCH được dùng để khớp bộ chấm điểm hậu xử lý, còn dữ liệu xác thực được dùng để chuẩn hóa điểm mà không sử dụng mẫu ngoài phân phối. Bộ phát hiện của cấu hình chỉ ảnh chỉ sử dụng khoảng cách k-NN trong không gian thị giác; bốn cấu hình còn lại tổng hợp điểm chuẩn hóa của biểu diễn ảnh và văn bản. Tập đánh giá gồm 669 mẫu CTCH trong phân phối và 18 mẫu bệnh lý ngoài không gian nhãn của CTCH. Ba độ đo AUROC-OOD, AUPR-Out và FPR@95%TPR lần lượt phản ánh khả năng phân tách tổng thể, chất lượng xếp hạng khi coi mẫu ngoài phân phối là lớp dương và tỷ lệ chấp nhận nhầm tại ngưỡng đánh giá được xác định trên tập kiểm thử.

4.4.3 Kết quả

Bảng 4.15 so sánh năm cấu hình và đặt cấu hình chỉ ảnh ngay trước XBone-Net. Cấu hình chỉ ảnh đạt AUROC-OOD 0,5598, AUPR-Out 0,0350 và FPR@95%TPR 0,9815. Khi bổ sung văn bản lâm sàng, AUROC-OOD của XBone-Net tăng 0,2000 và AUPR-Out tăng 0,1123. Đồng thời, FPR@95%TPR giảm 0,3519. Kết quả cho thấy biểu diễn văn bản cung cấp tín hiệu bổ sung rõ rệt để phân biệt bệnh lý ngoài không gian nhãn trong thiết lập hậu xử lý hiện tại.

Trong các cấu hình đa phương thức, Chỉ pha 2 đạt AUROC-OOD 0,7735 và AUPR-Out 0,2197, cao nhất trong năm cấu hình. XBone-Net và BiomedCLIP tinh chỉnh toàn bộ cùng đạt FPR@95%TPR trung bình 0,6296 ở độ chính xác bốn chữ số. Tuy nhiên, FPR@95%TPR sử dụng τ_{95}^{test} được xác định lại từ tập kiểm thử nên kết quả này chỉ mô tả một điểm trên đường cong đánh giá và không phải hành vi của ngưỡng triển khai. Việc cảnh báo ca ngoài không gian nhãn có thể hạn chế tình trạng buộc một mẫu OOD vào một lớp bệnh đã biết, nhưng sai số này khác với FP của từng lớp trong bài toán phân loại ID.

Kịch bản	**Cấu hình**	**AUROC-OOD ↑**	**AUPR-Out ↑**	**FPR@95%TPR ↓**
OOD CTCH	XBone-Net (chỉ ảnh)	$0{,}5598 \pm 0{,}0610$	$0{,}0350 \pm 0{,}0008$	$0{,}9815 \pm 0{,}0321$
	XBone-Net	$0{,}7598 \pm 0{,}0219$	$0{,}1473 \pm 0{,}0094$	$\mathbf{0{,}6296 \pm 0{,}0642}$
	Chỉ pha 2	$\mathbf{0{,}7735 \pm 0{,}0349}$	$\mathbf{0{,}2197 \pm 0{,}0112}$	$0{,}6667 \pm 0{,}1111$
	Nối đặc trưng	$0{,}7186 \pm 0{,}0199$	$0{,}1055 \pm 0{,}0143$	$0{,}6481 \pm 0{,}0321$
	BiomedCLIP tinh chỉnh toàn bộ	$0{,}7572 \pm 0{,}0499$	$0{,}1495 \pm 0{,}0310$	$\mathbf{0{,}6296 \pm 0{,}1156}$

Bảng 4.15: Đánh giá cảnh báo OOD hậu xử lý trên CTCH với cấu hình có và không sử dụng bệnh sử lâm sàng

4.4.4 Kết luận

Thực nghiệm này cho thấy việc bổ sung văn bản lâm sàng cải thiện rõ rệt cả khả năng xếp hạng OOD và tỷ lệ chấp nhận nhầm so với cấu hình chỉ ảnh. Tuy nhiên, XBone-Net không dẫn đầu đồng thời trên AUROC-OOD và AUPR-Out, còn FPR@95%TPR vẫn ở mức cao ngay cả với các cấu hình tốt hơn. Vì vậy, OOD chỉ được xem là tín hiệu cảnh báo hỗ trợ chuyển ca nghi ngờ, không phải cơ chế từ chối tự động hay bằng chứng rằng mô hình đã bền vững trước mọi dạng dịch chuyển miền.

4.5 Khảo sát mức phụ thuộc của dự đoán vào ảnh và văn bản

4.5.1 Mục đích

Thực nghiệm này đánh giá mức phụ thuộc của dự đoán vào ảnh và văn bản dựa vào tích phân gradient kết hợp với can thiệp đầu vào so với các biến thể kiến trúc.

4.5.2 Nội dung

Phân tích sử dụng hạt giống 42 của XBone-Net chỉ ảnh, XBone-Net, Chỉ pha 2, Nối đặc trưng và BiomedCLIP tinh chỉnh toàn bộ trên cùng toàn bộ 669 mẫu kiểm thử CTCH mà không lọc theo dự đoán đúng hay sai. Lớp được từng mô hình dự đoán trên đầu vào đầy đủ được cố định làm lớp đích của chính mô hình đó. Tích phân gradient được xấp xỉ bằng 24 điểm nội suy từ mốc tham chiếu đến đầu vào. Mốc ảnh là tensor bằng 0 sau chuẩn hóa; mốc văn bản dùng embedding của token đệm cho các vị trí nội dung, giữ token đặc biệt và mặt nạ chú ý. Hai mốc này không đồng nhất với ảnh RGB đen hoặc chuỗi văn bản rỗng. Với cấu hình chỉ ảnh, các chỉ số IG và can thiệp văn bản không áp dụng và được ký hiệu bằng "-". Cả năm cấu hình đều sử dụng cùng một quy trình tiền xử lý ảnh, chuyển ảnh RGB gốc trực tiếp cho quy trình resize, cắt vùng trung tâm và chuẩn hóa nguyên bản của BiomedCLIP, không thêm bước đệm viền riêng.

Độ trung thực được đánh giá bằng cách loại bỏ hoặc khôi phục dần các vùng ảnh kích thước 16×16 và các đơn vị nội dung theo mức đóng góp giảm dần. Tại mỗi tỷ lệ can thiệp, kết quả được đối chiếu với trung bình của 16 thứ tự loại bỏ ngẫu nhiên. Phép can thiệp nguồn thay toàn bộ ảnh hoặc toàn bộ đơn vị nội dung bằng mốc tham chiếu tương ứng, sau đó ghi nhận mức giảm xác suất của lớp đích so với đầu vào đầy đủ. Danh sách mẫu, mốc tham chiếu và mức can thiệp được áp dụng cho cả năm cấu hình; can thiệp văn bản chỉ áp dụng cho bốn cấu hình đa phương thức, trong khi lớp đích được xác định riêng từ dự đoán của từng cấu hình.

4.5.3 Kết quả

Bảng 4.16 tổng hợp độ trung thực của tích phân gradient và mức giảm xác suất khi che từng nguồn thông tin trên toàn bộ 669 mẫu kiểm thử ở hạt giống 42. Do chỉ có một hạt giống và không có khoảng tin cậy ghép cặp giữa các cấu hình, mọi chênh lệch chỉ mang tính mô tả.

(a) Độ trung thực theo thứ tự đóng góp IG

Cấu hình	**Ảnh X-quang**		**Văn bản lâm sàng**	
	AUC khôi phục ↑	AUC loại bỏ ↓	AUC khôi phục ↑	AUC loại bỏ ↓
XBone-Net (chỉ ảnh)	0,2517	**0,1541**	–	–
XBone-Net	**0,4023**	0,2997	**0,4399**	0,2811
Chỉ pha 2	0,3880	0,2730	0,4318	0,2909
Nối đặc trưng	0,3561	0,2394	0,3519	0,2339
BiomedCLIP tinh chỉnh toàn bộ	0,3471	0,1586	0,2953	**0,2199**

(b) Can thiệp toàn bộ nguồn thông tin

Cấu hình	Mức giảm xác suất khi che ảnh Δp_{img}	Mức giảm xác suất khi che văn bản Δp_{txt}
XBone-Net (chỉ ảnh)	0,3283	–
XBone-Net	0,3187	0,2725
Chỉ pha 2	0,3203	0,2176
Nối đặc trưng	0,3164	0,2678
BiomedCLIP tinh chỉnh toàn bộ	0,3132	0,2065

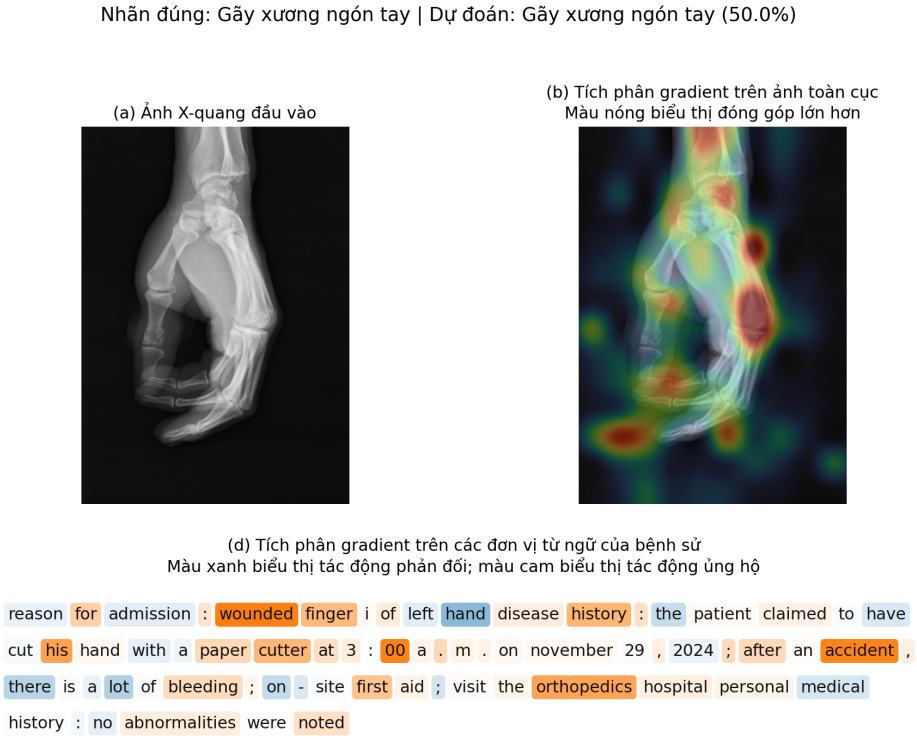
Bảng 4.16: Đánh giá tích phân gradient và can thiệp nguồn trên toàn bộ 669 mẫu kiểm thử CTCH ở hạt giống 42

Đối với văn bản lâm sàng, XBone-Net đạt AUC khôi phục cao nhất ở mức 0,4399, tiếp theo là biến thể Chỉ pha 2 ở mức 0,4318; BiomedCLIP tinh chỉnh toàn bộ đạt AUC loại bỏ thấp nhất là 0,2199. Đối với ảnh X-quang, XBone-Net đạt AUC khôi phục cao nhất với 0,4023, còn cấu hình chỉ ảnh đạt 0,2517. Ngược lại, cấu hình chỉ ảnh đạt AUC loại bỏ thấp nhất với 0,1541, thấp hơn nhẹ BiomedCLIP tinh chỉnh toàn bộ ở mức 0,1586. Kết quả cho thấy cấu hình đầy đủ khôi phục dự đoán tốt hơn khi lần lượt đưa các vùng ảnh quan trọng trở lại, trong khi cấu hình chỉ ảnh nhạy hơn theo thứ tự loại bỏ; không cấu hình nào tốt nhất ở cả hai phép đo.

Khi che toàn bộ ảnh, xác suất lớp đích của cấu hình chỉ ảnh giảm 0,3283, cao hơn mức 0,3187 của XBone-Net. Với cấu hình đầy đủ, khi thay

embedding các token nội dung của bệnh sử bằng embedding đệm, xác suất lớp đích giảm 0,2725 so với đầu vào đầy đủ, cao nhất trong bốn cấu hình có văn bản. Các giá trị này cho thấy mô hình chỉ ảnh tập trung toàn bộ sự phụ thuộc đầu vào vào kênh thị giác, còn XBone-Net phân bố sự phụ thuộc lên cả ảnh và văn bản lâm sàng. Đây là bằng chứng về mức sử dụng nguồn thông tin dưới phép can thiệp đã chọn, không phải bằng chứng rằng văn bản luôn cải thiện từng dự đoán.

Sự khác nhau giữa phép khôi phục, phép loại bỏ và phép che toàn bộ có thể xuất phát từ việc bằng chứng được phân bố trên nhiều vùng ảnh, nhiều đơn vị văn bản và các tương tác giữa hai phương thức. Khi đó, thứ tự đóng góp cục bộ không nhất thiết phản ánh giống mức phụ thuộc khi loại bỏ toàn bộ nguồn thông tin, đồng thời kết quả còn phụ thuộc vào mốc tham chiếu và tiền xử lý của từng cấu hình. Nhận định rút ra là XBone-Net sử dụng cả ảnh và văn bản theo phép che nguồn, nhưng mức phụ thuộc quan sát được không đồng nghĩa đóng góp trung thực hơn.



Hình 4.6: Tích phân gradient trên ảnh X-quang và văn bản lâm sàng của mẫu 3563. Màu nóng trên ảnh biểu thị độ lớn đóng góp. Trong văn bản, màu cam và màu xanh lần lượt biểu thị ủng hộ và phản đối lớp dự đoán.

Hình 4.6 minh họa cụ thể kết quả của XBone-Net trên mẫu 3563. Mô hình dự đoán đúng nhãn "Gãy xương ngón tay" với xác suất 50,0%. Trên ảnh X-quang, mức đóng góp lớn tập trung chủ yếu quanh bàn tay, các ngón tay và vùng cổ tay. Tuy nhiên, bản đồ vẫn ghi nhận một số vùng đóng góp nằm ngoài cấu trúc xương, vì vậy kết quả chỉ cho thấy những vị trí đầu vào làm thay đổi dự đoán và không được diễn giải như bằng chứng định vị chính xác tổn thương.

Đối với văn bản lâm sàng, các từ như *wounded*, *finger*, *cutter* và *accident* tạo tác động ủng hộ nổi bật, phù hợp với mô tả ngón tay bị thương do dao rọc giấy. Ngược lại, một số từ và mảnh số không đặc hiệu cũng nhận mức đóng góp đáng kể, cho thấy mô hình chưa chỉ dựa vào các khái niệm lâm sàng trực tiếp. Khi thay ảnh bằng tensor tham chiếu bằng 0 sau chuẩn hóa, xác suất lớp đích giảm 0,4875, còn khi thay embedding các token nội dung của bệnh sử bằng embedding đệm, xác suất giảm 0,3782. Trường hợp này minh họa rằng cả ảnh và văn bản đều tham gia đáng kể vào dự đoán đúng, trong đó ảnh có ảnh hưởng lớn hơn theo phép che nguồn đã sử dụng.

4.5.4 Kết luận

Thực nghiệm thứ tư cho thấy cấu hình chỉ ảnh chỉ phụ thuộc vào kênh thị giác, trong khi XBone-Net sử dụng đồng thời ảnh và bệnh sử dưới phép che toàn bộ nguồn. Cấu hình đầy đủ đạt AUC khôi phục ảnh cao hơn, nhưng cấu hình chỉ ảnh đạt AUC loại bỏ ảnh thấp hơn; do đó dữ liệu lâm sàng không tạo ra ưu thế nhất quán trên mọi chỉ số IG. Trên một hạt giống với toàn bộ 669 mẫu kiểm thử CTCH, kết quả chỉ cung cấp bằng chứng mô tả về mức phụ thuộc vào từng nguồn dưới các mốc tham chiếu đã chọn, chưa chứng minh đóng góp nhân quả, khả năng định vị tổn thương, tính đúng lâm sàng hoặc ưu thế giải thích ổn định.

Chương 5

Kết luận và hướng phát triển

5.1 Tổng kết

Khóa luận đã xây dựng và đánh giá XBone-Net cho bài toán phân loại ảnh X-quang xương kết hợp văn bản lâm sàng. Mô hình kế thừa BiomedCLIP, sử dụng bộ điều hợp hạng thấp (LoRA), quy trình huấn luyện hai pha và chú ý chéo hai chiều để dung hợp đặc trưng ảnh–văn bản. Đóng góp chính là một cấu hình thích nghi đa phương thức có hiệu năng phân loại cạnh tranh, đồng thời giảm số tham số cập nhật và bộ nhớ huấn luyện. Bộ cảnh báo dữ liệu ngoài phân phối (OOD) và tích phân gradient (IG) bổ sung khả năng khảo sát mẫu bất thường và mức phụ thuộc của dự đoán vào từng nguồn thông tin.

Các mục tiêu nghiên cứu đã đạt trong phạm vi thực nghiệm trên BTXRD và CTCH. Kết quả được tổng hợp qua ba hạt giống (42, 123, 456) trên cùng phân hoạch dữ liệu; riêng phân tích IG sử dụng toàn bộ 669 mẫu kiểm thử CTCH tại hạt giống 42. BTXRD dùng văn bản sinh từ siêu dữ liệu, còn CTCH dùng bệnh sử lâm sàng. Vì vậy, kết luận về vai trò bệnh sử được giới hạn ở CTCH.

5.2 Trả lời các câu hỏi nghiên cứu

Câu hỏi 1: Hiệu năng phân loại, vai trò bệnh sử và chi phí tài nguyên. XBone-Net đạt Accuracy/Macro-F1 trung bình 0,8302/0,6240 trên BTXRD và 0,6183/0,5727 trên CTCH. Mô hình vượt ResNet-50 và DenseNet-121 có ý nghĩa thống kê trên cả ba độ đo phân loại ở hai bộ dữ liệu ($p_{\text{Holm}} < 0{,}001$), nhưng chưa ghi nhận khác biệt có ý nghĩa so với BiomedCLIP tinh chỉnh toàn bộ. Trên CTCH, bổ sung bệnh sử cùng quy trình huấn luyện đa phương thức làm tăng Macro-F1 từ 0,3813 lên 0,5727, đồng thời cải thiện Accuracy và Balanced Accuracy. So sánh này chưa tách riêng tác động của văn bản khỏi quy trình huấn luyện và chưa chứng minh FP hoặc FN giảm ở mọi lớp.

Về tài nguyên, XBone-Net chỉ cập nhật khoảng 8,44 triệu tham số (4,13% tổng số tham số) và giảm hơn 60% bộ nhớ GPU cực đại khi huấn luyện so với BiomedCLIP tinh chỉnh toàn bộ. Đổi lại, thời gian huấn luyện tăng khoảng 2,0 đến 2,5 lần, còn số phép tính và bộ nhớ suy luận tăng nhẹ. Lợi ích chính là duy trì hiệu năng cạnh tranh với ít tham số cập nhật và bộ nhớ huấn luyện hơn.

Câu hỏi 2: Vai trò của quy trình hai pha và cơ chế dung hợp. Trên CTCH, cấu hình đầy đủ có Accuracy và Macro-F1 quan sát được cao hơn Chỉ pha 2 và Nối đặc trưng; riêng Nối đặc trưng có Balanced Accuracy cao hơn nhẹ (0,5983 so với 0,5935). Các chênh lệch chưa có ý nghĩa thống kê sau hiệu chỉnh Holm ($p_{\text{Holm}} \geq 0{,}05$). Do đó, thực nghiệm hiện tại chưa đủ bằng chứng xác nhận lợi ích độc lập của quy trình hai pha hoặc chú ý chéo hai chiều.

Câu hỏi 3: Khả năng cảnh báo dữ liệu ngoài phân phối. Trên 669 mẫu trong phân phối và 18 mẫu bệnh lý ngoài không gian nhãn CTCH, XBone-Net đạt AUROC-OOD 0,7598, cao hơn cấu hình chỉ ảnh (0,5598); FPR@95%TPR giảm từ 0,9815 xuống 0,6296. Kết quả ghi nhận tín hiệu bổ sung của văn bản trong thiết lập này, nhưng tỷ lệ chấp nhận nhầm mẫu OOD vẫn cao. Ngưỡng tính FPR@95%TPR được chọn trên tập kiểm thử, chưa đại diện cho ngưỡng triển khai cố định. Bộ OOD chưa đủ cơ sở để từ chối ca tự động.

Câu hỏi 4: Mức phụ thuộc của dự đoán vào ảnh và văn bản. Với XBone-Net, xác suất lớp đích giảm trung bình 0,3187 khi che ảnh và 0,2725 khi che văn bản bằng mốc tham chiếu tương ứng, cho thấy dự đoán phụ thuộc vào cả hai nguồn. So với cấu hình chỉ ảnh, XBone-Net có AUC khôi phục ảnh tốt hơn (0,4023 so với 0,2517), nhưng AUC loại bỏ ảnh kém hơn (0,2997 so với 0,1541). Như vậy, cấu hình đa phương thức chưa có ưu thế nhất quán trên các chỉ số IG. Các kết quả này mô tả độ nhạy dưới phép can thiệp đã chọn, chưa chứng minh vị trí tổn thương, quan hệ nhân quả hoặc tính đúng lâm sàng.

5.3 Hạn chế và hướng phát triển

Phạm vi kiểm chứng còn giới hạn ở một phân hoạch dữ liệu, CTCH đơn trung tâm, 18 mẫu OOD và phân tích IG tại một hạt giống. Từ các giới hạn này và những đánh đổi đã ghi nhận, nghiên cứu ưu tiên năm hướng phát triển:

1. **Mở rộng kiểm định và làm rõ đóng góp thành phần.** Đánh giá trên dữ liệu bệnh viện độc lập với mô hình và siêu tham số được giữ cố định; lặp lại thực nghiệm trên nhiều phân hoạch theo người bệnh. Bổ sung đối chứng về mục tiêu huấn luyện và chiều chú ý chéo để kiểm tra riêng vai trò của quy trình hai pha, cơ chế dung hợp và văn bản lâm sàng.

2. **Cải thiện phân loại tổn thương nhỏ và lớp hiếm.** Khảo sát ảnh đa tỷ lệ, vùng ảnh độ phân giải cao và nhiều góc chụp của cùng một ca. Kết hợp lấy mẫu cân bằng hoặc hàm mất mát cho dữ liệu đuôi dài, đánh giá bằng Precision, Recall và F1 từng lớp để xác định nhóm bệnh được cải thiện.

3. **Cải thiện cảnh báo OOD và xử lý đầu vào thiếu hoặc nhiễu.** Mở rộng tập OOD theo bệnh lý, vùng giải phẫu và chất lượng ảnh; so sánh bộ k-NN với các cách chấm điểm khác. Chọn ngưỡng trên tập xác thực và giữ cố định khi kiểm định ngoài. Đồng thời, đánh

giá thiếu văn bản, ghép sai cặp ảnh–văn bản và dữ liệu mâu thuẫn để thiết kế cơ chế dung hợp giảm ảnh hưởng của nguồn không đáng tin cậy.

4. **Kiểm chứng độ ổn định và ý nghĩa của lời giải thích.** Lặp lại IG với nhiều hạt giống, mốc tham chiếu và phép can thiệp. Khi có chú thích vùng tổn thương, đối chiếu bản đồ đóng góp với vùng bệnh lý và đánh giá độc lập bởi bác sĩ, phân biệt độ trung thực đối với mô hình với tính hợp lý lâm sàng.

5. **Giảm chi phí và đánh giá khả năng hỗ trợ thực tế.** Khảo sát huấn luyện một giai đoạn, đơn giản hóa dung hợp, chưng cất tri thức và lượng tử hóa; đo đồng thời hiệu năng, thời gian và bộ nhớ. Sau khi hoàn tất kiểm định ngoài, hiệu chỉnh xác suất và kiểm chứng ngưỡng OOD, tiến hành đánh giá tiền cứu có bác sĩ giám sát với các tiêu chí như thời gian đọc ảnh, tỷ lệ bỏ sót và số ca cần chuyển chuyên gia.

Tài liệu tham khảo

Tiếng Anh

[1] Kay Henning Brodersen et al. "The Balanced Accuracy and Its Posterior Distribution". In: *Proceedings of the 20th International Conference on Pattern Recognition (ICPR)*. IEEE, 2010, pp. 3121–3124. DOI: 10.1109/ICPR.2010.764.

[2] Alfredo Canziani, Adam Paszke, and Eugenio Culurciello. "An Analysis of Deep Neural Network Models for Practical Applications". In: *arXiv preprint arXiv:1605.07678* (2017). URL: https://arxiv.org/abs/1605.07678.

[3] Ting Chen et al. "A Simple Framework for Contrastive Learning of Visual Representations". In: *Proceedings of the 37th International Conference on Machine Learning (ICML)*. Vol. 119. Proceedings of Machine Learning Research. PMLR, 2020, pp. 1597–1607. URL: https://proceedings.mlr.press/v119/chen20j.html.

[4] Yin Cui et al. "Class-Balanced Loss Based on Effective Number of Samples". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2019, pp. 9260–9269. DOI: 10.1109/CVPR.2019.00949.

[5] deep-translator contributors. *deep-translator: A flexible tool to translate between different languages in Python*. 2020. URL: https://github.com/nidhaloff/deep-translator (visited on 08/14/2026).

[6] Jay DeYoung et al. "ERASER: A Benchmark to Evaluate Rationalized NLP Models". In: *Proceedings of the 58th Annual Meeting of the*

Association for Computational Linguistics. Association for Computational Linguistics, 2020, pp. 4443–4458. DOI: 10.18653/v1/2020.acl-main.408. URL: https://aclanthology.org/2020.acl-main.408/.

[7] Alexey Dosovitskiy et al. "An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale". In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2021. URL: https://openreview.net/forum?id=YicbFdNTTy.

[8] Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993. ISBN: 0-412-04231-2.

[9] Sedigheh Eslami, Christoph Meinel, and Gerard de Melo. "PubMedCLIP: How Much Does CLIP Benefit Visual Question Answering in the Medical Domain?" In: *Findings of the Association for Computational Linguistics: EACL 2023*. Association for Computational Linguistics, 2023, pp. 1181–1193. DOI: 10.18653/v1/2023.findings-eacl.88. URL: https://aclanthology.org/2023.findings-eacl.88/.

[10] Phillip I. Good. *Permutation, Parametric, and Bootstrap Tests of Hypotheses*. 3rd ed. Springer Series in Statistics. New York: Springer, 2005. DOI: 10.1007/b138696.

[11] Yu Gu et al. "Domain-Specific Language Model Pretraining for Biomedical Natural Language Processing". In: *ACM Transactions on Computing for Healthcare* 3.1 (2021), pp. 1–23. DOI: 10.1145/3458754.

[12] Kaiming He et al. "Deep Residual Learning for Image Recognition". In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 770–778. DOI: 10.1109/CVPR.2016.90.

[13] Kaiming He et al. "Momentum Contrast for Unsupervised Visual Representation Learning". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2020, pp. 9729–9738. URL: https://openaccess.thecvf.com/cont

ent_CVPR_2020/html/He_Momentum_Contrast_for_Unsupervised_Visual_Representation_Learning_CVPR_2020_paper.html.

[14] Dan Hendrycks and Kevin Gimpel. "A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks". In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2017. URL: https://arxiv.org/abs/1610.02136.

[15] Sture Holm. "A Simple Sequentially Rejective Multiple Test Procedure". In: *Scandinavian Journal of Statistics* 6.2 (1979), pp. 65–70. URL: https://www.jstor.org/stable/4615733.

[16] Neil Houlsby et al. "Parameter-Efficient Transfer Learning for NLP". In: *Proceedings of the 36th International Conference on Machine Learning (ICML)*. Vol. 97. Proceedings of Machine Learning Research. PMLR, 2019, pp. 2790–2799. URL: https://proceedings.mlr.press/v97/houlsby19a.html.

[17] Edward J. Hu et al. "LoRA: Low-Rank Adaptation of Large Language Models". In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2022. URL: https://openreview.net/forum?id=nZeVKeeFYf9.

[18] Gao Huang et al. "Densely Connected Convolutional Networks". In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017, pp. 2261–2269. DOI: 10.1109/CVPR.2017.243.

[19] Shih-Cheng Huang et al. "GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-Efficient Medical Image Recognition". In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.

[20] Sarthak Jain and Byron C. Wallace. "Attention Is Not Explanation". In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Association for Computational

Linguistics, 2019, pp. 3543–3556. DOI: 10.18653/v1/N19-1357. URL: https://aclanthology.org/N19-1357/.

[21] Taha Koleilat et al. "BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2025, pp. 14766–14776. DOI: 10.1109/CVPR52734.2025.01376.

[22] Zhengfeng Lai et al. "CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts". In: *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*. IEEE, 2023, pp. 2366–2372. DOI: 10.1109/iccvw60793.2023.00251.

[23] Kimin Lee et al. "A Simple Unified Framework for Detecting Out-of-Distribution Samples and Adversarial Attacks". In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 31. 2018, pp. 7167–7177. URL: https://papers.nips.cc/paper/2018/hash/abdeb6f575ac5c6676b747bca8d09cc2-Abstract.html.

[24] Brian Lester, Rami Al-Rfou, and Noah Constant. "The Power of Scale for Parameter-Efficient Prompt Tuning". In: *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2021, pp. 3045–3059. DOI: 10.18653/v1/2021.emnlp-main.243. URL: https://aclanthology.org/2021.emnlp-main.243/.

[25] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. 2023. arXiv: 2306.00890. URL: https://arxiv.org/abs/2306.00890.

[26] Chenyu Lian et al. "Less Could Be Better: Parameter-Efficient Fine-Tuning Advances Medical Vision Foundation Models". In: *arXiv preprint arXiv:2401.12215* (2024). DOI: 10.48550/arXiv.2401.12215. URL: https://arxiv.org/abs/2401.12215.

[27] Shiyu Liang, Yixuan Li, and R. Srikant. "Enhancing The Reliability of Out-of-Distribution Image Detection in Neural Networks". In: *Proceedings of the International Conference on Learning Representa-*

tions (ICLR). 2018. URL: https://openreview.net/forum?id=H1VGkIxRZ.

[28] Weitang Liu et al. "Energy-Based Out-of-Distribution Detection". In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33. 2020, pp. 21464–21475. URL: https://proceedings.neurips.cc/paper/2020/hash/f5496252609c43eb8a3d147ab9b9c006-Abstract.html.

[29] Jiasen Lu et al. "ViLBERT: Pretraining Task-Agnostic Visiolinguistic Representations for Vision-and-Language Tasks". In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 32. 2019. URL: https://proceedings.neurips.cc/paper_files/paper/2019/hash/c74d97b01eae257e44aa9d5bade97baf-Abstract.html.

[30] Xueyan Mei et al. "Artificial Intelligence–Enabled Rapid Diagnosis of Patients with COVID-19". In: *Nature Medicine* 26.8 (2020), pp. 1224–1228. DOI: 10.1038/s41591-020-0931-3.

[31] Michael Moor et al. "Med-Flamingo: A Multimodal Medical Few-Shot Learner". In: *Proceedings of the 3rd Machine Learning for Health Symposium*. Vol. 225. Proceedings of Machine Learning Research. PMLR, 2023, pp. 353–367. URL: https://proceedings.mlr.press/v225/moor23a.html.

[32] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. "Representation Learning with Contrastive Predictive Coding". In: *arXiv preprint arXiv:1807.03748* (2018). DOI: 10.48550/arXiv.1807.03748. URL: https://arxiv.org/abs/1807.03748.

[33] OpenAI. *GPT-4o System Card*. 2024. URL: https://openai.com/index/gpt-4o-system-card/ (visited on 08/01/2026).

[34] Vitali Petsiuk, Abir Das, and Kate Saenko. "RISE: Randomized Input Sampling for Explanation of Black-Box Models". In: *Proceedings of the British Machine Vision Conference (BMVC)*. BMVA Press, 2018, p. 151. URL: https://bmva-archive.org.uk/bmvc/2018/contents/papers/1064.pdf.

[35] Jiuming Qin et al. “Freeze the Backbones: A Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.

[36] Alec Radford et al. “Learning Transferable Visual Models From Natural Language Supervision”. In: *Proceedings of the 38th International Conference on Machine Learning (ICML)*. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 8748–8763. URL: https://proceedings.mlr.press/v139/radford21a.html.

[37] Vijay Janapa Reddi et al. “MLPerf Inference Benchmark”. In: *Proceedings of the 2020 ACM/IEEE 47th Annual International Symposium on Computer Architecture (ISCA)*. IEEE, 2020, pp. 446–459. DOI: 10.1109/ISCA45697.2020.00045.

[38] Nils Reimers and Iryna Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, Nov. 2019. URL: http://arxiv.org/abs/1908.10084.

[39] Bryan C. Russell et al. “LabelMe: A Database and Web-Based Tool for Image Annotation”. In: *International Journal of Computer Vision* 77.1–3 (2008), pp. 157–173. DOI: 10.1007/s11263-007-0090-8.

[40] Jake Snell, Kevin Swersky, and Richard S. Zemel. “Prototypical Networks for Few-Shot Learning”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30. 2017, pp. 4077–4087. URL: https://papers.nips.cc/paper_files/paper/2017/hash/cb8da6767461f2812ae4290eac7cbc42-Abstract.html.

[41] Yiyou Sun et al. “Out-of-Distribution Detection with Deep Nearest Neighbors”. In: *Proceedings of the 39th International Conference on Machine Learning (ICML)*. Vol. 162. Proceedings of Machine Learning Research. PMLR, 2022, pp. 20827–20840. URL: https://proceedings.mlr.press/v162/sun22d.html.

[42] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. "Axiomatic Attribution for Deep Networks". In: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. Vol. 70. Proceedings of Machine Learning Research. PMLR, 2017, pp. 3319–3328. URL: https://proceedings.mlr.press/v70/sundararajan17a.html.

[43] Tao Tu et al. "Towards Generalist Biomedical AI". In: *NEJM AI* 1.3, AIoa2300138 (2024). DOI: 10.1056/AIoa2300138.

[44] Ashish Vaswani et al. "Attention Is All You Need". In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017, pp. 5998–6008. URL: https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.

[45] Xiaosong Wang et al. "TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays". In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018, pp. 9049–9058. DOI: 10.1109/cvpr.2018.00943.

[46] Zifeng Wang et al. "MedCLIP: Contrastive Learning from Unpaired Medical Images and Text". In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256.

[47] Yandong Wen et al. "A Discriminative Feature Learning Approach for Deep Face Recognition". In: *Proceedings of the European Conference on Computer Vision (ECCV)*. Springer, 2016, pp. 499–515. DOI: 10.1007/978-3-319-46478-7_31.

[48] Sarah Wiegreffe and Yuval Pinter. "Attention Is Not Not Explanation". In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. Association for Computational Linguistics, 2019, pp. 11–20. DOI: 10.18653/v1/D19-1002. URL: https://aclanthology.org/D19-1002/.

[49] Shunhan Yao et al. "A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors". In: *Scientific Data* 12.1 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y.

[50] Jiajin Zhang et al. "Disease-Informed Adaptation of Vision-Language Models". In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. 15011. Lecture Notes in Computer Science. Springer Nature Switzerland, 2024, pp. 232–242. DOI: 10.1007/978-3-031-72120-5_22.

[51] Sheng Zhang et al. "A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs". In: *NEJM AI* 2.1, AIoa2400640 (2025). DOI: 10.1056/AIoa2400640.

[52] Yuhao Zhang et al. "Contrastive Learning of Medical Visual Representations from Paired Images and Text". In: *Proceedings of the 7th Machine Learning for Healthcare Conference*. Vol. 182. Proceedings of Machine Learning Research. PMLR, 2022, pp. 2–25. URL: https://proceedings.mlr.press/v182/zhang22a.html.

[53] Hong-Yu Zhou et al. "A Transformer-Based Representation-Learning Model with Unified Processing of Multimodal Input for Clinical Diagnostics". In: *Nature Biomedical Engineering* 7.6 (2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x.

Phụ lục A

Chi tiết về bộ dữ liệu

Phụ lục này bổ sung các thông tin kỹ thuật cần thiết để tái lập quá trình chuẩn bị hai bộ dữ liệu BTXRD và CTCH. Nội dung của mỗi bộ dữ liệu được tổ chức theo cấu trúc dữ liệu, cách xây dựng nguồn văn bản sử dụng trong thực nghiệm đối với bộ dữ liệu BTXRD và cách sàng lọc dữ liệu đối với bộ dữ liệu CTCH. Các thống kê được tính trực tiếp từ phiên bản dữ liệu mà mã nguồn hiện tại sử dụng.

A.1 Bộ dữ liệu BTXRD

Phần này trình bày cấu trúc dữ liệu, đặc điểm kỹ thuật của ảnh và phương pháp xây dựng văn bản dạng lâm sàng tổng hợp cho BTXRD. Ảnh và siêu dữ liệu thuộc phiên bản BTXRD được sử dụng trong nghiên cứu riêng văn bản tổng hợp được sinh ngoại tuyến và cố định trước khi huấn luyện. Nội dung này tập trung vào cách sinh nguồn dữ liệu giả lâm sàng.

A.1.1 Cấu trúc lưu trữ và đặc điểm kỹ thuật

Bảng A.1 mô tả các thành phần liên quan đến phạm vi phân loại của nghiên cứu. Định danh ảnh là khóa liên kết một-một giữa siêu dữ liệu, nhãn, tập chia, ảnh và văn bản tổng hợp.

Thành phần	Số tệp	Vai trò
`images/`	3.746	Lưu ảnh X-quang đầu vào.
`Annotations/`	1.867	Lưu chú thích JSON cho các ảnh có u, nhưng không được sử dụng trong huấn luyện phân loại.
`reports/`	3.746	Mỗi ảnh có một văn bản dạng lâm sàng được sinh ngoại tuyến từ siêu dữ liệu.
`dataset.csv`	3.746	Siêu dữ liệu gốc, gồm định danh ảnh, nguồn thu thập, tuổi, giới tính, vị trí giải phẫu, tư thế chụp và các cờ nhóm bệnh.
`btxrd-labels.csv`	3.746	Chứa định danh ảnh và 10 cột chỉ báo lớp.
`btxrd-split.csv`	3.746	Ánh xạ mỗi ảnh vào `train`, `validate` hoặc `test`.

Bảng A.1: Cấu trúc lưu trữ của bộ dữ liệu BTXRD trong nghiên cứu

Bảng A.2 cho thấy dữ liệu ảnh có định dạng không hoàn toàn đồng nhất. Mặc dù tất cả tên tệp đều mang định dạng JPEG, kiểm tra nội dung tệp xác định 3.744 ảnh được mã hóa JPEG, một ảnh được mã hóa BMP và một ảnh được nhận diện là MPO. Toàn bộ 3.746 ảnh vẫn giải mã thành công. Khi nạp dữ liệu, mỗi ảnh được chuyển sang RGB trước khi tạo tensor, do đó ảnh thang xám và ảnh ba kênh đều tạo đầu vào ba kênh cho mô hình.

Thuộc tính	Kết quả kiểm tra
Phần mở rộng	3.719 tệp `.jpeg` và 27 tệp `.jpg`.
Chế độ màu khi giải mã	2.895 ảnh thang xám `L` và 851 ảnh `RGB`.
Định dạng mã hóa	3.744 JPEG, 1 BMP và 1 MPO.
Chiều rộng	Nhỏ nhất 153 px, trung vị 1.612 px, lớn nhất 3.594 px.
Chiều cao	Nhỏ nhất 311 px, trung vị 2.256 px, lớn nhất 4.881 px.
Khả năng giải mã	3.746/3.746 tệp được đọc thành công.

Bảng A.2: Đặc điểm kỹ thuật của các tệp ảnh BTXRD

A.1.2 Phương pháp tạo dữ liệu giả lâm sàng

BTXRD không cung cấp bệnh sử tự do tương ứng với từng ảnh. Để mô phỏng đầu vào văn bản của một hệ thống đa phương thức, nghiên cứu xây dựng một văn bản dạng lâm sàng cho mỗi mẫu bằng quy trình dựa trên luật và ngân hàng mẫu câu. Mục tiêu của quy trình là tạo một cấu trúc đầu vào thống nhất, không phải khôi phục bệnh sử thật của người bệnh.

Thông tin đầu vào và luật điều kiện

Các trường được lấy trực tiếp từ siêu dữ liệu gồm tuổi, giới tính, vị trí xương, vị trí khớp, vùng giải phẫu và tư thế chụp. Vị trí chính được chọn theo thứ tự ưu tiên xương, khớp, vùng giải phẫu nếu không có trường vị trí cụ thể, một mô tả tổng quát về xương sẽ được sử dụng. Tuổi được chia thành bốn nhóm gồm dưới 20 tuổi, 20-34 tuổi, 35-49 tuổi và từ 50 tuổi trở lên để lựa chọn ngữ cảnh tiền sử phù hợp.

Ngân hàng mẫu câu được chia thành ba nhóm hành vi. Mẫu không có cờ u được gán nhóm "không u" còn mẫu có cờ u và cờ ác tính được gán nhóm "ác tính" và các mẫu có u còn lại được gán nhóm "lành tính". Theo luật này, dữ liệu gồm 1.879 mẫu không u, 1.525 mẫu có u nhưng không mang cờ ác tính và 342 mẫu ác tính. Nhóm này quyết định tập mẫu câu dùng cho lý do vào viện, diễn tiến bệnh và khám thực thể. Ngoài ra, 182 mẫu có nhiều hơn một xương được đánh dấu và 61 mẫu có khớp liên quan thì được nối thêm một câu mô tả bối cảnh nhiều vị trí hoặc hạn chế vận động quanh khớp.

Ghép văn bản và cố định dữ liệu

Các lựa chọn ngẫu nhiên sử dụng phân phối đều trên từng ngân hàng câu và hạt giống 42. Ngân hàng mẫu câu ban đầu được sinh từ tên bệnh bằng ChatGPT-4o [33], tham chiếu cấu trúc các trường bệnh sử của CTCH để mô phỏng cách trình bày. Danh sách khoảng thời gian có 10 lựa chọn. Số mẫu câu lý do vào viện của ba nhóm không u/lành tính/ác tính lần lượt là 6/7/6, số mẫu diễn tiến bệnh là 6/8/8 và số mẫu khám thực thể là 4/7/7. Ngân hàng tiền sử chung có 9 câu, mỗi nhóm tuổi có 3 câu ngữ cảnh, còn hai ngân hàng bổ sung nhiều xương và quanh khớp đều có 5 câu. Sau bước biên soạn ngân hàng, quy trình chọn và ghép văn bản không gọi mô hình ngôn ngữ và không có bước xác nhận nội dung bởi bác sĩ.

Với thứ tự hàng siêu dữ liệu được giữ cố định, mỗi lần chạy quy trình tạo ra cùng một lựa chọn mẫu câu. Văn bản được ghép theo thứ tự: thông tin người bệnh, lý do vào viện, diễn tiến bệnh, khám thực thể, tiền sử bản thân và thông tin thu nhận ảnh.

Bảng A.3 liệt kê các mẫu câu đại diện cho từng ngân hàng. Các mẫu được giữ nguyên bằng tiếng Anh vì đây là ngôn ngữ của đầu vào văn bản BTXRD trong thí nghiệm với các ký hiệu "location", "duration" và "joint" lần lượt được thay bằng vị trí chính, khoảng thời gian được chọn và khớp liên quan.

Ngân hàng	**Mẫu câu đại diện**
Khoảng thời gian	*2 weeks*; *1 month*; *3 months*; *6 months*; *several weeks*; *a few months*; *2 months*; *4 weeks*; *several months*; *1 year*.
Lý do vào viện	Không u: *Pain in the {location}.* Lành tính: *Swelling of the {location}.* Ác tính: *Persistent pain in the {location}.*
Diễn tiến bệnh	Không u: *Onset {duration} ago; mild symptoms.* Lành tính: *The patient noticed swelling in the {location} {duration} ago.* Ác tính: *Pain and swelling in the {location} for {duration}; progressively worsening.*
Khám thực thể	Không u: *No tenderness or swelling on palpation.* Lành tính: *Palpable firm mass; non-tender; no skin changes.* Ác tính: *Firm, tender mass on the {location}; local warmth noted.*
Bổ sung nhiều xương	*Multiple bony prominences palpated at several sites* hoặc *Multiple hard masses involving several bones on examination.*
Bổ sung quanh khớp	*Joint involvement noted; restricted range of motion at the {joint}* hoặc *Soft tissue swelling observed around the {joint}.*
Tiền sử chung	*No significant medical history*, *No prior bone disease or fracture* hoặc *No relevant prior medical or surgical history.*
Ngữ cảnh theo tuổi	Dưới 20 tuổi: *Growth and development appropriate for age.* Từ 20–34 tuổi: *No prior bone lesions.* Từ 35–49 tuổi: *No relevant surgical or medical history.* Từ 50 tuổi trở lên: *History of age-related degenerative changes; no prior bone lesions.*

Bảng A.3: Các mẫu câu đại diện trong ngân hàng văn bản giả lâm sàng BTXRD

Quy trình không chèn trực tiếp tên của 10 lớp đích vào văn bản. Tuy nhiên, cờ có u và cờ ác tính tham gia trực tiếp vào việc chọn ngân hàng mẫu câu, vì vậy nội dung tổng hợp vẫn mang tín hiệu liên hệ mạnh với nhãn. Các triệu chứng, thời gian mắc bệnh, dấu hiệu khám và tiền sử được chọn từ mẫu câu là dữ liệu giả lập, không phải lời khai của người bệnh hoặc ghi nhận của nhân viên y tế. Do đó, kết quả liên quan đến văn bản BTXRD chỉ phản ánh thiết lập giả lâm sàng có điều kiện này và không được diễn giải tương đương với bệnh sử tự nhiên của CTCH.

Kiểm chứng liên kết và khả năng tái lập

Để kiểm tra văn bản đã được ghép đúng với hàng siêu dữ liệu, bộ sinh được phát lại từ đầu trên toàn bộ `dataset.csv` với hạt giống 42 và giữ nguyên thứ tự 3.746 hàng. Văn bản tái tạo của mỗi hàng được so sánh từng ký tự với tệp có cùng định danh ảnh trong `reports/`. Cách kiểm tra tuần tự này là cần thiết vì lựa chọn mẫu câu của một hàng phụ thuộc vào trạng thái bộ sinh giả ngẫu nhiên sau các hàng đứng trước. Việc gọi hàm sinh riêng lẻ cho một mẫu không bảo toàn trạng thái đó. Ngoài liên kết văn bản, phép kiểm tra còn đối chiếu nhãn với siêu dữ liệu nguồn và xác nhận quy mô ba tập chia. Kết quả được trình bày trong Bảng A.4.

Phép kiểm tra	**Kết quả**
Định danh duy nhất trong siêu dữ liệu, nhãn và tập chia	3.746/3.746 (100%)
Nhãn có đúng một lớp trong 10 lớp	3.746/3.746 (100%)
Nhãn khớp với các cờ lớp trong `dataset.csv`	3.746/3.746 (100%)
Quy mô `train/validate/test`	2.621/375/750
Hàng siêu dữ liệu có văn bản cùng định danh	3.746/3.746 (100%)
Văn bản khớp chính xác khi phát lại bộ sinh	3.746/3.746 (100%)
Tệp thiếu/tệp dư so với `dataset.csv`	0/0
Văn bản có đủ sáu trường cấu trúc	3.746/3.746 (100%)
Văn bản duy nhất	3.745/3.746 (99,97%)
Độ dài trung bình	$57{,}70 \pm 6{,}66$ từ
Trung vị và miền độ dài	56 từ, với miền 44–91 từ
Thiếu tuổi, giới tính, vị trí hoặc tư thế chụp	0 mẫu
Xuất hiện trực tiếp tên bệnh đích trong danh sách kiểm tra	0/3.746

Bảng A.4: Kết quả kiểm chứng tính toàn vẹn của dữ liệu BTXRD

Hai mẫu `IMG002607.jpeg` và `IMG003588.jpeg` tạo cùng một văn bản, giải thích vì sao số văn bản duy nhất thấp hơn tổng số mẫu một đơn vị. Kiểm tra từ khóa không phát hiện sự xuất hiện trực tiếp của các tên bệnh đích như *osteochondroma*, *osteosarcoma*, *simple bone cyst* hoặc *giant cell tumor*. Phép kiểm tra này xác nhận bộ sinh không chèn trực tiếp các tên bệnh được rà soát, nhưng không tự loại trừ tín hiệu nhãn gián tiếp. Trong phiên bản dữ liệu hiện tại, cả 3.746 hàng đều là nhãn một-nóng. Mẫu `IMG001276.jpeg` chỉ mang nhãn cụ thể *synovial osteochondroma* và không còn đồng thời mang nhãn cha *osteochondroma*.

Kiểm tra rò rỉ nhãn trực tiếp và gián tiếp

Quy trình được thực hiện trên toàn bộ 3.746 cặp văn bản–nhãn theo các bước sau:

1. **Kiểm tra trực tiếp:** chuẩn hóa chữ hoa–chữ thường và rà soát mỗi báo cáo để tìm sự xuất hiện nguyên văn của tên bệnh đích cùng các biến thể tên đã định nghĩa trước.

2. **Tạo câu nhắc lớp:** tạo một câu nhắc theo cùng mẫu *Clinical history associated with [disease label]* cho từng lớp trong 10 lớp bệnh.

3. **Mã hóa ngữ nghĩa:** mã hóa báo cáo và các câu nhắc lớp bằng bộ mã hóa văn bản BiomedCLIP, sau đó chuẩn hóa embedding và tính độ tương đồng cosin giữa mỗi báo cáo với cả 10 câu nhắc.

4. **Tính cosine margin:** với mẫu i có nhãn đúng y_i, tính

$$m_i = \cos(r_i, p_{y_i}) - \max_{c \neq y_i} \cos(r_i, p_c), \tag{A.1}$$

   trong đó r_i là embedding của báo cáo và p_c là embedding câu nhắc lớp c. Margin dương nghĩa là câu nhắc đúng nhãn gần báo cáo nhất, còn margin âm nghĩa là có ít nhất một câu nhắc nhãn khác gần hơn.

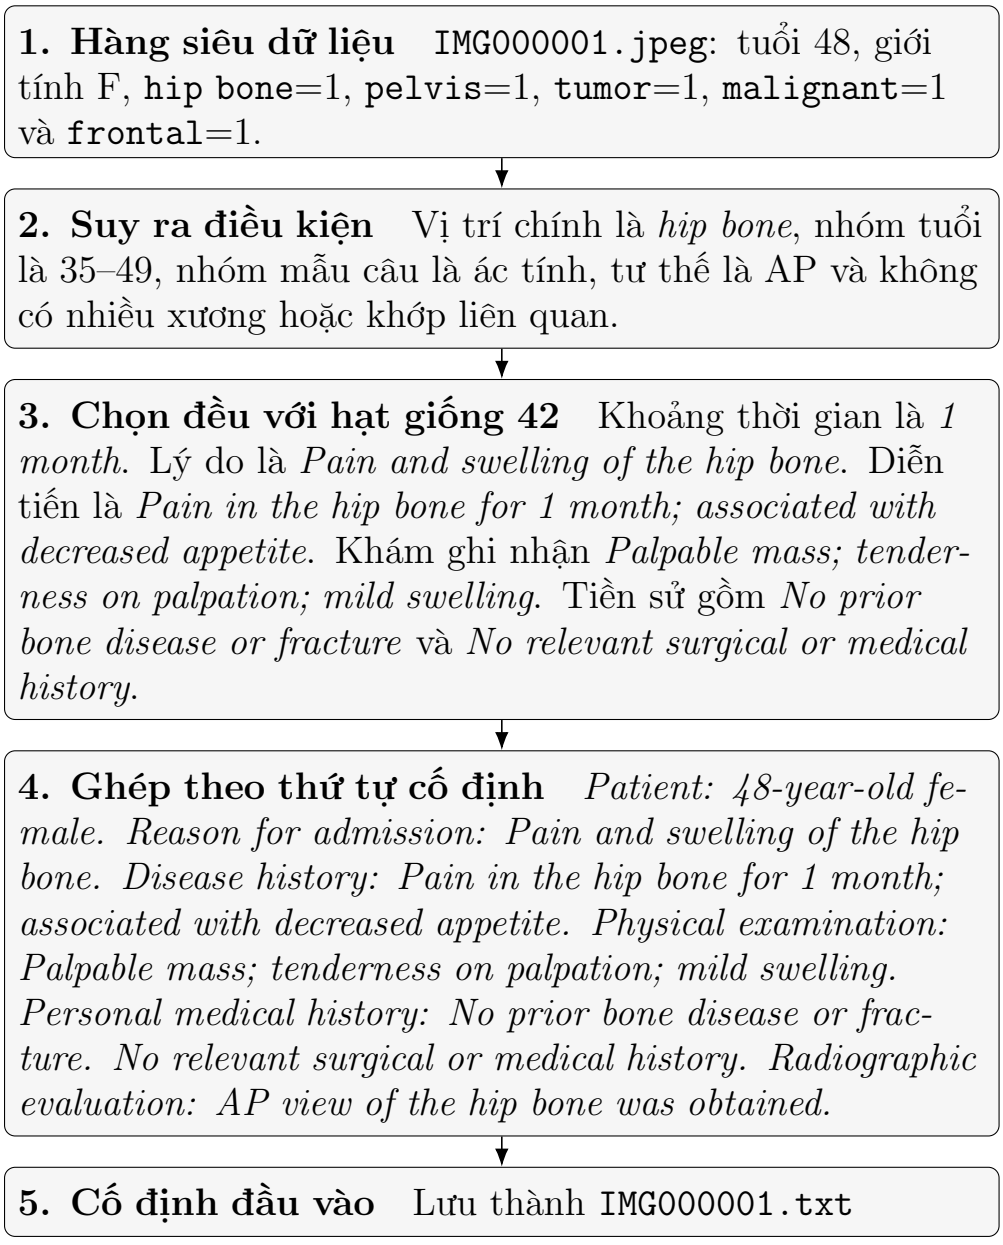
5. **Tổng hợp:** lấy trung bình m_i trên toàn bộ tập dữ liệu để đánh giá liệu tên bệnh đúng có thể được truy hồi ổn định từ nội dung văn bản hay không.

Bảng A.5 chỉ giữ hai kết quả có diễn giải trực tiếp đối với nguy cơ rò rỉ nhãn, còn các kết quả trung gian được lược bỏ để tránh gây nhầm lẫn.

Phép kiểm tra	**Kết quả**
Báo cáo chứa trực tiếp tên bệnh đích trong danh sách rà soát	0/3.746
Cosine margin trung bình giữa đúng nhãn và nhãn khác gần nhất	−0,0400

Bảng A.5: Kiểm tra nguy cơ rò rỉ nhãn trực tiếp và gián tiếp trong văn bản BTXRD

Không phát hiện trường hợp tên bệnh đích xuất hiện trực tiếp trong văn bản. Cosine margin trung bình bằng −0,0400, tức là độ tương đồng với đúng nhãn thấp hơn nhãn khác gần nhất trung bình 0,04 đơn vị cosin. Vì vậy, phép kiểm tra không cho thấy tên bệnh cụ thể có thể được suy ra trực tiếp và ổn định từ báo cáo tổng hợp. Kết quả này chỉ đánh giá nguy cơ lộ tên nhãn và không đánh giá tính đúng đắn lâm sàng hay hình thái của nội dung văn bản.



Hình A.1: Quá trình tạo văn bản minh họa cho mẫu IMG000001.jpeg

A.2 Bộ dữ liệu CTCH

Phụ lục này mô tả quy trình chuẩn bị CTCH nhằm hỗ trợ tái lập và đánh giá tính hợp lệ của dữ liệu. Nội dung tập trung vào tiêu chí lựa chọn mẫu, cách hình thành nhãn, nguyên tắc chia tập, nguồn gốc văn bản và các phép kiểm tra toàn vẹn.

Sàng lọc và xác định quần thể nghiên cứu

Quần thể đích của bộ dữ liệu CTCH gồm các bệnh nhân được chụp X-quang xương khớp nhằm hỗ trợ chẩn đoán bệnh lý hoặc chấn thương xương. Quần thể tiếp cận bao gồm các bệnh nhân có bệnh án và dữ liệu hình ảnh được thu thập tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.

Dữ liệu ban đầu gồm 12.949 bệnh án. Tuy nhiên, các hồ sơ này chưa thể được sử dụng trực tiếp vì có sự khác biệt về loại dữ liệu cận lâm sàng, thời điểm thăm khám, tình trạng điều trị và mức độ phù hợp của nhãn. Quy trình sàng lọc được thực hiện tuần tự nhằm hình thành quần thể có ảnh X-quang, bệnh sử và nhãn phù hợp với phạm vi phân loại của nghiên cứu. Số lượng hồ sơ còn lại sau từng bước được trình bày trong Hình A.2.



Hình A.2: Quy trình sàng lọc hồ sơ cho bộ dữ liệu CTCH

A.2.1 Cấu trúc dữ liệu và đặc điểm kỹ thuật

Bảng A.6 mô tả các thành phần liên quan đến phạm vi phân loại của nghiên cứu. Định danh ảnh là khóa liên kết một-một giữa siêu dữ liệu, nhãn, tập chia, ảnh và bệnh sử lâm sàng.

Thành phần	**Số lượng sử dụng**	**Vai trò**
`images/`	3.267	Lưu ảnh X-quang đầu vào được liên kết bởi manifest.
`reports/`	3.267 cặp song ngữ (6.534 tệp)	Mỗi ảnh được chọn có một bệnh sử lâm sàng tiếng Việt và một bản tiếng Anh tương ứng.
`ctch-labels.csv`	3.249	Chứa định danh ảnh và 22 cột chỉ báo lớp.
`ctch-ood.csv`	18	Chứa định danh và thông tin các mẫu ngoài phân phối.
`ctch-split.csv`	3.249	Ánh xạ mỗi ảnh vào `train`, `validate` hoặc `test`.

Bảng A.6: Cấu trúc lưu trữ của bộ dữ liệu CTCH trong nghiên cứu

Bảng A.7 cho thấy dữ liệu ảnh có định dạng đồng nhất. Toàn bộ 3.267 tệp lưu trữ đều có phần mở rộng JPEG và được mã hóa chuẩn JPEG với toàn bộ 3.267 ảnh giải mã thành công. Khi nạp dữ liệu, mỗi ảnh được chuyển sang RGB trước khi tạo tensor, bảo đảm đầu vào ba kênh cho mô hình.

Thuộc tính	**Kết quả kiểm tra**
Phần mở rộng	3.267 tệp `.jpg`.
Chế độ màu khi giải mã	3.267 ảnh `RGB`.
Định dạng mã hóa	3.267 JPEG.
Chiều rộng	Nhỏ nhất 1.186 px, trung vị 1.213 px, lớn nhất 2.836 px.
Chiều cao	Nhỏ nhất 1.213 px, trung vị 1.713 px, lớn nhất 2.880 px.
Khả năng giải mã	3.267/3.267 tệp được đọc thành công.

Bảng A.7: Đặc điểm kỹ thuật của các tệp ảnh CTCH

Dữ liệu nguồn gồm 3.641 hồ sơ đã được lựa chọn sơ bộ từ các ca khám tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh. Mỗi hồ sơ liên kết thông tin bệnh án với một ảnh đại diện cho vị trí cần khảo sát. Quá trình sàng lọc tiếp tục loại những ca có nẹp, đinh hoặc phương tiện kết hợp xương vì các cấu trúc này có thể che khuất tổn thương và tạo dấu hiệu thị giác ngoài mục tiêu phân loại.

Hiện tại 374 hồ sơ có dụng cụ y tế bị loại nhằm đảm bảo phạm vi nghiên cứu, đồng thời giúp đảm bảo chất lượng dữ liệu đầu vào là đồng

nhất. Phần còn lại gồm 3.267 mẫu, được tách thành 3.249 mẫu trong phân phối phục vụ phân loại và 18 mẫu ngoài phân phối về ngữ nghĩa. Hai quần thể không giao nhau theo ảnh hoặc theo mã nhóm người bệnh.

Giai đoạn	**Số hồ sơ**
Hồ sơ nguồn	3.641
Loại do có dụng cụ y tế	374
Còn lại sau sàng lọc	3.267
Quần thể trong phân phối	3.249
Quần thể ngoài phân phối	18

Bảng A.8: Dòng dữ liệu qua các bước sàng lọc CTCH

Quần thể ngoài phân phối gồm 6 mẫu thuộc nhóm chấn thương, 7 mẫu thuộc nhóm viêm nhiễm và 5 mẫu thuộc nhóm u xương, nhưng biểu hiện cụ thể không thuộc 22 lớp đích. Cách tổ chức này tạo một kịch bản ngoài dữ liệu trong cùng nguồn bệnh viện, qua đó giảm mức trộn lẫn giữa sai lệch ngữ nghĩa với thay đổi thiết bị hoặc cơ sở thu nhận. Tuy nhiên, số lượng 18 mẫu còn nhỏ nên khoảng bất định của các độ đo ngoài phân phối cần được trình bày và kết quả không nên được khái quát thành mọi dạng bất thường lâm sàng.

Nguồn văn bản và kiểm soát rò rỉ nhãn

Văn bản đầu vào CTCH được tạo ngoại tuyến từ ba trường có sẵn trước kết luận chẩn đoán cuối cùng gồm lý do vào viện, diễn tiến bệnh và tiền sử. Các trường kết quả khảo sát hình ảnh, chẩn đoán chuyên môn và nhãn phân lớp không được nối vào chuỗi văn bản đầu vào như thể hiện trong Bảng A.9. Chẩn đoán chuyên môn chỉ được sử dụng trong quá trình chuẩn hóa và dùng làm nhãn đích, còn nhãn phân loại chỉ tham gia kiểm tra và xác minh nhãn.

Trường dữ liệu nguồn	Dùng làm đầu vào	Vai trò trong nghiên cứu
Lý do vào viện	Có	Cung cấp triệu chứng hoặc vấn đề chính được ghi nhận khi tiếp nhận.
Diễn tiến bệnh	Có	Cung cấp cơ chế, thời điểm và diễn biến trước khi hình thành kết luận chẩn đoán.
Tiền sử	Có	Cung cấp thông tin bệnh lý, phẫu thuật hoặc điều trị trước đó khi trường này có dữ liệu.
Kết quả khảo sát hình ảnh	Không	Bị loại khỏi chuỗi đầu vào vì có thể chứa mô tả trực tiếp dấu hiệu trên phim.
Chẩn đoán chuyên môn	Không	Chỉ dùng để chuẩn hóa, ánh xạ và dùng làm nhãn phân loại chính, nhưng không được mã hóa bởi nhánh văn bản.
Nhãn phân lớp	Không	Dùng để kiểm tra và xác minh nhãn.

Bảng A.9: Vai trò của các trường bệnh án CTCH và nguyên tắc loại thông tin có nguy cơ rò rỉ nhãn

Trong bước tạo thư mục `reports/`, ba trường được giữ lại được làm sạch và ghép theo thứ tự cố định, trong đó không có tên lớp, kết quả đọc ảnh hoặc chẩn đoán được bổ sung từ tệp nhãn. Việc chia tập được thực hiện theo mã người bệnh trước khi huấn luyện, còn mã liên kết không được đưa vào văn bản hoặc mô hình. Cách tổ chức này loại rò rỉ trực tiếp từ các cột chẩn đoán, nhưng không loại bỏ khả năng bệnh sử chứa những triệu chứng hoặc vị trí giải phẫu có tính dự báo cao. Vì vậy, khóa luận vẫn báo cáo đối chứng chỉ văn bản và phép ghép sai để khảo sát mức phụ thuộc vào nguồn này.

Công cụ dịch tiếng Anh. Bệnh sử tiếng Anh được tạo ngoại tuyến từ bản tiếng Việt bằng gói `deep-translator` phiên bản 1.11.4 với lớp `GoogleTranslator`, thiết lập ngôn ngữ nguồn là tiếng Việt (`vi`) và ngôn ngữ đích là tiếng Anh (`en`) [5]. Nội dung của từng trường được dịch riêng, trong khi tên trường, thứ tự trường và định danh liên kết với ảnh được giữ nguyên. Các đoạn tiếng Việt đã dịch được lưu trong một tệp bộ nhớ đệm JSON, do đó khi một đoạn xuất hiện lại, quy trình tái sử dụng đúng bản dịch đã lưu thay vì gửi một yêu cầu mới. Cơ chế này làm cho các câu lặp lại nhận cùng một bản dịch và hỗ trợ tái lập dữ liệu đã tạo.

Đánh giá độ tương đồng ngữ nghĩa của bản dịch. Chất lượng bản dịch được sàng lọc tự động bằng mô hình MiniLM đa ngôn ngữ `paraphrase-multilingual-MiniLM-L12-v2` [38]. Phép đánh giá chỉ chạy trên 3.267 ảnh còn lại sau sàng lọc và có tệp ảnh hợp lệ, không chạy trên các tệp vật lý ngoài manifest. Với mỗi trường có nội dung ở cả hai ngôn ngữ, câu tiếng Việt và câu tiếng Anh được mã hóa riêng với độ dài tối đa 256 token. Vector câu được tạo bằng trung bình có mặt nạ trên các token hợp lệ, sau đó chuẩn hóa theo chuẩn L_2 và tính cosine similarity giữa hai ngôn ngữ. Điểm càng gần 1 biểu thị hai biểu diễn càng gần nhau về ngữ nghĩa. Ngưỡng 0,70 chỉ được dùng để gắn cờ các cặp cần rà soát, không được xem là tiêu chuẩn tuyệt đối về tính đúng đắn y khoa.

Trung bình phản ánh mức điểm chung nhưng nhạy với phần đuôi điểm thấp, còn trung vị mô tả vị trí trung tâm bền vững hơn trước các trường hợp ngoại lệ. Bảng A.10 báo cáo cả hai đại lượng trên 9.464 cặp trường song ngữ được liên kết.

Trường bệnh sử	**Số cặp**	**Trung bình**	**Trung vị**	**Dưới 0,70**
Lý do vào viện	3.267	0,7264	0,7767	1.083 (33,15%)
Diễn tiến bệnh	3.267	0,7462	0,7747	839 (25,68%)
Tiền sử cá nhân	2.930	0,5330	0,4737	2.474 (84,44%)
Toàn bộ	9.464	0,6733	0,7234	4.396 (46,45%)

Bảng A.10: Độ tương đồng ngữ nghĩa giữa bệnh sử tiếng Việt và bản dịch tiếng Anh của CTCH

Ở hai trường cốt lõi, điểm trung bình đạt 0,7264–0,7462 và trung vị đạt 0,7747–0,7767. Các đại lượng trung tâm gần nhau và trung vị xấp xỉ 0,78 cho thấy phần trung tâm của phân bố tương đồng tương đối ổn định. Điểm tiền sử thấp hơn vì trường này có nhiều câu rất ngắn và 1.980 trường hợp thuộc ba biến thể của phát biểu "chưa phát hiện/chưa ghi nhận bất thường". Bản dịch đúng ý nghĩa nhưng chỉ nhận cosine similarity khoảng 0,41–0,47. Rà soát phần đuôi điểm thấp ghi nhận cả cảnh báo giả lẫn một số lỗi thuật ngữ cần sửa. Do đó, trung bình và trung vị cung cấp bằng chứng định lượng rằng bản dịch tiếng Anh nhìn chung giữ được ngữ nghĩa, đặc biệt ở lý do vào viện và diễn tiến bệnh, nhưng vẫn cần kiểm tra thủ công bởi người có chuyên môn.

Kiểm chứng liên kết, nhãn và tập chia

Khác với BTXRD, bệnh sử CTCH là dữ liệu được trích từ bệnh án nên không thể kiểm chứng bằng cách phát lại một ngân hàng mẫu câu. Phép kiểm tra phù hợp là đối chiếu khóa định danh giữa manifest, ảnh, văn bản và nhãn, xác nhận tính một-nóng của nhãn, đồng thời kiểm tra giao nhau theo người bệnh giữa các tập dữ liệu. Kết quả tính trực tiếp trên quần thể được manifest lựa chọn được trình bày trong Bảng A.11.

Phép kiểm tra	**Kết quả**
Định danh trong phân phối là duy nhất	3.249/3.249 (100%)
Định danh ngoài phân phối là duy nhất	18/18 (100%)
Giao nhau theo ảnh giữa quần thể trong và ngoài phân phối	0 mẫu
Giao nhau theo người bệnh giữa quần thể trong và ngoài phân phối	0 người bệnh
Mẫu được chọn có ảnh giải mã được	3.267/3.267 (100%)
Mẫu được chọn có đủ bệnh sử tiếng Việt và tiếng Anh	3.267/3.267 (100%)
Tệp bệnh sử được liên kết có nội dung khác rỗng	6.534/6.534 (100%)
Nhãn trong phân phối có đúng một lớp trong 22 lớp	3.249/3.249 (100%)
`class_id`, tên lớp và cột một-nóng nhất quán	3.249/3.249 (100%)
Giao nhau theo người bệnh giữa `train`/`validate`/`test`	0/0/0
Quy mô `train`/`validate`/`test`	2.265/315/669

Bảng A.11: Kết quả kiểm chứng tính toàn vẹn của quần thể CTCH được sử dụng

Trong 3.267 bệnh sử tiếng Anh được liên kết, trường lý do vào viện và diễn tiến bệnh có nội dung ở toàn bộ mẫu, còn trường tiền sử có nội dung ở 2.930 mẫu (89,68%) và không có dữ liệu ở 337 mẫu. Hai con số tương ứng giống nhau ở nguồn tiếng Việt, nên tổng cộng có 5.860/6.534 tệp (89,68%) chứa nội dung tiền sử. Việc thiếu tiền sử được giữ như trạng thái dữ liệu nguồn, không được nội suy bằng câu giả lập.

Phụ lục B

Cấu hình chi tiết của XBone-Net

Phụ lục này trình bày cấu hình chi tiết của phương pháp được mô tả trong Chương 3. Nội dung tập trung vào mô hình nền tảng, kích thước các biểu diễn, vị trí thích nghi hạng thấp, cấu hình dung hợp, đầu phân lớp và các tham số huấn luyện. Các quy tắc tiền xử lý ảnh và công thức tối ưu được giữ tại Chương 3 để tránh lặp lại phần mô tả phương pháp.

B.1 Mô hình nền tảng và chuẩn hóa đầu vào

XBone-Net sử dụng trọng số công bố của BiomedCLIP với định danh `hf-hub:microsoft/BiomedCLIP-PubMedBERT_256-vit_base_patch16_224` [51]. Định danh này xác định đồng thời bộ mã hóa thị giác ViT-B/16, bộ mã hóa văn bản PubMedBERT, hai lớp chiếu về không gian 512 chiều, bộ biến đổi ảnh và bộ tách đơn vị biểu diễn tương ứng. Trọng số nền của hai bộ mã hóa được nạp trước khi chèn LoRA và được giữ cố định trong cả hai giai đoạn huấn luyện.

Thành phần	Cấu hình	Vai trò
Ảnh đầu vào	Một ảnh 224×224	Là đầu vào duy nhất của bộ mã hóa thị giác, không sử dụng nhánh ảnh bổ sung.
Mảnh ảnh	Lưới 14×14, mỗi mảnh 16×16	Tạo 196 đơn vị biểu diễn không gian và một đơn vị đại diện cho mỗi ảnh.
Văn bản	Tối đa 256 đơn vị biểu diễn	Chuỗi dài hơn bị cắt, chuỗi ngắn hơn được đệm và mặt nạ chú ý loại các vị trí đệm.
Văn bản khuyết	`no clinical information available.`	Là chuỗi thay thế cố định khi trường văn bản rỗng.
Chiều biểu diễn	$D = 512$	Là chiều chung của chuỗi ảnh, chuỗi văn bản, biểu diễn dung hợp và đầu phân lớp.

Bảng B.1: Cấu hình đầu vào và mô hình nền tảng của XBone-Net

Văn bản được đọc bằng mã hóa UTF-8, loại khoảng trắng ở hai đầu và chuyển về chữ thường trước khi tách đơn vị biểu diễn. Đối với CTCH, đầu vào gồm lý do vào viện, diễn tiến bệnh và tiền sử. Đối với BTXRD, đầu vào là văn bản tổng hợp đã được cố định trước khi huấn luyện. Bộ tách đơn vị biểu diễn và phép chuẩn hóa ảnh được lấy trực tiếp từ cùng định danh BiomedCLIP nhằm tránh sai khác giữa tiền huấn luyện và thích nghi trên dữ liệu đích.

B.2 Kích thước biểu diễn qua các thành phần

Gọi B là kích thước lô và K là số lớp. Cấu hình chính sử dụng $K = 22$ trên CTCH và $K = 10$ trên BTXRD. Bảng B.2 trình bày kích thước đầu ra tại các bước chính. Các kích thước này không phụ thuộc vào độ phân giải ban đầu vì ảnh đầu vào duy nhất được đưa về 224×224 trước khi mã hóa.

Vị trí	Kích thước	Diễn giải
Chuỗi của một ảnh sau ViT	$B \times 197 \times 512$	Một đơn vị đại diện và 196 đơn vị mảnh ảnh.
Chuỗi thị giác dùng cho dung hợp	$B \times 197 \times 512$	Chuỗi đầu ra gốc gồm một đơn vị đại diện và 196 đơn vị mảnh ảnh, không qua nhánh ảnh bổ sung hoặc bước gom trung gian.
Chuỗi văn bản	$B \times 256 \times 512$	Một đơn vị đại diện, các đơn vị nội dung và các vị trí đệm.
Biểu diễn ảnh nhận ngữ cảnh văn bản	$B \times 512$	Kết quả truy vấn văn bản bằng biểu diễn ảnh toàn cục.
Biểu diễn văn bản nhận ngữ cảnh ảnh	$B \times 512$	Kết quả truy vấn các đơn vị ảnh cục bộ bằng biểu diễn văn bản toàn cục.
Biểu diễn dung hợp	$B \times 512$	Đầu vào của đầu phân lớp tuyến tính.
Logit phân lớp	$B \times K$	Điểm của từng lớp trước Softmax.

Bảng B.2: Kích thước các biểu diễn tại những bước chính của XBone-Net

Trong pha 1, mạng nền trả về biểu diễn toàn cục đã chuẩn hóa của ảnh và văn bản để tối ưu mục tiêu khớp ngữ nghĩa. Trong pha 2, mạng nền trả về trực tiếp chuỗi gồm đơn vị đại diện và các đơn vị nội dung của từng phương thức. Cấu hình chính truyền các chuỗi gốc này vào mô-đun dung hợp mà không tạo nhánh ảnh bổ sung hoặc gom các đơn vị ảnh qua một mô-đun trung gian.

B.3 Cấu hình thích nghi hạng thấp

LoRA [17] được chèn vào cả bộ mã hóa ảnh và bộ mã hóa văn bản. Cấu hình chung sử dụng hạng $r = 16$, hệ số tỷ lệ $\alpha = 32$ và tỷ lệ bỏ học 0,1. Các ma trận LoRA được cập nhật trong cả hai pha, còn các trọng số nền tương ứng không nhận gradient. Bảng B.3 liệt kê các phép chiếu tuyến tính được thích nghi.

Các tham số học được ngoài LoRA gồm các phép chiếu đầu vào, hai mô-đun chú ý chéo, mạng dung hợp cùng trọng số và độ lệch của đầu phân lớp tuyến tính. Tất cả các thành phần này được tối ưu trực tiếp trong pha 2 bằng lan truyền ngược.

Bộ mã hóa	Mô-đun đích	Ý nghĩa
Thị giác ViT-B/16	attn.qkv, attn.proj, mlp.fc1, mlp.fc2	Thích nghi các phép chiếu truy vấn-khóa-giá trị, đầu ra chú ý và hai lớp của mạng truyền thẳng trong mỗi khối thị giác.
Văn bản PubMedBERT	query, key, value, attention.output.dense, intermediate.dense, output.dense	Thích nghi các phép chiếu tự chú ý, đầu ra chú ý và hai phép chiếu của mạng truyền thẳng trong mỗi khối văn bản.

Bảng B.3: Các mô-đun tuyến tính được thích nghi bằng LoRA

B.4 Dung hợp và đầu phân lớp

Mô-đun dung hợp sử dụng chú ý chéo hai chiều với tám đầu chú ý, chiều ẩn 512 và tỷ lệ bỏ học 0,1. Ở chiều thứ nhất, biểu diễn ảnh toàn cục truy vấn các đơn vị văn bản không đệm. Ở chiều còn lại, biểu diễn văn bản toàn cục truy vấn 196 đơn vị mảnh ảnh từ chuỗi đầu ra gốc của BiomedCLIP. Hai kết quả được cộng thặng dư với biểu diễn toàn cục tương ứng, chuẩn hóa lớp, nối với nhau và đưa qua mạng hai lớp để tạo biểu diễn dung hợp 512 chiều.

Thành phần	Giá trị	Ghi chú
Hướng chú ý	Hai chiều	Ảnh truy vấn văn bản và văn bản truy vấn ảnh dùng hai mô-đun độc lập.
Số đầu chú ý	8	Mỗi đầu có chiều $512/8 = 64$.
Tỷ lệ bỏ học	0,1	Áp dụng trong chú ý, nhánh thặng dư và mạng dung hợp.
Mạng dung hợp	$1024 \to 512 \to 512$	Sử dụng GELU giữa hai lớp tuyến tính và chuẩn hóa đầu ra.
Đầu phân lớp	Tuyến tính $512 \to K$	Ánh xạ biểu diễn dung hợp thành K điểm số lớp.
Tham số đầu phân lớp	Trọng số và độ lệch	Được tối ưu cùng mô-đun dung hợp bằng lan truyền ngược trong pha 2.

Bảng B.4: Cấu hình mô-đun dung hợp và đầu phân lớp

B.5 Cấu hình huấn luyện

Hai pha sử dụng AdamW, lịch tốc độ học cosine, tỷ lệ khởi động 0,1, hệ số suy giảm trọng số 10^{-4} và kích thước lô 16. Huấn luyện sử dụng bfloat16 trên ba hạt giống 42, 123 và 456. Pha 1 lựa chọn trạng thái có mất mát xác thực thấp nhất, còn pha 2 lựa chọn trạng thái có Macro-F1 xác thực cao nhất. Tập kiểm thử không tham gia dừng sớm, lựa chọn trạng thái hoặc cập nhật tham số.

Thuộc tính	**Pha 1**	**Pha 2**	**Diễn giải**
Mục tiêu	Khớp ngữ nghĩa	Phân lớp tuyến tính	Pha 1 căn chỉnh ảnh-văn bản, pha 2 tối ưu biểu diễn dung hợp và biên quyết định cho lớp đích.
Tốc độ học	5×10^{-5}	10^{-4}	Áp dụng cho các tham số được phép cập nhật trong từng pha.
Số vòng tối đa	30	50	Đánh giá và lưu trạng thái sau mỗi vòng.
Dừng sớm	3 vòng	5 vòng	Dừng khi độ đo lựa chọn không cải thiện.
Độ đo lựa chọn	Mất mát xác thực	Macro-F1 xác thực	Chiều tối ưu lần lượt là giảm và tăng.
Đích mềm cùng lớp	$\rho = 0{,}50$	Không áp dụng	Giảm việc xem cặp khác mẫu nhưng cùng lớp là âm hoàn toàn.
Làm trơn nhãn	Không áp dụng	$\varepsilon = 0{,}1$	Giới hạn việc phân phối mục tiêu tập trung tuyệt đối vào một lớp.
Trọng số lớp	Không áp dụng	Số lượng hiệu dụng	Giới hạn trọng số lớn nhất bằng 5,0.

Bảng B.5: Cấu hình và tiêu chí lựa chọn trạng thái trong hai pha huấn luyện

Hai bộ dữ liệu khác nhau ở số lớp, với $K = 22$ trên CTCH và $K = 10$ trên BTXRD. Cả hai cấu hình chính đều dùng hệ số số lượng hiệu dụng mặc định $\beta = 0{,}999$. Các cấu hình còn lại trong Bảng B.5 được giữ giống nhau.

Phụ lục C

Kết quả chi tiết theo từng hạt giống

C.1 Phạm vi trình bày

Phụ lục này công bố các kết quả riêng của ba hạt giống ngẫu nhiên 42, 123 và 456 nhằm bổ trợ cho các giá trị trung bình và độ lệch chuẩn được trình bày trong Chương 4. Sự thay đổi giữa các hạt giống được sử dụng để đánh giá độ nhạy của quy trình huấn luyện theo khởi tạo trên cùng một phép chia dữ liệu. Các giá trị này không được diễn giải như độ bất định do thay đổi tập dữ liệu.

Các nội dung được báo cáo chi tiết gồm: hiệu năng phân loại khi sử dụng toàn bộ dữ liệu huấn luyện, đối chứng theo phương thức trên CTCH, khảo sát loại bỏ thành phần, kiểm định thống kê và khoảng tin cậy ghép cặp, cùng đánh giá khả năng cảnh báo dữ liệu ngoài phân phối (OOD). Đây là các nội dung trong Chương 4 có đủ kết quả cho cả ba hạt giống và có thể đối chiếu trực tiếp với các bảng tổng hợp. Chi phí huấn luyện được tổng hợp qua ba hạt giống trong chương chính, còn phép đo tham số, chi phí suy luận và đánh giá định lượng bằng tích phân gradient được thực hiện trên hạt giống 42.

C.2 Phân loại khi sử dụng toàn bộ dữ liệu huấn luyện

Bảng C.1 và Bảng C.2 trình bày ba độ đo phân loại (Accuracy, Balanced Accuracy và Macro-F1) của từng mô hình tại từng hạt giống. Việc theo dõi đồng thời ba độ đo này cho phép kiểm tra liệu thứ hạng trung bình trong Chương 4 có xuất hiện nhất quán hay phụ thuộc vào một lần khởi tạo ngẫu nhiên cụ thể.

Bảng C.1: Kết quả phân loại của từng hạt giống trên BTXRD

Mô hình	**Hạt giống**	**Accuracy**	**BAcc**	**Macro-F1**
BiomedCLIP	42	0,8320	0,5769	0,5870
BiomedCLIP	123	0,8280	0,6197	0,5993
BiomedCLIP	456	0,8333	0,6219	0,6118
CLIP	42	0,8200	0,5949	0,5722
CLIP	123	0,7720	0,5802	0,5574
CLIP	456	0,8187	0,6121	0,6064
DenseNet-121	42	0,6320	0,3644	0,3688
DenseNet-121	123	0,6333	0,3862	0,3904
DenseNet-121	456	0,6307	0,3575	0,3562
MedCLIP	42	0,8307	0,5860	0,5931
MedCLIP	123	0,8040	0,6204	0,6014
MedCLIP	456	0,8280	0,6317	0,6228
PubMedCLIP	42	0,7573	0,5716	0,5067
PubMedCLIP	123	0,7947	0,6163	0,5946
PubMedCLIP	456	0,8133	0,6388	0,6155
ResNet-50	42	0,6067	0,3031	0,3174
ResNet-50	123	0,6200	0,3231	0,3347
ResNet-50	456	0,5933	0,3278	0,3333
XBone-Net	42	0,8227	0,5960	0,6140
XBone-Net	123	0,8413	0,6230	0,6370
XBone-Net	456	0,8267	0,6155	0,6209

Bảng C.2: Kết quả phân loại của từng hạt giống trên CTCH

Mô hình	**Hạt giống**	**Accuracy**	**BAcc**	**Macro-F1**
BiomedCLIP	42	0,5904	0,6203	0,5520
BiomedCLIP	123	0,5755	0,6107	0,5472

Còn tiếp ở trang sau

Bảng C.2 (tiếp theo)

Mô hình	**Hạt giống**	**Accuracy**	**BAcc**	**Macro-F1**
BiomedCLIP	456	0,6248	0,5758	0,5628
CLIP	42	0,5725	0,6579	0,5727
CLIP	123	0,5785	0,6209	0,5547
CLIP	456	0,6114	0,5862	0,5624
DenseNet-121	42	0,4813	0,5327	0,4596
DenseNet-121	123	0,4858	0,4413	0,4113
DenseNet-121	456	0,4783	0,5019	0,4372
MedCLIP	42	0,5605	0,5813	0,5282
MedCLIP	123	0,5994	0,5519	0,5299
MedCLIP	456	0,5202	0,5838	0,4902
PubMedCLIP	42	0,5306	0,6108	0,5313
PubMedCLIP	123	0,5486	0,4912	0,4902
PubMedCLIP	456	0,5770	0,5747	0,5395
ResNet-50	42	0,4963	0,4229	0,4171
ResNet-50	123	0,5067	0,4139	0,4158
ResNet-50	456	0,4918	0,4171	0,4132
XBone-Net chỉ ảnh	42	0,5232	0,4705	0,4435
XBone-Net chỉ ảnh	123	0,3976	0,4846	0,3388
XBone-Net chỉ ảnh	456	0,4111	0,4976	0,3614
XBone-Net	42	0,6024	0,5788	0,5589
XBone-Net	123	0,6114	0,5966	0,5645
XBone-Net	456	0,6413	0,6051	0,5948

Các hàng XBone-Net đầy đủ trong hai bảng dùng chiến lược huấn luyện LoRA hai pha, chú ý chéo hai chiều và đầu phân lớp tuyến tính. Bảng CTCH còn bổ sung XBone-Net chỉ ảnh ngay trước cấu hình đầy đủ để đối chiếu với Bảng 4.9; đối chứng theo phương thức này không thuộc nghiên cứu loại bỏ thành phần. Số liệu theo từng hạt giống cho thấy XBone-Net có hiệu năng phân loại cạnh tranh nhưng không dẫn đầu đồng thời trên mọi độ đo và mọi bộ dữ liệu.

Các bảng phân lớp được tính từ cùng tệp dự đoán đã căn chỉnh theo định danh mẫu và nhãn, cũng là đầu vào của kiểm định ghép cặp. Các tệp tổng hợp từ lần chạy cũ có thể khác phiên bản dự đoán này, nên không được trộn lẫn khi tái lập bảng. Tất cả kết luận phân lớp trong báo cáo sử dụng Accuracy, Balanced Accuracy và Macro-F1.

C.3 Nghiên cứu loại bỏ từng thành phần

Bảng C.3 trình bày kết quả của XBone-Net và hai biến thể được dùng trực tiếp để trả lời câu hỏi nghiên cứu về vai trò của các thành phần tại từng hạt giống trên CTCH. Biến thể Chỉ pha 2 loại bỏ pha khớp ngữ nghĩa, còn biến thể Nối đặc trưng thay chú ý chéo hai chiều bằng phép nối đặc trưng. Số liệu xác nhận rằng cấu hình đầy đủ đạt Accuracy và Macro-F1 trung bình cao nhất, trong khi Nối đặc trưng đạt Balanced Accuracy trung bình cao hơn. Vì vậy, không thành phần đơn lẻ nào tạo ưu thế đồng thời trên cả ba độ đo quyết định lớp.

Cấu hình	**Hạt giống**	**Accuracy**	**BAcc**	**Macro-F1**
XBone-Net	42	0,6024	0,5788	0,5589
XBone-Net	123	0,6114	0,5966	0,5645
XBone-Net	456	0,6413	0,6051	0,5948
Chỉ pha 2	42	0,6099	0,5529	0,5624
Chỉ pha 2	123	0,5979	0,5223	0,5286
Chỉ pha 2	456	0,5934	0,5904	0,5582
Nối đặc trưng	42	0,5785	0,6016	0,5507
Nối đặc trưng	123	0,5830	0,5699	0,5302
Nối đặc trưng	456	0,5859	0,6233	0,5621

Bảng C.3: Kết quả phân loại của từng hạt giống trong nghiên cứu loại bỏ thành phần trên CTCH

C.4 Chi tiết kiểm định thống kê và khoảng tin cậy ghép cặp

Phần này cung cấp toàn bộ số liệu thống kê chi tiết và khoảng tin cậy Bootstrap 95% nhằm đối chiếu, bổ trợ cho các biểu đồ trực quan đã trình bày trong Chương 4. Đối với thực nghiệm so sánh với các mô hình đối chứng, Bảng C.4 báo cáo khoảng tin cậy 95% của mức chênh lệch ghép cặp trên cả ba độ đo phân loại qua ba hạt giống. Đối với khảo sát loại

bỏ thành phần, Bảng C.5 và Bảng C.6 cung cấp lần lượt các giá trị kiểm định chênh lệch quan sát $\widehat{\Delta}$, mức ý nghĩa hiệu chỉnh p_{Holm} và khoảng tin cậy 95% cho các cấu hình biến thể trên CTCH.

Tất cả các phép phân tích đều sử dụng quy trình lấy mẫu lại ghép cặp chéo trên cùng bệnh nhân và hạt giống với $N_{\text{boot}} = N_{\text{perm}} = 10.000$. Theo đúng quy tắc đã thiết lập, kết luận về ý nghĩa thống kê được xác định duy nhất dựa trên tiêu chuẩn $p_{\text{Holm}} < 0{,}05$ từ kiểm định hoán vị. Khoảng tin cậy Bootstrap 95% được cung cấp nhằm mô tả độ bất định và độ lớn của chênh lệch, không đóng vai trò là điều kiện quyết định độc lập. Vì vậy, các trường hợp khoảng tin cậy cắt qua mốc 0 nhưng đạt $p_{\text{Holm}} < 0{,}05$ (hoặc ngược lại) ở các ca sát ngưỡng vẫn tuân thủ kết luận của kiểm định hoán vị và được diễn giải thận trọng trên phân hoạch thực nghiệm hiện tại.

Dữ liệu	**Đối chứng**	**Δ Accuracy**	**Δ BAcc**	**Δ Macro-F1**
CTCH	ResNet-50	+0,1201 [+0,0762; +0,1634]	+0,1755 [+0,1282; +0,2229]	+0,1573 [+0,1106; +0,2068]
	DenseNet-121	+0,1365 [+0,0957; +0,1779]	+0,1015 [+0,0348; +0,1671]	+0,1367 [+0,0835; +0,1878]
	CLIP	+0,0309 [−0,0005; +0,0623]	−0,0282 [−0,0889; +0,0302]	+0,0094 [−0,0340; +0,0514]
	MedCLIP	+0,0583 [−0,0000; +0,1211]	+0,0212 [−0,0224; +0,0640]	+0,0566 [+0,0066; +0,1107]
	PubMedCLIP	+0,0663 [+0,0344; +0,0987]	+0,0346 [−0,0379; +0,1084]	+0,0524 [+0,0089; +0,0985]
	BiomedCLIP	+0,0214 [−0,0095; +0,0523]	−0,0088 [−0,0567; +0,0418]	+0,0187 [−0,0192; +0,0570]
BTXRD	ResNet-50	+0,2236 [+0,1929; +0,2538]	+0,2935 [+0,2394; +0,3466]	+0,2955 [+0,2400; +0,3483]
	DenseNet-121	+0,1982 [+0,1684; +0,2271]	+0,2421 [+0,1900; +0,2953]	+0,2522 [+0,1983; +0,3054]
	CLIP	+0,0267 [−0,0098; +0,0689]	+0,0158 [−0,0457; +0,0745]	+0,0453 [−0,0186; +0,1052]
	MedCLIP	+0,0093 [−0,0200; +0,0409]	−0,0012 [−0,0506; +0,0472]	+0,0182 [−0,0325; +0,0662]
	PubMedCLIP	+0,0418 [+0,0089; +0,0733]	+0,0026 [−0,0576; +0,0648]	+0,0517 [−0,0205; +0,1255]
	BiomedCLIP	−0,0009 [−0,0218; +0,0200]	+0,0053 [−0,0399; +0,0506]	+0,0246 [−0,0225; +0,0697]

Bảng C.4: Khoảng tin cậy 95% của chênh lệch ghép cặp giữa XBone-Net và các mô hình đối chứng đối với các độ đo phân loại qua ba hạt giống. Chênh lệch được tính bằng XBone-Net trừ mô hình đối chứng. Giá trị trong ngoặc vuông được ước lượng từ 10.000 lần bootstrap ghép cặp chéo bệnh nhân và hạt giống.

Biến thể	Độ đo	Δ	p_{Holm}
Chỉ pha 2	Accuracy ↑	+0,0179	0,262
	Balanced Accuracy ↑	+0,0383	0,119
	Macro-F1 ↑	+0,0230	0,292
Nối đặc trưng	Accuracy ↑	+0,0359	0,052
	Balanced Accuracy ↑	−0,0048	0,783
	Macro-F1 ↑	+0,0250	0,292

Bảng C.5: Giá trị kiểm định ghép cặp giữa XBone-Net và các biến thể. Chênh lệch được tính bằng XBone-Net trừ biến thể.

Biến thể	Độ đo	Δ	Khoảng tin cậy 95%
Chỉ pha 2	Accuracy	+0,0179	[−0,0214; +0,0578]
	Balanced Accuracy	+0,0383	[−0,0084; +0,0862]
	Macro-F1	+0,0230	[−0,0196; +0,0665]
Nối đặc trưng	Accuracy	+0,0359	[+0,0025; +0,0688]
	Balanced Accuracy	−0,0048	[−0,0452; +0,0363]
	Macro-F1	+0,0250	[−0,0109; +0,0609]

Bảng C.6: Khoảng tin cậy 95% của chênh lệch ghép cặp trên 669 mẫu kiểm thử CTCH qua các hạt giống 42, 123 và 456. Chênh lệch được tính bằng XBone-Net trừ biến thể, thống nhất với bảng kiểm định và hình ở chương chính. Khoảng tin cậy được ước lượng từ 10.000 lần bootstrap ghép cặp chéo bệnh nhân và hạt giống.

C.5 Kết quả đánh giá dữ liệu ngoài phân phối

Bảng C.7 công bố kết quả theo từng hạt giống của năm cấu hình trên kịch bản OOD CTCH. XBone-Net chỉ ảnh dùng khoảng cách k-NN thị giác; XBone-Net đầy đủ, hai biến thể và BiomedCLIP tinh chỉnh toàn bộ dùng điểm tổ hợp ảnh–văn bản hậu xử lý. Số mẫu trong phân phối và ngoài phân phối được ghi trực tiếp trong bảng vì AUPR-Out và FPR@95%TPR chịu ảnh hưởng bởi số lượng và tỷ lệ mẫu.

Mỗi lần đánh giá sử dụng 669 mẫu CTCH trong phân phối và đủ 18 mẫu bệnh lý ngoài không gian nhãn đã được xác nhận trong danh sách

đánh giá. Kết quả được tính từ các ngân hàng đặc trưng hiện hành với cùng giao thức k-NN, chuẩn hóa trên tập xác thực ID và tổng hợp qua ba hạt giống như Bảng 4.15. FPR@95%TPR còn cao ở cả năm cấu hình, do đó bộ phát hiện chỉ được xem là tín hiệu cảnh báo bổ sung đối với các trường hợp gần miền.

Kịch bản	**Cấu hình**	**Hạt giống**	N_{ID}	N_{OOD}	**AUROC-OOD**	**AUPR-Out**	**FPR@95%TPR**
OOD CTCH	XBone-Net chỉ ảnh	42	669	18	0,4903	0,0355	0,9444
	XBone-Net chỉ ảnh	123	669	18	0,6043	0,0354	1,0000
	XBone-Net chỉ ảnh	456	669	18	0,5850	0,0340	1,0000
	XBone-Net	42	669	18	0,7736	0,1521	0,6667
	XBone-Net	123	669	18	0,7713	0,1365	0,6667
	XBone-Net	456	669	18	0,7346	0,1533	0,5556
	Chỉ pha 2	42	669	18	0,7922	0,2194	0,5556
	Chỉ pha 2	123	669	18	0,7951	0,2310	0,6667
	Chỉ pha 2	456	669	18	0,7333	0,2086	0,7778
	Nối đặc trưng	42	669	18	0,7139	0,1103	0,6111
	Nối đặc trưng	123	669	18	0,7015	0,1167	0,6667
	Nối đặc trưng	456	669	18	0,7404	0,0894	0,6667
	BiomedCLIP tinh chỉnh toàn bộ	42	669	18	0,7848	0,1694	0,5000
	BiomedCLIP tinh chỉnh toàn bộ	123	669	18	0,7872	0,1653	0,6667
	BiomedCLIP tinh chỉnh toàn bộ	456	669	18	0,6996	0,1139	0,7222

Bảng C.7: Kết quả cảnh báo OOD của từng hạt giống trên CTCH. Cấu hình chỉ ảnh dùng điểm thị giác; các cấu hình còn lại tổ hợp điểm ảnh và văn bản.