

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - Nguyễn Gia Kiệt

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

TP. HỒ CHÍ MINH, THÁNG 08/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - 22127390

Nguyễn Gia Kiệt - 22127221

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

GIẢNG VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

TP. HỒ CHÍ MINH, THÁNG 08/2026

Lời cam đoan

Nhóm xin cam đoan đây là công trình nghiên cứu của riêng nhóm. Dữ liệu và kết quả nghiên cứu trong khóa luận này là trung thực và không trùng lặp với bất kỳ chủ đề nào khác. Nhóm cam đoan toàn bộ nội dung khóa luận này không đạo văn hoặc sao chép từ các công trình nghiên cứu khác. Ngoài ra, trong quá trình nghiên cứu và viết khóa luận, nhóm tuân thủ nghiêm ngặt các quy định về bảo mật do các tập dữ liệu nhóm sử dụng trong nghiên cứu của mình cung cấp. Hơn nữa, nhóm luôn tuân thủ mọi nguyên tắc đạo đức trong suốt quá trình nghiên cứu. Nhóm đảm bảo rằng tất cả các nguồn và tài liệu tham khảo đều được trích dẫn đúng cách và nhóm duy trì tính chính trực học thuật trong mọi khía cạnh công việc của mình.

Lời cảm ơn

Nhóm xin chân thành cảm ơn PGS.TS Lý Quốc Ngọc và ThS. Đỗ Thị Thanh Hà đã dành rất nhiều thời gian, tâm huyết để định hướng, tận tình hướng dẫn và đưa ra những lời khuyên quý báu cho nhóm trong suốt quá trình nghiên cứu và thực hiện khóa luận tốt nghiệp với đề tài "Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức".

Xin trân trọng gửi lời cảm ơn sâu sắc đến Ban Chủ nhiệm cùng toàn thể quý thầy cô Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG-HCM. Những kiến thức nền tảng vững chắc mà các thầy cô đã truyền đạt trong bốn năm học vừa qua và môi trường thí nghiệm tuyệt vời chính là hành trang quan trọng nhất giúp nhóm có thể hoàn thành tốt hướng nghiên cứu này.

Nhóm cũng xin gửi lời cảm ơn đến các y bác sĩ tại Bệnh viện Chấn thương Chỉnh hình TP.HCM, thầy Đỗ Phúc Thịnh và thầy Võ Thế Hào đã hỗ trợ chia sẻ nguồn dữ liệu ảnh X-quang cũng như tư vấn các kiến thức chuyên môn về y khoa, giúp mô hình nghiên cứu bám sát với quy trình chẩn đoán thực tế.

Mặc dù đã có nhiều cố gắng trong quá trình thực hiện, nhưng do hạn chế về mặt thời gian và kinh nghiệm nghiên cứu, khóa luận chắc chắn không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô và hội đồng đánh giá để đề tài được hoàn thiện hơn.

Xin chân thành cảm ơn!



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO HỌC SÂU ĐA PHƯƠNG THỨC

*(Developing a bone X-ray image classification
system based on multimodal deep learning)*

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm Sinh viên thực hiện:

1. Nguyễn Văn Lê Bá Thành (MSSV: 22127390)
2. Nguyễn Gia Kiệt (MSSV: 22127221)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 02/2026 đến 08/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn đầu. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, các nghiên cứu hiện nay đã ứng dụng các mô hình học sâu vào để giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ để đưa vào ứng dụng thực tế. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để bổ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác. Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống.

Khác với các mô hình đơn phương thức chỉ xử lý trên một phương thức như ảnh hay văn bản duy nhất, các mô hình đa phương thức có thể sử dụng nhiều phương thức và tìm ra sự tương quan giữa các phương thức nhằm tạo nên biểu diễn có ý nghĩa hơn từ đó nâng cao hiệu năng của hệ thống. Với thực tế lâm sàng hiện nay, các mô hình nghiên cứu tập trung

vào kết hợp ngôn ngữ và hình ảnh hay còn được gọi là mô hình ngôn ngữ trực quan đang là các mô hình đang nhận được nhiều sự chú ý.

2.2 Định nghĩa các khái niệm

Thông tin lâm sàng

Thông tin lâm sàng là những dữ liệu thu thập trực tiếp qua quá trình bác sĩ thăm khám người bệnh, bao gồm việc khai thác bệnh sử và khám thực thể (nhìn, sờ, gõ, nghe) [23]. Dữ liệu này mang tính chất định hướng ban đầu, giúp bác sĩ khoanh vùng tổn thương và đưa ra các quyết định chỉ định thăm khám chuyên sâu tiếp theo [2].

Thông tin cận lâm sàng

Thông tin cận lâm sàng là các dữ liệu khách quan thu được từ việc áp dụng các trang thiết bị và kỹ thuật y khoa hiện đại (như hình ảnh X-quang, cắt lớp, hay xét nghiệm sinh hóa) [23]. Nếu lâm sàng dùng để định hướng, thì cận lâm sàng cung cấp bằng chứng xác thực từ bên trong cơ thể để chẩn đoán chính xác bệnh lý.

2.3 Phát biểu bài toán

Đầu vào (Input)

Hệ thống nhận vào các nguồn dữ liệu sau:

- Thông tin lâm sàng bao gồm báo cáo cận lâm sàng, khám xét toàn thân, lý do vào viện của bệnh nhân.
- Ảnh X-quang xương của bệnh nhân tương ứng.
- Tập nhãn được định nghĩa trước.


Đầu ra (Output)

Hệ thống sẽ sinh ra các nhãn sau:

- Tỷ lệ mà ảnh và thông tin lâm sàng tương ứng thuộc vào các lớp được định nghĩa trước.
- Ảnh trực quan hóa giải thích cho kết quả.

Kiến trúc tổng quan

Với bài toán này, kiến trúc tổng quan của một mô hình học sâu đa phương thức được sử dụng bao gồm bốn thành phần chính: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại như được thể hiện ở Hình 1.



Hình 1: Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức

Trong đó, bộ mã hóa ảnh có chức năng rút trích đặc trưng từ ảnh đầu vào, bộ mã hóa văn bản có chức năng rút trích đặc trưng từ văn bản đầu vào, bộ dung hợp dữ liệu có chức năng dung hợp hay căn chỉnh các đặc trưng được rút trích từ hai phương thức dữ liệu trên để tạo ra một biểu diễn có ý nghĩa và có đầy đủ tính chất của phương thức đầu vào, đây cũng là mô-đun quan trọng nhất đối với một mô hình học sâu đa phương thức, cuối cùng là bộ phân loại, nhận biểu diễn đặc trưng chung của các phương thức đầu vào để phân loại và đưa ra kết quả cuối cùng.

2.4 Mục tiêu đề tài

Trong bối cảnh già hóa dân số và các tác nhân gây bệnh từ ô nhiễm và lối sống thiếu lành mạnh trong đời sống hiện đại, các bệnh lý về xương và chấn thương có thể ảnh hưởng trực tiếp đến đời sống và tính mạng dẫn đến việc chẩn đoán và tiên lượng để đưa ra hướng điều trị phù hợp đang trở thành gánh nặng cho các y bác sĩ, các hệ thống học sâu đa phương

thức tuy đã phát triển nhưng lại thiếu khả năng giải thích. Đề tài hướng đến phát triển một hệ thống phân loại ảnh X-quang có khả năng:

- Đạt được độ chính xác cao trên các bộ dữ liệu nội bộ và quốc tế.
- Có khả năng giải thích được kết quả.
- Tích hợp kết quả để trợ giúp y bác sĩ trong quá trình chẩn đoán.

2.5 Phạm vi của đề tài

Nội dung nghiên cứu của đề tài tập trung vào việc khảo sát các mô hình nền tảng và thiết kế, huấn luyện, tinh chỉnh, đánh giá kiến trúc được đề xuất trên ảnh X-quang xương và các bộ dữ liệu quốc tế để so sánh, đánh giá với các kiến trúc trước.

Đối tượng nghiên cứu xoay quanh các thành phần bên trong một mạng học sâu đa phương thức bao gồm: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại, tập trung vào các phương pháp dung hợp dữ liệu hình ảnh và văn bản cùng với các phương pháp tinh chỉnh tham số cho các bộ mã hóa đã được huấn luyện trước nhằm tận dụng lại các tri thức đã có và nâng cao hiệu năng trên các tác vụ đích.

Đề tài chủ yếu sử dụng các bộ dữ liệu cặp ảnh - văn bản, không có trường hợp thiếu đã được công bố và bộ dữ liệu nội bộ được thu thập và cung cấp bởi giảng viên có hợp tác với bệnh viện ở khu vực Thành phố Hồ Chí Minh, một số thông tin cơ bản về các bộ dữ liệu được thể hiện ở Bảng 1. Nhóm sử dụng các bộ dữ liệu này nhằm đánh giá hiệu năng của kiến trúc đề xuất thông qua các độ đo phổ biến và tiến hành so sánh với các phương pháp trước đó nhằm chứng minh sự hiệu quả của phương pháp đề xuất.

2.6 Cách tiếp cận dự kiến

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ cung cấp tổng quan tình hình nghiên cứu

Bộ dữ liệu	Nguồn	Loại dữ liệu	Số lượng mẫu	Số lượng lớp
RSNA Pneumonia (2018)	Radiological Society of North America	Ảnh X-quang ngực metadata/tags	30,000	3
CheXpert (2019)	Stanford ML Group - Stanford Hospital	Ảnh X-quang ngực Báo cáo đọc ảnh	224,316	14
MIMIC-CXR v2 (2019)	Beth Israel Deaconess Medical Center	Ảnh X-quang ngực Báo cáo đọc ảnh	227,835	14
SARCOMA-CTCH (2025)	Bệnh viện Chấn Thương Chỉnh Hình - TPHCM	Ảnh X-quang xương Báo cáo đọc ảnh Báo cáo lâm sàng	Đang cập nhật	Đang cập nhật

Bảng 1: Tổng hợp các bộ dữ liệu dự kiến được sử dụng để thí nghiệm

từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

Các mô hình xây dựng từ đầu là các mô hình đơn giản, khởi điểm trong bài toán học sâu đa phương thức, thiết kế và huấn luyện một hệ thống mới từ đầu, điểm chung của các phương pháp này là chúng tập trung vào việc thiết kế các cơ chế để "trộn" (fusion) đặc trưng từ các bộ mã hóa (encoder) chuyên biệt ở các cấp độ khác nhau để tối ưu hóa hiệu suất cho các tác vụ cụ thể, sử dụng những bộ mã hóa hình ảnh đơn giản như CNN.

Khởi điểm vào 2020, X. Mei [15] và đồng nghiệp đã đề xuất lấy đặc trưng được tạo ra từ các lớp cuối của mô hình CNN (véc-tơ 512 chiều) và các đặc trưng từ dữ liệu lâm sàng rồi nối lại. Véc-tơ kết hợp này được đưa vào một mạng MLP cuối cùng để đưa ra dự đoán.

Clinical-BERT [25] và TGANet [20] tìm cách học biểu diễn đa phương thức bằng cách thúc đẩy mô hình hiểu và liên kết (align) các đặc trưng giữa các vùng trong ảnh và các từ khóa trong văn bản báo cáo thông qua các nhiệm vụ tự giám sát (self-supervised objectives), cho phép mô hình học được các biểu diễn ngữ nghĩa chung. Hay LViT [12] đề xuất một kiến trúc hybrid CNN-Transformer "Double-U", cấu trúc CNN-Transformer kết hợp mô-đun Pixel-Level Attention Module để giữ lại các đặc trưng cục bộ của ảnh giúp mô hình giữ được khả năng trích xuất đặc trưng cục bộ mạnh mẽ của CNN, đồng thời tận dụng khả năng mô hình hóa ngữ cảnh toàn cục của Transformer.

Việc chỉ nối các đặc trưng có điểm yếu về sự khác biệt về giá trị hoặc sự ngữ nghĩa lớn giữa các phương thức dữ liệu, IRENE [34] đã đưa tất

cả dữ liệu gốc về dạng token chung và học biểu diễn tổng thể (holistic representation) ngay từ đầu, sử dụng một mô hình Transformer duy nhất học các biểu diễn toàn diện cho cả hai phương thức. IRENE còn sử dụng cơ chế chú ý hai chiều ở cấp độ token để nắm bắt "các kết nối cục bộ".

Nghiên cứu của Dai và cộng sự [4] đề xuất mô hình TransMed, giải quyết bài toán kết hợp đa phương thức bằng cách tích hợp CNN và Transformer. Bằng việc chuyển đổi đặc trưng ảnh từ CNN thành dạng chuỗi để Transformer xử lý, mô hình này tối ưu hóa việc nắm bắt các đặc điểm toàn cục của hình ảnh y khoa. Cách tiếp cận này mang lại hiệu quả cao hơn các kỹ thuật fusion thông thường nhờ khả năng biểu diễn dữ liệu đa phương thức một cách toàn diện và chính xác.

Những nghiên cứu này đã khai phá và chứng minh về tác động tích cực của các phương thức dữ liệu khác như văn bản đến kết quả của việc chẩn đoán hình ảnh, tuy nhiên độ chính xác của các phương thức này còn chưa quá cao bởi các bộ mã hóa và phương pháp dung hợp dữ liệu còn đơn giản.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Kiến trúc mô hình			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	X. Mei [15]	Full Fine-Tuning	Pretrain với Cross-Entropy loss	Inception-ResNet-v2	ResNet-18	Decision-level	N/a
2	Clinical-BERT [25]	Full Fine-Tuning	Cross-modal Repr. Learning	DenseNet121	Uncased BERT-base	Early fusion	N/a
3	LViT [12]	Full Fine-Tuning	Semi-supervised (Pseudo-label)	Hybrid U-shape (CNN + ViT)	BERT_12_768_12	Intermediate	N/a
4	TGANet [20]	Train from scratch	Exponential Pseudo-label Iteration	ResNet50	Không có	Intermediate	N/a
5	IRENE [34]	Train from scratch	BCE Loss & AdamW optimizer	Convolution layer	Pretrained BERT	Simultaneous	Upsampling, FEM, CBAM Attention
6	TransMed [4]	Full Fine-Tuning	Supervised (SGD, 100 epochs)	2D CNN (ResNet18 đến 152)	N/a	Attention fusion	Lớp kết nối đầy đủ (FC Layer)

Bảng 2: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tinh chỉnh của các mô hình kết hợp ngôn ngữ - ảnh

Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu (thường cố gắng dung hợp dữ liệu thô thành một khối thống nhất), Med-VLMs chú trọng vào việc đối chiếu và liên kết chặt chẽ ngữ nghĩa giữa hình ảnh và ngôn ngữ tự nhiên. Cụ thể, kiến trúc của chúng thường kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này khớp với

nhau. Lúc này, bộ phân loại không gán nhãn theo cách truyền thống mà đóng vai trò là một cơ chế đo lường mức độ tương đồng. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Để đạt được khả năng trên, các nghiên cứu tiền huấn luyện Med-VLMs hiện nay đang phát triển chủ yếu theo ba hướng: học tương phản, học có che giấu và tích hợp tri thức y khoa (chi tiết tổng hợp được trình bày tại các Bảng 3, 4, 5).

Thứ nhất, **học tương phản (Contrastive Learning)** là chiến lược được ứng dụng rộng rãi nhất, tiêu biểu với các mô hình như ConVIRT [30], GLoRIA [7], MedCLIP [22] và BiomedCLIP [28]. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau ở mức độ cục bộ lẫn toàn cục. Phương pháp này đem lại hiệu năng ấn tượng; ví dụ, BiomedCLIP [28] (huấn luyện trên 15 triệu cặp dữ liệu) đạt độ chính xác phân loại 83%, trong khi ConVIRT [30] đạt 90,3% trên bộ dữ liệu COVIDx. Mặc dù có ưu điểm vượt trội là khả năng học biểu diễn không cần gán nhãn thủ công, học tương phản vẫn bộc lộ hạn chế về việc tiêu tốn tài nguyên tính toán lớn và rủi ro xảy ra hiện tượng âm tính giả (đẩy xa các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý).

Thứ hai, **học có che giấu (Masked Learning)** là hướng đi tập trung vào mục tiêu tái tạo dữ liệu, với các đại diện nổi bật như MRM [35] và MedViLL [16]. Bằng cách ẩn ngẫu nhiên các vùng ảnh hoặc từ ngữ trong báo cáo y khoa, kiến trúc này buộc mô hình phải dự đoán và khôi phục phần thông tin bị khuyết. Hướng tiếp cận này thể hiện ưu thế rõ rệt trong các môi trường khan hiếm dữ liệu; điển hình là MRM [35] đạt mức 92,7% AUC chỉ với 10% dữ liệu từ tập RSNA. Tuy nhiên, rào cản chính của phương pháp này nằm ở việc phụ thuộc vào nguồn dữ liệu đã được ghép cặp sẵn từ trước, cộng với độ phức tạp tính toán cao của quá trình khôi phục điểm ảnh/token.

Thứ ba, **tích hợp tri thức y khoa (Knowledge Integration)** ra đời nhằm giải quyết những đặc thù phức tạp của ngôn ngữ lâm sàng. Các

mô hình như MedKLIP [24], BioViL [3], BioViL-T [1] và KAD [29] tận dụng đồ thị tri thức (như RadGraph) hoặc dữ liệu chuỗi thời gian để cung cấp tín hiệu giám sát chi tiết về cả loại và vị trí bệnh lý. Cách tiếp cận này giúp giải quyết triệt để sự mơ hồ của các từ vựng diễn tả tiến triển bệnh (ví dụ: "cải thiện", "xấu đi"). Về mặt hiệu năng, KAD [29] đạt 0.966 AUC trên tập PadChest ở thiết lập không mẫu (zero-shot), còn BioViL-T [1] đạt độ chính xác 67,4% trong bài toán phân loại tiến triển bệnh. Dù vậy, các phương pháp này chưa loại bỏ hoàn toàn được hiện tượng âm tính giả và rất dễ gặp sai số nếu nhãn chẩn đoán thực tế nằm ngoài cơ sở tri thức đồ thị gốc.

Dựa trên sự phân tích các ưu và nhược điểm từ những khảo sát trên, hướng tiếp cận đề xuất trong nghiên cứu này được thiết kế có chọn lọc nhằm tối ưu hóa hiệu năng và chi phí:

- **Kế thừa BiomedCLIP [28]:** Tận dụng sức mạnh của các bộ mã hóa đã được huấn luyện với chất lượng cao.
- **Không áp dụng học tương phản & học có che giấu:** Khó khắc phục rào cản về tài nguyên tính toán lớn và giảm thiểu rủi ro gặp phải hiện tượng âm tính giả.
- **Tích hợp tri thức từ UMLS (tương tự MedKLIP [24]):** Sử dụng để làm giàu thêm tri thức trong các báo cáo lâm sàng.

Mặc dù các phương pháp tiền huấn luyện Med-VLMs giúp xây dựng nền tảng tri thức đa phương thức khổng lồ, việc áp dụng trực tiếp vào lâm sàng lại vấp phải rào cản lớn về chi phí tính toán và sự khan hiếm dữ liệu y tế ghép cặp. Để giải quyết vấn đề này, các nghiên cứu thường chuyển hướng sang tinh chỉnh mô hình. Tuy nhiên, nếu tinh chỉnh toàn phần trên một tập dữ liệu nhỏ, sự chênh lệch phân phối sẽ dễ dẫn đến hiện tượng chuyển giao tiêu cực hoặc "quên thảm khốc", làm đánh mất tri thức gốc. Do đó, giới nghiên cứu đang tập trung vào các chiến lược tinh chỉnh hiệu quả tham số (PEFT) nhằm đảm bảo tính linh hoạt, tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các nghiên cứu gần đây được chia thành ba hướng tiếp cận chính:

STT	Tên phương pháp	Phân loại	Nguyên lý
1	ConVIRT (2020)	Học tương phản	Tối ưu bộ mã hoá ảnh và văn bản bằng cách kéo các cặp đặc trưng ảnh-văn bản giống nhau lại gần nhau và đẩy các cặp đặc trưng ảnh-văn bản khác nhau ra xa
2	GLoRIA (2021)	Học tương phản	Dùng hai hàm mất mát global contrastive để kéo các cặp đặc trưng ảnh-văn bản, trong khi đó hàm mất mát local contrastive học cách căn chỉnh chi tiết của các vùng trong ảnh và các từ trong câu
3	MedCLIP (2022)	Học tương phản	Đề xuất cơ chế tách cặp và trích xuất tri thức, và đề xuất hàm mất mát Semantic Matching nhằm giải quyết vấn đề false negative
4	BiomedCLIP (2023)	Học tương phản	Có cơ chế tương tự như CLIP nhưng được tiền huấn luyện với bộ dữ liệu PMC-15M
5	MRM (2023)	Học có che giấu	Ẩn ngẫu nhiên các thông tin trong văn bản và các vùng trong ảnh để cho mô hình dự đoán lại ảnh và văn bản hoàn chỉnh.
6	MedViLL (2022)	Học có che giấu	Đề xuất một kiến trúc dựa trên BERT kết hợp với một mặt nạ chú ý mới được đề xuất (BAR) cho phép ảnh tương tác tự do với văn bản trong các tác vụ hiểu, đồng thời đảm bảo tính tự hồi quy cho các token trong văn bản trong các tác vụ sinh
7	BioViL (2022)	Tích hợp kiến thức y khoa	Đề xuất một bộ mã hoá văn bản CXR-BERT được tối ưu cho ảnh X-quang, duy trì hàm mất mát MLM để giúp mô hình giữ lại được các kiến thức văn bản trong quá trình căn chỉnh với ảnh
8	BioViL-T (2023)	Tích hợp kiến thức y khoa	Sử dụng các ảnh X-quang từ trước kết hợp với ảnh hiện tại để học được các đặc trưng không gian, thời gian từ đó giải thích cho các từ vụng như "cải thiện" giúp giảm đi sự mơ hồ trong báo cáo
9	MedKLIP (2023)	Tích hợp kiến thức y khoa	Đề xuất một mô-đun trích xuất bộ ba và cơ chế mã hoá tăng cường tri thức, từ đó tạo ra biểu diễn tốt hơn cho văn bản
10	KAD (2023)	Tích hợp kiến thức y khoa	Tích hợp kiến thức y khoa vào quá trình tiền huấn luyện để giúp mô hình học các biểu diễn có ý nghĩa hơn

Bảng 3: Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Mục tiêu tiền huấn luyện	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	CL	GCL	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	CL	LCL, GCL	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	CL	GCL	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	CL	GCL	ViT-Base	PubMedBERT	Contrastive Alignment	N/a
5	MRM (2023)	MP	MIM, MLM	Kiến trúc giống ViT	WordPiece	Global Context Injection	Văn bản: Transformer; Hình ảnh: Fully Connected
6	MedViLL (2022)	HA	MLM, ITM	ResNet50	BERT	Cross-modal Self-Attention	Multi-Layer Perceptron
7	BioViL (2022)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
8	BioViL-T (2023)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
9	MedKLIP (2023)	CL	LCL	ResNet50	ClinicalBERT	Knowledge-enhanced Alignment	Contrastive head, Cross-Entropy head
10	KAD (2023)	HA	CL, Disease Diagnosis Prediction	ResNet50, ViT-Base	PubMedBERT	Contrastive Alignment	Disease Query Network

Bảng 4: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;

STT	Tên phương pháp	Bộ dữ liệu tiền huấn luyện	Hiệu năng			
			Tác vụ	Bộ dữ liệu đánh giá	Độ đo	Kết quả
1	ConVIRT (2020)	MIMIC-CXR, Private Bone image	- Phân loại ảnh - Phân loại ít mẫu	RSNA Pneumonia, CheXpert, COVIDx, MURA	AUC, Accuracy	- Phân loại ít mẫu: RSNA (1%): 88.8% AUC, (10%): 91.5% AUC; CheXpert (1%): 87.0% AUC, (10%): 88.1% AUC; MURA (1%): 81.3% AUC, (10%): 86.5% AUC - Phân loại ảnh: RSNA: 92.7% AUC, CheXpert: 88.1% AUC, MURA: 89.0% AUC; COVIDx 90.3% ACC
2	GLoRIA (2021)	CheXpert	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	CheXpert, RSNA Pneumonia	AUROC	- Phân loại không mẫu: CheXpert 5x200: 0.61 ACC, 0.67 F1; RSNA: 0.70 ACC, 0.58 F1; - Phân loại ít mẫu: CheXpert (1%): 86.6 AUC, (10%): 87.8 AUC, RSNA (1%): 86.1 AUC, (10%): 88.0 AUC - Phân loại ảnh: CheXpert: 88.1 AUC, RSNA: 88.6 AUC
3	MedCLIP (2022)	MIMIC-CXR, CheXpert	- Phân loại ảnh - Phân loại không mẫu	MIMIC-5x200, COVID, RSNA Pneumonia	Mean Accuracy	- Phân loại không mẫu: CheXpert-5x200: 0.5942 ACC; MIMIC-5x200: 0.5430 ACC; COVID: 0.8472 ACC; RSNA: 0.7682 ACC - Phân loại ảnh: CheXpert-5x200: 0.5960 ACC; MIMIC-5x200: 0.5650 ACC; COVID: 0.7890 ACC; RSNA: 0.8075 ACC
4	BiomedCLIP (2023)	PMC-15M	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PCam, LC25000 (Lung, Colon), TCGA-TIL, RSNA Pneumonia	AUC, Accuracy	- Phân loại không mẫu: PCam: 73.41% ACC; LC25000 Lung 65.23% ACC; LC25000 Colon 92.98%; RSNA 78.95%; TCGA-TIL: 67.04% - Phân loại ít mẫu: PCam (1%): 82% ACC, (10%): 83%; RSNA (1%): 77% ACC, (10%): 82% ACC - Phân loại ảnh: PCam: 83% ACC, RSNA: 83% ACC
5	MRM (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu	CheXpert, NIH ChestX-ray, RSNA Pneumonia, COVID-19 Image Data Collection	AUC, Accuracy	- Phân loại ít mẫu: CheXpert (1%): 88.5 AUC, (10%): 88.5 AUC; RSNA (1%): 91.3 AUC, (10%): 92.7 AUC; NIH ChestX-ray (1%): 79.4 AUC, (10%): 84.0 AUC - Phân loại ảnh: CheXpert: 88.7 AUC, RSNA 93.3, NIH ChestX-ray: 85.9, COVID-19: 85.8
6	MedViLL (2022)	MIMIC-CXR	- Phân loại chẩn đoán	MIMIC-CXR, Open-I	Micro-averaged AUROC, Micro-averaged F1 score	- Phân loại ảnh: MIMIC-CXR: 0.980 avg AUROC, 0.839 F1; Open-I: 0.892 avg AUROC, 0.407 F1
7	BioViL (2022)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	RSNA Pneumonia	Accuracy, F1-score, AUROC, Sensitivity Specificity.	- Phân loại không mẫu: RSNA: 0.732 ACC, 0.831 AUC; ChestX-ray14: 0.6912 AUC - Phân loại ít mẫu: RSNA (1%): 0.805 ACC, 0.881 AUC; (10%): 0.812 ACC, 0.884 AUC - Phân loại ảnh: RSNA: 0.822 ACC, 0.891 AUC
8	BioViL-T (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu - Phân loại ảnh tiến triển	MS-CXR-T, RSNA Penumonia, Chest ImaGenome	Macro-Accuracy, Accuracy, F1, AUROC.	- Phân loại Tiến triển: MS-CXR-T: 67.4% Acc - Phân loại không mẫu: RSNA: 0.805 ACC, 0.871 AUC - Phân loại ít mẫu: RSNA (1%): 0.814 ACC, 0.890 AUC
9	MedKLIP (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại không mẫu	ChestX-ray14, RSNA Pneumonia, SIIM-ACR Pneumothorax, COVIDx CXR-2, COVID Rural, Edema Severity	AUC, F1-score, Accuracy.	- Phân loại không mẫu: RSNA: 0.8694 AUC, 0.6342 F1; SIIM-ACR: 0.8924 AUC, 0.6833 F1; ChestX-ray14: 0.7676 AUC, 0.2525 F1; COVID-19: 0.7396 AUC, 0.7670 F1 - Phân loại ít mẫu: ChestX-ray14 (1%): 0.7721 AUC, (10%): 0.7894; RSNA (1%): 0.8731 AUC, (10%): 0.8799 AUC - Phân loại mẫu: ChestX-ray14: 0.8323 AUC, RSNA 0.8931
10	KAD (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PadChest, NIH ChestXray14, CheXpert, ChestX-Det	AUC, F1-Score, MCC	- Phân loại không mẫu: PadChest: 0.966 AUC; CheXpert: 0.905 AUC, 0.647 F1, 0.589 MCC - Phân loại ít mẫu: ChestXray-14 (1%): 0.78 AUC, 0.31 F1; (10%): 0.80 AUC, 0.33 F1 - Phân loại ảnh: ChestXray-14: 0.82 AUC, 0.34 F1

Bảng 5: Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

Tinh chỉnh sử dụng câu nhắc (Prompt Tuning): Hướng này chèn thêm các tham số có thể học được vào không gian đầu vào của mô hình. Các phương pháp như CITE [31], FPT [8] hay PLIP [27] khai thác đặc trưng thị giác kết hợp với tri thức lâm sàng, cho thấy hiệu quả vượt trội ngay cả khi thiếu hụt dữ liệu (ví dụ: PLIP đạt 0.896 AUC chỉ với 5% dữ liệu PanNuke). Nhằm giải quyết khó khăn khi thiết kế thủ công, MedPrompt [32] và UniDCP [26] tự động sinh câu nhắc động dựa trên ngữ cảnh ảnh để xử lý đa tác vụ. Gần đây hơn, việc tích hợp Mô hình ngôn ngữ Lớn (LLM) qua ViP [6], CILMP [5] và BiomedCoOp [9] giúp tạo sinh các câu nhắc ngữ nghĩa sâu sắc, đồng bộ hóa qua cơ chế chú ý chéo và cân chỉnh tương phản, mang lại hiệu năng cao trong các kịch bản ít mẫu hoặc không mẫu.

Tinh chỉnh bộ điều hợp (Adapter Tuning): Thay vì can thiệp ở đầu vào, phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ giữa các lớp của kiến trúc gốc. Điển hình, CLIPath [10] sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu nhỏ; FTB [18] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức. Ở hướng bán giám sát, mô hình MedUnA [19] dùng LLM tạo nhãn giả và tinh chỉnh không giám sát bộ điều hợp trên ảnh chưa gán nhãn, giúp mô hình thích ứng tốt mà không thay đổi trọng số.

Tinh chỉnh chọn lọc (Selective Tuning): Hướng đi này tối ưu hóa kiến trúc bằng cách chỉ cập nhật một lượng nhỏ các trọng số quyết định hiệu năng. TransMed [33] kết hợp LLM để chuyển đổi nhãn bệnh thành mô tả chi tiết, trong khi SH-PEFT [14] chỉ tìm và cập nhật các trọng số quan trọng nhất trên bộ mã hóa thị giác nhằm khai thác tính thừa thớt của mạng. Tương tự, LCBP [13] áp dụng kỹ thuật LoRA để tinh chỉnh tham số hiệu quả cho Med-VLMs, giúp bám sát hiệu năng của tinh chỉnh toàn phần (đạt 93.1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn) nhưng giảm thiểu tối đa chi phí tính toán.

Tóm lại, các phương pháp tinh chỉnh hiệu quả tham số (PEFT) thể hiện ưu điểm vượt trội trong việc tiết kiệm tài nguyên tính toán, ngăn chặn hiện tượng quên tri thức và giúp mô hình thích ứng tốt ngay cả khi đối mặt với các bộ dữ liệu y tế khan hiếm. Tuy nhiên, hướng tiếp cận này vẫn tồn tại một số hạn chế nhất định. Hiệu năng cuối cùng của hệ thống

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	CITE (2023)	Parameter-efficient fine tuning	Visual prompt tuning	CLIP ViT-Base, ImageNet-21k ViT-Base, INTERN ViT-Base	BioLinkBERT-large, BioBERT-large , Kế thừa CLIP	Contrastive Alignment	N/a
2	UniDCP (2023)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	CLIP ViT	RoBERTa	Cross Attention, Contrastive Alignment	N/a
3	ViP (2024)	Parameter-efficient fine tuning	Textual prompt tuning	ViT-Base	Kế thừa CLIP	Cross Attention, Contrastive Alignment	N/a
4	PLIP (2024)	Parameter-efficient fine tuning	Visual prompt tuning, Efficient Selective tuning	ViT-Base	Kế thừa CLIP	Concatnate	N/a
5	FPT (2024)	Parameter-efficient fine tuning	Visual prompt tuning	ViT-Base	N/a	Cross Attention	N/a
6	MedPrompt (2024)	Parameter-efficient fine tuning	Textual prompt tuning	Swin Transformer, ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
7	CILMP (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	ViT-Base	Kế thừa CLIP	Hadamard Product, Concatnate	N/a
8	BiomedCoOp (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	Kế thừa BiomedCLIP	Kế thừa BiomedCLIP	Contrastive Alignment	N/a
9	CLIPath (2023)	Parameter-efficient fine tuning	Adapter tuning	ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
10	FTB (2024)	Parameter-efficient fine tuning	Adapter tuning	ResNet autoencoder, DINOv2-small, DINOv2-base	BERT, BioBERT, ClinicalBERT, CXR-BERT, PubMedBERT	Cross Attention	N/a
11	MedUnA (2024)	Parameter-efficient fine tuning	Adapter tuning	ViT-Base, MedCLIP-Swin	Kế thừa CLIP, MedCLIP	No Fusion	N/a
12	TransMed (2023)	Parameter-efficient fine tuning	Direct Selective tuning	Swin Transformer, ViT-Base	BERT, LLM/GPT-4	Contrastive Alignment	N/a
13	SH-PEFT (2024)	Parameter-efficient fine tuning	Direct Selective tuning	ViT-Base	Kế thừa CLIP	No Fusion	N/a
14	LCBB (2024)	Parameter-efficient fine tuning	Efficient Selective tuning	Kế thừa MAE, MRM	Kế thừa MAE, MRM	Kế thừa MAE, MRM	N/a

Bảng 6: Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan

phụ thuộc rất lớn vào chất lượng của mô hình tiền huấn luyện gốc. Đồng thời, quá trình thiết kế câu nhắc mang đậm tính chuyên môn hay xác định vị trí tối ưu để chèn bộ điều hợp thường phức tạp và đòi hỏi nhiều thử nghiệm. Ngoài ra, việc bổ sung các thành phần này ít nhiều làm tăng tính "hộp đen" của mô hình, gây ra những thách thức về tính minh bạch khi cần giải thích các quyết định dự đoán cho bác sĩ trên thực tế lâm sàng.

Các mô hình ngôn ngữ lớn y khoa đa phương thức

Trong thời gian gần đây, với sự phát triển của các mô hình ngôn ngữ lớn được huấn luyện trên những tập dữ liệu rất lớn phục vụ cho rất nhiều tác vụ khác nhau, các mô hình này đang thể hiện sự ảnh hưởng và đa dụng trong lĩnh vực y tế với độ chính xác rất tốt khi chỉ học ít mẫu hoặc không mẫu.

Med-Flamingo [17] là mô hình đầu tiên có khả năng học ít mẫu chuyên dụng cho y tế, thông qua hội thoại tự nhiên để hỗ trợ chẩn đoán. Theo sau đó, LLaVA-Med [11] là mô hình chuyển đổi khả năng thực hiện theo chỉ dẫn (instruction-following) từ miền tổng quát sang lĩnh vực y sinh bằng cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn với 600.000 cặp, với dữ liệu hội thoại tạo ra từ chú thích ảnh y khoa được tạo ra bằng cách sử dụng GPT-4. Phương pháp này đã đề xuất quy trình huấn luyện 2 bước: (1) Căn chỉnh khái niệm; (2) Tinh chỉnh chỉ dẫn đầy đủ; 2 bước này tương ứng với giai đoạn học và suy luận. Kết quả thể hiện khả năng suy luận vượt trội trên dữ liệu chưa từng thấy.

Med-Palm M [21] là mô hình của Google, đánh dấu bước tiến từ các mô hình đơn nhiệm sang đa nhiệm quy mô lớn, có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì sử dụng các mô hình chuyên biệt cho từng tác vụ. Gần đây hơn, SkinGPT-4 [36] là hệ thống chẩn đoán da liễu tương tác đầu tiên sử dụng LLM quy mô lớn với độ chính xác cao, đã kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM), tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Dù đưa đến các phương pháp có độ chính xác cao đến rất cao trong nhiều tác vụ cùng việc hỗ trợ trong việc giao tiếp với mô hình, kích cỡ và chi phí huấn luyện (Med-Flamingo có đến 9 tỷ thông số) để vận hành các

mô hình ngôn ngữ lớn đa phương thức là một vấn đề lớn, đi kèm với vấn đề ảo giác có thể gặp phải khi đối mặt với dữ liệu mới hoặc những câu hỏi phức tạp. Ngoài ra nếu yêu cầu một độ chính xác cao - một yêu cầu quan trọng trong lĩnh vực y tế trong một tác vụ cụ thể thì đây không phải một cách tiếp cận tốt cho bài toán này.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Cấu trúc phương pháp			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	Med-Flamingo [17]	PEFT	Parameter-efficient + Domain adaptation	Frozen CLIP ViT	LLaMA-7B	Intermediate fusion	LLaMA Decoder
2	LLaVA-Med [11]	Full FT	Visual Instruction Tuning (GPT-4 data)	CLIP ViT-L/14	LLaMA	Projection Matrix	LLM (Vicuna)
3	Med-PaLM M [21]	Full FT	Instruction Fine-tuning	ViT (4B - 22B)	PaLM	Multimodal embedding	PaLM
4	SkinGPT-4 [36]	PEFT	LoRA	Vision Transformer	GPT-4	Linear alignment	LLaMA-2-13B


Bảng 7: Tổng hợp chiến lược và cấu trúc các mô hình ngôn ngữ lớn đa phương thức

Phương pháp đề xuất: Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế theo hướng tích hợp tri thức y khoa nhằm nâng cao khả năng giải thích của mô hình được minh họa ở Hình 2. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Bộ mã hóa ảnh:** Kế thừa lại mô hình ViT-Base của phương pháp BiomedCLIP [28]
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [28]
- **Bộ dung hợp dữ liệu:** Nhóm hướng đến sử dụng cơ chế *Knowledge-guided Cross-Attention* - Các khái niệm y học được trích xuất và liên kết từ văn bản lâm sàng sẽ được sử dụng để tạo thiên lệch trong quá trình tính toán cross attention. Cơ chế này giúp điều hướng mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Nhờ đó, mô hình không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.

- **Bộ phân loại:** Sử dụng một mạng phân loại (Multi-Layer Perceptron) để dự đoán nhãn bệnh lý.

Đồng thời, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán.



Hình 2: Kiến trúc tổng thể của hệ thống đề xuất

2.7 Kết quả dự kiến của đề tài

- **Số liệu định lượng:** Độ chính xác, điểm F1, AUC-ROC đạt kết quả cạnh tranh trên các bộ dữ liệu đã nêu.
- **Sản phẩm đầu ra:**
 - Hệ thống demo phân loại ảnh X-quang xương với khả năng nhận ảnh và văn bản và trả ra các lớp thuộc bộ dữ liệu Sarcoma-CTCH.
 - Giao diện đơn giản để hiển thị kết quả phân loại.
 - Cho phép trực quan hóa sau khi hiện kết quả phân loại.
- **Báo cáo khoa học:** hoàn thiện phương pháp và hệ thống để hướng tới công bố trên các hội nghị và tạp chí uy tín trong lĩnh vực Trí tuệ nhân tạo và Y sinh, như MICCAI, CVPR hoặc các tạp chí được công nhận.
- **Hướng phát triển:**
 - Mở rộng ra cho các bệnh lý khác.
 - Cải thiện độ chính xác và hiệu suất của hệ thống.

2.8 Kế hoạch thực hiện

Mục tiêu	Thời gian	Phân công	Nội dung
Khoá luận tốt nghiệp	01 tháng	Giai đoạn 1	
		Bá Thành	Khảo sát tổng quan về bài toán phân loại ảnh X-quang về xương
		Gia Kiệt	Khảo sát các mô hình tiền huấn luyện trên dữ liệu y khoa
		Bá Thành	Khảo sát các phương pháp học chuyển giao và các mô hình liên quan
	02 tháng	Giai đoạn 2	
		Cả nhóm	Phát triển mô hình học sâu đa phương thức áp dụng phương pháp học chuyển giao
		Gia Kiệt	Cài đặt môi trường, thu thập các bộ dữ liệu liên quan
		Bá Thành	Thực hiện thí nghiệm trên mô hình đề xuất
	02 tháng	Giai đoạn 3	
		Bá Thành	Phân tích so sánh kết quả thực nghiệm.
		Gia Kiệt	Xây dựng nguyên mẫu cho hệ thống phân loại
	0.5 tháng	Giai đoạn 4	
		Cả nhóm	Viết 01 bài báo khoa học cho hội nghị - tạp chí chuyên ngành trong nước hoặc ngoài nước
	0.5 tháng	Giai đoạn 5	
		Bá Thành	Viết báo cáo khoá luận tốt nghiệp.
		Gia Kiệt	Thiết kế slide cho lễ bảo vệ đề tài tốt nghiệp

Bảng 8: Kế hoạch bố trí thời gian nghiên cứu

Tài liệu tham khảo

- [1] Shruthi Bannur et al. “Learning to exploit temporal structure for biomedical vision-language processing”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2023, pp. 15016–15027.
- [2] Lynn S. Bickley, Peter G. Szilagyi, and Richard M. Hoffman. *Bates’ Guide to Physical Examination and History Taking*. 13th. Lippincott Williams & Wilkins, 2020.
- [3] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing”. In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5.

- [4] Yin Dai and Yifan Gao. “TransMed: Transformers Advance Multi-modal Medical Image Classification”. In: *CoRR* abs/2103.05940 (2021). arXiv: 2103.05940. URL: <https://arxiv.org/abs/2103.05940>.
- [5] Ye Du, Nanxi Yu, and Shujun Wang. “Medical Knowledge Intervention Prompt Tuning for Medical Image Classification”. In: *IEEE Transactions on Medical Imaging* 44.12 (2025), pp. 4945–4959. DOI: 10.1109/TMI.2025.3584841.
- [6] Xiao Fang et al. “Aligning Medical Images with General Knowledge from Large Language Models”. In: *International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. 2024. URL: <https://papers.miccai.org/miccai-2024/062-Paper1358.html>.
- [7] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [8] Yijin Huang et al. “Fine-Grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-Resolution Medical Image Classification”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Cham: Springer Nature Switzerland, 2024, pp. 124–134. ISBN: 978-3-031-72390-2.
- [9] Tarek Koleilat et al. “BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2025.
- [10] Zhengfeng Lai et al. “CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*. 2023, pp. 2374–2380.

- [11] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: <https://arxiv.org/abs/2306.00890>.
- [12] Zihan Li et al. “LViT: Language Meets Vision Transformer in Medical Image Segmentation”. In: *IEEE Transactions on Medical Imaging* 43 (Jan. 2024), pp. 96–107. DOI: 10.1109/tmi.2023.3291719. (Visited on 02/19/2024).
- [13] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: <https://arxiv.org/abs/2401.12215>.
- [14] Mingyuan Liu et al. “Sparsity- and Hybridity-Inspired Visual Parameter-Efficient Fine-Tuning for Medical Diagnosis”. In: *MICCAI (5)*. Vol. 15005. Lecture Notes in Computer Science. Springer, 2024, pp. 627–637. DOI: 10.1007/978-3-031-72086-4_59. URL: https://doi.org_59.
- [15] Xueyan Mei et al. “Artificial intelligence-enabled rapid diagnosis of patients with COVID-19”. In: *Nature Medicine* 26 (Aug. 2020), 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: <https://www.nature.com/articles/s41591-020-0931-3>.
- [16] Jong Hak Moon et al. “Multi-Modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training”. In: *IEEE Journal of Biomedical and Health Informatics* 26.12 (2022), pp. 6070–6080. DOI: 10.1109/JBHI.2022.3207502.
- [17] Michael Moor et al. *Med-Flamingo: a Multimodal Medical Few-shot Learner*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.15189. URL: <https://arxiv.org/abs/2307.15189>.
- [18] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.

- [19] Umaima Rahman et al. “Can language-guided unsupervised adaptation improve medical image classification using unpaired images and texts?” In: *2025 IEEE 22nd International Symposium on Biomedical Imaging (ISBI)*. IEEE. 2025, pp. 1–5.
- [20] Nikhil Kumar Tomar et al. “TGANet: Text-Guided Attention for Improved Polyp Segmentation”. In: *Lecture notes in computer science* (Jan. 2022), pp. 151–160. DOI: 10.1007/978-3-031-16437-8_15. (Visited on 09/04/2024).
- [21] Tao Tu et al. *Towards Generalist Biomedical AI*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.14334. URL: <https://arxiv.org/abs/2307.14334>.
- [22] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, Dec. 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: <https://aclanthology.org/2022.emnlp-main.256/>.
- [23] W.B. Saunders. *Dorland’s Illustrated Medical Dictionary*. 32nd. Elsevier Health Sciences, 2011.
- [24] Chaoyi Wu et al. “MedKLIP: Medical Knowledge Enhanced Language-Image Pre-Training for X-ray Diagnosis”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023, pp. 21372–21383.
- [25] Bin Yan and Mingtao Pei. “Clinical-BERT: Vision-Language Pre-training for Radiograph Diagnosis and Reports Generation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence* 36 (June 2022), pp. 2982–2990. DOI: 10.1609/aaai.v36i3.20204. (Visited on 07/08/2022).
- [26] Chenlu Zhan et al. “UniDCP: Unifying Multiple Medical Vision-Language Tasks via Dynamic Cross-Modal Learnable Prompts”. In:

- IEEE Transactions on Multimedia* 26 (2024), pp. 9736–9748. DOI: 10.1109/TMM.2024.3397191.
- [27] Jiajin Zhang et al. “Disease-Informed Adaptation of Vision-Language Models”. In: *IEEE Transactions on Medical Imaging* 44.10 (2025), pp. 3984–3996. DOI: 10.1109/TMI.2024.3475877.
 - [28] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoa2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoa2400640>.
 - [29] Xiaoman Zhang et al. “Knowledge-enhanced visual-language pre-training on chest radiology images”. In: *Nature Communications* 14 (July 2023). DOI: 10.1038/s41467-023-40260-7. URL: <https://arxiv.org/pdf/2302.14042.pdf>.
 - [30] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 38th International Conference on Machine Learning*. Ed. by Marina Meila and Tong Zhang. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 12133–12145. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
 - [31] Yunkun Zhang et al. “Text-Guided Foundation Model Adaptation for Pathological Image Classification”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*. Ed. by Hayit Greenspan et al. Cham: Springer Nature Switzerland, 2023, pp. 272–282. ISBN: 978-3-031-43904-9.
 - [32] Fudan Zheng et al. “Exploring low-resource medical image classification with weakly supervised prompt learning”. In: *Pattern Recognition* 149 (2024), p. 110250. ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2024.110250>. URL: <https://www.sciencedirect.com/science/article/pii/S0031320324000013>.
 - [33] Kaipeng Zheng, Weiran Huang, and Lichao Sun. “TransMed: Large Language Models Enhance Vision Transformer for Biomedical Image Classification”. In: *arXiv preprint arXiv:2312.07125* (2023).

- [34] Hong-Yu Zhou et al. “A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics”. In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).
- [35] Hong-Yu Zhou et al. “Advancing Radiograph Representation Learning with Masked Record Modeling”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=w-x7U26GM7j>.
- [36] Juexiao Zhou et al. “Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4”. In: *Nature Communications* 15 (July 2024). DOI: 10.1038/s41467-024-50043-3. URL: <https://doi.org/10.1038/s41467-024-50043-3>.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 05 tháng 04 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Đề cương chi tiết	
Mục lục	i
Danh sách hình	v
Danh sách bảng	vi
Danh mục ký hiệu	ix
Tóm tắt	x
1 Giới thiệu	1
1.1 Bối cảnh và lý do chọn đề tài	1
1.2 Động lực nghiên cứu	3
1.2.1 Kịch bản thực tế	3
1.2.2 Ý nghĩa khoa học của đề tài	5
1.2.3 Ý nghĩa thực tiễn của đề tài	5
1.3 Giới thiệu bài toán	6
1.3.1 Đầu vào	6
1.3.2 Đầu ra	7
1.3.3 Các thách thức trong bài toán	7
1.4 Mục tiêu nghiên cứu	8
1.5 Đối tượng nghiên cứu	9

1.6	Phạm vi nghiên cứu	10
1.7	Câu hỏi nghiên cứu	11
1.8	Đóng góp chính của đề tài	11
1.9	Bố cục khóa luận	13
2	Các công trình nghiên cứu liên quan	14
2.1	Các hướng tiếp cận chính và các mô hình nền tảng	15
2.1.1	Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu	15
2.1.2	Mô hình ngôn ngữ trực quan y khoa	16
2.2	Các kỹ thuật tinh chỉnh hiệu quả tham số	19
2.2.1	Tinh chỉnh sử dụng câu nhắc	20
2.2.2	Tinh chỉnh bộ điều hợp	20
2.2.3	Tinh chỉnh thích nghi hạng thấp	21
2.3	Các phương pháp phát hiện dữ liệu ngoài phân phối	22
2.3.1	Các phương pháp hậu xử lý dựa trên đầu ra của mô hình	22
2.3.2	Các phương pháp dựa trên độ không chắc chắn và tái tạo	23
2.3.3	Các phương pháp dựa trên khoảng cách	23
2.3.4	Học biểu diễn phục vụ phát hiện dữ liệu ngoài phân phối	25
2.4	Các phương pháp giải thích và đánh giá độ trung thực . .	26
2.5	Bàn luận	26
2.5.1	Hạn chế của các nghiên cứu hiện nay	26
2.5.2	Cơ sở lựa chọn và định hướng phương pháp đề xuất	28
3	Phương pháp đề xuất	30
3.1	Tổng quan phương pháp đề xuất	30
3.2	Nhánh mã hóa hình ảnh	31
3.3	Nhánh biểu diễn văn bản	33
3.4	Thích nghi tham số hiệu quả bằng LoRA	35
3.5	mô-đun dung hợp đa phương thức với chú ý chéo hai chiều	37
3.6	Huấn luyện hai giai đoạn trong quá trình ngoại tuyến . . .	40
3.6.1	Giai đoạn 1: Thích nghi miền bằng khớp ngữ nghĩa	40

3.6.2	Giai đoạn 2: học dung hợp và phân lớp	43
3.7	Phát hiện dữ liệu lệch phân phối bằng thuật toán k-NN đa phương thức	46
3.8	Suy luận trong quá trình trực tuyến	48
4	Thực nghiệm và kết quả	54
4.1	Thiết kế thực nghiệm	54
4.1.1	Chuẩn bị dữ liệu	54
4.1.2	Cấu hình thí nghiệm	60
4.1.3	Các độ đo	61
4.2	Kiểm tra hiệu năng phân lớp và đánh đổi chi phí	68
4.2.1	Mục đích	68
4.2.2	Nội dung	69
4.2.3	Kết quả	69
4.2.4	Kết luận	74
4.3	Khảo sát ảnh hưởng của các thành phần	75
4.3.1	Mục đích	75
4.3.2	Nội dung	75
4.3.3	Kết quả	75
4.3.4	Kết luận	77
4.4	Khảo sát khả năng cảnh báo dữ liệu ngoài phân phối . . .	78
4.4.1	Mục đích	78
4.4.2	Nội dung	78
4.4.3	Kết quả	78
4.4.4	Kết luận	79
4.5	Khảo sát mức phụ thuộc của dự đoán vào ảnh và văn bản	80
4.5.1	Mục đích	80
4.5.2	Nội dung	80
4.5.3	Kết quả	80
4.5.4	Kết luận	83
5	Kết luận và hướng phát triển	84
5.1	Tổng kết	84
5.2	Trả lời các câu hỏi nghiên cứu	85

5.3	Hướng phát triển	88
Tài liệu tham khảo		91
A	Chi tiết về bộ dữ liệu	98
A.1	Bộ dữ liệu BTXRD	98
A.1.1	Cấu trúc lưu trữ và đặc điểm kỹ thuật	98
A.1.2	Phương pháp tạo dữ liệu giả lâm sàng	99
A.2	Bộ dữ liệu CTCH	105
A.2.1	Cấu trúc dữ liệu và đặc điểm kỹ thuật	106
B	Cấu hình chi tiết của XBone-Net	111
B.1	Mô hình nền tảng và chuẩn hóa đầu vào	111
B.2	Kích thước biểu diễn qua các thành phần	112
B.3	Cấu hình thích nghi hạng thấp	113
B.4	Dung hợp và đầu phân lớp	114
B.5	Cấu hình huấn luyện	115
C	Kết quả chi tiết theo từng hạt giống	116
C.1	Phạm vi trình bày	116
C.1.1	Khả năng chuyển giao trực tiếp của các mô hình nền tảng	117
C.1.2	Vai trò của ảnh và văn bản	118
C.2	Phân loại khi sử dụng toàn bộ dữ liệu huấn luyện	120
C.3	Nghiên cứu loại bỏ từng thành phần	122
C.4	Kết quả đánh giá dữ liệu ngoài phân phối	123

Danh sách hình

1.1	Sơ đồ quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam)	3
1.2	Sơ đồ tích hợp hệ thống hỗ trợ phân tích (các khối tím) vào quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam)	4
3.1	Sơ đồ tổng quan phương pháp XBone-Net đề xuất	30
3.2	Phân rã hạng r với ma trận cập nhật trọng số ΔW	35
3.3	Mô-đun dung hợp bằng chú ý chéo hai chiều	38
3.4	Giai đoạn thích nghi miền bằng khớp ngữ nghĩa ảnh-văn bản	41
3.5	Giai đoạn học dung hợp và phân lớp	44
3.6	Quy trình suy luận trực tuyến và phát hiện mẫu ngoài phân phối	49
4.1	Phân bố độ tuổi và giới tính của các bệnh nhân được quan sát trong bộ dữ liệu BTXRD	56
4.2	Tích phân gradient trên ảnh X-quang và bệnh sử lâm sàng của mẫu 3563. Màu nóng trên ảnh biểu thị độ lớn đóng góp. Trong văn bản, màu cam và màu xanh lần lượt biểu thị tác động ủng hộ và phản đối lớp dự đoán.	82
A.1	Quá trình tạo văn bản minh họa cho mẫu IMG000001.jpeg	104
A.2	Quy trình sàng lọc hồ sơ cho bộ dữ liệu CTCH	105

Danh sách bảng

2.1	Tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản	16
2.2	Tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện cho các mô hình ngôn ngữ trực quan y khoa	21
3.1	Các ma trận được gắn LoRA trong hai bộ mã hóa của XBone-Net	37
4.1	Phân bổ mẫu theo các tập chia trong BTXRD	56
4.2	Phân bổ các lớp đơn nhãn sau chuẩn hóa trong bộ dữ liệu BTXRD	56
4.3	Ví dụ ảnh, nhãn và văn bản giả lâm sàng được sinh của bộ dữ liệu BTXRD	57
4.4	Phân bổ mẫu trong phân phối của CTCH theo tập dữ liệu	59
4.5	Phân bổ 22 lớp của CTCH trong ba tập dữ liệu	59
4.6	Các ví dụ ảnh, nhãn và bệnh sử lâm sàng của bộ dữ liệu CTCH	60
4.7	Môi trường thực nghiệm	60
4.8	Cấu hình chính của các thực nghiệm	61
4.9	Kết quả phân loại trên BTXRD và CTCH	69
4.10	Kết quả xếp hạng xác suất trên BTXRD và CTCH	70

4.11	Kiểm định thống kê ghép cặp về hiệu năng phân lớp giữa XBone-Net và các mô hình đối chứng qua 3 hạt giống ($N_{\text{perm}} = 10.000$). $\Delta = \text{XBone-Net} - \text{Mô hình đối chứng}$. Giá trị trong ngoặc đơn là mức ý nghĩa p_{Holm} sau hiệu chỉnh đa so sánh; màu xanh lá biểu thị XBone-Net vượt trội có ý nghĩa thống kê ($p_{\text{Holm}} < 0,05, \Delta > 0$); màu đỏ biểu thị đối chứng vượt trội có ý nghĩa ($p_{\text{Holm}} < 0,05, \Delta < 0$)	71
4.12	Kiểm định thống kê ghép cặp về chất lượng xếp hạng xác suất dự đoán giữa XBone-Net và các mô hình đối chứng qua 3 hạt giống ($N_{\text{perm}} = 10.000$). $\Delta = \text{XBone-Net} - \text{Mô hình đối chứng}$. Giá trị trong ngoặc đơn là mức ý nghĩa p_{Holm} sau hiệu chỉnh đa so sánh; màu xanh lá biểu thị XBone-Net vượt trội có ý nghĩa thống kê ($p_{\text{Holm}} < 0,05, \Delta > 0$); màu đỏ biểu thị đối chứng vượt trội có ý nghĩa ($p_{\text{Holm}} < 0,05, \Delta < 0$); văn bản thường biểu thị khác biệt không có ý nghĩa thống kê ($p_{\text{Holm}} \geq 0,05$)	72
4.13	Số lượng tham số khi sử dụng toàn bộ dữ liệu	73
4.14	Chi phí tính toán và tốc độ suy luận khi sử dụng toàn bộ dữ liệu	73
4.15	Nghiên cứu loại bỏ từng thành phần của XBone-Net trên CTCH	76
4.16	So sánh thống kê ghép cặp giữa XBone-Net và các biến thể loại bỏ thành phần	76
4.17	Đánh giá cảnh báo ngoài phân phối hậu xử lý của XBone-Net và hai biến thể	79
4.18	Đánh giá tích phân gradient và can thiệp nguồn của XBone-Net và hai biến thể	81
A.1	Cấu trúc lưu trữ của bộ dữ liệu BTXRD trong nghiên cứu	99
A.2	Đặc điểm kỹ thuật của các tệp ảnh BTXRD	99
A.3	Các mẫu câu đại diện trong ngân hàng văn bản giả lâm sàng BTXRD	101
A.4	Kết quả kiểm chứng tính toàn vẹn của dữ liệu BTXRD	102

A.5	Kiểm tra nguy cơ rò rỉ nhân trực tiếp và gián tiếp trong văn bản BTXRD	103
A.6	Cấu trúc lưu trữ của bộ dữ liệu CTCH trong nghiên cứu .	106
A.7	Đặc điểm kỹ thuật của các tệp ảnh CTCH	106
A.8	Dòng dữ liệu qua các bước sàng lọc CTCH	107
A.9	Vai trò của các trường bệnh án CTCH và nguyên tắc loại thông tin có nguy cơ rò rỉ nhân	108
A.10	Độ tương đồng ngữ nghĩa giữa bệnh sử tiếng Việt và bản dịch tiếng Anh của CTCH	109
A.11	Kết quả kiểm chứng tính toàn vẹn của quần thể CTCH được sử dụng	110
B.1	Cấu hình đầu vào và mô hình nền tảng của XBone-Net . .	112
B.2	Kích thước các biểu diễn tại những bước chính của XBone-Net	113
B.3	Các mô-đun tuyến tính được thích nghi bằng LoRA	114
B.4	Cấu hình mô-đun dung hợp và đầu phân lớp	114
B.5	Cấu hình và tiêu chí lựa chọn trạng thái trong hai pha huấn luyện	115
C.1	Kết quả phân loại zero-shot với một câu nhắc cho mỗi lớp trên BTXRD và CTCH; mỗi mô hình được đánh giá một lần tại hạt giống 42.	117
C.2	So sánh giữa các phương thức đầu vào trên hai bộ dữ liệu BTXRD và CTCH	119
C.3	Kết quả phân loại của từng hạt giống trên BTXRD	121
C.4	Kết quả phân loại của từng hạt giống trên CTCH	121
C.5	Kết quả phân loại của từng hạt giống trong nghiên cứu loại bỏ thành phần trên CTCH. Cấu hình đầy đủ được tô xám.	123
C.6	Kết quả cảnh báo OOD của từng hạt giống trên kịch bản OOD CTCH bằng điểm tổ hợp đa phương thức	124
C.7	Kết quả cảnh báo OOD của từng hạt giống trên kịch bản BTXRD bằng điểm tổ hợp đa phương thức	124

Danh mục ký hiệu

Ký hiệu	Mô tả	Trang
x^{img}	Ảnh X-quang đầu vào của hệ thống.	6
H, W, C	Chiều cao, chiều rộng và số kênh của ảnh.	6
x^{txt}	Chuỗi văn bản lâm sàng đầu vào.	6
w_t, T	Token tại vị trí t và tổng số token (hoặc nhiệt độ).	6
$\mathcal{Y}, y_k, K$	Tập nhãn trong phân phối, lớp thứ k và tổng số lớp.	6
$\hat{y}$	Nhãn dự đoán cuối cùng.	6
ω_{OOD}	Cảnh báo mẫu ngoài phân phối.	6
$s_{\text{OOD}}(\cdot)$	Điểm ngoài phân phối của mẫu đầu vào.	6
$p(y_k x^{\text{img}}, x^{\text{txt}})$	Xác suất dự đoán lớp y_k .	6
$E(x)$	Energy score của mẫu x .	22
$f_i(x)$	Logit phân loại của lớp i .	22
$d_E(z, c_k)$	Khoảng cách Euclid giữa đặc trưng z và tâm lớp c_k .	24
$d_M(z, \mu_k)$	Khoảng cách Mahalanobis giữa đặc trưng z và trung bình μ_k .	24
Σ, λ, I	Ma trận hiệp phương sai, hệ số điều chuẩn và ma trận đơn vị.	24
S_k, f_θ, c_k	Tập hỗ trợ, hàm đặc trưng và prototype của lớp k .	25
$\mathcal{D}_{\text{train}}, N$	Tập dữ liệu và tổng số mẫu huấn luyện.	31
X_i, R_i, y_i	Ảnh X-quang, bệnh sử và nhãn của mẫu thứ i .	31
TP_c, FP_c, TN_c, FN_c	Các trường hợp dương/âm tính thật/giả của lớp c .	61
$\text{TPR}_c, \text{FPR}_c$	Tỷ lệ dương tính thật và dương tính giả.	61
AUROC_c	Diện tích dưới đường cong ROC của lớp c .	63
$\text{Precision}_c, \text{Recall}_c$	Độ chính xác và độ thu hồi của lớp c .	62
AUPRC_c	Average Precision (AP) của lớp c .	63
$\mathcal{D}_{\text{ID}}, \mathcal{D}_{\text{OOD}}$	Tập dữ liệu trong phân phối và ngoài phân phối.	61
τ_{alert}	Ngưỡng cảnh báo OOD được hiệu chỉnh trên tập xác thực.	48
τ_{95}^{test}	Ngưỡng đánh giá $\text{FPR}@95\%\text{TPR}$ được xác định trên tập kiểm thử.	65
$\text{Precision}_{\text{OOD}}, \text{Recall}_{\text{OOD}}$	Precision và recall khi xem OOD là lớp dương.	65

Tóm tắt

Phân lớp ảnh X-quang xương bằng học sâu còn gặp khó khăn do dữ liệu gán nhãn hạn chế, mất cân bằng lớp, tổn thương nhỏ và nguy cơ tiếp nhận dữ liệu khác với phân phối huấn luyện. Khóa luận hướng đến xây dựng và đánh giá XBone-Net, mô hình đa phương thức kết hợp ảnh X-quang với văn bản để hỗ trợ phân lớp, cảnh báo ngoài phân phối và phân tích nguồn thông tin của dự đoán. XBone-Net kế thừa BiomedCLIP, thích nghi các bộ mã hóa bằng LoRA, sử dụng chuỗi đơn vị ảnh và văn bản gốc của mạng nền, dung hợp hai phương thức bằng chú ý chéo hai chiều và dự đoán bằng đầu phân lớp tuyến tính. Cơ chế tổ hợp đa phương thức (Multi-modal Ensemble) được khảo sát cho cảnh báo ngoài phân phối, còn tích phân gradient và can thiệp đầu vào được dùng để đánh giá lời giải thích. Thực nghiệm trên BTXRD và CTCH với ba hạt giống bao gồm phân loại, nghiên cứu thành phần, học ít mẫu, chi phí tính toán, phát hiện ngoài phân phối và khả năng giải thích. Trên CTCH, XBone-Net đạt Macro-F1 $0,5558 \pm 0,0072$ và Macro-AUROC $0,9473 \pm 0,0246$, trong khi mô hình chỉ cập nhật khoảng 4,13% tổng số tham số trong quá trình huấn luyện. Trên BTXRD, cảnh báo OOD đạt AUROC-OOD $0,9321 \pm 0,0174$, và trên CTCH gần miền đạt AUROC-OOD $0,7598 \pm 0,0219$. Kết quả cho thấy XBone-Net duy trì hiệu năng cạnh tranh và hỗ trợ đánh giá hiệu quả tham số, cảnh báo ngoài phân phối và khả năng truy vết dự đoán. Tuy nhiên, mô hình chưa đạt ưu thế nhất quán và cần được kiểm định trên dữ liệu đa trung tâm trước khi xem xét ứng dụng thực tế.

Chương 1

Giới thiệu

Chương này trình bày bối cảnh, vấn đề nghiên cứu và phạm vi của bài toán phân lớp ảnh X-quang xương bằng học sâu đa phương thức. Trọng tâm của khóa luận là khai thác đồng thời ảnh X-quang và nguồn văn bản đi kèm. Khóa luận áp dụng hai kịch bản dữ liệu gồm nguồn văn bản chính là bệnh sử lâm sàng có sẵn trong bệnh án và văn bản lâm sàng được sinh ngoại tuyến từ siêu dữ liệu do bộ dữ liệu không cung cấp bệnh sử tương ứng với từng ảnh. Hai nguồn này được phân tích riêng vì không có mức độ xác thực lâm sàng và quan hệ với nhãn giống nhau. Chương cũng xác định các thách thức liên quan đến độ phân giải ảnh, dữ liệu hạn chế, mất cân bằng lớp, dữ liệu ngoài phân phối và khả năng giải thích để từ đó xây dựng mục tiêu, câu hỏi nghiên cứu và các đóng góp của khóa luận.

1.1 Bối cảnh và lý do chọn đề tài

Hệ xương đóng vai trò quan trọng trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ khảo sát cấu trúc xương, phát hiện tổn thương, bất thường và hỗ trợ định hướng điều trị.

Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay có thể gặp khó khăn khi tổn thương nhỏ, ảnh có tương phản thấp hoặc khi số lượng ca cần đọc lớn, lúc đó kết quả phụ thuộc đáng kể vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ.

Để giải quyết các thách thức này, nhiều nghiên cứu đã ứng dụng các mô hình học sâu vào việc hỗ trợ phân tích và phân lớp ảnh X-quang và đưa ra quyết định dựa trên thông tin trên ảnh như các kiến trúc mạng nơ-ron tích chập ResNet [12] và DenseNet [16]. Tuy nhiên, các mô hình chỉ sử dụng hình ảnh không khai thác được các thông tin lâm sàng có sẵn trước khi đọc ảnh, chẳng hạn triệu chứng, tiền sử bệnh hoặc cơ chế chấn thương. Trong khi đó, quá trình ra quyết định lâm sàng thực tế của bác sĩ thường dựa trên sự kết hợp giữa bằng chứng hình ảnh và bối cảnh bệnh hoặc chấn thương của người bệnh.


Dựa vào thực tế đó, các mô hình ngôn ngữ trực quan y khoa như MedCLIP [38], BiomedCLIP [42] và BioViL [1] cung cấp một hướng tiếp cận phù hợp để học biểu diễn chung giữa ảnh và văn bản. Nhờ được tiền huấn luyện trên các tập dữ liệu ảnh–văn bản y khoa quy mô lớn, các mô hình này có thể được chuyển giao sang những bài toán y khoa ở tác vụ đích.

Tuy nhiên, việc chuyển giao các mô hình ngôn ngữ trực quan y khoa sang bài toán phân lớp ảnh X-quang xương vẫn gặp nhiều trở ngại. Những trở ngại này xuất phát từ sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu đầu vào thực tế, số lượng dữ liệu gán nhãn hạn chế và mất cân bằng, nguy cơ xuất hiện dữ liệu ngoài phân phối, yêu cầu bảo toàn các tổn thương nhỏ trên ảnh có độ phân giải cao, cũng như nhu cầu giải thích quyết định của mô hình.

1.2 Động lực nghiên cứu

1.2.1 Kịch bản thực tế


Trong thực hành lâm sàng với các ca bệnh có chỉ định chụp X-quang, quy trình chẩn đoán bệnh lý xương thường tuân theo Hình 1.1 bao gồm các bước: bác sĩ chính khai thác bệnh sử, khám lâm sàng, chỉ định chụp X-quang. Sau đó, bác sĩ đọc ảnh sẽ phân tích ảnh X-quang và kết hợp với các ngữ cảnh lâm sàng để đưa ra nhận định cận lâm sàng. Cuối cùng, bác sĩ chính sử dụng tất cả các thông tin kể trên để làm căn cứ cho quyết định chẩn đoán cuối cùng và đưa ra hướng xử trí.



Hình 1.1: Sơ đồ quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam)

Hệ thống được đề xuất trong khóa luận được thiết kế nhằm hỗ trợ quá trình phân tích ảnh X-quang bằng cách khai thác đồng thời ảnh X-quang và dữ liệu văn bản đi kèm để dự đoán lớp bệnh lý của bệnh nhân như thể hiện ở Hình 1.2. Hai kịch bản văn bản là bệnh sử có sẵn trong bệnh án

và văn bản lâm sàng được chuẩn bị trước do dữ liệu nguồn không có bệnh sử tự do. Việc kết hợp hai nguồn dữ liệu cho phép khảo sát khả năng học biểu diễn đa phương thức, nhưng kết quả có được từ văn bản tổng hợp không được diễn giải tương đương với việc sử dụng bệnh sử tự nhiên.



Hình 1.2: Sơ đồ tích hợp hệ thống hỗ trợ phân tích (các khối tím) vào quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam)

Đề tài xem trí tuệ nhân tạo là công cụ hỗ trợ làm rõ quy trình suy luận lâm sàng, không thay thế bác sĩ hay làm thay đổi bản chất của hoạt động khám và chẩn đoán. Theo định hướng này, thông tin đầu vào, nguồn bằng chứng và mức độ bất định cần được biểu diễn có cấu trúc, có thể kiểm tra và kèm cảnh báo khi mô hình gặp dữ liệu không phù hợp với phân phối đã quan sát. Các đầu ra cũng cần được lưu lại để phục vụ truy cứu, giám sát sai lệch và cải tiến hệ thống. Trong phạm vi khóa luận, định hướng này được hiện thực hóa một phần thông qua đầu vào ảnh-bệnh sử, cảnh báo dữ liệu ngoài phân phối và phân tích mức quy đóng. Các cơ chế nhật ký vận hành và đánh giá trong môi trường lâm sàng được xem là hướng phát triển tiếp theo.

1.2.2 Ý nghĩa khoa học của đề tài

Đề tài cung cấp đánh giá thực nghiệm về việc kết hợp ảnh X-quang với văn bản trong hai điều kiện dữ liệu lâm sàng khác nhau. Một kịch bản cho phép khảo sát bệnh sử lâm sàng có sẵn trong bệnh án, trong khi kịch bản còn lại được sử dụng để khảo sát quy trình đa phương thức với văn bản tổng hợp từ siêu dữ liệu. Sự phân biệt này giúp tránh quy kết giá trị lâm sàng của văn bản tổng hợp cho bệnh sử tự nhiên.

Nghiên cứu đồng thời khảo sát khả năng thích nghi của mô hình ngôn ngữ trực quan y khoa được tiền huấn luyện trên dữ liệu quy mô lớn đối với dữ liệu X-quang xương có quy mô hạn chế và phân bố mất cân bằng. Kết quả nghiên cứu cung cấp thêm cơ sở thực nghiệm cho việc ứng dụng các mô hình nền tảng đa phương thức vào những miền y khoa chuyên biệt.

Bên cạnh hiệu quả phân lớp, đề tài xem xét khả năng nhận diện dữ liệu ngoài phân phối và phân tích các vùng ảnh có ảnh hưởng đến dự đoán. Việc đánh giá đồng thời các khía cạnh này góp phần mở rộng tiêu chí nghiên cứu từ độ chính xác đơn thuần sang độ bền dưới các kịch bản dịch chuyển đã xác định, độ tin cậy và tính minh bạch của hệ thống.

1.2.3 Ý nghĩa thực tiễn của đề tài

Hệ thống được đề xuất hướng đến hỗ trợ bác sĩ trong quá trình phân tích ảnh X-quang bằng cách kết hợp thông tin từ ảnh và dữ liệu lâm sàng ban đầu để đưa ra kết quả phân lớp. Khả năng phù hợp với quy trình khám chữa bệnh thực tế được xem xét chủ yếu trên kịch bản bệnh sử có sẵn trong bệnh án. Kịch bản còn lại đóng vai trò bổ sung để đánh giá thuật toán với văn bản tổng hợp và không được dùng làm bằng chứng trực tiếp về hiệu quả triển khai với bệnh sử thực.

Ngoài ra, quá trình nghiên cứu góp phần xây dựng và chuẩn hóa một bộ dữ liệu đa phương thức gồm ảnh X-quang và bệnh sử lâm sàng từ dữ liệu thực tế tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh. Bộ dữ liệu và quy trình xử lý có thể tạo nền tảng cho các nghiên cứu tiếp theo về phân lớp bệnh lý xương và mô hình ngôn ngữ trực quan y khoa tại Việt Nam.

Đồng thời, mô hình cung cấp bản đồ nhiệt đóng góp để khảo sát những vùng ảnh và đơn vị từ ngữ có liên hệ với dự đoán, cùng các điểm bất thường hậu xử lý cho dữ liệu ngoài phân phối. Các đầu ra này phục vụ phân tích mô hình, chưa phải bằng chứng định vị tổn thương hoặc cơ chế bảo đảm an toàn lâm sàng.

1.3 Giới thiệu bài toán

Bài toán được nghiên cứu trong đề tài là bài toán phân lớp đa lớp ảnh X-quang sử dụng học sâu đa phương thức. Mục tiêu của hệ thống là dự đoán các loại bệnh hoặc tổn thương dựa đồng thời vào ảnh X-quang và văn bản đi kèm.

1.3.1 Đầu vào

Hệ thống nhận vào các nguồn dữ liệu sau:

- **Ảnh X-quang của bệnh nhân:**

$$x^{\text{img}} \in \mathbb{R}^{H \times W \times C}$$

Với H, W là chiều cao và chiều rộng ảnh, C là số kênh màu của ảnh.

- **Văn bản đi kèm:** bệnh sử lâm sàng hoặc văn bản lâm sàng được sinh từ siêu dữ liệu.

$$x^{\text{txt}} = (w_1, w_2, \dots, w_T)$$

Với w_t là đơn vị từ ngữ tại vị trí thứ t trong văn bản, T là số lượng đơn vị từ ngữ trong văn bản.

- **Tập nhãn được định nghĩa trước:**

$$\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$$

với K là số lớp bệnh cần phân lớp.

1.3.2 Đầu ra

Hệ thống sinh ra ba đầu ra chính:

- **Nhãn dự đoán cuối cùng:**

$$\hat{y} = \arg \max_{y_k \in \mathcal{Y}} p(y_k | x^{\text{img}}, x^{\text{txt}}),$$

Với $p(y_k | x^{\text{img}}, x^{\text{txt}})$ là xác suất dự đoán của lớp y_k .

- **Cảnh báo dữ liệu ngoài phân phối:**

$$\omega_{\text{OOD}} = \begin{cases} 1, & \text{nếu } s_{\text{OOD}}(x^{\text{img}}, x^{\text{txt}}) > \tau_{\text{alert}}, \\ 0, & \text{ngược lại,} \end{cases}$$

Với $s_{\text{OOD}}(x^{\text{img}}, x^{\text{txt}})$ là điểm ngoài phân phối của mẫu đầu vào, τ_{alert} là ngưỡng cảnh báo được hiệu chỉnh trước trên tập xác thực và $\omega_{\text{OOD}} = 1$ biểu thị rằng mẫu được phát hiện là dữ liệu ngoài phân phối.

- **Thông tin hỗ trợ giải thích:** Hệ thống sinh ra các bản đồ nhiệt đóng góp cho ảnh toàn cục, các vùng ảnh cục bộ và văn bản đi kèm nhằm khảo sát mức độ liên hệ của từng nguồn thông tin với dự đoán của mô hình.

1.3.3 Các thách thức trong bài toán

Mặc dù các mô hình học sâu đa phương thức đã đạt được nhiều kết quả tích cực, bài toán vẫn tồn tại nhiều thách thức cần được giải quyết:

- **Sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu đầu vào thực tế:** Tồn tại sự chênh lệch giữa các bộ dữ liệu đa phương thức hiện có, thường là cặp ảnh X-quang và báo cáo đọc ảnh, so với dữ liệu đầu vào được khảo sát trong khóa luận gồm ảnh X-quang kết hợp với bệnh sử hoặc thông tin lâm sàng ban đầu. Sự khác biệt này có thể hạn chế khả năng chuyển giao trực tiếp của mô hình.

- **Sự khác biệt về không gian và ngữ nghĩa giữa dữ liệu hình ảnh và dữ liệu văn bản:** Sự khác biệt này gây khó khăn cho quá trình học biểu diễn chung, yêu cầu một cơ chế dung hợp hiệu quả.
- **Bảo toàn tổn thương nhỏ trên ảnh độ phân giải cao:** Việc co toàn bộ ảnh X-quang về kích thước cố định ở độ phân giải thấp của các mô hình hiện nay có thể làm mất đi các chi tiết cục bộ quan trọng, đặc biệt là các tổn thương nhỏ, dẫn đến hiệu quả phân lớp bị hạn chế.
- **Hạn chế của dữ liệu thực tế:** Dữ liệu y tế thường có số lượng hạn chế và mất cân bằng giữa các loại bệnh, đặt ra yêu cầu đặc biệt về thiết kế mô hình để tận dụng tối đa thông tin có sẵn.
- **Dữ liệu ngoài phân phối:** Các bộ phân lớp theo giả định tập đóng chưa được thiết kế để xử lý các trường hợp dữ liệu ngoài phân phối, dẫn đến nguy cơ đưa ra dự đoán không chính xác với độ tin cậy cao đối với những ca bệnh mới chưa từng xuất hiện trong dữ liệu huấn luyện, đặt ra yêu cầu về khả năng tổng quát hóa và thích ứng của mô hình.
- **Khả năng giải thích của mô hình:** Khả năng giải thích của các mô hình vẫn còn hạn chế khiến độ tin cậy của người dùng vào các dự đoán của hệ thống là không cao, gây khó khăn cho việc triển khai trong thực tế lâm sàng.

1.4 Mục tiêu nghiên cứu

Đề tài hướng đến xây dựng và đánh giá một hệ thống học sâu đa phương thức phục vụ phân lớp bệnh lý trên ảnh X-quang xương bằng cách kết hợp thông tin hình ảnh và bệnh sử lâm sàng. Hệ thống được nghiên cứu trong điều kiện dữ liệu hạn chế và mất cân bằng lớp, đồng thời được đánh giá về hiệu năng phân lớp, chi phí tính toán, khả năng cảnh báo dữ liệu ngoài phân phối và mức độ giải thích của dự đoán.

Các mục tiêu cụ thể của đề tài bao gồm:

1. Xây dựng XBone-Net bằng cách thích nghi BioMedCLIP với LoRA, quy trình huấn luyện hai giai đoạn và mô-đun dung hợp ảnh–văn bản cho bài toán phân lớp X-quang xương.
2. Đánh giá hiệu năng phân lớp của XBone-Net so với các mô hình đối chứng trong thiết lập ít mẫu và toàn bộ dữ liệu, đồng thời định lượng sự đánh đổi giữa số tham số cập nhật và chi phí suy luận.
3. Thực hiện các thí nghiệm loại bỏ và thay thế thành phần để xác định ảnh hưởng của quy trình huấn luyện, cơ chế dung hợp, cách mã hóa ảnh và đầu phân lớp đến các nhóm độ đo khác nhau.
4. Đánh giá hai đầu ra hỗ trợ của hệ thống gồm cảnh báo dữ liệu ngoài phân phối bằng các điểm bất thường hậu xử lý và truy vết nguồn phụ thuộc của dự đoán bằng tích phân gradient kết hợp can thiệp đầu vào.

1.5 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học sâu đa phương thức trong bài toán phân lớp bệnh lý trên ảnh X-quang xương, sử dụng đồng thời thông tin hình ảnh và bệnh sử lâm sàng. Nghiên cứu tập trung vào các nhóm mô hình và thành phần kỹ thuật sau:

- Các mô hình ngôn ngữ trực quan được tiền huấn luyện trên dữ liệu tổng quát hoặc dữ liệu y khoa, đóng vai trò bộ mã hóa đặc trưng hình ảnh và văn bản.
- Các phương pháp biểu diễn ảnh X-quang bằng đơn vị toàn cục và chuỗi đơn vị mảnh ảnh từ bộ mã hóa thị giác tiền huấn luyện.
- Các chiến lược dung hợp đa phương thức, bao gồm phép nối đặc trưng và cơ chế chú ý chéo, để kết hợp biểu diễn hình ảnh với thông tin bệnh sử lâm sàng.

- Các phương pháp tinh chỉnh hiệu quả tham số cho mô hình tiền huấn luyện quy mô lớn, tập trung vào việc giới hạn số tham số cần cập nhật trong quá trình huấn luyện.
- Đầu phân lớp tuyến tính kết hợp hàm mất mát có trọng số để xử lý bài toán phân lớp đa lớp trên dữ liệu mất cân bằng.
- Các phương pháp phát hiện dữ liệu ngoài phân phối và trực quan hóa bản đồ tích phân gradient nhằm hỗ trợ đánh giá độ tin cậy và khả năng giải thích của mô hình.

1.6 Phạm vi nghiên cứu

Đề tài tập trung vào bài toán phân lớp đa lớp bệnh lý xương trên ảnh X-quang, kết hợp với bệnh sử lâm sàng. Phạm vi cụ thể bao gồm:

- **Dữ liệu:** Nghiên cứu sử dụng bộ dữ liệu BTXRD [40] gồm 10 lớp bệnh lý xương và bộ dữ liệu CTCH được thu thập từ Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.
- **Dữ liệu văn bản:** Bộ dữ liệu CTCH sử dụng bệnh sử có sẵn trong bệnh án, gồm lý do vào viện, diễn tiến bệnh và tiền sử. Bộ dữ liệu BTXRD không có bệnh sử tự do nên sử dụng văn bản lâm sàng được sinh ngoại tuyến từ siêu dữ liệu. Vì mẫu câu tổng hợp có phụ thuộc vào các cờ nhóm bệnh, kết quả BTXRD chỉ phản ánh thiết lập văn bản tổng hợp và không được xem là bằng chứng tương đương với bệnh sử lâm sàng tự nhiên.
- **Vai trò hệ thống:** Hệ thống được thiết kế làm công cụ hỗ trợ phân tích ảnh, không thay thế vai trò của bác sĩ trong quá trình ra quyết định.
- **Giới hạn:** Đề tài không tập trung vào các bài toán phát hiện đối tượng, phân đoạn ảnh hay sinh báo cáo y khoa tự động.

1.7 Câu hỏi nghiên cứu

Để đạt được các mục tiêu đã đề ra, nghiên cứu tập trung trả lời các câu hỏi sau:

- **Câu hỏi nghiên cứu 1:** Trong tác vụ phân loại, XBone-Net đạt mức hiệu năng phân lớp nào so với các mô hình đối chứng, đồng thời đánh đổi như thế nào giữa số tham số cần cập nhật và chi phí suy luận?
- **Câu hỏi nghiên cứu 2:** Các thành phần do khóa luận lựa chọn cho XBone-Net, gồm quy trình huấn luyện và cơ chế dung hợp, ảnh hưởng như thế nào đến quyết định lớp và chất lượng xếp hạng?
- **Câu hỏi nghiên cứu 3:** Điểm cảnh báo hậu xử lý được xây dựng từ không gian biểu diễn của XBone-Net có thể phân biệt dữ liệu trong phân phối với các dạng dữ liệu ngoài phân phối được xác định trước ở mức nào, và giới hạn của cảnh báo này khác nhau ra sao giữa dịch chuyển gần miền và dịch chuyển khác bộ dữ liệu?
- **Câu hỏi nghiên cứu 4:** Tích phân gradient kết hợp với can thiệp đầu vào phản ánh mức phụ thuộc của dự đoán XBone-Net vào thông tin hình ảnh và văn bản như thế nào, và thứ tự quy đóng có làm thay đổi đầu ra rõ hơn đối chứng ngẫu nhiên hay không?

1.8 Đóng góp chính của đề tài

Các đóng góp của đề tài tập trung vào quy trình thích nghi, cách đánh giá các lựa chọn do khóa luận đề xuất và phân tích giới hạn của hệ thống. Đồng thời, việc sử dụng kết hợp ảnh và văn bản không được xem là một đóng góp cần chứng minh lại. Cụ thể:

1. **Quy trình thích nghi XBone-Net:** Đề xuất và hiện thực hóa quy trình thích nghi BioMedCLIP cho phân lớp X-quang xương bằng LoRA, huấn luyện hai pha và chú ý chéo hai chiều, nhằm hạn chế số tham số cần cập nhật trong khi khai thác biểu diễn ảnh–văn bản. CTCH sử dụng bệnh sử có sẵn trong bệnh án, trong khi BTXRD sử dụng văn bản tổng hợp từ siêu dữ liệu. Vì hai nguồn văn bản không có mức độ xác thực lâm sàng tương đương nên kết quả trên từng bộ dữ liệu được diễn giải riêng.
2. **Bằng chứng về hiệu năng, thành phần và chi phí:** Đánh giá XBone-Net với các mô hình đối chứng trong thiết lập sử dụng toàn bộ dữ liệu, khảo sát riêng vai trò của quy trình huấn luyện hai pha và cơ chế dung hợp, đồng thời đo số tham số cập nhật, số phép toán, thông lượng, độ trễ và bộ nhớ GPU cực đại. Qua đó, phân tích làm rõ mức hiệu năng phân lớp cạnh tranh, lợi ích về tham số cập nhật và phần chi phí suy luận phải đánh đổi.
3. **Đánh giá cảnh báo dữ liệu ngoài phân phối:** Xây dựng điểm cảnh báo hậu xử lý từ biểu diễn ảnh và văn bản, sau đó đánh giá trong hai kịch bản được xác định trước: dịch chuyển gần miền trên CTCH và dịch chuyển khác bộ dữ liệu sang BTXRD. Đây là tín hiệu hỗ trợ, không phải cơ chế bảo đảm phát hiện hoặc từ chối dự đoán tự động.
4. **Truy vết nguồn phụ thuộc của dự đoán:** Kết hợp tích phân gradient với can thiệp đầu vào để khảo sát mức phụ thuộc của dự đoán vào thông tin hình ảnh và văn bản. Phân tích cung cấp bằng chứng thăm dò về độ trung thực của thứ tự quy đóng và hỗ trợ truy vết đầu ra, nhưng không xác lập đóng góp nhân quả, khả năng định vị tổn thương hoặc độ đúng lâm sàng.

1.9 Bố cục khóa luận

Khóa luận được tổ chức thành năm chương như sau:

Chương 1: Giới thiệu. Chương này trình bày bối cảnh nghiên cứu, vấn đề đặt ra, mục tiêu, đối tượng, câu hỏi nghiên cứu và các đóng góp chính của đề tài. Nội dung chương đóng vai trò định hướng cho toàn bộ khóa luận.

Chương 2: Các công trình nghiên cứu liên quan. Chương này tổng quan các nghiên cứu về mô hình ngôn ngữ trực quan, phân lớp ảnh X-quang xương, xử lý ảnh độ phân giải cao, dung hợp đa phương thức, tinh chỉnh hiệu quả tham số, phát hiện dữ liệu ngoài phân phối và khả năng giải thích mô hình. Trên cơ sở đó, chương xác định khoảng trống nghiên cứu và định vị phương pháp đề xuất so với các công trình trước.

Chương 3: Phương pháp đề xuất. Chương này mô tả kiến trúc XBone-Net, quy trình xử lý ảnh và văn bản, cơ chế dung hợp hai chiều, đầu phân lớp tuyến tính, các hàm mất mát và chiến lược huấn luyện hai giai đoạn với LoRA. Quy trình phát hiện dữ liệu ngoài phân phối và giải thích dự đoán cũng được trình bày trong chương này.

Chương 4: Thực nghiệm và kết quả. Chương này giới thiệu các bộ dữ liệu, thiết lập thực nghiệm, mô hình đối sánh và các độ đo đánh giá. Các kết quả không mẫu, mẫu hạn chế, toàn bộ mẫu, nghiên cứu loại bỏ thành phần, đánh giá hiệu quả tính toán, phát hiện dữ liệu ngoài phân phối và giải thích mô hình được phân tích nhằm làm rõ ưu điểm, hạn chế và sự đánh đổi của phương pháp đề xuất.

Chương 5: Kết luận và hướng phát triển. Chương cuối tổng kết các kết quả đạt được, trả lời các câu hỏi nghiên cứu, chỉ ra những hạn chế còn tồn tại và đề xuất các hướng cải tiến, mở rộng trong tương lai.

Chương 2

Các công trình nghiên cứu liên quan

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Nhằm xác lập cơ sở cho việc thiết kế hệ thống phân lớp, phần này sẽ mô tả tổng quan các nghiên cứu về các mô hình nền tảng của các cách tiếp cận khác nhau cho bài toán phân lớp ảnh y khoa, đặc biệt là cách kết hợp ngữ cảnh toàn cục với đặc trưng cục bộ, các kỹ thuật tinh chỉnh hiệu quả tham số và phương pháp phát hiện dữ liệu ngoài phân phối. Trên cơ sở đó, đối chiếu ưu điểm, hạn chế và mức độ phù hợp của các hướng tiếp cận hiện có đối với dữ liệu thực tế, chương xác định khoảng trống nghiên cứu và làm rõ cơ sở lựa chọn các thành phần trong phương pháp được đề xuất ở Chương 3.

2.1 Các hướng tiếp cận chính và các mô hình nền tảng

2.1.1 Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu

Sự kết hợp giữa dữ liệu cận lâm sàng và báo cáo lâm sàng, lịch sử bệnh lý đã tạo ra những bước tiến lớn trong việc cải thiện độ chính xác của các mô hình chẩn đoán, đặc biệt là thông qua việc sử dụng văn bản để bù đắp những thiếu sót thông tin mà hình ảnh đơn thuần không thể cung cấp, hoặc giúp mô hình tập trung vào những vùng trên ảnh được xác định bởi thông tin từ nguồn văn bản. Nghiên cứu của X. Mei [22] trong việc chẩn đoán COVID-19 là một minh chứng rõ nét: khi ảnh chụp CT ngực ở giai đoạn sớm có thể chưa biểu hiện bất thường, việc tích hợp thông tin lâm sàng thông qua mạng MLP với đặc trưng ảnh từ CNN đã giúp mô hình nhận diện chính xác 68% số bệnh nhân dương tính mà các bác sĩ X-quang đã bỏ sót. Mô hình TieNet [37] đã mã hóa các báo cáo y tế và tích hợp các cơ chế chú ý đa cấp để giống hàng các từ mang ý nghĩa quan trọng với các vùng ảnh tương ứng, cải thiện trung bình 6% chỉ số AUC so với các mô hình chỉ dùng ảnh. Gần đây, IRENE [45] đưa tất cả dữ liệu về một dạng đơn vị biểu diễn chung và sử dụng một mô hình Transformer duy nhất, cho phép văn bản trực tiếp tương tác và giải thích các đơn vị biểu diễn của ảnh ở cấp độ cục bộ.

Nhìn chung, những nghiên cứu này minh chứng rằng sự đóng góp của nhiều nguồn dữ liệu, đặc biệt là văn bản đã đi từ việc chỉ là một véc-tơ thông tin ghép nối thêm, trở thành một thành phần cốt lõi có khả năng giống hàng ngữ nghĩa và định hướng trong cơ chế chú ý. Tuy nhiên, các mô hình xây dựng từ đầu thường đòi hỏi dữ liệu ghép cặp quy mô lớn và chi phí huấn luyện cao, tạo tiền đề cho sự xuất hiện của các mô hình ngôn ngữ trực quan y khoa.

2.1.2 Mô hình ngôn ngữ trực quan y khoa

Các mô hình ngôn ngữ trực quan đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu, các mô hình ngôn ngữ trực quan nói chung và các mô hình ngôn ngữ trực quan y khoa nói riêng tập trung vào hai nguồn dữ liệu đầu vào chính là ảnh và văn bản. Các mô hình ngôn ngữ trực quan y khoa kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet [12] hoặc ViT [7] cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, các mô hình ngôn ngữ trực quan y khoa tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Chiến lược học tương phản là hướng tiếp cận được ứng dụng rộng rãi nhất. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh-văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau. Bảng 2.1 tổng hợp các mô hình ngôn ngữ trực quan y khoa tiêu biểu sử dụng học tương phản.

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Phương pháp			
			Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	Học tương phản	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	Học tương phản	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	Học tương phản	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	Học tương phản	ViT-Base	PubMedBERT	Contrastive Alignment	N/a

Bảng 2.1: Tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản

ConVIRT [43] là nghiên cứu tiên phong áp dụng học tương phản cho dữ liệu y khoa, sử dụng ResNet50 và BERT để tối ưu bộ mã hóa ảnh và văn bản, đạt độ chính xác 90,3% trên bộ dữ liệu COVIDx. GLoRIA [17] mở rộng hướng tiếp cận này bằng cách kết hợp hai hàm mất mát toàn cục

và cục bộ, cho phép căn chỉnh chi tiết giữa các vùng trong ảnh và các từ trong câu. MedCLIP [38] đề xuất cơ chế tách cặp và trích xuất tri thức cùng hàm mất mát khớp ngữ nghĩa nhằm giải quyết vấn đề âm tính giả khi các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý. BiomedCLIP [42] kế thừa kiến trúc CLIP [28] với bộ mã hóa ViT-Base và PubMedBERT, được tiền huấn luyện trên 15 triệu cặp dữ liệu từ tập PMC-15M, đạt độ chính xác phân lớp 83%, giúp mô hình có độ phủ và khả năng tổng quát tốt với nhiều nguồn dữ liệu và tác vụ y khoa.

Ngoài học tương phản, các hướng tiếp cận khác bao gồm học có che giấu và tích hợp tri thức y khoa. Tuy nhiên, các phương pháp này thường phụ thuộc vào nguồn dữ liệu ghép cặp sẵn hoặc đồ thị tri thức chuyên biệt, hạn chế khả năng ứng dụng trên các bài toán không có sẵn nguồn tri thức ngoài. Song song với các mô hình ngôn ngữ trực quan y khoa, sự phát triển của các mô hình ngôn ngữ lớn đa phương thức như Med-Flamingo [23], LLaVA-Med [19] hay Med-PaLM M [36] đã cho thấy tiềm năng trong các tác vụ hội thoại và hỗ trợ ra quyết định y khoa. Tuy nhiên, các mô hình này thường có quy mô rất lớn, chi phí huấn luyện và suy luận cao, đồng thời vẫn tồn tại nguy cơ tạo ra thông tin không chính xác. Do đó, đối với các bài toán phân lớp chuyên biệt như phân lớp ảnh X-quang xương, việc sử dụng các mô hình ngôn ngữ - thị giác chuyên dụng kết hợp tinh chỉnh hiệu quả tham số thường phù hợp và hiệu quả hơn.

Lựa chọn BiomedCLIP làm mô hình nền tảng

Trong số các mô hình ngôn ngữ trực quan y khoa được khảo sát, khóa luận lựa chọn BiomedCLIP [42] làm mô hình nền tảng dựa trên mức độ phù hợp với bài toán, thay vì chỉ dựa trên kết quả của một bộ dữ liệu riêng lẻ. Thứ nhất, BiomedCLIP được tiền huấn luyện trên PMC-15M, gồm khoảng 15 triệu cặp ảnh-văn bản thu thập từ nhiều loại dữ liệu y sinh, trong khi một số mô hình trước đó chủ yếu được xây dựng và đánh giá trên ảnh X-quang ngực. Phạm vi tiền huấn luyện rộng hơn tạo cơ sở phù hợp cho việc chuyển giao sang ảnh X-quang xương, vốn có sự đa dạng lớn về vùng giải phẫu, tư thế chụp và loại tổn thương.

Thứ hai, mô hình sử dụng kiến trúc hai bộ mã hóa độc lập gồm Vision

Transformer cho ảnh và PubMedBERT cho văn bản, phù hợp với thiết kế hai nhánh của hệ thống và cho phép kế thừa trực tiếp biểu diễn của cả hai phương thức. Thứ ba, kiến trúc CLIP của mô hình hỗ trợ đánh giá không mẫu thông qua độ tương đồng ảnh-văn bản, đồng thời có thể được mở rộng bằng các kỹ thuật tinh chỉnh hiệu quả tham số và mô-đun dung hợp cho bài toán đích. Vì vậy, BiomedCLIP được sử dụng làm mô hình nền tảng khởi tạo, trong khi các ý tưởng phù hợp từ những nghiên cứu khác, chẳng hạn hàm mất mát khớp ngữ nghĩa của MedCLIP, được kế thừa để cải thiện quá trình thích nghi trên dữ liệu X-quang xương. Kết quả phân lớp không mẫu của BiomedCLIP và các mô hình nền tảng khác được trình bày trong Phần C.1.1.

Cơ chế phân lớp không mẫu của BiomedCLIP

BiomedCLIP có thể thực hiện phân lớp trong thiết lập *không mẫu* mà không cần huấn luyện một đầu phân lớp riêng trên dữ liệu đích. Thay vào đó, mô hình biểu diễn ảnh đầu vào và các câu nhắc mô tả lớp trong cùng một không gian đặc trưng, sau đó xác định lớp dựa trên mức độ tương đồng giữa hai phương thức.

Ảnh đầu vào x trước hết được tiền xử lý theo cấu hình của BiomedCLIP, bao gồm thay đổi kích thước, cắt vùng trung tâm và chuẩn hóa, để thu được tensor ảnh có kích thước 224×224 . Ảnh sau đó được chia thành các patch kích thước 16×16 và đưa qua bộ mã hóa thị giác ViT-B/16 để tạo biểu diễn ảnh.

Với mỗi lớp k , tên lớp được đưa vào một mẫu câu nhắc thống nhất, chẳng hạn **A radiograph showing [tên lớp]**. Câu nhắc được mã hóa bởi bộ mã hóa văn bản PubMedBERT để thu được biểu diễn văn bản t_k . Điểm số của lớp k được tính bằng độ tương đồng cosine:

$$s_k = \frac{v^\top t_k}{\|v\|_2 \|t_k\|_2}. \quad (2.1)$$

Các điểm tương đồng được chuẩn hóa bằng hàm Softmax để tạo phân phối xác suất trên tập lớp:

$$p(y = k | x) = \frac{\exp(s_k/\tau)}{\sum_{j=1}^K \exp(s_j/\tau)}, \quad (2.2)$$

trong đó τ là hệ số nhiệt độ. Lớp có xác suất lớn nhất được chọn làm kết quả dự đoán. Cơ chế này cho phép BiomedCLIP chuyển giao tri thức đã học sang các tập nhãn mới mà không cần cập nhật tham số. Tuy nhiên, hiệu quả phụ thuộc đáng kể vào mức độ tương đồng giữa dữ liệu tiền huấn luyện và dữ liệu đích, cách xây dựng câu nhắc, cũng như khả năng biểu diễn các dấu hiệu bệnh lý chuyên biệt của bộ mã hóa.

2.2 Các kỹ thuật tinh chỉnh hiệu quả tham số

Sự xuất hiện của các mô hình nền tảng nói chung và mô hình ngôn ngữ-thị giác y sinh nói riêng đã mang lại một nền tảng tri thức đa phương thức khổng lồ. Tuy nhiên, để triển khai hiệu quả các mô hình này vào các bài toán lâm sàng đặc thù, quá trình chuyển giao tri thức là bắt buộc.

Hướng đến yêu cầu cụ thể hơn cho bài toán sử dụng hai nguồn ảnh và văn bản lâm sàng, khóa luận tập trung vào các kỹ thuật tinh chỉnh để khai thác tối đa từ hai nguồn dữ liệu này với đặc điểm dữ liệu thực tế còn hạn chế.

Trước đây, hai chiến lược phổ biến nhất là tinh chỉnh toàn phần và dò tuyến tính. Tinh chỉnh toàn phần cập nhật lại toàn bộ tham số của mô hình gốc, mang lại khả năng thích ứng cao nhưng đòi hỏi chi phí tính toán, bộ nhớ khổng lồ, yêu cầu dữ liệu huấn luyện lớn đến rất lớn, dẫn đến hiện tượng quên biểu diễn trên các tập dữ liệu y tế nhỏ. Ngược lại, dò tuyến tính đóng băng toàn bộ mạng nơ-ron gốc và chỉ huấn luyện một lớp phân lớp duy nhất ở cuối, tiết kiệm tài nguyên nhưng hạn chế khả năng thích ứng khi sự chênh lệch phân phối giữa dữ liệu gốc và dữ liệu y tế là quá lớn.

Để giải quyết bài toán đánh đổi giữa hiệu năng và chi phí tính toán, tinh chỉnh hiệu quả tham số đã nổi lên như một giải pháp thay thế. Kỹ thuật này chỉ cập nhật hoặc thêm mới một lượng rất nhỏ tham số, giúp

tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các phương pháp tinh chỉnh hiệu quả tham số được chia thành ba hướng tiếp cận chính:

2.2.1 Tinh chỉnh sử dụng câu nhắc

Hướng tiếp cận này chèn thêm các tham số (vectơ) có thể học được vào không gian đầu vào của mô hình mà không thay đổi cấu trúc mạng bên trong.

- **Điểm mạnh:** Tiết kiệm tham số tối đa, bảo toàn nguyên vẹn tri thức của mô hình gốc, đặc biệt hiệu quả trong các kịch bản học ít mẫu hoặc không mẫu.
- **Điểm yếu:** Tối ưu hóa khó khăn do không gian biểu diễn bị giới hạn ở đầu vào, nhạy cảm với cách khởi tạo, và chiếm dụng một phần độ dài của chuỗi đầu vào.

Trong lĩnh vực y tế, PLIP [41] kết hợp đặc trưng thị giác với câu nhắc hiệu quả, đạt 0,896 AUC chỉ với 5% dữ liệu PanNuke. BiomedCoOp [32] tích hợp mô hình ngôn ngữ lớn để tự động sinh các câu nhắc ngữ nghĩa, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản.

2.2.2 Tinh chỉnh bộ điều hợp

Phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ, còn được gọi là bộ điều hợp vào giữa các lớp kiến trúc của mạng học sâu.

- **Điểm mạnh:** Tính mô-đun hóa cao, dễ dàng thêm/bớt các bộ điều hợp cho các tác vụ khác nhau mà không can thiệp vào tham số gốc.
- **Điểm yếu:** Việc chèn thêm các lớp mạng vật lý làm tăng độ trễ suy luận, hạn chế khả năng triển khai trên các hệ thống đòi hỏi thời gian thực.

Điển hình, CLIPath [44] sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu nhỏ. FTB [27] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức.

2.2.3 Tinh chỉnh thích nghi hạng thấp

Tinh chỉnh thích nghi hạng thấp (LoRA) giữ cố định trọng số nền và bổ sung các ma trận hạng thấp có thể huấn luyện để tham số hóa phần cập nhật trọng số. Cách tiếp cận này làm tăng một lượng nhỏ tham số huấn luyện nhưng tránh cập nhật toàn bộ mô hình.

- **Điểm mạnh:** Giảm đáng kể số tham số cần cập nhật và bộ nhớ tối ưu hóa. Ngoài ra, các ma trận cập nhật có thể được hợp nhất vào trọng số nền khi cách triển khai hỗ trợ.
- **Điểm yếu:** Hiệu quả phụ thuộc vào vị trí chèn, hạng của ma trận và cấu hình tối ưu. Tuy nhiên, việc giảm tham số huấn luyện không đồng nghĩa với giảm chi phí lan truyền tiến của toàn bộ kiến trúc.

LCBB [24] áp dụng LoRA cho mô hình ngôn ngữ trực quan y khoa và đạt 93,1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn, cho thấy khả năng thích nghi với số tham số cập nhật thấp hơn tinh chỉnh toàn phần.

Bảng 2.2 tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Nguyên lý	Kết quả nổi bật
1	PLIP (2024)	Tinh chỉnh sử dụng câu nhắc	Kết hợp câu nhắc thị giác với tinh chỉnh chọn lọc, tận dụng đặc trưng hình ảnh để tinh chỉnh hiệu quả	0,896 AUC (5% PanNuke)
2	CLIPath (2023)	Tinh chỉnh sử dụng bộ điều hợp	Sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu mô bệnh học	Cải thiện so với CLIP trên dữ liệu nhỏ
3	LCBB (2024)	Thích nghi hạng thấp bằng LoRA	Bổ sung ma trận hạng thấp vào bộ mã hóa thị giác, giữ cố định trọng số nền	93,1% AUROC (RSNA, 10%)
4	FTB (2024)	Tinh chỉnh sử dụng bộ điều hợp	Mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản, chất lọc thông tin đa phương thức	Cải thiện trên CheXpert, RSNA

Bảng 2.2: Tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện cho các mô hình ngôn ngữ trực quan y khoa

2.3 Các phương pháp phát hiện dữ liệu ngoài phân phối

Phát hiện dữ liệu ngoài phân phối nhằm nhận diện các mẫu không phù hợp với phân phối quan sát trong tập huấn luyện. Trong phân tích ảnh y khoa, điểm ngoài phân phối có thể cung cấp tín hiệu cảnh báo hỗ trợ khi mô hình gặp dữ liệu lạ, nhưng không tự thân bảo đảm tính an toàn hoặc thay thế quy trình đánh giá lâm sàng. Dựa trên cách tiếp cận, các phương pháp phát hiện dữ liệu ngoài phân phối hiện nay được chia thành các nhóm chính sau.

2.3.1 Các phương pháp hậu xử lý dựa trên đầu ra của mô hình

Nhóm phương pháp này không can thiệp vào quá trình huấn luyện mà tận dụng trực tiếp đầu ra (thường là các logit hoặc xác suất) của một bộ phân lớp đã được huấn luyện.

- **Xác suất softmax cực đại [13]:** Sử dụng giá trị cực đại của hàm softmax làm độ tin cậy. Dữ liệu có xác suất cực đại thấp sẽ bị đánh dấu là ngoài phân phối. Tuy nhiên, điểm yếu chí mạng của xác suất softmax cực đại là các mạng nơ-ron sâu thường mắc lỗi "tự tin thái quá", dẫn đến việc gán xác suất rất cao cho cả những mẫu ngoài phân phối hoàn toàn không liên quan.
- **ODIN [20]:** Cải thiện xác suất softmax cực đại bằng cách sử dụng hiệu chỉnh nhiệt độ và thêm nhiễu đầu vào để gia tăng sự chênh lệch logit giữa dữ liệu trong phân phối và dữ liệu ngoài phân phối.
- **Điểm năng lượng [21]:** Chuyển đổi vectơ logit thành hàm năng lượng thay vì xác suất softmax:

$$E(x) = -T \log \sum_i \exp \left(\frac{f_i(x)}{T} \right) \quad (2.3)$$

trong đó $f_i(x)$ là logit của lớp thứ i và T là hệ số nhiệt độ. Mặc dù điểm năng lượng khai thác độ lớn tuyệt đối của các logit và thường khắc phục một phần hiện tượng quá tự tin của hàm softmax, các phương pháp hậu xử lý dựa trên đầu ra vẫn phụ thuộc mạnh vào biểu diễn và biên quyết định của bộ phân lớp đã huấn luyện. Do mô hình phân lớp đóng buộc mọi đầu vào vào một trong các lớp đã biết, các mẫu ngoài phân phối nằm xa dữ liệu huấn luyện vẫn có thể nhận điểm tin cậy cao.

2.3.2 Các phương pháp dựa trên độ không chắc chắn và tái tạo

Để tránh phụ thuộc vào đầu ra hàm softmax, một số nghiên cứu tiếp cận bài toán bằng cách đánh giá khả năng sinh hoặc sự bất định của mô hình.

- **Sai số tái tạo:** Sử dụng các mô hình sinh như bộ tự mã hóa được huấn luyện chỉ trên dữ liệu trong phân phối. Khi gặp dữ liệu ngoài phân phối, sai số tái tạo sẽ tăng đột biến. Dù hiệu quả, phương pháp này gặp khó khăn khi tái tạo các ảnh y khoa có độ phân giải cao và chi tiết phức tạp.
- **Dropout Monte Carlo:** Kích hoạt hàm tắt ngẫu nhiên trong quá trình suy luận và thực hiện dự đoán nhiều lần để tính phương sai. Tuy nhiên, việc phải suy luận nhiều lần làm tăng chi phí tính toán, không phù hợp cho các hệ thống đòi hỏi thời gian thực.

2.3.3 Các phương pháp dựa trên khoảng cách đặc trưng

Nhận thấy những hạn chế của không gian logit, các nghiên cứu gần đây chuyển hướng sang thực hiện phát hiện dữ liệu ngoài phân phối trực tiếp trên không gian đặc trưng. Việc đánh giá bằng khoảng cách giúp giới hạn không gian rủi ro mở.

- **Khoảng cách euclid và cosine:** Khoảng cách euclid đo độ lệch hình học tuyệt đối $d_E(z, c_k) = \|z - c_k\|_2$ và phù hợp với hình học đẳng hướng khi các chiều có cùng thang đo. Khoảng cách cosine loại bỏ ảnh hưởng của độ lớn vectơ và chỉ so sánh hướng, nhưng không mô hình hóa mức phân tán khác nhau theo từng chiều.
- **Khoảng cách Mahalanobis [18]:** Khoảng cách Mahalanobis bổ sung thông tin hiệp phương sai để chuẩn hóa độ lệch theo cấu trúc phân tán của không gian đặc trưng:

$$d_M(z, \mu_k) = \sqrt{(z - \mu_k)^\top (\Sigma + \lambda I)^{-1} (z - \mu_k)} \quad (2.4)$$

Trong đó, z là vectơ biểu diễn của mẫu kiểm thử, μ_k là trung bình đặc trưng của lớp k và Σ là ma trận hiệp phương sai. Độ tin cậy của phép đo phụ thuộc vào chất lượng ước lượng hiệp phương sai và mức phù hợp của giả định phân phối.

- **Khoảng cách láng giềng gần nhất (kNN) [34]:** Thay vì mô hình hóa không gian đặc trưng bằng một dạng phân phối tham số, phương pháp kNN đánh giá mẫu kiểm thử dựa trên quan hệ lân cận trực tiếp với các biểu diễn của dữ liệu trong phân phối đã quan sát. Với tập tham chiếu $\mathcal{Z}_{\text{ID}} = \{z_i\}_{i=1}^N$, tập k láng giềng gần nhất của biểu diễn kiểm thử z được xác định bởi:

$$\mathcal{N}_k(z) = \text{kNN}(z, \mathcal{Z}_{\text{ID}}). \quad (2.5)$$

Điểm ngoài phân phối có thể được xây dựng từ khoảng cách đến láng giềng gần thứ k hoặc từ thống kê khoảng cách trên tập $\mathcal{N}_k(z)$. Khi mẫu kiểm thử nằm xa vùng lân cận của các biểu diễn trong phân phối, điểm bất thường có xu hướng tăng. Cách tiếp cận phi tham số này không yêu cầu ước lượng trước dạng phân phối của không gian đặc trưng, nhưng phụ thuộc trực tiếp vào chất lượng biểu diễn, kích thước tập tham chiếu, giá trị k và độ đo khoảng cách được sử dụng.

2.3.4 Học biểu diễn phức vụ phát hiện dữ liệu ngoài phân phối

Sự thành công của các phương pháp dựa trên khoảng cách phụ thuộc rất lớn vào chất lượng của không gian đặc trưng. Nếu mô hình được huấn luyện bằng hàm entropy chéo thông thường, dữ liệu của các lớp không được tối ưu để co cụm lại, làm giảm hiệu quả của các phép đo khoảng cách. Để giải quyết vấn đề này, các kỹ thuật học biểu diễn được áp dụng.

- **Học tương phản:** Học biểu diễn bằng cách kéo gần các mẫu tương đồng và đẩy xa các mẫu khác lớp trong không gian đặc trưng.
- **Mất mát tâm lớp [39]:** Giảm phương sai nội lớp bằng cách học một tâm biểu diễn cho mỗi lớp và ép các đặc trưng tiến gần tâm tương ứng.
- **Mạng nguyên mẫu [33]:** Phương pháp học theo hệ đo này biểu diễn mỗi lớp bằng một nguyên mẫu c_k :

$$c_k = \frac{1}{|S_k|} \sum_{x_i \in S_k} f_\theta(x_i) \quad (2.6)$$

Trong quá trình huấn luyện, mạng được tối ưu hóa để cực tiểu hóa khoảng cách giữa đặc trưng của dữ liệu và nguyên mẫu tương ứng của nó.

Đối với các phương pháp dựa trên khoảng cách, chất lượng của không gian biểu diễn đặc biệt quan trọng vì điểm ngoài phân phối được suy ra trực tiếp từ cấu trúc lân cận của các đặc trưng. Một không gian đặc trưng duy trì tốt quan hệ tương đồng giữa các mẫu trong phân phối sẽ tạo cơ sở phù hợp hơn cho việc đánh giá mức độ xa lạ của mẫu mới bằng khoảng cách láng giềng.

2.4 Các phương pháp giải thích và đánh giá độ trung thực

Các phương pháp quy đóng gán mức ảnh hưởng cho từng thành phần đầu vào đối với một đầu ra cụ thể. Tích phân gradient [35] tích lũy gradient dọc theo đường nội suy từ một mốc tham chiếu đến đầu vào, nhờ đó có thể áp dụng cho vùng ảnh, đơn vị biểu diễn cục bộ và từ ngữ. Kết quả phản ánh mức phụ thuộc của đầu ra đối với mốc tham chiếu và lớp đích đã chọn, không mặc nhiên biểu thị quan hệ nhân quả hoặc vị trí tổn thương.

Độ trung thực của lời giải thích thường được kiểm tra bằng can thiệp đầu vào. Trong phép loại bỏ, các thành phần được xếp hạng cao được thay dần bằng mốc tham chiếu. Khi đó, xác suất lớp đích giảm nhanh hơn so với thứ tự ngẫu nhiên cung cấp bằng chứng thuận lợi hơn cho thứ tự quy đóng. Phép khôi phục thực hiện theo chiều ngược lại. Kết quả phụ thuộc vào mốc thay thế, tỷ lệ can thiệp và không gian biểu diễn, do đó cần báo cáo giao thức cùng đối chứng ngẫu nhiên thay vì chỉ dựa vào bản đồ nhiệt.

Trọng số chú ý mô tả cách mô-đun phân bổ tương tác trong một lần truyền thuận nhưng không mặc nhiên là lời giải thích trung thực cho quyết định. Ngoài độ trung thực, đánh giá trong y khoa còn cần phân biệt độ ổn định của bản đồ, mức phù hợp với chú thích tổn thương và nhận định của chuyên gia. Khóa luận vì vậy sử dụng tích phân gradient và can thiệp đầu vào để khảo sát nguồn thông tin liên hệ với dự đoán, đồng thời không diễn giải bản đồ quy đóng như bằng chứng định vị hoặc xác nhận lâm sàng.

2.5 Bàn luận

2.5.1 Hạn chế của các nghiên cứu hiện nay

Mặc dù đạt được nhiều kết quả tích cực, các nghiên cứu hiện có vẫn chưa giải quyết đồng thời các yêu cầu của bài toán phân lớp ảnh X-quang xương đa phương thức. Cùng với những hạn chế của mô hình BiomedCLIP khi phân lớp trực tiếp đã được trình bày trong Phần 2.1.2, các vấn đề chính

được tổng hợp như sau:

Thứ nhất, phần lớn mô hình y khoa đa phương thức được phát triển trên X-quang ngực hoặc các bộ dữ liệu lớn. Ảnh X-quang xương có phạm vi giải phẫu, tư thế chụp và kiểu tổn thương đa dạng, trong khi số lượng mẫu giữa các lớp thường mất cân bằng đáng kể. Vì vậy, hiệu quả trên các miền dữ liệu khác chưa thể được chuyển trực tiếp sang bài toán này.

Thứ hai, nhiều nghiên cứu sử dụng báo cáo đọc ảnh hoặc kết luận chẩn đoán làm đầu vào văn bản. Tuy nhiên, các báo cáo này thường được hình thành sau khi bác sĩ hoặc bác sĩ chẩn đoán hình ảnh đã quan sát phim và có thể mô tả trực tiếp vị trí, hình thái hoặc mức độ tổn thương, chẳng hạn đường gãy, di lệch hay bất thường xương. Việc sử dụng các nguồn văn bản này trong giai đoạn suy luận có thể gây rò rỉ nhãn, khiến mô hình chủ yếu học cách ánh xạ một mô tả gần với kết luận chẩn đoán sang nhãn tương ứng. Trong bối cảnh triển khai thực tế, để tạo được báo cáo chi tiết, bác sĩ đã phải nhận diện tổn thương trước, do đó mô hình không còn đóng vai trò hỗ trợ phát hiện mà chủ yếu lặp lại thông tin đã được xác định. Ngược lại, các thông tin lâm sàng có sẵn trước chẩn đoán cuối cùng, như triệu chứng, tiền sử bệnh, vị trí đau hoặc cơ chế chấn thương, vẫn chưa được khai thác đầy đủ, mặc dù đây là những nguồn thông tin quan trọng giúp định hướng quá trình chẩn đoán. Bên cạnh đó, nhiều phương pháp chỉ nổi hai vectơ đặc trưng toàn cục, nên chưa mô hình hóa được quan hệ cụ thể giữa các vùng ảnh và nội dung lâm sàng liên quan.

Thứ ba, mặc dù các mô hình nền tảng đạt hiệu quả cao, nhiều nghiên cứu vẫn lựa chọn tính chỉnh toàn bộ tham số của mô hình. Cách tiếp cận này đòi hỏi chi phí tính toán lớn, đồng thời làm tăng nguy cơ quên tri thức đã được học trong giai đoạn tiền huấn luyện.

Cuối cùng, hầu hết các nghiên cứu chỉ tập trung tối ưu hiệu năng phân lớp mà chưa quan tâm đầy đủ đến khả năng phát hiện dữ liệu ngoài phân phối. Trong môi trường lâm sàng, mô hình có thể gặp các trường hợp bệnh lý hiếm, dữ liệu có chất lượng thấp hoặc các bất thường chưa xuất hiện trong tập huấn luyện. Nếu không có cơ chế phát hiện dữ liệu ngoài phân phối, mô hình vẫn có thể đưa ra dự đoán với độ tin cậy cao mặc dù kết quả không chính xác.

2.5.2 Cơ sở lựa chọn và định hướng phương pháp đề xuất

Từ những hạn chế trên, khóa luận lựa chọn xây dựng hệ thống dựa trên việc kế thừa mô hình BiomedCLIP [42] kết hợp với thông tin lâm sàng để khai thác đồng thời đặc trưng hình ảnh và văn bản. Các lựa chọn thiết kế cụ thể được đưa ra dựa trên phân tích sau:

Về thích nghi mô hình nền tảng: LoRA [15] được sử dụng để thích nghi hai bộ mã hóa của BiomedCLIP với miền ảnh X-quang xương mà không cần cập nhật toàn bộ tham số nền. Lựa chọn này giúp giảm chi phí huấn luyện, hạn chế nguy cơ quá khớp trên các lớp có ít mẫu và bảo toàn phần lớn tri thức y sinh đã được học trong giai đoạn tiền huấn luyện.

Bên cạnh đó, hàm mất mát tương phản InfoNCE nguyên bản xem các mẫu khác nhau trong cùng lô là các cặp âm, kể cả khi chúng thuộc cùng một lớp hoặc có nội dung lâm sàng tương đồng. Do đó, khóa luận sử dụng hàm mất mát khớp ngữ nghĩa kế thừa từ MedCLIP và xây dựng phân phối đích mềm theo nhãn lớp. Mục tiêu này vẫn ưu tiên sự tương hợp của cặp ảnh-văn bản tương ứng, đồng thời giảm ảnh hưởng của các cặp âm tính giả giữa những mẫu có quan hệ ngữ nghĩa gần nhau.

Về khai thác và dung hợp thông tin lâm sàng: Thiết lập phân lớp không mẫu của BiomedCLIP chỉ đối sánh ảnh với các câu nhắc đại diện cho lớp và không sử dụng thông tin riêng của từng người bệnh. Phương pháp đề xuất bổ sung nhánh văn bản để mã hóa những thông tin lâm sàng có sẵn trước kết luận chẩn đoán, chẳng hạn lý do vào viện, triệu chứng và bệnh sử. Báo cáo đọc ảnh, chẩn đoán xác định và nhãn phân lớp không được đưa trực tiếp vào đầu vào nhằm hạn chế rò rỉ nhãn.

Thay vì chỉ ghép nối hai biểu diễn toàn cục, khóa luận lựa chọn cơ chế chú ý chéo hai chiều để đặc trưng ảnh lựa chọn các thông tin lâm sàng liên quan, đồng thời đặc trưng văn bản định hướng mô hình đến các vùng ảnh phù hợp. Thiết kế này cho phép mô hình hóa quan hệ cụ thể giữa dấu hiệu X-quang và ngữ cảnh lâm sàng.

Về phân lớp đa lớp và mất cân bằng dữ liệu: Phương pháp sử dụng Hàm mất mát entropy chéo có trọng số được sử dụng nhằm giảm

ảnh hưởng của sự chênh lệch số lượng mẫu giữa các lớp.

Về phát hiện dữ liệu ngoài phân phối: Ngoài nhiệm vụ chính, khóa luận bổ sung cơ chế phát hiện dữ liệu ngoài phân phối ở giai đoạn hậu xử lý mà không cần mẫu OOD khi huấn luyện. Phương pháp sử dụng kNN trực tiếp trên đặc trưng ảnh và văn bản từ hai bộ mã hóa BiomedCLIP, với hai ngân hàng tham chiếu $\mathcal{BI}$ và $\mathcal{BT}$ được xây dựng từ tập huấn luyện. Với mẫu mới, hai đặc trưng được đối sánh riêng với ngân hàng tương ứng để tạo tín hiệu khoảng cách lân cận và cảnh báo OOD theo ngưỡng hiệu chỉnh trên tập xác thực; chi tiết cách tính và kết hợp hai tín hiệu được trình bày trong Chương 3.

Về quy trình huấn luyện: Từ các lựa chọn trên, hệ thống được tổ chức thành hai giai đoạn ngoại tuyến:

- **Giai đoạn 1 - Thích nghi và căn chỉnh biểu diễn:** hai bộ mã hóa của BiomedCLIP được thích nghi thông qua LoRA bằng hàm mất mát khớp ngữ nghĩa. Mô-đun dung hợp và đầu phân lớp chưa được tối ưu trong giai đoạn này.
- **Giai đoạn 2 - Dung hợp và phân lớp:** các bộ mã hóa tiếp tục được thích nghi thông qua LoRA, đồng thời mô-đun xử lý đặc trưng cục bộ và cơ chế chú ý chéo hai chiều được tối ưu cho nhiệm vụ phân lớp. Sau khi quá trình thích nghi hoàn tất, đặc trưng ảnh và đặc trưng văn bản của tập huấn luyện được trích xuất từ hai bộ mã hóa để xây dựng hai ngân hàng tham chiếu phục vụ kNN trong giai đoạn suy luận.


Các định hướng trên được hiện thực hóa trong phương pháp XBone-Net. Kiến trúc chi tiết, quy trình huấn luyện và cơ chế suy luận được trình bày trong Chương 3.

Chương 3

Phương pháp đề xuất

3.1 Tổng quan phương pháp đề xuất

Nhóm nghiên cứu đề xuất XBone-Net cho bài toán phân loại đa lớp ảnh X-quang xương có kết hợp thông tin lâm sàng. Hệ thống được xây dựng theo kiến trúc hai nhánh. Nhánh ảnh khai thác đồng thời cấu trúc giải phẫu toàn cục và các vùng cục bộ giàu chi tiết, trong khi nhánh văn bản biểu diễn bệnh sử và lý do vào viện. Hai nguồn thông tin được ánh xạ vào cùng một không gian đặc trưng, trao đổi ngữ cảnh bằng cơ chế chú ý chéo hai chiều, sau đó được phân lớp.



Hình 3.1: Sơ đồ tổng quan phương pháp XBone-Net đề xuất

Như minh họa trong Hình 3.1, XBone-Net kế thừa bộ mã hóa thị giác và bộ mã hóa văn bản của BiomedCLIP [42]. Các tham số nền được giữ cố định để bảo toàn tri thức y sinh đã học trước, trong khi các ma trận thích nghi hạng thấp LoRA [15] được huấn luyện để thích nghi trên dữ liệu đích. Sau bước mã hóa, mô-đun dung hợp kết hợp đặc trưng toàn cục và cục bộ

của hai phương thức. Biểu diễn tổng hợp cuối cùng được đưa vào mô-đun phân loại. Định danh mô hình nền tảng, kích thước biểu diễn, vị trí chèn LoRA và cấu hình tái lập đầy đủ được trình bày tại Phụ lục B.

Mỗi mẫu dữ liệu được ký hiệu bởi bộ ba gồm ảnh X-quang, thông tin lâm sàng và nhãn lớp. Tập huấn luyện có dạng:

$$\mathcal{D}_{\text{train}} = \left\{ \left(x_i^{\text{img}}, x_i^{\text{txt}}, y_i \right) \right\}_{i=1}^N, \quad y_i \in \mathcal{Y}. \quad (3.1)$$

Trong đó, $x_i^{\text{img}} \in \mathbb{R}^{H_i \times W_i \times C_{\text{in}}}$ là ảnh X-quang của mẫu thứ i . Các ký hiệu H_i , W_i và C_{in} lần lượt là chiều cao, chiều rộng và số kênh ảnh. Thông tin lâm sàng được ký hiệu $x_i^{\text{txt}} = (w_{i,1}, \dots, w_{i,L_i})$, với L_i là số đơn vị biểu diễn trước khi cắt hoặc đệm. Nhãn y_i thuộc tập nhãn $\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$, còn N là số mẫu huấn luyện.

Quá trình xây dựng mô hình được chia thành hai giai đoạn ngoại tuyến. Giai đoạn thứ nhất thích nghi hai nhánh mã hóa và căn chỉnh không gian ảnh-văn bản bằng hàm mất mát khớp ngữ nghĩa. Giai đoạn thứ hai học cơ chế dung hợp và phân loại. Khi suy luận trực tuyến, toàn bộ tham số được cố định, mô hình chỉ thực hiện tính toán truyền thuận cho một ca mới.

Để làm rõ cách hệ thống chuyển đổi từng nguồn dữ liệu thành biểu diễn có thể sử dụng cho quá trình dung hợp, các phần tiếp theo lần lượt trình bày nhánh biểu diễn ảnh, nhánh biểu diễn văn bản và cơ chế thích nghi hai bộ mã hóa trước khi đi đến mô-đun dung hợp và phân lớp.

Với ký hiệu $D_{\text{enc}} = 768$ là chiều ẩn bên trong hai Transformer của BiomedCLIP, còn $D = 512$ là chiều biểu diễn chung sau các lớp chiếu của BiomedCLIP. Mọi đặc trưng được truyền vào mô-đun dung hợp, bộ phân lớp và bộ phát hiện OOD đều nằm trong không gian $D = 512$ chiều.

3.2 Nhánh mã hóa hình ảnh

Mô hình kế thừa bộ mã hóa của BiomedCLIP [42], được xây dựng theo kiến trúc Vision Transformer [7] ViT-B/16. Hình ảnh y tế đầu vào v ban đầu được chuẩn hóa về độ phân giải tiêu chuẩn 224×224 pixels với 3 kênh

màu (RGB). Quá trình biến đổi dữ liệu để trích xuất đặc trưng qua bộ mã hóa Vision Transformer (ViT-B/16) diễn ra tuần tự như sau:

1. **Phân mảnh ảnh (Patch Extraction):** Hình ảnh $v \in \mathbb{R}^{224 \times 224 \times 3}$ được phân rã thành chuỗi N mảnh ảnh nhỏ không chồng lấn (patches) có kích thước cố định là 16×16 pixels. Số lượng mảnh ảnh thu được, đồng thời là độ dài chuỗi đầu vào của mạng Transformer, được xác định bằng công thức:

$$N = \frac{224 \times 224}{16^2} = 196 \quad (3.2)$$

2. **Nhúng tuyến tính và chèn token $[CLS]$:** Các mảnh ảnh được trải phẳng và chiếu tuyến tính qua ma trận trọng số $E \in \mathbb{R}^{(16^2 \cdot 3) \times D_{\text{enc}}}$ vào không gian ẩn $D_{\text{enc}} = 768$ chiều để tạo thành các *patch embeddings*. Để tổng hợp thông tin ngữ nghĩa toàn cục của bức ảnh, một token phân loại học được đặc biệt - ký hiệu là $v_{\text{CLS}} \in \mathbb{R}^{1 \times D_{\text{enc}}}$ - được chèn vào ngay đầu chuỗi đặc trưng. Đồng thời, một ma trận nhúng vị trí một chiều học được $E_{\text{pos}} \in \mathbb{R}^{(N+1) \times D_{\text{enc}}}$ được cộng trực tiếp vào chuỗi nhằm bảo toàn thông tin cấu trúc không gian:

$$z_0 = [v_{\text{CLS}}; v_p^1 E; v_p^2 E; \dots; v_p^N E] + E_{\text{pos}} \quad (3.3)$$

3. **Xử lý qua Transformer Encoder:** Chuỗi biểu diễn tích hợp z_0 được truyền qua chồng gồm $L = 12$ tầng Transformer Encoder. Tại mỗi tầng, các cơ chế tự chú ý đa đầu (Multi-Head Self-Attention) và mạng truyền thẳng (MLP) liên tục cập nhật trạng thái của toàn bộ chuỗi thông qua chuẩn hóa trước và kết nối tắt residual.
4. **Trích xuất và chiếu chuỗi đặc trưng:** Tại tầng mã hóa cuối cùng ($L = 12$), toàn bộ chuỗi trạng thái ẩn được chuẩn hóa và chiếu từ $D_{\text{enc}} = 768$ xuống không gian chung $D = 512$ chiều bằng ma trận $W_v^{\text{proj}} \in \mathbb{R}^{D_{\text{enc}} \times D}$:

$$y_v = \text{LN}(z_L) W_v^{\text{proj}} \in \mathbb{R}^{(N+1) \times D}. \quad (3.4)$$

Dòng đầu $y_v^0 \in \mathbb{R}^D$ là biểu diễn ảnh toàn cục tại vị trí $[CLS]$, còn $y_v^1 \in \mathbb{R}^{N \times D}$ gồm $N = 196$ biểu diễn mảnh ảnh cục bộ. Hai phần này đều được giữ lại cho mô-đun dung hợp.

3.3 Nhánh biểu diễn văn bản

Bổ sung cho các bằng chứng hình thái được trích xuất từ ảnh X-quang, nhánh biểu diễn văn bản có nhiệm vụ mã hóa thông tin lâm sàng t thành các đặc trưng ngữ cảnh theo từng đơn vị biểu diễn và một vectơ đại diện cho toàn bộ chuỗi. Trong khóa luận, nhánh này được kế thừa từ bộ mã hóa văn bản của BiomedCLIP [42], với thành phần chính là PubMedBERT. Khác với các mô hình ngôn ngữ được tiền huấn luyện trên văn bản tổng quát, PubMedBERT được tiền huấn luyện từ đầu trên kho ngữ liệu y sinh và sử dụng bộ từ vựng được xây dựng trực tiếp từ miền dữ liệu này. Nhờ đó, mô hình phù hợp hơn với các thuật ngữ chuyên ngành xuất hiện trong thông tin lâm sàng. Chuỗi văn bản mô tả y khoa đầu vào t được chuyển đổi thành vector biểu diễn ngữ nghĩa thông qua các bước biến đổi tuần tự như sau:

1. **Phân tách từ tố (Tokenization):** Văn bản thô t được phân tách thành chuỗi các từ tố (subwords) bằng thuật toán WordPiece dựa trên từ vựng y sinh chuyên biệt gồm 30.000 từ. Tổng độ dài chuỗi sau khi thêm token đặc biệt, cắt và đệm được cố định ở $T = 256$ vị trí.
2. **Khởi tạo chuỗi và chèn các token đặc biệt $[CLS]$ và $[SEP]$:** Để cấu trúc hóa chuỗi đầu vào theo chuẩn BERT, một token phân loại đặc biệt ký hiệu là t_{CLS} được chèn vào đầu chuỗi, và một token phân tách đặc biệt ký hiệu là t_{SEP} được bổ sung ở cuối chuỗi để phân định ranh giới ngữ cảnh:

$$t_{seq} = [t_{CLS}, t_1, t_2, \dots, t_\ell, t_{SEP}, t_{PAD}, \dots], \quad T = 256, \quad (3.5)$$

trong đó ℓ là số từ tố nội dung còn lại sau khi cắt; các vị trí đệm được loại khỏi phép chú ý chéo bằng mặt nạ chú ý.

Vector nhúng ban đầu g_0 sau đó được thiết lập bằng cách cộng phần tử (element-wise summation) giữa các vector nhúng từ tổ (token embeddings), nhúng phân đoạn (segment embeddings) và nhúng vị trí (position embeddings) trong không gian ẩn $D_{\text{enc}} = 768$ chiều:

$$g_0 = \text{Embedding}(t_{\text{seq}}) \quad (3.6)$$

3. **Xử lý qua Transformer Encoder:** Chuỗi biểu diễn tích hợp g_0 được truyền qua chồng gồm $L = 12$ tầng Transformer Encoder hai chiều (bidirectional). Tại mỗi tầng, cơ chế tự chú ý đa đầu (Multi-Head Self-Attention) và mạng truyền thẳng (MLP) liên tục cập nhật trạng thái ngữ cảnh của toàn bộ chuỗi thông qua chuẩn hóa trước và kết nối tắt residual.
4. **Trích xuất và chiếu chuỗi đặc trưng:** Tại tầng mã hóa cuối cùng ($L = 12$), toàn bộ chuỗi trạng thái ẩn được chiếu từ $D_{\text{enc}} = 768$ xuống không gian chung $D = 512$ chiều bằng ma trận $W_t^{\text{proj}} \in \mathbb{R}^{D_{\text{enc}} \times D}$:


$$y_t = g_L W_t^{\text{proj}} \in \mathbb{R}^{T \times D}. \quad (3.7)$$

Dòng đầu $y_t^0 \in \mathbb{R}^D$ là biểu diễn văn bản toàn cục tại vị trí $[CLS]$. Các dòng còn lại tạo ngữ cảnh cục bộ theo từng vị trí từ tổ; những vị trí đệm không tham gia chú ý chéo.

Kết thúc hai nhánh mã hóa, mỗi mẫu được biểu diễn bởi chuỗi đặc trưng ảnh $\mathbf{V}_i$, ma trận đặc trưng văn bản $\mathbf{H}_i^T$ và các vectơ toàn cục tương ứng. Mặc dù các biểu diễn này kế thừa tri thức y sinh từ BiomedCLIP, sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu X-quang xương đích vẫn đòi hỏi hai bộ mã hóa được thích nghi trước khi thực hiện dung hợp.

3.4 Thích nghi tham số hiệu quả bằng LoRA

Trong quá trình thích nghi các mô hình lớn (như PubMedBERT hay ViT trong BiomedCLIP) cho các tác vụ y sinh hạ nguồn, phương pháp tinh chỉnh toàn bộ tham số đòi hỏi chi phí tính toán và bộ nhớ lưu trữ cực kỳ lớn. Để giải quyết rào cản này, phương pháp Thích nghi tham số hạng thấp (LoRA - Low-Rank Adaptation) được áp dụng. Phương pháp này hoạt động dựa trên giả thuyết rằng sự thay đổi trọng số của các lớp liên kết dày đặc trong quá trình học thực chất nằm trong một không gian có "hạng nội tại" rất thấp.



Hình 3.2: Phân rã hạng r với ma trận cập nhật trọng số ΔW

Quy trình toán học và dòng chảy dữ liệu của cơ chế LoRA được mô tả cụ thể qua các bước sau:

1. **Đóng băng trọng số nền và thiết lập nhánh song song:** Gọi $W_0 \in \mathbb{R}^{d \times k}$ là ma trận trọng số tiền huấn luyện của một lớp tuyến tính bất kỳ trong mạng Transformer. Trong suốt quá trình huấn luyện thích nghi, ma trận W_0 này hoàn toàn bị đóng băng và không nhận bất kỳ cập nhật gradient nào. Sự thay đổi trọng số tích lũy ΔW được biểu diễn gián tiếp thông qua tích của hai ma trận phân rã hạng thấp được đặt song song với lớp gốc:

$$W = W_0 + \Delta W = W_0 + BA \quad (3.8)$$

Trong đó, $B \in \mathbb{R}^{d \times r}$ và $A \in \mathbb{R}^{r \times k}$ là hai ma trận chứa các tham số học được, với hạng $r \ll \min(d, k)$ là một siêu tham số đại diện cho rank của LoRA.

2. **Khởi tạo tham số ban đầu:** Để đảm bảo ma trận cập nhật ΔW bằng 0 tại thời điểm bắt đầu huấn luyện (tránh gây nhiễu cho tri thức pre-trained gốc), các ma trận phân rã được khởi tạo như sau:

- Ma trận A được khởi tạo ngẫu nhiên theo phân phối Gaussian: $A \sim \mathcal{N}(0, \sigma^2)$.
- Ma trận B được khởi tạo bằng 0.

Phép nhân ma trận ban đầu mang lại $\Delta W = B \cdot A = 0$, giúp bảo toàn nguyên vẹn đầu ra của mô hình gốc ở vạch xuất phát.

3. **Lan truyền tiến tích hợp tham số tỷ lệ:** Với một vector đầu vào x , phép toán lan truyền tiến (forward pass) qua lớp tuyến tính được điều chỉnh bởi LoRA sẽ cộng trực tiếp kết quả của hai nhánh:

$$h = W_0 x + \frac{\alpha}{r} B A x \quad (3.9)$$

Trong đó, α là một hằng số tỷ lệ cố định. Việc nhân thêm hệ số điều chỉnh $\frac{\alpha}{r}$ đóng vai trò quan trọng trong việc ổn định hóa quá trình tối ưu hóa, giúp giảm thiểu tối đa việc phải tinh chỉnh lại các siêu tham số huấn luyện khác (như tốc độ học) khi người dùng thay đổi giá trị của hạng r .

4. **Tích hợp vào kiến trúc Transformer:** Trong cấu hình XBoneNet, LoRA không chỉ được gắn vào các phép chiếu Query, Key và Value mà còn được gắn vào phép chiếu đầu ra chú ý và hai lớp tuyến tính của MLP trong mỗi khối Transformer. ViT-B/16 cài đặt ba phép chiếu Query-Key-Value bằng một ma trận gộp W_{QKV} , trong khi PubMedBERT sử dụng ba ma trận riêng W_Q , W_K và W_V . Bảng 3.1 liệt kê đầy đủ các ma trận đích theo đúng cấu hình mã nguồn.

Với $D_{\text{enc}} = 768$, kích thước trung gian của MLP là $4D_{\text{enc}} = 3072$. Các adapter được chèn vào các ma trận trên ở cả 12 khối Transformer của mỗi

Bộ mã hóa	Mô-đun trong mã nguồn	Ma trận được gắn LoRA	Vai trò
ViT-B/16	attn.qkv	$W_{QKV}^{(v)} \in \mathbb{R}^{3D_{enc} \times D_{enc}}$	Chiều đồng thời Query, Key và Value.
ViT-B/16	attn.proj	$W_O^{(v)} \in \mathbb{R}^{D_{enc} \times D_{enc}}$	Chiều đầu ra của chú ý đa đầu.
ViT-B/16	mlp.fc1, mlp.fc2	$W_1^{(v)} \in \mathbb{R}^{4D_{enc} \times D_{enc}}, W_2^{(v)} \in \mathbb{R}^{D_{enc} \times 4D_{enc}}$	Mở rộng rồi thu hẹp chiều trong MLP.
PubMedBERT	query, key, value	$W_Q^{(t)}, W_K^{(t)}, W_V^{(t)} \in \mathbb{R}^{D_{enc} \times D_{enc}}$	Ba phép chiếu Query, Key và Value riêng biệt.
PubMedBERT	attention.output.dense	$W_O^{(t)} \in \mathbb{R}^{D_{enc} \times D_{enc}}$	Chiều đầu ra của chú ý đa đầu.
PubMedBERT	intermediate.dense, output.dense	$W_1^{(t)} \in \mathbb{R}^{4D_{enc} \times D_{enc}}, W_2^{(t)} \in \mathbb{R}^{D_{enc} \times 4D_{enc}}$	Mở rộng rồi thu hẹp chiều trong mạng truyền thẳng.

Bảng 3.1: Các ma trận được gắn LoRA trong hai bộ mã hóa của XBoneNet

bộ mã hóa; mỗi ma trận có một cặp tham số hạng thấp (A, B) riêng và không chia sẻ adapter với ma trận khác. Cấu hình chính sử dụng $r = 16$, $\alpha = 32$ và tỷ lệ bỏ học LoRA bằng 0,1. Các độ chệch, lớp embedding, LayerNorm và hai lớp chiếu cuối từ 768 xuống 512 chiều không được gắn LoRA; trọng số nền của chúng tiếp tục được giữ cố định. Mô-đun chú ý chéo, mạng dung hợp và đầu phân lớp cũng không sử dụng LoRA mà được tối ưu trực tiếp trong giai đoạn thứ hai.


LoRA chỉ điều chỉnh cách từng bộ mã hóa biểu diễn dữ liệu trong miền đích. Bản thân kỹ thuật này chưa thực hiện trao đổi thông tin giữa ảnh và văn bản. Sau khi hai nhánh đã tạo ra các đặc trưng thích nghi, các biểu diễn này được chuyển đến mô-đun dung hợp để mô hình hóa quan hệ giữa dấu hiệu thị giác và ngữ cảnh lâm sàng.

3.5 mô-đun dung hợp đa phương thức với chú ý chéo hai chiều

Sau khi đi qua các bộ mã hóa chuyên biệt, ta thu được các ma trận biểu diễn đặc trưng đầy đủ chứa cả thông tin toàn cục lẫn cục bộ của hai nhánh:

- Ma trận đặc trưng hình ảnh $y_v \in \mathbb{R}^{197 \times D}$, trong đó dòng đầu tiên $y_v^0 \in \mathbb{R}^D$ đại diện cho token phân loại $[CLS]$, và phần còn lại $y_v^1: \in \mathbb{R}^{196 \times D}$ đại diện cho đặc trưng cục bộ của 196 mảnh ảnh.
- Ma trận đặc trưng văn bản $y_t \in \mathbb{R}^{T \times D}$ với $T = 256$, trong đó dòng đầu

tiên $y_t^0 \in \mathbb{R}^D$ đại diện cho token đặc biệt $[CLS]$, còn $y_t^1: \in \mathbb{R}^{(T-1) \times D}$ chứa các vị trí ngữ cảnh còn lại; mặt nạ chú ý loại các vị trí đệm. Trong cả hai nhánh, $D = 512$.



Hình 3.3: Mô-đun dung hợp bằng chú ý chéo hai chiều

Quy trình dung hợp thông tin sử dụng cơ chế chú ý chéo hai chiều (Bidirectional Cross-Attention), trực quan hóa ở hình 3.3 được thực hiện tuần tự như sau:

1. **Chú ý chéo từ hình ảnh sang văn bản (Image-to-Text Attention):** Cơ chế này sử dụng đặc trưng hình ảnh toàn cục y_v^0 làm truy vấn (Query) để tìm kiếm và trích xuất ngữ cảnh liên quan từ chuỗi đặc trưng văn bản cục bộ y_t^1 : đóng vai trò là Keys và Values:

$$Q_v = y_v^0 W_q^{(v)}, \quad K_t = y_t^1 W_k^{(t)}, \quad V_t = y_t^1 W_v^{(t)} \quad (3.10)$$

$$A_{v \rightarrow t} = \text{softmax} \left(\frac{Q_v (K_t)^T}{\sqrt{d_k}} \right) \quad (3.11)$$

$$f_{v \rightarrow t} = A_{v \rightarrow t} V_t \in \mathbb{R}^D \quad (3.12)$$

Trong đó, $W_q^{(v)}, W_k^{(t)}, W_v^{(t)} \in \mathbb{R}^{D \times d_k}$ là các ma trận chiều tuyến tính học được, và d_k là số chiều của không gian chú ý. $A_{v \rightarrow t}$ là biểu thị phân phối trọng số thể hiện mức độ tương quan ngữ nghĩa giữa bối cảnh thị giác toàn cục của bức ảnh (Query) và từng từ tổ mô tả bệnh lý cục bộ (Keys). Giá trị của từng phần tử chỉ ra mức độ đóng góp ngữ nghĩa của từ tổ tương ứng vào việc giải thích hoặc bổ nghĩa cho thực thể trực quan xuất hiện trong ảnh y tế. Vector $f_{v \rightarrow t}$ là biểu diễn văn bản đã được căn chỉnh theo ngữ cảnh hình ảnh.

2. **Chú ý chéo từ văn bản sang hình ảnh (Text-to-Image Attention):** Tương tự, đặc trưng văn bản toàn cục y_t^0 được sử dụng làm Query để rà quét và tập trung vào các vùng đặc trưng không gian trên chuỗi mảnh ảnh cục bộ $y_v^{1:}$:

$$Q_t = y_t^0 W_q^{(t)}, \quad K_v = y_v^{1:} W_k^{(v)}, \quad V_v = y_v^{1:} W_v^{(v)} \quad (3.13)$$

$$A_{t \rightarrow v} = \text{softmax} \left(\frac{Q_t (K_v)^T}{\sqrt{d_k}} \right) \quad (3.14)$$

$$f_{t \rightarrow v} = A_{t \rightarrow v} V_v \in \mathbb{R}^D \quad (3.15)$$

Vector $f_{t \rightarrow v}$ đại diện cho đặc trưng hình ảnh đã được căn chỉnh theo ngữ cảnh của câu mô tả.

3. **Chuẩn hóa và Ghép nối đặc trưng (Normalization & Concatenation):** Hai đặc trưng sau khi chú ý chéo được tích hợp lại với các vector toàn cục gốc tương ứng bằng kết nối tắt residual, đi qua lớp chuẩn hóa tầng (LN) rồi tiến hành ghép nối (concatenate) để tạo thành vector dung hợp sơ bộ:

$$h_v = \text{LN}(f_{v \rightarrow t} + y_v^0) \in \mathbb{R}^D \quad (3.16)$$

$$h_t = \text{LN}(f_{t \rightarrow v} + y_t^0) \in \mathbb{R}^D \quad (3.17)$$

$$h_{\text{concat}} = [h_v; h_t] \in \mathbb{R}^{2D} \quad (3.18)$$

4. **Dung hợp phi tuyến qua MLP để tạo vector tổng hợp cuối cùng:** Cuối cùng, vector ghép nối h_{concat} được đưa qua mạng truyền

thẳng (MLP) để thực hiện tương tác phi tuyến tính sâu giữa hai miền dữ liệu, ánh xạ đầu ra về một vector đặc trưng dung hợp tổng hợp duy nhất y_{fusion} phục vụ tác vụ hạ nguồn:

$$y_{\text{fusion}} = \text{MLP}(h_{\text{concat}}) \in \mathbb{R}^D \quad (3.19)$$


Kết quả của quá trình trên là vectơ đa phương thức ***y_{fusion}***, trong đó thông tin ảnh và văn bản đã được tổng hợp trong cùng một biểu diễn. Vectơ này là đầu vào trực tiếp của bộ phân lớp, do đó quyết định cuối cùng không còn dựa trên từng phương thức riêng lẻ mà dựa trên quan hệ đã học giữa chúng.

3.6 Huấn luyện hai giai đoạn trong quá trình ngoại tuyến

Quy trình ngoại tuyến lần lượt giải quyết hai yêu cầu của hệ thống. Giai đoạn thứ nhất điều chỉnh các bộ mã hóa để ảnh X-quang và thông tin lâm sàng tương ứng được biểu diễn phù hợp hơn trong miền dữ liệu đích. Trên nền không gian đã thích nghi, giai đoạn thứ hai học tương tác liên phương thức và tối ưu quyết định phân lớp có xét đến sự mất cân bằng giữa các lớp.

3.6.1 Giai đoạn 1: Thích nghi miền bằng khớp ngữ nghĩa

Giai đoạn thứ nhất được minh họa trong Hình 3.4. Trong giai đoạn này, mô hình thực hiện quá trình thích nghi miền nhằm chuyển đổi không gian biểu diễn tổng quát của bộ mã hóa tiền huấn luyện sang miền dữ liệu y khoa chuyên biệt. Để tối ưu hóa hiệu quả và bảo toàn tri thức nền tảng, các tham số gốc của bộ mã hóa hình ảnh và bộ mã hóa văn bản đều được đóng băng, và quá trình huấn luyện thích nghi được thực hiện thông qua cơ chế thích nghi hạng thấp LoRA.



Hình 3.4: Giai đoạn thích nghi miền bằng khớp ngữ nghĩa ảnh-văn bản

Trọng tâm của giai đoạn này là giải quyết hiện tượng tiêu cực giả (false negatives) - xảy ra khi các mẫu ảnh và văn bản của các bệnh nhân khác nhau nhưng mang cùng một bệnh lý bị ép phải đẩy ra xa nhau trong không gian nhúng của học tương phản truyền thống. Giai đoạn này sử dụng hàm mất mát khớp ngữ nghĩa (Semantic Matching Loss - SML) kết hợp với ma trận đích mềm (soft target matrix) để dẫn đường cho mô hình.

Quy trình toán học trong một batch huấn luyện kích thước B được mô tả cụ thể như sau:

1. **Xây dựng ma trận đích mềm:** Với mỗi cặp thực thể i (hình ảnh) và j (văn bản) trong batch, ta xây dựng một ma trận đích tương đồng mềm $P \in \mathbb{R}^{B \times B}$. Giá trị phân phối mục tiêu P_{ij} đại diện cho mối tương quan y khoa giữa hai mẫu và được định nghĩa theo quy tắc phân cấp ngữ nghĩa:

$$P_{ij} = \begin{cases} 1.0, & \text{nếu } i = j \quad (\text{cặp khớp}) \\ 0.5, & \text{nếu } \text{class}(i) = \text{class}(j) \text{ và } i \neq j \quad (\text{cùng lớp khác mẫu}) \\ 0.0, & \text{nếu } \text{class}(i) \neq \text{class}(j) \quad (\text{khác lớp bệnh lý}) \end{cases} \quad (3.20)$$

2. **Chuẩn hóa phân phối mục tiêu:** Để biến đổi ma trận đích mềm P thành phân phối xác suất hợp lệ, ta áp dụng phép chuẩn hóa dòng (từ ảnh sang văn bản) và chuẩn hóa cột (từ văn bản sang ảnh) thông qua hàm Softmax:

$$y_{ij}^{v \rightarrow t} = \frac{\exp(P_{ij})}{\sum_{k=1}^B \exp(P_{ik})} \quad (3.21)$$

$$y_{ji}^{t \rightarrow v} = \frac{\exp(P_{ji})}{\sum_{k=1}^B \exp(P_{ki})} \quad (3.22)$$

3. **Tính toán tương đồng dự đoán:** Gọi I_i và T_j lần lượt là các vector nhúng chuẩn hóa L_2 của hình ảnh thứ i và văn bản thứ j trong không gian chung. Lượng logits tương đồng dự đoán scaled cosine similarity $\hat{s}_{ij}$ được tính toán bằng:

$$\hat{s}_{ij} = \frac{I_i \cdot T_j}{\tau} \quad (3.23)$$

Trong đó, τ là tham số nhiệt độ học được. Phân phối xác suất dự đoán tương ứng được xác định bởi:

$$\hat{y}_{ij}^{v \rightarrow t} = \frac{\exp(\hat{s}_{ij})}{\sum_{k=1}^B \exp(\hat{s}_{ik})}, \quad \hat{y}_{ji}^{t \rightarrow v} = \frac{\exp(\hat{s}_{ji})}{\sum_{k=1}^B \exp(\hat{s}_{ki})} \quad (3.24)$$

4. Hàm mất mát khớp ngữ nghĩa (Semantic Matching Loss):

Hàm mất mát SML được định nghĩa là trung bình cộng của sai số entropy chéo hai chiều đối xứng giữa phân phối đích mềm và phân phối dự đoán của mô hình thích nghi LoRA:

$$\mathcal{L}_{\text{SML}} = \frac{\mathcal{L}_{v \rightarrow t} + \mathcal{L}_{t \rightarrow v}}{2} \quad (3.25)$$

Trong đó:

$$\mathcal{L}_{v \rightarrow t} = -\frac{1}{B} \sum_{i=1}^B \sum_{j=1}^B y_{ij}^{v \rightarrow t} \log \hat{y}_{ij}^{v \rightarrow t} \quad (3.26)$$


$$\mathcal{L}_{t \rightarrow v} = -\frac{1}{B} \sum_{j=1}^B \sum_{i=1}^B y_{ji}^{t \rightarrow v} \log \hat{y}_{ji}^{t \rightarrow v} \quad (3.27)$$

Sau giai đoạn này, hai bộ mã hóa đã được điều chỉnh để tạo ra không gian ảnh-văn bản phù hợp hơn với dữ liệu X-quang xương. Tuy nhiên, các đặc trưng của cặp ảnh-văn bản mới chỉ được căn chỉnh gần nhau hơn ở mức biểu diễn trong không gian nhúng và chưa được tối ưu trực tiếp cho quyết định phân lớp đa lớp. Vì vậy, giai đoạn thứ hai tiếp tục sử dụng các bộ mã hóa đã thích nghi, đồng thời đưa mô-đun dung hợp và mô-đun phân loại vào quá trình huấn luyện có giám sát.

3.6.2 Giai đoạn 2: học dung hợp và phân lớp

Hình 3.5 minh họa quy trình học dung hợp và phân lớp trong giai đoạn này.

Trong giai đoạn thứ hai (Phase 2), mục tiêu cốt lõi của mạng là tiến hành dung hợp sâu sắc các thông tin đa phương thức từ hai nhánh ảnh-



Hình 3.5: Giai đoạn học dung hợp và phân lớp

chữ, sau đó đưa qua một bộ phân loại tuyến tính (Linear Classifier) đơn giản để dự đoán trực tiếp các lớp bệnh lý hạ nguồn.

Quy trình lan truyền tiến, tính toán hàm mất mát và cập nhật trọng số trong giai đoạn này được thực hiện tuần tự theo các bước sau:

1. **Khởi tạo đầu vào bộ phân loại:** Gọi $\mathbf{z} = y_{\text{fusion}} \in \mathbb{R}^D$ là vector đặc trưng dung hợp tổng hợp thu được từ đầu ra của mô-đun chú ý chéo hai chiều, với $D = 512$. Bộ phân loại hạ nguồn được thiết lập để dự đoán $C = 22$ lớp bệnh lý y khoa mục tiêu.
2. **Phép chiếu tuyến tính và tính xác suất dự đoán (Forward Pass):** Vector đặc trưng dung hợp $\mathbf{z}$ được đưa trực tiếp qua một lớp tuyến tính đơn giản (Linear Layer) để tính toán ma trận logits điểm số $\mathbf{s} \in \mathbb{R}^C$:

$$\mathbf{s} = W_{\text{clf}}\mathbf{z} + b_{\text{clf}} \quad (3.28)$$

Trong đó, $W_{\text{clf}} \in \mathbb{R}^{C \times D}$ là ma trận trọng số khả huấn của bộ phân loại, và $b_{\text{clf}} \in \mathbb{R}^C$ là vector sai số (bias).

Điểm logits thô s_c của từng lớp $c \in [1, C]$ sau đó được đưa qua hàm kích hoạt Softmax để chuyển đổi thành phân phối xác suất dự đoán $\hat{p}_c \in [1]$ tương ứng:

$$\hat{p}_c = \text{Softmax}(s_c) = \frac{\exp(s_c)}{\sum_{j=1}^C \exp(s_j)} \quad (3.29)$$

3. **Hàm mất mát Entropy chéo có trọng số (Weighted Cross-Entropy Loss):** Để đối phó với hiện tượng mất cân bằng mẫu nghiêm trọng giữa 22 lớp bệnh lý trong tập dữ liệu y khoa, mô hình áp dụng hàm mất mát Weighted Cross-Entropy ($\mathcal{L}_{\text{WCE}}$). Với nhãn thực tế dạng mã hóa một nóng (one-hot) ký hiệu là $y \in \{0, 1\}^C$, hàm mất mát được định nghĩa như sau:

$$\mathcal{L}_{\text{WCE}} = - \sum_{c=1}^C w_c y_c \log(\hat{p}_c) \quad (3.30)$$

Trong đó, w_c là hệ số trọng số phạt được gán cho lớp thứ c (tỉ lệ nghịch với tần suất xuất hiện của lớp đó trong tập huấn luyện).

4. **Lan truyền ngược sai số gradient (Backpropagation):** Để tối ưu hóa toàn bộ mô hình, mạng tính toán đạo hàm riêng của hàm lỗi $\mathcal{L}_{\text{WCE}}$ đối với các điểm logit đầu ra s_i ($i = 1, \dots, C$):

$$\frac{\partial \mathcal{L}_{\text{WCE}}}{\partial s_i} = \left(\sum_{c=1}^C w_c y_c \right) \hat{p}_i - w_i y_i \quad (3.31)$$

Giả sử mẫu dữ liệu thuộc về lớp thực tế c^* (tức $y_{c^*} = 1$ và $y_{i \neq c^*} = 0$), phương trình trên được thu gọn tối giản về dạng:

$$\frac{\partial \mathcal{L}_{\text{WCE}}}{\partial s_i} = w_{c^*} (\hat{p}_i - y_i) \quad (3.32)$$

Gradient của hàm lỗi đối với các tham số trực tiếp của lớp phân loại

tuyến tính (W_{clf} và b_{clf}) được xác định bằng:

$$\frac{\partial \mathcal{L}_{\text{WCE}}}{\partial W_{\text{clf}}} = \left(\frac{\partial \mathcal{L}_{\text{WCE}}}{\partial \mathbf{s}} \right) \mathbf{z}^T, \quad \frac{\partial \mathcal{L}_{\text{WCE}}}{\partial b_{\text{clf}}} = \frac{\partial \mathcal{L}_{\text{WCE}}}{\partial \mathbf{s}} \quad (3.33)$$

Để tiếp tục cập nhật các khối bên dưới, gradient sai số được truyền ngược về vector dung hợp đầu vào $\mathbf{z}$:

$$\frac{\partial \mathcal{L}_{\text{WCE}}}{\partial \mathbf{z}} = W_{\text{clf}}^T \left(\frac{\partial \mathcal{L}_{\text{WCE}}}{\partial \mathbf{s}} \right) \quad (3.34)$$

5. **Quy trình cập nhật trọng số hệ thống:** Gradient $\frac{\partial \mathcal{L}_{\text{WCE}}}{\partial \mathbf{z}}$ tiếp tục lan truyền ngược qua khối MLP, các lớp chuẩn hóa tầng LN, các ma trận chiếu của mô-đun chú ý chéo hai chiều, và đi sâu xuống các ma trận thích ứng LoRA (A và B) của cả hai nhánh bộ mã hóa ảnh và chữ.

Gọi Θ_2 là tập hợp tất cả các tham số có quyền cập nhật trong giai đoạn này. Tại mỗi bước lặp t , thuật toán tối ưu hóa AdamW thực hiện cập nhật đồng thời các tham số theo công thức:

$$\Theta_2^{(t+1)} = \Theta_2^{(t)} - \eta \cdot \text{AdamW} \left(\nabla_{\Theta_2} \mathcal{L}_{\text{WCE}}^{(t)} \right) \quad (3.35)$$

Trong đó, η là tốc độ học được thiết lập theo lịch trình suy giảm tuyến tính.

3.7 Phát hiện dữ liệu lệch phân phối bằng thuật toán k-NN đa phương thức

Sau hai giai đoạn huấn luyện, hệ thống sử dụng các biểu diễn đơn phương thức để xây dựng một điểm cảnh báo ngoài phân phối (Out-of-Distribution, OOD) theo phương pháp hậu xử lý. Với cặp đầu vào (v, t) đã được định nghĩa ở các phần trên, $y_v^0 \in \mathbb{R}^D$ và $y_t^0 \in \mathbb{R}^D$ lần lượt là các

vectơ toàn cục ở vị trí [CLS] của nhánh ảnh và nhánh văn bản. Bộ phát hiện OOD không cập nhật tham số của XBone-Net và không sử dụng mẫu OOD để xây dựng ngân hàng tham chiếu hoặc chọn ngưỡng.

Việc dùng hai biểu diễn đơn phương thức thay cho vectơ dung hợp y_{fusion} cho phép đo độ lệch riêng trên từng nguồn dữ liệu. Đây là một lựa chọn thiết kế cần được đánh giá thực nghiệm; không giả định rằng phép dung hợp luôn làm mất thông tin cần thiết cho phát hiện OOD.

Trước tiên, hai vectơ toàn cục được chuẩn hóa theo chuẩn L_2 :

$$\tilde{y}_v = \frac{y_v^0}{\|y_v^0\|_2}, \quad \tilde{y}_t = \frac{y_t^0}{\|y_t^0\|_2}. \quad (3.36)$$

Với các vectơ đơn vị, thứ tự theo khoảng cách Euclid tương ứng với thứ tự theo độ tương đồng cosine vì $\|a - b\|_2^2 = 2 - 2a^\top b$ khi $\|a\|_2 = \|b\|_2 = 1$.

Từ N_{train} mẫu huấn luyện trong phân phối, hai ngân hàng tham chiếu đã chuẩn hóa được xây dựng độc lập:

$$\mathcal{D}_v = \{z_{v,1}, z_{v,2}, \dots, z_{v,N_{\text{train}}}\}, \quad \mathcal{D}_t = \{z_{t,1}, z_{t,2}, \dots, z_{t,N_{\text{train}}}\}. \quad (3.37)$$

Mỗi $z_{v,i}$ hoặc $z_{t,i}$ là vectơ toàn cục đã được chuẩn hóa của mẫu huấn luyện thứ i trong không gian biểu diễn tương ứng.

Với một mẫu cần đánh giá, gọi $z_v^{(k)} \in \mathcal{D}_v$ và $z_t^{(k)} \in \mathcal{D}_t$ là láng giềng gần thứ k trong từng không gian. Hai khoảng cách k -NN đơn phương thức được xác định bởi

$$d_v(\tilde{y}_v) = \left\| \tilde{y}_v - z_v^{(k)} \right\|_2, \quad d_t(\tilde{y}_t) = \left\| \tilde{y}_t - z_t^{(k)} \right\|_2. \quad (3.38)$$

Mặc dù đầu vào đã được chuẩn hóa L_2 , phân phối của d_v và d_t vẫn có thể khác nhau. Vì vậy, trước khi hợp nhất, trung bình và độ lệch chuẩn của từng khoảng cách được ước lượng trên tập xác thực ID $\mathcal{V}_{\text{ID}}$. Ký hiệu các thống kê này là $\mu_v^{\text{val}}, \sigma_v^{\text{val}}$ và $\mu_t^{\text{val}}, \sigma_t^{\text{val}}$; hai khoảng cách sau chuẩn hóa Z-score là

$$\tilde{d}_v = \frac{d_v - \mu_v^{\text{val}}}{\sigma_v^{\text{val}} + \epsilon}, \quad \tilde{d}_t = \frac{d_t - \mu_t^{\text{val}}}{\sigma_t^{\text{val}} + \epsilon}, \quad (3.39)$$

trong đó $\epsilon > 0$ là hằng số nhỏ dùng để bảo đảm ổn định số. Phép biến

đổi này đưa hai khoảng cách về cùng thang đo không thứ nguyên, nhưng không hàm ý rằng chúng tuân theo phân phối Gauss.

Điểm OOD đa phương thức giữ ký hiệu d_{OOD} đã dùng ở phần trên và được hợp nhất bằng toán tử cực đại:

$$d_{\text{OOD}}(\tilde{y}_v, \tilde{y}_t) = \max \left\{ \tilde{d}_v, \tilde{d}_t \right\}. \quad (3.40)$$

Quy tắc này làm điểm tổng hợp tăng khi ít nhất một phương thức khác biệt so với dữ liệu tham chiếu. Tuy nhiên, giá trị lớn chỉ tạo tín hiệu cảnh báo, không tự thân chứng minh rằng mẫu chắc chắn là OOD.

Ngưỡng λ được hiệu chỉnh trên cùng tập xác thực ID tại mức cảnh báo nhầm mục tiêu $\alpha = 0,05$:

$$\lambda = Q_{1-\alpha}^+(\{d_{\text{OOD}}(\tilde{y}_{v,i}, \tilde{y}_{t,i}) \mid (v_i, t_i) \in \mathcal{V}_{\text{ID}}\}), \quad \alpha = 0,05, \quad (3.41)$$

trong đó Q_q^+ là phân vị thực nghiệm phía trên ở mức q . Với tập mẫu hữu hạn, cách chọn này nhằm giữ lại ít nhất khoảng 95% mẫu xác thực ID theo quy ước phân vị; nó không đồng nhất với chỉ số FPR@95%TPR dùng để đánh giá trên tập kiểm thử.


Quy tắc cảnh báo:

$$G(\tilde{y}_v, \tilde{y}_t) = \begin{cases} \text{ID}, & \text{nếu } d_{\text{OOD}}(\tilde{y}_v, \tilde{y}_t) \leq \lambda, \\ \text{OOD}, & \text{nếu } d_{\text{OOD}}(\tilde{y}_v, \tilde{y}_t) > \lambda. \end{cases} \quad (3.42)$$

Kết quả của G là tín hiệu cảnh báo hỗ trợ cho dự đoán phân lớp, không phải bằng chứng bảo đảm an toàn và không được diễn giải như một cơ chế tự động từ chối chẩn đoán.

3.8 Suy luận trong quá trình trực tuyến

Hình 3.6 minh họa quy trình suy luận trực tuyến và phát hiện mẫu ngoài phân phối.



Hình 3.6: Quy trình suy luận trực tuyến và phát hiện mẫu ngoài phân phối

Tại pha suy luận (inference), khi nhận được một mẫu dữ liệu bệnh nhân mới bao gồm cặp hình ảnh y tế đầu vào v và văn bản mô tả lâm sàng t , hệ thống thực hiện một quy trình xử lý khép kín, an toàn và tối ưu hóa thời gian phản hồi.

Để triệt tiêu hoàn toàn độ trễ tính toán phát sinh từ các nhánh thích ứng hỗ trợ trong pha suy luận thực tế, các ma trận trọng số LoRA học được (A và B) được cộng tích hợp trực tiếp vào ma trận trọng số gốc của các lớp tuyến tính tương ứng trong bộ mã hóa ảnh và văn bản trước khi triển khai:

$$W_{\text{inference}} = W_0 + \frac{\alpha}{r}BA \quad (3.43)$$

Nhờ phép cộng gộp này, mô hình suy luận hoạt động với cấu trúc và số lượng tham số tương đương mô hình pre-trained gốc nhưng đã mang đầy đủ tri thức thích nghi miền. Dòng chảy dữ liệu và quyết định của quy trình suy luận diễn ra tuần tự qua các bước sau:

1. **Trích xuất đặc trưng:** Cặp đầu vào (v, t) được đưa vào hai bộ mã hóa thích ứng để trích xuất các ma trận đặc trưng biểu diễn ngữ nghĩa:

- Bộ mã hóa hình ảnh trích xuất ma trận đặc trưng đầy đủ $y_v \in \mathbb{R}^{197 \times D}$, được chia thành vector toàn cục ở dòng đầu tiên $y_v^0 \in$

$\mathbb{R}^D$ (token $[CLS]$) và ma trận đặc trưng cục bộ của các mảnh ảnh ở các dòng còn lại $y_v^{1:} \in \mathbb{R}^{196 \times D}$.

- Bộ mã hóa văn bản trích xuất ma trận đặc trưng đầy đủ $y_t \in \mathbb{R}^{T \times D}$ với $T = 256$, được chia thành vector toàn cục ở dòng đầu tiên $y_t^0 \in \mathbb{R}^D$ (token $[CLS]$) và chuỗi ngữ cảnh còn lại $y_t^{1:} \in \mathbb{R}^{(T-1) \times D}$; các vị trí đệm bị loại bằng mặt nạ chú ý.

2. **Tính điểm cảnh báo OOD bằng k -NN đa phương thức:** Các vectơ toàn cục được đưa qua bộ phát hiện OOD đã trình bày tại Mục 3.7:

- Tiến hành chuẩn hóa chuẩn L_2 trên các vector toàn cục để đưa về mặt cầu đơn vị:

$$\tilde{y}_v = \frac{y_v^0}{\|y_v^0\|_2}, \quad \tilde{y}_t = \frac{y_t^0}{\|y_t^0\|_2}. \quad (3.44)$$

- Tính khoảng cách Euclid d_v và d_t tới láng giềng thứ k trong hai ngân hàng tham chiếu $\mathcal{D}_v$ và $\mathcal{D}_t$, sau đó chuẩn hóa chúng thành $\tilde{d}_v$ và $\tilde{d}_t$ bằng các thống kê của $\mathcal{V}_{ID}$.
- Hợp nhất hai khoảng cách đã chuẩn hóa bằng toán tử cực đại:

$$d_{OOD} = \max \left\{ \tilde{d}_v, \tilde{d}_t \right\}. \quad (3.45)$$

- So sánh d_{OOD} với ngưỡng λ . Trường hợp $d_{OOD} > \lambda$ tạo cảnh báo để người dùng xem xét mẫu; trường hợp còn lại chỉ cho biết mẫu không vượt ngưỡng đã hiệu chỉnh, không xác nhận rằng mẫu chắc chắn an toàn hay thuộc phân phối huấn luyện.

3. **Dung hợp ngữ cảnh bằng chú ý chéo hai chiều (Bidirectional Cross-Attention Fusion):** Với dữ liệu an toàn, mô hình thực hiện dung hợp sâu sắc thông tin đa phương thức:

- Nhánh ảnh-sang-chữ dùng Query y_v^0 rà quét chuỗi cục bộ $y_t^{1:}$ để tạo ra đặc trưng chữ căn chỉnh bối cảnh ảnh $f_{v \rightarrow t} \in \mathbb{R}^D$.

- Nhánh chữ-sang-ảnh dùng Query y_t^0 rà quét chuỗi cục bộ y_v^1 : để tạo ra đặc trưng ảnh căn chỉnh bối cảnh chữ $f_{t \rightarrow v} \in \mathbb{R}^D$.
- Thực hiện chuẩn hóa LN kết hợp kết nối tắt và ghép nối (concatenation) đặc trưng:

$$h_v = \text{LN}(f_{v \rightarrow t} + y_v^0), \quad h_t = \text{LN}(f_{t \rightarrow v} + y_t^0), \quad h_{\text{concat}} = [h_v; h_t] \in \mathbb{R}^{2D} \quad (3.46)$$

- Đưa qua mạng truyền thẳng (MLP) để tạo vector biểu diễn dung hợp tổng hợp cuối cùng:

$$\mathbf{z} = y_{\text{fusion}} = \text{MLP}(h_{\text{concat}}) \in \mathbb{R}^D \quad (3.47)$$

4. **Phân lớp chẩn đoán bệnh lý (Diagnostic Classification):** Vector dung hợp tối ưu $\mathbf{z} \in \mathbb{R}^{512}$ được đưa qua bộ phân loại tuyến tính đơn giản cuối cùng để đưa ra quyết định lâm sàng:

- Tính vector logits điểm số $\mathbf{s}$ cho 22 lớp bệnh lý hạ nguồn:

$$\mathbf{s} = W_{\text{clf}} \mathbf{z} + b_{\text{clf}} \in \mathbb{R}^{22} \quad (3.48)$$

- Áp dụng hàm Softmax để thu được xác suất dự đoán cho từng nhãn $y_k \in \mathcal{Y} = \{y_1, y_2, \dots, y_K\}$:

$$\hat{p}_k = \frac{\exp(s_k)}{\sum_{j=1}^K \exp(s_j)}. \quad (3.49)$$

- Hệ thống xuất ra nhãn có xác suất lớn nhất:

$$\hat{y} = \arg \max_{y_k \in \mathcal{Y}} p(y_k \mid v, t). \quad (3.50)$$

Sau khi mô hình đưa ra nhãn dự đoán, hệ thống có thể sử dụng phương pháp tích phân gradient [35] để xác định những vùng ảnh và đơn vị văn bản làm thay đổi điểm số của nhãn đó. Lớp có xác suất lớn nhất trên cặp đầu vào đầy đủ được cố định làm lớp đích trong toàn bộ phép phân tích. Khi giải thích ảnh, văn bản của mẫu được giữ nguyên. Ngược lại, khi giải

thích văn bản, ảnh X-quang được giữ nguyên. Các tham số mô hình cũng được giữ cố định vì gradient chỉ được tính theo đầu vào cần giải thích và không dùng để cập nhật mô hình.

Với tập nhãn $\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$, gọi $\hat{y} = y_{\hat{k}} \in \mathcal{Y}$ là nhãn dự đoán và $F_{\hat{k}}(\mathbf{u}) = s_{\hat{k}} \in \mathbb{R}$ là logit của lớp này tại đầu vào $\mathbf{u}$. Nếu $\mathbf{u}^0$ là mốc tham chiếu, mức đóng góp của thành phần thứ j được xác định bởi

$$\text{IG}_j(\mathbf{u}, \mathbf{u}^0) = (u_j - u_j^0) \int_0^1 \frac{\partial F_{\hat{k}}(\mathbf{u}^0 + \beta(\mathbf{u} - \mathbf{u}^0))}{\partial u_j} d\beta. \quad (3.51)$$

Trong đó, $\beta \in [0, 1]$ xác định các điểm trên đường nội suy từ mốc tham chiếu đến đầu vào thật. Tích phân được xấp xỉ bằng quy tắc hình thang với 24 điểm nội suy, đồng bộ với thiết lập đánh giá ở Chương 4. Mức đóng góp dương cho biết thành phần đang xét làm tăng logit của lớp dự đoán so với mốc tham chiếu, còn mức đóng góp âm cho biết thành phần đó làm giảm logit. Do lớp đích được giữ cố định, các mức đóng góp đều giải thích cùng một quyết định phân loại.

Mốc tham chiếu của ảnh là một nền đen được biểu diễn bằng tenxơ không tại đầu vào của phép giải thích. Mốc tham chiếu của văn bản là văn bản trống, nghĩa là không chứa từ nội dung. Trong mã nguồn, các vị trí nội dung được thay bằng đặc trưng của đơn vị đệm, còn các đơn vị đặc biệt cần thiết cho bộ mã hóa được giữ nguyên. Hai mốc này cũng được sử dụng khi đánh giá mức phụ thuộc của dự đoán vào từng nguồn thông tin ở Mục 4.5.

Kết quả trên ảnh được tổng hợp qua ba kênh màu để tạo bản đồ nhiệt, trong đó màu nóng biểu thị những vị trí có độ lớn đóng góp cao đối với lớp dự đoán. Kết quả trên văn bản được tổng hợp theo chiều đặc trưng của từng đơn vị, trong đó màu cam biểu thị tác động ủng hộ và màu xanh biểu thị tác động phản đối lớp dự đoán. Các đơn vị đệm và đơn vị đặc biệt không được hiển thị như nội dung giải thích. Khi toàn bộ đóng góp dương gần bằng không, độ lớn tuyệt đối được dùng làm quy tắc dự phòng để tránh tạo bản đồ rỗng.

Độ trung thực của mức đóng góp được kiểm tra bằng cách lần lượt loại bỏ hoặc khôi phục các vùng ảnh kích thước 16×16 và các đơn vị văn bản

theo thứ tự đóng góp giảm dần. Nếu các thành phần được xếp hạng cao thực sự quan trọng đối với quyết định, xác suất của lớp đích được kỳ vọng giảm nhanh khi chúng bị thay bằng mốc tham chiếu và tăng nhanh khi chúng được khôi phục. Hệ thống còn thay toàn bộ ảnh bằng nền đen hoặc toàn bộ nội dung văn bản bằng văn bản trống, sau đó so sánh xác suất lớp đích với đầu vào đầy đủ. Mức giảm xác suất lớn hơn cho thấy dự đoán phụ thuộc nhiều hơn vào nguồn thông tin bị che trong phép can thiệp đã chọn.

Tích phân gradient thỏa tính đầy đủ theo nghĩa tổng mức đóng góp xấp xỉ chênh lệch logit giữa đầu vào và mốc tham chiếu:

$$\sum_j \text{IG}_j(\mathbf{u}, \mathbf{u}^0) \approx F_{\hat{k}}(\mathbf{u}) - F_{\hat{k}}(\mathbf{u}^0). \quad (3.52)$$

Sai số của quan hệ này được dùng để kiểm tra chất lượng xấp xỉ số. Tuy nhiên, bản đồ ảnh, điểm văn bản và mức giảm xác suất chỉ phản ánh sự phụ thuộc của dự đoán đối với đầu vào, lớp đích và mốc tham chiếu đã chọn. Các kết quả này không chứng minh quan hệ nhân quả, không xác nhận vị trí tổn thương, không bảo đảm tính đúng lâm sàng và không thay thế đánh giá của chuyên gia.

Chương 4

Thực nghiệm và kết quả

Chương này trình bày thiết kế thực nghiệm và kết quả theo bốn câu hỏi nghiên cứu đã nêu ở Chương 1. Câu hỏi thứ nhất xem xét hiệu năng phân lớp và đánh đổi chi phí. Câu hỏi thứ hai đánh giá ảnh hưởng của các thành phần. Câu hỏi thứ ba xác định khả năng và giới hạn của cảnh báo dữ liệu ngoài phân phối hậu xử lý. Câu hỏi thứ tư khảo sát mức phụ thuộc của dự đoán vào ảnh và văn bản qua tích phân gradient kết hợp can thiệp đầu vào. Các cấu hình có huấn luyện được đánh giá trên ba hạt giống 42, 123 và 456, sau đó giá trị tổng hợp được báo cáo dưới dạng trung bình $\pm$ độ lệch chuẩn. Riêng phân tích tích phân gradient sử dụng hạt giống 42 trên 44 mẫu chuẩn hóa. Kết quả theo từng hạt giống và các phân tích bổ sung được trình bày tại Phụ lục C.

4.1 Thiết kế thực nghiệm

4.1.1 Chuẩn bị dữ liệu

Nghiên cứu sử dụng bộ dữ liệu BTXRD [40] được công bố và bộ dữ liệu CTCH được thu thập tại Bệnh viện CTCH Thành phố Hồ Chí Minh do giảng viên cung cấp. Các phần dưới đây mô tả nguồn gốc, cách thức thu thập và những số liệu thống kê liên quan đến từng bộ dữ liệu. Ngoài ra, cấu trúc thư mục và các bước tiền xử lý sẽ được mô tả ở Phụ lục A.

Bộ dữ liệu BTXRD


BTXRD là bộ dữ liệu ảnh X-quang được xây dựng cho các bài toán phân lớp, định vị và phân vùng u xương nguyên phát. Phiên bản được sử dụng trong nghiên cứu gồm 3.746 ảnh, siêu dữ liệu về tuổi, giới tính, vị trí giải phẫu và tư thế chụp, cùng các chỉ báo về sự hiện diện, tính lành tính hoặc ác tính và phân nhóm tổn thương. Đối với 1.867 ảnh có u, bộ dữ liệu còn cung cấp tệp chú thích chứa thông tin vùng tổn thương.

Theo mô tả của bộ dữ liệu công bố, dữ liệu được tổng hợp từ ba bệnh viện tại Trung Quốc, Radiopaedia và MedPix. Dữ liệu bệnh viện được thu thập trong giai đoạn từ tháng 7 năm 2013 đến tháng 7 năm 2023, các chẩn đoán được xác nhận bằng mô bệnh học hoặc được hai bác sĩ X-quang thống nhất. Đối với hai nguồn trực tuyến, các ảnh liên quan đến u xương được hai chuyên gia tuyển chọn, đồng thời yêu cầu có thông tin tuổi và giới tính. Những vùng giải phẫu có ít mẫu hoặc nhiều nhiễu như đầu, cổ, ngực và bụng được loại bỏ, do đó phạm vi còn lại tập trung vào chi trên, chi dưới và xương chậu.

Quy trình chú thích được thực hiện bằng Labelme [30]: một bác sĩ chuyên khoa u xương có 10 năm kinh nghiệm xác định vùng tổn thương, sau đó kết quả được một chuyên gia có 20 năm kinh nghiệm kiểm tra.

Đặc điểm dữ liệu và bài toán phân lớp Trong 3.746 mẫu, có 1.879 ảnh bình thường, 1.525 ảnh thuộc nhóm u lành tính và 342 ảnh thuộc nhóm u ác tính. Tuổi dao động từ 1 đến 88, gồm 2.098 mẫu nam và 1.648 mẫu nữ như được thể hiện trong Hình 4.1.

Nhân được thiết lập dưới dạng phân lớp đơn nhãn với 10 lớp. Nhân bình thường được suy ra khi cờ chỉ báo u bằng 0, chín lớp còn lại được lấy từ các chỉ báo bệnh lý trong siêu dữ liệu. Bảng 4.1 trình bày số lượng mẫu theo tập chia, trong khi Bảng 4.2 trình bày phân bố lớp ở các tập chia.



Hình 4.1: Phân bố độ tuổi và giới tính của các bệnh nhân được quan sát trong bộ dữ liệu BTXRD

Tập chia	Số lượng hình ảnh	Tỷ lệ (%)
Huấn luyện	2.621	70
Xác thực	375	10
Kiểm thử	750	20
Tổng cộng	3.746	100,00

Bảng 4.1: Phân bố mẫu theo các tập chia trong BTXRD

Nhân bệnh lý	Huấn luyện	Xác thực	Kiểm thử	Tổng	Tỷ lệ
Bình thường	1.322	191	366	1.879	50,16%
U xương sụn	538	70	145	753	20,10%
Sarcoma xương	200	32	65	297	7,93%
Đa u xương sụn	189	29	45	263	7,02%
Nang xương đơn thuần	149	17	40	206	5,50%
U lành tính khác	83	8	24	115	3,07%
U tế bào khổng lồ	54	8	31	93	2,48%
U sụn màng hoạt dịch	35	7	9	51	1,36%
U ác tính khác	27	5	13	45	1,20%
U xơ xương	24	8	12	44	1,17%
Tổng	2.621	375	750	3.746	100,00%

Bảng 4.2: Phân bố các lớp đơn nhân sau chuẩn hóa trong bộ dữ liệu BTXRD

Bộ dữ liệu được chia ngẫu nhiên ở mức ảnh với hạt giống 42 và tỷ lệ 70/10/20 cho các tập huấn luyện, xác thực và kiểm thử. Tập siêu dữ liệu không cung cấp mã người bệnh ổn định để nhóm các ảnh của cùng một ca trước khi chia. Vì vậy, kết quả BTXRD chỉ được diễn giải trong phạm vi phép chia ở mức ảnh.

Bộ dữ liệu BTXRD không cung cấp bệnh sử lâm sàng tương ứng với từng bệnh nhân. Do đó, để bổ sung nguồn văn bản đi kèm, nghiên cứu sử dụng quy trình sinh văn bản lâm sàng bằng siêu dữ liệu có sẵn được mô tả ở Phụ lục A.1 và kết quả được minh họa như Bảng 4.3.

Ảnh	Nhãn	Văn bản giả lâm sàng được sinh
	<i>other mt</i>	Patient: 48-year-old female. Reason for admission: Pain and swelling of the hip bone. Disease history: Pain in the hip bone for 1 month; associated with decreased appetite. Physical examination: Palpable mass; tenderness on palpation; mild swelling. Personal medical history: No prior bone disease or fracture. No relevant surgical or medical history. Radiographic evaluation: AP view of the hip bone was obtained.
	<i>multiple osteochondromas</i>	Patient: 64-year-old male. Reason for admission: Progressive pain in the humerus. Disease history: The patient reports worsening pain in the humerus for 1 month. Physical examination: Palpable mass with local tenderness; no lymphadenopathy detected. Personal medical history: No prior bone disease or fracture. History of age-related degenerative changes; no prior bone lesions. Radiographic evaluation: AP view of the humerus was obtained.

Bảng 4.3: Ví dụ ảnh, nhãn và văn bản giả lâm sàng được sinh của bộ dữ liệu BTXRD

Trong thiết kế thực nghiệm, BTXRD được sử dụng để khảo sát khả năng chuyển giao sang bài toán u xương, ảnh hưởng của mất cân bằng lớp và hành vi của mô hình trong thiết lập văn bản tổng hợp. Do văn bản lâm sàng được sinh từ siêu dữ liệu và chịu ảnh hưởng của các cờ nhóm bệnh, kết quả trên bộ dữ liệu này không được diễn giải tương đương với kết quả thu được từ bệnh sử lâm sàng thực tế.

Bộ dữ liệu CTCH

CTCH là bộ dữ liệu X-quang xương được thu thập tại Bệnh viện CTCH Thành phố Hồ Chí Minh và được giảng viên Võ Thế Hào cùng giảng viên Đỗ Phúc Thịnh cung cấp cho nghiên cứu. Dữ liệu nguồn gồm ảnh được lựa chọn từ từng ca khám và các trường bệnh án tiếng Việt liên quan đến lý do vào viện, diễn tiến bệnh, tiền sử, kết quả khảo sát hình ảnh và chẩn đoán chuyên môn. Văn bản đầu vào chỉ sử dụng lý do vào viện, diễn tiến bệnh và tiền sử. Kết quả khảo sát hình ảnh, chẩn đoán chuyên môn và nhãn không được đưa vào chuỗi văn bản. Phạm vi thực nghiệm chỉ sử dụng ảnh X-quang đại diện cho vị trí bệnh lý. Ảnh từ phương thức tạo ảnh khác hoặc không đại diện cho vị trí bệnh lý không được đưa vào tập phân lớp. Quy trình lựa chọn trường và kiểm soát rò rỉ nhãn được trình bày tại Phụ lục A.2.

Đạo đức nghiên cứu, quyền riêng tư và tính sẵn có của dữ liệu
Bộ dữ liệu được sử dụng theo thỏa thuận bảo mật đã ký kết và chỉ phục vụ mục đích nghiên cứu. Trước khi xử lý, các thông tin có khả năng định danh trực tiếp người bệnh đã được loại bỏ và các mã hồ sơ chỉ được dùng để liên kết dữ liệu, kiểm soát việc phân chia tập và không được công bố trong kết quả nghiên cứu.

Do chứa thông tin y tế nhạy cảm, bộ dữ liệu gốc không được công khai và khóa luận chỉ trình bày số liệu thống kê cùng kết quả tổng hợp. Mọi hoạt động kiểm định hoặc triển khai trong môi trường lâm sàng về sau cần tuân thủ quy định bảo vệ dữ liệu và được cơ quan có thẩm quyền phê duyệt.

Đặc điểm dữ liệu và bài toán phân lớp Việc chia dữ liệu được thực hiện theo người bệnh với hạt giống ngẫu nhiên 42 và tỷ lệ mục tiêu 70/10/20. Người bệnh được nhóm theo lớp chính trước khi phân bổ để duy trì sự hiện diện của các lớp ít mẫu ở cả ba tập khi số lượng cho phép. Kết quả như được thể hiện ở Bảng 4.4 gồm 2.265 mẫu huấn luyện, 315 mẫu xác thực và 669 mẫu kiểm thử và Bảng 4.5 thể hiện chi tiết số lượng mẫu trong từng lớp trong các tập chia.

Tập dữ liệu	Số lượng ảnh	Tỷ lệ
Huấn luyện	2.265	69,71%
Xác thực	315	9,70%
Kiểm thử	669	20,59%
Tổng cộng	3.249	100,00%

Bảng 4.4: Phân bố mẫu trong phân phối của CTCH theo tập dữ liệu

Lớp	Huấn luyện	Xác thực	Kiểm thử	Tổng	Tỷ lệ
Bình thường	760	108	218	1.086	33,43%
Gãy xương quay	209	29	61	299	9,20%
Gãy xương cánh tay	147	21	42	210	6,46%
Gãy xương đùi	106	15	31	152	4,68%
Gãy xương ngón tay	102	14	31	147	4,52%
Gãy xương chày	99	14	29	142	4,37%
Gãy xương cẳng tay	99	14	29	142	4,37%
Gãy xương cổ chân	87	12	26	125	3,85%
Gãy xương cẳng chân	85	12	25	122	3,76%
Gãy xương vùng vai	70	10	21	101	3,11%
Gãy xương bàn chân	68	9	21	98	3,02%
Gãy cột sống thắt lưng	53	7	16	76	2,34%
Gãy xương bàn tay	53	7	16	76	2,34%
Gãy xương ngón chân	52	7	16	75	2,31%
Viêm khớp	47	6	15	68	2,09%
Gãy xương trụ	46	6	14	66	2,03%
Cắt cụt ngón tay	42	6	13	61	1,88%
Gãy xương bánh chè	41	5	13	59	1,82%
Gãy xương gót	36	5	11	52	1,60%
Gãy cột sống ngực	28	4	8	40	1,23%
Gãy xương thuyền	19	2	7	28	0,86%
Gãy xương vùng chậu	16	2	6	24	0,74%
Tổng cộng	2.265	315	669	3.249	100,00%

Bảng 4.5: Phân bố 22 lớp của CTCH trong ba tập dữ liệu

Mỗi hồ sơ được liên kết với một ảnh X-quang duy nhất. Trong quần thể phân lớp hiện tại, 3.249 ảnh tương ứng với 3.249 mã bệnh nhân và quần thể ngoài phân phối gồm 18 ảnh từ 18 mã khác, không giao với quần thể phân lớp. Bảng 4.6 minh họa một số mẫu sau tiền xử lý. Quy trình sàng lọc, lựa chọn trường văn bản và kiểm tra toàn vẹn được mô tả tại Phụ lục A.2.

Các mẫu ngoài phân phối không được đưa vào huấn luyện, xác thực hoặc kiểm thử bộ phân lớp 22 lớp. Nhóm này gồm các bệnh lý ngoại vi

nằm ngoài không gian nhãn đích và chỉ được sử dụng trong kịch bản đánh giá dữ liệu ngoài phân phối được trình bày ở phần thực nghiệm.

Ảnh	Nhãn	Bệnh sử lâm sàng
	<i>Lower leg fracture</i>	Reason for admission: Right lower leg pain. Disease history: The patient fell from the roof at 3:00 p.m. on October 17, 2024 in Tien Giang; no first aid. to the Orthopedic Trauma Hospital. Personal medical history: Nasopharynx is being treated
	<i>Finger phalanx fracture</i>	Reason for admission: Right hand wound. Disease history: The patient had his right hand cut by a saw at 2:00 p.m. on October 17, 2024 in Dong Nai; Go to the local medical station for first aid. to the Orthopedic Trauma Hospital. Personal medical history: Right hand third metatarsal fusion surgery 9 years ago

Bảng 4.6: Các ví dụ ảnh, nhãn và bệnh sử lâm sàng của bộ dữ liệu CTCH

CTCH là nguồn bằng chứng chính của khóa luận vì mỗi ảnh được liên kết với bệnh sử lâm sàng có sẵn và phép chia được thực hiện theo người bệnh. Bộ dữ liệu này đồng thời cung cấp quần thể ngoài không gian nhãn để khảo sát cảnh báo dữ liệu ngoài phân phối. Phân tích nguồn thông tin sử dụng một tập con chuẩn hóa gồm 44 mẫu kiểm thử tại hạt giống 42.

4.1.2 Cấu hình thí nghiệm

Mỗi cấu hình có huấn luyện được chạy với ba hạt giống 42, 123 và 456 trên cùng phân chia dữ liệu và môi trường ở Bảng 4.7. Bảng 4.8 trình bày các siêu tham số chính dùng trong thực nghiệm.

Thành phần	Cấu hình
Phần cứng	RTX 5060 Ti 16 GB, Intel Core Ultra 7 265KF và 32 GB RAM
Phần mềm	Python 3.11.15, Torch 2.11.0+cu128 và CUDA 12.8
Độ chính xác số học	bfloat16

Bảng 4.7: Môi trường thực nghiệm

Thành phần	Cấu hình
Đầu vào ảnh	1 ảnh qua phép biến đổi chuẩn của BiomedCLIP
Bộ tối ưu và kích thước lô	AdamW, 16
Hệ số suy giảm trọng số	10^{-4}
Lịch tốc độ học	cosine
Tỷ lệ khởi động	0,1
Độ chính xác số học	bfloat16
Cấu hình LoRA	Hạng 16, hệ số 32 và tỷ lệ bỏ học 0,1
Huấn luyện pha 1	Tốc độ học 5×10^{-5} , tối đa 30 vòng lặp và dừng sớm sau 3 vòng
Huấn luyện pha 2	Tốc độ học 10^{-4} , tối đa 50 vòng lặp và dừng sớm sau 5 vòng
Xử lý mất cân bằng lớp	Hệ số số lượng hiệu dụng 0,999 và giới hạn trọng số lớp 5,0

Bảng 4.8: Cấu hình chính của các thực nghiệm

4.1.3 Các độ đo

Hai bộ dữ liệu BTXRD và CTCH được thiết lập dưới dạng bài toán phân lớp đa lớp, với BTXRD có 10 lớp và CTCH có 22 lớp. Các độ đo được chia theo bốn mục tiêu gồm phân lớp, phát hiện dữ liệu ngoài phân phối, đánh giá tích phân gradient và đánh giá hiệu quả tham số cùng chi phí suy luận.

Độ đo phân lớp

Gọi N là số mẫu, C là số lớp và TP_c , FP_c , FN_c lần lượt là số dương đúng, dương sai và âm sai khi xem lớp c là lớp dương. Ký hiệu $\mathcal{C}_v$ chỉ các lớp có cả mẫu dương và mẫu âm trong phép đánh giá một đối với tất cả.

Độ chính xác Độ chính xác là tỷ lệ mẫu được dự đoán đúng trên toàn bộ tập đánh giá:

$$\text{Accuracy} = \frac{\sum_{c=1}^C TP_c}{N}. \quad (4.1)$$

Độ đo này được dùng để mô tả hiệu năng tổng thể, nhưng có thể bị chi phối bởi các lớp có nhiều mẫu.

Độ chính xác cân bằng Độ chính xác cân bằng [2] là trung bình độ nhạy của các lớp:

$$\text{Balanced Accuracy} = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FN_c}. \quad (4.2)$$

Mỗi lớp đóng góp như nhau, vì vậy độ đo được dùng để hạn chế ảnh hưởng của mất cân bằng lớp.

Độ chính xác dự đoán theo lớp Độ chính xác dự đoán của lớp c là tỷ lệ dự đoán lớp c thực sự thuộc lớp đó:

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c}. \quad (4.3)$$

Độ đo được dùng khi cần xem xét mức dự đoán dương sai của từng lớp và là thành phần của đường cong độ chính xác-độ nhạy.

Độ nhạy theo lớp Độ nhạy của lớp c là tỷ lệ mẫu thuộc lớp c được nhận diện:

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c}. \quad (4.4)$$

Độ đo phản ánh mức bỏ sót của từng lớp và tạo trục còn lại của đường cong độ chính xác-độ nhạy.

Macro-F1 Điểm F1 trung bình theo lớp lấy trung bình điểm F1 của từng lớp:

$$\text{Macro-F1} = \frac{1}{C} \sum_{c=1}^C \frac{2TP_c}{2TP_c + FP_c + FN_c}. \quad (4.5)$$

Độ đo cân bằng giữa dự đoán dương đúng và mức bỏ sót ở từng lớp, đồng thời được dùng làm độ đo phân lớp chính của nghiên cứu.

Macro-AUROC Diện tích dưới đường cong đặc trưng hoạt động trung bình theo lớp [10] lấy trung bình diện tích dưới đường cong ROC của từng lớp theo chiến lược một đối với tất cả:

$$\text{Macro-AUROC} = \frac{1}{|\mathcal{C}_v|} \sum_{c \in \mathcal{C}_v} \text{AUROC}_c. \quad (4.6)$$

Trong đó, AUROC_c là xác suất một mẫu lớp c được xếp hạng cao hơn một mẫu không thuộc lớp c . Độ đo này đánh giá chất lượng xếp hạng của mô hình trên toàn bộ các ngưỡng, trong đó giá trị cao hơn biểu thị khả năng phân biệt tốt hơn.

Độ chính xác trung bình theo lớp Độ chính xác trung bình của lớp c tóm tắt đường cong độ chính xác-độ nhảy tại các ngưỡng xếp hạng:

$$\text{AUPRC}_c = \sum_{k=1}^{K_c} (R_{c,k} - R_{c,k-1}) P_{c,k}. \quad (4.7)$$

Trong đó, $P_{c,k}$ và $R_{c,k}$ là độ chính xác dự đoán và độ nhảy tại ngưỡng thứ k , còn K_c là số ngưỡng được xét. Độ đo được dùng để tổng hợp chất lượng xếp hạng của riêng lớp c .

Macro-AUPRC Điểm độ chính xác trung bình theo lớp [4] lấy trung bình Average Precision trên các lớp hợp lệ:

$$\text{Macro-AUPRC} = \frac{1}{|\mathcal{C}_v|} \sum_{c \in \mathcal{C}_v} \text{AUPRC}_c. \quad (4.8)$$

Độ đo được tính bằng tổng bậc thang của Average Precision, không phải phép tích phân hình thang tổng quát dưới đường cong độ chính xác-độ nhảy. Giá trị cao hơn thường biểu thị kết quả thuận lợi hơn khi các lớp mất cân bằng.

Đánh giá thống kê ghép cặp Nghiên cứu sử dụng bootstrap ghép cặp để tính khoảng tin cậy và kiểm định hoán vị ghép cặp để tính giá trị p . Gọi X là XBone-Net, B_k là mô hình đối sánh thứ k , $S = 3$ là số hạt giống và $\mathcal{M}$ là độ đo cần xét. Chênh lệch trung bình giữa hai mô hình là:

$$\hat{\Delta}_k = \frac{1}{S} \sum_{s=1}^S [\mathcal{M}(\mathbf{y}, \hat{\mathbf{p}}_{X,s}) - \mathcal{M}(\mathbf{y}, \hat{\mathbf{p}}_{B_k,s})]. \quad (4.9)$$

Với các độ đo phân lớp trên, $\hat{\Delta}_k > 0$ có nghĩa XBone-Net đạt giá trị cao hơn mô hình đối sánh.

Bootstrap ghép cặp. Theo Efron và Tibshirani [8], ở lần lặp thứ b , nghiên cứu lấy mẫu có hoàn lại các bệnh nhân trong từng lớp và ba hạt giống huấn luyện. Cùng tập bệnh nhân $\mathcal{I}_b$ và cùng dãy hạt giống $s_1^{(b)}, \dots, s_S^{(b)}$ được dùng cho cả hai mô hình. Chênh lệch tại lần lặp này là:

$$\hat{\Delta}_k^{*(b)} = \frac{1}{S} \sum_{j=1}^S \left[\mathcal{M}(\mathbf{y}_{\mathcal{I}_b}, \hat{\mathbf{p}}_{X, s_j^{(b)}, \mathcal{I}_b}) - \mathcal{M}(\mathbf{y}_{\mathcal{I}_b}, \hat{\mathbf{p}}_{B_k, s_j^{(b)}, \mathcal{I}_b}) \right]. \quad (4.10)$$

Khoảng tin cậy 95% là hai phân vị 2,5% và 97,5% của các chênh lệch bootstrap $\{\hat{\Delta}_k^{*(b)}\}_{b=1}^{N_{\text{boot}}}$.

Kiểm định hoán vị ghép cặp. Theo Good [11], giả thuyết không cho rằng hai mô hình không có chênh lệch có hệ thống. Ở mỗi lần hoán vị r , dự đoán của hai mô hình được hoán đổi với xác suất 0,5 theo từng bệnh nhân; cùng quyết định hoán đổi được dùng cho mọi hạt giống, còn ba hạt giống được lấy mẫu có hoàn lại. Sau đó, chênh lệch $\hat{\Delta}_k^{\pi(r)}$ được tính lại. Giá trị p hai phía là:

$$p_k = \frac{1 + \sum_{r=1}^{N_{\text{perm}}} \mathbb{I}\left(\left|\hat{\Delta}_k^{\pi(r)}\right| \geq \left|\hat{\Delta}_k\right|\right)}{N_{\text{perm}} + 1}. \quad (4.11)$$

Phân tích dùng $N_{\text{boot}} = N_{\text{perm}} = 10\,000$, $\alpha = 0,05$ và hạt giống 2026. Sáu giá trị p trong mỗi độ đo được hiệu chỉnh Holm [14]. XBone-Net có ưu thế thống kê khi $\hat{\Delta}_k > 0$, khoảng tin cậy 95% không chứa 0 và $p_{\text{Holm}} < 0,05$; kết luận chỉ áp dụng cho phân hoạch hiện tại.

Độ đo phát hiện dữ liệu ngoài phân phối

Gọi $\mathcal{D}_{\text{ID}}$ và $\mathcal{D}_{\text{OOD}}$ lần lượt là tập trong và ngoài phân phối, $N_{\text{OOD}} = |\mathcal{D}_{\text{OOD}}|$, còn $s(x)$ là điểm bất thường với giá trị lớn hơn biểu thị khả năng ngoài phân phối cao hơn.

AUROC-OOD Diện tích dưới đường cong phân biệt dữ liệu ngoài phân phối [13] là xác suất điểm của một mẫu ngoài phân phối cao hơn điểm của một mẫu trong phân phối, với trường hợp bằng điểm được tính một nửa:

$$\text{AUROC}_{\text{OOD}} = \Pr(s(x_{\text{OOD}}) > s(x_{\text{ID}})) + \frac{1}{2} \Pr(s(x_{\text{OOD}}) = s(x_{\text{ID}})). \quad (4.12)$$

Độ đo được dùng để đánh giá khả năng xếp hạng hai phân phối trên mọi ngưỡng. Các giá trị cao hơn thường biểu thị mức phân biệt tốt hơn.

AUPR-Out Độ chính xác trung bình khi dữ liệu ngoài phân phối là lớp dương [13, 20] được tính bằng tổng bậc thang trên đường cong độ chính xác-độ nhạy:

$$\text{AUPR-Out} = \sum_{k=1}^K (R_k^{\text{OOD}} - R_{k-1}^{\text{OOD}}) P_k^{\text{OOD}}. \quad (4.13)$$

Trong đó, P_k^{OOD} và R_k^{OOD} lần lượt là độ chính xác dự đoán và độ nhạy tại ngưỡng thứ k . Độ đo bổ sung cho AUROC-OOD khi tỷ lệ mẫu ngoài phân phối thay đổi giữa các kịch bản, trong đó giá trị cao hơn thường thuận lợi hơn.

FPR@95%TPR Tỷ lệ chấp nhận nhầm tại điểm vận hành giữ lại 95% mẫu trong phân phối [20, 21] được xác định trên các điểm số của tập kiểm thử. Đặt τ_{95}^{test} là ngưỡng thấp nhất giữ lại ít nhất 95% mẫu trong phân phối của tập kiểm thử:

$$\begin{aligned} \text{FPR@95\%TPR} &= \frac{1}{N_{\text{OOD}}} \sum_{x \in \mathcal{D}_{\text{OOD}}} \mathbb{I}[s(x) \leq \tau_{95}^{\text{test}}], \\ \Pr_{x \sim \mathcal{D}_{\text{ID}}}^{\text{test}} [s(x) \leq \tau_{95}^{\text{test}}] &\geq 0,95. \end{aligned} \quad (4.14)$$

FPR@95%TPR là độ đo đánh giá, nên không sử dụng ngưỡng cảnh báo đã hiệu chỉnh trên tập xác thực. Ngưỡng cảnh báo triển khai được hiệu chỉnh riêng trên tập xác thực để giữ lại khoảng 95% mẫu trong phân phối và chỉ dùng cho quyết định cảnh báo. Giá trị FPR@95%TPR thấp hơn thường thuận lợi hơn.

Độ đo đánh giá tích phân gradient

Với mỗi mẫu, lớp đích t được chọn là lớp có xác suất dự đoán lớn nhất. Gọi $F_t(\mathbf{u})$ là logit của lớp này tại đầu vào hoặc dãy đơn vị biểu diễn $\mathbf{u}$, $\mathbf{u}'$ là mốc tham chiếu và L là số thành phần được đóng góp. Các đường loại bỏ và khôi phục dùng xác suất Softmax của cùng lớp dự đoán. Các độ đo dưới đây tập trung vào mức đóng góp và độ trung thực qua phép loại bỏ, khôi phục và đối chứng ngẫu nhiên.

Mức đóng góp bằng tích phân gradient Tích phân gradient [35] gán mức đóng góp cho thành phần j dọc theo đoạn thẳng từ mốc tham chiếu đến đầu vào:

$$\text{IG}_j(\mathbf{u}) = (u_j - u'_j) \int_0^1 \frac{\partial F_t(\mathbf{u}' + \alpha(\mathbf{u} - \mathbf{u}'))}{\partial u_j} d\alpha. \quad (4.15)$$

Trong đó, α là hệ số nội suy. Tích phân được xấp xỉ bằng quy tắc hình thang với 24 điểm. Thứ tự loại bỏ ưu tiên phần đóng góp dương đối với logit của lớp dự đoán. Chỉ khi toàn bộ phần đóng góp dương gần bằng 0, độ lớn tuyệt đối mới được dùng làm quy tắc dự phòng.

Diện tích dưới đường cong loại bỏ Theo phép đánh giá loại bỏ của Petsiuk và cộng sự [26], gọi $p_t(\mathbf{u}^{\text{del}}(q))$ là xác suất lớp đích sau khi thay tỷ lệ q đơn vị có mức đóng góp cao nhất bằng mốc tham chiếu. Diện tích dưới đường cong loại bỏ được xác định bởi:

$$\text{AUC}_{\text{del}} = \int_0^1 p_t(\mathbf{u}^{\text{del}}(q)) dq. \quad (4.16)$$

Tích phân được xấp xỉ bằng quy tắc hình thang tại các tỷ lệ can thiệp được định trước. Độ đo được dùng để kiểm tra liệu các đơn vị được tích phân gradient xếp hạng cao có làm xác suất lớp đích giảm nhanh hay không. Giá trị thấp hơn thường cung cấp bằng chứng thuận lợi hơn về độ trung thực.

Diện tích dưới đường cong khôi phục Theo phép đánh giá khôi phục của Petsiuk và cộng sự [26], gọi $p_t(\mathbf{u}^{\text{ins}}(q))$ là xác suất lớp đích khi bắt đầu từ mốc tham chiếu và khôi phục tỷ lệ q đơn vị theo thứ tự đóng góp giảm dần. Diện tích dưới đường cong khôi phục được xác định bởi:

$$\text{AUC}_{\text{ins}} = \int_0^1 p_t(\mathbf{u}^{\text{ins}}(q)) \, dq. \quad (4.17)$$

Độ đo đánh giá khả năng các đơn vị được xếp hạng cao khôi phục xác suất lớp đích từ mốc tham chiếu. Giá trị cao hơn thường cho thấy xác suất được phục hồi sớm hơn.

Mức giảm xác suất khi che nguồn thông tin Dựa vào độ đo tính toàn diện của DeYoung và cộng sự [6]. Gọi $p_t(x)$ là xác suất lớp đích tại đầu vào đầy đủ và $p_t(x_{\setminus m})$ là xác suất sau khi nguồn m được thay bằng mốc tham chiếu. Mức giảm xác suất do che nguồn được tính bằng:

$$\Delta p_m = p_t(x) - p_t(x_{\setminus m}), \quad m \in \{\text{img}, \text{txt}\}. \quad (4.18)$$

Giá trị dương cho thấy xác suất lớp đích giảm khi loại bỏ nguồn tương ứng. Đại lượng này phản ánh mức phụ thuộc của đầu ra theo mốc tham chiếu đã chọn.

Độ đo hiệu quả suy luận

Gọi Θ_{pre} là tập tham số của đồ thị huấn luyện trước khi hợp nhất LoRA và $\Theta_{\text{train}} \subseteq \Theta_{\text{pre}}$ là tập tham số có thể huấn luyện. Tổng tham số, tham số huấn luyện và tỷ lệ tham số huấn luyện được tính bằng:

$$P_{\text{total}} = \sum_{\theta \in \Theta_{\text{pre}}} |\theta|, \quad P_{\text{train}} = \sum_{\theta \in \Theta_{\text{train}}} |\theta|, \quad r_{\text{train}} = 100 \frac{P_{\text{train}}}{P_{\text{total}}}. \quad (4.19)$$

Đối với XBone-Net, P_{train} gồm tham số LoRA, mô-đun dung hợp và đầu phân lớp. Các tham số backbone còn lại được giữ cố định. Ba đại lượng trong bảng tham số được lấy trước khi hợp nhất LoRA nhằm phản ánh đúng số tham số cần cập nhật trong huấn luyện. Trước khi đo suy luận, trọng số LoRA được hợp nhất vào các lớp backbone nên không còn được tính như một nhánh tham số riêng.

Nghiên cứu đồng thời báo cáo số phép toán dấu phẩy động trên mỗi mẫu, thông lượng, độ trễ trung bình và bộ nhớ đồ họa cực đại [3, 29]. Số phép toán được đếm trên các phép toán mà bộ đếm của PyTorch hỗ trợ, trong đó một phép nhân-cộng được tính là hai phép toán. Thông lượng và độ trễ sử dụng kích thước lô 1 trên 20 lô kiểm thử. Mỗi lô gồm 10 lượt khởi động và 10 lượt ghi thời gian. Thời gian chỉ bao gồm lan truyền tiến sau khi dữ liệu đã nằm trong bộ nhớ GPU, không bao gồm nạp dữ liệu và truyền dữ liệu từ CPU. Các phép đo được thực hiện trên cùng phần cứng, độ chính xác số học và đồ thị suy luận sau khi hợp nhất LoRA.

4.2 Kiểm tra hiệu năng phân lớp và đánh đổi chi phí

4.2.1 Mục đích

Thực nghiệm này nhằm trả lời câu hỏi: XBone-Net đạt mức hiệu năng phân lớp như thế nào khi so với các mô hình đối chứng, đồng thời đánh đổi như thế nào giữa số tham số cần cập nhật và chi phí suy luận. Thực nghiệm tập trung vào hai khía cạnh gồm chất lượng dự đoán trên bộ dữ liệu CTCH và bộ BTXRD, cùng hiệu quả tham số và chi phí suy luận so với BiomedCLIP tinh chỉnh toàn bộ.

4.2.2 Nội dung

Nhóm đối chứng gồm ResNet-50 và DenseNet-121 chỉ nhận ảnh X-quang, cùng với CLIP, MedCLIP, PubMedCLIP và BiomedCLIP nhận cặp ảnh-văn bản. Hai mạng nơ-ron tích chập được khởi tạo từ trọng số ImageNet, còn bốn mô hình ngôn ngữ trực quan sử dụng trọng số tiền huấn luyện tương ứng. Tất cả sáu mô hình được tinh chỉnh toàn bộ trong pha phân lớp. Việc so sánh được thực hiện trên cùng tập chia của bộ dữ liệu CTCH và bộ BTXRD với các hạt giống 42, 123 và 456. Sáu mô hình dùng chung cấu hình thực nghiệm trên cả hai bộ dữ liệu. Kết quả phân lớp được tổng hợp qua ba hạt giống. Phép đo tham số và chi phí suy luận chỉ so sánh XBone-Net với BiomedCLIP tinh chỉnh toàn bộ trong cùng môi trường phần cứng, cùng kích thước lô và cùng dữ liệu đầu vào.

4.2.3 Kết quả

Kết quả phân lớp trên toàn bộ dữ liệu

Bảng 4.9 và Bảng 4.10 lần lượt trình bày các độ đo quyết định lớp và độ đo xếp hạng trong thiết lập sử dụng toàn bộ dữ liệu huấn luyện. Kiểm định thống kê được trình bày ở phần sau của thực nghiệm.

Dữ liệu	Mô hình	Acc $\uparrow$	BAcc $\uparrow$	Macro-F1 $\uparrow$
BTXRD	ResNet-50	0.6071 ± 0.0140	0.3188 ± 0.0136	0.3291 ± 0.0102
	DenseNet-121	0.6320 ± 0.0013	0.3694 ± 0.0150	0.3718 ± 0.0173
	CLIP	0.8036 ± 0.0273	0.5957 ± 0.0160	0.5787 ± 0.0252
	MedCLIP	0.8204 ± 0.0144	0.6125 ± 0.0235	0.6054 ± 0.0147
	PubMedCLIP	0.7884 ± 0.0285	0.6089 ± 0.0342	0.5723 ± 0.0577
	BiomedCLIP	0.8311 ± 0.0028	0.6062 ± 0.0254	0.5994 ± 0.0124
	XBone-Net	0.8302 ± 0.0098	0.6115 ± 0.0140	0.6240 ± 0.0118
CTCH	ResNet-50	0.4928 ± 0.0017	0.4126 ± 0.0106	0.4078 ± 0.0051
	DenseNet-121	0.4818 ± 0.0052	0.4927 ± 0.0461	0.4367 ± 0.0238
	CLIP	0.5874 ± 0.0209	0.6217 ± 0.0359	0.5633 ± 0.0090
	MedCLIP	0.5590 ± 0.0389	0.5717 ± 0.0186	0.5151 ± 0.0216
	PubMedCLIP	0.5521 ± 0.0234	0.5589 ± 0.0614	0.5203 ± 0.0264
	BiomedCLIP	0.5969 ± 0.0253	0.6023 ± 0.0234	0.5540 ± 0.0080
	XBone-Net	0.6183 ± 0.0203	0.5935 ± 0.0134	0.5727 ± 0.0193

Bảng 4.9: Kết quả phân loại trên BTXRD và CTCH

Dữ liệu	Mô hình	Macro-AUROC $\uparrow$	Macro-AUPRC $\uparrow$
BTXRD	ResNet-50	0.7236 ± 0.0259	0.3338 ± 0.0061
	DenseNet-121	0.7717 ± 0.0173	0.3831 ± 0.0036
	CLIP	0.8973 ± 0.0231	0.6251 ± 0.0080
	MedCLIP	0.8599 ± 0.0330	0.6228 ± 0.0253
	PubMedCLIP	0.9048 ± 0.0240	0.6149 ± 0.0245
	BiomedCLIP	0.8865 ± 0.0165	0.6511 ± 0.0104
	XBone-Net	0.8045 ± 0.0159	0.5865 ± 0.0110
CTCH	ResNet-50	0.9145 ± 0.0037	0.4492 ± 0.0042
	DenseNet-121	0.9350 ± 0.0046	0.4762 ± 0.0136
	CLIP	0.9290 ± 0.0387	0.6002 ± 0.0400
	MedCLIP	0.9215 ± 0.0333	0.5839 ± 0.0185
	PubMedCLIP	0.9279 ± 0.0214	0.5888 ± 0.0196
	BiomedCLIP	0.9390 ± 0.0289	0.6169 ± 0.0090
	XBone-Net	0.9020 ± 0.0095	0.5904 ± 0.0224

Bảng 4.10: Kết quả xếp hạng xác suất trên BTXRD và CTCH

Về kết quả quyết định lớp, XBone-Net đạt độ chính xác 0,8302 và điểm macro-F1 0,6240 trên bộ BTXRD, trong khi các giá trị tương ứng trên bộ dữ liệu CTCH là 0,6183 và 0,5727. Mô hình có kết quả quan sát cao hơn rõ rệt so với ResNet-50 và DenseNet-121 chỉ dùng ảnh. So với các mô hình ngôn ngữ trực quan, XBone-Net đạt điểm macro-F1 cao nhất trên cả hai bộ dữ liệu, đạt độ chính xác cao nhất trên bộ dữ liệu CTCH và gần bằng BiomedCLIP trên bộ BTXRD. Tuy nhiên, mô hình không tốt hơn mọi độ đo khi không đạt độ chính xác cân bằng cao nhất.

Kết quả trên khả năng xếp hạng xác suất cho thấy bức tranh khác. XBone-Net có diện tích trung bình dưới đường cong đặc trưng hoạt động thấp hơn bốn mô hình ngôn ngữ trực quan trên hai bộ dữ liệu. Đối với diện tích trung bình dưới đường cong độ chính xác-độ nhạy, mô hình cũng không dẫn đầu về giá trị quan sát. Như vậy, XBone-Net tạo được quyết định lớp cuối cùng cạnh tranh, nhưng chưa sắp thứ tự mức tin cậy giữa các mẫu tốt bằng nhiều mô hình được tinh chỉnh toàn bộ. Hai nhóm độ đo phản ánh hai khía cạnh khác nhau, nên kết quả quyết định lớp tốt không đồng nghĩa xác suất dự đoán có chất lượng xếp hạng tốt hơn.

Nhằm kiểm chứng liệu các chênh lệch quan sát được có ý nghĩa thống kê hay không, Bảng 4.11 và Bảng 4.12 lần lượt báo cáo kết quả phân tích

bootstrap ghép cặp chéo bệnh nhân và hạt giống với 10.000 lần lấy mẫu lại, cùng kiểm định hoán vị ghép cặp với 10.000 lần hoán vị. Các giá trị xác suất được hiệu chỉnh bằng phương pháp Holm trong từng độ đo.

Dữ liệu	Mô hình	Δ Acc (p_{Holm})	Δ BAcc (p_{Holm})	Δ Macro-F1 (p_{Holm})
BTXRD	ResNet-50	+0,2236 ($p < 0,001$)	+0,2935 ($p < 0,001$)	+0,2955 ($p < 0,001$)
	DenseNet-121	+0,1982 ($p < 0,001$)	+0,2421 ($p < 0,001$)	+0,2522 ($p < 0,001$)
	CLIP	+0,0267 ($p = 0,046$)	+0,0158 ($p = 1,000$)	+0,0453 ($p = 0,299$)
	MedCLIP	+0,0093 ($p = 0,715$)	-0,0012 ($p = 1,000$)	+0,0182 ($p = 0,581$)
	PubMedCLIP	+0,0418 ($p = 0,002$)	+0,0026 ($p = 1,000$)	+0,0517 ($p = 0,276$)
	BiomedCLIP	-0,0009 ($p = 0,946$)	+0,0053 ($p = 1,000$)	+0,0246 ($p = 0,581$)
CTCH	ResNet-50	+0,1201 ($p < 0,001$)	+0,1755 ($p < 0,001$)	+0,1573 ($p < 0,001$)
	DenseNet-121	+0,1365 ($p < 0,001$)	+0,1015 ($p < 0,001$)	+0,1367 ($p < 0,001$)
	CLIP	+0,0309 ($p = 0,150$)	-0,0282 ($p = 0,555$)	+0,0094 ($p = 0,711$)
	MedCLIP	+0,0583 ($p = 0,003$)	+0,0212 ($p = 0,586$)	+0,0566 ($p = 0,027$)
	PubMedCLIP	+0,0663 ($p = 0,002$)	+0,0346 ($p = 0,480$)	+0,0524 ($p = 0,042$)
	BiomedCLIP	+0,0214 ($p = 0,161$)	-0,0088 ($p = 0,672$)	+0,0187 ($p = 0,711$)

Bảng 4.11: Kiểm định thống kê ghép cặp về hiệu năng phân lớp giữa XBone-Net và các mô hình đối chứng qua 3 hạt giống ($N_{\text{perm}} = 10.000$). $\Delta = \text{XBone-Net} - \text{Mô hình đối chứng}$. Giá trị trong ngoặc đơn là mức ý nghĩa p_{Holm} sau hiệu chỉnh đa so sánh; **màu xanh lá** biểu thị XBone-Net vượt trội có ý nghĩa thống kê ($p_{\text{Holm}} < 0,05, \Delta > 0$); **màu đỏ** biểu thị đối chứng vượt trội có ý nghĩa ($p_{\text{Holm}} < 0,05, \Delta < 0$)

Kiểm định ghép cặp xác nhận XBone-Net tốt hơn có ý nghĩa so với ResNet-50 và DenseNet-121 về độ chính xác, độ chính xác cân bằng và điểm macro-F1 trên cả hai bộ dữ liệu. Mức tăng của điểm macro-F1 nằm trong khoảng từ 0,137 đến 0,157 trên bộ dữ liệu CTCH và từ 0,252 đến 0,296 trên bộ BTXRD. Mô hình cũng cải thiện có ý nghĩa khả năng xếp hạng chú trọng các lớp ít mẫu. Một cách giải thích phù hợp là XBone-Net khai thác đồng thời ảnh toàn cục, các vùng ảnh cục bộ và văn bản đi kèm, trong khi hai đối chứng này chỉ sử dụng ảnh. Nguồn thông tin bổ sung có thể giúp phân biệt những lớp có biểu hiện hình ảnh gần nhau hoặc ít mẫu. Tuy vậy, do các đối chứng còn khác nhau về kiến trúc và dữ liệu tiền huấn luyện, thực nghiệm này chỉ xác nhận lợi thế của cấu hình hoàn chỉnh, chưa cô lập được phần cải thiện do riêng văn bản hoặc từng nhánh ảnh tạo ra.

Dữ liệu	Mô hình	Δ Macro-AUROC (p_{Holm})	Δ Macro-AUPRC (p_{Holm})
BTXRD	ResNet-50	+0,0810 ($p = 0,004$)	+0,2526 ($p < 0,001$)
	DenseNet-121	+0,0328 ($p = 0,154$)	+0,2034 ($p < 0,001$)
	CLIP	-0,0927 ($p < 0,001$)	-0,0386 ($p = 0,510$)
	MedCLIP	-0,0553 ($p = 0,013$)	-0,0362 ($p = 0,510$)
	PubMedCLIP	-0,1002 ($p < 0,001$)	-0,0284 ($p = 0,510$)
	BiomedCLIP	-0,0819 ($p < 0,001$)	-0,0645 ($p = 0,053$)
CTCH	ResNet-50	-0,0115 ($p = 0,447$)	+0,1419 ($p < 0,001$)
	DenseNet-121	-0,0330 ($p = 0,068$)	+0,1137 ($p = 0,001$)
	CLIP	-0,0270 ($p = 0,030$)	-0,0099 ($p = 1,000$)
	MedCLIP	-0,0195 ($p = 0,148$)	+0,0063 ($p = 1,000$)
	PubMedCLIP	-0,0259 ($p = 0,047$)	+0,0016 ($p = 1,000$)
	BiomedCLIP	-0,0370 ($p < 0,001$)	-0,0265 ($p = 0,702$)

Bảng 4.12: Kiểm định thống kê ghép cặp về chất lượng xếp hạng xác suất dự đoán giữa XBone-Net và các mô hình đối chứng qua 3 hạt giống ($N_{\text{perm}} = 10.000$). $\Delta = \text{XBone-Net} - \text{Mô hình đối chứng}$. Giá trị trong ngoặc đơn là mức ý nghĩa p_{Holm} sau hiệu chỉnh đa so sánh; **màu xanh lá** biểu thị XBone-Net vượt trội có ý nghĩa thống kê ($p_{\text{Holm}} < 0,05, \Delta > 0$); **màu đỏ** biểu thị đối chứng vượt trội có ý nghĩa thống kê ($p_{\text{Holm}} < 0,05, \Delta < 0$); văn bản thường biểu thị khác biệt không có ý nghĩa thống kê ($p_{\text{Holm}} \geq 0,05$)

So với các mô hình ngôn ngữ trực quan tinh chỉnh toàn bộ, XBone-Net chỉ tốt hơn ở một số đối sánh. Trên bộ dữ liệu CTCH, mô hình cải thiện có ý nghĩa độ chính xác và điểm macro-F1 trước MedCLIP và PubMedCLIP, nhưng chưa đủ bằng chứng xác nhận khác biệt với CLIP và BiomedCLIP. Trên bộ BTXRD, mô hình cải thiện có ý nghĩa độ chính xác trước CLIP và PubMedCLIP, trong khi chênh lệch điểm macro-F1 với cả bốn mô hình ngôn ngữ trực quan chưa được xác nhận. Vì vậy, XBone-Net có chất lượng quyết định lớp cạnh tranh, nhưng không tốt hơn toàn bộ nhóm đối chứng ảnh-văn bản.

Kết quả trên phù hợp với vai trò của quy trình huấn luyện hai pha, cơ chế chú ý chéo hai chiều và đầu phân lớp tuyến tính. Hai pha huấn luyện giúp thích nghi biểu diễn ảnh và văn bản trước khi tối ưu trực tiếp biên quyết định phân lớp, trong khi cơ chế chú ý chéo cho phép trao đổi thông tin giữa hai phương thức. Sau đó, đầu phân lớp tuyến tính ánh xạ biểu diễn dung hợp thành điểm số lớp và được tối ưu cùng mô-đun dung hợp trong pha phân lớp. Việc chỉ cập nhật một phần nhỏ tham số của mạng nền có thể giúp duy trì tri thức tiền huấn luyện, nhưng cũng giới hạn mức độ điều chỉnh toàn bộ không gian xác suất. Đây là một cách giải thích

hợp lý cho việc XBone-Net đạt kết quả quyết định lớp cạnh tranh nhưng khả năng xếp hạng chưa dẫn đầu. Tuy nhiên, diễn giải này dựa trên thiết kế mô hình và chưa chứng minh được quan hệ nhân quả. Vì vậy, cần thực nghiệm tách riêng quy trình huấn luyện, cơ chế dung hợp và đầu phân lớp để kiểm chứng.

Nhận định chính của nhóm kết quả phân lớp là XBone-Net tận dụng đa phương thức để cải thiện rõ rệt so với các mô hình chỉ dùng ảnh và vẫn cạnh tranh với các mô hình ngôn ngữ trực quan dù cập nhật ít tham số hơn. Lợi ích tập trung ở quyết định lớp cuối cùng, không mở rộng đồng đều sang khả năng xếp hạng xác suất. Do đó, đóng góp nổi bật của mô hình là đạt sự cân bằng giữa chất lượng phân lớp và mức độ tham số cần cập nhật, thay vì vượt trội tuyệt đối trên mọi độ đo.

Hiệu quả tham số và chi phí suy luận

Số lượng tham số và chi phí tính toán của XBone-Net so với BiomedCLIP tinh chỉnh toàn bộ được trình bày tại Bảng 4.13 và Bảng 4.14.

Dữ liệu	Mô hình	Tổng tham số	Tham số huấn luyện	Tỷ lệ (%)
BTXRD	BiomedCLIP (FFT)	196,433,675	196,433,675	100.00%
	XBone-Net	204,342,539	8,439,818	4.13%
CTCH	BiomedCLIP (FFT)	196,439,831	196,439,831	100.00%
	XBone-Net	204,348,695	8,445,974	4.13%

Bảng 4.13: Số lượng tham số khi sử dụng toàn bộ dữ liệu

Dữ liệu	Mô hình	GFLOPs	Thông lượng	Độ trễ	Bộ nhớ GPU
BTXRD	BiomedCLIP (FFT)	81.032	64.7	15.48	770.7
	XBone-Net	82.318	68.2	15.26	782.4
CTCH	BiomedCLIP (FFT)	81.032	75.6	13.77	770.7
	XBone-Net	82.318	64.1	16.17	782.5

Bảng 4.14: Chi phí tính toán và tốc độ suy luận khi sử dụng toàn bộ dữ liệu

Trong quá trình huấn luyện, XBone-Net có tổng số 204.342.539 tham số trên bộ dữ liệu ảnh X-quang u xương và 204.348.695 tham số trên bộ dữ liệu Chấn thương Chỉnh hình. Trong đó, số tham số cần cập nhật lần lượt là 8.439.818 và 8.445.974, đều tương ứng khoảng 4,13% tổng số tham

số và giảm khoảng 95,70% so với BiomedCLIP tinh chỉnh toàn bộ. Các tham số trước hợp nhất này có tính cả 5.013.504 tham số của bộ điều hợp hạng thấp. Sau huấn luyện, các trọng số thích nghi được hợp nhất vào mạng nền và các ma trận bộ điều hợp được loại khỏi đồ thị suy luận, nên tổng số tham số giảm còn 199.329.035 trên bộ dữ liệu ảnh X-quang u xương và 199.335.191 trên bộ dữ liệu Chấn thương Chỉnh hình, thấp hơn khoảng 2,45% so với đồ thị huấn luyện tương ứng. Vì vậy, giá trị khoảng 204,34 triệu phản ánh cấu trúc dùng trong huấn luyện chứ không phải kích thước mô hình sau hợp nhất. Tuy nhiên, do vẫn giữ mô-đun dung hợp và đầu phân lớp, tổng số tham số sau hợp nhất của XBone-Net vẫn cao hơn BiomedCLIP tinh chỉnh toàn bộ khoảng 1,47%.

Về tốc độ suy luận, XBone-Net không tốt hơn BiomedCLIP tinh chỉnh toàn bộ: mô hình cần khoảng 82,318 tỷ phép toán dấu phẩy động cho mỗi mẫu, cao hơn khoảng 1,6%, và bộ nhớ đồ họa cực đại cũng cao hơn khoảng 11,8 MiB. Nhận định rút ra là tiết kiệm tham số huấn luyện không đồng nghĩa tiết kiệm chi phí suy luận, bởi vì ưu thế của XBone-Net nằm ở khả năng thích nghi với ít tham số cần cập nhật chứ không phải ở tốc độ, bộ nhớ hoặc khối lượng tính toán khi triển khai.

4.2.4 Kết luận

Thực nghiệm này cho thấy XBone-Net tốt hơn rõ rệt các mô hình chỉ dùng ảnh và đạt hiệu năng quyết định lớp cạnh tranh với các mô hình ngôn ngữ trực quan, nhưng chưa vượt trội toàn diện về độ chính xác cân bằng và khả năng xếp hạng xác suất. Thiết kế đa phương thức, quy trình huấn luyện hai pha và đầu phân lớp tuyến tính được tối ưu trực tiếp trên biểu diễn dung hợp là cách giải thích hợp lý cho chất lượng quyết định lớp. Đồng thời, việc chỉ cập nhật một phần tham số giúp duy trì tri thức tiền huấn luyện, còn mô-đun dung hợp tạo ra đánh đổi về chi phí suy luận. Nhận định nổi bật là XBone-Net đạt khả năng thích nghi tham số hiệu quả mà vẫn giữ chất lượng phân lớp cạnh tranh, nhưng không tối ưu đồng thời mọi độ đo và tài nguyên triển khai.

4.3 Khảo sát ảnh hưởng của các thành phần

4.3.1 Mục đích

Thực nghiệm này kiểm tra xem quy trình huấn luyện hai pha và cơ chế dung hợp bằng chú ý chéo hai chiều ảnh hưởng như thế nào đến quyết định lớp và chất lượng xếp hạng của XBone-Net. Mục tiêu là xác định ảnh hưởng quan sát được của từng lựa chọn kiến trúc trong cùng điều kiện đánh giá.

4.3.2 Nội dung

Thực nghiệm được thực hiện trên bộ dữ liệu CTCH với hai biến thể của XBone-Net, Chỉ pha 2 và Nối đặc trưng. Biến thể Chỉ pha 2 bỏ lần huấn luyện pha 1 và khởi tạo trực tiếp cho pha phân lớp. Biến thể Nối đặc trưng giữ nguyên pha 1 nhưng thay thiết lập dung hợp ở pha 2 bằng phép nối. Ngoài yếu tố được thay đổi, các cấu hình dùng chung được giữ nguyên.

4.3.3 Kết quả

Bảng 4.15 so sánh XBone-Net với hai biến thể qua ba hạt giống trên bộ dữ liệu CTCH. Xét các giá trị quan sát, XBone-Net đạt độ chính xác 0,6183 và macro-F1 0,5727, cao hơn lần lượt 0,6004 và 0,5497 của biến thể Chỉ pha 2, đồng thời cao hơn 0,5825 và 0,5477 của biến thể Nối đặc trưng. XBone-Net cũng đạt diện tích trung bình dưới đường cong độ chính xác-độ nhạy cao nhất ở mức 0,5904. Tuy nhiên, biến thể Nối đặc trưng đạt độ chính xác cân bằng 0,5983 và diện tích trung bình dưới đường cong đặc trưng hoạt động 0,9251, cao hơn các giá trị tương ứng 0,5935 và 0,9020 của XBone-Net. Như vậy, cấu hình đầy đủ có lợi thế quan sát được về quyết định lớp, nhưng không tốt hơn hai biến thể trên mọi độ đo.

Thành phần hoặc độ đo	XBone-Net	Chỉ pha 2	Nổi đặc trưng
Huấn luyện pha 1	✓		✓
Chú ý chéo hai chiều	✓	✓	
Accuracy ↑	0.6183 ± 0.0203	0.6004 ± 0.0085	0.5825 ± 0.0038
Balanced Accuracy ↑	0.5935 ± 0.0134	0.5552 ± 0.0341	0.5983 ± 0.0268
Macro-F1 ↑	0.5727 ± 0.0193	0.5497 ± 0.0184	0.5477 ± 0.0162
Macro-AUROC ↑	0.9020 ± 0.0095	0.9068 ± 0.0249	0.9251 ± 0.0195
Macro-AUPRC ↑	0.5904 ± 0.0224	0.5787 ± 0.0148	0.5811 ± 0.0179

Bảng 4.15: Nghiên cứu loại bỏ từng thành phần của XBone-Net trên CTCH

Để đánh giá liệu các chênh lệch này có ổn định trên cùng các mẫu kiểm thử hay không, Bảng 4.16 trình bày kiểm định ghép cặp giữa từng biến thể và XBone-Net. Giá trị xác suất được tính bằng phép kiểm định hoán vị ghép cặp, sau đó được hiệu chỉnh theo phương pháp Holm trong từng độ đo cho hai phép so sánh. Chênh lệch được định nghĩa bằng kết quả của biến thể trừ kết quả của XBone-Net.

Biến thể	Độ đo	Δ	p_{Holm}
Chỉ pha 2	Accuracy ↑	−0,0179	0,262
	Balanced Accuracy ↑	−0,0383	0,119
	Macro-F1 ↑	−0,0230	0,292
	Macro-AUROC ↑	+0,0049	0,616
	Macro-AUPRC ↑	−0,0117	1,000
Nổi đặc trưng	Accuracy ↑	−0,0359	0,052
	Balanced Accuracy ↑	+0,0048	0,783
	Macro-F1 ↑	−0,0250	0,292
	Macro-AUROC ↑	+0,0231	0,021
	Macro-AUPRC ↑	−0,0093	1,000

Bảng 4.16: So sánh thống kê ghép cặp giữa XBone-Net và các biến thể loại bỏ thành phần

Đối với biến thể Chỉ pha 2, kiểm định không xác nhận khác biệt có ý nghĩa thống kê ở cả năm độ đo vì các giá trị xác suất sau hiệu chỉnh Holm đều không nhỏ hơn 0,119. Vì vậy, dù XBone-Net có giá trị trung bình cao hơn ở bốn trong năm độ đo, kết quả hiện tại chưa đủ bằng chứng để khẳng định pha thích nghi tương phản tạo ra cải thiện ổn định trên tập kiểm thử cố định này.

Đối với biến thể Nối đặc trưng, khác biệt duy nhất được xác nhận là diện tích trung bình dưới đường cong đặc trưng hoạt động. Biến thể này cao hơn XBone-Net 0,0231 và giá trị xác suất sau hiệu chỉnh Holm bằng 0,021. Độ chính xác quan sát được của XBone-Net cao hơn 0,0359, nhưng giá trị xác suất sau hiệu chỉnh Holm bằng 0,052 nên chưa đạt ngưỡng ý nghĩa 0,05. Các độ đo còn lại cũng chưa cho thấy khác biệt có ý nghĩa thống kê.

Một cách giải thích phù hợp với kết quả là phép nối giữ hai biểu diễn ảnh và văn bản tách biệt hơn trước đầu phân lớp, nhờ đó có thể bảo toàn thứ tự điểm số giữa các lớp và tạo lợi thế về khả năng xếp hạng. Trong khi đó, chú ý chéo hai chiều biến đổi hai nguồn thông tin theo ngữ cảnh của nhau và cấu hình đầy đủ đạt giá trị quan sát cao hơn về độ chính xác cùng macro-F1. Tuy nhiên, kiểm định chỉ xác nhận lợi thế xếp hạng của phép nối, nên các diễn giải về cơ chế chỉ là giả thuyết dựa trên thiết kế kiến trúc chứ chưa phải quan hệ nhân quả đã được chứng minh.

4.3.4 Kết luận

Thực nghiệm này cho thấy XBone-Net đạt độ chính xác và macro-F1 quan sát được cao hơn hai biến thể, nhưng kiểm định ghép cặp chưa xác nhận lợi thế này sau hiệu chỉnh đa so sánh. Việc loại bỏ pha thích nghi tương phản không tạo ra khác biệt có ý nghĩa thống kê ở cả năm độ đo, còn phép nối đặc trưng cải thiện có ý nghĩa thống kê khả năng xếp hạng theo diện tích trung bình dưới đường cong đặc trưng hoạt động. Nhận định nổi bật là quy trình huấn luyện hai pha và chú ý chéo hai chiều không tạo lợi ích đồng đều trên mọi mục tiêu, đồng thời chưa có đủ bằng chứng để xem từng thành phần là nguyên nhân trực tiếp làm tăng hiệu năng phân lớp.

4.4 Khảo sát khả năng cảnh báo dữ liệu ngoài phân phối

4.4.1 Mục đích

Thực nghiệm này đánh giá khả năng phát hiện mẫu ngoài phân phối hậu xử lý được xây dựng từ không gian biểu diễn của XBone-Net có thể phân biệt dữ liệu trong phân phối với các dạng dữ liệu ngoài phân phối đã xác định, đồng thời khảo sát sự khác biệt giữa dịch chuyển gần miền và dịch chuyển sang bộ dữ liệu khác.

4.4.2 Nội dung

Ba cấu hình được đánh giá gồm XBone-Net, Chỉ pha 2 và Nói đặc trưng. Dữ liệu huấn luyện CTCH được dùng để khớp bộ chấm điểm hậu xử lý, còn dữ liệu xác thực được dùng để chuẩn hóa điểm và chọn ngưỡng tại phân vị 95, tương ứng mục tiêu cảnh báo nhằm 5% mẫu trong phân phối. Ngưỡng được xác định riêng cho từng cấu hình và từng hạt giống mà không sử dụng mẫu ngoài phân phối. Tập kiểm thử gồm 18 mẫu ngoài không gian nhãn từ bộ CTCH và 750 mẫu từ bộ BTXRD. Cùng một ngưỡng đã hiệu chỉnh được giữ nguyên cho hai kịch bản. Ba độ đo lần lượt phản ánh khả năng phân tách tổng thể, chất lượng xếp hạng khi coi mẫu ngoài phân phối là lớp dương và tỷ lệ chấp nhận nhằm mẫu ngoài phân phối tại mức giữ lại 95% mẫu trong phân phối.

4.4.3 Kết quả

Bảng 4.17 so sánh XBone-Net với hai biến thể khi cùng sử dụng điểm tổng hợp đa phương thức. Trong kịch bản gần miền, XBone-Net không tốt hơn hoàn toàn hai biến thể. Biến thể Chỉ pha 2 đạt khả năng phân tách và xếp hạng tổng thể cao nhất, còn XBone-Net đạt tỷ lệ lỗi thấp nhất tại điểm vận hành giữ lại 95% mẫu trong phân phối. Tuy vậy, giá trị này vẫn xấp xỉ 63%, chỉ thấp hơn hai biến thể còn lại từ khoảng hai đến bốn điểm

phần trăm. Như vậy, lợi thế của XBone-Net chỉ xuất hiện ở một điểm vận hành cụ thể và chưa khắc phục được tỷ lệ lỗi cao đối với các mẫu ngoài phân phối gần miền.

Kịch bản	Cấu hình	AUROC-ODD $\uparrow$	AUPR-Out $\uparrow$	FPR@95%TPR $\downarrow$
OOD CTCH	XBone-Net	0.7598 ± 0.0219	0.1473 ± 0.0094	0.6296 ± 0.0642
	Chỉ pha 2	0.7735 ± 0.0349	0.2197 ± 0.0112	0.6667 ± 0.1111
	Nối đặc trưng	0.7186 ± 0.0199	0.1055 ± 0.0143	0.6481 ± 0.0321
BTXRD	XBone-Net	0.9321 ± 0.0174	0.9052 ± 0.0171	0.3604 ± 0.1129
	Chỉ pha 2	0.9350 ± 0.0114	0.9081 ± 0.0176	0.3924 ± 0.1167
	Nối đặc trưng	0.9263 ± 0.0059	0.8975 ± 0.0027	0.4627 ± 0.0650

Bảng 4.17: Đánh giá cảnh báo ngoài phân phối hậu xử lý của XBone-Net và hai biến thể

Khi chuyển sang bộ BTXRD, XBone-Net đạt khả năng phân tách tổng thể 0,9321 và tỷ lệ lỗi khoảng 36% tại cùng điểm vận hành. Biến thể Chỉ pha 2 vẫn nhỉnh hơn về hai độ đo xếp hạng, trong khi XBone-Net tiếp tục có tỷ lệ lỗi thấp nhất. Cả ba cấu hình đều tốt hơn rõ rệt so với kịch bản gần miền, cho thấy việc nhận diện dữ liệu từ một nguồn khác biệt lớn dễ hơn nhận diện các bệnh lý nằm gần không gian dữ liệu huấn luyện.

Nguyên nhân hợp lý nằm ở khoảng cách biểu diễn. Các mẫu từ bộ BTXRD thay đổi đồng thời về nguồn ảnh, văn bản và không gian nhân nên nằm xa dữ liệu huấn luyện và dễ được điểm hậu xử lý phát hiện. Ngược lại, các mẫu gần miền vẫn chia sẻ nhiều đặc trưng hình ảnh và ngữ nghĩa với dữ liệu trong phân phối, làm khoảng cách giữa hai nhóm bị thu hẹp. Huấn luyện hai pha có thể làm biểu diễn trong cùng miền gắn kết hơn, giúp XBone-Net giảm lỗi tại ngưỡng đã chọn nhưng không cải thiện toàn bộ thứ tự xếp hạng so với biến thể Chỉ pha 2.

4.4.4 Kết luận

Thực nghiệm này cho thấy XBone-Net cạnh tranh với hai biến thể và đạt tỷ lệ lỗi thấp nhất tại điểm vận hành đã chọn, nhưng không tốt hơn về khả năng phân tách và xếp hạng tổng thể. Nhận định quan trọng là hiệu quả cảnh báo phụ thuộc nhiều vào loại dịch chuyển hơn là chênh lệch kiến trúc: thay đổi lớn giữa hai nguồn dữ liệu dễ nhận diện, còn bệnh lý gần miền vẫn là trường hợp khó.

4.5 Khảo sát mức phụ thuộc của dự đoán vào ảnh và văn bản

4.5.1 Mục đích

Thực nghiệm này đánh giá mức phụ thuộc của dự đoán vào ảnh và văn bản dựa vào tích phân gradient kết hợp với can thiệp đầu vào so với các biến thể kiến trúc.

4.5.2 Nội dung

Phân tích sử dụng hạt giống 42 của XBone-Net, Chỉ pha 2 và Nối đặc trưng. Từ tập kiểm thử của bộ dữ liệu CTCH, 44 mẫu được chọn với tối đa hai mẫu cho mỗi lớp và cùng hạt giống lấy mẫu 1907 cho mọi cấu hình. Lớp được mô hình dự đoán trên đầu vào được cố định làm lớp đích. Tích phân gradient được xấp xỉ bằng 24 điểm nội suy từ mốc tham chiếu đến đầu vào. Mốc tham chiếu của ảnh là một nền đen, còn mốc tham chiếu của văn bản là văn bản trống.

Độ trung thực được đánh giá bằng cách loại bỏ hoặc khôi phục dần các vùng ảnh kích thước 16×16 và các đơn vị nội dung theo mức đóng góp giảm dần. Phép can thiệp nguồn thay toàn bộ ảnh hoặc toàn bộ đơn vị nội dung bằng mốc tham chiếu tương ứng, sau đó ghi nhận mức giảm xác suất của lớp đích so với đầu vào đầy đủ. Danh sách mẫu, mốc tham chiếu và mức can thiệp được áp dụng cho cả ba cấu hình, trong khi lớp đích được xác định riêng từ dự đoán của từng cấu hình.

4.5.3 Kết quả

Bảng 4.18 tổng hợp độ trung thực của tích phân gradient và mức giảm xác suất khi che từng nguồn thông tin trên 44 mẫu ở hạt giống 42. Do chỉ có một hạt giống và không có khoảng tin cậy ghép cặp giữa các cấu hình, mọi chênh lệch chỉ mang tính mô tả.

Nhóm đánh giá	Chỉ số	XBone-Net	Chỉ pha 2	Nối đặc trưng
Độ trung thực văn bản lâm sàng	AUC Khôi phục theo IG $\uparrow$	0.4232	0.3895	0.3231
	AUC Loại bỏ theo IG $\downarrow$	0.2704	0.2292	0.2026
Độ trung thực ảnh X-quang	AUC Khôi phục theo IG $\uparrow$	0.3755	0.3756	0.3172
	AUC Loại bỏ theo IG $\downarrow$	0.2869	0.2723	0.2329
Can thiệp nguồn thông tin	Mức giảm xác suất khi che ảnh (Δp_{img}) $\uparrow$	0.3654	0.3100	0.2737
	Mức giảm xác suất khi che văn bản (Δp_{txt}) $\uparrow$	0.2874	0.2581	0.2571

Bảng 4.18: Đánh giá tích phân gradient và can thiệp nguồn của XBone-Net và hai biến thể

Đối với văn bản lâm sàng, XBone-Net đạt giá trị khôi phục cao nhất với 0,4232, tốt hơn biến thể Chỉ pha 2 và biến thể Nối đặc trưng. Tuy nhiên, trong phép loại bỏ, biến thể Nối đặc trưng lại đạt kết quả tốt nhất. Đối với ảnh X-quang, XBone-Net gần như bằng biến thể Chỉ pha 2 trong phép khôi phục và tiếp tục kém biến thể Nối đặc trưng trong phép loại bỏ. Vì hai hướng đánh giá không cùng chọn một cấu hình, XBone-Net chưa thể được xem là tốt hơn hai biến thể về độ trung thực của đóng góp.

Kết quả rõ hơn xuất hiện khi che toàn bộ từng nguồn thông tin. Với XBone-Net, che ảnh làm xác suất lớp đích giảm 0,3654 và che văn bản làm giảm 0,2874, trong đó cả hai mức giảm đều lớn hơn hai biến thể. Điều này cho thấy dự đoán của cấu hình đầy đủ phụ thuộc mạnh hơn vào cả ảnh và bệnh sử lâm sàng. Một cách giải thích phù hợp là huấn luyện hai pha kết hợp với chú ý chéo hai chiều tạo liên kết chặt hơn giữa hai nguồn biểu diễn, nên việc loại bỏ hoàn toàn một nguồn gây ảnh hưởng lớn hơn đến xác suất dự đoán.

Sự khác nhau giữa phép khôi phục, phép loại bỏ và phép che toàn bộ có thể xuất phát từ việc bằng chứng được phân bố trên nhiều vùng ảnh, nhiều đơn vị văn bản và các tương tác giữa hai phương thức. Khi đó, thứ tự đóng góp cục bộ không nhất thiết phản ánh giống mức phụ thuộc khi loại bỏ toàn bộ nguồn thông tin, đồng thời kết quả còn phụ thuộc vào mốc tham chiếu đã chọn. Nhận định rút ra là XBone-Net sử dụng cả ảnh và văn bản mạnh hơn theo phép che nguồn, nhưng mức phụ thuộc lớn hơn không đồng nghĩa đóng góp trung thực hơn, không chứng minh đóng góp nhân quả và không xác nhận tính đúng lâm sàng của từng nguồn.

Nhãn đúng: Gãy xương ngón tay | Dự đoán: Gãy xương ngón tay (50.0%)



Hình 4.2: Tích phân gradient trên ảnh X-quang và bệnh sử lâm sàng của mẫu 3563. Màu nóng trên ảnh biểu thị độ lớn đóng góp. Trong văn bản, màu cam và màu xanh lần lượt biểu thị tác động ủng hộ và phản đối lớp dự đoán.

Hình 4.2 minh họa cụ thể kết quả của XBone-Net trên mẫu 3563. Mô hình dự đoán đúng nhãn “Gãy xương ngón tay” với xác suất 50,0%. Trên ảnh X-quang, mức đóng góp lớn tập trung chủ yếu quanh bàn tay, các ngón tay và vùng cổ tay. Tuy nhiên, bản đồ vẫn ghi nhận một số vùng đóng góp nằm ngoài cấu trúc xương, vì vậy kết quả chỉ cho thấy những vị trí đầu vào làm thay đổi dự đoán và không được diễn giải như bằng chứng định vị chính xác tổn thương.

Đối với bệnh sử lâm sàng, các từ như *wounded*, *finger*, *cutter* và *accident* tạo tác động ủng hộ nổi bật, phù hợp với mô tả ngón tay bị thương do dao rọc giấy. Ngược lại, một số từ và mảnh số không đặc hiệu cũng nhận mức đóng góp đáng kể, cho thấy mô hình chưa chỉ dựa vào các khái niệm lâm

sàng trực tiếp. Khi thay toàn bộ ảnh bằng nền đen, xác suất lớp đích giảm 0,4875, còn khi thay bệnh sử bằng văn bản trống, xác suất giảm 0,3782. Trường hợp này minh họa rằng cả ảnh và văn bản đều tham gia đáng kể vào dự đoán đúng, trong đó ảnh có ảnh hưởng lớn hơn theo phép che nguồn đã sử dụng.

4.5.4 Kết luận

Thực nghiệm thứ tư cho thấy XBone-Net tốt hơn hai biến thể về mức suy giảm xác suất khi che toàn bộ ảnh hoặc văn bản, nhưng không tốt hơn nhất quán trong các phép khôi phục và loại bỏ theo đóng góp. Cơ chế huấn luyện hai pha và chú ý chéo hai chiều có thể giải thích mức phụ thuộc đa phương thức mạnh hơn, song chưa đủ bằng chứng để khẳng định đây là nguyên nhân trực tiếp. Nhận định chính là XBone-Net thực sự sử dụng cả hai nguồn thông tin, nhưng độ trung thực của phương pháp giải thích vẫn phụ thuộc vào tiêu chí và mốc tham chiếu. Do phân tích chỉ sử dụng một hạt giống trên 44 mẫu, kết quả chưa chứng minh đóng góp nhân quả, tính đúng lâm sàng hoặc ưu thế giải thích ổn định của cấu hình đầy đủ.

Chương 5

Kết luận và hướng phát triển

5.1 Tổng kết

Khóa luận đã xây dựng và đánh giá XBone-Net cho bài toán phân lớp ảnh X-quang xương kết hợp bệnh sử lâm sàng. Mô hình kế thừa bộ mã hóa ảnh và bộ mã hóa văn bản của BiomedCLIP, giữ cố định phần lớn tham số nền và thích nghi bằng các bộ điều hợp hạng thấp LoRA. Quy trình huấn luyện gồm pha thích nghi biểu diễn ảnh–văn bản và pha phân lớp có giám sát. Đặc trưng toàn cục cùng các đơn vị cục bộ của hai phương thức được trao đổi ngữ cảnh bằng chú ý chéo hai chiều, sau đó biểu diễn dung hợp được đưa vào đầu phân lớp tuyến tính. Trên các biểu diễn đã học, khóa luận còn khảo sát bộ cảnh báo dữ liệu ngoài phân phối hậu xử lý và sử dụng tích phân gradient kết hợp can thiệp đầu vào để phân tích mức phụ thuộc của dự đoán vào ảnh và văn bản.

Thực nghiệm được tổ chức thành bốn nhóm tương ứng với bốn câu hỏi nghiên cứu. Nhóm thứ nhất so sánh hiệu năng phân lớp và chi phí với các mô hình chỉ dùng ảnh cùng các mô hình ngôn ngữ trực quan được tinh chỉnh toàn bộ. Nhóm thứ hai khảo sát ảnh hưởng của pha thích nghi biểu diễn và cơ chế chú ý chéo hai chiều. Nhóm thứ ba đánh giá cảnh báo dữ liệu ngoài phân phối trong kịch bản gần miền trên CTCH và kịch bản dịch chuyển sang BTRD. Nhóm cuối cùng đánh giá độ trung thực của tích

phân gradient và mức giảm xác suất khi che từng nguồn thông tin. Các mô hình có huấn luyện được chạy với ba hạt giống trên cùng tập chia, ngoại trừ phân tích tích phân gradient sử dụng một hạt giống trên 44 mẫu kiểm thử CTCH.

Kết quả tổng thể cho thấy XBone-Net đạt chất lượng quyết định lớp cạnh tranh và giảm mạnh số tham số cần cập nhật, nhưng không dẫn đầu nhất quán về khả năng xếp hạng xác suất hoặc chi phí suy luận. Quy trình huấn luyện hai pha và chú ý chéo hai chiều tạo ra một điểm đánh đổi giữa các mục tiêu thay vì cải thiện đồng thời mọi độ đo. Bộ cảnh báo hậu xử lý nhận diện dịch chuyển lớn tốt hơn dịch chuyển gần miền, trong khi phân tích can thiệp cho thấy mô hình sử dụng cả ảnh và bệnh sử nhưng chưa chứng minh được quan hệ nhân quả hoặc tính đúng lâm sàng. Vì vậy, đóng góp chính của khóa luận là một phương pháp thích nghi đa phương thức hiệu quả về tham số cùng quy trình đánh giá có cấu trúc cho các đánh đổi giữa hiệu năng phân lớp, tài nguyên triển khai, cảnh báo dữ liệu bất thường và khả năng truy vết nguồn thông tin.

5.2 Trả lời các câu hỏi nghiên cứu

Đối với câu hỏi nghiên cứu thứ nhất, trên bộ BTXRD, XBone-Net đạt độ chính xác 0,8302 và điểm macro-F1 0,6240, trong khi các giá trị tương ứng trên bộ CTCH là 0,6183 và 0,5727. Kiểm định ghép cặp xác nhận mô hình tốt hơn có ý nghĩa thống kê so với ResNet-50 và DenseNet-121 về độ chính xác, độ chính xác cân bằng và điểm macro-F1 trên cả hai bộ dữ liệu. Kết quả này cho thấy cấu hình đa phương thức tạo lợi thế rõ rệt so với hai đối chứng chỉ dùng ảnh. Tuy nhiên, vì các mô hình còn khác nhau về kiến trúc và nguồn tiền huấn luyện, chênh lệch này không thể được quy hoàn toàn cho riêng bệnh sử hoặc một nhánh biểu diễn cụ thể. So với các mô hình ngôn ngữ trực quan được tinh chỉnh toàn bộ, lợi thế của XBone-Net chỉ xuất hiện ở một số phép so sánh. Trên CTCH, mô hình cải thiện có ý nghĩa độ chính xác và điểm macro-F1 trước MedCLIP và PubMedCLIP, nhưng chưa đủ bằng chứng xác nhận khác biệt với CLIP và BiomedCLIP. Trên BTXRD, XBone-Net cải thiện có ý nghĩa độ chính xác trước CLIP và

PubMedCLIP, trong khi chênh lệch điểm macro-F1 với cả bốn đối chứng ảnh-văn bản chưa được xác nhận. Đồng thời, diện tích trung bình dưới đường cong đặc trưng hoạt động của XBone-Net thấp hơn các mô hình ngôn ngữ trực quan trên cả hai bộ dữ liệu. Như vậy, ưu thế quan sát được tập trung vào quyết định lớp cuối cùng và không mở rộng đồng đều sang chất lượng xếp hạng xác suất. XBone-Net chỉ cập nhật khoảng 8,44 triệu tham số, tương ứng 4,13% tổng số tham số trong đồ thị huấn luyện và giảm khoảng 95,70% số tham số cần cập nhật so với BiomedCLIP tinh chỉnh toàn bộ. Tổng số khoảng 204,34 triệu tham số trong quá trình huấn luyện có tính cả 5,01 triệu tham số LoRA. Sau khi hợp nhất các trọng số thích nghi và loại các ma trận LoRA khỏi đồ thị suy luận, mô hình còn khoảng 199,33 triệu tham số. Giá trị này vẫn cao hơn BiomedCLIP tinh chỉnh toàn bộ khoảng 1,47% do XBone-Net giữ thêm mô-đun dung hợp và đầu phân lớp. Mô hình cũng cần 82,318 tỷ phép toán dấu phẩy động cho mỗi mẫu, cao hơn khoảng 1,6%, đồng thời sử dụng thêm khoảng 11,8 MiB bộ nhớ đồ họa. Tốc độ suy luận không cải thiện nhất quán giữa hai bộ dữ liệu. Do đó, kết luận cho câu hỏi thứ nhất là XBone-Net đạt khả năng thích nghi hiệu quả về số tham số cập nhật và giữ chất lượng quyết định lớp cạnh tranh, nhưng mô hình sau hợp nhất không nhỏ hơn BiomedCLIP tinh chỉnh toàn bộ và cũng không giảm chi phí suy luận.

Đối với câu hỏi nghiên cứu thứ hai, trên CTCH, XBone-Net đạt độ chính xác 0,6183 và điểm macro-F1 0,5727, cao hơn các giá trị quan sát của biến thể Chỉ pha 2 và biến thể Nối đặc trưng. Tuy nhiên, kiểm định ghép cặp sau hiệu chỉnh Holm không xác nhận khác biệt có ý nghĩa giữa XBone-Net và biến thể Chỉ pha 2 ở cả năm độ đo. Vì vậy, kết quả hiện tại chưa đủ bằng chứng để khẳng định pha thích nghi biểu diễn trước phân lớp tạo ra cải thiện ổn định trên tập kiểm thử cố định. Đối với cơ chế dung hợp, biến thể Nối đặc trưng đạt diện tích trung bình dưới đường cong đặc trưng hoạt động cao hơn XBone-Net 0,0231 với giá trị xác suất sau hiệu chỉnh Holm bằng 0,021. XBone-Net có độ chính xác quan sát cao hơn 0,0359, nhưng giá trị xác suất sau hiệu chỉnh bằng 0,052 nên chưa đạt ngưỡng ý nghĩa 0,05. Các độ đo còn lại cũng không cho thấy khác biệt có ý nghĩa. Kết luận cho câu hỏi thứ hai là huấn luyện hai pha và chú ý chéo hai chiều không tạo lợi ích đồng đều trên mọi mục tiêu. Cấu hình đầy đủ

thuận lợi hơn về một số độ đo quyết định lớp, trong khi phép nổi đặc trưng có lợi thế đã được xác nhận về khả năng xếp hạng. Các kết quả này mô tả sự đánh đổi giữa hai thiết kế và chưa chứng minh từng thành phần là nguyên nhân trực tiếp làm tăng hiệu năng.

Đối với câu hỏi nghiên cứu thứ ba, trong kịch bản gần miền gồm 18 mẫu ngoài không gian nhãn của CTCH, XBone-Net đạt khả năng phân tách tổng thể 0,7598, chất lượng xếp hạng 0,1473 và tỷ lệ chấp nhận nhầm mẫu ngoài phân phối 0,6296 tại mức giữ lại 95% mẫu trong phân phối. Biến thể Chỉ pha 2 đạt hai độ đo phân tách và xếp hạng cao hơn, còn XBone-Net có tỷ lệ chấp nhận nhầm thấp nhất tại điểm vận hành đã chọn. Tuy vậy, khoảng 63% mẫu ngoài phân phối gần miền vẫn bị chấp nhận nhầm, nên lợi thế tại điểm vận hành này chưa đủ để hình thành cơ chế từ chối tự động. Khi chuyển sang bộ BTXRD, XBone-Net đạt khả năng phân tách 0,9321, chất lượng xếp hạng 0,9052 và tỷ lệ chấp nhận nhầm khoảng 0,3604. Biến thể Chỉ pha 2 tiếp tục nhỉnh hơn ở hai độ đo xếp hạng, trong khi XBone-Net giữ tỷ lệ chấp nhận nhầm thấp nhất. Sự cải thiện rõ rệt so với kịch bản gần miền cho thấy hiệu quả cảnh báo phụ thuộc chủ yếu vào dạng dịch chuyển. Những thay đổi đồng thời về nguồn ảnh, văn bản và không gian nhãn dễ nhận diện hơn các bệnh lý còn gần miền huấn luyện. Vì vậy, kết luận cho câu hỏi thứ ba là biểu diễn của XBone-Net chứa tín hiệu hữu ích để cảnh báo dữ liệu ngoài phân phối, nhưng bộ cảnh báo hiện tại chỉ phù hợp làm tín hiệu hỗ trợ và chưa chứng minh khả năng chống chịu ổn định trước dữ liệu bất thường.

Đối với câu hỏi nghiên cứu thứ tư, phép che toàn bộ nguồn thông tin trên 44 mẫu CTCH tại hạt giống 42 cho thấy xác suất lớp đích của XBone-Net giảm trung bình 0,3654 khi thay ảnh bằng nền đen và giảm 0,2874 khi thay bệnh sử bằng văn bản trống. Cả hai mức giảm đều lớn hơn hai biến thể, cho thấy dự đoán của cấu hình đầy đủ phụ thuộc đáng kể vào ảnh và văn bản trong phép can thiệp đã chọn. Kết quả độ trung thực không chọn ra một cấu hình tốt nhất nhất quán. XBone-Net đạt giá trị khôi phục văn bản cao nhất ở mức 0,4232, nhưng biến thể Nổi đặc trưng tốt hơn trong phép loại bỏ văn bản. Đối với ảnh, XBone-Net gần như bằng biến thể Chỉ pha 2 trong phép khôi phục và kém biến thể Nổi đặc trưng trong phép loại bỏ. Hình minh họa mẫu 3563 cho thấy mức đóng góp trên ảnh tập

trung nhiều quanh bàn tay, ngón tay và cổ tay, còn các từ liên quan đến vết thương và tai nạn tạo tác động ủng hộ nổi bật. Tuy nhiên, bản đồ ảnh vẫn có đóng góp ngoài cấu trúc xương và một số mảnh văn bản không đặc hiệu cũng nhận trọng số đáng kể. Do đó, kết luận cho câu hỏi thứ tư là XBone-Net sử dụng cả hai nguồn thông tin, nhưng tích phân gradient chỉ phản ánh mức phụ thuộc đối với đầu vào và mốc tham chiếu đã chọn. Kết quả không chứng minh khả năng định vị tổn thương, đóng góp nhân quả hoặc tính đúng lâm sàng của lời giải thích.

5.3 Hướng phát triển

Về điểm mạnh, XBone-Net đạt chất lượng quyết định lớp cạnh tranh với các mô hình ngôn ngữ trực quan và tốt hơn rõ rệt hai đối chứng chỉ dùng ảnh, đồng thời chỉ cập nhật khoảng 4,13% tổng số tham số trong quá trình huấn luyện. Mô hình khai thác được cả ảnh X-quang và bệnh sử lâm sàng, còn quy trình đánh giá đã xem xét đồng thời hiệu năng phân lớp, kiểm định thống kê, tài nguyên suy luận, ảnh hưởng của thành phần, cảnh báo dữ liệu ngoài phân phối và mức phụ thuộc vào từng nguồn thông tin. Nhờ đó, kết quả không chỉ cho biết mô hình dự đoán tốt đến đâu mà còn làm rõ những đánh đổi và điều kiện giới hạn của cấu hình đầy đủ.

Về điểm yếu, khả năng xếp hạng xác suất của XBone-Net chưa tốt bằng nhiều mô hình ngôn ngữ trực quan và việc giảm tham số cần cập nhật không làm mô hình sau hợp nhất nhỏ hơn BiomedCLIP hoặc giảm chi phí suy luận. Huấn luyện hai pha cùng chú ý chéo hai chiều chưa tạo lợi ích có ý nghĩa thống kê đồng đều trên mọi độ đo, trong khi phép nối đặc trưng tốt hơn có ý nghĩa về khả năng xếp hạng. Bộ cảnh báo vẫn chấp nhận nhầm khoảng 63% mẫu ngoài phân phối gần miền. Phân tích tích phân gradient chỉ dùng một hạt giống trên 44 mẫu và phụ thuộc vào nền đen cùng văn bản trống làm mốc tham chiếu, đồng thời chưa có chú thích vùng tổn thương hoặc đánh giá của bác sĩ. Ngoài ra, CTCH chỉ đến từ một cơ sở y tế, còn BTRD không có mã người bệnh ổn định và sử dụng văn bản sinh từ siêu dữ liệu. Vì vậy, kết quả chưa phản ánh đầy đủ khả năng chuyển giao giữa cơ sở hoặc giá trị hỗ trợ trong thực hành lâm sàng.

Hướng phát triển đầu tiên là mở rộng dữ liệu và quy trình kiểm định. XBone-Net cần được đánh giá trên dữ liệu từ nhiều cơ sở, thiết bị, quy trình chụp, ngôn ngữ bệnh sử và phân bố bệnh lý khác nhau. Đối với CTCH, có thể xây dựng nhiều tập chia theo người bệnh hoặc sử dụng kiểm định chéo lồng nhau để tách biến thiên do tối ưu khỏi biến thiên do cách chia dữ liệu. Đối với bài toán u xương, cần thu thập bệnh sử tự nhiên ghép cặp với ảnh thay cho văn bản sinh từ siêu dữ liệu. Các lớp ít mẫu cần được mở rộng có kiểm soát và đánh giá riêng để xác định lợi ích của đa phương thức có duy trì khi phân bố lớp thay đổi hay không. Việc đánh giá nên bổ sung tập kiểm thử ngoài độc lập và báo cáo khoảng tin cậy ghép cặp cho từng nhóm bệnh, từng cơ sở và từng điều kiện chất lượng dữ liệu. Ngoài đầu vào đầy đủ, cần khảo sát bệnh sử thiếu, bệnh sử nhiều, ảnh sai tư thế và sự bất đồng giữa ảnh với văn bản. Những kịch bản này phản ánh sát hơn điều kiện thực tế và giúp xác định khi nào dung hợp đa phương thức mang lại lợi ích hoặc làm tăng rủi ro.

Hướng phát triển tiếp theo là cải thiện mô hình và hiệu quả triển khai. Kết quả thành phần cho thấy chú ý chéo hai chiều không tốt hơn phép nối trên mọi mục tiêu, vì vậy cần khảo sát dung hợp có cổng, chú ý một chiều hoặc cơ chế lựa chọn động theo độ tin cậy của từng nguồn. Việc tối ưu cần xem đồng thời điểm macro-F1, khả năng xếp hạng, hiệu chuẩn xác suất, số tham số cập nhật, số phép toán, độ trễ và bộ nhớ thay vì chỉ chọn cấu hình theo một độ đo phân lớp. Để giảm chi phí triển khai, có thể khảo sát giảm số đầu chú ý, giảm chiều biểu diễn dung hợp, chia sẻ phép chiếu giữa hai hướng chú ý, chưng cất sang mô hình nhỏ hơn hoặc lượng tử hóa sau huấn luyện. Sau mỗi thay đổi, trọng số LoRA cần được hợp nhất trước khi đo tổng tham số và tốc độ suy luận. Bên cạnh đó, các phương pháp hiệu chỉnh xác suất trên tập xác thực và hàm mất mát chú trọng chất lượng xếp hạng có thể được nghiên cứu nhằm khắc phục khoảng cách giữa quyết định lớp cạnh tranh và khả năng xếp hạng chưa tốt của XBone-Net.

Đối với cảnh báo dữ liệu ngoài phân phối, cần mở rộng tập đánh giá theo từng dạng dịch chuyển, gồm bệnh lý gần miền ngoài không gian nhãn, thay đổi thiết bị hoặc cơ sở, văn bản không phù hợp và đầu vào thiếu một phương thức. Trên các tập này, cần so sánh nhiều phương pháp chấm điểm, chiến lược tổng hợp điểm ảnh-văn bản và cách hiệu chỉnh ngưỡng

bằng tập xác thực độc lập. Đánh giá cần bổ sung đường cong rủi ro—độ bao phủ, tỷ lệ từ chối, chi phí lỗi và độ ổn định của ngưỡng theo thời gian. Trước mắt, điểm ngoài phân phối chỉ nên tạo cảnh báo để chuyển trường hợp khó sang chuyên gia. Cơ chế từ chối có điều kiện chỉ nên được xem xét khi tỷ lệ chấp nhận nhằm giảm rõ rệt trên nhiều nguồn dữ liệu và ngưỡng duy trì ổn định trong đánh giá tiền cứu.

Cuối cùng, phân tích tích phân gradient cần được mở rộng cho toàn bộ hạt giống và nhiều mốc tham chiếu. Độ trung thực nên được kiểm tra bằng nhiều mức che, kích thước vùng và đối chứng ngẫu nhiên ghép cặp. Chú thích vùng tổn thương cùng đánh giá độc lập của bác sĩ sẽ giúp phân biệt vùng ảnh hưởng đến mô hình với vùng có ý nghĩa lâm sàng. Các trường hợp ảnh và văn bản mâu thuẫn cũng cần được phân tích để kiểm tra liệu mô hình có ưu tiên đúng nguồn đáng tin cậy hay không. Trước khi ứng dụng, XBone-Net cần được nghiên cứu tiền cứu trong chế độ quan sát và không tác động trực tiếp đến điều trị. Hệ thống thử nghiệm cần lưu phiên bản mô hình, nguồn dữ liệu, xác suất, cảnh báo, bản đồ đóng góp, quyết định của bác sĩ và kết quả cuối cùng để truy cứu sai sót cùng giám sát dịch chuyển. Hoạt động triển khai phải bảo đảm bảo mật, phê duyệt đạo đức và quyền ghi đè của chuyên gia. XBone-Net chỉ nên được cân nhắc như công cụ hỗ trợ lâm sàng sau khi các yếu tố trên được xác nhận bằng dữ liệu ngoài và nghiên cứu tiền cứu.

Tài liệu tham khảo

Tiếng Anh

- [1] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision-Language Models”. In: *Proceedings of the European Conference on Computer Vision (ECCV)*. Springer, 2022, pp. 1–18. DOI: 10.1007/978-3-031-19836-6_1.
- [2] Kay Henning Brodersen et al. “The Balanced Accuracy and Its Posterior Distribution”. In: *Proceedings of the 20th International Conference on Pattern Recognition (ICPR)*. IEEE, 2010, pp. 3121–3124. DOI: 10.1109/ICPR.2010.764.
- [3] Alfredo Canziani, Adam Paszke, and Eugenio Culurciello. “An Analysis of Deep Neural Network Models for Practical Applications”. In: *arXiv preprint arXiv:1605.07678* (2017). URL: <https://arxiv.org/abs/1605.07678>.
- [4] Jesse Davis and Mark H. Goadrich. “The Relationship Between Precision-Recall and ROC Curves”. In: *Proceedings of the 23rd International Conference on Machine Learning (ICML)*. ACM, 2006, pp. 233–240. DOI: 10.1145/1143844.1143874.
- [5] deep-translator contributors. *deep-translator: A flexible tool to translate between different languages in Python*. 2020. URL: <https://github.com/nidhaloff/deep-translator> (visited on 08/14/2026).
- [6] Jay DeYoung et al. “ERASER: A Benchmark to Evaluate Rationalized NLP Models”. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Compu-

- tational Linguistics, 2020, pp. 4443–4458. DOI: 10.18653/v1/2020.acl-main.408. URL: <https://aclanthology.org/2020.acl-main.408/>.
- [7] Alexey Dosovitskiy et al. “An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2021. URL: <https://openreview.net/forum?id=YicbFdNTTy>.
 - [8] Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993. ISBN: 0-412-04231-2.
 - [9] Sedigheh Eslami, Gerard de Melo, and Christoph Meinel. “Does CLIP Hurt Medical Image Classification? Evaluating and Improving CLIP for Medical Image Classification”. In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2023, pp. 15600–15611. DOI: 10.18653/v1/2023.emnlp-main.965.
 - [10] Tom Fawcett. “An Introduction to ROC Analysis”. In: *Pattern Recognition Letters* 27.8 (2006), pp. 861–874. DOI: 10.1016/j.patrec.2005.10.010.
 - [11] Phillip I. Good. *Permutation, Parametric, and Bootstrap Tests of Hypotheses*. 3rd ed. Springer Series in Statistics. New York: Springer, 2005. DOI: 10.1007/b138696.
 - [12] Kaiming He et al. “Deep Residual Learning for Image Recognition”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 770–778. DOI: 10.1109/CVPR.2016.90.
 - [13] Dan Hendrycks and Kevin Gimpel. “A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2017. URL: <https://arxiv.org/abs/1610.02136>.
 - [14] Sture Holm. “A Simple Sequentially Rejective Multiple Test Procedure”. In: *Scandinavian Journal of Statistics* 6.2 (1979), pp. 65–70. DOI: 10.2307/4615733.

- [15] Edward J. Hu et al. “LoRA: Low-Rank Adaptation of Large Language Models”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2022. URL: <https://openreview.net/forum?id=nZeVKeeFYf9>.
- [16] Gao Huang et al. “Densely Connected Convolutional Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017, pp. 4700–4708. DOI: 10.1109/CVPR.2017.243.
- [17] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-Efficient Medical Image Recognition”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [18] Kimin Lee et al. “A Simple Unified Framework for Detecting Out-of-Distribution Samples and Adversarial Attacks”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 31. 2018, pp. 7167–7177. URL: <https://papers.nips.cc/paper/2018/hash/abdeb6f575ac5c6676b747bca8d09cc2-Abstract.html>.
- [19] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv preprint arXiv:2306.00890 2023. URL: <https://arxiv.org/abs/2306.00890>.
- [20] Shiyu Liang, Yixuan Li, and R. Srikant. “Enhancing The Reliability of Out-of-Distribution Image Detection in Neural Networks”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2018. URL: <https://openreview.net/forum?id=H1VGkIxRZ>.
- [21] Weitang Liu et al. “Energy-Based Out-of-Distribution Detection”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33. 2020, pp. 21464–21475. URL: <https://papers.nips.cc/paper/2020/hash/f5449014e28707da7d360e46a5e95299-Abstract.html>.

- [22] Xueyan Mei et al. “Artificial Intelligence–Enabled Rapid Diagnosis of Patients with COVID-19”. In: *Nature Medicine* 26.8 (2020), pp. 1224–1228. DOI: 10.1038/s41591-020-0931-3.
- [23] Michael Moor et al. *Med-Flamingo: A Multimodal Medical Few-Shot Learner*. arXiv preprint arXiv:2307.15189. 2023. URL: <https://arxiv.org/abs/2307.15189>.
- [24] Thi-Huong Nguyen et al. “LCBB: Low-Rank Adaptation of Vision-Language Models for Medical Image Classification”. In: *arXiv preprint arXiv:2403.18245* (2024). URL: <https://arxiv.org/abs/2403.18245>.
- [25] OpenAI. *GPT-4o System Card*. 2024. URL: <https://openai.com/index/gpt-4o-system-card/> (visited on 08/01/2026).
- [26] Vitali Petsiuk, Abir Das, and Kate Saenko. “RISE: Randomized Input Sampling for Explanation of Black-Box Models”. In: *Proceedings of the British Machine Vision Conference (BMVC)*. BMVA Press, 2018, p. 151. URL: <https://bmva-archive.org.uk/bmvc/2018/contents/papers/1064.pdf>.
- [27] Jiuming Qin et al. “Freeze the Backbones: A Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.
- [28] Alec Radford et al. “Learning Transferable Visual Models From Natural Language Supervision”. In: *Proceedings of the 38th International Conference on Machine Learning (ICML)*. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 8748–8763. URL: <https://proceedings.mlr.press/v139/radford21a.html>.
- [29] Vijay Janapa Reddi et al. “MLPerf Inference Benchmark”. In: *Proceedings of the 2020 ACM/IEEE 47th Annual International Symposium on Computer Architecture (ISCA)*. IEEE, 2020, pp. 446–459. DOI: 10.1109/ISCA45697.2020.00045.

- [30] Bryan C. Russell et al. “LabelMe: A Database and Web-Based Tool for Image Annotation”. In: *International Journal of Computer Vision* 77.1–3 (2008), pp. 157–173. DOI: 10.1007/s11263-007-0090-8.
- [31] Sentence Transformers. *Paraphrase Multilingual MiniLM-L12-v2 Model Card*. 2021. URL: <https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2> (visited on 08/14/2026).
- [32] Yiqing Shi et al. “BiomedCoOp: Explainable Medical Vision-Language Prompting”. In: *Proceedings of the 2024 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*. 2024, pp. 7920–7929. DOI: 10.1109/WACV57701.2024.00776.
- [33] Jake Snell, Kevin Swersky, and Richard S. Zemel. “Prototypical Networks for Few-Shot Learning”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30. 2017, pp. 4077–4087. URL: https://papers.nips.cc/paper_files/paper/2017/hash/cb8da6767461f2812ae4290eac7cbc42-Abstract.html.
- [34] Yiyu Sun et al. “Out-of-Distribution Detection with Deep Nearest Neighbors”. In: *Proceedings of the 39th International Conference on Machine Learning (ICML)*. Vol. 162. Proceedings of Machine Learning Research. PMLR, 2022, pp. 20827–20840. URL: <https://proceedings.mlr.press/v162/sun22d.html>.
- [35] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. “Axiomatic Attribution for Deep Networks”. In: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. Vol. 70. Proceedings of Machine Learning Research. PMLR, 2017, pp. 3319–3328. URL: <https://proceedings.mlr.press/v70/sundararajan17a.html>.
- [36] Tao Tu et al. “Towards Generalist Biomedical AI”. In: *NEJM AI* 1.3 (2024), AIoa2300138. DOI: 10.1056/AIoa2300138.
- [37] Xiaosong Wang et al. “TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays”. In: *Proceedings of the IEEE Conference on Computer Vision*

- and Pattern Recognition (CVPR)*. 2018, pp. 9043–9052. DOI: 10.1109/CVPR.2018.00942.
- [38] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256.
 - [39] Yandong Wen et al. “A Discriminative Feature Learning Approach for Deep Face Recognition”. In: *Proceedings of the European Conference on Computer Vision (ECCV)*. Springer, 2016, pp. 499–515. DOI: 10.1007/978-3-319-46478-7_31.
 - [40] Shunhan Yao et al. “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors”. In: *Scientific Data* 12.1 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y.
 - [41] Jiajin Zhang et al. “Disease-Informed Adaptation of Vision-Language Models”. In: *IEEE Transactions on Medical Imaging* 44.10 (2025), pp. 3984–3996. DOI: 10.1109/TMI.2024.3475877.
 - [42] Sheng Zhang et al. “Large-Scale Domain-Specific Pretraining for Biomedical Vision-Language Processing”. In: *npj Digital Medicine* 6.1 (2023), p. 233. DOI: 10.1038/s41746-023-00958-6. URL: <https://doi.org/10.1038/s41746-023-00958-6>.
 - [43] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 38th International Conference on Machine Learning (ICML)*. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 12133–12145. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
 - [44] Rongfu Zheng et al. “CLIPath: A Parameter-Efficient Adaptation Framework for Pathology Image Analysis”. In: *Proceedings of the International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Springer, 2023, pp. 334–344. DOI: 10.1007/978-3-031-43907-0_33.

- [45] Hong-Yu Zhou et al. “A Transformer-Based Representation-Learning Model with Unified Processing of Multimodal Input for Clinical Diagnostics”. In: *Nature Biomedical Engineering* 7.6 (2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x.

Phụ lục A

Chi tiết về bộ dữ liệu

Phụ lục này bổ sung các thông tin kỹ thuật cần thiết để tái lập quá trình chuẩn bị hai bộ dữ liệu BTXRD và CTCH. Nội dung của mỗi bộ dữ liệu được tổ chức theo cấu trúc dữ liệu, cách xây dựng nguồn văn bản sử dụng trong thực nghiệm đối với bộ dữ liệu BTXRD và cách sàng lọc dữ liệu đối với bộ dữ liệu CTCH. Các thống kê được tính trực tiếp từ phiên bản dữ liệu mà mã nguồn hiện tại sử dụng.

A.1 Bộ dữ liệu BTXRD

Phần này trình bày cấu trúc dữ liệu, đặc điểm kỹ thuật của ảnh và phương pháp xây dựng văn bản dạng lâm sàng tổng hợp cho BTXRD. Ảnh và siêu dữ liệu thuộc phiên bản BTXRD được sử dụng trong nghiên cứu riêng văn bản tổng hợp được sinh ngoại tuyến và cố định trước khi huấn luyện. Nội dung này tập trung vào cách sinh nguồn dữ liệu giả lâm sàng.

A.1.1 Cấu trúc lưu trữ và đặc điểm kỹ thuật

Bảng A.1 mô tả các thành phần liên quan đến phạm vi phân loại của nghiên cứu. Định danh ảnh là khóa liên kết một-một giữa siêu dữ liệu, nhãn, tập chia, ảnh và văn bản tổng hợp.

Thành phần	Số tệp	Vai trò
images/	3.746	Lưu ảnh X-quang đầu vào.
Annotations/	1.867	Lưu chú thích JSON cho các ảnh có u, nhưng không được sử dụng trong huấn luyện phân loại.
reports/	3.746	Mỗi ảnh có một văn bản dạng lâm sàng được sinh ngoại tuyến từ siêu dữ liệu.
dataset.csv	3.746	Siêu dữ liệu gốc, gồm định danh ảnh, nguồn thu thập, tuổi, giới tính, vị trí giải phẫu, tư thế chụp và các cờ nhóm bệnh.
btxrd-labels.csv	3.746	Chứa định danh ảnh và 10 cột chỉ báo lớp.
btxrd-split.csv	3.746	Ánh xạ mỗi ảnh vào <code>train</code> , <code>validate</code> hoặc <code>test</code> .

Bảng A.1: Cấu trúc lưu trữ của bộ dữ liệu BTXRD trong nghiên cứu

Bảng A.2 cho thấy dữ liệu ảnh có định dạng không hoàn toàn đồng nhất. Mặc dù tất cả tên tệp đều mang định dạng JPEG, kiểm tra nội dung tệp xác định 3.744 ảnh được mã hóa JPEG, một ảnh được mã hóa BMP và một ảnh được nhận diện là MPO. Toàn bộ 3.746 ảnh vẫn giải mã thành công. Khi nạp dữ liệu, mỗi ảnh được chuyển sang RGB trước khi tạo tensor, do đó ảnh thang xám và ảnh ba kênh đều tạo đầu vào ba kênh cho mô hình.

Thuộc tính	Kết quả kiểm tra
Phần mở rộng	3.719 tệp .jpeg và 27 tệp .jpg.
Chế độ màu khi giải mã	2.895 ảnh thang xám L và 851 ảnh RGB.
Định dạng mã hóa	3.744 JPEG, 1 BMP và 1 MPO.
Chiều rộng	Nhỏ nhất 153 px, trung vị 1.612 px, lớn nhất 3.594 px.
Chiều cao	Nhỏ nhất 311 px, trung vị 2.256 px, lớn nhất 4.881 px.
Khả năng giải mã	3.746/3.746 tệp được đọc thành công.

Bảng A.2: Đặc điểm kỹ thuật của các tệp ảnh BTXRD

A.1.2 Phương pháp tạo dữ liệu giả lâm sàng

BTXRD không cung cấp bệnh sử tự do tương ứng với từng ảnh. Để mô phỏng đầu vào văn bản của một hệ thống đa phương thức, nghiên cứu xây dựng một văn bản dạng lâm sàng cho mỗi mẫu bằng quy trình dựa trên luật và ngân hàng mẫu câu. Mục tiêu của quy trình là tạo một cấu trúc đầu vào thống nhất, không phải khôi phục bệnh sử thật của người bệnh.

Thông tin đầu vào và luật điều kiện

Các trường được lấy trực tiếp từ siêu dữ liệu gồm tuổi, giới tính, vị trí xương, vị trí khớp, vùng giải phẫu và tư thế chụp. Vị trí chính được chọn theo thứ tự ưu tiên xương, khớp, vùng giải phẫu nếu không có trường vị trí cụ thể, một mô tả tổng quát về xương sẽ được sử dụng. Tuổi được chia thành bốn nhóm gồm dưới 20 tuổi, 20-34 tuổi, 35-49 tuổi và từ 50 tuổi trở lên để lựa chọn ngữ cảnh tiền sử phù hợp.

Ngân hàng mẫu câu được chia thành ba nhóm hành vi. Mẫu không có cờ u được gán nhóm "không u" còn mẫu có cờ u và cờ ác tính được gán nhóm "ác tính" và các mẫu có u còn lại được gán nhóm "lành tính". Theo luật này, dữ liệu gồm 1.879 mẫu không u, 1.525 mẫu có u nhưng không mang cờ ác tính và 342 mẫu ác tính. Nhóm này quyết định tập mẫu câu dùng cho lý do vào viện, diễn tiến bệnh và khám thực thể. Ngoài ra, 182 mẫu có nhiều hơn một xương được đánh dấu và 61 mẫu có khớp liên quan thì được nối thêm một câu mô tả bối cảnh nhiều vị trí hoặc hạn chế vận động quanh khớp.

Ghép văn bản và cố định dữ liệu

Các lựa chọn ngẫu nhiên sử dụng phân phối đều trên từng ngân hàng câu và hạt giống 42. Ngân hàng mẫu câu ban đầu được sinh từ tên bệnh bằng ChatGPT-4o [25], tham chiếu cấu trúc các trường bệnh sử của CTCH để mô phỏng cách trình bày. Danh sách khoảng thời gian có 10 lựa chọn. Số mẫu câu lý do vào viện của ba nhóm không u/lành tính/ác tính lần lượt là 6/7/6, số mẫu diễn tiến bệnh là 6/8/8 và số mẫu khám thực thể là 4/7/7. Ngân hàng tiền sử chung có 9 câu, mỗi nhóm tuổi có 3 câu ngữ cảnh, còn hai ngân hàng bổ sung nhiều xương và quanh khớp đều có 5 câu. Sau bước biên soạn ngân hàng, quy trình chọn và ghép văn bản không gọi mô hình ngôn ngữ và không có bước xác nhận nội dung bởi bác sĩ.

Với thứ tự hàng siêu dữ liệu được giữ cố định, mỗi lần chạy quy trình tạo ra cùng một lựa chọn mẫu câu. Văn bản được ghép theo thứ tự: thông tin người bệnh, lý do vào viện, diễn tiến bệnh, khám thực thể, tiền sử bản thân và thông tin thu nhận ảnh.

Bảng A.3 liệt kê các mẫu câu đại diện cho từng ngân hàng. Các mẫu được giữ nguyên bằng tiếng Anh vì đây là ngôn ngữ của đầu vào văn bản BTXRD trong thí nghiệm với các ký hiệu "location", "duration" và "joint" lần lượt được thay bằng vị trí chính, khoảng thời gian được chọn và khớp liên quan.

Ngân hàng	Mẫu câu đại diện
Khoảng thời gian	<i>2 weeks; 1 month; 3 months; 6 months; several weeks; a few months; 2 months; 4 weeks; several months; 1 year.</i>
Lý do vào viện	Không u: <i>Pain in the {location}.</i> Lành tính: <i>Swelling of the {location}.</i> Ác tính: <i>Persistent pain in the {location}.</i>
Diễn tiến bệnh	Không u: <i>Onset {duration} ago; mild symptoms.</i> Lành tính: <i>The patient noticed swelling in the {location} {duration} ago.</i> Ác tính: <i>Pain and swelling in the {location} for {duration}; progressively worsening.</i>
Khám thực thể	Không u: <i>No tenderness or swelling on palpation.</i> Lành tính: <i>Palpable firm mass; non-tender; no skin changes.</i> Ác tính: <i>Firm, tender mass on the {location}; local warmth noted.</i>
Bổ sung nhiều xương	<i>Multiple bony prominences palpated at several sites hoặc Multiple hard masses involving several bones on examination.</i>
Bổ sung quanh khớp	<i>Joint involvement noted; restricted range of motion at the {joint} hoặc Soft tissue swelling observed around the {joint}.</i>
Tiền sử chung	<i>No significant medical history, No prior bone disease or fracture hoặc No relevant prior medical or surgical history.</i>
Ngữ cảnh theo tuổi	Dưới 20 tuổi: <i>Growth and development appropriate for age.</i> Từ 20–34 tuổi: <i>No prior bone lesions.</i> Từ 35–49 tuổi: <i>No relevant surgical or medical history.</i> Từ 50 tuổi trở lên: <i>History of age-related degenerative changes; no prior bone lesions.</i>

Bảng A.3: Các mẫu câu đại diện trong ngân hàng văn bản giả lâm sàng BTXRD

Quy trình không chèn trực tiếp tên của 10 lớp đích vào văn bản. Tuy nhiên, cờ có u và cờ ác tính tham gia trực tiếp vào việc chọn ngân hàng mẫu câu, vì vậy nội dung tổng hợp vẫn mang tín hiệu liên hệ mạnh với nhãn. Các triệu chứng, thời gian mắc bệnh, dấu hiệu khám và tiền sử được chọn từ mẫu câu là dữ liệu giả lập, không phải lời khai của người bệnh hoặc ghi nhận của nhân viên y tế. Do đó, kết quả liên quan đến văn bản BTXRD chỉ phản ánh thiết lập giả lâm sàng có điều kiện này và không được diễn giải tương đương với bệnh sử tự nhiên của CTCH.

Kiểm chứng liên kết và khả năng tái lập

Để kiểm tra văn bản đã được ghép đúng với hàng siêu dữ liệu, bộ sinh được phát lại từ đầu trên toàn bộ `dataset.csv` với hạt giống 42 và giữ nguyên thứ tự 3.746 hàng. Văn bản tái tạo của mỗi hàng được so sánh từng ký tự với tệp có cùng định danh ảnh trong `reports/`. Cách kiểm tra tuần tự này là cần thiết vì lựa chọn mẫu câu của một hàng phụ thuộc vào trạng thái bộ sinh giả ngẫu nhiên sau các hàng đứng trước. Việc gọi hàm sinh riêng lẻ cho một mẫu không bảo toàn trạng thái đó. Ngoài liên kết văn bản, phép kiểm tra còn đối chiếu nhãn với siêu dữ liệu nguồn và xác nhận quy mô ba tập chia. Kết quả được trình bày trong Bảng A.4.

Phép kiểm tra	Kết quả
Định danh duy nhất trong siêu dữ liệu, nhãn và tập chia	3.746/3.746 (100%)
Nhãn có đúng một lớp trong 10 lớp	3.746/3.746 (100%)
Nhãn khớp với các cờ lớp trong <code>dataset.csv</code>	3.746/3.746 (100%)
Quy mô <code>train/validate/test</code>	2.621/375/750
Hàng siêu dữ liệu có văn bản cùng định danh	3.746/3.746 (100%)
Văn bản khớp chính xác khi phát lại bộ sinh	3.746/3.746 (100%)
Tệp thiếu/tệp dư so với <code>dataset.csv</code>	0/0
Văn bản có đủ sáu trường cấu trúc	3.746/3.746 (100%)
Văn bản duy nhất	3.745/3.746 (99,97%)
Độ dài trung bình	57,70 $\pm$ 6,66 từ
Trung vị và miền độ dài	56 từ, với miền 44–91 từ
Thiếu tuổi, giới tính, vị trí hoặc tư thế chụp	0 mẫu
Xuất hiện trực tiếp tên bệnh đích trong danh sách kiểm tra	0/3.746

Bảng A.4: Kết quả kiểm chứng tính toàn vẹn của dữ liệu BTXRD

Hai mẫu `IMG002607.jpeg` và `IMG003588.jpeg` tạo cùng một văn bản, giải thích vì sao số văn bản duy nhất thấp hơn tổng số mẫu một đơn vị. Kiểm tra từ khóa không phát hiện sự xuất hiện trực tiếp của các tên bệnh đích như *osteochondroma*, *osteosarcoma*, *simple bone cyst* hoặc *giant cell tumor*. Phép kiểm tra này xác nhận bộ sinh không chèn trực tiếp các tên bệnh được rà soát, nhưng không tự loại trừ tín hiệu nhãn gián tiếp. Trong phiên bản dữ liệu hiện tại, cả 3.746 hàng đều là nhãn một-nóng. Mẫu `IMG001276.jpeg` chỉ mang nhãn cụ thể *synovial osteochondroma* và không còn đồng thời mang nhãn cha *osteochondroma*.

Kiểm tra rò rỉ nhãn trực tiếp và gián tiếp

Quy trình được thực hiện trên toàn bộ 3.746 cặp văn bản–nhãn theo các bước sau:

1. **Kiểm tra trực tiếp:** chuẩn hóa chữ hoa–chữ thường và rà soát mỗi báo cáo để tìm sự xuất hiện nguyên văn của tên bệnh đích cùng các biến thể tên đã định nghĩa trước.
2. **Tạo câu nhắc lớp:** tạo một câu nhắc theo cùng mẫu *Clinical history associated with [disease label]* cho từng lớp trong 10 lớp bệnh.
3. **Mã hóa ngữ nghĩa:** mã hóa báo cáo và các câu nhắc lớp bằng bộ mã hóa văn bản BioMedCLIP, sau đó chuẩn hóa embedding và tính độ tương đồng cosin giữa mỗi báo cáo với cả 10 câu nhắc.
4. **Tính cosine margin:** với mẫu i có nhãn đúng y_i , tính

$$m_i = \cos(r_i, p_{y_i}) - \max_{c \neq y_i} \cos(r_i, p_c), \quad (\text{A.1})$$

trong đó r_i là embedding của báo cáo và p_c là embedding câu nhắc lớp c . Margin dương nghĩa là câu nhắc đúng nhãn gần báo cáo nhất, còn margin âm nghĩa là có ít nhất một câu nhắc nhãn khác gần hơn.

5. **Tổng hợp:** lấy trung bình m_i trên toàn bộ tập dữ liệu để đánh giá liệu tên bệnh đúng có thể được truy hồi ổn định từ nội dung văn bản hay không.

Bảng A.5 chỉ giữ hai kết quả có diễn giải trực tiếp đối với nguy cơ rò rỉ nhãn, còn các kết quả trung gian được lược bỏ để tránh gây nhầm lẫn.

Phép kiểm tra	Kết quả
Báo cáo chứa trực tiếp tên bệnh đích trong danh sách rà soát	0/3.746
Cosine margin trung bình giữa đúng nhãn và nhãn khác gần nhất	−0,0400

Bảng A.5: Kiểm tra nguy cơ rò rỉ nhãn trực tiếp và gián tiếp trong văn bản BTXRD

Không phát hiện trường hợp tên bệnh đích xuất hiện trực tiếp trong văn bản. Cosine margin trung bình bằng $-0,0400$, tức là độ tương đồng với đúng nhãn thấp hơn nhãn khác gần nhất trung bình $0,04$ đơn vị cosin. Vì vậy, phép kiểm tra không cho thấy tên bệnh cụ thể có thể được suy ra trực tiếp và ổn định từ báo cáo tổng hợp. Kết quả này chỉ đánh giá nguy cơ lộ tên nhãn và không đánh giá tính đúng đắn lâm sàng hay hình thái của nội dung văn bản.

1. Hàng siêu dữ liệu IMG000001.jpeg: tuổi 48, giới tính F, hip bone=1, pelvis=1, tumor=1, malignant=1 và frontal=1.



2. Suy ra điều kiện Vị trí chính là *hip bone*, nhóm tuổi là 35–49, nhóm mẫu câu là ác tính, tư thế là AP và không có nhiều xương hoặc khớp liên quan.



3. Chọn đầu với hạt giống 42 Khoảng thời gian là *1 month*. Lý do là *Pain and swelling of the hip bone*. Diễn tiến là *Pain in the hip bone for 1 month; associated with decreased appetite*. Khám ghi nhận *Palpable mass; tenderness on palpation; mild swelling*. Tiền sử gồm *No prior bone disease or fracture* và *No relevant surgical or medical history*.



4. Ghép theo thứ tự cố định *Patient: 48-year-old female. Reason for admission: Pain and swelling of the hip bone. Disease history: Pain in the hip bone for 1 month; associated with decreased appetite. Physical examination: Palpable mass; tenderness on palpation; mild swelling. Personal medical history: No prior bone disease or fracture. No relevant surgical or medical history. Radiographic evaluation: AP view of the hip bone was obtained.*



5. Cố định đầu vào Lưu thành IMG000001.txt

Hình A.1: Quá trình tạo văn bản minh họa cho mẫu IMG000001.jpeg

A.2 Bộ dữ liệu CTCH

Phụ lục này mô tả quy trình chuẩn bị CTCH nhằm hỗ trợ tái lập và đánh giá tính hợp lệ của dữ liệu. Nội dung tập trung vào tiêu chí lựa chọn mẫu, cách hình thành nhãn, nguyên tắc chia tập, nguồn gốc văn bản và các phép kiểm tra toàn vẹn.

Sàng lọc và xác định quần thể nghiên cứu

Quần thể đích của bộ dữ liệu CTCH gồm các bệnh nhân được chụp X-quang xương khớp nhằm hỗ trợ chẩn đoán bệnh lý hoặc chấn thương xương. Quần thể tiếp cận bao gồm các bệnh nhân có bệnh án và dữ liệu hình ảnh được thu thập tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.

Dữ liệu ban đầu gồm 12.949 bệnh án. Tuy nhiên, các hồ sơ này chưa thể được sử dụng trực tiếp vì có sự khác biệt về loại dữ liệu cận lâm sàng, thời điểm thăm khám, tình trạng điều trị và mức độ phù hợp của nhãn. Quy trình sàng lọc được thực hiện tuần tự nhằm hình thành quần thể có ảnh X-quang, bệnh sử và nhãn phù hợp với phạm vi phân loại của nghiên cứu. Số lượng hồ sơ còn lại sau từng bước được trình bày trong Hình A.2.



Hình A.2: Quy trình sàng lọc hồ sơ cho bộ dữ liệu CTCH

A.2.1 Cấu trúc dữ liệu và đặc điểm kỹ thuật

Bảng A.6 mô tả các thành phần liên quan đến phạm vi phân loại của nghiên cứu. Định danh ảnh là khóa liên kết một-một giữa siêu dữ liệu, nhãn, tập chia, ảnh và bệnh sử lâm sàng.

Thành phần	Số lượng sử dụng	Vai trò
images/	3.267	Lưu ảnh X-quang đầu vào được liên kết bởi manifest.
reports/	3.267 cặp song ngữ (6.534 tệp)	Mỗi ảnh được chọn có một bệnh sử lâm sàng tiếng Việt và một bản tiếng Anh tương ứng.
ctch-labels.csv	3.249	Chứa định danh ảnh và 22 cột chỉ báo lớp.
ctch-ood.csv	18	Chứa định danh và thông tin các mẫu ngoài phân phối.
ctch-split.csv	3.249	Ảnh xạ mỗi ảnh vào <code>train</code> , <code>validate</code> hoặc <code>test</code> .

Bảng A.6: Cấu trúc lưu trữ của bộ dữ liệu CTCH trong nghiên cứu

Bảng A.7 cho thấy dữ liệu ảnh có định dạng đồng nhất. Toàn bộ 3.267 tệp lưu trữ đều có phần mở rộng JPEG và được mã hóa chuẩn JPEG với toàn bộ 3.267 ảnh giải mã thành công. Khi nạp dữ liệu, mỗi ảnh được chuyển sang RGB trước khi tạo tensor, bảo đảm đầu vào ba kênh cho mô hình.

Thuộc tính	Kết quả kiểm tra
Phần mở rộng	3.267 tệp .jpg.
Chế độ màu khi giải mã	3.267 ảnh RGB.
Định dạng mã hóa	3.267 JPEG.
Chiều rộng	Nhỏ nhất 1.186 px, trung vị 1.213 px, lớn nhất 2.836 px.
Chiều cao	Nhỏ nhất 1.213 px, trung vị 1.713 px, lớn nhất 2.880 px.
Khả năng giải mã	3.267/3.267 tệp được đọc thành công.

Bảng A.7: Đặc điểm kỹ thuật của các tệp ảnh CTCH

Dữ liệu nguồn gồm 3.641 hồ sơ đã được lựa chọn sơ bộ từ các ca khám tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh. Mỗi hồ sơ liên kết thông tin bệnh án với một ảnh đại diện cho vị trí cần khảo sát. Quá trình sàng lọc tiếp tục loại những ca có nếp, dính hoặc phương tiện kết hợp xương vì các cấu trúc này có thể che khuất tổn thương và tạo dấu hiệu thị giác ngoài mục tiêu phân loại.

Hiện tại 374 hồ sơ có dụng cụ y tế bị loại nhằm đảm bảo phạm vi nghiên cứu, đồng thời giúp đảm bảo chất lượng dữ liệu đầu vào là đồng

nhất. Phần còn lại gồm 3.267 mẫu, được tách thành 3.249 mẫu trong phân phối phục vụ phân loại và 18 mẫu ngoài phân phối về ngữ nghĩa. Hai quần thể không giao nhau theo ảnh hoặc theo mã nhóm người bệnh.

Giai đoạn	Số hồ sơ
Hồ sơ nguồn	3.641
Loại do có dụng cụ y tế	374
Còn lại sau sàng lọc	3.267
Quần thể trong phân phối	3.249
Quần thể ngoài phân phối	18

Bảng A.8: Dòng dữ liệu qua các bước sàng lọc CTCH

Quần thể ngoài phân phối gồm 6 mẫu thuộc nhóm chấn thương, 7 mẫu thuộc nhóm viêm nhiễm và 5 mẫu thuộc nhóm u xương, nhưng biểu hiện cụ thể không thuộc 22 lớp đích. Cách tổ chức này tạo một kịch bản ngoài dữ liệu trong cùng nguồn bệnh viện, qua đó giảm mức trộn lẫn giữa sai lệch ngữ nghĩa với thay đổi thiết bị hoặc cơ sở thu nhận. Tuy nhiên, số lượng 18 mẫu còn nhỏ nên khoảng bất định của các độ đo ngoài phân phối cần được trình bày và kết quả không nên được khái quát thành mọi dạng bất thường lâm sàng.

Nguồn văn bản và kiểm soát rò rỉ nhãn

Văn bản đầu vào CTCH được tạo ngoại tuyến từ ba trường có sẵn trước kết luận chẩn đoán cuối cùng gồm lý do vào viện, diễn tiến bệnh và tiền sử. Các trường kết quả khảo sát hình ảnh, chẩn đoán chuyên môn và nhãn phân lớp không được nối vào chuỗi văn bản đầu vào như thể hiện trong Bảng A.9. Chẩn đoán chuyên môn chỉ được sử dụng trong quá trình chuẩn hóa và dùng làm nhãn đích, còn nhãn phân loại chỉ tham gia kiểm tra và xác minh nhãn.

Trường dữ liệu nguồn	Dùng làm đầu vào	Vai trò trong nghiên cứu
Lý do vào viện	Có	Cung cấp triệu chứng hoặc vấn đề chính được ghi nhận khi tiếp nhận.
Diễn tiến bệnh	Có	Cung cấp cơ chế, thời điểm và diễn biến trước khi hình thành kết luận chẩn đoán.
Tiền sử	Có	Cung cấp thông tin bệnh lý, phẫu thuật hoặc điều trị trước đó khi trường này có dữ liệu.
Kết quả khảo sát hình ảnh	Không	Bị loại khỏi chuỗi đầu vào vì có thể chứa mô tả trực tiếp dấu hiệu trên phim.
Chẩn đoán chuyên môn	Không	Chỉ dùng để chuẩn hóa, ánh xạ và dùng làm nhãn phân loại chính, nhưng không được mã hóa bởi nhánh văn bản.
Nhân phân lớp	Không	Dùng để kiểm tra và xác minh nhãn.

Bảng A.9: Vai trò của các trường bệnh án CTCH và nguyên tắc loại thông tin có nguy cơ rò rỉ nhãn

Trong bước tạo thư mục **reports/**, ba trường được giữ lại được làm sạch và ghép theo thứ tự cố định, trong đó không có tên lớp, kết quả đọc ảnh hoặc chẩn đoán được bổ sung từ tệp nhãn. Việc chia tập được thực hiện theo mã người bệnh trước khi huấn luyện, còn mã liên kết không được đưa vào văn bản hoặc mô hình. Cách tổ chức này loại rò rỉ trực tiếp từ các cột chẩn đoán, nhưng không loại bỏ khả năng bệnh sử chứa những triệu chứng hoặc vị trí giải phẫu có tính dự báo cao. Vì vậy, khóa luận vẫn báo cáo đối chứng chỉ văn bản và phép ghép sai để khảo sát mức phụ thuộc vào nguồn này.

Công cụ dịch tiếng Anh. Bệnh sử tiếng Anh được tạo ngoại tuyến từ bản tiếng Việt bằng gói **deep-translator** phiên bản 1.11.4 với lớp **GoogleTranslator**, thiết lập ngôn ngữ nguồn là tiếng Việt (**vi**) và ngôn ngữ đích là tiếng Anh (**en**) [5]. Nội dung của từng trường được dịch riêng, trong khi tên trường, thứ tự trường và định danh liên kết với ảnh được giữ nguyên. Các đoạn tiếng Việt đã dịch được lưu trong một tệp bộ nhớ đệm JSON, do đó khi một đoạn xuất hiện lại, quy trình tái sử dụng đúng bản dịch đã lưu thay vì gửi một yêu cầu mới. Cơ chế này làm cho các câu lặp lại nhận cùng một bản dịch và hỗ trợ tái lập dữ liệu đã tạo.

Đánh giá độ tương đồng ngữ nghĩa của bản dịch. Chất lượng bản dịch được sàng lọc tự động bằng mô hình MiniLM đa ngôn ngữ `paraphrase-multilingual-MiniLM-L12-v2` [31]. Phép đánh giá chỉ chạy trên 3.267 ảnh còn lại sau sàng lọc và có tệp ảnh hợp lệ, không chạy trên các tệp vật lý ngoài manifest. Với mỗi trường có nội dung ở cả hai ngôn ngữ, câu tiếng Việt và câu tiếng Anh được mã hóa riêng với độ dài tối đa 256 token. Vector câu được tạo bằng trung bình có mặt nạ trên các token hợp lệ, sau đó chuẩn hóa theo chuẩn L_2 và tính cosine similarity giữa hai ngôn ngữ. Điểm càng gần 1 biểu thị hai biểu diễn càng gần nhau về ngữ nghĩa. Ngưỡng 0,70 chỉ được dùng để gán cờ các cặp cần rà soát, không được xem là tiêu chuẩn tuyệt đối về tính đúng đắn y khoa.

Trung bình phản ánh mức điểm chung nhưng nhạy với phần đuôi điểm thấp, còn trung vị mô tả vị trí trung tâm bền vững hơn trước các trường hợp ngoại lệ. Bảng A.10 báo cáo cả hai đại lượng trên 9.542 cặp trường song ngữ được liên kết.

Trường bệnh sử	Số cặp	Trung bình	Trung vị	Dưới 0,70
Lý do vào viện	3.267	0,7264	0,7767	1.083 (33,15%)
Diễn tiến bệnh	3.267	0,7462	0,7747	839 (25,68%)
Tiền sử cá nhân	2.930	0,5330	0,4737	2.474 (84,44%)
Toàn bộ	9.464	0,6733	0,7234	4.396 (46,45%)

Bảng A.10: Độ tương đồng ngữ nghĩa giữa bệnh sử tiếng Việt và bản dịch tiếng Anh của CTCH

Ở hai trường cốt lõi, điểm trung bình đạt 0,7264–0,7462 và trung vị đạt 0,7747–0,7767. Các đại lượng trung tâm gần nhau và trung vị xấp xỉ 0,78 cho thấy phần trung tâm của phân bố tương đồng tương đối ổn định. Điểm tiền sử thấp hơn vì trường này có nhiều câu rất ngắn và 1.980 trường hợp thuộc ba biến thể của phát biểu “chưa phát hiện/chưa ghi nhận bất thường”. Bản dịch đúng ý nghĩa nhưng chỉ nhận cosine similarity khoảng 0,41–0,47. Rà soát phần đuôi điểm thấp ghi nhận cả cảnh báo giả lẫn một số lỗi thuật ngữ cần sửa. Do đó, trung bình và trung vị cung cấp bằng chứng định lượng rằng bản dịch tiếng Anh nhìn chung giữ được ngữ nghĩa, đặc biệt ở lý do vào viện và diễn tiến bệnh, nhưng vẫn cần kiểm tra thủ công bởi người có chuyên môn.

Kiểm chứng liên kết, nhãn và tập chia

Khác với BTXRD, bệnh sử CTCH là dữ liệu được trích từ bệnh án nên không thể kiểm chứng bằng cách phát lại một ngân hàng mẫu câu. Phép kiểm tra phù hợp là đối chiếu khóa định danh giữa manifest, ảnh, văn bản và nhãn, xác nhận tính một-nóng của nhãn, đồng thời kiểm tra giao nhau theo người bệnh giữa các tập dữ liệu. Kết quả tính trực tiếp trên quần thể được manifest lựa chọn được trình bày trong Bảng A.11.

Phép kiểm tra	Kết quả
Định danh trong phân phối là duy nhất	3.249/3.249 (100%)
Định danh ngoài phân phối là duy nhất	18/18 (100%)
Giao nhau theo ảnh giữa quần thể trong và ngoài phân phối	0 mẫu
Giao nhau theo người bệnh giữa quần thể trong và ngoài phân phối	0 người bệnh
Mẫu được chọn có ảnh giải mã được	3.267/3.267 (100%)
Mẫu được chọn có đủ bệnh sử tiếng Việt và tiếng Anh	3.267/3.267 (100%)
Tập bệnh sử được liên kết có nội dung khác rỗng	6.534/6.534 (100%)
Nhãn trong phân phối có đúng một lớp trong 22 lớp	3.249/3.249 (100%)
<code>class_id</code> , tên lớp và cột một-nóng nhất quần	3.249/3.249 (100%)
Giao nhau theo người bệnh giữa <code>train/validate/test</code>	0/0/0
Quy mô <code>train/validate/test</code>	2.265/315/669

Bảng A.11: Kết quả kiểm chứng tính toàn vẹn của quần thể CTCH được sử dụng

Trong 3.267 bệnh sử tiếng Anh được liên kết, trường lý do vào viện và diễn tiến bệnh có nội dung ở toàn bộ mẫu, còn trường tiền sử có nội dung ở 2.930 mẫu (89,68%) và không có dữ liệu ở 337 mẫu. Hai con số tương ứng giống nhau ở nguồn tiếng Việt, nên tổng cộng có 5.860/6.534 tập (89,68%) chứa nội dung tiền sử. Việc thiếu tiền sử được giữ như trạng thái dữ liệu nguồn, không được nội suy bằng câu giả lập.

Phụ lục B

Cấu hình chi tiết của XBone-Net

Phụ lục này trình bày cấu hình chi tiết của phương pháp được mô tả trong Chương 3. Nội dung tập trung vào mô hình nền tảng, kích thước các biểu diễn, vị trí thích nghi hạng thấp, cấu hình dung hợp, đầu phân lớp và các tham số huấn luyện. Các quy tắc tiền xử lý ảnh và công thức tối ưu được giữ tại Chương 3 để tránh lặp lại phần mô tả phương pháp.

B.1 Mô hình nền tảng và chuẩn hóa đầu vào

XBone-Net sử dụng trọng số công bố của BiomedCLIP với định danh `hf-hub:microsoft/BiomedCLIP-PubMedBERT_256-vit_base_patch16_224` [42]. Định danh này xác định đồng thời bộ mã hóa thị giác ViT-B/16, bộ mã hóa văn bản PubMedBERT, hai lớp chiếu về không gian 512 chiều, bộ biến đổi ảnh và bộ tách đơn vị biểu diễn tương ứng. Trọng số nền của hai bộ mã hóa được nạp trước khi chèn LoRA và được giữ cố định trong cả hai giai đoạn huấn luyện.

Thành phần	Cấu hình	Vai trò
Ảnh đầu vào	Một ảnh 224×224	Là đầu vào duy nhất của bộ mã hóa thị giác, không sử dụng nhánh ảnh bổ sung.
Mảnh ảnh	Lưới 14×14 , mỗi mảnh 16×16	Tạo 196 đơn vị biểu diễn không gian và một đơn vị đại diện cho mỗi ảnh.
Văn bản	Tối đa 256 đơn vị biểu diễn	Chuỗi dài hơn bị cắt, chuỗi ngắn hơn được đệm và mặt nạ chú ý loại các vị trí đệm.
Văn bản khuyết	no clinical information available.	Là chuỗi thay thế cố định khi trường văn bản rỗng.
Chiều biểu diễn	$D = 512$	Là chiều chung của chuỗi ảnh, chuỗi văn bản, biểu diễn dung hợp và đầu phân lớp.

Bảng B.1: Cấu hình đầu vào và mô hình nền tảng của XBone-Net

Văn bản được đọc bằng mã hóa UTF-8, loại khoảng trắng ở hai đầu và chuyển về chữ thường trước khi tách đơn vị biểu diễn. Đối với CTCH, đầu vào gồm lý do vào viện, diễn tiến bệnh và tiền sử. Đối với BTXRD, đầu vào là văn bản tổng hợp đã được cố định trước khi huấn luyện. Bộ tách đơn vị biểu diễn và phép chuẩn hóa ảnh được lấy trực tiếp từ cùng định danh BiomedCLIP nhằm tránh sai khác giữa tiền huấn luyện và thích nghi trên dữ liệu đích.

B.2 Kích thước biểu diễn qua các thành phần

Gọi B là kích thước lô và K là số lớp. Cấu hình chính sử dụng $K = 22$ trên CTCH và $K = 10$ trên BTXRD. Bảng B.2 trình bày kích thước đầu ra tại các bước chính. Các kích thước này không phụ thuộc vào độ phân giải ban đầu vì ảnh đầu vào duy nhất được đưa về 224×224 trước khi mã hóa.

Vị trí	Kích thước	Diễn giải
Chuỗi của một ảnh sau ViT	$B \times 197 \times 512$	Một đơn vị đại diện và 196 đơn vị mảnh ảnh.
Chuỗi thị giác dùng cho dung hợp	$B \times 197 \times 512$	Chuỗi đầu ra gốc gồm một đơn vị đại diện và 196 đơn vị mảnh ảnh, không qua nhánh ảnh bổ sung hoặc bước gom trung gian.
Chuỗi văn bản	$B \times 256 \times 512$	Một đơn vị đại diện, các đơn vị nội dung và các vị trí đệm.
Biểu diễn ảnh nhận ngữ cảnh văn bản	$B \times 512$	Kết quả truy vấn văn bản bằng biểu diễn ảnh toàn cục.
Biểu diễn văn bản nhận ngữ cảnh ảnh	$B \times 512$	Kết quả truy vấn các đơn vị ảnh cục bộ bằng biểu diễn văn bản toàn cục.
Biểu diễn dung hợp	$B \times 512$	Đầu vào của đầu phân lớp tuyến tính và các điểm OOD hậu xử lý.
Logit phân lớp	$B \times K$	Điểm của từng lớp trước Softmax.

Bảng B.2: Kích thước các biểu diễn tại những bước chính của XBone-Net

Trong pha 1, mạng nền trả về biểu diễn toàn cục đã chuẩn hóa của ảnh và văn bản để tối ưu mục tiêu khớp ngữ nghĩa. Trong pha 2, mạng nền trả về trực tiếp chuỗi gồm đơn vị đại diện và các đơn vị nội dung của từng phương thức. Cấu hình chính truyền các chuỗi gốc này vào mô-đun dung hợp mà không tạo nhánh ảnh bổ sung hoặc gom các đơn vị ảnh qua một mô-đun trung gian.

B.3 Cấu hình thích nghi hạng thấp

LoRA [15] được chèn vào cả bộ mã hóa ảnh và bộ mã hóa văn bản. Cấu hình chung sử dụng hạng $r = 16$, hệ số tỷ lệ $\alpha = 32$ và tỷ lệ bỏ học 0,1. Các ma trận LoRA được cập nhật trong cả hai pha, còn các trọng số nền tương ứng không nhận gradient. Bảng B.3 liệt kê các phép chiếu tuyến tính được thích nghi.

Các tham số học được ngoài LoRA gồm các phép chiếu đầu vào, hai mô-đun chú ý chéo, mạng dung hợp cùng trọng số và độ lệch của đầu phân lớp tuyến tính. Tất cả các thành phần này được tối ưu trực tiếp trong pha 2 bằng lan truyền ngược.

Bộ mã hóa	Mô-đun đích	Ý nghĩa
Thị giác ViT-B/16	attn.qkv, attn.proj, mlp.fc1, mlp.fc2	Thích nghi các phép chiếu truy vấn–khóa–giá trị, đầu ra chú ý và hai lớp của mạng truyền thẳng trong mỗi khối thị giác.
Văn bản PubMedBERT	query, key, value, attention.output.dense, intermediate.dense, output.dense	Thích nghi các phép chiếu tự chú ý, đầu ra chú ý và hai phép chiếu của mạng truyền thẳng trong mỗi khối văn bản.

Bảng B.3: Các mô-đun tuyến tính được thích nghi bằng LoRA

B.4 Dung hợp và đầu phân lớp

Mô-đun dung hợp sử dụng chú ý chéo hai chiều với tám đầu chú ý, chiều ảnh 512 và tỷ lệ bỏ học 0,1. Ở chiều thứ nhất, biểu diễn ảnh toàn cục truy vấn các đơn vị văn bản không đậm. Ở chiều còn lại, biểu diễn văn bản toàn cục truy vấn 196 đơn vị mảnh ảnh từ chuỗi đầu ra gốc của BiomedCLIP. Hai kết quả được cộng thẳng dư với biểu diễn toàn cục tương ứng, chuẩn hóa lớp, nối với nhau và đưa qua mạng hai lớp để tạo biểu diễn dung hợp 512 chiều.

Thành phần	Giá trị	Ghi chú
Hướng chú ý	Hai chiều	Ảnh truy vấn văn bản và văn bản truy vấn ảnh dùng hai mô-đun độc lập.
Số đầu chú ý	8	Mỗi đầu có chiều $512/8 = 64$.
Tỷ lệ bỏ học	0,1	Áp dụng trong chú ý, nhánh thẳng dư và mạng dung hợp.
Mạng dung hợp	$1024 \rightarrow 512 \rightarrow 512$	Sử dụng GELU giữa hai lớp tuyến tính và chuẩn hóa đầu ra.
Đầu phân lớp	Tuyến tính $512 \rightarrow K$	Ánh xạ biểu diễn dung hợp thành K điểm số lớp.
Tham số đầu phân lớp	Trọng số và độ lệch	Được tối ưu cùng mô-đun dung hợp bằng lan truyền ngược trong pha 2.

Bảng B.4: Cấu hình mô-đun dung hợp và đầu phân lớp

B.5 Cấu hình huấn luyện

Hai pha sử dụng AdamW, lịch tốc độ học cosine, tỷ lệ khởi động 0,1, hệ số suy giảm trọng số 10^{-4} và kích thước lô 16. Huấn luyện sử dụng bfloat16 trên ba hạt giống 42, 123 và 456. Pha 1 lựa chọn trạng thái có mất mát xác thực thấp nhất, còn pha 2 lựa chọn trạng thái có Macro-F1 xác thực cao nhất. Tập kiểm thử không tham gia dừng sớm, lựa chọn trạng thái hoặc cập nhật tham số.

Thuộc tính	Pha 1	Pha 2	Diễn giải
Mục tiêu	Khớp ngữ nghĩa	Phân lớp tuyến tính	Pha 1 căn chỉnh ảnh-văn bản, pha 2 tối ưu biểu diễn dung hợp và biên quyết định cho lớp đích.
Tốc độ học	5×10^{-5}	10^{-4}	Áp dụng cho các tham số được phép cập nhật trong từng pha.
Số vòng tối đa	30	50	Đánh giá và lưu trạng thái sau mỗi vòng.
Dừng sớm	3 vòng	5 vòng	Dừng khi độ đo lựa chọn không cải thiện.
Độ đo lựa chọn	Mất mát xác thực	Macro-F1 xác thực	Chiều tối ưu lần lượt là giảm và tăng.
Đích mềm cùng lớp	$\rho = 0,50$	Không áp dụng	Giảm việc xem cặp khác mẫu nhưng cùng lớp là âm hoàn toàn.
Làm trơn nhãn	Không áp dụng	$\varepsilon = 0,1$	Giới hạn việc phân phối mục tiêu tập trung tuyệt đối vào một lớp.
Trọng số lớp	Không áp dụng	Số lượng hiệu dụng	Giới hạn trọng số lớn nhất bằng 5,0.

Bảng B.5: Cấu hình và tiêu chí lựa chọn trạng thái trong hai pha huấn luyện

Hai bộ dữ liệu khác nhau ở số lớp, với $K = 22$ trên CTCH và $K = 10$ trên BTXRD. Cả hai cấu hình chính đều dùng hệ số số lượng hiệu dụng mặc định $\beta = 0,999$. Các cấu hình còn lại trong Bảng B.5 được giữ giống nhau. Trong thiết lập ít mẫu, chỉ tập huấn luyện được lấy tối đa 1, 10 hoặc 20 mẫu trên mỗi lớp theo từng hạt giống. Tập xác thực và tập kiểm thử được giữ nguyên.

Phụ lục C

Kết quả chi tiết theo từng hạt giống

C.1 Phạm vi trình bày

Phụ lục này công bố các kết quả riêng của ba hạt giống ngẫu nhiên 42, 123 và 456 nhằm hỗ trợ cho các giá trị trung bình và độ lệch chuẩn được trình bày trong Chương 4. Sự thay đổi giữa các hạt giống được sử dụng để đánh giá độ nhạy của quy trình huấn luyện theo khởi tạo trên cùng một phép chia dữ liệu. Các giá trị này không được diễn giải như độ bất định do thay đổi tập dữ liệu.

Các kết quả gồm phân loại khi sử dụng toàn bộ dữ liệu, hai biến thể loại bỏ thành phần và đánh giá dữ liệu ngoài phân phối bằng hậu xử lý. Đây là các nội dung trong Chương 4 có đủ kết quả cho cả ba hạt giống và có thể đối chiếu trực tiếp với các bảng tổng hợp. Phép đo hiệu quả và đánh giá định lượng bằng tích phân gradient được thực hiện ở hạt giống 42 nên được trình bày trong chương chính mà không lặp lại thành bảng ba hạt giống.

C.1.1 Khả năng chuyển giao trực tiếp của các mô hình nền tảng

Kết quả phân loại không mẫu

Kết quả không mẫu được sử dụng để khảo sát mức độ phù hợp ban đầu của các mô hình nền tảng với hai bài toán đích trước khi thực hiện bất kỳ bước thích nghi nào. Bảng C.1 trình bày kết quả của CLIP [28], MedCLIP [38], PubMedCLIP [9] và BiomedCLIP [42] khi toàn bộ tham số được giữ cố định và mỗi lớp được biểu diễn bằng cùng một khuôn câu nhắc.

Dữ liệu	Mô hình	Acc $\uparrow$	BAcc $\uparrow$	Macro-F1 $\uparrow$	Macro-AUROC $\uparrow$	Macro-AUPRC $\uparrow$
BTXRD	CLIP	0.0560	0.1033	0.0189	0.6051	0.1532
	MedCLIP	0.0440	0.0991	0.0217	0.4594	0.1109
	PubMedCLIP	0.0733	0.1196	0.0613	0.5745	0.1303
	BiomedCLIP	0.1453	0.1261	0.0837	0.5912	0.1656
CTCH	CLIP	0.1868	0.2915	0.1532	0.8308	0.2220
	MedCLIP	0.0239	0.0455	0.0021	0.5074	0.0570
	PubMedCLIP	0.1943	0.2737	0.1607	0.8357	0.2297
	BiomedCLIP	0.2720	0.3898	0.2698	0.8976	0.3244

Bảng C.1: Kết quả phân loại zero-shot với một câu nhắc cho mỗi lớp trên BTXRD và CTCH; mỗi mô hình được đánh giá một lần tại hạt giống 42.

Trên BTXRD, BiomedCLIP đạt độ chính xác 0,1453, độ chính xác cân bằng 0,1261, điểm F1 trung bình theo lớp 0,0837 và Macro-AUPRC 0,1656, cao nhất trong bốn mô hình ở các độ đo này. Trong khi đó, Macro-AUROC cao nhất thuộc về CLIP với giá trị 0,6051. Độ chính xác cân bằng của các mô hình chỉ dao động từ 0,0991 đến 0,1261 và điểm F1 trung bình theo lớp không vượt quá 0,0837, cho thấy một câu nhắc chung chưa đủ để phân biệt ổn định các nhóm u xương có tên gọi và biểu hiện hình ảnh chuyên biệt. Việc CLIP đạt Macro-AUROC cao hơn nhưng có điểm F1 thấp hơn BiomedCLIP cũng cho thấy chất lượng xếp hạng chưa chuyển trực tiếp thành quyết định đa lớp phù hợp.

Trên CTCH, BiomedCLIP đạt kết quả cao nhất ở cả năm độ đo, gồm độ chính xác 0,2720, độ chính xác cân bằng 0,3898, điểm F1 trung bình theo lớp 0,2698, Macro-AUROC 0,8976 và Macro-AUPRC 0,3244. Tuy nhiên, khoảng cách lớn giữa Macro-AUROC và điểm F1 cho thấy biểu diễn tiền huấn luyện có khả năng sắp thứ tự mẫu tương đối tốt nhưng ranh giới

quyết định trực tiếp từ câu nhắc vẫn chưa phù hợp với không gian 22 lớp của CTCH.

Ý nghĩa đối với lựa chọn mô hình nền tảng

BiomedCLIP được lựa chọn làm mô hình nền tảng của XBone-Net dựa trên phạm vi tiền huấn luyện y sinh, kiến trúc hai bộ mã hóa và khả năng thích nghi bằng LoRA. Kết quả không mẫu được sử dụng để phân tích khả năng chuyển giao trực tiếp, không phải để lựa chọn mô hình dựa trên tập kiểm thử. Kết quả ở Bảng C.1 cho thấy biểu diễn của BiomedCLIP phù hợp tương đối với các khái niệm giải phẫu và bệnh lý xương, đặc biệt trên CTCH, nhưng không chứng minh rằng mô hình có thể được sử dụng trực tiếp cho bài toán đích. Vì vậy, các phần tiếp theo lần lượt khảo sát vai trò của văn bản đi kèm, hiệu quả của thích nghi miền, ảnh hưởng của từng thành phần và khả năng duy trì thông tin ảnh cục bộ.

C.1.2 Vai trò của ảnh và văn bản

Kết quả trên CTCH và BTXRD

Bảng C.2 so sánh cấu hình đa phương thức với hai cấu hình chỉ sử dụng một nguồn đầu vào. Các cấu hình sử dụng cùng tập chia và thiết lập tối ưu ở pha phân lớp. Tuy nhiên, các cấu hình đơn phương thức không thực hiện pha khớp ảnh–văn bản. Vì vậy, chênh lệch quan sát được phản ánh hiệu quả của toàn bộ thiết lập đa phương thức, không phải đóng góp biên thuần túy của riêng phương thức được bổ sung.

Bộ dữ liệu	Phương thức đầu vào	BAcc $\uparrow$	Macro-F1 $\uparrow$	Macro-AUROC $\uparrow$	Macro-AUPRC $\uparrow$
BTXRD	Ảnh và văn bản tổng hợp	0.5916 ± 0.0116	0.6010 ± 0.0034	0.9243 ± 0.0298	0.6301 ± 0.0211
	Chỉ ảnh	0.3167 ± 0.0191	0.3165 ± 0.0081	0.7756 ± 0.0179	0.3358 ± 0.0074
	Chỉ văn bản	0.5393 ± 0.0160	0.5315 ± 0.0121	0.9279 ± 0.0172	0.5721 ± 0.0096
	Ảnh và văn bản xáo trộn khác lớp	0.0078 ± 0.0016	0.0068 ± 0.0014	0.4124 ± 0.0644	0.0800 ± 0.0059
CTCH	Ảnh và bệnh sử lâm sàng	0.5844 ± 0.0454	0.5558 ± 0.0072	0.9473 ± 0.0246	0.6189 ± 0.0145
	Chỉ ảnh	0.4405 ± 0.0082	0.3984 ± 0.0176	0.9275 ± 0.0041	0.4177 ± 0.0075
	Chỉ văn bản	0.5401 ± 0.0149	0.4770 ± 0.0133	0.9393 ± 0.0020	0.5165 ± 0.0036
	Ảnh và bệnh sử xáo trộn khác lớp	0.3120 ± 0.0172	0.3039 ± 0.0048	0.8494 ± 0.0537	0.3098 ± 0.0264

Bảng C.2: So sánh giữa các phương thức đầu vào trên hai bộ dữ liệu BTXRD và CTCH

Trên CTCH, XBone-Net sử dụng đồng thời ảnh và bệnh sử đạt độ chính xác cân bằng $0,5844 \pm 0,0454$ và điểm F1 trung bình theo lớp $0,5558 \pm 0,0072$. Cấu hình chỉ ảnh đạt lần lượt $0,4405 \pm 0,0082$ và $0,3984 \pm 0,0176$, trong khi cấu hình chỉ bệnh sử đạt $0,5401 \pm 0,0149$ và $0,4770 \pm 0,0133$. Chênh lệch điểm F1 lần lượt là 0,1574 và 0,0788 điểm theo hướng có lợi cho thiết lập đa phương thức. Kết quả cho thấy toàn bộ thiết lập kết hợp ảnh và bệnh sử khai thác được thông tin bổ sung giữa hai nguồn, nhưng không tách riêng được ảnh hưởng của phương thức khỏi ảnh hưởng của pha khớp ảnh-văn bản.

Trên BTXRD, cấu hình ảnh kết hợp văn bản tổng hợp đạt điểm F1 trung bình theo lớp $0,6010 \pm 0,0034$, cao hơn cấu hình chỉ ảnh 0,2845 điểm và cao hơn cấu hình chỉ văn bản 0,0695 điểm. Kết quả cho thấy mô hình có thể khai thác quan hệ giữa ảnh và chuỗi văn bản trong thiết lập này. Tuy nhiên, văn bản BTXRD được sinh từ siêu dữ liệu và chịu ảnh hưởng của các cờ nhóm bệnh, do đó mức cải thiện không được diễn giải tương đương với lợi ích của bệnh sử lâm sàng tự nhiên trên CTCH.

Phân tích tính nhất quán ảnh-văn bản

Khi bệnh sử của mỗi mẫu CTCH được thay bằng bệnh sử của một mẫu thuộc lớp khác, điểm F1 trung bình theo lớp giảm từ $0,5558 \pm 0,0072$ xuống $0,3039 \pm 0,0048$. Trên BTXRD, điểm F1 giảm từ $0,6010 \pm 0,0034$ xuống $0,0068 \pm 0,0014$, đồng thời Macro-AUROC giảm từ $0,9243 \pm 0,0298$

xuống $0,4124 \pm 0,0644$. Phép can thiệp cho thấy mô hình nhảy với tính nhất quán của cặp ảnh–văn bản, thay vì chỉ hưởng lợi từ sự hiện diện độc lập của hai đầu vào.

Mức suy giảm trên BTXRD lớn hơn đáng kể so với CTCH vì phép ghép bắt buộc chọn văn bản khác lớp và văn bản tổng hợp mang tín hiệu liên hệ mạnh với nhãn. Do đó, kết quả BTXRD chỉ xác nhận độ nhảy của mô hình đối với quan hệ ghép cặp trong thiết lập văn bản có điều kiện theo siêu dữ liệu. Trên CTCH, sự suy giảm khi ghép sai cùng với kết quả đơn phương thức cho thấy mô hình sử dụng quan hệ ảnh–bệnh sử, nhưng chưa phải ước lượng đóng góp biên thuần túy của bệnh sử.

Tổng kết

Thiết lập đa phương thức có điểm F1 trung bình theo lớp quan sát được cao hơn các thiết lập đơn phương thức trên cả hai bộ dữ liệu, đồng thời phép ghép sai làm hiệu năng giảm rõ rệt. Do các đối chứng đơn phương thức không thực hiện pha khớp ảnh–văn bản và chưa có khoảng tin cậy ghép cặp kèm p-value cho phép so sánh này, kết quả chỉ cho thấy XBone-Net sử dụng quan hệ liên phương thức, không được dùng để khẳng định ưu thế thống kê của kiến trúc đa phương thức. CTCH là nguồn bằng chứng chính cho kịch bản bệnh sử thực, còn BTXRD chỉ phản ánh thiết lập văn bản tổng hợp có điều kiện.

C.2 Phân loại khi sử dụng toàn bộ dữ liệu huấn luyện

Bảng C.3 và Bảng C.4 trình bày năm độ đo phân loại của từng mô hình tại từng hạt giống. Việc giữ đồng thời Accuracy, Balanced Accuracy, Macro-F1, Macro-AUROC và Macro-AUPRC cho phép kiểm tra liệu thứ hạng trung bình trong Chương 4 có xuất hiện nhất quán hay phụ thuộc vào một lần khởi tạo cụ thể.

Bảng C.3: Kết quả phân loại của từng hạt giống trên BTRD

Mô hình	Hạt giống	Accuracy	BACC	Macro-F1	Macro-AUROC	Macro-AUPRC
BiomedCLIP	42	0,8320	0,5769	0,5870	0,8679	0,6395
BiomedCLIP	123	0,8280	0,6197	0,5993	0,8918	0,6542
BiomedCLIP	456	0,8333	0,6219	0,6118	0,8996	0,6595
CLIP	42	0,8200	0,5949	0,5722	0,9114	0,6342
CLIP	123	0,7720	0,5802	0,5574	0,8706	0,6192
CLIP	456	0,8187	0,6121	0,6064	0,9099	0,6219
DenseNet-121	42	0,6320	0,3644	0,3688	0,7916	0,3852
DenseNet-121	123	0,6333	0,3862	0,3904	0,7596	0,3790
DenseNet-121	456	0,6307	0,3575	0,3562	0,7639	0,3851
MedCLIP	42	0,8307	0,5860	0,5931	0,8221	0,6089
MedCLIP	123	0,8040	0,6204	0,6014	0,8736	0,6074
MedCLIP	456	0,8267	0,6310	0,6217	0,8838	0,6520
PubMedCLIP	42	0,7573	0,5716	0,5067	0,8856	0,5874
PubMedCLIP	123	0,7947	0,6163	0,5946	0,8970	0,6233
PubMedCLIP	456	0,8133	0,6388	0,6155	0,9317	0,6341
ResNet-50	42	0,6067	0,3031	0,3174	0,6947	0,3279
ResNet-50	123	0,6213	0,3253	0,3364	0,7447	0,3401
ResNet-50	456	0,5933	0,3278	0,3333	0,7313	0,3333
XBone-Net	42	0,8227	0,5960	0,6140	0,8201	0,5902
XBone-Net	123	0,8413	0,6230	0,6370	0,7883	0,5741
XBone-Net	456	0,8267	0,6155	0,6209	0,8052	0,5953

Bảng C.4: Kết quả phân loại của từng hạt giống trên CTCH

Mô hình	Hạt giống	Accuracy	BACC	Macro-F1	Macro-AUROC	Macro-AUPRC
BiomedCLIP	42	0,5904	0,6203	0,5520	0,9559	0,6248
BiomedCLIP	123	0,5755	0,6107	0,5472	0,9555	0,6188
BiomedCLIP	456	0,6248	0,5758	0,5628	0,9057	0,6071
CLIP	42	0,5725	0,6579	0,5727	0,9547	0,6270
CLIP	123	0,5785	0,6209	0,5547	0,9478	0,6196
CLIP	456	0,6114	0,5862	0,5624	0,8845	0,5542
DenseNet-121	42	0,4813	0,5348	0,4610	0,9404	0,4917
DenseNet-121	123	0,4873	0,4435	0,4134	0,9323	0,4667
DenseNet-121	456	0,4768	0,4999	0,4356	0,9325	0,4703
MedCLIP	42	0,5590	0,5811	0,5265	0,9354	0,5973
MedCLIP	123	0,5979	0,5503	0,5285	0,8835	0,5628
MedCLIP	456	0,5202	0,5838	0,4902	0,9456	0,5916
PubMedCLIP	42	0,5306	0,6108	0,5313	0,9350	0,6073
PubMedCLIP	123	0,5486	0,4912	0,4902	0,9038	0,5683

Còn tiếp ở trang sau

Bảng C.4 (tiếp theo)

Mô hình	Hạt giống	Accuracy	BAcc	Macro-F1	Macro-AUROC	Macro-AUPRC
PubMedCLIP	456	0,5770	0,5747	0,5395	0,9448	0,5907
ResNet-50	42	0,4918	0,4238	0,4131	0,9130	0,4489
ResNet-50	123	0,4948	0,4027	0,4029	0,9118	0,4452
ResNet-50	456	0,4918	0,4114	0,4076	0,9188	0,4536
XBone-Net	42	0,6024	0,5788	0,5589	0,8990	0,5839
XBone-Net	123	0,6114	0,5966	0,5645	0,8943	0,5719
XBone-Net	456	0,6413	0,6051	0,5948	0,9127	0,6153

Các hàng XBone-Net trong hai bảng dùng đúng cấu hình hiện tại với chiến lược `direct_resize`, huấn luyện LoRA hai pha, chú ý chéo hai chiều và đầu phân lớp tuyến tính. Số liệu theo từng hạt giống xác nhận kết luận của chương chính rằng XBone-Net có hiệu năng phân loại cạnh tranh nhưng không dẫn đầu đồng thời trên mọi độ đo và mọi bộ dữ liệu.

C.3 Nghiên cứu loại bỏ từng thành phần

Bảng C.5 trình bày kết quả của XBone-Net và hai biến thể được dùng trực tiếp để trả lời RQ2 tại từng hạt giống trên CTCH. Biến thể Chỉ pha 2 loại bỏ pha thích nghi tương phản, còn biến thể Nối đặc trưng thay chú ý chéo hai chiều bằng phép nối đặc trưng. Số liệu xác nhận rằng cấu hình đầy đủ đạt Accuracy trung bình cao nhất, trong khi Nối đặc trưng thuận lợi hơn ở Balanced Accuracy, Macro-AUROC và Macro-AUPRC. Vì vậy, không thành phần nào tạo ưu thế đồng thời trên toàn bộ độ đo.

Cấu hình	Hạt giống	Accuracy	B _{Acc}	Macro-F1	Macro-AUROC	Macro-AUPRC
XBone-Net	42	0,6024	0,5788	0,5589	0,8990	0,5839
XBone-Net	123	0,6114	0,5966	0,5645	0,8943	0,5719
XBone-Net	456	0,6413	0,6051	0,5948	0,9127	0,6153
Chỉ pha 2	42	0,6173	0,5611	0,5767	0,9200	0,6097
Chỉ pha 2	123	0,6188	0,5904	0,5815	0,9093	0,5975
Chỉ pha 2	456	0,5934	0,6067	0,5604	0,9352	0,6176
Nối đặc trưng	42	0,5605	0,6274	0,5529	0,9493	0,6204
Nối đặc trưng	123	0,5830	0,5990	0,5596	0,9291	0,6164
Nối đặc trưng	456	0,5904	0,6333	0,5741	0,9399	0,6236

Bảng C.5: Kết quả phân loại của từng hạt giống trong nghiên cứu loại bỏ thành phần trên CTCH. Cấu hình đầy đủ được tô xám.

C.4 Kết quả đánh giá dữ liệu ngoài phân phối

Bảng C.6 công bố kết quả theo từng hạt giống của XBone-Net và hai biến thể trên kịch bản OOD ngữ nghĩa và BTXRD. Cả ba cấu hình sử dụng cùng điểm tổ hợp đa phương thức hậu xử lý. Số mẫu trong phân phối và ngoài phân phối được ghi trực tiếp trong bảng vì AUPR-Out và FPR@95%TPR chịu ảnh hưởng bởi số lượng và tỷ lệ mẫu của từng kịch bản.

Mỗi lần đánh giá sử dụng 669 mẫu CTCH trong phân phối. Kịch bản OOD ngữ nghĩa sử dụng đủ 18 mẫu đã được xác nhận trong danh sách đánh giá và kịch bản BTXRD sử dụng đủ 750 mẫu ngoài phân phối. AUPR-Out và FPR@95%TPR chịu ảnh hưởng của chênh lệch quy mô và tỷ lệ mẫu trong-ngoài phân phối giữa hai kịch bản, vì vậy kết luận được đưa ra cùng AUROC-ODD và cỡ mẫu ghi trong bảng. Kết quả xác nhận cảnh báo OOD có hiệu lực rõ hơn trong dịch chuyển khác bộ dữ liệu, còn kịch bản OOD ngữ nghĩa gần miền vẫn có FPR@95%TPR cao.

Kịch bản	Cấu hình	Hạt giống	N_{ID}	N_{OOD}	AUROC- OOD	AUPR- Out	FPR@ 95%TPR
OOD CTCH	XBone-Net	42	669	18	0,7736	0,1521	0,6667
	XBone-Net	123	669	18	0,7713	0,1365	0,6667
	XBone-Net	456	669	18	0,7346	0,1533	0,5556
	BioMedCLIP (FFT)	42	669	18	0,7574	0,1679	0,5000
	BioMedCLIP (FFT)	123	669	18	0,7503	0,1385	0,7222
	BioMedCLIP (FFT)	456	669	18	0,6440	0,1051	0,7222
	Chỉ pha 2	42	669	18	0,7922	0,2194	0,5556
	Chỉ pha 2	123	669	18	0,7951	0,2310	0,6667
	Chỉ pha 2	456	669	18	0,7333	0,2086	0,7778
	Nối đặc trưng	42	669	18	0,7139	0,1103	0,6111
	Nối đặc trưng	123	669	18	0,7015	0,1167	0,6667
	Nối đặc trưng	456	669	18	0,7404	0,0894	0,6667

Bảng C.6: Kết quả cảnh báo OOD của từng hạt giống trên kịch bản OOD CTCH bằng điểm tổ hợp đa phương thức

Kịch bản	Cấu hình	Hạt giống	N_{ID}	N_{OOD}	AUROC- OOD	AUPR- Out	FPR@ 95%TPR
BTXRD	XBone-Net	42	669	750	0,9142	0,8873	0,4773
	XBone-Net	123	669	750	0,9490	0,9214	0,2520
	XBone-Net	456	669	750	0,9330	0,9069	0,3520
	BioMedCLIP (FFT)	42	669	750	0,9972	0,9960	0,0013
	BioMedCLIP (FFT)	123	669	750	0,9934	0,9923	0,0013
	BioMedCLIP (FFT)	456	669	750	0,9660	0,9490	0,2280
	Chỉ pha 2	42	669	750	0,9406	0,9107	0,3573
	Chỉ pha 2	123	669	750	0,9424	0,9242	0,2973
	Chỉ pha 2	456	669	750	0,9219	0,8893	0,5227
	Nối đặc trưng	42	669	750	0,9202	0,8955	0,4400
	Nối đặc trưng	123	669	750	0,9320	0,9005	0,5360
	Nối đặc trưng	456	669	750	0,9268	0,8964	0,4120

Bảng C.7: Kết quả cảnh báo OOD của từng hạt giống trên kịch bản BTXRD bằng điểm tổ hợp đa phương thức