

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - Nguyễn Gia
Kiệt

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - 22127390

Nguyễn Gia Kiệt - 22127221

**PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

GIÁO VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

Tp. Hồ Chí Minh, tháng 07/2026

Lời cam đoan

Nhóm xin cam đoan đây là công trình nghiên cứu của riêng nhóm. Dữ liệu và kết quả nghiên cứu trong luận văn này là trung thực và không trùng lặp với bất kỳ chủ đề nào khác. Nhóm cam đoan toàn bộ nội dung luận văn này không đạo văn hoặc sao chép từ các công trình nghiên cứu khác. Ngoài ra, trong quá trình nghiên cứu và viết luận văn, nhóm tuân thủ nghiêm ngặt các quy định về bảo mật do các tập dữ liệu nhóm sử dụng trong nghiên cứu của mình cung cấp. Hơn nữa, nhóm luôn tuân thủ mọi nguyên tắc đạo đức trong suốt quá trình nghiên cứu. Nhóm đảm bảo rằng tất cả các nguồn và tài liệu tham khảo đều được trích dẫn đúng cách và nhóm duy trì tính chính trực học thuật trong mọi khía cạnh công việc của mình.

Lời cảm ơn

Nhóm xin chân thành cảm ơn PGS.TS Lý Quốc Ngọc và ThS. Đỗ Thị Thanh Hà đã dành rất nhiều thời gian, tâm huyết để định hướng, tận tình hướng dẫn và đưa ra những lời khuyên quý báu cho nhóm trong suốt quá trình nghiên cứu và thực hiện khóa luận tốt nghiệp với đề tài "Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức".

Xin trân trọng gửi lời cảm ơn sâu sắc đến Ban Chủ nhiệm cùng toàn thể quý thầy cô Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG-HCM. Những kiến thức nền tảng vững chắc mà các thầy cô đã truyền đạt trong bốn năm học vừa qua và môi trường thí nghiệm tuyệt vời chính là hành trang quan trọng nhất giúp nhóm có thể hoàn thành tốt hướng nghiên cứu này.

Nhóm cũng xin gửi lời cảm ơn đến các y bác sĩ tại Bệnh viện Chấn thương Chỉnh hình TP.HCM, thầy Đỗ Phúc Thịnh và thầy Võ Thế Hào đã hỗ trợ chia sẻ nguồn dữ liệu ảnh X-quang cũng như tư vấn các kiến thức chuyên môn về y khoa, giúp mô hình nghiên cứu bám sát với quy trình chẩn đoán thực tế.

Mặc dù đã có nhiều cố gắng trong quá trình thực hiện, nhưng do hạn chế về mặt thời gian và kinh nghiệm nghiên cứu, khóa luận chắc chắn không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô và hội đồng đánh giá để đề tài được hoàn thiện hơn.

Xin chân thành cảm ơn!



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO HỌC SÂU ĐA PHƯƠNG THỨC

*(Developing a bone X-ray image classification
system based on multimodal deep learning)*

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm Sinh viên thực hiện:

1. Nguyễn Văn Lê Bá Thành (MSSV: 22127390)
2. Nguyễn Gia Kiệt (MSSV: 22127221)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 02/2026 đến 08/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn đầu. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, các nghiên cứu hiện nay đã ứng dụng các mô hình học sâu vào để giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ để đưa vào ứng dụng thực tế. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để bổ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác. Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống.

Khác với các mô hình đơn phương thức chỉ xử lý trên một phương thức như ảnh hay văn bản duy nhất, các mô hình đa phương thức có thể sử dụng nhiều phương thức và tìm ra sự tương quan giữa các phương thức nhằm tạo nên biểu diễn có ý nghĩa hơn từ đó nâng cao hiệu năng của hệ thống. Với thực tế lâm sàng hiện nay, các mô hình nghiên cứu tập trung

vào kết hợp ngôn ngữ và hình ảnh hay còn được gọi là mô hình ngôn ngữ trực quan đang là các mô hình đang nhận được nhiều sự chú ý.

2.2 Định nghĩa các khái niệm

Thông tin lâm sàng

Thông tin lâm sàng là những dữ liệu thu thập trực tiếp qua quá trình bác sĩ thăm khám người bệnh, bao gồm việc khai thác bệnh sử và khám thực thể (nhìn, sờ, gõ, nghe) [44]. Dữ liệu này mang tính chất định hướng ban đầu, giúp bác sĩ khoanh vùng tổn thương và đưa ra các quyết định chỉ định thăm khám chuyên sâu tiếp theo [4].

Thông tin cận lâm sàng

Thông tin cận lâm sàng là các dữ liệu khách quan thu được từ việc áp dụng các trang thiết bị và kỹ thuật y khoa hiện đại (như hình ảnh X-quang, cắt lớp, hay xét nghiệm sinh hóa) [44]. Nếu lâm sàng dùng để định hướng, thì cận lâm sàng cung cấp bằng chứng xác thực từ bên trong cơ thể để chẩn đoán chính xác bệnh lý.

2.3 Phát biểu bài toán

Đầu vào (Input)

Hệ thống nhận vào các nguồn dữ liệu sau:

- Thông tin lâm sàng bao gồm báo cáo cận lâm sàng, khám xét toàn thân, lý do vào viện của bệnh nhân.
- Ảnh X-quang xương của bệnh nhân tương ứng.
- Tập nhãn được định nghĩa trước.


Đầu ra (Output)

Hệ thống sẽ sinh ra các nhãn sau:

- Tỷ lệ mà ảnh và thông tin lâm sàng tương ứng thuộc vào các lớp được định nghĩa trước.
- Ảnh trực quan hóa giải thích cho kết quả.

Kiến trúc tổng quan

Với bài toán này, kiến trúc tổng quan của một mô hình học sâu đa phương thức được sử dụng bao gồm bốn thành phần chính: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại như được thể hiện ở Hình 1.



Hình 1: Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức

Trong đó, bộ mã hóa ảnh có chức năng rút trích đặc trưng từ ảnh đầu vào, bộ mã hóa văn bản có chức năng rút trích đặc trưng từ văn bản đầu vào, bộ dung hợp dữ liệu có chức năng dung hợp hay căn chỉnh các đặc trưng được rút trích từ hai phương thức dữ liệu trên để tạo ra một biểu diễn có ý nghĩa và có đầy đủ tính chất của phương thức đầu vào, đây cũng là mô-đun quan trọng nhất đối với một mô hình học sâu đa phương thức, cuối cùng là bộ phân loại, nhận biểu diễn đặc trưng chung của các phương thức đầu vào để phân loại và đưa ra kết quả cuối cùng.

2.4 Mục tiêu đề tài

Trong bối cảnh già hóa dân số và các tác nhân gây bệnh từ ô nhiễm và lối sống thiếu lành mạnh trong đời sống hiện đại, các bệnh lý về xương và chấn thương có thể ảnh hưởng trực tiếp đến đời sống và tính mạng dẫn đến việc chẩn đoán và tiên lượng để đưa ra hướng điều trị phù hợp đang trở thành gánh nặng cho các y bác sĩ, các hệ thống học sâu đa phương

thức tuy đã phát triển nhưng lại thiếu khả năng giải thích. Đề tài hướng đến phát triển một hệ thống phân loại ảnh X-quang có khả năng:

- Đạt được độ chính xác cao trên các bộ dữ liệu nội bộ và quốc tế.
- Có khả năng giải thích được kết quả.
- Tích hợp kết quả để trợ giúp y bác sĩ trong quá trình chẩn đoán.

2.5 Phạm vi của đề tài

Nội dung nghiên cứu của đề tài tập trung vào việc khảo sát các mô hình nền tảng và thiết kế, huấn luyện, tinh chỉnh, đánh giá kiến trúc được đề xuất trên ảnh X-quang xương và các bộ dữ liệu quốc tế để so sánh, đánh giá với các kiến trúc trước.

Đối tượng nghiên cứu xoay quanh các thành phần bên trong một mạng học sâu đa phương thức bao gồm: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại, tập trung vào các phương pháp dung hợp dữ liệu hình ảnh và văn bản cùng với các phương pháp tinh chỉnh tham số cho các bộ mã hóa đã được huấn luyện trước nhằm tận dụng lại các tri thức đã có và nâng cao hiệu năng trên các tác vụ đích.

Đề tài chủ yếu sử dụng các bộ dữ liệu cặp ảnh - văn bản, không có trường hợp thiếu đã được công bố và bộ dữ liệu nội bộ được thu thập và cung cấp bởi giảng viên có hợp tác với bệnh viện ở khu vực Thành phố Hồ Chí Minh, một số thông tin cơ bản về các bộ dữ liệu được thể hiện ở Bảng 1. Nhóm sử dụng các bộ dữ liệu này nhằm đánh giá hiệu năng của kiến trúc đề xuất thông qua các độ đo phổ biến và tiến hành so sánh với các phương pháp trước đó nhằm chứng minh sự hiệu quả của phương pháp đề xuất.

2.6 Cách tiếp cận dự kiến

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ cung cấp tổng quan tình hình nghiên cứu

Bộ dữ liệu	Nguồn	Loại dữ liệu	Số lượng mẫu	Số lượng lớp
RSNA Pneumonia (2018)	Radiological Society of North America	Ảnh X-quang ngực metadata/tags	30,000	3
CheXpert (2019)	Stanford ML Group - Stanford Hospital	Ảnh X-quang ngực Báo cáo đọc ảnh	224,316	14
MIMIC-CXR v2 (2019)	Beth Israel Deaconess Medical Center	Ảnh X-quang ngực Báo cáo đọc ảnh	227,835	14
SARCOMA-CTCH (2025)	Bệnh viện Chấn Thương Chỉnh Hình - TPHCM	Ảnh X-quang xương Báo cáo đọc ảnh Báo cáo lâm sàng	Đang cập nhật	Đang cập nhật

Bảng 1: Tổng hợp các bộ dữ liệu dự kiến được sử dụng để thí nghiệm

từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

Các mô hình xây dựng từ đầu là các mô hình đơn giản, khởi điểm trong bài toán học sâu đa phương thức, thiết kế và huấn luyện một hệ thống mới từ đầu, điểm chung của các phương pháp này là chúng tập trung vào việc thiết kế các cơ chế để "trộn" (fusion) đặc trưng từ các bộ mã hóa (encoder) chuyên biệt ở các cấp độ khác nhau để tối ưu hóa hiệu suất cho các tác vụ cụ thể, sử dụng những bộ mã hóa hình ảnh đơn giản như CNN.

Khởi điểm vào 2020, X. Mei [29] và đồng nghiệp đã đề xuất lấy đặc trưng được tạo ra từ các lớp cuối của mô hình CNN (véc-tơ 512 chiều) và các đặc trưng từ dữ liệu lâm sàng rồi nối lại. Véc-tơ kết hợp này được đưa vào một mạng MLP cuối cùng để đưa ra dự đoán.

Clinical-BERT [46] và TGANet [39] tìm cách học biểu diễn đa phương thức bằng cách thúc đẩy mô hình hiểu và liên kết (align) các đặc trưng giữa các vùng trong ảnh và các từ khóa trong văn bản báo cáo thông qua các nhiệm vụ tự giám sát (self-supervised objectives), cho phép mô hình học được các biểu diễn ngữ nghĩa chung. Hay LViT [25] đề xuất một kiến trúc hybrid CNN-Transformer "Double-U", cấu trúc CNN-Transformer kết hợp mô-đun Pixel-Level Attention Module để giữ lại các đặc trưng cục bộ của ảnh giúp mô hình giữ được khả năng trích xuất đặc trưng cục bộ mạnh mẽ của CNN, đồng thời tận dụng khả năng mô hình hóa ngữ cảnh toàn cục của Transformer.

Việc chỉ nối các đặc trưng có điểm yếu về sự khác biệt về giá trị hoặc sự ngữ nghĩa lớn giữa các phương thức dữ liệu, IRENE [56] đã đưa tất

cả dữ liệu gốc về dạng token chung và học biểu diễn tổng thể (holistic representation) ngay từ đầu, sử dụng một mô hình Transformer duy nhất học các biểu diễn toàn diện cho cả hai phương thức. IRENE còn sử dụng cơ chế chú ý hai chiều ở cấp độ token để nắm bắt "các kết nối cục bộ".

Nghiên cứu của Dai và cộng sự [8] đề xuất mô hình TransMed, giải quyết bài toán kết hợp đa phương thức bằng cách tích hợp CNN và Transformer. Bằng việc chuyển đổi đặc trưng ảnh từ CNN thành dạng chuỗi để Transformer xử lý, mô hình này tối ưu hóa việc nắm bắt các đặc điểm toàn cục của hình ảnh y khoa. Cách tiếp cận này mang lại hiệu quả cao hơn các kỹ thuật fusion thông thường nhờ khả năng biểu diễn dữ liệu đa phương thức một cách toàn diện và chính xác.

Những nghiên cứu này đã khai phá và chứng minh về tác động tích cực của các phương thức dữ liệu khác như văn bản đến kết quả của việc chẩn đoán hình ảnh, tuy nhiên độ chính xác của các phương thức này còn chưa quá cao bởi các bộ mã hóa và phương pháp dung hợp dữ liệu còn đơn giản.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Kiến trúc mô hình			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	X. Mei [29]	Full Fine-Tuning	Pretrain với Cross-Entropy loss	Inception-ResNet-v2	ResNet-18	Decision-level	N/a
2	Clinical-BERT [46]	Full Fine-Tuning	Cross-modal Repr. Learning	DenseNet121	Uncased BERT-base	Early fusion	N/a
3	LViT [25]	Full Fine-Tuning	Semi-supervised (Pseudo-label)	Hybrid U-shape (CNN + ViT)	BERT_12_768_12	Intermediate	N/a
4	TGANet [39]	Train from scratch	Exponential Pseudo-label Iteration	ResNet50	Không có	Intermediate	N/a
5	IRENE [56]	Train from scratch	BCE Loss & AdamW optimizer	Convolution layer	Pretrained BERT	Simultaneous	Upsampling, FEM, CBAM Attention
6	TransMed [8]	Full Fine-Tuning	Supervised (SGD, 100 epochs)	2D CNN (ResNet18 đến 152)	N/a	Attention fusion	Lớp kết nối đầy đủ (FC Layer)

Bảng 2: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tinh chỉnh của các mô hình kết hợp ngôn ngữ - ảnh

Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu (thường cố gắng dung hợp dữ liệu thô thành một khối thống nhất), Med-VLMs chú trọng vào việc đối chiếu và liên kết chặt chẽ ngữ nghĩa giữa hình ảnh và ngôn ngữ tự nhiên. Cụ thể, kiến trúc của chúng thường kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này khớp với

nhau. Lúc này, bộ phân loại không gán nhãn theo cách truyền thống mà đóng vai trò là một cơ chế đo lường mức độ tương đồng. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Để đạt được khả năng trên, các nghiên cứu tiền huấn luyện Med-VLMs hiện nay đang phát triển chủ yếu theo ba hướng: học tương phản, học có che giấu và tích hợp tri thức y khoa (chi tiết tổng hợp được trình bày tại các Bảng 3, 2.1, 5).

Thứ nhất, **học tương phản (Contrastive Learning)** là chiến lược được ứng dụng rộng rãi nhất, tiêu biểu với các mô hình như ConVIRT [52], GLoRIA [16], MedCLIP [43] và BiomedCLIP [50]. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau ở mức độ cục bộ lẫn toàn cục. Phương pháp này đem lại hiệu năng ấn tượng; ví dụ, BiomedCLIP [50] (huấn luyện trên 15 triệu cặp dữ liệu) đạt độ chính xác phân loại 83%, trong khi ConVIRT [52] đạt 90,3% trên bộ dữ liệu COVIDx. Mặc dù có ưu điểm vượt trội là khả năng học biểu diễn không cần gán nhãn thủ công, học tương phản vẫn bộc lộ hạn chế về việc tiêu tốn tài nguyên tính toán lớn và rủi ro xảy ra hiện tượng âm tính giả (đẩy xa các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý).

Thứ hai, **học có che giấu (Masked Learning)** là hướng đi tập trung vào mục tiêu tái tạo dữ liệu, với các đại diện nổi bật như MRM [57] và MedViLL [31]. Bằng cách ẩn ngẫu nhiên các vùng ảnh hoặc từ ngữ trong báo cáo y khoa, kiến trúc này buộc mô hình phải dự đoán và khôi phục phần thông tin bị khuyết. Hướng tiếp cận này thể hiện ưu thế rõ rệt trong các môi trường khan hiếm dữ liệu; điển hình là MRM [57] đạt mức 92,7% AUC chỉ với 10% dữ liệu từ tập RSNA. Tuy nhiên, rào cản chính của phương pháp này nằm ở việc phụ thuộc vào nguồn dữ liệu đã được ghép cặp sẵn từ trước, cộng với độ phức tạp tính toán cao của quá trình khôi phục điểm ảnh/token.

Thứ ba, **tích hợp tri thức y khoa (Knowledge Integration)** ra đời nhằm giải quyết những đặc thù phức tạp của ngôn ngữ lâm sàng. Các

mô hình như MedKLIP [45], BioViL [5], BioViL-T [3] và KAD [51] tận dụng đồ thị tri thức (như RadGraph) hoặc dữ liệu chuỗi thời gian để cung cấp tín hiệu giám sát chi tiết về cả loại và vị trí bệnh lý. Cách tiếp cận này giúp giải quyết triệt để sự mơ hồ của các từ vựng diễn tả tiến triển bệnh (ví dụ: "cải thiện", "xấu đi"). Về mặt hiệu năng, KAD [51] đạt 0.966 AUC trên tập PadChest ở thiết lập không mẫu (zero-shot), còn BioViL-T [3] đạt độ chính xác 67,4% trong bài toán phân loại tiến triển bệnh. Dù vậy, các phương pháp này chưa loại bỏ hoàn toàn được hiện tượng âm tính giả và rất dễ gặp sai số nếu nhãn chẩn đoán thực tế nằm ngoài cơ sở tri thức đồ thị gốc.

Dựa trên sự phân tích các ưu và nhược điểm từ những khảo sát trên, hướng tiếp cận đề xuất trong nghiên cứu này được thiết kế có chọn lọc nhằm tối ưu hóa hiệu năng và chi phí:

- **Kế thừa BiomedCLIP [50]:** Tận dụng sức mạnh của các bộ mã hóa đã được huấn luyện với chất lượng cao.
- **Không áp dụng học tương phản & học có che giấu:** Khó khắc phục rào cản về tài nguyên tính toán lớn và giảm thiểu rủi ro gặp phải hiện tượng âm tính giả.
- **Tích hợp tri thức từ UMLS (tương tự MedKLIP [45]):** Sử dụng để làm giàu thêm tri thức trong các báo cáo lâm sàng.

Mặc dù các phương pháp tiền huấn luyện Med-VLMs giúp xây dựng nền tảng tri thức đa phương thức khổng lồ, việc áp dụng trực tiếp vào lâm sàng lại vấp phải rào cản lớn về chi phí tính toán và sự khan hiếm dữ liệu y tế ghép cặp. Để giải quyết vấn đề này, các nghiên cứu thường chuyển hướng sang tinh chỉnh mô hình. Tuy nhiên, nếu tinh chỉnh toàn phần trên một tập dữ liệu nhỏ, sự chênh lệch phân phối sẽ dễ dẫn đến hiện tượng chuyển giao tiêu cực hoặc "quên thảm khốc", làm đánh mất tri thức gốc. Do đó, giới nghiên cứu đang tập trung vào các chiến lược tinh chỉnh hiệu quả tham số (PEFT) nhằm đảm bảo tính linh hoạt, tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các nghiên cứu gần đây được chia thành ba hướng tiếp cận chính:

STT	Tên phương pháp	Phân loại	Nguyên lý
1	ConVIRT (2020)	Học tương phản	Tối ưu bộ mã hoá ảnh và văn bản bằng cách kéo các cặp đặc trưng ảnh-văn bản giống nhau lại gần nhau và đẩy các cặp đặc trưng ảnh-văn bản khác nhau ra xa
2	GLoRIA (2021)	Học tương phản	Dùng hai hàm mất mát global contrastive để kéo các cặp đặc trưng ảnh-văn bản, trong khi đó hàm mất mát local contrastive học cách căn chỉnh chi tiết của các vùng trong ảnh và các từ trong câu
3	MedCLIP (2022)	Học tương phản	Đề xuất cơ chế tách cặp và trích xuất tri thức, và đề xuất hàm mất mát Semantic Matching nhằm giải quyết vấn đề false negative
4	BiomedCLIP (2023)	Học tương phản	Có cơ chế tương tự như CLIP nhưng được tiền huấn luyện với bộ dữ liệu PMC-15M
5	MRM (2023)	Học có che giấu	Ẩn ngẫu nhiên các thông tin trong văn bản và các vùng trong ảnh để cho mô hình dự đoán lại ảnh và văn bản hoàn chỉnh.
6	MedViLL (2022)	Học có che giấu	Đề xuất một kiến trúc dựa trên BERT kết hợp với một mặt nạ chú ý mới được đề xuất (BAR) cho phép ảnh tương tác tự do với văn bản trong các tác vụ hiểu, đồng thời đảm bảo tính tự hồi quy cho các token trong văn bản trong các tác vụ sinh
7	BioViL (2022)	Tích hợp kiến thức y khoa	Đề xuất một bộ mã hoá văn bản CXR-BERT được tối ưu cho ảnh X-quang, duy trì hàm mất mát MLM để giúp mô hình giữ lại được các kiến thức văn bản trong quá trình căn chỉnh với ảnh
8	BioViL-T (2023)	Tích hợp kiến thức y khoa	Sử dụng các ảnh X-quang từ trước kết hợp với ảnh hiện tại để học được các đặc trưng không gian, thời gian từ đó giải thích cho các từ vựng như "cải thiện" giúp giảm đi sự mơ hồ trong báo cáo
9	MedKLIP (2023)	Tích hợp kiến thức y khoa	Đề xuất một mô-đun trích xuất bộ ba và cơ chế mã hoá tăng cường tri thức, từ đó tạo ra biểu diễn tốt hơn cho văn bản
10	KAD (2023)	Tích hợp kiến thức y khoa	Tích hợp kiến thức y khoa vào quá trình tiền huấn luyện để giúp mô hình học các biểu diễn có ý nghĩa hơn

Bảng 3: Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Mục tiêu tiền huấn luyện	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	CL	GCL	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	CL	LCL, GCL	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	CL	GCL	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	CL	GCL	ViT-Base	PubMedBERT	Contrastive Alignment	N/a
5	MRM (2023)	MP	MIM, MLM	Kiến trúc giống ViT	WordPiece	Global Context Injection	Văn bản: Transformer; Hình ảnh: Fully Connected
6	MedViLL (2022)	HA	MLM, ITM	ResNet50	BERT	Cross-modal Self-Attention	Multi-Layer Perceptron
7	BioViL (2022)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
8	BioViL-T (2023)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
9	MedKLIP (2023)	CL	LCL	ResNet50	ClinicalBERT	Knowledge-enhanced Alignment	Contrastive head, Cross-Entropy head
10	KAD (2023)	HA	CL, Disease Diagnosis Prediction	ResNet50, ViT-Base	PubMedBERT	Contrastive Alignment	Disease Query Network

Bảng 4: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;

STT	Tên phương pháp	Bộ dữ liệu tiền huấn luyện	Hiệu năng			
			Tác vụ	Bộ dữ liệu đánh giá	Độ đo	Kết quả
1	ConVIRT (2020)	MIMIC-CXR, Private Bone image	- Phân loại ảnh - Phân loại ít mẫu	RSNA Pneumonia, CheXpert, COVIDx, MURA	AUC, Accuracy	- Phân loại ít mẫu: RSNA (1%): 88.8% AUC, (10%): 91.5% AUC; CheXpert (1%): 87.0% AUC, (10%): 88.1% AUC; MURA (1%): 81.3% AUC, (10%): 86.5% AUC - Phân loại ảnh: RSNA: 92.7% AUC, CheXpert: 88.1% AUC, MURA: 89.0% AUC; COVIDx 90.3% ACC
2	GLoRIA (2021)	CheXpert	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	CheXpert, RSNA Pneumonia	AUROC	- Phân loại không mẫu: CheXpert 5x200: 0.61 ACC, 0.67 F1; RSNA: 0.70 ACC, 0.58 F1; - Phân loại ít mẫu: CheXpert (1%): 86.6 AUC, (10%): 87.8 AUC, RSNA (1%): 86.1 AUC, (10%): 88.0 AUC - Phân loại ảnh: CheXpert: 88.1 AUC, RSNA: 88.6 AUC
3	MedCLIP (2022)	MIMIC-CXR, CheXpert	- Phân loại ảnh - Phân loại không mẫu	MIMIC-5x200, COVID, RSNA Pneumonia	Mean Accuracy	- Phân loại không mẫu: CheXpert-5x200: 0.5942 ACC; MIMIC-5x200: 0.5430 ACC; COVID: 0.8472 ACC; RSNA: 0.7682 ACC - Phân loại ảnh: CheXpert-5x200: 0.5960 ACC; MIMIC-5x200: 0.5650 ACC; COVID: 0.7890 ACC; RSNA: 0.8075 ACC
4	BiomedCLIP (2023)	PMC-15M	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PCam, LC25000 (Lung, Colon), TCGA-TIL, RSNA Pneumonia	AUC, Accuracy	- Phân loại không mẫu: PCam: 73.41% ACC; LC25000 Lung 65.23% ACC; LC25000 Colon 92.98%; RSNA 78.95%; TCGA-TIL: 67.04% - Phân loại ít mẫu: PCam (1%): 82% ACC, (10%): 83%; RSNA (1%): 77% ACC, (10%): 82% ACC - Phân loại ảnh: PCam: 83% ACC, RSNA: 83% ACC
5	MRM (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu	CheXpert, NIH ChestX-ray, RSNA Pneumonia, COVID-19 Image Data Collection	AUC, Accuracy	- Phân loại ít mẫu: CheXpert (1%): 88.5 AUC, (10%): 88.5 AUC; RSNA (1%): 91.3 AUC, (10%): 92.7 AUC; NIH ChestX-ray (1%): 79.4 AUC, (10%): 84.0 AUC - Phân loại ảnh: CheXpert: 88.7 AUC, RSNA 93.3, NIH ChestX-ray: 85.9, COVID-19: 85.8
6	MedViLL (2022)	MIMIC-CXR	- Phân loại chẩn đoán	MIMIC-CXR, Open-I	Micro-averaged AUROC, Micro-averaged F1 score	- Phân loại ảnh: MIMIC-CXR: 0.980 avg AUROC, 0.839 F1; Open-I: 0.892 avg AUROC, 0.407 F1
7	BioViL (2022)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	RSNA Pneumonia	Accuracy, F1-score, AUROC, Sensitivity Specificity.	- Phân loại không mẫu: RSNA: 0.732 ACC, 0.831 AUC; ChestX-ray14: 0.6912 AUC - Phân loại ít mẫu: RSNA (1%): 0.805 ACC, 0.881 AUC; (10%): 0.812 ACC, 0.884 AUC - Phân loại ảnh: RSNA: 0.822 ACC, 0.891 AUC
8	BioViL-T (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu - Phân loại ảnh tiến triển	MS-CXR-T, RSNA Penumonia, Chest ImaGenome	Macro-Accuracy, Accuracy, F1, AUROC.	- Phân loại Tiến triển: MS-CXR-T: 67.4% Acc - Phân loại không mẫu: RSNA: 0.805 ACC, 0.871 AUC - Phân loại ít mẫu: RSNA (1%): 0.814 ACC, 0.890 AUC
9	MedKLIP (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại không mẫu	ChestX-ray14, RSNA Pneumonia, SIIM-ACR Pneumothorax, COVIDx CXR-2, COVID Rural, Edema Severity	AUC, F1-score, Accuracy.	- Phân loại không mẫu: RSNA: 0.8694 AUC, 0.6342 F1; SIIM-ACR: 0.8924 AUC, 0.6833 F1; ChestX-ray14: 0.7676 AUC, 0.2525 F1; COVID-19: 0.7396 AUC, 0.7670 F1 - Phân loại ít mẫu: ChestX-ray14 (1%): 0.7721 AUC, (10%): 0.7894; RSNA (1%): 0.8731 AUC, (10%): 0.8799 AUC - Phân loại mẫu: ChestX-ray14: 0.8323 AUC, RSNA 0.8931
10	KAD (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PadChest, NIH ChestXray14, CheXpert, ChestX-Det	AUC, F1-Score, MCC	- Phân loại không mẫu: PadChest: 0.966 AUC; CheXpert: 0.905 AUC, 0.647 F1, 0.589 MCC - Phân loại ít mẫu: ChestXray-14 (1%): 0.78 AUC, 0.31 F1; (10%): 0.80 AUC, 0.33 F1 - Phân loại ảnh: ChestXray-14: 0.82 AUC, 0.34 F1

Bảng 5: Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

Tinh chỉnh sử dụng câu nhắc (Prompt Tuning): Hướng này chèn thêm các tham số có thể học được vào không gian đầu vào của mô hình. Các phương pháp như CITE [53], FPT [17] hay PLIP [49] khai thác đặc trưng thị giác kết hợp với tri thức lâm sàng, cho thấy hiệu quả vượt trội ngay cả khi thiếu hụt dữ liệu (ví dụ: PLIP đạt 0.896 AUC chỉ với 5% dữ liệu PanNuke). Nhằm giải quyết khó khăn khi thiết kế thủ công, MedPrompt [54] và UniDCP [48] tự động sinh câu nhắc động dựa trên ngữ cảnh ảnh để xử lý đa tác vụ. Gần đây hơn, việc tích hợp Mô hình ngôn ngữ Lớn (LLM) qua ViP [10], CILMP [9] và BiomedCoOp [20] giúp tạo sinh các câu nhắc ngữ nghĩa sâu sắc, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản, mang lại hiệu năng cao trong các kịch bản ít mẫu hoặc không mẫu.

Tinh chỉnh bộ điều hợp (Adapter Tuning): Thay vì can thiệp ở đầu vào, phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ giữa các lớp của kiến trúc gốc. Điển hình, CLIPath [21] sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu nhỏ; FTB [33] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức. Ở hướng bán giám sát, mô hình MedUnA [34] dùng LLM tạo nhãn giả và tinh chỉnh không giám sát bộ điều hợp trên ảnh chưa gán nhãn, giúp mô hình thích ứng tốt mà không thay đổi trọng số.

Tinh chỉnh chọn lọc (Selective Tuning): Hướng đi này tối ưu hóa kiến trúc bằng cách chỉ cập nhật một lượng nhỏ các trọng số quyết định hiệu năng. TransMed [55] kết hợp LLM để chuyển đổi nhãn bệnh thành mô tả chi tiết, trong khi SH-PEFT [27] chỉ tìm và cập nhật các trọng số quan trọng nhất trên bộ mã hóa thị giác nhằm khai thác tính thừa thớt của mạng. Tương tự, LCBP [26] áp dụng kỹ thuật LoRA để tinh chỉnh tham số hiệu quả cho Med-VLMs, giúp bám sát hiệu năng của tinh chỉnh toàn phần (đạt 93.1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn) nhưng giảm thiểu tối đa chi phí tính toán.

Tóm lại, các phương pháp tinh chỉnh hiệu quả tham số (PEFT) thể hiện ưu điểm vượt trội trong việc tiết kiệm tài nguyên tính toán, ngăn chặn hiện tượng quên tri thức và giúp mô hình thích ứng tốt ngay cả khi đối mặt với các bộ dữ liệu y tế khan hiếm. Tuy nhiên, hướng tiếp cận này vẫn tồn tại một số hạn chế nhất định. Hiệu năng cuối cùng của hệ thống phụ thuộc rất lớn vào chất lượng của mô hình tiền huấn luyện gốc. Đồng

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	CITE (2023)	Parameter-efficient fine tuning	Visual prompt tuning	CLIP ViT-Base, ImageNet-21k ViT-Base, INTERN ViT-Base	BioLinkBERT-large, BioBERT-large, Kế thừa CLIP	Contrastive Alignment	N/a
2	UniDCP (2023)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	CLIP ViT	RoBERTa	Cross Attention, Contrastive Alignment	N/a
3	ViP (2024)	Parameter-efficient fine tuning	Textual prompt tuning	ViT-Base	Kế thừa CLIP	Cross Attention, Contrastive Alignment	N/a
4	PLIP (2024)	Parameter-efficient fine tuning	Visual prompt tuning, Efficient Selective tuning	ViT-Base	Kế thừa CLIP	Concatnate	N/a
5	FPT (2024)	Parameter-efficient fine tuning	Visual prompt tuning	ViT-Base	N/a	Cross Attention	N/a
6	MedPrompt (2024)	Parameter-efficient fine tuning	Textual prompt tuning	Swin Transformer, ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
7	CILMP (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	ViT-Base	Kế thừa CLIP	Hadamard Product, Concatnate	N/a
8	BiomedCoOp (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	Kế thừa BiomedCLIP	Kế thừa BiomedCLIP	Contrastive Alignment	N/a
9	CLIPath (2023)	Parameter-efficient fine tuning	Adapter tuning	ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
10	FTB (2024)	Parameter-efficient fine tuning	Adapter tuning	ResNet autoencoder, DINOv2-small, DINOv2-base	BERT, BioBERT, ClinicalBERT, CXR-BERT, PubMedBERT	Cross Attention	N/a
11	MedUnA (2024)	Parameter-efficient fine tuning	Adapter tuning	ViT-Base, MedCLIP-Swin	Kế thừa CLIP, MedCLIP	No Fusion	N/a
12	TransMed (2023)	Parameter-efficient fine tuning	Direct Selective tuning	Swin Transformer, ViT-Base	BERT, LLM/GPT-4	Contrastive Alignment	N/a
13	SH-PEFT (2024)	Parameter-efficient fine tuning	Direct Selective tuning	ViT-Base	Kế thừa CLIP	No Fusion	N/a
14	LCBB (2024)	Parameter-efficient fine tuning	Efficient Selective tuning	Kế thừa MAE, MRM	Kế thừa MAE, MRM	Kế thừa MAE, MRM	N/a

Bảng 6: Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan

thời, quá trình thiết kế câu nhắc mang đậm tính chuyên môn hay xác định vị trí tối ưu để chèn bộ điều hợp thường phức tạp và đòi hỏi nhiều thử nghiệm. Ngoài ra, việc bổ sung các thành phần này ít nhiều làm tăng tính "hộp đen" của mô hình, gây ra những thách thức về tính minh bạch khi cần giải thích các quyết định dự đoán cho bác sĩ trên thực tế lâm sàng.

Các mô hình ngôn ngữ lớn y khoa đa phương thức

Trong thời gian gần đây, với sự phát triển của các mô hình ngôn ngữ lớn được huấn luyện trên những tập dữ liệu rất lớn phục vụ cho rất nhiều tác vụ khác nhau, các mô hình này đang thể hiện sự ảnh hưởng và đa dụng trong lĩnh vực y tế với độ chính xác rất tốt khi chỉ học ít mẫu hoặc không mẫu.

Med-Flamingo [32] là mô hình đầu tiên có khả năng học ít mẫu chuyên dụng cho y tế, thông qua hội thoại tự nhiên để hỗ trợ chẩn đoán. Theo sau đó, LLaVA-Med [24] là mô hình chuyển đổi khả năng thực hiện theo chỉ dẫn (instruction-following) từ miền tổng quát sang lĩnh vực y sinh bằng cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn với 600.000 cặp, với dữ

liệu hội thoại tạo ra từ chú thích ảnh y khoa được tạo ra bằng cách sử dụng GPT-4. Phương pháp này đã đề xuất quy trình huấn luyện 2 bước: (1) Căn chỉnh khái niệm; (2) Tinh chỉnh chỉ dẫn đầy đủ; 2 bước này tương ứng với giai đoạn học và suy luận. Kết quả thể hiện khả năng suy luận vượt trội trên dữ liệu chưa từng thấy.

Med-Palm M [40] là mô hình của Google, đánh dấu bước tiến từ các mô hình đơn nhiệm sang đa nhiệm quy mô lớn, có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì sử dụng các mô hình chuyên biệt cho từng tác vụ. Gần đây hơn, SkinGPT-4 [58] là hệ thống chẩn đoán da liễu tương tác đầu tiên sử dụng LLM quy mô lớn với độ chính xác cao, đã kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM), tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Dù đưa đến các phương pháp có độ chính xác cao đến rất cao trong nhiều tác vụ cùng việc hỗ trợ trong việc giao tiếp với mô hình, kích cỡ và chi phí huấn luyện (Med-Flamingo có đến 9 tỷ thông số) để vận hành các mô hình ngôn ngữ lớn đa phương thức là một vấn đề lớn, đi kèm với vấn đề ảo giác có thể gặp phải khi đối mặt với dữ liệu mới hoặc những câu hỏi phức tạp. Ngoài ra nếu yêu cầu một độ chính xác cao - một yêu cầu quan trọng trong lĩnh vực y tế trong một tác vụ cụ thể thì đây không phải một cách tiếp cận tốt cho bài toán này.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Cấu trúc phương pháp			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	Med-Flamingo [32]	PEFT	Parameter-efficient + Domain adaptation	Frozen CLIP ViT	LLaMA-7B	Intermediate fusion	LLaMA Decoder
2	LLaVA-Med [24]	Full FT	Visual Instruction Tuning (GPT-4 data)	CLIP ViT-L/14	LLaMA	Projection Matrix	LLM (Vicuna)
3	Med-PaLM M [40]	Full FT	Instruction Fine-tuning	ViT (4B - 22B)	PaLM	Multimodal embedding	PaLM
4	SkinGPT-4 [58]	PEFT	LoRA	Vision Transformer	GPT-4	Linear alignment	LLaMA-2-13B


Bảng 7: Tổng hợp chiến lược và cấu trúc các mô hình ngôn ngữ lớn đa phương thức

Phương pháp đề xuất: Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế theo hướng tích hợp tri thức y khoa nhằm nâng cao

khả năng giải thích của mô hình được minh họa ở Hình 2. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Bộ mã hóa ảnh:** Kế thừa lại mô hình ViT-Base của phương pháp BiomedCLIP [50]
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [50]
- **Bộ dung hợp dữ liệu:** Nhóm hướng đến sử dụng cơ chế *Knowledge-guided Cross-Attention* - Các khái niệm y học được trích xuất và liên kết từ văn bản lâm sàng thông qua sẽ được sử dụng để tạo thiên lệch (bias) trong quá trình tính toán cross attention. Cơ chế này giúp điều hướng mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Nhờ đó, mô hình không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.
- **Bộ phân loại:** Sử dụng một mạng phân loại (Multi-Layer Perceptron) để dự đoán nhãn bệnh lý.

Đồng thời, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán.



Hình 2: Kiến trúc tổng thể của hệ thống đề xuất

2.7 Kết quả dự kiến của đề tài

- **Số liệu định lượng:** Độ chính xác, điểm F1, AUC-ROC đạt kết quả cạnh tranh trên các bộ dữ liệu đã nêu.
- **Sản phẩm đầu ra:**

- Hệ thống demo phân loại ảnh X-quang xương với khả năng nhận ảnh và văn bản và trả ra các lớp thuộc bộ dữ liệu Sarcoma-CTCH.
 - Giao diện đơn giản để hiển thị kết quả phân loại.
 - Cho phép trực quan hóa sau khi hiện kết quả phân loại.
- **Báo cáo khoa học:** hoàn thiện phương pháp và hệ thống để hướng tới công bố trên các hội nghị và tạp chí uy tín trong lĩnh vực Trí tuệ nhân tạo và Y sinh, như MICCAI, CVPR hoặc các tạp chí được công nhận.
 - **Hướng phát triển:**
 - Mở rộng ra cho các bệnh lý khác.
 - Cải thiện độ chính xác và hiệu suất của hệ thống.

2.8 Kế hoạch thực hiện

Mục tiêu	Thời gian	Phân công	Nội dung
Khoá luận tốt nghiệp	01 tháng	Giai đoạn 1	
		Bá Thành	Khảo sát tổng quan về bài toán phân loại ảnh X-quang về xương
		Gia Kiệt	Khảo sát các mô hình tiền huấn luyện trên dữ liệu y khoa
		Bá Thành	Khảo sát các phương pháp học chuyển giao và các mô hình liên quan
	02 tháng	Giai đoạn 2	
		Cả nhóm	Phát triển mô hình học sâu đa phương thức áp dụng phương pháp học chuyển giao
		Gia Kiệt	Cài đặt môi trường, thu thập các bộ dữ liệu liên quan
		Bá Thành	Thực hiện thí nghiệm trên mô hình đề xuất
	02 tháng	Giai đoạn 3	
		Bá Thành	Phân tích so sánh kết quả thực nghiệm.
		Gia Kiệt	Xây dựng nguyên mẫu cho hệ thống phân loại
	0.5 tháng	Giai đoạn 4	
		Cả nhóm	Viết 01 bài báo khoa học cho hội nghị - tạp chí chuyên ngành trong nước hoặc ngoài nước
	0.5 tháng	Giai đoạn 5	
		Bá Thành	Viết báo cáo khoá luận tốt nghiệp.
		Gia Kiệt	Thiết kế slide cho lễ bảo vệ đề tài tốt nghiệp

Bảng 8: Kế hoạch bố trí thời gian nghiên cứu

Tài liệu tham khảo

- [1] Samira Abnar and Willem Zuidema. “Quantifying Attention Flow in Transformers”. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2020, pp. 4190–4197. DOI: 10.18653/v1/2020.acl-main.385. URL: <https://aclanthology.org/2020.acl-main.385/>.
- [2] Jean-Baptiste Alayrac et al. “Flamingo: a Visual Language Model for Few-Shot Learning”. In: *Advances in Neural Information Processing Systems*. Vol. 35. 2022, pp. 23716–23736. URL: https://papers.nips.cc/paper_files/paper/2022/hash/960a172bc7fbf0177ccccbb411a7c Abstract-Conference.html.
- [3] Shruthi Bannur et al. “Learning to exploit temporal structure for biomedical vision-language processing”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2023, pp. 15016–15027.
- [4] Lynn S. Bickley, Peter G. Szilagyi, and Richard M. Hoffman. *Bates’ Guide to Physical Examination and History Taking*. 13th. Lippincott Williams & Wilkins, 2020.
- [5] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing”. In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5.
- [6] Bệnh viện Nguyễn Tri Phương. *Quy trình khám bệnh tại khoa khám bệnh*. URL: <https://bvnguyentriphuong.com.vn/quy-trinh-kham-benh/quy-trinh-kham-benh-tai-khoa-kham-benh> (visited on 07/06/2026).
- [7] Yin Cui et al. “Class-Balanced Loss Based on Effective Number of Samples”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, pp. 9268–9277. URL: https://openaccess.thecvf.com/content_CVPR_2019/html/Cui_Class-

Balanced_Loss_Based_on_Effective_Number_of_Samples_CVPR_2019_paper.html.

- [8] Yin Dai and Yifan Gao. “TransMed: Transformers Advance Multi-modal Medical Image Classification”. In: *CoRR* abs/2103.05940 (2021). arXiv: 2103.05940. URL: <https://arxiv.org/abs/2103.05940>.
- [9] Ye Du, Nanxi Yu, and Shujun Wang. “Medical Knowledge Intervention Prompt Tuning for Medical Image Classification”. In: *IEEE Transactions on Medical Imaging* 44.12 (2025), pp. 4945–4959. DOI: 10.1109/TMI.2025.3584841.
- [10] Xiao Fang et al. “Aligning Medical Images with General Knowledge from Large Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15010. Springer Nature Switzerland, 2024.
- [11] Kaiming He et al. “Deep Residual Learning for Image Recognition”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016.
- [12] Dan Hendrycks and Kevin Gimpel. “A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks”. In: *International Conference on Learning Representations*. 2017. URL: <https://arxiv.org/abs/1610.02136>.
- [13] Dan Hendrycks et al. “Scaling Out-of-Distribution Detection for Real-World Settings”. In: *Proceedings of the 39th International Conference on Machine Learning*. Vol. 162. Proceedings of Machine Learning Research. PMLR, 2022, pp. 8759–8773. URL: <https://proceedings.mlr.press/v162/hendrycks22a.html>.
- [14] Edward J. Hu et al. “LoRA: Low-Rank Adaptation of Large Language Models”. In: *International Conference on Learning Representations*. 2022. URL: <https://openreview.net/forum?id=nZeVKeeFYf9>.
- [15] Gao Huang et al. “Densely Connected Convolutional Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017.

- [16] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [17] Yijin Huang et al. “Fine-grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-resolution Medical Image Classification”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15012. Springer Nature Switzerland, 2024, pp. 120–130. DOI: 10.1007/978-3-031-72390-2_12.
- [18] Andrew Jaegle et al. “Perceiver: General Perception with Iterative Attention”. In: *Proceedings of the 38th International Conference on Machine Learning*. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 4651–4664. URL: <https://proceedings.mlr.press/v139/jaegle21a.html>.
- [19] Sarthak Jain and Byron C. Wallace. “Attention is not Explanation”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, 2019, pp. 3543–3556. DOI: 10.18653/v1/N19-1357. URL: <https://aclanthology.org/N19-1357/>.
- [20] Taha Koleilat et al. “BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models”. In: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*. 2025, pp. 14766–14776.
- [21] Zhengfeng Lai et al. “CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*. 2023, pp. 2374–2380.

- [22] Olivier Ledoit and Michael Wolf. “A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices”. In: *Journal of Multivariate Analysis* 88.2 (2004), pp. 365–411. DOI: 10.1016/S0047-259X(03)00096-4.
- [23] Kimin Lee et al. “A Simple Unified Framework for Detecting Out-of-Distribution Samples and Adversarial Attacks”. In: *Advances in Neural Information Processing Systems*. Vol. 31. 2018, pp. 7167–7177. URL: <https://proceedings.neurips.cc/paper/2018/hash/abdeb6f575ac5c6676b747bca8d09cc2-Abstract.html>.
- [24] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: <https://arxiv.org/abs/2306.00890>.
- [25] Zihan Li et al. “LViT: Language Meets Vision Transformer in Medical Image Segmentation”. In: *IEEE Transactions on Medical Imaging* 43.1 (2024), pp. 96–107. DOI: 10.1109/TMI.2023.3291719.
- [26] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: <https://arxiv.org/abs/2401.12215>.
- [27] Mingyuan Liu et al. “Sparsity- and Hybridity-Inspired Visual Parameter-Efficient Fine-Tuning for Medical Diagnosis”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15005. Springer Nature Switzerland, 2024.
- [28] Weitang Liu et al. “Energy-based Out-of-distribution Detection”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 21464–21475. URL: <https://proceedings.neurips.cc/paper/2020/hash/f5496252609c43eb8a3d147ab9b9c006-Abstract.html>.
- [29] Xueyan Mei et al. “Artificial intelligence-enabled rapid diagnosis of patients with COVID-19”. In: *Nature Medicine* 26 (Aug. 2020), 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: <https://www.nature.com/articles/s41591-020-0931-3>.

- [30] Yifei Ming et al. “Delving into Out-of-Distribution Detection with Vision-Language Representations”. In: *Advances in Neural Information Processing Systems*. Vol. 35. 2022, pp. 35087–35102. URL: https://papers.nips.cc/paper_files/paper/2022/hash/e43a33994a28f746dcfc Abstract-Conference.html.
- [31] Jong Hak Moon et al. “Multi-Modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training”. In: *IEEE Journal of Biomedical and Health Informatics* 26.12 (2022), pp. 6070–6080. DOI: 10.1109/JBHI.2022.3207502.
- [32] Michael Moor et al. *Med-Flamingo: a Multimodal Medical Few-shot Learner*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.15189. URL: <https://arxiv.org/abs/2307.15189>.
- [33] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.
- [34] Umair Rahman et al. “Can language-guided unsupervised adaptation improve medical image classification using unpaired images and texts?” In: *2025 IEEE 22nd International Symposium on Biomedical Imaging (ISBI)*. IEEE. 2025, pp. 1–5.
- [35] Bryan C Russell et al. “LabelMe: a database and web-based tool for image annotation”. In: *International journal of computer vision* 77.1-3 (2008), pp. 157–173.
- [36] Ramprasaath R. Selvaraju et al. “Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization”. In: *Proceedings of the IEEE International Conference on Computer Vision*. 2017, pp. 618–626. URL: https://openaccess.thecvf.com/content_iccv_2017/html/Selvaraju_Grad-CAM_Visual_Explanations_ICCV_2017_paper.html.

- [37] Jake Snell, Kevin Swersky, and Richard S. Zemel. “Prototypical Networks for Few-shot Learning”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017, pp. 4077–4087. URL: https://papers.nips.cc/paper_files/paper/2017/hash/cb8da6767461f2812ae429Abstract.html.
- [38] Yiyu Sun et al. “Out-of-Distribution Detection with Deep Nearest Neighbors”. In: *Proceedings of the 39th International Conference on Machine Learning*. Vol. 162. Proceedings of Machine Learning Research. PMLR, 2022, pp. 20827–20840. URL: <https://proceedings.mlr.press/v162/sun22d.html>.
- [39] Nikhil Kumar Tomar et al. “TGANet: Text-Guided Attention for Improved Polyp Segmentation”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2022*. Cham, Switzerland: Springer Nature Switzerland, 2022, pp. 151–160. ISBN: 978-3-031-16437-8. DOI: 10.1007/978-3-031-16437-8_15.
- [40] Tao Tu et al. *Towards Generalist Biomedical AI*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.14334. URL: <https://arxiv.org/abs/2307.14334>.
- [41] Xiaosong Wang et al. “TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018.
- [42] Yan Wang et al. *SimpleShot: Revisiting Nearest-Neighbor Classification for Few-Shot Learning*. 2019. arXiv: 1911.04623 [cs.CV]. URL: <https://arxiv.org/abs/1911.04623>.
- [43] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, Dec. 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: <https://aclanthology.org/2022.emnlp-main.256/>.

- [44] W.B. Saunders. *Dorland's Illustrated Medical Dictionary*. 32nd. Elsevier Health Sciences, 2011.
- [45] Chaoyi Wu et al. “MedKLIP: Medical Knowledge Enhanced Language-Image Pre-Training for X-ray Diagnosis”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023, pp. 21372–21383.
- [46] Bin Yan and Mingtao Pei. “Clinical-BERT: Vision-Language Pre-training for Radiograph Diagnosis and Reports Generation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 36. 3. 2022, pp. 2982–2990. DOI: 10.1609/aaai.v36i3.20204. URL: <https://doi.org/10.1609/aaai.v36i3.20204>.
- [47] Shunhan Yao et al. “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors”. In: *Scientific Data* 12.1 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y. URL: <https://doi.org/10.1038/s41597-024-04311-y>.
- [48] Chenlu Zhan et al. “UniDCP: Unifying Multiple Medical Vision-Language Tasks via Dynamic Cross-Modal Learnable Prompts”. In: *IEEE Transactions on Multimedia* 26 (2024), pp. 9736–9748. DOI: 10.1109/TMM.2024.3397191.
- [49] Jiajin Zhang et al. “Disease-informed Adaptation of Vision-Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15011. Springer Nature Switzerland, 2024.
- [50] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoA2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoA2400640>.
- [51] Xiaoman Zhang et al. “Knowledge-enhanced visual-language pre-training on chest radiology images”. In: *Nature Communications* 14 (July 2023). DOI: 10.1038/s41467-023-40260-7. URL: <https://arxiv.org/pdf/2302.14042.pdf>.

- [52] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 7th Machine Learning for Healthcare Conference*. Ed. by Zachary Lipton et al. Vol. 182. Proceedings of Machine Learning Research. PMLR, 2022, pp. 2–25. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
- [53] Yunkun Zhang et al. “Text-Guided Foundation Model Adaptation for Pathological Image Classification”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*. Ed. by Hayit Greenspan et al. Cham: Springer Nature Switzerland, 2023, pp. 272–282. ISBN: 978-3-031-43904-9.
- [54] Fudan Zheng et al. “Exploring low-resource medical image classification with weakly supervised prompt learning”. In: *Pattern Recognition* 149 (2024), p. 110250. ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2024.110250>. URL: <https://www.sciencedirect.com/science/article/pii/S0031320324000013>.
- [55] Kaipeng Zheng, Weiran Huang, and Lichao Sun. “TransMed: Large Language Models Enhance Vision Transformer for Biomedical Image Classification”. In: *arXiv preprint arXiv:2312.07125* (2023).
- [56] Hong-Yu Zhou et al. “A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics”. In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).
- [57] Hong-Yu Zhou et al. “Advancing Radiograph Representation Learning with Masked Record Modeling”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=w-x7U26GM7j>.
- [58] Juexiao Zhou et al. “Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4”. In: *Nature Communications* 15 (July 2024). DOI: 10.1038/s41467-024-50043-3. URL: <https://doi.org/10.1038/s41467-024-50043-3>.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 05 tháng 04 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Đề cương chi tiết	iii
Mục lục	xxxi
Danh sách hình	xxxv
Danh sách bảng	xxxvi
Tóm tắt	xxxvii
1 Giới thiệu	1
1.1 Bối cảnh và lý do chọn đề tài	1
1.2 Động lực nghiên cứu	2
1.2.1 Kịch bản thực tế	2
1.2.2 Ý nghĩa khoa học của đề tài	6
1.2.3 Ý nghĩa thực tiễn của đề tài	6
1.3 Giới thiệu bài toán	7
1.3.1 Các thách thức trong bài toán	8
1.4 Mục tiêu nghiên cứu	9
1.5 Đối tượng và phạm vi nghiên cứu	10
1.5.1 Đối tượng nghiên cứu	10
1.5.2 Phạm vi nghiên cứu	11
1.6 Các câu hỏi nghiên cứu và giả thuyết	11
1.7 Đóng góp chính của đề tài	14

1.8	Bố cục luận văn	15
2	Các công trình nghiên cứu liên quan	17
2.1	Các mô hình nền tảng	17
2.1.1	Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu	17
2.1.2	Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) .	18
2.2	Biểu diễn ảnh độ phân giải cao và thông tin không gian . .	20
2.2.1	Giới hạn của phép co giãn ảnh toàn cục	20
2.2.2	Kết hợp ngữ cảnh toàn cục và vùng cục bộ	20
2.3	Các kỹ thuật tinh chỉnh hiệu quả tham số	22
2.3.1	Tinh chỉnh sử dụng câu nhắc (Prompt Tuning) . .	22
2.3.2	Tinh chỉnh bộ điều hợp (Adapter Tuning)	23
2.3.3	Tinh chỉnh chọn lọc (Selective Tuning)	23
2.4	Các phương pháp phát hiện dữ liệu ngoài phân phối	24
2.4.1	Các phương pháp hậu xử lý dựa trên đầu ra mô hình (Post-hoc Methods)	25
2.4.2	Các phương pháp dựa trên không gian đặc trưng (Feature-space-based Methods)	25
2.4.3	Các phương pháp học biểu diễn phục vụ phát hiện OOD (Representation Learning)	26
2.4.4	Các phương pháp sinh và định lượng độ không chắc chắc	27
2.5	Bàn luận	28
2.5.1	Xu hướng ứng dụng học sâu đa phương thức trong chẩn đoán ảnh y khoa	28
2.5.2	Hạn chế của các nghiên cứu hiện nay	28
2.5.3	Cơ sở lựa chọn và định hướng phương pháp đề xuất	29
3	Phương pháp đề xuất	31
3.1	Tổng quan phương pháp đề xuất	31
3.1.1	Huấn luyện hai giai đoạn trong quá trình ngoại tuyến (Offline)	32
3.1.2	Suy luận trong quá trình trực tuyến (Online) . . .	33
3.2	Các thành phần của pipeline	33

3.2.1	Dầu vào và tiền xử lý (Input and Preprocessing) . .	33
3.2.2	Bộ mã hóa (Encoders)	35
3.2.3	Bộ dung hợp (Cross-Attention)	40
3.2.4	Bộ phân loại dựa trên tâm lớp thực nghiệm (Classifier)	42
3.3	Tóm tắt chương	44
4	Thực nghiệm	46
4.1	Chuẩn bị dữ liệu	46
4.1.1	Bộ dữ liệu BTXRD	46
4.1.2	Bộ dữ liệu CTCH	50
4.2	Độ đo đánh giá	55
4.2.1	Độ đo phân loại	55
4.2.2	Độ đo phát hiện dữ liệu ngoài phân phối	59
4.2.3	Độ đo phân tích chú ý và dung hợp	61
4.3	Thiết lập thực nghiệm	64
4.3.1	Môi trường thực nghiệm	64
4.3.2	Tham số thực nghiệm	65
4.3.3	Tham số thực nghiệm	65
4.4	Nội dung thực nghiệm	66
4.4.1	Đánh giá mô hình nền tảng	66
4.4.2	So sánh với các mô hình nền tảng	67
4.4.3	Đánh giá thành phần	68
4.4.4	OOD hậu xử lý	69
4.4.5	Giải thích và biểu diễn	70
4.5	Kết quả thực nghiệm và thảo luận	71
4.5.1	Đánh giá mô hình nền tảng	71
4.5.2	So sánh với các mô hình nền tảng	73
4.5.3	Đánh giá thành phần	74
4.5.4	OOD hậu xử lý	75
4.5.5	Giải thích và biểu diễn	76
5	Kết luận và hướng phát triển	78
5.1	Kết luận	78
5.2	Hướng phát triển	79

Danh sách hình

1.1	Sơ đồ quy trình khám chữa bệnh giản hóa (Tham khảo từ quy trình thực tế tại Bệnh viện Nguyễn Tri Phương [6]).	4
1.2	Sơ đồ tích hợp hệ thống hỗ trợ phân tích.	5
4.1	Sơ đồ cấu trúc của bộ dữ liệu BTXRD	48
4.2	Sơ đồ phân cấp cấu trúc dữ liệu CTCH	52

Danh sách bảng

2.1	Bảng tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản.	19
2.2	Các chiến lược xử lý ảnh độ phân giải cao và sự đánh đổi chính.	21
2.3	Bảng tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện cho các mô hình ngôn ngữ trực quan y khoa. .	24
4.1	Ví dụ các mẫu dữ liệu đa phương thức trong bộ dữ liệu BTXRD	51
4.2	Phân bổ hình ảnh theo các tập dữ liệu trong BTXRD . . .	53
4.3	Phân bổ các lớp đơn nhãn sau chuẩn hóa trong bộ dữ liệu BTXRD	53
4.4	Môi trường phần cứng được thiết lập	64
4.5	Phiên bản của các thư viện chính trong môi trường thí nghiệm	64
4.6	Bảng tổng hợp siêu tham số ở pha 1 và thiết lập của chúng	65
4.7	Bảng tổng hợp siêu tham số ở pha 2 và thiết lập của chúng	66
4.8	Kết quả zero-shot trên BTXRD và CTCH, chữ đậm biểu thị giá trị tốt nhất theo từng bộ dữ liệu	72
4.9	Kết quả phân loại khi sử dụng toàn bộ dữ liệu, chữ đậm biểu thị giá trị tốt nhất theo từng cột trong mỗi bộ dữ liệu	73
4.10	Kết quả few-shot của các thiết lập có đủ ba lần chạy; chữ đậm biểu thị giá trị tốt nhất trong từng mức shot và bộ dữ liệu	74
4.11	Kết quả đánh giá thành phần tiền xử lý ảnh trên CTCH .	74
4.12	Kết quả OOD hậu xử lý của XBone-Net trên CTCH; chữ đậm biểu thị kết quả tốt nhất trong từng kịch bản chính .	75

4.13	Kết quả phân bổ mức đóng góp của XBone-Net trên CTCH	76
4.14	Kết quả hình học biểu diễn của XBone-Net trên CTCH; chữ đậm biểu thị giá trị tốt nhất theo từng cột	77

Tóm tắt

Các bệnh lý và chấn thương xương ngày càng phổ biến, làm gia tăng nhu cầu ứng dụng trí tuệ nhân tạo nhằm hỗ trợ bác sĩ trong quá trình phân tích ảnh X-quang. Tuy nhiên, dữ liệu X-quang y khoa thường có số lượng mẫu gán nhãn hạn chế, mất cân bằng giữa các lớp bệnh và tồn tại nhiều trường hợp ngoài phân phối (Out-of-Distribution - OOD), khiến hiệu quả của các mô hình học sâu suy giảm khi triển khai trong thực tế.

Đề tài hướng đến xây dựng một hệ thống phân loại đa lớp ảnh X-quang xương theo hướng đa phương thức, khai thác đồng thời thông tin từ ảnh X-quang và văn bản lâm sàng nhằm nâng cao hiệu quả dự đoán.

Hệ thống được xây dựng trên nền tảng BioMedCLIP với hai giai đoạn huấn luyện. Giai đoạn thứ nhất thực hiện thích nghi miền bằng kỹ thuật LoRA sử dụng Semantic Matching Loss nhằm cải thiện khả năng biểu diễn đặc trưng đối với dữ liệu X-quang xương. Giai đoạn hai học phân loại sử dụng cơ chế chú ý hai chiều để hợp nhất đặc trưng ảnh và văn bản, kết hợp Asymmetric Loss nhằm xử lý mất cân bằng lớp và mạng nguyên mẫu để tăng cường khả năng phân biệt giữa các lớp, hỗ trợ các lớp có ít mẫu và làm cơ sở cho phát hiện dữ liệu ngoài phân phối. Hệ thống được đánh giá thông qua các thực nghiệm thành phần, so sánh với các mô hình nền tảng và đánh giá trên bộ dữ liệu X-quang xương được xây dựng từ dữ liệu thực từ Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.

Kết quả thực nghiệm cho thấy phương pháp đề xuất cải thiện hiệu quả phân loại đa lớp so với mô hình nền, đồng thời nâng cao khả năng tổng quát và hỗ trợ phát hiện dữ liệu ngoài phân phối. Ngoài ra, đề tài còn đóng góp một bộ dữ liệu X-quang xương đã được tinh lọc và chuẩn hóa, tạo nền tảng cho các nghiên cứu tiếp theo về học đa phương thức và ứng dụng mô hình thị giác-ngôn ngữ trong phân tích ảnh y khoa.

Chương 1

Giới thiệu

Chương này trình bày bối cảnh, vấn đề nghiên cứu và phạm vi của bài toán phân loại ảnh X-quang xương bằng học sâu đa phương thức. Trọng tâm của luận văn là khai thác đồng thời ảnh X-quang và bệnh sử lâm sàng được thu nhận trước khi đọc ảnh, qua đó đánh giá giá trị bổ sung của thông tin lâm sàng đối với mô hình chỉ sử dụng hình ảnh. Chương cũng xác định các thách thức liên quan đến độ phân giải ảnh, dữ liệu hạn chế, mất cân bằng lớp, dữ liệu ngoài phân phối và khả năng giải thích; từ đó xây dựng mục tiêu, câu hỏi nghiên cứu và các đóng góp của luận văn.

1.1 Bối cảnh và lý do chọn đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ khảo sát cấu trúc xương, phát hiện tổn thương, bất thường và hỗ trợ định hướng điều trị. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay có thể gặp khó khăn khi tổn thương nhỏ, ảnh có tương phản thấp hoặc khi số lượng ca cần đọc lớn, lúc đó kết quả phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ.

Để giải quyết các thách thức này, nhiều nghiên cứu đã ứng dụng các mô hình học sâu vào việc hỗ trợ phân tích và phân loại ảnh X-quang và đưa ra quyết định dựa trên thông tin trên ảnh như các kiến trúc mạng nơ-ron tích chập ResNet [11] và DenseNet [15]. Tuy nhiên, các mô hình chỉ sử dụng hình ảnh không khai thác được các thông tin lâm sàng có sẵn trước khi đọc ảnh, chẳng hạn triệu chứng, tiền sử bệnh hoặc cơ chế chấn thương. Trong khi đó, quá trình ra quyết định lâm sàng thực tế của bác sĩ thường dựa trên sự kết hợp giữa bằng chứng hình ảnh và bối cảnh bệnh hoặc chấn thương của người bệnh.

Dựa vào thực tế đó, các mô hình ngôn ngữ trực quan y khoa như MedCLIP [43], BiomedCLIP [50] và BioViL [5] cung cấp một hướng tiếp cận phù hợp để học biểu diễn chung giữa ảnh và văn bản. Nhờ được tiền huấn luyện trên các tập dữ liệu ảnh–văn bản quy mô lớn, các mô hình này có thể được chuyển giao sang những bài toán y khoa chuyên biệt với lượng dữ liệu gán nhãn hạn chế.

Tuy nhiên, việc chuyển giao các mô hình ngôn ngữ trực quan y khoa sang bài toán phân loại ảnh X-quang xương vẫn gặp nhiều trở ngại. Những trở ngại này xuất phát từ sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu đầu vào thực tế, số lượng dữ liệu gán nhãn hạn chế và mất cân bằng, nguy cơ xuất hiện dữ liệu ngoài phân phối, yêu cầu bảo toàn các tổn thương nhỏ trên ảnh có độ phân giải cao, cũng như nhu cầu giải thích quyết định của mô hình. Các thách thức cụ thể của bài toán được trình bày tại Mục 1.3.1.

1.2 Động lực nghiên cứu


1.2.1 Kịch bản thực tế

Trong thực hành lâm sàng với các ca bệnh có chỉ định chụp X-quang, quy trình chẩn đoán bệnh lý xương thường tuân theo Hình 1.1 bao gồm khám lâm sàng, chỉ định chụp X-quang, phân tích hình ảnh và kết hợp với các thông tin bệnh án để đưa ra chẩn đoán cuối cùng. Sau khi ảnh X-quang được thu nhận, bác sĩ chẩn đoán hình ảnh sẽ đánh giá các dấu


hiệu bất thường như vị trí tổn thương, hình thái gãy xương, khối u hoặc các biến đổi bệnh lý khác, đồng thời đối chiếu với các thông tin lâm sàng như triệu chứng, tiền sử bệnh và cơ chế chấn thương để đưa ra kết quả đọc phim.

Hệ thống được đề xuất trong luận văn được thiết kế nhằm hỗ trợ quá trình phân tích ảnh X-quang bằng cách khai thác đồng thời ảnh X-quang và dữ liệu văn bản chứa thông tin lâm sàng để dự đoán lớp bệnh lý của bệnh nhân như thể hiện ở Hình 1.2. Việc kết hợp hai nguồn dữ liệu giúp mô hình tận dụng các thông tin bổ sung, từ đó nâng cao khả năng học biểu diễn và cải thiện hiệu quả phân loại so với việc chỉ sử dụng một phương thức dữ liệu.

Cần lưu ý rằng hệ thống được nghiên cứu như một công cụ hỗ trợ phân tích và không thay thế kết luận của bác sĩ. Các đầu ra của mô hình chỉ mang tính tham khảo, hiệu quả lâm sàng thực tế cần được đánh giá thêm thông qua nghiên cứu độc lập với sự tham gia của chuyên gia y tế. Về lý tưởng, hệ thống được kỳ vọng sẽ giúp rút ngắn thời gian đọc phim, giảm nguy cơ bỏ sót tổn thương và nâng cao hiệu quả chẩn đoán, đặc biệt tại các cơ sở y tế có khối lượng bệnh nhân lớn hoặc nguồn nhân lực chuyên khoa còn hạn chế.



Hình 1.1: Sơ đồ quy trình khám chữa bệnh giản hóa (Tham khảo từ quy trình thực tế tại Bệnh viện Nguyễn Tri Phương [6]).



Hình 1.2: Sơ đồ tích hợp hệ thống hỗ trợ phân tích.

1.2.2 Ý nghĩa khoa học của đề tài

Đề tài cung cấp đánh giá thực nghiệm về giá trị bổ sung của bệnh sử lâm sàng được thu nhận trước khi đọc ảnh đối với bài toán phân loại ảnh X-quang xương. Qua đó, nghiên cứu góp phần làm rõ mức độ mà thông tin lâm sàng có thể cải thiện biểu diễn và hiệu quả phân loại so với phương pháp chỉ sử dụng hình ảnh.

Nghiên cứu đồng thời khảo sát khả năng thích nghi của mô hình ngôn ngữ-thị giác y khoa được tiền huấn luyện trên dữ liệu quy mô lớn đối với dữ liệu X-quang xương có quy mô hạn chế và phân bố mất cân bằng. Kết quả nghiên cứu cung cấp thêm cơ sở thực nghiệm cho việc ứng dụng các mô hình nền tảng đa phương thức vào những miền y khoa chuyên biệt.

Bên cạnh hiệu quả phân loại, đề tài xem xét khả năng nhận diện dữ liệu ngoài phân phối và phân tích vùng ảnh ảnh hưởng đến dự đoán. Việc đánh giá đồng thời các khía cạnh này góp phần mở rộng tiêu chí nghiên cứu từ độ chính xác đơn thuần sang khả năng tổng quát hóa, độ tin cậy và tính minh bạch của hệ thống.

1.2.3 Ý nghĩa thực tiễn của đề tài

Hệ thống được đề xuất hướng đến hỗ trợ bác sĩ trong quá trình phân tích ảnh X-quang bằng cách kết hợp thông tin từ ảnh X-quang và dữ liệu lâm sàng ban đầu để đưa ra kết quả phân loại. Quá trình huấn luyện tận dụng bệnh sử lâm sàng nhằm học mối quan hệ giữa ảnh X-quang và biểu hiện của bệnh lý. Cách tiếp cận này phù hợp với quy trình khám chữa bệnh thực tế tại các cơ sở y tế, góp phần nâng cao khả năng ứng dụng của hệ thống trong thực tiễn.

Ngoài ra, quá trình nghiên cứu góp phần xây dựng và chuẩn hóa một bộ dữ liệu đa phương thức gồm ảnh X-quang và bệnh sử lâm sàng từ dữ liệu thực tế tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh. Bộ dữ liệu và quy trình xử lý có thể tạo nền tảng cho các nghiên cứu tiếp theo về phân loại bệnh lý xương và mô hình ngôn ngữ-thị giác y khoa tại Việt Nam.

Đồng thời, mô hình cung cấp các bản đồ nhiệt trực quan hóa vùng ảnh

trong ảnh X-quang ảnh hưởng đến kết quả dự đoán và cơ chế cảnh báo đối với các mẫu dữ liệu ngoài phân phối, góp phần nâng cao tính minh bạch, độ tin cậy và tính an toàn khi hỗ trợ bác sĩ trong quá trình phân tích và đưa ra chẩn đoán xác định.

1.3 Giới thiệu bài toán

Bài toán được nghiên cứu trong đề tài là bài toán phân loại đa lớp ảnh X-quang sử dụng học sâu đa phương thức. Mục tiêu của hệ thống là dự đoán các loại bệnh hoặc tổn thương dựa trên đồng thời dữ liệu hình ảnh X-quang và thông tin lâm sàng liên quan.

- **Đầu vào:** Hệ thống nhận vào các nguồn dữ liệu sau:

- Ảnh X-quang của bệnh nhân:

$$x^{img} \in \mathbb{R}^{H \times W \times C}$$

trong đó:

- * H, W : chiều cao và chiều rộng ảnh,
- * C : số kênh màu của ảnh.

- Thông tin lâm sàng (lời khai bệnh nhân, triệu chứng, tiền sử bệnh).

$$x^{txt} = (w_1, w_2, \dots, w_T)$$

trong đó:

- * w_t : token tại vị trí thứ t trong văn bản,
- * T : số lượng token trong văn bản.

- Tập nhãn được định nghĩa trước:

$$\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$$

với K là số lớp bệnh cần phân loại.

- **Đầu ra:** Hệ thống sinh ra hai đầu ra chính:

– Nhận dự đoán cuối cùng hoặc cảnh báo dữ liệu ngoài phân phối:

$$\hat{y} = \begin{cases} \text{OOD}, & \text{nếu } s_{\text{OOD}}(x^{img}, x^{txt}) > \tau, \\ \arg \max_{y_k \in \mathcal{Y}} p(y_k | x^{img}, x^{txt}), & \text{ngược lại.} \end{cases}$$

trong đó:

- * $s_{\text{OOD}}(x^{img}, x^{txt})$ là điểm ngoài phân phối của mẫu đầu vào;
 - * τ là ngưỡng từ chối được xác định trên tập dữ liệu;
 - * $p(y_k | x^{img}, x^{txt})$ là điểm dự đoán của lớp y_k ;
 - * $\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$ là tập các lớp nội phân phối đã biết.
- **Bản đồ nhiệt trực quan hóa:** Hệ thống sinh ra bản đồ nhiệt trên ảnh nhằm thể hiện các vùng có ảnh hưởng đến quyết định dự đoán của mô hình.

1.3.1 Các thách thức trong bài toán

Mặc dù các mô hình học sâu đa phương thức đã đạt được nhiều kết quả tích cực, bài toán vẫn tồn tại nhiều thách thức cần được giải quyết:

- **Sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu đầu vào thực tế:** Tồn tại sự chênh lệch lớn giữa các bộ dữ liệu đa phương thức hiện có (thường là cặp ảnh X-quang và báo cáo đọc ảnh X-quang) so với luồng công việc thực tế lâm sàng (bao gồm ảnh chụp X-quang kết hợp với báo cáo tổng quát), làm hạn chế khả năng ứng dụng trực tiếp của các mô hình.
- **Sự khác biệt về không gian và ngữ nghĩa giữa dữ liệu hình ảnh và dữ liệu văn bản:** Sự khác biệt này gây khó khăn cho quá trình học biểu diễn chung, yêu cầu một cơ chế dung hợp hiệu quả.
- **Bảo toàn tổn thương nhỏ trên ảnh độ phân giải cao:** Việc co toàn bộ ảnh X-quang về kích thước cố định ở độ phân giải thấp của

các mô hình hiện nay (224x224) có thể làm mất đi các chi tiết cục bộ quan trọng, đặc biệt là các tổn thương nhỏ, dẫn đến hiệu quả phân loại bị hạn chế.

- **Hạn chế của dữ liệu thực tế:** Dữ liệu y tế thường có số lượng hạn chế và mất cân bằng giữa các loại bệnh, đặt ra yêu cầu đặc biệt về thiết kế mô hình để tận dụng tối đa thông tin có sẵn.
- **Dữ liệu ngoài phân phối:** Các bộ phân loại đóng phổ biến hiện tại chưa được thiết kế để xử lý các trường hợp dữ liệu ngoài phân phối, dẫn đến nguy cơ đưa ra dự đoán không chính xác với độ tin cậy cao đối với những ca bệnh mới chưa từng xuất hiện trong dữ liệu huấn luyện, đặt ra yêu cầu về khả năng tổng quát hóa và thích ứng của mô hình.
- **Khả năng giải thích của mô hình:** Khả năng giải thích của các mô hình vẫn còn hạn chế khiến độ tin cậy của người dùng vào các dự đoán của hệ thống là không cao, gây khó khăn cho việc triển khai trong thực tế lâm sàng.

1.4 Mục tiêu nghiên cứu

Đề tài hướng đến việc nghiên cứu và xây dựng một hệ thống học sâu đa phương thức phục vụ phân loại bệnh lý trên ảnh X-quang xương, hỗ trợ phân tích ảnh, khai thác đồng thời dữ liệu hình ảnh và bệnh sử lâm sàng nhằm đảm bảo hiệu quả phân loại so với các phương pháp hiện có và có khả năng thích ứng với các tình huống thực tế như dữ liệu ngoài phân phối và mất cân bằng lớp.

Các mục tiêu cụ thể của đề tài bao gồm:

1. Đánh giá vai trò của bệnh sử lâm sàng trong việc nâng cao hiệu quả phân loại bệnh lý xương khi kết hợp với ảnh X-quang, so với các phương pháp chỉ sử dụng dữ liệu hình ảnh.
2. Nghiên cứu chiến lược dung hợp đặc trưng đa phương thức, cụ thể là cơ chế chú ý chéo và so sánh với các phương pháp khác, nhằm xác

định phương pháp kết hợp hiệu quả giữa đặc trưng hình ảnh và văn bản.

3. Khảo sát các phương pháp tinh chỉnh hiệu quả tham số, nhằm giảm chi phí tính toán trong khi duy trì hoặc cải thiện hiệu quả phân loại so với việc tinh chỉnh toàn bộ tham số.
4. Nghiên cứu cơ chế phát hiện dữ liệu ngoài phân phối nhằm tăng khả năng nhận diện các mẫu bệnh lý chưa từng xuất hiện trong dữ liệu huấn luyện, nâng cao độ tin cậy của hệ thống trong môi trường thực tế.
5. Xây dựng cơ chế giải thích dựa trên bản đồ chú ý giúp trực quan hóa các vùng ảnh mà mô hình tập trung khi đưa ra quyết định phân loại, hỗ trợ bác sĩ trong việc đánh giá và kiểm chứng kết quả dự đoán.
6. Xây dựng và đánh giá hệ thống XBone-Net trên bộ dữ liệu phân loại bệnh lý xương có phân bố mất cân bằng, so sánh với các mô hình nền tảng y khoa hiện có.

1.5 Đối tượng và phạm vi nghiên cứu

1.5.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học sâu đa phương thức sử dụng đồng thời dữ liệu hình ảnh và văn bản trong bài toán phân loại ảnh X-quang xương. Cụ thể, nghiên cứu tập trung vào các thành phần chính sau:

- Các mô hình ngôn ngữ trực quan tiền huấn luyện trên dữ liệu y khoa và dữ liệu tổng quát, được sử dụng làm bộ mã hóa đặc trưng đa phương thức.
- Các chiến lược dung hợp đặc trưng đa phương thức, bao gồm cơ chế chú ý chéo và phép nối đặc trưng, nhằm kết hợp thông tin từ ảnh X-quang và bệnh sử lâm sàng.

- Các phương pháp tinh chỉnh tham số hiệu quả cho các mô hình tiền huấn luyện quy mô lớn nhằm giảm chi phí tính toán.
- Các kiến trúc bộ phân loại, phục vụ bài toán phân loại đa lớp trên dữ liệu mất cân bằng và phát hiện dữ liệu ngoài phân phối.

1.5.2 Phạm vi nghiên cứu

Đề tài tập trung vào bài toán phân loại đa lớp bệnh lý xương trên ảnh X-quang, kết hợp với bệnh sử lâm sàng dạng văn bản. Phạm vi cụ thể bao gồm:

- **Dữ liệu:** Nghiên cứu sử dụng bộ dữ liệu BTXRD gồm 10 lớp bệnh lý xương, và bộ dữ liệu CTCH được thu thập từ Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.
- **Dữ liệu văn bản:** Trong quá trình huấn luyện và suy luận, hệ thống sử dụng bệnh sử lâm sàng được thu nhận trước khi đọc ảnh (chứa thông tin triệu chứng và tiền sử bệnh) thay vì báo cáo đọc ảnh X-quang, nhằm hạn chế rò rỉ nhãn và phù hợp hơn với thời điểm áp dụng hệ thống.
- **Vai trò hệ thống:** Hệ thống được thiết kế làm công cụ hỗ trợ phân tích ảnh, không thay thế vai trò của bác sĩ trong quá trình ra quyết định.
- **Giới hạn:** Đề tài không tập trung vào các bài toán phát hiện đối tượng, phân đoạn ảnh hay sinh báo cáo y khoa tự động.

1.6 Các câu hỏi nghiên cứu và giả thuyết

Trong các giả thuyết dưới đây, Macro F1-Score được sử dụng làm chỉ số chính cho bài toán phân loại do dữ liệu có phân bố mất cân bằng; Accuracy, Macro AUROC và Specificity được sử dụng làm các chỉ số bổ sung. Hiệu

quả tính toán được đánh giá thông qua số tham số có thể huấn luyện, mức sử dụng bộ nhớ và thời gian suy luận. Đối với phát hiện dữ liệu ngoài phân phối, các chỉ số chính gồm AUROC, AUPR-Out và FPR@95TPR.

- **Câu hỏi nghiên cứu 1:** Việc kết hợp bệnh sử lâm sàng được thu nhận trước khi ghi chụp ảnh với ảnh X-quang có cải thiện hiệu quả phân loại so với mô hình chỉ sử dụng ảnh không?

Giả thuyết 1: Mô hình sử dụng đồng thời ảnh X-quang và bệnh sử lâm sàng đạt Macro F1-Score cao hơn mô hình chỉ sử dụng ảnh hoặc chỉ sử dụng văn bản bệnh sử lâm sàng trên cùng tập dữ liệu và quy trình đánh giá.

- **Câu hỏi nghiên cứu 2:** Cơ chế chú ý chéo hai chiều có khai thác tương tác giữa ảnh và văn bản hiệu quả hơn phép nối đặc trưng và các biến thể chú ý chéo một chiều không?

Giả thuyết 2: Cơ chế chú ý chéo hai chiều đạt Macro F1-Score cao hơn các cấu hình dùng phép nối đặc trưng hoặc chỉ thực hiện chú ý theo một chiều khi các thành phần còn lại được giữ nguyên.

- **Câu hỏi nghiên cứu 3:** Chiến lược tinh chỉnh LoRA có đạt hiệu quả phân loại cạnh tranh trong khi giảm chi phí tính toán so với tinh chỉnh toàn bộ tham số trong trường hợp ít mẫu không?

Giả thuyết 3: LoRA đạt Macro F1-Score tương đương hoặc cao hơn tinh chỉnh toàn bộ tham số, đồng thời sử dụng ít tham số có thể huấn luyện và sử dụng ít bộ nhớ hơn.

- **Câu hỏi nghiên cứu 4:** Nhánh xử lý ảnh độ phân giải cao dựa trên lưới ảnh cục bộ và bộ tái lấy mẫu có tọa độ có cải thiện khả năng phân loại so với các phương pháp chỉ sử dụng ảnh toàn cục không?

Giả thuyết 4: Nhánh xử lý ảnh độ phân giải cao đạt Macro F1-Score cao hơn cấu hình chỉ sử dụng ảnh toàn cục khi sử dụng cùng mô hình xương sống và chiến lược huấn luyện.

- **Câu hỏi nghiên cứu 5:** Hệ thống đề xuất XBone-Net có đạt hiệu quả phân loại tốt hơn so với các mô hình nền tảng được tinh chỉnh

theo cùng cách thức đánh giá không?

Giả thuyết 5: XBone-Net đạt Macro F1-Score cao hơn mô hình đối chứng tốt nhất; các chỉ số còn lại được báo cáo như tiêu chí bổ sung thay vì giả định XBone-Net phải vượt trội trên mọi độ đo.

- **Câu hỏi nghiên cứu 6:** Không gian biểu diễn của XBone-Net có hỗ trợ phân biệt dữ liệu nội phân phối với các bộ dữ liệu ngoài phân phối được xác định trước không?

Giả thuyết 6: Ít nhất một phương pháp hậu xử lý được khảo sát, gồm khoảng cách Mahalanobis, Cosine-kNN, Energy Score và khoảng cách đến mốc văn bản, đạt AUROC lớn hơn mức ngẫu nhiên trong việc phân biệt dữ liệu nội phân phối và ngoài phân phối; phương pháp được lựa chọn dựa trên tập hiệu chỉnh thay vì tập kiểm thử.

- **Câu hỏi nghiên cứu 7:** Bản đồ chú ý của mô hình có tập trung vào các vùng tổn thương được chú thích trên ảnh X-quang không?

Giả thuyết 7: Trên các mẫu có chú thích tổn thương, tỷ lệ khối lượng chú ý nằm trong vùng tổn thương lớn hơn tỷ lệ diện tích của vùng này trên ảnh, tương ứng với tỷ số tập trung chú ý lớn hơn 1.

1.7 Đóng góp chính của đề tài

Các đóng góp chính của đề tài bao gồm:

1. **Quy trình sử dụng dữ liệu đa phương thức hạn chế rò rỉ nhãn:** Xây dựng quy trình sử dụng ảnh X-quang cùng bệnh sử lâm sàng được thu nhận trước khi đọc ảnh trong cả hai giai đoạn huấn luyện và khi suy luận. Báo cáo đọc ảnh, vốn có thể chứa trực tiếp kết luận chẩn đoán, được loại khỏi pipeline chính và chỉ được sử dụng trong các thí nghiệm loại bỏ thành phần nhằm đánh giá rò rỉ nhãn.
2. **Kiến trúc XBone-Net xử lý ảnh độ phân giải cao:** Phát triển nhánh thị giác bao phủ toàn bộ ảnh X-quang bằng lưới ảnh cục bộ xác định, tổng hợp các token cục bộ và nén chúng bằng bộ tái lấy mẫu có sử dụng thông tin tọa độ. Biểu diễn thị giác sau đó được kết hợp với biểu diễn bệnh sử lâm sàng bằng cơ chế chú ý chéo hai chiều.
3. **Quy trình huấn luyện hai giai đoạn với LoRA:** Thiết kế Giai đoạn 1 sử dụng Semantic Matching Loss để căn chỉnh biểu diễn ảnh và bệnh sử lâm sàng, sau đó tiếp tục tối ưu các adapter LoRA cùng mô-đun dung hợp trong Giai đoạn 2. Cách thiết kế này cho phép thích nghi mô hình BioMedCLIP với dữ liệu X-quang xương trong khi chỉ cập nhật một phần nhỏ tổng số tham số.

4. **Bộ phân loại dựa trên tâm lớp thực nghiệm:** Xây dựng bộ phân loại phi tham số sử dụng độ tương đồng cosine đến các tâm lớp được ước lượng lại từ biểu diễn của tập huấn luyện. Trong Giai đoạn 2, mô hình được tối ưu bằng Cross-Entropy có trọng số theo số mẫu hiệu dụng nhằm giảm ảnh hưởng của phân bố lớp mất cân bằng.
5. **Khung phát hiện dữ liệu ngoài phân phối:** Tích hợp quy trình phát hiện ngoài phân phối theo hướng hậu xử lý trên không gian biểu diễn đã học, hỗ trợ khoảng cách Mahalanobis, Cosine-kNN, Energy Score và khoảng cách đến mốc văn bản. Ngưỡng từ chối được hiệu chỉnh trên dữ liệu nội phân phối tách biệt trước khi đánh giá trên các bộ dữ liệu ngoài phân phối được xác định trước.
6. **Cung cấp khả năng giải thích kết quả:** Xây dựng công cụ trích xuất bản đồ chú ý đặc thù theo lớp từ mô-đun chú ý chéo hai chiều, chiếu trọng số chú ý ngược về các vùng ảnh gốc thông qua bộ tái lấy mẫu không gian và định lượng mức độ tập trung trên vùng tổn thương được chú thích. Công cụ này hỗ trợ phân tích quyết định của mô hình, tuy nhiên không được xem là bằng chứng thay thế cho đánh giá lâm sàng của bác sĩ.

1.8 Bố cục luận văn

Chương 1: Giới thiệu. Chương này cung cấp cái nhìn tổng quan về bối cảnh nghiên cứu, xác định rõ vấn đề cần giải quyết, mục tiêu, phương pháp tiếp cận và những đóng góp chính của đề tài. Đây là phần nền tảng định hướng cho toàn bộ nội dung khóa luận.

Chương 2: Các công trình nghiên cứu liên quan. Chương này tập trung hệ thống hóa các hướng tiếp cận đã được mô tả ở trên, làm tiền đề cho việc xây dựng giải pháp của khóa luận. Trọng tâm của chương là việc phân tích các kiến trúc mô hình ngôn ngữ trực quan cùng các chiến lược dung hợp đặc trưng đa phương thức. Bên cạnh đó, các kỹ thuật tinh chỉnh tối ưu và phương pháp nhận diện dữ liệu ngoài phân phối cũng được xem xét toàn diện, từ đó thiết lập cơ sở lý thuyết vững chắc và định vị rõ

ràng hướng giải quyết của đề tài so với các công trình đi trước.

Chương 3: Phương pháp đề xuất. Đây là chương trọng tâm mô tả chi tiết quy trình xây dựng hệ thống. Tại đây, nhóm sẽ trình bày cụ thể về kiến trúc mô hình được kế thừa, quy trình xử lý dữ liệu đầu vào (cả ảnh và văn bản), thiết kế các hàm mất mát, và chiến lược huấn luyện mô hình. Các sơ đồ khối và thuật toán sẽ được mô tả chi tiết để minh họa cho giải pháp.

Chương 4: Thực nghiệm và Kết quả. Chương này trình bày về bộ dữ liệu được sử dụng, thiết lập môi trường thực nghiệm và các chỉ số đánh giá. Kết quả thực nghiệm sẽ được phân tích, so sánh đối chiếu với các phương pháp khác để làm rõ ưu nhược điểm của mô hình đề xuất.

Chương 5: Kết luận và Hướng phát triển. Chương cuối cùng tổng kết lại những kết quả đạt được so với mục tiêu ban đầu, nhìn nhận những hạn chế còn tồn tại của hệ thống và đề xuất các hướng nghiên cứu tiếp theo để hoàn thiện và mở rộng ứng dụng trong tương lai.

Chương 2

Các công trình nghiên cứu liên quan

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ mô tả tổng quan các nghiên cứu về các mô hình nền tảng, các kỹ thuật tinh chỉnh hiệu quả tham số và phương pháp phát hiện dữ liệu ngoài phân phối, từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

2.1 Các mô hình nền tảng

2.1.1 Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu

Sự kết hợp giữa dữ liệu cận lâm sàng và báo cáo lâm sàng, lịch sử bệnh lý đã tạo ra những bước tiến lớn trong việc cải thiện độ chính xác của các mô hình chẩn đoán, đặc biệt là thông qua việc sử dụng văn bản để bù đắp những thiếu sót thông tin mà hình ảnh đơn thuần không thể cung cấp. Nghiên cứu của X. Mei [29] trong việc chẩn đoán COVID-19 là một minh chứng rõ nét: khi ảnh chụp CT ngực ở giai đoạn sớm có thể chưa biểu hiện bất thường, việc tích hợp thông tin lâm sàng thông qua mạng MLP với đặc trưng ảnh từ CNN đã giúp mô hình nhận diện chính xác 68% số

bệnh nhân dương tính mà các bác sĩ X-quang đã bỏ sót. Mô hình TieNet [41] đã mã hóa các báo cáo y tế và tích hợp các cơ chế chú ý đa cấp để giống hàng các từ mang ý nghĩa quan trọng với các vùng ảnh tương ứng, cải thiện trung bình 6% chỉ số AUC so với các mô hình chỉ dùng ảnh. Gần đây, IRENE [56] đưa tất cả dữ liệu về một dạng token chung và sử dụng một mô hình Transformer duy nhất, cho phép văn bản trực tiếp tương tác và giải thích các token của ảnh ở cấp độ cục bộ.

Nhìn chung, những nghiên cứu này minh chứng rằng sự đóng góp của văn bản đã đi từ việc chỉ là một véc-tơ thông tin ghép nối thêm, trở thành một thành phần cốt lõi có khả năng giống hàng ngữ nghĩa và định hướng trong cơ chế chú ý. Tuy nhiên, các mô hình xây dựng từ đầu thường đòi hỏi dữ liệu ghép cặp quy mô lớn và chi phí huấn luyện cao, tạo tiền đề cho sự xuất hiện của các mô hình ngôn ngữ trực quan y khoa.

2.1.2 Mô hình ngôn ngữ trực quan y khoa (Med-VLMs)

Các mô hình ngôn ngữ trực quan đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu, Med-VLMs kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Chiến lược **học tương phản (Contrastive Learning)** là hướng tiếp cận được ứng dụng rộng rãi nhất và có liên quan trực tiếp đến phương pháp đề xuất trong luận văn. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh – văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau.

ConVIRT [52] là nghiên cứu tiên phong áp dụng học tương phản cho

dữ liệu y khoa, sử dụng ResNet50 và BERT để tối ưu bộ mã hóa ảnh và văn bản, đạt 90,3% accuracy trên bộ dữ liệu COVIDx. GLoRIA [16] mở rộng hướng tiếp cận này bằng cách kết hợp hai hàm mất mát toàn cục (global contrastive) và cục bộ (local contrastive), cho phép căn chỉnh chi tiết giữa các vùng trong ảnh và các từ trong câu. MedCLIP [43] đề xuất cơ chế tách cặp và trích xuất tri thức cùng hàm mất mát Semantic Matching nhằm giải quyết vấn đề âm tính giả (false negative) — khi các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý. BiomedCLIP [50] kế thừa kiến trúc CLIP với bộ mã hóa ViT-Base và PubMedBERT, được tiền huấn luyện trên 15 triệu cặp dữ liệu từ tập PMC-15M, đạt độ chính xác phân loại 83%.

Ngoài học tương phản, các hướng tiếp cận khác bao gồm **học có che giấu (Masked Learning)** và **tích hợp tri thức y khoa (Knowledge Integration)**. Tuy nhiên, các phương pháp này thường phụ thuộc vào nguồn dữ liệu ghép cặp sẵn hoặc đồ thị tri thức chuyên biệt, hạn chế khả năng ứng dụng trên các bài toán không có sẵn nguồn tri thức ngoài.

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Phương pháp			
			Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	Học tương phản	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	Học tương phản	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	Học tương phản	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	Học tương phản	ViT-Base	PubMedBERT	Contrastive Alignment	N/a

Bảng 2.1: Bảng tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản.

Song song với các Med-VLMs, sự phát triển của các mô hình ngôn ngữ lớn (LLMs) đa phương thức như Med-Flamingo [32], LLaVA-Med [24] hay Med-PaLM M [40] đã cho thấy tiềm năng trong các tác vụ hội thoại và hỗ trợ ra quyết định y khoa. Tuy nhiên, các mô hình này thường có quy mô rất lớn, chi phí huấn luyện và suy luận cao, đồng thời vẫn tồn tại nguy cơ tạo ra thông tin không chính xác (hallucination). Do đó, đối với các bài toán phân loại chuyên biệt như phân loại ảnh X-quang xương, việc sử dụng các mô hình ngôn ngữ – thị giác chuyên dụng kết hợp tinh chỉnh hiệu

quả tham số thường phù hợp và hiệu quả hơn.

2.2 Biểu diễn ảnh độ phân giải cao và thông tin không gian

2.2.1 Giới hạn của phép co giãn ảnh toàn cục

Các backbone ViT được tiền huấn luyện thường sử dụng kích thước đầu vào cố định. Khi toàn bộ ảnh X-quang có kích thước lớn được co về một ảnh nhỏ, cấu trúc tổng thể vẫn được duy trì nhưng một số chi tiết cục bộ có thể bị làm mờ. Ngược lại, đưa trực tiếp ảnh độ phân giải cao vào Transformer làm tăng số token và chi phí attention. FPT [17] xem xét bài toán chuyển giao trên ảnh y khoa độ phân giải cao và sử dụng lựa chọn token cùng mạng nhánh để giảm yêu cầu bộ nhớ. Mặc dù cơ chế của FPT khác pipeline trong luận văn, công trình này cho thấy cần xem xét đồng thời độ chi tiết và chi phí tính toán khi thích nghi mô hình nền tảng cho ảnh y khoa.

Một hướng khác là chuyển tập đặc trưng đầu vào lớn thành ngân sách latent cố định. Perceiver [18] sử dụng attention bất đối xứng để ánh xạ đầu vào có số phần tử lớn vào một tập latent nhỏ. Flamingo [2] sử dụng Perceiver Resampler để tạo số token thị giác cố định trước khi kết nối với mô hình ngôn ngữ. Các nghiên cứu này cung cấp cơ sở khái niệm cho việc kiểm soát ngân sách token, nhưng không đồng nghĩa với việc pipeline của luận văn sử dụng learned queries giống Perceiver.

2.2.2 Kết hợp ngữ cảnh toàn cục và vùng cục bộ

Đối với ảnh X-quang xương, nhánh toàn cục hỗ trợ duy trì vị trí giải phẫu và cấu trúc chung, trong khi các vùng cục bộ giữ lại thông tin chi

tiết ở độ phân giải đầu vào của backbone. Tuy nhiên, nếu chỉ gom trung bình các token cục bộ, mô hình có thể mất thông tin về vị trí tương đối của từng vùng. Vì vậy, tọa độ đã chuẩn hóa có thể được bổ sung vào token trước khi dung hợp, với hệ số điều khiển để thông tin vị trí không lấn át nội dung ảnh.

Pipeline cuối cùng sử dụng một ảnh toàn cục (*global view*) và bốn ảnh cục bộ (*local view*) được chọn theo chiến lược chọn thưa có trọng tâm (*sparse-focal*) chỉ từ tín hiệu ảnh. Mỗi vùng cục bộ đóng góp CLS token và token tóm tắt patch; tám token được truyền trực tiếp qua mô-đun không gian có bổ sung tọa độ. Cách thiết kế này gần với một ngân sách token xác định hơn là một bộ resampler dùng truy vấn học được. Hiệu quả của toàn bộ nhánh ảnh độ phân giải cao cần được kiểm chứng bằng thí nghiệm loại bỏ thành phần, thay vì được giả định từ các công trình dùng kiến trúc khác. Nếu cần tách riêng đóng góp của tọa độ, quy trình thực nghiệm phải bổ sung một cấu hình chỉ tắt thành phần này trong khi giữ nguyên cách chọn vùng. Những đánh đổi chính được tổng hợp trong Bảng 2.2.

Chiến lược	Đặc điểm	Khả năng đáp ứng	Hạn chế cần xem xét
Co giãn ảnh toàn cục	Một ảnh được đưa về kích thước cố định	Chi phí thấp, duy trì bố cục tổng thể	Có thể làm giảm chi tiết cục bộ nhỏ.
Xử lý trực tiếp ảnh độ phân giải cao	Tăng kích thước ảnh hoặc số patch	Giữ nhiều chi tiết hơn	Tăng bộ nhớ và chi phí attention; FPT [17] xem xét sự đánh đổi này.
Latent resampling	Nén tập token đầu vào vào số latent cố định	Kiểm soát độ dài chuỗi	Hiệu quả phụ thuộc dữ liệu và cách tối ưu truy vấn học được; đại diện bởi Perceiver [18] và Flamingo [2].
Global-local với token cố định	Kết hợp ảnh toàn cục, các vùng cục bộ và tọa độ	Cân bằng ngữ cảnh, chi tiết và ngân sách token	Phụ thuộc vào quy tắc chọn vùng; cần đánh giá bằng ablation trên cùng dữ liệu.

Bảng 2.2: Các chiến lược xử lý ảnh độ phân giải cao và sự đánh đổi chính.

2.3 Các kỹ thuật tinh chỉnh hiệu quả tham số

Sự xuất hiện của các Mô hình Nền tảng (Foundation Models) nói chung và Mô hình Ngôn ngữ – Thị giác Y sinh (Med-VLMs) nói riêng đã mang lại một nền tảng tri thức đa phương thức khổng lồ. Tuy nhiên, để triển khai hiệu quả các mô hình này vào các bài toán lâm sàng đặc thù, quá trình chuyển giao tri thức là bắt buộc.

Trước đây, hai chiến lược phổ biến nhất là tinh chỉnh toàn phần (Full Fine-tuning) và dò tuyến tính (Linear Probing). Tinh chỉnh toàn phần cập nhật lại toàn bộ tham số của mô hình gốc, mang lại khả năng thích ứng cao nhưng đòi hỏi chi phí tính toán, bộ nhớ khổng lồ và rất dễ dẫn đến hiện tượng “quên thảm khốc” (catastrophic forgetting) trên các tập dữ liệu y tế nhỏ. Ngược lại, dò tuyến tính đóng băng toàn bộ mạng nơ-ron gốc và chỉ huấn luyện một lớp phân loại duy nhất ở cuối, tiết kiệm tài nguyên nhưng hạn chế khả năng thích ứng khi sự chênh lệch phân phối (domain shift) giữa dữ liệu gốc và dữ liệu y tế là quá lớn.

Để giải quyết bài toán đánh đổi giữa hiệu năng và chi phí tính toán, Tinh chỉnh Hiệu quả Tham số (Parameter-Efficient Fine-Tuning – PEFT) đã nổi lên như một giải pháp thay thế. Kỹ thuật này chỉ cập nhật hoặc thêm mới một lượng rất nhỏ tham số, giúp tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các phương pháp PEFT được chia thành ba hướng tiếp cận chính:

2.3.1 Tinh chỉnh sử dụng câu nhắc (Prompt Tuning)

Hướng tiếp cận này chèn thêm các tham số (vector) có thể học được vào không gian đầu vào của mô hình mà không thay đổi cấu trúc mạng bên trong.

- **Điểm mạnh:** Tiết kiệm tham số tối đa, bảo toàn nguyên vẹn tri thức của mô hình gốc, đặc biệt hiệu quả trong các kịch bản học ít

mẫu (few-shot) hoặc không mẫu (zero-shot).

- **Điểm yếu:** Tối ưu hóa khó khăn do không gian biểu diễn bị giới hạn ở đầu vào, nhạy cảm với cách khởi tạo, và chiếm dụng một phần độ dài của chuỗi đầu vào.

Trong lĩnh vực y tế, PLIP [49] kết hợp đặc trưng thị giác với câu nhắc hiệu quả, đạt 0,896 AUC chỉ với 5% dữ liệu PanNuke. BiomedCoOp [20] tích hợp mô hình ngôn ngữ lớn để tự động sinh các câu nhắc ngữ nghĩa, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản.

2.3.2 Tinh chỉnh bộ điều hợp (Adapter Tuning)

Phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ (adapters) vào giữa các lớp kiến trúc của mạng học sâu.

- **Điểm mạnh:** Tính mô-đun hóa cao, dễ dàng thêm/bớt các adapter cho các tác vụ khác nhau mà không can thiệp vào tham số gốc.
- **Điểm yếu:** Việc chèn thêm các lớp mạng vật lý làm tăng độ trễ suy luận (inference latency), hạn chế khả năng triển khai trên các hệ thống đòi hỏi thời gian thực.

Điện hình, CLIPath [21] sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu nhỏ. FTB [33] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức.

2.3.3 Tinh chỉnh chọn lọc (Selective Tuning)

Hướng đi này không thêm bất kỳ tham số mới nào, mà chỉ chọn lọc ra một lượng nhỏ các tham số quan trọng nhất của mô hình gốc để cập nhật.

- **Điểm mạnh:** Không làm thay đổi kiến trúc mô hình, hoàn toàn không gây tăng độ trễ (zero inference latency) do tham số cập nhật được hợp nhất trực tiếp vào trọng số gốc.

- **Điểm yếu:** Đòi hỏi phương pháp heuristic phức tạp để xác định chính xác các tham số nào ảnh hưởng lớn nhất đến hiệu năng của tác vụ mục tiêu.

Nổi bật nhất trong nhóm này là cơ chế thích ứng hạng thấp LoRA (Low-Rank Adaptation). LoRA đóng băng toàn bộ trọng số của mô hình tiền huấn luyện, đồng thời tiêm các ma trận phân rã hạng thấp vào các khối Attention. LCBB [26] áp dụng LoRA và đạt 93,1% AUROC trên tập RSNA với chỉ 10% dữ liệu gán nhãn, bám sát hiệu năng của tinh chỉnh toàn phần nhưng giảm thiểu tối đa chi phí.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Nguyên lý	Kết quả nổi bật
1	PLIP (2024)	Prompt Tuning	Kết hợp câu nhắc thị giác với selective tuning, tận dụng đặc trưng hình ảnh để tinh chỉnh hiệu quả	0,896 AUC (5% PanNuke)
2	CLIPath (2023)	Adapter Tuning	Sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu mô bệnh học	Cải thiện so với CLIP trên dữ liệu nhỏ
3	LCBB (2024)	Selective Tuning (LoRA)	Áp dụng LoRA vào bộ mã hóa thị giác, giữ nguyên hiệu năng tinh chỉnh toàn phần	93,1% AUROC (RSNA, 10%)
4	FTB (2024)	Adapter Tuning	Mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản, chất lọc thông tin đa phương thức	Cải thiện trên CheXpert, RSNA

Bảng 2.3: Bảng tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện cho các mô hình ngôn ngữ trực quan y khoa.

2.4 Các phương pháp phát hiện dữ liệu ngoài phân phối

Phát hiện dữ liệu ngoài phân phối (Out-of-Distribution Detection – OOD Detection) là bài toán xác định các mẫu dữ liệu không thuộc phân phối của tập huấn luyện nhằm nâng cao độ tin cậy và tính an toàn của các hệ thống học sâu. Trong lĩnh vực chẩn đoán hình ảnh y khoa, khả năng phát hiện các trường hợp chưa từng xuất hiện hoặc khác biệt đáng kể so với dữ liệu huấn luyện có ý nghĩa quan trọng nhằm giảm nguy cơ đưa ra các dự đoán sai với độ tin cậy cao. Các phương pháp OOD hiện nay có thể được chia thành các nhóm chính sau đây.

2.4.1 Các phương pháp hậu xử lý dựa trên đầu ra mô hình (Post-hoc Methods)

Nhóm phương pháp này tận dụng trực tiếp đầu ra của một mô hình đã được huấn luyện mà không cần thay đổi kiến trúc hoặc huấn luyện lại mô hình.

- **Maximum Softmax Probability (MSP):** Sử dụng xác suất Softmax lớn nhất làm độ tin cậy của dự đoán. Các mẫu có xác suất cực đại thấp được xem là ứng viên OOD. Tuy nhiên, các mạng nơ-ron sâu thường có xu hướng dự đoán quá tự tin (overconfidence), làm giảm hiệu quả của phương pháp.
- **ODIN (Out-of-Distribution detector for Neural Networks):** Mở rộng MSP bằng cách kết hợp Temperature Scaling và nhiễu đầu vào (input perturbation) nhằm gia tăng khoảng cách logit giữa dữ liệu trong phân phối (In-Distribution – ID) và dữ liệu OOD.
- **Energy-based Score:** Thay vì sử dụng xác suất Softmax, phương pháp này sử dụng giá trị năng lượng được tính từ vector logit:

$$E(x) = -T \log \sum_i \exp \left(\frac{f_i(x)}{T} \right),$$

trong đó $f_i(x)$ là logit của lớp thứ i và T là hệ số nhiệt độ. Dữ liệu ID thường có mức năng lượng thấp hơn so với dữ liệu OOD.

2.4.2 Các phương pháp dựa trên không gian đặc trưng (Feature-space-based Methods)

Khác với các phương pháp chỉ sử dụng đầu ra của mô hình, nhóm phương pháp này thực hiện phát hiện OOD trực tiếp trên không gian đặc trưng (embedding space). Ý tưởng chính là đo khoảng cách giữa embedding

của mẫu kiểm thử và phân bố đặc trưng của dữ liệu huấn luyện. Một số độ đo khoảng cách phổ biến bao gồm:

- **Khoảng cách Euclidean:**

$$d_E(z, c_k) = \|z - c_k\|_2.$$

Khoảng cách Euclidean giả định các cụm dữ liệu có dạng cầu và có phương sai đồng đều theo mọi chiều. Phương pháp đơn giản nhưng không phản ánh được sự tương quan giữa các chiều đặc trưng.

- **Khoảng cách Cosine:**

$$d_C(z, c_k) = 1 - \frac{z \cdot c_k}{\|z\| \|c_k\|}.$$

Khoảng cách Cosine chỉ xét hướng của vector đặc trưng và bỏ qua độ lớn (magnitude), thường được sử dụng trong các bài toán metric learning và Vision-Language Models.

- **Khoảng cách Mahalanobis:**

$$d_M(z, c_k) = \sqrt{(z - c_k)^T \Sigma_k^{-1} (z - c_k)},$$

trong đó Σ_k là ma trận hiệp phương sai của lớp k . Khác với Euclidean và Cosine, Mahalanobis khai thác thêm thông tin về phương sai và tương quan giữa các chiều đặc trưng, nhờ đó phản ánh chính xác hơn mức độ bất thường của mẫu kiểm thử đối với phân bố của từng lớp, đặc biệt trong các trường hợp Near-OOD.

2.4.3 Các phương pháp học biểu diễn phục vụ phát hiện OOD (Representation Learning)

Các phương pháp trong nhóm này không trực tiếp thực hiện phát hiện OOD mà tập trung xây dựng không gian đặc trưng có tính phân biệt cao,

từ đó nâng cao hiệu quả của các phương pháp phát hiện OOD dựa trên khoảng cách. Một số hướng tiếp cận tiêu biểu gồm:

- **Contrastive Learning:** Học biểu diễn bằng cách kéo gần các mẫu tương đồng và đẩy xa các mẫu khác lớp trong không gian đặc trưng.
- **Center Loss:** Giảm phương sai nội lớp bằng cách học một tâm biểu diễn cho mỗi lớp và ép các embedding tiến gần tâm tương ứng.
- **Prototypical Loss:** Biểu diễn mỗi lớp bởi một nguyên mẫu (prototype), được tính bằng trung bình embedding của các mẫu cùng lớp:

$$c_k = \frac{1}{|S_k|} \sum_{x_i \in S_k} f_{\theta}(x_i).$$

Trong quá trình huấn luyện, embedding của các mẫu được kéo về prototype của lớp tương ứng và tách xa prototype của các lớp khác, giúp giảm phương sai nội lớp và tăng khoảng cách giữa các lớp. Nhờ đó, không gian đặc trưng trở nên phân biệt hơn, tạo điều kiện thuận lợi cho các phương pháp OOD dựa trên khoảng cách như Mahalanobis.

2.4.4 Các phương pháp sinh và định lượng độ không chắc chắn

Nhóm phương pháp này tiếp cận bài toán OOD thông qua khả năng mô hình hóa phân phối dữ liệu hoặc ước lượng độ không chắc chắn của mô hình.

- **Reconstruction Error:** Các mô hình Autoencoder hoặc Variational Autoencoder được huấn luyện để tái tạo dữ liệu ID. Khi gặp dữ liệu OOD, sai số tái tạo thường tăng lên đáng kể.
- **Monte Carlo Dropout:** Thực hiện nhiều lần suy luận với Dropout được kích hoạt trong giai đoạn kiểm thử nhằm ước lượng độ không chắc chắn nhận thức (epistemic uncertainty). Phương sai lớn giữa các lần dự đoán là dấu hiệu cho thấy mẫu có khả năng thuộc OOD.

2.5 Bàn luận

2.5.1 Xu hướng ứng dụng học sâu đa phương thức trong chẩn đoán ảnh y khoa

Qua khảo sát các công trình nghiên cứu, có thể nhận thấy rằng học sâu đa phương thức đang trở thành xu hướng quan trọng trong lĩnh vực chẩn đoán ảnh y khoa. Thay vì chỉ khai thác thông tin từ ảnh y khoa, nhiều nghiên cứu đã kết hợp thêm dữ liệu văn bản như báo cáo chẩn đoán, tiền sử bệnh hoặc thông tin lâm sàng nhằm tận dụng tính bổ sung giữa các phương thức dữ liệu.

Song song với đó, sự xuất hiện của các mô hình ngôn ngữ trực quan y khoa như BiomedCLIP [50] đã mở ra hướng tiếp cận mới cho các bài toán phân loại ảnh y khoa. Nhờ được tiền huấn luyện trên tập dữ liệu ảnh – văn bản quy mô lớn, các mô hình này học được biểu diễn đa phương thức giàu ngữ nghĩa và có khả năng thích nghi tốt với nhiều tác vụ khác nhau. Kết hợp với các phương pháp tinh chỉnh hiệu quả tham số, việc khai thác các mô hình nền tảng trở nên khả thi hơn ngay cả khi dữ liệu huấn luyện còn hạn chế.

2.5.2 Hạn chế của các nghiên cứu hiện nay

Mặc dù đạt được nhiều kết quả tích cực, các nghiên cứu hiện nay vẫn tồn tại một số hạn chế khi áp dụng vào bài toán phân loại ảnh X-quang xương.

Thứ nhất, phần lớn các nghiên cứu được phát triển trên các bộ dữ liệu X-quang ngực hoặc các bệnh lý phổ biến, trong khi số lượng nghiên cứu dành riêng cho ảnh X-quang xương và các bệnh lý xương vẫn còn hạn chế. Đặc điểm của các tổn thương xương thường đa dạng, số lượng mẫu ít và có sự mất cân bằng giữa các lớp, khiến việc xây dựng mô hình có khả năng tổng quát tốt trở nên khó khăn hơn.

Thứ hai, nhiều phương pháp đa phương thức chỉ khai thác báo cáo đọc ảnh hoặc mô tả ngắn đi kèm ảnh mà chưa tận dụng đầy đủ các thông tin

lâm sàng như triệu chứng, tiền sử bệnh hoặc cơ chế chấn thương. Trong thực tế lâm sàng, đây đều là những nguồn thông tin quan trọng giúp bác sĩ đưa ra chẩn đoán chính xác hơn.

Thứ ba, mặc dù các mô hình nền tảng đạt hiệu quả cao, nhiều nghiên cứu vẫn lựa chọn tinh chỉnh toàn bộ tham số của mô hình. Cách tiếp cận này đòi hỏi chi phí tính toán lớn, đồng thời làm tăng nguy cơ quên tri thức đã được học trong giai đoạn tiền huấn luyện.

Cuối cùng, hầu hết các nghiên cứu chỉ tập trung tối ưu hiệu năng phân loại mà chưa quan tâm đầy đủ đến khả năng phát hiện dữ liệu ngoài phân phối. Trong môi trường lâm sàng, mô hình có thể gặp các trường hợp bệnh lý hiếm, dữ liệu có chất lượng thấp hoặc các bất thường chưa xuất hiện trong tập huấn luyện. Nếu không có cơ chế phát hiện OOD, mô hình vẫn có thể đưa ra dự đoán với độ tin cậy cao mặc dù kết quả không chính xác.

2.5.3 Cơ sở lựa chọn và định hướng phương pháp đề xuất

Từ những hạn chế trên, luận văn lựa chọn xây dựng hệ thống dựa trên việc kế thừa mô hình BiomedCLIP [50] kết hợp với thông tin lâm sàng để khai thác đồng thời đặc trưng hình ảnh và văn bản. Các lựa chọn thiết kế cụ thể được đưa ra dựa trên phân tích sau:

Về kỹ thuật tinh chỉnh: Kỹ thuật LoRA được lựa chọn thay vì tinh chỉnh toàn phần hoặc các phương pháp tinh chỉnh hiệu quả tham số khác, vì ba lý do chính:

- LoRA giảm số lượng tham số cần huấn luyện xuống đáng kể bằng cách tiêm các ma trận phân rã hạng thấp vào mạng nơ-ron, cho phép tinh chỉnh các mô hình VLM ngay cả khi nguồn lực tính toán bị hạn chế.
- Khác với Adapter Tuning chèn thêm các lớp ẩn vật lý làm chậm tốc độ xử lý, các ma trận trọng số của LoRA có thể được cộng gộp trực tiếp vào trọng số gốc, giúp không tăng độ trễ trong lúc suy luận.
- LoRA cho phép mô hình bám sát dữ liệu y tế đặc thù trong khi không

phá vỡ các cấu trúc tri thức đa phương thức tổng quát đã được tiền huấn luyện.

Về phương pháp phát hiện OOD: Luận văn kết hợp Weighted CE Loss và Mahalanobis Distance theo cơ chế hai giai đoạn tách biệt. Trong giai đoạn huấn luyện, Weighted CE Loss được sử dụng để tối ưu hóa việc phân loại. Sau khi mô hình được huấn luyện, Mahalanobis Distance được áp dụng theo cơ chế post-hoc để phát hiện dữ liệu ngoài phân phối. Mahalanobis được lựa chọn thay vì Euclidean hoặc Cosine vì có khả năng khai thác thêm thông tin về ma trận hiệp phương sai của từng lớp, phản ánh chính xác hơn mức độ bất thường của mẫu, đặc biệt đối với các trường hợp Near-OOD thường gặp trong dữ liệu y khoa.

Về kiến trúc pipeline: Hệ thống được thiết kế theo kiến trúc hai giai đoạn :

- **Giai đoạn 1 - Căn chỉnh tương phản:** Chỉ huấn luyện backbone (BiomedCLIP thông qua LoRA) bằng hàm mất mát tương phản, giúp backbone thích ứng với miền dữ liệu y khoa chuyên biệt. Mô-đun dung hợp và bộ phân loại được đóng băng trong giai đoạn này.
- **Giai đoạn 2 - Huấn luyện dung hợp và phân loại:** Trọng số nền của BiomedCLIP được giữ đóng băng, trong khi các adapter LoRA, spatial resampler và mô-đun dung hợp cross-attention tiếp tục được tối ưu. Bộ phân loại empirical-centroid không học prototype tự do mà cập nhật centroid từ trung bình embedding của tập huấn luyện, qua đó hạn chế nguy cơ quá khớp.

Kiến trúc chi tiết của hệ thống cùng quy trình huấn luyện và đánh giá sẽ được trình bày trong Chương 3.

Chương 3

Phương pháp đề xuất

3.1 Tổng quan phương pháp đề xuất

Nhóm nghiên cứu đề xuất XBone-Net như một pipeline học sâu đa phương thức dành cho phân loại ảnh X-quang xương, trong đó ảnh cung cấp bằng chứng hình thái và bệnh sử lâm sàng cung cấp ngữ cảnh liên quan đến tình trạng của người bệnh trước khi ảnh được diễn giải. Pipeline kế thừa bộ mã hóa thị giác và bộ mã hóa văn bản của BiomedCLIP [50], thích nghi hai bộ mã hóa bằng LoRA, bảo toàn đồng thời thông tin toàn cục và chi tiết cục bộ của ảnh, trao đổi thông tin giữa hai phương thức bằng chú ý chéo hai chiều, sau đó đưa biểu diễn dung hợp vào bộ phân loại dựa trên tâm lớp thực nghiệm. Báo cáo kết quả X-quang không được sử dụng làm đầu vào của pipeline chính nhằm hạn chế nguy cơ mô hình dựa vào từ khóa chẩn đoán thay vì học mối liên hệ giữa hình ảnh và bệnh sử.

Quy trình được chia thành quá trình huấn luyện ngoại tuyến và quá trình suy luận trực tuyến. Cách phân chia này làm rõ thành phần nào được cập nhật từ dữ liệu huấn luyện và thành phần nào chỉ thực hiện truyền thuận khi hệ thống tiếp nhận một ca mới. Trong cả hai quá trình, ảnh và văn bản đi qua cùng một quy tắc tiền xử lý và cùng một kiến trúc mã hóa; khác biệt chủ yếu nằm ở việc tính gradient, cập nhật tham số và ước lượng tâm lớp.

3.1.1 Huấn luyện hai giai đoạn trong quá trình ngoại tuyến (Offline)

Trong giai đoạn thứ nhất, ảnh X-quang và bệnh sử lâm sàng tương ứng được đưa qua hai bộ mã hóa để tạo biểu diễn trong một không gian chung. Mục tiêu khớp ngữ nghĩa được sử dụng để tăng mức tương hợp của cặp ảnh–văn bản tương ứng và ghi nhận quan hệ giữa các mẫu cùng lớp, qua đó giảm việc xem mọi cặp không trùng chỉ số là cặp âm. Mini-batch được lấy mẫu có nhận biết lớp để tăng khả năng mỗi lớp đóng góp nhiều hơn một mẫu vào cùng một batch, nhờ đó quan hệ đồng lớp trong mục tiêu mềm có thể được quan sát trực tiếp. Ở giai đoạn này, trọng số nền của BiomedCLIP được giữ cố định; các adapter LoRA và các thành phần tổng hợp đặc trưng ảnh cục bộ được cập nhật. Bộ dung hợp chú ý chéo và bộ phân loại chưa tham gia vào mục tiêu tối ưu của giai đoạn thứ nhất.

Trong giai đoạn thứ hai, các adapter LoRA được giữ ở dạng tách rời và tiếp tục được cập nhật thay vì hợp nhất vào trọng số nền. Biểu diễn ảnh và văn bản được đưa qua chú ý chéo hai chiều để hình thành biểu diễn dung hợp, sau đó các tâm lớp được ước lượng từ toàn bộ biểu diễn của tập huấn luyện. Hàm mất mát phân loại cập nhật adapter LoRA, thành phần biểu diễn ảnh cục bộ, mô-đun dung hợp và độ lệch riêng của từng lớp; các tâm lớp là thống kê thực nghiệm nên không nhận gradient. Việc tách hai giai đoạn giúp quá trình thích nghi không gian ảnh–văn bản được thực hiện trước khi tối ưu trực tiếp ranh giới quyết định của bài toán phân loại.

Sau mỗi epoch của giai đoạn thứ hai, tâm lớp được ước lượng lại bằng trạng thái hiện tại của bộ mã hóa trước khi đánh giá trên tập validation. Checkpoint được lựa chọn theo độ đo đã xác định trước trên tập validation, sau đó tâm lớp được tính lại một lần cuối từ tập huấn luyện bằng checkpoint được chọn. Tập kiểm thử không tham gia vào quá trình cập nhật tham số, lựa chọn checkpoint hoặc ước lượng tâm lớp.

3.1.2 Suy luận trong quá trình trực tuyến (Online)

Trong quá trình trực tuyến, một ảnh X-quang và bệnh sử lâm sàng của ca cần phân tích được xử lý bằng đúng pipeline đã sử dụng trong giai đoạn thứ hai. Các tham số của bộ mã hóa, adapter LoRA, mô-đun dung hợp, tâm lớp và độ lệch lớp đều được cố định; hệ thống chỉ thực hiện truyền thuận để tạo biểu diễn dung hợp, tính điểm của từng lớp và trả về lớp có điểm lớn nhất. Quá trình này không yêu cầu cập nhật gradient, không ước lượng lại tâm lớp từ mẫu mới và không sử dụng thông tin từ tập kiểm thử để điều chỉnh quyết định.

Biểu diễn dung hợp và đầu ra phân loại có thể được chuyển sang mô-đun OOD hậu xử lý đã hiệu chỉnh bằng dữ liệu huấn luyện và validation. Mô-đun OOD không làm thay đổi dự đoán phân loại bên trong XBone-Net mà bổ sung một tín hiệu về mức độ phù hợp của mẫu với phân phối đã quan sát. Vì vậy, kết quả phân loại và cảnh báo OOD được xem là hai đầu ra có mục đích khác nhau: đầu ra thứ nhất lựa chọn lớp gần nhất trong tập lớp đã biết, còn đầu ra thứ hai xem xét liệu mẫu có đủ tương đồng với dữ liệu trong phân phối hay không.

3.2 Các thành phần của pipeline

3.2.1 Đầu vào và tiền xử lý (Input and Pre-processing)

Mỗi mẫu huấn luyện gồm một ảnh X-quang, một bệnh sử lâm sàng và một nhãn lớp duy nhất. Tập dữ liệu huấn luyện được ký hiệu như sau.

$$\mathcal{D}_{\text{train}} = \{(X_i, R_i, y_i)\}_{i=1}^N. \quad (3.1)$$

Trong Công thức 3.1, N là số mẫu huấn luyện, X_i là ảnh X-quang gốc của mẫu thứ i , R_i là bệnh sử lâm sàng tương ứng và $y_i \in \{1, \dots, K\}$ là nhãn của một trong K lớp. Ký hiệu $\mathcal{D}_{\text{train}}$ chỉ tập huấn luyện và không

bao gồm tập validation hoặc tập kiểm thử.

Ảnh X-quang thường có độ phân giải và tỷ lệ khung hình khác nhau, trong khi bộ mã hóa thị giác kế thừa nhận đầu vào có kích thước cố định. Pipeline vì vậy tạo một ảnh toàn cục để giữ bố cục giải phẫu và bốn ảnh cục bộ để giữ lại chi tiết tại các vùng giàu thông tin. Ảnh toàn cục được tạo bằng phép biến đổi giữ tỷ lệ và thêm biên khi cần thiết, sau đó được chuẩn hóa theo quy tắc đầu vào của bộ mã hóa thị giác.

$$X_i^g = \mathcal{T}_g(X_i) \in \mathbb{R}^{3 \times H \times W}. \quad (3.2)$$

Trong Công thức 3.2, $\mathcal{T}_g$ là phép tiền xử lý ảnh toàn cục, X_i^g là ảnh toàn cục của mẫu thứ i , ba kênh đầu vào được tạo theo định dạng mà backbone yêu cầu, còn $H = W = 224$ là chiều cao và chiều rộng đưa vào bộ mã hóa. Phép biến đổi này không sử dụng nhân hoặc vị trí tổn thương.

Đối với nhánh cục bộ, ảnh nguồn trước hết được xác định vùng nội dung nhằm hạn chế các biên đen và vùng đệm của thiết bị chụp. Bốn cửa sổ được chọn theo chiến lược sparse-focal: hai cửa sổ hỗ trợ bao phủ dọc theo trục chính của vùng giải phẫu và hai cửa sổ ưu tiên vùng có năng lượng kết cấu cao, đồng thời hạn chế chồng lấp quá mức với các vùng đã chọn. Mỗi cửa sổ được ánh xạ về ảnh nguồn và biến đổi thành một local view có cùng kích thước đầu vào với ảnh toàn cục.

$$\mathcal{X}_i^\ell = \{X_{i,m}^\ell = \mathcal{T}_\ell(X_i; b_{i,m})\}_{m=1}^M. \quad (3.3)$$

Trong Công thức 3.3, $\mathcal{X}_i^\ell$ là tập local view của mẫu thứ i , $M = 4$ là số vùng cục bộ cố định, $b_{i,m}$ là hộp tọa độ của vùng thứ m trên ảnh nguồn, $\mathcal{T}_\ell$ là phép cắt, đổi kích thước và chuẩn hóa vùng ảnh, còn $X_{i,m}^\ell \in \mathbb{R}^{3 \times 224 \times 224}$ là local view thứ m . Các hộp $b_{i,m}$ chỉ được xác định từ tín hiệu ảnh, không sử dụng nhãn, bounding box tổn thương hoặc một mô hình phát hiện được huấn luyện riêng.

Bệnh sử lâm sàng được chuẩn hóa về mã hóa ký tự, khoảng trắng và các ký hiệu không mang nội dung trước khi token hóa. Chuỗi được cắt hoặc đệm đến độ dài tối đa, đồng thời một attention mask được tạo để phân biệt token nội dung với token đệm.

$$(\mathbf{u}_i, \mathbf{m}_i) = \mathcal{T}_t(R_i). \quad (3.4)$$

Trong Công thức 3.4, $\mathcal{T}_t$ là bộ tiền xử lý và token hóa văn bản, $\mathbf{u}_i \in \mathbb{N}^L$ là chuỗi chỉ số token, $\mathbf{m}_i \in \{0, 1\}^L$ là attention mask và L là độ dài chuỗi sau khi cắt hoặc đệm. Giá trị một trong $\mathbf{m}_i$ biểu thị token hợp lệ, còn giá trị không biểu thị vị trí đệm không được tham gia vào phép chú ý.

3.2.2 Bộ mã hóa (Encoders)

Hai bộ mã hóa được kế thừa từ BiomedCLIP để tận dụng không gian biểu diễn ảnh–văn bản đã được tiền huấn luyện trên dữ liệu y sinh. Bộ mã hóa thị giác xử lý ảnh toàn cục và các local view bằng cùng một tập trọng số, trong khi bộ mã hóa văn bản xử lý chuỗi token của bệnh sử. Đầu ra của hai nhánh được chiếu về cùng chiều $D = 512$, nhờ đó có thể được căn chỉnh ở giai đoạn thứ nhất và trao đổi thông tin trong mô-đun dung hợp ở giai đoạn thứ hai.

Bộ mã hóa thị giác (Visual Encoder)

Bộ mã hóa thị giác sử dụng Vision Transformer của BiomedCLIP. Ảnh toàn cục được chia thành các patch, kết hợp với token đại diện và embedding vị trí, sau đó đi qua các lớp Transformer. Token đại diện ở đầu ra được chiếu về không gian chung để tạo đặc trưng toàn cục.

$$\mathbf{g}_i^I = \mathcal{P}_I(\mathcal{E}_I(X_i^g)_{\text{CLS}}) \in \mathbb{R}^D. \quad (3.5)$$

Trong Công thức 3.5, $\mathcal{E}_I$ là bộ mã hóa thị giác, chỉ số CLS chỉ token đại diện của ảnh, $\mathcal{P}_I$ là phép chiếu thị giác sang không gian biểu diễn chung, $\mathbf{g}_i^I$ là embedding ảnh toàn cục và $D = 512$ là số chiều đặc trưng.

Mỗi local view đi qua cùng bộ mã hóa thị giác. Đối với từng vùng, pipeline giữ lại token CLS và một lưới 2×2 thu được bằng pooling thích nghi trên các patch token. Cách tổng hợp này tạo năm token cho mỗi vùng, gồm một token mang nội dung tổng quát của vùng và bốn token giữ phân bố không gian thô bên trong vùng.

$$\mathbf{L}_{i,m}^I = \mathcal{P}_I \left(\text{Concat} \left[\mathcal{E}_I (X_{i,m}^\ell)_{\text{CLS}}, \text{Pool}_{2 \times 2} \left(\mathcal{E}_I (X_{i,m}^\ell)_{\text{patch}} \right) \right] \right) \in \mathbb{R}^{5 \times D}. \quad (3.6)$$

Trong Công thức 3.6, $\mathbf{L}_{i,m}^I$ là tập token của local view thứ m , ký hiệu patch chỉ chuỗi patch token ở đầu ra của bộ mã hóa, $\text{Pool}_{2 \times 2}$ là phép pooling thích nghi tạo bốn vùng không gian, Concat là phép ghép theo chiều token và $\mathcal{P}_I$ là phép chiếu được áp dụng theo từng token. Số chiều của mỗi token sau phép chiếu được ký hiệu là D .

Token của bốn local view được ghép thành một chuỗi có ngân sách cố định. Cấu trúc cố định này giúp mô-đun dung hợp nhận cùng số token ảnh đối với mọi mẫu, không phụ thuộc kích thước ban đầu của ảnh X-quang.

$$\mathbf{L}_i^I = \text{Concat}_{m=1}^M (\mathbf{L}_{i,m}^I) \in \mathbb{R}^{P \times D}. \quad (3.7)$$

Trong Công thức 3.7, $\mathbf{L}_i^I$ là toàn bộ chuỗi token cục bộ, $M = 4$ là số local view và $P = 5M = 20$ là tổng số token cục bộ. Phép ghép giữ nguyên thứ tự vùng và thứ tự token bên trong từng vùng.

Do các vùng cục bộ được lấy từ những vị trí khác nhau trên ảnh nguồn, tọa độ chuẩn hóa của mỗi vùng được ánh xạ thành embedding không gian và cộng vào token tương ứng. Một hệ số có thể học kiểm soát cường độ của tín hiệu tọa độ để thông tin vị trí bổ sung cho nội dung thị giác mà không thay thế nội dung đó.

$$\tilde{\mathbf{L}}_i^I = \mathbf{L}_i^I + \gamma \mathcal{P}_s (\mathbf{B}_i). \quad (3.8)$$

Trong Công thức 3.8, $\mathbf{B}_i$ chứa tọa độ đã chuẩn hóa của bốn hộp cục bộ, $\mathcal{P}_s$ là phép chiếu tọa độ sang không gian D chiều, γ là hệ số vô hướng có thể học và $\tilde{\mathbf{L}}_i^I$ là chuỗi token cục bộ đã bổ sung vị trí. Embedding của một hộp được lặp cho năm token xuất phát từ hộp đó.

Trong giai đoạn thứ nhất, chuỗi token cục bộ được tổng hợp bằng attention pooling có điều kiện theo embedding toàn cục. Cơ chế này cho phép mức đóng góp của các vùng thay đổi theo từng ảnh thay vì sử dụng trung bình không trọng số.

$$e_{i,p} = \mathbf{w}_a^\top \tanh \left(\mathbf{W}_g \mathbf{g}_i^I + \mathbf{W}_\ell \tilde{\mathbf{L}}_{i,p}^I \right). \quad (3.9)$$

Trong Công thức 3.9, $e_{i,p}$ là điểm chú ý chưa chuẩn hóa của token cục bộ thứ p , $\tilde{\mathbf{L}}_{i,p}^I$ là token cục bộ tương ứng, $\mathbf{W}_g$ và $\mathbf{W}_\ell$ là các ma trận chiếu có thể học, $\mathbf{w}_a$ là vector tham số của attention pooling và $\tanh$ là hàm kích hoạt.

$$a_{i,p} = \frac{\exp(e_{i,p})}{\sum_{q=1}^P \exp(e_{i,q})}. \quad (3.10)$$

Trong Công thức 3.10, $a_{i,p}$ là trọng số đã chuẩn hóa của token thứ p , $P = 20$ là tổng số token cục bộ và chỉ số q duyệt qua toàn bộ token cục bộ của cùng một ảnh. Các trọng số không âm và có tổng bằng một.

$$\mathbf{z}_i^I = \text{Norm}_2 \left(\mathbf{g}_i^I + \lambda_\ell \sum_{p=1}^P a_{i,p} \tilde{\mathbf{L}}_{i,p}^I \right). \quad (3.11)$$

Trong Công thức 3.11, $\mathbf{z}_i^I$ là embedding thị giác dùng cho mục tiêu căn chỉnh ở giai đoạn thứ nhất, Norm_2 là phép chuẩn hóa theo chuẩn Euclid, $\lambda_\ell = 0,25$ là hệ số điều tiết đóng góp của nhánh cục bộ và tổng có trọng số biểu diễn thông tin cục bộ liên quan đến ngữ cảnh toàn cục.

Bộ mã hóa văn bản (Text Encoder)

Bộ mã hóa văn bản kế thừa PubMedBERT của BiomedCLIP và nhận chuỗi token cùng attention mask của bệnh sử. Chuỗi đặc trưng đầu ra giữ lại thông tin ở mức token để phục vụ chú ý chéo, trong khi token đại diện được chiếu sang không gian chung để phục vụ căn chỉnh và tạo query toàn cục.

$$\mathbf{H}_i^T = \mathcal{P}_T(\mathcal{E}_T(\mathbf{u}_i, \mathbf{m}_i)) \in \mathbb{R}^{L \times D}. \quad (3.12)$$

Trong Công thức 3.12, $\mathcal{E}_T$ là bộ mã hóa văn bản, $\mathcal{P}_T$ là phép chiếu được áp dụng theo từng token, $\mathbf{u}_i$ là chuỗi chỉ số token, $\mathbf{m}_i$ là attention mask, L là chiều dài chuỗi và $\mathbf{H}_i^T$ là ma trận biểu diễn theo token sau phép chiếu về D chiều. Các vị trí đệm được loại khỏi phép chú ý bằng attention mask.

$$\mathbf{z}_i^T = \text{Norm}_2(\mathbf{H}_{i,0}^T) \in \mathbb{R}^D. \quad (3.13)$$

Trong Công thức 3.13, $\mathbf{H}_{i,0}^T$ là token đại diện ở vị trí đầu chuỗi sau phép chiếu, Norm_2 là phép chuẩn hóa L_2 và $\mathbf{z}_i^T$ là embedding văn bản toàn cục.

Nhóm nghiên cứu sử dụng LoRA [14] để thích nghi các phép chiếu được lựa chọn trong cả hai bộ mã hóa. Trọng số tiền huấn luyện không bị thay thế; phân cập nhật được biểu diễn bằng tích của hai ma trận hạng thấp.

$$\mathbf{W}' = \mathbf{W} + \frac{\alpha_L}{r} \mathbf{B} \mathbf{A}. \quad (3.14)$$

Trong Công thức 3.14, $\mathbf{W} \in \mathbb{R}^{d \times k}$ là ma trận trọng số tiền huấn luyện được giữ cố định, $\mathbf{W}'$ là trọng số hiệu dụng khi truyền thuận, $\mathbf{A} \in \mathbb{R}^{r \times k}$ và $\mathbf{B} \in \mathbb{R}^{d \times r}$ là hai ma trận được huấn luyện, r là hạng LoRA và α_L là hệ số tỷ lệ. Điều kiện $r \ll \min(d, k)$ làm cho số tham số cần cập nhật nhỏ hơn đáng kể so với tinh chỉnh toàn bộ ma trận $\mathbf{W}$.

Trong giai đoạn thứ nhất, độ tương đồng giữa embedding ảnh và embedding văn bản được tính bằng cosine. Do hai embedding đã được chuẩn hóa, tích vô hướng tương ứng với độ tương đồng cosine; công thức tổng quát vẫn được trình bày để làm rõ đại lượng được tối ưu.

$$s_{ij} = \frac{(\mathbf{z}_i^I)^T \mathbf{z}_j^T}{\|\mathbf{z}_i^I\|_2 \|\mathbf{z}_j^T\|_2}. \quad (3.15)$$

Trong Công thức 3.15, s_{ij} là mức tương đồng giữa ảnh thứ i và bệnh sử thứ j , $\mathbf{z}_i^I$ là embedding thị giác, $\mathbf{z}_j^T$ là embedding văn bản, ký hiệu T biểu thị chuyển vị và $\|\cdot\|_2$ là chuẩn Euclid.

Mục tiêu mềm phân bổ trọng số lớn cho cặp tương ứng và một phần trọng số cho các cặp khác thuộc cùng lớp. Phân phối mục tiêu theo hàng được xây dựng như sau.

$$q_{ij} = \frac{\rho \mathbb{I}[i = j] + (1 - \rho) \mathbb{I}[y_i = y_j]}{\sum_{n=1}^B (\rho \mathbb{I}[i = n] + (1 - \rho) \mathbb{I}[y_i = y_n])}. \quad (3.16)$$

Trong Công thức 3.16, q_{ij} là xác suất mục tiêu của cặp ảnh i và văn bản j , B là kích thước mini-batch, $\rho \in [0, 1]$ là hệ số ưu tiên cặp tương ứng,

$\mathbb{K}[\cdot]$ là hàm chỉ thị và y_i, y_j là nhãn lớp. Mẫu số chuẩn hóa tổng trọng số mục tiêu của mỗi ảnh bằng một; khi trong mini-batch có nhiều mẫu cùng lớp, các mẫu này nhận trọng số mềm thay vì bị xem hoàn toàn là cặp âm.

Xác suất dự đoán theo hướng ảnh sang văn bản được tính từ toàn bộ văn bản trong cùng mini-batch.

$$p_{ij}^{I \rightarrow T} = \frac{\exp(s_{ij}/\tau)}{\sum_{n=1}^B \exp(s_{in}/\tau)}. \quad (3.17)$$

Trong Công thức 3.17, $p_{ij}^{I \rightarrow T}$ là xác suất văn bản j tương ứng với ảnh i , s_{ij} là độ tương đồng ảnh-văn bản, $\tau > 0$ là nhiệt độ và B là kích thước mini-batch. Nhiệt độ nhỏ tạo phân phối sắc hơn, còn nhiệt độ lớn tạo phân phối phẳng hơn.

Xác suất theo hướng văn bản sang ảnh được tính đối xứng trên toàn bộ ảnh trong mini-batch.

$$p_{ji}^{T \rightarrow I} = \frac{\exp(s_{ij}/\tau)}{\sum_{n=1}^B \exp(s_{nj}/\tau)}. \quad (3.18)$$

Trong Công thức 3.18, $p_{ji}^{T \rightarrow I}$ là xác suất ảnh i tương ứng với văn bản j , mẫu số duyệt qua các ảnh có chỉ số n trong mini-batch, còn s_{ij} , τ và B có ý nghĩa như trong Công thức 3.17.

Hàm mất mát khớp ngữ nghĩa lấy trung bình hai hướng để tránh ưu tiên riêng nhánh ảnh hoặc nhánh văn bản.

$$\mathcal{L}_{\text{SM}} = -\frac{1}{2B} \sum_{i=1}^B \sum_{j=1}^B q_{ij} (\log p_{ij}^{I \rightarrow T} + \log p_{ji}^{T \rightarrow I}). \quad (3.19)$$

Trong Công thức 3.19, $\mathcal{L}_{\text{SM}}$ là hàm mất mát của giai đoạn thứ nhất, q_{ij} là mục tiêu mềm, $p_{ij}^{I \rightarrow T}$ và $p_{ji}^{T \rightarrow I}$ là hai phân phối dự đoán, còn B là kích thước mini-batch. Gradient của hàm mất mát này cập nhật adapter LoRA và thành phần tổng hợp token ảnh cục bộ nhưng không cập nhật mô-đun dung hợp hoặc bộ phân loại.

3.2.3 Bộ dung hợp (Cross-Attention)

Bộ dung hợp chỉ được tối ưu và sử dụng từ giai đoạn thứ hai. Đầu vào thị giác gồm token toàn cục cùng 20 token cục bộ đã bổ sung tọa độ, trong khi đầu vào văn bản gồm embedding toàn cục và chuỗi token bệnh sử. Hai hướng chú ý có vai trò bổ sung: hướng ảnh sang văn bản dùng ngữ cảnh lâm sàng để làm giàu token ảnh toàn cục, còn hướng văn bản sang ảnh dùng bằng chứng thị giác toàn cục và cục bộ để làm giàu token văn bản toàn cục.

$$\mathbf{V}_i = \text{Concat} \left[\mathbf{g}_i^I, \tilde{\mathbf{L}}_i^I \right] \in \mathbb{R}^{(P+1) \times D}. \quad (3.20)$$

Trong Công thức 3.20, $\mathbf{V}_i$ là chuỗi token thị giác dùng cho dung hợp, $\mathbf{g}_i^I$ là token ảnh toàn cục, $\tilde{\mathbf{L}}_i^I$ là $P = 20$ token cục bộ đã bổ sung tọa độ và $D = 512$ là chiều đặc trưng. Vì vậy, chuỗi thị giác có tổng cộng $P + 1 = 21$ token.

Ở hướng ảnh sang văn bản, token ảnh toàn cục đóng vai trò query, còn chuỗi token văn bản đóng vai trò key và value. Attention mask của văn bản được áp dụng trước Softmax để token đệm không nhận trọng số.

$$\mathbf{A}_i^{I \leftarrow T} = \text{Softmax} \left(\frac{(\mathbf{g}_i^I \mathbf{W}_Q^I) (\mathbf{H}_i^T \mathbf{W}_K^T)^T}{\sqrt{d_h}} + \mathbf{M}_i^T \right). \quad (3.21)$$

Trong Công thức 3.21, $\mathbf{A}_i^{I \leftarrow T}$ là phân bố chú ý từ token ảnh đến các token văn bản, $\mathbf{W}_Q^I$ và $\mathbf{W}_K^T$ là ma trận chiếu query và key, d_h là chiều của mỗi attention head, $\mathbf{M}_i^T$ là mặt nạ cộng có giá trị không tại token hợp lệ và giá trị âm lớn tại token đệm, còn Softmax chuẩn hóa trọng số theo chiều token văn bản.

$$\mathbf{h}_i^I = \text{LN} \left(\mathbf{g}_i^I + \mathbf{A}_i^{I \leftarrow T} (\mathbf{H}_i^T \mathbf{W}_V^T) \right). \quad (3.22)$$

Trong Công thức 3.22, $\mathbf{h}_i^I$ là biểu diễn ảnh đã được bổ sung ngữ cảnh văn bản, $\mathbf{W}_V^T$ là ma trận chiếu value của nhánh văn bản, LN là Layer Normalization và phép cộng với $\mathbf{g}_i^I$ tạo kết nối residual giúp giữ thông tin ảnh ban đầu.

Ở hướng văn bản sang ảnh, embedding văn bản toàn cục đóng vai trò

query, còn chuỗi 21 token thị giác đóng vai trò key và value. Hướng này cho phép một biểu diễn văn bản tổng quát lựa chọn thông tin từ bố cục toàn cục và các vùng ảnh cục bộ.

$$\mathbf{A}_i^{T \leftarrow I} = \text{Softmax} \left(\frac{(\mathbf{z}_i^T \mathbf{W}_Q^T) (\mathbf{V}_i \mathbf{W}_K^I)^T}{\sqrt{d_h}} \right). \quad (3.23)$$

Trong Công thức 3.23, $\mathbf{A}_i^{T \leftarrow I}$ là phân bố chú ý từ embedding văn bản đến chuỗi token thị giác, $\mathbf{W}_Q^T$ và $\mathbf{W}_K^I$ là các ma trận chiếu query và key, $\mathbf{V}_i$ là chuỗi thị giác và d_h là chiều của mỗi attention head.

$$\mathbf{h}_i^T = \text{LN} (\mathbf{z}_i^T + \mathbf{A}_i^{T \leftarrow I} (\mathbf{V}_i \mathbf{W}_V^I)). \quad (3.24)$$

Trong Công thức 3.24, $\mathbf{h}_i^T$ là biểu diễn văn bản đã được bổ sung thông tin thị giác, $\mathbf{W}_V^I$ là ma trận chiếu value của nhánh ảnh, LN là Layer Normalization và kết nối residual giữ lại nội dung của embedding văn bản toàn cục.

Hai biểu diễn tăng cường được ghép và đưa qua MLP để tạo embedding dung hợp dùng chung cho bộ phân loại. MLP giảm vector ghép từ $2D = 1024$ chiều về $D = 512$ chiều, sau đó tiếp tục chiếu trong không gian D chiều và chuẩn hóa đầu ra. Các embedding toàn cục thô không được ghép lại thêm một lần nữa sau bước này.

$$\mathbf{z}_i^F = \text{LN} (\mathbf{W}_2 \phi (\mathbf{W}_1 \text{Concat} [\mathbf{h}_i^I, \mathbf{h}_i^T] + \mathbf{b}_1) + \mathbf{b}_2) \in \mathbb{R}^D. \quad (3.25)$$

Trong Công thức 3.25, $\mathbf{z}_i^F$ là embedding dung hợp, $\mathbf{W}_1$ và $\mathbf{W}_2$ là hai ma trận trọng số của MLP, $\mathbf{b}_1$ và $\mathbf{b}_2$ là các vector độ lệch, ϕ là hàm kích hoạt phi tuyến, Concat là phép ghép theo chiều đặc trưng và $D = 512$ là chiều đầu ra.

3.2.4 Bộ phân loại dựa trên tâm lớp thực nghiệm (Classifier)

Bộ phân loại biểu diễn mỗi lớp bằng trung bình embedding dung hợp của các mẫu huấn luyện thuộc lớp đó. Tâm lớp không phải là tham số tự do và không được optimizer cập nhật; khi bộ mã hóa hoặc bộ dung hợp thay đổi, các tâm được ước lượng lại từ tập huấn luyện. Thiết kế này giữ cho đại diện lớp gắn trực tiếp với hình học của không gian biểu diễn hiện tại.

$$\mathbf{c}_k = \frac{1}{N_k} \sum_{i:y_i=k} \mathbf{z}_i^F. \quad (3.26)$$

Trong Công thức 3.26, $\mathbf{c}_k \in \mathbb{R}^D$ là tâm thực nghiệm của lớp k , N_k là số mẫu huấn luyện thuộc lớp đó, $\mathbf{z}_i^F$ là embedding dung hợp của mẫu thứ i và điều kiện $y_i = k$ giới hạn phép tổng trên các mẫu có nhãn k . Mỗi lớp trong cấu hình phải có ít nhất một mẫu huấn luyện để tâm lớp được xác định.

Độ tương đồng giữa một mẫu và từng tâm lớp được tính bằng cosine, nhờ đó quyết định phụ thuộc chủ yếu vào hướng của embedding thay vì độ lớn tuyệt đối của vector.

$$r_{ik} = \frac{(\mathbf{z}_i^F)^\top \mathbf{c}_k}{\|\mathbf{z}_i^F\|_2 \|\mathbf{c}_k\|_2}. \quad (3.27)$$

Trong Công thức 3.27, r_{ik} là độ tương đồng cosine giữa mẫu i và lớp k , $\mathbf{z}_i^F$ là embedding dung hợp, $\mathbf{c}_k$ là tâm lớp, ký hiệu $\top$ biểu thị chuyển vị và $\|\cdot\|_2$ là chuẩn Euclid.

Điểm phân loại kết hợp độ tương đồng với một hệ số tỷ lệ cố định và một độ lệch riêng cho từng lớp. Độ lệch lớp được khởi tạo bằng không và được học trong giai đoạn thứ hai, qua đó cho phép điều chỉnh ranh giới quyết định mà không biến tâm thực nghiệm thành prototype tham số.

$$\ell_{ik} = \alpha_c r_{ik} + b_k. \quad (3.28)$$

Trong Công thức 3.28, ℓ_{ik} là logit của mẫu i đối với lớp k , r_{ik} là độ

tương đồng với tâm lớp, $\alpha_c = 15$ là hệ số tỷ lệ cố định và b_k là class-specific bias có thể học của lớp k .

Logit của tất cả các lớp được chuẩn hóa bằng Softmax để tạo phân phối xác suất dự đoán.

$$p_{ik} = \frac{\exp(\ell_{ik})}{\sum_{j=1}^K \exp(\ell_{ij})}. \quad (3.29)$$

Trong Công thức 3.29, p_{ik} là xác suất dự đoán lớp k cho mẫu i , ℓ_{ik} là logit tương ứng, K là tổng số lớp và chỉ số j duyệt qua toàn bộ lớp trong bài toán.

Để hạn chế việc các lớp có nhiều mẫu chi phối hàm mục tiêu, trọng số lớp được xây dựng từ số mẫu hiệu dụng [7]. Đại lượng số mẫu hiệu dụng của lớp k được xác định như sau.

$$E_k = \frac{1 - \beta^{N_k}}{1 - \beta}. \quad (3.30)$$

Trong Công thức 3.30, E_k là số mẫu hiệu dụng của lớp k , N_k là số mẫu thực tế của lớp và $\beta \in [0, 1)$ là hệ số kiểm soát mức bão hòa. Khi số mẫu tăng, đóng góp bổ sung của các mẫu mới giảm dần thay vì tăng tuyến tính không giới hạn.

Nghịch đảo số mẫu hiệu dụng được chuẩn hóa để trọng số trung bình của các lớp bằng một, đồng thời có thể được chặn trên nhằm hạn chế gradient quá lớn ở lớp rất hiếm.

$$w_k = \frac{K E_k^{-1}}{\sum_{j=1}^K E_j^{-1}}. \quad (3.31)$$

Trong Công thức 3.31, w_k là trọng số của lớp k , E_k^{-1} là nghịch đảo số mẫu hiệu dụng và K là tổng số lớp. Việc chuẩn hóa không làm các lớp có tần suất bằng nhau, mà chỉ thay đổi mức đóng góp tương đối của chúng vào hàm mất mát.

Label smoothing được áp dụng để tránh mục tiêu one-hot tuyệt đối và giảm mức quá tự tin của đầu phân loại. Phân phối mục tiêu sau làm tròn được xác định như sau.

$$\tilde{y}_{ik} = (1 - \varepsilon) \mathbb{1}[y_i = k] + \frac{\varepsilon}{K}. \quad (3.32)$$

Trong Công thức 3.32, $\tilde{y}_{ik}$ là xác suất mục tiêu của lớp k đối với mẫu i , $\varepsilon = 0,05$ là hệ số label smoothing, $\mathbb{1}[y_i = k]$ là hàm chỉ thị của nhãn đúng và K là tổng số lớp.

Hàm mất mát của giai đoạn thứ hai là Cross-Entropy có trọng số lớp trên phân phối mục tiêu đã làm trơn. Pipeline không bổ sung Prototypical Loss dạng pull-push vì các tâm lớp được xác định bằng thống kê của tập huấn luyện thay vì được học như tham số tự do.

$$\mathcal{L}_{P2} = -\frac{1}{B} \sum_{i=1}^B \sum_{k=1}^K w_k \tilde{y}_{ik} \log p_{ik}. \quad (3.33)$$

Trong Công thức 3.33, $\mathcal{L}_{P2}$ là hàm mất mát của giai đoạn thứ hai, B là kích thước mini-batch, w_k là trọng số của lớp k , $\tilde{y}_{ik}$ là mục tiêu đã làm trơn và p_{ik} là xác suất dự đoán. Gradient của hàm mất mát cập nhật các tham số có thể học của pipeline nhưng không cập nhật trực tiếp các tâm $\mathbf{c}_k$.

Trong quá trình trực tuyến, lớp dự đoán là lớp có logit lớn nhất. Quy tắc này tương đương lựa chọn tâm lớp có điểm cosine đã hiệu chỉnh lớn nhất.

$$\hat{y}_i = \arg \max_{k \in \{1, \dots, K\}} \ell_{ik}. \quad (3.34)$$

Trong Công thức 3.34, $\hat{y}_i$ là nhãn dự đoán của mẫu i , k là chỉ số lớp, K là tổng số lớp và ℓ_{ik} là logit đã kết hợp độ tương đồng tâm lớp với class-specific bias. Quy tắc dự đoán sử dụng các tâm và độ lệch lớp đã được cố định sau quá trình huấn luyện ngoại tuyến.

3.3 Tóm tắt chương

Chương này trình bày XBone-Net theo một luồng thống nhất từ đầu vào đến quyết định phân loại. Trong quá trình ngoại tuyến, giai đoạn thứ

nhất thích nghi hai bộ mã hóa và nhánh ảnh cục bộ bằng mục tiêu khớp ngữ nghĩa, còn giai đoạn thứ hai tiếp tục thích nghi biểu diễn đồng thời học chú ý chéo, MLP dung hợp và độ lệch lớp dưới mục tiêu Cross-Entropy có trọng số. Trong quá trình trực tuyến, cùng pipeline tiền xử lý, mã hóa và dung hợp được sử dụng với toàn bộ tham số đã cố định; nhận được xác định bằng khoảng cách tới các tâm lớp thực nghiệm. Cấu trúc này cho phép tách rõ vai trò của bảo toàn chi tiết ảnh, mã hóa bệnh sử, tương tác liên phương thức và ra quyết định dựa trên hình học của tập huấn luyện.

Chương 4

Thực nghiệm

Chương này mô tả các thực nghiệm được thực hiện gồm so sánh hiệu năng phân loại không mẫu của các mô hình nền tảng, so sánh hiệu năng phân loại đa lớp giữa mô hình đề xuất và các mô hình nền tảng khi huấn luyện trên BTXRD và CTCH, đánh giá khả năng phát hiện dữ liệu ngoài phân phối của XBone-Net trên CTCH, và phân tích hiệu chuẩn xác suất dự đoán. Ngoài ra, mô tả về các bộ dữ liệu, thiết lập thí nghiệm và nội dung thí nghiệm cùng với mục đích của các thí nghiệm này sẽ được trình bày.

4.1 Chuẩn bị dữ liệu

Nghiên cứu sử dụng bộ dữ liệu BTXRD được công bố [47] và bộ dữ liệu CTCH thu thập tại Bệnh viện Chấn thương Chỉnh hình. Phần dưới đây mô tả nguồn gốc của bộ dữ liệu cách thức thu thập, các bước tiền xử lý dữ liệu, cấu trúc dữ liệu và các số liệu thống kê liên quan đến bộ dữ liệu.

4.1.1 Bộ dữ liệu BTXRD

Bộ dữ liệu ảnh X-quang u xương BTXRD [47] được xây dựng phục vụ các nghiên cứu phân loại, định vị và phân vùng tự động khối u xương nguyên phát. Bộ dữ liệu gồm 3.746 hình ảnh, kèm theo các thông tin lâm sàng như giới tính, độ tuổi, vị trí cơ thể và góc chụp. Các ảnh có khối u

còn được gán nhãn lành tính hoặc ác tính, phân loại phụ, vị trí giải phẫu, hộp giới hạn và mặt nạ phân vùng thủ công.

Dữ liệu được thu thập từ ba nguồn: ba bệnh viện tại Trung Quốc, nền tảng Radiopaedia.org và cơ sở dữ liệu MedPix. Tại các bệnh viện, ảnh của bệnh nhân mắc u xương nguyên phát được thu thập từ tháng 7 năm 2013 đến tháng 7 năm 2023, với chẩn đoán được xác nhận bằng mô bệnh học hoặc bởi hai chuyên gia X-quang. Đối với Radiopaedia và MedPix, ảnh được hai chuyên gia tìm kiếm bằng các từ khóa liên quan đến u xương. Chỉ những ảnh có đầy đủ thông tin giới tính và độ tuổi mới được lựa chọn. Các mẫu thuộc vùng đầu, cổ, ngực và bụng bị loại bỏ do số lượng ít và chứa nhiều nhiễu; vì vậy, BTXRD chỉ gồm ảnh ở chi trên, chi dưới và xương chậu.

Trong quá trình gán nhãn, một bác sĩ chuyên khoa u xương có 10 năm kinh nghiệm sử dụng Labelme [35] để xác định mặt nạ phân vùng và hộp giới hạn khối u. Các chú thích sau đó được kiểm tra bởi một chuyên gia có 20 năm kinh nghiệm. Thông tin phân vùng và hộp giới hạn được lưu dưới dạng JSON, trong khi các nhãn lâm sàng được lưu trong các tệp CSV.

Cấu trúc bộ dữ liệu

Bộ dữ liệu này bao gồm tổng cộng 3.746 hình ảnh, trong đó phân bổ thành 1.879 ảnh xương bình thường, 1.525 ảnh u xương lành tính và 342 ảnh u xương ác tính. Dữ liệu hình ảnh được lưu dưới định dạng JPEG thang độ xám 8-bit, các dữ liệu về nhãn lâm sàng được lưu dưới định dạng CSV, và các thông tin về mặt nạ phân vùng cũng như hộp giới hạn được lưu dưới định dạng JSON. Cấu trúc thư mục của bộ dữ liệu được tổ chức như sau:

Trong đó:

- **images/**: Thư mục chứa toàn bộ hình ảnh chụp X-quang gốc của bệnh nhân dưới định dạng ảnh JPEG thang độ xám.
- **Annotations/**: Chứa các tệp JSON lưu tọa độ đa giác và hộp giới hạn. Các chú thích này thuộc dữ liệu công bố nhưng không được sử dụng trong các thí nghiệm hiện tại.

```
data/BTXRD/  
├── images/  
│   └── IMG000001.jpeg  
├── Annotations/  
│   └── IMG000001.json  
├── reports/  
│   ├── clinical_v2/  
│   │   └── IMG000001.txt  
│   ├── clinical/  
│   │   └── IMG000001.txt  
│   └── xray/  
│       └── IMG000001.txt  
├── dataset.csv  
├── btxrd-labels.csv  
└── btxrd-split.csv
```

Hình 4.1: Sơ đồ cấu trúc của bộ dữ liệu BTXRD

- **reports/**: Thư mục lưu trữ các nguồn văn bản phục vụ cho học máy đa phương thức:
 - **clinical/**: Chứa bệnh sử tổng hợp đã loại tên chẩn đoán trực tiếp.
 - **xray/**: Chứa mô tả X-quang tổng hợp từ nhãn bệnh lý và có thể chứa tên lớp.
- **dataset.csv**: Tập siêu dữ liệu thô gồm tuổi, giới tính, vùng xương, khớp, góc chụp và các cờ bệnh lý.
- **btxrd-labels.csv**: Tập lưu 10 cột chỉ báo lớp bệnh lý.
- **btxrd-split.csv**: Tập ánh xạ image_id vào một trong ba tập train, validate và tests.

Nguồn văn bản tổng hợp và giới hạn sử dụng

BTXRD công bố không kèm báo cáo tự do do bác sĩ viết. Các thư mục văn bản trong workspace đều được sinh bằng khuôn mẫu với hạt giống 42 và quy trình được mô tả trong Phụ lục ?? và cần được phân biệt như sau:

1. **clinical**: mỗi báo cáo gồm tuổi, giới tính, vị trí xương hoặc khớp, góc chụp, lý do vào viện, bệnh sử, khám thực thể và tiền sử. Quy trình không chèn tên của 10 lớp đích, nhưng vẫn chọn nhóm khuôn mẫu theo các cờ **tumor** và **malignant**, đồng thời sử dụng thông tin tổn thương nhiều xương và liên quan khớp từ **dataset.csv**.
2. **xray**: mô tả X-quang được sinh trực tiếp từ nhãn phân nhóm và các dấu hiệu điển hình, trong đó có thể xuất hiện tên chẩn đoán. Nguồn này được sử dụng nhằm mục đích hỗ trợ phân tích dữ liệu và trình bày không sử dụng trong quá trình huấn luyện.

Việc loại tên bệnh trực tiếp làm giảm dạng rò rỉ từ khóa, nhưng không khiến văn bản trở thành độc lập với nhãn vì quá trình sinh vẫn có điều kiện theo cờ u và ác tính. Do đó, mức cải thiện từ văn bản trên BTXRD được diễn giải như hiệu quả trên dữ liệu tổng hợp có điều kiện, không phải

bằng chứng trực tiếp về hiệu quả trên bệnh sử lâm sàng tự nhiên. Bảng 4.1 minh họa sự khác nhau giữa báo cáo lâm sàng và mô tả X-quang.

Thống kê số liệu

Nhằm cung cấp cái nhìn chi tiết và khách quan về cấu trúc dữ liệu, các bảng thống kê dưới đây trình bày phân bố số lượng mẫu hình ảnh theo các tập chia dữ liệu (Bảng 4.2) và phân bố theo các lớp u xương bệnh lý (Bảng 4.3).

Bộ dữ liệu được chia theo tỉ lệ 70% huấn luyện, 10% đánh giá và 20% kiểm thử. Tất cả các tập con đều được cân bằng theo các lớp bệnh lý. Bảng 4.3 cho thấy số lượng mẫu của mỗi lớp bệnh lý trong từng tập con, từ đó có thể thấy rằng các lớp bệnh lý phổ biến như u xương sụn và sarcoma xương chiếm tỷ lệ lớn trong bộ dữ liệu, trong khi các lớp hiếm gặp như u sụn màng hoạt dịch và u xơ xương chiếm tỷ lệ nhỏ hơn.

4.1.2 Bộ dữ liệu CTCH

Bộ dữ liệu hình ảnh X-quang xương CTCH được thu thập từ bệnh viện Chấn thương Chỉnh hình, bao gồm tổng cộng 400 hình ảnh X-quang từ 400 bệnh nhân khác nhau. Mỗi hình ảnh được gán nhãn với các thông tin lâm sàng bao gồm lý do vào viện, quá trình bệnh lý, tiền sử bệnh lý.

Cấu trúc bộ dữ liệu

Trong đó:

- **images/**: Thư mục chứa toàn bộ hình ảnh chụp X-quang gốc của bệnh nhân dưới định dạng ảnh JPEG thang độ xám.
- **reports/**: Thư mục lưu trữ hai nguồn văn bản phục vụ cho học máy đa phương thức:
 - **clinical/**: Chứa các báo cáo mô tả bệnh sử lâm sàng của từng bệnh nhân.

Hình ảnh X-quang	Bệnh sử tổng hợp canonical (clinical_v2)	Mô tả X-quang tổng hợp legacy
	Patient: 58-year-old male. Reason for admission: Pain and swelling of the tibia. Disease history: Swelling discovered 3 months ago; painless. Physical examination: Firm, fixed swelling on the tibia; mild local tenderness. Personal medical history: No significant medical history. Age-related musculoskeletal complaints; no prior bone surgeries. Radiographic evaluation: AP view of the tibia was obtained.	A musculoskeletal radiograph of the bone in standard projection with evidence of osteochondroma: a pedunculated or sessile bony projection with cartilage cap. Captured at standard radiographic technique. The overall appearance favors a benign process.
	Patient: 6-year-old male. Reason for admission: Persistent pain in the humerus. Disease history: Pain and swelling in the humerus for 1 year; progressively worsening. Physical examination: Tender swelling; overlying skin warm; reduced mobility. Personal medical history: History of mild hypertension; otherwise unremarkable. No significant past medical history. Age-appropriate development. Radiographic evaluation: AP view of the humerus was obtained.	A musculoskeletal radiograph of the bone in conventional radiographic view with evidence of osteosarcoma: an aggressive osteoblastic lesion with irregular periosteal new bone formation. In a routine clinical radiographic study. The imaging features raise concern for malignancy.
	Patient: 48-year-old female. Reason for admission: Pain and swelling of the hip bone. Disease history: Pain in the hip bone for 1 month; associated with decreased appetite. Physical examination: Palpable mass; tenderness on palpation; mild swelling. Personal medical history: No prior bone disease or fracture. No relevant surgical or medical history. Radiographic evaluation: AP view of the hip bone was obtained.	A musculoskeletal radiograph of the bone in standard projection with evidence of other mt: a destructive bone lesion with ill-defined borders suggestive of malignancy. In a high-resolution diagnostic acquisition. The imaging features raise concern for malignancy.

Bảng 4.1: Ví dụ các mẫu dữ liệu đa phương thức trong bộ dữ liệu BTXRD

```
data/BTXRD/  
├── images/  
│   └── IMG000001.jpeg  
├── reports/  
│   ├── clinical_vi/  
│   │   └── IMG000001.txt  
│   ├── clinical/  
│   │   └── IMG000001.txt  
│   ├── xray_vi/  
│   │   └── IMG000001.txt  
│   └── xray/  
│       └── IMG000001.txt  
├── data_labeled.csv  
├── ctch-labels.csv  
└── ctch-split.csv
```

Hình 4.2: Sơ đồ phân cấp cấu trúc dữ liệu CTCH

Tập dữ liệu	Số lượng hình ảnh	Tỷ lệ (%)
Huấn luyện	2.621	69,97%
Đánh giá	375	10,01%
Kiểm thử	750	20,02%
Tổng cộng	3.746	100,0%

Bảng 4.2: Phân bố hình ảnh theo các tập dữ liệu trong BTXRD

Nhãn bệnh lý	Train	Validation	Test	Tổng	Tỷ lệ
Bình thường (<i>normal</i>)	1.322	191	366	1.879	50,16%
U xương sụn (<i>osteochondroma</i>)	538	70	145	753	20,10%
Sarcoma xương (<i>osteosarcoma</i>)	200	32	65	297	7,93%
Đa u xương sụn (<i>multiple osteochondromas</i>)	189	29	45	263	7,02%
Nang xương đơn thuần (<i>simple bone cyst</i>)	149	17	40	206	5,50%
U lành tính khác (<i>other bt</i>)	83	8	24	115	3,07%
U tế bào khổng lồ (<i>giant cell tumor</i>)	54	8	31	93	2,48%
U sụn màng hoạt dịch (<i>synovial osteochondroma</i>)	35	7	9	51	1,36%
U ác tính khác (<i>other mt</i>)	27	5	13	45	1,20%
U xơ xương (<i>osteofibroma</i>)	24	8	12	44	1,17%
Tổng	2.621	375	750	3.746	100,00%

Bảng 4.3: Phân bố các lớp đơn nhãn sau chuẩn hóa trong bộ dữ liệu BTXRD

- **clinical_vi/**: Chứa các báo cáo mô tả bệnh sử lâm sàng của từng bệnh nhân bằng tiếng Việt.
- **xray/**: Chứa các văn bản mô tả phát hiện chẩn đoán hình ảnh trên phim X-quang.
- **xray_vi/**: Chứa các văn bản mô tả phát hiện chẩn đoán hình ảnh trên phim X-quang bằng tiếng Việt.
- **data_labeled.csv**: Tập bảng chứa siêu dữ liệu thô ban đầu.
- **ctch-labels.csv**: Tập lưu trữ ánh xạ các lớp bệnh lý của từng ảnh phục vụ cho huấn luyện phân loại.
- **ctch-split.csv**: Tập tin chỉ định phân tách phân bố tập dữ liệu (huấn luyện, đánh giá, kiểm thử).

Tiền xử lý dữ liệu

Dữ liệu gốc được thu thập từ bệnh viện Chấn thương Chỉnh hình có nhiều vấn đề như sau:

- Dữ liệu gốc được thu thập từ bệnh viện Chấn thương Chỉnh hình có nhiều loại ảnh khác nhau, bao gồm ảnh chụp X-quang, ảnh CT, ảnh MRI và các loại ảnh khác.
- Một ca khám có thể có nhiều ảnh chụp từ các vị trí giải phẫu khác nhau, từ 2 đến vài trăm ảnh, nhưng chỉ một trong số đó là đúng vị trí và có sự thể hiện rõ về bệnh lý ở mắt thị giác.
- Một bệnh nhân có thể tái khám nhiều lần, dẫn đến việc có nhiều mẫu dữ liệu tương tự.
- Nhiều ca khám thiếu hụt các trường thông tin quan trọng đến huấn luyện như không có chẩn đoán xác định, không có phân tích ảnh X-quang,...
- Đôi khi chẩn đoán xác định của bác sĩ là những căn bệnh về phần mềm (sụn, dây chằng, gân, cơ) không thể hiện được trên ảnh X-quang.

Nhóm nghiên cứu đã thực hiện các bước tiền xử lý dữ liệu để chuẩn hóa và làm sạch dữ liệu trước khi đưa vào huấn luyện mô hình. Các bước tiền xử lý bao gồm:

- Loại bỏ các ảnh không liên quan hoặc không có giá trị chẩn đoán, có các dụng cụ y tế (nẹp, đinh) che vùng tổn thương.
- Đánh dấu và phân loại các mẫu dữ liệu theo lớp bệnh lý của ảnh X-quang (nếu bệnh là gãy dây chằng thuộc về phần mềm thì nhãn vẫn là "bình thường" nếu ảnh không ghi nhận tổn thương về xương).
- Loại bỏ các ca khám trùng lặp, tái khám nhiều lần.
- Chuẩn hóa và biên dịch các báo cáo y khoa từ tiếng Việt sang tiếng Anh.
- Lọc các ca hiếm gặp, không đủ số lượng mẫu để làm dữ liệu ngoài phân phối.

4.2 Độ đo đánh giá

BTXRD và CTCH được thiết lập dưới dạng bài toán phân loại đa lớp đơn nhãn, với $C = 10$ đối với BTXRD và $C = 22$ đối với CTCH. Đối với một tập đánh giá gồm N mẫu, y_i và $\hat{y}_i$ lần lượt ký hiệu nhãn thật và nhãn dự đoán của mẫu thứ i , còn p_{ic} là xác suất mô hình gán cho lớp c . Khi xem lớp c là lớp dương và các lớp còn lại là lớp âm, TP_c , FP_c và FN_c lần lượt là số dương tính thật, dương tính giả và âm tính giả của lớp đó. Các độ đo được chia thành ba nhóm nhằm tách biệt hiệu năng phân loại, khả năng nhận diện dữ liệu ngoài phân phối và đặc tính của cơ chế chú ý–dung hợp.

4.2.1 Độ đo phân loại

Accuracy

Accuracy, hay độ chính xác tổng thể, biểu thị tỷ lệ mẫu có nhãn dự đoán trùng với nhãn thật trên toàn bộ tập đánh giá.

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(y_i = \hat{y}_i). \quad (4.1)$$

Trong Công thức 4.1, N là số mẫu đánh giá, y_i là nhãn thật, $\hat{y}_i$ là nhãn dự đoán và $\mathbb{I}(\cdot)$ là hàm chỉ thị nhận giá trị một khi điều kiện đúng và bằng không trong trường hợp còn lại.

Accuracy được sử dụng vì có cách diễn giải trực tiếp và được báo cáo phổ biến trong phân loại ảnh y khoa. Tuy nhiên, độ đo này có thể bị chi phối bởi các lớp có nhiều mẫu, do đó không được sử dụng riêng lẻ mà được đọc cùng Balanced Accuracy và Macro-F1. Giá trị cao hơn biểu thị tỷ lệ dự đoán đúng lớn hơn.

Balanced Accuracy

Balanced Accuracy tính trung bình độ nhạy của từng lớp, nhờ đó mỗi lớp đóng góp như nhau vào kết quả bất kể tần suất xuất hiện trong tập

đánh giá.

$$\text{Balanced Accuracy} = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FN_c}. \quad (4.2)$$

Trong Công thức 4.2, C là tổng số lớp, TP_c là số mẫu lớp c được dự đoán đúng và FN_c là số mẫu thuộc lớp c nhưng bị dự đoán thành lớp khác. Tỷ số $TP_c/(TP_c + FN_c)$ là recall của lớp c .

Balanced Accuracy được sử dụng để giảm ảnh hưởng của mất cân bằng lớp trên BTXRD và CTCH. Độ đo này cho biết liệu khả năng nhận diện có được duy trì trên các lớp ít mẫu thay vì chủ yếu phản ánh lớp phổ biến. Giá trị cao hơn biểu thị recall trung bình giữa các lớp tốt hơn.

Macro-F1

Macro-F1 tổng hợp đồng thời precision và recall của từng lớp, sau đó lấy trung bình không trọng số trên toàn bộ lớp. Dạng viết theo các thành phần của ma trận nhầm lẫn giúp công thức không cần định nghĩa thêm precision và recall riêng biệt.

$$\text{Macro-F1} = \frac{1}{C} \sum_{c=1}^C \frac{2TP_c}{2TP_c + FP_c + FN_c}. \quad (4.3)$$

Trong Công thức 4.3, C là tổng số lớp, TP_c là số dự đoán đúng lớp c , FP_c là số mẫu lớp khác bị dự đoán nhầm thành lớp c và FN_c là số mẫu lớp c bị dự đoán thành lớp khác. Thành phần của lớp có mẫu số bằng không được quy ước bằng không.

Macro-F1 được sử dụng làm độ đo chính để lựa chọn checkpoint vì một lớp chỉ đạt F1 cao khi precision và recall đều được duy trì. Phép trung bình macro hạn chế việc kết quả của lớp phổ biến che khuất sai số tại lớp hiếm. Giá trị cao hơn biểu thị sự cân bằng tốt hơn giữa hai loại sai số.

Macro-AUROC

Macro-AUROC đánh giá khả năng xếp hạng xác suất của từng lớp theo chiến lược one-versus-rest trên toàn bộ ngưỡng, sau đó trao trọng số bằng

nhau cho các lớp hợp lệ.

$$\text{Macro-AUROC} = \frac{1}{|\mathcal{C}_v|} \sum_{c \in \mathcal{C}_v} \int_0^1 \text{TPR}_c(u) du. \quad (4.4)$$

Trong Công thức 4.4, $\mathcal{C}_v$ là tập lớp có cả mẫu dương và mẫu âm, $|\mathcal{C}_v|$ là số lớp hợp lệ, $u \in [0, 1]$ là một mức false-positive rate và $\text{TPR}_c(u)$ là true-positive rate của lớp c tại mức u . Tích phân là diện tích dưới đường ROC của lớp c .

Macro-AUROC được sử dụng vì không phụ thuộc vào một ngưỡng quyết định duy nhất và phản ánh chất lượng xếp hạng xác suất trước phép argmax. Độ đo này bổ sung cho Macro-F1 nhưng có thể ít nhạy hơn với mất cân bằng dương–âm, vì vậy cần được đọc cùng Macro-AUPRC. Giá trị cao hơn biểu thị khả năng xếp hạng tốt hơn.

Macro-AUPRC

Macro-AUPRC đánh giá sự đánh đổi giữa precision và recall cho từng lớp theo chiến lược one-versus-rest, sau đó lấy trung bình không trọng số trên các lớp hợp lệ. Phù hợp với cách tính trong thực nghiệm, diện tích của mỗi lớp được ước lượng bằng average precision không nội suy.

$$\text{AP}_c = \sum_{k=1}^{K_c} (R_{c,k} - R_{c,k-1}) P_{c,k}. \quad (4.5)$$

Trong Công thức 4.5, AP_c là average precision của lớp c , K_c là số điểm ngưỡng trên đường precision–recall, còn $P_{c,k}$ và $R_{c,k}$ lần lượt là precision và recall tại điểm thứ k ; $R_{c,0} = 0$ là mức recall khởi đầu.

$$\text{Macro-AUPRC} = \frac{1}{|\mathcal{C}_v|} \sum_{c \in \mathcal{C}_v} \text{AP}_c. \quad (4.6)$$

Trong Công thức 4.6, $\mathcal{C}_v$ là tập lớp có cả mẫu dương và mẫu âm, $|\mathcal{C}_v|$ là số lớp hợp lệ và AP_c là đại lượng được xác định trong Công thức 4.5.

Macro-AUPRC được sử dụng vì nhạy với chất lượng nhận diện lớp dương khi số mẫu dương ít hơn đáng kể số mẫu âm. Độ đo này giúp phát hiện trường hợp AUROC tương đối cao nhưng precision của lớp hiếm vẫn

thấp. Giá trị cao hơn biểu thị sự đánh đổi precision–recall tốt hơn; khi diễn giải cần đối chiếu với tỷ lệ lưu hành của từng lớp.

Expected Calibration Error

Expected Calibration Error (ECE) đánh giá mức phù hợp giữa độ tin cậy dự đoán và tần suất dự đoán đúng quan sát được. Các mẫu được chia vào M khoảng theo xác suất lớn nhất của mô hình trước khi so sánh độ tin cậy trung bình với độ chính xác thực nghiệm trong từng khoảng.

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{N} |\text{Acc}(B_m) - \text{Conf}(B_m)|. \quad (4.7)$$

Trong Công thức 4.7, M là số khoảng độ tin cậy, B_m là tập mẫu thuộc khoảng thứ m , $|B_m|$ là số mẫu trong khoảng, N là tổng số mẫu, $\text{Acc}(B_m)$ là tỷ lệ dự đoán đúng và $\text{Conf}(B_m)$ là trung bình xác suất lớn nhất trong khoảng. Báo cáo sử dụng $M = 15$ khoảng có độ rộng bằng nhau.

ECE được sử dụng vì một mô hình có Accuracy cao vẫn có thể đưa ra xác suất quá tự tin hoặc thiếu tự tin. Trong bài toán hỗ trợ phân tích ảnh y khoa, mức tin cậy cần được diễn giải thận trọng, đặc biệt khi được dùng để sắp xếp ca hoặc hỗ trợ cơ chế từ chối. Giá trị ECE thấp hơn biểu thị độ hiệu chuẩn tốt hơn, nhưng độ đo vẫn phụ thuộc vào cách chia khoảng.

Confusion Matrix

Confusion Matrix, hay ma trận nhầm lẫn, ghi nhận số mẫu của từng lớp thật được phân bố vào từng lớp dự đoán. Hàng của ma trận tương ứng với nhãn thật và cột tương ứng với nhãn dự đoán.

$$\mathbf{M}_{ab} = \sum_{i=1}^N \mathbb{I}(y_i = a) \mathbb{I}(\hat{y}_i = b). \quad (4.8)$$

Trong Công thức 4.8, $\mathbf{M} \in \mathbb{N}^{C \times C}$ là ma trận nhầm lẫn, $\mathbf{M}_{ab}$ là số mẫu có nhãn thật a nhưng được dự đoán thành lớp b , N là số mẫu và $\mathbb{I}(\cdot)$ là hàm chỉ thị. Các phần tử trên đường chéo là dự đoán đúng, còn các phần tử ngoài đường chéo biểu thị các cặp lớp bị nhầm lẫn.

Confusion Matrix được sử dụng vì các độ đo tổng hợp không cho biết mô hình thường nhầm giữa những bệnh lý nào. Ma trận hỗ trợ nhận diện thiên lệch về lớp phổ biến, các cặp bệnh có biểu hiện gần nhau và lớp hiếm bị bỏ sót. Độ đo này không có quy tắc cao hơn hoặc thấp hơn cho toàn ma trận; kết quả thuận lợi được thể hiện bằng khối lượng tập trung trên đường chéo.

4.2.2 Độ đo phát hiện dữ liệu ngoài phân phối

Đối với đánh giá OOD, $\mathcal{D}_{ID}$ và $\mathcal{D}_{OOD}$ lần lượt là tập trong phân phối và ngoài phân phối, còn N_{ID} và N_{OOD} là số mẫu tương ứng. Mọi detector được quy đổi về cùng quy ước $s(x)$ là điểm bất thường, trong đó giá trị lớn hơn biểu thị bằng chứng OOD mạnh hơn. Quy ước này cần được cố định trước khi tính các độ đo để tránh đảo chiều kết quả.

AUROC-OOD

AUROC-OOD biểu thị xác suất một mẫu OOD ngẫu nhiên nhận điểm bất thường cao hơn một mẫu ID ngẫu nhiên, đồng thời tính một nửa đóng góp cho trường hợp hai điểm bằng nhau.

$$\text{AUROC}_{\text{OOD}} = \Pr[s(x_{\text{OOD}}) > s(x_{\text{ID}})] + \frac{1}{2} \Pr[s(x_{\text{OOD}}) = s(x_{\text{ID}})]. \quad (4.9)$$

Trong Công thức 4.9, x_{OOD} và x_{ID} là các mẫu được lấy lần lượt từ $\mathcal{D}_{\text{OOD}}$ và $\mathcal{D}_{\text{ID}}$, $s(\cdot)$ là hàm điểm bất thường và $\Pr(\cdot)$ là xác suất của quan hệ xếp hạng.

AUROC-OOD được sử dụng để so sánh khả năng phân tách tổng quát của các detector trên toàn bộ ngưỡng. Độ đo không phụ thuộc vào một tỷ lệ ID/OOD cụ thể tại một điểm vận hành, nhưng có thể che khuất hiệu năng ở vùng false-positive rate thấp. Giá trị cao hơn biểu thị khả năng xếp hạng OOD tốt hơn.

AUPR-Out

AUPR-Out xem OOD là lớp dương và đánh giá sự đánh đổi giữa precision và recall khi ngưỡng của điểm bất thường thay đổi. Diện tích được ước lượng bằng average precision không nội suy để thống nhất với cách tính trong thực nghiệm.

$$\text{AUPR-Out} = \sum_{k=1}^K (R_k^{\text{OOD}} - R_{k-1}^{\text{OOD}}) P_k^{\text{OOD}}. \quad (4.10)$$

Trong Công thức 4.10, K là số điểm ngưỡng trên đường precision–recall, P_k^{OOD} và R_k^{OOD} lần lượt là precision và recall của lớp OOD tại điểm thứ k , còn $R_0^{\text{OOD}} = 0$ là mức recall khởi đầu.

AUPR-Out được sử dụng vì tập OOD thường có quy mô nhỏ hơn tập ID và precision phản ánh trực tiếp mức độ nhiễu trong các cảnh báo OOD. Độ đo bổ sung cho AUROC-OOD bằng cách nhấn mạnh chất lượng cảnh báo khi tỷ lệ lớp không cân bằng. Giá trị cao hơn biểu thị đường precision–recall tốt hơn, nhưng cần được đối chiếu với tỷ lệ OOD vì mức ngẫu nhiên của AUPR-Out bằng tỷ lệ lớp dương.

FPR@95%TPR

Trong báo cáo, FPR@95%TPR sử dụng ID làm lớp dương theo quy ước phổ biến của giao thức OOD: một mẫu ID được chấp nhận khi $s(x) \leq \tau$, còn một mẫu có $s(x) > \tau$ bị từ chối như OOD. Ngưỡng benchmark được chọn để giữ đúng ít nhất 95% mẫu ID.

$$\tau_{95} = \inf \left\{ \tau : \frac{1}{N_{\text{ID}}} \sum_{x \in \mathcal{D}_{\text{ID}}} \mathbb{I}[s(x) \leq \tau] \geq 0,95 \right\}. \quad (4.11)$$

Trong Công thức 4.11, τ_{95} là ngưỡng nhỏ nhất đạt ID-TPR ít nhất 0,95, N_{ID} là số mẫu ID, $\mathcal{D}_{\text{ID}}$ là tập ID, $s(x)$ là điểm bất thường và $\mathbb{I}(\cdot)$ là hàm chỉ thị của quyết định chấp nhận ID.

$$\text{FPR@95\%TPR} = \frac{1}{N_{\text{OOD}}} \sum_{x \in \mathcal{D}_{\text{OOD}}} \mathbb{I}[s(x) \leq \tau_{95}]. \quad (4.12)$$

Trong Công thức 4.12, N_{OOD} là số mẫu OOD, $\mathcal{D}_{\text{OOD}}$ là tập OOD, $s(x) \leq \tau_{95}$ biểu thị một mẫu OOD bị chấp nhận nhầm như ID và τ_{95} là ngưỡng được xác định trong Công thức 4.11.

FPR@95%TPR được sử dụng để phản ánh trực tiếp tỷ lệ OOD lọt qua detector khi hệ thống phải duy trì mức chấp nhận ID cao. Độ đo này cung cấp góc nhìn vận hành mà AUROC-OOD không thể hiện đầy đủ. Giá trị thấp hơn là tốt hơn; ngưỡng benchmark được tính để so sánh detector và cần được phân biệt với ngưỡng triển khai chỉ được hiệu chỉnh trên validation ID.

4.2.3 Độ đo phân tích chú ý và dung hợp

Các độ đo trong nhóm này được tính trên tập mẫu phân tích nhằm mô tả hành vi bên trong mô-đun chú ý chéo. Chúng không được xem là bằng chứng trực tiếp rằng mô hình định vị đúng tổn thương hoặc đưa ra giải thích có quan hệ nhân quả. Hai hướng dung hợp được ký hiệu bởi $\mathcal{M} = \{I \leftarrow T, T \leftarrow I\}$, tương ứng với ngữ cảnh văn bản bổ sung cho ảnh và ngữ cảnh ảnh bổ sung cho văn bản.

Attention Entropy

Attention Entropy đo mức phân tán của trọng số chú ý trên các token ngữ cảnh hợp lệ. Entropy được chuẩn hóa theo số token để các chuỗi có độ dài khác nhau có thể được đối chiếu trên cùng thang đo.

$$H_{\text{att}}^{(m)} = \frac{1}{N} \sum_{i=1}^N \frac{-\sum_{j=1}^{L_i^{(m)}} a_{ij}^{(m)} \log(a_{ij}^{(m)} + \epsilon)}{\log L_i^{(m)}}. \quad (4.13)$$

Trong Công thức 4.13, $m \in \mathcal{M}$ là một hướng chú ý, N là số mẫu, $L_i^{(m)}$ là số token key hợp lệ của mẫu i , $a_{ij}^{(m)}$ là trọng số chú ý của token thứ j sau khi đã tổng hợp các head và chuẩn hóa để tổng bằng một, còn ϵ là hằng số dương nhỏ dùng để tránh log 0. Giá trị được chuẩn hóa nằm gần khoảng từ không đến một.

Attention Entropy được sử dụng để phát hiện attention quá tập trung

vào rất ít token hoặc gần như phân bố đều trên mọi token. Giá trị thấp biểu thị phân bố tập trung, còn giá trị cao biểu thị phân bố rộng; không có chiều tốt hơn tuyệt đối vì mức tập trung phù hợp phụ thuộc nội dung mẫu và hướng chú ý. Độ đo cần được đọc cùng can thiệp đầu ra thay vì dùng riêng để kết luận về tính giải thích.

Fusion Contribution

Fusion Contribution mô tả tỷ phần đóng góp hỗ trợ của từng hướng dung hợp dựa trên mức giảm xác suất của lớp mục tiêu khi hướng đó bị loại bỏ. Chỉ phần giảm dương được sử dụng trong tỷ lệ để một nhánh làm tăng xác suất mục tiêu không bị triệt tiêu bởi một nhánh có tác động ngược chiều.

$$FC_m = \frac{\sum_{i=1}^N [\Delta p_i^{(m)}]_+}{\sum_{r \in \mathcal{M}} \sum_{i=1}^N [\Delta p_i^{(r)}]_+ + \epsilon}. \quad (4.14)$$

Trong Công thức 4.14, FC_m là tỷ phần đóng góp của hướng m , $\mathcal{M}$ là tập hai hướng dung hợp, N là số mẫu, $\Delta p_i^{(m)}$ là độ giảm xác suất sau can thiệp trên mẫu i , $[z]_+ = \max(z, 0)$ giữ lại phần dương và ϵ là hằng số nhỏ bảo đảm mẫu số khác không.

Fusion Contribution được sử dụng để so sánh mức phụ thuộc tương đối của dự đoán vào hai hướng truyền thông tin. Giá trị lớn hơn cho một hướng chỉ biểu thị hướng đó chiếm tỷ phần lớn hơn trong tổng tác động hỗ trợ đã quan sát; độ đo không chứng minh phương thức tương ứng quan trọng hơn về mặt lâm sàng và không thay thế đánh giá ablation trên tập kiểm thử.

Attention Context Cosine

Attention Context Cosine đo mức đồng hướng giữa hai vector ngữ cảnh do hai nhánh chú ý chéo tạo ra trước khi chúng được đưa vào MLP dung hợp.

$$\text{Cos}_{\text{ctx}} = \frac{1}{N} \sum_{i=1}^N \frac{(\mathbf{c}_i^{I \leftarrow T})^\top \mathbf{c}_i^{T \leftarrow I}}{\|\mathbf{c}_i^{I \leftarrow T}\|_2 \|\mathbf{c}_i^{T \leftarrow I}\|_2}. \quad (4.15)$$

Trong Công thức 4.15, N là số mẫu, $\mathbf{c}_i^{I \leftarrow T}$ là ngữ cảnh văn bản được truy hồi cho nhánh ảnh, $\mathbf{c}_i^{T \leftarrow I}$ là ngữ cảnh ảnh được truy hồi cho nhánh văn bản, ký hiệu $\top$ biểu thị chuyển vị và $\|\cdot\|_2$ là chuẩn Euclid.

Attention Context Cosine được sử dụng để khảo sát liệu hai hướng chú ý tạo thông tin tương đồng, gần trực giao hay đối nghịch trong không gian biểu diễn. Giá trị gần một biểu thị hai context đồng hướng, gần không biểu thị mức đồng hướng thấp và giá trị âm biểu thị xu hướng đối nghịch. Không có chiều tốt hơn tuyệt đối vì hai nhánh có thể hữu ích khi mang thông tin bổ sung thay vì lặp lại nhau.

Prediction Drop after Intervention

Prediction Drop after Intervention đo thay đổi xác suất của lớp mục tiêu khi một nhánh dung hợp bị đặt về không trong khi các thành phần còn lại được giữ nguyên. Lớp mục tiêu là lớp được mô hình đầy đủ dự đoán trước can thiệp.

$$\text{PD}_m = \frac{1}{N} \sum_{i=1}^N \left[p_{i, \hat{y}_i}^{\text{full}} - p_{i, \hat{y}_i}^{(-m)} \right]. \quad (4.16)$$

Trong Công thức 4.16, PD_m là độ giảm xác suất trung bình khi loại bỏ hướng m , N là số mẫu, $\hat{y}_i$ là lớp dự đoán của mô hình đầy đủ, $p_{i, \hat{y}_i}^{\text{full}}$ là xác suất của lớp đó trước can thiệp và $p_{i, \hat{y}_i}^{(-m)}$ là xác suất sau khi vector của hướng m bị đặt về không.

Prediction Drop được sử dụng để kiểm tra liệu tín hiệu được mô-đun dung hợp tạo ra có ảnh hưởng thực tế đến đầu ra hay không. Giá trị dương lớn cho thấy việc loại bỏ nhánh làm giảm độ tin cậy của dự đoán ban đầu, giá trị gần không cho thấy tác động nhỏ và giá trị âm cho thấy xác suất tăng sau khi loại bỏ. Vì can thiệp có thể tạo biểu diễn khác phân phối huấn luyện, kết quả được diễn giải như bằng chứng chức năng hỗ trợ thay vì quan hệ nhân quả đầy đủ.

4.3 Thiết lập thực nghiệm

Phần này trình bày các thiết lập thực nghiệm, bao gồm môi trường phần cứng và phần mềm, cũng như các siêu tham số được sử dụng trong quá trình huấn luyện mô hình. Các thiết lập này nhằm đảm bảo tính nhất quán và khả năng tái tạo của các thí nghiệm.

4.3.1 Môi trường thực nghiệm

Mô hình đề xuất được chạy ba lần trong các điều kiện và siêu tham số giống nhau. Môi trường phần cứng được trình bày trong Bảng 4.4.

Thành phần	Cấu hình
GPU	1 × RTX 5060 Ti 16 GB VRAM
CPU	Intel Core Ultra 7 265KF
Bộ nhớ hệ thống	32 GB RAM
Độ chính xác số học	BF16 trong cả hai pha huấn luyện

Bảng 4.4: Môi trường phần cứng được thiết lập

Môi trường phần mềm được cố định theo tệp phụ thuộc của dự án và được tóm tắt trong Bảng 4.5.

Thành phần	Phiên bản
Python	3.11.15
Torch	2.11.0+cu128
CUDA runtime	12.8

Bảng 4.5: Phiên bản của các thư viện chính trong môi trường thí nghiệm

Đối với phân tích hiệu quả suy luận, năm đại lượng được báo cáo gồm tổng số và số tham số có thể huấn luyện (Params), số phép toán trên một mẫu (GFLOPs), thông lượng (mẫu/giây), độ trễ suy luận (ms/mẫu) và bộ nhớ GPU cực đại (MiB). Độ trễ được tổng hợp bằng giá trị trung bình, P50 và P95 sau các lượt khởi động; bộ nhớ GPU cực đại là lượng bộ nhớ CUDA được cấp phát lớn nhất trong một lượt truyền thuận. Thời gian nạp dữ liệu, tiền xử lý trên CPU và truyền dữ liệu từ CPU sang GPU không được tính vào độ trễ. Mọi mô hình được đo trên cùng GPU, độ

chính xác số học, kích thước lô, số lượt khởi động và số lần lặp; với các mô hình zero-shot, biểu diễn prompt được tính trước và không được tính vào thời gian suy luận từng ảnh. Thiết lập này nhằm phản ánh chi phí của chính mô hình và duy trì tính nhất quán giữa các phép đối sánh.

4.3.2 Tham số thực nghiệm

Các Bảng 4.6 và 4.7 dưới đây mô tả cấu hình siêu tham số của mô hình đề xuất. Các siêu tham số được lựa chọn dựa trên các nghiên cứu trước và thử nghiệm sơ bộ để tối ưu hóa hiệu suất mô hình trên cả hai bộ dữ liệu BTXRD và CTCH. Các siêu tham số này bao gồm độ phân giải ảnh đầu vào, bộ tối ưu hóa, tốc độ học, suy giảm trọng số, bộ điều chỉnh tốc độ học, tỷ lệ khởi động, kích thước lô, số epoch tối đa, số epoch dừng sớm, nhiệt độ tương phản (τ), trạng thái tham số Backbone, hạng LoRA (r), hệ số LoRA (α) và tỷ lệ bỏ học LoRA.

4.3.3 Tham số thực nghiệm

Siêu tham số	Pha 1
Độ phân giải ảnh đầu vào	1 ảnh global 224×224 và 4 tile cùng kích thước
Bộ tối ưu hóa	AdamW
Tốc độ học	5×10^{-5}
Suy giảm trọng số	1×10^{-4}
Bộ điều chỉnh tốc độ học	Cosine
Tỷ lệ khởi động	0.1
Kích thước lô	16
Số epoch tối đa	30
Số epoch dừng sớm	3 epochs
Nhiệt độ tương phản (τ)	0.07
Trạng thái tham số Backbone	Tinh chỉnh qua LoRA
Hạng QLoRA (r)	16
Hệ số QLoRA (α)	32
Tỷ lệ bỏ học QLoRA	0.1

Bảng 4.6: Bảng tổng hợp siêu tham số ở pha 1 và thiết lập của chúng

Siêu tham số	Pha 2
Độ phân giải ảnh đầu vào	Giống pha 1
Bộ tối ưu hóa	AdamW
Tốc độ học	1×10^{-4}
Suy giảm trọng số	1×10^{-4}
Bộ điều chỉnh tốc độ học	Cosine
Tỷ lệ khởi động	0.1
Kích thước lô	16
Số epoch tối đa	50
Số epoch dừng sớm	5 epochs
Nhiệt độ tương phản (τ)	Không áp dụng
Trạng thái tham số Backbone	Tinh chỉnh qua LoRA
Hạng QLoRA (r)	16
Hệ số QLoRA (α)	32
Tỷ lệ bỏ học QLoRA	0.1

Bảng 4.7: Bảng tổng hợp siêu tham số ở pha 2 và thiết lập của chúng

4.4 Nội dung thực nghiệm

Phần này trình bày các nhóm thí nghiệm được thực hiện trên hai bộ dữ liệu BTXRD và CTCH, bao gồm nội dung, mục đích và các mô hình sử dụng.

4.4.1 Đánh giá mô hình nền tảng

Thiết kế mô hình: Nhóm thí nghiệm này sử dụng bốn mô hình ngôn ngữ trực quan gồm CLIP, MedCLIP, PubMedCLIP và BiomedCLIP ở chế độ zero-shot. Toàn bộ tham số của backbone được giữ cố định; mô hình không được huấn luyện trên dữ liệu đích. Với mỗi lớp, tên lớp được đưa vào một mẫu prompt cố định để tạo biểu diễn văn bản. Nhãn dự đoán được xác định từ lớp có độ tương đồng lớn nhất giữa biểu diễn ảnh và biểu diễn văn bản.

Mục đích thực nghiệm: Thí nghiệm khảo sát khả năng chuyển trực tiếp tri thức đã tiền huấn luyện sang bài toán phân loại X-quang xương. Thiết lập này cung cấp một mốc tham chiếu không sử dụng mẫu huấn

luyện của bộ dữ liệu đích, qua đó cho phép xem xét mức độ phù hợp ban đầu của các mô hình ngôn ngữ trực quan

Dữ liệu và độ đo: Bốn mô hình được đánh giá độc lập trên tập kiểm thử của BTXRD và CTCH; các tập huấn luyện và validation không được sử dụng để cập nhật mô hình. Các độ đo báo cáo gồm Accuracy, Balanced Accuracy, Macro-F1, Macro-AUROC, Macro-AUPRC và ECE theo định nghĩa tại Mục 4.2; Confusion Matrix được sử dụng để phân tích các cặp lớp thường bị nhầm lẫn. Do suy luận zero-shot không có biến thiên từ quá trình huấn luyện, khoảng tin cậy bootstrap 95% với $B = 10.000$ lần lấy mẫu lại được dùng để mô tả độ bất định do tập kiểm thử hữu hạn.

4.4.2 So sánh với các mô hình nền tảng

Thiết kế mô hình: Nhóm đối sánh có ba thiết lập bổ sung cho nhau:

1. Mẫu hạn chế:

XBone-Net, LoRA-BiomedCLIP và LoRA-PubMedCLIP được huấn luyện với 1, 10 hoặc 20 mẫu cho mỗi lớp ở tập huấn luyện, tập đánh giá và kiểm thử được giữ nguyên. Hai mô hình áp dụng kỹ thuật LoRA sử dụng quy trình hai pha, phép nối đặc trưng và đầu phân loại tuyến tính.

2. Toàn bộ dữ liệu:

ResNet-50 và DenseNet-121 được tinh chỉnh toàn bộ với đầu tuyến tính và chỉ nhận ảnh. Các mô hình ngôn ngữ trực quan y khoa gồm CLIP, MedCLIP, PubMedCLIP và BiomedCLIP được tinh chỉnh toàn bộ, sử dụng ảnh cùng báo cáo lâm sàng, phép nối đặc trưng và đầu tuyến tính.

3. Đối sánh tinh chỉnh hiệu quả tham số:

Hai mô hình BiomedCLIP và PubMedCLIP được áp dụng kỹ thuật LoRA. Hai mô hình này giữ phép nối đặc trưng và đầu tuyến tính.

Mục đích thực nghiệm: Thiết lập mẫu hạn chế đánh giá khả năng học khi số mẫu gán nhãn bị giới hạn và mức suy giảm so với khi huấn luyện trên toàn bộ dữ liệu khi áp dụng kỹ thuật LoRA. Thiết lập toàn bộ dữ liệu cung cấp đối sánh tổng thể giữa mô hình ảnh đơn phương thức, các

mô hình ngôn ngữ trực quan y khoa được tinh chỉnh và pipeline đề xuất. Đối sánh tinh chỉnh hiệu quả tham số được dùng để xem xét liệu các mô hình ngôn ngữ trực quan y khoa có thể đạt được hiệu suất tương tự như mô hình tinh chỉnh toàn bộ khi chỉ được huấn luyện với một số lượng nhỏ tham số.

Dữ liệu và độ đo: Tất cả ba thiết lập được thực hiện trên BTXRD và CTCH với các tập huấn luyện, validation và kiểm thử cố định. Kết quả được tổng hợp trên ba hạt giống 42, 123 và 456 bằng Accuracy, Balanced Accuracy, Macro-F1, Macro-AUROC, Macro-AUPRC và ECE; Macro-F1 là độ đo dùng để lựa chọn checkpoint trên tập validation, còn Confusion Matrix hỗ trợ phân tích sai số theo cặp lớp. Khoảng tin cậy bootstrap 95% với $B = 10.000$ được tính trên tập kiểm thử. Nhằm mô tả đánh đổi giữa hiệu năng dự đoán và chi phí suy luận, tổng số và số tham số có thể huấn luyện, GFLOPs trên mỗi mẫu, thông lượng, độ trễ suy luận và bộ nhớ GPU cực đại cũng được báo cáo.

4.4.3 Đánh giá thành phần

Thiết kế biến thể. Các biến thể kế thừa cấu hình của mô hình đề xuất ngoài thành phần đang khảo sát, dữ liệu, hạt giống và quy trình chọn checkpoint được giữ cố định. Bốn nhóm biến thể gồm:

1. **Tiền xử lý ảnh:** mô hình đề xuất dùng một ảnh toàn cục và bốn vùng tiêu điểm thừa. Biến thể **nohighres** dùng direct resize về 224×224 , còn **letterbox** giữ tỷ lệ ảnh và thêm biên đệm. Hai biến thể vẫn tạo tám token từ một ảnh để giữ ổn định đầu vào của mô-đun dung hợp.
2. **Tinh chỉnh:** mô hình đề xuất cập nhật adapter LoRA trong cả hai pha huấn luyện. Biến thể **no finetune** đóng băng các encoder được kế thừa từ BioMedCLIP [50] nhưng vẫn cho phép mô-đun lấy mẫu không gian được huấn luyện và **full finetune** cập nhật toàn bộ tham số mô hình kế thừa.
3. **Dung hợp:** cross-attention hai chiều của mô hình đề xuất được so

sánh với phép nổi đặc trưng và hai biến thể attention **một chiều ảnh sang văn bản, văn bản sang ảnh**.

4. **Đầu phân loại và cân bằng lớp:** đầu tính tâm cụm với trọng số lớp được so sánh với biến thể sử dụng đầu tuyến tính và biến thể giữ đầu tính tâm cụm nhưng loại bỏ trọng số lớp.

Mục đích thực nghiệm. Nhóm thí nghiệm lần lượt xem xét vai trò của việc bảo toàn chi tiết ảnh độ phân giải cao, chiến lược cập nhật mô hình kế thừa, hướng trao đổi thông tin giữa hai phương thức và lựa chọn đầu phân loại trong điều kiện mất cân bằng lớp. Thiết kế kế thừa cùng cấu hình giúp giới hạn thay đổi trong từng phép so sánh, từ đó hỗ trợ diễn giải chênh lệch theo thành phần.

Dữ liệu và độ đo. Toàn bộ đánh giá thành phần được thực hiện trên CTCH với ba hạt giống 42, 123 và 456. Hiệu năng phân loại được đánh giá bằng Accuracy, Balanced Accuracy, Macro-F1, Macro-AUROC, Macro-AUPRC và ECE, kèm Confusion Matrix cho các biến thể cần phân tích sai số theo lớp và khoảng tin cậy bootstrap 95% với $B = 10.000$. Với nhóm tinh chỉnh và tiền xử lý ảnh, tổng số và số tham số có thể huấn luyện, GFLOPs trên mỗi mẫu, thông lượng, độ trễ suy luận và bộ nhớ GPU cực đại được ghi nhận bổ sung để mô tả đánh đổi về tài nguyên.

4.4.4 OOD hậu xử lý

Thiết kế phương pháp. Phân tích OOD không huấn luyện lại mô hình phân loại mà sử dụng trọng số của CTCH ở ba hạt giống. Các bộ phát hiện dựa trên đặc trưng gồm khoảng cách Mahalanobis tới tâm lớp gần nhất và cosine kNN với $k = 5$. Hai phương pháp này sử dụng biểu diễn fused đã được huấn luyện, trong đó token ảnh toàn cục, các token ảnh cục bộ độ phân giải cao và các token bệnh sử được kết hợp bằng cross-attention hai chiều trước khi chiếu qua fusion MLP. Các bộ phát hiện dựa trên đầu ra gồm MSP, entropy chuẩn hóa, energy với $T = 1$ và negative max-logit. Thống kê của bộ phát hiện đặc trưng được ước lượng từ CTCH train. Ngưỡng vận hành được hiệu chỉnh chỉ trên CTCH validation-ID sao cho tỷ lệ từ chối ID xấp xỉ 5%, sau đó được khóa trước khi đánh giá.

Mục đích thực nghiệm. Nhóm thí nghiệm đánh giá liệu các điểm hậu xử lý có thể tách mẫu ngoài phân phối khỏi mẫu thuộc phân phối huấn luyện mà không thay đổi bộ phân loại hay không. Ba dạng sai lệch được xem xét riêng gồm khác biệt ngữ nghĩa bệnh, dịch chuyển miền ảnh và sự không nhất quán giữa ảnh với bệnh sử. Cách tách scenario này hạn chế việc quy mọi trường hợp bất thường về một nguồn sai lệch duy nhất.

Dữ liệu và độ đo. Tập ID gồm CTCH train để khớp bộ phát hiện, CTCH validation để hiệu chỉnh ngưỡng và CTCH test để đánh giá. Semantic OOD sử dụng archive `ctch_ood`; domain OOD sử dụng riêng tập kiểm thử FracAtlas và 750 mẫu thuộc tập kiểm thử BTXRD. Với cả hai nguồn domain OOD, Mahalanobis và kNN trên biểu diễn fused ảnh–bệnh sử là phân tích chính. BTXRD được xem như một nguồn OOD khác bộ dữ liệu, kết hợp dịch chuyển miền thu nhận với thay đổi không gian nhãn theo các bệnh lý u xương; riêng lớp bình thường có ngữ nghĩa giao một phần với CTCH. Vì bệnh sử `clinical_v2` của BTXRD là văn bản tổng hợp, kết quả trên nguồn này được diễn giải như khả năng phát hiện OOD đa phương thức, không được dùng làm bằng chứng riêng cho dịch chuyển miền ảnh. Report mismatch được tạo bằng cách ghép ảnh với bệnh sử khác lớp, còn ghép cùng lớp là phân tích phụ. Ba độ đo chính là AUROC-OOD, AUPR-Out và FPR@95%TPR theo quy ước ID-TPR; khoảng tin cậy bootstrap 95% được tính với $B = 2.000$ lần lấy mẫu lại. AUROC-OOD và AUPR-Out cao hơn biểu thị khả năng phân tách hoặc chất lượng cảnh báo tốt hơn, trong khi FPR@95%TPR thấp hơn biểu thị ít mẫu OOD bị chấp nhận nhầm hơn tại mức giữ lại 95% ID.

4.4.5 Giải thích và biểu diễn

Thiết kế phương pháp. Phân tích sử dụng checkpoint XBone-Net canonical trên CTCH ở ba hạt giống. Với mỗi hạt giống, mẫu test được lấy phân tầng theo nhãn thật, tối đa hai mẫu mỗi lớp và không quá 44 mẫu. Integrated Gradients với 24 bước được áp dụng cho các token ảnh cục bộ; token bệnh sử được phân tích bằng can thiệp thay thế. Độ trung thực được kiểm tra bằng các đường deletion và insertion so với thứ tự ngẫu nhiên và thứ tự ít liên quan. Độ ổn định được khảo sát dưới nhiễu nhỏ,

đồng thời classifier-randomization được dùng như một sanity check. Phần biểu diễn khảo sát sáu không gian gồm đặc trưng fused, ảnh toàn cục, tóm tắt ảnh cục bộ, văn bản toàn cục và hai hướng cross-attention.

Mục đích thực nghiệm. Phân tích attribution nhằm xác định mức độ phụ thuộc của dự đoán vào các token ảnh và bệnh sử, đồng thời kiểm tra liệu thứ hạng attribution có ổn định và phản ánh đầu ra của mô hình hay không. Phân tích biểu diễn khảo sát mức độ kết cụm theo lớp và khoảng cách giữa mẫu với tâm lớp trong từng không gian nhúng. CTCH chưa có annotation vùng tổn thương trong protocol, do đó nhóm này không báo cáo IoU, Dice hoặc độ chính xác định vị.

Dữ liệu và độ đo. Phân tích được thực hiện trên tập con test CTCH đã chọn và báo cáo Attention Entropy riêng cho hai hướng chú ý, Fusion Contribution của từng hướng, Attention Context Cosine giữa hai vector ngữ cảnh và Prediction Drop after Intervention khi lần lượt loại bỏ từng nhánh dung hợp. Các phân tích hình học biểu diễn khác được trình bày như kết quả bổ sung và không thuộc bộ độ đo chính được định nghĩa tại Mục 4.2. Các đại lượng chú ý và dung hợp được xem là chỉ báo định lượng hỗ trợ cho phân tích cơ chế, không phải bằng chứng trực tiếp về khả năng định vị tổn thương hoặc quan hệ nhân quả lâm sàng.

4.5 Kết quả thực nghiệm và thảo luận

Phần này trình bày các kết quả thí nghiệm đối với thí nghiệm có huấn luyện, giá trị trong bảng là trung bình $\pm$ độ lệch chuẩn mẫu trên ba hạt giống ngẫu nhiên 42, 123 và 456. Kết quả phân loại không mẫu được báo cáo bằng ước lượng điểm do quá trình suy luận có tính xác định. Giá trị tốt nhất theo từng cột và trong cùng một thiết lập được in đậm, khoảng tin cậy bootstrap 95% được lưu cho từng lần chạy.

4.5.1 Đánh giá mô hình nền tảng

Kết quả zero-shot trên hai bộ dữ liệu được trình bày trong Bảng 4.8 theo bốn độ đo chính đã xác định ở Mục 4.2.

Dữ liệu	Mô hình	Acc $\uparrow$	Balanced Acc $\uparrow$	Macro-F1 $\uparrow$	Macro AUROC $\uparrow$
BTXRD	CLIP	0.0640	0.1297	0.0631	0.4997
	MedCLIP	0.0387	0.0935	0.0075	0.4628
	PubMedCLIP	0.0893	0.1334	0.0690	0.5531
	BiomedCLIP	0.3427	0.1493	0.1289	0.5786
CTCH	CLIP	0.1540	0.2367	0.1307	0.8003
	MedCLIP	0.0179	0.0224	0.0043	0.4707
	PubMedCLIP	0.1016	0.1294	0.0698	0.7920
	BiomedCLIP	0.2556	0.2109	0.1659	0.8191

Bảng 4.8: Kết quả zero-shot trên BTXRD và CTCH, chữ đậm biểu thị giá trị tốt nhất theo từng bộ dữ liệu

Trên BTXRD, BiomedCLIP đạt giá trị cao nhất ở cả bốn độ đo. Khoảng tin cậy bootstrap 95% của Acc, Balanced Acc, Macro-F1 và Macro AUROC lần lượt là $[0.3093; 0.3760]$, $[0.1116; 0.1927]$, $[0.0945; 0.1661]$ và $[0.5443; 0.6118]$. Tuy nhiên, Macro-F1 và Balanced Acc vẫn thấp, cho thấy cấu hình zero-shot hiện tại chưa bao phủ đồng đều mười lớp BTXRD.

Trên CTCH, BiomedCLIP đạt Acc, Macro-F1 và Macro AUROC cao nhất, trong khi CLIP có Balanced Acc cao nhất. Macro-F1 của BiomedCLIP đạt 0.1659 với khoảng tin cậy $[0.1263; 0.1966]$; Balanced Acc của CLIP đạt 0.2367 với khoảng tin cậy $[0.2055; 0.2648]$. Kết quả này cho thấy thứ hạng mô hình phụ thuộc vào độ đo và chưa hỗ trợ việc sử dụng trực tiếp các mô hình nền tảng cho bài toán 22 lớp CTCH mà không thích ứng dữ liệu đích.

Dựa vào bảng số liệu trên, nhóm nghiên cứu nhận thấy BiomedCLIP là mô hình nền tảng có hiệu năng tốt nhất trong bối cảnh zero-shot, đặc biệt trên bộ dữ liệu BTXRD. Tuy nhiên, để đạt được hiệu quả cao hơn trong các bài toán phân loại đa lớp phức tạp như CTCH, cần thực hiện các bước tinh chỉnh và thích ứng mô hình với dữ liệu đích.

4.5.2 So sánh với các mô hình nền tảng

Kết quả khi sử dụng toàn bộ dữ liệu huấn luyện

Dữ liệu	Mô hình	Acc $\uparrow$	Balanced Acc $\uparrow$	Macro-F1 $\uparrow$	Macro AUROC $\uparrow$
BTXRD	ResNet-50	0.6071 $\pm$ 0.0140	0.3188 $\pm$ 0.0136	0.3291 $\pm$ 0.0102	0.7236 $\pm$ 0.0259
	DenseNet-121	0.6320 $\pm$ 0.0013	0.3694 $\pm$ 0.0150	0.3718 $\pm$ 0.0173	0.7717 $\pm$ 0.0173
	CLIP (full FT)	0.8036 $\pm$ 0.0273	0.5957 $\pm$ 0.0160	0.5787 $\pm$ 0.0252	0.8973 $\pm$ 0.0231
	MedCLIP (full FT)	0.8204 $\pm$ 0.0144	0.6125 $\pm$ 0.0235	0.6054 $\pm$ 0.0147	0.8599 $\pm$ 0.0330
	PubMedCLIP (full FT)	0.7884 $\pm$ 0.0285	0.6089 $\pm$ 0.0342	0.5723 $\pm$ 0.0577	0.9048 $\pm$ 0.0240
	BiomedCLIP (full FT)	0.8311 $\pm$ 0.0028	0.6062 $\pm$ 0.0254	0.5994 $\pm$ 0.0124	0.8865 $\pm$ 0.0165
	LoRA-BiomedCLIP	0.8302 $\pm$ 0.0008	0.6339 $\pm$ 0.0291	0.6326 $\pm$ 0.0217	0.8771 $\pm$ 0.0298
	LoRA-PubMedCLIP	0.8316 $\pm$ 0.0134	0.6457 $\pm$ 0.0319	0.6397 $\pm$ 0.0214	0.9031 $\pm$ 0.0170
	XBone-Net	0.8324 $\pm$ 0.0015	0.5878 $\pm$ 0.0106	0.6001 $\pm$ 0.0116	0.9383 $\pm$ 0.0072
CTCH	ResNet-50	0.4928 $\pm$ 0.0017	0.4126 $\pm$ 0.0106	0.4078 $\pm$ 0.0051	0.9145 $\pm$ 0.0037
	DenseNet-121	0.4818 $\pm$ 0.0052	0.4927 $\pm$ 0.0461	0.4367 $\pm$ 0.0238	0.9350 $\pm$ 0.0046
	CLIP (full FT)	0.5874 $\pm$ 0.0209	0.6217 $\pm$ 0.0359	0.5633 $\pm$ 0.0090	0.9290 $\pm$ 0.0387
	MedCLIP (full FT)	0.5590 $\pm$ 0.0389	0.5717 $\pm$ 0.0186	0.5151 $\pm$ 0.0216	0.9215 $\pm$ 0.0333
	PubMedCLIP (full FT)	0.5521 $\pm$ 0.0234	0.5589 $\pm$ 0.0614	0.5203 $\pm$ 0.0264	0.9279 $\pm$ 0.0214
	BiomedCLIP (full FT)	0.5969 $\pm$ 0.0253	0.6023 $\pm$ 0.0234	0.5540 $\pm$ 0.0080	0.9390 $\pm$ 0.0289
	LoRA-BiomedCLIP	0.5959 $\pm$ 0.0212	0.6092 $\pm$ 0.0243	0.5599 $\pm$ 0.0220	0.9334 $\pm$ 0.0216
	LoRA-PubMedCLIP	0.6203 $\pm$ 0.0105	0.6091 $\pm$ 0.0267	0.5816 $\pm$ 0.0102	0.9275 $\pm$ 0.0088
	XBone-Net	0.5830 $\pm$ 0.0065	0.6049 $\pm$ 0.0296	0.5646 $\pm$ 0.0084	0.9568 $\pm$ 0.0086

Bảng 4.9: Kết quả phân loại khi sử dụng toàn bộ dữ liệu, chữ đậm biểu thị giá trị tốt nhất theo từng cột trong mỗi bộ dữ liệu

Trên BTXRD, LoRA-PubMedCLIP đạt Macro-F1 và Balanced Acc cao nhất, trong khi XBone-Net đạt Acc và Macro AUROC cao nhất. Chênh lệch cho thấy XBone-Net có khả năng xếp hạng xác suất tốt hơn trong bảng so sánh, nhưng chưa đạt kết quả cao nhất trên các độ đo cân bằng lớp. Trên CTCH, LoRA-PubMedCLIP đạt Acc và Macro-F1 cao nhất, CLIP được tinh chỉnh toàn bộ đạt Balanced Acc cao nhất, còn XBone-Net đạt Macro AUROC cao nhất. Vì thứ hạng thay đổi theo độ đo ở cả hai bộ dữ liệu, kết quả hiện tại phù hợp hơn với diễn giải về sự đánh đổi giữa các tiêu chí thay vì một kết luận vượt trội tổng thể.

Kết quả trong trường hợp mẫu học hạn chế

Dữ liệu	Shot	Mô hình	Acc $\uparrow$	Balanced Acc $\uparrow$	Macro-F1 $\uparrow$	Macro AUROC $\uparrow$
BTXRD	1	LoRA-BiomedCLIP	0.2560 ± 0.1068	0.2285 ± 0.0728	0.1675 ± 0.0670	0.6142 ± 0.0395
		LoRA-PubMedCLIP	0.3067 ± 0.0987	0.2225 ± 0.0288	0.1841 ± 0.0283	0.6433 ± 0.0222
		XBone-Net	0.2529 ± 0.0756	0.2107 ± 0.0719	0.1587 ± 0.0494	0.6172 ± 0.0249
	10	LoRA-BiomedCLIP	0.6809 ± 0.0301	0.4610 ± 0.0146	0.4121 ± 0.0139	0.8572 ± 0.0114
		LoRA-PubMedCLIP	0.6533 ± 0.0340	0.4602 ± 0.0078	0.4140 ± 0.0259	0.8579 ± 0.0243
		XBone-Net	0.6564 ± 0.0146	0.4685 ± 0.0379	0.4053 ± 0.0296	0.8477 ± 0.0165
CTCH	1	LoRA-BiomedCLIP	0.2028 ± 0.0175	0.2904 ± 0.0080	0.1976 ± 0.0049	0.8231 ± 0.0274
		LoRA-PubMedCLIP	0.1749 ± 0.0345	0.2451 ± 0.0482	0.1721 ± 0.0286	0.7848 ± 0.0279
		XBone-Net	0.2422 ± 0.0235	0.3407 ± 0.0737	0.2382 ± 0.0283	0.8388 ± 0.0334
	10	LoRA-BiomedCLIP	0.3986 ± 0.0321	0.5496 ± 0.0309	0.4272 ± 0.0219	0.9368 ± 0.0125
		LoRA-PubMedCLIP	0.3921 ± 0.0136	0.5466 ± 0.0126	0.4189 ± 0.0093	0.9269 ± 0.0099
		XBone-Net	0.3981 ± 0.0452	0.5563 ± 0.0408	0.4363 ± 0.0418	0.9350 ± 0.0070
	20	LoRA-BiomedCLIP	0.4410 ± 0.0152	0.6028 ± 0.0214	0.4794 ± 0.0171	0.9339 ± 0.0178
		LoRA-PubMedCLIP	0.4245 ± 0.0079	0.5887 ± 0.0148	0.4511 ± 0.0068	0.9354 ± 0.0062
		XBone-Net	0.4395 ± 0.0235	0.5909 ± 0.0084	0.4702 ± 0.0210	0.9499 ± 0.0011

Bảng 4.10: Kết quả few-shot của các thiết lập có đủ ba lần chạy; chữ đậm biểu thị giá trị tốt nhất trong từng mức shot và bộ dữ liệu

Trên BTXRD, không có mô hình dẫn đầu đồng thời bốn độ đo ở mức 1-shot hoặc 10-shot. LoRA-PubMedCLIP đạt Macro-F1 và Macro AUROC cao nhất ở cả hai mức, trong khi XBone-Net chỉ đạt Balanced Acc cao nhất ở mức 10-shot. Trên CTCH, XBone-Net đạt cao nhất cả bốn độ đo ở mức 1-shot. Khi tăng lên 10-shot, mô hình này vẫn có Macro-F1 và Balanced Acc cao nhất, còn LoRA-BiomedCLIP dẫn đầu Acc và Macro AUROC. Ở mức tối đa 20 mẫu mỗi lớp, LoRA-BiomedCLIP đạt ba độ đo phân loại theo quyết định cao nhất, trong khi XBone-Net giữ Macro AUROC cao nhất. Hai lớp hiếm của CTCH chỉ có lần lượt 19 và 16 mẫu huấn luyện, nhưng ba mô hình nhận cùng tập con nên phép đối sánh trong mức shot vẫn nhất quán.

4.5.3 Đánh giá thành phần

Kết quả của ba biến thể tiền xử lý ảnh trên ba lần chạy được trình bày trong Bảng 4.11.

Mô hình	Acc $\uparrow$	Balanced Acc $\uparrow$	Macro-F1 $\uparrow$	Macro AUROC $\uparrow$
XBone-Net (sparse-focal)	0.5830 ± 0.0065	0.6049 ± 0.0296	0.5646 ± 0.0084	0.9568 ± 0.0086
XBone-Net (letterbox)	0.5954 ± 0.0116	0.6028 ± 0.0488	0.5781 ± 0.0279	0.9581 ± 0.0064
XBone-Net (direct resize)	0.5914 ± 0.0587	0.5783 ± 0.0485	0.5547 ± 0.0118	0.9500 ± 0.0142

Bảng 4.11: Kết quả đánh giá thành phần tiền xử lý ảnh trên CTCH

Letterbox đạt trung bình cao nhất về Acc, Macro-F1 và Macro AUROC, còn sparse-focal đạt Balanced Acc cao nhất. Chênh lệch giữa letterbox và sparse-focal nhỏ so với độ lệch chuẩn ở Macro-F1 và Balanced Acc. Vì vậy, kết quả hiện tại chưa cho thấy một phương án dẫn đầu ổn định trên mọi độ đo. Direct resize có Macro-F1, Balanced Acc và Macro AUROC thấp nhất trong ba biến thể, nhưng độ biến thiên Acc của biến thể này cũng lớn hơn đáng kể. Các kết quả này chưa hỗ trợ kết luận rằng sparse-focal là lựa chọn tốt nhất trên toàn bộ tiêu chí; lợi ích của phương pháp này cần được cân nhắc cùng chi phí tính toán.

4.5.4 OOD hậu xử lý

Bảng 4.12 tổng hợp các phương pháp chính trong bốn kịch bản OOD trên mô hình XBone-Net đã huấn luyện. Domain OOD được báo cáo riêng cho FracAtlas và BTXRD; bảng chỉ đưa Mahalanobis và kNN trên biểu diễn fused ảnh–bệnh sử vào hai kịch bản này theo giao thức đánh giá chính.

Kịch bản	Phương pháp	AUROC-OOD $\uparrow$	FPR@95% $\downarrow$
Semantic OOD	Mahalanobis	0.6070 $\pm$ 0.0123	0.8939 $\pm$ 0.0572
	kNN	0.6046 $\pm$ 0.0199	0.9015 $\pm$ 0.0262
	MSP	0.5672 $\pm$ 0.0040	0.9242 $\pm$ 0.0131
	Entropy	0.5719 $\pm$ 0.0072	0.9394 $\pm$ 0.0347
	Energy	0.5962 $\pm$ 0.0232	0.9242 $\pm$ 0.0131
	Max-logit	0.5968 $\pm$ 0.0235	0.9242 $\pm$ 0.0131
Domain OOD–FracAtlas	Mahalanobis	0.8906 $\pm$ 0.0236	0.4633 $\pm$ 0.0840
	kNN	0.8353 $\pm$ 0.0173	0.6253 $\pm$ 0.0640
Cross-dataset OOD–BTXRD	Mahalanobis	0.8429 $\pm$ 0.0208	0.6533 $\pm$ 0.0335
	kNN	0.7843 $\pm$ 0.0140	0.7831 $\pm$ 0.0104
Bệnh sử không tương hợp khác lớp	Mahalanobis	0.7106 $\pm$ 0.0091	0.8032 $\pm$ 0.0238
	kNN	0.7412 $\pm$ 0.0119	0.7519 $\pm$ 0.0312
	MSP	0.6350 $\pm$ 0.0059	0.8974 $\pm$ 0.0195
	Entropy	0.6575 $\pm$ 0.0129	0.8640 $\pm$ 0.0220
	Energy	0.7293 $\pm$ 0.0101	0.8191 $\pm$ 0.0113
	Max-logit	0.7253 $\pm$ 0.0122	0.8231 $\pm$ 0.0242

Bảng 4.12: Kết quả OOD hậu xử lý của XBone-Net trên CTCH; chữ đậm biểu thị kết quả tốt nhất trong từng kịch bản chính

Mahalanobis có kết quả cao nhất trong semantic OOD, nhưng AUROC-OOD chỉ đạt 0.6070 và FPR@95% vẫn ở mức 0.8939. Với FracAtlas, Mahalanobis đạt AUROC-OOD 0.8906 ± 0.0236 và FPR@95% 0.4633 ± 0.0840 , tốt hơn kNN trong hai phương pháp chính. Trên BTXRD, Mahalanobis đạt AUROC-OOD 0.8429 ± 0.0208 và FPR@95% 0.6533 ± 0.0335 ; kNN đạt

lần lượt 0.7843 ± 0.0140 và 0.7831 ± 0.0104 . Các kết quả này cho thấy biểu diễn fused chứa tín hiệu hữu ích để nhận biết thay đổi đồng thời trong ảnh và bệnh sử. Tuy nhiên, do BTXRD chứa lớp bình thường giao với CTCH, các lớp u xương ngoài không gian nhãn và bệnh sử tổng hợp theo một lược đồ riêng, mức phân tách cao hơn không thể được quy hoàn toàn cho khả năng phát hiện dịch chuyển miền ảnh. Trong trường hợp bệnh sử không tương hợp khác lớp, kNN đạt kết quả tốt nhất với AUROC-OOD 0.7412 và FPR@95% 0.7519. Đối chứng ghép bệnh sử cùng lớp khó phân biệt hơn; kNN chỉ đạt AUROC-OOD 0.5580 ± 0.0111 và FPR@95% 0.9292 ± 0.0121 .

Nhìn chung, các điểm hậu xử lý có tín hiệu xếp hạng nhất định đối với domain OOD và bệnh sử không tương hợp khác lớp, nhưng chưa tạo được điểm vận hành có tỷ lệ chấp nhận nhầm thấp. Do đó, kết quả hiện tại chưa đủ để xem các detector này như một cơ chế từ chối đáng tin cậy trong triển khai; chúng phù hợp hơn với vai trò phân tích ban đầu và cần được đánh giá thêm trên tập OOD đa dạng hơn.

4.5.5 Giải thích và biểu diễn

Các kết quả định lượng của XBone-Net trên 44 mẫu ở mỗi lần chạy được tóm tắt trong Bảng 4.13. Giá trị độ giảm dương cho biết đầu ra của lớp mục tiêu giảm khi nhánh tương ứng bị loại bỏ.

Kết quả của XBone-Net	Trung bình $\pm$ độ lệch chuẩn
Độ giảm logit khi bỏ nhánh image-from-text	4.2750 ± 0.1492
Độ giảm logit khi bỏ nhánh text-from-image	1.8471 ± 0.0877
Độ giảm xác suất khi bỏ nhánh image-from-text	0.3670 ± 0.0833
Độ giảm xác suất khi bỏ nhánh text-from-image	0.2082 ± 0.0180
Integrated Gradients completeness error	0.000092 ± 0.000012
Integrated Gradients relative completeness error	0.000669 ± 0.000055
Lợi thế deletion logit-AUC của token ảnh so với thứ tự ngẫu nhiên	0.0382 ± 0.0062
Lợi thế deletion logit-AUC của token bệnh sử so với thứ tự ngẫu nhiên	0.0116 ± 0.0042
Tương quan Spearman dưới nhiễu nhỏ	0.8906 ± 0.0203
Tương quan Spearman sau khi ngẫu nhiên hóa classifier	0.3741 ± 0.2199
Tương quan Spearman giữa Integrated Gradients và gradient	0.0053 ± 0.0257

Bảng 4.13: Kết quả phân bổ mức đóng góp của XBone-Net trên CTCH

Hai nhánh cross-attention đều ảnh hưởng đến đầu ra; việc loại bỏ nhánh image-from-text tạo độ giảm logit và xác suất trung bình lớn hơn. Integrated Gradients có sai số completeness nhỏ và thứ hạng mức đóng góp tương đối ổn định dưới nhiễu. Tuy nhiên, lợi thế của thứ tự token được

xếp hạng so với thứ tự ngẫu nhiên còn nhỏ, tương quan giữa Integrated Gradients và gradient gần 0, và tương quan sau khi ngẫu nhiên hóa đầu phân loại vẫn là 0.3741 ± 0.2199 . Các kết quả này chỉ hỗ trợ một kết luận hạn chế về tính ổn định số học; chưa đủ để khẳng định mức đóng góp có độ trung thực hoặc tính đặc hiệu mô hình cao.

Không gian biểu diễn	Silhouette $\uparrow$	Davies–Bouldin $\downarrow$	NMI $\uparrow$	Tâm lớp Balanced Acc $\uparrow$
Dung hợp (fused)	-0.0301 ± 0.0068	2.6078 ± 0.0514	0.5371 ± 0.0041	0.6049 ± 0.0296
Ảnh toàn cục	-0.0977 ± 0.0070	4.1172 ± 0.0685	0.4617 ± 0.0147	0.5057 ± 0.0165
Tóm tắt ảnh cục bộ	-0.1444 ± 0.0059	4.5634 ± 0.2262	0.3886 ± 0.0117	0.4264 ± 0.0139
Văn bản toàn cục	-0.0978 ± 0.0143	3.5501 ± 0.0443	0.4952 ± 0.0018	0.5631 ± 0.0115
Image-from-text	-0.1006 ± 0.0069	3.7604 ± 0.0783	0.4703 ± 0.0067	0.5228 ± 0.0294
Text-from-image	-0.0981 ± 0.0173	3.4334 ± 0.0358	0.4963 ± 0.0080	0.5729 ± 0.0171

Bảng 4.14: Kết quả hình học biểu diễn của XBone-Net trên CTCH; chữ đậm biểu thị giá trị tốt nhất theo từng cột

Không gian dung hợp đạt giá trị tốt nhất trong sáu không gian ở bốn chỉ báo trong Bảng 4.14. Không gian này cũng đạt ARI 0.1842 ± 0.0177 và kNN Balanced Acc 0.5586 ± 0.0260 , cao nhất trong các không gian được khảo sát. Dù vậy, Silhouette vẫn âm, cho thấy các lớp còn chồng lấn trong không gian nhúng. Vì thế, kết quả chỉ cho thấy cấu trúc lớp của biểu diễn dung hợp tốt hơn tương đối so với các biểu diễn thành phần; chưa thể diễn giải thành sự phân tách cụm rõ ràng hoặc khả năng định vị tổn thương.

Chương 5

Kết luận và hướng phát triển

5.1 Kết luận

Khóa luận đã nghiên cứu và đề xuất một hệ thống phân loại ảnh X-quang xương đa phương thức kết hợp khả năng phát hiện dữ liệu ngoài phân phối nhằm hỗ trợ chẩn đoán các bệnh lý cơ xương khớp. Hệ thống khai thác đồng thời hai nguồn thông tin gồm ảnh X-quang và thông tin lâm sàng, từ đó tận dụng được tính bổ sung giữa hai phương thức dữ liệu để nâng cao hiệu quả phân loại.

Trên cơ sở mô hình nền BioMedCLIP, nghiên cứu áp dụng kỹ thuật tinh chỉnh tham số hiệu quả LoRA để thích nghi với miền dữ liệu X-quang xương mà không làm thay đổi toàn bộ trọng số của mô hình. Đặc trưng hình ảnh và văn bản được kết hợp thông qua cơ chế chú ý hai chiều, sau đó được huấn luyện bằng sự kết hợp giữa hàm mất mát Cross-Entropy và Prototypical Loss. Trong đó, Cross-Entropy đảm nhiệm nhiệm vụ tối ưu phân loại, còn Prototypical Loss giúp xây dựng không gian đặc trưng có tính phân biệt cao, tạo tiền đề cho giai đoạn phát hiện dữ liệu ngoài phân phối.

Đối với bài toán phát hiện dữ liệu ngoài phân phối, luận văn lựa chọn phương pháp Mahalanobis Distance theo cơ chế hậu xử lý (post-hoc), với không gian đặc trưng đã được học dựa vào mạng nguyên mẫu. Cách tiếp

cận này tận dụng trực tiếp không gian đặc trưng đã được học trong quá trình huấn luyện để đánh giá mức độ bất thường của mẫu kiểm thử mà không cần thay đổi kiến trúc hoặc huấn luyện lại mô hình. Điều này giúp nâng cao độ tin cậy của hệ thống khi triển khai trong các tình huống lâm sàng thực tế, nơi có thể xuất hiện các bệnh lý hoặc trường hợp chưa từng xuất hiện trong dữ liệu huấn luyện.

Các thực nghiệm được thực hiện trên bộ dữ liệu BTXRD kết hợp với bộ dữ liệu nội bộ CTCH đã cho thấy phương pháp đề xuất đạt hiệu quả tốt trong nhiệm vụ phân loại, đồng thời xây dựng được không gian đặc trưng phù hợp để hỗ trợ phát hiện dữ liệu ngoài phân phối. Kết quả cũng cho thấy việc kết hợp thông tin lâm sàng với ảnh X-quang giúp cải thiện khả năng nhận diện bệnh lý so với việc chỉ sử dụng một nguồn dữ liệu.

Nhìn chung, luận văn đã hoàn thành các mục tiêu nghiên cứu đã đề ra, bao gồm xây dựng mô hình phân loại đa phương thức dựa trên BioMed-CLIP, tối ưu biểu diễn đặc trưng bằng Prototypical Loss và tích hợp cơ chế phát hiện dữ liệu ngoài phân phối dựa trên khoảng cách Mahalanobis. Các kết quả đạt được là cơ sở cho việc phát triển các hệ thống hỗ trợ chẩn đoán có độ tin cậy cao hơn trong lĩnh vực chẩn đoán hình ảnh y khoa.

5.2 Hướng phát triển

Mặc dù đạt được những kết quả khả quan, phương pháp đề xuất vẫn còn một số hạn chế và có thể được mở rộng trong các nghiên cứu tiếp theo.

Thứ nhất, phương pháp phát hiện dữ liệu ngoài phân phối hiện được xây dựng theo hướng hậu xử lý bằng khoảng cách Mahalanobis. Các nghiên cứu tiếp theo có thể khảo sát những phương pháp OOD hiện đại hơn hoặc tích hợp trực tiếp mục tiêu phát hiện OOD vào quá trình huấn luyện để nâng cao khả năng phát hiện các trường hợp Near-OOD.

Thứ hai, phạm vi thực nghiệm của luận văn mới được đánh giá trên bộ dữ liệu BTXRD và bộ dữ liệu CTCH. Trong tương lai, cần mở rộng thực nghiệm trên nhiều bộ dữ liệu X-quang xương có quy mô lớn hơn cũng như đánh giá khả năng tổng quát hóa giữa các bệnh viện, thiết bị chụp và điều kiện thu nhận ảnh khác nhau.

Cuối cùng, hệ thống hiện tập trung vào hai nhiệm vụ chính là phân loại và phát hiện dữ liệu ngoài phân phối. Trong tương lai, có thể tích hợp thêm các phương pháp giải thích mô hình (Explainable AI) hoặc các mô hình ngôn ngữ lớn y khoa nhằm hỗ trợ sinh báo cáo chẩn đoán, giải thích kết quả dự đoán và tăng cường khả năng tương tác với bác sĩ trong quá trình hỗ trợ ra quyết định lâm sàng.

Tài liệu tham khảo

Tiếng Anh

- [1] Samira Abnar and Willem Zuidema. “Quantifying Attention Flow in Transformers”. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2020, pp. 4190–4197. DOI: 10.18653/v1/2020.acl-main.385. URL: <https://aclanthology.org/2020.acl-main.385/>.
- [2] Jean-Baptiste Alayrac et al. “Flamingo: a Visual Language Model for Few-Shot Learning”. In: *Advances in Neural Information Processing Systems*. Vol. 35. 2022, pp. 23716–23736. URL: https://papers.nips.cc/paper_files/paper/2022/hash/960a172bc7fbf0177ccccbb411a7c Abstract-Conference.html.
- [3] Shruthi Bannur et al. “Learning to exploit temporal structure for biomedical vision-language processing”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2023, pp. 15016–15027.
- [4] Lynn S. Bickley, Peter G. Szilagyi, and Richard M. Hoffman. *Bates’ Guide to Physical Examination and History Taking*. 13th. Lippincott Williams & Wilkins, 2020.
- [5] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing”. In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5.

- [7] Yin Cui et al. “Class-Balanced Loss Based on Effective Number of Samples”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, pp. 9268–9277. URL: https://openaccess.thecvf.com/content_CVPR_2019/html/Cui_Class-Balanced_Loss_Based_on_Effective_Number_of_Samples_CVPR_2019_paper.html.
- [8] Yin Dai and Yifan Gao. “TransMed: Transformers Advance Multi-modal Medical Image Classification”. In: *CoRR* abs/2103.05940 (2021). arXiv: 2103.05940. URL: <https://arxiv.org/abs/2103.05940>.
- [9] Ye Du, Nanxi Yu, and Shujun Wang. “Medical Knowledge Intervention Prompt Tuning for Medical Image Classification”. In: *IEEE Transactions on Medical Imaging* 44.12 (2025), pp. 4945–4959. DOI: 10.1109/TMI.2025.3584841.
- [10] Xiao Fang et al. “Aligning Medical Images with General Knowledge from Large Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15010. Springer Nature Switzerland, 2024.
- [11] Kaiming He et al. “Deep Residual Learning for Image Recognition”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016.
- [12] Dan Hendrycks and Kevin Gimpel. “A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks”. In: *International Conference on Learning Representations*. 2017. URL: <https://arxiv.org/abs/1610.02136>.
- [13] Dan Hendrycks et al. “Scaling Out-of-Distribution Detection for Real-World Settings”. In: *Proceedings of the 39th International Conference on Machine Learning*. Vol. 162. Proceedings of Machine Learning Research. PMLR, 2022, pp. 8759–8773. URL: <https://proceedings.mlr.press/v162/hendrycks22a.html>.
- [14] Edward J. Hu et al. “LoRA: Low-Rank Adaptation of Large Language Models”. In: *International Conference on Learning Representations*. 2022. URL: <https://openreview.net/forum?id=nZeVKeeFYf9>.

- [15] Gao Huang et al. “Densely Connected Convolutional Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017.
- [16] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [17] Yijin Huang et al. “Fine-grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-resolution Medical Image Classification”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15012. Springer Nature Switzerland, 2024, pp. 120–130. DOI: 10.1007/978-3-031-72390-2_12.
- [18] Andrew Jaegle et al. “Perceiver: General Perception with Iterative Attention”. In: *Proceedings of the 38th International Conference on Machine Learning*. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 4651–4664. URL: <https://proceedings.mlr.press/v139/jaegle21a.html>.
- [19] Sarthak Jain and Byron C. Wallace. “Attention is not Explanation”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, 2019, pp. 3543–3556. DOI: 10.18653/v1/N19-1357. URL: <https://aclanthology.org/N19-1357/>.
- [20] Taha Koleilat et al. “BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models”. In: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*. 2025, pp. 14766–14776.
- [21] Zhengfeng Lai et al. “CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts”. In: *Proceedings of the IEEE/CVF International*

- Conference on Computer Vision (ICCV) Workshops*. 2023, pp. 2374–2380.
- [22] Olivier Ledoit and Michael Wolf. “A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices”. In: *Journal of Multivariate Analysis* 88.2 (2004), pp. 365–411. DOI: 10.1016/S0047-259X(03)00096-4.
 - [23] Kimin Lee et al. “A Simple Unified Framework for Detecting Out-of-Distribution Samples and Adversarial Attacks”. In: *Advances in Neural Information Processing Systems*. Vol. 31. 2018, pp. 7167–7177. URL: <https://proceedings.neurips.cc/paper/2018/hash/abdeb6f575ac5c6676b747bca8d09cc2-Abstract.html>.
 - [24] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: <https://arxiv.org/abs/2306.00890>.
 - [25] Zihan Li et al. “LViT: Language Meets Vision Transformer in Medical Image Segmentation”. In: *IEEE Transactions on Medical Imaging* 43.1 (2024), pp. 96–107. DOI: 10.1109/TMI.2023.3291719.
 - [26] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: <https://arxiv.org/abs/2401.12215>.
 - [27] Mingyuan Liu et al. “Sparsity- and Hybridity-Inspired Visual Parameter-Efficient Fine-Tuning for Medical Diagnosis”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15005. Springer Nature Switzerland, 2024.
 - [28] Weitang Liu et al. “Energy-based Out-of-distribution Detection”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 21464–21475. URL: <https://proceedings.neurips.cc/paper/2020/hash/f5496252609c43eb8a3d147ab9b9c006-Abstract.html>.
 - [29] Xueyan Mei et al. “Artificial intelligence-enabled rapid diagnosis of patients with COVID-19”. In: *Nature Medicine* 26 (Aug. 2020),

- 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: <https://www.nature.com/articles/s41591-020-0931-3>.
- [30] Yifei Ming et al. “Delving into Out-of-Distribution Detection with Vision-Language Representations”. In: *Advances in Neural Information Processing Systems*. Vol. 35. 2022, pp. 35087–35102. URL: https://papers.nips.cc/paper_files/paper/2022/hash/e43a33994a28f746dcfc Abstract-Conference.html.
 - [31] Jong Hak Moon et al. “Multi-Modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training”. In: *IEEE Journal of Biomedical and Health Informatics* 26.12 (2022), pp. 6070–6080. DOI: 10.1109/JBHI.2022.3207502.
 - [32] Michael Moor et al. *Med-Flamingo: a Multimodal Medical Few-shot Learner*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.15189. URL: <https://arxiv.org/abs/2307.15189>.
 - [33] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.
 - [34] Umair Rahman et al. “Can language-guided unsupervised adaptation improve medical image classification using unpaired images and texts?” In: *2025 IEEE 22nd International Symposium on Biomedical Imaging (ISBI)*. IEEE. 2025, pp. 1–5.
 - [35] Bryan C Russell et al. “LabelMe: a database and web-based tool for image annotation”. In: *International journal of computer vision* 77.1-3 (2008), pp. 157–173.
 - [36] Ramprasaath R. Selvaraju et al. “Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization”. In: *Proceedings of the IEEE International Conference on Computer Vision*. 2017, pp. 618–626. URL: https://openaccess.thecvf.com/content_iccv_2017/html/Selvaraju_Grad-CAM_Visual_Explanations_ICCV_2017_paper.html.

- [37] Jake Snell, Kevin Swersky, and Richard S. Zemel. “Prototypical Networks for Few-shot Learning”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017, pp. 4077–4087. URL: https://papers.nips.cc/paper_files/paper/2017/hash/cb8da6767461f2812ae429Abstract.html.
- [38] Yiyu Sun et al. “Out-of-Distribution Detection with Deep Nearest Neighbors”. In: *Proceedings of the 39th International Conference on Machine Learning*. Vol. 162. Proceedings of Machine Learning Research. PMLR, 2022, pp. 20827–20840. URL: <https://proceedings.mlr.press/v162/sun22d.html>.
- [39] Nikhil Kumar Tomar et al. “TGANet: Text-Guided Attention for Improved Polyp Segmentation”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2022*. Cham, Switzerland: Springer Nature Switzerland, 2022, pp. 151–160. ISBN: 978-3-031-16437-8. DOI: 10.1007/978-3-031-16437-8_15.
- [40] Tao Tu et al. *Towards Generalist Biomedical AI*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.14334. URL: <https://arxiv.org/abs/2307.14334>.
- [41] Xiaosong Wang et al. “TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018.
- [42] Yan Wang et al. *SimpleShot: Revisiting Nearest-Neighbor Classification for Few-Shot Learning*. 2019. arXiv: 1911.04623 [cs.CV]. URL: <https://arxiv.org/abs/1911.04623>.
- [43] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, Dec. 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: <https://aclanthology.org/2022.emnlp-main.256/>.

- [44] W.B. Saunders. *Dorland's Illustrated Medical Dictionary*. 32nd. Elsevier Health Sciences, 2011.
- [45] Chaoyi Wu et al. “MedKLIP: Medical Knowledge Enhanced Language-Image Pre-Training for X-ray Diagnosis”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023, pp. 21372–21383.
- [46] Bin Yan and Mingtao Pei. “Clinical-BERT: Vision-Language Pre-training for Radiograph Diagnosis and Reports Generation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 36. 3. 2022, pp. 2982–2990. DOI: 10.1609/aaai.v36i3.20204. URL: <https://doi.org/10.1609/aaai.v36i3.20204>.
- [47] Shunhan Yao et al. “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors”. In: *Scientific Data* 12.1 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y. URL: <https://doi.org/10.1038/s41597-024-04311-y>.
- [48] Chenlu Zhan et al. “UniDCP: Unifying Multiple Medical Vision-Language Tasks via Dynamic Cross-Modal Learnable Prompts”. In: *IEEE Transactions on Multimedia* 26 (2024), pp. 9736–9748. DOI: 10.1109/TMM.2024.3397191.
- [49] Jiajin Zhang et al. “Disease-informed Adaptation of Vision-Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15011. Springer Nature Switzerland, 2024.
- [50] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoA2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoA2400640>.
- [51] Xiaoman Zhang et al. “Knowledge-enhanced visual-language pre-training on chest radiology images”. In: *Nature Communications* 14 (July 2023). DOI: 10.1038/s41467-023-40260-7. URL: <https://arxiv.org/pdf/2302.14042.pdf>.

- [52] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 7th Machine Learning for Healthcare Conference*. Ed. by Zachary Lipton et al. Vol. 182. Proceedings of Machine Learning Research. PMLR, 2022, pp. 2–25. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
- [53] Yunkun Zhang et al. “Text-Guided Foundation Model Adaptation for Pathological Image Classification”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*. Ed. by Hayit Greenspan et al. Cham: Springer Nature Switzerland, 2023, pp. 272–282. ISBN: 978-3-031-43904-9.
- [54] Fudan Zheng et al. “Exploring low-resource medical image classification with weakly supervised prompt learning”. In: *Pattern Recognition* 149 (2024), p. 110250. ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2024.110250>. URL: <https://www.sciencedirect.com/science/article/pii/S0031320324000013>.
- [55] Kaipeng Zheng, Weiran Huang, and Lichao Sun. “TransMed: Large Language Models Enhance Vision Transformer for Biomedical Image Classification”. In: *arXiv preprint arXiv:2312.07125* (2023).
- [56] Hong-Yu Zhou et al. “A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics”. In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).
- [57] Hong-Yu Zhou et al. “Advancing Radiograph Representation Learning with Masked Record Modeling”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=w-x7U26GM7j>.
- [58] Juexiao Zhou et al. “Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4”. In: *Nature Communications* 15 (July 2024). DOI: 10.1038/s41467-024-50043-3. URL: <https://doi.org/10.1038/s41467-024-50043-3>.