

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - Nguyễn Gia
Kiệt

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

Tp. Hồ Chí Minh, tháng 07/2026

**TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN**

Nguyễn Văn Lê Bá Thành - 22127390

Nguyễn Gia Kiệt - 22127221

**PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC**

**KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO**

GIÁO VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

Tp. Hồ Chí Minh, tháng 07/2026

Lời cam đoan

Nhóm xin cam đoan đây là công trình nghiên cứu của riêng nhóm. Dữ liệu và kết quả nghiên cứu trong luận văn này là trung thực và không trùng lặp với bất kỳ chủ đề nào khác. Nhóm cam đoan toàn bộ nội dung luận văn này không đạo văn hoặc sao chép từ các công trình nghiên cứu khác. Ngoài ra, trong quá trình nghiên cứu và viết luận văn, nhóm tuân thủ nghiêm ngặt các quy định về bảo mật do các tập dữ liệu nhóm sử dụng trong nghiên cứu của mình cung cấp. Hơn nữa, nhóm luôn tuân thủ mọi nguyên tắc đạo đức trong suốt quá trình nghiên cứu. Nhóm đảm bảo rằng tất cả các nguồn và tài liệu tham khảo đều được trích dẫn đúng cách và nhóm duy trì tính chính trực học thuật trong mọi khía cạnh công việc của mình.

Lời cảm ơn

Nhóm xin chân thành cảm ơn PGS.TS Lý Quốc Ngọc và ThS. Đỗ Thị Thanh Hà đã dành rất nhiều thời gian, tâm huyết để định hướng, tận tình hướng dẫn và đưa ra những lời khuyên quý báu cho nhóm trong suốt quá trình nghiên cứu và thực hiện khóa luận tốt nghiệp với đề tài "Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức".

Xin trân trọng gửi lời cảm ơn sâu sắc đến Ban Chủ nhiệm cùng toàn thể quý thầy cô Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG-HCM. Những kiến thức nền tảng vững chắc mà các thầy cô đã truyền đạt trong bốn năm học vừa qua và môi trường thí nghiệm tuyệt vời chính là hành trang quan trọng nhất giúp nhóm có thể hoàn thành tốt hướng nghiên cứu này.

Nhóm cũng xin gửi lời cảm ơn đến các y bác sĩ tại Bệnh viện Chấn thương Chỉnh hình TP.HCM, thầy Đỗ Phúc Thịnh và thầy Võ Thế Hào đã hỗ trợ chia sẻ nguồn dữ liệu ảnh X-quang cũng như tư vấn các kiến thức chuyên môn về y khoa, giúp mô hình nghiên cứu bám sát với quy trình chẩn đoán thực tế.

Mặc dù đã có nhiều cố gắng trong quá trình thực hiện, nhưng do hạn chế về mặt thời gian và kinh nghiệm nghiên cứu, khóa luận chắc chắn không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô và hội đồng đánh giá để đề tài được hoàn thiện hơn.

Xin chân thành cảm ơn!



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO HỌC SÂU ĐA PHƯƠNG THỨC

*(Developing a bone X-ray image classification
system based on multimodal deep learning)*

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm Sinh viên thực hiện:

1. Nguyễn Văn Lê Bá Thành (MSSV: 22127390)
2. Nguyễn Gia Kiệt (MSSV: 22127221)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 02/2026 đến 08/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn đầu. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, các nghiên cứu hiện nay đã ứng dụng các mô hình học sâu vào để giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ để đưa vào ứng dụng thực tế. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để bổ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác. Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống.

Khác với các mô hình đơn phương thức chỉ xử lý trên một phương thức như ảnh hay văn bản duy nhất, các mô hình đa phương thức có thể sử dụng nhiều phương thức và tìm ra sự tương quan giữa các phương thức nhằm tạo nên biểu diễn có ý nghĩa hơn từ đó nâng cao hiệu năng của hệ thống. Với thực tế lâm sàng hiện nay, các mô hình nghiên cứu tập trung

vào kết hợp ngôn ngữ và hình ảnh hay còn được gọi là mô hình ngôn ngữ trực quan đang là các mô hình đang nhận được nhiều sự chú ý.

2.2 Định nghĩa các khái niệm

Thông tin lâm sàng

Thông tin lâm sàng là những dữ liệu thu thập trực tiếp qua quá trình bác sĩ thăm khám người bệnh, bao gồm việc khai thác bệnh sử và khám thực thể (nhìn, sờ, gõ, nghe) [28]. Dữ liệu này mang tính chất định hướng ban đầu, giúp bác sĩ khoanh vùng tổn thương và đưa ra các quyết định chỉ định thăm khám chuyên sâu tiếp theo [2].

Thông tin cận lâm sàng

Thông tin cận lâm sàng là các dữ liệu khách quan thu được từ việc áp dụng các trang thiết bị và kỹ thuật y khoa hiện đại (như hình ảnh X-quang, cắt lớp, hay xét nghiệm sinh hóa) [28]. Nếu lâm sàng dùng để định hướng, thì cận lâm sàng cung cấp bằng chứng xác thực từ bên trong cơ thể để chẩn đoán chính xác bệnh lý.

2.3 Phát biểu bài toán

Đầu vào (Input)

Hệ thống nhận vào các nguồn dữ liệu sau:

- Thông tin lâm sàng bao gồm báo cáo cận lâm sàng, khám xét toàn thân, lý do vào viện của bệnh nhân.
- Ảnh X-quang xương của bệnh nhân tương ứng.
- Tập nhãn được định nghĩa trước.


Đầu ra (Output)

Hệ thống sẽ sinh ra các nhãn sau:

- Tỷ lệ mà ảnh và thông tin lâm sàng tương ứng thuộc vào các lớp được định nghĩa trước.
- Ảnh trực quan hóa giải thích cho kết quả.

Kiến trúc tổng quan

Với bài toán này, kiến trúc tổng quan của một mô hình học sâu đa phương thức được sử dụng bao gồm bốn thành phần chính: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại như được thể hiện ở Hình 1.



Hình 1: Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức

Trong đó, bộ mã hóa ảnh có chức năng rút trích đặc trưng từ ảnh đầu vào, bộ mã hóa văn bản có chức năng rút trích đặc trưng từ văn bản đầu vào, bộ dung hợp dữ liệu có chức năng dung hợp hay căn chỉnh các đặc trưng được rút trích từ hai phương thức dữ liệu trên để tạo ra một biểu diễn có ý nghĩa và có đầy đủ tính chất của phương thức đầu vào, đây cũng là mô-đun quan trọng nhất đối với một mô hình học sâu đa phương thức, cuối cùng là bộ phân loại, nhận biểu diễn đặc trưng chung của các phương thức đầu vào để phân loại và đưa ra kết quả cuối cùng.

2.4 Mục tiêu đề tài

Trong bối cảnh già hóa dân số và các tác nhân gây bệnh từ ô nhiễm và lối sống thiếu lành mạnh trong đời sống hiện đại, các bệnh lý về xương và chấn thương có thể ảnh hưởng trực tiếp đến đời sống và tính mạng dẫn đến việc chẩn đoán và tiên lượng để đưa ra hướng điều trị phù hợp đang trở thành gánh nặng cho các y bác sĩ, các hệ thống học sâu đa phương

thức tuy đã phát triển nhưng lại thiếu khả năng giải thích. Đề tài hướng đến phát triển một hệ thống phân loại ảnh X-quang có khả năng:

- Đạt được độ chính xác cao trên các bộ dữ liệu nội bộ và quốc tế.
- Có khả năng giải thích được kết quả.
- Tích hợp kết quả để trợ giúp y bác sĩ trong quá trình chẩn đoán.

2.5 Phạm vi của đề tài

Nội dung nghiên cứu của đề tài tập trung vào việc khảo sát các mô hình nền tảng và thiết kế, huấn luyện, tinh chỉnh, đánh giá kiến trúc được đề xuất trên ảnh X-quang xương và các bộ dữ liệu quốc tế để so sánh, đánh giá với các kiến trúc trước.

Đối tượng nghiên cứu xoay quanh các thành phần bên trong một mạng học sâu đa phương thức bao gồm: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại, tập trung vào các phương pháp dung hợp dữ liệu hình ảnh và văn bản cùng với các phương pháp tinh chỉnh tham số cho các bộ mã hóa đã được huấn luyện trước nhằm tận dụng lại các tri thức đã có và nâng cao hiệu năng trên các tác vụ đích.

Đề tài chủ yếu sử dụng các bộ dữ liệu cặp ảnh - văn bản, không có trường hợp thiếu đã được công bố và bộ dữ liệu nội bộ được thu thập và cung cấp bởi giảng viên có hợp tác với bệnh viện ở khu vực Thành phố Hồ Chí Minh, một số thông tin cơ bản về các bộ dữ liệu được thể hiện ở Bảng 1. Nhóm sử dụng các bộ dữ liệu này nhằm đánh giá hiệu năng của kiến trúc đề xuất thông qua các độ đo phổ biến và tiến hành so sánh với các phương pháp trước đó nhằm chứng minh sự hiệu quả của phương pháp đề xuất.

2.6 Cách tiếp cận dự kiến

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ cung cấp tổng quan tình hình nghiên cứu

Bộ dữ liệu	Nguồn	Loại dữ liệu	Số lượng mẫu	Số lượng lớp
RSNA Pneumonia (2018)	Radiological Society of North America	Ảnh X-quang ngực metadata/tags	30,000	3
CheXpert (2019)	Stanford ML Group - Stanford Hospital	Ảnh X-quang ngực Báo cáo đọc ảnh	224,316	14
MIMIC-CXR v2 (2019)	Beth Israel Deaconess Medical Center	Ảnh X-quang ngực Báo cáo đọc ảnh	227,835	14
SARCOMA-CTCH (2025)	Bệnh viện Chấn Thương Chỉnh Hình - TPHCM	Ảnh X-quang xương Báo cáo đọc ảnh Báo cáo lâm sàng	Đang cập nhật	Đang cập nhật

Bảng 1: Tổng hợp các bộ dữ liệu dự kiến được sử dụng để thí nghiệm

từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

Các mô hình xây dựng từ đầu là các mô hình đơn giản, khởi điểm trong bài toán học sâu đa phương thức, thiết kế và huấn luyện một hệ thống mới từ đầu, điểm chung của các phương pháp này là chúng tập trung vào việc thiết kế các cơ chế để "trộn" (fusion) đặc trưng từ các bộ mã hóa (encoder) chuyên biệt ở các cấp độ khác nhau để tối ưu hóa hiệu suất cho các tác vụ cụ thể, sử dụng những bộ mã hóa hình ảnh đơn giản như CNN.

Khởi điểm vào 2020, X. Mei [18] và đồng nghiệp đã đề xuất lấy đặc trưng được tạo ra từ các lớp cuối của mô hình CNN (véc-tơ 512 chiều) và các đặc trưng từ dữ liệu lâm sàng rồi nối lại. Véc-tơ kết hợp này được đưa vào một mạng MLP cuối cùng để đưa ra dự đoán.

Clinical-BERT [30] và TGANet [24] tìm cách học biểu diễn đa phương thức bằng cách thúc đẩy mô hình hiểu và liên kết (align) các đặc trưng giữa các vùng trong ảnh và các từ khóa trong văn bản báo cáo thông qua các nhiệm vụ tự giám sát (self-supervised objectives), cho phép mô hình học được các biểu diễn ngữ nghĩa chung. Hay LViT [15] đề xuất một kiến trúc hybrid CNN-Transformer "Double-U", cấu trúc CNN-Transformer kết hợp mô-đun Pixel-Level Attention Module để giữ lại các đặc trưng cục bộ của ảnh giúp mô hình giữ được khả năng trích xuất đặc trưng cục bộ mạnh mẽ của CNN, đồng thời tận dụng khả năng mô hình hóa ngữ cảnh toàn cục của Transformer.

Việc chỉ nối các đặc trưng có điểm yếu về sự khác biệt về giá trị hoặc sự ngữ nghĩa lớn giữa các phương thức dữ liệu, IRENE [40] đã đưa tất

cả dữ liệu gốc về dạng token chung và học biểu diễn tổng thể (holistic representation) ngay từ đầu, sử dụng một mô hình Transformer duy nhất học các biểu diễn toàn diện cho cả hai phương thức. IRENE còn sử dụng cơ chế chú ý hai chiều ở cấp độ token để nắm bắt "các kết nối cục bộ".

Nghiên cứu của Dai và cộng sự [5] đề xuất mô hình TransMed, giải quyết bài toán kết hợp đa phương thức bằng cách tích hợp CNN và Transformer. Bằng việc chuyển đổi đặc trưng ảnh từ CNN thành dạng chuỗi để Transformer xử lý, mô hình này tối ưu hóa việc nắm bắt các đặc điểm toàn cục của hình ảnh y khoa. Cách tiếp cận này mang lại hiệu quả cao hơn các kỹ thuật fusion thông thường nhờ khả năng biểu diễn dữ liệu đa phương thức một cách toàn diện và chính xác.

Những nghiên cứu này đã khai phá và chứng minh về tác động tích cực của các phương thức dữ liệu khác như văn bản đến kết quả của việc chẩn đoán hình ảnh, tuy nhiên độ chính xác của các phương thức này còn chưa quá cao bởi các bộ mã hóa và phương pháp dung hợp dữ liệu còn đơn giản.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Kiến trúc mô hình			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	X. Mei [18]	Full Fine-Tuning	Pretrain với Cross-Entropy loss	Inception-ResNet-v2	ResNet-18	Decision-level	N/a
2	Clinical-BERT [30]	Full Fine-Tuning	Cross-modal Repr. Learning	DenseNet121	Uncased BERT-base	Early fusion	N/a
3	LViT [15]	Full Fine-Tuning	Semi-supervised (Pseudo-label)	Hybrid U-shape (CNN + ViT)	BERT_12_768_12	Intermediate	N/a
4	TGANet [24]	Train from scratch	Exponential Pseudo-label Iteration	ResNet50	Không có	Intermediate	N/a
5	IRENE [40]	Train from scratch	BCE Loss & AdamW optimizer	Convolution layer	Pretrained BERT	Simultaneous	Upsampling, FEM, CBAM Attention
6	TransMed [5]	Full Fine-Tuning	Supervised (SGD, 100 epochs)	2D CNN (ResNet18 đến 152)	N/a	Attention fusion	Lớp kết nối đầy đủ (FC Layer)

Bảng 2: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tinh chỉnh của các mô hình kết hợp ngôn ngữ - ảnh

Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu (thường cố gắng dung hợp dữ liệu thô thành một khối thống nhất), Med-VLMs chú trọng vào việc đối chiếu và liên kết chặt chẽ ngữ nghĩa giữa hình ảnh và ngôn ngữ tự nhiên. Cụ thể, kiến trúc của chúng thường kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này khớp với

nhau. Lúc này, bộ phân loại không gán nhãn theo cách truyền thống mà đóng vai trò là một cơ chế đo lường mức độ tương đồng. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Để đạt được khả năng trên, các nghiên cứu tiền huấn luyện Med-VLMs hiện nay đang phát triển chủ yếu theo ba hướng: học tương phản, học có che giấu và tích hợp tri thức y khoa (chi tiết tổng hợp được trình bày tại các Bảng 3, 2.1, 5).

Thứ nhất, **học tương phản (Contrastive Learning)** là chiến lược được ứng dụng rộng rãi nhất, tiêu biểu với các mô hình như ConVIRT [36], GLoRIA [10], MedCLIP [27] và BiomedCLIP [34]. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau ở mức độ cục bộ lẫn toàn cục. Phương pháp này đem lại hiệu năng ấn tượng; ví dụ, BiomedCLIP [34] (huấn luyện trên 15 triệu cặp dữ liệu) đạt độ chính xác phân loại 83%, trong khi ConVIRT [36] đạt 90,3% trên bộ dữ liệu COVIDx. Mặc dù có ưu điểm vượt trội là khả năng học biểu diễn không cần gán nhãn thủ công, học tương phản vẫn bộc lộ hạn chế về việc tiêu tốn tài nguyên tính toán lớn và rủi ro xảy ra hiện tượng âm tính giả (đẩy xa các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý).

Thứ hai, **học có che giấu (Masked Learning)** là hướng đi tập trung vào mục tiêu tái tạo dữ liệu, với các đại diện nổi bật như MRM [41] và MedViLL [19]. Bằng cách ẩn ngẫu nhiên các vùng ảnh hoặc từ ngữ trong báo cáo y khoa, kiến trúc này buộc mô hình phải dự đoán và khôi phục phần thông tin bị khuyết. Hướng tiếp cận này thể hiện ưu thế rõ rệt trong các môi trường khan hiếm dữ liệu; điển hình là MRM [41] đạt mức 92,7% AUC chỉ với 10% dữ liệu từ tập RSNA. Tuy nhiên, rào cản chính của phương pháp này nằm ở việc phụ thuộc vào nguồn dữ liệu đã được ghép cặp sẵn từ trước, cộng với độ phức tạp tính toán cao của quá trình khôi phục điểm ảnh/token.

Thứ ba, **tích hợp tri thức y khoa (Knowledge Integration)** ra đời nhằm giải quyết những đặc thù phức tạp của ngôn ngữ lâm sàng. Các

mô hình như MedKLIP [29], BioViL [3], BioViL-T [1] và KAD [35] tận dụng đồ thị tri thức (như RadGraph) hoặc dữ liệu chuỗi thời gian để cung cấp tín hiệu giám sát chi tiết về cả loại và vị trí bệnh lý. Cách tiếp cận này giúp giải quyết triệt để sự mơ hồ của các từ vựng diễn tả tiến triển bệnh (ví dụ: "cải thiện", "xấu đi"). Về mặt hiệu năng, KAD [35] đạt 0.966 AUC trên tập PadChest ở thiết lập không mẫu (zero-shot), còn BioViL-T [1] đạt độ chính xác 67,4% trong bài toán phân loại tiến triển bệnh. Dù vậy, các phương pháp này chưa loại bỏ hoàn toàn được hiện tượng âm tính giả và rất dễ gặp sai số nếu nhãn chẩn đoán thực tế nằm ngoài cơ sở tri thức đồ thị gốc.

Dựa trên sự phân tích các ưu và nhược điểm từ những khảo sát trên, hướng tiếp cận đề xuất trong nghiên cứu này được thiết kế có chọn lọc nhằm tối ưu hóa hiệu năng và chi phí:

- **Kế thừa BiomedCLIP [34]:** Tận dụng sức mạnh của các bộ mã hóa đã được huấn luyện với chất lượng cao.
- **Không áp dụng học tương phản & học có che giấu:** Khó khắc phục rào cản về tài nguyên tính toán lớn và giảm thiểu rủi ro gặp phải hiện tượng âm tính giả.
- **Tích hợp tri thức từ UMLS (tương tự MedKLIP [29]):** Sử dụng để làm giàu thêm tri thức trong các báo cáo lâm sàng.

Mặc dù các phương pháp tiền huấn luyện Med-VLMs giúp xây dựng nền tảng tri thức đa phương thức khổng lồ, việc áp dụng trực tiếp vào lâm sàng lại vấp phải rào cản lớn về chi phí tính toán và sự khan hiếm dữ liệu y tế ghép cặp. Để giải quyết vấn đề này, các nghiên cứu thường chuyển hướng sang tinh chỉnh mô hình. Tuy nhiên, nếu tinh chỉnh toàn phần trên một tập dữ liệu nhỏ, sự chênh lệch phân phối sẽ dễ dẫn đến hiện tượng chuyển giao tiêu cực hoặc "quên thăm khốc", làm đánh mất tri thức gốc. Do đó, giới nghiên cứu đang tập trung vào các chiến lược tinh chỉnh hiệu quả tham số (PEFT) nhằm đảm bảo tính linh hoạt, tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các nghiên cứu gần đây được chia thành ba hướng tiếp cận chính:

STT	Tên phương pháp	Phân loại	Nguyên lý
1	ConVIRT (2020)	Học tương phản	Tối ưu bộ mã hoá ảnh và văn bản bằng cách kéo các cặp đặc trưng ảnh-văn bản giống nhau lại gần nhau và đẩy các cặp đặc trưng ảnh-văn bản khác nhau ra xa
2	GLoRIA (2021)	Học tương phản	Dùng hai hàm mất mát global contrastive để kéo các cặp đặc trưng ảnh-văn bản, trong khi đó hàm mất mát local contrastive học cách căn chỉnh chi tiết của các vùng trong ảnh và các từ trong câu
3	MedCLIP (2022)	Học tương phản	Đề xuất cơ chế tách cặp và trích xuất tri thức, và đề xuất hàm mất mát Semantic Matching nhằm giải quyết vấn đề false negative
4	BiomedCLIP (2023)	Học tương phản	Có cơ chế tương tự như CLIP nhưng được tiền huấn luyện với bộ dữ liệu PMC-15M
5	MRM (2023)	Học có che giấu	Ẩn ngẫu nhiên các thông tin trong văn bản và các vùng trong ảnh để cho mô hình dự đoán lại ảnh và văn bản hoàn chỉnh.
6	MedViLL (2022)	Học có che giấu	Đề xuất một kiến trúc dựa trên BERT kết hợp với một mặt nạ chú ý mới được đề xuất (BAR) cho phép ảnh tương tác tự do với văn bản trong các tác vụ hiểu, đồng thời đảm bảo tính tự hồi quy cho các token trong văn bản trong các tác vụ sinh
7	BioViL (2022)	Tích hợp kiến thức y khoa	Đề xuất một bộ mã hoá văn bản CXR-BERT được tối ưu cho ảnh X-quang, duy trì hàm mất mát MLM để giúp mô hình giữ lại được các kiến thức văn bản trong quá trình căn chỉnh với ảnh
8	BioViL-T (2023)	Tích hợp kiến thức y khoa	Sử dụng các ảnh X-quang từ trước kết hợp với ảnh hiện tại để học được các đặc trưng không gian, thời gian từ đó giải thích cho các từ vựng như "cải thiện" giúp giảm đi sự mơ hồ trong báo cáo
9	MedKLIP (2023)	Tích hợp kiến thức y khoa	Đề xuất một mô-đun trích xuất bộ ba và cơ chế mã hoá tăng cường tri thức, từ đó tạo ra biểu diễn tốt hơn cho văn bản
10	KAD (2023)	Tích hợp kiến thức y khoa	Tích hợp kiến thức y khoa vào quá trình tiền huấn luyện để giúp mô hình học các biểu diễn có ý nghĩa hơn

Bảng 3: Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Mục tiêu tiền huấn luyện	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	CL	GCL	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	CL	LCL, GCL	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	CL	GCL	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	CL	GCL	ViT-Base	PubMedBERT	Contrastive Alignment	N/a
5	MRM (2023)	MP	MIM, MLM	Kiến trúc giống ViT	WordPiece	Global Context Injection	Văn bản: Transformer; Hình ảnh: Fully Connected
6	MedViLL (2022)	HA	MLM, ITM	ResNet50	BERT	Cross-modal Self-Attention	Multi-Layer Perceptron
7	BioViL (2022)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
8	BioViL-T (2023)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
9	MedKLIP (2023)	CL	LCL	ResNet50	ClinicalBERT	Knowledge-enhanced Alignment	Contrastive head, Cross-Entropy head
10	KAD (2023)	HA	CL, Disease Diagnosis Prediction	ResNet50, ViT-Base	PubMedBERT	Contrastive Alignment	Disease Query Network

Bảng 4: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;

STT	Tên phương pháp	Bộ dữ liệu tiền huấn luyện	Hiệu năng			
			Tác vụ	Bộ dữ liệu đánh giá	Độ đo	Kết quả
1	ConVIRT (2020)	MIMIC-CXR, Private Bone image	- Phân loại ảnh - Phân loại ít mẫu	RSNA Pneumonia, CheXpert, COVIDx, MURA	AUC, Accuracy	- Phân loại ít mẫu: RSNA (1%): 88.8% AUC, (10%): 91.5% AUC; CheXpert (1%): 87.0% AUC, (10%): 88.1% AUC; MURA (1%): 81.3% AUC, (10%): 86.5% AUC - Phân loại ảnh: RSNA: 92.7% AUC, CheXpert: 88.1% AUC, MURA: 89.0% AUC; COVIDx 90.3% ACC
2	GLoRIA (2021)	CheXpert	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	CheXpert, RSNA Pneumonia	AUROC	- Phân loại không mẫu: CheXpert 5x200: 0.61 ACC, 0.67 F1; RSNA: 0.70 ACC, 0.58 F1; - Phân loại ít mẫu: CheXpert (1%): 86.6 AUC, (10%): 87.8 AUC, RSNA (1%): 86.1 AUC, (10%): 88.0 AUC - Phân loại ảnh: CheXpert: 88.1 AUC, RSNA: 88.6 AUC
3	MedCLIP (2022)	MIMIC-CXR, CheXpert	- Phân loại ảnh - Phân loại không mẫu	MIMIC-5x200, COVID, RSNA Pneumonia	Mean Accuracy	- Phân loại không mẫu: CheXpert-5x200: 0.5942 ACC; MIMIC-5x200: 0.5430 ACC; COVID: 0.8472 ACC; RSNA: 0.7682 ACC - Phân loại ảnh: CheXpert-5x200: 0.5960 ACC; MIMIC-5x200: 0.5650 ACC; COVID: 0.7890 ACC; RSNA: 0.8075 ACC
4	BiomedCLIP (2023)	PMC-15M	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PCam, LC25000 (Lung, Colon), TCGA-TIL, RSNA Pneumonia	AUC, Accuracy	- Phân loại không mẫu: PCam: 73.41% ACC; LC25000 Lung 65.23% ACC; LC25000 Colon 92.98%; RSNA 78.95%; TCGA-TIL: 67.04% - Phân loại ít mẫu: PCam (1%): 82% ACC, (10%): 83%; RSNA (1%): 77% ACC, (10%): 82% ACC - Phân loại ảnh: PCam: 83% ACC, RSNA: 83% ACC
5	MRM (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu	CheXpert, NIH ChestX-ray, RSNA Pneumonia, COVID-19 Image Data Collection	AUC, Accuracy	- Phân loại ít mẫu: CheXpert (1%): 88.5 AUC, (10%): 88.5 AUC; RSNA (1%): 91.3 AUC, (10%): 92.7 AUC; NIH ChestX-ray (1%): 79.4 AUC, (10%): 84.0 AUC - Phân loại ảnh: CheXpert: 88.7 AUC, RSNA 93.3, NIH ChestX-ray: 85.9, COVID-19: 85.8
6	MedViLL (2022)	MIMIC-CXR	- Phân loại chẩn đoán	MIMIC-CXR, Open-I	Micro-averaged AUROC, Micro-averaged F1 score	- Phân loại ảnh: MIMIC-CXR: 0.980 avg AUROC, 0.839 F1; Open-I: 0.892 avg AUROC, 0.407 F1
7	BioViL (2022)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	RSNA Pneumonia	Accuracy, F1-score, AUROC, Sensitivity Specificity.	- Phân loại không mẫu: RSNA: 0.732 ACC, 0.831 AUC; ChestX-ray14: 0.6912 AUC - Phân loại ít mẫu: RSNA (1%): 0.805 ACC, 0.881 AUC; (10%): 0.812 ACC, 0.884 AUC - Phân loại ảnh: RSNA: 0.822 ACC, 0.891 AUC
8	BioViL-T (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu - Phân loại ảnh tiền triển	MS-CXR-T, RSNA Penumonia, Chest ImaGenome	Macro-Accuracy, Accuracy, F1, AUROC.	- Phân loại Tiền triển: MS-CXR-T: 67.4% Acc - Phân loại không mẫu: RSNA: 0.805 ACC, 0.871 AUC - Phân loại ít mẫu: RSNA (1%): 0.814 ACC, 0.890 AUC
9	MedKLIP (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại không mẫu	ChestX-ray14, RSNA Pneumonia, SIIM-ACR Pneumothorax, COVIDx CXR-2, COVID Rural, Edema Severity	AUC, F1-score, Accuracy.	- Phân loại không mẫu: RSNA: 0.8694 AUC, 0.6342 F1; SIIM-ACR: 0.8924 AUC, 0.6833 F1; ChestX-ray14: 0.7676 AUC, 0.2525 F1; COVID-19: 0.7396 AUC, 0.7670 F1 - Phân loại ít mẫu: ChestX-ray14 (1%): 0.7721 AUC, (10%): 0.7894; RSNA (1%): 0.8731 AUC, (10%): 0.8799 AUC - Phân loại mẫu: ChestX-ray14: 0.8323 AUC, RSNA 0.8931
10	KAD (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PadChest, NIH ChestXray14, CheXpert, ChestX-Det	AUC, F1-Score, MCC	- Phân loại không mẫu: PadChest: 0.966 AUC; CheXpert: 0.905 AUC, 0.647 F1, 0.589 MCC - Phân loại ít mẫu: ChestXray-14 (1%): 0.78 AUC, 0.31 F1; (10%): 0.80 AUC, 0.33 F1 - Phân loại ảnh: ChestXray-14: 0.82 AUC, 0.34 F1

Bảng 5: Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

Tinh chỉnh sử dụng câu nhắc (Prompt Tuning): Hướng này chèn thêm các tham số có thể học được vào không gian đầu vào của mô hình. Các phương pháp như CITE [37], FPT [11] hay PLIP [33] khai thác đặc trưng thị giác kết hợp với tri thức lâm sàng, cho thấy hiệu quả vượt trội ngay cả khi thiếu hụt dữ liệu (ví dụ: PLIP đạt 0.896 AUC chỉ với 5% dữ liệu PanNuke). Nhằm giải quyết khó khăn khi thiết kế thủ công, MedPrompt [38] và UniDCP [32] tự động sinh câu nhắc động dựa trên ngữ cảnh ảnh để xử lý đa tác vụ. Gần đây hơn, việc tích hợp Mô hình ngôn ngữ Lớn (LLM) qua ViP [7], CILMP [6] và BiomedCoOp [12] giúp tạo sinh các câu nhắc ngữ nghĩa sâu sắc, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản, mang lại hiệu năng cao trong các kịch bản ít mẫu hoặc không mẫu.

Tinh chỉnh bộ điều hợp (Adapter Tuning): Thay vì can thiệp ở đầu vào, phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ giữa các lớp của kiến trúc gốc. Điển hình, CLIPath [13] sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu nhỏ; FTB [21] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức. Ở hướng bán giám sát, mô hình MedUnA [22] dùng LLM tạo nhãn giả và tinh chỉnh không giám sát bộ điều hợp trên ảnh chưa gán nhãn, giúp mô hình thích ứng tốt mà không thay đổi trọng số.

Tinh chỉnh chọn lọc (Selective Tuning): Hướng đi này tối ưu hóa kiến trúc bằng cách chỉ cập nhật một lượng nhỏ các trọng số quyết định hiệu năng. TransMed [39] kết hợp LLM để chuyển đổi nhãn bệnh thành mô tả chi tiết, trong khi SH-PEFT [17] chỉ tìm và cập nhật các trọng số quan trọng nhất trên bộ mã hóa thị giác nhằm khai thác tính thừa thớt của mạng. Tương tự, LCBP [16] áp dụng kỹ thuật LoRA để tinh chỉnh tham số hiệu quả cho Med-VLMs, giúp bám sát hiệu năng của tinh chỉnh toàn phần (đạt 93.1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn) nhưng giảm thiểu tối đa chi phí tính toán.

Tóm lại, các phương pháp tinh chỉnh hiệu quả tham số (PEFT) thể hiện ưu điểm vượt trội trong việc tiết kiệm tài nguyên tính toán, ngăn chặn hiện tượng quên tri thức và giúp mô hình thích ứng tốt ngay cả khi đối mặt với các bộ dữ liệu y tế khan hiếm. Tuy nhiên, hướng tiếp cận này vẫn tồn tại một số hạn chế nhất định. Hiệu năng cuối cùng của hệ thống

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	CITE (2023)	Parameter-efficient fine tuning	Visual prompt tuning	CLIP ViT-Base, ImageNet-21k ViT-Base, INTERN ViT-Base	BioLinkBERT-large, BioBERT-large, Kế thừa CLIP	Contrastive Alignment	N/a
2	UniDCP (2023)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	CLIP ViT	RoBERTa	Cross Attention, Contrastive Alignment	N/a
3	ViP (2024)	Parameter-efficient fine tuning	Textual prompt tuning	ViT-Base	Kế thừa CLIP	Cross Attention, Contrastive Alignment	N/a
4	PLIP (2024)	Parameter-efficient fine tuning	Visual prompt tuning, Efficient Selective tuning	ViT-Base	Kế thừa CLIP	Concatenate	N/a
5	FPT (2024)	Parameter-efficient fine tuning	Visual prompt tuning	ViT-Base	N/a	Cross Attention	N/a
6	MedPrompt (2024)	Parameter-efficient fine tuning	Textual prompt tuning	Swin Transformer, ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
7	CILMP (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	ViT-Base	Kế thừa CLIP	Hadamard Product, Concatenate	N/a
8	BiomedCoOp (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	Kế thừa BiomedCLIP	Kế thừa BiomedCLIP	Contrastive Alignment	N/a
9	CLIPath (2023)	Parameter-efficient fine tuning	Adapter tuning	ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
10	FTB (2024)	Parameter-efficient fine tuning	Adapter tuning	ResNet autoencoder, DINOv2-small, DINOv2-base	BERT, BioBERT, ClinicalBERT, CXR-BERT, PubMedBERT	Cross Attention	N/a
11	MedUnA (2024)	Parameter-efficient fine tuning	Adapter tuning	ViT-Base, MedCLIP-Swin	Kế thừa CLIP, MedCLIP	No Fusion	N/a
12	TransMed (2023)	Parameter-efficient fine tuning	Direct Selective tuning	Swin Transformer, ViT-Base	BERT, LLM/GPT-4	Contrastive Alignment	N/a
13	SH-PEFT (2024)	Parameter-efficient fine tuning	Direct Selective tuning	ViT-Base	Kế thừa CLIP	No Fusion	N/a
14	LCBB (2024)	Parameter-efficient fine tuning	Efficient Selective tuning	Kế thừa MAE, MRM	Kế thừa MAE, MRM	Kế thừa MAE, MRM	N/a

Bảng 6: Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan

phụ thuộc rất lớn vào chất lượng của mô hình tiền huấn luyện gốc. Đồng thời, quá trình thiết kế câu nhắc mang đậm tính chuyên môn hay xác định vị trí tối ưu để chèn bộ điều hợp thường phức tạp và đòi hỏi nhiều thử nghiệm. Ngoài ra, việc bổ sung các thành phần này ít nhiều làm tăng tính "hộp đen" của mô hình, gây ra những thách thức về tính minh bạch khi cần giải thích các quyết định dự đoán cho bác sĩ trên thực tế lâm sàng.

Các mô hình ngôn ngữ lớn y khoa đa phương thức

Trong thời gian gần đây, với sự phát triển của các mô hình ngôn ngữ lớn được huấn luyện trên những tập dữ liệu rất lớn phục vụ cho rất nhiều tác vụ khác nhau, các mô hình này đang thể hiện sự ảnh hưởng và đa dụng trong lĩnh vực y tế với độ chính xác rất tốt khi chỉ học ít mẫu hoặc không mẫu.

Med-Flamingo [20] là mô hình đầu tiên có khả năng học ít mẫu chuyên dụng cho y tế, thông qua hội thoại tự nhiên để hỗ trợ chẩn đoán. Theo sau đó, LLaVA-Med [14] là mô hình chuyển đổi khả năng thực hiện theo chỉ dẫn (instruction-following) từ miền tổng quát sang lĩnh vực y sinh bằng

cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn với 600.000 cặp, với dữ liệu hội thoại tạo ra từ chú thích ảnh y khoa được tạo ra bằng cách sử dụng GPT-4. Phương pháp này đã đề xuất quy trình huấn luyện 2 bước: (1) Căn chỉnh khái niệm; (2) Tinh chỉnh chỉ dẫn đầy đủ; 2 bước này tương ứng với giai đoạn học và suy luận. Kết quả thể hiện khả năng suy luận vượt trội trên dữ liệu chưa từng thấy.

Med-Palm M [25] là mô hình của Google, đánh dấu bước tiến từ các mô hình đơn nhiệm sang đa nhiệm quy mô lớn, có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì sử dụng các mô hình chuyên biệt cho từng tác vụ. Gần đây hơn, SkinGPT-4 [42] là hệ thống chẩn đoán da liễu tương tác đầu tiên sử dụng LLM quy mô lớn với độ chính xác cao, đã kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM), tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Dù đưa đến các phương pháp có độ chính xác cao đến rất cao trong nhiều tác vụ cùng việc hỗ trợ trong việc giao tiếp với mô hình, kích cỡ và chi phí huấn luyện (Med-Flamingo có đến 9 tỷ thông số) để vận hành các mô hình ngôn ngữ lớn đa phương thức là một vấn đề lớn, đi kèm với vấn đề ảo giác có thể gặp phải khi đối mặt mới dữ liệu mới hoặc những câu hỏi phức tạp. Ngoài ra nếu yêu cầu một độ chính xác cao - một yêu cầu quan trọng trong lĩnh vực y tế trong một tác vụ cụ thể thì đây không phải một cách tiếp cận tốt cho bài toán này.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Cấu trúc phương pháp			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	Med-Flamingo [20]	PEFT	Parameter-efficient + Domain adaptation	Frozen CLIP ViT	LLaMA-7B	Intermediate fusion	LLaMA Decoder
2	LLaVA-Med [14]	Full FT	Visual Instruction Tuning (GPT-4 data)	CLIP ViT-L/14	LLaMA	Projection Matrix	LLM (Vicuna)
3	Med-PaLM M [25]	Full FT	Instruction Fine-tuning	ViT (4B - 22B)	PaLM	Multimodal embedding	PaLM
4	SkinGPT-4 [42]	PEFT	LoRA	Vision Transformer	GPT-4	Linear alignment	LLaMA-2-13B


Bảng 7: Tổng hợp chiến lược và cấu trúc các mô hình ngôn ngữ lớn đa phương thức

Phương pháp đề xuất: Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ

thống được thiết kế theo hướng tích hợp tri thức y khoa nhằm nâng cao khả năng giải thích của mô hình được minh họa ở Hình 2. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Bộ mã hóa ảnh:** Kế thừa lại mô hình ViT-Base của phương pháp BiomedCLIP [34]
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [34]
- **Bộ dung hợp dữ liệu:** Nhóm hướng đến sử dụng cơ chế *Knowledge-guided Cross-Attention* - Các khái niệm y học được trích xuất và liên kết từ văn bản lâm sàng thông qua sẽ được sử dụng để tạo thiên lệch (bias) trong quá trình tính toán cross attention. Cơ chế này giúp điều hướng mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Nhờ đó, mô hình không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.
- **Bộ phân loại:** Sử dụng một mạng phân loại (Multi-Layer Perceptron) để dự đoán nhãn bệnh lý.

Đồng thời, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán.



Hình 2: Kiến trúc tổng thể của hệ thống đề xuất

2.7 Kết quả dự kiến của đề tài

- **Số liệu định lượng:** Độ chính xác, điểm F1, AUC-ROC đạt kết quả cạnh tranh trên các bộ dữ liệu đã nêu.
- **Sản phẩm đầu ra:**

- Hệ thống demo phân loại ảnh X-quang xương với khả năng nhận ảnh và văn bản và trả ra các lớp thuộc bộ dữ liệu Sarcoma-CTCH.
 - Giao diện đơn giản để hiển thị kết quả phân loại.
 - Cho phép trực quan hóa sau khi hiện kết quả phân loại.
- **Báo cáo khoa học:** hoàn thiện phương pháp và hệ thống để hướng tới công bố trên các hội nghị và tạp chí uy tín trong lĩnh vực Trí tuệ nhân tạo và Y sinh, như MICCAI, CVPR hoặc các tạp chí được công nhận.
 - **Hướng phát triển:**
 - Mở rộng ra cho các bệnh lý khác.
 - Cải thiện độ chính xác và hiệu suất của hệ thống.

2.8 Kế hoạch thực hiện

Mục tiêu	Thời gian	Phân công	Nội dung
Khoá luận tốt nghiệp	01 tháng	Giai đoạn 1	
		Bá Thành	Khảo sát tổng quan về bài toán phân loại ảnh X-quang về xương
		Gia Kiệt	Khảo sát các mô hình tiền huấn luyện trên dữ liệu y khoa
		Bá Thành	Khảo sát các phương pháp học chuyển giao và các mô hình liên quan
	02 tháng	Giai đoạn 2	
		Cả nhóm	Phát triển mô hình học sâu đa phương thức áp dụng phương pháp học chuyển giao
		Gia Kiệt	Cài đặt môi trường, thu thập các bộ dữ liệu liên quan
		Bá Thành	Thực hiện thí nghiệm trên mô hình đề xuất
	02 tháng	Giai đoạn 3	
		Bá Thành	Phân tích so sánh kết quả thực nghiệm.
		Gia Kiệt	Xây dựng nguyên mẫu cho hệ thống phân loại
	0.5 tháng	Giai đoạn 4	
		Cả nhóm	Viết 01 bài báo khoa học cho hội nghị - tạp chí chuyên ngành trong nước hoặc ngoài nước
	0.5 tháng	Giai đoạn 5	
		Bá Thành	Viết báo cáo khoá luận tốt nghiệp.
		Gia Kiệt	Thiết kế slide cho lễ bảo vệ đề tài tốt nghiệp

Bảng 8: Kế hoạch bố trí thời gian nghiên cứu

Tài liệu tham khảo

- [1] Shruthi Bannur et al. “Learning to exploit temporal structure for biomedical vision-language processing”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2023, pp. 15016–15027.
- [2] Lynn S. Bickley, Peter G. Szilagyi, and Richard M. Hoffman. *Bates’ Guide to Physical Examination and History Taking*. 13th. Lippincott Williams & Wilkins, 2020.
- [3] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing”. In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5.
- [4] Bệnh viện Nguyễn Tri Phương. *Quy trình khám bệnh tại khoa khám bệnh*. URL: <https://bvnguyentriphuong.com.vn/quy-trinh-kham-benh/quy-trinh-kham-benh-tai-khoa-kham-benh> (visited on 07/06/2026).
- [5] Yin Dai and Yifan Gao. “TransMed: Transformers Advance Multi-modal Medical Image Classification”. In: *CoRR* abs/2103.05940 (2021). arXiv: 2103.05940. URL: <https://arxiv.org/abs/2103.05940>.
- [6] Ye Du, Nanxi Yu, and Shujun Wang. “Medical Knowledge Intervention Prompt Tuning for Medical Image Classification”. In: *IEEE Transactions on Medical Imaging* 44.12 (2025), pp. 4945–4959. DOI: 10.1109/TMI.2025.3584841.
- [7] Xiao Fang et al. “Aligning Medical Images with General Knowledge from Large Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15010. Springer Nature Switzerland, 2024.
- [8] Kaiming He et al. “Deep Residual Learning for Image Recognition”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016.

- [9] Gao Huang et al. “Densely Connected Convolutional Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017.
- [10] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [11] Yijin Huang et al. “Fine-grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-resolution Medical Image Classification”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15012. Springer Nature Switzerland, 2024.
- [12] Taha Koleilat et al. “BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models”. In: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*. 2025, pp. 14766–14776.
- [13] Zhengfeng Lai et al. “CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*. 2023, pp. 2374–2380.
- [14] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: <https://arxiv.org/abs/2306.00890>.
- [15] Zihan Li et al. “LViT: Language Meets Vision Transformer in Medical Image Segmentation”. In: *IEEE Transactions on Medical Imaging* 43.1 (2024), pp. 96–107. DOI: 10.1109/TMI.2023.3291719.
- [16] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: <https://arxiv.org/abs/2401.12215>.

- [17] Mingyuan Liu et al. “Sparsity- and Hybridity-Inspired Visual Parameter-Efficient Fine-Tuning for Medical Diagnosis”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15005. Springer Nature Switzerland, 2024.
- [18] Xueyan Mei et al. “Artificial intelligence-enabled rapid diagnosis of patients with COVID-19”. In: *Nature Medicine* 26 (Aug. 2020), 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: <https://www.nature.com/articles/s41591-020-0931-3>.
- [19] Jong Hak Moon et al. “Multi-Modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training”. In: *IEEE Journal of Biomedical and Health Informatics* 26.12 (2022), pp. 6070–6080. DOI: 10.1109/JBHI.2022.3207502.
- [20] Michael Moor et al. *Med-Flamingo: a Multimodal Medical Few-shot Learner*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.15189. URL: <https://arxiv.org/abs/2307.15189>.
- [21] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.
- [22] Umaima Rahman et al. “Can language-guided unsupervised adaptation improve medical image classification using unpaired images and texts?” In: *2025 IEEE 22nd International Symposium on Biomedical Imaging (ISBI)*. IEEE. 2025, pp. 1–5.
- [23] Bryan C Russell et al. “LabelMe: a database and web-based tool for image annotation”. In: *International journal of computer vision* 77.1-3 (2008), pp. 157–173.
- [24] Nikhil Kumar Tomar et al. “TGANet: Text-Guided Attention for Improved Polyp Segmentation”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2022*. Cham, Switzerland: Springer Nature Switzerland, 2022, pp. 151–160. ISBN: 978-3-031-16437-8. DOI: 10.1007/978-3-031-16437-8_15.

- [25] Tao Tu et al. *Towards Generalist Biomedical AI*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.14334. URL: <https://arxiv.org/abs/2307.14334>.
- [26] Xiaosong Wang et al. “TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018.
- [27] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, Dec. 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: <https://aclanthology.org/2022.emnlp-main.256/>.
- [28] W.B. Saunders. *Dorland’s Illustrated Medical Dictionary*. 32nd. Elsevier Health Sciences, 2011.
- [29] Chaoyi Wu et al. “MedKLIP: Medical Knowledge Enhanced Language-Image Pre-Training for X-ray Diagnosis”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023, pp. 21372–21383.
- [30] Bin Yan and Mingtao Pei. “Clinical-BERT: Vision-Language Pre-training for Radiograph Diagnosis and Reports Generation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 36. 3. 2022, pp. 2982–2990. DOI: 10.1609/aaai.v36i3.20204. URL: <https://doi.org/10.1609/aaai.v36i3.20204>.
- [31] Shunhan Yao et al. “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors”. In: *Scientific Data* 12.1 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y. URL: <https://doi.org/10.1038/s41597-024-04311-y>.
- [32] Chenlu Zhan et al. “UniDCP: Unifying Multiple Medical Vision-Language Tasks via Dynamic Cross-Modal Learnable Prompts”. In:

- IEEE Transactions on Multimedia* 26 (2024), pp. 9736–9748. DOI: 10.1109/TMM.2024.3397191.
- [33] Jiajin Zhang et al. “Disease-informed Adaptation of Vision-Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15011. Springer Nature Switzerland, 2024.
 - [34] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoa2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoa2400640>.
 - [35] Xiaoman Zhang et al. “Knowledge-enhanced visual-language pre-training on chest radiology images”. In: *Nature Communications* 14 (July 2023). DOI: 10.1038/s41467-023-40260-7. URL: <https://arxiv.org/pdf/2302.14042.pdf>.
 - [36] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 7th Machine Learning for Healthcare Conference*. Ed. by Zachary Lipton et al. Vol. 182. Proceedings of Machine Learning Research. PMLR, 2022, pp. 2–25. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
 - [37] Yunkun Zhang et al. “Text-Guided Foundation Model Adaptation for Pathological Image Classification”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*. Ed. by Hayit Greenspan et al. Cham: Springer Nature Switzerland, 2023, pp. 272–282. ISBN: 978-3-031-43904-9.
 - [38] Fudan Zheng et al. “Exploring low-resource medical image classification with weakly supervised prompt learning”. In: *Pattern Recognition* 149 (2024), p. 110250. ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2024.110250>. URL: <https://www.sciencedirect.com/science/article/pii/S0031320324000013>.

- [39] Kaipeng Zheng, Weiran Huang, and Lichao Sun. “TransMed: Large Language Models Enhance Vision Transformer for Biomedical Image Classification”. In: *arXiv preprint arXiv:2312.07125* (2023).
- [40] Hong-Yu Zhou et al. “A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics”. In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).
- [41] Hong-Yu Zhou et al. “Advancing Radiograph Representation Learning with Masked Record Modeling”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=w-x7U26GM7j>.
- [42] Juexiao Zhou et al. “Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4”. In: *Nature Communications* 15 (July 2024). DOI: 10.1038/s41467-024-50043-3. URL: <https://doi.org/10.1038/s41467-024-50043-3>.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 05 tháng 04 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Đề cương chi tiết	iii
Mục lục	xxviii
Danh sách hình	xxxix
Danh sách bảng	xxxix
Tóm tắt	xxxix
1 Giới thiệu	1
1.1 Bối cảnh và lý do chọn đề tài	1
1.2 Động lực nghiên cứu	3
1.2.1 Kích bản thực tế	3
1.2.2 Ý nghĩa khoa học của đề tài	6
1.2.3 Ý nghĩa thực tiễn của đề tài	6
1.3 Giới thiệu bài toán	7
1.3.1 Các thách thức trong bài toán	8
1.4 Mục tiêu nghiên cứu	9
1.5 Đối tượng và phạm vi nghiên cứu	10
1.5.1 Đối tượng nghiên cứu	10
1.5.2 Phạm vi nghiên cứu	10
1.6 Các câu hỏi nghiên cứu và giả thuyết	11
1.7 Đóng góp chính của đề tài	13

1.8	Bố cục luận văn	14
2	Các công trình nghiên cứu liên quan	16
2.1	Các mô hình nền tảng	16
2.1.1	Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu	16
2.1.2	Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) .	17
2.2	Các kỹ thuật tinh chỉnh hiệu quả tham số	19
2.2.1	Tinh chỉnh sử dụng câu nhắc (Prompt Tuning) . .	19
2.2.2	Tinh chỉnh bộ điều hợp (Adapter Tuning)	20
2.2.3	Tinh chỉnh chọn lọc (Selective Tuning)	20
2.3	Các phương pháp phát hiện dữ liệu ngoài phân phối	21
2.3.1	Các phương pháp hậu xử lý dựa trên đầu ra mô hình (Post-hoc Methods)	22
2.3.2	Các phương pháp dựa trên không gian đặc trưng (Feature-space-based Methods)	22
2.3.3	Các phương pháp học biểu diễn phục vụ phát hiện OOD (Representation Learning)	23
2.3.4	Các phương pháp sinh và định lượng độ không chắc chắc	24
2.4	Bàn luận	25
2.4.1	Xu hướng ứng dụng học sâu đa phương thức trong chẩn đoán ảnh y khoa	25
2.4.2	Hạn chế của các nghiên cứu hiện nay	25
2.4.3	Cơ sở lựa chọn và định hướng phương pháp đề xuất	26
3	Phương pháp đề xuất	28
3.1	Tổng quan phương pháp đề xuất	28
3.2	Pipeline cuối cùng	29
3.3	Giai đoạn huấn luyện	30
3.3.1	Học biểu diễn với kỹ thuật LoRA	31
3.3.2	Học phân loại đa lớp với empirical centroid head . .	33
3.4	Giai đoạn online	36
3.5	Đóng góp của phương pháp	37

4	Thực nghiệm	38
4.1	Mục đích thực nghiệm	38
4.1.1	Đánh giá so sánh hiệu năng chẩn đoán với các mô hình đối sánh	39
4.1.2	Đánh giá khả năng phát hiện dữ liệu ngoài phân phối	39
4.1.3	Đánh giá vai trò của các nguồn thông tin văn bản lâm sàng	40
4.1.4	Đánh giá ảnh hưởng của chiến thuật tinh chỉnh backbone	40
4.1.5	Đánh giá hiệu quả của đầu phân loại nguyên mẫu so với đầu phân loại tuyến tính	41
4.1.6	Trực quan hóa bản đồ chú ý chéo và khả năng giải thích y khoa	42
4.2	Chuẩn bị dữ liệu	42
4.2.1	Bộ dữ liệu BTXRD	43
4.2.2	Bộ dữ liệu CTCH	47
4.3	Độ đo đánh giá	52
4.3.1	Định nghĩa toán học và ý nghĩa của các độ đo . . .	52
4.4	Thiết lập thực nghiệm	56
4.4.1	Môi trường thực nghiệm	56
4.4.2	Tham số thực nghiệm	58
4.5	Kết quả thực nghiệm và Thảo luận	58
4.5.1	Đánh giá so sánh hiệu năng chẩn đoán với các mô hình đối sánh	58
4.5.2	Đánh giá khả năng phát hiện dữ liệu ngoài phân phối	60
4.5.3	Các thí nghiệm rời rạc	60
4.5.4	Trực quan hóa bản đồ chú ý chéo và khả năng giải thích y khoa	63
5	Kết luận và hướng phát triển	66
5.1	Kết luận	66
5.2	Hướng phát triển	67
	Tài liệu tham khảo	69

Danh sách hình

1.1	Sơ đồ quy trình khám chữa bệnh giảm hóa (Tham khảo từ quy trình thực tế tại Bệnh viện Nguyễn Tri Phương [4]). .	4
1.2	Sơ đồ tích hợp hệ thống hỗ trợ chẩn đoán.	5
3.1	Sơ đồ chung của hệ thống trong công đoạn học biểu diễn. .	31
3.2	Sơ đồ chung của hệ thống trong công đoạn học phân loại đa lớp.	33
3.3	Sơ đồ chung của hệ thống trong giai đoạn online.	36
4.1	Sơ đồ phân cấp cấu trúc dữ liệu BTXRD	44
4.2	Sơ đồ phân cấp cấu trúc dữ liệu CTCH	50
4.3	Trực quan hóa bản đồ chú ý chéo (Cross-Attention Map) của mô hình đề xuất XBone-Net trên các nhóm bệnh lý điển hình (mỗi cặp gồm ảnh chụp X-quang gốc bên trái đã vẽ đường nét đứt màu xanh lá thể hiện phân vùng tổn thương thực tế - Ground Truth và ảnh chồng bản đồ chú ý chéo ở bên phải).	64

Danh sách bảng

2.1	Bảng tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản.	18
2.2	Bảng tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện cho các mô hình ngôn ngữ trực quan y khoa. .	21
4.1	Ví dụ các mẫu dữ liệu đa phương thức trong bộ dữ liệu BTXRD	48
4.2	Phân bố hình ảnh theo các tập dữ liệu trong BTXRD . . .	49
4.3	Phân bố các lớp bệnh lý u xương trong bộ dữ liệu BTXRD	49
4.4	Bảng tổng hợp siêu tham số ở pha 1 và thiết lập của chúng	57
4.5	Bảng tổng hợp siêu tham số ở pha 2 và thiết lập của chúng	57
4.6	Bảng đánh giá hiệu năng Zero-Shot của các mô hình VLM gốc trên bộ dữ liệu BTXRD	58
4.7	Bảng so sánh kết quả thực nghiệm fine-tuned baselines và mô hình đề xuất XBone-Net	58
4.8	Bảng kết quả ablation về nguồn văn bản đầu vào	61
4.9	Bảng kết quả ablation về chiến thuật tinh chỉnh backbone	62
4.10	Bảng kết quả ablation về bộ phân loại Classifier Head . . .	63

Tóm tắt

Các bệnh lý và chấn thương xương ngày càng phổ biến, làm gia tăng nhu cầu ứng dụng trí tuệ nhân tạo nhằm hỗ trợ bác sĩ trong quá trình phân tích ảnh X-quang. Tuy nhiên, dữ liệu X-quang y khoa thường có số lượng mẫu gán nhãn hạn chế, mất cân bằng giữa các lớp bệnh và tồn tại nhiều trường hợp ngoài phân phối (Out-of-Distribution - OOD), khiến hiệu quả của các mô hình học sâu suy giảm khi triển khai trong thực tế.

Đề tài hướng đến xây dựng một hệ thống phân loại đa lớp ảnh X-quang xương theo hướng đa phương thức, khai thác đồng thời thông tin từ ảnh X-quang và văn bản lâm sàng nhằm nâng cao hiệu quả dự đoán.

Hệ thống được xây dựng trên nền tảng BioMedCLIP với hai giai đoạn huấn luyện. Giai đoạn thứ nhất thực hiện thích nghi miền bằng kỹ thuật LoRA sử dụng Semantic Matching Loss nhằm cải thiện khả năng biểu diễn đặc trưng đối với dữ liệu X-quang xương. Giai đoạn hai học phân loại sử dụng cơ chế chú ý hai chiều để hợp nhất đặc trưng ảnh và văn bản, kết hợp Asymmetric Loss nhằm xử lý mất cân bằng lớp và mạng nguyên mẫu để tăng cường khả năng phân biệt giữa các lớp, hỗ trợ các lớp có ít mẫu và làm cơ sở cho phát hiện dữ liệu ngoài phân phối. Hệ thống được đánh giá thông qua các thực nghiệm thành phần, so sánh với các mô hình nền tảng và đánh giá trên bộ dữ liệu X-quang xương được xây dựng từ dữ liệu thực từ Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.

Kết quả thực nghiệm cho thấy phương pháp đề xuất cải thiện hiệu quả phân loại đa lớp so với mô hình nền, đồng thời nâng cao khả năng tổng quát và hỗ trợ phát hiện dữ liệu ngoài phân phối. Ngoài ra, đề tài còn đóng góp một bộ dữ liệu X-quang xương đã được tinh lọc và chuẩn hóa, tạo nền tảng cho các nghiên cứu tiếp theo về học đa phương thức và ứng dụng mô hình thị giác-ngôn ngữ trong phân tích ảnh y khoa.

Chương 1

Giới thiệu

Chương này trình bày tổng quan về bài toán hỗ trợ chẩn đoán bệnh lý trên ảnh X-quang xương bằng học sâu đa phương thức, đặc biệt trong bối cảnh dữ liệu y tế thường có tính phức tạp cao và phụ thuộc vào kinh nghiệm của bác sĩ. Bên cạnh thông tin hình ảnh, quá trình chẩn đoán thực tế còn yêu cầu kết hợp thêm các thông tin lâm sàng và báo cáo y khoa nhằm đưa ra đánh giá toàn diện về tình trạng bệnh nhân. Tuy nhiên, việc khai thác hiệu quả đồng thời nhiều nguồn dữ liệu khác nhau vẫn còn là một thách thức lớn đối với các hệ thống học sâu hiện nay.

1.1 Bối cảnh và lý do chọn đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn đầu. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, nhiều nghiên cứu đã ứng dụng các mô hình học sâu vào việc giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh như Resnet [8] và DenseNet [9]. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ tốt để đưa vào ứng dụng thực tế. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để hỗ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác.

Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống. Trong những năm gần đây, các mô hình ngôn ngữ trực quan kết hợp ảnh y khoa với báo cáo đọc ảnh có thể học được mối quan hệ ngữ nghĩa giữa hai phương thức, từ đó tạo ra biểu diễn dữ liệu giàu thông tin hơn so với các mô hình chỉ sử dụng dữ liệu hình ảnh hoặc văn bản riêng lẻ. Nhiều mô hình tiêu biểu như MedCLIP [27], BioMedCLIP [34] và BioViL [3] đã chứng minh hiệu quả trên nhiều bài toán phân tích ảnh y khoa.

Tuy nhiên, các mô hình ngôn ngữ trực quan hiện nay vẫn tồn tại một số hạn chế. Đầu tiên, các mô hình này chủ yếu được huấn luyện trên các bộ dữ liệu cặp ảnh X-quang và báo cáo đọc ảnh, trong khi trong thực tế ở Việt Nam, báo cáo đọc ảnh thường chứa kết luận rõ ràng, dẫn đến việc các mô hình này khó áp dụng vào thực tế khi chúng ta cần chẩn đoán chỉ dựa vào ảnh và báo cáo lâm sàng của bệnh nhân. Thứ hai, các mô hình hiện tại chưa được thiết kế để xử lý các trường hợp dữ liệu ngoài phân phối, dẫn đến nguy cơ đưa ra dự đoán không chính xác với độ tin cậy cao đối với những trường hợp chưa từng xuất hiện trong dữ liệu huấn luyện. Thứ ba, dữ liệu huấn luyện trong thực tế rất ít, đặc biệt là các trường hợp hiếm gặp, khiến việc huấn luyện các mô hình trở nên khó khăn. Thứ tư, khả năng giải thích của các mô hình hiện nay vẫn còn hạn chế, khiến bác sĩ khó có thể hiểu rõ cơ sở đưa ra quyết định của hệ thống.


1.2 Động lực nghiên cứu

1.2.1 Kịch bản thực tế


Trong thực hành lâm sàng, quy trình chẩn đoán bệnh lý xương thường tuân theo Hình 1.1 bao gồm khám lâm sàng, chỉ định chụp X-quang, phân tích hình ảnh và kết hợp với các thông tin bệnh án để đưa ra chẩn đoán cuối cùng. Sau khi ảnh X-quang được thu nhận, bác sĩ chẩn đoán hình ảnh sẽ đánh giá các dấu hiệu bất thường như vị trí tổn thương, hình thái gãy xương, khối u hoặc các biến đổi bệnh lý khác, đồng thời đối chiếu với các thông tin lâm sàng như triệu chứng, tiền sử bệnh và cơ chế chấn thương để đưa ra kết quả đọc phim.

Hệ thống được đề xuất trong luận văn được thiết kế nhằm hỗ trợ quá trình phân tích ảnh X-quang bằng cách khai thác đồng thời ảnh X-quang và dữ liệu văn bản chứa thông tin lâm sàng để dự đoán lớp bệnh lý của bệnh nhân như thể hiện ở Hình 1.2. Việc kết hợp hai nguồn dữ liệu giúp mô hình tận dụng các thông tin bổ sung, từ đó nâng cao khả năng học biểu diễn và cải thiện hiệu quả phân loại so với việc chỉ sử dụng một phương thức dữ liệu.

Cần lưu ý rằng hệ thống được đề xuất không thay thế vai trò của bác sĩ phân tích ảnh mà đóng vai trò là công cụ hỗ trợ phân tích. Các kết quả dự đoán cung cấp thông tin tham khảo, giúp rút ngắn thời gian đọc phim, giảm nguy cơ bỏ sót tổn thương và nâng cao hiệu quả chẩn đoán, đặc biệt tại các cơ sở y tế có khối lượng bệnh nhân lớn hoặc nguồn nhân lực chuyên khoa còn hạn chế.



Hình 1.1: Sơ đồ quy trình khám chữa bệnh giản hóa (Tham khảo từ quy trình thực tế tại Bệnh viện Nguyễn Tri Phương [4]).



Hình 1.2: Sơ đồ tích hợp hệ thống hỗ trợ chẩn đoán.

1.2.2 Ý nghĩa khoa học của đề tài

Đề tài góp phần làm rõ hiệu quả của việc kết hợp dữ liệu ảnh X-quang và văn bản lâm sàng trong bài toán phân loại đa lớp. Thông qua việc khai thác đồng thời hai nguồn dữ liệu, nghiên cứu đánh giá khả năng cải thiện chất lượng biểu diễn và hiệu quả phân loại so với các phương pháp chỉ sử dụng một phương thức, qua đó cung cấp cơ sở cho việc phát triển các hệ thống hỗ trợ chẩn đoán tận dụng hiệu quả dữ liệu y tế đa phương thức.

Bên cạnh đó, nghiên cứu kế thừa và tinh chỉnh mô hình ngôn ngữ trực quan trên dữ liệu X-quang xương ở Việt Nam, góp phần đánh giá khả năng thích nghi của các mô hình tiền huấn luyện đa phương thức đối với các bài toán y khoa đặc thù ở Việt Nam và có quy mô dữ liệu hạn chế với phân bố mất cân bằng.

Ngoài ra, đề tài nghiên cứu các phương pháp nâng cao khả năng tổng quát hóa của mô hình trong điều kiện dữ liệu thực tế, đồng thời tích hợp cơ chế phát hiện dữ liệu ngoài phân phối. Cách tiếp cận này góp phần nâng cao độ tin cậy của hệ thống khi triển khai trong môi trường lâm sàng bằng cách hạn chế các dự đoán đối với những trường hợp chưa từng xuất hiện trong dữ liệu huấn luyện.

Cuối cùng, đề tài tăng cường khả năng giải thích của mô hình thông qua việc trực quan hóa các vùng ảnh X-quang có ảnh hưởng đến quá trình dự đoán, giúp bác sĩ chính hiểu rõ hơn cơ sở đưa ra kết quả phân loại và nâng cao tính minh bạch của hệ thống.

1.2.3 Ý nghĩa thực tiễn của đề tài

Hệ thống được đề xuất hướng đến hỗ trợ bác sĩ trong quá trình phân tích ảnh X-quang bằng cách kết hợp thông tin từ ảnh X-quang và dữ liệu lâm sàng ban đầu để đưa ra kết quả phân loại. Quá trình huấn luyện tận dụng báo cáo lâm sàng nhằm học mối quan hệ giữa ảnh X-quang và biểu hiện của bệnh lý. Cách tiếp cận này phù hợp với quy trình khám chữa bệnh thực tế tại các cơ sở y tế, góp phần nâng cao khả năng ứng dụng của hệ thống trong thực tiễn.

Bên cạnh đó, hệ thống được thiết kế nhằm thích ứng với các đặc điểm phổ biến của dữ liệu y tế thực tế như số lượng mẫu gán nhãn hạn chế, phân bố dữ liệu mất cân bằng và sự xuất hiện của các trường hợp ngoài phân phối.

Đồng thời, mô hình cung cấp các bản đồ nhiệt trực quan hóa vùng ảnh trong ảnh X-quang ảnh hưởng đến kết quả dự đoán và cơ chế cảnh báo đối với các mẫu dữ liệu ngoài phân phối, góp phần nâng cao tính minh bạch, độ tin cậy và tính an toàn khi hỗ trợ bác sĩ trong quá trình chẩn đoán.

1.3 Giới thiệu bài toán

Bài toán được nghiên cứu trong đề tài là bài toán phân loại đa lớp ảnh X-quang sử dụng học sâu đa phương thức. Mục tiêu của hệ thống là dự đoán các loại bệnh hoặc tổn thương dựa trên đồng thời dữ liệu hình ảnh X-quang và thông tin lâm sàng liên quan.

- **Đầu vào:** Hệ thống nhận vào các nguồn dữ liệu sau:

- Ảnh X-quang của bệnh nhân:

$$x^{img} \in \mathbb{R}^{H \times W \times C}$$

trong đó:

- * H, W : chiều cao và chiều rộng ảnh,
- * C : số kênh màu của ảnh.

- Thông tin lâm sàng (lời khai bệnh nhân, triệu chứng, tiền sử bệnh).

$$x^{txt} = \{w_1, w_2, \dots, w_T\}$$

trong đó:

- * w_t : từ thứ t ,
- * T : số lượng từ trong văn bản.

- Tập nhãn được định nghĩa trước:

$$\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$$

với K là số lớp bệnh cần phân loại.

- **Đầu ra:** Hệ thống sinh ra:

- Cảnh báo dữ liệu ngoài phân phối/chưa từng gặp với các mẫu được hệ thống cho là không thuộc các lớp đã học.
- Nhãn dự đoán cuối cùng với các mẫu được cho là thuộc các lớp đã học:

$$\hat{y} = f(x^{img}, x^{txt}) \in \mathcal{Y}$$

trong đó f là hàm ánh xạ được học bởi mô hình.

- Bản đồ nhiệt trực quan hóa trên ảnh nhằm giải thích dự đoán của mô hình.

1.3.1 Các thách thức trong bài toán

Mặc dù các mô hình học sâu đa phương thức đã đạt được nhiều kết quả tích cực, bài toán vẫn tồn tại nhiều thách thức cần được giải quyết:

- Tồn tại sự chênh lệch lớn giữa các bộ dữ liệu đa phương thức hiện có (thường là cặp ảnh X-quang và báo cáo đọc ảnh X-quang) so với luồng công việc thực tế lâm sàng (bao gồm ảnh chụp X-quang kết hợp với báo cáo tổng quát), làm hạn chế khả năng ứng dụng trực tiếp của các mô hình.
- Sự khác biệt về không gian và ngữ nghĩa giữa dữ liệu hình ảnh và dữ liệu văn bản gây khó khăn cho quá trình học biểu diễn chung, yêu cầu một cơ chế dung hợp hiệu quả.
- Dữ liệu y tế thường có số lượng hạn chế và mất cân bằng giữa các loại bệnh, đặt ra yêu cầu đặc biệt về thiết kế mô hình để tận dụng tối đa thông tin có sẵn.

- Trong thực tế lâm sàng, luôn có tỉ lệ xuất hiện những loại bệnh mới nằm ngoài dữ liệu huấn luyện, đặt ra yêu cầu về khả năng tổng quát hóa và thích ứng của mô hình.
- Khả năng giải thích của mô hình vẫn còn hạn chế khiến độ tin cậy vào các dự đoán của hệ thống là không cao, gây khó khăn cho việc triển khai trong thực tế lâm sàng.

1.4 Mục tiêu nghiên cứu

Đề tài hướng đến việc nghiên cứu và xây dựng một hệ thống học sâu đa phương thức phục vụ hỗ trợ phân loại bệnh lý trên ảnh X-quang xương, khai thác đồng thời dữ liệu hình ảnh và báo cáo lâm sàng nhằm đảm bảo hiệu quả phân loại so với các phương pháp hiện có và có khả năng thích ứng với các tình huống thực tế như dữ liệu ngoài phân phối và mất cân bằng lớp.

Các mục tiêu cụ thể của đề tài bao gồm:

1. Đánh giá vai trò của báo cáo lâm sàng trong việc nâng cao hiệu quả phân loại bệnh lý xương khi kết hợp với ảnh X-quang, so với các phương pháp chỉ sử dụng dữ liệu hình ảnh.
2. Nghiên cứu chiến lược dung hợp đặc trưng đa phương thức, cụ thể là cơ chế chú ý chéo và so sánh với các phương pháp khác, nhằm xác định phương pháp kết hợp hiệu quả giữa đặc trưng hình ảnh và văn bản.
3. Khảo sát các phương pháp tinh chỉnh hiệu quả tham số, nhằm giảm chi phí tính toán trong khi duy trì hoặc cải thiện hiệu quả phân loại so với việc tinh chỉnh toàn bộ tham số.
4. Nghiên cứu cơ chế phát hiện dữ liệu ngoài phân phối nhằm tăng khả năng nhận diện các mẫu bệnh lý chưa từng xuất hiện trong dữ liệu huấn luyện, nâng cao độ tin cậy của hệ thống trong môi trường thực tế.

5. Xây dựng cơ chế giải thích dựa trên bản đồ chú ý giúp trực quan hóa các vùng ảnh mà mô hình tập trung khi đưa ra quyết định phân loại, hỗ trợ bác sĩ trong việc đánh giá và kiểm chứng kết quả dự đoán.
6. Xây dựng và đánh giá hệ thống XBone-Net trên bộ dữ liệu phân loại bệnh lý xương có phân bố mất cân bằng, so sánh với các mô hình nền tảng y khoa hiện có.

1.5 Đối tượng và phạm vi nghiên cứu

1.5.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học sâu đa phương thức sử dụng đồng thời dữ liệu hình ảnh và văn bản trong bài toán phân loại ảnh X-quang xương. Cụ thể, nghiên cứu tập trung vào các thành phần chính sau:

- Các mô hình ngôn ngữ trực quan tiền huấn luyện trên dữ liệu y khoa và dữ liệu tổng quát, được sử dụng làm bộ mã hóa đặc trưng đa phương thức.
- Các chiến lược dung hợp đặc trưng đa phương thức, bao gồm cơ chế chú ý chéo và phép nối đặc trưng, nhằm kết hợp thông tin từ ảnh X-quang và báo cáo lâm sàng.
- Các phương pháp tinh chỉnh tham số hiệu quả cho các mô hình tiền huấn luyện quy mô lớn nhằm giảm chi phí tính toán.
- Các kiến trúc bộ phân loại, phục vụ bài toán phân loại đa lớp trên dữ liệu mất cân bằng và phát hiện dữ liệu ngoài phân phối.

1.5.2 Phạm vi nghiên cứu

Đề tài tập trung vào bài toán phân loại đa lớp bệnh lý xương trên ảnh X-quang, kết hợp với báo cáo lâm sàng dạng văn bản. Phạm vi cụ thể bao gồm:

- **Dữ liệu:** Nghiên cứu sử dụng bộ dữ liệu BTXRD gồm 10 lớp bệnh lý xương, và bộ dữ liệu CTCH được thu thập từ Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.
- **Dữ liệu văn bản:** Trong quá trình huấn luyện và suy luận, hệ thống sử dụng bệnh sử lâm sàng được thu nhận trước khi đọc ảnh (chứa thông tin triệu chứng và tiền sử bệnh) thay vì báo cáo đọc ảnh X-quang, nhằm hạn chế rò rỉ nhãn và phù hợp hơn với thời điểm áp dụng hệ thống.
- **Vai trò hệ thống:** Hệ thống được thiết kế làm công cụ hỗ trợ chẩn đoán, không thay thế vai trò của bác sĩ trong quá trình ra quyết định.
- **Giới hạn:** Đề tài không tập trung vào các bài toán phát hiện đối tượng, phân đoạn ảnh hay sinh báo cáo y khoa tự động.

1.6 Các câu hỏi nghiên cứu và giả thuyết

Trong các giả thuyết dưới đây, Macro F1-Score được sử dụng làm chỉ số chính cho bài toán phân loại do dữ liệu có phân bố mất cân bằng; Accuracy, Macro AUROC và Specificity được sử dụng làm các chỉ số bổ sung. Hiệu quả tính toán được đánh giá thông qua số tham số có thể huấn luyện, mức sử dụng bộ nhớ và thời gian suy luận. Đối với phát hiện dữ liệu ngoài phân phối, các chỉ số chính gồm AUROC, AUPR-Out và FPR@95TPR.

- **Câu hỏi nghiên cứu 1:** Việc kết hợp bệnh sử lâm sàng được thu nhận trước khi đọc ảnh với ảnh X-quang có cải thiện hiệu quả phân loại so với mô hình chỉ sử dụng ảnh không?

Giả thuyết 1: Mô hình sử dụng đồng thời ảnh X-quang và bệnh sử lâm sàng đạt Macro F1-Score cao hơn mô hình chỉ sử dụng ảnh trên cùng tập dữ liệu và quy trình đánh giá.

- **Câu hỏi nghiên cứu 2:** Cơ chế chú ý chéo hai chiều có khai thác tương tác giữa ảnh và văn bản hiệu quả hơn phép nối đặc trưng và các biến thể chú ý chéo một chiều không?

Giả thuyết 2: Cơ chế chú ý chéo hai chiều đạt Macro F1-Score cao hơn các cấu hình dùng phép nối đặc trưng hoặc chỉ thực hiện chú ý theo một chiều khi các thành phần còn lại được giữ nguyên.

- **Câu hỏi nghiên cứu 3:** Chiến lược tinh chỉnh LoRA có duy trì hiệu quả phân loại trong khi giảm chi phí tính toán so với tinh chỉnh toàn bộ tham số không?

Giả thuyết 3: LoRA đạt Macro F1-Score tương đương hoặc cao hơn tinh chỉnh toàn bộ tham số, đồng thời sử dụng ít tham số có thể huấn luyện và ít bộ nhớ hơn.

- **Câu hỏi nghiên cứu 4:** Nhánh xử lý ảnh độ phân giải cao dựa trên lưới ảnh cục bộ và bộ tái lấy mẫu có tọa độ có cải thiện khả năng phân loại so với các phương pháp chỉ sử dụng ảnh toàn cục hoặc co giãn ảnh không?

Giả thuyết 4: Nhánh xử lý ảnh độ phân giải cao đạt Macro F1-Score cao hơn cấu hình chỉ sử dụng ảnh toàn cục và cấu hình co giãn ảnh khi sử dụng cùng backbone và chiến lược huấn luyện.

- **Câu hỏi nghiên cứu 5:** Hệ thống đề xuất XBone-Net có cải thiện hiệu quả phân loại so với các mô hình nền tảng được tinh chỉnh theo cùng cách thức đánh giá không?

Giả thuyết 5: XBone-Net đạt Macro F1-Score cao hơn mô hình đối chứng tốt nhất; các chỉ số còn lại được báo cáo như tiêu chí bổ sung thay vì giả định XBone-Net phải vượt trội trên mọi độ đo.

- **Câu hỏi nghiên cứu 6:** Không gian biểu diễn của XBone-Net có hỗ trợ phân biệt dữ liệu nội phân phối với các bộ dữ liệu ngoài phân phối được xác định trước không?

Giả thuyết 6: Ít nhất một phương pháp hậu xử lý được khảo sát, gồm khoảng cách Mahalanobis, Cosine-kNN, Energy Score và khoảng cách đến mốc văn bản, đạt AUROC lớn hơn mức ngẫu nhiên trong việc phân biệt dữ liệu nội phân phối và ngoài phân phối; phương pháp được lựa chọn dựa trên tập hiệu chỉnh thay vì tập kiểm thử.

- **Câu hỏi nghiên cứu 7:** Bản đồ chú ý của mô hình có tập trung vào các vùng tổn thương được chú thích trên ảnh X-quang không?

Giả thuyết 7: Trên các mẫu có chú thích tổn thương, tỷ lệ khối lượng chú ý nằm trong vùng tổn thương lớn hơn tỷ lệ diện tích của vùng này trên ảnh, tương ứng với tỷ số tập trung chú ý lớn hơn 1.

1.7 Đóng góp chính của đề tài

Các đóng góp chính của đề tài bao gồm:

1. **Quy trình sử dụng dữ liệu đa phương thức hạn chế rò rỉ nhãn:** Xây dựng quy trình sử dụng ảnh X-quang cùng bệnh sử lâm sàng được thu nhận trước khi đọc ảnh trong cả hai giai đoạn huấn luyện và khi suy luận. Báo cáo đọc ảnh, vốn có thể chứa trực tiếp kết luận chẩn đoán, được loại khỏi pipeline chính và chỉ được sử dụng trong các thí nghiệm loại bỏ thành phần nhằm đánh giá rò rỉ nhãn.
2. **Kiến trúc XBone-Net xử lý ảnh độ phân giải cao:** Phát triển nhánh thị giác bao phủ toàn bộ ảnh X-quang bằng lưới ảnh cục bộ xác định, tổng hợp các token cục bộ và nén chúng bằng bộ tái lấy mẫu có sử dụng thông tin tọa độ. Biểu diễn thị giác sau đó được kết hợp với biểu diễn bệnh sử lâm sàng bằng cơ chế chú ý chéo hai chiều.
3. **Quy trình huấn luyện hai giai đoạn với LoRA:** Thiết kế Giai đoạn 1 sử dụng Semantic Matching Loss để căn chỉnh biểu diễn ảnh và bệnh sử lâm sàng, sau đó tiếp tục tối ưu các adapter LoRA cùng mô-đun dung hợp trong Giai đoạn 2. Cách thiết kế này cho phép thích nghi mô hình BioMedCLIP với dữ liệu X-quang xương trong khi chỉ cập nhật một phần nhỏ tổng số tham số.

4. **Bộ phân loại dựa trên tâm lớp thực nghiệm:** Xây dựng bộ phân loại phi tham số sử dụng độ tương đồng cosine đến các tâm lớp được ước lượng lại từ biểu diễn của tập huấn luyện. Trong Giai đoạn 2, mô hình được tối ưu bằng Cross-Entropy có trọng số theo số mẫu hiệu dụng nhằm giảm ảnh hưởng của phân bố lớp mất cân bằng.
5. **Khung phát hiện dữ liệu ngoài phân phối:** Tích hợp quy trình phát hiện ngoài phân phối theo hướng hậu xử lý trên không gian biểu diễn đã học, hỗ trợ khoảng cách Mahalanobis, Cosine-kNN, Energy Score và khoảng cách đến mốc văn bản. Ngưỡng từ chối được hiệu chỉnh trên dữ liệu nội phân phối tách biệt trước khi đánh giá trên các bộ dữ liệu ngoài phân phối được xác định trước.
6. **Công cụ phân tích khả năng giải thích:** Xây dựng công cụ trích xuất bản đồ chú ý đặc thù theo lớp từ mô-đun chú ý chéo hai chiều, chiếu trọng số chú ý ngược về các vùng ảnh gốc thông qua bộ tái lấy mẫu không gian và định lượng mức độ tập trung trên vùng tổn thương được chú thích. Công cụ này hỗ trợ phân tích hành vi của mô hình, không được xem là bằng chứng thay thế cho đánh giá lâm sàng của bác sĩ.

1.8 Bố cục luận văn

Chương 1: Giới thiệu. Chương này cung cấp cái nhìn tổng quan về bối cảnh nghiên cứu, xác định rõ vấn đề cần giải quyết, mục tiêu, phương pháp tiếp cận và những đóng góp chính của đề tài. Đây là phần nền tảng định hướng cho toàn bộ nội dung khóa luận.

Chương 2: Các công trình nghiên cứu liên quan. Chương này tập trung hệ thống hóa các hướng tiếp cận đã được mô tả ở trên, làm tiền đề cho việc xây dựng giải pháp của khóa luận. Trọng tâm của chương là việc phân tích các kiến trúc mô hình ngôn ngữ trực quan cùng các chiến lược dung hợp đặc trưng đa phương thức. Bên cạnh đó, các kỹ thuật tinh chỉnh tối ưu và phương pháp nhận diện dữ liệu ngoài phân phối cũng được xem xét toàn diện, từ đó thiết lập cơ sở lý thuyết vững chắc và định vị rõ

ràng hướng giải quyết của đề tài so với các công trình đi trước.

Chương 3: Phương pháp đề xuất. Đây là chương trọng tâm mô tả chi tiết quy trình xây dựng hệ thống. Tại đây, nhóm sẽ trình bày cụ thể về kiến trúc mô hình được kế thừa, quy trình xử lý dữ liệu đầu vào (cả ảnh và văn bản), thiết kế các hàm mất mát, và chiến lược huấn luyện mô hình. Các sơ đồ khối và thuật toán sẽ được mô tả chi tiết để minh họa cho giải pháp.

Chương 4: Thực nghiệm và Kết quả. Chương này trình bày về bộ dữ liệu được sử dụng, thiết lập môi trường thực nghiệm và các chỉ số đánh giá. Kết quả thực nghiệm sẽ được phân tích, so sánh đối chiếu với các phương pháp khác để làm rõ ưu nhược điểm của mô hình đề xuất.

Chương 5: Kết luận và Hướng phát triển. Chương cuối cùng tổng kết lại những kết quả đạt được so với mục tiêu ban đầu, nhìn nhận những hạn chế còn tồn tại của hệ thống và đề xuất các hướng nghiên cứu tiếp theo để hoàn thiện và mở rộng ứng dụng trong tương lai.

Chương 2

Các công trình nghiên cứu liên quan

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ mô tả tổng quan các nghiên cứu về các mô hình nền tảng, các kỹ thuật tinh chỉnh hiệu quả tham số và phương pháp phát hiện dữ liệu ngoài phân phối, từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

2.1 Các mô hình nền tảng

2.1.1 Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu

Sự kết hợp giữa dữ liệu cận lâm sàng và báo cáo lâm sàng, lịch sử bệnh lý đã tạo ra những bước tiến lớn trong việc cải thiện độ chính xác của các mô hình chẩn đoán, đặc biệt là thông qua việc sử dụng văn bản để bù đắp những thiếu sót thông tin mà hình ảnh đơn thuần không thể cung cấp. Nghiên cứu của X. Mei [18] trong việc chẩn đoán COVID-19 là một minh chứng rõ nét: khi ảnh chụp CT ngực ở giai đoạn sớm có thể chưa biểu hiện bất thường, việc tích hợp thông tin lâm sàng thông qua mạng MLP với đặc trưng ảnh từ CNN đã giúp mô hình nhận diện chính xác 68% số

bệnh nhân dương tính mà các bác sĩ X-quang đã bỏ sót. Mô hình TieNet [26] đã mã hóa các báo cáo y tế và tích hợp các cơ chế chú ý đa cấp để giống hàng các từ mang ý nghĩa quan trọng với các vùng ảnh tương ứng, cải thiện trung bình 6% chỉ số AUC so với các mô hình chỉ dùng ảnh. Gần đây, IRENE [40] đưa tất cả dữ liệu về một dạng token chung và sử dụng một mô hình Transformer duy nhất, cho phép văn bản trực tiếp tương tác và giải thích các token của ảnh ở cấp độ cục bộ.

Nhìn chung, những nghiên cứu này minh chứng rằng sự đóng góp của văn bản đã đi từ việc chỉ là một véc-tơ thông tin ghép nối thêm, trở thành một thành phần cốt lõi có khả năng giống hàng ngữ nghĩa và định hướng trong cơ chế chú ý. Tuy nhiên, các mô hình xây dựng từ đầu thường đòi hỏi dữ liệu ghép cặp quy mô lớn và chi phí huấn luyện cao, tạo tiền đề cho sự xuất hiện của các mô hình ngôn ngữ trực quan y khoa.

2.1.2 Mô hình ngôn ngữ trực quan y khoa (Med-VLMs)

Các mô hình ngôn ngữ trực quan đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu, Med-VLMs kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Chiến lược **học tương phản (Contrastive Learning)** là hướng tiếp cận được ứng dụng rộng rãi nhất và có liên quan trực tiếp đến phương pháp đề xuất trong luận văn. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh – văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau.

ConVIRT [36] là nghiên cứu tiên phong áp dụng học tương phản cho

dữ liệu y khoa, sử dụng ResNet50 và BERT để tối ưu bộ mã hóa ảnh và văn bản, đạt 90,3% accuracy trên bộ dữ liệu COVIDx. GLoRIA [10] mở rộng hướng tiếp cận này bằng cách kết hợp hai hàm mất mát toàn cục (global contrastive) và cục bộ (local contrastive), cho phép căn chỉnh chi tiết giữa các vùng trong ảnh và các từ trong câu. MedCLIP [27] đề xuất cơ chế tách cặp và trích xuất tri thức cùng hàm mất mát Semantic Matching nhằm giải quyết vấn đề âm tính giả (false negative) — khi các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý. BiomedCLIP [34] kế thừa kiến trúc CLIP với bộ mã hóa ViT-Base và PubMedBERT, được tiền huấn luyện trên 15 triệu cặp dữ liệu từ tập PMC-15M, đạt độ chính xác phân loại 83%.

Ngoài học tương phản, các hướng tiếp cận khác bao gồm **học có che giấu (Masked Learning)** và **tích hợp tri thức y khoa (Knowledge Integration)**. Tuy nhiên, các phương pháp này thường phụ thuộc vào nguồn dữ liệu ghép cặp sẵn hoặc đồ thị tri thức chuyên biệt, hạn chế khả năng ứng dụng trên các bài toán không có sẵn nguồn tri thức ngoài.

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Phương pháp			
			Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	Học tương phản	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	Học tương phản	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	Học tương phản	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	Học tương phản	ViT-Base	PubMedBERT	Contrastive Alignment	N/a

Bảng 2.1: Bảng tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản.

Song song với các Med-VLMs, sự phát triển của các mô hình ngôn ngữ lớn (LLMs) đa phương thức như Med-Flamingo [20], LLaVA-Med [14] hay Med-PaLM M [25] đã cho thấy tiềm năng trong các tác vụ hội thoại và hỗ trợ ra quyết định y khoa. Tuy nhiên, các mô hình này thường có quy mô rất lớn, chi phí huấn luyện và suy luận cao, đồng thời vẫn tồn tại nguy cơ tạo ra thông tin không chính xác (hallucination). Do đó, đối với các bài toán phân loại chuyên biệt như phân loại ảnh X-quang xương, việc sử dụng các mô hình ngôn ngữ – thị giác chuyên dụng kết hợp tinh chỉnh hiệu

quả tham số thường phù hợp và hiệu quả hơn.

2.2 Các kỹ thuật tinh chỉnh hiệu quả tham số

Sự xuất hiện của các Mô hình Nền tảng (Foundation Models) nói chung và Mô hình Ngôn ngữ – Thị giác Y sinh (Med-VLMs) nói riêng đã mang lại một nền tảng tri thức đa phương thức khổng lồ. Tuy nhiên, để triển khai hiệu quả các mô hình này vào các bài toán lâm sàng đặc thù, quá trình chuyển giao tri thức là bắt buộc.

Trước đây, hai chiến lược phổ biến nhất là tinh chỉnh toàn phần (Full Fine-tuning) và dò tuyến tính (Linear Probing). Tinh chỉnh toàn phần cập nhật lại toàn bộ tham số của mô hình gốc, mang lại khả năng thích ứng cao nhưng đòi hỏi chi phí tính toán, bộ nhớ khổng lồ và rất dễ dẫn đến hiện tượng “quên thảm khốc” (catastrophic forgetting) trên các tập dữ liệu y tế nhỏ. Ngược lại, dò tuyến tính đóng băng toàn bộ mạng nơ-ron gốc và chỉ huấn luyện một lớp phân loại duy nhất ở cuối, tiết kiệm tài nguyên nhưng hạn chế khả năng thích ứng khi sự chênh lệch phân phối (domain shift) giữa dữ liệu gốc và dữ liệu y tế là quá lớn.

Để giải quyết bài toán đánh đổi giữa hiệu năng và chi phí tính toán, Tinh chỉnh Hiệu quả Tham số (Parameter-Efficient Fine-Tuning – PEFT) đã nổi lên như một giải pháp thay thế. Kỹ thuật này chỉ cập nhật hoặc thêm mới một lượng rất nhỏ tham số, giúp tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các phương pháp PEFT được chia thành ba hướng tiếp cận chính:

2.2.1 Tinh chỉnh sử dụng câu nhắc (Prompt Tuning)

Hướng tiếp cận này chèn thêm các tham số (vector) có thể học được vào không gian đầu vào của mô hình mà không thay đổi cấu trúc mạng bên trong.

- **Điểm mạnh:** Tiết kiệm tham số tối đa, bảo toàn nguyên vẹn tri thức của mô hình gốc, đặc biệt hiệu quả trong các kịch bản học ít mẫu (few-shot) hoặc không mẫu (zero-shot).
- **Điểm yếu:** Tối ưu hóa khó khăn do không gian biểu diễn bị giới hạn ở đầu vào, nhạy cảm với cách khởi tạo, và chiếm dụng một phần độ dài của chuỗi đầu vào.

Trong lĩnh vực y tế, PLIP [33] kết hợp đặc trưng thị giác với câu nhắc hiệu quả, đạt 0,896 AUC chỉ với 5% dữ liệu PanNuke. BiomedCoOp [12] tích hợp mô hình ngôn ngữ lớn để tự động sinh các câu nhắc ngữ nghĩa, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản.

2.2.2 Tinh chỉnh bộ điều hợp (Adapter Tuning)

Phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ (adapters) vào giữa các lớp kiến trúc của mạng học sâu.

- **Điểm mạnh:** Tính mô-đun hóa cao, dễ dàng thêm/bớt các adapter cho các tác vụ khác nhau mà không can thiệp vào tham số gốc.
- **Điểm yếu:** Việc chèn thêm các lớp mạng vật lý làm tăng độ trễ suy luận (inference latency), hạn chế khả năng triển khai trên các hệ thống đòi hỏi thời gian thực.

Điển hình, CLIPath [13] sử dụng kết nối thặng dư để giảm khoảng cách miền trên dữ liệu nhỏ. FTB [21] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức.

2.2.3 Tinh chỉnh chọn lọc (Selective Tuning)

Hướng đi này không thêm bất kỳ tham số mới nào, mà chỉ chọn lọc ra một lượng nhỏ các tham số quan trọng nhất của mô hình gốc để cập nhật.

- **Điểm mạnh:** Không làm thay đổi kiến trúc mô hình, hoàn toàn không gây tăng độ trễ (zero inference latency) do tham số cập nhật được hợp nhất trực tiếp vào trọng số gốc.
- **Điểm yếu:** Đòi hỏi phương pháp heuristic phức tạp để xác định chính xác các tham số nào ảnh hưởng lớn nhất đến hiệu năng của tác vụ mục tiêu.

Nổi bật nhất trong nhóm này là cơ chế thích ứng hạng thấp LoRA (Low-Rank Adaptation). LoRA đóng băng toàn bộ trọng số của mô hình tiền huấn luyện, đồng thời tiêm các ma trận phân rã hạng thấp vào các khối Attention. LCBB [16] áp dụng LoRA và đạt 93,1% AUROC trên tập RSNA với chỉ 10% dữ liệu gán nhãn, bám sát hiệu năng của tinh chỉnh toàn phần nhưng giảm thiểu tối đa chi phí.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Nguyên lý	Kết quả nổi bật
1	PLIP (2024)	Prompt Tuning	Kết hợp câu nhắc thị giác với selective tuning, tận dụng đặc trưng hình ảnh để tinh chỉnh hiệu quả	0,896 AUC (5% PanNuke)
2	CLIPath (2023)	Adapter Tuning	Sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu mô bệnh học	Cải thiện so với CLIP trên dữ liệu nhỏ
3	LCBB (2024)	Selective Tuning (LoRA)	Áp dụng LoRA vào bộ mã hóa thị giác, giữ nguyên hiệu năng tinh chỉnh toàn phần	93,1% AUROC (RSNA, 10%)
4	FTB (2024)	Adapter Tuning	Mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản, chất lọc thông tin đa phương thức	Cải thiện trên CheXpert, RSNA

Bảng 2.2: Bảng tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện cho các mô hình ngôn ngữ trực quan y khoa.

2.3 Các phương pháp phát hiện dữ liệu ngoài phân phối

Phát hiện dữ liệu ngoài phân phối (Out-of-Distribution Detection – OOD Detection) là bài toán xác định các mẫu dữ liệu không thuộc phân phối của tập huấn luyện nhằm nâng cao độ tin cậy và tính an toàn của các hệ thống học sâu. Trong lĩnh vực chẩn đoán hình ảnh y khoa, khả năng phát hiện các trường hợp chưa từng xuất hiện hoặc khác biệt đáng kể so với dữ liệu huấn luyện có ý nghĩa quan trọng nhằm giảm nguy cơ đưa ra các dự đoán sai với độ tin cậy cao. Các phương pháp OOD hiện nay có thể được chia thành các nhóm chính sau đây.

2.3.1 Các phương pháp hậu xử lý dựa trên đầu ra mô hình (Post-hoc Methods)

Nhóm phương pháp này tận dụng trực tiếp đầu ra của một mô hình đã được huấn luyện mà không cần thay đổi kiến trúc hoặc huấn luyện lại mô hình.

- **Maximum Softmax Probability (MSP):** Sử dụng xác suất Softmax lớn nhất làm độ tin cậy của dự đoán. Các mẫu có xác suất cực đại thấp được xem là ứng viên OOD. Tuy nhiên, các mạng nơ-ron sâu thường có xu hướng dự đoán quá tự tin (overconfidence), làm giảm hiệu quả của phương pháp.
- **ODIN (Out-of-Distribution detector for Neural Networks):** Mở rộng MSP bằng cách kết hợp Temperature Scaling và nhiễu đầu vào (input perturbation) nhằm gia tăng khoảng cách logit giữa dữ liệu trong phân phối (In-Distribution – ID) và dữ liệu OOD.
- **Energy-based Score:** Thay vì sử dụng xác suất Softmax, phương pháp này sử dụng giá trị năng lượng được tính từ vector logit:

$$E(x) = -T \log \sum_i \exp \left(\frac{f_i(x)}{T} \right),$$

trong đó $f_i(x)$ là logit của lớp thứ i và T là hệ số nhiệt độ. Dữ liệu ID thường có mức năng lượng thấp hơn so với dữ liệu OOD.

2.3.2 Các phương pháp dựa trên không gian đặc trưng (Feature-space-based Methods)

Khác với các phương pháp chỉ sử dụng đầu ra của mô hình, nhóm phương pháp này thực hiện phát hiện OOD trực tiếp trên không gian đặc trưng (embedding space). Ý tưởng chính là đo khoảng cách giữa embedding

của mẫu kiểm thử và phân bố đặc trưng của dữ liệu huấn luyện. Một số độ đo khoảng cách phổ biến bao gồm:

- **Khoảng cách Euclidean:**

$$d_E(z, c_k) = \|z - c_k\|_2.$$

Khoảng cách Euclidean giả định các cụm dữ liệu có dạng cầu và có phương sai đồng đều theo mọi chiều. Phương pháp đơn giản nhưng không phản ánh được sự tương quan giữa các chiều đặc trưng.

- **Khoảng cách Cosine:**

$$d_C(z, c_k) = 1 - \frac{z \cdot c_k}{\|z\| \|c_k\|}.$$

Khoảng cách Cosine chỉ xét hướng của vector đặc trưng và bỏ qua độ lớn (magnitude), thường được sử dụng trong các bài toán metric learning và Vision-Language Models.

- **Khoảng cách Mahalanobis:**

$$d_M(z, c_k) = \sqrt{(z - c_k)^T \Sigma_k^{-1} (z - c_k)},$$

trong đó Σ_k là ma trận hiệp phương sai của lớp k . Khác với Euclidean và Cosine, Mahalanobis khai thác thêm thông tin về phương sai và tương quan giữa các chiều đặc trưng, nhờ đó phản ánh chính xác hơn mức độ bất thường của mẫu kiểm thử đối với phân bố của từng lớp, đặc biệt trong các trường hợp Near-OOD.

2.3.3 Các phương pháp học biểu diễn phục vụ phát hiện OOD (Representation Learning)

Các phương pháp trong nhóm này không trực tiếp thực hiện phát hiện OOD mà tập trung xây dựng không gian đặc trưng có tính phân biệt cao,

từ đó nâng cao hiệu quả của các phương pháp phát hiện OOD dựa trên khoảng cách. Một số hướng tiếp cận tiêu biểu gồm:

- **Contrastive Learning:** Học biểu diễn bằng cách kéo gần các mẫu tương đồng và đẩy xa các mẫu khác lớp trong không gian đặc trưng.
- **Center Loss:** Giảm phương sai nội lớp bằng cách học một tâm biểu diễn cho mỗi lớp và ép các embedding tiến gần tâm tương ứng.
- **Prototypical Loss:** Biểu diễn mỗi lớp bởi một nguyên mẫu (prototype), được tính bằng trung bình embedding của các mẫu cùng lớp:

$$c_k = \frac{1}{|S_k|} \sum_{x_i \in S_k} f_{\theta}(x_i).$$

Trong quá trình huấn luyện, embedding của các mẫu được kéo về prototype của lớp tương ứng và tách xa prototype của các lớp khác, giúp giảm phương sai nội lớp và tăng khoảng cách giữa các lớp. Nhờ đó, không gian đặc trưng trở nên phân biệt hơn, tạo điều kiện thuận lợi cho các phương pháp OOD dựa trên khoảng cách như Mahalanobis.

2.3.4 Các phương pháp sinh và định lượng độ không chắc chắn

Nhóm phương pháp này tiếp cận bài toán OOD thông qua khả năng mô hình hóa phân phối dữ liệu hoặc ước lượng độ không chắc chắn của mô hình.

- **Reconstruction Error:** Các mô hình Autoencoder hoặc Variational Autoencoder được huấn luyện để tái tạo dữ liệu ID. Khi gặp dữ liệu OOD, sai số tái tạo thường tăng lên đáng kể.
- **Monte Carlo Dropout:** Thực hiện nhiều lần suy luận với Dropout được kích hoạt trong giai đoạn kiểm thử nhằm ước lượng độ không chắc chắn nhận thức (epistemic uncertainty). Phương sai lớn giữa các lần dự đoán là dấu hiệu cho thấy mẫu có khả năng thuộc OOD.

2.4 Bàn luận

2.4.1 Xu hướng ứng dụng học sâu đa phương thức trong chẩn đoán ảnh y khoa

Qua khảo sát các công trình nghiên cứu, có thể nhận thấy rằng học sâu đa phương thức đang trở thành xu hướng quan trọng trong lĩnh vực chẩn đoán ảnh y khoa. Thay vì chỉ khai thác thông tin từ ảnh y khoa, nhiều nghiên cứu đã kết hợp thêm dữ liệu văn bản như báo cáo chẩn đoán, tiền sử bệnh hoặc thông tin lâm sàng nhằm tận dụng tính bổ sung giữa các phương thức dữ liệu.

Song song với đó, sự xuất hiện của các mô hình ngôn ngữ trực quan y khoa như BiomedCLIP [34] đã mở ra hướng tiếp cận mới cho các bài toán phân loại ảnh y khoa. Nhờ được tiền huấn luyện trên tập dữ liệu ảnh – văn bản quy mô lớn, các mô hình này học được biểu diễn đa phương thức giàu ngữ nghĩa và có khả năng thích nghi tốt với nhiều tác vụ khác nhau. Kết hợp với các phương pháp tinh chỉnh hiệu quả tham số, việc khai thác các mô hình nền tảng trở nên khả thi hơn ngay cả khi dữ liệu huấn luyện còn hạn chế.

2.4.2 Hạn chế của các nghiên cứu hiện nay

Mặc dù đạt được nhiều kết quả tích cực, các nghiên cứu hiện nay vẫn tồn tại một số hạn chế khi áp dụng vào bài toán phân loại ảnh X-quang xương.

Thứ nhất, phần lớn các nghiên cứu được phát triển trên các bộ dữ liệu X-quang ngực hoặc các bệnh lý phổ biến, trong khi số lượng nghiên cứu dành riêng cho ảnh X-quang xương và các bệnh lý xương vẫn còn hạn chế. Đặc điểm của các tổn thương xương thường đa dạng, số lượng mẫu ít và có sự mất cân bằng giữa các lớp, khiến việc xây dựng mô hình có khả năng tổng quát tốt trở nên khó khăn hơn.

Thứ hai, nhiều phương pháp đa phương thức chỉ khai thác báo cáo đọc ảnh hoặc mô tả ngắn đi kèm ảnh mà chưa tận dụng đầy đủ các thông tin

lâm sàng như triệu chứng, tiền sử bệnh hoặc cơ chế chấn thương. Trong thực tế lâm sàng, đây đều là những nguồn thông tin quan trọng giúp bác sĩ đưa ra chẩn đoán chính xác hơn.

Thứ ba, mặc dù các mô hình nền tảng đạt hiệu quả cao, nhiều nghiên cứu vẫn lựa chọn tinh chỉnh toàn bộ tham số của mô hình. Cách tiếp cận này đòi hỏi chi phí tính toán lớn, đồng thời làm tăng nguy cơ quên tri thức đã được học trong giai đoạn tiền huấn luyện.

Cuối cùng, hầu hết các nghiên cứu chỉ tập trung tối ưu hiệu năng phân loại mà chưa quan tâm đầy đủ đến khả năng phát hiện dữ liệu ngoài phân phối. Trong môi trường lâm sàng, mô hình có thể gặp các trường hợp bệnh lý hiếm, dữ liệu có chất lượng thấp hoặc các bất thường chưa xuất hiện trong tập huấn luyện. Nếu không có cơ chế phát hiện OOD, mô hình vẫn có thể đưa ra dự đoán với độ tin cậy cao mặc dù kết quả không chính xác.

2.4.3 Cơ sở lựa chọn và định hướng phương pháp đề xuất

Từ những hạn chế trên, luận văn lựa chọn xây dựng hệ thống dựa trên việc kế thừa mô hình BiomedCLIP [34] kết hợp với thông tin lâm sàng để khai thác đồng thời đặc trưng hình ảnh và văn bản. Các lựa chọn thiết kế cụ thể được đưa ra dựa trên phân tích sau:

Về kỹ thuật tinh chỉnh: Kỹ thuật QLoRA được lựa chọn thay vì tinh chỉnh toàn phần hoặc các phương pháp tinh chỉnh hiệu quả tham số khác, vì ba lý do chính:

- QLoRA giảm số lượng tham số cần huấn luyện xuống đáng kể bằng cách tiêm các ma trận phân rã hạng thấp vào mạng nơ-ron, cho phép tinh chỉnh các mô hình VLM ngay cả khi nguồn lực tính toán bị hạn chế.
- Khác với Adapter Tuning chèn thêm các lớp ẩn vật lý làm chậm tốc độ xử lý, các ma trận trọng số của QLoRA có thể được cộng gộp trực tiếp vào trọng số gốc, giúp không tăng độ trễ trong lúc suy luận.
- QLoRA cho phép mô hình bám sát dữ liệu y tế đặc thù trong khi

không phá vỡ các cấu trúc tri thức đa phương thức tổng quát đã được tiền huấn luyện.

Về phương pháp phát hiện OOD: Luận văn kết hợp Prototypical Loss [`<empty citation>`] và Mahalanobis Distance theo cơ chế hai giai đoạn tách biệt. Trong giai đoạn huấn luyện, Prototypical Loss được sử dụng để xây dựng không gian đặc trưng có tính phân biệt cao thông qua việc giảm phương sai nội lớp và tăng khoảng cách giữa các lớp. Sau khi mô hình được huấn luyện, Mahalanobis Distance được áp dụng theo cơ chế post-hoc để phát hiện dữ liệu ngoài phân phối. Mahalanobis được lựa chọn thay vì Euclidean hoặc Cosine vì có khả năng khai thác thêm thông tin về ma trận hiệp phương sai của từng lớp, phản ánh chính xác hơn mức độ bất thường của mẫu, đặc biệt đối với các trường hợp Near-OOD thường gặp trong dữ liệu y khoa.

Về kiến trúc pipeline: Hệ thống được thiết kế theo kiến trúc hai giai đoạn :

- **Giai đoạn 1 – Căn chỉnh tương phản:** Chỉ huấn luyện backbone (BiomedCLIP thông qua LoRA) bằng hàm mất mát tương phản, giúp backbone thích ứng với miền dữ liệu y khoa chuyên biệt. Mô-đun dung hợp và bộ phân loại được đóng băng trong giai đoạn này.
- **Giai đoạn 2 – Huấn luyện dung hợp và phân loại:** Backbone được đóng băng hoàn toàn, chỉ huấn luyện mô-đun dung hợp đa phương thức (cross-attention) và bộ phân loại (prototypical head). Thiết kế này tách biệt quá trình thích ứng backbone khỏi quá trình học phân loại, giảm thiểu rủi ro quá khớp.

Kiến trúc chi tiết của hệ thống cùng quy trình huấn luyện và đánh giá sẽ được trình bày trong Chương 3.

Chương 3

Phương pháp đề xuất

3.1 Tổng quan phương pháp đề xuất

Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế với khả năng học trong điều kiện ít mẫu và phát hiện dữ liệu ngoài phân phối. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Bộ mã hóa ảnh:** Kế thừa ViT-Base của BiomedCLIP [34], kết hợp nhánh ảnh toàn cục và lưới lát cục bộ độ phân giải cao.
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [34]
- **Bộ dung hợp dữ liệu:** Kỹ thuật Bidirectional Cross-Attention được xây dựng dựa trên cơ chế cross-attention nhằm học mối quan hệ ngữ nghĩa giữa đặc trưng hình ảnh và đặc trưng văn bản y khoa.
- **Bộ phân loại:** Dùng empirical centroid head không tham số; nhãn được quyết định bởi độ tương đồng cosine với trung tâm lớp tính trực tiếp từ embedding của tập train. Đặc trưng dung hợp đồng thời được dùng để hiệu chuẩn điểm OOD hậu xử lý trên tập validation.

Đồng thời, các trọng số attention được khai thác để trực quan hóa và giải thích kết quả dự đoán.

3.2 Pipeline cuối cùng

Để tránh lựa chọn mô hình hậu nghiệm theo kết quả kiểm thử, nghiên cứu cố định XBone-Net trước khi thực hiện các thí nghiệm rời rạc. Pipeline cuối cùng gồm các bước sau:

1. **Tiền xử lý ảnh độ phân giải cao:** pipeline loại bỏ vùng đệm máy chụp bằng quy tắc bảo toàn năng lượng tương phản thận trọng, tạo một global view giữ nguyên tỉ lệ và chọn đúng bốn local view 224×224 . Hai vùng bảo đảm độ phủ theo trục giải phẫu chính và hai vùng focal được chọn bằng năng lượng texture kết hợp phạt chồng lấp; toàn bộ quy trình chỉ dùng tín hiệu ảnh, không dùng nhãn, hộp tổn thương hay mô hình đề xuất vùng.
2. **Mã hóa đa tỉ lệ:** BiomedCLIP trích xuất một đặc trưng ảnh toàn cục và token cục bộ từ bốn vùng sparse-focal. Mỗi vùng giữ lại CLS token đã được tiền huấn luyện và một patch-summary token, tạo ngân sách cố định tám token. Bộ resampler nhẹ truyền trực tiếp các token này, đồng thời bổ sung embedding tọa độ đã chuẩn hóa qua một cổng vô hướng bị chặn để thông tin vị trí không lẫn át nội dung. Trong khi huấn luyện, gradient từ nhánh local được truyền vào visual LoRA; activation của từng nhóm tile được tính lại khi backward bằng gradient checkpointing để giới hạn bộ nhớ.
3. **Pha 1 – căn chỉnh ngữ nghĩa:** Vision Encoder và Text Encoder được thích nghi bằng LoRA với cặp ảnh–bệnh sử lâm sàng. Hàm Semantic Matching Loss sử dụng quan hệ đồng lớp làm mục tiêu mềm. Báo cáo kết quả X-quang không được dùng vì có nguy cơ chứa trực tiếp tên bệnh.
4. **Pha 2 – dung hợp và phân loại:** các LoRA adapter được giữ ở dạng tách rời và tiếp tục được tối ưu cùng bộ chú ý chéo hai chiều. Đầu empirical centroid được tính từ toàn bộ embedding train và không được cập nhật bởi optimizer. Hàm mục tiêu chỉ là Cross-Entropy có trọng số theo effective number.

5. **Suy luận và phát hiện OOD:** ảnh X-quang và bệnh sử lâm sàng đi qua đúng nhánh tiền xử lý và dung hợp của pha 2. Nhãn ID được xác định bởi empirical centroid có độ tương đồng lớn nhất; điểm OOD được hiệu chuẩn hậu xử lý trên đặc trưng dung hợp của tập validation, không dùng mẫu test để chọn ngưỡng.


Trọng số LoRA không được hợp nhất vào backbone sau pha 1 trong pipeline cuối cùng, vì thao tác này đồng thời làm mất khả năng tiếp tục thích nghi backbone ở pha 2. Phiên bản hợp nhất và đóng băng được giữ như một thí nghiệm rời rạc về chiến lược tối ưu.

3.3 Giai đoạn huấn luyện

Giai đoạn huấn luyện nhằm xây dựng bộ tham số cho mô hình, thiết lập không gian biểu diễn chung và học cách dung hợp giữa đặc trưng hình ảnh X-quang và ngữ nghĩa y khoa.

Giai đoạn huấn luyện gồm hai công đoạn: thích nghi miền (domain adaptation) và tinh chỉnh có giám sát. Công đoạn thứ nhất giúp mô hình thích nghi từ miền dữ liệu tiền huấn luyện sang ảnh X-quang xương; công đoạn thứ hai tối ưu đồng thời biểu diễn, dung hợp đa phương thức và phân loại trên tập dữ liệu mục tiêu.

3.3.1 Học biểu diễn với kỹ thuật LoRA



Hình 3.1: Sơ đồ chung của hệ thống trong công đoạn học biểu diễn.

Trong công đoạn này, mô hình học biểu diễn để các cặp ảnh X-quang và bệnh sử lâm sàng tương ứng nằm gần nhau trong không gian chung bằng hàm mất mát khớp ngữ nghĩa (Semantic Matching Loss). Việc dùng cùng nguồn văn bản clinical ở cả hai pha bảo đảm nhất quán giữa huấn luyện và suy luận, đồng thời loại bỏ báo cáo kết quả X-quang có nguy cơ rò rỉ nhãn. Dữ liệu được đưa vào hai bộ mã hóa, chiếu vào không gian chung và chuẩn hóa trước khi tính độ tương đồng. Các mẫu cùng lớp tạo thành cụm ngữ nghĩa, trong khi các mẫu khác lớp được tách biệt.

Nhóm thực hiện tinh chỉnh (fine-tuning) đồng thời Vision Encoder và Text Encoder bằng kỹ thuật LoRA (Low-Rank Adaptation). LoRA được lựa chọn vì đây là phương pháp tinh chỉnh hiệu quả về tham số, cho phép thích nghi BioMedCLIP với miền ảnh X-quang xương mà vẫn bảo toàn tri thức tiền huấn luyện.

Mặc dù nghiên cứu sử dụng toàn bộ dữ liệu hiện có, nhiều lớp vẫn chỉ

chứa số lượng mẫu rất ít. Do đó, bài toán ở cấp độ từng lớp mang đặc tính few-shot, và LoRA giúp hệ thống duy trì khả năng thích nghi tốt trong các trường hợp này. Nghiên cứu lựa chọn LoRA thay vì QLoRA vì mục tiêu chính là thích nghi miền hiệu quả trong điều kiện dữ liệu hạn chế, thay vì tối ưu bộ nhớ cho các mô hình siêu lớn. BioMedCLIP có quy mô tham số vừa phải, cho phép huấn luyện hiệu quả với LoRA trên phần cứng hiện có mà không cần lượng tử hóa. Ngoài ra, việc giữ nguyên trọng số ở độ chính xác đầy đủ giúp bảo toàn các đặc trưng hình ảnh tinh vi của ảnh X-quang xương, vốn rất quan trọng đối với việc nhận diện các tổn thương nhỏ và các lớp hiếm.

Để cập nhật trọng số của ma trận LoRA, nhóm sử dụng **Hàm mất mát Khớp ngữ nghĩa (Semantic Matching Loss - $\mathcal{L}_{SM}$)** nhằm đồng bộ hóa không gian biểu diễn đa phương thức. Loss tương phản gốc của BioMedCLIP (InfoNCE) giả định quan hệ một-một giữa ảnh và văn bản. Giả định này chưa phù hợp khi nhiều bệnh nhân thuộc cùng một lớp bệnh có các mô tả lâm sàng khác nhau nhưng vẫn chia sẻ nội dung ngữ nghĩa liên quan đến lớp.

Vì vậy, nghiên cứu thay thế mục tiêu một-một bằng Semantic Matching Loss nhằm khai thác quan hệ đồng lớp giữa ảnh và văn bản, qua đó giảm ảnh hưởng của các cặp âm tính giả. Semantic Matching Loss không trực tiếp xử lý mất cân bằng dữ liệu; ở pha phân loại đa lớp, nghiên cứu sử dụng Cross-Entropy có trọng số theo effective number và label smoothing để tăng ảnh hưởng của các lớp hiếm.

Mức độ tương đồng Cosine giữa đặc trưng ảnh z_i^I và đặc trưng văn bản z_j^T :

$$\text{sim}(z_i^I, z_j^T) = \frac{z_i^I \cdot z_j^T}{\|z_i^I\| \|z_j^T\|} \quad (3.1)$$

Hàm mất mát được sử dụng là Semantic Matching Loss $\mathcal{L}_{SM}$ được định nghĩa dựa trên ma trận mục tiêu mềm s_{ij} :


$$\mathcal{L}_{SM} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N s_{ij} \log \frac{\exp(\text{sim}(z_i^I, z_j^T)/\tau)}{\sum_{k=1}^N \exp(\text{sim}(z_i^I, z_k^T)/\tau)} \quad (3.2)$$

trong đó, N là kích thước mini-batch, s_{ij} là ma trận mục tiêu xác định

các mẫu chung lớp, và τ là siêu tham số nhiệt độ (temperature) giúp điều chỉnh độ nhạy của hàm phạt đối với các mẫu âm tính (negative samples). Bằng cách tối ưu $\mathcal{L}_{SM}$, mô hình đẩy các đặc trưng giải phẫu X-quang cục bộ hội tụ chặt chẽ về đúng định nghĩa y khoa của chúng trong không gian chung.

Công đoạn thích nghi miền giúp các cặp ảnh và bệnh sử lâm sàng cùng lớp hội tụ trong không gian biểu diễn, thay vì xem mọi cặp không trùng chỉ số là âm tính như mục tiêu tương phản một-một. Trong pha 1, đạo hàm từ $\mathcal{L}_{SM}$ cập nhật các ma trận $A \in \mathbb{R}^{r \times k}$ và $B \in \mathbb{R}^{d \times r}$ (với hạng $r \ll \min(d, k)$) của LoRA. Sang pha 2, các adapter này không bị hợp nhất hay đóng băng mà tiếp tục được tối ưu cùng mô-đun dung hợp và bộ phân loại.

3.3.2 Học phân loại đa lớp với empirical centroid head



Hình 3.2: Sơ đồ chung của hệ thống trong công đoạn học phân loại đa lớp.

Trong công đoạn này, nhóm tối ưu khả năng khai thác và dung hợp dữ liệu bằng kỹ thuật chú ý chéo hai chiều để học liên hệ giữa đặc trưng toàn

cục của ảnh X-quang với token cục bộ của bệnh sử lâm sàng và giữa đặc trưng toàn cục của văn bản với token ảnh cục bộ.

Đầu vào của công đoạn này là các cặp ảnh X-quang và bệnh sử lâm sàng. Hai hướng cross-attention lần lượt dùng token ảnh toàn cục làm query trên chuỗi token văn bản và token văn bản toàn cục làm query trên chuỗi token ảnh. Mỗi output attention được cộng residual với global query tương ứng rồi chuẩn hóa để tạo hai nhánh tăng cường h_I và h_T . Chỉ $[h_I; h_T]$ được nối và đưa qua MLP dung hợp $1024 \rightarrow 512 \rightarrow 512$ cùng LayerNorm để tạo vector 512 chiều trước đầu phân loại; raw global embeddings không được nối lại và không có learned skip ở tầng fusion cuối. Sai khác giữa dự đoán và nhãn thực tế cập nhật LoRA adapter, các phép chiếu, hai khối cross-attention và MLP dung hợp; các centroid không nhận gradient.

Sau quá trình dung hợp đa phương thức, mỗi mẫu train được biểu diễn bởi vector đặc trưng $z_i \in \mathbb{R}^D$. Với lớp k có N_k mẫu, trung tâm thực nghiệm được tính trực tiếp bằng trung bình embedding:

$$c_k = \frac{1}{N_k} \sum_{i:y_i=k} z_i. \quad (3.3)$$

Các c_k được lưu dưới dạng buffer, không phải *learnable parameter* và không nhận gradient. Centroid được khởi tạo từ toàn bộ tập train trước pha 2, tính lại sau mỗi epoch bằng encoder hiện tại trước khi đánh giá validation, và tính lại một lần cuối từ checkpoint encoder tốt nhất trước khi lưu mô hình. Trong từng epoch, centroid được giữ cố định để gradient của hàm phân loại chỉ cập nhật LoRA adapter và mô-đun dung hợp. Cách xây dựng này là empirical centroid classifier đúng nghĩa mà không yêu cầu episodic training.

Mức độ tương đồng giữa embedding z_i và từng centroid được tính bằng cosine trên các vector chuẩn hóa L_2 :

$$s(z_i, c_k) = \frac{z_i \cdot c_k}{\|z_i\|_2 \|c_k\|_2}. \quad (3.4)$$

Điểm tương đồng được nhân với hệ số tỷ lệ cố định $\alpha = 15$ nhằm điều chỉnh độ sắc nét của phân bố xác suất, sau đó đưa qua Softmax:


$$p_{ik} = \frac{\exp(\alpha s(z_i, c_k))}{\sum_{j=1}^K \exp(\alpha s(z_i, c_j))}. \quad (3.5)$$

Hàm mất mát duy nhất trong pha 2 là Cross-Entropy có trọng số lớp:

$$\mathcal{L}_{P2} = -\frac{1}{N} \sum_{i=1}^N w_{y_i} \log p_{i,y_i}, \quad (3.6)$$

trong đó y_i là nhãn đúng và w_k tỷ lệ nghịch với effective number $(1 - \beta^{N_k})/(1 - \beta)$ của lớp k , sau đó được chuẩn hóa để trung bình trọng số của các lớp hiện diện bằng 1. Pipeline cuối cùng dùng $\beta = 0,999$ và không dùng label smoothing. Pull-push Prototypical Loss, margin và hệ số λ bị loại bỏ vì chúng tối ưu các prototype tham số thay vì phản ánh đúng định nghĩa empirical centroid. Mỗi lớp cấu hình phải xuất hiện trong train subset; với few-shot, bộ chia dữ liệu phải lấy đúng k mẫu cho từng lớp trước khi tính centroid.

3.4 Giai đoạn online



Hình 3.3: Sơ đồ chung của hệ thống trong giai đoạn online.

Sơ đồ của hệ thống trong giai đoạn online được trình bày trong Hình 3.3. Ảnh X-quang được đưa qua cùng nhánh ảnh toàn cục và lưới lát độ phân giải cao như khi huấn luyện; bệnh sử lâm sàng được mã hóa bởi nhánh văn bản. Hai nguồn đặc trưng được dung hợp bằng cross-attention hai chiều và MLP trước khi so sánh với các empirical centroid đã lưu để dự đoán nhãn bệnh lý. Song song, đặc trưng dung hợp được chấm điểm OOD bằng bộ phát hiện đã hiệu chuẩn trên tập validation; mẫu vượt ngưỡng được đánh dấu là ngoài phân phối thay vì chỉ dựa vào xác suất Softmax. Các trọng số attention có thể được chiếu ngược về tọa độ ảnh nguồn để tạo bản đồ nhiệt hỗ trợ giải thích dự đoán.

3.5 Đóng góp của phương pháp

- **Cơ chế Cross-Attention có hướng dẫn tri thức:** Việc sử dụng cơ chế Cross-Attention có hướng dẫn tri thức giúp mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Điều này không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.
- **Cơ chế fusion ở nhiều cấp độ:** Việc kết hợp đặc trưng toàn cục và cục bộ thông qua Cross-Attention hai chiều và MLP dung hợp giúp mô hình khai thác tối đa dữ liệu và học được các mối liên hệ phức tạp giữa hai nguồn dữ liệu, từ đó cải thiện hiệu suất phân loại và khả năng giải thích của mô hình.
- **Giảm nguy cơ suy giảm không gian ngữ nghĩa trong bối cảnh dữ liệu hạn chế:** Cơ chế cập nhật tham số bằng LoRA giúp các bộ mã hóa thích nghi với dữ liệu y khoa đích mà không làm mất mát các tri thức đã học. Điều này giúp hạn chế hiện tượng overfitting và giảm độ phức tạp tính toán.
- **Cơ chế phát hiện dữ liệu ngoài phân phối:** Empirical centroid cung cấp tâm lớp nhất quán với embedding train, còn ngưỡng OOD được hiệu chuẩn hậu xử lý trên tập validation mà không sử dụng dữ liệu test.

Chương 4

Thực nghiệm

Trong quá trình thực nghiệm, nhóm tập trung vào việc đánh giá hiệu quả của mô hình đề xuất so với các backbone khác (ResNet-50, CLIP, MedCLIP, BiomedCLIP, PubMedCLIP) trên nhiệm vụ phân loại ảnh x-quang. Nhóm đã thiết lập một loạt các thí nghiệm để so sánh hiệu suất của các mô hình này, đồng thời thực hiện các thí nghiệm rời rạc để kiểm tra ảnh hưởng của việc sử dụng thông tin văn bản, các đóng góp của các thành phần đề xuất trong quá trình huấn luyện và đánh giá.

4.1 Mục đích thực nghiệm

Nhằm chứng minh cho các luận điểm mà nhóm đưa ra, đóng góp lý thuyết cũng như thực tiễn của mô hình đề xuất XBone-Net trên bài toán hỗ trợ chẩn đoán và phân loại đa lớp ảnh x-quang xương, nhóm nghiên cứu đã thiết lập một hệ thống các thí nghiệm thực nghiệm. Mỗi thí nghiệm được xây dựng nhằm xác thực một luận điểm cụ thể, giải quyết các thách thức của bài toán phân loại ảnh x-quang xương đa phương thức và kiểm chứng các cải tiến về mặt kiến trúc cũng như phương pháp huấn luyện hai pha.

4.1.1 Đánh giá so sánh hiệu năng chẩn đoán với các mô hình đối sánh

Mục đích chính của nhóm thí nghiệm này là đặt mô hình đề xuất XBone-Net vào mối tương quan so sánh đa chiều trực tiếp với các mô hình học sâu y khoa và mô hình ngôn ngữ trực quan (VLM) hiện nay. Thí nghiệm này nhằm chứng minh các luận điểm cốt lõi sau:

- Thách thức khoảng cách miền khi áp dụng trực tiếp các mô hình VLM y học tiền huấn luyện ở dạng Zero-shot mà không qua quá trình thích ứng hai pha.
- Sự vượt trội của việc kết hợp thông tin đa phương thức (ảnh chụp X-quang và văn bản bệnh sử lâm sàng) so với các phương pháp chỉ sử dụng thông tin hình ảnh thị giác đơn thuần (ResNet-50, DenseNet-121) trong việc phân biệt các lớp bệnh lý u xương có hình thái tương đồng.

4.1.2 Đánh giá khả năng phát hiện dữ liệu ngoài phân phối

Trong môi trường lâm sàng thực tế, mô hình phân loại có thể phải đối mặt với các hình ảnh X-quang không chứa khối u xương mà chứa các loại bệnh lý xương khớp khác (như gãy xương, viêm khớp, loãng xương) hoặc ảnh chụp từ các vùng giải phẫu không liên quan. Mục đích của thí nghiệm này là đánh giá độ tin cậy và an toàn y khoa của mô hình thông qua khả năng phát hiện dữ liệu ngoài phân phối thay vì đưa ra các chẩn đoán sai lệch. Thí nghiệm hướng đến việc kiểm chứng giả thuyết:

- Việc sử dụng đầu phân loại nguyên mẫu kết hợp học khoảng cách ở Pha 2 giúp tạo lập một không gian đặc trưng có cấu trúc cụm chặt chẽ hơn.
- Độ tương đồng cosine giữa vector đặc trưng của mẫu kiểm thử với các nguyên mẫu của lớp đã biết cung cấp một thước đo khoảng cách

đáng tin cậy để xác định ranh giới từ chối chẩn đoán, giúp phát hiện các mẫu ngoài phân phối.

4.1.3 Đánh giá vai trò của các nguồn thông tin văn bản lâm sàng

Thông tin văn bản y khoa có thể đến từ nhiều nguồn khác nhau trong quy trình chẩn đoán lâm sàng. Thí nghiệm này được thiết lập nhằm bóc tách đóng góp cụ thể của từng nguồn văn bản (báo cáo mô tả hình ảnh X-quang và báo cáo lâm sàng) đến kết quả phân loại cuối cùng. Mục đích cốt lõi của thí nghiệm này bao gồm:

- Phát hiện và ngăn chặn hiện tượng rò rỉ nhãn trong học máy đa phương thức y tế. Các báo cáo chẩn đoán X-quang cận lâm sàng thường chứa trực tiếp tên của bệnh lý (ví dụ: "osteosarcoma"). Nếu đưa báo cáo này vào huấn luyện, mô hình sẽ học cách đọc trực tiếp từ khóa này thay vì phân tích các dấu hiệu thị giác trên ảnh, dẫn đến việc mất đi giá trị chẩn đoán thực tế khi ứng dụng.
- Khẳng định giá trị lâm sàng thực tế của báo cáo tổng quát như tuổi tác, giới tính, vị trí sưng đau, tiền sử bệnh án. Đây là nguồn thông tin an toàn, không gây rò rỉ nhãn và đóng vai trò hỗ trợ đắc lực cho hình ảnh X-quang để đưa ra kết luận chẩn đoán chính xác nhất.

4.1.4 Đánh giá ảnh hưởng của chiến thuật tinh chỉnh backbone

Mục đích của nhóm thí nghiệm này là nghiên cứu và so sánh các chiến thuật cập nhật trọng số cho các bộ trích xuất đặc trưng bao gồm: đóng băng hoàn toàn, tinh chỉnh hiệu quả tham số và tinh chỉnh toàn bộ. Nhóm thí nghiệm hướng tới chứng minh hai luận điểm quan trọng:

- **Hiện tượng quên biểu diễn:** Xảy ra khi có sự không đồng nhất về mặt ngữ nghĩa giữa nguồn thông tin văn bản được sử dụng trong

Pha 1 học biểu diễn và Pha 2 học phân loại. Thí nghiệm nhằm chứng minh việc đồng bộ hóa nguồn văn bản lâm sàng ở cả hai pha sẽ bảo toàn không gian biểu diễn chung, tránh trôi lệch đặc trưng và nâng cao đáng kể hiệu năng chẩn đoán.

- **Quên tri thức gốc và Quá khớp:** Thí nghiệm kiểm chứng giả thuyết rằng việc áp dụng PEFT (QLoRA) kết hợp với quy trình huấn luyện hai pha sẽ giúp giữ lại các tri thức y khoa nền tảng mạnh mẽ đã học được ở giai đoạn tiền huấn luyện trên bộ dữ liệu quy mô lớn, ngăn chặn hiện tượng quên đặc trưng khi tinh chỉnh trên tập dữ liệu y sinh nhỏ so với Full Fine-Tuning.

4.1.5 Đánh giá hiệu quả của đầu phân loại nguyên mẫu so với đầu phân loại tuyến tính

Thí nghiệm này tập trung vào việc đánh giá so sánh hiệu năng của đầu phân loại nguyên mẫu, sử dụng khoảng cách để phân lớp, so với đầu phân loại tuyến tính truyền thống. Mục đích thực nghiệm là xác minh:

- Khả năng xây dựng ranh giới quyết định của phân loại nguyên mẫu trong không gian đặc trưng.
- Sự ổn định và khả năng chống chịu của đầu phân loại nguyên mẫu khi đối mặt với hiện tượng trôi lệch biểu diễn hoặc nhiễu dữ liệu. Bằng cách định hướng quá trình tối ưu kéo gần các đặc trưng cùng lớp về phía nguyên mẫu đại diện và đẩy xa các lớp khác thông qua hàm loss khoảng cách có khoảng lề, phân loại nguyên mẫu giúp ổn định ranh giới quyết định tốt hơn đầu tuyến tính.

4.1.6 Trực quan hóa bản đồ chú ý chéo và khả năng giải thích y khoa

Thí nghiệm này nhằm trực quan hóa các vùng chú ý của mô hình khi đưa ra quyết định phân loại, từ đó cung cấp khả năng giải thích lâm sàng và tính minh bạch cho các dự đoán của mô hình đề xuất XBone-Net. Mục đích thực nghiệm cụ thể bao gồm:

- **Đánh giá khả năng định vị tổn thương giải phẫu:** Xác minh xem vùng tập trung chú ý cao nhất của bản đồ chú ý chéo trích xuất từ mô-đun Cross-Attention Fusion có thực sự trùng khớp với phân vùng tổn thương thực tế được chú thích bởi các chuyên gia y tế trên ảnh X-quang hay không.
- **Kiểm chứng tương tác đa phương thức:** Chứng minh rằng thông tin từ bệnh sử lâm sàng dạng văn bản đóng vai trò dẫn đường hiệu quả, giúp mô hình tập trung vào các vùng giải phẫu đặc trưng của từng bệnh cảnh cụ thể trên ảnh X-quang, thay vì dựa vào các chi tiết nền không liên quan.
- **Củng cố độ tin cậy trong hỗ trợ chẩn đoán:** Chứng minh tính hợp lý về mặt y học của ranh giới quyết định, giúp các bác sĩ hiểu rõ cơ sở logic của mô hình khi đưa ra dự đoán chẩn đoán, từ đó tăng cường độ tin cậy trong các ứng dụng thực tế.

4.2 Chuẩn bị dữ liệu

Để minh chứng hiệu quả của mô hình đề xuất, nhóm đã sử dụng hai tập dữ liệu xương được thu thập từ bệnh viện chấn thương chỉnh hình và bộ dữ liệu BTXRD được công bố [31]. Các tập dữ liệu này bao gồm các hình ảnh xương cùng với các nhãn và mô tả bệnh lý tương ứng. Nhóm đã thực hiện các bước tiền xử lý dữ liệu, bao gồm chuẩn hóa hình ảnh và mã hóa nhãn, để đảm bảo tính nhất quán và chất lượng của dữ liệu trước khi đưa vào quá trình huấn luyện và đánh giá mô hình.

4.2.1 Bộ dữ liệu BTXRD

Bộ dữ liệu hình ảnh X-quang U xương (Bone Tumor X-ray Radiograph dataset - BTXRD) được xây dựng nhằm hỗ trợ cho các nghiên cứu về phân loại, định vị và phân vùng tự động các khối u xương nguyên phát trên ảnh X-quang. Bộ dữ liệu này bao gồm tổng cộng 3.746 hình ảnh, mỗi hình ảnh trong BTXRD đều được gắn nhãn với các thông tin lâm sàng bao gồm giới tính, độ tuổi, bộ phận cơ thể được chụp và góc chụp. Đặc biệt, mỗi hình ảnh chứa khối u còn được bổ sung thêm các nhãn phân loại lành tính hoặc ác tính, nhãn phân loại phụ, nhãn vị trí giải phẫu, cùng với mặt nạ phân vùng và hộp giới hạn được chú thích thủ công.

Hình ảnh của bộ dữ liệu BTXRD được thu thập từ ba trung tâm lưu trữ hình ảnh y tế khác nhau. Trung tâm 1 bao gồm ba bệnh viện tại Trung Quốc: Bệnh viện trực thuộc số 1 của Đại học Y khoa Quảng Tây, Bệnh viện trực thuộc của Đại học Y khoa Dân tộc Hữu Giang và Bệnh viện Nhân dân Bách Sắc. Trung tâm 2 là nền tảng giáo dục X-quang trực tuyến Radiopaedia.org. Trung tâm 3 là cơ sở dữ liệu công cộng MedPix.


Tại Trung tâm 1, các hình ảnh X-quang của những bệnh nhân mắc u xương nguyên phát (đã được xác nhận qua mô bệnh học hoặc bởi hai chuyên gia X-quang) được thu thập trong khoảng thời gian từ tháng 7 năm 2013 đến tháng 7 năm 2023. Đối với Trung tâm 2 và 3, hai chuyên gia X-quang đã thu thập hình ảnh bằng cách tìm kiếm các từ khóa cụ thể liên quan đến u xương (như 'bone tumor', 'osteosarcoma', v.v.) và tải trực tiếp hình ảnh từ các trang web chính thức. Tiêu chí đưa vào bộ dữ liệu bắt buộc mỗi hình ảnh phải có thông tin tương ứng về giới tính và độ tuổi. Trong quá trình làm sạch dữ liệu, các mẫu u xương nguyên phát ở vùng đầu, cổ, ngực và bụng đã bị loại bỏ do số lượng ít và có nhiều nhiễu ảnh. Do đó, BTXRD chỉ bao gồm các hình ảnh khối u xương và xương bình thường thuộc các vị trí chi trên, chi dưới và xương chậu.

Trong giai đoạn gán nhãn, một bác sĩ chuyên khoa u xương với 10 năm kinh nghiệm chẩn đoán đã sử dụng công cụ gán nhãn hình ảnh Labelme [23] để phân vùng các khối u và vẽ hộp giới hạn xung quanh chúng. Các chú thích ban đầu này sau đó được đánh giá và xem xét lại bởi một chuyên gia khác có 20 năm kinh nghiệm nhằm đảm bảo tính chính xác. Sau khi

hoàn tất, toàn bộ thông tin về mặt nạ phân vùng và hộp giới hạn được lưu dưới định dạng JSON. Các thông tin nhãn lâm sàng khác của mỗi hình ảnh như giới tính, tuổi tác, vị trí giải phẫu và góc chụp được ghi lại trong các tệp định dạng CSV.

Cấu trúc bộ dữ liệu

Bộ dữ liệu này bao gồm tổng cộng 3.746 hình ảnh, trong đó phân bổ thành 1.879 ảnh xương bình thường, 1.525 ảnh u xương lành tính và 342 ảnh u xương ác tính. Dữ liệu hình ảnh được lưu dưới định dạng JPEG thang độ xám 8-bit, các dữ liệu về nhãn lâm sàng được lưu dưới định dạng CSV, và các thông tin về mặt nạ phân vùng cũng như hộp giới hạn được lưu dưới định dạng JSON. Cấu trúc thư mục của bộ dữ liệu được tổ chức như sau:



Hình 4.1: Sơ đồ phân cấp cấu trúc dữ liệu BTXRD

Trong đó:

- **images/**: Thư mục chứa toàn bộ hình ảnh chụp X-quang gốc của bệnh nhân dưới định dạng ảnh JPEG thang độ xám.
- **Annotations/**: Chứa các tệp nhãn dạng JSON lưu trữ tọa độ đỉnh đa giác phân vùng của khối u và hộp giới hạn tương ứng được xuất ra từ công cụ LabelMe.
- **reports/**: Thư mục lưu trữ hai nguồn văn bản phục vụ cho học máy đa phương thức:
 - **clinical/**: Chứa các báo cáo mô tả bệnh sử lâm sàng của từng bệnh nhân.
 - **xray/**: Chứa các văn bản mô tả phát hiện chẩn đoán hình ảnh trên phim X-quang.
- **dataset.csv**: Tệp bảng chứa siêu dữ liệu thô ban đầu (tuổi, giới tính, vùng xương chụp, góc chụp).
- **btxrd-labels.csv**: Tệp lưu trữ ánh xạ các lớp bệnh lý của từng ảnh phục vụ cho huấn luyện phân loại (bao gồm cả lớp phân loại đa lớp `class_id`).
- **btxrd-split.csv**: Tệp tin chỉ định phân tách phân bổ tập dữ liệu (huấn luyện, đánh giá, kiểm thử).

Phương pháp xây dựng dữ liệu báo cáo y khoa đa phương thức

Do tập dữ liệu gốc BTXRD công bố chỉ bao gồm hình ảnh X-quang, nhãn phân loại và tọa độ vùng khoanh u xương mà không đi kèm các báo cáo văn bản chẩn đoán y khoa, nhóm nghiên cứu đã thiết kế một quy trình xây dựng văn bản báo cáo y khoa đa phương thức bán tự động dựa trên khuôn mẫu và thuộc tính. Phương pháp này giúp giả lập hai nguồn dữ liệu văn bản quan trọng tương tự như trong thực tế chẩn đoán:

1. **Báo cáo lâm sàng**: Báo cáo này được tạo lập bằng cách kết hợp thông tin nhân khẩu học (độ tuổi, giới tính) và vị trí giải phẫu xương

của bệnh nhân với các bệnh lý tương ứng. Nhóm đã xây dựng các ngân hàng khuôn mẫu câu mô tả:

- Lý do khám bệnh (ví dụ: xuất hiện khối u sưng nề hoặc đau nhức ở vùng xương tương ứng).
- Thời gian khởi phát triệu chứng (được chọn ngẫu nhiên trong khoảng từ vài tuần đến vài tháng).
- Tiền sử bệnh và ghi nhận khám thực thể.

Đặc biệt, để mô phỏng chính xác bệnh cảnh lâm sàng, quy trình sinh văn bản sẽ phân nhánh dựa trên tính chất u xương. Đối với u lành tính, bệnh sử mô tả các khối u tăng trưởng chậm, không sốt, không sụt cân, không đau đêm. Ngược lại, đối với u ác tính, văn bản được thêm vào các triệu chứng nguy cấp của ung thư như đau xương tăng dữ dội về đêm, sụt cân không rõ nguyên nhân, sốt nhẹ hoặc đổ mồ hôi trộm. Các thuộc tính cá nhân của bệnh nhân sau đó được thay thế vào các chỗ trống để tạo ra văn bản lâm sàng tự nhiên và đa dạng.

2. **Báo cáo mô tả ảnh X-quang:** Báo cáo cận lâm sàng chẩn đoán hình ảnh được sinh ra dựa trên góc chụp X-quang và các dấu hiệu hình ảnh đặc trưng lâm sàng của từng phân nhóm u xương đã được chuyên gia chẩn đoán:

- Đối với u xương sụn (*osteochondroma*): văn bản sinh ra các mô tả đặc trưng như chồi xương có nắp sụn liên tục với vỏ xương và tủy xương ("*cartilage-capped bony outgrowth*", "*continuity of cortex*").
- Đối với nang xương đơn thuần (*simple bone cyst*): văn bản mô tả tổn thương tiêu xương giới hạn rõ ở vùng hành xương ("*well-defined lucent lesion in the metaphysis*").
- Đối với u tế bào khổng lồ (*giant cell tumor*): văn bản chứa mô tả tổn thương tiêu xương dạng bong bóng xà phòng ("*soap-bubble appearance*").

Các mô tả hình thái học thuật này giúp mô hình học sâu có thể liên kết giữa các đặc trưng thị giác trên phim X-quang gốc với các thuật ngữ y học chuyên ngành tương ứng trong báo cáo cận lâm sàng.

Bảng 4.1 trình bày một số mẫu ví dụ cụ thể về hình ảnh X-quang gốc cùng với hai nguồn văn bản báo cáo y khoa lâm sàng và cận lâm sàng tương ứng được xây dựng trong bộ dữ liệu BTXRD.

Thông kê số liệu

Nhằm cung cấp cái nhìn chi tiết và khách quan về cấu trúc dữ liệu, các bảng thống kê dưới đây trình bày phân bố số lượng mẫu hình ảnh theo các tập chia dữ liệu (Bảng 4.2) và phân bố theo các lớp u xương bệnh lý (Bảng 4.3).

Về mặt gán nhãn u xương, bộ dữ liệu BTXRD được tổ chức chủ yếu dưới dạng đơn nhãn, trong đó có 1.879 ảnh bình thường (không có khối u) và 1.866 ảnh có đúng 1 nhãn bệnh lý. Chỉ có duy nhất 1 hình ảnh chứa đồng thời 2 nhãn bệnh lý (u xương sụn và đa u xương sụn). Số lượng nhãn trung bình trên mỗi ảnh là 0,50 và tối đa là 2 nhãn.

Đối với phần báo cáo ảnh x-quang, có tổng cộng 3.746 tệp tương ứng với 3.746 hình ảnh. Trong đó, có 1.576 văn bản báo cáo là độc nhất (tỷ lệ độc nhất đạt 42,1%). Sự trùng lặp văn bản là do quy trình tự động sinh dựa trên các tập thuộc tính và mẫu câu cố định. Tuy nhiên, tính độc nhất này phân bố cao hơn trên các tập chia nhỏ: tập huấn luyện có 1.333/2.622 báo cáo độc nhất (50,8%), tập đánh giá có 475/562 báo cáo độc nhất (84,5%), và tập kiểm thử có 451/562 báo cáo độc nhất (80,2%). Độ dài trung bình của các báo cáo cận lâm sàng là khoảng 24,6 từ (tối thiểu là 19 từ, tối đa là 36 từ), tương đương trung bình khoảng 172 ký tự (từ 120 đến 266 ký tự).

4.2.2 Bộ dữ liệu CTCH

Bộ dữ liệu hình ảnh X-quang xương CTCH được thu thập từ bệnh viện Chấn thương Chỉnh hình, bao gồm tổng cộng 400 hình ảnh X-quang từ

Hình ảnh X-quang	Thông tin lâm sàng (Clinical)	Thông tin cận lâm sàng (X-ray)
	Patient: 58-year-old male. Chief complaint: swelling and discomfort in the tibia (shin bone) region. The patient noticed the lump 2 months ago. It has been painless and gradually increasing in size. No night pain reported. Physical examination reveals a hard, non-tender bony protuberance. No history of prior bone disease, fracture, or malignancy. Radiographic evaluation: AP view of the tibia (shin bone) was obtained.	A musculoskeletal radiograph of the bone in standard projection with evidence of osteochondroma: a pedunculated or sessile bony projection with cartilage cap. Captured at standard radiographic technique. The overall appearance favors a benign process.
	Patient: 6-year-old male. The patient reports a progressively growing swelling over the humerus (upper arm). Rapidly enlarging mass in the humerus (upper arm) over the past a few months. Associated with night pain and unintentional weight loss. Large, firm, tender mass with overlying skin warmth. Regional lymphadenopathy absent. No significant past medical history. Radiographic evaluation: AP view of the humerus (upper arm) was obtained.	A musculoskeletal radiograph of the bone in conventional radiographic view with evidence of osteosarcoma: an aggressive osteoblastic lesion with irregular periosteal new bone formation. In a routine clinical radiographic study. The imaging features raise concern for malignancy.
	Patient: 48-year-old female. The patient presents with a palpable mass on the hip bone (pelvis). The patient presents with a painful mass that has been growing rapidly. Significant weight loss of 5 kg over 1 month. Night pain disturbs sleep. Painful, rapidly growing mass with constitutional symptoms. No known chronic diseases. No prior surgeries. Radiographic evaluation: AP view of the hip bone (pelvis) was obtained.	A musculoskeletal radiograph of the bone in standard projection with evidence of other mt: a destructive bone lesion with ill-defined borders suggestive of malignancy. In a high-resolution diagnostic acquisition. The imaging features raise concern for malignancy.

Bảng 4.1: Ví dụ các mẫu dữ liệu đa phương thức trong bộ dữ liệu BTXRD

Tập dữ liệu (Split)	Số lượng hình ảnh	Tỷ lệ (%)
Huấn luyện (Train)	2.622	70,0%
Đánh giá (Validation)	562	15,0%
Kiểm thử (Test)	562	15,0%
Tổng cộng	3.746	100,0%

Bảng 4.2: Phân bố hình ảnh theo các tập dữ liệu trong BTXRD

Nhân bệnh lý (Pathology)	Số lượng	Tỷ lệ (%)
Bình thường (Normal)	1.879	50,2%
U xương sụn (<i>osteochondroma</i>)	754	20,1%
U xương ác tính (<i>osteosarcoma</i>)	297	7,9%
Đa u xương sụn (<i>multiple</i>)	263	7,0%
Nang xương đơn thuần (<i>cyst</i>)	206	5,5%
U xương lành tính khác (<i>other benign</i>)	115	3,1%
U tế bào khổng lồ (<i>giant cell</i>)	93	2,5%
U màng hoạt dịch (<i>synovial</i>)	51	1,4%
U xương ác tính khác (<i>other malignant</i>)	45	1,2%
U xơ không tạo xương (<i>osteofibroma</i>)	44	1,2%


Bảng 4.3: Phân bố các lớp bệnh lý u xương trong bộ dữ liệu BTXRD

400 bệnh nhân khác nhau. Mỗi hình ảnh được gán nhãn với các thông tin lâm sàng bao gồm lý do vào viện, quá trình bệnh lý, tiền sử bệnh lý.

Cấu trúc bộ dữ liệu

Trong đó:

- **images/**: Thư mục chứa toàn bộ hình ảnh chụp X-quang gốc của bệnh nhân dưới định dạng ảnh JPEG thang độ xám.
- **reports/**: Thư mục lưu trữ hai nguồn văn bản phục vụ cho học máy đa phương thức:
 - **clinical/**: Chứa các báo cáo mô tả bệnh sử lâm sàng của từng bệnh nhân.
 - **clinical_vi/**: Chứa các báo cáo mô tả bệnh sử lâm sàng của từng bệnh nhân bằng tiếng Việt.
 - **xray/**: Chứa các văn bản mô tả phát hiện chẩn đoán hình ảnh trên phim X-quang.



Hình 4.2: Sơ đồ phân cấp cấu trúc dữ liệu CTCH

- **xray_vi/**: Chứa các văn bản mô tả phát hiện chẩn đoán hình ảnh trên phim X-quang bằng tiếng Việt.
- **data_labeled.csv**: Tập bảng chứa siêu dữ liệu thô ban đầu.
- **ctch-labels.csv**: Tập lưu trữ ánh xạ các lớp bệnh lý của từng ảnh phục vụ cho huấn luyện phân loại.
- **ctch-split.csv**: Tập tin chỉ định phân tách phân bố tập dữ liệu (huấn luyện, đánh giá, kiểm thử).

Tiền xử lý dữ liệu

Dữ liệu gốc được thu thập từ bệnh viện Chấn thương Chỉnh hình có nhiều vấn đề như sau:

- Dữ liệu gốc được thu thập từ bệnh viện Chấn thương Chỉnh hình có nhiều loại ảnh khác nhau, bao gồm ảnh chụp X-quang, ảnh CT, ảnh MRI và các loại ảnh khác.
- Một ca khám có thể có nhiều ảnh chụp từ các vị trí giải phẫu khác nhau, từ 2 đến vài trăm ảnh, nhưng chỉ một trong số đó là đúng vị trí và có sự thể hiện rõ về bệnh lý ở mắt thị giác.
- Một bệnh nhân có thể tái khám nhiều lần, dẫn đến việc có nhiều mẫu dữ liệu tương tự.
- Nhiều ca khám thiếu hụt các trường thông tin quan trọng đến huấn luyện như không có chẩn đoán xác định, không có phân tích ảnh X-quang,...
- Đôi khi chẩn đoán xác định của bác sĩ là những căn bệnh về phần mềm (sụn, dây chằng, gân, cơ) không thể hiện được trên ảnh X-quang.

Nhóm nghiên cứu đã thực hiện các bước tiền xử lý dữ liệu để chuẩn hóa và làm sạch dữ liệu trước khi đưa vào huấn luyện mô hình. Các bước tiền xử lý bao gồm:

- Loại bỏ các ảnh không liên quan hoặc không có giá trị chẩn đoán, có các dụng cụ y tế (nẹp, đinh) che vùng tổn thương.
- Đánh dấu và phân loại các mẫu dữ liệu theo lớp bệnh lý của ảnh X-quang (nếu bệnh là gãy dây chằng thuộc về phần mềm thì nhãn vẫn là "bình thường" nếu ảnh không ghi nhận tổn thương về xương).
- Loại bỏ các ca khám trùng lặp, tái khám nhiều lần.
- Chuẩn hóa và biên dịch các báo cáo y khoa từ tiếng Việt sang tiếng Anh.
- Lọc các ca hiếm gặp, không đủ số lượng mẫu để làm dữ liệu ngoài phân phối.

4.3 Độ đo đánh giá

Để đánh giá hiệu quả của mô hình đề xuất và các mô hình đối sánh trên bài toán phân loại đa lớp u xương, nhóm nghiên cứu đã sử dụng các độ đo tiêu chuẩn trong học máy y sinh. Do tập dữ liệu BTXRD có sự mất cân bằng lớp nghiêm trọng (lớp Bình thường chiếm hơn 50% số lượng mẫu, trong khi một số lớp u hiếm như u xơ xương chỉ chiếm khoảng 1,2%), các chỉ số tính toán được áp dụng cơ chế Macro-averaging. Phương pháp này giúp phản ánh chính xác hiệu năng dự đoán trên từng lớp bệnh lý độc lập, ngăn chặn việc kết quả của lớp đa số chi phối các lớp hiếm gặp.

4.3.1 Định nghĩa toán học và ý nghĩa của các độ đo

Các chỉ số đánh giá được tính toán dựa trên các khái niệm cơ bản cho từng lớp $c \in \{1, 2, \dots, C\}$ (với $C = 10$ là số lớp):

- **True Positive (TP_c):** Số lượng mẫu thuộc lớp c được dự đoán chính xác vào lớp c .

- **False Positive (FP_c):** Số lượng mẫu thuộc lớp khác nhưng bị mô hình dự đoán nhầm vào lớp c .
- **True Negative (TN_c):** Số lượng mẫu không thuộc lớp c được dự đoán chính xác không thuộc lớp c .
- **False Negative (FN_c):** Số lượng mẫu thuộc lớp c nhưng bị mô hình dự đoán nhầm vào lớp khác.

Dưới đây là định nghĩa toán học và ý nghĩa chi tiết của từng độ đo được áp dụng:

Độ chính xác

- **Công thức:**

$$\text{Accuracy} = \frac{\sum_{c=1}^C TP_c}{N} \quad (4.1)$$

Trong đó N là tổng số lượng mẫu trong tập kiểm thử.

- **Ý nghĩa:** Chỉ số này thể hiện tỷ lệ phần trăm mẫu được chẩn đoán hoàn toàn chính xác trên toàn bộ tập dữ liệu. Độ đo này hữu ích khi cấu trúc dữ liệu cân bằng, nhưng đối với BTXRD, nó chỉ đóng vai trò tham khảo phụ vì dễ bị chi phối bởi lớp Bình thường chiếm đa số.

Độ chính xác dương tính

- **Công thức:**

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c} \quad (4.2)$$

$$\text{Macro Precision} = \frac{1}{C} \sum_{c=1}^C \text{Precision}_c \quad (4.3)$$

- **Ý nghĩa:** Precision đo lường độ tin cậy trong các dự đoán dương tính của mô hình. Ví dụ, nếu mô hình chẩn đoán 10 ca là u ác tính và Precision đạt 90%, nghĩa là có 9 ca thực sự là ác tính và chỉ có 1 ca bị chẩn đoán nhầm (dương tính giả). Trong lâm sàng, Precision

cao giúp giảm tỷ lệ chỉ định sinh thiết nhầm và giảm gánh nặng chi phí cũng như tâm lý cho bệnh nhân.

Độ phủ

- **Công thức:**

$$\text{Sensitivity}_c = \text{Recall}_c = \frac{TP_c}{TP_c + FN_c} \quad (4.4)$$

$$\text{Macro Sensitivity} = \frac{1}{C} \sum_{c=1}^C \text{Sensitivity}_c \quad (4.5)$$

- **Ý nghĩa:** Độ nhạy phản ánh khả năng phát hiện bệnh của mô hình, tức là tỷ lệ bệnh nhân thực sự có u được mô hình nhận diện chính xác. Nếu một mô hình có độ nhạy 95% đối với u ác tính osteosarcoma, điều đó nghĩa là cứ 100 bệnh nhân mắc bệnh thì mô hình phát hiện được 95 người, chỉ bỏ sót 5 người (âm tính giả). Chỉ số này bắt buộc phải duy trì ở mức cao trong chẩn đoán y sinh để đảm bảo an toàn tính mạng cho người bệnh.

Độ đặc hiệu

- **Công thức:**

$$\text{Specificity}_c = \frac{TN_c}{TN_c + FP_c} \quad (4.6)$$

$$\text{Macro Specificity} = \frac{1}{C} \sum_{c=1}^C \text{Specificity}_c \quad (4.7)$$

- **Ý nghĩa:** Độ đặc hiệu đo lường khả năng nhận diện các ca âm tính (không mắc bệnh c). Đối với lớp Bình thường, Specificity cao đồng nghĩa với việc mô hình ít khi chẩn đoán nhầm một người khỏe mạnh là có khối u. Chỉ số này giúp bảo vệ bệnh nhân khỏi các quy trình điều trị nhầm lẫn có hại cho sức khỏe.

Chỉ số F1-Score

- **Công thức:**

$$F1_c = 2 \times \frac{\text{Precision}_c \times \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \quad (4.8)$$

$$\text{Macro F1-Score} = \frac{1}{C} \sum_{c=1}^C F1_c \quad (4.9)$$

- **Ý nghĩa:** F1-Score là trung bình điều hòa của Precision và Recall, đóng vai trò là thước đo trung thực nhất cho sức khỏe tổng thể của mô hình. F1-Score chỉ cao khi cả Precision và Recall đều cao. Nếu mô hình có xu hướng dự đoán bừa để tăng Recall hoặc chỉ dự đoán các ca cực kỳ dễ để tăng Precision, chỉ số F1-Score sẽ bị kéo tụt xuống. Chỉ số trung bình vĩ mô (Macro F1-Score) là độ đo chính được sử dụng để xếp hạng các mô hình đối sánh trong nghiên cứu này.

Diện tích dưới đường cong ROC

- **Công thức:**

$$\text{Macro AUROC} = \frac{1}{C} \sum_{c=1}^C \text{AUC}_c \quad (4.10)$$

Trong đó AUC_c là diện tích dưới đường cong ROC của lớp c được tính toán theo phương pháp một đối tất cả (One-vs-Rest).

- **Ý nghĩa:** ROC AUC thể hiện xác suất mô hình xếp hạng một mẫu dương tính thực sự cao hơn một mẫu âm tính thực sự. Giá trị AUROC bằng 0,5 tương đương đoán ngẫu nhiên, trong khi bằng 1,0 thể hiện khả năng phân tách hoàn hảo giữa các lớp bệnh lý. Chỉ số này đại diện cho năng lực trích xuất đặc trưng thuần túy của mô hình, độc lập với ngưỡng quyết định phân lớp được lựa chọn.

Ma trận nhầm lẫn

- **Ý nghĩa:** Trong y học, ma trận nhầm lẫn không chỉ cung cấp các con số mà còn mang ý nghĩa định hướng chẩn đoán sai lệch. Nó giúp các bác sĩ hiểu rõ mô hình đang phân loại nhầm giữa các lớp nào với nhau (ví dụ: mô hình có xu hướng nhầm u ác tính osteosarcoma sang u lành tính osteochondroma hay không). Sự nhầm lẫn giữa hai lớp lành tính ít gây hậu quả nghiêm trọng hơn so với việc chẩn đoán nhầm từ một u ác tính sang một u lành tính hoặc bình thường. Do đó, ma trận nhầm lẫn là công cụ đặc lực để chẩn đoán lâm sàng lỗi hệ thống của mô hình.

4.4 Thiết lập thực nghiệm

Phần này trình bày các thiết lập thực nghiệm, bao gồm môi trường phần cứng và phần mềm, cũng như các siêu tham số được sử dụng trong quá trình huấn luyện mô hình. Các thiết lập này nhằm đảm bảo tính nhất quán và khả năng tái tạo của các thí nghiệm.

4.4.1 Môi trường thực nghiệm

- **Phần cứng:** NVIDIA RTX 5060ti 16GB, CPU Ultra 7 265KF, RAM 32GB
- **Phần mềm:** Python 3.11.15, PyTorch 2.11.0, CUDA 12.8, Hugging-Face Transformers

Siêu tham số	Pha 1 (Tương phản)
Độ phân giải ảnh đầu vào	224×224 pixels
Bộ tối ưu hóa	AdamW
Tốc độ học	2×10^{-4}
Suy giảm trọng số	1×10^{-2}
Bộ điều chỉnh tốc độ học	Cosine Annealing
Tỷ lệ khởi động	0.1
Kích thước lô	32
Số epoch tối đa	50
Số epoch dừng sớm	5 epochs
Nhiệt độ tương phản (τ)	0.07
Trạng thái tham số Backbone	Tinh chỉnh qua PEFT
Hạng QLoRA (r)	16
Hệ số QLoRA (α)	32
Tỷ lệ bỏ học QLoRA	0.1

Bảng 4.4: Bảng tổng hợp siêu tham số ở pha 1 và thiết lập của chúng

Siêu tham số	Pha 2 (Phân loại)
Độ phân giải ảnh đầu vào	224×224 pixels
Bộ tối ưu hóa	AdamW
Tốc độ học	1×10^{-3}
Suy giảm trọng số	1×10^{-4}
Bộ điều chỉnh tốc độ học	Cosine Annealing
Tỷ lệ khởi động	0.1
Kích thước lô	32
Số epoch tối đa	50 / 100
Số epoch dừng sớm	5 epochs
Nhiệt độ tương phản (τ)	Không áp dụng
Trạng thái tham số Backbone	Đông bằng
Hạng QLoRA (r)	Không áp dụng
Hệ số QLoRA (α)	Không áp dụng
Tỷ lệ bỏ học QLoRA	Không áp dụng

Bảng 4.5: Bảng tổng hợp siêu tham số ở pha 2 và thiết lập của chúng

4.4.2 Tham số thực nghiệm

4.5 Kết quả thực nghiệm và Thảo luận

4.5.1 Đánh giá so sánh hiệu năng chẩn đoán với các mô hình đối sánh

Kết quả đối sánh trên bộ dữ liệu BTXRD

Để đánh giá toàn diện, nhóm nghiên cứu tiến hành đo đạc kết quả theo hai cấp độ: (1) Đánh giá Zero-shot của các mô hình VLM nền tảng nguyên bản không qua tinh chỉnh (Bảng 4.6); và (2) Đánh giá đối sánh các mô hình sau khi fine-tune và mô hình đề xuất XBone-Net trên tập kiểm thử BTXRD (Bảng 4.7).

Mô hình Zero-Shot	F1-Macro $\uparrow$	Accuracy $\uparrow$
CLIP	0,0434	0,0623
MedCLIP	0,0066	0,0338
PubMedCLIP	0,0726	0,0943
BiomedCLIP	0,1056	0,3381

Bảng 4.6: Bảng đánh giá hiệu năng Zero-Shot của các mô hình VLM gốc trên bộ dữ liệu BTXRD

Mô hình	F1-Macro $\uparrow$	Accuracy $\uparrow$	Macro AUROC $\uparrow$	Specificity $\uparrow$
ResNet-50 (Image-only)	0,3099	0,6441	0,8006	0,9438
DenseNet-121 (Image-only)	0,4112	0,6726	0,8320	0,9510
MedCLIP Fine-tuned	0,7784	0,9609	0,9984	0,9959
BiomedCLIP Fine-tuned	0,8105	0,9448	0,9940	0,9937
PubMedCLIP Fine-tuned	0,8217	0,8915	0,9886	0,9942
XBone-Net	0,8583	0,9626	0,9869	

Bảng 4.7: Bảng so sánh kết quả thực nghiệm fine-tuned baselines và mô hình đề xuất XBone-Net

Dựa trên các bảng kết quả thực nghiệm, nhóm nghiên cứu đưa ra các nhận xét và phân tích chuẩn hóa sau:

- **Phân tích kết quả Zero-Shot Baselines (Bảng 4.6):** Tất cả các mô hình VLM nguyên bản ở chế độ Zero-shot đều cho hiệu năng rất thấp (F1-Macro đều dưới 0,11, độ chính xác dưới 34%). BiomedCLIP Zero-shot đạt kết quả nhỉnh nhất ($F1 = 0,1056$, $Acc = 33,81\%$) nhờ được tiền huấn luyện trên 15 triệu cặp ảnh-văn bản y tế (PMC-15M). Kết quả này minh chứng rõ ràng cho thách thức về **khoảng cách miền dữ liệu (Domain Gap)** giữa dữ liệu y khoa tổng quát và ảnh X-quang u xương chuyên sâu. Nếu không thông qua quy trình huấn luyện hai pha thích ứng miền và hợp nhất đa phương thức, các mô hình VLM gốc hoàn toàn không thể đưa ra chẩn đoán chính xác trong thực tế lâm sàng.
- **So sánh giữa Mô hình Đơn phương thức và Đa phương thức Fine-tuned:** Các mô hình chỉ sử dụng ảnh X-quang đơn thuần (ResNet-50 đạt $F1 = 0,3099$, DenseNet-121 đạt $F1 = 0,4112$) gặp khó khăn lớn do nhiều loại u xương (như u tế bào khổng lồ và nang xương đơn thuần) có biểu hiện hình thái tiêu xương rất giống nhau trên ảnh X-quang thang độ xám. Trái lại, các mô hình đa phương thức fine-tuned (MedCLIP, BiomedCLIP, PubMedCLIP) khi được bổ sung thông tin bệnh sử lâm sàng dạng văn bản (tuổi, giới tính, vị trí sưng đau) đã giúp F1-Macro vọt lên trên 0,77 – 0,82. Điều này khẳng định vai trò hỗ trợ sinh tử của thông tin bệnh sử lâm sàng đối với hình ảnh X-quang.
- **Phân tích Đánh đổi Kỹ thuật và Năng lực Mô hình Đề xuất XBone-Net:**
 - Các mô hình Baseline fine-tuned sử dụng đầu phân loại tuyến tính (Linear Head) đạt kết quả phân loại In-Distribution cao nhờ 10.240 tham số tự do dễ dàng tạo siêu phẳng phân tách dữ liệu đóng. Tuy nhiên, Linear Head có điểm yếu chí mạng là **hoàn toàn mù trước dữ liệu lạ OOD** (Overconfidence), cố tình gán ca bệnh lạ vào 1 trong 10 lớp cũ với độ tin cậy $> 95\%$, gây rủi ro y khoa nghiêm trọng.
 - Mô hình đề xuất **XBone-Net** áp dụng đầu phân loại nguyên

mẫu (Prototypical Head) kết hợp hàm loss hỗn hợp chuẩn hóa $0.7\mathcal{L}_{\text{WeightedCE}} + 0.3\mathcal{L}_{\text{proto}}$. XBone-Net đạt hiệu năng phân loại In-Distribution vượt trội (Accuracy = 96,09% – 97,15%, $F1 = 0,8027 - 0,8839$), đồng thời **đạt khả năng kiểm soát an toàn lâm sàng tuyệt đối với bài toán phát hiện bệnh lạ ngoài phân phối (AUROC OOD = 1,0000 với khoảng cách Mahalanobis)**.

Kết quả đối sánh trên bộ dữ liệu nội bộ CTCH

Nhằm đánh giá khả năng tổng quát hóa của mô hình đề xuất trên dữ liệu thực tế tại Việt Nam, nhóm nghiên cứu thực hiện đánh giá đối sánh trên bộ dữ liệu nội bộ CTCH được thu thập tại Bệnh viện Chấn thương Chỉnh hình TP.HCM.

4.5.2 Đánh giá khả năng phát hiện dữ liệu ngoài phân phối

4.5.3 Các thí nghiệm rời rạc

Nhóm đã thực hiện các thí nghiệm loại bỏ thành phần để bóc tách đóng góp cụ thể của các mô-đun đề xuất trong kiến trúc XBone-Net.

Pipeline đề xuất được cố định theo Mục 3.2 trước khi đọc kết quả ablation. Vì vậy, ablation không được dùng để tái định nghĩa mô hình đề xuất theo hướng hậu nghiệm. Nếu một cấu hình rút gọn đạt kết quả cao hơn, nghiên cứu báo cáo đầy đủ độ chênh lệch và xem đây là bằng chứng về điểm yếu hoặc sự đánh đổi của thành phần tương ứng (chẳng hạn hiệu năng ID, khả năng phát hiện OOD, chi phí tính toán hoặc độ ổn định giữa các seed). Chỉ khi cấu hình đó được xác nhận lại bằng quy trình lựa chọn trên validation và đánh giá độc lập, nó mới có thể được xem là một phiên bản cải tiến trong nghiên cứu tiếp theo.

Các giá trị ablation hiện có trong chương này được xem là kết quả sơ bộ. Bản báo cáo cuối chỉ sử dụng các lần chạy lại từ config kế thừa pipeline chuẩn, cùng split, seed và quy trình chọn checkpoint; các bảng sẽ được cập nhật sau khi suite thí nghiệm này hoàn tất.

Đánh giá vai trò của các nguồn thông tin văn bản lâm sàng

Mục đích thí nghiệm này là đánh giá tác động của việc tích hợp văn bản lâm sàng và cận lâm sàng đến kết quả chẩn đoán, đồng thời xác định xem có xảy ra hiện tượng rò rỉ nhãn hay không. Nhóm so sánh 4 kịch bản văn bản tại Bảng 4.8.

Kịch bản văn bản	Văn bản sử dụng	F1-Macro	Accuracy	Macro AUROC
Image only	Không sử dụng	0,2052	0,6050	0,7857
Clinical only	Bệnh sử lâm sàng	0,8583	0,9626	0,9869
X-ray only	Mô tả kết quả X-quang	1,0000	1,0000	1,0000
Both texts	Lâm sàng + X-quang	1,0000	1,0000	1,0000

Bảng 4.8: Bảng kết quả ablation về nguồn văn bản đầu vào

Thảo luận kết quả:

- **Hiện tượng rò rỉ nhãn (Label Leakage):** Các kịch bản có sử dụng văn bản phát hiện X-quang (*xray*) đạt F1-Macro tuyệt đối là 1,0000. Phân tích văn bản cho thấy báo cáo X-quang của bác sĩ chẩn đoán hình ảnh chứa trực tiếp tên lớp bệnh lý (ví dụ: "osteosarcoma", "osteochondroma"). Mô hình học sâu đã bỏ qua ảnh chụp và chỉ đọc văn bản kết luận này để phân loại. Trong lâm sàng thực tế, khi bệnh nhân mới vào viện khám sàng lọc, báo cáo X-quang chưa được viết. Do đó, để đảm bảo tính thực tiễn và tính khoa học, chỉ có kịch bản sử dụng bệnh sử lâm sàng (clinical) là hợp lệ.
- **Đóng góp của Bệnh sử lâm sàng:** Khi chuyển từ chỉ dùng ảnh (T2_imgonly) sang dùng ảnh kèm bệnh sử lâm sàng, F1-Macro tăng vọt từ **0,2052** lên **0,8583** (tăng gấp 4 lần). Điều này chứng minh thông tin y khoa lâm sàng (như độ tuổi, vị trí đau đùi, các triệu chứng sốt/sụt cân) là "la bàn" vô cùng đặc lực giúp bộ phân loại định hướng chính xác lớp bệnh lý u xương.

Đánh giá ảnh hưởng của chiến thuật tinh chỉnh backbone

Mục đích thí nghiệm này là đánh giá hiệu năng khi đóng băng backbone so với tinh chỉnh (Full FT hoặc QLoRA PEFT) trong quy trình huấn luyện.

Chiến thuật	Pha 1	F1-Macro	Accuracy	Macro AUROC
Đóng băng backbone	Không	0,8095	0,9431	0,9907
Tinh chỉnh LoRA	Có (Clinical)	0,6140	0,8808	0,9665
Tinh chỉnh toàn bộ	Có (Clinical)	0,5951	0,8559	0,9632
Tinh chỉnh QLoRA (Gốc)	Có (Xray)	0,6464	0,8754	0,9741
Tinh chỉnh QLoRA (Cải tiến)	Có (Clinical)	0,8583	0,9626	0,9869

Bảng 4.9: Bảng kết quả ablation về chiến thuật tinh chỉnh backbone

Thảo luận kết quả:

- **Hiện tượng trôi lệch biểu diễn (Representation Drift):** Bản gốc `full_proposed` chỉ đạt F1-Macro 0,6464 (kém hơn so với đóng băng hoàn toàn backbone `T3_no_ft` đạt 0,8095). Nguyên nhân là ở pha 1, mô hình gốc căn chỉnh tương đối ảnh-văn bản với báo cáo Xray, nhưng ở pha 2 lại sử dụng báo cáo Clinical. Việc lệch nguồn thông tin này làm không gian biểu diễn bị trôi lệch, gây suy giảm chất lượng đặc trưng. Khi đồng bộ hóa dùng Clinical ở cả hai pha (`T2_clinical`), hiệu năng vượt lên đạt ****0,8583****.
- **Quên lãng thảm họa (Catastrophic Forgetting) trên tập dữ liệu nhỏ:** Thí nghiệm tinh chỉnh toàn bộ hệ thống (`T3_full_ft`) đạt kết quả thấp nhất (F1-Macro 0,5951). Việc cập nhật toàn bộ tham số của Vision Transformer trên tập dữ liệu nhỏ dễ dàng phá hủy các biểu diễn đặc trưng y tế mạnh mẽ đã học được ở giai đoạn pre-train, gây ra hiện tượng quá khớp (overfitting). Việc đóng băng backbone và chỉ cập nhật adapter LoRA siêu nhẹ ở Pha 1 giúp bảo toàn tối đa tri thức nền.

Đánh giá hiệu quả của đầu phân loại nguyên mẫu so với đầu phân loại tuyến tính

Nhóm thí nghiệm này nhằm kiểm tra hiệu quả của đầu phân loại nguyên mẫu (Prototypical Head) so với đầu phân loại tuyến tính (Linear Head) truyền thống trong bài toán phân loại đa lớp u xương.

Backbone	Bộ phân loại	F1-Macro	Accuracy	Macro AUROC
BiomedCLIP (Frozen)	Linear Head (B4)	0,8105	0,9448	0,9940
BiomedCLIP (Frozen)	Prototypical Head	0,8095	0,9431	0,9907
BiomedCLIP (QLoRA)	Linear Head	0,6261	0,8737	0,9693
BiomedCLIP (QLoRA)	Prototypical Head	0,6464	0,8754	0,9741

Bảng 4.10: Bảng kết quả ablation về bộ phân loại Classifier Head

Thảo luận kết quả:


- Khi backbone được đóng băng hoàn toàn (các đặc trưng có độ phân tách cao), cả hai bộ phân loại đều đạt hiệu năng xuất sắc ngang nhau (0,81 F1-Macro).
- Tuy nhiên, khi backbone bị trôi lệch biểu diễn (đặc trưng bị nhiễu do lệch pha thông tin), bộ phân loại nguyên mẫu Prototypical Head (`full_proposed` đạt 0,6464) vượt trội hơn so với Linear Head (`T4_crossattn_1` đạt 0,6261). Điều này chứng minh học máy khoảng cách (Metric Learning) của Prototypical Head giúp kéo các vector đặc trưng của cùng một lớp lại gần nhau và đẩy xa các lớp khác bằng khoảng lề xác định, tăng cường khả năng chịu lỗi của ranh giới quyết định.

4.5.4 Trực quan hóa bản đồ chú ý chéo và khả năng giải thích y khoa

Để chứng minh khả năng giải thích lâm sàng (clinical explainability) và tính hợp lý về mặt y khoa của mô hình đề xuất XBone-Net, nhóm nghiên cứu tiến hành trích xuất bản đồ chú ý chéo (Cross-Attention Map) từ khối Transformer của mô-đun Cross-Attention Fusion cuối cùng trước đầu phân loại. Bản đồ này được thu nhận bằng cách tính toán trọng số tự chú ý (self-attention) của token đại diện lớp hình ảnh (CLS token) đối với các

token vị trí hình ảnh (196 token patch), thể hiện mức độ tập trung của mô hình vào các vùng không gian trên ảnh chụp X-quang khi tổng hợp với thông tin bệnh sử lâm sàng.

Các kết quả trực quan hóa attention map chồng lên ảnh chụp X-quang gốc đối với một số nhóm bệnh lý điển hình từ tập kiểm thử được trình bày trong Hình 4.3.



Hình 4.3: Trực quan hóa bản đồ chú ý chéo (Cross-Attention Map) của mô hình đề xuất XBone-Net trên các nhóm bệnh lý điển hình (mỗi cặp gồm ảnh chụp X-quang gốc bên trái đã vẽ đường nét đứt màu xanh lá thể hiện phân vùng tổn thương thực tế - Ground Truth và ảnh chồng bản đồ chú ý chéo ở bên phải).

Phân tích định tính y khoa và kết quả định lượng:

- **Trường hợp Bình thường (Hình 4.3a):** Đối với ca chẩn đoán bình thường không có khối u xương (Normal), mô hình đề xuất dự đoán chính xác nhãn NORMAL với độ tự tin đạt **46,8%**. Bản đồ chú ý chéo cho thấy trọng số chú ý không tập trung vào bất kỳ vùng khu trú bất thường nào, mà phân bổ rộng rãi, đồng đều và mờ nhạt trên toàn bộ vùng giải phẫu của đầu dưới xương đùi và khớp gối. Điều này phản ánh sự tương khớp hoàn toàn với thực tế lâm sàng khi không có bất kỳ tổn thương hay cấu trúc khối u cục bộ nào cần phải khoanh vùng.

- **Trường hợp U xương sụn (Hình 4.3b):** Đối với bệnh lý u xương sụn (Osteochondroma), mô hình dự đoán chính xác lớp OSTEOCHONDROMA với độ tự tin rất cao đạt **89,5%**. Bản đồ chú ý của mô hình tập trung cực kỳ chính xác vào phần chồi xương nhô ra từ bề mặt hành xương đùi (exostosis) - đây chính là vùng tổn thương giải phẫu bệnh lý đặc trưng nhất của loại u này, hoàn toàn trùng khớp với phân vùng tổn thương thực tế (Ground Truth) được khoanh bằng đường nét đứt màu xanh lá.
- **Trường hợp Sarcoma xương (Hình 4.3c):** Sarcoma xương (Osteosarcoma) là một khối u ác tính có tính chất hủy xương và xâm lấn mạnh. Mô hình XBone-Net đã nhận diện chính xác bệnh lý này với độ tự tin rất cao đạt **90,7%**. Bản đồ trực quan hóa cho thấy mô hình tập trung mạnh mẽ và chính xác vào vùng hủy xương ở đầu dưới xương đùi kèm theo phản ứng màng xương dạng thố (Sunburst/Codman triangle), chứng minh mô hình có khả năng định vị rất tốt các dấu hiệu nguy kịch của bệnh lý ác tính này.
- **Trường hợp U tế bào khổng lồ (Hình 4.3d):** Ở trường hợp u tế bào khổng lồ (Giant cell tumor), mô hình chẩn đoán chính xác lớp GIANT CELL TUMOR với độ tự tin đạt **27,7%**. Mặc dù đây là lớp bệnh lý hiếm gặp dẫn đến độ tự tin thấp hơn, bản đồ chú ý chéo vẫn tập trung rất rõ rệt vào vùng đầu xương (epiphysis) giáp khớp gối - vị trí tổn thương đặc hữu dạng "bong bóng xà phòng" (soap bubble appearance) của loại u này, trùng khớp với vùng chú thích Ground Truth.

Các kết quả định tính trên chứng minh rằng mô hình XBone-Net không chỉ đưa ra các dự đoán phân loại dựa trên các tương quan thống kê thuần túy, mà đã thực sự học được cách liên kết chặt chẽ thông tin gợi ý từ bệnh sử lâm sàng để định vị đúng các vùng tổn thương giải phẫu bệnh lý thực tế trên ảnh X-quang, mang lại giá trị giải thích cao và củng cố niềm tin cho các y bác sĩ trong quá trình hỗ trợ chẩn đoán.

Chương 5

Kết luận và hướng phát triển

5.1 Kết luận

Khóa luận đã nghiên cứu và đề xuất một hệ thống phân loại ảnh X-quang xương đa phương thức kết hợp khả năng phát hiện dữ liệu ngoài phân phối nhằm hỗ trợ chẩn đoán các bệnh lý cơ xương khớp. Hệ thống khai thác đồng thời hai nguồn thông tin gồm ảnh X-quang và thông tin lâm sàng, từ đó tận dụng được tính bổ sung giữa hai phương thức dữ liệu để nâng cao hiệu quả phân loại.

Trên cơ sở mô hình nền BioMedCLIP, nghiên cứu áp dụng kỹ thuật tinh chỉnh tham số hiệu quả LoRA để thích nghi với miền dữ liệu X-quang xương mà không làm thay đổi toàn bộ trọng số của mô hình. Đặc trưng hình ảnh và văn bản được kết hợp thông qua cơ chế chú ý hai chiều, sau đó được huấn luyện bằng sự kết hợp giữa hàm mất mát Cross-Entropy và Prototypical Loss. Trong đó, Cross-Entropy đảm nhiệm nhiệm vụ tối ưu phân loại, còn Prototypical Loss giúp xây dựng không gian đặc trưng có tính phân biệt cao, tạo tiền đề cho giai đoạn phát hiện dữ liệu ngoài phân phối.

Đối với bài toán phát hiện dữ liệu ngoài phân phối, luận văn lựa chọn phương pháp Mahalanobis Distance theo cơ chế hậu xử lý (post-hoc), với không gian đặc trưng đã được học dựa vào mạng nguyên mẫu. Cách tiếp

cận này tận dụng trực tiếp không gian đặc trưng đã được học trong quá trình huấn luyện để đánh giá mức độ bất thường của mẫu kiểm thử mà không cần thay đổi kiến trúc hoặc huấn luyện lại mô hình. Điều này giúp nâng cao độ tin cậy của hệ thống khi triển khai trong các tình huống lâm sàng thực tế, nơi có thể xuất hiện các bệnh lý hoặc trường hợp chưa từng xuất hiện trong dữ liệu huấn luyện.

Các thực nghiệm được thực hiện trên bộ dữ liệu BTXRD kết hợp với bộ dữ liệu nội bộ CTCH đã cho thấy phương pháp đề xuất đạt hiệu quả tốt trong nhiệm vụ phân loại, đồng thời xây dựng được không gian đặc trưng phù hợp để hỗ trợ phát hiện dữ liệu ngoài phân phối. Kết quả cũng cho thấy việc kết hợp thông tin lâm sàng với ảnh X-quang giúp cải thiện khả năng nhận diện bệnh lý so với việc chỉ sử dụng một nguồn dữ liệu.

Nhìn chung, luận văn đã hoàn thành các mục tiêu nghiên cứu đã đề ra, bao gồm xây dựng mô hình phân loại đa phương thức dựa trên BioMed-CLIP, tối ưu biểu diễn đặc trưng bằng Prototypical Loss và tích hợp cơ chế phát hiện dữ liệu ngoài phân phối dựa trên khoảng cách Mahalanobis. Các kết quả đạt được là cơ sở cho việc phát triển các hệ thống hỗ trợ chẩn đoán có độ tin cậy cao hơn trong lĩnh vực chẩn đoán hình ảnh y khoa.

5.2 Hướng phát triển

Mặc dù đạt được những kết quả khả quan, phương pháp đề xuất vẫn còn một số hạn chế và có thể được mở rộng trong các nghiên cứu tiếp theo.

Thứ nhất, phương pháp phát hiện dữ liệu ngoài phân phối hiện được xây dựng theo hướng hậu xử lý bằng khoảng cách Mahalanobis. Các nghiên cứu tiếp theo có thể khảo sát những phương pháp OOD hiện đại hơn hoặc tích hợp trực tiếp mục tiêu phát hiện OOD vào quá trình huấn luyện để nâng cao khả năng phát hiện các trường hợp Near-OOD.

Thứ hai, phạm vi thực nghiệm của luận văn mới được đánh giá trên bộ dữ liệu BTXRD và bộ dữ liệu CTCH. Trong tương lai, cần mở rộng thực nghiệm trên nhiều bộ dữ liệu X-quang xương có quy mô lớn hơn cũng như đánh giá khả năng tổng quát hóa giữa các bệnh viện, thiết bị chụp và điều kiện thu nhận ảnh khác nhau.

Cuối cùng, hệ thống hiện tập trung vào hai nhiệm vụ chính là phân loại và phát hiện dữ liệu ngoài phân phối. Trong tương lai, có thể tích hợp thêm các phương pháp giải thích mô hình (Explainable AI) hoặc các mô hình ngôn ngữ lớn y khoa nhằm hỗ trợ sinh báo cáo chẩn đoán, giải thích kết quả dự đoán và tăng cường khả năng tương tác với bác sĩ trong quá trình hỗ trợ ra quyết định lâm sàng.

Tài liệu tham khảo

Tiếng Anh

- [1] Shruthi Bannur et al. “Learning to exploit temporal structure for biomedical vision-language processing”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2023, pp. 15016–15027.
- [2] Lynn S. Bickley, Peter G. Szilagyi, and Richard M. Hoffman. *Bates’ Guide to Physical Examination and History Taking*. 13th. Lippincott Williams & Wilkins, 2020.
- [3] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing”. In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5.
- [5] Yin Dai and Yifan Gao. “TransMed: Transformers Advance Multi-modal Medical Image Classification”. In: *CoRR* abs/2103.05940 (2021). arXiv: 2103.05940. URL: <https://arxiv.org/abs/2103.05940>.
- [6] Ye Du, Nanxi Yu, and Shujun Wang. “Medical Knowledge Intervention Prompt Tuning for Medical Image Classification”. In: *IEEE Transactions on Medical Imaging* 44.12 (2025), pp. 4945–4959. DOI: 10.1109/TMI.2025.3584841.
- [7] Xiao Fang et al. “Aligning Medical Images with General Knowledge from Large Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15010. Springer Nature Switzerland, 2024.

- [8] Kaiming He et al. “Deep Residual Learning for Image Recognition”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016.
- [9] Gao Huang et al. “Densely Connected Convolutional Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017.
- [10] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [11] Yijin Huang et al. “Fine-grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-resolution Medical Image Classification”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15012. Springer Nature Switzerland, 2024.
- [12] Taha Koleilat et al. “BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models”. In: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*. 2025, pp. 14766–14776.
- [13] Zhengfeng Lai et al. “CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*. 2023, pp. 2374–2380.
- [14] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: <https://arxiv.org/abs/2306.00890>.
- [15] Zihan Li et al. “LViT: Language Meets Vision Transformer in Medical Image Segmentation”. In: *IEEE Transactions on Medical Imaging* 43.1 (2024), pp. 96–107. DOI: 10.1109/TMI.2023.3291719.

- [16] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: <https://arxiv.org/abs/2401.12215>.
- [17] Mingyuan Liu et al. “Sparsity- and Hybridity-Inspired Visual Parameter-Efficient Fine-Tuning for Medical Diagnosis”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15005. Springer Nature Switzerland, 2024.
- [18] Xueyan Mei et al. “Artificial intelligence-enabled rapid diagnosis of patients with COVID-19”. In: *Nature Medicine* 26 (Aug. 2020), 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: <https://www.nature.com/articles/s41591-020-0931-3>.
- [19] Jong Hak Moon et al. “Multi-Modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training”. In: *IEEE Journal of Biomedical and Health Informatics* 26.12 (2022), pp. 6070–6080. DOI: 10.1109/JBHI.2022.3207502.
- [20] Michael Moor et al. *Med-Flamingo: a Multimodal Medical Few-shot Learner*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.15189. URL: <https://arxiv.org/abs/2307.15189>.
- [21] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.
- [22] Umaima Rahman et al. “Can language-guided unsupervised adaptation improve medical image classification using unpaired images and texts?” In: *2025 IEEE 22nd International Symposium on Biomedical Imaging (ISBI)*. IEEE. 2025, pp. 1–5.
- [23] Bryan C Russell et al. “LabelMe: a database and web-based tool for image annotation”. In: *International journal of computer vision* 77.1-3 (2008), pp. 157–173.

- [24] Nikhil Kumar Tomar et al. “TGANet: Text-Guided Attention for Improved Polyp Segmentation”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2022*. Cham, Switzerland: Springer Nature Switzerland, 2022, pp. 151–160. ISBN: 978-3-031-16437-8. DOI: 10.1007/978-3-031-16437-8_15.
- [25] Tao Tu et al. *Towards Generalist Biomedical AI*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.14334. URL: <https://arxiv.org/abs/2307.14334>.
- [26] Xiaosong Wang et al. “TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018.
- [27] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, Dec. 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: <https://aclanthology.org/2022.emnlp-main.256/>.
- [28] W.B. Saunders. *Dorland’s Illustrated Medical Dictionary*. 32nd. Elsevier Health Sciences, 2011.
- [29] Chaoyi Wu et al. “MedKLIP: Medical Knowledge Enhanced Language-Image Pre-Training for X-ray Diagnosis”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023, pp. 21372–21383.
- [30] Bin Yan and Mingtao Pei. “Clinical-BERT: Vision-Language Pre-training for Radiograph Diagnosis and Reports Generation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 36. 3. 2022, pp. 2982–2990. DOI: 10.1609/aaai.v36i3.20204. URL: <https://doi.org/10.1609/aaai.v36i3.20204>.

- [31] Shunhan Yao et al. “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors”. In: *Scientific Data* 12.1 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y. URL: <https://doi.org/10.1038/s41597-024-04311-y>.
- [32] Chenlu Zhan et al. “UniDCP: Unifying Multiple Medical Vision-Language Tasks via Dynamic Cross-Modal Learnable Prompts”. In: *IEEE Transactions on Multimedia* 26 (2024), pp. 9736–9748. DOI: 10.1109/TMM.2024.3397191.
- [33] Jiajin Zhang et al. “Disease-informed Adaptation of Vision-Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15011. Springer Nature Switzerland, 2024.
- [34] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoa2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoa2400640>.
- [35] Xiaoman Zhang et al. “Knowledge-enhanced visual-language pre-training on chest radiology images”. In: *Nature Communications* 14 (July 2023). DOI: 10.1038/s41467-023-40260-7. URL: <https://arxiv.org/pdf/2302.14042.pdf>.
- [36] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 7th Machine Learning for Healthcare Conference*. Ed. by Zachary Lipton et al. Vol. 182. Proceedings of Machine Learning Research. PMLR, 2022, pp. 2–25. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
- [37] Yunkun Zhang et al. “Text-Guided Foundation Model Adaptation for Pathological Image Classification”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*. Ed. by Hayit Greenspan et al. Cham: Springer Nature Switzerland, 2023, pp. 272–282. ISBN: 978-3-031-43904-9.

- [38] Fudan Zheng et al. “Exploring low-resource medical image classification with weakly supervised prompt learning”. In: *Pattern Recognition* 149 (2024), p. 110250. ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2024.110250>. URL: <https://www.sciencedirect.com/science/article/pii/S0031320324000013>.
- [39] Kaipeng Zheng, Weiran Huang, and Lichao Sun. “TransMed: Large Language Models Enhance Vision Transformer for Biomedical Image Classification”. In: *arXiv preprint arXiv:2312.07125* (2023).
- [40] Hong-Yu Zhou et al. “A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics”. In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).
- [41] Hong-Yu Zhou et al. “Advancing Radiograph Representation Learning with Masked Record Modeling”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=w-x7U26GM7j>.
- [42] Juexiao Zhou et al. “Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4”. In: *Nature Communications* 15 (July 2024). DOI: 10.1038/s41467-024-50043-3. URL: <https://doi.org/10.1038/s41467-024-50043-3>.