

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - Nguyễn Gia Kiệt

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

TP. HỒ CHÍ MINH, THÁNG 08/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - 22127390

Nguyễn Gia Kiệt - 22127221

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

GIẢNG VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

TP. HỒ CHÍ MINH, THÁNG 08/2026

Lời cam đoan

Nhóm xin cam đoan đây là công trình nghiên cứu của riêng nhóm. Dữ liệu và kết quả nghiên cứu trong khóa luận này là trung thực và không trùng lặp với bất kỳ chủ đề nào khác. Nhóm cam đoan toàn bộ nội dung khóa luận này không đạo văn hoặc sao chép từ các công trình nghiên cứu khác. Ngoài ra, trong quá trình nghiên cứu và viết khóa luận, nhóm tuân thủ nghiêm ngặt các quy định về bảo mật do các tập dữ liệu nhóm sử dụng trong nghiên cứu của mình cung cấp. Hơn nữa, nhóm luôn tuân thủ mọi nguyên tắc đạo đức trong suốt quá trình nghiên cứu. Nhóm đảm bảo rằng tất cả các nguồn và tài liệu tham khảo đều được trích dẫn đúng cách và nhóm duy trì tính chính trực học thuật trong mọi khía cạnh công việc của mình.

Lời cảm ơn

Nhóm xin chân thành cảm ơn PGS.TS Lý Quốc Ngọc và ThS. Đỗ Thị Thanh Hà đã dành rất nhiều thời gian, tâm huyết để định hướng, tận tình hướng dẫn và đưa ra những lời khuyên quý báu cho nhóm trong suốt quá trình nghiên cứu và thực hiện khóa luận tốt nghiệp với đề tài "Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức".

Xin trân trọng gửi lời cảm ơn sâu sắc đến Ban Chủ nhiệm cùng toàn thể quý thầy cô Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG-HCM. Những kiến thức nền tảng vững chắc mà các thầy cô đã truyền đạt trong bốn năm học vừa qua và môi trường thí nghiệm tuyệt vời chính là hành trang quan trọng nhất giúp nhóm có thể hoàn thành tốt hướng nghiên cứu này.

Nhóm cũng xin gửi lời cảm ơn đến các y bác sĩ tại Bệnh viện Chấn thương Chỉnh hình TP.HCM, thầy Đỗ Phúc Thịnh và thầy Võ Thế Hào đã hỗ trợ chia sẻ nguồn dữ liệu ảnh X-quang cũng như tư vấn các kiến thức chuyên môn về y khoa, giúp mô hình nghiên cứu bám sát với quy trình chẩn đoán thực tế.

Mặc dù đã có nhiều cố gắng trong quá trình thực hiện, nhưng do hạn chế về mặt thời gian và kinh nghiệm nghiên cứu, khóa luận chắc chắn không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô và hội đồng đánh giá để đề tài được hoàn thiện hơn.

Xin chân thành cảm ơn!



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO HỌC SÂU ĐA PHƯƠNG THỨC

*(Developing a bone X-ray image classification
system based on multimodal deep learning)*

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm Sinh viên thực hiện:

1. Nguyễn Văn Lê Bá Thành (MSSV: 22127390)
2. Nguyễn Gia Kiệt (MSSV: 22127221)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 02/2026 đến 08/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn đầu. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, các nghiên cứu hiện nay đã ứng dụng các mô hình học sâu vào để giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ để đưa vào ứng dụng thực tế. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để bổ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác. Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống.

Khác với các mô hình đơn phương thức chỉ xử lý trên một phương thức như ảnh hay văn bản duy nhất, các mô hình đa phương thức có thể sử dụng nhiều phương thức và tìm ra sự tương quan giữa các phương thức nhằm tạo nên biểu diễn có ý nghĩa hơn từ đó nâng cao hiệu năng của hệ thống. Với thực tế lâm sàng hiện nay, các mô hình nghiên cứu tập trung

vào kết hợp ngôn ngữ và hình ảnh hay còn được gọi là mô hình ngôn ngữ trực quan đang là các mô hình đang nhận được nhiều sự chú ý.

2.2 Định nghĩa các khái niệm

Thông tin lâm sàng

Thông tin lâm sàng là những dữ liệu thu thập trực tiếp qua quá trình bác sĩ thăm khám người bệnh, bao gồm việc khai thác bệnh sử và khám thực thể (nhìn, sờ, gõ, nghe) [23]. Dữ liệu này mang tính chất định hướng ban đầu, giúp bác sĩ khoanh vùng tổn thương và đưa ra các quyết định chỉ định thăm khám chuyên sâu tiếp theo [2].

Thông tin cận lâm sàng

Thông tin cận lâm sàng là các dữ liệu khách quan thu được từ việc áp dụng các trang thiết bị và kỹ thuật y khoa hiện đại (như hình ảnh X-quang, cắt lớp, hay xét nghiệm sinh hóa) [23]. Nếu lâm sàng dùng để định hướng, thì cận lâm sàng cung cấp bằng chứng xác thực từ bên trong cơ thể để chẩn đoán chính xác bệnh lý.

2.3 Phát biểu bài toán

Đầu vào (Input)

Hệ thống nhận vào các nguồn dữ liệu sau:

- Thông tin lâm sàng bao gồm báo cáo cận lâm sàng, khám xét toàn thân, lý do vào viện của bệnh nhân.
- Ảnh X-quang xương của bệnh nhân tương ứng.
- Tập nhãn được định nghĩa trước.


Đầu ra (Output)

Hệ thống sẽ sinh ra các nhãn sau:

- Tỷ lệ mà ảnh và thông tin lâm sàng tương ứng thuộc vào các lớp được định nghĩa trước.
- Ảnh trực quan hóa giải thích cho kết quả.

Kiến trúc tổng quan

Với bài toán này, kiến trúc tổng quan của một mô hình học sâu đa phương thức được sử dụng bao gồm bốn thành phần chính: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại như được thể hiện ở Hình 1.



Hình 1: Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức

Trong đó, bộ mã hóa ảnh có chức năng rút trích đặc trưng từ ảnh đầu vào, bộ mã hóa văn bản có chức năng rút trích đặc trưng từ văn bản đầu vào, bộ dung hợp dữ liệu có chức năng dung hợp hay căn chỉnh các đặc trưng được rút trích từ hai phương thức dữ liệu trên để tạo ra một biểu diễn có ý nghĩa và có đầy đủ tính chất của phương thức đầu vào, đây cũng là mô-đun quan trọng nhất đối với một mô hình học sâu đa phương thức, cuối cùng là bộ phân loại, nhận biểu diễn đặc trưng chung của các phương thức đầu vào để phân loại và đưa ra kết quả cuối cùng.

2.4 Mục tiêu đề tài

Trong bối cảnh già hóa dân số và các tác nhân gây bệnh từ ô nhiễm và lối sống thiếu lành mạnh trong đời sống hiện đại, các bệnh lý về xương và chấn thương có thể ảnh hưởng trực tiếp đến đời sống và tính mạng dẫn đến việc chẩn đoán và tiên lượng để đưa ra hướng điều trị phù hợp đang trở thành gánh nặng cho các y bác sĩ, các hệ thống học sâu đa phương

thức tuy đã phát triển nhưng lại thiếu khả năng giải thích. Đề tài hướng đến phát triển một hệ thống phân loại ảnh X-quang có khả năng:

- Đạt được độ chính xác cao trên các bộ dữ liệu nội bộ và quốc tế.
- Có khả năng giải thích được kết quả.
- Tích hợp kết quả để trợ giúp y bác sĩ trong quá trình chẩn đoán.

2.5 Phạm vi của đề tài

Nội dung nghiên cứu của đề tài tập trung vào việc khảo sát các mô hình nền tảng và thiết kế, huấn luyện, tinh chỉnh, đánh giá kiến trúc được đề xuất trên ảnh X-quang xương và các bộ dữ liệu quốc tế để so sánh, đánh giá với các kiến trúc trước.

Đối tượng nghiên cứu xoay quanh các thành phần bên trong một mạng học sâu đa phương thức bao gồm: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại, tập trung vào các phương pháp dung hợp dữ liệu hình ảnh và văn bản cùng với các phương pháp tinh chỉnh tham số cho các bộ mã hóa đã được huấn luyện trước nhằm tận dụng lại các tri thức đã có và nâng cao hiệu năng trên các tác vụ đích.

Đề tài chủ yếu sử dụng các bộ dữ liệu cặp ảnh - văn bản, không có trường hợp thiếu đã được công bố và bộ dữ liệu nội bộ được thu thập và cung cấp bởi giảng viên có hợp tác với bệnh viện ở khu vực Thành phố Hồ Chí Minh, một số thông tin cơ bản về các bộ dữ liệu được thể hiện ở Bảng 1. Nhóm sử dụng các bộ dữ liệu này nhằm đánh giá hiệu năng của kiến trúc đề xuất thông qua các độ đo phổ biến và tiến hành so sánh với các phương pháp trước đó nhằm chứng minh sự hiệu quả của phương pháp đề xuất.

2.6 Cách tiếp cận dự kiến

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ cung cấp tổng quan tình hình nghiên cứu

Bộ dữ liệu	Nguồn	Loại dữ liệu	Số lượng mẫu	Số lượng lớp
RSNA Pneumonia (2018)	Radiological Society of North America	Ảnh X-quang ngực metadata/tags	30,000	3
CheXpert (2019)	Stanford ML Group - Stanford Hospital	Ảnh X-quang ngực Báo cáo đọc ảnh	224,316	14
MIMIC-CXR v2 (2019)	Beth Israel Deaconess Medical Center	Ảnh X-quang ngực Báo cáo đọc ảnh	227,835	14
SARCOMA-CTCH (2025)	Bệnh viện Chấn Thương Chỉnh Hình - TPHCM	Ảnh X-quang xương Báo cáo đọc ảnh Báo cáo lâm sàng	Đang cập nhật	Đang cập nhật

Bảng 1: Tổng hợp các bộ dữ liệu dự kiến được sử dụng để thí nghiệm

từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

Các mô hình xây dựng từ đầu là các mô hình đơn giản, khởi điểm trong bài toán học sâu đa phương thức, thiết kế và huấn luyện một hệ thống mới từ đầu, điểm chung của các phương pháp này là chúng tập trung vào việc thiết kế các cơ chế để "trộn" (fusion) đặc trưng từ các bộ mã hóa (encoder) chuyên biệt ở các cấp độ khác nhau để tối ưu hóa hiệu suất cho các tác vụ cụ thể, sử dụng những bộ mã hóa hình ảnh đơn giản như CNN.

Khởi điểm vào 2020, X. Mei [15] và đồng nghiệp đã đề xuất lấy đặc trưng được tạo ra từ các lớp cuối của mô hình CNN (véc-tơ 512 chiều) và các đặc trưng từ dữ liệu lâm sàng rồi nối lại. Véc-tơ kết hợp này được đưa vào một mạng MLP cuối cùng để đưa ra dự đoán.

Clinical-BERT [25] và TGANet [20] tìm cách học biểu diễn đa phương thức bằng cách thúc đẩy mô hình hiểu và liên kết (align) các đặc trưng giữa các vùng trong ảnh và các từ khóa trong văn bản báo cáo thông qua các nhiệm vụ tự giám sát (self-supervised objectives), cho phép mô hình học được các biểu diễn ngữ nghĩa chung. Hay LViT [12] đề xuất một kiến trúc hybrid CNN-Transformer "Double-U", cấu trúc CNN-Transformer kết hợp mô-đun Pixel-Level Attention Module để giữ lại các đặc trưng cục bộ của ảnh giúp mô hình giữ được khả năng trích xuất đặc trưng cục bộ mạnh mẽ của CNN, đồng thời tận dụng khả năng mô hình hóa ngữ cảnh toàn cục của Transformer.

Việc chỉ nối các đặc trưng có điểm yếu về sự khác biệt về giá trị hoặc sự ngữ nghĩa lớn giữa các phương thức dữ liệu, IRENE [34] đã đưa tất

cả dữ liệu gốc về dạng token chung và học biểu diễn tổng thể (holistic representation) ngay từ đầu, sử dụng một mô hình Transformer duy nhất học các biểu diễn toàn diện cho cả hai phương thức. IRENE còn sử dụng cơ chế chú ý hai chiều ở cấp độ token để nắm bắt "các kết nối cục bộ".

Nghiên cứu của Dai và cộng sự [4] đề xuất mô hình TransMed, giải quyết bài toán kết hợp đa phương thức bằng cách tích hợp CNN và Transformer. Bằng việc chuyển đổi đặc trưng ảnh từ CNN thành dạng chuỗi để Transformer xử lý, mô hình này tối ưu hóa việc nắm bắt các đặc điểm toàn cục của hình ảnh y khoa. Cách tiếp cận này mang lại hiệu quả cao hơn các kỹ thuật fusion thông thường nhờ khả năng biểu diễn dữ liệu đa phương thức một cách toàn diện và chính xác.

Những nghiên cứu này đã khai phá và chứng minh về tác động tích cực của các phương thức dữ liệu khác như văn bản đến kết quả của việc chẩn đoán hình ảnh, tuy nhiên độ chính xác của các phương thức này còn chưa quá cao bởi các bộ mã hóa và phương pháp dung hợp dữ liệu còn đơn giản.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Kiến trúc mô hình			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	X. Mei [15]	Full Fine-Tuning	Pretrain với Cross-Entropy loss	Inception-ResNet-v2	ResNet-18	Decision-level	N/a
2	Clinical-BERT [25]	Full Fine-Tuning	Cross-modal Repr. Learning	DenseNet121	Uncased BERT-base	Early fusion	N/a
3	LViT [12]	Full Fine-Tuning	Semi-supervised (Pseudo-label)	Hybrid U-shape (CNN + ViT)	BERT_12_768_12	Intermediate	N/a
4	TGANet [20]	Train from scratch	Exponential Pseudo-label Iteration	ResNet50	Không có	Intermediate	N/a
5	IRENE [34]	Train from scratch	BCE Loss & AdamW optimizer	Convolution layer	Pretrained BERT	Simultaneous	Upsampling, FEM, CBAM Attention
6	TransMed [4]	Full Fine-Tuning	Supervised (SGD, 100 epochs)	2D CNN (ResNet18 đến 152)	N/a	Attention fusion	Lớp kết nối đầy đủ (FC Layer)

Bảng 2: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tinh chỉnh của các mô hình kết hợp ngôn ngữ - ảnh

Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu (thường cố gắng dung hợp dữ liệu thô thành một khối thống nhất), Med-VLMs chú trọng vào việc đối chiếu và liên kết chặt chẽ ngữ nghĩa giữa hình ảnh và ngôn ngữ tự nhiên. Cụ thể, kiến trúc của chúng thường kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này khớp với

nhau. Lúc này, bộ phân loại không gán nhãn theo cách truyền thống mà đóng vai trò là một cơ chế đo lường mức độ tương đồng. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Để đạt được khả năng trên, các nghiên cứu tiền huấn luyện Med-VLMs hiện nay đang phát triển chủ yếu theo ba hướng: học tương phản, học có che giấu và tích hợp tri thức y khoa (chi tiết tổng hợp được trình bày tại các Bảng 3, 4, 5).

Thứ nhất, **học tương phản (Contrastive Learning)** là chiến lược được ứng dụng rộng rãi nhất, tiêu biểu với các mô hình như ConVIRT [30], GLoRIA [7], MedCLIP [22] và BiomedCLIP [28]. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau ở mức độ cục bộ lẫn toàn cục. Phương pháp này đem lại hiệu năng ấn tượng; ví dụ, BiomedCLIP [28] (huấn luyện trên 15 triệu cặp dữ liệu) đạt độ chính xác phân loại 83%, trong khi ConVIRT [30] đạt 90,3% trên bộ dữ liệu COVIDx. Mặc dù có ưu điểm vượt trội là khả năng học biểu diễn không cần gán nhãn thủ công, học tương phản vẫn bộc lộ hạn chế về việc tiêu tốn tài nguyên tính toán lớn và rủi ro xảy ra hiện tượng âm tính giả (đẩy xa các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý).

Thứ hai, **học có che giấu (Masked Learning)** là hướng đi tập trung vào mục tiêu tái tạo dữ liệu, với các đại diện nổi bật như MRM [35] và MedViLL [16]. Bằng cách ẩn ngẫu nhiên các vùng ảnh hoặc từ ngữ trong báo cáo y khoa, kiến trúc này buộc mô hình phải dự đoán và khôi phục phần thông tin bị khuyết. Hướng tiếp cận này thể hiện ưu thế rõ rệt trong các môi trường khan hiếm dữ liệu; điển hình là MRM [35] đạt mức 92,7% AUC chỉ với 10% dữ liệu từ tập RSNA. Tuy nhiên, rào cản chính của phương pháp này nằm ở việc phụ thuộc vào nguồn dữ liệu đã được ghép cặp sẵn từ trước, cộng với độ phức tạp tính toán cao của quá trình khôi phục điểm ảnh/token.

Thứ ba, **tích hợp tri thức y khoa (Knowledge Integration)** ra đời nhằm giải quyết những đặc thù phức tạp của ngôn ngữ lâm sàng. Các

mô hình như MedKLIP [24], BioViL [3], BioViL-T [1] và KAD [29] tận dụng đồ thị tri thức (như RadGraph) hoặc dữ liệu chuỗi thời gian để cung cấp tín hiệu giám sát chi tiết về cả loại và vị trí bệnh lý. Cách tiếp cận này giúp giải quyết triệt để sự mơ hồ của các từ vựng diễn tả tiến triển bệnh (ví dụ: "cải thiện", "xấu đi"). Về mặt hiệu năng, KAD [29] đạt 0.966 AUC trên tập PadChest ở thiết lập không mẫu (zero-shot), còn BioViL-T [1] đạt độ chính xác 67,4% trong bài toán phân loại tiến triển bệnh. Dù vậy, các phương pháp này chưa loại bỏ hoàn toàn được hiện tượng âm tính giả và rất dễ gặp sai số nếu nhãn chẩn đoán thực tế nằm ngoài cơ sở tri thức đồ thị gốc.

Dựa trên sự phân tích các ưu và nhược điểm từ những khảo sát trên, hướng tiếp cận đề xuất trong nghiên cứu này được thiết kế có chọn lọc nhằm tối ưu hóa hiệu năng và chi phí:

- **Kế thừa BiomedCLIP [28]:** Tận dụng sức mạnh của các bộ mã hóa đã được huấn luyện với chất lượng cao.
- **Không áp dụng học tương phản & học có che giấu:** Khó khắc phục rào cản về tài nguyên tính toán lớn và giảm thiểu rủi ro gặp phải hiện tượng âm tính giả.
- **Tích hợp tri thức từ UMLS (tương tự MedKLIP [24]):** Sử dụng để làm giàu thêm tri thức trong các báo cáo lâm sàng.

Mặc dù các phương pháp tiền huấn luyện Med-VLMs giúp xây dựng nền tảng tri thức đa phương thức khổng lồ, việc áp dụng trực tiếp vào lâm sàng lại vấp phải rào cản lớn về chi phí tính toán và sự khan hiếm dữ liệu y tế ghép cặp. Để giải quyết vấn đề này, các nghiên cứu thường chuyển hướng sang tinh chỉnh mô hình. Tuy nhiên, nếu tinh chỉnh toàn phần trên một tập dữ liệu nhỏ, sự chênh lệch phân phối sẽ dễ dẫn đến hiện tượng chuyển giao tiêu cực hoặc "quên thảm khốc", làm đánh mất tri thức gốc. Do đó, giới nghiên cứu đang tập trung vào các chiến lược tinh chỉnh hiệu quả tham số (PEFT) nhằm đảm bảo tính linh hoạt, tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các nghiên cứu gần đây được chia thành ba hướng tiếp cận chính:

STT	Tên phương pháp	Phân loại	Nguyên lý
1	ConVIRT (2020)	Học tương phản	Tối ưu bộ mã hoá ảnh và văn bản bằng cách kéo các cặp đặc trưng ảnh-văn bản giống nhau lại gần nhau và đẩy các cặp đặc trưng ảnh-văn bản khác nhau ra xa
2	GLoRIA (2021)	Học tương phản	Dùng hai hàm mất mát global contrastive để kéo các cặp đặc trưng ảnh-văn bản, trong khi đó hàm mất mát local contrastive học cách căn chỉnh chi tiết của các vùng trong ảnh và các từ trong câu
3	MedCLIP (2022)	Học tương phản	Đề xuất cơ chế tách cặp và trích xuất tri thức, và đề xuất hàm mất mát Semantic Matching nhằm giải quyết vấn đề false negative
4	BiomedCLIP (2023)	Học tương phản	Có cơ chế tương tự như CLIP nhưng được tiền huấn luyện với bộ dữ liệu PMC-15M
5	MRM (2023)	Học có che giấu	Ẩn ngẫu nhiên các thông tin trong văn bản và các vùng trong ảnh để cho mô hình dự đoán lại ảnh và văn bản hoàn chỉnh.
6	MedViLL (2022)	Học có che giấu	Đề xuất một kiến trúc dựa trên BERT kết hợp với một mặt nạ chú ý mới được đề xuất (BAR) cho phép ảnh tương tác tự do với văn bản trong các tác vụ hiểu, đồng thời đảm bảo tính tự hồi quy cho các token trong văn bản trong các tác vụ sinh
7	BioViL (2022)	Tích hợp kiến thức y khoa	Đề xuất một bộ mã hoá văn bản CXR-BERT được tối ưu cho ảnh X-quang, duy trì hàm mất mát MLM để giúp mô hình giữ lại được các kiến thức văn bản trong quá trình căn chỉnh với ảnh
8	BioViL-T (2023)	Tích hợp kiến thức y khoa	Sử dụng các ảnh X-quang từ trước kết hợp với ảnh hiện tại để học được các đặc trưng không gian, thời gian từ đó giải thích cho các từ vụng như "cải thiện" giúp giảm đi sự mơ hồ trong báo cáo
9	MedKLIP (2023)	Tích hợp kiến thức y khoa	Đề xuất một mô-đun trích xuất bộ ba và cơ chế mã hoá tăng cường tri thức, từ đó tạo ra biểu diễn tốt hơn cho văn bản
10	KAD (2023)	Tích hợp kiến thức y khoa	Tích hợp kiến thức y khoa vào quá trình tiền huấn luyện để giúp mô hình học các biểu diễn có ý nghĩa hơn

Bảng 3: Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Mục tiêu tiền huấn luyện	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	CL	GCL	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	CL	LCL, GCL	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	CL	GCL	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	CL	GCL	ViT-Base	PubMedBERT	Contrastive Alignment	N/a
5	MRM (2023)	MP	MIM, MLM	Kiến trúc giống ViT	WordPiece	Global Context Injection	Văn bản: Transformer; Hình ảnh: Fully Connected
6	MedViLL (2022)	HA	MLM, ITM	ResNet50	BERT	Cross-modal Self-Attention	Multi-Layer Perceptron
7	BioViL (2022)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
8	BioViL-T (2023)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
9	MedKLIP (2023)	CL	LCL	ResNet50	ClinicalBERT	Knowledge-enhanced Alignment	Contrastive head, Cross-Entropy head
10	KAD (2023)	HA	CL, Disease Diagnosis Prediction	ResNet50, ViT-Base	PubMedBERT	Contrastive Alignment	Disease Query Network

Bảng 4: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;

STT	Tên phương pháp	Bộ dữ liệu tiền huấn luyện	Hiệu năng			
			Tác vụ	Bộ dữ liệu đánh giá	Độ đo	Kết quả
1	ConVIRT (2020)	MIMIC-CXR, Private Bone image	- Phân loại ảnh - Phân loại ít mẫu	RSNA Pneumonia, CheXpert, COVIDx, MURA	AUC, Accuracy	- Phân loại ít mẫu: RSNA (1%): 88.8% AUC, (10%): 91.5% AUC; CheXpert (1%): 87.0% AUC, (10%): 88.1% AUC; MURA (1%): 81.3% AUC, (10%): 86.5% AUC - Phân loại ảnh: RSNA: 92.7% AUC, CheXpert: 88.1% AUC, MURA: 89.0% AUC; COVIDx 90.3% ACC
2	GLoRIA (2021)	CheXpert	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	CheXpert, RSNA Pneumonia	AUROC	- Phân loại không mẫu: CheXpert 5x200: 0.61 ACC, 0.67 F1; RSNA: 0.70 ACC, 0.58 F1; - Phân loại ít mẫu: CheXpert (1%): 86.6 AUC, (10%): 87.8 AUC, RSNA (1%): 86.1 AUC, (10%): 88.0 AUC - Phân loại ảnh: CheXpert: 88.1 AUC, RSNA: 88.6 AUC
3	MedCLIP (2022)	MIMIC-CXR, CheXpert	- Phân loại ảnh - Phân loại không mẫu	MIMIC-5x200, COVID, RSNA Pneumonia	Mean Accuracy	- Phân loại không mẫu: CheXpert-5x200: 0.5942 ACC; MIMIC-5x200: 0.5430 ACC; COVID: 0.8472 ACC; RSNA: 0.7682 ACC - Phân loại ảnh: CheXpert-5x200: 0.5960 ACC; MIMIC-5x200: 0.5650 ACC; COVID: 0.7890 ACC; RSNA: 0.8075 ACC
4	BiomedCLIP (2023)	PMC-15M	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PCam, LC25000 (Lung, Colon), TCGA-TIL, RSNA Pneumonia	AUC, Accuracy	- Phân loại không mẫu: PCam: 73.41% ACC; LC25000 Lung 65.23% ACC; LC25000 Colon 92.98%; RSNA 78.95%; TCGA-TIL: 67.04% - Phân loại ít mẫu: PCam (1%): 82% ACC, (10%): 83%; RSNA (1%): 77% ACC, (10%): 82% ACC - Phân loại ảnh: PCam: 83% ACC, RSNA: 83% ACC
5	MRM (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu	CheXpert, NIH ChestX-ray, RSNA Pneumonia, COVID-19 Image Data Collection	AUC, Accuracy	- Phân loại ít mẫu: CheXpert (1%): 88.5 AUC, (10%): 88.5 AUC; RSNA (1%): 91.3 AUC, (10%): 92.7 AUC; NIH ChestX-ray (1%): 79.4 AUC, (10%): 84.0 AUC - Phân loại ảnh: CheXpert: 88.7 AUC, RSNA 93.3, NIH ChestX-ray: 85.9, COVID-19: 85.8
6	MedViLL (2022)	MIMIC-CXR	- Phân loại chẩn đoán	MIMIC-CXR, Open-I	Micro-averaged AUROC, Micro-averaged F1 score	- Phân loại ảnh: MIMIC-CXR: 0.980 avg AUROC, 0.839 F1; Open-I: 0.892 avg AUROC, 0.407 F1
7	BioViL (2022)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	RSNA Pneumonia	Accuracy, F1-score, AUROC, Sensitivity Specificity.	- Phân loại không mẫu: RSNA: 0.732 ACC, 0.831 AUC; ChestX-ray14: 0.6912 AUC - Phân loại ít mẫu: RSNA (1%): 0.805 ACC, 0.881 AUC; (10%): 0.812 ACC, 0.884 AUC - Phân loại ảnh: RSNA: 0.822 ACC, 0.891 AUC
8	BioViL-T (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu - Phân loại ảnh tiến triển	MS-CXR-T, RSNA Penumonia, Chest ImaGenome	Macro-Accuracy, Accuracy, F1, AUROC.	- Phân loại Tiến triển: MS-CXR-T: 67.4% Acc - Phân loại không mẫu: RSNA: 0.805 ACC, 0.871 AUC - Phân loại ít mẫu: RSNA (1%): 0.814 ACC, 0.890 AUC
9	MedKLIP (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại không mẫu	ChestX-ray14, RSNA Pneumonia, SIIM-ACR Pneumothorax, COVIDx CXR-2, COVID Rural, Edema Severity	AUC, F1-score, Accuracy.	- Phân loại không mẫu: RSNA: 0.8694 AUC, 0.6342 F1; SIIM-ACR: 0.8924 AUC, 0.6833 F1; ChestX-ray14: 0.7676 AUC, 0.2525 F1; COVID-19: 0.7396 AUC, 0.7670 F1 - Phân loại ít mẫu: ChestX-ray14 (1%): 0.7721 AUC, (10%): 0.7894; RSNA (1%): 0.8731 AUC, (10%): 0.8799 AUC - Phân loại mẫu: ChestX-ray14: 0.8323 AUC, RSNA 0.8931
10	KAD (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PadChest, NIH ChestXray14, CheXpert, ChestX-Det	AUC, F1-Score, MCC	- Phân loại không mẫu: PadChest: 0.966 AUC; CheXpert: 0.905 AUC, 0.647 F1, 0.589 MCC - Phân loại ít mẫu: ChestXray-14 (1%): 0.78 AUC, 0.31 F1; (10%): 0.80 AUC, 0.33 F1 - Phân loại ảnh: ChestXray-14: 0.82 AUC, 0.34 F1

Bảng 5: Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

Tinh chỉnh sử dụng câu nhắc (Prompt Tuning): Hướng này chèn thêm các tham số có thể học được vào không gian đầu vào của mô hình. Các phương pháp như CITE [31], FPT [8] hay PLIP [27] khai thác đặc trưng thị giác kết hợp với tri thức lâm sàng, cho thấy hiệu quả vượt trội ngay cả khi thiếu hụt dữ liệu (ví dụ: PLIP đạt 0.896 AUC chỉ với 5% dữ liệu PanNuke). Nhằm giải quyết khó khăn khi thiết kế thủ công, MedPrompt [32] và UniDCP [26] tự động sinh câu nhắc động dựa trên ngữ cảnh ảnh để xử lý đa tác vụ. Gần đây hơn, việc tích hợp Mô hình ngôn ngữ Lớn (LLM) qua ViP [6], CILMP [5] và BiomedCoOp [9] giúp tạo sinh các câu nhắc ngữ nghĩa sâu sắc, đồng bộ hóa qua cơ chế chú ý chéo và cân chỉnh tương phản, mang lại hiệu năng cao trong các kịch bản ít mẫu hoặc không mẫu.

Tinh chỉnh bộ điều hợp (Adapter Tuning): Thay vì can thiệp ở đầu vào, phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ giữa các lớp của kiến trúc gốc. Điển hình, CLIPath [10] sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu nhỏ; FTB [18] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức. Ở hướng bán giám sát, mô hình MedUnA [19] dùng LLM tạo nhãn giả và tinh chỉnh không giám sát bộ điều hợp trên ảnh chưa gán nhãn, giúp mô hình thích ứng tốt mà không thay đổi trọng số.

Tinh chỉnh chọn lọc (Selective Tuning): Hướng đi này tối ưu hóa kiến trúc bằng cách chỉ cập nhật một lượng nhỏ các trọng số quyết định hiệu năng. TransMed [33] kết hợp LLM để chuyển đổi nhãn bệnh thành mô tả chi tiết, trong khi SH-PEFT [14] chỉ tìm và cập nhật các trọng số quan trọng nhất trên bộ mã hóa thị giác nhằm khai thác tính thừa thớt của mạng. Tương tự, LCBP [13] áp dụng kỹ thuật LoRA để tinh chỉnh tham số hiệu quả cho Med-VLMs, giúp bám sát hiệu năng của tinh chỉnh toàn phần (đạt 93.1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn) nhưng giảm thiểu tối đa chi phí tính toán.

Tóm lại, các phương pháp tinh chỉnh hiệu quả tham số (PEFT) thể hiện ưu điểm vượt trội trong việc tiết kiệm tài nguyên tính toán, ngăn chặn hiện tượng quên tri thức và giúp mô hình thích ứng tốt ngay cả khi đối mặt với các bộ dữ liệu y tế khan hiếm. Tuy nhiên, hướng tiếp cận này vẫn tồn tại một số hạn chế nhất định. Hiệu năng cuối cùng của hệ thống

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	CITE (2023)	Parameter-efficient fine tuning	Visual prompt tuning	CLIP ViT-Base, ImageNet-21k ViT-Base, INTERN ViT-Base	BioLinkBERT-large, BioBERT-large , Kế thừa CLIP	Contrastive Alignment	N/a
2	UniDCP (2023)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	CLIP ViT	RoBERTa	Cross Attention, Contrastive Alignment	N/a
3	ViP (2024)	Parameter-efficient fine tuning	Textual prompt tuning	ViT-Base	Kế thừa CLIP	Cross Attention, Contrastive Alignment	N/a
4	PLIP (2024)	Parameter-efficient fine tuning	Visual prompt tuning, Efficient Selective tuning	ViT-Base	Kế thừa CLIP	Concatnate	N/a
5	FPT (2024)	Parameter-efficient fine tuning	Visual prompt tuning	ViT-Base	N/a	Cross Attention	N/a
6	MedPrompt (2024)	Parameter-efficient fine tuning	Textual prompt tuning	Swin Transformer, ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
7	CILMP (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	ViT-Base	Kế thừa CLIP	Hadamard Product, Concatnate	N/a
8	BiomedCoOp (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	Kế thừa BiomedCLIP	Kế thừa BiomedCLIP	Contrastive Alignment	N/a
9	CLIPath (2023)	Parameter-efficient fine tuning	Adapter tuning	ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
10	FTB (2024)	Parameter-efficient fine tuning	Adapter tuning	ResNet autoencoder, DINOv2-small, DINOv2-base	BERT, BioBERT, ClinicalBERT, CXR-BERT, PubMedBERT	Cross Attention	N/a
11	MedUnA (2024)	Parameter-efficient fine tuning	Adapter tuning	ViT-Base, MedCLIP-Swin	Kế thừa CLIP, MedCLIP	No Fusion	N/a
12	TransMed (2023)	Parameter-efficient fine tuning	Direct Selective tuning	Swin Transformer, ViT-Base	BERT, LLM/GPT-4	Contrastive Alignment	N/a
13	SH-PEFT (2024)	Parameter-efficient fine tuning	Direct Selective tuning	ViT-Base	Kế thừa CLIP	No Fusion	N/a
14	LCBB (2024)	Parameter-efficient fine tuning	Efficient Selective tuning	Kế thừa MAE, MRM	Kế thừa MAE, MRM	Kế thừa MAE, MRM	N/a

Bảng 6: Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan

phụ thuộc rất lớn vào chất lượng của mô hình tiền huấn luyện gốc. Đồng thời, quá trình thiết kế câu nhắc mang đậm tính chuyên môn hay xác định vị trí tối ưu để chèn bộ điều hợp thường phức tạp và đòi hỏi nhiều thử nghiệm. Ngoài ra, việc bổ sung các thành phần này ít nhiều làm tăng tính "hộp đen" của mô hình, gây ra những thách thức về tính minh bạch khi cần giải thích các quyết định dự đoán cho bác sĩ trên thực tế lâm sàng.

Các mô hình ngôn ngữ lớn y khoa đa phương thức

Trong thời gian gần đây, với sự phát triển của các mô hình ngôn ngữ lớn được huấn luyện trên những tập dữ liệu rất lớn phục vụ cho rất nhiều tác vụ khác nhau, các mô hình này đang thể hiện sự ảnh hưởng và đa dụng trong lĩnh vực y tế với độ chính xác rất tốt khi chỉ học ít mẫu hoặc không mẫu.

Med-Flamingo [17] là mô hình đầu tiên có khả năng học ít mẫu chuyên dụng cho y tế, thông qua hội thoại tự nhiên để hỗ trợ chẩn đoán. Theo sau đó, LLaVA-Med [11] là mô hình chuyển đổi khả năng thực hiện theo chỉ dẫn (instruction-following) từ miền tổng quát sang lĩnh vực y sinh bằng cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn với 600.000 cặp, với dữ liệu hội thoại tạo ra từ chú thích ảnh y khoa được tạo ra bằng cách sử dụng GPT-4. Phương pháp này đã đề xuất quy trình huấn luyện 2 bước: (1) Căn chỉnh khái niệm; (2) Tinh chỉnh chỉ dẫn đầy đủ; 2 bước này tương ứng với giai đoạn học và suy luận. Kết quả thể hiện khả năng suy luận vượt trội trên dữ liệu chưa từng thấy.

Med-Palm M [21] là mô hình của Google, đánh dấu bước tiến từ các mô hình đơn nhiệm sang đa nhiệm quy mô lớn, có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì sử dụng các mô hình chuyên biệt cho từng tác vụ. Gần đây hơn, SkinGPT-4 [36] là hệ thống chẩn đoán da liễu tương tác đầu tiên sử dụng LLM quy mô lớn với độ chính xác cao, đã kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM), tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Dù đưa đến các phương pháp có độ chính xác cao đến rất cao trong nhiều tác vụ cùng việc hỗ trợ trong việc giao tiếp với mô hình, kích cỡ và chi phí huấn luyện (Med-Flamingo có đến 9 tỷ thông số) để vận hành các

mô hình ngôn ngữ lớn đa phương thức là một vấn đề lớn, đi kèm với vấn đề ảo giác có thể gặp phải khi đối mặt với dữ liệu mới hoặc những câu hỏi phức tạp. Ngoài ra nếu yêu cầu một độ chính xác cao - một yêu cầu quan trọng trong lĩnh vực y tế trong một tác vụ cụ thể thì đây không phải một cách tiếp cận tốt cho bài toán này.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Cấu trúc phương pháp			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	Med-Flamingo [17]	PEFT	Parameter-efficient + Domain adaptation	Frozen CLIP ViT	LLaMA-7B	Intermediate fusion	LLaMA Decoder
2	LLaVA-Med [11]	Full FT	Visual Instruction Tuning (GPT-4 data)	CLIP ViT-L/14	LLaMA	Projection Matrix	LLM (Vicuna)
3	Med-PaLM M [21]	Full FT	Instruction Fine-tuning	ViT (4B - 22B)	PaLM	Multimodal embedding	PaLM
4	SkinGPT-4 [36]	PEFT	LoRA	Vision Transformer	GPT-4	Linear alignment	LLaMA-2-13B


Bảng 7: Tổng hợp chiến lược và cấu trúc các mô hình ngôn ngữ lớn đa phương thức

Phương pháp đề xuất: Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế theo hướng tích hợp tri thức y khoa nhằm nâng cao khả năng giải thích của mô hình được minh họa ở Hình 2. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Bộ mã hóa ảnh:** Kế thừa lại mô hình ViT-Base của phương pháp BiomedCLIP [28]
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [28]
- **Bộ dung hợp dữ liệu:** Nhóm hướng đến sử dụng cơ chế *Knowledge-guided Cross-Attention* - Các khái niệm y học được trích xuất và liên kết từ văn bản lâm sàng sẽ được sử dụng để tạo thiên lệch trong quá trình tính toán cross attention. Cơ chế này giúp điều hướng mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Nhờ đó, mô hình không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.

- **Bộ phân loại:** Sử dụng một mạng phân loại (Multi-Layer Perceptron) để dự đoán nhãn bệnh lý.

Đồng thời, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán.



Hình 2: Kiến trúc tổng thể của hệ thống đề xuất

2.7 Kết quả dự kiến của đề tài

- **Số liệu định lượng:** Độ chính xác, điểm F1, AUC-ROC đạt kết quả cạnh tranh trên các bộ dữ liệu đã nêu.
- **Sản phẩm đầu ra:**
 - Hệ thống demo phân loại ảnh X-quang xương với khả năng nhận ảnh và văn bản và trả ra các lớp thuộc bộ dữ liệu Sarcoma-CTCH.
 - Giao diện đơn giản để hiển thị kết quả phân loại.
 - Cho phép trực quan hóa sau khi hiện kết quả phân loại.
- **Báo cáo khoa học:** hoàn thiện phương pháp và hệ thống để hướng tới công bố trên các hội nghị và tạp chí uy tín trong lĩnh vực Trí tuệ nhân tạo và Y sinh, như MICCAI, CVPR hoặc các tạp chí được công nhận.
- **Hướng phát triển:**
 - Mở rộng ra cho các bệnh lý khác.
 - Cải thiện độ chính xác và hiệu suất của hệ thống.

2.8 Kế hoạch thực hiện

Mục tiêu	Thời gian	Phân công	Nội dung
Khoá luận tốt nghiệp	01 tháng	Giai đoạn 1	
		Bá Thành	Khảo sát tổng quan về bài toán phân loại ảnh X-quang về xương
		Gia Kiệt	Khảo sát các mô hình tiền huấn luyện trên dữ liệu y khoa
		Bá Thành	Khảo sát các phương pháp học chuyển giao và các mô hình liên quan
	02 tháng	Giai đoạn 2	
		Cả nhóm	Phát triển mô hình học sâu đa phương thức áp dụng phương pháp học chuyển giao
		Gia Kiệt	Cài đặt môi trường, thu thập các bộ dữ liệu liên quan
		Bá Thành	Thực hiện thí nghiệm trên mô hình đề xuất
	02 tháng	Giai đoạn 3	
		Bá Thành	Phân tích so sánh kết quả thực nghiệm.
		Gia Kiệt	Xây dựng nguyên mẫu cho hệ thống phân loại
	0.5 tháng	Giai đoạn 4	
		Cả nhóm	Viết 01 bài báo khoa học cho hội nghị - tạp chí chuyên ngành trong nước hoặc ngoài nước
	0.5 tháng	Giai đoạn 5	
		Bá Thành	Viết báo cáo khoá luận tốt nghiệp.
		Gia Kiệt	Thiết kế slide cho lễ bảo vệ đề tài tốt nghiệp

Bảng 8: Kế hoạch bố trí thời gian nghiên cứu

Tài liệu tham khảo

- [1] Shruthi Bannur et al. “Learning to exploit temporal structure for biomedical vision-language processing”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2023, pp. 15016–15027.
- [2] Lynn S. Bickley, Peter G. Szilagyi, and Richard M. Hoffman. *Bates’ Guide to Physical Examination and History Taking*. 13th. Lippincott Williams & Wilkins, 2020.
- [3] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing”. In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5.

- [4] Yin Dai and Yifan Gao. “TransMed: Transformers Advance Multi-modal Medical Image Classification”. In: *CoRR* abs/2103.05940 (2021). arXiv: 2103.05940. URL: <https://arxiv.org/abs/2103.05940>.
- [5] Ye Du, Nanxi Yu, and Shujun Wang. “Medical Knowledge Intervention Prompt Tuning for Medical Image Classification”. In: *IEEE Transactions on Medical Imaging* 44.12 (2025), pp. 4945–4959. DOI: 10.1109/TMI.2025.3584841.
- [6] Xiao Fang et al. “Aligning Medical Images with General Knowledge from Large Language Models”. In: *International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. 2024. URL: <https://papers.miccai.org/miccai-2024/062-Paper1358.html>.
- [7] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [8] Yijin Huang et al. “Fine-Grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-Resolution Medical Image Classification”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Cham: Springer Nature Switzerland, 2024, pp. 124–134. ISBN: 978-3-031-72390-2.
- [9] Tarek Koleilat et al. “BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2025.
- [10] Zhengfeng Lai et al. “CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*. 2023, pp. 2374–2380.

- [11] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: <https://arxiv.org/abs/2306.00890>.
- [12] Zihan Li et al. “LViT: Language Meets Vision Transformer in Medical Image Segmentation”. In: *IEEE Transactions on Medical Imaging* 43 (Jan. 2024), pp. 96–107. DOI: 10.1109/tmi.2023.3291719. (Visited on 02/19/2024).
- [13] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: <https://arxiv.org/abs/2401.12215>.
- [14] Mingyuan Liu et al. “Sparsity- and Hybridity-Inspired Visual Parameter-Efficient Fine-Tuning for Medical Diagnosis”. In: *MICCAI (5)*. Vol. 15005. Lecture Notes in Computer Science. Springer, 2024, pp. 627–637. DOI: 10.1007/978-3-031-72086-4_59. URL: https://doi.org_59.
- [15] Xueyan Mei et al. “Artificial intelligence-enabled rapid diagnosis of patients with COVID-19”. In: *Nature Medicine* 26 (Aug. 2020), 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: <https://www.nature.com/articles/s41591-020-0931-3>.
- [16] Jong Hak Moon et al. “Multi-Modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training”. In: *IEEE Journal of Biomedical and Health Informatics* 26.12 (2022), pp. 6070–6080. DOI: 10.1109/JBHI.2022.3207502.
- [17] Michael Moor et al. *Med-Flamingo: a Multimodal Medical Few-shot Learner*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.15189. URL: <https://arxiv.org/abs/2307.15189>.
- [18] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.

- [19] Umair Rahman et al. “Can language-guided unsupervised adaptation improve medical image classification using unpaired images and texts?” In: *2025 IEEE 22nd International Symposium on Biomedical Imaging (ISBI)*. IEEE. 2025, pp. 1–5.
- [20] Nikhil Kumar Tomar et al. “TGANet: Text-Guided Attention for Improved Polyp Segmentation”. In: *Lecture notes in computer science* (Jan. 2022), pp. 151–160. DOI: 10.1007/978-3-031-16437-8_15. (Visited on 09/04/2024).
- [21] Tao Tu et al. *Towards Generalist Biomedical AI*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.14334. URL: <https://arxiv.org/abs/2307.14334>.
- [22] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, Dec. 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: <https://aclanthology.org/2022.emnlp-main.256/>.
- [23] W.B. Saunders. *Dorland’s Illustrated Medical Dictionary*. 32nd. Elsevier Health Sciences, 2011.
- [24] Chaoyi Wu et al. “MedKLIP: Medical Knowledge Enhanced Language-Image Pre-Training for X-ray Diagnosis”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023, pp. 21372–21383.
- [25] Bin Yan and Mingtao Pei. “Clinical-BERT: Vision-Language Pre-training for Radiograph Diagnosis and Reports Generation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence* 36 (June 2022), pp. 2982–2990. DOI: 10.1609/aaai.v36i3.20204. (Visited on 07/08/2022).
- [26] Chenlu Zhan et al. “UniDCP: Unifying Multiple Medical Vision-Language Tasks via Dynamic Cross-Modal Learnable Prompts”. In:

- IEEE Transactions on Multimedia* 26 (2024), pp. 9736–9748. DOI: 10.1109/TMM.2024.3397191.
- [27] Jiajin Zhang et al. “Disease-Informed Adaptation of Vision-Language Models”. In: *IEEE Transactions on Medical Imaging* 44.10 (2025), pp. 3984–3996. DOI: 10.1109/TMI.2024.3475877.
 - [28] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoa2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoa2400640>.
 - [29] Xiaoman Zhang et al. “Knowledge-enhanced visual-language pre-training on chest radiology images”. In: *Nature Communications* 14 (July 2023). DOI: 10.1038/s41467-023-40260-7. URL: <https://arxiv.org/pdf/2302.14042.pdf>.
 - [30] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 38th International Conference on Machine Learning*. Ed. by Marina Meila and Tong Zhang. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 12133–12145. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
 - [31] Yunkun Zhang et al. “Text-Guided Foundation Model Adaptation for Pathological Image Classification”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*. Ed. by Hayit Greenspan et al. Cham: Springer Nature Switzerland, 2023, pp. 272–282. ISBN: 978-3-031-43904-9.
 - [32] Fudan Zheng et al. “Exploring low-resource medical image classification with weakly supervised prompt learning”. In: *Pattern Recognition* 149 (2024), p. 110250. ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2024.110250>. URL: <https://www.sciencedirect.com/science/article/pii/S0031320324000013>.
 - [33] Kaipeng Zheng, Weiran Huang, and Lichao Sun. “TransMed: Large Language Models Enhance Vision Transformer for Biomedical Image Classification”. In: *arXiv preprint arXiv:2312.07125* (2023).

- [34] Hong-Yu Zhou et al. “A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics”. In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).
- [35] Hong-Yu Zhou et al. “Advancing Radiograph Representation Learning with Masked Record Modeling”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=w-x7U26GM7j>.
- [36] Juexiao Zhou et al. “Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4”. In: *Nature Communications* 15 (July 2024). DOI: 10.1038/s41467-024-50043-3. URL: <https://doi.org/10.1038/s41467-024-50043-3>.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 05 tháng 04 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Đề cương chi tiết	
Mục lục	i
Danh sách hình	v
Danh sách bảng	vi
Danh mục ký hiệu	ix
Tóm tắt	xi
1 Giới thiệu	1
1.1 Bối cảnh và lý do chọn đề tài	1
1.2 Động lực nghiên cứu	3
1.2.1 Kịch bản thực tế	3
1.2.2 Ý nghĩa khoa học của đề tài	5
1.2.3 Ý nghĩa thực tiễn của đề tài	5
1.3 Giới thiệu bài toán	6
1.3.1 Đầu vào	6
1.3.2 Đầu ra	7
1.3.3 Các thách thức trong bài toán	7
1.4 Mục tiêu nghiên cứu	8
1.5 Đối tượng nghiên cứu	9

1.6	Phạm vi nghiên cứu	10
1.7	Câu hỏi nghiên cứu	11
1.8	Đóng góp chính của đề tài	11
1.9	Bố cục khóa luận	13
2	Các công trình nghiên cứu liên quan	14
2.1	Các hướng tiếp cận chính và các mô hình nền tảng	15
2.1.1	Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu	15
2.1.2	Mô hình ngôn ngữ trực quan y khoa	16
2.2	Các kỹ thuật tinh chỉnh hiệu quả tham số	19
2.2.1	Tinh chỉnh sử dụng câu nhắc	20
2.2.2	Tinh chỉnh bộ điều hợp	20
2.2.3	Tinh chỉnh thích nghi hạng thấp	21
2.3	Các phương pháp phát hiện dữ liệu ngoài phân phối	22
2.3.1	Các phương pháp hậu xử lý dựa trên đầu ra của mô hình	22
2.3.2	Các phương pháp dựa trên độ không chắc chắn và tái tạo	23
2.3.3	Các phương pháp dựa trên khoảng cách	23
2.3.4	Học biểu diễn phục vụ phát hiện dữ liệu ngoài phân phối	24
2.4	Các phương pháp giải thích và đánh giá độ trung thực	25
2.5	Bàn luận	26
2.5.1	Hạn chế của các nghiên cứu hiện nay	26
2.5.2	Cơ sở lựa chọn và định hướng phương pháp đề xuất	27
3	Phương pháp đề xuất	30
3.1	Tổng quan phương pháp đề xuất	30
3.2	Nhánh biểu diễn ảnh	31
3.2.1	Tiền xử lý ảnh X-quang theo kỹ thuật Letterbox	31
3.2.2	Bộ mã hóa thị giác BiomedCLIP	34
3.3	Nhánh biểu diễn văn bản	35
3.3.1	Tiền xử lý và mã hóa đầu vào	35
3.3.2	Bộ mã hóa văn bản BiomedCLIP	36

3.4	Thích nghi tham số bằng LoRA	36
3.5	Dung hợp đa phương thức bằng chú ý chéo	37
3.6	Bộ phân lớp bằng tâm lớp thực nghiệm	40
3.7	Huấn luyện hai giai đoạn trong quá trình ngoại tuyến . . .	42
3.7.1	Giai đoạn 1: thích nghi miền bằng khớp ngữ nghĩa	42
3.7.2	Giai đoạn 2: học dung hợp và phân lớp	44
3.8	Suy luận trong quá trình trực tuyến	46
4	Thực nghiệm và kết quả	51
4.1	Thiết kế thực nghiệm	51
4.1.1	Chuẩn bị dữ liệu	51
4.1.2	Nội dung thực nghiệm	57
4.1.3	Độ đo đánh giá	60
4.1.4	Cấu hình thực nghiệm	66
4.2	Kết quả theo câu hỏi nghiên cứu	67
4.2.1	RQ1: Hiệu năng phân lớp và đánh đổi chi phí . . .	67
4.2.2	RQ2: Ảnh hưởng của quy trình huấn luyện và dung hợp	70
4.2.3	RQ3: Khả năng và giới hạn của cảnh báo OOD hậu xử lý	71
4.2.4	RQ4: Tích phân gradient và can thiệp nguồn đầu vào	72
5	Kết luận và hướng phát triển	74
5.1	Tổng kết	74
5.2	Trả lời các câu hỏi nghiên cứu	75
5.2.1	RQ1: Hiệu năng phân lớp và chi phí	75
5.2.2	RQ2: Ảnh hưởng của các thành phần XBone-Net .	75
5.2.3	RQ3: Phân biệt dữ liệu ngoài phân phối	76
5.2.4	RQ4: Vai trò của các nguồn thông tin trong lời giải thích	76
5.3	Hướng phát triển	76
	Tài liệu tham khảo	78

A	Chi tiết về bộ dữ liệu	84
A.1	Bộ dữ liệu BTXRD	84
A.1.1	Cấu trúc lưu trữ và đặc điểm kỹ thuật	84
A.1.2	Phương pháp tạo dữ liệu giả lâm sàng	85
A.2	Bộ dữ liệu CTCH	91
A.2.1	Cấu trúc dữ liệu và đặc điểm kỹ thuật	92
B	Cấu hình chi tiết của XBone-Net	97
B.1	Mô hình nền tảng và chuẩn hóa đầu vào	97
B.2	Kích thước biểu diễn qua các thành phần	98
B.3	Cấu hình thích nghi hạng thấp	99
B.4	Dung hợp và đầu phân lớp	100
B.5	Cấu hình huấn luyện	101
C	Kết quả chi tiết theo từng hạt giống	102
C.1	Phạm vi trình bày	102
C.1.1	Khả năng chuyển giao trực tiếp của các mô hình nền tảng	103
C.1.2	Vai trò của ảnh và văn bản	104
C.2	Phân loại khi sử dụng toàn bộ dữ liệu huấn luyện	106
C.3	Nghiên cứu loại bỏ từng thành phần	108
C.4	Kết quả đánh giá dữ liệu ngoài phân phối	109

Danh sách hình

1.1	Sơ đồ quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam)	3
1.2	Sơ đồ tích hợp hệ thống hỗ trợ phân tích (các khối tím) vào quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam)	4
3.1	Sơ đồ tổng quan phương pháp XBone-Net đề xuất	30
3.2	Quy trình tiền xử lý ảnh X-quang	32
3.3	Mô-đun dung hợp bằng chú ý chéo hai chiều	38
3.4	Phân lớp vectơ đặc trưng tổng hợp trong không gian nguyên mẫu	41
3.5	Giai đoạn thích nghi miền bằng khớp ngữ nghĩa ảnh-văn bản	42
3.6	Giai đoạn học dung hợp và phân lớp bằng tâm cụm thực nghiệm	45
3.7	Quy trình suy luận trực tuyến và phát hiện mẫu ngoài phân phối	47
4.1	Phân bố độ tuổi và giới tính của các bệnh nhân được quan sát trong bộ dữ liệu BTXRD	53
A.1	Quá trình tạo văn bản minh họa cho mẫu IMG000001.jpeg	90
A.2	Quy trình sàng lọc hồ sơ cho bộ dữ liệu CTCH	91

Danh sách bảng

2.1	Tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản	16
2.2	Tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện cho các mô hình ngôn ngữ trực quan y khoa	21
4.1	Phân bổ mẫu theo các tập chia trong BTXRD	53
4.2	Phân bổ các lớp đơn nhãn sau chuẩn hóa trong bộ dữ liệu BTXRD	53
4.3	Ví dụ ảnh, nhãn và văn bản giả lâm sàng được sinh của bộ dữ liệu BTXRD	54
4.4	Phân bổ mẫu trong phân phối của CTCH theo tập dữ liệu	56
4.5	Phân bổ 22 lớp của CTCH trong ba tập dữ liệu	56
4.6	Các ví dụ ảnh, nhãn và bệnh sử lâm sàng của bộ dữ liệu CTCH	57
4.7	Ánh xạ câu hỏi nghiên cứu với thực nghiệm và độ đo chính	58
4.8	Môi trường thực nghiệm	66
4.9	Cấu hình chính của các thực nghiệm	67
4.10	Kết quả phân loại toàn bộ mẫu trên BTXRD và CTCH	67
4.11	Các độ đo xếp hạng xác suất khi sử dụng toàn bộ tập huấn luyện	68
4.12	Đánh giá số lượng tham số của các mô hình khi sử dụng toàn bộ dữ liệu	69
4.13	Đánh giá chi phí tính toán và tốc độ suy luận của các mô hình khi sử dụng toàn bộ dữ liệu	69
4.14	Nghiên cứu loại bỏ từng thành phần của XBone-Net trên CTCH	70

4.15	Đánh giá cảnh báo OOD hậu xử lý của XBone-Net và hai biến thể	71
4.16	Đánh giá IG và can thiệp nguồn của XBone-Net và hai biến thể trên 44 mẫu ở hạt giống 42	73
A.1	Cấu trúc lưu trữ của bộ dữ liệu BTXRD trong nghiên cứu	85
A.2	Đặc điểm kỹ thuật của các tệp ảnh BTXRD	85
A.3	Các mẫu câu đại diện trong ngân hàng văn bản giả lâm sàng BTXRD	87
A.4	Kết quả kiểm chứng tính toàn vẹn của dữ liệu BTXRD . .	88
A.5	Kiểm tra nguy cơ rò rỉ nhãn trực tiếp và gián tiếp trong văn bản BTXRD	89
A.6	Cấu trúc lưu trữ của bộ dữ liệu CTCH trong nghiên cứu .	92
A.7	Đặc điểm kỹ thuật của các tệp ảnh CTCH	92
A.8	Dòng dữ liệu qua các bước sàng lọc CTCH	93
A.9	Vai trò của các trường bệnh án CTCH và nguyên tắc loại thông tin có nguy cơ rò rỉ nhãn	94
A.10	Độ tương đồng ngữ nghĩa giữa bệnh sử tiếng Việt và bản dịch tiếng Anh của CTCH	95
A.11	Kết quả kiểm chứng tính toàn vẹn của quần thể CTCH được sử dụng	96
B.1	Cấu hình đầu vào và mô hình nền tảng của XBone-Net . .	98
B.2	Kích thước các biểu diễn tại những bước chính của XBone-Net	99
B.3	Các mô-đun tuyến tính được thích nghi bằng LoRA	100
B.4	Cấu hình mô-đun dung hợp và đầu phân lớp	100
B.5	Cấu hình và tiêu chí lựa chọn trạng thái trong hai pha huấn luyện	101
C.1	Kết quả phân loại không mẫu của các mô hình nền tảng trên BTXRD và CTCH	103
C.2	So sánh giữa các phương thức đầu vào trên hai bộ dữ liệu BTXRD và CTCH	105
C.3	Kết quả phân loại của từng hạt giống trên BTXRD	107
C.4	Kết quả phân loại của từng hạt giống trên CTCH	107

C.5	Kết quả phân loại của từng hạt giống trong nghiên cứu loại bỏ thành phần trên CTCH. Cấu hình đầy đủ được tô xám.	109
C.6	Kết quả cảnh báo OOD của từng hạt giống trên kịch bản OOD CTCH bằng điểm tổ hợp đa phương thức	110
C.7	Kết quả cảnh báo OOD của từng hạt giống trên kịch bản BTXRD bằng điểm tổ hợp đa phương thức	110

Danh mục ký hiệu

Ký hiệu	Mô tả	Trang
x^{img}	Ảnh X-quang đầu vào của hệ thống.	6
H, W, C	Chiều cao, chiều rộng và số kênh của ảnh.	6
x^{txt}	Chuỗi văn bản lâm sàng đầu vào.	6
w_t, T	Token tại vị trí t và tổng số token (hoặc nhiệt độ).	6
$\mathcal{Y}, y_k, K$	Tập nhãn trong phân phối, lớp thứ k và tổng số lớp.	6
$\hat{y}$	Nhãn dự đoán cuối cùng.	6
ω_{OOD}	Cảnh báo mẫu ngoài phân phối.	6
$s_{\text{OOD}}(\cdot)$	Điểm ngoài phân phối của mẫu đầu vào.	6
$p(y_k x^{\text{img}}, x^{\text{txt}})$	Xác suất dự đoán lớp y_k .	6
$E(x)$	Energy score của mẫu x .	22
$f_i(x)$	Logit phân loại của lớp i .	22
$d_E(z, c_k)$	Khoảng cách Euclid giữa đặc trưng z và tâm lớp c_k .	24
$d_M(z, \mu_k)$	Khoảng cách Mahalanobis giữa đặc trưng z và trung bình μ_k .	24
Σ, λ, I	Ma trận hiệp phương sai, hệ số điều chuẩn và ma trận đơn vị.	24
S_k, f_θ, c_k	Tập hỗ trợ, hàm đặc trưng và prototype của lớp k .	25
$\mathcal{D}_{\text{train}}, N$	Tập dữ liệu và tổng số mẫu huấn luyện.	31
X_i, R_i, y_i	Ảnh X-quang, bệnh sử và nhãn của mẫu thứ i .	31
$\mathbf{u}_i, \mathbf{m}_i$	Chuỗi chỉ số token và attention mask của mẫu i .	35
$\mathcal{T}_t, L$	Phép xử lý văn bản và chiều dài chuỗi.	35
$\mathcal{E}_I, \mathcal{P}_I$	Bộ mã hóa thị giác và phép chiếu đặc trưng.	34
$\mathbf{g}_i^I, D$	Đặc trưng ảnh toàn cục và số chiều không gian chung.	34
$\mathbf{L}_{i,m}^I$	Các token thị giác sinh từ vùng cục bộ m .	34
$\mathbf{L}_i^I, P$	Chuỗi token cục bộ và tổng số token cục bộ.	34
$\mathbf{B}_i, \mathcal{P}_s$	Tọa độ chuẩn hóa hộp cục bộ và phép chiếu tọa độ.	34
$\gamma, \tilde{\mathbf{L}}_i^I$	Hệ số vị trí học được và chuỗi token đã nhúng tọa độ.	34
$e_{i,p}, a_{i,p}$	Điểm chú ý và trọng số pooling của token thứ p .	43
$\mathbf{W}_g, \mathbf{W}_\ell, \mathbf{w}_a$	Trọng số học được của mô-đun attention pooling.	43
$\mathbf{z}_i^I, \lambda_\ell$	Đặc trưng thị giác pha 1 và hệ số đóng góp cục bộ.	43
$\mathcal{E}_T, \mathcal{P}_T$	Bộ mã hóa văn bản và phép chiếu tương ứng.	36
$\mathbf{H}_i^T, \mathbf{z}_i^T$	Chuỗi đặc trưng token và đặc trưng văn bản toàn cục.	36
$\mathbf{W}, \mathbf{W}'$	Trọng số tiền huấn luyện và trọng số sau cập nhật LoRA.	37

Còn tiếp ở trang sau

Ký hiệu	Mô tả	Trang
$\mathbf{A}, \mathbf{B}, r$	Các ma trận hạng thấp và hạng của LoRA.	37
s_{ij}	Độ tương đồng cosine giữa ảnh i và văn bản j .	43
q_{ij}, ρ	Xác suất mục tiêu mềm và hệ số ưu tiên cặp.	44
B	Kích thước mini-batch (hoặc số lần lấy mẫu lặp).	44
$p_{ij}^{I \rightarrow T}, p_{ji}^{T \rightarrow I}$	Xác suất dự đoán ghép cặp ảnh-văn bản và văn bản-ảnh.	44
τ_{SM}	Nhiệt độ khớp ngữ nghĩa.	44
$\mathcal{L}_{\text{SM}}$	Hàm mất mát khớp ngữ nghĩa hai chiều (pha 1).	44
$\mathbf{V}_i$	Chuỗi đặc trưng thị giác kết hợp.	35
$\mathbf{A}_i^{I \leftarrow T}, \mathbf{A}_i^{T \leftarrow I}$	Phân bố chú ý chéo giữa hai phương thức.	39
$\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$	Ma trận query, key, value trong mô-đun chú ý chéo.	39
$\mathbf{h}_i^I, \mathbf{h}_i^T$	Biểu diễn đặc trưng sau dung hợp.	39
$\mathbf{z}_i^F$	Đặc trưng tổng hợp cuối cùng cho bộ phân loại.	39
$\mathbf{c}_k, N_k$	Tâm đặc trưng thực nghiệm và số mẫu huấn luyện lớp k .	40
r_{ik}	Độ tương đồng cosine giữa mẫu i và tâm lớp k .	40
ℓ_{ik}, α_c, b_k	Logit, hệ số tỷ lệ cố định và độ lệch riêng lớp k .	41
E_k, β	Số mẫu hiệu dụng của lớp k và hệ số bão hòa.	45
w_k	Trọng số phạt tổn thất của lớp k .	45
$\tilde{y}_{ik}, \varepsilon$	Mục tiêu huấn luyện sau làm trơn nhân và hệ số làm trơn.	46
$\mathcal{L}_{\text{P2}}$	Hàm mất mát phân loại có trọng số (pha 2).	46
TP_c, FP_c, TN_c, FN_c	Các trường hợp dương/âm tính thật/giả của lớp c .	60
$\text{TPR}_c, \text{FPR}_c$	Tỷ lệ dương tính thật và dương tính giả.	60
AUROC_c	Diện tích dưới đường cong ROC của lớp c .	61
$\text{Precision}_c, \text{Recall}_c$	Độ chính xác và độ thu hồi của lớp c .	60
AUPRC_c	Average Precision (AP) của lớp c .	61
$\mathcal{D}_{\text{ID}}, \mathcal{D}_{\text{OOD}}$	Tập dữ liệu trong phân phối và ngoài phân phối.	60
τ_{alert}	Ngưỡng cảnh báo OOD được hiệu chỉnh trên tập xác thực.	49
τ_{95}^{test}	Ngưỡng đánh giá $\text{FPR}@95\%\text{TPR}$ được xác định trên tập kiểm thử.	63
$\text{Precision}_{\text{OOD}}, \text{Recall}_{\text{OOD}}$	Precision và recall khi xem OOD là lớp dương.	63

Tóm tắt

Phân lớp ảnh X-quang xương bằng học sâu còn gặp khó khăn do dữ liệu gán nhãn hạn chế, mất cân bằng lớp, tổn thương nhỏ và nguy cơ tiếp nhận dữ liệu khác với phân phối huấn luyện. Khóa luận hướng đến xây dựng và đánh giá XBone-Net, mô hình đa phương thức kết hợp ảnh X-quang với văn bản để hỗ trợ phân lớp, cảnh báo ngoài phân phối và phân tích nguồn thông tin của dự đoán. XBone-Net kế thừa BiomedCLIP, thích nghi các bộ mã hóa bằng LoRA, kết hợp ảnh toàn cục với vùng ảnh cục bộ độ phân giải cao, dung hợp ảnh-văn bản bằng chú ý chéo và phân lớp theo tâm lớp. Khoảng cách Mahalanobis được khảo sát cho cảnh báo ngoài phân phối, còn tích phân gradient và can thiệp đầu vào được dùng để đánh giá lời giải thích. Thử nghiệm trên BTXRD và CTCH với ba hạt giống bao gồm phân loại, nghiên cứu thành phần, học ít mẫu, chi phí tính toán, phát hiện ngoài phân phối và khả năng giải thích. Trên CTCH, XBone-Net đạt Macro-F1 $0,5558 \pm 0,0072$ và Macro-AUROC $0,9473 \pm 0,0246$, trong khi LoRA chỉ cập nhật 4,22% tổng số tham số. Trên BTXRD, khoảng cách Mahalanobis đạt AUROC-OOD $0,8042 \pm 0,0938$, nhưng FPR@95%TPR còn ở mức $0,7071 \pm 0,0678$. Kết quả cho thấy XBone-Net duy trì hiệu năng cạnh tranh và hỗ trợ đánh giá hiệu quả tham số, cảnh báo ngoài phân phối và khả năng truy vết dự đoán. Tuy nhiên, mô hình chưa đạt ưu thế nhất quán và cần được kiểm định trên dữ liệu đa trung tâm trước khi xem xét ứng dụng thực tế.

Chương 1

Giới thiệu

Chương này trình bày bối cảnh, vấn đề nghiên cứu và phạm vi của bài toán phân lớp ảnh X-quang xương bằng học sâu đa phương thức. Trọng tâm của khóa luận là khai thác đồng thời ảnh X-quang và nguồn văn bản đi kèm. Khóa luận áp dụng hai kịch bản dữ liệu gồm nguồn văn bản chính là bệnh sử lâm sàng có sẵn trong bệnh án và văn bản lâm sàng được sinh ngoại tuyến từ siêu dữ liệu do bộ dữ liệu không cung cấp bệnh sử tương ứng với từng ảnh. Hai nguồn này được phân tích riêng vì không có mức độ xác thực lâm sàng và quan hệ với nhãn giống nhau. Chương cũng xác định các thách thức liên quan đến độ phân giải ảnh, dữ liệu hạn chế, mất cân bằng lớp, dữ liệu ngoài phân phối và khả năng giải thích để từ đó xây dựng mục tiêu, câu hỏi nghiên cứu và các đóng góp của khóa luận.

1.1 Bối cảnh và lý do chọn đề tài

Hệ xương đóng vai trò quan trọng trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ khảo sát cấu trúc xương, phát hiện tổn thương, bất thường và hỗ trợ định hướng điều trị.

Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay có thể gặp khó khăn khi tổn thương nhỏ, ảnh có tương phản thấp hoặc khi số lượng ca cần đọc lớn, lúc đó kết quả phụ thuộc đáng kể vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ.

Để giải quyết các thách thức này, nhiều nghiên cứu đã ứng dụng các mô hình học sâu vào việc hỗ trợ phân tích và phân lớp ảnh X-quang và đưa ra quyết định dựa trên thông tin trên ảnh như các kiến trúc mạng nơ-ron tích chập ResNet [10] và DenseNet [13]. Tuy nhiên, các mô hình chỉ sử dụng hình ảnh không khai thác được các thông tin lâm sàng có sẵn trước khi đọc ảnh, chẳng hạn triệu chứng, tiền sử bệnh hoặc cơ chế chấn thương. Trong khi đó, quá trình ra quyết định lâm sàng thực tế của bác sĩ thường dựa trên sự kết hợp giữa bằng chứng hình ảnh và bối cảnh bệnh hoặc chấn thương của người bệnh.


Dựa vào thực tế đó, các mô hình ngôn ngữ trực quan y khoa như MedCLIP [34], BiomedCLIP [38] và BioViL [1] cung cấp một hướng tiếp cận phù hợp để học biểu diễn chung giữa ảnh và văn bản. Nhờ được tiền huấn luyện trên các tập dữ liệu ảnh–văn bản y khoa quy mô lớn, các mô hình này có thể được chuyển giao sang những bài toán y khoa ở tác vụ đích.

Tuy nhiên, việc chuyển giao các mô hình ngôn ngữ trực quan y khoa sang bài toán phân lớp ảnh X-quang xương vẫn gặp nhiều trở ngại. Những trở ngại này xuất phát từ sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu đầu vào thực tế, số lượng dữ liệu gán nhãn hạn chế và mất cân bằng, nguy cơ xuất hiện dữ liệu ngoài phân phối, yêu cầu bảo toàn các tổn thương nhỏ trên ảnh có độ phân giải cao, cũng như nhu cầu giải thích quyết định của mô hình.

1.2 Động lực nghiên cứu

1.2.1 Kịch bản thực tế


Trong thực hành lâm sàng với các ca bệnh có chỉ định chụp X-quang, quy trình chẩn đoán bệnh lý xương thường tuân theo Hình 1.1 bao gồm các bước: bác sĩ chính khai thác bệnh sử, khám lâm sàng, chỉ định chụp X-quang. Sau đó, bác sĩ đọc ảnh sẽ phân tích ảnh X-quang và kết hợp với các ngữ cảnh lâm sàng để đưa ra nhận định cận lâm sàng. Cuối cùng, bác sĩ chính sử dụng tất cả các thông tin kể trên để làm căn cứ cho quyết định chẩn đoán cuối cùng và đưa ra hướng xử trí.



Hình 1.1: Sơ đồ quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam)

Hệ thống được đề xuất trong khóa luận được thiết kế nhằm hỗ trợ quá trình phân tích ảnh X-quang bằng cách khai thác đồng thời ảnh X-quang và dữ liệu văn bản đi kèm để dự đoán lớp bệnh lý của bệnh nhân như thể hiện ở Hình 1.2. Hai kịch bản văn bản là bệnh sử có sẵn trong bệnh án

và văn bản lâm sàng được chuẩn bị trước do dữ liệu nguồn không có bệnh sử tự do. Việc kết hợp hai nguồn dữ liệu cho phép khảo sát khả năng học biểu diễn đa phương thức, nhưng kết quả có được từ văn bản tổng hợp không được diễn giải tương đương với việc sử dụng bệnh sử tự nhiên.



Hình 1.2: Sơ đồ tích hợp hệ thống hỗ trợ phân tích (các khối tím) vào quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam)

Đề tài xem trí tuệ nhân tạo là công cụ hỗ trợ làm rõ quy trình suy luận lâm sàng, không thay thế bác sĩ hay làm thay đổi bản chất của hoạt động khám và chẩn đoán. Theo định hướng này, thông tin đầu vào, nguồn bằng chứng và mức độ bất định cần được biểu diễn có cấu trúc, có thể kiểm tra và kèm cảnh báo khi mô hình gặp dữ liệu không phù hợp với phân phối đã quan sát. Các đầu ra cũng cần được lưu lại để phục vụ truy cứu, giám sát sai lệch và cải tiến hệ thống. Trong phạm vi khóa luận, định hướng này được hiện thực hóa một phần thông qua đầu vào ảnh-bệnh sử, cảnh báo dữ liệu ngoài phân phối và phân tích mức quy đóng. Các cơ chế nhật ký vận hành và đánh giá trong môi trường lâm sàng được xem là hướng phát triển tiếp theo.

1.2.2 Ý nghĩa khoa học của đề tài

Đề tài cung cấp đánh giá thực nghiệm về việc kết hợp ảnh X-quang với văn bản trong hai điều kiện dữ liệu lâm sàng khác nhau. Một kịch bản cho phép khảo sát bệnh sử lâm sàng có sẵn trong bệnh án, trong khi kịch bản còn lại được sử dụng để khảo sát quy trình đa phương thức với văn bản tổng hợp từ siêu dữ liệu. Sự phân biệt này giúp tránh quy kết giá trị lâm sàng của văn bản tổng hợp cho bệnh sử tự nhiên.

Nghiên cứu đồng thời khảo sát khả năng thích nghi của mô hình ngôn ngữ trực quan y khoa được tiền huấn luyện trên dữ liệu quy mô lớn đối với dữ liệu X-quang xương có quy mô hạn chế và phân bố mất cân bằng. Kết quả nghiên cứu cung cấp thêm cơ sở thực nghiệm cho việc ứng dụng các mô hình nền tảng đa phương thức vào những miền y khoa chuyên biệt.

Bên cạnh hiệu quả phân lớp, đề tài xem xét khả năng nhận diện dữ liệu ngoài phân phối và phân tích các vùng ảnh có ảnh hưởng đến dự đoán. Việc đánh giá đồng thời các khía cạnh này góp phần mở rộng tiêu chí nghiên cứu từ độ chính xác đơn thuần sang độ bền dưới các kịch bản dịch chuyển đã xác định, độ tin cậy và tính minh bạch của hệ thống.

1.2.3 Ý nghĩa thực tiễn của đề tài

Hệ thống được đề xuất hướng đến hỗ trợ bác sĩ trong quá trình phân tích ảnh X-quang bằng cách kết hợp thông tin từ ảnh và dữ liệu lâm sàng ban đầu để đưa ra kết quả phân lớp. Khả năng phù hợp với quy trình khám chữa bệnh thực tế được xem xét chủ yếu trên kịch bản bệnh sử có sẵn trong bệnh án. Kịch bản còn lại đóng vai trò bổ sung để đánh giá thuật toán với văn bản tổng hợp và không được dùng làm bằng chứng trực tiếp về hiệu quả triển khai với bệnh sử thực.

Ngoài ra, quá trình nghiên cứu góp phần xây dựng và chuẩn hóa một bộ dữ liệu đa phương thức gồm ảnh X-quang và bệnh sử lâm sàng từ dữ liệu thực tế tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh. Bộ dữ liệu và quy trình xử lý có thể tạo nền tảng cho các nghiên cứu tiếp theo về phân lớp bệnh lý xương và mô hình ngôn ngữ trực quan y khoa tại Việt Nam.

Đồng thời, mô hình cung cấp bản đồ nhiệt đóng góp để khảo sát những vùng ảnh và đơn vị từ ngữ có liên hệ với dự đoán, cùng các điểm bất thường hậu xử lý cho dữ liệu ngoài phân phối. Các đầu ra này phục vụ phân tích mô hình, chưa phải bằng chứng định vị tổn thương hoặc cơ chế bảo đảm an toàn lâm sàng.

1.3 Giới thiệu bài toán

Bài toán được nghiên cứu trong đề tài là bài toán phân lớp đa lớp ảnh X-quang sử dụng học sâu đa phương thức. Mục tiêu của hệ thống là dự đoán các loại bệnh hoặc tổn thương dựa đồng thời vào ảnh X-quang và văn bản đi kèm.

1.3.1 Đầu vào

Hệ thống nhận vào các nguồn dữ liệu sau:

- **Ảnh X-quang của bệnh nhân:**

$$x^{\text{img}} \in \mathbb{R}^{H \times W \times C}$$

Với H, W là chiều cao và chiều rộng ảnh, C là số kênh màu của ảnh.

- **Văn bản đi kèm:** bệnh sử lâm sàng hoặc văn bản lâm sàng được sinh từ siêu dữ liệu.

$$x^{\text{txt}} = (w_1, w_2, \dots, w_T)$$

Với w_t là đơn vị từ ngữ tại vị trí thứ t trong văn bản, T là số lượng đơn vị từ ngữ trong văn bản.

- **Tập nhãn được định nghĩa trước:**

$$\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$$

với K là số lớp bệnh cần phân lớp.

1.3.2 Đầu ra

Hệ thống sinh ra ba đầu ra chính:

- **Nhãn dự đoán cuối cùng:**

$$\hat{y} = \arg \max_{y_k \in \mathcal{Y}} p(y_k | x^{\text{img}}, x^{\text{txt}}),$$

Với $p(y_k | x^{\text{img}}, x^{\text{txt}})$ là xác suất dự đoán của lớp y_k .

- **Cảnh báo dữ liệu ngoài phân phối:**

$$\omega_{\text{OOD}} = \begin{cases} 1, & \text{nếu } s_{\text{OOD}}(x^{\text{img}}, x^{\text{txt}}) > \tau_{\text{alert}}, \\ 0, & \text{ngược lại,} \end{cases}$$

Với $s_{\text{OOD}}(x^{\text{img}}, x^{\text{txt}})$ là điểm ngoài phân phối của mẫu đầu vào, τ_{alert} là ngưỡng cảnh báo được hiệu chỉnh trước trên tập xác thực và $\omega_{\text{OOD}} = 1$ biểu thị rằng mẫu được phát hiện là dữ liệu ngoài phân phối.

- **Thông tin hỗ trợ giải thích:** Hệ thống sinh ra các bản đồ nhiệt đóng góp cho ảnh toàn cục, các vùng ảnh cục bộ và văn bản đi kèm nhằm khảo sát mức độ liên hệ của từng nguồn thông tin với dự đoán của mô hình.

1.3.3 Các thách thức trong bài toán

Mặc dù các mô hình học sâu đa phương thức đã đạt được nhiều kết quả tích cực, bài toán vẫn tồn tại nhiều thách thức cần được giải quyết:

- **Sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu đầu vào thực tế:** Tồn tại sự chênh lệch giữa các bộ dữ liệu đa phương thức hiện có, thường là cặp ảnh X-quang và báo cáo đọc ảnh, so với dữ liệu đầu vào được khảo sát trong khóa luận gồm ảnh X-quang kết hợp với bệnh sử hoặc thông tin lâm sàng ban đầu. Sự khác biệt này có thể hạn chế khả năng chuyển giao trực tiếp của mô hình.

- **Sự khác biệt về không gian và ngữ nghĩa giữa dữ liệu hình ảnh và dữ liệu văn bản:** Sự khác biệt này gây khó khăn cho quá trình học biểu diễn chung, yêu cầu một cơ chế dung hợp hiệu quả.
- **Bảo toàn tổn thương nhỏ trên ảnh độ phân giải cao:** Việc co toàn bộ ảnh X-quang về kích thước cố định ở độ phân giải thấp của các mô hình hiện nay có thể làm mất đi các chi tiết cục bộ quan trọng, đặc biệt là các tổn thương nhỏ, dẫn đến hiệu quả phân lớp bị hạn chế.
- **Hạn chế của dữ liệu thực tế:** Dữ liệu y tế thường có số lượng hạn chế và mất cân bằng giữa các loại bệnh, đặt ra yêu cầu đặc biệt về thiết kế mô hình để tận dụng tối đa thông tin có sẵn.
- **Dữ liệu ngoài phân phối:** Các bộ phân lớp theo giả định tập đóng chưa được thiết kế để xử lý các trường hợp dữ liệu ngoài phân phối, dẫn đến nguy cơ đưa ra dự đoán không chính xác với độ tin cậy cao đối với những ca bệnh mới chưa từng xuất hiện trong dữ liệu huấn luyện, đặt ra yêu cầu về khả năng tổng quát hóa và thích ứng của mô hình.
- **Khả năng giải thích của mô hình:** Khả năng giải thích của các mô hình vẫn còn hạn chế khiến độ tin cậy của người dùng vào các dự đoán của hệ thống là không cao, gây khó khăn cho việc triển khai trong thực tế lâm sàng.

1.4 Mục tiêu nghiên cứu

Đề tài hướng đến xây dựng và đánh giá một hệ thống học sâu đa phương thức phục vụ phân lớp bệnh lý trên ảnh X-quang xương bằng cách kết hợp thông tin hình ảnh và bệnh sử lâm sàng. Hệ thống được nghiên cứu trong điều kiện dữ liệu hạn chế và mất cân bằng lớp, đồng thời được đánh giá về hiệu năng phân lớp, chi phí tính toán, khả năng cảnh báo dữ liệu ngoài phân phối và mức độ giải thích của dự đoán.

Các mục tiêu cụ thể của đề tài bao gồm:

1. Xây dựng XBone-Net bằng cách thích nghi BioMedCLIP với LoRA, quy trình huấn luyện hai giai đoạn và mô-đun dung hợp ảnh–văn bản cho bài toán phân lớp X-quang xương.
2. Đánh giá hiệu năng phân lớp của XBone-Net so với các mô hình đối chứng trong thiết lập ít mẫu và toàn bộ dữ liệu, đồng thời định lượng sự đánh đổi giữa số tham số cập nhật và chi phí suy luận.
3. Thực hiện các thí nghiệm loại bỏ và thay thế thành phần để xác định ảnh hưởng của quy trình huấn luyện, cơ chế dung hợp, cách mã hóa ảnh và đầu phân lớp đến các nhóm độ đo khác nhau.
4. Đánh giá hai đầu ra hỗ trợ của hệ thống gồm cảnh báo dữ liệu ngoài phân phối bằng các điểm bất thường hậu xử lý và truy vết nguồn phụ thuộc của dự đoán bằng tích phân gradient kết hợp can thiệp đầu vào.

1.5 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học sâu đa phương thức trong bài toán phân lớp bệnh lý trên ảnh X-quang xương, sử dụng đồng thời thông tin hình ảnh và bệnh sử lâm sàng. Nghiên cứu tập trung vào các nhóm mô hình và thành phần kỹ thuật sau:

- Các mô hình ngôn ngữ trực quan được tiền huấn luyện trên dữ liệu tổng quát hoặc dữ liệu y khoa, đóng vai trò bộ mã hóa đặc trưng hình ảnh và văn bản.
- Các phương pháp xử lý ảnh X-quang độ phân giải cao nhằm khai thác đồng thời đặc trưng toàn cục và đặc trưng cục bộ của vùng tổn thương.
- Các chiến lược dung hợp đa phương thức, bao gồm phép nối đặc trưng và cơ chế chú ý chéo, để kết hợp biểu diễn hình ảnh với thông tin bệnh sử lâm sàng.

- Các phương pháp tinh chỉnh hiệu quả tham số cho mô hình tiền huấn luyện quy mô lớn, tập trung vào việc giới hạn số tham số cần cập nhật trong quá trình huấn luyện.
- Các kiến trúc đầu phân lớp đa lớp trên dữ liệu mất cân bằng, bao gồm bộ phân lớp tuyến tính và bộ phân lớp dựa trên tâm lớp.
- Các phương pháp phát hiện dữ liệu ngoài phân phối và trực quan hóa bản đồ tích phân gradient nhằm hỗ trợ đánh giá độ tin cậy và khả năng giải thích của mô hình.

1.6 Phạm vi nghiên cứu

Đề tài tập trung vào bài toán phân lớp đa lớp bệnh lý xương trên ảnh X-quang, kết hợp với bệnh sử lâm sàng. Phạm vi cụ thể bao gồm:

- **Dữ liệu:** Nghiên cứu sử dụng bộ dữ liệu BTXRD [36] gồm 10 lớp bệnh lý xương và bộ dữ liệu CTCH được thu thập từ Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.
- **Dữ liệu văn bản:** Bộ dữ liệu CTCH sử dụng bệnh sử có sẵn trong bệnh án, gồm lý do vào viện, diễn tiến bệnh và tiền sử. Bộ dữ liệu BTXRD không có bệnh sử tự do nên sử dụng văn bản lâm sàng được sinh ngoại tuyến từ siêu dữ liệu. Vì mẫu câu tổng hợp có phụ thuộc vào các cờ nhóm bệnh, kết quả BTXRD chỉ phản ánh thiết lập văn bản tổng hợp và không được xem là bằng chứng tương đương với bệnh sử lâm sàng tự nhiên.
- **Vai trò hệ thống:** Hệ thống được thiết kế làm công cụ hỗ trợ phân tích ảnh, không thay thế vai trò của bác sĩ trong quá trình ra quyết định.
- **Giới hạn:** Đề tài không tập trung vào các bài toán phát hiện đối tượng, phân đoạn ảnh hay sinh báo cáo y khoa tự động.

1.7 Câu hỏi nghiên cứu

Để đạt được các mục tiêu đã đề ra, nghiên cứu tập trung trả lời các câu hỏi sau:

- **Câu hỏi nghiên cứu 1:** Trong tác vụ phân loại, XBone-Net đạt mức hiệu năng phân lớp nào so với các mô hình đối chứng, đồng thời đánh đổi như thế nào giữa số tham số cần cập nhật và chi phí suy luận?
- **Câu hỏi nghiên cứu 2:** Các thành phần do khóa luận lựa chọn cho XBone-Net, gồm quy trình huấn luyện và cơ chế dung hợp, ảnh hưởng như thế nào đến quyết định lớp và chất lượng xếp hạng?
- **Câu hỏi nghiên cứu 3:** Điểm cảnh báo hậu xử lý được xây dựng từ không gian biểu diễn của XBone-Net có thể phân biệt dữ liệu trong phân phối với các dạng dữ liệu ngoài phân phối được xác định trước ở mức nào, và giới hạn của cảnh báo này khác nhau ra sao giữa dịch chuyển gần miền và dịch chuyển khác bộ dữ liệu?
- **Câu hỏi nghiên cứu 4:** Tích phân gradient kết hợp với can thiệp đầu vào phản ánh mức phụ thuộc của dự đoán XBone-Net vào thông tin hình ảnh và văn bản như thế nào, và thứ tự quy đóng có làm thay đổi đầu ra rõ hơn đối chứng ngẫu nhiên hay không?

1.8 Đóng góp chính của đề tài

Các đóng góp của đề tài tập trung vào quy trình thích nghi, cách đánh giá các lựa chọn do khóa luận đề xuất và phân tích giới hạn của hệ thống. Đồng thời, việc sử dụng kết hợp ảnh và văn bản không được xem là một đóng góp cần chứng minh lại. Cụ thể:

1. **Quy trình thích nghi XBone-Net:** Đề xuất và hiện thực hóa quy trình thích nghi BioMedCLIP cho phân lớp X-quang xương bằng LoRA, huấn luyện hai pha và chú ý chéo hai chiều, nhằm hạn chế số tham số cần cập nhật trong khi khai thác biểu diễn ảnh–văn bản. CTCH sử dụng bệnh sử có sẵn trong bệnh án, trong khi BTXRD sử dụng văn bản tổng hợp từ siêu dữ liệu. Vì hai nguồn văn bản không có mức độ xác thực lâm sàng tương đương nên kết quả trên từng bộ dữ liệu được diễn giải riêng.
2. **Bằng chứng về hiệu năng, thành phần và chi phí:** Đánh giá XBone-Net với các mô hình đối chứng trong thiết lập sử dụng toàn bộ dữ liệu, khảo sát riêng vai trò của quy trình huấn luyện hai pha và cơ chế dung hợp, đồng thời đo số tham số cập nhật, số phép toán, thông lượng, độ trễ và bộ nhớ GPU cực đại. Qua đó, phân tích làm rõ mức hiệu năng phân lớp cạnh tranh, lợi ích về tham số cập nhật và phần chi phí suy luận phải đánh đổi.
3. **Đánh giá cảnh báo dữ liệu ngoài phân phối:** Xây dựng điểm cảnh báo hậu xử lý từ biểu diễn ảnh và văn bản, sau đó đánh giá trong hai kịch bản được xác định trước: dịch chuyển gần miền trên CTCH và dịch chuyển khác bộ dữ liệu sang BTXRD. Đây là tín hiệu hỗ trợ, không phải cơ chế bảo đảm phát hiện hoặc từ chối dự đoán tự động.
4. **Truy vết nguồn phụ thuộc của dự đoán:** Kết hợp tích phân gradient với can thiệp đầu vào để khảo sát mức phụ thuộc của dự đoán vào thông tin hình ảnh và văn bản. Phân tích cung cấp bằng chứng thăm dò về độ trung thực của thứ tự quy đóng và hỗ trợ truy vết đầu ra, nhưng không xác lập đóng góp nhân quả, khả năng định vị tổn thương hoặc độ đúng lâm sàng.

1.9 Bố cục khóa luận

Khóa luận được tổ chức thành năm chương như sau:

Chương 1: Giới thiệu. Chương này trình bày bối cảnh nghiên cứu, vấn đề đặt ra, mục tiêu, đối tượng, câu hỏi nghiên cứu và các đóng góp chính của đề tài. Nội dung chương đóng vai trò định hướng cho toàn bộ khóa luận.

Chương 2: Các công trình nghiên cứu liên quan. Chương này tổng quan các nghiên cứu về mô hình ngôn ngữ trực quan, phân lớp ảnh X-quang xương, xử lý ảnh độ phân giải cao, dung hợp đa phương thức, tinh chỉnh hiệu quả tham số, phát hiện dữ liệu ngoài phân phối và khả năng giải thích mô hình. Trên cơ sở đó, chương xác định khoảng trống nghiên cứu và định vị phương pháp đề xuất so với các công trình trước.

Chương 3: Phương pháp đề xuất. Chương này mô tả kiến trúc XBone-Net, quy trình xử lý ảnh và văn bản, cơ chế dung hợp hai chiều, bộ phân lớp dựa trên tâm lớp, các hàm mất mát và chiến lược huấn luyện hai giai đoạn với LoRA. Quy trình phát hiện dữ liệu ngoài phân phối và giải thích dự đoán cũng được trình bày trong chương này.

Chương 4: Thực nghiệm và kết quả. Chương này giới thiệu các bộ dữ liệu, thiết lập thực nghiệm, mô hình đối sánh và các độ đo đánh giá. Các kết quả không mẫu, mẫu hạn chế, toàn bộ mẫu, nghiên cứu loại bỏ thành phần, đánh giá hiệu quả tính toán, phát hiện dữ liệu ngoài phân phối và giải thích mô hình được phân tích nhằm làm rõ ưu điểm, hạn chế và sự đánh đổi của phương pháp đề xuất.

Chương 5: Kết luận và hướng phát triển. Chương cuối tổng kết các kết quả đạt được, trả lời các câu hỏi nghiên cứu, chỉ ra những hạn chế còn tồn tại và đề xuất các hướng cải tiến, mở rộng trong tương lai.

Chương 2

Các công trình nghiên cứu liên quan

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Nhằm xác lập cơ sở cho việc thiết kế hệ thống phân lớp, phần này sẽ mô tả tổng quan các nghiên cứu về các mô hình nền tảng của các cách tiếp cận khác nhau cho bài toán phân lớp ảnh y khoa, các chiến lược bảo toàn thông tin trên ảnh độ phân giải cao, đặc biệt là cách kết hợp ngữ cảnh toàn cục với đặc trưng cục bộ, các kỹ thuật tinh chỉnh hiệu quả tham số và phương pháp phát hiện dữ liệu ngoài phân phối. Trên cơ sở đó, đối chiếu ưu điểm, hạn chế và mức độ phù hợp của các hướng tiếp cận hiện có đối với dữ liệu thực tế, chương xác định khoảng trống nghiên cứu và làm rõ cơ sở lựa chọn các thành phần trong phương pháp được đề xuất ở Chương 3.

2.1 Các hướng tiếp cận chính và các mô hình nền tảng

2.1.1 Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu

Sự kết hợp giữa dữ liệu cận lâm sàng và báo cáo lâm sàng, lịch sử bệnh lý đã tạo ra những bước tiến lớn trong việc cải thiện độ chính xác của các mô hình chẩn đoán, đặc biệt là thông qua việc sử dụng văn bản để bù đắp những thiếu sót thông tin mà hình ảnh đơn thuần không thể cung cấp, hoặc giúp mô hình tập trung vào những vùng trên ảnh được xác định bởi thông tin từ nguồn văn bản. Nghiên cứu của X. Mei [19] trong việc chẩn đoán COVID-19 là một minh chứng rõ nét: khi ảnh chụp CT ngực ở giai đoạn sớm có thể chưa biểu hiện bất thường, việc tích hợp thông tin lâm sàng thông qua mạng MLP với đặc trưng ảnh từ CNN đã giúp mô hình nhận diện chính xác 68% số bệnh nhân dương tính mà các bác sĩ X-quang đã bỏ sót. Mô hình TieNet [33] đã mã hóa các báo cáo y tế và tích hợp các cơ chế chú ý đa cấp để giống hàng các từ mang ý nghĩa quan trọng với các vùng ảnh tương ứng, cải thiện trung bình 6% chỉ số AUC so với các mô hình chỉ dùng ảnh. Gần đây, IRENE [41] đưa tất cả dữ liệu về một dạng đơn vị biểu diễn chung và sử dụng một mô hình Transformer duy nhất, cho phép văn bản trực tiếp tương tác và giải thích các đơn vị biểu diễn của ảnh ở cấp độ cục bộ.

Nhìn chung, những nghiên cứu này minh chứng rằng sự đóng góp của nhiều nguồn dữ liệu, đặc biệt là văn bản đã đi từ việc chỉ là một véc-tơ thông tin ghép nối thêm, trở thành một thành phần cốt lõi có khả năng giống hàng ngữ nghĩa và định hướng trong cơ chế chú ý. Tuy nhiên, các mô hình xây dựng từ đầu thường đòi hỏi dữ liệu ghép cặp quy mô lớn và chi phí huấn luyện cao, tạo tiền đề cho sự xuất hiện của các mô hình ngôn ngữ trực quan y khoa.

2.1.2 Mô hình ngôn ngữ trực quan y khoa

Các mô hình ngôn ngữ trực quan đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu, các mô hình ngôn ngữ trực quan nói chung và các mô hình ngôn ngữ trực quan y khoa nói riêng tập trung vào hai nguồn dữ liệu đầu vào chính là ảnh và văn bản. Các mô hình ngôn ngữ trực quan y khoa kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet [10] hoặc ViT [7] cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, các mô hình ngôn ngữ trực quan y khoa tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Chiến lược học tương phản là hướng tiếp cận được ứng dụng rộng rãi nhất. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh-văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau. Bảng 2.1 tổng hợp các mô hình ngôn ngữ trực quan y khoa tiêu biểu sử dụng học tương phản.

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Phương pháp			
			Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	Học tương phản	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	Học tương phản	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	Học tương phản	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	Học tương phản	ViT-Base	PubMedBERT	Contrastive Alignment	N/a

Bảng 2.1: Tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản

ConVIRT [39] là nghiên cứu tiên phong áp dụng học tương phản cho dữ liệu y khoa, sử dụng ResNet50 và BERT để tối ưu bộ mã hóa ảnh và văn bản, đạt độ chính xác 90,3% trên bộ dữ liệu COVIDx. GLoRIA [14] mở rộng hướng tiếp cận này bằng cách kết hợp hai hàm mất mát toàn cục

và cục bộ, cho phép căn chỉnh chi tiết giữa các vùng trong ảnh và các từ trong câu. MedCLIP [34] đề xuất cơ chế tách cặp và trích xuất tri thức cùng hàm mất mát khớp ngữ nghĩa nhằm giải quyết vấn đề âm tính giả khi các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý. BiomedCLIP [38] kế thừa kiến trúc CLIP [24] với bộ mã hóa ViT-Base và PubMedBERT, được tiền huấn luyện trên 15 triệu cặp dữ liệu từ tập PMC-15M, đạt độ chính xác phân lớp 83%, giúp mô hình có độ phủ và khả năng tổng quát tốt với nhiều nguồn dữ liệu và tác vụ y khoa.

Ngoài học tương phản, các hướng tiếp cận khác bao gồm học có che giấu và tích hợp tri thức y khoa. Tuy nhiên, các phương pháp này thường phụ thuộc vào nguồn dữ liệu ghép cặp sẵn hoặc đồ thị tri thức chuyên biệt, hạn chế khả năng ứng dụng trên các bài toán không có sẵn nguồn tri thức ngoài. Song song với các mô hình ngôn ngữ trực quan y khoa, sự phát triển của các mô hình ngôn ngữ lớn đa phương thức như Med-Flamingo [20], LLaVA-Med [16] hay Med-PaLM M [32] đã cho thấy tiềm năng trong các tác vụ hội thoại và hỗ trợ ra quyết định y khoa. Tuy nhiên, các mô hình này thường có quy mô rất lớn, chi phí huấn luyện và suy luận cao, đồng thời vẫn tồn tại nguy cơ tạo ra thông tin không chính xác. Do đó, đối với các bài toán phân lớp chuyên biệt như phân lớp ảnh X-quang xương, việc sử dụng các mô hình ngôn ngữ - thị giác chuyên dụng kết hợp tinh chỉnh hiệu quả tham số thường phù hợp và hiệu quả hơn.

Lựa chọn BiomedCLIP làm mô hình nền tảng

Trong số các mô hình ngôn ngữ trực quan y khoa được khảo sát, khóa luận lựa chọn BiomedCLIP [38] làm mô hình nền tảng dựa trên mức độ phù hợp với bài toán, thay vì chỉ dựa trên kết quả của một bộ dữ liệu riêng lẻ. Thứ nhất, BiomedCLIP được tiền huấn luyện trên PMC-15M, gồm khoảng 15 triệu cặp ảnh-văn bản thu thập từ nhiều loại dữ liệu y sinh, trong khi một số mô hình trước đó chủ yếu được xây dựng và đánh giá trên ảnh X-quang ngực. Phạm vi tiền huấn luyện rộng hơn tạo cơ sở phù hợp cho việc chuyển giao sang ảnh X-quang xương, vốn có sự đa dạng lớn về vùng giải phẫu, tư thế chụp và loại tổn thương.

Thứ hai, mô hình sử dụng kiến trúc hai bộ mã hóa độc lập gồm Vision

Transformer cho ảnh và PubMedBERT cho văn bản, phù hợp với thiết kế hai nhánh của hệ thống và cho phép kế thừa trực tiếp biểu diễn của cả hai phương thức. Thứ ba, kiến trúc CLIP của mô hình hỗ trợ đánh giá không mẫu thông qua độ tương đồng ảnh-văn bản, đồng thời có thể được mở rộng bằng các kỹ thuật tinh chỉnh hiệu quả tham số và mô-đun dung hợp cho bài toán đích. Vì vậy, BiomedCLIP được sử dụng làm mô hình nền tảng khởi tạo, trong khi các ý tưởng phù hợp từ những nghiên cứu khác, chẳng hạn hàm mất mát khớp ngữ nghĩa của MedCLIP, được kế thừa để cải thiện quá trình thích nghi trên dữ liệu X-quang xương. Kết quả phân lớp không mẫu của BiomedCLIP và các mô hình nền tảng khác được trình bày trong Phần C.1.1.

Cơ chế phân lớp không mẫu của BiomedCLIP

BiomedCLIP có thể thực hiện phân lớp trong thiết lập *không mẫu* mà không cần huấn luyện một đầu phân lớp riêng trên dữ liệu đích. Thay vào đó, mô hình biểu diễn ảnh đầu vào và các câu nhắc mô tả lớp trong cùng một không gian đặc trưng, sau đó xác định lớp dựa trên mức độ tương đồng giữa hai phương thức.

Ảnh đầu vào x trước hết được tiền xử lý theo cấu hình của BiomedCLIP, bao gồm thay đổi kích thước, cắt vùng trung tâm và chuẩn hóa, để thu được tensor ảnh có kích thước 224×224 . Ảnh sau đó được chia thành các patch kích thước 16×16 và đưa qua bộ mã hóa thị giác ViT-B/16 để tạo biểu diễn ảnh.

Với mỗi lớp k , tên lớp được đưa vào một mẫu câu nhắc thống nhất, chẳng hạn A radiograph showing [tên lớp]. Câu nhắc được mã hóa bởi bộ mã hóa văn bản PubMedBERT để thu được biểu diễn văn bản t_k . Điểm số của lớp k được tính bằng độ tương đồng cosine:

$$s_k = \frac{v^\top t_k}{\|v\|_2 \|t_k\|_2}. \quad (2.1)$$

Các điểm tương đồng được chuẩn hóa bằng hàm Softmax để tạo phân phối xác suất trên tập lớp:

$$p(y = k | x) = \frac{\exp(s_k/\tau)}{\sum_{j=1}^K \exp(s_j/\tau)}, \quad (2.2)$$

trong đó τ là hệ số nhiệt độ. Lớp có xác suất lớn nhất được chọn làm kết quả dự đoán. Cơ chế này cho phép BiomedCLIP chuyển giao tri thức đã học sang các tập nhãn mới mà không cần cập nhật tham số. Tuy nhiên, hiệu quả phụ thuộc đáng kể vào mức độ tương đồng giữa dữ liệu tiền huấn luyện và dữ liệu đích, cách xây dựng câu nhắc, cũng như khả năng biểu diễn các dấu hiệu bệnh lý chuyên biệt của bộ mã hóa.

2.2 Các kỹ thuật tinh chỉnh hiệu quả tham số

Sự xuất hiện của các mô hình nền tảng nói chung và mô hình ngôn ngữ-thị giác y sinh nói riêng đã mang lại một nền tảng tri thức đa phương thức khổng lồ. Tuy nhiên, để triển khai hiệu quả các mô hình này vào các bài toán lâm sàng đặc thù, quá trình chuyển giao tri thức là bắt buộc.

Hướng đến yêu cầu cụ thể hơn cho bài toán sử dụng hai nguồn ảnh và văn bản lâm sàng, khóa luận tập trung vào các kỹ thuật tinh chỉnh để khai thác tối đa từ hai nguồn dữ liệu này với đặc điểm dữ liệu thực tế còn hạn chế.

Trước đây, hai chiến lược phổ biến nhất là tinh chỉnh toàn phần và dò tuyến tính. Tinh chỉnh toàn phần cập nhật lại toàn bộ tham số của mô hình gốc, mang lại khả năng thích ứng cao nhưng đòi hỏi chi phí tính toán, bộ nhớ khổng lồ, yêu cầu dữ liệu huấn luyện lớn đến rất lớn, dẫn đến hiện tượng quên biểu diễn trên các tập dữ liệu y tế nhỏ. Ngược lại, dò tuyến tính đóng băng toàn bộ mạng nơ-ron gốc và chỉ huấn luyện một lớp phân lớp duy nhất ở cuối, tiết kiệm tài nguyên nhưng hạn chế khả năng thích ứng khi sự chênh lệch phân phối giữa dữ liệu gốc và dữ liệu y tế là quá lớn.

Để giải quyết bài toán đánh đổi giữa hiệu năng và chi phí tính toán, tinh chỉnh hiệu quả tham số đã nổi lên như một giải pháp thay thế. Kỹ thuật này chỉ cập nhật hoặc thêm mới một lượng rất nhỏ tham số, giúp

tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các phương pháp tinh chỉnh hiệu quả tham số được chia thành ba hướng tiếp cận chính:

2.2.1 Tinh chỉnh sử dụng câu nhắc

Hướng tiếp cận này chèn thêm các tham số (vector) có thể học được vào không gian đầu vào của mô hình mà không thay đổi cấu trúc mạng bên trong.

- **Điểm mạnh:** Tiết kiệm tham số tối đa, bảo toàn nguyên vẹn tri thức của mô hình gốc, đặc biệt hiệu quả trong các kịch bản học ít mẫu hoặc không mẫu.
- **Điểm yếu:** Tối ưu hóa khó khăn do không gian biểu diễn bị giới hạn ở đầu vào, nhạy cảm với cách khởi tạo, và chiếm dụng một phần độ dài của chuỗi đầu vào.

Trong lĩnh vực y tế, PLIP [37] kết hợp đặc trưng thị giác với câu nhắc hiệu quả, đạt 0,896 AUC chỉ với 5% dữ liệu PanNuke. BiomedCoOp [28] tích hợp mô hình ngôn ngữ lớn để tự động sinh các câu nhắc ngữ nghĩa, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản.

2.2.2 Tinh chỉnh bộ điều hợp

Phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ, còn được gọi là bộ điều hợp vào giữa các lớp kiến trúc của mạng học sâu.

- **Điểm mạnh:** Tính mô-đun hóa cao, dễ dàng thêm/bớt các bộ điều hợp cho các tác vụ khác nhau mà không can thiệp vào tham số gốc.
- **Điểm yếu:** Việc chèn thêm các lớp mạng vật lý làm tăng độ trễ suy luận, hạn chế khả năng triển khai trên các hệ thống đòi hỏi thời gian thực.

Diễn hình, CLIPath [40] sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu nhỏ. FTB [23] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức.

2.2.3 Tinh chỉnh thích nghi hạng thấp

Tinh chỉnh thích nghi hạng thấp (LoRA) giữ cố định trọng số nền và bổ sung các ma trận hạng thấp có thể huấn luyện để tham số hóa phần cập nhật trọng số. Cách tiếp cận này làm tăng một lượng nhỏ tham số huấn luyện nhưng tránh cập nhật toàn bộ mô hình.

- **Điểm mạnh:** Giảm đáng kể số tham số cần cập nhật và bộ nhớ tối ưu hóa. Ngoài ra, các ma trận cập nhật có thể được hợp nhất vào trọng số nền khi cách triển khai hỗ trợ.
- **Điểm yếu:** Hiệu quả phụ thuộc vào vị trí chèn, hạng của ma trận và cấu hình tối ưu. Tuy nhiên, việc giảm tham số huấn luyện không đồng nghĩa với giảm chi phí lan truyền tiến của toàn bộ kiến trúc.

LCBB [21] áp dụng LoRA cho mô hình ngôn ngữ trực quan y khoa và đạt 93,1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn, cho thấy khả năng thích nghi với số tham số cập nhật thấp hơn tinh chỉnh toàn phần.

Bảng 2.2 tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Nguyên lý	Kết quả nổi bật
1	PLIP (2024)	Tinh chỉnh sử dụng câu nhắc	Kết hợp câu nhắc thị giác với tinh chỉnh chọn lọc, tận dụng đặc trưng hình ảnh để tinh chỉnh hiệu quả	0,896 AUC (5% PanNuke)
2	CLIPath (2023)	Tinh chỉnh sử dụng bộ điều hợp	Sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu mô bệnh học	Cải thiện so với CLIP trên dữ liệu nhỏ
3	LCBB (2024)	Thích nghi hạng thấp bằng LoRA	Bổ sung ma trận hạng thấp vào bộ mã hóa thị giác, giữ cố định trọng số nền	93,1% AUROC (RSNA, 10%)
4	FTB (2024)	Tinh chỉnh sử dụng bộ điều hợp	Mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản, chất lọc thông tin đa phương thức	Cải thiện trên CheXpert, RSNA

Bảng 2.2: Tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện cho các mô hình ngôn ngữ trực quan y khoa

2.3 Các phương pháp phát hiện dữ liệu ngoài phân phối

Phát hiện dữ liệu ngoài phân phối nhằm nhận diện các mẫu không phù hợp với phân phối quan sát trong tập huấn luyện. Trong phân tích ảnh y khoa, điểm ngoài phân phối có thể cung cấp tín hiệu cảnh báo hỗ trợ khi mô hình gặp dữ liệu lạ, nhưng không tự thân bảo đảm tính an toàn hoặc thay thế quy trình đánh giá lâm sàng. Dựa trên cách tiếp cận, các phương pháp phát hiện dữ liệu ngoài phân phối hiện nay được chia thành các nhóm chính sau.

2.3.1 Các phương pháp hậu xử lý dựa trên đầu ra của mô hình

Nhóm phương pháp này không can thiệp vào quá trình huấn luyện mà tận dụng trực tiếp đầu ra (thường là các logit hoặc xác suất) của một bộ phân lớp đã được huấn luyện.

- **Xác suất softmax cực đại [11]:** Sử dụng giá trị cực đại của hàm softmax làm độ tin cậy. Dữ liệu có xác suất cực đại thấp sẽ bị đánh dấu là ngoài phân phối. Tuy nhiên, điểm yếu chí mạng của xác suất softmax cực đại là các mạng nơ-ron sâu thường mắc lỗi "tự tin thái quá", dẫn đến việc gán xác suất rất cao cho cả những mẫu ngoài phân phối hoàn toàn không liên quan.
- **ODIN [17]:** Cải thiện xác suất softmax cực đại bằng cách sử dụng hiệu chỉnh nhiệt độ và thêm nhiễu đầu vào để gia tăng sự chênh lệch logit giữa dữ liệu trong phân phối và dữ liệu ngoài phân phối.
- **Điểm năng lượng [18]:** Chuyển đổi vectơ logit thành hàm năng lượng thay vì xác suất softmax:

$$E(x) = -T \log \sum_i \exp \left(\frac{f_i(x)}{T} \right) \quad (2.3)$$

trong đó $f_i(x)$ là logit của lớp thứ i và T là hệ số nhiệt độ. Mặc dù điểm năng lượng khai thác độ lớn tuyệt đối của các logit và thường khắc phục một phần hiện tượng quá tự tin của hàm softmax, các phương pháp hậu xử lý dựa trên đầu ra vẫn phụ thuộc mạnh vào biểu diễn và biên quyết định của bộ phân lớp đã huấn luyện. Do mô hình phân lớp đóng buộc mọi đầu vào vào một trong các lớp đã biết, các mẫu ngoài phân phối nằm xa dữ liệu huấn luyện vẫn có thể nhận điểm tin cậy cao.

2.3.2 Các phương pháp dựa trên độ không chắc chắn và tái tạo

Để tránh phụ thuộc vào đầu ra hàm softmax, một số nghiên cứu tiếp cận bài toán bằng cách đánh giá khả năng sinh hoặc sự bất định của mô hình.

- **Sai số tái tạo:** Sử dụng các mô hình sinh như bộ tự mã hóa được huấn luyện chỉ trên dữ liệu trong phân phối. Khi gặp dữ liệu ngoài phân phối, sai số tái tạo sẽ tăng đột biến. Dù hiệu quả, phương pháp này gặp khó khăn khi tái tạo các ảnh y khoa có độ phân giải cao và chi tiết phức tạp.
- **Dropout Monte Carlo:** Kích hoạt hàm tắt ngẫu nhiên trong quá trình suy luận và thực hiện dự đoán nhiều lần để tính phương sai. Tuy nhiên, việc phải suy luận nhiều lần làm tăng chi phí tính toán, không phù hợp cho các hệ thống đòi hỏi thời gian thực.

2.3.3 Các phương pháp dựa trên khoảng cách đặc trưng

Nhận thấy những hạn chế của không gian logit, các nghiên cứu gần đây chuyển hướng sang thực hiện phát hiện dữ liệu ngoài phân phối trực tiếp trên không gian đặc trưng. Việc đánh giá bằng khoảng cách giúp giới hạn không gian rủi ro mở.

- **Khoảng cách euclid và cosine:** Khoảng cách euclid đo độ lệch hình học tuyệt đối $d_E(z, c_k) = \|z - c_k\|_2$ và phù hợp với hình học đẳng hướng khi các chiều có cùng thang đo. Khoảng cách cosine loại bỏ ảnh hưởng của độ lớn vectơ và chỉ so sánh hướng, nhưng không mô hình hóa mức phân tán khác nhau theo từng chiều.
- **Khoảng cách Mahalanobis [15]:** Khoảng cách Mahalanobis bổ sung thông tin hiệp phương sai để chuẩn hóa độ lệch theo cấu trúc phân tán của không gian đặc trưng:

$$d_M(z, \mu_k) = \sqrt{(z - \mu_k)^\top (\Sigma + \lambda I)^{-1} (z - \mu_k)} \quad (2.4)$$

Trong đó, z là vectơ biểu diễn của mẫu kiểm thử, μ_k là trung bình đặc trưng của lớp k và Σ là ma trận hiệp phương sai. Độ tin cậy của phép đo phụ thuộc vào chất lượng ước lượng hiệp phương sai và mức phù hợp của giả định phân phối.

2.3.4 Học biểu diễn phục vụ phát hiện dữ liệu ngoài phân phối

Sự thành công của các phương pháp dựa trên khoảng cách phụ thuộc rất lớn vào chất lượng của không gian đặc trưng. Nếu mô hình được huấn luyện bằng hàm entropy chéo thông thường, dữ liệu của các lớp không được tối ưu để co cụm lại, làm giảm hiệu quả của các phép đo khoảng cách. Để giải quyết vấn đề này, các kỹ thuật học biểu diễn được áp dụng.

- **Học tương phản:** Học biểu diễn bằng cách kéo gần các mẫu tương đồng và đẩy xa các mẫu khác lớp trong không gian đặc trưng.
- **Mất mát tâm lớp [35]:** Giảm phương sai nội lớp bằng cách học một tâm biểu diễn cho mỗi lớp và ép các embedding tiến gần tâm tương ứng.
- **Mạng nguyên mẫu [29]:** Phương pháp học theo hệ đo này biểu

diễn mỗi lớp bằng một nguyên mẫu c_k :

$$c_k = \frac{1}{|S_k|} \sum_{x_i \in S_k} f_\theta(x_i) \quad (2.5)$$

Trong quá trình huấn luyện, mạng được tối ưu hóa để cực tiểu hóa khoảng cách giữa đặc trưng của dữ liệu và nguyên mẫu tương ứng của nó.

2.4 Các phương pháp giải thích và đánh giá độ trung thực

Các phương pháp quy đóng gán mức ảnh hưởng cho từng thành phần đầu vào đối với một đầu ra cụ thể. Tích phân gradient [31] tích lũy gradient dọc theo đường nội suy từ một mốc tham chiếu đến đầu vào, nhờ đó có thể áp dụng cho vùng ảnh, đơn vị biểu diễn cục bộ và từ ngữ. Kết quả phản ánh mức phụ thuộc của đầu ra đối với mốc tham chiếu và lớp đích đã chọn, không mặc nhiên biểu thị quan hệ nhân quả hoặc vị trí tổn thương.

Độ trung thực của lời giải thích thường được kiểm tra bằng can thiệp đầu vào. Trong phép loại bỏ, các thành phần được xếp hạng cao được thay dần bằng mốc tham chiếu. Khi đó, xác suất lớp đích giảm nhanh hơn so với thứ tự ngẫu nhiên cung cấp bằng chứng thuận lợi hơn cho thứ tự quy đóng. Phép khôi phục thực hiện theo chiều ngược lại. Kết quả phụ thuộc vào mốc thay thế, tỷ lệ can thiệp và không gian biểu diễn, do đó cần báo cáo giao thức cùng đối chứng ngẫu nhiên thay vì chỉ dựa vào bản đồ nhiệt.

Trọng số chú ý mô tả cách mô-đun phân bổ tương tác trong một lần truyền thuận nhưng không mặc nhiên là lời giải thích trung thực cho quyết định. Ngoài độ trung thực, đánh giá trong y khoa còn cần phân biệt độ ổn định của bản đồ, mức phù hợp với chú thích tổn thương và nhận định của chuyên gia. Khó khăn vì vậy sử dụng tích phân gradient và can thiệp đầu vào để khảo sát nguồn thông tin liên hệ với dự đoán, đồng thời không diễn giải bản đồ quy đóng như bằng chứng định vị hoặc xác nhận lâm sàng.

2.5 Bàn luận

2.5.1 Hạn chế của các nghiên cứu hiện nay

Mặc dù đạt được nhiều kết quả tích cực, các nghiên cứu hiện có vẫn chưa giải quyết đồng thời các yêu cầu của bài toán phân lớp ảnh X-quang xương đa phương thức. Cùng với những hạn chế của mô hình BiomedCLIP khi phân lớp trực tiếp đã được trình bày trong Phần 2.1.2, các vấn đề chính được tổng hợp như sau:

Thứ nhất, phần lớn mô hình y khoa đa phương thức được phát triển trên X-quang ngực hoặc các bộ dữ liệu lớn. Ảnh X-quang xương có phạm vi giải phẫu, tư thế chụp và kiểu tổn thương đa dạng, trong khi số lượng mẫu giữa các lớp thường mất cân bằng đáng kể. Vì vậy, hiệu quả trên các miền dữ liệu khác chưa thể được chuyển trực tiếp sang bài toán này.

Thứ hai, việc co toàn bộ ảnh về kích thước cố định có thể làm mất các đường gãy hoặc bất thường khu trú. Ngược lại, xử lý toàn bộ ảnh ở độ phân giải cao hoặc chia thành quá nhiều vùng làm số đơn vị biểu diễn và chi phí tính toán tăng nhanh. Do đó, cần kết hợp ngữ cảnh toàn cục với các vùng cục bộ có ích trong một ngân sách đơn vị biểu diễn được kiểm soát.

Thứ ba, nhiều nghiên cứu sử dụng báo cáo đọc ảnh hoặc kết luận chẩn đoán làm đầu vào văn bản. Tuy nhiên, các báo cáo này thường được hình thành sau khi bác sĩ hoặc bác sĩ chẩn đoán hình ảnh đã quan sát phim và có thể mô tả trực tiếp vị trí, hình thái hoặc mức độ tổn thương, chẳng hạn đường gãy, di lệch hay bất thường xương. Việc sử dụng các nguồn văn bản này trong giai đoạn suy luận có thể gây rò rỉ nhãn, khiến mô hình chủ yếu học cách ánh xạ một mô tả gần với kết luận chẩn đoán sang nhãn tương ứng. Trong bối cảnh triển khai thực tế, để tạo được báo cáo chi tiết, bác sĩ đã phải nhận diện tổn thương trước, do đó mô hình không còn đóng vai trò hỗ trợ phát hiện mà chủ yếu lặp lại thông tin đã được xác định. Ngược lại, các thông tin lâm sàng có sẵn trước chẩn đoán cuối cùng, như triệu chứng, tiền sử bệnh, vị trí đau hoặc cơ chế chấn thương, vẫn chưa được khai thác đầy đủ, mặc dù đây là những nguồn thông tin quan trọng giúp

định hướng quá trình chẩn đoán. Bên cạnh đó, nhiều phương pháp chỉ nổi hai vectơ đặc trưng toàn cục, nên chưa mô hình hóa được quan hệ cụ thể giữa các vùng ảnh và nội dung lâm sàng liên quan.

Thứ tư, mặc dù các mô hình nền tảng đạt hiệu quả cao, nhiều nghiên cứu vẫn lựa chọn tinh chỉnh toàn bộ tham số của mô hình. Cách tiếp cận này đòi hỏi chi phí tính toán lớn, đồng thời làm tăng nguy cơ quên tri thức đã được học trong giai đoạn tiền huấn luyện.

Cuối cùng, hầu hết các nghiên cứu chỉ tập trung tối ưu hiệu năng phân lớp mà chưa quan tâm đầy đủ đến khả năng phát hiện dữ liệu ngoài phân phối. Trong môi trường lâm sàng, mô hình có thể gặp các trường hợp bệnh lý hiếm, dữ liệu có chất lượng thấp hoặc các bất thường chưa xuất hiện trong tập huấn luyện. Nếu không có cơ chế phát hiện dữ liệu ngoài phân phối, mô hình vẫn có thể đưa ra dự đoán với độ tin cậy cao mặc dù kết quả không chính xác.

2.5.2 Cơ sở lựa chọn và định hướng phương pháp đề xuất

Từ những hạn chế trên, khóa luận lựa chọn xây dựng hệ thống dựa trên việc kế thừa mô hình BiomedCLIP [38] kết hợp với thông tin lâm sàng để khai thác đồng thời đặc trưng hình ảnh và văn bản. Các lựa chọn thiết kế cụ thể được đưa ra dựa trên phân tích sau:

Về xử lý ảnh độ phân giải cao: Việc co toàn bộ ảnh X-quang về kích thước đầu vào cố định có thể làm suy giảm các dấu hiệu tổn thương nhỏ, trong khi xử lý toàn bộ ảnh ở độ phân giải cao làm tăng đáng kể chi phí tính toán. Vì vậy, khóa luận lựa chọn chiến lược toàn cục-cục bộ, trong đó ảnh toàn cục duy trì bố cục giải phẫu chung, còn bốn vùng cục bộ được lựa chọn nhằm bảo toàn các vùng giàu thông tin. Các đặc trưng cục bộ được bổ sung thông tin vị trí và nén về số lượng đơn vị biểu diễn cố định để cân bằng giữa khả năng giữ lại chi tiết và chi phí xử lý.

Về thích nghi mô hình nền tảng: LoRA [12] được sử dụng để thích nghi hai bộ mã hóa của BiomedCLIP với miền ảnh X-quang xương mà không cần cập nhật toàn bộ tham số nền. Lựa chọn này giúp giảm chi phí

huấn luyện, hạn chế nguy cơ quá khớp trên các lớp có ít mẫu và bảo toàn phần lớn tri thức y sinh đã được học trong giai đoạn tiền huấn luyện.

Bên cạnh đó, hàm mất mát tương phản InfoNCE nguyên bản xem các mẫu khác nhau trong cùng lô là các cặp âm, kể cả khi chúng thuộc cùng một lớp hoặc có nội dung lâm sàng tương đồng. Do đó, khóa luận sử dụng hàm mất mát khớp ngữ nghĩa kế thừa từ MedCLIP và xây dựng phân phối đích mềm theo nhãn lớp. Mục tiêu này vẫn ưu tiên sự tương hợp của cặp ảnh-văn bản tương ứng, đồng thời giảm ảnh hưởng của các cặp âm tính giả giữa những mẫu có quan hệ ngữ nghĩa gần nhau.

Về khai thác và dung hợp thông tin lâm sàng: Thiết lập phân lớp không mẫu của BiomedCLIP chỉ đối sánh ảnh với các câu nhắc đại diện cho lớp và không sử dụng thông tin riêng của từng người bệnh. Phương pháp đề xuất bổ sung nhánh văn bản để mã hóa những thông tin lâm sàng có sẵn trước kết luận chẩn đoán, chẳng hạn lý do vào viện, triệu chứng và bệnh sử. Báo cáo đọc ảnh, chẩn đoán xác định và nhãn phân lớp không được đưa trực tiếp vào đầu vào nhằm hạn chế rò rỉ nhãn.

Thay vì chỉ ghép nối hai biểu diễn toàn cục, khóa luận lựa chọn cơ chế chú ý chéo hai chiều để đặc trưng ảnh lựa chọn các thông tin lâm sàng liên quan, đồng thời đặc trưng văn bản định hướng mô hình đến các vùng ảnh phù hợp. Thiết kế này cho phép mô hình hóa quan hệ cụ thể giữa dấu hiệu X-quang và ngữ cảnh lâm sàng.

Về phân lớp đa lớp và mất cân bằng dữ liệu: Phương pháp sử dụng đầu phân lớp dựa trên tâm lớp thực nghiệm, được phát triển từ ý tưởng của mạng nguyên mẫu, trong đó mỗi lớp được đại diện bằng trung bình các vectơ biểu diễn thuộc lớp đó thay vì một nguyên mẫu được học tự do. Độ tương đồng cosine với từng tâm được chuyển thành logit và kết hợp với độ lệch học được theo lớp trước khi áp dụng Softmax. Vì vậy, nhãn dự đoán không nhất thiết luôn là tâm có độ tương đồng lớn nhất. Hàm mất mát entropy chéo có trọng số được sử dụng nhằm giảm ảnh hưởng của sự chênh lệch số lượng mẫu giữa các lớp.

Về phát hiện dữ liệu ngoài phân phối: Ngoài nhiệm vụ phân lớp, khóa luận bổ sung cơ chế phát hiện dữ liệu ngoài phân phối ở giai đoạn hậu xử lý mà không yêu cầu mẫu ngoài phân phối trong quá trình huấn luyện, hoạt động dựa trên cơ chế phân loại trong không gian đặc trưng

được xây dựng từ bộ phân loại. Khoảng cách Mahalanobis được tính giữa biểu diễn của mẫu mới và các trung bình lớp thực nghiệm, có xét đến cấu trúc hiệp phương sai của không gian đặc trưng. Mẫu có điểm vượt ngưỡng được gắn thêm cảnh báo ngoài phân phối. Trong phạm vi khóa luận, cảnh báo này không thay đổi nhãn phân lớp nội tại và chưa được sử dụng để tự động từ chối dự đoán. Ngưỡng được hiệu chỉnh trên tập xác thực.

Về quy trình huấn luyện: Từ các lựa chọn trên, hệ thống được tổ chức thành hai giai đoạn ngoại tuyến:

- **Giai đoạn 1 - Thích nghi và căn chỉnh biểu diễn:** hai bộ mã hóa của BiomedCLIP được thích nghi thông qua LoRA bằng hàm mất mát khớp ngữ nghĩa. Mô-đun dung hợp và đầu phân lớp chưa được tối ưu trong giai đoạn này.
- **Giai đoạn 2 - Dung hợp và phân lớp:** các bộ mã hóa tiếp tục được thích nghi thông qua LoRA, đồng thời mô-đun xử lý đặc trưng cục bộ và cơ chế chú ý chéo hai chiều được tối ưu cho nhiệm vụ phân lớp. Các tâm lớp thực nghiệm được cập nhật từ đặc trưng của tập huấn luyện và được sử dụng cho cả phân lớp lẫn phát hiện dữ liệu ngoài phân phối.


Các định hướng trên được hiện thực hóa trong phương pháp XBone-Net. Kiến trúc chi tiết, quy trình huấn luyện và cơ chế suy luận được trình bày trong Chương 3.

Chương 3

Phương pháp đề xuất

3.1 Tổng quan phương pháp đề xuất

Nhóm nghiên cứu đề xuất XBone-Net cho bài toán phân loại đa lớp ảnh X-quang xương có kết hợp thông tin lâm sàng. Hệ thống được xây dựng theo kiến trúc hai nhánh. Nhánh ảnh khai thác đồng thời cấu trúc giải phẫu toàn cục và các vùng cục bộ giàu chi tiết, trong khi nhánh văn bản biểu diễn bệnh sử và lý do vào viện. Hai nguồn thông tin được ánh xạ vào cùng một không gian đặc trưng, trao đổi ngữ cảnh bằng cơ chế chú ý chéo hai chiều, sau đó được phân lớp bằng tâm cụm thực nghiệm.



Hình 3.1: Sơ đồ tổng quan phương pháp XBone-Net đề xuất

Như minh họa trong Hình 3.1, XBone-Net kế thừa bộ mã hóa thị giác và bộ mã hóa văn bản của BiomedCLIP [38]. Các tham số nền được giữ cố định để bảo toàn tri thức y sinh đã học trước, trong khi các ma trận thích nghi hạng thấp LoRA [12] được huấn luyện trên dữ liệu đích. Sau bước mã hóa, mô-đun dung hợp kết hợp đặc trưng toàn cục và cục bộ của hai

phương thức. Biểu diễn tổng hợp cuối cùng được so sánh với các nguyên mẫu lớp để đưa ra dự đoán. Định danh mô hình nền tảng, kích thước biểu diễn, vị trí chèn LoRA và cấu hình tái lập đầy đủ được trình bày tại Phụ lục B.

Mỗi mẫu dữ liệu được ký hiệu bởi bộ ba gồm ảnh X-quang, thông tin lâm sàng và nhãn lớp. Tập huấn luyện có dạng:

$$\mathcal{D}_{\text{train}} = \left\{ \left(x_i^{\text{img}}, x_i^{\text{txt}}, y_i \right) \right\}_{i=1}^N, \quad y_i \in \mathcal{Y}. \quad (3.1)$$

Trong đó, $x_i^{\text{img}} \in \mathbb{R}^{H_i \times W_i \times C_{\text{in}}}$ là ảnh X-quang của mẫu thứ i . Các ký hiệu H_i , W_i và C_{in} lần lượt là chiều cao, chiều rộng và số kênh ảnh. Thông tin lâm sàng được ký hiệu $x_i^{\text{txt}} = (w_{i,1}, \dots, w_{i,L_i})$, với L_i là số đơn vị biểu diễn trước khi cắt hoặc đệm. Nhãn y_i thuộc tập chỉ số lớp $\mathcal{Y} = \{1, \dots, K\}$, còn N là số mẫu huấn luyện.

Quá trình xây dựng mô hình được chia thành hai giai đoạn ngoại tuyến. Giai đoạn thứ nhất thích nghi hai nhánh mã hóa và căn chỉnh không gian ảnh-văn bản bằng hàm mất mát khớp ngữ nghĩa. Giai đoạn thứ hai học cơ chế dung hợp và ranh giới phân lớp trong không gian nguyên mẫu. Khi suy luận trực tuyến, toàn bộ tham số và các nguyên mẫu lớp được cố định, mô hình chỉ thực hiện tính toán truyền thuận cho một ca mới.


Để làm rõ cách hệ thống chuyển đổi từng nguồn dữ liệu thành biểu diễn có thể sử dụng cho quá trình dung hợp, các phần tiếp theo lần lượt trình bày nhánh biểu diễn ảnh, nhánh biểu diễn văn bản và cơ chế thích nghi hai bộ mã hóa trước khi đi đến mô-đun dung hợp và phân lớp.

3.2 Nhánh biểu diễn ảnh

3.2.1 Tiền xử lý ảnh X-quang theo kỹ thuật Letterbox

Ảnh X-quang đầu vào x_i^{img} thu thập trong thực tế lâm sàng thường có độ phân giải cao và tỷ lệ khung hình không vuông (ví dụ ảnh chụp xương dài, bàn tay hay cẳng chân có dạng hình chữ nhật đứng), trong khi bộ

mã hóa thị giác của BiomedCLIP [38] yêu cầu đầu vào kích thước chuẩn 224×224 . Để bảo toàn nguyên vẹn cấu trúc giải phẫu học và không làm méo hình thái xương, XBone-Net áp dụng quy trình tiền xử lý gồm 3 bước tuần tự như minh họa tại Hình 3.2.



Hình 3.2: Quy trình tiền xử lý ảnh X-quang

Các bước thực hiện tiền xử lý

Quy trình tiền xử lý được chuẩn hóa qua các bước tính toán hình học và nội suy số học cụ thể như sau:

- **Ảnh đầu vào:** Ảnh chụp X-quang gốc x_i^{img} có kích thước ban đầu $W \times H$ (ví dụ: 1213×1713 điểm ảnh).
- **Bước 1 – Tính toán tỷ lệ và giảm kích thước:** Nhằm bảo toàn tỷ lệ khung hình thực tế, hệ thống xác định hệ số thu phóng s theo cạnh dài nhất hướng tới kích thước mục tiêu $S_{\text{target}} = 224$:

$$s = \min \left(\frac{S_{\text{target}}}{W}, \frac{S_{\text{target}}}{H} \right). \quad (3.2)$$

Kích thước mới của ảnh được xác định bởi $W' = \text{round}(W \cdot s)$ và $H' = \text{round}(H \cdot s)$. Với ảnh kích thước 1213×1713 , ảnh được giảm kích thước về 159×224 , đảm bảo cạnh dài nhất vừa khít 224 điểm ảnh mà không làm co giãn méo hình.

- **Bước 2 – Nội suy bậc ba (Bicubic Resampling):** Các điểm ảnh tại kích thước mới (W', H') được tái tạo giá trị thông qua phép nội suy bậc ba hai chiều. Thuật toán sử dụng hàm đa thức bậc ba trên lân cận 16 điểm ảnh (4×4) xung quanh:

$$I(x, y) = \sum_{j=0}^3 \sum_{k=0}^3 a_{jk} x^j y^k. \quad (3.3)$$

Phép nội suy bậc ba giúp duy trì độ sắc nét cao của các đường bờ viền xương, đường nứt gãy và cấu trúc bề xương, đồng thời khử triệt để hiện tượng răng cưa hay mờ nhòe vốn thường gặp ở các phép nội suy lân cận gần nhất hoặc song tuyến tính.

- **Bước 3 – Thêm vùng đệm (Letterbox Padding):** Hệ thống khởi tạo một khung ảnh vuông kích thước 224×224 với giá trị màu đệm là màu đen $(0, 0, 0)$. Ảnh sau khi nội suy được dán vào chính giữa Canvas tại các khoảng bù tọa độ:

$$\Delta x = \left\lfloor \frac{S_{\text{target}} - W'}{2} \right\rfloor, \quad \Delta y = \left\lfloor \frac{S_{\text{target}} - H'}{2} \right\rfloor. \quad (3.4)$$

Khoảng trống ở hai bên (hoặc trên/dưới) được lấp đầy bằng màu đen đồng nhất, tạo ra ảnh vuông $x_i^{\text{img},g} \in \mathbb{R}^{224 \times 224 \times 3}$.

So sánh với cơ chế tiền xử lý của BiomedCLIP gốc

Trong mô hình BiomedCLIP gốc, cơ chế cắt trung tâm vốn được thiết kế cho các ảnh y tế tổng quát hoặc ảnh chụp ngực tiêu chuẩn. Tuy nhiên, đối với ảnh X-quang cơ xương khớp (vốn có tỷ lệ chiều dọc lớn như xương đùi, xương cẳng tay, khớp bàn tay), phép cắt trung tâm làm mất đi phần lớn các đầu xương và khớp nằm ở phía trên hoặc phía dưới của khung hình. Kỹ thuật tiền xử lý của XBone-Net khắc phục điểm này bằng cách đưa toàn bộ bức ảnh vào vùng nhìn của mạng nơ-ron.

3.2.2 Bộ mã hóa thị giác BiomedCLIP

Mô hình kế thừa bộ mã hóa của BiomedCLIP [38], được xây dựng theo kiến trúc Vision Transformer [7]. Mỗi ảnh 224×224 được chia thành lưới 14×14 mảnh ảnh kích thước 16×16 . Sau khi thêm một đơn vị đại diện, bộ mã hóa và lớp chiếu tạo chuỗi gồm 197 vectơ có chiều $D = 512$:

$$\mathbf{H}_{i,m}^I = \mathcal{F}_I(x_{i,m}) = [\mathbf{h}_{i,m,0}; \mathbf{h}_{i,m,1}; \dots; \mathbf{h}_{i,m,196}] \in \mathbb{R}^{197 \times D}. \quad (3.5)$$

$\mathcal{F}_I$ gồm bộ mã hóa thị giác và lớp chiếu của BiomedCLIP. Chỉ số $m = g$ biểu thị ảnh toàn cục, còn $m = 1, \dots, 4$ biểu thị bốn ảnh cục bộ. Chỉ số 0 chỉ đơn vị đại diện, còn các chỉ số 1 đến 196 tương ứng với lưới mảnh ảnh. Ảnh toàn cục được biểu diễn bằng vectơ đại diện đã chuẩn hóa:

$$\mathbf{g}_i = \text{Norm}(\mathbf{h}_{i,g,0}) \in \mathbb{R}^D. \quad (3.6)$$

Ảnh toàn cục và bốn ảnh cục bộ dùng chung $\mathcal{F}_I$, do đó không hình thành một bộ mã hóa riêng cho nhánh cục bộ. Đối với mỗi ảnh cục bộ, lưới 14×14 được gộp trung bình thích nghi thành lưới 2×2 , trong khi đơn vị đại diện của vùng được giữ lại. Vì vậy, mỗi vùng tạo năm đơn vị biểu diễn:

$$\mathbf{L}_{i,m} = \text{Norm}([\mathbf{h}_{i,m,0}; \text{Pool}_{2 \times 2}(\mathbf{h}_{i,m,1:196})]) \in \mathbb{R}^{5 \times D}. \quad (3.7)$$

Phép Norm chuẩn hóa từng vectơ theo chuẩn ℓ_2 . Ghép kết quả của bốn vùng thu được $P = 4 \times 5 = 20$ đơn vị cục bộ. Hộp của đơn vị đại diện bằng hộp của toàn vùng, còn bốn đơn vị còn lại nhận tọa độ của bốn ô con trong lưới 2×2 .

Gọi $\ell_{i,n}$ và $\mathbf{b}_{i,n} \in [0, 1]^4$ lần lượt là đơn vị cục bộ thứ n và hộp tọa độ tương ứng. Tọa độ được chiếu qua một mạng hai lớp, cộng có kiểm soát vào nội dung và chuẩn hóa lại, tạo ra đơn vị biểu diễn ảnh có thông tin vị trí:

$$\tilde{\ell}_{i,n} = \text{Norm}(\text{Norm}(\ell_{i,n}) + \tanh(\gamma) \text{Norm}(\mathcal{P}_s(\mathbf{b}_{i,n}))), \quad n = 1, \dots, P. \quad (3.8)$$

$\mathcal{P}_s : \mathbb{R}^4 \rightarrow \mathbb{R}^D$ là phép chiếu tọa độ và γ là hệ số học được, khởi tạo bằng 0,1. Cấu hình chính truyền nguyên 20 đơn vị sau khi bổ sung tọa độ, không gộp chúng bằng các truy vấn học được. Chuỗi thị giác dùng cho dung hợp vì vậy là:

$$\mathbf{V}_i = [\mathbf{g}_i; \tilde{\ell}_{i,1}; \dots; \tilde{\ell}_{i,20}] \in \mathbb{R}^{21 \times 512}. \quad (3.9)$$

Trong giai đoạn khớp ngữ nghĩa, chuỗi $\mathbf{V}_i$ được rút thành một vectơ ảnh bằng phép gộp có điều kiện theo đặc trưng toàn cục, như trình bày trong Công thức 3.25. Ở giai đoạn dung hợp, mô hình sử dụng trực tiếp toàn bộ chuỗi $\mathbf{V}_i$ để giữ lại thông tin theo từng vùng.

3.3 Nhánh biểu diễn văn bản

Bổ sung cho các bằng chứng hình thái được trích xuất từ ảnh X-quang, nhánh biểu diễn văn bản có nhiệm vụ mã hóa thông tin lâm sàng x_i^{txt} thành các đặc trưng ngữ cảnh theo từng đơn vị biểu diễn và một vectơ đại diện cho toàn bộ chuỗi. Trong khóa luận, nhánh này được kế thừa từ bộ mã hóa văn bản của BiomedCLIP [38], với thành phần chính là PubMedBERT. Khác với các mô hình ngôn ngữ được tiền huấn luyện trên văn bản tổng quát, PubMedBERT được tiền huấn luyện từ đầu trên kho ngữ liệu y sinh và sử dụng bộ từ vựng được xây dựng trực tiếp từ miền dữ liệu này. Nhờ đó, mô hình phù hợp hơn với các thuật ngữ chuyên ngành xuất hiện trong thông tin lâm sàng.

3.3.1 Tiền xử lý và mã hóa đầu vào

Trước khi đưa vào PubMedBERT, chuỗi văn bản x_i^{txt} được phân tách thành các đơn vị từ con bằng bộ mã hóa WordPiece tương ứng với mô hình. Hai đơn vị biểu diễn đặc biệt [CLS] và [SEP] lần lượt được thêm vào đầu và cuối chuỗi. Chuỗi sau khi mã hóa được cắt hoặc đệm đến độ dài tối đa T_T :

$$(\mathbf{u}_i, \mathbf{m}_i) = \text{Tokenizer}_T(x_i^{\text{txt}}), \quad (3.10)$$

trong đó $\mathbf{u}_i \in \mathbb{N}^{T_T}$ là chuỗi chỉ số đơn vị biểu diễn và $\mathbf{m}_i \in \{0, 1\}^{T_T}$ là mặt nạ chú ý. Giá trị bằng 1 trong $\mathbf{m}_i$ biểu thị một đơn vị biểu diễn hợp lệ, trong khi giá trị bằng 0 biểu thị vị trí được thêm vào để đệm chuỗi.

3.3.2 Bộ mã hóa văn bản BiomedCLIP

Mô hình kế thừa bộ mã hóa văn bản PubMedBERT của BiomedCLIP [38]. Chuỗi chỉ số đơn vị biểu diễn $\mathbf{u}_i$ cùng mặt nạ chú ý $\mathbf{m}_i$ được đưa qua bộ mã hóa và lớp chiếu để tạo chuỗi đặc trưng có cùng chiều $D = 512$ với nhánh ảnh:

$$\mathbf{H}_i^T = \mathcal{F}_T(\mathbf{u}_i, \mathbf{m}_i) = [\mathbf{h}_{i,0}^T; \mathbf{h}_{i,1}^T; \dots; \mathbf{h}_{i,T_T-1}^T] \in \mathbb{R}^{T_T \times D}. \quad (3.11)$$

$\mathcal{F}_T$ gồm bộ mã hóa văn bản và lớp chiếu của BiomedCLIP, còn T_T là độ dài chuỗi sau khi cắt hoặc đệm. Mặt nạ $\mathbf{m}_i$ loại bỏ ảnh hưởng của các vị trí đệm. Chỉ số 0 biểu thị đơn vị biểu diễn [CLS], được dùng để tạo vectơ văn bản toàn cục đã chuẩn hóa:

$$\mathbf{t}_i = \text{Norm}(\mathbf{h}_{i,0}^T) \in \mathbb{R}^D. \quad (3.12)$$

Chuỗi $\mathbf{H}_i^T$ được giữ lại cho bước dung hợp bằng chú ý chéo, trong khi $\mathbf{t}_i$ được sử dụng làm biểu diễn toàn cục của văn bản.

Kết thúc hai nhánh mã hóa, mỗi mẫu được biểu diễn bởi chuỗi đặc trưng ảnh $\mathbf{V}_i$, ma trận đặc trưng văn bản $\mathbf{H}_i^T$ và các vectơ toàn cục tương ứng. Mặc dù các biểu diễn này kế thừa tri thức y sinh từ BiomedCLIP, sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu X-quang xương đích vẫn đòi hỏi hai bộ mã hóa được thích nghi trước khi thực hiện dung hợp.

3.4 Thích nghi tham số bằng LoRA

Hai bộ mã hóa đã được tiền huấn luyện trên dữ liệu y sinh quy mô lớn, nhưng dữ liệu X-quang xương đích vẫn có khác biệt về phân bố ảnh, cách ghi bệnh sử và hệ thống nhãn. Việc tinh chỉnh toàn bộ tham số có chi phí

lớn và dễ quá khớp khi dữ liệu gán nhãn hạn chế. XBone-Net vì vậy sử dụng LoRA để học phần cập nhật hạng thấp cho các phép biến đổi tuyến tính quan trọng.

Với ma trận trọng số nền $\mathbf{W} \in \mathbb{R}^{d_o \times d_i}$, LoRA biểu diễn ma trận sau thích nghi theo công thức chuẩn:

$$\mathbf{W}' = \mathbf{W} + \frac{\alpha}{r} \mathbf{B} \mathbf{A}, \quad \mathbf{A} \in \mathbb{R}^{r \times d_i}, \quad \mathbf{B} \in \mathbb{R}^{d_o \times r}, \quad r \ll \min(d_i, d_o). \quad (3.13)$$


Trong Công thức 3.13, $\mathbf{W}$ được giữ cố định, $\mathbf{A}$ và $\mathbf{B}$ là hai ma trận được cập nhật, r là hạng thích nghi và α là hệ số tỷ lệ. Nhờ đó, mô hình chỉ học một phần nhỏ tham số bổ sung nhưng vẫn có thể điều chỉnh cả biểu diễn ảnh lẫn biểu diễn văn bản cho miền dữ liệu mới. Khi triển khai, phần cập nhật có thể được giữ riêng hoặc gộp tương đương vào trọng số nền mà không làm thay đổi kết quả tính toán.

LoRA chỉ điều chỉnh cách từng bộ mã hóa biểu diễn dữ liệu trong miền đích. Bản thân kỹ thuật này chưa thực hiện trao đổi thông tin giữa ảnh và văn bản. Sau khi hai nhánh đã tạo ra các đặc trưng thích nghi, các biểu diễn này được chuyển đến mô-đun dung hợp để mô hình hóa quan hệ giữa dấu hiệu thị giác và ngữ cảnh lâm sàng.

3.5 Dung hợp đa phương thức bằng chú ý chéo

Từ hai nhánh mã hóa, hệ thống thu được chuỗi đặc trưng ảnh $\mathbf{V}_i$, ma trận đặc trưng văn bản $\mathbf{H}_i^T$ và hai biểu diễn toàn cục $\mathbf{g}_i, \mathbf{t}_i$. Nếu chỉ ghép nối trực tiếp các vectơ toàn cục, mô hình chưa thể hiện rõ nội dung lâm sàng nào liên quan đến từng dấu hiệu trên ảnh. Vì vậy, XBone-Net sử dụng cơ chế chú ý chéo hai chiều để mỗi phương thức chủ động truy vấn thông tin cần thiết từ phương thức còn lại trước khi hình thành biểu diễn chung, được thể hiện trong Hình 3.3.

Trước khi chú ý, mỗi chuỗi được chuẩn hóa lớp và chiếu riêng về cùng



Hình 3.3: Mô-đun dung hợp bằng chú ý chéo hai chiều

không gian D chiều:

$$\widehat{\mathbf{V}}_i = \text{Linear}_I(\text{LN}(\mathbf{V}_i)), \quad \widehat{\mathbf{H}}_i^T = \text{Linear}_T(\text{LN}(\mathbf{H}_i^T)). \quad (3.14)$$

Trong đó, Linear_I và Linear_T là hai lớp tuyến tính $D \rightarrow D$ có tham số độc lập, lần lượt biến đổi đặc trưng ảnh và đặc trưng văn bản trước khi thực hiện chú ý chéo.

XBone-Net sử dụng cơ chế chú ý đa đầu chia không gian đặc trưng thành H_a không gian con. Mỗi đầu thực hiện một phép chú ý độc lập, sau đó các kết quả được ghép và chiếu để tạo đầu ra chung:

$$\text{head}_h = \text{Attn}_h(\mathbf{X}, \mathbf{Y}; \mathbf{M}), \quad h = 1, \dots, H_a. \quad (3.15)$$

Sau đó, đầu ra của các đầu được ghép và chiếu bởi ma trận $\mathbf{W}_O$:

$$\text{MHA}(\mathbf{X}, \mathbf{Y}; \mathbf{M}) = [\text{head}_1; \dots; \text{head}_{H_a}] \mathbf{W}_O. \quad (3.16)$$

Với đầu chú ý thứ h có truy vấn $\mathbf{X}$, ngữ cảnh $\mathbf{Y}$ và mặt nạ cộng $\mathbf{M}$,

phép tính chú ý một đầu là:

$$\text{Attn}_h(\mathbf{X}, \mathbf{Y}; \mathbf{M}) = \text{softmax} \left(\frac{(\mathbf{X}\mathbf{W}_Q^{(h)})(\mathbf{Y}\mathbf{W}_K^{(h)})^\top}{\sqrt{d_h}} + \mathbf{M} \right) (\mathbf{Y}\mathbf{W}_V^{(h)}). \quad (3.17)$$

Trong đó, $d_h = D/H_a$ là số chiều của một trong H_a đầu chú ý. Mỗi đầu trong mỗi hướng có các ma trận $\mathbf{W}_Q^{(h)}, \mathbf{W}_K^{(h)}, \mathbf{W}_V^{(h)}$ riêng, còn $\mathbf{W}_O$ chiếu kết quả sau khi ghép các đầu. Mặt nạ $\mathbf{M}$ nhận giá trị $-\infty$ tại đơn vị biểu diễn đệm và 0 tại đơn vị biểu diễn hợp lệ.

Việc sử dụng nhiều đầu cho phép mô hình đồng thời khảo sát các quan hệ ảnh-văn bản trong những không gian biểu diễn khác nhau, cung cấp cho mô hình các phép chiếu truy vấn, khóa và giá trị khác nhau, qua đó tạo khả năng học đồng thời nhiều kiểu quan hệ giữa ảnh và văn bản. Do đó, các đầu có thể chú ý đến những khía cạnh bổ sung nhau.

XBone-Net sử dụng đơn vị biểu diễn toàn cục chỉ làm truy vấn, còn khóa và giá trị loại bỏ đơn vị biểu diễn toàn cục ở vị trí đầu. Ở chiều ảnh truy vấn văn bản:

$$\mathbf{h}_i^{I \leftarrow T} = \text{LN} \left(\widehat{\mathbf{V}}_{i,0} + \text{MHA}_{I \leftarrow T} \left(\widehat{\mathbf{V}}_{i,0:1}, \widehat{\mathbf{H}}_{i,1:}^T; \mathbf{M}_i^T \right)_0 \right) \in \mathbb{R}^D. \quad (3.18)$$

Ở chiều văn bản truy vấn ảnh, một mô-đun chú ý độc lập sử dụng P đơn vị biểu diễn ảnh cục bộ:

$$\mathbf{h}_i^{T \leftarrow I} = \text{LN} \left(\widehat{\mathbf{H}}_{i,0}^T + \text{MHA}_{T \leftarrow I} \left(\widehat{\mathbf{H}}_{i,0:1}^T, \widehat{\mathbf{V}}_{i,1:}; \mathbf{M}_i^I \right)_0 \right) \in \mathbb{R}^D. \quad (3.19)$$

Hai biểu diễn sau chú ý được ghép và đưa qua một perceptron đa tầng để tạo vectơ đặc trưng tổng hợp:

$$\mathbf{z}_i = \text{LN} \left(\text{MLP} \left([\mathbf{h}_i^{I \leftarrow T}; \mathbf{h}_i^{T \leftarrow I}] \right) \right) \in \mathbb{R}^D. \quad (3.20)$$

Hình 3.3 cho thấy hai hướng chú ý được thực hiện song song. Hai mô-đun không chia sẻ tham số vì vai trò truy vấn-ngữ cảnh đảo ngược nhau.

Kết nối phần dư giữ lại đơn vị biểu diễn toàn cục, còn MLP học cách tổng hợp hai biểu diễn đã được bổ sung ngữ cảnh.

Kết quả của quá trình trên là vectơ đa phương thức $\mathbf{z}_i$, trong đó thông tin ảnh và văn bản đã được tổng hợp trong cùng một biểu diễn. Vectơ này là đầu vào trực tiếp của bộ phân lớp, do đó quyết định cuối cùng không còn dựa trên từng phương thức riêng lẻ mà dựa trên quan hệ đã học giữa chúng.

3.6 Bộ phân lớp bằng tâm lớp thực nghiệm

Hình 3.4 minh họa cách phân lớp vectơ đặc trưng trong không gian nguyên mẫu.

Trên không gian đặc trưng đa phương thức được tạo bởi mô-đun dung hợp, XBone-Net thực hiện phân lớp theo nguyên lý của mạng nguyên mẫu [29]. Thay vì sử dụng một lớp tuyến tính với trọng số lớp được học trực tiếp, mỗi lớp được biểu diễn bằng tâm của các vectơ $\mathbf{z}_i$ thuộc lớp tương ứng. Cách xây dựng này cho phép diễn giải dự đoán thông qua mức độ gần giữa mẫu và từng tâm lớp, đồng thời tạo ra một không gian khoảng cách có thể tiếp tục được khai thác trong bước phát hiện OOD.


Với $\mathcal{I}_k = \{i \mid y_i = k\}$ là tập chỉ số các mẫu huấn luyện thuộc lớp k , tâm thực nghiệm được ước lượng bằng trung bình đặc trưng:

$$\mathbf{c}_k = \frac{1}{|\mathcal{I}_k|} \sum_{i \in \mathcal{I}_k} \mathbf{z}_i. \quad (3.21)$$

Điểm tương đồng giữa mẫu và tâm lớp được xác định bằng cosine:

$$r_{ik} = \frac{\mathbf{z}_i^T \mathbf{c}_k}{\|\mathbf{z}_i\|_2 \|\mathbf{c}_k\|_2}. \quad (3.22)$$

Đầu phân lớp chuyển điểm tương đồng thành logit sử dụng hệ số tỷ lệ α_c và một độ lệch học được riêng cho từng lớp:



Hình 3.4: Phân lớp vectơ đặc trưng tổng hợp trong không gian nguyên mẫu

$$\ell_{ik} = \alpha_c r_{ik} + b_k, \quad \alpha_c > 0. \quad (3.23)$$

Xác suất dự đoán được tính bằng Softmax trên các logit:

$$p_{ik} = p(y = k \mid \mathbf{z}_i) = \frac{\exp(\ell_{ik})}{\sum_{j=1}^K \exp(\ell_{ij})}, \quad (3.24)$$


trong đó α_c điều chỉnh độ sắc của phân phối xác suất, còn b_k được tối ưu trong pha 2. Khi các độ lệch bằng nhau, nhãn dự đoán tương đương với tâm có cosine lớn nhất. Khi b_k được học, ranh giới còn được hiệu chỉnh theo lớp. Các tâm $\mathbf{c}_k$ là thống kê của tập huấn luyện, không phải tham số nhận đạo hàm.

Các phần trên xác định luồng truyền thuận của XBone-Net từ dữ liệu đầu vào đến xác suất phân lớp. Tuy nhiên, các thành phần không được tối ưu đồng thời ngay từ đầu, bởi việc thích nghi không gian ảnh-văn bản và việc học nhiệm vụ phân lớp có mục tiêu khác nhau. Vì vậy, quá trình huấn luyện được tách thành hai giai đoạn ngoại tuyến.

3.7 Huấn luyện hai giai đoạn trong quá trình ngoại tuyến

Quy trình ngoại tuyến lần lượt giải quyết hai yêu cầu của hệ thống. Giai đoạn thứ nhất điều chỉnh các bộ mã hóa để ảnh X-quang và thông tin lâm sàng tương ứng được biểu diễn phù hợp hơn trong miền dữ liệu đích. Trên nền không gian đã thích nghi, giai đoạn thứ hai học tương tác liên phương thức và tối ưu quyết định phân lớp có xét đến sự mất cân bằng giữa các lớp.

3.7.1 Giai đoạn 1: thích nghi miền bằng khớp ngữ nghĩa



Hình 3.5: Giai đoạn thích nghi miền bằng khớp ngữ nghĩa ảnh-văn bản

Giai đoạn thứ nhất được minh họa trong Hình 3.5. Ảnh X-quang và thông tin lâm sàng tương ứng được đưa qua hai bộ mã hóa để tạo các vectơ trong cùng một không gian. Các trọng số nền của BiomedCLIP được đóng băng, còn các ma trận LoRA và thành phần tổng hợp đặc trưng ảnh cục bộ được cập nhật. Mô-đun dung hợp và tâm cụm thực nghiệm chưa tham gia vào mục tiêu tối ưu ở giai đoạn này.

Giai đoạn này sử dụng hàm mất mát khớp ngữ nghĩa với phân phối đích mềm theo nhãn lớp. Trước hết, các đơn vị biểu diễn ảnh cục bộ được tóm tắt bằng tổng có trọng số rồi bổ sung vào đặc trưng toàn cục:

$$\begin{aligned} \mathbf{v}_i^{\text{local}} &= \sum_{n \in \mathcal{P}_i} \alpha_{i,n} \tilde{\ell}_{i,n}, \\ \bar{\mathbf{v}}_i &= \text{Norm}(\mathbf{g}_i + 0,25 \text{Norm}(\mathbf{v}_i^{\text{local}})). \end{aligned} \quad (3.25)$$

Trong đó, $\mathcal{P}_i$ là tập chỉ số đơn vị biểu diễn cục bộ hợp lệ, còn $\alpha_{i,n}$ biểu thị mức đóng góp tương đối của đơn vị biểu diễn cục bộ thứ n vào biểu diễn của ảnh i . Trọng số này không phải là một tham số được học trực tiếp mà được tính riêng cho từng ảnh bằng Softmax trên các điểm số sinh từ đơn vị biểu diễn cục bộ $\tilde{\ell}_{i,n}$ và đặc trưng toàn cục $\mathbf{g}_i$ thông qua một hàm chấm điểm có tham số học được. Do đó, $\alpha_{i,n} \geq 0$ và $\sum_{n \in \mathcal{P}_i} \alpha_{i,n} = 1$. Giá trị càng lớn thì đơn vị biểu diễn tương ứng đóng góp càng nhiều. Vectơ $\mathbf{v}_i^{\text{local}}$ tóm tắt thông tin cục bộ, còn $\bar{\mathbf{v}}_i$ giữ đặc trưng toàn cục làm thành phần chính và bổ sung 0,25 lần bản tóm tắt này.

Độ tương đồng giữa ảnh i và văn bản j được tính trong không gian đã chuẩn hóa:

$$s_{ij} = \frac{\bar{\mathbf{v}}_i^{\text{T}} \mathbf{t}_j}{\tau_{\text{SM}}}. \quad (3.26)$$

Trong đó, τ_{SM} là nhiệt độ tương ứng với hệ số tỷ lệ logit được kế thừa từ BiomedCLIP. Với một lô gồm B ảnh và B văn bản, đặt $\tilde{\mathbf{Q}} = [\tilde{q}_{ij}]$ là ma trận đích mềm chưa chuẩn hóa. Phần tử $\tilde{q}_{ij}$ nhận giá trị 1 đối với cặp ảnh–văn bản của cùng một mẫu, nhận giá trị ρ đối với hai mẫu khác nhau nhưng cùng lớp, và nhận giá trị 0 đối với hai mẫu khác lớp. Cấu hình chính sử dụng $\rho = 0,50$. Các phân phối đích theo hai hướng được chuẩn hóa từ ma trận này:

$$q_{ij}^{I \rightarrow T} = \frac{\tilde{q}_{ij}}{\sum_{n=1}^B \tilde{q}_{in}}, \quad q_{ij}^{T \rightarrow I} = \frac{\tilde{q}_{ji}}{\sum_{n=1}^B \tilde{q}_{ni}}. \quad (3.27)$$

Trong đó, $q_{ij}^{I \rightarrow T}$ là xác suất đích của văn bản j khi ảnh i làm truy vấn, còn $q_{ij}^{T \rightarrow I}$ là xác suất đích của ảnh j khi văn bản i làm truy vấn.

Đặt $\mathbf{S} = [s_{ij}]$, còn $p_{ij}^{I \rightarrow T}$ và $p_{ij}^{T \rightarrow I}$ lần lượt là các phần tử của hai phân phối dự đoán. Hàm mất mát khớp ngữ nghĩa được viết gọn như sau:

$$\begin{aligned} \mathbf{P}^{I \rightarrow T} &= \text{softmax}_{\text{row}}(\mathbf{S}), & \mathbf{P}^{T \rightarrow I} &= \text{softmax}_{\text{row}}(\mathbf{S}^T), \\ \mathcal{L}_{\text{SM}} &= -\frac{1}{2B} \sum_{i=1}^B \sum_{j=1}^B [q_{ij}^{I \rightarrow T} \log p_{ij}^{I \rightarrow T} + q_{ij}^{T \rightarrow I} \log p_{ij}^{T \rightarrow I}]. \end{aligned} \quad (3.28)$$


Dạng mất mát trong Công thức 3.28 kế thừa nguyên lý khớp ngữ nghĩa hai chiều của các mô hình ảnh-văn bản y khoa [34]. So với nhãn khớp cứng, phân phối đích mềm tránh xem mọi cặp khác mẫu là âm hoàn toàn khi chúng cùng mô tả một lớp bệnh. Việc lấy mẫu theo lớp làm tăng khả năng một lô có nhiều cặp cùng lớp để cung cấp tín hiệu ngữ nghĩa cho mục tiêu này.

Sau giai đoạn này, hai bộ mã hóa đã được điều chỉnh để tạo ra không gian ảnh-văn bản phù hợp hơn với dữ liệu X-quang xương. Tuy nhiên, các đặc trưng của cặp ảnh-văn bản mới chỉ được căn chỉnh gần nhau hơn ở mức biểu diễn trong không gian nhúng và chưa được tối ưu trực tiếp cho quyết định phân lớp đa lớp. Vì vậy, giai đoạn thứ hai tiếp tục sử dụng các bộ mã hóa đã thích nghi, đồng thời đưa mô-đun dung hợp và tâm cụm thực nghiệm vào quá trình huấn luyện có giám sát.

3.7.2 Giai đoạn 2: học dung hợp và phân lớp

Hình 3.6 minh họa quy trình học dung hợp và phân lớp bằng tâm cụm thực nghiệm trong giai đoạn này.

Trong giai đoạn thứ hai, hai nhánh mã hóa tạo chuỗi đặc trưng toàn cục và cục bộ. Các chuỗi này được đưa qua mô-đun chú ý chéo để tạo



Hình 3.6: Giai đoạn học dung hợp và phân lớp bằng tâm cụm thực nghiệm

vectơ tổng hợp z_i . tâm lớp thực nghiệm sử dụng các vectơ của tập huấn luyện để ước lượng tâm lớp và tính xác suất dự đoán. Trọng số nền của BiomedCLIP tiếp tục được giữ cố định, trong khi LoRA, thành phần biểu diễn ảnh cục bộ và mô-đun dung hợp tiếp tục được cập nhật, với mục tiêu giúp biểu diễn đa phương thức có tính phân biệt giữa các lớp.

Do số mẫu của các lớp có thể chênh lệch lớn, hàm mất mát sử dụng trọng số lớp dựa trên số lượng mẫu hiệu dụng [4]. Với n_k là số mẫu của lớp k , trọng số sau khi chuẩn hóa và giới hạn trên được tính trực tiếp bởi:

$$w_k = \min \left(w_{\max}, \frac{K (1 - \beta^{n_k})^{-1}}{\sum_{j=1}^K (1 - \beta^{n_j})^{-1}} \right). \quad (3.29)$$

Trong đó, β điều khiển mức hiệu chỉnh theo tần suất lớp và $w_{\max}$ giới hạn trọng số lớn nhất. Cấu hình chính sử dụng $\beta = 0,999$ và $w_{\max} = 5,0$. Nhân được làm tròn với hệ số $\varepsilon = 0,05$. Ký hiệu $\tilde{y}_{ik}$ biểu thị xác suất mục tiêu của lớp k đối với mẫu i .

Với Z_B là hệ số chuẩn hóa, mục tiêu pha 2 là hàm mất mát entropy

chéo có trọng số theo lớp, kết hợp làm trơn nhãn:

$$\mathcal{L}_{\text{WCE}} = -\frac{1}{Z_{\mathcal{B}}} \sum_{i=1}^B \sum_{k=1}^K w_k \tilde{y}_{ik} \log p_{ik}. \quad (3.30)$$

Trong Công thức 3.30, các lớp hiếm nhận trọng số lớn hơn, còn làm trơn nhãn hạn chế việc phân phối dự đoán tập trung tuyệt đối vào một lớp.


Các tâm lớp được khởi tạo từ toàn bộ tập huấn luyện trước lần lặp đầu tiên. Trong mỗi lần lặp, chúng được giữ cố định như bộ nhớ đệm và không nhận gradient. Ngay sau lần lặp, mô hình chuyển sang chế độ đánh giá, tính lại đặc trưng của tập huấn luyện bằng trạng thái tham số mới nhất, cập nhật các tâm theo Công thức 3.21, rồi mới đánh giá trên tập kiểm định. Trạng thái tốt nhất được lựa chọn theo độ đo đã định trước. Cuối cùng, các tâm được tính lại từ tập huấn luyện bằng trạng thái này. Tập kiểm thử không tham gia cập nhật tham số, ước lượng tâm hoặc lựa chọn mô hình.

Kết quả của quá trình ngoại tuyến là tập tham số LoRA, mô-đun dung hợp, trạng thái bộ mã hóa và các tâm lớp đã được xác định từ dữ liệu huấn luyện. Các thành phần này được cố định và chuyển sang quy trình trực tuyến để xử lý từng ca mới mà không thực hiện thêm bất kỳ bước cập nhật nào.

3.8 Suy luận trong quá trình trực tuyến

Hình 3.7 minh họa quy trình suy luận trực tuyến và phát hiện mẫu ngoài phân phối.

Khi tiếp nhận một ca mới, ảnh X-quang và thông tin lâm sàng được xử lý bằng đúng các phép biến đổi đã sử dụng trong huấn luyện. Hai bộ mã hóa tạo đặc trưng ảnh và văn bản, mô-đun chú ý chéo tạo vectơ tổng hợp, sau đó bộ phân lớp tính xác suất cho từng lớp. Toàn bộ tham số LoRA, mô-đun dung hợp và các nguyên mẫu lớp đều được cố định. Bước phân



Hình 3.7: Quy trình suy luận trực tuyến và phát hiện mẫu ngoài phân phối

lớp và tính điểm ngoài phân phối không tính đạo hàm, đồng thời không cập nhật tâm lớp từ mẫu mới. Kết quả phân loại cho biết lớp nào phù hợp nhất trong số các lớp đã biết, nhưng chưa cho biết mẫu có thực sự thuộc phân bố huấn luyện hay không.

Để phát hiện mẫu ngoài phân phối (OOD), việc chỉ dựa vào không gian biểu diễn sau khi dung hợp ($\mathbf{z}_{\text{fused}}$) có thể gặp hạn chế do mô-đun chú ý chéo có xu hướng ép các đặc trưng dị biệt vào cấu trúc không gian lớp nội tại để tối ưu phân loại, làm suy giảm độ nhạy phát hiện bất thường ở từng phương thức riêng lẻ. Vì vậy, hệ thống xây dựng cơ chế **Multi-Modal Modality-Decoupled Ensemble OOD Detection** bằng cách tách rời hai phương thức, áp dụng phương pháp khoảng cách k -láng giềng gần nhất (k NN) trên từng không gian biểu diễn đơn phương thức, chuẩn hóa Z -score trên tập xác thực ID và hợp nhất bằng toán tử max:

1. **Khoảng cách k NN đơn phương thức tách rời:** Gọi $\mathcal{D}_{\text{ID}}^{\text{train}}$ là tập biểu diễn tham chiếu trong phân phối đã được chuẩn hóa L_2 . Với mỗi mẫu kiểm thử có biểu diễn ảnh $\mathbf{z}_{\text{img}}$ và biểu diễn văn bản $\mathbf{z}_{\text{txt}}$, điểm bất thường đơn phương thức được tính bằng khoảng cách Euclid tới

láng giềng thứ k gần nhất [30]:

$$s_{\text{vis}}(\mathbf{z}_{\text{img}}) = d_{k\text{NN}}(\mathbf{z}_{\text{img}}, \mathcal{D}_{\text{ID}, \text{img}}^{\text{train}}), \quad (3.31)$$

$$s_{\text{txt}}(\mathbf{z}_{\text{txt}}) = d_{k\text{NN}}(\mathbf{z}_{\text{txt}}, \mathcal{D}_{\text{ID}, \text{txt}}^{\text{train}}). \quad (3.32)$$

2. **Chuẩn hóa Z-score trên tập ID Validation:** Do thang đo khoảng cách trên không gian ảnh và không gian văn bản có thể khác biệt, hệ thống ước lượng giá trị kỳ vọng và độ lệch chuẩn của từng phương thức trên tập xác thực $\mathcal{D}_{\text{ID}}^{\text{val}}$ ($\mu_{\text{vis}}^{\text{val}}, \sigma_{\text{vis}}^{\text{val}}$ và $\mu_{\text{txt}}^{\text{val}}, \sigma_{\text{txt}}^{\text{val}}$) để đưa các điểm số về phân phối chuẩn hóa không thứ nguyên:

$$\tilde{s}_{\text{vis}} = \frac{s_{\text{vis}}(\mathbf{z}_{\text{img}}) - \mu_{\text{vis}}^{\text{val}}}{\sigma_{\text{vis}}^{\text{val}} + \epsilon}, \quad \tilde{s}_{\text{txt}} = \frac{s_{\text{txt}}(\mathbf{z}_{\text{txt}}) - \mu_{\text{txt}}^{\text{val}}}{\sigma_{\text{txt}}^{\text{val}} + \epsilon}. \quad (3.33)$$

3. **Hợp nhất bằng toán tử max (Max-pooling Fusion):** Điểm ngoài phân phối tổng hợp được xác định theo nguyên lý phòng vệ nghiêm ngặt (worst-case anomaly):

$$s_{\text{OOD}}(\mathbf{x}) = \max(\tilde{s}_{\text{vis}}, \tilde{s}_{\text{txt}}). \quad (3.34)$$

Theo cơ chế này, chỉ cần một trong hai phương thức (ảnh hoặc văn bản lâm sàng) có mức độ bất thường vượt trội so với phân phối huấn luyện, toàn bộ ca bệnh sẽ lập tức được nhận diện và cảnh báo là dữ liệu ngoài phân phối.

Ngưỡng cảnh báo τ_{alert} được hiệu chỉnh trên tập xác thực $\mathcal{D}_{\text{ID}}^{\text{val}}$ ở mức tỷ lệ cảnh báo giả mục tiêu $\alpha = 0,05$:

$$\tau_{\text{alert}} = Q_{1-\alpha}^+(\{s_{\text{OOD}}(\mathbf{x}_i) \mid \mathbf{x}_i \in \mathcal{D}_{\text{ID}}^{\text{val}}\}), \quad \alpha = 0,05, \quad (3.35)$$

trong đó Q_q^+ là phân vị thực nghiệm phía trên ở mức q , nhằm bảo đảm giữ lại ít nhất 95% mẫu trong phân phối. Quy tắc đưa ra cảnh báo OOD độc

lập với kết quả phân lớp:

$$\begin{aligned}\hat{y} &= \arg \max_{k \in \mathcal{Y}} p(y = k \mid \mathbf{x}), \\ \omega_{\text{OOD}} &= \begin{cases} 1, & \text{nếu } s_{\text{OOD}}(\mathbf{x}) > \tau_{\text{alert}}, \\ 0, & \text{ngược lại.} \end{cases}\end{aligned}\quad (3.36)$$

Mô-đun phát hiện ngoài phân phối không thay đổi dự đoán nội tại của XBone-Net mà cung cấp thêm tín hiệu cảnh báo ω_{OOD} khi mẫu đầu vào có dấu hiệu bất thường về thị giác hoặc bất thường về nội dung văn bản lâm sàng.

Bên cạnh hai thành phần dự đoán trên, đối với mẫu không bị cảnh báo ngoài phân phối, quá trình suy luận còn có thể cung cấp thông tin hỗ trợ giải thích bằng phương pháp tích phân gradient [31]. Thành phần này được thực hiện như một lượt tính riêng khi cần giải thích. Các tham số mô hình vẫn được cố định, còn đạo hàm chỉ được tính đối với đầu vào hoặc biểu diễn cần khảo sát và không được dùng để cập nhật mô hình.

Với mỗi mẫu, lớp đích được chọn là lớp do mô hình dự đoán $\hat{y}$, kể cả khi dự đoán này khác nhãn tham chiếu. Gọi $F_{\hat{y}}(\mathbf{u})$ là giá trị logit của lớp đích tại đầu vào hoặc biểu diễn $\mathbf{u}$, và $\mathbf{u}^0$ là mốc tham chiếu tương ứng. Quy đóng của thành phần thứ j được xác định bởi:

$$\text{IG}_j(\mathbf{u}) = (u_j - u_j^0) \int_0^1 \frac{\partial F_{\hat{y}}(\mathbf{u}^0 + \beta(\mathbf{u} - \mathbf{u}^0))}{\partial u_j} d\beta, \quad (3.37)$$

trong đó $\beta \in [0, 1]$ xác định một điểm trên đường thẳng từ mốc tham chiếu đến đầu vào. Trong phần đánh giá thực nghiệm, tích phân được xấp xỉ bằng quy tắc hình thang tại 24 điểm cách đều. Đối với ảnh toàn cục, mốc tham chiếu là tenxơ bằng không trong không gian đầu vào đã chuẩn hóa. Đối với các đơn vị ảnh cục bộ, mốc tham chiếu là biểu diễn ảnh toàn cục được lặp lại theo số đơn vị. Đối với bệnh sử, các từ nội dung được nội suy từ biểu diễn của ký hiệu đậm, trong khi các ký hiệu đặc biệt được giữ nguyên.

Để thu được mức liên quan của từng điểm ảnh, đơn vị ảnh cục bộ hoặc từ, các quy đóng theo chiều biểu diễn được cộng lại và chỉ giữ phần dương.

Nếu tổng phần dương gần bằng không, tổng trị tuyệt đối được sử dụng làm phương án dự phòng. Bản đồ và điểm liên quan thu được phản ánh mức đóng góp của từng thành phần đối với logit của lớp dự đoán trong lân cận đường nội suy, do đó được sử dụng như thông tin hỗ trợ diễn giải thay vì một kết luận nhân quả.

Chương 4

Thực nghiệm và kết quả

Chương này trình bày thiết kế thực nghiệm và kết quả theo bốn câu hỏi nghiên cứu đã nêu ở Chương 1. Câu hỏi thứ nhất xem xét hiệu năng phân lớp và đánh đổi chi phí. Câu hỏi thứ hai đánh giá ảnh hưởng của các thành phần được lựa chọn. Câu hỏi thứ ba xác định khả năng và giới hạn của cảnh báo dữ liệu ngoài phân phối hậu xử lý. Câu hỏi thứ tư khảo sát mức phụ thuộc của dự đoán vào ảnh và văn bản qua tích phân gradient kết hợp can thiệp đầu vào. Các cấu hình có huấn luyện được đánh giá trên ba hạt giống 42, 123 và 456, sau đó giá trị tổng hợp được báo cáo dưới dạng trung bình $\pm$ độ lệch chuẩn. Riêng phân tích tích phân gradient sử dụng hạt giống 42 trên 44 mẫu chuẩn hóa. Kết quả theo từng hạt giống và các phân tích bổ sung được trình bày tại Phụ lục C.

4.1 Thiết kế thực nghiệm

4.1.1 Chuẩn bị dữ liệu

Nghiên cứu sử dụng bộ dữ liệu BTXRD [36] được công bố và bộ dữ liệu CTCH được thu thập tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh do giảng viên cung cấp. Các phần dưới đây mô tả nguồn gốc, cách thức thu thập và những số liệu thống kê liên quan đến từng bộ dữ liệu. Ngoài ra, cấu trúc thư mục và các bước tiền xử lý sẽ được mô tả ở Phụ lục A.

Bộ dữ liệu BTXRD


BTXRD là bộ dữ liệu ảnh X-quang được xây dựng cho các bài toán phân lớp, định vị và phân vùng u xương nguyên phát. Phiên bản được sử dụng trong nghiên cứu gồm 3.746 ảnh, siêu dữ liệu về tuổi, giới tính, vị trí giải phẫu và tư thế chụp, cùng các chỉ báo về sự hiện diện, tính lành tính hoặc ác tính và phân nhóm tổn thương. Đối với 1.867 ảnh có u, bộ dữ liệu còn cung cấp tệp chú thích chứa thông tin vùng tổn thương.

Theo mô tả của bộ dữ liệu công bố, dữ liệu được tổng hợp từ ba bệnh viện tại Trung Quốc, Radiopaedia và MedPix. Dữ liệu bệnh viện được thu thập trong giai đoạn từ tháng 7 năm 2013 đến tháng 7 năm 2023, các chẩn đoán được xác nhận bằng mô bệnh học hoặc được hai bác sĩ X-quang thống nhất. Đối với hai nguồn trực tuyến, các ảnh liên quan đến u xương được hai chuyên gia tuyển chọn, đồng thời yêu cầu có thông tin tuổi và giới tính. Những vùng giải phẫu có ít mẫu hoặc nhiều nhiễu như đầu, cổ, ngực và bụng được loại bỏ, do đó phạm vi còn lại tập trung vào chi trên, chi dưới và xương chậu.

Quy trình chú thích được thực hiện bằng Labelme [26]: một bác sĩ chuyên khoa u xương có 10 năm kinh nghiệm xác định vùng tổn thương, sau đó kết quả được một chuyên gia có 20 năm kinh nghiệm kiểm tra.

Đặc điểm dữ liệu và bài toán phân lớp Trong 3.746 mẫu, có 1.879 ảnh bình thường, 1.525 ảnh thuộc nhóm u lành tính và 342 ảnh thuộc nhóm u ác tính. Tuổi dao động từ 1 đến 88, gồm 2.098 mẫu nam và 1.648 mẫu nữ như được thể hiện trong Hình 4.1.

Nhân được thiết lập dưới dạng phân lớp đơn nhãn với 10 lớp. Nhân bình thường được suy ra khi cờ chỉ báo u bằng 0, chín lớp còn lại được lấy từ các chỉ báo bệnh lý trong siêu dữ liệu. Bảng 4.1 trình bày số lượng mẫu theo tập chia, trong khi Bảng 4.2 trình bày phân bố lớp ở các tập chia.



Hình 4.1: Phân bố độ tuổi và giới tính của các bệnh nhân được quan sát trong bộ dữ liệu BTXRD

Tập chia	Số lượng hình ảnh	Tỷ lệ (%)
Huấn luyện	2.621	70
Xác thực	375	10
Kiểm thử	750	20
Tổng cộng	3.746	100,00

Bảng 4.1: Phân bố mẫu theo các tập chia trong BTXRD

Nhân bệnh lý	Huấn luyện	Xác thực	Kiểm thử	Tổng	Tỷ lệ
Bình thường	1.322	191	366	1.879	50,16%
U xương sụn	538	70	145	753	20,10%
Sarcoma xương	200	32	65	297	7,93%
Đa u xương sụn	189	29	45	263	7,02%
Nang xương đơn thuần	149	17	40	206	5,50%
U lành tính khác	83	8	24	115	3,07%
U tế bào khổng lồ	54	8	31	93	2,48%
U sụn màng hoạt dịch	35	7	9	51	1,36%
U ác tính khác	27	5	13	45	1,20%
U xơ xương	24	8	12	44	1,17%
Tổng	2.621	375	750	3.746	100,00%

Bảng 4.2: Phân bố các lớp đơn nhân sau chuẩn hóa trong bộ dữ liệu BTXRD

Bộ dữ liệu được chia ngẫu nhiên ở mức ảnh với hạt giống 42 và tỷ lệ 70/10/20 cho các tập huấn luyện, xác thực và kiểm thử. Tập siêu dữ liệu không cung cấp mã người bệnh ổn định để nhóm các ảnh của cùng một ca trước khi chia. Vì vậy, kết quả BTXRD chỉ được diễn giải trong phạm vi phép chia ở mức ảnh.

Bộ dữ liệu BTXRD không cung cấp bệnh sử lâm sàng tương ứng với từng bệnh nhân. Do đó, để bổ sung nguồn văn bản đi kèm, nghiên cứu sử dụng quy trình sinh văn bản lâm sàng bằng siêu dữ liệu có sẵn được mô tả ở Phụ lục A.1 và kết quả được minh họa như Bảng 4.3.

Ảnh	Nhãn	Văn bản giả lâm sàng được sinh
	<i>other mt</i>	Patient: 48-year-old female. Reason for admission: Pain and swelling of the hip bone. Disease history: Pain in the hip bone for 1 month; associated with decreased appetite. Physical examination: Palpable mass; tenderness on palpation; mild swelling. Personal medical history: No prior bone disease or fracture. No relevant surgical or medical history. Radiographic evaluation: AP view of the hip bone was obtained.
	<i>multiple osteo-chondromas</i>	Patient: 64-year-old male. Reason for admission: Progressive pain in the humerus. Disease history: The patient reports worsening pain in the humerus for 1 month. Physical examination: Palpable mass with local tenderness; no lymphadenopathy detected. Personal medical history: No prior bone disease or fracture. History of age-related degenerative changes; no prior bone lesions. Radiographic evaluation: AP view of the humerus was obtained.

Bảng 4.3: Ví dụ ảnh, nhãn và văn bản giả lâm sàng được sinh của bộ dữ liệu BTXRD

Trong thiết kế thực nghiệm, BTXRD được sử dụng để khảo sát khả năng chuyển giao sang bài toán u xương, ảnh hưởng của mất cân bằng lớp và hành vi của mô hình trong thiết lập văn bản tổng hợp. Do văn bản lâm sàng được sinh từ siêu dữ liệu và chịu ảnh hưởng của các cờ nhóm bệnh, kết quả trên bộ dữ liệu này không được diễn giải tương đương với kết quả thu được từ bệnh sử lâm sàng thực tế.

Bộ dữ liệu CTCH

CTCH là bộ dữ liệu X-quang xương được thu thập tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh và được giảng viên Võ Thế Hào cùng giảng viên Đỗ Phúc Thịnh cung cấp cho nghiên cứu. Dữ liệu nguồn gồm ảnh được lựa chọn từ từng ca khám và các trường bệnh án tiếng Việt liên quan đến lý do vào viện, diễn tiến bệnh, tiền sử, kết quả khảo sát hình ảnh và chẩn đoán chuyên môn. Văn bản đầu vào chỉ sử dụng lý do vào viện, diễn tiến bệnh và tiền sử. Kết quả khảo sát hình ảnh, chẩn đoán chuyên môn và nhãn không được đưa vào chuỗi văn bản. Phạm vi thực nghiệm chỉ sử dụng ảnh X-quang đại diện cho vị trí bệnh lý. Ảnh từ phương thức tạo ảnh khác hoặc không đại diện cho vị trí bệnh lý không được đưa vào tập phân lớp. Quy trình lựa chọn trường và kiểm soát rò rỉ nhãn được trình bày tại Phụ lục A.2.

Đạo đức nghiên cứu, quyền riêng tư và tính sẵn có của dữ liệu
Bộ dữ liệu được sử dụng theo thỏa thuận bảo mật đã ký kết và chỉ phục vụ mục đích nghiên cứu. Trước khi xử lý, các thông tin có khả năng định danh trực tiếp người bệnh đã được loại bỏ và các mã hồ sơ chỉ được dùng để liên kết dữ liệu, kiểm soát việc phân chia tập và không được công bố trong kết quả nghiên cứu.

Do chứa thông tin y tế nhạy cảm, bộ dữ liệu gốc không được công khai và khóa luận chỉ trình bày số liệu thống kê cùng kết quả tổng hợp. Mọi hoạt động kiểm định hoặc triển khai trong môi trường lâm sàng về sau cần tuân thủ quy định bảo vệ dữ liệu và được cơ quan có thẩm quyền phê duyệt.

Đặc điểm dữ liệu và bài toán phân lớp Việc chia dữ liệu được thực hiện theo người bệnh với hạt giống ngẫu nhiên 42 và tỷ lệ mục tiêu 70/10/20. Người bệnh được nhóm theo lớp chính trước khi phân bổ để duy trì sự hiện diện của các lớp ít mẫu ở cả ba tập khi số lượng cho phép. Kết quả như được thể hiện ở Bảng 4.4 gồm 2.265 mẫu huấn luyện, 315 mẫu xác thực và 669 mẫu kiểm thử và Bảng 4.5 thể hiện chi tiết số lượng mẫu trong từng lớp trong các tập chia.

Tập dữ liệu	Số lượng ảnh	Tỷ lệ
Huấn luyện	2.265	69,71%
Xác thực	315	9,70%
Kiểm thử	669	20,59%
Tổng cộng	3.249	100,00%

Bảng 4.4: Phân bố mẫu trong phân phối của CTCH theo tập dữ liệu

Lớp	Huấn luyện	Xác thực	Kiểm thử	Tổng	Tỷ lệ
Bình thường	760	108	218	1.086	33,43%
Gãy xương quay	209	29	61	299	9,20%
Gãy xương cánh tay	147	21	42	210	6,46%
Gãy xương đùi	106	15	31	152	4,68%
Gãy xương ngón tay	102	14	31	147	4,52%
Gãy xương chày	99	14	29	142	4,37%
Gãy xương cẳng tay	99	14	29	142	4,37%
Gãy xương cổ chân	87	12	26	125	3,85%
Gãy xương cẳng chân	85	12	25	122	3,76%
Gãy xương vùng vai	70	10	21	101	3,11%
Gãy xương bàn chân	68	9	21	98	3,02%
Gãy cột sống thắt lưng	53	7	16	76	2,34%
Gãy xương bàn tay	53	7	16	76	2,34%
Gãy xương ngón chân	52	7	16	75	2,31%
Viêm khớp	47	6	15	68	2,09%
Gãy xương trụ	46	6	14	66	2,03%
Cắt cụt ngón tay	42	6	13	61	1,88%
Gãy xương bánh chè	41	5	13	59	1,82%
Gãy xương gót	36	5	11	52	1,60%
Gãy cột sống ngực	28	4	8	40	1,23%
Gãy xương thuyền	19	2	7	28	0,86%
Gãy xương vùng chậu	16	2	6	24	0,74%
Tổng cộng	2.265	315	669	3.249	100,00%

Bảng 4.5: Phân bố 22 lớp của CTCH trong ba tập dữ liệu

Mỗi hồ sơ được liên kết với một ảnh X-quang duy nhất. Trong quần thể phân lớp hiện tại, 3.249 ảnh tương ứng với 3.249 mã bệnh nhân và quần thể ngoài phân phối gồm 26 ảnh từ 26 mã khác, không giao với quần thể phân lớp. Bảng 4.6 minh họa một số mẫu sau tiền xử lý. Quy trình sàng lọc, lựa chọn trường văn bản và kiểm tra toàn vẹn được mô tả tại Phụ lục A.2.

Các mẫu ngoài phân phối không được đưa vào huấn luyện, xác thực hoặc kiểm thử bộ phân lớp 22 lớp. Nhóm này gồm các bệnh lý ngoại vi

nằm ngoài không gian nhãn đích và chỉ được sử dụng trong kịch bản đánh giá dữ liệu ngoài phân phối được trình bày ở phần thực nghiệm.

Ảnh	Nhãn	Bệnh sử lâm sàng
	<i>Lower leg fracture</i>	Reason for admission: Right lower leg pain. Disease history: The patient fell from the roof at 3:00 p.m. on October 17, 2024 in Tien Giang; no first aid. to the Orthopedic Trauma Hospital. Personal medical history: Nasopharynx is being treated
	<i>Finger phalanx fracture</i>	Reason for admission: Right hand wound. Disease history: The patient had his right hand cut by a saw at 2:00 p.m. on October 17, 2024 in Dong Nai; Go to the local medical station for first aid. to the Orthopedic Trauma Hospital. Personal medical history: Right hand third metatarsal fusion surgery 9 years ago

Bảng 4.6: Các ví dụ ảnh, nhãn và bệnh sử lâm sàng của bộ dữ liệu CTCH

CTCH là nguồn bằng chứng chính của khóa luận vì mỗi ảnh được liên kết với bệnh sử lâm sàng có sẵn và phép chia được thực hiện theo người bệnh. Bộ dữ liệu này đồng thời cung cấp quần thể ngoài không gian nhãn để khảo sát cảnh báo dữ liệu ngoài phân phối. Phân tích nguồn thông tin sử dụng một tập con chuẩn hóa gồm 44 mẫu kiểm thử tại hạt giống 42.

4.1.2 Nội dung thực nghiệm

Các thực nghiệm được tổ chức theo bốn câu hỏi nghiên cứu ở Chương 1. Bảng 4.7 ánh xạ từng câu hỏi với thiết lập đánh giá và các độ đo tương ứng. Macro-F1 được chọn làm độ đo phân lớp chính vì hai bộ dữ liệu có phân bố lớp mất cân bằng. Accuracy và Balanced Accuracy bổ sung góc nhìn về quyết định lớp, trong khi Macro-AUROC và Macro-AUPRC đánh giá chất lượng xếp hạng xác suất. Các thực nghiệm về chi phí, OOD và IG sử dụng các độ đo chuyên biệt được mô tả tại Mục 4.1.3.

Thực nghiệm phân loại và chi phí Nhóm đối chứng gồm ResNet-50 và DenseNet-121 chỉ nhận ảnh X-quang, cùng với CLIP, MedCLIP,

Câu hỏi nghiên cứu	Thực nghiệm chính	Độ đo chính
RQ1: Hiệu năng và chi phí	So sánh với hai CNN chỉ ảnh và bốn mô hình ảnh–văn bản tinh chỉnh toàn bộ, sau đó đo tham số và chi phí suy luận.	Acc, BAcc, Macro-F1, Macro-AUROC, Macro-AUPRC, tham số và chi phí suy luận.
RQ2: Ảnh hưởng thành phần	Đối sánh cấu hình đầy đủ với biến thể Chỉ pha 2 và biến thể Nói đặc trưng trong cùng điều kiện huấn luyện.	Acc, BAcc, Macro-F1, Macro-AUROC và Macro-AUPRC.
RQ3: Cảnh báo OOD hậu xử lý	Hiệu chỉnh trên validation ID, sau đó đánh giá 669 mẫu test ID với 26 mẫu OOD CTCH và 750 mẫu BTXRD.	AUROC-OOD, AUPR-Out và FPR@95%TPR.
RQ4: IG và can thiệp	Tính IG, loại bỏ, khôi phục và che toàn bộ từng nguồn trên 44 mẫu phân tầng ở hạt giống 42, đồng thời dùng đối chứng ngẫu nhiên.	AUC loại bỏ, AUC khôi phục, chênh lệch so với ngẫu nhiên và mức giảm xác suất.

Bảng 4.7: Ánh xạ câu hỏi nghiên cứu với thực nghiệm và độ đo chính

PubMedCLIP và BioMedCLIP nhận cặp ảnh–văn bản. Hai mô hình CNN được khởi tạo từ trọng số ImageNet, còn bốn mô hình ảnh–văn bản sử dụng trọng số tiền huấn luyện tương ứng. Tất cả sáu mô hình được tinh chỉnh toàn bộ trong pha phân loại. Việc so sánh được thực hiện trên cùng tập chia của CTCH và BTXRD với các hạt giống 42, 123 và 456. Sáu mô hình dùng chung số vòng lặp tối đa, quy tắc dừng sớm trên cả hai bộ dữ liệu. Kết quả phân loại được tổng hợp qua ba hạt giống. Phép đo tham số và chi phí suy luận chỉ đối sánh XBone-Net với BioMedCLIP tinh chỉnh toàn bộ trong cùng môi trường phần cứng, cùng kích thước lô và cùng dữ liệu đầu vào.

Thực nghiệm thành phần Thực nghiệm được thực hiện trên CTCH với ba cấu hình gồm XBone-Net, Chỉ pha 2 và Nói đặc trưng. Biến thể Chỉ pha 2 bỏ lần huấn luyện pha 1 và khởi tạo trực tiếp cho pha phân loại. Biến thể Nói đặc trưng giữ nguyên pha 1 nhưng thay thiết lập dung hợp ở pha 2 bằng phép nối. Ngoài yếu tố được thay đổi, các cấu hình dùng chung được giữ nguyên. Cách thiết lập này tạo hai đối chứng riêng cho quy trình huấn luyện và cấu hình dung hợp.

Thực nghiệm ngoài phân phối Dữ liệu huấn luyện CTCH được dùng để khớp bộ chấm điểm hậu xử lý, còn dữ liệu xác thực CTCH được dùng để chuẩn hóa điểm và chọn ngưỡng tại phân vị 95, tương ứng mục tiêu cảnh báo nhằm 5% mẫu ID trên tập xác thực. Ngưỡng được xác định riêng cho từng cấu hình và từng hạt giống mà không sử dụng mẫu ngoài phân phối. Tập đánh giá gồm 669 mẫu kiểm tra của CTCH ghép lần lượt với hai tập ngoài phân phối. Kịch bản thứ nhất sử dụng đủ 26 mẫu CTCH ngoài không gian nhãn để khảo sát dịch chuyển gần miền. Kịch bản thứ hai sử dụng 750 mẫu BTXRD để khảo sát dịch chuyển khác bộ dữ liệu. Cùng một ngưỡng đã hiệu chỉnh được giữ nguyên cho hai kịch bản. AUROC-OD, AUPR-Out và FPR@95%TPR được tính từ toàn bộ điểm của tập test ID và tập ngoài phân phối tương ứng, sau đó được tổng hợp qua ba hạt giống.

Thực nghiệm tích phân gradient và can thiệp đầu vào Phân tích sử dụng hạt giống 42 của mô hình XBone-Net, Chỉ pha 2 và Nối đặc trưng. Từ tập kiểm thử CTCH, 44 mẫu được chọn phân tầng với tối đa hai mẫu cho mỗi lớp và cùng hạt giống lấy mẫu 1907 cho mọi cấu hình. Lớp được mô hình dự đoán trên đầu vào đầy đủ được cố định làm lớp đích. Tích phân gradient được xấp xỉ bằng 24 điểm nội suy từ mốc tham chiếu đến đầu vào. Mốc tham chiếu của ảnh là ảnh đen không trong không gian đầu vào đã chuẩn hóa, còn mốc tham chiếu của văn bản là đặc trưng của token đệm và giữ nguyên các token đặc biệt.

Độ trung thực được đánh giá bằng cách loại bỏ hoặc khôi phục dần các vùng ảnh kích thước 16×16 và các token nội dung theo thứ tự quy đóng giảm dần. Mỗi đường cong sử dụng 11 mức can thiệp từ 0% đến 100%. Đường cong loại bỏ theo IG được đối chiếu với trung bình của 16 thứ tự ngẫu nhiên cố định. Phép can thiệp nguồn thay toàn bộ ảnh hoặc toàn bộ token nội dung bằng mốc tham chiếu tương ứng, sau đó ghi nhận mức giảm xác suất của lớp đích so với đầu vào đầy đủ. Cùng danh sách mẫu, mốc tham chiếu, mức can thiệp và quy tắc sinh thứ tự ngẫu nhiên được áp dụng cho cả ba cấu hình, trong khi lớp đích được xác định riêng từ dự đoán của từng cấu hình.

4.1.3 Độ đo đánh giá

Hai bộ dữ liệu BTXRD và CTCH được thiết lập dưới dạng bài toán phân lớp đa lớp, với BTXRD có 10 lớp và CTCH có 22 lớp. Các độ đo được chia theo bốn mục tiêu gồm phân lớp, phát hiện dữ liệu ngoài phân phối, đánh giá tích phân gradient và đánh giá hiệu quả tham số cùng chi phí suy luận.

Độ đo phân lớp

Gọi N là số mẫu, C là số lớp và TP_c , FP_c , FN_c lần lượt là số dương đúng, dương sai và âm sai khi xem lớp c là lớp dương. Ký hiệu $\mathcal{C}_v$ chỉ các lớp có cả mẫu dương và mẫu âm trong phép đánh giá một đối với tất cả.

Độ chính xác Độ chính xác là tỷ lệ mẫu được dự đoán đúng trên toàn bộ tập đánh giá:

$$\text{Accuracy} = \frac{\sum_{c=1}^C TP_c}{N}. \quad (4.1)$$

Độ đo này được dùng để mô tả hiệu năng tổng thể, nhưng có thể bị chi phối bởi các lớp có nhiều mẫu.

Độ chính xác cân bằng Độ chính xác cân bằng [2] là trung bình độ nhạy của các lớp:

$$\text{Balanced Accuracy} = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FN_c}. \quad (4.2)$$

Mỗi lớp đóng góp như nhau, vì vậy độ đo được dùng để hạn chế ảnh hưởng của mất cân bằng lớp.

Độ chính xác dự đoán theo lớp Độ chính xác dự đoán của lớp c là tỷ lệ dự đoán lớp c thực sự thuộc lớp đó:

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c}. \quad (4.3)$$

Độ đo được dùng khi cần xem xét mức dự đoán dương sai của từng lớp và là thành phần của đường cong độ chính xác-độ nhạy.

Độ nhạy theo lớp Độ nhạy của lớp c là tỷ lệ mẫu thuộc lớp c được nhận diện:

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c}. \quad (4.4)$$

Độ đo phản ánh mức bỏ sót của từng lớp và tạo trục còn lại của đường cong độ chính xác-độ nhạy.

Macro-F1 Điểm F1 trung bình theo lớp lấy trung bình điểm F1 của từng lớp:

$$\text{Macro-F1} = \frac{1}{C} \sum_{c=1}^C \frac{2TP_c}{2TP_c + FP_c + FN_c}. \quad (4.5)$$

Độ đo cân bằng giữa dự đoán dương đúng và mức bỏ sót ở từng lớp, đồng thời được dùng làm độ đo phân lớp chính của nghiên cứu.

Macro-AUROC Diện tích dưới đường cong đặc trưng hoạt động trung bình theo lớp [9] lấy trung bình diện tích dưới đường cong ROC của từng lớp theo chiến lược một đối với tất cả:

$$\text{Macro-AUROC} = \frac{1}{|\mathcal{C}_v|} \sum_{c \in \mathcal{C}_v} \text{AUROC}_c. \quad (4.6)$$

Trong đó, AUROC_c là xác suất một mẫu lớp c được xếp hạng cao hơn một mẫu không thuộc lớp c . Độ đo này đánh giá chất lượng xếp hạng của mô hình trên toàn bộ các ngưỡng, trong đó giá trị cao hơn biểu thị khả năng phân biệt tốt hơn.

Độ chính xác trung bình theo lớp Độ chính xác trung bình của lớp c tóm tắt đường cong độ chính xác-độ nhạy tại các ngưỡng xếp hạng:

$$\text{AUPRC}_c = \sum_{k=1}^{K_c} (R_{c,k} - R_{c,k-1}) P_{c,k}. \quad (4.7)$$

Trong đó, $P_{c,k}$ và $R_{c,k}$ là độ chính xác dự đoán và độ nhạy tại ngưỡng thứ k , còn K_c là số ngưỡng được xét. Độ đo được dùng để tổng hợp chất lượng xếp hạng của riêng lớp c .

Macro-AUPRC Điểm độ chính xác trung bình theo lớp [5] lấy trung bình Average Precision trên các lớp hợp lệ:

$$\text{Macro-AUPRC} = \frac{1}{|\mathcal{C}_v|} \sum_{c \in \mathcal{C}_v} \text{AUPRC}_c. \quad (4.8)$$

Độ đo được tính bằng tổng bậc thang của Average Precision, không phải phép tích phân hình thang tổng quát dưới đường cong độ chính xác-độ nhạy. Giá trị cao hơn thường biểu thị kết quả thuận lợi hơn khi các lớp mất cân bằng.

Độ đo phát hiện dữ liệu ngoài phân phối

Gọi $\mathcal{D}_{\text{ID}}$ và $\mathcal{D}_{\text{OOD}}$ lần lượt là tập trong và ngoài phân phối, $N_{\text{OOD}} = |\mathcal{D}_{\text{OOD}}|$, còn $s(x)$ là điểm bất thường với giá trị lớn hơn biểu thị khả năng ngoài phân phối cao hơn.

AUROC-OOD Diện tích dưới đường cong phân biệt dữ liệu ngoài phân phối [11] là xác suất điểm của một mẫu ngoài phân phối cao hơn điểm của một mẫu trong phân phối, với trường hợp bằng điểm được tính một nửa:

$$\text{AUROC}_{\text{OOD}} = \Pr(s(x_{\text{OOD}}) > s(x_{\text{ID}})) + \frac{1}{2} \Pr(s(x_{\text{OOD}}) = s(x_{\text{ID}})). \quad (4.9)$$

Độ đo được dùng để đánh giá khả năng xếp hạng hai phân phối trên mọi ngưỡng. Các giá trị cao hơn thường biểu thị mức phân biệt tốt hơn.

AUPR-Out Độ chính xác trung bình khi dữ liệu ngoài phân phối là lớp dương [11, 17] được tính bằng tổng bậc thang trên đường cong độ chính

xác-độ nhảy:

$$\text{AUPR-Out} = \sum_{k=1}^K (R_k^{\text{OOD}} - R_{k-1}^{\text{OOD}}) P_k^{\text{OOD}}. \quad (4.10)$$

Trong đó, P_k^{OOD} và R_k^{OOD} lần lượt là độ chính xác dự đoán và độ nhảy tại ngưỡng thứ k . Cách tính này tương ứng với Average Precision trong mã đánh giá. Độ đo bổ sung cho AUROC-OOD khi tỷ lệ mẫu ngoài phân phối thay đổi giữa các kịch bản, trong đó giá trị cao hơn thường thuận lợi hơn.

FPR@95%TPR Tỷ lệ chấp nhận nhầm tại điểm vận hành giữ lại 95% mẫu trong phân phối [17, 18] được xác định trên các điểm số của tập kiểm thử. Đặt τ_{95}^{test} là ngưỡng thấp nhất giữ lại ít nhất 95% mẫu trong phân phối của tập kiểm thử:

$$\begin{aligned} \text{FPR@95\%TPR} &= \frac{1}{N_{\text{OOD}}} \sum_{x \in \mathcal{D}_{\text{OOD}}} \mathbb{I}[s(x) \leq \tau_{95}^{\text{test}}], \\ \Pr_{x \sim \mathcal{D}_{\text{ID}}^{\text{test}}} [s(x) \leq \tau_{95}^{\text{test}}] &\geq 0,95. \end{aligned} \quad (4.11)$$

FPR@95%TPR là độ đo đánh giá, nên không sử dụng ngưỡng cảnh báo đã hiệu chỉnh trên tập xác thực. Ngưỡng cảnh báo triển khai được hiệu chỉnh riêng trên tập xác thực để giữ lại khoảng 95% mẫu trong phân phối và chỉ dùng cho quyết định cảnh báo. Giá trị FPR@95%TPR thấp hơn thường thuận lợi hơn.

Độ đo đánh giá tích phân gradient

Với mỗi mẫu, lớp đích t được chọn là lớp có xác suất dự đoán lớn nhất. Gọi $F_t(\mathbf{u})$ là logit của lớp này tại đầu vào hoặc dãy đơn vị biểu diễn $\mathbf{u}$, $\mathbf{u}'$ là mốc tham chiếu và L là số thành phần được quy đóng. Các đường loại bỏ và khôi phục dùng xác suất Softmax của cùng lớp dự đoán. Các độ đo dưới đây tập trung vào mức quy đóng và độ trung thực qua phép loại bỏ, khôi phục và đối chứng ngẫu nhiên.

Mức quy đóng bằng tích phân gradient Tích phân gradient [31] gán mức quy đóng cho thành phần j dọc theo đoạn thẳng từ mốc tham chiếu đến đầu vào:

$$\text{IG}_j(\mathbf{u}) = (u_j - u'_j) \int_0^1 \frac{\partial F_t(\mathbf{u}' + \alpha(\mathbf{u} - \mathbf{u}'))}{\partial u_j} d\alpha. \quad (4.12)$$

Trong đó, α là hệ số nội suy. Tích phân được xấp xỉ bằng quy tắc hình thang với 24 điểm. Thứ tự loại bỏ ưu tiên phần quy đóng dương đối với logit của lớp dự đoán. Chỉ khi toàn bộ phần quy đóng dương gần bằng 0, độ lớn tuyệt đối mới được dùng làm quy tắc dự phòng.

Diện tích dưới đường cong loại bỏ Gọi $p_t(\mathbf{u}^{\text{del}}(q))$ là xác suất lớp đích sau khi thay tỷ lệ q đơn vị có mức quy đóng cao nhất bằng mốc tham chiếu. Diện tích dưới đường cong loại bỏ được xác định bởi:

$$\text{AUC}_{\text{del}} = \int_0^1 p_t(\mathbf{u}^{\text{del}}(q)) dq. \quad (4.13)$$

Tích phân được xấp xỉ bằng quy tắc hình thang tại các tỷ lệ can thiệp được định trước. Độ đo được dùng để kiểm tra liệu các đơn vị được tích phân gradient xếp hạng cao có làm xác suất lớp đích giảm nhanh hay không. Giá trị thấp hơn thường cung cấp bằng chứng thuận lợi hơn về độ trung thực.

Diện tích dưới đường cong khôi phục Gọi $p_t(\mathbf{u}^{\text{ins}}(q))$ là xác suất lớp đích khi bắt đầu từ mốc tham chiếu và khôi phục tỷ lệ q đơn vị theo thứ tự quy đóng giảm dần. Diện tích dưới đường cong khôi phục được xác định bởi:

$$\text{AUC}_{\text{ins}} = \int_0^1 p_t(\mathbf{u}^{\text{ins}}(q)) dq. \quad (4.14)$$

Độ đo đánh giá khả năng các đơn vị được xếp hạng cao khôi phục xác suất lớp đích từ mốc tham chiếu. Giá trị cao hơn thường cho thấy xác suất được phục hồi sớm hơn.

Đối chứng thứ tự loại bỏ ngẫu nhiên Để kiểm tra liệu thứ tự do tích phân gradient tạo ra có mang thông tin hay không, nghiên cứu lặp lại phép loại bỏ với $R = 16$ thứ tự ngẫu nhiên cố định. Gọi $\text{AUC}_{\text{del},\text{random}}^{(r)}$ là AUC loại bỏ của lần ngẫu nhiên thứ r . AUC ngẫu nhiên và chênh lệch so với thứ tự tích phân gradient được xác định bởi:

$$\begin{aligned}\overline{\text{AUC}}_{\text{del},\text{random}} &= \frac{1}{R} \sum_{r=1}^R \text{AUC}_{\text{del},\text{random}}^{(r)}, \\ \Delta \text{AUC}_{\text{del}} &= \overline{\text{AUC}}_{\text{del},\text{random}} - \text{AUC}_{\text{del}}.\end{aligned}\tag{4.15}$$

Giá trị $\Delta \text{AUC}_{\text{del}} > 0$ cho thấy các thành phần được tích phân gradient xếp hạng cao làm xác suất lớp đích giảm nhanh hơn thứ tự ngẫu nhiên. Giá trị càng lớn cung cấp bằng chứng thuận lợi hơn cho độ trung thực của thứ tự quy đóng.

Mức giảm xác suất khi che nguồn thông tin Gọi $p_t(x)$ là xác suất lớp đích tại đầu vào đầy đủ và $p_t(x_{\setminus m})$ là xác suất sau khi nguồn m được thay bằng mốc tham chiếu. Mức giảm xác suất do che nguồn được tính bằng:

$$\Delta p_m = p_t(x) - p_t(x_{\setminus m}), \quad m \in \{\text{img}, \text{txt}\}.\tag{4.16}$$

Giá trị dương cho thấy xác suất lớp đích giảm khi loại bỏ nguồn tương ứng. Đại lượng này phản ánh mức phụ thuộc của đầu ra theo mốc tham chiếu đã chọn, nhưng không đo quan hệ nhân quả và không phải độ đo chất lượng giải thích độc lập.

Độ đo hiệu quả suy luận

Gọi Θ_{pre} là tập tham số của đồ thị huấn luyện trước khi hợp nhất LoRA và $\Theta_{\text{train}} \subseteq \Theta_{\text{pre}}$ là tập tham số có thuộc tính `requires_grad=True`. Tổng tham số, tham số huấn luyện và tỷ lệ tham số huấn luyện được tính bằng:

$$P_{\text{total}} = \sum_{\theta \in \Theta_{\text{pre}}} |\theta|, \quad P_{\text{train}} = \sum_{\theta \in \Theta_{\text{train}}} |\theta|, \quad r_{\text{train}} = 100 \frac{P_{\text{train}}}{P_{\text{total}}}.\tag{4.17}$$

Đối với XBone-Net, P_{train} gồm tham số LoRA, mô-đun dung hợp và

đầu phân lớp. Các tham số backbone còn lại được giữ cố định. Ba đại lượng trong bảng tham số được lấy trước khi hợp nhất LoRA nhằm phản ánh đúng số tham số cần cập nhật trong huấn luyện. Trước khi đo suy luận, trọng số LoRA được hợp nhất vào các lớp backbone nên không còn được tính như một nhánh tham số riêng.

Nghiên cứu đồng thời báo cáo số phép toán dấu phẩy động trên mỗi mẫu, thông lượng, độ trễ trung bình và bộ nhớ đồ họa cực đại [3, 25]. Số phép toán được đếm trên các phép toán mà bộ đếm của PyTorch hỗ trợ, trong đó một phép nhân–cộng được tính là hai phép toán. Thông lượng và độ trễ sử dụng kích thước lô 1 trên 20 lô kiểm thử. Mỗi lô gồm 10 lượt khởi động và 10 lượt ghi thời gian. Thời gian chỉ bao gồm lan truyền tiến sau khi dữ liệu đã nằm trong bộ nhớ GPU, không bao gồm nạp dữ liệu và truyền dữ liệu từ CPU. Các phép đo được thực hiện trên cùng phần cứng, độ chính xác số học và đồ thị suy luận sau khi hợp nhất LoRA.

4.1.4 Cấu hình thực nghiệm

Mỗi cấu hình có huấn luyện được chạy với ba hạt giống 42, 123 và 456 trên cùng phân chia dữ liệu và môi trường ở Bảng 4.8. Bảng 4.9 trình bày các siêu tham số chính dùng trong thực nghiệm.

Thành phần	Cấu hình
Phần cứng	RTX 5060 Ti 16 GB, Intel Core Ultra 7 265KF và 32 GB RAM
Phần mềm	Python 3.11.15, Torch 2.11.0+cu128 và CUDA 12.8
Độ chính xác số học	bfloat16

Bảng 4.8: Môi trường thực nghiệm

Thành phần	Cấu hình
Đầu vào ảnh	1 ảnh qua phép biến đổi chuẩn của BioMedCLIP
Bộ tối ưu và kích thước lô	AdamW, 16
Hệ số suy giảm trọng số	10^{-4}
Lịch tốc độ học	cosine
Tỷ lệ khởi động	0,1
Độ chính xác số học	bfloat16
Cấu hình LoRA	Hạng 16, hệ số 32 và tỷ lệ bỏ học 0,1
Huấn luyện pha 1	Tốc độ học 5×10^{-5} , tối đa 30 vòng lặp và dừng sớm sau 3 vòng
Huấn luyện pha 2	Tốc độ học 10^{-4} , tối đa 50 vòng lặp và dừng sớm sau 5 vòng
Xử lý mất cân bằng lớp	Hệ số số lượng hiệu dụng 0,999 và giới hạn trọng số lớp 5,0

Bảng 4.9: Cấu hình chính của các thực nghiệm

4.2 Kết quả theo câu hỏi nghiên cứu

4.2.1 RQ1: Hiệu năng phân lớp và đánh đổi chi phí

Kết quả khi sử dụng toàn bộ dữ liệu

Bảng 4.10 và Bảng 4.11 lần lượt trình bày các độ đo quyết định lớp và độ đo xếp hạng trong thiết lập sử dụng toàn bộ dữ liệu huấn luyện.

Dữ liệu	Mô hình	Acc $\uparrow$	BAcc $\uparrow$	Macro-F1 $\uparrow$
BTXRD	BiomedCLIP	0.8311 ± 0.0028	0.6062 ± 0.0254	0.5994 ± 0.0124
	CLIP	0.8036 ± 0.0273	0.5957 ± 0.0160	0.5787 ± 0.0252
	DenseNet-121	0.6320 ± 0.0013	0.3694 ± 0.0150	0.3718 ± 0.0173
	MedCLIP	0.8204 ± 0.0144	0.6125 ± 0.0235	0.6054 ± 0.0147
	PubMedCLIP	0.7884 ± 0.0285	0.6089 ± 0.0342	0.5723 ± 0.0577
	ResNet-50	0.6071 ± 0.0140	0.3188 ± 0.0136	0.3291 ± 0.0102
	XBone-Net	0.8302 ± 0.0098	0.6115 ± 0.0140	0.6240 ± 0.0118
CTCH	BiomedCLIP	0.5969 ± 0.0253	0.6023 ± 0.0234	0.5540 ± 0.0080
	CLIP	0.5874 ± 0.0209	0.6217 ± 0.0359	0.5633 ± 0.0090
	DenseNet-121	0.4818 ± 0.0052	0.4927 ± 0.0461	0.4367 ± 0.0238
	MedCLIP	0.5590 ± 0.0389	0.5717 ± 0.0186	0.5151 ± 0.0216
	PubMedCLIP	0.5521 ± 0.0234	0.5589 ± 0.0614	0.5203 ± 0.0264
	ResNet-50	0.4928 ± 0.0017	0.4126 ± 0.0106	0.4078 ± 0.0051
	XBone-Net	0.6183 ± 0.0203	0.5935 ± 0.0134	0.5727 ± 0.0193

Bảng 4.10: Kết quả phân loại toàn bộ mẫu trên BTXRD và CTCH

Xét trung bình ba hạt giống, XBone-Net đạt Macro-F1 cao nhất trên BTXRD ($0,6240 \pm 0,0118$) và CTCH ($0,5727 \pm 0,0193$). Mô hình đồng thời đạt Accuracy cao nhất trên CTCH và gần như tương đương BiomedCLIP trên BTXRD. Tuy nhiên, XBone-Net không dẫn đầu Balanced Accuracy: MedCLIP cao nhất trên BTXRD và CLIP cao nhất trên CTCH. Vì vậy, kết quả thuận lợi nhất của XBone-Net nằm ở độ đo quyết định lớp, đặc biệt là Macro-F1, chứ không phải mọi độ đo.

Dữ liệu	Mô hình	Macro-AUROC $\uparrow$	Macro-AUPRC $\uparrow$
BTXRD	BiomedCLIP	0.8865 ± 0.0165	0.6511 ± 0.0104
	CLIP	0.8973 ± 0.0231	0.6251 ± 0.0080
	DenseNet-121	0.7717 ± 0.0173	0.3831 ± 0.0036
	MedCLIP	0.8599 ± 0.0330	0.6228 ± 0.0253
	PubMedCLIP	0.9048 ± 0.0240	0.6149 ± 0.0245
	ResNet-50	0.7236 ± 0.0259	0.3338 ± 0.0061
	XBone-Net	0.8045 ± 0.0159	0.5865 ± 0.0110
CTCH	BiomedCLIP	0.9390 ± 0.0289	0.6169 ± 0.0090
	CLIP	0.9290 ± 0.0387	0.6002 ± 0.0400
	DenseNet-121	0.9350 ± 0.0046	0.4762 ± 0.0136
	MedCLIP	0.9215 ± 0.0333	0.5839 ± 0.0185
	PubMedCLIP	0.9279 ± 0.0214	0.5888 ± 0.0196
	ResNet-50	0.9145 ± 0.0037	0.4492 ± 0.0042
	XBone-Net	0.9020 ± 0.0095	0.5904 ± 0.0224

Bảng 4.11: Các độ đo xếp hạng xác suất khi sử dụng toàn bộ tập huấn luyện

Đánh đổi thể hiện rõ hơn ở các độ đo xếp hạng. Trên BTXRD, Macro-AUROC và Macro-AUPRC của XBone-Net lần lượt là $0,8045 \pm 0,0159$ và $0,5865 \pm 0,0110$, thấp hơn nhiều mô hình ngôn ngữ-thị giác được tinh chỉnh toàn bộ. Trên CTCH, XBone-Net đạt $0,9020 \pm 0,0095$ và $0,5904 \pm 0,0224$, trong khi BiomedCLIP đạt $0,9390 \pm 0,0289$ và $0,6169 \pm 0,0090$. Kết quả xác định rằng ưu thế quan sát được của XBone-Net nằm ở độ đo quyết định lớp, còn chất lượng xếp hạng xác suất thấp hơn BiomedCLIP tinh chỉnh toàn bộ.

Các bảng báo cáo trung bình và độ lệch chuẩn qua ba hạt giống, còn Phụ lục C cung cấp kết quả riêng của từng lần chạy. Những số liệu này cho phép đánh giá mức ổn định theo khởi tạo nhưng không thay thế khoảng tin

cây ghép cặp hoặc kiểm định giả thuyết. Vì vậy, kết luận phù hợp với bằng chứng hiện có là XBone-Net *cạnh tranh* với nhóm mô hình ngôn ngữ-thị giác và có Macro-F1 trung bình cao hơn hai CNN, nhưng chưa chứng minh ưu thế thống kê trước mọi mô hình nền tảng.

Hiệu quả tham số và chi phí suy luận

Số lượng tham số và chi phí tính toán của XBone-Net so với BiomedCLIP tinh chỉnh toàn bộ được trình bày tại Bảng 4.12 và Bảng 4.13.

Dữ liệu	Mô hình	Tổng tham số	Tham số huấn luyện	Tỷ lệ (%)
BTXRD	BiomedCLIP (FFT)	196,433,675	196,433,675	100.00%
	XBone-Net	204,342,539	8,439,818	4.13%
CTCH	BiomedCLIP (FFT)	196,439,831	196,439,831	100.00%
	XBone-Net	204,348,695	8,445,974	4.13%

Bảng 4.12: Đánh giá số lượng tham số của các mô hình khi sử dụng toàn bộ dữ liệu

Dữ liệu	Mô hình	GFLOPs	Thông lượng	Độ trễ	Bộ nhớ GPU
BTXRD	BiomedCLIP (FFT)	81.032	64.7	15.48	770.7
	XBone-Net	82.318	68.2	15.26	782.4
CTCH	BiomedCLIP (FFT)	81.032	75.6	13.77	770.7
	XBone-Net	82.318	64.1	16.17	782.5

Bảng 4.13: Đánh giá chi phí tính toán và tốc độ suy luận của các mô hình khi sử dụng toàn bộ dữ liệu

XBone-Net cập nhật khoảng 8,44 triệu tham số, tương ứng 4,13% tổng tham số hiện diện trong mô hình và giảm khoảng 95,87% số tham số cần cập nhật so với tinh chỉnh toàn bộ. Kết quả này trực tiếp hỗ trợ đóng góp về thích nghi tham số hiệu quả. Tuy nhiên, tổng số tham số của XBone-Net lớn hơn BiomedCLIP tinh chỉnh toàn bộ do có thêm LoRA và mô-đun dung hợp. Vì vậy, lợi ích về tham số huấn luyện không đồng nghĩa mô hình suy luận nhỏ hơn.

Chi phí suy luận của XBone-Net là 82,318 GFLOPs, cao hơn khoảng 1,6% so với 81,032 GFLOPs của BiomedCLIP. Trên BTXRD, hai mô hình có độ trễ gần nhau với 15,26 so với 15,48 mili giây. Trên CTCH, XBone-Net chậm hơn với 16,17 so với 13,77 mili giây, có thông lượng thấp hơn với

64,1 so với 75,6 mẫu/giây và dùng thêm khoảng 11,8 MiB bộ nhớ GPU cực đại. Đây là phép đo tại một môi trường phần cứng và không kèm khoảng tin cậy. Kết quả chốt lại rằng mức tăng GFLOPs là nhỏ, nhưng độ trễ thực đo có thể tăng rõ tùy bộ dữ liệu.

Trả lời RQ1 Kết quả trả lời RQ1 rằng XBone-Net đạt hiệu năng quyết định lớp cạnh tranh và Macro-F1 trung bình cao nhất trên cả hai bộ dữ liệu, đồng thời chỉ cập nhật 4,13% tổng tham số trước khi hợp nhất LoRA. Đánh đổi của phương pháp là chất lượng xếp hạng không dẫn đầu và chi phí suy luận không thấp hơn BiomedCLIP tinh chỉnh toàn bộ. Do đó, kết luận của RQ1 là XBone-Net đạt hiệu năng phân lớp cạnh tranh với thích nghi tham số hiệu quả, nhưng không tạo ưu thế đồng thời về mọi độ đo hoặc chi phí suy luận.

4.2.2 RQ2: Ảnh hưởng của quy trình huấn luyện và dung hợp

Bảng 4.14 so sánh XBone-Net với hai biến thể qua ba hạt giống trên CTCH: bỏ pha thích nghi tương phản và thay chú ý chéo hai chiều bằng phép nổi đặc trưng.

Thành phần hoặc độ đo	XBone-Net	Chỉ pha 2	Nổi đặc trưng
Huấn luyện pha 1	✓		✓
Chú ý chéo hai chiều	✓	✓	
Accuracy ↑	0.6183 ± 0.0203	0.6099 ± 0.0143	0.5780 ± 0.0156
Balanced Accuracy ↑	0.5935 ± 0.0134	0.5861 ± 0.0231	0.6199 ± 0.0184
Macro-F1 ↑	0.5727 ± 0.0193	0.5728 ± 0.0111	0.5622 ± 0.0108
Macro-AUROC ↑	0.9020 ± 0.0095	0.9215 ± 0.0130	0.9394 ± 0.0101
Macro-AUPRC ↑	0.5904 ± 0.0224	0.6082 ± 0.0101	0.6201 ± 0.0036

Bảng 4.14: Nghiên cứu loại bỏ từng thành phần của XBone-Net trên CTCH

XBone-Net đạt Accuracy cao nhất ($0,6183 \pm 0,0203$), cao hơn biến thể Chỉ pha 2 khoảng 0,0084 và cao hơn Nổi đặc trưng khoảng 0,0403. Macro-F1 của XBone-Net cao hơn Nổi đặc trưng 0,0105, nhưng gần như bằng Chỉ pha 2 (0,5727 so với 0,5728). Ngược lại, Nổi đặc trưng đạt Balanced

Accuracy, Macro-AUROC và Macro-AUPRC cao nhất. Như vậy, chú ý chéo hai chiều và pha 1 gắn với Accuracy thuận lợi hơn, nhưng chưa tạo ưu thế đồng thời về cân bằng lớp và xếp hạng xác suất.

Các giá trị trung bình $\pm$ độ lệch chuẩn qua ba hạt giống mô tả độ nhạy theo khối tạo nhưng không tự tạo thành bằng chứng về ý nghĩa thống kê. Mỗi đối chứng thay đổi một khối chức năng trong toàn bộ quy trình nên chênh lệch được diễn giải là ảnh hưởng quan sát được của cấu hình thay thế, không phải đóng góp nhân quả độc lập của từng thành phần.

Trả lời RQ2 Kết quả trả lời RQ2 rằng huấn luyện hai pha và chú ý chéo hai chiều không cải thiện đồng thời mọi độ đo. Cấu hình đầy đủ đạt Accuracy cao nhất và giữ Macro-F1 tương đương Chỉ pha 2, trong khi Nối đặc trưng đạt BAcc, Macro-AUROC và Macro-AUPRC cao nhất. Vì mục tiêu chính ưu tiên quyết định lớp và Macro-F1, XBone-Net được giữ làm cấu hình đề xuất. Kết luận này chỉ áp dụng cho hai thay đổi đã được đối chứng trực tiếp là quy trình huấn luyện và cơ chế dung hợp.

4.2.3 RQ3: Khả năng và giới hạn của cảnh báo OOD hậu xử lý

Bảng 4.15 đối sánh XBone-Net với hai biến thể khi cùng sử dụng điểm Multi-modal Ensemble. Các số liệu là trung bình $\pm$ độ lệch chuẩn qua ba hạt giống. Tập Semantic OOD chỉ có 26 mẫu nên kết quả được diễn giải trong phạm vi đúng tập đánh giá này.

Kịch bản	Cấu hình	AUROC-ODD $\uparrow$	AUPR-Out $\uparrow$	FPR@95%TPR $\downarrow$
OOD CTCH	XBone-Net	0.7250 ± 0.0372	0.1451 ± 0.0093	0.7051 ± 0.0444
	Chỉ pha 2	0.7240 ± 0.0304	0.1978 ± 0.0053	0.6795 ± 0.0801
	Nối đặc trưng	0.7339 ± 0.0137	0.1166 ± 0.0120	0.7179 ± 0.0222
BTXRD	XBone-Net	0.9321 ± 0.0174	0.9052 ± 0.0171	0.3604 ± 0.1129
	Chỉ pha 2	0.9513 ± 0.0055	0.9289 ± 0.0062	0.2476 ± 0.0198
	Nối đặc trưng	0.9392 ± 0.0049	0.9082 ± 0.0024	0.4289 ± 0.0609

Bảng 4.15: Đánh giá cảnh báo OOD hậu xử lý của XBone-Net và hai biến thể

Trong kịch bản Semantic OOD gần miền, XBone-Net đạt AUROC-ODD $0,7250 \pm 0,0372$, gần bằng Chỉ pha 2 và thấp hơn Nối đặc trưng $0,0089$.

Chỉ pha 2 đạt AUPR-Out cao nhất với $0,1978 \pm 0,0053$ và $\text{FPR@95\%TPR}$ thấp nhất với $0,6795 \pm 0,0801$. $\text{FPR@95\%TPR}$ của cả ba cấu hình vẫn nằm trong khoảng từ 0,6795 đến 0,7179, cho thấy tỷ lệ chấp nhận nhầm mẫu OOD còn cao tại điểm vận hành giữ lại 95% mẫu ID. Trong kịch bản khác bộ dữ liệu BTXRD, Chỉ pha 2 tốt nhất trên cả AUROC-ODD, AUPR-Out và $\text{FPR@95\%TPR}$. XBone-Net đạt AUROC-ODD $0,9321 \pm 0,0174$ và AUPR-Out $0,9052 \pm 0,0171$, nhưng $\text{FPR@95\%TPR}$ vẫn ở mức $0,3604 \pm 0,1129$.

Kết quả cho thấy khả năng phát hiện OOD phụ thuộc rõ vào loại dịch chuyển và trạng thái biểu diễn. Cả ba cấu hình phân biệt dịch chuyển khác bộ dữ liệu tốt hơn dịch chuyển gần miền, trong khi việc bỏ pha 1 lại tạo kết quả thuận lợi nhất trên BTXRD. Vì vậy, huấn luyện hai pha và chú ý chéo hai chiều không tạo ra ưu thế OOD nhất quán. Điểm hậu xử lý hiện tại phù hợp làm tín hiệu cảnh báo bổ trợ, nhưng không đủ để dùng làm cơ chế từ chối dự đoán tự động.

Trả lời RQ3 Kết quả trả lời RQ3 rằng điểm Multi-modal Ensemble của XBone-Net phân biệt dữ liệu ID và OOD trên mức ngẫu nhiên trong cả hai kịch bản, nhưng không dẫn đầu trong nhóm cấu hình được so sánh. Dịch chuyển khác bộ dữ liệu được phát hiện rõ hơn dịch chuyển gần miền, còn $\text{FPR@95\%TPR}$ cao trên Semantic OOD xác định giới hạn chính của cảnh báo. Do đó, đầu ra OOD được sử dụng như tín hiệu bổ trợ và không được diễn giải là bảo đảm an toàn.

4.2.4 RQ4: Tích phân gradient và can thiệp nguồn đầu vào

Bảng 4.16 tổng hợp các chỉ số độ trung thực IG và mức giảm xác suất khi che từng nguồn trên tập mẫu chuẩn hóa $N = 44$ ở hạt giống 42. Do chỉ có một hạt giống và không có khoảng tin cậy ghép cặp, các chênh lệch chỉ mang tính mô tả.

XBone-Net có AUC khôi phục văn bản cao nhất với 0,4232. Chênh lệch AUC loại bỏ ngẫu nhiên so với thứ tự IG đạt +0,0767, gần bằng mức

Nhóm đánh giá	Chỉ số	XBone-Net	Chỉ pha 2	Nổi đặc trưng
Độ trung thực văn bản lâm sàng	AUC Khôi phục theo IG $\uparrow$	0.4232	0.3895	0.3231
	AUC Loại bỏ theo IG $\downarrow$	0.2704	0.2292	0.2026
Đối chứng ngẫu nhiên văn bản lâm sàng	AUC ngẫu nhiên – AUC theo IG $\uparrow$	0.0767	0.0781	0.0622
Độ trung thực ảnh X-quang	AUC Khôi phục theo IG $\uparrow$	0.3755	0.3756	0.3172
	AUC Loại bỏ theo IG $\downarrow$	0.2869	0.2723	0.2329
Đối chứng ngẫu nhiên ảnh X-quang	AUC ngẫu nhiên – AUC theo IG $\uparrow$	0.0374	0.0300	0.0131
Can thiệp nguồn thông tin	Mức giảm xác suất khi che Ảnh (Δp_{img})	0.3654	0.3100	0.2737
	Mức giảm xác suất khi che Văn bản (Δp_{txt})	0.2874	0.2581	0.2571

Bảng 4.16: Đánh giá IG và can thiệp nguồn của XBone-Net và hai biến thể trên 44 mẫu ở hạt giống 42

cao nhất +0,0781 của Chỉ pha 2 và cao hơn Nổi đặc trưng. Trên ảnh, AUC khôi phục của XBone-Net là 0,3755, gần bằng Chỉ pha 2 với 0,3756. XBone-Net đồng thời có chênh lệch so với ngẫu nhiên cao nhất trên ảnh với +0,0374. Tuy nhiên, AUC loại bỏ theo IG của XBone-Net cao nhất ở cả ảnh và văn bản, là kết quả bất lợi vì giá trị thấp hơn mới thuận lợi. Như vậy, XBone-Net có thứ tự IG tốt hơn đối chứng ngẫu nhiên nhưng không dẫn đầu đồng thời ở mọi độ đo độ trung thực.

Che ảnh hoặc văn bản làm xác suất lớp đích của XBone-Net giảm lần lượt 0,3654 và 0,2874, lớn hơn hai biến thể. Kết quả này cho thấy đầu ra XBone-Net phụ thuộc vào cả hai nguồn trong mốc can thiệp đã chọn. Mức giảm lớn chỉ phản ánh độ nhạy của đầu ra và không đồng nghĩa phương pháp giải thích tốt hơn, mô hình chính xác hơn hoặc tồn tại quan hệ nhân quả.

Trả lời RQ4 Kết quả trả lời RQ4 rằng dự đoán của XBone-Net phụ thuộc vào cả ảnh và bệnh sử trong phép can thiệp đã chọn. Chênh lệch AUC dương trên cả hai nguồn cho thấy thứ tự do IG xác định làm xác suất lớp đích giảm nhanh hơn đối chứng ngẫu nhiên. Tuy nhiên, XBone-Net không dẫn đầu đồng thời AUC loại bỏ và AUC khôi phục. Vì vậy, IG được dùng để truy vết nguồn thông tin ảnh hưởng đến đầu ra trong phạm vi phân tích thăm dò, không được xem là bằng chứng về quan hệ nhân quả hoặc lợi thế hiệu năng.

Chương 5

Kết luận và hướng phát triển

5.1 Tổng kết

Khóa luận đã xây dựng và đánh giá XBone-Net cho bài toán phân lớp ảnh X-quang xương đa phương thức. Phương pháp kế thừa hai bộ mã hóa của BiomedCLIP, tiền xử lý ảnh bằng letterbox, thích nghi bằng LoRA qua hai giai đoạn, dung hợp ảnh–văn bản bằng chú ý chéo và dự đoán bằng đầu phân lớp tuyến tính. Trên biểu diễn dung hợp, khóa luận khảo sát các điểm OOD hậu xử lý và sử dụng tích phân gradient cùng can thiệp đầu vào để truy vết nguồn thông tin liên hệ với dự đoán.

Thực nghiệm được tiến hành trên BTXRD và CTCH với ba hạt giống, bao gồm so sánh mô hình, nghiên cứu thành phần, các mức thích nghi bộ mã hóa, thiết lập ít mẫu, chi phí tính toán, hai kịch bản OOD và phân tích lời giải thích. Các đối chứng phương thức chỉ được dùng như kiểm tra bổ sung rằng mô hình có sử dụng hai đầu vào, không phải bằng chứng cho một đóng góp nghiên cứu riêng. Kết quả cho thấy XBone-Net đạt hiệu năng cạnh tranh và có ưu thế ở một số độ đo xếp hạng, một số ngân sách ít mẫu và hiệu quả tham số, nhưng không có cấu hình nào dẫn đầu nhất quán trên mọi tiêu chí. Vì vậy, đóng góp chính của khóa luận nằm ở phương pháp thích nghi và quy trình đánh giá có cấu trúc cho các đánh đổi giữa hiệu năng phân lớp, chi phí, cảnh báo OOD và khả năng truy vết

dự đoán.

5.2 Trả lời các câu hỏi nghiên cứu

5.2.1 RQ1: Hiệu năng phân lớp và chi phí

Trong thiết lập toàn bộ dữ liệu, Macro-F1 của XBone-Net cạnh tranh với các Med-VLM trên cả BTXRD và CTCH vì các phép so sánh không đồng thời có khoảng tin cậy loại trừ 0 và $p < 0,05$. Trong thiết lập ít mẫu, Macro-F1 tiếp tục cạnh tranh với hai mô hình PEFT đối chứng tại toàn bộ ngân sách, trong khi các lợi thế hoặc bất lợi nhất quán chỉ xuất hiện ở một số độ đo phụ trên CTCH. LoRA cập nhật 8,63 triệu tham số, tương ứng 4,22% tổng số tham số, thấp hơn nhiều so với tinh chỉnh toàn bộ. Tuy nhiên, XBone-Net cần 229,020 GFLOPs mỗi mẫu và có thông lượng thấp hơn các mô hình LoRA đối chứng. Do đó, bằng chứng hỗ trợ claim hiệu năng cạnh tranh với ít tham số cập nhật hơn, đồng thời xác nhận sự đánh đổi bằng chi phí suy luận cao hơn.

5.2.2 RQ2: Ảnh hưởng của các thành phần XBone-Net

Theo đồng thời khoảng tin cậy 95% và p-value thô, XBone-Net cạnh tranh với gộp trung bình và nổi đặc trưng trên toàn bộ năm độ đo được kiểm định. Cấu hình chỉ pha 2 và đầu tuyến tính có Accuracy cao hơn XBone-Net, trong khi XBone-Net có Macro-AUROC cao hơn cấu hình không dùng ảnh độ phân giải cao và đầu tuyến tính. Không khác biệt nào nhất quán về Balanced Accuracy, Macro-F1 hoặc Macro-AUPRC. Vì vậy, chưa có biến thể nào vượt trội trên toàn bộ tiêu chí. Cấu hình đầy đủ được xem là một điểm đánh đổi giữa quyết định lớp và chất lượng xếp hạng.

5.2.3 RQ3: Phân biệt dữ liệu ngoài phân phối

Trong bốn điểm hậu xử lý được đánh giá trên biểu diễn XBone-Net, khoảng cách Mahalanobis đạt AUROC-ODD $0,8042 \pm 0,0938$ trên BTXRD và $0,6286 \pm 0,0177$ trên 44 mẫu OOD ngữ nghĩa của CTCH. Kết quả cho thấy biểu diễn có chứa tín hiệu dịch chuyển, nhưng khả năng phân biệt phụ thuộc mạnh vào dạng OOD. FPR@95%TPR vẫn cao ở cả hai kịch bản. Do đó, mô-đun hiện tại chỉ phù hợp làm cảnh báo hỗ trợ và chưa đủ để tự động từ chối dự đoán.

5.2.4 RQ4: Vai trò của các nguồn thông tin trong lời giải thích

Can thiệp trên 669 mẫu kiểm thử CTCH cho thấy ảnh toàn cục tạo mức giảm xác suất trung bình $0,3740 \pm 0,0278$ và bệnh sử tạo mức giảm $0,2614 \pm 0,0621$, trong khi ảnh cục bộ có ảnh hưởng biên gần 0 với mốc thay thế hiện tại. So với thứ tự ngẫu nhiên, AUC loại bỏ theo tích phân gradient giảm 0,0793 đối với ảnh toàn cục, 0,0699 đối với bệnh sử nhưng chỉ 0,0062 đối với ảnh cục bộ. Do đó, tích phân gradient cung cấp tín hiệu truy vết rõ hơn ở hai nguồn đầu nhưng độ trung thực phụ thuộc vào nguồn thông tin và mốc thay thế. Kết quả chưa chứng minh quan hệ nhân quả, khả năng định vị tổn thương hoặc độ đúng lâm sàng.

5.3 Hướng phát triển

Về dữ liệu, cần kiểm định trên nhiều cơ sở và thiết bị, bổ sung các nhóm OOD gần miền có quy mô lớn hơn, đồng thời chuẩn hóa và kiểm tra rò rỉ thông tin trong văn bản. Đối với BTXRD, nên tách văn bản sinh từ thông tin không chứa nhãn khỏi các trường có liên hệ trực tiếp với nhóm bệnh. Đối với CTCH, cần đánh giá ảnh hưởng của dịch thuật, thiếu trường bệnh sử, thông tin sai hoặc lỗi thời và thực hiện các phép xáo trộn có kiểm soát

theo từng thành phần văn bản.

Về kiến trúc và chi phí, cần khảo sát phiên bản XBone-Net gọn hơn với ít vùng cục bộ, gộp trung bình, nổi đặc trưng hoặc chú ý một chiều, đồng thời đánh giá đa mục tiêu theo Macro-F1, Macro-AUROC, Macro-AUPRC, ECE, GFLOPs, độ trễ và bộ nhớ. Các phương pháp OOD cần được hiệu chỉnh trên tập xác thực độc lập và đánh giá cùng tỷ lệ từ chối, chi phí lỗi và độ ổn định theo miền trước khi xem xét cơ chế từ chối tự động.

Về khả năng giải thích và triển khai, cần bổ sung chú thích vùng tổn thương, đánh giá của bác sĩ, nhiều mốc tham chiếu và đối chứng loại bỏ phù hợp hơn để kiểm tra độ trung thực của tích phân gradient. Một hệ thống hỗ trợ thực tế cũng cần lưu nhật ký gồm phiên bản mô hình, nguồn dữ liệu đầu vào, xác suất theo lớp, điểm và ngưỡng OOD, bản đồ quy đóng, quyết định chấp nhận hoặc ghi đề của bác sĩ và kết quả cuối cùng để phục vụ truy cứu, giám sát sai lệch và cải tiến. Chỉ sau kiểm định ngoài và nghiên cứu tiền cứu với chuyên gia, XBone-Net mới có thể được xem xét như một công cụ hỗ trợ quyết định lâm sàng.

Tài liệu tham khảo

Tiếng Anh

- [1] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision-Language Models”. In: *Proceedings of the European Conference on Computer Vision (ECCV)*. Springer, 2022, pp. 1–18. DOI: 10.1007/978-3-031-19836-6_1.
- [2] Kay Henning Brodersen et al. “The Balanced Accuracy and Its Posterior Distribution”. In: *Proceedings of the 20th International Conference on Pattern Recognition (ICPR)*. IEEE, 2010, pp. 3121–3124. DOI: 10.1109/ICPR.2010.764.
- [3] Alfredo Canziani, Adam Paszke, and Eugenio Culurciello. “An Analysis of Deep Neural Network Models for Practical Applications”. In: *arXiv preprint arXiv:1605.07678* (2017). URL: <https://arxiv.org/abs/1605.07678>.
- [4] Yin Cui et al. “Class-Balanced Loss Based on Effective Number of Samples”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2019, pp. 9268–9277. DOI: 10.1109/CVPR.2019.00949.
- [5] Jesse Davis and Mark H. Goadrich. “The Relationship Between Precision-Recall and ROC Curves”. In: *Proceedings of the 23rd International Conference on Machine Learning (ICML)*. ACM, 2006, pp. 233–240. DOI: 10.1145/1143844.1143874.

- [6] deep-translator contributors. *deep-translator: A flexible tool to translate between different languages in Python*. 2020. URL: <https://github.com/nidhaloff/deep-translator> (visited on 08/14/2026).
- [7] Alexey Dosovitskiy et al. “An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2021. URL: <https://openreview.net/forum?id=YicbFdNTTy>.
- [8] Sedigheh Eslami, Gerard de Melo, and Christoph Meinel. “Does CLIP Hurt Medical Image Classification? Evaluating and Improving CLIP for Medical Image Classification”. In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2023, pp. 15600–15611. DOI: 10.18653/v1/2023.emnlp-main.965.
- [9] Tom Fawcett. “An Introduction to ROC Analysis”. In: *Pattern Recognition Letters* 27.8 (2006), pp. 861–874. DOI: 10.1016/j.patrec.2005.10.010.
- [10] Kaiming He et al. “Deep Residual Learning for Image Recognition”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 770–778. DOI: 10.1109/CVPR.2016.90.
- [11] Dan Hendrycks and Kevin Gimpel. “A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2017. URL: <https://arxiv.org/abs/1610.02136>.
- [12] Edward J. Hu et al. “LoRA: Low-Rank Adaptation of Large Language Models”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2022. URL: <https://openreview.net/forum?id=nZeVKeeFYf9>.
- [13] Gao Huang et al. “Densely Connected Convolutional Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017, pp. 4700–4708. DOI: 10.1109/CVPR.2017.243.

- [14] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-Efficient Medical Image Recognition”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [15] Kimin Lee et al. “A Simple Unified Framework for Detecting Out-of-Distribution Samples and Adversarial Attacks”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 31. 2018, pp. 7167–7177. URL: <https://papers.nips.cc/paper/2018/hash/abdeb6f575ac5c6676b747bca8d09cc2-Abstract.html>.
- [16] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv preprint arXiv:2306.00890 2023. URL: <https://arxiv.org/abs/2306.00890>.
- [17] Shiyu Liang, Yixuan Li, and R. Srikant. “Enhancing The Reliability of Out-of-Distribution Image Detection in Neural Networks”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2018. URL: <https://openreview.net/forum?id=H1VGkIxRZ>.
- [18] Weitang Liu et al. “Energy-Based Out-of-Distribution Detection”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33. 2020, pp. 21464–21475. URL: <https://papers.nips.cc/paper/2020/hash/f5449014e28707da7d360e46a5e95299-Abstract.html>.
- [19] Xueyan Mei et al. “Artificial Intelligence–Enabled Rapid Diagnosis of Patients with COVID-19”. In: *Nature Medicine* 26.8 (2020), pp. 1224–1228. DOI: 10.1038/s41591-020-0931-3.
- [20] Michael Moor et al. *Med-Flamingo: A Multimodal Medical Few-Shot Learner*. arXiv preprint arXiv:2307.15189. 2023. URL: <https://arxiv.org/abs/2307.15189>.
- [21] Thi-Huong Nguyen et al. “LCBB: Low-Rank Adaptation of Vision-Language Models for Medical Image Classification”. In: *arXiv preprint*

- arXiv:2403.18245* (2024). URL: <https://arxiv.org/abs/2403.18245>.
- [22] OpenAI. *GPT-4o System Card*. 2024. URL: <https://openai.com/index/gpt-4o-system-card/> (visited on 08/01/2026).
 - [23] Jiuming Qin et al. “Freeze the Backbones: A Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.
 - [24] Alec Radford et al. “Learning Transferable Visual Models From Natural Language Supervision”. In: *Proceedings of the 38th International Conference on Machine Learning (ICML)*. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 8748–8763. URL: <https://proceedings.mlr.press/v139/radford21a.html>.
 - [25] Vijay Janapa Reddi et al. “MLPerf Inference Benchmark”. In: *Proceedings of the 2020 ACM/IEEE 47th Annual International Symposium on Computer Architecture (ISCA)*. IEEE, 2020, pp. 446–459. DOI: 10.1109/ISCA45697.2020.00045.
 - [26] Bryan C. Russell et al. “LabelMe: A Database and Web-Based Tool for Image Annotation”. In: *International Journal of Computer Vision* 77.1–3 (2008), pp. 157–173. DOI: 10.1007/s11263-007-0090-8.
 - [27] Sentence Transformers. *Paraphrase Multilingual MiniLM-L12-v2 Model Card*. 2021. URL: <https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2> (visited on 08/14/2026).
 - [28] Yiqing Shi et al. “BiomedCoOp: Explainable Medical Vision-Language Prompting”. In: *Proceedings of the 2024 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*. 2024, pp. 7920–7929. DOI: 10.1109/WACV57701.2024.00776.
 - [29] Jake Snell, Kevin Swersky, and Richard S. Zemel. “Prototypical Networks for Few-Shot Learning”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30. 2017, pp. 4077–4087. URL:

https://papers.nips.cc/paper_files/paper/2017/hash/cb8da6767461f2812ae4290eac7cbc42-Abstract.html.

- [30] Yiyou Sun et al. “Out-of-Distribution Detection with Deep Nearest Neighbors”. In: *Proceedings of the 39th International Conference on Machine Learning (ICML)*. Vol. 162. Proceedings of Machine Learning Research. PMLR, 2022, pp. 20827–20840. URL: <https://proceedings.mlr.press/v162/sun22d.html>.
- [31] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. “Axiomatic Attribution for Deep Networks”. In: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. Vol. 70. Proceedings of Machine Learning Research. PMLR, 2017, pp. 3319–3328. URL: <https://proceedings.mlr.press/v70/sundararajan17a.html>.
- [32] Tao Tu et al. “Towards Generalist Biomedical AI”. In: *NEJM AI* 1.3 (2024), AIoa2300138. DOI: 10.1056/AIoa2300138.
- [33] Xiaosong Wang et al. “TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018, pp. 9043–9052. DOI: 10.1109/CVPR.2018.00942.
- [34] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256.
- [35] Yandong Wen et al. “A Discriminative Feature Learning Approach for Deep Face Recognition”. In: *Proceedings of the European Conference on Computer Vision (ECCV)*. Springer, 2016, pp. 499–515. DOI: 10.1007/978-3-319-46478-7_31.
- [36] Shunhan Yao et al. “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors”. In: *Scientific Data* 12.1 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y.

- [37] Jiajin Zhang et al. “Disease-Informed Adaptation of Vision-Language Models”. In: *IEEE Transactions on Medical Imaging* 44.10 (2025), pp. 3984–3996. DOI: 10.1109/TMI.2024.3475877.
- [38] Sheng Zhang et al. “Large-Scale Domain-Specific Pretraining for Biomedical Vision-Language Processing”. In: *npj Digital Medicine* 6.1 (2023), p. 233. DOI: 10.1038/s41746-023-00958-6. URL: <https://doi.org/10.1038/s41746-023-00958-6>.
- [39] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 38th International Conference on Machine Learning (ICML)*. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 12133–12145. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
- [40] Rongfu Zheng et al. “CLIPath: A Parameter-Efficient Adaptation Framework for Pathology Image Analysis”. In: *Proceedings of the International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Springer, 2023, pp. 334–344. DOI: 10.1007/978-3-031-43907-0_33.
- [41] Hong-Yu Zhou et al. “A Transformer-Based Representation-Learning Model with Unified Processing of Multimodal Input for Clinical Diagnostics”. In: *Nature Biomedical Engineering* 7.6 (2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x.

Phụ lục A

Chi tiết về bộ dữ liệu

Phụ lục này bổ sung các thông tin kỹ thuật cần thiết để tái lập quá trình chuẩn bị hai bộ dữ liệu BTXRD và CTCH. Nội dung của mỗi bộ dữ liệu được tổ chức theo cấu trúc dữ liệu, cách xây dựng nguồn văn bản sử dụng trong thực nghiệm đối với bộ dữ liệu BTXRD và cách sàng lọc dữ liệu đối với bộ dữ liệu CTCH. Các thống kê được tính trực tiếp từ phiên bản dữ liệu mà mã nguồn hiện tại sử dụng.

A.1 Bộ dữ liệu BTXRD

Phần này trình bày cấu trúc dữ liệu, đặc điểm kỹ thuật của ảnh và phương pháp xây dựng văn bản dạng lâm sàng tổng hợp cho BTXRD. Ảnh và siêu dữ liệu thuộc phiên bản BTXRD được sử dụng trong nghiên cứu riêng văn bản tổng hợp được sinh ngoại tuyến và cố định trước khi huấn luyện. Nội dung này tập trung vào cách sinh nguồn dữ liệu giả lâm sàng.

A.1.1 Cấu trúc lưu trữ và đặc điểm kỹ thuật

Bảng A.1 mô tả các thành phần liên quan đến phạm vi phân loại của nghiên cứu. Định danh ảnh là khóa liên kết một-một giữa siêu dữ liệu, nhãn, tập chia, ảnh và văn bản tổng hợp.

Thành phần	Số tệp	Vai trò
images/	3.746	Lưu ảnh X-quang đầu vào.
Annotations/	1.867	Lưu chú thích JSON cho các ảnh có u, nhưng không được sử dụng trong huấn luyện phân loại.
reports/	3.746	Mỗi ảnh có một văn bản dạng lâm sàng được sinh ngoại tuyến từ siêu dữ liệu.
dataset.csv	3.746	Siêu dữ liệu gốc, gồm định danh ảnh, nguồn thu thập, tuổi, giới tính, vị trí giải phẫu, tư thế chụp và các cờ nhóm bệnh.
btxrd-labels.csv	3.746	Chứa định danh ảnh và 10 cột chỉ báo lớp.
btxrd-split.csv	3.746	Ánh xạ mỗi ảnh vào <code>train</code> , <code>validate</code> hoặc <code>test</code> .

Bảng A.1: Cấu trúc lưu trữ của bộ dữ liệu BTXRD trong nghiên cứu

Bảng A.2 cho thấy dữ liệu ảnh có định dạng không hoàn toàn đồng nhất. Mặc dù tất cả tên tệp đều mang định dạng JPEG, kiểm tra nội dung tệp xác định 3.744 ảnh được mã hóa JPEG, một ảnh được mã hóa BMP và một ảnh được nhận diện là MPO. Toàn bộ 3.746 ảnh vẫn giải mã thành công. Khi nạp dữ liệu, mỗi ảnh được chuyển sang RGB trước khi tạo tensor, do đó ảnh thang xám và ảnh ba kênh đều tạo đầu vào ba kênh cho mô hình.

Thuộc tính	Kết quả kiểm tra
Phần mở rộng	3.719 tệp .jpeg và 27 tệp .jpg.
Chế độ màu khi giải mã	2.895 ảnh thang xám L và 851 ảnh RGB.
Định dạng mã hóa	3.744 JPEG, 1 BMP và 1 MPO.
Chiều rộng	Nhỏ nhất 153 px, trung vị 1.612 px, lớn nhất 3.594 px.
Chiều cao	Nhỏ nhất 311 px, trung vị 2.256 px, lớn nhất 4.881 px.
Khả năng giải mã	3.746/3.746 tệp được đọc thành công.

Bảng A.2: Đặc điểm kỹ thuật của các tệp ảnh BTXRD

A.1.2 Phương pháp tạo dữ liệu giả lâm sàng

BTXRD không cung cấp bệnh sử tự do tương ứng với từng ảnh. Để mô phỏng đầu vào văn bản của một hệ thống đa phương thức, nghiên cứu xây dựng một văn bản dạng lâm sàng cho mỗi mẫu bằng quy trình dựa trên luật và ngân hàng mẫu câu. Mục tiêu của quy trình là tạo một cấu trúc đầu vào thống nhất, không phải khôi phục bệnh sử thật của người bệnh.

Thông tin đầu vào và luật điều kiện

Các trường được lấy trực tiếp từ siêu dữ liệu gồm tuổi, giới tính, vị trí xương, vị trí khớp, vùng giải phẫu và tư thế chụp. Vị trí chính được chọn theo thứ tự ưu tiên xương, khớp, vùng giải phẫu nếu không có trường vị trí cụ thể, một mô tả tổng quát về xương sẽ được sử dụng. Tuổi được chia thành bốn nhóm gồm dưới 20 tuổi, 20-34 tuổi, 35-49 tuổi và từ 50 tuổi trở lên để lựa chọn ngữ cảnh tiền sử phù hợp.

Ngân hàng mẫu câu được chia thành ba nhóm hành vi. Mẫu không có cờ u được gán nhóm "không u" còn mẫu có cờ u và cờ ác tính được gán nhóm "ác tính" và các mẫu có u còn lại được gán nhóm "lành tính". Theo luật này, dữ liệu gồm 1.879 mẫu không u, 1.525 mẫu có u nhưng không mang cờ ác tính và 342 mẫu ác tính. Nhóm này quyết định tập mẫu câu dùng cho lý do vào viện, diễn tiến bệnh và khám thực thể. Ngoài ra, 182 mẫu có nhiều hơn một xương được đánh dấu và 61 mẫu có khớp liên quan thì được nối thêm một câu mô tả bối cảnh nhiều vị trí hoặc hạn chế vận động quanh khớp.

Ghép văn bản và cố định dữ liệu

Các lựa chọn ngẫu nhiên sử dụng phân phối đều trên từng ngân hàng câu và hạt giống 42. Ngân hàng mẫu câu ban đầu được sinh từ tên bệnh bằng ChatGPT-4o [22], tham chiếu cấu trúc các trường bệnh sử của CTCH để mô phỏng cách trình bày. Danh sách khoảng thời gian có 10 lựa chọn. Số mẫu câu lý do vào viện của ba nhóm không u/lành tính/ác tính lần lượt là 6/7/6, số mẫu diễn tiến bệnh là 6/8/8 và số mẫu khám thực thể là 4/7/7. Ngân hàng tiền sử chung có 9 câu, mỗi nhóm tuổi có 3 câu ngữ cảnh, còn hai ngân hàng bổ sung nhiều xương và quanh khớp đều có 5 câu. Sau bước biên soạn ngân hàng, quy trình chọn và ghép văn bản không gọi mô hình ngôn ngữ và không có bước xác nhận nội dung bởi bác sĩ.

Với thứ tự hàng siêu dữ liệu được giữ cố định, mỗi lần chạy quy trình tạo ra cùng một lựa chọn mẫu câu. Văn bản được ghép theo thứ tự: thông tin người bệnh, lý do vào viện, diễn tiến bệnh, khám thực thể, tiền sử bản thân và thông tin thu nhận ảnh.

Bảng A.3 liệt kê các mẫu câu đại diện cho từng ngân hàng. Các mẫu được giữ nguyên bằng tiếng Anh vì đây là ngôn ngữ của đầu vào văn bản BTXRD trong thí nghiệm với các ký hiệu "location", "duration" và "joint" lần lượt được thay bằng vị trí chính, khoảng thời gian được chọn và khớp liên quan.

Ngân hàng	Mẫu câu đại diện
Khoảng thời gian	<i>2 weeks; 1 month; 3 months; 6 months; several weeks; a few months; 2 months; 4 weeks; several months; 1 year.</i>
Lý do vào viện	Không u: <i>Pain in the {location}.</i> Lành tính: <i>Swelling of the {location}.</i> Ác tính: <i>Persistent pain in the {location}.</i>
Diễn tiến bệnh	Không u: <i>Onset {duration} ago; mild symptoms.</i> Lành tính: <i>The patient noticed swelling in the {location} {duration} ago.</i> Ác tính: <i>Pain and swelling in the {location} for {duration}; progressively worsening.</i>
Khám thực thể	Không u: <i>No tenderness or swelling on palpation.</i> Lành tính: <i>Palpable firm mass; non-tender; no skin changes.</i> Ác tính: <i>Firm, tender mass on the {location}; local warmth noted.</i>
Bổ sung nhiều xương	<i>Multiple bony prominences palpated at several sites hoặc Multiple hard masses involving several bones on examination.</i>
Bổ sung quanh khớp	<i>Joint involvement noted; restricted range of motion at the {joint} hoặc Soft tissue swelling observed around the {joint}.</i>
Tiền sử chung	<i>No significant medical history, No prior bone disease or fracture hoặc No relevant prior medical or surgical history.</i>
Ngữ cảnh theo tuổi	Dưới 20 tuổi: <i>Growth and development appropriate for age.</i> Từ 20–34 tuổi: <i>No prior bone lesions.</i> Từ 35–49 tuổi: <i>No relevant surgical or medical history.</i> Từ 50 tuổi trở lên: <i>History of age-related degenerative changes; no prior bone lesions.</i>

Bảng A.3: Các mẫu câu đại diện trong ngân hàng văn bản giả lâm sàng BTXRD

Quy trình không chèn trực tiếp tên của 10 lớp đích vào văn bản. Tuy nhiên, cờ có u và cờ ác tính tham gia trực tiếp vào việc chọn ngân hàng mẫu câu, vì vậy nội dung tổng hợp vẫn mang tín hiệu liên hệ mạnh với nhãn. Các triệu chứng, thời gian mắc bệnh, dấu hiệu khám và tiền sử được chọn từ mẫu câu là dữ liệu giả lập, không phải lời khai của người bệnh hoặc ghi nhận của nhân viên y tế. Do đó, kết quả liên quan đến văn bản BTXRD chỉ phản ánh thiết lập giả lâm sàng có điều kiện này và không được diễn giải tương đương với bệnh sử tự nhiên của CTCH.

Kiểm chứng liên kết và khả năng tái lập

Để kiểm tra văn bản đã được ghép đúng với hàng siêu dữ liệu, bộ sinh được phát lại từ đầu trên toàn bộ `dataset.csv` với hạt giống 42 và giữ nguyên thứ tự 3.746 hàng. Văn bản tái tạo của mỗi hàng được so sánh từng ký tự với tệp có cùng định danh ảnh trong `reports/`. Cách kiểm tra tuần tự này là cần thiết vì lựa chọn mẫu câu của một hàng phụ thuộc vào trạng thái bộ sinh giả ngẫu nhiên sau các hàng đứng trước. Việc gọi hàm sinh riêng lẻ cho một mẫu không bảo toàn trạng thái đó. Ngoài liên kết văn bản, phép kiểm tra còn đối chiếu nhãn với siêu dữ liệu nguồn và xác nhận quy mô ba tập chia. Kết quả được trình bày trong Bảng A.4.

Phép kiểm tra	Kết quả
Định danh duy nhất trong siêu dữ liệu, nhãn và tập chia	3.746/3.746 (100%)
Nhãn có đúng một lớp trong 10 lớp	3.746/3.746 (100%)
Nhãn khớp với các cờ lớp trong <code>dataset.csv</code>	3.746/3.746 (100%)
Quy mô <code>train/validate/test</code>	2.621/375/750
Hàng siêu dữ liệu có văn bản cùng định danh	3.746/3.746 (100%)
Văn bản khớp chính xác khi phát lại bộ sinh	3.746/3.746 (100%)
Tệp thiếu/tệp dư so với <code>dataset.csv</code>	0/0
Văn bản có đủ sáu trường cấu trúc	3.746/3.746 (100%)
Văn bản duy nhất	3.745/3.746 (99,97%)
Độ dài trung bình	57,70 $\pm$ 6,66 từ
Trung vị và miền độ dài	56 từ, với miền 44–91 từ
Thiếu tuổi, giới tính, vị trí hoặc tư thế chụp	0 mẫu
Xuất hiện trực tiếp tên bệnh đích trong danh sách kiểm tra	0/3.746

Bảng A.4: Kết quả kiểm chứng tính toàn vẹn của dữ liệu BTXRD

Hai mẫu `IMG002607.jpeg` và `IMG003588.jpeg` tạo cùng một văn bản, giải thích vì sao số văn bản duy nhất thấp hơn tổng số mẫu một đơn vị. Kiểm tra từ khóa không phát hiện sự xuất hiện trực tiếp của các tên bệnh đích như *osteochondroma*, *osteosarcoma*, *simple bone cyst* hoặc *giant cell tumor*. Phép kiểm tra này xác nhận bộ sinh không chèn trực tiếp các tên bệnh được rà soát, nhưng không tự loại trừ tín hiệu nhãn gián tiếp. Trong phiên bản dữ liệu hiện tại, cả 3.746 hàng đều là nhãn một-nóng. Mẫu `IMG001276.jpeg` chỉ mang nhãn cụ thể *synovial osteochondroma* và không còn đồng thời mang nhãn cha *osteochondroma*.

Kiểm tra rò rỉ nhãn trực tiếp và gián tiếp

Quy trình được thực hiện trên toàn bộ 3.746 cặp văn bản–nhãn theo các bước sau:

1. **Kiểm tra trực tiếp:** chuẩn hóa chữ hoa–chữ thường và rà soát mỗi báo cáo để tìm sự xuất hiện nguyên văn của tên bệnh đích cùng các biến thể tên đã định nghĩa trước.
2. **Tạo câu nhắc lớp:** tạo một câu nhắc theo cùng mẫu *Clinical history associated with [disease label]* cho từng lớp trong 10 lớp bệnh.
3. **Mã hóa ngữ nghĩa:** mã hóa báo cáo và các câu nhắc lớp bằng bộ mã hóa văn bản BioMedCLIP, sau đó chuẩn hóa embedding và tính độ tương đồng cosin giữa mỗi báo cáo với cả 10 câu nhắc.
4. **Tính cosine margin:** với mẫu i có nhãn đúng y_i , tính

$$m_i = \cos(r_i, p_{y_i}) - \max_{c \neq y_i} \cos(r_i, p_c), \quad (\text{A.1})$$

trong đó r_i là embedding của báo cáo và p_c là embedding câu nhắc lớp c . Margin dương nghĩa là câu nhắc đúng nhãn gần báo cáo nhất, còn margin âm nghĩa là có ít nhất một câu nhắc nhãn khác gần hơn.

5. **Tổng hợp:** lấy trung bình m_i trên toàn bộ tập dữ liệu để đánh giá liệu tên bệnh đúng có thể được truy hồi ổn định từ nội dung văn bản hay không.

Bảng A.5 chỉ giữ hai kết quả có diễn giải trực tiếp đối với nguy cơ rò rỉ nhãn, còn các kết quả trung gian được lược bỏ để tránh gây nhầm lẫn.

Phép kiểm tra	Kết quả
Báo cáo chứa trực tiếp tên bệnh đích trong danh sách rà soát	0/3.746
Cosine margin trung bình giữa đúng nhãn và nhãn khác gần nhất	−0,0400

Bảng A.5: Kiểm tra nguy cơ rò rỉ nhãn trực tiếp và gián tiếp trong văn bản BTXRD

Không phát hiện trường hợp tên bệnh đích xuất hiện trực tiếp trong văn bản. Cosine margin trung bình bằng $-0,0400$, tức là độ tương đồng với đúng nhãn thấp hơn nhãn khác gần nhất trung bình $0,04$ đơn vị cosin. Vì vậy, phép kiểm tra không cho thấy tên bệnh cụ thể có thể được suy ra trực tiếp và ổn định từ báo cáo tổng hợp. Kết quả này chỉ đánh giá nguy cơ lộ tên nhãn và không đánh giá tính đúng đắn lâm sàng hay hình thái của nội dung văn bản.

1. Hàng siêu dữ liệu IMG000001.jpeg: tuổi 48, giới tính F, hip bone=1, pelvis=1, tumor=1, malignant=1 và frontal=1.



2. Suy ra điều kiện Vị trí chính là *hip bone*, nhóm tuổi là 35–49, nhóm mẫu câu là ác tính, tư thế là AP và không có nhiều xương hoặc khớp liên quan.



3. Chọn đầu với hạt giống 42 Khoảng thời gian là *1 month*. Lý do là *Pain and swelling of the hip bone*. Diễn tiến là *Pain in the hip bone for 1 month; associated with decreased appetite*. Khám ghi nhận *Palpable mass; tenderness on palpation; mild swelling*. Tiền sử gồm *No prior bone disease or fracture* và *No relevant surgical or medical history*.



4. Ghép theo thứ tự cố định *Patient: 48-year-old female. Reason for admission: Pain and swelling of the hip bone. Disease history: Pain in the hip bone for 1 month; associated with decreased appetite. Physical examination: Palpable mass; tenderness on palpation; mild swelling. Personal medical history: No prior bone disease or fracture. No relevant surgical or medical history. Radiographic evaluation: AP view of the hip bone was obtained.*



5. Cố định đầu vào Lưu thành IMG000001.txt

Hình A.1: Quá trình tạo văn bản minh họa cho mẫu IMG000001.jpeg


A.2 Bộ dữ liệu CTCH

Phụ lục này mô tả quy trình chuẩn bị CTCH nhằm hỗ trợ tái lập và đánh giá tính hợp lệ của dữ liệu. Nội dung tập trung vào tiêu chí lựa chọn mẫu, cách hình thành nhãn, nguyên tắc chia tập, nguồn gốc văn bản và các phép kiểm tra toàn vẹn.

Sàng lọc và xác định quần thể nghiên cứu

Quần thể đích của bộ dữ liệu CTCH gồm các bệnh nhân được chụp X-quang xương khớp nhằm hỗ trợ chẩn đoán bệnh lý hoặc chấn thương xương. Quần thể tiếp cận bao gồm các bệnh nhân có bệnh án và dữ liệu hình ảnh được thu thập tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.

Dữ liệu ban đầu gồm 12.949 bệnh án. Tuy nhiên, các hồ sơ này chưa thể được sử dụng trực tiếp vì có sự khác biệt về loại dữ liệu cận lâm sàng, thời điểm thăm khám, tình trạng điều trị và mức độ phù hợp của nhãn. Quy trình sàng lọc được thực hiện tuần tự nhằm hình thành quần thể có ảnh X-quang, bệnh sử và nhãn phù hợp với phạm vi phân loại của nghiên cứu. Số lượng hồ sơ còn lại sau từng bước được trình bày trong Hình A.2.



Hình A.2: Quy trình sàng lọc hồ sơ cho bộ dữ liệu CTCH

A.2.1 Cấu trúc dữ liệu và đặc điểm kỹ thuật

Bảng A.6 mô tả các thành phần liên quan đến phạm vi phân loại của nghiên cứu. Định danh ảnh là khóa liên kết một-một giữa siêu dữ liệu, nhãn, tập chia, ảnh và bệnh sử lâm sàng.

Thành phần	Số lượng sử dụng	Vai trò
images/	3.293	Lưu ảnh X-quang đầu vào được liên kết bởi manifest.
reports/	3.293 cặp song ngữ (6.586 tệp)	Mỗi ảnh được chọn có một bệnh sử lâm sàng tiếng Việt và một bản tiếng Anh tương ứng.
ctch-labels.csv	3.249	Chứa định danh ảnh và 22 cột chỉ báo lớp.
ctch-ood.csv	44	Chứa định danh và thông tin các mẫu ngoài phân phối.
ctch-split.csv	3.249	Ảnh xạ mỗi ảnh vào <code>train</code> , <code>validate</code> hoặc <code>test</code> .

Bảng A.6: Cấu trúc lưu trữ của bộ dữ liệu CTCH trong nghiên cứu

Bảng A.7 cho thấy dữ liệu ảnh có định dạng đồng nhất. Toàn bộ 3.293 tệp lưu trữ đều có phần mở rộng JPEG và được mã hóa chuẩn JPEG với toàn bộ 3.293 ảnh giải mã thành công. Khi nạp dữ liệu, mỗi ảnh được chuyển sang RGB trước khi tạo tensor, bảo đảm đầu vào ba kênh cho mô hình.

Thuộc tính	Kết quả kiểm tra
Phần mở rộng	3.293 tệp .jpg.
Chế độ màu khi giải mã	3.293 ảnh RGB.
Định dạng mã hóa	3.293 JPEG.
Chiều rộng	Nhỏ nhất 1.186 px, trung vị 1.213 px, lớn nhất 2.836 px.
Chiều cao	Nhỏ nhất 1.213 px, trung vị 1.713 px, lớn nhất 2.880 px.
Khả năng giải mã	3.293/3.293 tệp được đọc thành công.

Bảng A.7: Đặc điểm kỹ thuật của các tệp ảnh CTCH

Dữ liệu nguồn gồm 3.641 hồ sơ đã được lựa chọn sơ bộ từ các ca khám tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh. Mỗi hồ sơ liên kết thông tin bệnh án với một ảnh đại diện cho vị trí cần khảo sát. Quá trình sàng lọc tiếp tục loại những ca có nếp, dính hoặc phương tiện kết hợp xương vì các cấu trúc này có thể che khuất tổn thương và tạo dấu hiệu thị giác ngoài mục tiêu phân loại.

Hiện tại 348 hồ sơ có dụng cụ y tế bị loại nhằm đảm bảo phạm vi nghiên cứu, đồng thời giúp đảm bảo chất lượng dữ liệu đầu vào là đồng

nhất. Phần còn lại gồm 3.293 mẫu, được tách thành 3.249 mẫu trong phân phối phục vụ phân loại và 44 mẫu ngoài phân phối về ngữ nghĩa. Hai quần thể không giao nhau theo ảnh hoặc theo mã nhóm người bệnh.

Giai đoạn	Số hồ sơ
Hồ sơ nguồn	3.641
Loại do có dụng cụ y tế	348
Còn lại sau sàng lọc	3.293
Quần thể trong phân phối	3.249
Quần thể ngoài phân phối	44

Bảng A.8: Dòng dữ liệu qua các bước sàng lọc CTCH

Quần thể ngoài phân phối gồm 34 mẫu thuộc nhóm chấn thương và 10 mẫu thuộc nhóm viêm nhiễm, nhưng biểu hiện cụ thể không thuộc 22 lớp đích. Cách tổ chức này tạo một kịch bản ngoài dữ liệu trong cùng nguồn bệnh viện, qua đó giảm mức trộn lẫn giữa sai lệch ngữ nghĩa với thay đổi thiết bị hoặc cơ sở thu nhận. Tuy nhiên, số lượng 44 mẫu còn nhỏ nên khoảng bất định của các độ đo ngoài phân phối cần được trình bày và kết quả không nên được khái quát thành mọi dạng bất thường lâm sàng.

Nguồn văn bản và kiểm soát rò rỉ nhãn

Văn bản đầu vào CTCH được tạo ngoại tuyến từ ba trường có sẵn trước kết luận chẩn đoán cuối cùng gồm lý do vào viện, diễn tiến bệnh và tiền sử. Các trường kết quả khảo sát hình ảnh, chẩn đoán chuyên môn và nhãn phân lớp không được nối vào chuỗi văn bản đầu vào như thể hiện trong Bảng A.9. Chẩn đoán chuyên môn chỉ được sử dụng trong quá trình chuẩn hóa và dùng làm nhãn đích, còn nhãn phân loại chỉ tham gia kiểm tra và xác minh nhãn.

Trường dữ liệu nguồn	Dùng làm đầu vào	Vai trò trong nghiên cứu
Lý do vào viện	Có	Cung cấp triệu chứng hoặc vấn đề chính được ghi nhận khi tiếp nhận.
Diễn tiến bệnh	Có	Cung cấp cơ chế, thời điểm và diễn biến trước khi hình thành kết luận chẩn đoán.
Tiền sử	Có	Cung cấp thông tin bệnh lý, phẫu thuật hoặc điều trị trước đó khi trường này có dữ liệu.
Kết quả khảo sát hình ảnh	Không	Bị loại khỏi chuỗi đầu vào vì có thể chứa mô tả trực tiếp dấu hiệu trên phim.
Chẩn đoán chuyên môn	Không	Chỉ dùng để chuẩn hóa, ánh xạ và dùng làm nhãn phân loại chính, nhưng không được mã hóa bởi nhánh văn bản.
Nhân phân lớp	Không	Dùng để kiểm tra và xác minh nhãn.

Bảng A.9: Vai trò của các trường bệnh án CTCH và nguyên tắc loại thông tin có nguy cơ rò rỉ nhãn

Trong bước tạo thư mục **reports/**, ba trường được giữ lại được làm sạch và ghép theo thứ tự cố định, trong đó không có tên lớp, kết quả đọc ảnh hoặc chẩn đoán được bổ sung từ tệp nhãn. Việc chia tập được thực hiện theo mã người bệnh trước khi huấn luyện, còn mã liên kết không được đưa vào văn bản hoặc mô hình. Cách tổ chức này loại rò rỉ trực tiếp từ các cột chẩn đoán, nhưng không loại bỏ khả năng bệnh sử chứa những triệu chứng hoặc vị trí giải phẫu có tính dự báo cao. Vì vậy, khóa luận vẫn báo cáo đối chứng chỉ văn bản và phép ghép sai để khảo sát mức phụ thuộc vào nguồn này.

Công cụ dịch tiếng Anh. Bệnh sử tiếng Anh được tạo ngoại tuyến từ bản tiếng Việt bằng gói **deep-translator** phiên bản 1.11.4 với lớp **GoogleTranslator**, thiết lập ngôn ngữ nguồn là tiếng Việt (**vi**) và ngôn ngữ đích là tiếng Anh (**en**) [6]. Nội dung của từng trường được dịch riêng, trong khi tên trường, thứ tự trường và định danh liên kết với ảnh được giữ nguyên. Các đoạn tiếng Việt đã dịch được lưu trong một tệp bộ nhớ đệm JSON, do đó khi một đoạn xuất hiện lại, quy trình tái sử dụng đúng bản dịch đã lưu thay vì gửi một yêu cầu mới. Cơ chế này làm cho các câu lặp lại nhận cùng một bản dịch và hỗ trợ tái lập dữ liệu đã tạo.

Đánh giá độ tương đồng ngữ nghĩa của bản dịch. Chất lượng bản dịch được sàng lọc tự động bằng mô hình MiniLM đa ngôn ngữ `paraphrase-multilingual-MiniLM-L12-v2` [27]. Phép đánh giá chỉ chạy trên 3.293 ảnh còn lại sau sàng lọc và có tệp ảnh hợp lệ, không chạy trên các tệp vật lý ngoài manifest. Với mỗi trường có nội dung ở cả hai ngôn ngữ, câu tiếng Việt và câu tiếng Anh được mã hóa riêng với độ dài tối đa 256 token. Vector câu được tạo bằng trung bình có mặt nạ trên các token hợp lệ, sau đó chuẩn hóa theo chuẩn L_2 và tính cosine similarity giữa hai ngôn ngữ. Điểm càng gần 1 biểu thị hai biểu diễn càng gần nhau về ngữ nghĩa. Ngưỡng 0,70 chỉ được dùng để gán cờ các cặp cần rà soát, không được xem là tiêu chuẩn tuyệt đối về tính đúng đắn y khoa.

Trung bình phản ánh mức điểm chung nhưng nhạy với phần đuôi điểm thấp, còn trung vị mô tả vị trí trung tâm bền vững hơn trước các trường hợp ngoại lệ. Bảng A.10 báo cáo cả hai đại lượng trên 9.542 cặp trường song ngữ được liên kết.

Trường bệnh sử	Số cặp	Trung bình	Trung vị	Dưới 0,70
Lý do vào viện	3.293	0,7264	0,7767	1.083 (32,89%)
Diễn tiến bệnh	3.293	0,7462	0,7747	839 (25,48%)
Tiền sử cá nhân	2.956	0,5330	0,4737	2.474 (83,69%)
Toàn bộ	9.542	0,6733	0,7234	4.396 (46,07%)

Bảng A.10: Độ tương đồng ngữ nghĩa giữa bệnh sử tiếng Việt và bản dịch tiếng Anh của CTCH

Ở hai trường cốt lõi, điểm trung bình đạt 0,7264–0,7462 và trung vị đạt 0,7747–0,7767. Các đại lượng trung tâm gần nhau và trung vị xấp xỉ 0,78 cho thấy phần trung tâm của phân bố tương đồng tương đối ổn định. Điểm tiền sử thấp hơn vì trường này có nhiều câu rất ngắn và 1.980 trường hợp thuộc ba biến thể của phát biểu “chưa phát hiện/chưa ghi nhận bất thường”. Bản dịch đúng ý nghĩa nhưng chỉ nhận cosine similarity khoảng 0,41–0,47. Rà soát phần đuôi điểm thấp ghi nhận cả cảnh báo giả lẫn một số lỗi thuật ngữ cần sửa. Do đó, trung bình và trung vị cung cấp bằng chứng định lượng rằng bản dịch tiếng Anh nhìn chung giữ được ngữ nghĩa, đặc biệt ở lý do vào viện và diễn tiến bệnh, nhưng vẫn cần kiểm tra thủ công bởi người có chuyên môn.

Kiểm chứng liên kết, nhãn và tập chia

Khác với BTXRD, bệnh sử CTCH là dữ liệu được trích từ bệnh án nên không thể kiểm chứng bằng cách phát lại một ngân hàng mẫu câu. Phép kiểm tra phù hợp là đối chiếu khóa định danh giữa manifest, ảnh, văn bản và nhãn, xác nhận tính một-nóng của nhãn, đồng thời kiểm tra giao nhau theo người bệnh giữa các tập dữ liệu. Kết quả tính trực tiếp trên quần thể được manifest lựa chọn được trình bày trong Bảng A.11.

Phép kiểm tra	Kết quả
Định danh trong phân phối là duy nhất	3.249/3.249 (100%)
Định danh ngoài phân phối là duy nhất	44/44 (100%)
Giao nhau theo ảnh giữa quần thể trong và ngoài phân phối	0 mẫu
Giao nhau theo người bệnh giữa quần thể trong và ngoài phân phối	0 người bệnh
Mẫu được chọn có ảnh giải mã được	3.293/3.293 (100%)
Mẫu được chọn có đủ bệnh sử tiếng Việt và tiếng Anh	3.293/3.293 (100%)
Tập bệnh sử được liên kết có nội dung khác rỗng	6.586/6.586 (100%)
Nhãn trong phân phối có đúng một lớp trong 22 lớp	3.249/3.249 (100%)
<code>class_id</code> , tên lớp và cột một-nóng nhất quần	3.249/3.249 (100%)
Giao nhau theo người bệnh giữa <code>train/validate/test</code>	0/0/0
Quy mô <code>train/validate/test</code>	2.265/315/669

Bảng A.11: Kết quả kiểm chứng tính toàn vẹn của quần thể CTCH được sử dụng

Trong 3.293 bệnh sử tiếng Anh được liên kết, trường lý do vào viện và diễn tiến bệnh có nội dung ở toàn bộ mẫu, còn trường tiền sử có nội dung ở 2.956 mẫu (89,77%) và không có dữ liệu ở 337 mẫu. Hai con số tương ứng giống nhau ở nguồn tiếng Việt, nên tổng cộng có 5.912/6.586 tập (89,77%) chứa nội dung tiền sử. Việc thiếu tiền sử được giữ như trạng thái dữ liệu nguồn, không được nội suy bằng câu giả lập.

Phụ lục B

Cấu hình chi tiết của XBone-Net

Phụ lục này trình bày cấu hình chi tiết của phương pháp được mô tả trong Chương 3. Nội dung tập trung vào mô hình nền tảng, kích thước các biểu diễn, vị trí thích nghi hạng thấp, cấu hình dung hợp, đầu phân lớp và các tham số huấn luyện. Các quy tắc tiền xử lý ảnh và công thức tối ưu được giữ tại Chương 3 để tránh lặp lại phần mô tả phương pháp.

B.1 Mô hình nền tảng và chuẩn hóa đầu vào

XBone-Net sử dụng trọng số công bố của BiomedCLIP với định danh `hf-hub:microsoft/BiomedCLIP-PubMedBERT_256-vit_base_patch16_224` [38]. Định danh này xác định đồng thời bộ mã hóa thị giác ViT-B/16, bộ mã hóa văn bản PubMedBERT, hai lớp chiếu về không gian 512 chiều, bộ biến đổi ảnh và bộ tách đơn vị biểu diễn tương ứng. Trọng số nền của hai bộ mã hóa được nạp trước khi chèn LoRA và được giữ cố định trong cả hai giai đoạn huấn luyện.

Thành phần	Cấu hình	Vai trò
Ảnh toàn cục	Một ảnh 224×224	Giữ bố cục giải phẫu chung của ảnh X-quang.
Ảnh cục bộ	Bốn vùng 224×224 được cắt từ ảnh gốc	Giữ chi tiết tại các vùng được quy trình toàn cục-cục bộ lựa chọn.
Mảnh ảnh	Lưới 14×14 , mỗi mảnh 16×16	Tạo 196 đơn vị biểu diễn không gian và một đơn vị đại diện cho mỗi ảnh.
Văn bản	Tối đa 256 đơn vị biểu diễn	Chuỗi dài hơn bị cắt, chuỗi ngắn hơn được đệm và mặt nạ chú ý loại các vị trí đệm.
Văn bản khuyết	no clinical information available.	Là chuỗi thay thế cố định khi trường văn bản rỗng.
Chiều biểu diễn	$D = 512$	Là chiều chung của ảnh, văn bản, dung hợp và tâm lớp.

Bảng B.1: Cấu hình đầu vào và mô hình nền tảng của XBone-Net

Văn bản được đọc bằng mã hóa UTF-8, loại khoảng trắng ở hai đầu và chuyển về chữ thường trước khi tách đơn vị biểu diễn. Đối với CTCH, đầu vào gồm lý do vào viện, diễn tiến bệnh và tiền sử. Đối với BTXRD, đầu vào là văn bản tổng hợp đã được cố định trước khi huấn luyện. Bộ tách đơn vị biểu diễn và phép chuẩn hóa ảnh được lấy trực tiếp từ cùng định danh BiomedCLIP nhằm tránh sai khác giữa tiền huấn luyện và thích nghi trên dữ liệu đích.

B.2 Kích thước biểu diễn qua các thành phần

Gọi B là kích thước lô và K là số lớp. Cấu hình chính sử dụng $K = 22$ trên CTCH và $K = 10$ trên BTXRD. Bảng B.2 trình bày kích thước đầu ra tại các bước chính. Các kích thước này không phụ thuộc vào độ phân giải ban đầu của ảnh vì ảnh toàn cục và các vùng cục bộ đều được đưa về 224×224 trước khi mã hóa.

Vị trí	Kích thước	Diễn giải
Chuỗi của một ảnh sau ViT	$B \times 197 \times 512$	Một đơn vị đại diện và 196 đơn vị mảnh ảnh.
Một vùng ảnh cục bộ sau gộp	$B \times 5 \times 512$	Một đơn vị đại diện và lưới gộp 2×2 .
Bốn vùng ảnh cục bộ	$B \times 20 \times 512$	Ghép năm đơn vị của mỗi vùng theo thứ tự xác định.
Chuỗi thị giác dùng cho dung hợp	$B \times 21 \times 512$	Một biểu diễn ảnh toàn cục và 20 đơn vị ảnh cục bộ đã bổ sung tọa độ.
Chuỗi văn bản	$B \times 256 \times 512$	Một đơn vị đại diện, các đơn vị nội dung và các vị trí đệm.
Biểu diễn ảnh nhận ngữ cảnh văn bản	$B \times 512$	Kết quả truy vấn văn bản bằng biểu diễn ảnh toàn cục.
Biểu diễn văn bản nhận ngữ cảnh ảnh	$B \times 512$	Kết quả truy vấn các đơn vị ảnh cục bộ bằng biểu diễn văn bản toàn cục.
Biểu diễn dung hợp	$B \times 512$	Đầu vào của bộ phân lớp theo tâm lớp và các điểm OOD hậu xử lý.
Logit phân lớp	$B \times K$	Điểm của từng lớp trước Softmax.

Bảng B.2: Kích thước các biểu diễn tại những bước chính của XBone-Net

Trong pha 1, bốn vùng cục bộ được tổng hợp bằng trọng số chú ý có điều kiện theo biểu diễn ảnh toàn cục. Bản tóm tắt cục bộ được nhân với hệ số 0,25 trước khi cộng với biểu diễn toàn cục và chuẩn hóa. Trong pha 2, cấu hình chính không nén 20 đơn vị ảnh cục bộ bằng truy vấn học được mà truyền trực tiếp toàn bộ chuỗi này vào mô-đun dung hợp.

B.3 Cấu hình thích nghi hạng thấp

LoRA [12] được chèn vào cả bộ mã hóa ảnh và bộ mã hóa văn bản. Cấu hình chung sử dụng hạng $r = 16$, hệ số tỷ lệ $\alpha = 32$ và tỷ lệ bỏ học 0,1. Các ma trận LoRA được cập nhật trong cả hai pha, còn các trọng số nền tương ứng không nhận gradient. Bảng B.3 liệt kê các phép chiếu tuyến tính được thích nghi.

Các tham số học được ngoài LoRA gồm phép chiếu tọa độ của vùng ảnh, hệ số tọa độ khởi tạo bằng 0,1, hàm chấm điểm dùng để tổng hợp ảnh cục bộ, mô-đun chú ý chéo, mạng dung hợp và độ lệch theo lớp của

Bộ mã hóa	Mô-đun đích	Ý nghĩa
Thị giác ViT-B/16	attn.qkv, attn.proj, mlp.fc1, mlp.fc2	Thích nghi các phép chiếu truy vấn–khóa–giá trị, đầu ra chú ý và hai lớp của mạng truyền thẳng trong mỗi khối thị giác.
Văn bản PubMedBERT	query, key, value, attention.output.dense, intermediate.dense, output.dense	Thích nghi các phép chiếu tự chú ý, đầu ra chú ý và hai phép chiếu của mạng truyền thẳng trong mỗi khối văn bản.

Bảng B.3: Các mô-đun tuyến tính được thích nghi bằng LoRA

đầu phân loại. Các tâm lớp là thống kê của biểu diễn tập huấn luyện nên không được tối ưu trực tiếp bằng lan truyền ngược.

B.4 Dung hợp và đầu phân lớp

Mô-đun dung hợp sử dụng chú ý chéo hai chiều với tám đầu chú ý, chiều ảnh 512 và tỷ lệ bỏ học 0,1. Ở chiều thứ nhất, biểu diễn ảnh toàn cục truy vấn các đơn vị văn bản không đậm. Ở chiều còn lại, biểu diễn văn bản toàn cục truy vấn 20 đơn vị ảnh cục bộ. Hai kết quả được cộng thẳng dư với biểu diễn toàn cục tương ứng, chuẩn hóa lớp, nối với nhau và đưa qua mạng hai lớp để tạo biểu diễn dung hợp 512 chiều.

Thành phần	Giá trị	Ghi chú
Hướng chú ý	Hai chiều	Ảnh truy vấn văn bản và văn bản truy vấn ảnh dùng hai mô-đun độc lập.
Số đầu chú ý	8	Mỗi đầu có chiều $512/8 = 64$.
Tỷ lệ bỏ học	0,1	Áp dụng trong chú ý, nhánh thẳng dư và mạng dung hợp.
Mạng dung hợp	$1024 \rightarrow 512 \rightarrow 512$	Sử dụng GELU giữa hai lớp tuyến tính và chuẩn hóa đầu ra.
Hệ số logit của đầu tâm lớp	15,0	Nhân với độ tương đồng cosine trước khi cộng độ lệch lớp.
Độ lệch theo lớp	Có, khởi tạo bằng 0	Được tối ưu trong pha 2 để hiệu chỉnh ranh giới quyết định theo lớp.
Cập nhật tâm lớp	Mỗi vòng huấn luyện	Tính lại từ toàn bộ tập huấn luyện trước khi đánh giá trên tập xác thực.

Bảng B.4: Cấu hình mô-đun dung hợp và đầu phân lớp

B.5 Cấu hình huấn luyện

Hai pha sử dụng AdamW, lịch tốc độ học cosine, tỷ lệ khởi động 0,1, hệ số suy giảm trọng số 10^{-4} và kích thước lô 16. Huấn luyện sử dụng bfloat16 trên ba hạt giống 42, 123 và 456. Pha 1 lựa chọn trạng thái có mất mát xác thực thấp nhất, còn pha 2 lựa chọn trạng thái có Macro-F1 xác thực cao nhất. Tập kiểm thử không tham gia dừng sớm, lựa chọn trạng thái hoặc cập nhật tâm lớp.

Thuộc tính	Pha 1	Pha 2	Diễn giải
Mục tiêu	Khớp ngữ nghĩa	Phân lớp theo tâm lớp	Pha 1 căn chỉnh ảnh-văn bản, pha 2 tối ưu biểu diễn dung hợp cho lớp đích.
Tốc độ học	5×10^{-5}	10^{-4}	Áp dụng cho các tham số được phép cập nhật trong từng pha.
Số vòng tối đa	30	50	Đánh giá và lưu trạng thái sau mỗi vòng.
Dừng sớm	3 vòng	5 vòng	Dừng khi độ đo lựa chọn không cải thiện.
Độ đo lựa chọn	Mất mát xác thực	Macro-F1 xác thực	Chiều tối ưu lần lượt là giảm và tăng.
Đích mềm cùng lớp	$\rho = 0,50$	Không áp dụng	Giảm việc xem cặp khác mẫu nhưng cùng lớp là âm hoàn toàn.
Làm trơn nhãn	Không áp dụng	$\varepsilon = 0,05$	Giới hạn việc phân phối mục tiêu tập trung tuyệt đối vào một lớp.
Trọng số lớp	Không áp dụng	Số lượng hiệu dụng	Giới hạn trọng số lớn nhất bằng 5,0.

Bảng B.5: Cấu hình và tiêu chí lựa chọn trạng thái trong hai pha huấn luyện

Hai bộ dữ liệu chỉ khác nhau ở số lớp và hệ số số lượng hiệu dụng. CTCH sử dụng $K = 22$ và $\beta = 0,999$, trong khi BTXRD sử dụng $K = 10$ và $\beta = 0,99$. Các cấu hình còn lại trong Bảng B.5 được giữ giống nhau. Trong thiết lập ít mẫu, chỉ tập huấn luyện được lấy tối đa 1, 10 hoặc 20 mẫu trên mỗi lớp theo từng hạt giống. Tập xác thực và tập kiểm thử được giữ nguyên.

Phụ lục C

Kết quả chi tiết theo từng hạt giống

C.1 Phạm vi trình bày

Phụ lục này công bố các kết quả riêng của ba hạt giống ngẫu nhiên 42, 123 và 456 nhằm hỗ trợ cho các giá trị trung bình và độ lệch chuẩn được trình bày trong Chương 4. Sự thay đổi giữa các hạt giống được sử dụng để đánh giá độ nhạy của quy trình huấn luyện theo khởi tạo trên cùng một phép chia dữ liệu. Các giá trị này không được diễn giải như độ bất định do thay đổi tập dữ liệu.

Các kết quả gồm phân loại khi sử dụng toàn bộ dữ liệu, hai biến thể loại bỏ thành phần và đánh giá dữ liệu ngoài phân phối bằng hậu xử lý. Đây là các nội dung trong Chương 4 có đủ kết quả cho cả ba hạt giống và có thể đối chiếu trực tiếp với các bảng tổng hợp. Phép đo hiệu quả và đánh giá định lượng bằng tích phân gradient được thực hiện ở hạt giống 42 nên được trình bày trong chương chính mà không lặp lại thành bảng ba hạt giống.

C.1.1 Khả năng chuyển giao trực tiếp của các mô hình nền tảng

Kết quả phân loại không mẫu

Kết quả không mẫu được sử dụng để khảo sát mức độ phù hợp ban đầu của các mô hình nền tảng với hai bài toán đích trước khi thực hiện bất kỳ bước thích nghi nào. Bảng C.1 trình bày kết quả của CLIP [24], MedCLIP [34], PubMedCLIP [8] và BiomedCLIP [38] khi toàn bộ tham số được giữ cố định và mỗi lớp được biểu diễn bằng cùng một khuôn câu nhắc.

Dữ liệu	Mô hình	Acc $\uparrow$	BAcc $\uparrow$	Macro-F1 $\uparrow$	Macro-AUROC $\uparrow$	Macro-AUPRC $\uparrow$
BTXRD	BioMedCLIP	0.1453	0.1261	0.0837	0.5912	0.1656
	CLIP	0.0560	0.1033	0.0189	0.6051	0.1532
	MedCLIP	0.0440	0.0991	0.0217	0.4594	0.1109
	PubMedCLIP	0.0733	0.1196	0.0613	0.5745	0.1303
CTCH	BioMedCLIP	0.2720	0.3898	0.2698	0.8976	0.3244
	CLIP	0.1868	0.2915	0.1532	0.8308	0.2220
	MedCLIP	0.0239	0.0455	0.0021	0.5074	0.0570
	PubMedCLIP	0.1943	0.2737	0.1607	0.8357	0.2297

Bảng C.1: Kết quả phân loại không mẫu của các mô hình nền tảng trên BTXRD và CTCH

Trên BTXRD, BiomedCLIP đạt độ chính xác 0,1453, độ chính xác cân bằng 0,1261, điểm F1 trung bình theo lớp 0,0837 và Macro-AUPRC 0,1656, cao nhất trong bốn mô hình ở các độ đo này. Trong khi đó, Macro-AUROC cao nhất thuộc về CLIP với giá trị 0,6051. Độ chính xác cân bằng của các mô hình chỉ dao động từ 0,0991 đến 0,1261 và điểm F1 trung bình theo lớp không vượt quá 0,0837, cho thấy một câu nhắc chung chưa đủ để phân biệt ổn định các nhóm u xương có tên gọi và biểu hiện hình ảnh chuyên biệt. Việc CLIP đạt Macro-AUROC cao hơn nhưng có điểm F1 thấp hơn BiomedCLIP cũng cho thấy chất lượng xếp hạng chưa chuyển trực tiếp thành quyết định đa lớp phù hợp.

Trên CTCH, BiomedCLIP đạt kết quả cao nhất ở cả năm độ đo, gồm độ chính xác 0,2720, độ chính xác cân bằng 0,3898, điểm F1 trung bình theo lớp 0,2698, Macro-AUROC 0,8976 và Macro-AUPRC 0,3244. Tuy nhiên, khoảng cách lớn giữa Macro-AUROC và điểm F1 cho thấy biểu diễn tiền huấn luyện có khả năng sắp thứ tự mẫu tương đối tốt nhưng ranh giới

quyết định trực tiếp từ câu nhắc vẫn chưa phù hợp với không gian 22 lớp của CTCH.

Ý nghĩa đối với lựa chọn mô hình nền tảng

BiomedCLIP được lựa chọn làm mô hình nền tảng của XBone-Net dựa trên phạm vi tiền huấn luyện y sinh, kiến trúc hai bộ mã hóa và khả năng thích nghi bằng LoRA. Kết quả không mẫu được sử dụng để phân tích khả năng chuyển giao trực tiếp, không phải để lựa chọn mô hình dựa trên tập kiểm thử. Kết quả ở Bảng C.1 cho thấy biểu diễn của BiomedCLIP phù hợp tương đối với các khái niệm giải phẫu và bệnh lý xương, đặc biệt trên CTCH, nhưng không chứng minh rằng mô hình có thể được sử dụng trực tiếp cho bài toán đích. Vì vậy, các phần tiếp theo lần lượt khảo sát vai trò của văn bản đi kèm, hiệu quả của thích nghi miền, ảnh hưởng của từng thành phần và khả năng duy trì thông tin ảnh cục bộ.

C.1.2 Vai trò của ảnh và văn bản

Kết quả trên CTCH và BTXRD

Bảng C.2 so sánh cấu hình đa phương thức với hai cấu hình chỉ sử dụng một nguồn đầu vào. Các cấu hình sử dụng cùng tập chia và thiết lập tối ưu ở pha phân lớp. Tuy nhiên, các cấu hình đơn phương thức không thực hiện pha khớp ảnh–văn bản. Vì vậy, chênh lệch quan sát được phản ánh hiệu quả của toàn bộ thiết lập đa phương thức, không phải đóng góp biên thuần túy của riêng phương thức được bổ sung.

Bộ dữ liệu	Phương thức đầu vào	BAcc $\uparrow$	Macro-F1 $\uparrow$	Macro-AUROC $\uparrow$	Macro-AUPRC $\uparrow$
BTXRD	Ảnh và văn bản tổng hợp	0.5916 ± 0.0116	0.6010 ± 0.0034	0.9243 ± 0.0298	0.6301 ± 0.0211
	Chỉ ảnh	0.3167 ± 0.0191	0.3165 ± 0.0081	0.7756 ± 0.0179	0.3358 ± 0.0074
	Chỉ văn bản	0.5393 ± 0.0160	0.5315 ± 0.0121	0.9279 ± 0.0172	0.5721 ± 0.0096
	Ảnh và văn bản xáo trộn khác lớp	0.0078 ± 0.0016	0.0068 ± 0.0014	0.4124 ± 0.0644	0.0800 ± 0.0059
CTCH	Ảnh và bệnh sử lâm sàng	0.5844 ± 0.0454	0.5558 ± 0.0072	0.9473 ± 0.0246	0.6189 ± 0.0145
	Chỉ ảnh	0.4405 ± 0.0082	0.3984 ± 0.0176	0.9275 ± 0.0041	0.4177 ± 0.0075
	Chỉ văn bản	0.5401 ± 0.0149	0.4770 ± 0.0133	0.9393 ± 0.0020	0.5165 ± 0.0036
	Ảnh và bệnh sử xáo trộn khác lớp	0.3120 ± 0.0172	0.3039 ± 0.0048	0.8494 ± 0.0537	0.3098 ± 0.0264

Bảng C.2: So sánh giữa các phương thức đầu vào trên hai bộ dữ liệu BTXRD và CTCH

Trên CTCH, XBone-Net sử dụng đồng thời ảnh và bệnh sử đạt độ chính xác cân bằng $0,5844 \pm 0,0454$ và điểm F1 trung bình theo lớp $0,5558 \pm 0,0072$. Cấu hình chỉ ảnh đạt lần lượt $0,4405 \pm 0,0082$ và $0,3984 \pm 0,0176$, trong khi cấu hình chỉ bệnh sử đạt $0,5401 \pm 0,0149$ và $0,4770 \pm 0,0133$. Chênh lệch điểm F1 lần lượt là 0,1574 và 0,0788 điểm theo hướng có lợi cho thiết lập đa phương thức. Kết quả cho thấy toàn bộ thiết lập kết hợp ảnh và bệnh sử khai thác được thông tin bổ sung giữa hai nguồn, nhưng không tách riêng được ảnh hưởng của phương thức khỏi ảnh hưởng của pha khớp ảnh–văn bản.

Trên BTXRD, cấu hình ảnh kết hợp văn bản tổng hợp đạt điểm F1 trung bình theo lớp $0,6010 \pm 0,0034$, cao hơn cấu hình chỉ ảnh 0,2845 điểm và cao hơn cấu hình chỉ văn bản 0,0695 điểm. Kết quả cho thấy mô hình có thể khai thác quan hệ giữa ảnh và chuỗi văn bản trong thiết lập này. Tuy nhiên, văn bản BTXRD được sinh từ siêu dữ liệu và chịu ảnh hưởng của các cờ nhóm bệnh, do đó mức cải thiện không được diễn giải tương đương với lợi ích của bệnh sử lâm sàng tự nhiên trên CTCH.

Phân tích tính nhất quán ảnh-văn bản

Khi bệnh sử của mỗi mẫu CTCH được thay bằng bệnh sử của một mẫu thuộc lớp khác, điểm F1 trung bình theo lớp giảm từ $0,5558 \pm 0,0072$ xuống $0,3039 \pm 0,0048$. Trên BTXRD, điểm F1 giảm từ $0,6010 \pm 0,0034$ xuống $0,0068 \pm 0,0014$, đồng thời Macro-AUROC giảm từ $0,9243 \pm 0,0298$

xuống $0,4124 \pm 0,0644$. Phép can thiệp cho thấy mô hình nhảy với tính nhất quán của cặp ảnh–văn bản, thay vì chỉ hưởng lợi từ sự hiện diện độc lập của hai đầu vào.

Mức suy giảm trên BTXRD lớn hơn đáng kể so với CTCH vì phép ghép bắt buộc chọn văn bản khác lớp và văn bản tổng hợp mang tín hiệu liên hệ mạnh với nhãn. Do đó, kết quả BTXRD chỉ xác nhận độ nhảy của mô hình đối với quan hệ ghép cặp trong thiết lập văn bản có điều kiện theo siêu dữ liệu. Trên CTCH, sự suy giảm khi ghép sai cùng với kết quả đơn phương thức cho thấy mô hình sử dụng quan hệ ảnh–bệnh sử, nhưng chưa phải ước lượng đóng góp biên thuần túy của bệnh sử.

Tổng kết

Thiết lập đa phương thức có điểm F1 trung bình theo lớp quan sát được cao hơn các thiết lập đơn phương thức trên cả hai bộ dữ liệu, đồng thời phép ghép sai làm hiệu năng giảm rõ rệt. Do các đối chứng đơn phương thức không thực hiện pha khớp ảnh–văn bản và chưa có khoảng tin cậy ghép cặp kèm p-value cho phép so sánh này, kết quả chỉ cho thấy XBone-Net sử dụng quan hệ liên phương thức, không được dùng để khẳng định ưu thế thống kê của kiến trúc đa phương thức. CTCH là nguồn bằng chứng chính cho kịch bản bệnh sử thực, còn BTXRD chỉ phản ánh thiết lập văn bản tổng hợp có điều kiện.

C.2 Phân loại khi sử dụng toàn bộ dữ liệu huấn luyện

Bảng C.3 và Bảng C.4 trình bày năm độ đo phân loại của từng mô hình tại từng hạt giống. Việc giữ đồng thời Accuracy, Balanced Accuracy, Macro-F1, Macro-AUROC và Macro-AUPRC cho phép kiểm tra liệu thứ hạng trung bình trong Chương 4 có xuất hiện nhất quán hay phụ thuộc vào một lần khởi tạo cụ thể.

Bảng C.3: Kết quả phân loại của từng hạt giống trên BTXRD

Mô hình	Hạt giống	Accuracy	BAcc	Macro-F1	Macro-AUROC	Macro-AUPRC
BiomedCLIP	42	0,8320	0,5769	0,5870	0,8679	0,6395
BiomedCLIP	123	0,8280	0,6197	0,5993	0,8918	0,6542
BiomedCLIP	456	0,8333	0,6219	0,6118	0,8996	0,6595
CLIP	42	0,8200	0,5949	0,5722	0,9114	0,6342
CLIP	123	0,7720	0,5802	0,5574	0,8706	0,6192
CLIP	456	0,8187	0,6121	0,6064	0,9099	0,6219
DenseNet-121	42	0,6320	0,3644	0,3688	0,7916	0,3852
DenseNet-121	123	0,6333	0,3862	0,3904	0,7596	0,3790
DenseNet-121	456	0,6307	0,3575	0,3562	0,7639	0,3851
MedCLIP	42	0,8307	0,5860	0,5931	0,8221	0,6089
MedCLIP	123	0,8040	0,6204	0,6014	0,8736	0,6074
MedCLIP	456	0,8267	0,6310	0,6217	0,8838	0,6520
PubMedCLIP	42	0,7573	0,5716	0,5067	0,8856	0,5874
PubMedCLIP	123	0,7947	0,6163	0,5946	0,8970	0,6233
PubMedCLIP	456	0,8133	0,6388	0,6155	0,9317	0,6341
ResNet-50	42	0,6067	0,3031	0,3174	0,6947	0,3279
ResNet-50	123	0,6213	0,3253	0,3364	0,7447	0,3401
ResNet-50	456	0,5933	0,3278	0,3333	0,7313	0,3333
XBone-Net	42	0,8227	0,5960	0,6140	0,8201	0,5902
XBone-Net	123	0,8413	0,6230	0,6370	0,7883	0,5741
XBone-Net	456	0,8267	0,6155	0,6209	0,8052	0,5953

Bảng C.4: Kết quả phân loại của từng hạt giống trên CTCH

Mô hình	Hạt giống	Accuracy	BAcc	Macro-F1	Macro-AUROC	Macro-AUPRC
BiomedCLIP	42	0,5904	0,6203	0,5520	0,9559	0,6248
BiomedCLIP	123	0,5755	0,6107	0,5472	0,9555	0,6188
BiomedCLIP	456	0,6248	0,5758	0,5628	0,9057	0,6071
CLIP	42	0,5725	0,6579	0,5727	0,9547	0,6270
CLIP	123	0,5785	0,6209	0,5547	0,9478	0,6196
CLIP	456	0,6114	0,5862	0,5624	0,8845	0,5542
DenseNet-121	42	0,4813	0,5348	0,4610	0,9404	0,4917
DenseNet-121	123	0,4873	0,4435	0,4134	0,9323	0,4667
DenseNet-121	456	0,4768	0,4999	0,4356	0,9325	0,4703
MedCLIP	42	0,5590	0,5811	0,5265	0,9354	0,5973
MedCLIP	123	0,5979	0,5503	0,5285	0,8835	0,5628
MedCLIP	456	0,5202	0,5838	0,4902	0,9456	0,5916
PubMedCLIP	42	0,5306	0,6108	0,5313	0,9350	0,6073
PubMedCLIP	123	0,5486	0,4912	0,4902	0,9038	0,5683

Còn tiếp ở trang sau

Bảng C.4 (tiếp theo)

Mô hình	Hạt giống	Accuracy	BAcc	Macro-F1	Macro-AUROC	Macro-AUPRC
PubMedCLIP	456	0,5770	0,5747	0,5395	0,9448	0,5907
ResNet-50	42	0,4918	0,4238	0,4131	0,9130	0,4489
ResNet-50	123	0,4948	0,4027	0,4029	0,9118	0,4452
ResNet-50	456	0,4918	0,4114	0,4076	0,9188	0,4536
XBone-Net	42	0,6024	0,5788	0,5589	0,8990	0,5839
XBone-Net	123	0,6114	0,5966	0,5645	0,8943	0,5719
XBone-Net	456	0,6413	0,6051	0,5948	0,9127	0,6153

Các hàng XBone-Net trong hai bảng dùng đúng cấu hình hiện tại với chiến lược `direct_resize`, huấn luyện LoRA hai pha, chú ý chéo hai chiều và đầu phân lớp tuyến tính. Số liệu theo từng hạt giống xác nhận kết luận của chương chính rằng XBone-Net có hiệu năng phân loại cạnh tranh nhưng không dẫn đầu đồng thời trên mọi độ đo và mọi bộ dữ liệu.

C.3 Nghiên cứu loại bỏ từng thành phần

Bảng C.5 trình bày kết quả của XBone-Net và hai biến thể được dùng trực tiếp để trả lời RQ2 tại từng hạt giống trên CTCH. Biến thể Chỉ pha 2 loại bỏ pha thích nghi tương phản, còn biến thể Nối đặc trưng thay chú ý chéo hai chiều bằng phép nối đặc trưng. Số liệu xác nhận rằng cấu hình đầy đủ đạt Accuracy trung bình cao nhất, trong khi Nối đặc trưng thuận lợi hơn ở Balanced Accuracy, Macro-AUROC và Macro-AUPRC. Vì vậy, không thành phần nào tạo ưu thế đồng thời trên toàn bộ độ đo.

Cấu hình	Hạt giống	Accuracy	BAcc	Macro-F1	Macro-AUROC	Macro-AUPRC
XBone-Net	42	0,6024	0,5788	0,5589	0,8990	0,5839
XBone-Net	123	0,6114	0,5966	0,5645	0,8943	0,5719
XBone-Net	456	0,6413	0,6051	0,5948	0,9127	0,6153
Chỉ pha 2	42	0,6173	0,5611	0,5767	0,9200	0,6097
Chỉ pha 2	123	0,6188	0,5904	0,5815	0,9093	0,5975
Chỉ pha 2	456	0,5934	0,6067	0,5604	0,9352	0,6176
Nối đặc trưng	42	0,5605	0,6274	0,5529	0,9493	0,6204
Nối đặc trưng	123	0,5830	0,5990	0,5596	0,9291	0,6164
Nối đặc trưng	456	0,5904	0,6333	0,5741	0,9399	0,6236

Bảng C.5: Kết quả phân loại của từng hạt giống trong nghiên cứu loại bỏ thành phần trên CTCH. Cấu hình đầy đủ được tô xám.

C.4 Kết quả đánh giá dữ liệu ngoài phân phối

Bảng C.6 công bố kết quả theo từng hạt giống của XBone-Net và hai biến thể trên kịch bản OOD ngữ nghĩa và BTXRD. Cả ba cấu hình sử dụng cùng điểm tổ hợp đa phương thức hậu xử lý. Số mẫu trong phân phối và ngoài phân phối được ghi trực tiếp trong bảng vì AUPR-Out và $FPR@95\%TPR$ chịu ảnh hưởng bởi số lượng và tỷ lệ mẫu của từng kịch bản.

Mỗi lần đánh giá sử dụng 669 mẫu CTCH trong phân phối. Kịch bản OOD ngữ nghĩa sử dụng đủ 26 mẫu đã được xác nhận trong danh sách đánh giá và kịch bản BTXRD sử dụng đủ 750 mẫu ngoài phân phối. AUPR-Out và $FPR@95\%TPR$ chịu ảnh hưởng của chênh lệch quy mô và tỷ lệ mẫu trong-ngoài phân phối giữa hai kịch bản, vì vậy kết luận được đưa ra cùng AUROC-ODD và cỡ mẫu ghi trong bảng. Kết quả xác nhận cảnh báo OOD có hiệu lực rõ hơn trong dịch chuyển khác bộ dữ liệu, còn kịch bản OOD ngữ nghĩa gần miền vẫn có $FPR@95\%TPR$ cao.

Kịch bản	Cấu hình	Hạt giống	N_{ID}	N_{OOD}	AUROC- OOD	AUPR- Out	FPR@ 95%TPR
OOD CTCH	XBone-Net	42	669	26	0,7135	0,1559	0,7308
	XBone-Net	123	669	26	0,7666	0,1395	0,7308
	XBone-Net	456	669	26	0,6950	0,1399	0,6538
	Chỉ pha 2	42	669	26	0,7589	0,1946	0,6538
	Chỉ pha 2	123	669	26	0,7097	0,2039	0,6154
	Chỉ pha 2	456	669	26	0,7033	0,1949	0,7692
	Nối đặc trưng	42	669	26	0,7321	0,1166	0,7308
	Nối đặc trưng	123	669	26	0,7484	0,1285	0,7308
	Nối đặc trưng	456	669	26	0,7212	0,1046	0,6923

Bảng C.6: Kết quả cảnh báo OOD của từng hạt giống trên kịch bản OOD CTCH bằng điểm tổ hợp đa phương thức

Kịch bản	Cấu hình	Hạt giống	N_{ID}	N_{OOD}	AUROC- OOD	AUPR- Out	FPR@ 95%TPR
BTXRD	XBone-Net	42	669	750	0,9142	0,8873	0,4773
	XBone-Net	123	669	750	0,9490	0,9214	0,2520
	XBone-Net	456	669	750	0,9330	0,9069	0,3520
	Chỉ pha 2	42	669	750	0,9536	0,9250	0,2693
	Chỉ pha 2	123	669	750	0,9553	0,9361	0,2307
	Chỉ pha 2	456	669	750	0,9450	0,9256	0,2427
	Nối đặc trưng	42	669	750	0,9336	0,9054	0,4347
	Nối đặc trưng	123	669	750	0,9422	0,9094	0,4867
	Nối đặc trưng	456	669	750	0,9418	0,9096	0,3653

Bảng C.7: Kết quả cảnh báo OOD của từng hạt giống trên kịch bản BTXRD bằng điểm tổ hợp đa phương thức