

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - Nguyễn Gia
Kiệt

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - 22127390

Nguyễn Gia Kiệt - 22127221

**PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

GIÁO VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

Tp. Hồ Chí Minh, tháng 07/2026

Lời cam đoan

Nhóm xin cam đoan đây là công trình nghiên cứu của riêng nhóm. Dữ liệu và kết quả nghiên cứu trong luận văn này là trung thực và không trùng lặp với bất kỳ chủ đề nào khác. Nhóm cam đoan toàn bộ nội dung luận văn này không đạo văn hoặc sao chép từ các công trình nghiên cứu khác. Ngoài ra, trong quá trình nghiên cứu và viết luận văn, nhóm tuân thủ nghiêm ngặt các quy định về bảo mật do các tập dữ liệu nhóm sử dụng trong nghiên cứu của mình cung cấp. Hơn nữa, nhóm luôn tuân thủ mọi nguyên tắc đạo đức trong suốt quá trình nghiên cứu. Nhóm đảm bảo rằng tất cả các nguồn và tài liệu tham khảo đều được trích dẫn đúng cách và nhóm duy trì tính chính trực học thuật trong mọi khía cạnh công việc của mình.

Lời cảm ơn

Nhóm xin chân thành cảm ơn PGS.TS Lý Quốc Ngọc và ThS. Đỗ Thị Thanh Hà đã dành rất nhiều thời gian, tâm huyết để định hướng, tận tình hướng dẫn và đưa ra những lời khuyên quý báu cho nhóm trong suốt quá trình nghiên cứu và thực hiện khóa luận tốt nghiệp với đề tài "Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức".

Xin trân trọng gửi lời cảm ơn sâu sắc đến Ban Chủ nhiệm cùng toàn thể quý thầy cô Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG-HCM. Những kiến thức nền tảng vững chắc mà các thầy cô đã truyền đạt trong bốn năm học vừa qua và môi trường thí nghiệm tuyệt vời chính là hành trang quan trọng nhất giúp nhóm có thể hoàn thành tốt hướng nghiên cứu này.

Nhóm cũng xin gửi lời cảm ơn đến các y bác sĩ tại Bệnh viện Chấn thương Chỉnh hình TP.HCM, thầy Đỗ Phúc Thịnh và thầy Võ Thế Hào đã hỗ trợ chia sẻ nguồn dữ liệu ảnh X-quang cũng như tư vấn các kiến thức chuyên môn về y khoa, giúp mô hình nghiên cứu bám sát với quy trình chẩn đoán thực tế.

Mặc dù đã có nhiều cố gắng trong quá trình thực hiện, nhưng do hạn chế về mặt thời gian và kinh nghiệm nghiên cứu, khóa luận chắc chắn không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô và hội đồng đánh giá để đề tài được hoàn thiện hơn.

Xin chân thành cảm ơn!



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO HỌC SÂU ĐA PHƯƠNG THỨC

*(Developing a bone X-ray image classification
system based on multimodal deep learning)*

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm Sinh viên thực hiện:

1. Nguyễn Văn Lê Bá Thành (MSSV: 22127390)
2. Nguyễn Gia Kiệt (MSSV: 22127221)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 02/2026 đến 08/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn đầu. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, các nghiên cứu hiện nay đã ứng dụng các mô hình học sâu vào để giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ để đưa vào ứng dụng thực tế. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để bổ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác. Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống.

Khác với các mô hình đơn phương thức chỉ xử lý trên một phương thức như ảnh hay văn bản duy nhất, các mô hình đa phương thức có thể sử dụng nhiều phương thức và tìm ra sự tương quan giữa các phương thức nhằm tạo nên biểu diễn có ý nghĩa hơn từ đó nâng cao hiệu năng của hệ thống. Với thực tế lâm sàng hiện nay, các mô hình nghiên cứu tập trung

vào kết hợp ngôn ngữ và hình ảnh hay còn được gọi là mô hình ngôn ngữ trực quan đang là các mô hình đang nhận được nhiều sự chú ý.

2.2 Định nghĩa các khái niệm

Thông tin lâm sàng

Thông tin lâm sàng là những dữ liệu thu thập trực tiếp qua quá trình bác sĩ thăm khám người bệnh, bao gồm việc khai thác bệnh sử và khám thực thể (nhìn, sờ, gõ, nghe) [44]. Dữ liệu này mang tính chất định hướng ban đầu, giúp bác sĩ khoanh vùng tổn thương và đưa ra các quyết định chỉ định thăm khám chuyên sâu tiếp theo [4].

Thông tin cận lâm sàng

Thông tin cận lâm sàng là các dữ liệu khách quan thu được từ việc áp dụng các trang thiết bị và kỹ thuật y khoa hiện đại (như hình ảnh X-quang, cắt lớp, hay xét nghiệm sinh hóa) [44]. Nếu lâm sàng dùng để định hướng, thì cận lâm sàng cung cấp bằng chứng xác thực từ bên trong cơ thể để chẩn đoán chính xác bệnh lý.

2.3 Phát biểu bài toán

Đầu vào (Input)

Hệ thống nhận vào các nguồn dữ liệu sau:

- Thông tin lâm sàng bao gồm báo cáo cận lâm sàng, khám xét toàn thân, lý do vào viện của bệnh nhân.
- Ảnh X-quang xương của bệnh nhân tương ứng.
- Tập nhãn được định nghĩa trước.


Đầu ra (Output)

Hệ thống sẽ sinh ra các nhãn sau:

- Tỷ lệ mà ảnh và thông tin lâm sàng tương ứng thuộc vào các lớp được định nghĩa trước.
- Ảnh trực quan hóa giải thích cho kết quả.

Kiến trúc tổng quan

Với bài toán này, kiến trúc tổng quan của một mô hình học sâu đa phương thức được sử dụng bao gồm bốn thành phần chính: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại như được thể hiện ở Hình 1.



Hình 1: Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức

Trong đó, bộ mã hóa ảnh có chức năng rút trích đặc trưng từ ảnh đầu vào, bộ mã hóa văn bản có chức năng rút trích đặc trưng từ văn bản đầu vào, bộ dung hợp dữ liệu có chức năng dung hợp hay căn chỉnh các đặc trưng được rút trích từ hai phương thức dữ liệu trên để tạo ra một biểu diễn có ý nghĩa và có đầy đủ tính chất của phương thức đầu vào, đây cũng là mô-đun quan trọng nhất đối với một mô hình học sâu đa phương thức, cuối cùng là bộ phân loại, nhận biểu diễn đặc trưng chung của các phương thức đầu vào để phân loại và đưa ra kết quả cuối cùng.

2.4 Mục tiêu đề tài

Trong bối cảnh già hóa dân số và các tác nhân gây bệnh từ ô nhiễm và lối sống thiếu lành mạnh trong đời sống hiện đại, các bệnh lý về xương và chấn thương có thể ảnh hưởng trực tiếp đến đời sống và tính mạng dẫn đến việc chẩn đoán và tiên lượng để đưa ra hướng điều trị phù hợp đang trở thành gánh nặng cho các y bác sĩ, các hệ thống học sâu đa phương

thức tuy đã phát triển nhưng lại thiếu khả năng giải thích. Đề tài hướng đến phát triển một hệ thống phân loại ảnh X-quang có khả năng:

- Đạt được độ chính xác cao trên các bộ dữ liệu nội bộ và quốc tế.
- Có khả năng giải thích được kết quả.
- Tích hợp kết quả để trợ giúp y bác sĩ trong quá trình chẩn đoán.

2.5 Phạm vi của đề tài

Nội dung nghiên cứu của đề tài tập trung vào việc khảo sát các mô hình nền tảng và thiết kế, huấn luyện, tinh chỉnh, đánh giá kiến trúc được đề xuất trên ảnh X-quang xương và các bộ dữ liệu quốc tế để so sánh, đánh giá với các kiến trúc trước.

Đối tượng nghiên cứu xoay quanh các thành phần bên trong một mạng học sâu đa phương thức bao gồm: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại, tập trung vào các phương pháp dung hợp dữ liệu hình ảnh và văn bản cùng với các phương pháp tinh chỉnh tham số cho các bộ mã hóa đã được huấn luyện trước nhằm tận dụng lại các tri thức đã có và nâng cao hiệu năng trên các tác vụ đích.

Đề tài chủ yếu sử dụng các bộ dữ liệu cặp ảnh - văn bản, không có trường hợp thiếu đã được công bố và bộ dữ liệu nội bộ được thu thập và cung cấp bởi giảng viên có hợp tác với bệnh viện ở khu vực Thành phố Hồ Chí Minh, một số thông tin cơ bản về các bộ dữ liệu được thể hiện ở Bảng 1. Nhóm sử dụng các bộ dữ liệu này nhằm đánh giá hiệu năng của kiến trúc đề xuất thông qua các độ đo phổ biến và tiến hành so sánh với các phương pháp trước đó nhằm chứng minh sự hiệu quả của phương pháp đề xuất.

2.6 Cách tiếp cận dự kiến

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ cung cấp tổng quan tình hình nghiên cứu

Bộ dữ liệu	Nguồn	Loại dữ liệu	Số lượng mẫu	Số lượng lớp
RSNA Pneumonia (2018)	Radiological Society of North America	Ảnh X-quang ngực metadata/tags	30,000	3
CheXpert (2019)	Stanford ML Group - Stanford Hospital	Ảnh X-quang ngực Báo cáo đọc ảnh	224,316	14
MIMIC-CXR v2 (2019)	Beth Israel Deaconess Medical Center	Ảnh X-quang ngực Báo cáo đọc ảnh	227,835	14
SARCOMA-CTCH (2025)	Bệnh viện Chấn Thương Chỉnh Hình - TPHCM	Ảnh X-quang xương Báo cáo đọc ảnh Báo cáo lâm sàng	Đang cập nhật	Đang cập nhật

Bảng 1: Tổng hợp các bộ dữ liệu dự kiến được sử dụng để thí nghiệm

từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

Các mô hình xây dựng từ đầu là các mô hình đơn giản, khởi điểm trong bài toán học sâu đa phương thức, thiết kế và huấn luyện một hệ thống mới từ đầu, điểm chung của các phương pháp này là chúng tập trung vào việc thiết kế các cơ chế để "trộn" (fusion) đặc trưng từ các bộ mã hóa (encoder) chuyên biệt ở các cấp độ khác nhau để tối ưu hóa hiệu suất cho các tác vụ cụ thể, sử dụng những bộ mã hóa hình ảnh đơn giản như CNN.

Khởi điểm vào 2020, X. Mei [29] và đồng nghiệp đã đề xuất lấy đặc trưng được tạo ra từ các lớp cuối của mô hình CNN (véc-tơ 512 chiều) và các đặc trưng từ dữ liệu lâm sàng rồi nối lại. Véc-tơ kết hợp này được đưa vào một mạng MLP cuối cùng để đưa ra dự đoán.

Clinical-BERT [46] và TGANet [39] tìm cách học biểu diễn đa phương thức bằng cách thúc đẩy mô hình hiểu và liên kết (align) các đặc trưng giữa các vùng trong ảnh và các từ khóa trong văn bản báo cáo thông qua các nhiệm vụ tự giám sát (self-supervised objectives), cho phép mô hình học được các biểu diễn ngữ nghĩa chung. Hay LViT [25] đề xuất một kiến trúc hybrid CNN-Transformer "Double-U", cấu trúc CNN-Transformer kết hợp mô-đun Pixel-Level Attention Module để giữ lại các đặc trưng cục bộ của ảnh giúp mô hình giữ được khả năng trích xuất đặc trưng cục bộ mạnh mẽ của CNN, đồng thời tận dụng khả năng mô hình hóa ngữ cảnh toàn cục của Transformer.

Việc chỉ nối các đặc trưng có điểm yếu về sự khác biệt về giá trị hoặc sự ngữ nghĩa lớn giữa các phương thức dữ liệu, IRENE [56] đã đưa tất

cả dữ liệu gốc về dạng token chung và học biểu diễn tổng thể (holistic representation) ngay từ đầu, sử dụng một mô hình Transformer duy nhất học các biểu diễn toàn diện cho cả hai phương thức. IRENE còn sử dụng cơ chế chú ý hai chiều ở cấp độ token để nắm bắt "các kết nối cục bộ".

Nghiên cứu của Dai và cộng sự [8] đề xuất mô hình TransMed, giải quyết bài toán kết hợp đa phương thức bằng cách tích hợp CNN và Transformer. Bằng việc chuyển đổi đặc trưng ảnh từ CNN thành dạng chuỗi để Transformer xử lý, mô hình này tối ưu hóa việc nắm bắt các đặc điểm toàn cục của hình ảnh y khoa. Cách tiếp cận này mang lại hiệu quả cao hơn các kỹ thuật fusion thông thường nhờ khả năng biểu diễn dữ liệu đa phương thức một cách toàn diện và chính xác.

Những nghiên cứu này đã khai phá và chứng minh về tác động tích cực của các phương thức dữ liệu khác như văn bản đến kết quả của việc chẩn đoán hình ảnh, tuy nhiên độ chính xác của các phương thức này còn chưa quá cao bởi các bộ mã hóa và phương pháp dung hợp dữ liệu còn đơn giản.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Kiến trúc mô hình			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	X. Mei [29]	Full Fine-Tuning	Pretrain với Cross-Entropy loss	Inception-ResNet-v2	ResNet-18	Decision-level	N/a
2	Clinical-BERT [46]	Full Fine-Tuning	Cross-modal Repr. Learning	DenseNet121	Uncased BERT-base	Early fusion	N/a
3	LViT [25]	Full Fine-Tuning	Semi-supervised (Pseudo-label)	Hybrid U-shape (CNN + ViT)	BERT_12_768_12	Intermediate	N/a
4	TGANet [39]	Train from scratch	Exponential Pseudo-label Iteration	ResNet50	Không có	Intermediate	N/a
5	IRENE [56]	Train from scratch	BCE Loss & AdamW optimizer	Convolution layer	Pretrained BERT	Simultaneous	Upsampling, FEM, CBAM Attention
6	TransMed [8]	Full Fine-Tuning	Supervised (SGD, 100 epochs)	2D CNN (ResNet18 đến 152)	N/a	Attention fusion	Lớp kết nối đầy đủ (FC Layer)

Bảng 2: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tinh chỉnh của các mô hình kết hợp ngôn ngữ - ảnh

Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu (thường cố gắng dung hợp dữ liệu thô thành một khối thống nhất), Med-VLMs chú trọng vào việc đối chiếu và liên kết chặt chẽ ngữ nghĩa giữa hình ảnh và ngôn ngữ tự nhiên. Cụ thể, kiến trúc của chúng thường kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này khớp với

nhau. Lúc này, bộ phân loại không gán nhãn theo cách truyền thống mà đóng vai trò là một cơ chế đo lường mức độ tương đồng. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Để đạt được khả năng trên, các nghiên cứu tiền huấn luyện Med-VLMs hiện nay đang phát triển chủ yếu theo ba hướng: học tương phản, học có che giấu và tích hợp tri thức y khoa (chi tiết tổng hợp được trình bày tại các Bảng 3, 4, 5).

Thứ nhất, **học tương phản (Contrastive Learning)** là chiến lược được ứng dụng rộng rãi nhất, tiêu biểu với các mô hình như ConVIRT [52], GLoRIA [16], MedCLIP [43] và BiomedCLIP [50]. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau ở mức độ cục bộ lẫn toàn cục. Phương pháp này đem lại hiệu năng ấn tượng; ví dụ, BiomedCLIP [50] (huấn luyện trên 15 triệu cặp dữ liệu) đạt độ chính xác phân loại 83%, trong khi ConVIRT [52] đạt 90,3% trên bộ dữ liệu COVIDx. Mặc dù có ưu điểm vượt trội là khả năng học biểu diễn không cần gán nhãn thủ công, học tương phản vẫn bộc lộ hạn chế về việc tiêu tốn tài nguyên tính toán lớn và rủi ro xảy ra hiện tượng âm tính giả (đẩy xa các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý).

Thứ hai, **học có che giấu (Masked Learning)** là hướng đi tập trung vào mục tiêu tái tạo dữ liệu, với các đại diện nổi bật như MRM [57] và MedViLL [31]. Bằng cách ẩn ngẫu nhiên các vùng ảnh hoặc từ ngữ trong báo cáo y khoa, kiến trúc này buộc mô hình phải dự đoán và khôi phục phần thông tin bị khuyết. Hướng tiếp cận này thể hiện ưu thế rõ rệt trong các môi trường khan hiếm dữ liệu; điển hình là MRM [57] đạt mức 92,7% AUC chỉ với 10% dữ liệu từ tập RSNA. Tuy nhiên, rào cản chính của phương pháp này nằm ở việc phụ thuộc vào nguồn dữ liệu đã được ghép cặp sẵn từ trước, cộng với độ phức tạp tính toán cao của quá trình khôi phục điểm ảnh/token.

Thứ ba, **tích hợp tri thức y khoa (Knowledge Integration)** ra đời nhằm giải quyết những đặc thù phức tạp của ngôn ngữ lâm sàng. Các

mô hình như MedKLIP [45], BioViL [5], BioViL-T [3] và KAD [51] tận dụng đồ thị tri thức (như RadGraph) hoặc dữ liệu chuỗi thời gian để cung cấp tín hiệu giám sát chi tiết về cả loại và vị trí bệnh lý. Cách tiếp cận này giúp giải quyết triệt để sự mơ hồ của các từ vựng diễn tả tiến triển bệnh (ví dụ: "cải thiện", "xấu đi"). Về mặt hiệu năng, KAD [51] đạt 0.966 AUC trên tập PadChest ở thiết lập không mẫu (zero-shot), còn BioViL-T [3] đạt độ chính xác 67,4% trong bài toán phân loại tiến triển bệnh. Dù vậy, các phương pháp này chưa loại bỏ hoàn toàn được hiện tượng âm tính giả và rất dễ gặp sai số nếu nhãn chẩn đoán thực tế nằm ngoài cơ sở tri thức đồ thị gốc.

Dựa trên sự phân tích các ưu và nhược điểm từ những khảo sát trên, hướng tiếp cận đề xuất trong nghiên cứu này được thiết kế có chọn lọc nhằm tối ưu hóa hiệu năng và chi phí:

- **Kế thừa BiomedCLIP [50]:** Tận dụng sức mạnh của các bộ mã hóa đã được huấn luyện với chất lượng cao.
- **Không áp dụng học tương phản & học có che giấu:** Khó khắc phục rào cản về tài nguyên tính toán lớn và giảm thiểu rủi ro gặp phải hiện tượng âm tính giả.
- **Tích hợp tri thức từ UMLS (tương tự MedKLIP [45]):** Sử dụng để làm giàu thêm tri thức trong các báo cáo lâm sàng.

Mặc dù các phương pháp tiền huấn luyện Med-VLMs giúp xây dựng nền tảng tri thức đa phương thức khổng lồ, việc áp dụng trực tiếp vào lâm sàng lại vấp phải rào cản lớn về chi phí tính toán và sự khan hiếm dữ liệu y tế ghép cặp. Để giải quyết vấn đề này, các nghiên cứu thường chuyển hướng sang tinh chỉnh mô hình. Tuy nhiên, nếu tinh chỉnh toàn phần trên một tập dữ liệu nhỏ, sự chênh lệch phân phối sẽ dễ dẫn đến hiện tượng chuyển giao tiêu cực hoặc "quên thảm khốc", làm đánh mất tri thức gốc. Do đó, giới nghiên cứu đang tập trung vào các chiến lược tinh chỉnh hiệu quả tham số (PEFT) nhằm đảm bảo tính linh hoạt, tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các nghiên cứu gần đây được chia thành ba hướng tiếp cận chính:

STT	Tên phương pháp	Phân loại	Nguyên lý
1	ConVIRT (2020)	Học tương phản	Tối ưu bộ mã hoá ảnh và văn bản bằng cách kéo các cặp đặc trưng ảnh-văn bản giống nhau lại gần nhau và đẩy các cặp đặc trưng ảnh-văn bản khác nhau ra xa
2	GLoRIA (2021)	Học tương phản	Dùng hai hàm mất mát global contrastive để kéo các cặp đặc trưng ảnh-văn bản, trong khi đó hàm mất mát local contrastive học cách căn chỉnh chi tiết của các vùng trong ảnh và các từ trong câu
3	MedCLIP (2022)	Học tương phản	Đề xuất cơ chế tách cặp và trích xuất tri thức, và đề xuất hàm mất mát Semantic Matching nhằm giải quyết vấn đề false negative
4	BiomedCLIP (2023)	Học tương phản	Có cơ chế tương tự như CLIP nhưng được tiền huấn luyện với bộ dữ liệu PMC-15M
5	MRM (2023)	Học có che giấu	Ẩn ngẫu nhiên các thông tin trong văn bản và các vùng trong ảnh để cho mô hình dự đoán lại ảnh và văn bản hoàn chỉnh.
6	MedViLL (2022)	Học có che giấu	Đề xuất một kiến trúc dựa trên BERT kết hợp với một mặt nạ chú ý mới được đề xuất (BAR) cho phép ảnh tương tác tự do với văn bản trong các tác vụ hiểu, đồng thời đảm bảo tính tự hồi quy cho các token trong văn bản trong các tác vụ sinh
7	BioViL (2022)	Tích hợp kiến thức y khoa	Đề xuất một bộ mã hoá văn bản CXR-BERT được tối ưu cho ảnh X-quang, duy trì hàm mất mát MLM để giúp mô hình giữ lại được các kiến thức văn bản trong quá trình căn chỉnh với ảnh
8	BioViL-T (2023)	Tích hợp kiến thức y khoa	Sử dụng các ảnh X-quang từ trước kết hợp với ảnh hiện tại để học được các đặc trưng không gian, thời gian từ đó giải thích cho các từ vựng như "cải thiện" giúp giảm đi sự mơ hồ trong báo cáo
9	MedKLIP (2023)	Tích hợp kiến thức y khoa	Đề xuất một mô-đun trích xuất bộ ba và cơ chế mã hoá tăng cường tri thức, từ đó tạo ra biểu diễn tốt hơn cho văn bản
10	KAD (2023)	Tích hợp kiến thức y khoa	Tích hợp kiến thức y khoa vào quá trình tiền huấn luyện để giúp mô hình học các biểu diễn có ý nghĩa hơn

Bảng 3: Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Mục tiêu tiền huấn luyện	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	CL	GCL	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	CL	LCL, GCL	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	CL	GCL	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	CL	GCL	ViT-Base	PubMedBERT	Contrastive Alignment	N/a
5	MRM (2023)	MP	MIM, MLM	Kiến trúc giống ViT	WordPiece	Global Context Injection	Văn bản: Transformer; Hình ảnh: Fully Connected
6	MedViLL (2022)	HA	MLM, ITM	ResNet50	BERT	Cross-modal Self-Attention	Multi-Layer Perceptron
7	BioViL (2022)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
8	BioViL-T (2023)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
9	MedKLIP (2023)	CL	LCL	ResNet50	ClinicalBERT	Knowledge-enhanced Alignment	Contrastive head, Cross-Entropy head
10	KAD (2023)	HA	CL, Disease Diagnosis Prediction	ResNet50, ViT-Base	PubMedBERT	Contrastive Alignment	Disease Query Network

Bảng 4: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;

STT	Tên phương pháp	Bộ dữ liệu tiền huấn luyện	Hiệu năng			
			Tác vụ	Bộ dữ liệu đánh giá	Độ đo	Kết quả
1	ConVIRT (2020)	MIMIC-CXR, Private Bone image	- Phân loại ảnh - Phân loại ít mẫu	RSNA Pneumonia, CheXpert, COVIDx, MURA	AUC, Accuracy	- Phân loại ít mẫu: RSNA (1%): 88.8% AUC, (10%): 91.5% AUC; CheXpert (1%): 87.0% AUC, (10%): 88.1% AUC; MURA (1%): 81.3% AUC, (10%): 86.5% AUC - Phân loại ảnh: RSNA: 92.7% AUC, CheXpert: 88.1% AUC, MURA: 89.0% AUC; COVIDx 90.3% ACC
2	GLoRIA (2021)	CheXpert	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	CheXpert, RSNA Pneumonia	AUROC	- Phân loại không mẫu: CheXpert 5x200: 0.61 ACC, 0.67 F1; RSNA: 0.70 ACC, 0.58 F1; - Phân loại ít mẫu: CheXpert (1%): 86.6 AUC, (10%): 87.8 AUC, RSNA (1%): 86.1 AUC, (10%) 88.0 AUC - Phân loại ảnh: CheXpert: 88.1 AUC, RSNA: 88.6 AUC
3	MedCLIP (2022)	MIMIC-CXR, CheXpert	- Phân loại ảnh - Phân loại không mẫu	MIMIC-5x200, COVID, RSNA Pneumonia	Mean Accuracy	- Phân loại không mẫu: CheXpert-5x200: 0.5942 ACC; MIMIC-5x200: 0.5430 ACC; COVID: 0.8472 ACC; RSNA: 0.7682 ACC - Phân loại ảnh: CheXpert-5x200: 0.5960 ACC; MIMIC-5x200: 0.5650 ACC; COVID: 0.7890 ACC; RSNA: 0.8075 ACC
4	BiomedCLIP (2023)	PMC-15M	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PCam, LC25000 (Lung, Colon), TCGA-TIL, RSNA Pneumonia	AUC, Accuracy	- Phân loại không mẫu: PCam: 73.41% ACC; LC25000 Lung 65.23% ACC; LC25000 Colon 92.98%; RSNA 78.95%; TCGA-TIL: 67.04% - Phân loại ít mẫu: PCam (1%): 82% ACC, (10%): 83%; RSNA (1%): 77% ACC, (10%): 82% ACC - Phân loại ảnh: PCam: 83% ACC, RSNA: 83% ACC
5	MRM (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu	CheXpert, NIH ChestX-ray, RSNA Pneumonia, COVID-19 Image Data Collection	AUC, Accuracy	- Phân loại ít mẫu: CheXpert (1%): 88.5 AUC, (10%): 88.5 AUC; RSNA (1%): 91.3 AUC, (10%): 92.7 AUC; NIH ChestX-ray (1%): 79.4 AUC, (10%): 84.0 AUC - Phân loại ảnh: CheXpert: 88.7 AUC, RSNA 93.3, NIH ChestX-ray: 85.9, COVID-19: 85.8
6	MedViLL (2022)	MIMIC-CXR	- Phân loại chẩn đoán	MIMIC-CXR, Open-I	Micro-averaged AUROC, Micro-averaged F1 score	- Phân loại ảnh: MIMIC-CXR: 0.980 avg AUROC, 0.839 F1; Open-I: 0.892 avg AUROC, 0.407 F1
7	BioViL (2022)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	RSNA Pneumonia	Accuracy, F1-score, AUROC, Sensitivity Specificity.	- Phân loại không mẫu: RSNA: 0.732 ACC, 0.831 AUC; ChestX-ray14: 0.6912 AUC - Phân loại ít mẫu: RSNA (1%): 0.805 ACC, 0.881 AUC; (10%): 0.812 ACC, 0.884 AUC - Phân loại ảnh: RSNA: 0.822 ACC, 0.891 AUC
8	BioViL-T (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu - Phân loại ảnh tiến triển	MS-CXR-T, RSNA Penumonia, Chest ImaGenome	Macro-Accuracy, Accuracy, F1, AUROC.	- Phân loại Tiến triển: MS-CXR-T: 67.4% Acc - Phân loại không mẫu: RSNA: 0.805 ACC, 0.871 AUC - Phân loại ít mẫu: RSNA (1%): 0.814 ACC, 0.890 AUC
9	MedKLIP (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại không mẫu	ChestX-ray14, RSNA Pneumonia, SIIM-ACR Pneumothorax, COVIDx CXR-2, COVID Rural, Edema Severity	AUC, F1-score, Accuracy.	- Phân loại không mẫu: RSNA: 0.8694 AUC, 0.6342 F1; SIIM-ACR: 0.8924 AUC, 0.6833 F1; ChestX-ray14: 0.7676 AUC, 0.2525 F1; COVID-19: 0.7396 AUC, 0.7670 F1 - Phân loại ít mẫu: ChestX-ray14 (1%): 0.7721 AUC, (10%): 0.7894; RSNA (1%): 0.8731 AUC, (10%): 0.8799 AUC - Phân loại mẫu: ChestX-ray14: 0.8323 AUC, RSNA 0.8931
10	KAD (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PadChest, NIH ChestXray14, CheXpert, ChestX-Det	AUC, F1-Score, MCC	- Phân loại không mẫu: PadChest: 0.966 AUC; CheXpert: 0.905 AUC, 0.647 F1, 0.589 MCC - Phân loại ít mẫu: ChestXray-14 (1%): 0.78 AUC, 0.31 F1; (10%): 0.80 AUC, 0.33 F1 - Phân loại ảnh: ChestXray-14: 0.82 AUC, 0.34 F1

Bảng 5: Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

Tinh chỉnh sử dụng câu nhắc (Prompt Tuning): Hướng này chèn thêm các tham số có thể học được vào không gian đầu vào của mô hình. Các phương pháp như CITE [53], FPT [17] hay PLIP [49] khai thác đặc trưng thị giác kết hợp với tri thức lâm sàng, cho thấy hiệu quả vượt trội ngay cả khi thiếu hụt dữ liệu (ví dụ: PLIP đạt 0.896 AUC chỉ với 5% dữ liệu PanNuke). Nhằm giải quyết khó khăn khi thiết kế thủ công, MedPrompt [54] và UniDCP [48] tự động sinh câu nhắc động dựa trên ngữ cảnh ảnh để xử lý đa tác vụ. Gần đây hơn, việc tích hợp Mô hình ngôn ngữ Lớn (LLM) qua ViP [10], CILMP [9] và BiomedCoOp [20] giúp tạo sinh các câu nhắc ngữ nghĩa sâu sắc, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản, mang lại hiệu năng cao trong các kịch bản ít mẫu hoặc không mẫu.

Tinh chỉnh bộ điều hợp (Adapter Tuning): Thay vì can thiệp ở đầu vào, phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ giữa các lớp của kiến trúc gốc. Điển hình, CLIPath [21] sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu nhỏ; FTB [33] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức. Ở hướng bán giám sát, mô hình MedUnA [34] dùng LLM tạo nhãn giả và tinh chỉnh không giám sát bộ điều hợp trên ảnh chưa gán nhãn, giúp mô hình thích ứng tốt mà không thay đổi trọng số.

Tinh chỉnh chọn lọc (Selective Tuning): Hướng đi này tối ưu hóa kiến trúc bằng cách chỉ cập nhật một lượng nhỏ các trọng số quyết định hiệu năng. TransMed [55] kết hợp LLM để chuyển đổi nhãn bệnh thành mô tả chi tiết, trong khi SH-PEFT [27] chỉ tìm và cập nhật các trọng số quan trọng nhất trên bộ mã hóa thị giác nhằm khai thác tính thừa thớt của mạng. Tương tự, LCBP [26] áp dụng kỹ thuật LoRA để tinh chỉnh tham số hiệu quả cho Med-VLMs, giúp bám sát hiệu năng của tinh chỉnh toàn phần (đạt 93.1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn) nhưng giảm thiểu tối đa chi phí tính toán.

Tóm lại, các phương pháp tinh chỉnh hiệu quả tham số (PEFT) thể hiện ưu điểm vượt trội trong việc tiết kiệm tài nguyên tính toán, ngăn chặn hiện tượng quên tri thức và giúp mô hình thích ứng tốt ngay cả khi đối mặt với các bộ dữ liệu y tế khan hiếm. Tuy nhiên, hướng tiếp cận này vẫn tồn tại một số hạn chế nhất định. Hiệu năng cuối cùng của hệ thống phụ thuộc rất lớn vào chất lượng của mô hình tiền huấn luyện gốc. Đồng

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	CITE (2023)	Parameter-efficient fine tuning	Visual prompt tuning	CLIP ViT-Base, ImageNet-21k ViT-Base, INTERN ViT-Base	BioLinkBERT-large, BioBERT-large, Kế thừa CLIP	Contrastive Alignment	N/a
2	UniDCP (2023)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	CLIP ViT	RoBERTa	Cross Attention, Contrastive Alignment	N/a
3	ViP (2024)	Parameter-efficient fine tuning	Textual prompt tuning	ViT-Base	Kế thừa CLIP	Cross Attention, Contrastive Alignment	N/a
4	PLIP (2024)	Parameter-efficient fine tuning	Visual prompt tuning, Efficient Selective tuning	ViT-Base	Kế thừa CLIP	Concatnate	N/a
5	FPT (2024)	Parameter-efficient fine tuning	Visual prompt tuning	ViT-Base	N/a	Cross Attention	N/a
6	MedPrompt (2024)	Parameter-efficient fine tuning	Textual prompt tuning	Swin Transformer, ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
7	CLMP (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	ViT-Base	Kế thừa CLIP	Hadamard Product, Concatnate	N/a
8	BiomedCoOp (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	Kế thừa BiomedCLIP	Kế thừa BiomedCLIP	Contrastive Alignment	N/a
9	CLIPath (2023)	Parameter-efficient fine tuning	Adapter tuning	ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
10	FTB (2024)	Parameter-efficient fine tuning	Adapter tuning	ResNet autoencoder, DINOv2-small, DINOv2-base	BERT, BioBERT, ClinicalBERT, CXR-BERT, PubMedBERT	Cross Attention	N/a
11	MedUnA (2024)	Parameter-efficient fine tuning	Adapter tuning	ViT-Base, MedCLIP-Swin	Kế thừa CLIP, MedCLIP	No Fusion	N/a
12	TransMed (2023)	Parameter-efficient fine tuning	Direct Selective tuning	Swin Transformer, ViT-Base	BERT, LLM/GPT-4	Contrastive Alignment	N/a
13	SH-PEFT (2024)	Parameter-efficient fine tuning	Direct Selective tuning	ViT-Base	Kế thừa CLIP	No Fusion	N/a
14	LCBB (2024)	Parameter-efficient fine tuning	Efficient Selective tuning	Kế thừa MAE, MRM	Kế thừa MAE, MRM	Kế thừa MAE, MRM	N/a

Bảng 6: Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan

thời, quá trình thiết kế câu nhắc mang đậm tính chuyên môn hay xác định vị trí tối ưu để chèn bộ điều hợp thường phức tạp và đòi hỏi nhiều thử nghiệm. Ngoài ra, việc bổ sung các thành phần này ít nhiều làm tăng tính "hộp đen" của mô hình, gây ra những thách thức về tính minh bạch khi cần giải thích các quyết định dự đoán cho bác sĩ trên thực tế lâm sàng.

Các mô hình ngôn ngữ lớn y khoa đa phương thức

Trong thời gian gần đây, với sự phát triển của các mô hình ngôn ngữ lớn được huấn luyện trên những tập dữ liệu rất lớn phục vụ cho rất nhiều tác vụ khác nhau, các mô hình này đang thể hiện sự ảnh hưởng và đa dụng trong lĩnh vực y tế với độ chính xác rất tốt khi chỉ học ít mẫu hoặc không mẫu.

Med-Flamingo [32] là mô hình đầu tiên có khả năng học ít mẫu chuyên dụng cho y tế, thông qua hội thoại tự nhiên để hỗ trợ chẩn đoán. Theo sau đó, LLaVA-Med [24] là mô hình chuyển đổi khả năng thực hiện theo chỉ dẫn (instruction-following) từ miền tổng quát sang lĩnh vực y sinh bằng cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn với 600.000 cặp, với dữ

liệu hội thoại tạo ra từ chú thích ảnh y khoa được tạo ra bằng cách sử dụng GPT-4. Phương pháp này đã đề xuất quy trình huấn luyện 2 bước: (1) Căn chỉnh khái niệm; (2) Tinh chỉnh chỉ dẫn đầy đủ; 2 bước này tương ứng với giai đoạn học và suy luận. Kết quả thể hiện khả năng suy luận vượt trội trên dữ liệu chưa từng thấy.

Med-Palm M [40] là mô hình của Google, đánh dấu bước tiến từ các mô hình đơn nhiệm sang đa nhiệm quy mô lớn, có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì sử dụng các mô hình chuyên biệt cho từng tác vụ. Gần đây hơn, SkinGPT-4 [58] là hệ thống chẩn đoán da liễu tương tác đầu tiên sử dụng LLM quy mô lớn với độ chính xác cao, đã kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM), tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Dù đưa đến các phương pháp có độ chính xác cao đến rất cao trong nhiều tác vụ cùng việc hỗ trợ trong việc giao tiếp với mô hình, kích cỡ và chi phí huấn luyện (Med-Flamingo có đến 9 tỷ thông số) để vận hành các mô hình ngôn ngữ lớn đa phương thức là một vấn đề lớn, đi kèm với vấn đề ảo giác có thể gặp phải khi đối mặt với dữ liệu mới hoặc những câu hỏi phức tạp. Ngoài ra nếu yêu cầu một độ chính xác cao - một yêu cầu quan trọng trong lĩnh vực y tế trong một tác vụ cụ thể thì đây không phải một cách tiếp cận tốt cho bài toán này.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Cấu trúc phương pháp			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	Med-Flamingo [32]	PEFT	Parameter-efficient + Domain adaptation	Frozen CLIP ViT	LLaMA-7B	Intermediate fusion	LLaMA Decoder
2	LLaVA-Med [24]	Full FT	Visual Instruction Tuning (GPT-4 data)	CLIP ViT-L/14	LLaMA	Projection Matrix	LLM (Vicuna)
3	Med-PaLM M [40]	Full FT	Instruction Fine-tuning	ViT (4B - 22B)	PaLM	Multimodal embedding	PaLM
4	SkinGPT-4 [58]	PEFT	LoRA	Vision Transformer	GPT-4	Linear alignment	LLaMA-2-13B


Bảng 7: Tổng hợp chiến lược và cấu trúc các mô hình ngôn ngữ lớn đa phương thức

Phương pháp đề xuất: Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế theo hướng tích hợp tri thức y khoa nhằm nâng cao

khả năng giải thích của mô hình được minh họa ở Hình 2. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Bộ mã hóa ảnh:** Kế thừa lại mô hình ViT-Base của phương pháp BiomedCLIP [50]
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [50]
- **Bộ dung hợp dữ liệu:** Nhóm hướng đến sử dụng cơ chế *Knowledge-guided Cross-Attention* - Các khái niệm y học được trích xuất và liên kết từ văn bản lâm sàng thông qua sẽ được sử dụng để tạo thiên lệch (bias) trong quá trình tính toán cross attention. Cơ chế này giúp điều hướng mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Nhờ đó, mô hình không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.
- **Bộ phân loại:** Sử dụng một mạng phân loại (Multi-Layer Perceptron) để dự đoán nhãn bệnh lý.

Đồng thời, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán.



Hình 2: Kiến trúc tổng thể của hệ thống đề xuất

2.7 Kết quả dự kiến của đề tài

- **Số liệu định lượng:** Độ chính xác, điểm F1, AUC-ROC đạt kết quả cạnh tranh trên các bộ dữ liệu đã nêu.
- **Sản phẩm đầu ra:**

- Hệ thống demo phân loại ảnh X-quang xương với khả năng nhận ảnh và văn bản và trả ra các lớp thuộc bộ dữ liệu Sarcoma-CTCH.
 - Giao diện đơn giản để hiển thị kết quả phân loại.
 - Cho phép trực quan hóa sau khi hiện kết quả phân loại.
- **Báo cáo khoa học:** hoàn thiện phương pháp và hệ thống để hướng tới công bố trên các hội nghị và tạp chí uy tín trong lĩnh vực Trí tuệ nhân tạo và Y sinh, như MICCAI, CVPR hoặc các tạp chí được công nhận.
 - **Hướng phát triển:**
 - Mở rộng ra cho các bệnh lý khác.
 - Cải thiện độ chính xác và hiệu suất của hệ thống.

2.8 Kế hoạch thực hiện

Mục tiêu	Thời gian	Phân công	Nội dung
Khoá luận tốt nghiệp	01 tháng	Giai đoạn 1	
		Bá Thành	Khảo sát tổng quan về bài toán phân loại ảnh X-quang về xương
		Gia Kiệt	Khảo sát các mô hình tiền huấn luyện trên dữ liệu y khoa
		Bá Thành	Khảo sát các phương pháp học chuyển giao và các mô hình liên quan
	02 tháng	Giai đoạn 2	
		Cả nhóm	Phát triển mô hình học sâu đa phương thức áp dụng phương pháp học chuyển giao
		Gia Kiệt	Cài đặt môi trường, thu thập các bộ dữ liệu liên quan
		Bá Thành	Thực hiện thí nghiệm trên mô hình đề xuất
	02 tháng	Giai đoạn 3	
		Bá Thành	Phân tích so sánh kết quả thực nghiệm.
		Gia Kiệt	Xây dựng nguyên mẫu cho hệ thống phân loại
	0.5 tháng	Giai đoạn 4	
		Cả nhóm	Viết 01 bài báo khoa học cho hội nghị - tạp chí chuyên ngành trong nước hoặc ngoài nước
	0.5 tháng	Giai đoạn 5	
		Bá Thành	Viết báo cáo khoá luận tốt nghiệp.
		Gia Kiệt	Thiết kế slide cho lễ bảo vệ đề tài tốt nghiệp

Bảng 8: Kế hoạch bố trí thời gian nghiên cứu

Tài liệu tham khảo

- [1] Samira Abnar and Willem Zuidema. “Quantifying Attention Flow in Transformers”. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2020, pp. 4190–4197. DOI: 10.18653/v1/2020.acl-main.385. URL: <https://aclanthology.org/2020.acl-main.385/>.
- [2] Jean-Baptiste Alayrac et al. “Flamingo: a Visual Language Model for Few-Shot Learning”. In: *Advances in Neural Information Processing Systems*. Vol. 35. 2022, pp. 23716–23736. URL: https://papers.nips.cc/paper_files/paper/2022/hash/960a172bc7fbf0177ccccbb411a7c Abstract-Conference.html.
- [3] Shruthi Bannur et al. “Learning to exploit temporal structure for biomedical vision-language processing”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2023, pp. 15016–15027.
- [4] Lynn S. Bickley, Peter G. Szilagyi, and Richard M. Hoffman. *Bates’ Guide to Physical Examination and History Taking*. 13th. Lippincott Williams & Wilkins, 2020.
- [5] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing”. In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5.
- [6] Bệnh viện Nguyễn Tri Phương. *Quy trình khám bệnh tại khoa khám bệnh*. URL: <https://bvnguyentriphuong.com.vn/quy-trinh-kham-benh/quy-trinh-kham-benh-tai-khoa-kham-benh> (visited on 07/06/2026).
- [7] Yin Cui et al. “Class-Balanced Loss Based on Effective Number of Samples”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, pp. 9268–9277. URL: https://openaccess.thecvf.com/content_CVPR_2019/html/Cui_Class-

Balanced_Loss_Based_on_Effective_Number_of_Samples_CVPR_2019_paper.html.

- [8] Yin Dai and Yifan Gao. “TransMed: Transformers Advance Multi-modal Medical Image Classification”. In: *CoRR* abs/2103.05940 (2021). arXiv: 2103.05940. URL: <https://arxiv.org/abs/2103.05940>.
- [9] Ye Du, Nanxi Yu, and Shujun Wang. “Medical Knowledge Intervention Prompt Tuning for Medical Image Classification”. In: *IEEE Transactions on Medical Imaging* 44.12 (2025), pp. 4945–4959. DOI: 10.1109/TMI.2025.3584841.
- [10] Xiao Fang et al. “Aligning Medical Images with General Knowledge from Large Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15010. Springer Nature Switzerland, 2024.
- [11] Kaiming He et al. “Deep Residual Learning for Image Recognition”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016.
- [12] Dan Hendrycks and Kevin Gimpel. “A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks”. In: *International Conference on Learning Representations*. 2017. URL: <https://arxiv.org/abs/1610.02136>.
- [13] Dan Hendrycks et al. “Scaling Out-of-Distribution Detection for Real-World Settings”. In: *Proceedings of the 39th International Conference on Machine Learning*. Vol. 162. Proceedings of Machine Learning Research. PMLR, 2022, pp. 8759–8773. URL: <https://proceedings.mlr.press/v162/hendrycks22a.html>.
- [14] Edward J. Hu et al. “LoRA: Low-Rank Adaptation of Large Language Models”. In: *International Conference on Learning Representations*. 2022. URL: <https://openreview.net/forum?id=nZeVKeeFYf9>.
- [15] Gao Huang et al. “Densely Connected Convolutional Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017.

- [16] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [17] Yijin Huang et al. “Fine-grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-resolution Medical Image Classification”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15012. Springer Nature Switzerland, 2024, pp. 120–130. DOI: 10.1007/978-3-031-72390-2_12.
- [18] Andrew Jaegle et al. “Perceiver: General Perception with Iterative Attention”. In: *Proceedings of the 38th International Conference on Machine Learning*. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 4651–4664. URL: <https://proceedings.mlr.press/v139/jaegle21a.html>.
- [19] Sarthak Jain and Byron C. Wallace. “Attention is not Explanation”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, 2019, pp. 3543–3556. DOI: 10.18653/v1/N19-1357. URL: <https://aclanthology.org/N19-1357/>.
- [20] Taha Koleilat et al. “BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models”. In: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*. 2025, pp. 14766–14776.
- [21] Zhengfeng Lai et al. “CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*. 2023, pp. 2374–2380.

- [22] Olivier Ledoit and Michael Wolf. “A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices”. In: *Journal of Multivariate Analysis* 88.2 (2004), pp. 365–411. DOI: 10.1016/S0047-259X(03)00096-4.
- [23] Kimin Lee et al. “A Simple Unified Framework for Detecting Out-of-Distribution Samples and Adversarial Attacks”. In: *Advances in Neural Information Processing Systems*. Vol. 31. 2018, pp. 7167–7177. URL: <https://proceedings.neurips.cc/paper/2018/hash/abdeb6f575ac5c6676b747bca8d09cc2-Abstract.html>.
- [24] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: <https://arxiv.org/abs/2306.00890>.
- [25] Zihan Li et al. “LViT: Language Meets Vision Transformer in Medical Image Segmentation”. In: *IEEE Transactions on Medical Imaging* 43.1 (2024), pp. 96–107. DOI: 10.1109/TMI.2023.3291719.
- [26] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: <https://arxiv.org/abs/2401.12215>.
- [27] Mingyuan Liu et al. “Sparsity- and Hybridity-Inspired Visual Parameter-Efficient Fine-Tuning for Medical Diagnosis”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15005. Springer Nature Switzerland, 2024.
- [28] Weitang Liu et al. “Energy-based Out-of-distribution Detection”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 21464–21475. URL: <https://proceedings.neurips.cc/paper/2020/hash/f5496252609c43eb8a3d147ab9b9c006-Abstract.html>.
- [29] Xueyan Mei et al. “Artificial intelligence-enabled rapid diagnosis of patients with COVID-19”. In: *Nature Medicine* 26 (Aug. 2020), 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: <https://www.nature.com/articles/s41591-020-0931-3>.

- [30] Yifei Ming et al. “Delving into Out-of-Distribution Detection with Vision-Language Representations”. In: *Advances in Neural Information Processing Systems*. Vol. 35. 2022, pp. 35087–35102. URL: https://papers.nips.cc/paper_files/paper/2022/hash/e43a33994a28f746dcfc Abstract-Conference.html.
- [31] Jong Hak Moon et al. “Multi-Modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training”. In: *IEEE Journal of Biomedical and Health Informatics* 26.12 (2022), pp. 6070–6080. DOI: 10.1109/JBHI.2022.3207502.
- [32] Michael Moor et al. *Med-Flamingo: a Multimodal Medical Few-shot Learner*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.15189. URL: <https://arxiv.org/abs/2307.15189>.
- [33] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.
- [34] Umair Rahman et al. “Can language-guided unsupervised adaptation improve medical image classification using unpaired images and texts?” In: *2025 IEEE 22nd International Symposium on Biomedical Imaging (ISBI)*. IEEE. 2025, pp. 1–5.
- [35] Bryan C Russell et al. “LabelMe: a database and web-based tool for image annotation”. In: *International journal of computer vision* 77.1-3 (2008), pp. 157–173.
- [36] Ramprasaath R. Selvaraju et al. “Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization”. In: *Proceedings of the IEEE International Conference on Computer Vision*. 2017, pp. 618–626. URL: https://openaccess.thecvf.com/content_iccv_2017/html/Selvaraju_Grad-CAM_Visual_Explanations_ICCV_2017_paper.html.

- [37] Jake Snell, Kevin Swersky, and Richard S. Zemel. “Prototypical Networks for Few-shot Learning”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017, pp. 4077–4087. URL: https://papers.nips.cc/paper_files/paper/2017/hash/cb8da6767461f2812ae429...Abstract.html.
- [38] Yiyu Sun et al. “Out-of-Distribution Detection with Deep Nearest Neighbors”. In: *Proceedings of the 39th International Conference on Machine Learning*. Vol. 162. Proceedings of Machine Learning Research. PMLR, 2022, pp. 20827–20840. URL: <https://proceedings.mlr.press/v162/sun22d.html>.
- [39] Nikhil Kumar Tomar et al. “TGANet: Text-Guided Attention for Improved Polyp Segmentation”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2022*. Cham, Switzerland: Springer Nature Switzerland, 2022, pp. 151–160. ISBN: 978-3-031-16437-8. DOI: 10.1007/978-3-031-16437-8_15.
- [40] Tao Tu et al. *Towards Generalist Biomedical AI*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.14334. URL: <https://arxiv.org/abs/2307.14334>.
- [41] Xiaosong Wang et al. “TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018.
- [42] Yan Wang et al. *SimpleShot: Revisiting Nearest-Neighbor Classification for Few-Shot Learning*. 2019. arXiv: 1911.04623 [cs.CV]. URL: <https://arxiv.org/abs/1911.04623>.
- [43] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, Dec. 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: <https://aclanthology.org/2022.emnlp-main.256/>.

- [44] W.B. Saunders. *Dorland's Illustrated Medical Dictionary*. 32nd. Elsevier Health Sciences, 2011.
- [45] Chaoyi Wu et al. “MedKLIP: Medical Knowledge Enhanced Language-Image Pre-Training for X-ray Diagnosis”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023, pp. 21372–21383.
- [46] Bin Yan and Mingtao Pei. “Clinical-BERT: Vision-Language Pre-training for Radiograph Diagnosis and Reports Generation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 36. 3. 2022, pp. 2982–2990. DOI: 10.1609/aaai.v36i3.20204. URL: <https://doi.org/10.1609/aaai.v36i3.20204>.
- [47] Shunhan Yao et al. “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors”. In: *Scientific Data* 12.1 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y. URL: <https://doi.org/10.1038/s41597-024-04311-y>.
- [48] Chenlu Zhan et al. “UniDCP: Unifying Multiple Medical Vision-Language Tasks via Dynamic Cross-Modal Learnable Prompts”. In: *IEEE Transactions on Multimedia* 26 (2024), pp. 9736–9748. DOI: 10.1109/TMM.2024.3397191.
- [49] Jiajin Zhang et al. “Disease-informed Adaptation of Vision-Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15011. Springer Nature Switzerland, 2024.
- [50] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoA2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoA2400640>.
- [51] Xiaoman Zhang et al. “Knowledge-enhanced visual-language pre-training on chest radiology images”. In: *Nature Communications* 14 (July 2023). DOI: 10.1038/s41467-023-40260-7. URL: <https://arxiv.org/pdf/2302.14042.pdf>.

- [52] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 7th Machine Learning for Healthcare Conference*. Ed. by Zachary Lipton et al. Vol. 182. Proceedings of Machine Learning Research. PMLR, 2022, pp. 2–25. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
- [53] Yunkun Zhang et al. “Text-Guided Foundation Model Adaptation for Pathological Image Classification”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*. Ed. by Hayit Greenspan et al. Cham: Springer Nature Switzerland, 2023, pp. 272–282. ISBN: 978-3-031-43904-9.
- [54] Fudan Zheng et al. “Exploring low-resource medical image classification with weakly supervised prompt learning”. In: *Pattern Recognition* 149 (2024), p. 110250. ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2024.110250>. URL: <https://www.sciencedirect.com/science/article/pii/S0031320324000013>.
- [55] Kaipeng Zheng, Weiran Huang, and Lichao Sun. “TransMed: Large Language Models Enhance Vision Transformer for Biomedical Image Classification”. In: *arXiv preprint arXiv:2312.07125* (2023).
- [56] Hong-Yu Zhou et al. “A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics”. In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).
- [57] Hong-Yu Zhou et al. “Advancing Radiograph Representation Learning with Masked Record Modeling”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=w-x7U26GM7j>.
- [58] Juexiao Zhou et al. “Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4”. In: *Nature Communications* 15 (July 2024). DOI: 10.1038/s41467-024-50043-3. URL: <https://doi.org/10.1038/s41467-024-50043-3>.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 05 tháng 04 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Đề cương chi tiết	iii
Mục lục	xxxi
Danh sách hình	xxxv
Danh sách bảng	xxxvi
Tóm tắt	xxxvii
1 Giới thiệu	1
1.1 Bối cảnh và lý do chọn đề tài	1
1.2 Động lực nghiên cứu	3
1.2.1 Kịch bản thực tế	3
1.2.2 Ý nghĩa khoa học của đề tài	6
1.2.3 Ý nghĩa thực tiễn của đề tài	6
1.3 Giới thiệu bài toán	7
1.3.1 Các thách thức trong bài toán	8
1.4 Mục tiêu nghiên cứu	9
1.5 Đối tượng và phạm vi nghiên cứu	10
1.5.1 Đối tượng nghiên cứu	10
1.5.2 Phạm vi nghiên cứu	10
1.6 Các câu hỏi nghiên cứu và giả thuyết	11
1.7 Đóng góp chính của đề tài	13

1.8	Bố cục luận văn	14
2	Cơ sở lý thuyết và các công trình nghiên cứu liên quan	16
2.1	Học đa phương thức trong chẩn đoán hình ảnh y khoa . .	17
2.1.1	Tính bổ sung giữa hình ảnh và thông tin lâm sàng	17
2.1.2	Lựa chọn nguồn văn bản và kiểm soát rò rỉ nhãn .	19
2.2	Mô hình ngôn ngữ – thị giác y khoa	19
2.2.1	Học biểu diễn tương phản ảnh–văn bản	19
2.2.2	Lý do kế thừa mô hình nền tảng thay vì huấn luyện từ đầu	21
2.3	Biểu diễn ảnh độ phân giải cao và thông tin không gian . .	21
2.3.1	Giới hạn của phép co giãn ảnh toàn cục	21
2.3.2	Kết hợp ngữ cảnh toàn cục và vùng cục bộ	22
2.4	Tinh chỉnh hiệu quả tham số	23
2.4.1	Các nhóm phương pháp	23
2.4.2	Thích nghi hạng thấp	24
2.5	Dung hợp đa phương thức và huấn luyện hai pha	24
2.5.1	Từ phép nối đặc trưng đến chú ý chéo	24
2.5.2	Vai trò của hai pha huấn luyện	26
2.6	Phân loại dựa trên tâm lớp và dữ liệu mất cân bằng	27
2.6.1	Từ prototypical networks đến tâm lớp thực nghiệm	27
2.6.2	Cross-Entropy có trọng số theo số mẫu hiệu dụng .	28
2.7	Phát hiện dữ liệu ngoài phân phối	29
2.7.1	Bài toán và nguyên tắc đánh giá	29
2.7.2	Điểm dựa trên đầu ra mô hình	29
2.7.3	Điểm dựa trên không gian đặc trưng	30
2.8	Trực quan hóa và phân tích mức đóng góp	31
2.9	Bàn luận và khoảng trống nghiên cứu	33
2.9.1	Những điểm đã được hỗ trợ bởi nghiên cứu trước .	33
2.9.2	Khoảng trống đối với bài toán X-quang xương . . .	34
2.9.3	Cơ sở hình thành pipeline đề xuất	34
3	Phương pháp đề xuất	37
3.1	Tổng quan phương pháp đề xuất	37

3.2	Pipeline cuối cùng	38
3.3	Giai đoạn huấn luyện	39
3.3.1	Học biểu diễn với kỹ thuật LoRA	40
3.3.2	Học phân loại đa lớp với empirical centroid head . .	42
3.4	Giai đoạn online	45
3.5	Đóng góp của phương pháp	46
4	Thực nghiệm	47
4.1	Chuẩn bị dữ liệu	47
4.1.1	Bộ dữ liệu BTXRD	47
4.1.2	Bộ dữ liệu CTCH	51
4.2	Độ đo đánh giá	56
4.2.1	Độ chính xác	56
4.2.2	Độ chính xác cân bằng	57
4.2.3	Macro F1-Score	57
4.2.4	Macro AUROC	58
4.2.5	AUROC-OOD	58
4.2.6	FPR@95% ID-TPR	59
4.2.7	Khoảng tin cậy bootstrap 95%	59
4.3	Thiết lập thực nghiệm	60
4.3.1	Môi trường thực nghiệm	60
4.3.2	Tham số thực nghiệm	61
4.3.3	Tham số thực nghiệm	61
4.4	Nội dung thực nghiệm	62
4.4.1	Đánh giá mô hình nền tảng	62
4.4.2	So sánh với các mô hình nền tảng	63
4.4.3	Đánh giá thành phần	64
4.4.4	OOD hậu xử lý	65
4.4.5	Giải thích và biểu diễn	66
4.5	Kết quả thực nghiệm và thảo luận	67
4.5.1	Đánh giá mô hình nền tảng	67
4.5.2	So sánh với các mô hình nền tảng	68
4.5.3	Đánh giá thành phần	70
4.5.4	OOD hậu xử lý	70

4.5.5	Giải thích và biểu diễn	71
5	Kết luận và hướng phát triển	73
5.1	Kết luận	73
5.2	Hướng phát triển	74
	Tài liệu tham khảo	76

Danh sách hình

1.1	Sơ đồ quy trình khám chữa bệnh giản hóa (Tham khảo từ quy trình thực tế tại Bệnh viện Nguyễn Tri Phương [6]). .	4
1.2	Sơ đồ tích hợp hệ thống hỗ trợ chẩn đoán.	5
3.1	Sơ đồ chung của hệ thống trong công đoạn học biểu diễn. .	40
3.2	Sơ đồ chung của hệ thống trong công đoạn học phân loại đa lớp.	42
3.3	Sơ đồ chung của hệ thống trong giai đoạn online.	45
4.1	Sơ đồ cấu trúc của bộ dữ liệu BTXRD	49
4.2	Sơ đồ phân cấp cấu trúc dữ liệu CTCH	53

Danh sách bảng

2.1	Tổng hợp một số hướng kết hợp hình ảnh và dữ liệu lâm sàng.	18
2.2	So sánh các mô hình ngôn ngữ – thị giác y khoa có liên quan trực tiếp.	20
2.3	Các chiến lược xử lý ảnh độ phân giải cao và sự đánh đổi chính.	23
2.4	So sánh các chiến lược thích nghi mô hình nền tảng.	25
2.5	Phân biệt các dạng đầu phân loại dựa trên trọng số và tâm lớp.	28
2.6	Các nhóm điểm OOD có liên quan đến pipeline đánh giá. .	31
2.7	Các hướng trực quan hóa và giới hạn diễn giải.	33
2.8	Liên hệ giữa khoảng trống nghiên cứu, lựa chọn thiết kế và nội dung đánh giá.	35
4.1	Ví dụ các mẫu dữ liệu đa phương thức trong bộ dữ liệu BTXRD	52
4.2	Phân bố hình ảnh theo các tập dữ liệu trong BTXRD . . .	54
4.3	Phân bố các lớp đơn nhãn sau chuẩn hóa trong bộ dữ liệu BTXRD	54
4.4	Môi trường phần cứng được thiết lập	60
4.5	Phiên bản của các thư viện chính trong môi trường thí nghiệm	60
4.6	Bảng tổng hợp siêu tham số ở pha 1 và thiết lập của chúng	61
4.7	Bảng tổng hợp siêu tham số ở pha 2 và thiết lập của chúng	62
4.8	Kết quả zero-shot trên BTXRD và CTCH, chữ đậm biểu thị giá trị tốt nhất theo từng bộ dữ liệu	67
4.9	Kết quả phân loại khi sử dụng toàn bộ dữ liệu, chữ đậm biểu thị giá trị tốt nhất theo từng cột trong mỗi bộ dữ liệu	68

4.10	Kết quả few-shot của các thiết lập có đủ ba lần chạy; chữ đậm biểu thị giá trị tốt nhất trong từng mức shot và bộ dữ liệu	69
4.11	Kết quả đánh giá thành phần tiền xử lý ảnh trên CTCH .	70
4.12	Kết quả OOD hậu xử lý của XBone-Net trên CTCH; chữ đậm biểu thị kết quả tốt nhất trong từng kịch bản chính .	70
4.13	Kết quả phân bổ mức đóng góp của XBone-Net trên CTCH	71
4.14	Kết quả hình học biểu diễn của XBone-Net trên CTCH; chữ đậm biểu thị giá trị tốt nhất theo từng cột	72

Tóm tắt

Các bệnh lý và chấn thương xương ngày càng phổ biến, làm gia tăng nhu cầu ứng dụng trí tuệ nhân tạo nhằm hỗ trợ bác sĩ trong quá trình phân tích ảnh X-quang. Tuy nhiên, dữ liệu X-quang y khoa thường có số lượng mẫu gán nhãn hạn chế, mất cân bằng giữa các lớp bệnh và tồn tại nhiều trường hợp ngoài phân phối (Out-of-Distribution - OOD), khiến hiệu quả của các mô hình học sâu suy giảm khi triển khai trong thực tế.

Đề tài hướng đến xây dựng một hệ thống phân loại đa lớp ảnh X-quang xương theo hướng đa phương thức, khai thác đồng thời thông tin từ ảnh X-quang và văn bản lâm sàng nhằm nâng cao hiệu quả dự đoán.

Hệ thống được xây dựng trên nền tảng BioMedCLIP với hai giai đoạn huấn luyện. Giai đoạn thứ nhất thực hiện thích nghi miền bằng kỹ thuật LoRA sử dụng Semantic Matching Loss nhằm cải thiện khả năng biểu diễn đặc trưng đối với dữ liệu X-quang xương. Giai đoạn hai học phân loại sử dụng cơ chế chú ý hai chiều để hợp nhất đặc trưng ảnh và văn bản, kết hợp Asymmetric Loss nhằm xử lý mất cân bằng lớp và mạng nguyên mẫu để tăng cường khả năng phân biệt giữa các lớp, hỗ trợ các lớp có ít mẫu và làm cơ sở cho phát hiện dữ liệu ngoài phân phối. Hệ thống được đánh giá thông qua các thực nghiệm thành phần, so sánh với các mô hình nền tảng và đánh giá trên bộ dữ liệu X-quang xương được xây dựng từ dữ liệu thực từ Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.

Kết quả thực nghiệm cho thấy phương pháp đề xuất cải thiện hiệu quả phân loại đa lớp so với mô hình nền, đồng thời nâng cao khả năng tổng quát và hỗ trợ phát hiện dữ liệu ngoài phân phối. Ngoài ra, đề tài còn đóng góp một bộ dữ liệu X-quang xương đã được tinh lọc và chuẩn hóa, tạo nền tảng cho các nghiên cứu tiếp theo về học đa phương thức và ứng dụng mô hình thị giác-ngôn ngữ trong phân tích ảnh y khoa.

Chương 1

Giới thiệu

Chương này trình bày tổng quan về bài toán hỗ trợ chẩn đoán bệnh lý trên ảnh X-quang xương bằng học sâu đa phương thức, đặc biệt trong bối cảnh dữ liệu y tế thường có tính phức tạp cao và phụ thuộc vào kinh nghiệm của bác sĩ. Bên cạnh thông tin hình ảnh, quá trình chẩn đoán thực tế còn yêu cầu kết hợp thêm các thông tin lâm sàng và báo cáo y khoa nhằm đưa ra đánh giá toàn diện về tình trạng bệnh nhân. Tuy nhiên, việc khai thác hiệu quả đồng thời nhiều nguồn dữ liệu khác nhau vẫn còn là một thách thức lớn đối với các hệ thống học sâu hiện nay.

1.1 Bối cảnh và lý do chọn đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn đầu. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, nhiều nghiên cứu đã ứng dụng các mô hình học sâu vào việc giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh như Resnet [11] và DenseNet [15]. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ tốt để đưa vào ứng dụng thực tế. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để hỗ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác.

Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống. Trong những năm gần đây, các mô hình ngôn ngữ trực quan kết hợp ảnh y khoa với báo cáo đọc ảnh có thể học được mối quan hệ ngữ nghĩa giữa hai phương thức, từ đó tạo ra biểu diễn dữ liệu giàu thông tin hơn so với các mô hình chỉ sử dụng dữ liệu hình ảnh hoặc văn bản riêng lẻ. Nhiều mô hình tiêu biểu như MedCLIP [43], BioMedCLIP [50] và BioViL [5] đã chứng minh hiệu quả trên nhiều bài toán phân tích ảnh y khoa.

Tuy nhiên, các mô hình ngôn ngữ trực quan hiện nay vẫn tồn tại một số hạn chế. Đầu tiên, các mô hình này chủ yếu được huấn luyện trên các bộ dữ liệu cặp ảnh X-quang và báo cáo đọc ảnh, trong khi trong thực tế ở Việt Nam, báo cáo đọc ảnh thường chứa kết luận rõ ràng, dẫn đến việc các mô hình này khó áp dụng vào thực tế khi chúng ta cần chẩn đoán chỉ dựa vào ảnh và báo cáo lâm sàng của bệnh nhân. Thứ hai, các mô hình hiện tại chưa được thiết kế để xử lý các trường hợp dữ liệu ngoài phân phối, dẫn đến nguy cơ đưa ra dự đoán không chính xác với độ tin cậy cao đối với những trường hợp chưa từng xuất hiện trong dữ liệu huấn luyện. Thứ ba, dữ liệu huấn luyện trong thực tế rất ít, đặc biệt là các trường hợp hiếm gặp, khiến việc huấn luyện các mô hình trở nên khó khăn. Thứ tư, khả năng giải thích của các mô hình hiện nay vẫn còn hạn chế, khiến bác sĩ khó có thể hiểu rõ cơ sở đưa ra quyết định của hệ thống.


1.2 Động lực nghiên cứu

1.2.1 Kịch bản thực tế


Trong thực hành lâm sàng, quy trình chẩn đoán bệnh lý xương thường tuân theo Hình 1.1 bao gồm khám lâm sàng, chỉ định chụp X-quang, phân tích hình ảnh và kết hợp với các thông tin bệnh án để đưa ra chẩn đoán cuối cùng. Sau khi ảnh X-quang được thu nhận, bác sĩ chẩn đoán hình ảnh sẽ đánh giá các dấu hiệu bất thường như vị trí tổn thương, hình thái gãy xương, khối u hoặc các biến đổi bệnh lý khác, đồng thời đối chiếu với các thông tin lâm sàng như triệu chứng, tiền sử bệnh và cơ chế chấn thương để đưa ra kết quả đọc phim.

Hệ thống được đề xuất trong luận văn được thiết kế nhằm hỗ trợ quá trình phân tích ảnh X-quang bằng cách khai thác đồng thời ảnh X-quang và dữ liệu văn bản chứa thông tin lâm sàng để dự đoán lớp bệnh lý của bệnh nhân như thể hiện ở Hình 1.2. Việc kết hợp hai nguồn dữ liệu giúp mô hình tận dụng các thông tin bổ sung, từ đó nâng cao khả năng học biểu diễn và cải thiện hiệu quả phân loại so với việc chỉ sử dụng một phương thức dữ liệu.

Cần lưu ý rằng hệ thống được đề xuất không thay thế vai trò của bác sĩ phân tích ảnh mà đóng vai trò là công cụ hỗ trợ phân tích. Các kết quả dự đoán cung cấp thông tin tham khảo, giúp rút ngắn thời gian đọc phim, giảm nguy cơ bỏ sót tổn thương và nâng cao hiệu quả chẩn đoán, đặc biệt tại các cơ sở y tế có khối lượng bệnh nhân lớn hoặc nguồn nhân lực chuyên khoa còn hạn chế.



Hình 1.1: Sơ đồ quy trình khám chữa bệnh giản hóa (Tham khảo từ quy trình thực tế tại Bệnh viện Nguyễn Tri Phương [6]).



Hình 1.2: Sơ đồ tích hợp hệ thống hỗ trợ chẩn đoán.

1.2.2 Ý nghĩa khoa học của đề tài

Đề tài góp phần làm rõ hiệu quả của việc kết hợp dữ liệu ảnh X-quang và văn bản lâm sàng trong bài toán phân loại đa lớp. Thông qua việc khai thác đồng thời hai nguồn dữ liệu, nghiên cứu đánh giá khả năng cải thiện chất lượng biểu diễn và hiệu quả phân loại so với các phương pháp chỉ sử dụng một phương thức, qua đó cung cấp cơ sở cho việc phát triển các hệ thống hỗ trợ chẩn đoán tận dụng hiệu quả dữ liệu y tế đa phương thức.

Bên cạnh đó, nghiên cứu kế thừa và tinh chỉnh mô hình ngôn ngữ trực quan trên dữ liệu X-quang xương ở Việt Nam, góp phần đánh giá khả năng thích nghi của các mô hình tiền huấn luyện đa phương thức đối với các bài toán y khoa đặc thù ở Việt Nam và có quy mô dữ liệu hạn chế với phân bố mất cân bằng.

Ngoài ra, đề tài nghiên cứu các phương pháp nâng cao khả năng tổng quát hóa của mô hình trong điều kiện dữ liệu thực tế, đồng thời tích hợp cơ chế phát hiện dữ liệu ngoài phân phối. Cách tiếp cận này góp phần nâng cao độ tin cậy của hệ thống khi triển khai trong môi trường lâm sàng bằng cách hạn chế các dự đoán đối với những trường hợp chưa từng xuất hiện trong dữ liệu huấn luyện.

Cuối cùng, đề tài tăng cường khả năng giải thích của mô hình thông qua việc trực quan hóa các vùng ảnh X-quang có ảnh hưởng đến quá trình dự đoán, giúp bác sĩ chính hiểu rõ hơn cơ sở đưa ra kết quả phân loại và nâng cao tính minh bạch của hệ thống.

1.2.3 Ý nghĩa thực tiễn của đề tài

Hệ thống được đề xuất hướng đến hỗ trợ bác sĩ trong quá trình phân tích ảnh X-quang bằng cách kết hợp thông tin từ ảnh X-quang và dữ liệu lâm sàng ban đầu để đưa ra kết quả phân loại. Quá trình huấn luyện tận dụng báo cáo lâm sàng nhằm học mối quan hệ giữa ảnh X-quang và biểu hiện của bệnh lý. Cách tiếp cận này phù hợp với quy trình khám chữa bệnh thực tế tại các cơ sở y tế, góp phần nâng cao khả năng ứng dụng của hệ thống trong thực tiễn.

Bên cạnh đó, hệ thống được thiết kế nhằm thích ứng với các đặc điểm phổ biến của dữ liệu y tế thực tế như số lượng mẫu gán nhãn hạn chế, phân bố dữ liệu mất cân bằng và sự xuất hiện của các trường hợp ngoài phân phối.

Đồng thời, mô hình cung cấp các bản đồ nhiệt trực quan hóa vùng ảnh trong ảnh X-quang ảnh hưởng đến kết quả dự đoán và cơ chế cảnh báo đối với các mẫu dữ liệu ngoài phân phối, góp phần nâng cao tính minh bạch, độ tin cậy và tính an toàn khi hỗ trợ bác sĩ trong quá trình chẩn đoán.

1.3 Giới thiệu bài toán

Bài toán được nghiên cứu trong đề tài là bài toán phân loại đa lớp ảnh X-quang sử dụng học sâu đa phương thức. Mục tiêu của hệ thống là dự đoán các loại bệnh hoặc tổn thương dựa trên đồng thời dữ liệu hình ảnh X-quang và thông tin lâm sàng liên quan.

- **Đầu vào:** Hệ thống nhận vào các nguồn dữ liệu sau:

- Ảnh X-quang của bệnh nhân:

$$x^{img} \in \mathbb{R}^{H \times W \times C}$$

trong đó:

- * H, W : chiều cao và chiều rộng ảnh,
- * C : số kênh màu của ảnh.

- Thông tin lâm sàng (lời khai bệnh nhân, triệu chứng, tiền sử bệnh).

$$x^{txt} = \{w_1, w_2, \dots, w_T\}$$

trong đó:

- * w_t : từ thứ t ,
- * T : số lượng từ trong văn bản.

- Tập nhãn được định nghĩa trước:

$$\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$$

với K là số lớp bệnh cần phân loại.

- **Đầu ra:** Hệ thống sinh ra:

- Cảnh báo dữ liệu ngoài phân phối/chưa từng gặp với các mẫu được hệ thống cho là không thuộc các lớp đã học.
- Nhãn dự đoán cuối cùng với các mẫu được cho là thuộc các lớp đã học:

$$\hat{y} = f(x^{img}, x^{txt}) \in \mathcal{Y}$$

trong đó f là hàm ánh xạ được học bởi mô hình.

- Bản đồ nhiệt trực quan hóa trên ảnh nhằm giải thích dự đoán của mô hình.

1.3.1 Các thách thức trong bài toán

Mặc dù các mô hình học sâu đa phương thức đã đạt được nhiều kết quả tích cực, bài toán vẫn tồn tại nhiều thách thức cần được giải quyết:

- Tồn tại sự chênh lệch lớn giữa các bộ dữ liệu đa phương thức hiện có (thường là cặp ảnh X-quang và báo cáo đọc ảnh X-quang) so với luồng công việc thực tế lâm sàng (bao gồm ảnh chụp X-quang kết hợp với báo cáo tổng quát), làm hạn chế khả năng ứng dụng trực tiếp của các mô hình.
- Sự khác biệt về không gian và ngữ nghĩa giữa dữ liệu hình ảnh và dữ liệu văn bản gây khó khăn cho quá trình học biểu diễn chung, yêu cầu một cơ chế dung hợp hiệu quả.
- Dữ liệu y tế thường có số lượng hạn chế và mất cân bằng giữa các loại bệnh, đặt ra yêu cầu đặc biệt về thiết kế mô hình để tận dụng tối đa thông tin có sẵn.

- Trong thực tế lâm sàng, luôn có tỉ lệ xuất hiện những loại bệnh mới nằm ngoài dữ liệu huấn luyện, đặt ra yêu cầu về khả năng tổng quát hóa và thích ứng của mô hình.
- Khả năng giải thích của mô hình vẫn còn hạn chế khiến độ tin cậy vào các dự đoán của hệ thống là không cao, gây khó khăn cho việc triển khai trong thực tế lâm sàng.

1.4 Mục tiêu nghiên cứu

Đề tài hướng đến việc nghiên cứu và xây dựng một hệ thống học sâu đa phương thức phục vụ hỗ trợ phân loại bệnh lý trên ảnh X-quang xương, khai thác đồng thời dữ liệu hình ảnh và báo cáo lâm sàng nhằm đảm bảo hiệu quả phân loại so với các phương pháp hiện có và có khả năng thích ứng với các tình huống thực tế như dữ liệu ngoài phân phối và mất cân bằng lớp.

Các mục tiêu cụ thể của đề tài bao gồm:

1. Đánh giá vai trò của báo cáo lâm sàng trong việc nâng cao hiệu quả phân loại bệnh lý xương khi kết hợp với ảnh X-quang, so với các phương pháp chỉ sử dụng dữ liệu hình ảnh.
2. Nghiên cứu chiến lược dung hợp đặc trưng đa phương thức, cụ thể là cơ chế chú ý chéo và so sánh với các phương pháp khác, nhằm xác định phương pháp kết hợp hiệu quả giữa đặc trưng hình ảnh và văn bản.
3. Khảo sát các phương pháp tinh chỉnh hiệu quả tham số, nhằm giảm chi phí tính toán trong khi duy trì hoặc cải thiện hiệu quả phân loại so với việc tinh chỉnh toàn bộ tham số.
4. Nghiên cứu cơ chế phát hiện dữ liệu ngoài phân phối nhằm tăng khả năng nhận diện các mẫu bệnh lý chưa từng xuất hiện trong dữ liệu huấn luyện, nâng cao độ tin cậy của hệ thống trong môi trường thực tế.

5. Xây dựng cơ chế giải thích dựa trên bản đồ chú ý giúp trực quan hóa các vùng ảnh mà mô hình tập trung khi đưa ra quyết định phân loại, hỗ trợ bác sĩ trong việc đánh giá và kiểm chứng kết quả dự đoán.
6. Xây dựng và đánh giá hệ thống XBone-Net trên bộ dữ liệu phân loại bệnh lý xương có phân bố mất cân bằng, so sánh với các mô hình nền tảng y khoa hiện có.

1.5 Đối tượng và phạm vi nghiên cứu

1.5.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học sâu đa phương thức sử dụng đồng thời dữ liệu hình ảnh và văn bản trong bài toán phân loại ảnh X-quang xương. Cụ thể, nghiên cứu tập trung vào các thành phần chính sau:

- Các mô hình ngôn ngữ trực quan tiền huấn luyện trên dữ liệu y khoa và dữ liệu tổng quát, được sử dụng làm bộ mã hóa đặc trưng đa phương thức.
- Các chiến lược dung hợp đặc trưng đa phương thức, bao gồm cơ chế chú ý chéo và phép nối đặc trưng, nhằm kết hợp thông tin từ ảnh X-quang và báo cáo lâm sàng.
- Các phương pháp tinh chỉnh tham số hiệu quả cho các mô hình tiền huấn luyện quy mô lớn nhằm giảm chi phí tính toán.
- Các kiến trúc bộ phân loại, phục vụ bài toán phân loại đa lớp trên dữ liệu mất cân bằng và phát hiện dữ liệu ngoài phân phối.

1.5.2 Phạm vi nghiên cứu

Đề tài tập trung vào bài toán phân loại đa lớp bệnh lý xương trên ảnh X-quang, kết hợp với báo cáo lâm sàng dạng văn bản. Phạm vi cụ thể bao gồm:

- **Dữ liệu:** Nghiên cứu sử dụng bộ dữ liệu BTXRD gồm 10 lớp bệnh lý xương, và bộ dữ liệu CTCH được thu thập từ Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.
- **Dữ liệu văn bản:** Trong quá trình huấn luyện và suy luận, hệ thống sử dụng bệnh sử lâm sàng được thu nhận trước khi đọc ảnh (chứa thông tin triệu chứng và tiền sử bệnh) thay vì báo cáo đọc ảnh X-quang, nhằm hạn chế rò rỉ nhãn và phù hợp hơn với thời điểm áp dụng hệ thống.
- **Vai trò hệ thống:** Hệ thống được thiết kế làm công cụ hỗ trợ chẩn đoán, không thay thế vai trò của bác sĩ trong quá trình ra quyết định.
- **Giới hạn:** Đề tài không tập trung vào các bài toán phát hiện đối tượng, phân đoạn ảnh hay sinh báo cáo y khoa tự động.

1.6 Các câu hỏi nghiên cứu và giả thuyết

Trong các giả thuyết dưới đây, Macro F1-Score được sử dụng làm chỉ số chính cho bài toán phân loại do dữ liệu có phân bố mất cân bằng; Accuracy, Macro AUROC và Specificity được sử dụng làm các chỉ số bổ sung. Hiệu quả tính toán được đánh giá thông qua số tham số có thể huấn luyện, mức sử dụng bộ nhớ và thời gian suy luận. Đối với phát hiện dữ liệu ngoài phân phối, các chỉ số chính gồm AUROC, AUPR-Out và FPR@95TPR.

- **Câu hỏi nghiên cứu 1:** Việc kết hợp bệnh sử lâm sàng được thu nhận trước khi đọc ảnh với ảnh X-quang có cải thiện hiệu quả phân loại so với mô hình chỉ sử dụng ảnh không?

Giả thuyết 1: Mô hình sử dụng đồng thời ảnh X-quang và bệnh sử lâm sàng đạt Macro F1-Score cao hơn mô hình chỉ sử dụng ảnh trên cùng tập dữ liệu và quy trình đánh giá.

- **Câu hỏi nghiên cứu 2:** Cơ chế chú ý chéo hai chiều có khai thác tương tác giữa ảnh và văn bản hiệu quả hơn phép nổi đặc trưng và các biến thể chú ý chéo một chiều không?

Giả thuyết 2: Cơ chế chú ý chéo hai chiều đạt Macro F1-Score cao hơn các cấu hình dùng phép nổi đặc trưng hoặc chỉ thực hiện chú ý theo một chiều khi các thành phần còn lại được giữ nguyên.

- **Câu hỏi nghiên cứu 3:** Chiến lược tinh chỉnh LoRA có duy trì hiệu quả phân loại trong khi giảm chi phí tính toán so với tinh chỉnh toàn bộ tham số không?

Giả thuyết 3: LoRA đạt Macro F1-Score tương đương hoặc cao hơn tinh chỉnh toàn bộ tham số, đồng thời sử dụng ít tham số có thể huấn luyện và ít bộ nhớ hơn.

- **Câu hỏi nghiên cứu 4:** Nhánh xử lý ảnh độ phân giải cao dựa trên lưới ảnh cục bộ và bộ tái lấy mẫu có tọa độ có cải thiện khả năng phân loại so với các phương pháp chỉ sử dụng ảnh toàn cục hoặc co giãn ảnh không?

Giả thuyết 4: Nhánh xử lý ảnh độ phân giải cao đạt Macro F1-Score cao hơn cấu hình chỉ sử dụng ảnh toàn cục và cấu hình co giãn ảnh khi sử dụng cùng backbone và chiến lược huấn luyện.

- **Câu hỏi nghiên cứu 5:** Hệ thống đề xuất XBone-Net có cải thiện hiệu quả phân loại so với các mô hình nền tảng được tinh chỉnh theo cùng cách thức đánh giá không?

Giả thuyết 5: XBone-Net đạt Macro F1-Score cao hơn mô hình đối chứng tốt nhất; các chỉ số còn lại được báo cáo như tiêu chí bổ sung thay vì giả định XBone-Net phải vượt trội trên mọi độ đo.

- **Câu hỏi nghiên cứu 6:** Không gian biểu diễn của XBone-Net có hỗ trợ phân biệt dữ liệu nội phân phối với các bộ dữ liệu ngoài phân phối được xác định trước không?

Giả thuyết 6: Ít nhất một phương pháp hậu xử lý được khảo sát, gồm khoảng cách Mahalanobis, Cosine-kNN, Energy Score và khoảng cách đến mốc văn bản, đạt AUROC lớn hơn mức ngẫu nhiên trong việc phân biệt dữ liệu nội phân phối và ngoài phân phối; phương pháp được lựa chọn dựa trên tập hiệu chỉnh thay vì tập kiểm thử.

- **Câu hỏi nghiên cứu 7:** Bản đồ chú ý của mô hình có tập trung vào các vùng tổn thương được chú thích trên ảnh X-quang không?

Giả thuyết 7: Trên các mẫu có chú thích tổn thương, tỷ lệ khối lượng chú ý nằm trong vùng tổn thương lớn hơn tỷ lệ diện tích của vùng này trên ảnh, tương ứng với tỷ số tập trung chú ý lớn hơn 1.

1.7 Đóng góp chính của đề tài

Các đóng góp chính của đề tài bao gồm:

1. **Quy trình sử dụng dữ liệu đa phương thức hạn chế rò rỉ nhãn:** Xây dựng quy trình sử dụng ảnh X-quang cùng bệnh sử lâm sàng được thu nhận trước khi đọc ảnh trong cả hai giai đoạn huấn luyện và khi suy luận. Báo cáo đọc ảnh, vốn có thể chứa trực tiếp kết luận chẩn đoán, được loại khỏi pipeline chính và chỉ được sử dụng trong các thí nghiệm loại bỏ thành phần nhằm đánh giá rò rỉ nhãn.
2. **Kiến trúc XBone-Net xử lý ảnh độ phân giải cao:** Phát triển nhánh thị giác bao phủ toàn bộ ảnh X-quang bằng lưới ảnh cục bộ xác định, tổng hợp các token cục bộ và nén chúng bằng bộ tái lấy mẫu có sử dụng thông tin tọa độ. Biểu diễn thị giác sau đó được kết hợp với biểu diễn bệnh sử lâm sàng bằng cơ chế chú ý chéo hai chiều.
3. **Quy trình huấn luyện hai giai đoạn với LoRA:** Thiết kế Giai đoạn 1 sử dụng Semantic Matching Loss để căn chỉnh biểu diễn ảnh và bệnh sử lâm sàng, sau đó tiếp tục tối ưu các adapter LoRA cùng mô-đun dung hợp trong Giai đoạn 2. Cách thiết kế này cho phép thích nghi mô hình BioMedCLIP với dữ liệu X-quang xương trong khi chỉ cập nhật một phần nhỏ tổng số tham số.

4. **Bộ phân loại dựa trên tâm lớp thực nghiệm:** Xây dựng bộ phân loại phi tham số sử dụng độ tương đồng cosine đến các tâm lớp được ước lượng lại từ biểu diễn của tập huấn luyện. Trong Giai đoạn 2, mô hình được tối ưu bằng Cross-Entropy có trọng số theo số mẫu hiệu dụng nhằm giảm ảnh hưởng của phân bố lớp mất cân bằng.
5. **Khung phát hiện dữ liệu ngoài phân phối:** Tích hợp quy trình phát hiện ngoài phân phối theo hướng hậu xử lý trên không gian biểu diễn đã học, hỗ trợ khoảng cách Mahalanobis, Cosine-kNN, Energy Score và khoảng cách đến mốc văn bản. Ngưỡng từ chối được hiệu chỉnh trên dữ liệu nội phân phối tách biệt trước khi đánh giá trên các bộ dữ liệu ngoài phân phối được xác định trước.
6. **Công cụ phân tích khả năng giải thích:** Xây dựng công cụ trích xuất bản đồ chú ý đặc thù theo lớp từ mô-đun chú ý chéo hai chiều, chiếu trọng số chú ý ngược về các vùng ảnh gốc thông qua bộ tái lấy mẫu không gian và định lượng mức độ tập trung trên vùng tổn thương được chú thích. Công cụ này hỗ trợ phân tích hành vi của mô hình, không được xem là bằng chứng thay thế cho đánh giá lâm sàng của bác sĩ.

1.8 Bố cục luận văn

Chương 1: Giới thiệu. Chương này cung cấp cái nhìn tổng quan về bối cảnh nghiên cứu, xác định rõ vấn đề cần giải quyết, mục tiêu, phương pháp tiếp cận và những đóng góp chính của đề tài. Đây là phần nền tảng định hướng cho toàn bộ nội dung khóa luận.

Chương 2: Các công trình nghiên cứu liên quan. Chương này tập trung hệ thống hóa các hướng tiếp cận đã được mô tả ở trên, làm tiền đề cho việc xây dựng giải pháp của khóa luận. Trọng tâm của chương là việc phân tích các kiến trúc mô hình ngôn ngữ trực quan cùng các chiến lược dung hợp đặc trưng đa phương thức. Bên cạnh đó, các kỹ thuật tinh chỉnh tối ưu và phương pháp nhận diện dữ liệu ngoài phân phối cũng được xem xét toàn diện, từ đó thiết lập cơ sở lý thuyết vững chắc và định vị rõ

ràng hướng giải quyết của đề tài so với các công trình đi trước.

Chương 3: Phương pháp đề xuất. Đây là chương trọng tâm mô tả chi tiết quy trình xây dựng hệ thống. Tại đây, nhóm sẽ trình bày cụ thể về kiến trúc mô hình được kế thừa, quy trình xử lý dữ liệu đầu vào (cả ảnh và văn bản), thiết kế các hàm mất mát, và chiến lược huấn luyện mô hình. Các sơ đồ khối và thuật toán sẽ được mô tả chi tiết để minh họa cho giải pháp.

Chương 4: Thực nghiệm và Kết quả. Chương này trình bày về bộ dữ liệu được sử dụng, thiết lập môi trường thực nghiệm và các chỉ số đánh giá. Kết quả thực nghiệm sẽ được phân tích, so sánh đối chiếu với các phương pháp khác để làm rõ ưu nhược điểm của mô hình đề xuất.

Chương 5: Kết luận và Hướng phát triển. Chương cuối cùng tổng kết lại những kết quả đạt được so với mục tiêu ban đầu, nhìn nhận những hạn chế còn tồn tại của hệ thống và đề xuất các hướng nghiên cứu tiếp theo để hoàn thiện và mở rộng ứng dụng trong tương lai.

Chương 2

Cơ sở lý thuyết và các công trình nghiên cứu liên quan

Chương này tổng hợp các hướng nghiên cứu có liên quan trực tiếp đến bài toán phân loại ảnh X-quang xương đa phương thức được xem xét trong luận văn. Thay vì khảo sát toàn bộ các mô hình y sinh đa phương thức, nội dung được tổ chức theo các quyết định thiết kế của hệ thống: lựa chọn nguồn văn bản, kế thừa mô hình ngôn ngữ – thị giác y khoa, bảo toàn thông tin trên ảnh độ phân giải cao, tinh chỉnh hiệu quả tham số (Parameter-Efficient Fine-Tuning – PEFT), dung hợp hai phương thức, phân loại trong điều kiện mất cân bằng, phát hiện dữ liệu ngoài phân phối (Out-of-Distribution – OOD) và phân tích bản đồ chú ý. Cách tổ chức này nhằm làm rõ mối liên hệ giữa các công trình trước đây, khoảng trống còn lại và quy trình (pipeline) được trình bày ở Chương 3.

Các kết quả định lượng trong những nghiên cứu được trích dẫn không được đặt cạnh nhau như một bảng xếp hạng, do khác biệt về bộ dữ liệu, cách chia tập, loại bệnh lý và chỉ số đánh giá. Thay vào đó, các bảng trong chương tập trung so sánh giả định, loại đầu vào, cơ chế học và mức độ liên quan với bài toán của luận văn.

2.1 Học đa phương thức trong chẩn đoán hình ảnh y khoa

2.1.1 Tính bổ sung giữa hình ảnh và thông tin lâm sàng

Ảnh X-quang mô tả cấu trúc giải phẫu và các biểu hiện có thể quan sát được tại thời điểm chụp, trong khi bệnh sử lâm sàng cung cấp thêm bối cảnh như triệu chứng, thời gian khởi phát, tuổi và vị trí đau. Hai nguồn dữ liệu vì vậy có thể mang thông tin bổ sung cho nhau. Tuy nhiên, mức độ hữu ích của văn bản phụ thuộc đáng kể vào thời điểm và mục đích thu nhận. Bệnh sử được ghi nhận trước khi đọc ảnh chủ yếu phản ánh bối cảnh lâm sàng; ngược lại, báo cáo X-quang có thể chứa mô tả tổn thương hoặc kết luận chẩn đoán được dùng làm nhãn. Nếu báo cáo này xuất hiện ở đầu vào, mô hình có thể dựa vào từ khóa chẩn đoán thay vì học quan hệ giữa ảnh, bệnh sử và bệnh lý. Đây là một dạng rò rỉ thông tin đích cần được kiểm soát ở cả huấn luyện và suy luận.

Các nghiên cứu trước cho thấy nhiều mức độ kết hợp ảnh và dữ liệu lâm sàng. Mei và cộng sự [29] kết hợp đặc trưng CT ngực với thông tin lâm sàng bằng một mô-đun dự đoán chung. TieNet [41] sử dụng cơ chế chú ý để liên kết từ trong báo cáo với vùng ảnh X-quang ngực. IRENE [56] biểu diễn nhiều loại dữ liệu lâm sàng dưới dạng token và cho phép chúng tương tác trong Transformer. FTB [33] giữ cố định các backbone ảnh và văn bản, đồng thời học mô-đun kết nối giữa hai phía. Các công trình này cung cấp bằng chứng phương pháp luận cho việc khai thác tương tác đa phương thức, nhưng loại văn bản, miền giải phẫu và mục tiêu dự đoán của chúng không hoàn toàn trùng với bài toán u xương trong luận văn. Bảng 2.1 tóm tắt sự khác biệt chính giữa các hướng tiếp cận này.

Công trình	Dữ liệu hình ảnh	Nguồn văn bản / dữ liệu phụ	Cơ chế kết hợp chính	Liên hệ và giới hạn đối với luận văn
Mei và cộng sự [29]	CT ngực	Triệu chứng và thông tin lâm sàng	Ghép đặc trưng ảnh và lâm sàng cho dự đoán chung	Hỗ trợ giả định về tính bổ sung của dữ liệu lâm sàng; khác miền ảnh và bệnh lý.
TieNet [41]	X-quang ngực	Báo cáo X-quang	Chú ý giữa từ và vùng ảnh	Cung cấp tiền lệ cho tương tác cục bộ ảnh-văn bản; nguồn văn bản có thể chứa thông tin gần với nhân.
IRENE [56]	Nhiều loại ảnh y khoa	Dữ liệu lâm sàng không đồng nhất	Mã hóa thống nhất bằng token và Transformer	Liên quan đến tương tác token đa phương thức; kiến trúc và phạm vi dữ liệu rộng hơn bài toán hiện tại.
FTB [33]	Ảnh y khoa	Văn bản y khoa	Giữ cố định back-bone và học khối kết nối	Gợi ý cách thích nghi tiết kiệm tham số; không sử dụng cùng bộ phân loại và quy trình OOD của luận văn.

Bảng 2.1: Tổng hợp một số hướng kết hợp hình ảnh và dữ liệu lâm sàng.

2.1.2 Lựa chọn nguồn văn bản và kiểm soát rò rỉ nhãn

Từ góc độ thiết kế thí nghiệm, cần phân biệt rõ *bệnh sử lâm sàng được ghi nhận trước khi có kết luận đọc ảnh* với *báo cáo đọc ảnh*. Hai nguồn này có thể cùng được lưu dưới dạng văn bản nhưng mang vai trò khác nhau trong quy trình khám. Với mục tiêu dự đoán loại bệnh từ ảnh và thông tin sẵn có trước khi có kết luận X-quang, bệnh sử lâm sàng phù hợp hơn với điều kiện suy luận dự kiến của đề tài. Việc sử dụng cùng một loại văn bản trong cả hai pha huấn luyện còn giúp hạn chế sai khác phân phối đầu vào giữa pha căn chỉnh và pha phân loại.

Do đó, luận văn sử dụng ảnh X-quang và bệnh sử lâm sàng trong pipeline chính. Báo cáo đọc ảnh không được xem là một phương thức đầu vào tương đương, mà chỉ phù hợp cho các phân tích riêng về nguy cơ rò rỉ nhãn. Lựa chọn này không hàm ý rằng báo cáo X-quang không hữu ích trong các nhiệm vụ khác, chẳng hạn sinh báo cáo hoặc truy hồi ảnh–văn bản; nó chỉ phản ánh phạm vi dự đoán và điều kiện đánh giá của đề tài.

2.2 Mô hình ngôn ngữ – thị giác y khoa

2.2.1 Học biểu diễn tương phản ảnh–văn bản

Các mô hình ngôn ngữ – thị giác y khoa thường sử dụng một bộ mã hóa ảnh và một bộ mã hóa văn bản, sau đó đưa hai loại biểu diễn về cùng không gian để tối ưu một mục tiêu căn chỉnh. Với một mini-batch gồm các cặp ảnh và văn bản, mục tiêu tương phản làm tăng độ tương đồng của các cặp liên quan và giảm độ tương đồng của các cặp còn lại. Cơ chế này cho phép tận dụng văn bản đi kèm ảnh trong giai đoạn tiền huấn luyện hoặc thích nghi miền mà không nhất thiết phải xây dựng một bộ phân loại riêng cho từng nhãn.

ConVIRT [52] cho thấy khả năng học biểu diễn ảnh y khoa từ các cặp

ảnh–văn bản bằng mục tiêu tương phản hai chiều. GLoRIA [16] mở rộng căn chỉnh toàn cục bằng quan hệ cục bộ giữa vùng ảnh và từ. MedCLIP [43] xem xét vấn đề cặp âm tính giả và đề xuất Semantic Matching để sử dụng quan hệ ngữ nghĩa mềm thay cho giả định mỗi ảnh chỉ khớp với đúng một văn bản. BiomedCLIP [50] được tiền huấn luyện trên PMC-15M với ViT và PubMedBERT, qua đó cung cấp một điểm khởi tạo đa phương thức thuộc miền y sinh.

Trong dữ liệu bệnh lý, nhiều bệnh nhân cùng lớp có thể có các mô tả khác nhau nhưng vẫn chia sẻ nội dung ngữ nghĩa liên quan. Nếu mọi cặp không trùng chỉ số trong mini-batch đều bị xem là âm tính, mục tiêu một–một có thể tạo ra tín hiệu tối ưu chưa phù hợp. Semantic Matching là tiền đề gần với pha 1 của luận văn, trong đó các cặp cùng lớp được gán quan hệ mềm sau khi chuẩn hóa theo hàng, còn cặp ảnh–bệnh sử tương ứng vẫn giữ mức khớp cao nhất. Bảng 2.2 đối chiếu các mô hình theo bộ mã hóa, mục tiêu học và vai trò đối với pipeline.

Mô hình	Bộ mã hóa ảnh	Bộ mã hóa văn bản	Mục tiêu hoặc cơ chế chính	Vai trò đối với pipeline đề xuất
ConVIRT [52]	ResNet-50	BERT	Tương phản ảnh–văn bản hai chiều	Cơ sở cho học biểu diễn y khoa từ dữ liệu ghép cặp.
GLoRIA [16]	ResNet-50	BioClinical-BERT	Căn chỉnh toàn cục và cục bộ	Gợi ý rằng thông tin vùng ảnh và token văn bản có thể bổ sung cho biểu diễn toàn cục.
MedCLIP [43]	ResNet-50 hoặc Swin Transformer	BioClinical-BERT	Semantic Matching và dữ liệu không ghép cặp hoàn toàn	Cơ sở trực tiếp cho mục tiêu soft-target ở pha 1.
Biomed-CLIP [50]	ViT-Base	PubMed-BERT	Tiền huấn luyện tương phản trên PMC-15M	Backbone y sinh được kế thừa và thích nghi cho ảnh X-quang xương.

Bảng 2.2: So sánh các mô hình ngôn ngữ – thị giác y khoa có liên quan trực tiếp.

2.2.2 Lý do kế thừa mô hình nền tảng thay vì huấn luyện từ đầu

Huấn luyện một mô hình đa phương thức từ đầu thường cần số lượng lớn cặp ảnh–văn bản và tài nguyên tính toán đáng kể. Trong bài toán u xương, số mẫu ở từng lớp có thể hạn chế và phân bố lớp không đồng đều. Kế thừa BiomedCLIP giúp bắt đầu từ các bộ mã hóa đã có khả năng biểu diễn ngôn ngữ và hình ảnh y sinh, sau đó chỉ thích nghi các thành phần cần thiết cho miền X-quang xương. Tuy vậy, tiền huấn luyện trên dữ liệu y sinh rộng không bảo đảm mô hình đã phù hợp với phân bố đích; vì vậy, thích nghi miền và đánh giá bằng các đối chứng vẫn là cần thiết.

Các mô hình đa phương thức sinh văn bản quy mô lớn phù hợp hơn với hội thoại, hỏi–đáp hoặc sinh báo cáo. Do luận văn tập trung vào phân loại đóng, phát hiện OOD và phân tích attention, nhóm mô hình này không được khảo sát như một nhánh chính. Flamingo [2] chỉ được nhắc lại ở phần sau như một ví dụ về cơ chế gom token thị giác, thay vì làm nền tảng cho tác vụ sinh văn bản.

2.3 Biểu diễn ảnh độ phân giải cao và thông tin không gian

2.3.1 Giới hạn của phép co giãn ảnh toàn cục

Các backbone ViT được tiền huấn luyện thường sử dụng kích thước đầu vào cố định. Khi toàn bộ ảnh X-quang có kích thước lớn được co về một ảnh nhỏ, cấu trúc tổng thể vẫn được duy trì nhưng một số chi tiết cục bộ có thể bị làm mờ. Ngược lại, đưa trực tiếp ảnh độ phân giải cao vào Transformer làm tăng số token và chi phí attention. FPT [17] xem xét bài toán chuyển giao trên ảnh y khoa độ phân giải cao và sử dụng lựa chọn token cùng mạng nhánh để giảm yêu cầu bộ nhớ. Mặc dù cơ chế của FPT

khác pipeline trong luận văn, công trình này cho thấy cần xem xét đồng thời độ chi tiết và chi phí tính toán khi thích nghi mô hình nền tảng cho ảnh y khoa.

Một hướng khác là chuyển tập đặc trưng đầu vào lớn thành ngân sách latent cố định. Perceiver [18] sử dụng attention bất đối xứng để ánh xạ đầu vào có số phần tử lớn vào một tập latent nhỏ. Flamingo [2] sử dụng Perceiver Resampler để tạo số token thị giác cố định trước khi kết nối với mô hình ngôn ngữ. Các nghiên cứu này cung cấp cơ sở khái niệm cho việc kiểm soát ngân sách token, nhưng không đồng nghĩa với việc pipeline của luận văn sử dụng learned queries giống Perceiver.

2.3.2 Kết hợp ngữ cảnh toàn cục và vùng cục bộ

Đối với ảnh X-quang xương, nhánh toàn cục hỗ trợ duy trì vị trí giải phẫu và cấu trúc chung, trong khi các vùng cục bộ giữ lại thông tin chi tiết ở độ phân giải đầu vào của backbone. Tuy nhiên, nếu chỉ gom trung bình các token cục bộ, mô hình có thể mất thông tin về vị trí tương đối của từng vùng. Vì vậy, tọa độ đã chuẩn hóa có thể được bổ sung vào token trước khi dung hợp, với hệ số điều khiển để thông tin vị trí không lấn át nội dung ảnh.

Pipeline cuối cùng sử dụng một ảnh toàn cục (*global view*) và bốn ảnh cục bộ (*local view*) được chọn theo chiến lược chọn thưa có trọng tâm (*sparse-focal*) chỉ từ tín hiệu ảnh. Mỗi vùng cục bộ đóng góp CLS token và token tóm tắt patch; tám token được truyền trực tiếp qua mô-đun không gian có bổ sung tọa độ. Cách thiết kế này gần với một ngân sách token xác định hơn là một bộ resampler dùng truy vấn học được. Hiệu quả của toàn bộ nhánh ảnh độ phân giải cao cần được kiểm chứng bằng thí nghiệm loại bỏ thành phần, thay vì được giả định từ các công trình dùng kiến trúc khác. Nếu cần tách riêng đóng góp của tọa độ, quy trình thực nghiệm phải bổ sung một cấu hình chỉ tắt thành phần này trong khi giữ nguyên cách chọn vùng. Những đánh đổi chính được tổng hợp trong Bảng 2.3.

Chiến lược	Đặc điểm	Khả năng đáp ứng	Hạn chế cần xem xét
Co giãn ảnh toàn cục	Một ảnh được đưa về kích thước cố định	Chi phí thấp, duy trì bộ cục tổng thể	Có thể làm giảm chi tiết cục bộ nhỏ.
Xử lý trực tiếp ảnh độ phân giải cao	Tăng kích thước ảnh hoặc số patch	Giữ nhiều chi tiết hơn	Tăng bộ nhớ và chi phí attention; FPT [17] xem xét sự đánh đổi này.
Latent resampling	Nén tập token đầu vào vào số latent cố định	Kiểm soát độ dài chuỗi	Hiệu quả phụ thuộc dữ liệu và cách tối ưu truy vấn học được; đại diện bởi Perceiver [18] và Flamingo [2].
Global-local với token cố định	Kết hợp ảnh toàn cục, các vùng cục bộ và tọa độ	Cân bằng ngữ cảnh, chi tiết và ngân sách token	Phụ thuộc vào quy tắc chọn vùng; cần đánh giá bằng ablation trên cùng dữ liệu.

Bảng 2.3: Các chiến lược xử lý ảnh độ phân giải cao và sự đánh đổi chính.

2.4 Tinh chỉnh hiệu quả tham số

2.4.1 Các nhóm phương pháp

Tinh chỉnh toàn bộ tham số cho phép mô hình thay đổi linh hoạt theo dữ liệu đích, nhưng yêu cầu lưu gradient và trạng thái optimizer cho toàn bộ mô hình nền (backbone). Dò tuyến tính (*linear probing*) giảm chi phí bằng cách chỉ học đầu phân loại, song giới hạn khả năng thích nghi biểu diễn. Các phương pháp PEFT nằm giữa hai lựa chọn này: phần lớn trọng số tiền huấn luyện được giữ cố định, còn một tập tham số nhỏ được thêm vào hoặc lựa chọn để cập nhật.

Prompt tuning học các token đầu vào hoặc prompt trung gian; PLIP [49], BiomedCoOp [20] và FPT [17] là các ví dụ trong ảnh y khoa. Adapter tuning chèn các mô-đun nhỏ vào mạng hoặc giữa các backbone; FTB [33] đại diện cho hướng học khối kết nối đa phương thức. Những nghiên cứu này có giá trị so sánh, nhưng pipeline của luận văn không triển khai prompt

tuning làm thành phần chính.

2.4.2 Thích nghi hạng thấp

LoRA [14] giữ cố định ma trận trọng số tiền huấn luyện W và biểu diễn phần cập nhật bằng tích hai ma trận hạng thấp:

$$W' = W + \Delta W, \quad \Delta W = BA, \quad (2.1)$$

trong đó $A \in \mathbb{R}^{r \times k}$, $B \in \mathbb{R}^{d \times r}$ và $r \ll \min(d, k)$. Cách tham số hóa này giảm số tham số được tối ưu so với cập nhật toàn bộ W . LCB [26] khảo sát PEFT trên các mô hình nền tảng thị giác y khoa và cung cấp thêm bằng chứng thực nghiệm cho việc sử dụng LoRA trong miền y tế.

LoRA khác với selective tuning thuần túy vì nó bổ sung các ma trận có thể học, thay vì chỉ chọn một tập con trọng số gốc. LoRA cũng khác QLoRA ở chỗ QLoRA kết hợp thích nghi hạng thấp với lượng tử hóa trọng số nền. Pipeline của luận văn sử dụng LoRA không lượng tử hóa và không khảo sát QLoRA, nên không đưa ra kết luận thực nghiệm về ảnh hưởng của lượng tử hóa. Các adapter được giữ tách rời sau pha 1 để có thể tiếp tục nhận gradient trong pha 2; việc hợp nhất rồi đóng băng chỉ phù hợp như một cấu hình thí nghiệm loại bỏ thành phần. Bảng 2.4 đặt lựa chọn này trong tương quan với các chiến lược thích nghi khác.

2.5 Dung hợp đa phương thức và huấn luyện hai pha

2.5.1 Từ phép nối đặc trưng đến chú ý chéo

Phép nối đặc trưng toàn cục là một baseline đơn giản: hai vector ảnh và văn bản được ghép trước khi đưa vào MLP. Cơ chế này cho phép bộ phân loại sử dụng cả hai nguồn dữ liệu nhưng không mô hình hóa tương quan hệ giữa các token. Chú ý chéo cho phép một phương thức truy

Chiến lược	Tham số được cập nhật	Đặc điểm	Mức liên quan với luận văn
Tinh chỉnh toàn phần	Toàn bộ backbone và đầu ra	Khả năng thích nghi cao nhưng chi phí huấn luyện lớn	Đối chứng về hiệu năng và tài nguyên.
Dò tuyến tính	Chỉ đầu phân loại tuyến tính	Backbone được giữ cố định; chi phí huấn luyện thấp	Đối chứng cho mức độ hữu ích của biểu diễn chưa thích nghi.
Prompt tuning	Prompt hoặc token có thể học	Giữ phần lớn backbone cố định; hiệu quả phụ thuộc thiết kế prompt	Hướng liên quan nhưng không phải thành phần pipeline chính [49, 20, 17].
Adapter / khối nối	Mô-đun nhỏ được chèn thêm	Có tính mô-đun; có thể tăng độ sâu đường suy luận	Tham khảo cho kết nối đa phương thức [33].
LoRA	Hai ma trận hạng thấp cho các lớp được chọn	Giảm số tham số huấn luyện và vẫn thích nghi biểu diễn	Chiến lược được dùng ở cả hai pha [14, 26].

Bảng 2.4: So sánh các chiến lược thích nghi mô hình nền tảng.

vấn phương thức còn lại:

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V. \quad (2.2)$$

Khi Q được tạo từ ảnh và (K, V) từ văn bản, biểu diễn ảnh được điều kiện hóa bởi token lâm sàng. Chiều ngược lại cho phép biểu diễn văn bản nhận thông tin từ các token ảnh. TieNet [41] và IRENE [56] cho thấy attention có thể được sử dụng để mô hình hóa tương tác đa phương thức; tuy nhiên, chúng không trực tiếp xác nhận rằng chú ý hai chiều luôn tốt hơn phép nối trong mọi bộ dữ liệu.

Pipeline đề xuất vì vậy sử dụng chú ý chéo hai chiều như một giả thuyết thiết kế cần được kiểm chứng. Hai nhánh đầu ra được cộng residual với truy vấn toàn cục, chuẩn hóa và đưa qua MLP dung hợp. Các đối chứng gồm phép nối và chú ý một chiều được sử dụng để tách ảnh hưởng của cơ chế dung hợp khỏi ảnh hưởng của backbone hoặc dữ liệu đầu vào.

2.5.2 Vai trò của hai pha huấn luyện

Pha 1 thích nghi hai bộ mã hóa và mô-đun token không gian bằng Semantic Matching trên cặp ảnh X-quang và bệnh sử; mô-đun dung hợp và đầu phân loại chưa tham gia vào pha này. Mục tiêu của pha 1 là điều chỉnh không gian ảnh–văn bản trước khi tối ưu trực tiếp cho phân loại. Pha 2 tiếp tục cập nhật các LoRA adapter và mô-đun token không gian, đồng thời bắt đầu tối ưu mô-đun chú ý chéo. Cách tách hai pha là một tổng hợp thiết kế từ học tương phản y khoa, PEFT và dung hợp token; nó không được xem là bản sao nguyên vẹn của một công trình đơn lẻ.

Việc tiếp tục tối ưu LoRA trong pha 2 cho phép gradient phân loại tác động đến biểu diễn của hai phương thức trong phạm vi hạng thấp. Ngược lại, nếu hợp nhất và đóng băng LoRA ngay sau pha 1, mô-đun dung hợp phải thích nghi với một backbone cố định. Hai chiến lược này cần được so sánh trên cùng thiết lập để đánh giá vai trò của việc thích nghi liên tục.

2.6 Phân loại dựa trên tâm lớp và dữ liệu mất cân bằng

2.6.1 Từ prototypical networks đến tâm lớp thực nghiệm

Prototypical Networks [37] biểu diễn mỗi lớp bằng trung bình embedding của support set và phân loại query theo khoảng cách đến các prototype. Phương pháp này thường đi kèm episodic training nhằm mô phỏng tác vụ few-shot. SimpleShot [42] sử dụng quy tắc láng giềng gần nhất trong thiết lập one-shot và tâm trung bình của từng lớp trong thiết lập multi-shot; nghiên cứu này cũng xem xét phép trừ trung bình và chuẩn hóa L_2 mà không cần meta-learning. Vì vậy, biến thể multi-shot của SimpleShot là tiền đề gần hơn cho đầu empirical centroid so với một bộ phân loại kNN trên từng mẫu train.

Các ý tưởng trên tạo cơ sở cho phân loại theo tâm lớp, nhưng cần phân biệt với empirical centroid head của luận văn. Với lớp k , tâm lớp được tính từ toàn bộ mẫu huấn luyện hiện có:

$$c_k = \frac{1}{N_k} \sum_{i:y_i=k} z_i. \quad (2.3)$$

Sau khi chuẩn hóa L_2 , logit của mẫu z đối với lớp k được tính bằng độ tương đồng cosine có hệ số tỉ lệ α :

$$\ell_k(z) = \alpha \frac{z^\top c_k}{\|z\|_2 \|c_k\|_2}. \quad (2.4)$$

Các centroid là thống kê của tập huấn luyện, được lưu như buffer và không được optimizer cập nhật như tham số tự do. Khi encoder thay đổi, centroid được ước lượng lại từ embedding train. Vì vậy, pipeline không sử dụng Prototypical Loss dạng pull-push và cũng không cần episodic training để học prototype. Bảng 2.5 làm rõ sự khác biệt giữa centroid thực nghiệm và

các dạng đại diện lớp có nhận gradient.

Đầu phân loại	Cách xác định đại diện lớp	Cách huấn luyện	Nhận xét
Linear head	Trọng số học được cho từng lớp	Tối ưu bằng gradient cùng encoder hoặc riêng đầu ra	Linh hoạt nhưng thêm tham số phân loại.
Prototype học được	Vector lớp là tham số tự do	Tối ưu trực tiếp bằng loss phân loại hoặc metric loss	Có thể lệch khỏi trung bình embedding train nếu không có ràng buộc.
Prototypical Networks [37]	Trung bình support set trong từng episode	Episodic training trên support-query	Nền tảng của phân loại theo prototype trong few-shot.
SimpleShot [42]	Mẫu support trong one-shot hoặc trung bình lớp trong multi-shot	Không dùng meta-learning; biến đổi đặc trưng trước phân loại láng giềng	Tiền đề gần với phân loại theo tâm lớp trên đặc trưng chuẩn hóa.
Empirical centroid	Trung bình toàn bộ embedding train của mỗi lớp	Centroid cố định trong epoch và được ước lượng lại khi encoder đổi	Phù hợp với mục tiêu đầu phân loại phi tham số của luận văn.

Bảng 2.5: Phân biệt các dạng đầu phân loại dựa trên trọng số và tâm lớp.

2.6.2 Cross-Entropy có trọng số theo số mẫu hiệu dụng

Khi số mẫu giữa các lớp chênh lệch, Cross-Entropy không trọng số có thể làm gradient bị chi phối nhiều hơn bởi các lớp phổ biến. Cui và cộng sự [7] đề xuất số mẫu hiệu dụng của lớp có N_k quan sát:

$$E_k = \frac{1 - \beta^{N_k}}{1 - \beta}, \quad 0 \leq \beta < 1, \quad (2.5)$$

và sử dụng trọng số tỉ lệ nghịch với E_k . Loss phân loại trong pha 2 có dạng:

$$\mathcal{L}_{\text{cls}} = -\frac{1}{N} \sum_{i=1}^N w_{y_i} \log p(y_i | z_i), \quad (2.6)$$

trong đó các trọng số được chuẩn hóa trên những lớp hiện diện. Phương pháp này điều chỉnh đóng góp của lớp trong hàm mục tiêu mà không tạo thêm mẫu tổng hợp. Hiệu quả thực tế vẫn phụ thuộc vào giá trị β , số mẫu và chất lượng biểu diễn, do đó cần được báo cáo cùng các chỉ số macro và kết quả theo lớp.

2.7 Phát hiện dữ liệu ngoài phân phối

2.7.1 Bài toán và nguyên tắc đánh giá

Phát hiện OOD nhằm gán một điểm bất thường cho mẫu không phù hợp với phân phối huấn luyện. Dữ liệu thuộc phân phối (In-Distribution – ID) nhưng khó vẫn có thể bị phân loại sai, trong khi một mẫu OOD đôi khi vẫn nhận logit cao ở một lớp đã biết. Vì vậy, xác suất dự đoán không nên được xem như bảo đảm về độ tin cậy.

Với điểm OOD $s(x)$ được quy ước càng lớn càng bất thường, ngưỡng từ chối phải được lựa chọn trên tập hiệu chỉnh độc lập với tập kiểm thử. Việc dùng mẫu OOD test để chọn phương pháp, tham số hoặc ngưỡng có thể làm sai lệch đánh giá. Pipeline khảo sát song song nhóm điểm dựa trên đầu ra và nhóm điểm dựa trên không gian đặc trưng; kết quả cuối cùng được báo cáo bằng AUROC, AUPR-Out và FPR@95TPR theo các kịch bản OOD được xác định trước. Trong quy ước đánh giá của luận văn, FPR@95TPR là tỷ lệ mẫu OOD bị chấp nhận nhầm như ID khi tỷ lệ chấp nhận đúng mẫu ID được giữ ở mức 95%.

2.7.2 Điểm dựa trên đầu ra mô hình

Maximum Softmax Probability (MSP) [12] sử dụng xác suất Softmax lớn nhất làm baseline; trong quy ước điểm bất thường có thể dùng $1 -$

$\max_k p_k(x)$. Entropy đánh giá độ phân tán của toàn bộ phân phối dự đoán. Maximum Logit [13] sử dụng logit lớn nhất trước Softmax và có thể giảm bớt ảnh hưởng của phép chuẩn hóa giữa các lớp.

Energy score [28] được tính từ vector logit $f(x)$:

$$E(x) = -T \log \sum_{k=1}^K \exp\left(\frac{f_k(x)}{T}\right), \quad (2.7)$$

trong đó T là nhiệt độ. Khi sử dụng quy ước trên, giá trị năng lượng lớn hơn được xem là bằng chứng OOD mạnh hơn. Các điểm đầu ra có ưu điểm là không cần lưu toàn bộ embedding train, nhưng có thể chịu ảnh hưởng của mức hiệu chuẩn và hình học của đầu phân loại.

2.7.3 Điểm dựa trên không gian đặc trưng

Lee và cộng sự [23] mô hình hóa đặc trưng theo phân bố Gaussian có điều kiện theo lớp và dùng khoảng cách Mahalanobis làm điểm tin cậy. Với embedding đã chuẩn hóa, tâm lớp c_k và ma trận hiệp phương sai dùng chung Σ ước lượng từ phần dư trong lớp, biến thể được sử dụng trong luận văn có dạng:

$$s_{\text{Maha}}(z) = \min_k (z - c_k)^\top \Sigma^{-1} (z - c_k). \quad (2.8)$$

Cách viết này khác với giả định một ma trận Σ_k riêng cho từng lớp. Hiệp phương sai dùng chung giúp giảm số lượng đại lượng cần ước lượng khi một số lớp có ít mẫu; pipeline còn sử dụng shrinkage Ledoit–Wolf [22] khi ước lượng để cải thiện tính ổn định số.

Deep k-Nearest Neighbors [38] sử dụng khoảng cách đến các embedding train gần nhất và không cần giả định Gaussian. Trong luận văn, các vector được chuẩn hóa và khoảng cách cosine trung bình tới k láng giềng gần nhất được dùng làm điểm OOD. Phương pháp này linh hoạt hơn về hình dạng phân bố nhưng cần lưu tập đặc trưng tham chiếu và có chi phí truy vấn theo kích thước tập train nếu không dùng chỉ mục gần đúng.

Đối với mô hình ngôn ngữ – thị giác, MCM [30] sử dụng độ tương đồng giữa ảnh và các khái niệm văn bản để phát hiện OOD zero-shot. Theo hướng tương tự, mã nguồn hỗ trợ khoảng cách đến các mốc văn bản của

lớp ID. Tuy nhiên, phương pháp này chưa thuộc protocol OOD được khóa cho thí nghiệm chính, nên được xem là hướng mở rộng; muốn báo cáo như một kết quả kiểm định, cần bổ sung nó vào protocol và xác định trước cách xây dựng prompt, tập hiệu chỉnh và siêu tham số. Bảng 2.6 tổng hợp tín hiệu đầu vào và giả định của từng nhóm điểm OOD.

Phương pháp	Tín hiệu sử dụng	Giả định / đặc điểm	Vai trò trong đánh giá
MSP [12]	Xác suất Softmax	Baseline đơn giản; nhạy với dự đoán quá tự tin	So sánh đầu ra hậu xử lý.
Entropy	Phân phối xác suất	Xem xét độ phân tán trên tất cả lớp	Baseline bổ sung, không cần mô hình mới.
Maximum Logit [13]	Logit lớn nhất	Không chuẩn hóa qua tổng Softmax	So sánh với MSP và Energy.
Energy [28]	Toàn bộ vector logit	Điểm vô hướng hậu xử lý có nhiệt độ	Phương pháp đầu ra chính được khảo sát.
Mahalanobis [23]	Tâm lớp và hiệp phương sai	Giả định hình học Gaussian trong feature space	Điểm mật độ tham số trên embedding.
Cosine-kNN [38]	Láng giềng trong tập train	Phi tham số, không giả định dạng cụm	Điểm khoảng cách bổ sung cho Mahalanobis.
Mốc văn bản [30]	Tương đồng ảnh-khái niệm	Phụ thuộc prompt và khả năng căn chỉnh VLM	Hướng mở rộng đã được mã nguồn hỗ trợ nhưng chưa nằm trong protocol chính.

Bảng 2.6: Các nhóm điểm OOD có liên quan đến pipeline đánh giá.

2.8 Trực quan hóa và phân tích mức đóng góp

Grad-CAM [36] tạo bản đồ định vị theo lớp từ gradient và activation của mạng tích chập, qua đó cung cấp một baseline phổ biến cho trực quan

hóa vùng ảnh. Với Transformer, attention weight thường được sử dụng như một tín hiệu để khảo sát quan hệ token. Tuy nhiên, attention ở nhiều tầng làm thông tin nguồn bị trộn; attention rollout và attention flow [1] được đề xuất để tổng hợp đường truyền attention thay vì chỉ đọc một ma trận đơn lẻ.

Việc diễn giải attention cần được thực hiện thận trọng. Jain và Wallace [19] chỉ ra rằng attention weight không mặc nhiên tương ứng với mức quan trọng nhân quả của đầu vào. Vì vậy, bản đồ attention trong luận văn được xem là công cụ phân tích hành vi và hỗ trợ kiểm tra vị trí mô hình tập trung, không phải bằng chứng duy nhất giải thích quyết định hoặc thay thế đánh giá của bác sĩ.

Trong XBone-Net, attention từ nhánh văn bản đến token ảnh có thể được tổng hợp và chiếu ngược về tọa độ các vùng nguồn. Nếu một tập đánh giá có chú thích tổn thương, mức tập trung có thể được định lượng bằng tỷ lệ khối lượng attention nằm trong vùng tổn thương, tỷ lệ diện tích vùng tổn thương và tỷ số giữa hai đại lượng. So sánh với tỷ lệ diện tích giúp hạn chế kết luận dựa trên bản đồ nhiệt trực quan đơn thuần. Protocol CTCH hiện không báo cáo định vị không gian khi chưa có chú thích vùng tổn thương; do đó, công cụ này chỉ thể hiện khả năng hỗ trợ phân tích có điều kiện, không đồng nghĩa đã có kết quả định lượng định vị trong thí nghiệm chính. Các phép kiểm tra deletion/insertion hoặc gradient-based attribution có thể được dùng như phân tích bổ sung để đánh giá mức liên hệ giữa bản đồ và đầu ra mô hình. Bảng 2.7 phân biệt giá trị sử dụng và giới hạn của các tín hiệu trực quan hóa.

Hướng phân tích	Tín hiệu	Giá trị sử dụng	Giới hạn
Grad-CAM [36]	Gradient và activation	Bản đồ theo lớp cho mạng tích chập	Không trùng trực tiếp với attention của mô hình đa phương thức.
Attention trực tiếp	Trọng số giữa query và token	Thuận tiện để khảo sát tương tác ảnh–văn bản	Không mặc nhiên phản ánh đóng góp nhân quả [19].
Attention rollout / flow [1]	Attention qua nhiều tầng	Theo dõi sự truyền thông tin giữa các lớp Transformer	Vẫn là phép xấp xỉ hậu xử lý.
Định lượng trên vùng tổn thương	Attention đã chiếu về ảnh và chú thích vùng	Cho phép so sánh với tỷ lệ diện tích khi có annotation	Phụ thuộc chất lượng chú thích và phép chiếu token–pixel; chưa báo cáo cho CTCH khi thiếu chú thích vùng.

Bảng 2.7: Các hướng trực quan hóa và giới hạn diễn giải.

2.9 Bàn luận và khoảng trống nghiên cứu

2.9.1 Những điểm đã được hỗ trợ bởi nghiên cứu trước

Tổng quan cho thấy từng thành phần của pipeline đều có tiền đề trong các nhánh nghiên cứu hiện có. MedCLIP và BiomedCLIP hỗ trợ hướng căn chỉnh rồi thích nghi mô hình ngôn ngữ – thị giác y khoa. TieNet, IRENE và FTB cung cấp các ví dụ về tương tác ảnh–văn bản. LoRA tạo cơ sở cho thích nghi hạng thấp. Prototypical Networks và SimpleShot cung cấp góc nhìn về phân loại theo đại diện lớp, trong khi class-balanced loss điều chỉnh mức đóng góp không đồng đều giữa các lớp. Các phương pháp Mahalanobis, kNN, Energy và MCM cung cấp những điểm OOD có giả định bổ sung cho nhau.

Tuy vậy, kết quả từ các công trình này không trực tiếp chứng minh hiệu quả của tổ hợp cụ thể trên dữ liệu u xương. Phần lớn nghiên cứu sử dụng X-quang ngực, CT, ảnh mô bệnh học hoặc bộ dữ liệu tự nhiên; loại văn bản và phân bố lớp cũng khác nhau. Do đó, mỗi quyết định của XBone-Net cần được đánh giá bằng baseline và ablation trên cùng cách chia dữ liệu.

2.9.2 Khoảng trống đối với bài toán X-quang xương

Thứ nhất, nhiều công trình được khảo sát ở trên sử dụng báo cáo X-quang, trong khi điều kiện dự đoán của đề tài yêu cầu sử dụng thông tin có trước kết luận đọc ảnh. Điều này đặt ra nhu cầu kiểm soát nguồn văn bản và rò rỉ nhãn. Thứ hai, ảnh X-quang xương có thể chứa tổn thương cục bộ nhưng backbone chỉ nhận kích thước cố định, tạo sự đánh đổi giữa ngữ cảnh toàn cục và chi tiết. Thứ ba, dữ liệu hạn chế và mất cân bằng làm tăng nhu cầu về PEFT, đầu phân loại ít tham số và hàm mất mát có trọng số. Thứ tư, một hệ thống phân loại đóng cần cơ chế từ chối các mẫu khác phân phối. Cuối cùng, bản đồ attention cần được định lượng và trình bày với giới hạn diễn giải rõ ràng. Bảng 2.8 ánh xạ các khoảng trống này tới thành phần thiết kế và nội dung cần kiểm chứng.

2.9.3 Cơ sở hình thành pipeline đề xuất

Từ các phân tích trên, pipeline được xây dựng theo hai pha. Pha 1 thích nghi BiomedCLIP bằng LoRA và Semantic Matching trên cặp ảnh X-quang–bệnh sử lâm sàng; mô-đun token không gian thuộc nhánh thị giác cũng nhận gradient trong pha này. Pha 2 tiếp tục cập nhật LoRA và mô-đun token không gian, đồng thời tối ưu chú ý chéo hai chiều; empirical centroid được ước lượng từ embedding train và Cross-Entropy được tái trọng số theo số mẫu hiệu dụng. Sau huấn luyện, Mahalanobis và kNN được khớp trên đặc trưng train, còn các điểm dựa trên logit được tính trực tiếp từ đầu ra mô hình; ngưỡng của từng phương pháp được hiệu chỉnh

Vấn đề	Tiền đề nghiên cứu	Lựa chọn trong XBone-Net	Nội dung cần kiểm chứng
Kết hợp bối cảnh lâm sàng	Mei, TieNet và IRENE [29, 41, 56]	Ảnh X-quang và bệnh sử trước khi có kết luận đọc ảnh ở cả hai pha	So sánh đa phương thức với ảnh đơn thuần; đánh giá ảnh hưởng của báo cáo đọc ảnh trong pha căn chỉnh.
Căn chỉnh miền y sinh	MedCLIP và BiomedCLIP [43, 50]	Semantic Matching ở pha 1 trên backbone BiomedCLIP	So sánh với baseline không có pha căn chỉnh hoặc mục tiêu khác.
Ảnh độ phân giải cao	FPT, Perceiver và Flamingo [17, 18, 2]	Global view, local view và token có tọa độ với ngân sách cố định	Ablation nhánh độ phân giải cao; cần cấu hình bổ sung nếu muốn cô lập riêng tác động của tọa độ.
Thích nghi ít tham số	LoRA và LCB [14, 26]	LoRA tiếp tục được tối ưu qua hai pha	So sánh với tinh chỉnh toàn phần và chiến lược đóng băng sau pha 1.
Phân loại mất cân bằng	ProtoNet, SimpleShot và effective number [37, 42, 7]	Empirical centroid và weighted Cross-Entropy	Báo cáo Macro F1, kết quả theo lớp và ablation đầu phân loại/loss.
Phát hiện OOD	MSP, Energy, Mahalanobis, kNN và MCM [12, 28, 23, 38, 30]	Sáu điểm trong protocol chính; mốc văn bản là hướng mở rộng	So sánh trên các kịch bản xác định trước, hiệu chỉnh ngưỡng bằng validation và không dùng test để lựa chọn.
Phân tích vùng chú ý	Grad-CAM và attention flow [36, 1]	Chiều attention về ảnh; định lượng chỉ khi có chú thích vùng	Phân tích định tính trên CTCH và nêu rõ giới hạn; không báo cáo định vị nếu thiếu annotation.

Bảng 2.8: Liên hệ giữa khoảng trống nghiên cứu, lựa chọn thiết kế và nội dung đánh giá.

trên validation. Attention được trích xuất như một tín hiệu phân tích, chiếu về ảnh nguồn và đánh giá trên vùng tổn thương khi có chú thích.

Thiết kế này không giả định rằng mọi thành phần đều mang lại cải thiện trong mọi điều kiện. Vai trò của từng thành phần được chuyển thành các câu hỏi nghiên cứu và được kiểm tra bằng mốc đối chứng, thí nghiệm loại bỏ thành phần, chỉ số macro, đánh giá OOD và phân tích attention; chỉ số định vị chỉ được tính khi có chú thích vùng phù hợp. Kiến trúc, hàm mục tiêu và quy trình đánh giá cụ thể được trình bày trong Chương 3.

Chương 3

Phương pháp đề xuất

3.1 Tổng quan phương pháp đề xuất

Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế với khả năng học trong điều kiện ít mẫu và phát hiện dữ liệu ngoài phân phối. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Bộ mã hóa ảnh:** Kế thừa ViT-Base của BiomedCLIP [50], kết hợp nhánh ảnh toàn cục và lưới lát cục bộ độ phân giải cao.
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [50]
- **Bộ dung hợp dữ liệu:** Kỹ thuật Bidirectional Cross-Attention được xây dựng dựa trên cơ chế cross-attention nhằm học mối quan hệ ngữ nghĩa giữa đặc trưng hình ảnh và đặc trưng văn bản y khoa.
- **Bộ phân loại:** Dùng empirical centroid head không tham số; nhãn được quyết định bởi độ tương đồng cosine với trung tâm lớp tính trực tiếp từ embedding của tập train. Đặc trưng dung hợp đồng thời được dùng để hiệu chuẩn điểm OOD hậu xử lý trên tập validation.

Đồng thời, các trọng số attention được khai thác để trực quan hóa và giải thích kết quả dự đoán.

3.2 Pipeline cuối cùng

Để tránh lựa chọn mô hình hậu nghiệm theo kết quả kiểm thử, nghiên cứu cố định XBone-Net trước khi thực hiện các thí nghiệm rời rạc. Pipeline cuối cùng gồm các bước sau:

1. **Tiền xử lý ảnh độ phân giải cao:** pipeline loại bỏ vùng đệm máy chụp bằng quy tắc bảo toàn năng lượng tương phản thận trọng, tạo một global view giữ nguyên tỉ lệ và chọn đúng bốn local view 224×224 . Hai vùng bảo đảm độ phủ theo trục giải phẫu chính và hai vùng focal được chọn bằng năng lượng texture kết hợp phạt chồng lấp; toàn bộ quy trình chỉ dùng tín hiệu ảnh, không dùng nhãn, hộp tổn thương hay mô hình đề xuất vùng.
2. **Mã hóa đa tỉ lệ:** BiomedCLIP trích xuất một đặc trưng ảnh toàn cục và token cục bộ từ bốn vùng sparse-focal. Mỗi vùng giữ lại CLS token đã được tiền huấn luyện và một patch-summary token, tạo ngân sách cố định tám token. Bộ resampler nhẹ truyền trực tiếp các token này, đồng thời bổ sung embedding tọa độ đã chuẩn hóa qua một cổng vô hướng bị chặn để thông tin vị trí không lẫn át nội dung. Trong khi huấn luyện, gradient từ nhánh local được truyền vào visual LoRA; activation của từng nhóm tile được tính lại khi backward bằng gradient checkpointing để giới hạn bộ nhớ.
3. **Pha 1 – căn chỉnh ngữ nghĩa:** Vision Encoder và Text Encoder được thích nghi bằng LoRA với cặp ảnh–bệnh sử lâm sàng. Hàm Semantic Matching Loss sử dụng quan hệ đồng lớp làm mục tiêu mềm. Báo cáo kết quả X-quang không được dùng vì có nguy cơ chứa trực tiếp tên bệnh.
4. **Pha 2 – dung hợp và phân loại:** các LoRA adapter được giữ ở dạng tách rời và tiếp tục được tối ưu cùng bộ chú ý chéo hai chiều. Đầu empirical centroid được tính từ toàn bộ embedding train và không được cập nhật bởi optimizer. Hàm mục tiêu chỉ là Cross-Entropy có trọng số theo effective number.

5. **Suy luận và phát hiện OOD:** ảnh X-quang và bệnh sử lâm sàng đi qua đúng nhánh tiền xử lý và dung hợp của pha 2. Nhãn ID được xác định bởi empirical centroid có độ tương đồng lớn nhất; điểm OOD được hiệu chuẩn hậu xử lý trên đặc trưng dung hợp của tập validation, không dùng mẫu test để chọn ngưỡng.


Trọng số LoRA không được hợp nhất vào backbone sau pha 1 trong pipeline cuối cùng, vì thao tác này đồng thời làm mất khả năng tiếp tục thích nghi backbone ở pha 2. Phiên bản hợp nhất và đóng băng được giữ như một thí nghiệm rời rạc về chiến lược tối ưu.

3.3 Giai đoạn huấn luyện

Giai đoạn huấn luyện nhằm xây dựng bộ tham số cho mô hình, thiết lập không gian biểu diễn chung và học cách dung hợp giữa đặc trưng hình ảnh X-quang và ngữ nghĩa y khoa.

Giai đoạn huấn luyện gồm hai công đoạn: thích nghi miền (domain adaptation) và tinh chỉnh có giám sát. Công đoạn thứ nhất giúp mô hình thích nghi từ miền dữ liệu tiền huấn luyện sang ảnh X-quang xương; công đoạn thứ hai tối ưu đồng thời biểu diễn, dung hợp đa phương thức và phân loại trên tập dữ liệu mục tiêu.

3.3.1 Học biểu diễn với kỹ thuật LoRA



Hình 3.1: Sơ đồ chung của hệ thống trong công đoạn học biểu diễn.

Trong công đoạn này, mô hình học biểu diễn để các cặp ảnh X-quang và bệnh sử lâm sàng tương ứng nằm gần nhau trong không gian chung bằng hàm mất mát khớp ngữ nghĩa (Semantic Matching Loss). Việc dùng cùng nguồn văn bản clinical ở cả hai pha bảo đảm nhất quán giữa huấn luyện và suy luận, đồng thời loại bỏ báo cáo kết quả X-quang có nguy cơ rò rỉ nhãn. Dữ liệu được đưa vào hai bộ mã hóa, chiếu vào không gian chung và chuẩn hóa trước khi tính độ tương đồng. Các mẫu cùng lớp tạo thành cụm ngữ nghĩa, trong khi các mẫu khác lớp được tách biệt.

Nhóm thực hiện tinh chỉnh (fine-tuning) đồng thời Vision Encoder và Text Encoder bằng kỹ thuật LoRA (Low-Rank Adaptation). LoRA được lựa chọn vì đây là phương pháp tinh chỉnh hiệu quả về tham số, cho phép thích nghi BioMedCLIP với miền ảnh X-quang xương mà vẫn bảo toàn tri thức tiền huấn luyện.

Mặc dù nghiên cứu sử dụng toàn bộ dữ liệu hiện có, nhiều lớp vẫn chỉ

chứa số lượng mẫu rất ít. Do đó, bài toán ở cấp độ từng lớp mang đặc tính few-shot, và LoRA giúp hệ thống duy trì khả năng thích nghi tốt trong các trường hợp này. Nghiên cứu lựa chọn LoRA thay vì QLoRA vì mục tiêu chính là thích nghi miền hiệu quả trong điều kiện dữ liệu hạn chế, thay vì tối ưu bộ nhớ cho các mô hình siêu lớn. BioMedCLIP có quy mô tham số vừa phải, cho phép huấn luyện hiệu quả với LoRA trên phần cứng hiện có mà không cần lượng tử hóa. Ngoài ra, việc giữ nguyên trọng số ở độ chính xác đầy đủ giúp bảo toàn các đặc trưng hình ảnh tinh vi của ảnh X-quang xương, vốn rất quan trọng đối với việc nhận diện các tổn thương nhỏ và các lớp hiếm.

Để cập nhật trọng số của ma trận LoRA, nhóm sử dụng **Hàm mất mát Khớp ngữ nghĩa (Semantic Matching Loss - $\mathcal{L}_{SM}$)** nhằm đồng bộ hóa không gian biểu diễn đa phương thức. Loss tương phản gốc của BioMedCLIP (InfoNCE) giả định quan hệ một-một giữa ảnh và văn bản. Giả định này chưa phù hợp khi nhiều bệnh nhân thuộc cùng một lớp bệnh có các mô tả lâm sàng khác nhau nhưng vẫn chia sẻ nội dung ngữ nghĩa liên quan đến lớp.

Vì vậy, nghiên cứu thay thế mục tiêu một-một bằng Semantic Matching Loss nhằm khai thác quan hệ đồng lớp giữa ảnh và văn bản, qua đó giảm ảnh hưởng của các cặp âm tính giả. Semantic Matching Loss không trực tiếp xử lý mất cân bằng dữ liệu; ở pha phân loại đa lớp, nghiên cứu sử dụng Cross-Entropy có trọng số theo effective number và label smoothing để tăng ảnh hưởng của các lớp hiếm.

Mức độ tương đồng Cosine giữa đặc trưng ảnh z_i^I và đặc trưng văn bản z_j^T :

$$\text{sim}(z_i^I, z_j^T) = \frac{z_i^I \cdot z_j^T}{\|z_i^I\| \|z_j^T\|} \quad (3.1)$$

Hàm mất mát được sử dụng là Semantic Matching Loss $\mathcal{L}_{SM}$ được định nghĩa dựa trên ma trận mục tiêu mềm s_{ij} :


$$\mathcal{L}_{SM} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N s_{ij} \log \frac{\exp(\text{sim}(z_i^I, z_j^T)/\tau)}{\sum_{k=1}^N \exp(\text{sim}(z_i^I, z_k^T)/\tau)} \quad (3.2)$$

trong đó, N là kích thước mini-batch, s_{ij} là ma trận mục tiêu xác định

các mẫu chung lớp, và τ là siêu tham số nhiệt độ (temperature) giúp điều chỉnh độ nhạy của hàm phạt đối với các mẫu âm tính (negative samples). Bằng cách tối ưu $\mathcal{L}_{SM}$, mô hình đẩy các đặc trưng giải phẫu X-quang cục bộ hội tụ chặt chẽ về đúng định nghĩa y khoa của chúng trong không gian chung.

Công đoạn thích nghi miền giúp các cặp ảnh và bệnh sử lâm sàng cùng lớp hội tụ trong không gian biểu diễn, thay vì xem mọi cặp không trùng chỉ số là âm tính như mục tiêu tương phản một-một. Trong pha 1, đạo hàm từ $\mathcal{L}_{SM}$ cập nhật các ma trận $A \in \mathbb{R}^{r \times k}$ và $B \in \mathbb{R}^{d \times r}$ (với hạng $r \ll \min(d, k)$) của LoRA. Sang pha 2, các adapter này không bị hợp nhất hay đóng băng mà tiếp tục được tối ưu cùng mô-đun dung hợp và bộ phân loại.

3.3.2 Học phân loại đa lớp với empirical centroid head



Hình 3.2: Sơ đồ chung của hệ thống trong công đoạn học phân loại đa lớp.

Trong công đoạn này, nhóm tối ưu khả năng khai thác và dung hợp dữ liệu bằng kỹ thuật chú ý chéo hai chiều để học liên hệ giữa đặc trưng toàn

cục của ảnh X-quang với token cục bộ của bệnh sử lâm sàng và giữa đặc trưng toàn cục của văn bản với token ảnh cục bộ.

Đầu vào của công đoạn này là các cặp ảnh X-quang và bệnh sử lâm sàng. Hai hướng cross-attention lần lượt dùng token ảnh toàn cục làm query trên chuỗi token văn bản và token văn bản toàn cục làm query trên chuỗi token ảnh. Mỗi output attention được cộng residual với global query tương ứng rồi chuẩn hóa để tạo hai nhánh tăng cường h_I và h_T . Chỉ $[h_I; h_T]$ được nối và đưa qua MLP dung hợp $1024 \rightarrow 512 \rightarrow 512$ cùng LayerNorm để tạo vector 512 chiều trước đầu phân loại; raw global embeddings không được nối lại và không có learned skip ở tầng fusion cuối. Sai khác giữa dự đoán và nhãn thực tế cập nhật LoRA adapter, các phép chiếu, hai khối cross-attention và MLP dung hợp; các centroid không nhận gradient.

Sau quá trình dung hợp đa phương thức, mỗi mẫu train được biểu diễn bởi vector đặc trưng $z_i \in \mathbb{R}^D$. Với lớp k có N_k mẫu, trung tâm thực nghiệm được tính trực tiếp bằng trung bình embedding:

$$c_k = \frac{1}{N_k} \sum_{i:y_i=k} z_i. \quad (3.3)$$

Các c_k được lưu dưới dạng buffer, không phải *learnable parameter* và không nhận gradient. Centroid được khởi tạo từ toàn bộ tập train trước pha 2, tính lại sau mỗi epoch bằng encoder hiện tại trước khi đánh giá validation, và tính lại một lần cuối từ checkpoint encoder tốt nhất trước khi lưu mô hình. Trong từng epoch, centroid được giữ cố định để gradient của hàm phân loại chỉ cập nhật LoRA adapter và mô-đun dung hợp. Cách xây dựng này là empirical centroid classifier đúng nghĩa mà không yêu cầu episodic training.

Mức độ tương đồng giữa embedding z_i và từng centroid được tính bằng cosine trên các vector chuẩn hóa L_2 :

$$s(z_i, c_k) = \frac{z_i \cdot c_k}{\|z_i\|_2 \|c_k\|_2}. \quad (3.4)$$

Điểm tương đồng được nhân với hệ số tỷ lệ cố định $\alpha = 15$ nhằm điều chỉnh độ sắc nét của phân bố xác suất, sau đó đưa qua Softmax:


$$p_{ik} = \frac{\exp(\alpha s(z_i, c_k))}{\sum_{j=1}^K \exp(\alpha s(z_i, c_j))}. \quad (3.5)$$

Hàm mất mát duy nhất trong pha 2 là Cross-Entropy có trọng số lớp:

$$\mathcal{L}_{P2} = -\frac{1}{N} \sum_{i=1}^N w_{y_i} \log p_{i,y_i}, \quad (3.6)$$

trong đó y_i là nhãn đúng và w_k tỷ lệ nghịch với effective number $(1 - \beta^{N_k})/(1 - \beta)$ của lớp k , sau đó được chuẩn hóa để trung bình trọng số của các lớp hiện diện bằng 1. Pipeline cuối cùng dùng $\beta = 0,999$ và không dùng label smoothing. Pull-push Prototypical Loss, margin và hệ số λ bị loại bỏ vì chúng tối ưu các prototype tham số thay vì phản ánh đúng định nghĩa empirical centroid. Mỗi lớp cấu hình phải xuất hiện trong train subset; với few-shot, bộ chia dữ liệu phải lấy đúng k mẫu cho từng lớp trước khi tính centroid.

3.4 Giai đoạn online



Hình 3.3: Sơ đồ chung của hệ thống trong giai đoạn online.

Sơ đồ của hệ thống trong giai đoạn online được trình bày trong Hình 3.3. Ảnh X-quang được đưa qua cùng nhánh ảnh toàn cục và lưới lát độ phân giải cao như khi huấn luyện; bệnh sử lâm sàng được mã hóa bởi nhánh văn bản. Hai nguồn đặc trưng được dung hợp bằng cross-attention hai chiều và MLP trước khi so sánh với các empirical centroid đã lưu để dự đoán nhãn bệnh lý. Song song, đặc trưng dung hợp được chấm điểm OOD bằng bộ phát hiện đã hiệu chuẩn trên tập validation; mẫu vượt ngưỡng được đánh dấu là ngoài phân phối thay vì chỉ dựa vào xác suất Softmax. Các trọng số attention có thể được chiếu ngược về tọa độ ảnh nguồn để tạo bản đồ nhiệt hỗ trợ giải thích dự đoán.

3.5 Đóng góp của phương pháp

- **Cơ chế Cross-Attention có hướng dẫn tri thức:** Việc sử dụng cơ chế Cross-Attention có hướng dẫn tri thức giúp mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Điều này không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.
- **Cơ chế fusion ở nhiều cấp độ:** Việc kết hợp đặc trưng toàn cục và cục bộ thông qua Cross-Attention hai chiều và MLP dung hợp giúp mô hình khai thác tối đa dữ liệu và học được các mối liên hệ phức tạp giữa hai nguồn dữ liệu, từ đó cải thiện hiệu suất phân loại và khả năng giải thích của mô hình.
- **Giảm nguy cơ suy giảm không gian ngữ nghĩa trong bối cảnh dữ liệu hạn chế:** Cơ chế cập nhật tham số bằng LoRA giúp các bộ mã hóa thích nghi với dữ liệu y khoa đích mà không làm mất mát các tri thức đã học. Điều này giúp hạn chế hiện tượng overfitting và giảm độ phức tạp tính toán.
- **Cơ chế phát hiện dữ liệu ngoài phân phối:** Empirical centroid cung cấp tâm lớp nhất quán với embedding train, còn ngưỡng OOD được hiệu chuẩn hậu xử lý trên tập validation mà không sử dụng dữ liệu test.

Chương 4

Thực nghiệm

Chương này mô tả các thực nghiệm được thực hiện gồm so sánh hiệu năng phân loại không mẫu của các mô hình nền tảng, so sánh hiệu năng phân loại đa lớp giữa mô hình đề xuất và các mô hình nền tảng khi huấn luyện trên BTXRD và CTCH, đánh giá khả năng phát hiện dữ liệu ngoài phân phối của XBone-Net trên CTCH, và phân tích hiệu chuẩn xác suất dự đoán. Ngoài ra, mô tả về các bộ dữ liệu, thiết lập thí nghiệm và nội dung thí nghiệm cùng với mục đích của các thí nghiệm này sẽ được trình bày.

4.1 Chuẩn bị dữ liệu

Nghiên cứu sử dụng bộ dữ liệu BTXRD được công bố [47] và bộ dữ liệu CTCH thu thập tại Bệnh viện Chấn thương Chỉnh hình. Phần dưới đây mô tả nguồn gốc của bộ dữ liệu cách thức thu thập, các bước tiền xử lý dữ liệu, cấu trúc dữ liệu và các số liệu thống kê liên quan đến bộ dữ liệu.

4.1.1 Bộ dữ liệu BTXRD

Bộ dữ liệu ảnh X-quang u xương BTXRD [47] được xây dựng phục vụ các nghiên cứu phân loại, định vị và phân vùng tự động khối u xương nguyên phát. Bộ dữ liệu gồm 3.746 hình ảnh, kèm theo các thông tin lâm sàng như giới tính, độ tuổi, vị trí cơ thể và góc chụp. Các ảnh có khối u

còn được gán nhãn lành tính hoặc ác tính, phân loại phụ, vị trí giải phẫu, hộp giới hạn và mặt nạ phân vùng thủ công.

Dữ liệu được thu thập từ ba nguồn: ba bệnh viện tại Trung Quốc, nền tảng Radiopaedia.org và cơ sở dữ liệu MedPix. Tại các bệnh viện, ảnh của bệnh nhân mắc u xương nguyên phát được thu thập từ tháng 7 năm 2013 đến tháng 7 năm 2023, với chẩn đoán được xác nhận bằng mô bệnh học hoặc bởi hai chuyên gia X-quang. Đối với Radiopaedia và MedPix, ảnh được hai chuyên gia tìm kiếm bằng các từ khóa liên quan đến u xương. Chỉ những ảnh có đầy đủ thông tin giới tính và độ tuổi mới được lựa chọn. Các mẫu thuộc vùng đầu, cổ, ngực và bụng bị loại bỏ do số lượng ít và chứa nhiều nhiễu; vì vậy, BTXRD chỉ gồm ảnh ở chi trên, chi dưới và xương chậu.

Trong quá trình gán nhãn, một bác sĩ chuyên khoa u xương có 10 năm kinh nghiệm sử dụng Labelme [35] để xác định mặt nạ phân vùng và hộp giới hạn khối u. Các chú thích sau đó được kiểm tra bởi một chuyên gia có 20 năm kinh nghiệm. Thông tin phân vùng và hộp giới hạn được lưu dưới dạng JSON, trong khi các nhãn lâm sàng được lưu trong các tệp CSV.

Cấu trúc bộ dữ liệu

Bộ dữ liệu này bao gồm tổng cộng 3.746 hình ảnh, trong đó phân bổ thành 1.879 ảnh xương bình thường, 1.525 ảnh u xương lành tính và 342 ảnh u xương ác tính. Dữ liệu hình ảnh được lưu dưới định dạng JPEG thang độ xám 8-bit, các dữ liệu về nhãn lâm sàng được lưu dưới định dạng CSV, và các thông tin về mặt nạ phân vùng cũng như hộp giới hạn được lưu dưới định dạng JSON. Cấu trúc thư mục của bộ dữ liệu được tổ chức như sau:

Trong đó:

- **images/**: Thư mục chứa toàn bộ hình ảnh chụp X-quang gốc của bệnh nhân dưới định dạng ảnh JPEG thang độ xám.
- **Annotations/**: Chứa các tệp JSON lưu tọa độ đa giác và hộp giới hạn. Các chú thích này thuộc dữ liệu công bố nhưng không được sử dụng trong các thí nghiệm hiện tại.


```
data/BTXRD/  
├── images/  
│   └── IMG000001.jpeg  
├── Annotations/  
│   └── IMG000001.json  
├── reports/  
│   ├── clinical_v2/  
│   │   └── IMG000001.txt  
│   ├── clinical/  
│   │   └── IMG000001.txt  
│   └── xray/  
│       └── IMG000001.txt  
├── dataset.csv  
├── btxrd-labels.csv  
└── btxrd-split.csv
```

Hình 4.1: Sơ đồ cấu trúc của bộ dữ liệu BTXRD

- **reports/**: Thư mục lưu trữ các nguồn văn bản phục vụ cho học máy đa phương thức:
 - **clinical/**: Chứa bệnh sử tổng hợp đã loại tên chẩn đoán trực tiếp.
 - **xray/**: Chứa mô tả X-quang tổng hợp từ nhãn bệnh lý và có thể chứa tên lớp.
- **dataset.csv**: Tập siêu dữ liệu thô gồm tuổi, giới tính, vùng xương, khớp, góc chụp và các cờ bệnh lý.
- **btxrd-labels.csv**: Tập lưu 10 cột chỉ báo lớp bệnh lý.
- **btxrd-split.csv**: Tập ánh xạ image_id vào một trong ba tập train, validate và tests.

Nguồn văn bản tổng hợp và giới hạn sử dụng

BTXRD công bố không kèm báo cáo tự do do bác sĩ viết. Các thư mục văn bản trong workspace đều được sinh bằng khuôn mẫu với hạt giống 42 và quy trình được mô tả trong Phụ lục ?? và cần được phân biệt như sau:

1. **clinical**: mỗi báo cáo gồm tuổi, giới tính, vị trí xương hoặc khớp, góc chụp, lý do vào viện, bệnh sử, khám thực thể và tiền sử. Quy trình không chèn tên của 10 lớp đích, nhưng vẫn chọn nhóm khuôn mẫu theo các cờ **tumor** và **malignant**, đồng thời sử dụng thông tin tổn thương nhiều xương và liên quan khớp từ **dataset.csv**.
2. **xray**: mô tả X-quang được sinh trực tiếp từ nhãn phân nhóm và các dấu hiệu điển hình, trong đó có thể xuất hiện tên chẩn đoán. Nguồn này được sử dụng nhằm mục đích hỗ trợ phân tích dữ liệu và trình bày không sử dụng trong quá trình huấn luyện.

Việc loại tên bệnh trực tiếp làm giảm dạng rò rỉ từ khóa, nhưng không khiến văn bản trở thành độc lập với nhãn vì quá trình sinh vẫn có điều kiện theo cờ u và ác tính. Do đó, mức cải thiện từ văn bản trên BTXRD được diễn giải như hiệu quả trên dữ liệu tổng hợp có điều kiện, không phải

bằng chứng trực tiếp về hiệu quả trên bệnh sử lâm sàng tự nhiên. Bảng 4.1 minh họa sự khác nhau giữa báo cáo lâm sàng và mô tả X-quang.

Thống kê số liệu

Nhằm cung cấp cái nhìn chi tiết và khách quan về cấu trúc dữ liệu, các bảng thống kê dưới đây trình bày phân bố số lượng mẫu hình ảnh theo các tập chia dữ liệu (Bảng 4.2) và phân bố theo các lớp u xương bệnh lý (Bảng 4.3).

Bộ dữ liệu được chia theo tỉ lệ 70% huấn luyện, 10% đánh giá và 20% kiểm thử. Tất cả các tập con đều được cân bằng theo các lớp bệnh lý. Bảng 4.3 cho thấy số lượng mẫu của mỗi lớp bệnh lý trong từng tập con, từ đó có thể thấy rằng các lớp bệnh lý phổ biến như u xương sụn và sarcoma xương chiếm tỷ lệ lớn trong bộ dữ liệu, trong khi các lớp hiếm gặp như u sụn màng hoạt dịch và u xơ xương chiếm tỷ lệ nhỏ hơn.

4.1.2 Bộ dữ liệu CTCH

Bộ dữ liệu hình ảnh X-quang xương CTCH được thu thập từ bệnh viện Chấn thương Chỉnh hình, bao gồm tổng cộng 400 hình ảnh X-quang từ 400 bệnh nhân khác nhau. Mỗi hình ảnh được gán nhãn với các thông tin lâm sàng bao gồm lý do vào viện, quá trình bệnh lý, tiền sử bệnh lý.


Cấu trúc bộ dữ liệu

Trong đó:

- **images/**: Thư mục chứa toàn bộ hình ảnh chụp X-quang gốc của bệnh nhân dưới định dạng ảnh JPEG thang độ xám.
- **reports/**: Thư mục lưu trữ hai nguồn văn bản phục vụ cho học máy đa phương thức:
 - **clinical/**: Chứa các báo cáo mô tả bệnh sử lâm sàng của từng bệnh nhân.

Hình ảnh X-quang	Bệnh sử tổng hợp canonical (clinical_v2)	Mô tả X-quang tổng hợp legacy
	Patient: 58-year-old male. Reason for admission: Pain and swelling of the tibia. Disease history: Swelling discovered 3 months ago; painless. Physical examination: Firm, fixed swelling on the tibia; mild local tenderness. Personal medical history: No significant medical history. Age-related musculoskeletal complaints; no prior bone surgeries. Radiographic evaluation: AP view of the tibia was obtained.	A musculoskeletal radiograph of the bone in standard projection with evidence of osteochondroma: a pedunculated or sessile bony projection with cartilage cap. Captured at standard radiographic technique. The overall appearance favors a benign process.
	Patient: 6-year-old male. Reason for admission: Persistent pain in the humerus. Disease history: Pain and swelling in the humerus for 1 year; progressively worsening. Physical examination: Tender swelling; overlying skin warm; reduced mobility. Personal medical history: History of mild hypertension; otherwise unremarkable. No significant past medical history. Age-appropriate development. Radiographic evaluation: AP view of the humerus was obtained.	A musculoskeletal radiograph of the bone in conventional radiographic view with evidence of osteosarcoma: an aggressive osteoblastic lesion with irregular periosteal new bone formation. In a routine clinical radiographic study. The imaging features raise concern for malignancy.
	Patient: 48-year-old female. Reason for admission: Pain and swelling of the hip bone. Disease history: Pain in the hip bone for 1 month; associated with decreased appetite. Physical examination: Palpable mass; tenderness on palpation; mild swelling. Personal medical history: No prior bone disease or fracture. No relevant surgical or medical history. Radiographic evaluation: AP view of the hip bone was obtained.	A musculoskeletal radiograph of the bone in standard projection with evidence of other mt: a destructive bone lesion with ill-defined borders suggestive of malignancy. In a high-resolution diagnostic acquisition. The imaging features raise concern for malignancy.

Bảng 4.1: Ví dụ các mẫu dữ liệu đa phương thức trong bộ dữ liệu BTXRD



Hình 4.2: Sơ đồ phân cấp cấu trúc dữ liệu CTCH

Tập dữ liệu	Số lượng hình ảnh	Tỷ lệ (%)
Huấn luyện	2.621	69,97%
Đánh giá	375	10,01%
Kiểm thử	750	20,02%
Tổng cộng	3.746	100,0%

Bảng 4.2: Phân bố hình ảnh theo các tập dữ liệu trong BTXRD

Nhãn bệnh lý	Train	Validation	Test	Tổng	Tỷ lệ
Bình thường (<i>normal</i>)	1.322	191	366	1.879	50,16%
U xương sụn (<i>osteochondroma</i>)	538	70	145	753	20,10%
Sarcoma xương (<i>osteosarcoma</i>)	200	32	65	297	7,93%
Đa u xương sụn (<i>multiple osteochondromas</i>)	189	29	45	263	7,02%
Nang xương đơn thuần (<i>simple bone cyst</i>)	149	17	40	206	5,50%
U lành tính khác (<i>other bt</i>)	83	8	24	115	3,07%
U tế bào khổng lồ (<i>giant cell tumor</i>)	54	8	31	93	2,48%
U sụn màng hoạt dịch (<i>synovial osteochondroma</i>)	35	7	9	51	1,36%
U ác tính khác (<i>other mt</i>)	27	5	13	45	1,20%
U xơ xương (<i>osteofibroma</i>)	24	8	12	44	1,17%
Tổng	2.621	375	750	3.746	100,00%

Bảng 4.3: Phân bố các lớp đơn nhãn sau chuẩn hóa trong bộ dữ liệu BTXRD

- **clinical_vi/**: Chứa các báo cáo mô tả bệnh sử lâm sàng của từng bệnh nhân bằng tiếng Việt.
- **xray/**: Chứa các văn bản mô tả phát hiện chẩn đoán hình ảnh trên phim X-quang.
- **xray_vi/**: Chứa các văn bản mô tả phát hiện chẩn đoán hình ảnh trên phim X-quang bằng tiếng Việt.
- **data_labeled.csv**: Tập bảng chứa siêu dữ liệu thô ban đầu.
- **ctch-labels.csv**: Tập lưu trữ ánh xạ các lớp bệnh lý của từng ảnh phục vụ cho huấn luyện phân loại.
- **ctch-split.csv**: Tập tin chỉ định phân tách phân bố tập dữ liệu (huấn luyện, đánh giá, kiểm thử).

Tiền xử lý dữ liệu

Dữ liệu gốc được thu thập từ bệnh viện Chấn thương Chỉnh hình có nhiều vấn đề như sau:

- Dữ liệu gốc được thu thập từ bệnh viện Chấn thương Chỉnh hình có nhiều loại ảnh khác nhau, bao gồm ảnh chụp X-quang, ảnh CT, ảnh MRI và các loại ảnh khác.
- Một ca khám có thể có nhiều ảnh chụp từ các vị trí giải phẫu khác nhau, từ 2 đến vài trăm ảnh, nhưng chỉ một trong số đó là đúng vị trí và có sự thể hiện rõ về bệnh lý ở mắt thị giác.
- Một bệnh nhân có thể tái khám nhiều lần, dẫn đến việc có nhiều mẫu dữ liệu tương tự.
- Nhiều ca khám thiếu hụt các trường thông tin quan trọng đến huấn luyện như không có chẩn đoán xác định, không có phân tích ảnh X-quang,...
- Đôi khi chẩn đoán xác định của bác sĩ là những căn bệnh về phần mềm (sụn, dây chằng, gân, cơ) không thể hiện được trên ảnh X-quang.

Nhóm nghiên cứu đã thực hiện các bước tiền xử lý dữ liệu để chuẩn hóa và làm sạch dữ liệu trước khi đưa vào huấn luyện mô hình. Các bước tiền xử lý bao gồm:

- Loại bỏ các ảnh không liên quan hoặc không có giá trị chẩn đoán, có các dụng cụ y tế (nẹp, đinh) che vùng tổn thương.
- Đánh dấu và phân loại các mẫu dữ liệu theo lớp bệnh lý của ảnh X-quang (nếu bệnh là gãy dây chằng thuộc về phần mềm thì nhãn vẫn là "bình thường" nếu ảnh không ghi nhận tổn thương về xương).
- Loại bỏ các ca khám trùng lặp, tái khám nhiều lần.
- Chuẩn hóa và biên dịch các báo cáo y khoa từ tiếng Việt sang tiếng Anh.
- Lọc các ca hiếm gặp, không đủ số lượng mẫu để làm dữ liệu ngoài phân phối.

4.2 Độ đo đánh giá

BTXRD và CTCH được thiết lập dưới dạng bài toán phân loại đa lớp đơn nhãn. Số lớp C phụ thuộc vào bộ dữ liệu: $C = 10$ đối với BTXRD và $C = 22$ đối với CTCH. Phần này chỉ trình bày bảy đại lượng được sử dụng trong báo cáo kết quả. Các chỉ số đánh giá được tính toán dựa trên các khái niệm cơ bản cho từng lớp $c \in \{1, 2, \dots, C\}$:

- **True Positive (TP_c):** Số lượng mẫu thuộc lớp c được dự đoán chính xác vào lớp c .
- **False Positive (FP_c):** Số lượng mẫu thuộc lớp khác nhưng bị mô hình dự đoán nhầm vào lớp c .
- **True Negative (TN_c):** Số lượng mẫu không thuộc lớp c được dự đoán chính xác không thuộc lớp c .
- **False Negative (FN_c):** Số lượng mẫu thuộc lớp c nhưng bị mô hình dự đoán nhầm vào lớp khác.

4.2.1 Độ chính xác

Mục đích: Đo tỷ lệ mẫu được phân loại đúng trên toàn bộ tập đánh giá.

Công thức:

$$\text{Acc} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(y_i = \hat{y}_i) \quad (4.1)$$

Lý do sử dụng: Độ chính xác cung cấp một chỉ số tổng quát, dễ diễn giải và thuận tiện khi đối chiếu với các nghiên cứu trước. Tuy nhiên, do độ đo này có thể bị chi phối bởi lớp phổ biến, nó được báo cáo cùng các độ đo cân bằng lớp; giá trị cao hơn là tốt hơn.

4.2.2 Độ chính xác cân bằng

Mục đích: Đo độ phủ trung bình của các lớp, qua đó phản ánh khả năng nhận diện cả lớp phổ biến và lớp ít mẫu.

Công thức:

$$\text{Balanced Acc} = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FN_c} \quad (4.2)$$

Lý do sử dụng: Độ chính xác cân bằng trao trọng số bằng nhau cho từng lớp nên phù hợp hơn độ chính xác khi dữ liệu mất cân bằng. Độ đo này cho biết mô hình có duy trì khả năng bao phủ trên các lớp hiếm hay không; giá trị cao hơn là tốt hơn.

4.2.3 Macro F1-Score

Mục đích: Đánh giá đồng thời độ chuẩn xác và độ phủ của từng lớp trước khi tổng hợp kết quả trên toàn bộ bài toán.

Công thức:

$$P_c = \frac{TP_c}{TP_c + FP_c} \quad (4.3)$$

$$R_c = \frac{TP_c}{TP_c + FN_c} \quad (4.4)$$

$$\text{Macro-F1} = \frac{1}{C} \sum_{c=1}^C \frac{2P_cR_c}{P_c + R_c} \quad (4.5)$$

Khi mẫu số bằng 0, mã đánh giá gán giá trị 0 cho thành phần tương ứng.

Lý do sử dụng: Macro-F1 lấy trung bình không trọng số trên các lớp và phạt các trường hợp có độ chuẩn xác hoặc độ phủ thấp. Vì vậy, đây là độ đo chính để chọn checkpoint và so sánh các mô hình trong nghiên cứu; giá trị cao hơn là tốt hơn.

4.2.4 Macro AUROC

Mục đích: Đánh giá khả năng mô hình xếp hạng mẫu của mỗi lớp cao hơn các mẫu không thuộc lớp đó trên toàn bộ các ngưỡng quyết định.

Công thức: Với x_c^+ và x_c^- lần lượt là mẫu dương và mẫu âm đối với phần còn lại của lớp c ,

$$\text{AUROC}_c = \Pr[p_c(x_c^+) > p_c(x_c^-)] + \frac{1}{2} \Pr[p_c(x_c^+) = p_c(x_c^-)] \quad (4.6)$$

$$\text{Macro AUROC} = \frac{1}{|\mathcal{C}_v|} \sum_{c \in \mathcal{C}_v} \text{AUROC}_c \quad (4.7)$$

trong đó $\mathcal{C}_v$ là tập lớp có đủ cả mẫu dương và mẫu âm.

Lý do sử dụng: Macro AUROC đánh giá chất lượng xếp hạng độc lập với một ngưỡng phân loại cố định và trao trọng số như nhau cho các lớp hợp lệ. Độ đo này bổ sung cho Macro-F1, vốn phụ thuộc vào quyết định argmax; giá trị cao hơn là tốt hơn.

4.2.5 AUROC-OOD

Giao thức OOD hiện chỉ áp dụng cho CTCH. Gọi $s(x)$ là điểm OOD, trong đó giá trị cao hơn biểu thị bằng chứng ngoài phân phối mạnh hơn.

Mục đích: Đánh giá khả năng xếp hạng mẫu OOD cao hơn mẫu trong phân phối (ID) trên toàn bộ các ngưỡng.

Công thức:

$$\text{AUROC}_{OOD} = \Pr[s(x_{ood}) > s(x_{id})] + \frac{1}{2} \Pr[s(x_{ood}) = s(x_{id})] \quad (4.8)$$

Lý do sử dụng: AUROC-OOD không phụ thuộc vào một điểm vận hành duy nhất và cho phép so sánh thống nhất các hàm điểm OOD khác nhau; giá trị cao hơn là tốt hơn.

4.2.6 FPR@95% ID-TPR

Mục đích: Đo tỷ lệ mẫu OOD bị chấp nhận nhầm như ID khi hệ thống phải giữ lại ít nhất 95% mẫu ID.

Công thức: Tỷ lệ chấp nhận đúng ID tại ngưỡng τ là

$$\text{IDTPR}(\tau) = \frac{1}{N_{id}} \sum_{x \in D_{id}} \mathbb{I}[s(x) \leq \tau] \quad (4.9)$$

Trong độ đo benchmark, τ_{95} được chọn trên đường ROC để tỷ lệ OOD bị chấp nhận nhầm là nhỏ nhất trong các ngưỡng thỏa $\text{IDTPR}(\tau) \geq 0.95$. Khi đó,

$$\text{FPR@95\%} = \frac{1}{N_{ood}} \sum_{x \in D_{ood}} \mathbb{I}[s(x) \leq \tau_{95}] \quad (4.10)$$

Lý do sử dụng: FPR@95% phản ánh trực tiếp chi phí chấp nhận nhầm OOD tại một mức duy trì dữ liệu ID cao, nên có ý nghĩa vận hành rõ hơn AUROC-OOD; giá trị thấp hơn là tốt hơn. Ngưỡng benchmark này được xác định từ cả score ID và OOD của tập đánh giá; nó khác với ngưỡng triển khai chỉ được hiệu chỉnh trên validation ID.

4.2.7 Khoảng tin cậy bootstrap 95%

Mục đích: Ước lượng độ bất định của Acc, Balanced Acc, Macro-F1, Macro AUROC, AUROC-OOD và FPR@95% trên tập đánh giá hữu hạn.

Công thức: Từ tập đánh giá D có N mẫu, ở lần lặp thứ b tạo $D^{*(b)}$ bằng cách lấy N mẫu có hoàn lại và tính

$$\hat{\theta}^{*(b)} = m\left(D^{*(b)}\right) \quad b = 1, \dots, B \quad (4.11)$$

với m là độ đo cần báo cáo. Khoảng tin cậy percentile 95% được xác định bởi

$$\text{CI}_{95\%}(\theta) = \left[Q_{0.025}\left(\{\hat{\theta}^{*(b)}\}_{b=1}^B\right) Q_{0.975}\left(\{\hat{\theta}^{*(b)}\}_{b=1}^B\right) \right] \quad (4.12)$$

trong đó Q_q là phân vị bậc q . Pipeline sử dụng $B = 10.000$ cho phân loại và $B = 2.000$ cho OOD.

Lý do sử dụng: Bootstrap không yêu cầu giả định phân phối chuẩn cho các độ đo phi tuyến như Macro-F1 hoặc AUROC và cung cấp miền bất định dễ báo cáo cùng ước lượng điểm. Khoảng tin cậy được dùng để mô tả độ ổn định của từng mô hình, không được diễn giải riêng như một kiểm định ý nghĩa cho chênh lệch giữa hai mô hình.

4.3 Thiết lập thực nghiệm

Phần này trình bày các thiết lập thực nghiệm, bao gồm môi trường phần cứng và phần mềm, cũng như các siêu tham số được sử dụng trong quá trình huấn luyện mô hình. Các thiết lập này nhằm đảm bảo tính nhất quán và khả năng tái tạo của các thí nghiệm.

4.3.1 Môi trường thực nghiệm

Mô hình đề xuất được chạy ba lần trong các điều kiện và siêu tham số giống nhau. Môi trường phần cứng được trình bày trong Bảng 4.4.

Thành phần	Cấu hình
GPU	1 × RTX 5060 Ti 16 GB VRAM
CPU	Intel Core Ultra 7 265KF
Bộ nhớ hệ thống	32 GB RAM
Độ chính xác số học	BF16 trong cả hai pha huấn luyện

Bảng 4.4: Môi trường phần cứng được thiết lập

Môi trường phần mềm được cố định theo tệp phụ thuộc của dự án và được tóm tắt trong Bảng 4.5.

Thành phần	Phiên bản
Python	3.11.15
Torch	2.11.0+cu128
CUDA runtime	12.8

Bảng 4.5: Phiên bản của các thư viện chính trong môi trường thí nghiệm

4.3.2 Tham số thực nghiệm

Các Bảng 4.6 và 4.7 dưới đây mô tả cấu hình siêu tham số của mô hình đề xuất. Các siêu tham số được lựa chọn dựa trên các nghiên cứu trước và thử nghiệm sơ bộ để tối ưu hóa hiệu suất mô hình trên cả hai bộ dữ liệu BTXRD và CTCH. Các siêu tham số này bao gồm độ phân giải ảnh đầu vào, bộ tối ưu hóa, tốc độ học, suy giảm trọng số, bộ điều chỉnh tốc độ học, tỷ lệ khởi động, kích thước lô, số epoch tối đa, số epoch dừng sớm, nhiệt độ tương phản (τ), trạng thái tham số Backbone, hạng LoRA (r), hệ số LoRA (α) và tỷ lệ bỏ học LoRA.

4.3.3 Tham số thực nghiệm

Siêu tham số	Pha 1
Độ phân giải ảnh đầu vào	1 ảnh global 224×224 và 4 tile cùng kích thước
Bộ tối ưu hóa	AdamW
Tốc độ học	5×10^{-5}
Suy giảm trọng số	1×10^{-4}
Bộ điều chỉnh tốc độ học	Cosine
Tỷ lệ khởi động	0.1
Kích thước lô	16
Số epoch tối đa	30
Số epoch dừng sớm	3 epochs
Nhiệt độ tương phản (τ)	0.07
Trạng thái tham số Backbone	Tinh chỉnh qua LoRA
Hạng QLoRA (r)	16
Hệ số QLoRA (α)	32
Tỷ lệ bỏ học QLoRA	0.1

Bảng 4.6: Bảng tổng hợp siêu tham số ở pha 1 và thiết lập của chúng

Siêu tham số	Pha 2
Độ phân giải ảnh đầu vào	Giống pha 1
Bộ tối ưu hóa	AdamW
Tốc độ học	1×10^{-4}
Suy giảm trọng số	1×10^{-4}
Bộ điều chỉnh tốc độ học	Cosine
Tỷ lệ khởi động	0.1
Kích thước lô	16
Số epoch tối đa	50
Số epoch dừng sớm	5 epochs
Nhiệt độ tương phản (τ)	Không áp dụng
Trạng thái tham số Backbone	Tinh chỉnh qua LoRA
Hạng QLoRA (r)	16
Hệ số QLoRA (α)	32
Tỷ lệ bỏ học QLoRA	0.1

Bảng 4.7: Bảng tổng hợp siêu tham số ở pha 2 và thiết lập của chúng

4.4 Nội dung thực nghiệm

Phần này trình bày các nhóm thí nghiệm được thực hiện trên hai bộ dữ liệu BTXRD và CTCH, bao gồm nội dung, mục đích và các mô hình sử dụng.

4.4.1 Đánh giá mô hình nền tảng

Thiết kế mô hình: Nhóm thí nghiệm này sử dụng bốn mô hình ngôn ngữ trực quan gồm CLIP, MedCLIP, PubMedCLIP và BiomedCLIP ở chế độ zero-shot. Toàn bộ tham số của backbone được giữ cố định; mô hình không được huấn luyện trên dữ liệu đích. Với mỗi lớp, tên lớp được đưa vào một mẫu prompt cố định để tạo biểu diễn văn bản. Nhãn dự đoán được xác định từ lớp có độ tương đồng lớn nhất giữa biểu diễn ảnh và biểu diễn văn bản.

Mục đích thực nghiệm: Thí nghiệm khảo sát khả năng chuyển trực tiếp tri thức đã tiền huấn luyện sang bài toán phân loại X-quang xương. Thiết lập này cung cấp một mốc tham chiếu không sử dụng mẫu huấn

luyện của bộ dữ liệu đích, qua đó cho phép xem xét mức độ phù hợp ban đầu của các mô hình ngôn ngữ trực quan

Dữ liệu và độ đo: Bốn mô hình được đánh giá độc lập trên tập kiểm thử của BTXRD và CTCH; các tập huấn luyện và đánh giá không được sử dụng. Các độ đo báo cáo gồm độ chính xác, độ chính xác cân bằng, Điểm Macro-F1 và Macro AUROC theo định nghĩa tại Mục 4.2. Do suy luận zero-shot là xác định khoảng tin cậy bootstrap 95% với $B = 10.000$ lần lấy mẫu lại được dùng để mô tả độ bất định do tập kiểm thử hữu hạn, thay vì độ biến thiên giữa các lần huấn luyện.

4.4.2 So sánh với các mô hình nền tảng

Thiết kế mô hình: Nhóm đối sánh có ba thiết lập bổ sung cho nhau:

1. Mẫu hạn chế:

XBone-Net, LoRA-BiomedCLIP và LoRA-PubMedCLIP được huấn luyện với 1, 10 hoặc 20 mẫu cho mỗi lớp ở tập huấn luyện, tập đánh giá và kiểm thử được giữ nguyên. Hai mô hình áp dụng kỹ thuật LoRA sử dụng quy trình hai pha, phép nổi đặc trưng và đầu phân loại tuyến tính.

2. Toàn bộ dữ liệu:

ResNet-50 và DenseNet-121 được tinh chỉnh toàn bộ với đầu tuyến tính và chỉ nhận ảnh. Các mô hình ngôn ngữ trực quan y khoa gồm CLIP, MedCLIP, PubMedCLIP và BiomedCLIP được tinh chỉnh toàn bộ, sử dụng ảnh cùng báo cáo lâm sàng, phép nổi đặc trưng và đầu tuyến tính.

3. Đối sánh tinh chỉnh hiệu quả tham số:

Hai mô hình BiomedCLIP và PubMedCLIP được áp dụng kỹ thuật LoRA. Hai mô hình này giữ phép nổi đặc trưng và đầu tuyến tính.

Mục đích thực nghiệm: Thiết lập mẫu hạn chế đánh giá khả năng học khi số mẫu gán nhãn bị giới hạn và mức suy giảm so với khi huấn luyện trên toàn bộ dữ liệu khi áp dụng kỹ thuật LoRA. Thiết lập toàn bộ dữ liệu cung cấp đối sánh tổng thể giữa mô hình ảnh đơn phương thức, các mô hình ngôn ngữ trực quan y khoa được tinh chỉnh và pipeline đề xuất.

Đối sánh tinh chỉnh hiệu quả tham số được dùng để xem xét liệu các mô hình ngôn ngữ trực quan y khoa có thể đạt được hiệu suất tương tự như mô hình tinh chỉnh toàn bộ khi chỉ được huấn luyện với một số lượng nhỏ tham số.

Dữ liệu và độ đo: Tất cả ba thiết lập được thực hiện trên BTXRD và CTCH với các tập huấn luyện, đánh giá, kiểm thử cố định. Kết quả chính được tổng hợp trên ba hạt giống 42, 123 và 456 bằng độ chính xác, độ chính xác cân bằng, điểm Macro-F1 và Macro AUROC; điểm Macro-F1 là độ đo dùng để chọn mô hình tốt nhất trên tập đánh giá. Khoảng tin cậy bootstrap 95% với $B = 10.000$ được tính trên tập kiểm thử. Nhằm so sánh với các mô hình nền tảng áp dụng kỹ thuật LoRA, số tham số có thể huấn luyện, GFLOPs, thông lượng và thời gian huấn luyện cũng được báo cáo.

4.4.3 Đánh giá thành phần

Thiết kế biến thể. Các biến thể kế thừa cấu hình của mô hình đề xuất ngoài thành phần đang khảo sát, dữ liệu, hạt giống và quy trình chọn checkpoint được giữ cố định. Bốn nhóm biến thể gồm:

1. **Tiền xử lý ảnh:** mô hình đề xuất dùng một ảnh toàn cục và bốn vùng tiêu điểm thưa. Biến thể **nohighres** dùng direct resize về 224×224 , còn **letterbox** giữ tỷ lệ ảnh và thêm biên đệm. Hai biến thể vẫn tạo tám token từ một ảnh để giữ ổn định đầu vào của mô-đun dung hợp.
2. **Tinh chỉnh:** mô hình đề xuất cập nhật adapter LoRA trong cả hai pha huấn luyện. Biến thể **no finetune** đóng băng các encoder được kế thừa từ BioMedCLIP [50] nhưng vẫn cho phép mô-đun lấy mẫu không gian được huấn luyện và **full finetune** cập nhật toàn bộ tham số mô hình kế thừa.
3. **Dung hợp:** cross-attention hai chiều của mô hình đề xuất được so sánh với phép nối đặc trưng và hai biến thể attention **một chiều ảnh sang văn bản, văn bản sang ảnh**.

4. **Đầu phân loại và cân bằng lớp:** đầu tính tâm cụm với trọng số lớp được so sánh với biến thể sử dụng đầu tuyến tính và biến thể giữ đầu tính tâm cụm nhưng loại bỏ trọng số lớp.

Mục đích thực nghiệm. Nhóm thí nghiệm lần lượt xem xét vai trò của việc bảo toàn chi tiết ảnh độ phân giải cao, chiến lược cập nhật mô hình kế thừa, hướng trao đổi thông tin giữa hai phương thức và lựa chọn đầu phân loại trong điều kiện mất cân bằng lớp. Thiết kế kế thừa cùng cấu hình giúp giới hạn thay đổi trong từng phép so sánh, từ đó hỗ trợ diễn giải chênh lệch theo thành phần.

Dữ liệu và độ đo. Toàn bộ đánh giá thành phần được thực hiện trên CTCH với ba hạt giống 42, 123 và 456. Các độ đo được sử dụng bao gồm độ chính xác, độ chính xác cân bằng, điểm Macro-F1 và Macro AUROC để đánh giá hiệu năng phân loại, kèm khoảng tin cậy bootstrap 95% với $B = 10.000$. Với nhóm tinh chỉnh và tiền xử lý ảnh, số tham số có thể huấn luyện, số tham số có thể huấn luyện, GFLOPs, thông lượng và thời gian huấn luyện được ghi nhận bổ sung để mô tả đánh đổi về tài nguyên.

4.4.4 OOD hậu xử lý

Thiết kế phương pháp. Phân tích OOD không huấn luyện lại mô hình phân loại mà sử dụng trọng số của CTCH ở ba hạt giống. Các bộ phát hiện được sử dụng dựa trên đặc trưng gồm khoảng cách Mahalanobis tới tâm lớp gần nhất và cosine kNN với $k = 5$; các bộ phát hiện dựa trên đầu ra gồm MSP, entropy chuẩn hóa, energy với $T = 1$ và negative max-logit. Thống kê của bộ phát hiện đặc trưng được ước lượng từ CTCH train. Ngưỡng vận hành được hiệu chỉnh chỉ trên CTCH validation-ID sao cho tỷ lệ từ chối ID xấp xỉ 5%, sau đó được khóa trước khi đánh giá.

Mục đích thực nghiệm. Nhóm thí nghiệm đánh giá liệu các điểm hậu xử lý có thể tách mẫu ngoài phân phối khỏi mẫu thuộc phân phối huấn luyện mà không thay đổi bộ phân loại hay không. Ba dạng sai lệch được xem xét riêng gồm khác biệt ngữ nghĩa bệnh, dịch chuyển miền ảnh và sự không nhất quán giữa ảnh với bệnh sử. Cách tách scenario này hạn chế việc quy mọi trường hợp bất thường về một nguồn sai lệch duy nhất.

Dữ liệu và độ đo. Tập ID gồm CTCH train để khớp bộ phát hiện, CTCH validation để hiệu chỉnh ngưỡng và CTCH test để đánh giá. Semantic OOD sử dụng archive `ctch_ood`; domain OOD sử dụng FracAtlas, trong đó Mahalanobis và kNN trên đặc trưng thị giác là phân tích chính; report mismatch được tạo bằng cách ghép ảnh với bệnh sử khác lớp, còn ghép cùng lớp là phân tích phụ. Hai độ đo chính là AUROC-OOD và FPR@95% ID-TPR; khoảng tin cậy bootstrap 95% được tính với $B = 2.000$ lần lấy mẫu lại. AUROC-OOD cao hơn và FPR@95% thấp hơn biểu thị khả năng phân tách tốt hơn.

4.4.5 Giải thích và biểu diễn

Thiết kế phương pháp. Phân tích sử dụng checkpoint XBone-Net canonical trên CTCH ở ba hạt giống. Với mỗi hạt giống, mẫu test được lấy phân tầng theo nhãn thật, tối đa hai mẫu mỗi lớp và không quá 44 mẫu. Integrated Gradients với 24 bước được áp dụng cho các token ảnh cục bộ; token bệnh sử được phân tích bằng can thiệp thay thế. Độ trung thực được kiểm tra bằng các đường deletion và insertion so với thứ tự ngẫu nhiên và thứ tự ít liên quan. Độ ổn định được khảo sát dưới nhiễu nhỏ, đồng thời classifier-randomization được dùng như một sanity check. Phần biểu diễn khảo sát sáu không gian gồm đặc trưng fused, ảnh toàn cục, tóm tắt ảnh cục bộ, văn bản toàn cục và hai hướng cross-attention.

Mục đích thực nghiệm. Phân tích attribution nhằm xác định mức độ phụ thuộc của dự đoán vào các token ảnh và bệnh sử, đồng thời kiểm tra liệu thứ hạng attribution có ổn định và phản ánh đầu ra của mô hình hay không. Phân tích biểu diễn khảo sát mức độ kết cụm theo lớp và khoảng cách giữa mẫu với tâm lớp trong từng không gian nhúng. CTCH chưa có annotation vùng tổn thương trong protocol, do đó nhóm này không báo cáo IoU, Dice hoặc độ chính xác định vị.

Dữ liệu và độ đo. Đặc trưng train và test của CTCH được dùng cho phân tích hình học; attribution chỉ được tính trên tập con test đã chọn. Các độ đo attribution gồm độ giảm logit và xác suất khi loại bỏ nhánh, completeness error của Integrated Gradients, AUC của đường deletion/insertion, tương quan hạng Spearman giữa các phương pháp,

độ ổn định dưới nhiễu và tương quan sau khi ngẫu nhiên hóa classifier. Chất lượng biểu diễn được mô tả bằng Silhouette cosine, Davies–Bouldin, Calinski–Harabasz, NMI, ARI, Balanced Acc của bộ phân loại tâm lớp gần nhất và kNN, cùng biên độ tương đồng tới tâm lớp đúng. Các đại lượng này được xem là chỉ báo định lượng hỗ trợ cho minh họa trực quan, không phải bằng chứng định vị tổn thương.

4.5 Kết quả thực nghiệm và thảo luận

Phần này trình bày các kết quả thí nghiệm đối với thí nghiệm có huấn luyện, giá trị trong bảng là trung bình $\pm$ độ lệch chuẩn mẫu trên ba hạt giống ngẫu nhiên 42, 123 và 456. Kết quả phân loại không mẫu được báo cáo bằng ước lượng điểm do quá trình suy luận có tính xác định. Giá trị tốt nhất theo từng cột và trong cùng một thiết lập được in đậm, khoảng tin cậy bootstrap 95% được lưu cho từng lần chạy.

4.5.1 Đánh giá mô hình nền tảng

Kết quả zero-shot trên hai bộ dữ liệu được trình bày trong Bảng 4.8 theo bốn độ đo chính đã xác định ở Mục 4.2.

Dữ liệu	Mô hình	Acc $\uparrow$	Balanced Acc $\uparrow$	Macro-F1 $\uparrow$	Macro AUROC $\uparrow$
BTXRD	CLIP	0.0640	0.1297	0.0631	0.4997
	MedCLIP	0.0387	0.0935	0.0075	0.4628
	PubMedCLIP	0.0893	0.1334	0.0690	0.5531
	BiomedCLIP	0.3427	0.1493	0.1289	0.5786
CTCH	CLIP	0.1540	0.2367	0.1307	0.8003
	MedCLIP	0.0179	0.0224	0.0043	0.4707
	PubMedCLIP	0.1016	0.1294	0.0698	0.7920
	BiomedCLIP	0.2556	0.2109	0.1659	0.8191

Bảng 4.8: Kết quả zero-shot trên BTXRD và CTCH, chữ đậm biểu thị giá trị tốt nhất theo từng bộ dữ liệu

Trên BTXRD, BiomedCLIP đạt giá trị cao nhất ở cả bốn độ đo. Khoảng tin cậy bootstrap 95% của Acc, Balanced Acc, Macro-F1 và Macro AUROC lần lượt là [0.3093; 0.3760], [0.1116; 0.1927], [0.0945; 0.1661] và

[0.5443; 0.6118]. Tuy nhiên, Macro-F1 và Balanced Acc vẫn thấp, cho thấy cấu hình zero-shot hiện tại chưa bao phủ đồng đều mười lớp BTXRD.

Trên CTCH, BiomedCLIP đạt Acc, Macro-F1 và Macro AUROC cao nhất, trong khi CLIP có Balanced Acc cao nhất. Macro-F1 của BiomedCLIP đạt 0.1659 với khoảng tin cậy [0.1263; 0.1966]; Balanced Acc của CLIP đạt 0.2367 với khoảng tin cậy [0.2055; 0.2648]. Kết quả này cho thấy thứ hạng mô hình phụ thuộc vào độ đo và chưa hỗ trợ việc sử dụng trực tiếp các mô hình nền tảng cho bài toán 22 lớp CTCH mà không thích ứng dữ liệu đích.

Dựa vào bảng số liệu trên, nhóm nghiên cứu nhận thấy BiomedCLIP là mô hình nền tảng có hiệu năng tốt nhất trong bối cảnh zero-shot, đặc biệt trên bộ dữ liệu BTXRD. Tuy nhiên, để đạt được hiệu quả cao hơn trong các bài toán phân loại đa lớp phức tạp như CTCH, cần thực hiện các bước tinh chỉnh và thích ứng mô hình với dữ liệu đích.

4.5.2 So sánh với các mô hình nền tảng

Kết quả khi sử dụng toàn bộ dữ liệu huấn luyện

Dữ liệu	Mô hình	Acc $\uparrow$	Balanced Acc $\uparrow$	Macro-F1 $\uparrow$	Macro AUROC $\uparrow$
BTXRD	ResNet-50	0.6071 $\pm$ 0.0140	0.3188 $\pm$ 0.0136	0.3291 $\pm$ 0.0102	0.7236 $\pm$ 0.0259
	DenseNet-121	0.6320 $\pm$ 0.0013	0.3694 $\pm$ 0.0150	0.3718 $\pm$ 0.0173	0.7717 $\pm$ 0.0173
	CLIP (full FT)	0.8036 $\pm$ 0.0273	0.5957 $\pm$ 0.0160	0.5787 $\pm$ 0.0252	0.8973 $\pm$ 0.0231
	MedCLIP (full FT)	0.8204 $\pm$ 0.0144	0.6125 $\pm$ 0.0235	0.6054 $\pm$ 0.0147	0.8599 $\pm$ 0.0330
	PubMedCLIP (full FT)	0.7884 $\pm$ 0.0285	0.6089 $\pm$ 0.0342	0.5723 $\pm$ 0.0577	0.9048 $\pm$ 0.0240
	BiomedCLIP (full FT)	0.8311 $\pm$ 0.0028	0.6062 $\pm$ 0.0254	0.5994 $\pm$ 0.0124	0.8865 $\pm$ 0.0165
	LoRA-BiomedCLIP	0.8302 $\pm$ 0.0008	0.6339 $\pm$ 0.0291	0.6326 $\pm$ 0.0217	0.8771 $\pm$ 0.0298
	LoRA-PubMedCLIP	0.8316 $\pm$ 0.0134	0.6457 $\pm$ 0.0319	0.6397 $\pm$ 0.0214	0.9031 $\pm$ 0.0170
	XBone-Net	0.8324 $\pm$ 0.0015	0.5878 $\pm$ 0.0106	0.6001 $\pm$ 0.0116	0.9383 $\pm$ 0.0072
CTCH	ResNet-50	0.4928 $\pm$ 0.0017	0.4126 $\pm$ 0.0106	0.4078 $\pm$ 0.0051	0.9145 $\pm$ 0.0037
	DenseNet-121	0.4818 $\pm$ 0.0052	0.4927 $\pm$ 0.0461	0.4367 $\pm$ 0.0238	0.9350 $\pm$ 0.0046
	CLIP (full FT)	0.5874 $\pm$ 0.0209	0.6217 $\pm$ 0.0359	0.5633 $\pm$ 0.0090	0.9290 $\pm$ 0.0387
	MedCLIP (full FT)	0.5590 $\pm$ 0.0389	0.5717 $\pm$ 0.0186	0.5151 $\pm$ 0.0216	0.9215 $\pm$ 0.0333
	PubMedCLIP (full FT)	0.5521 $\pm$ 0.0234	0.5589 $\pm$ 0.0614	0.5203 $\pm$ 0.0264	0.9279 $\pm$ 0.0214
	BiomedCLIP (full FT)	0.5969 $\pm$ 0.0253	0.6023 $\pm$ 0.0234	0.5540 $\pm$ 0.0080	0.9390 $\pm$ 0.0289
	LoRA-BiomedCLIP	0.5959 $\pm$ 0.0212	0.6092 $\pm$ 0.0243	0.5599 $\pm$ 0.0220	0.9334 $\pm$ 0.0216
	LoRA-PubMedCLIP	0.6203 $\pm$ 0.0105	0.6091 $\pm$ 0.0267	0.5816 $\pm$ 0.0102	0.9275 $\pm$ 0.0088
	XBone-Net	0.5830 $\pm$ 0.0065	0.6049 $\pm$ 0.0296	0.5646 $\pm$ 0.0084	0.9568 $\pm$ 0.0086

Bảng 4.9: Kết quả phân loại khi sử dụng toàn bộ dữ liệu, chữ đậm biểu thị giá trị tốt nhất theo từng cột trong mỗi bộ dữ liệu

Trên BTXRD, LoRA-PubMedCLIP đạt Macro-F1 và Balanced Acc cao nhất, trong khi XBone-Net đạt Acc và Macro AUROC cao nhất. Chênh

lệch cho thấy XBone-Net có khả năng xếp hạng xác suất tốt hơn trong bảng so sánh, nhưng chưa đạt kết quả cao nhất trên các độ đo cân bằng lớp. Trên CTCH, LoRA-PubMedCLIP đạt Acc và Macro-F1 cao nhất, CLIP được tinh chỉnh toàn bộ đạt Balanced Acc cao nhất, còn XBone-Net đạt Macro AUROC cao nhất. Vì thứ hạng thay đổi theo độ đo ở cả hai bộ dữ liệu, kết quả hiện tại phù hợp hơn với diễn giải về sự đánh đổi giữa các tiêu chí thay vì một kết luận vượt trội tổng thể.

Kết quả trong trường hợp mẫu học hạn chế

Dữ liệu	Shot	Mô hình	Acc $\uparrow$	Balanced Acc $\uparrow$	Macro-F1 $\uparrow$	Macro AUROC $\uparrow$
BTXRD	1	LoRA-BiomedCLIP	0.2560 $\pm$ 0.1068	0.2285 $\pm$ 0.0728	0.1675 $\pm$ 0.0670	0.6142 $\pm$ 0.0395
		LoRA-PubMedCLIP	0.3067 $\pm$ 0.0987	0.2225 $\pm$ 0.0288	0.1841 $\pm$ 0.0283	0.6433 $\pm$ 0.0222
		XBone-Net	0.2529 $\pm$ 0.0756	0.2107 $\pm$ 0.0719	0.1587 $\pm$ 0.0494	0.6172 $\pm$ 0.0249
	10	LoRA-BiomedCLIP	0.6809 $\pm$ 0.0301	0.4610 $\pm$ 0.0146	0.4121 $\pm$ 0.0139	0.8572 $\pm$ 0.0114
		LoRA-PubMedCLIP	0.6533 $\pm$ 0.0340	0.4602 $\pm$ 0.0078	0.4140 $\pm$ 0.0259	0.8579 $\pm$ 0.0243
		XBone-Net	0.6564 $\pm$ 0.0146	0.4685 $\pm$ 0.0379	0.4053 $\pm$ 0.0296	0.8477 $\pm$ 0.0165
CTCH	1	LoRA-BiomedCLIP	0.2028 $\pm$ 0.0175	0.2904 $\pm$ 0.0080	0.1976 $\pm$ 0.0049	0.8231 $\pm$ 0.0274
		LoRA-PubMedCLIP	0.1749 $\pm$ 0.0345	0.2451 $\pm$ 0.0482	0.1721 $\pm$ 0.0286	0.7848 $\pm$ 0.0279
		XBone-Net	0.2422 $\pm$ 0.0235	0.3407 $\pm$ 0.0737	0.2382 $\pm$ 0.0283	0.8388 $\pm$ 0.0334
	10	LoRA-BiomedCLIP	0.3986 $\pm$ 0.0321	0.5496 $\pm$ 0.0309	0.4272 $\pm$ 0.0219	0.9368 $\pm$ 0.0125
		LoRA-PubMedCLIP	0.3921 $\pm$ 0.0136	0.5466 $\pm$ 0.0126	0.4189 $\pm$ 0.0093	0.9269 $\pm$ 0.0099
		XBone-Net	0.3981 $\pm$ 0.0452	0.5563 $\pm$ 0.0408	0.4363 $\pm$ 0.0418	0.9350 $\pm$ 0.0070
	20	LoRA-BiomedCLIP	0.4410 $\pm$ 0.0152	0.6028 $\pm$ 0.0214	0.4794 $\pm$ 0.0171	0.9339 $\pm$ 0.0178
		LoRA-PubMedCLIP	0.4245 $\pm$ 0.0079	0.5887 $\pm$ 0.0148	0.4511 $\pm$ 0.0068	0.9354 $\pm$ 0.0062
		XBone-Net	0.4395 $\pm$ 0.0235	0.5909 $\pm$ 0.0084	0.4702 $\pm$ 0.0210	0.9499 $\pm$ 0.0011

Bảng 4.10: Kết quả few-shot của các thiết lập có đủ ba lần chạy; chữ đậm biểu thị giá trị tốt nhất trong từng mức shot và bộ dữ liệu

Trên BTXRD, không có mô hình dẫn đầu đồng thời bốn độ đo ở mức 1-shot hoặc 10-shot. LoRA-PubMedCLIP đạt Macro-F1 và Macro AUROC cao nhất ở cả hai mức, trong khi XBone-Net chỉ đạt Balanced Acc cao nhất ở mức 10-shot. Trên CTCH, XBone-Net đạt cao nhất cả bốn độ đo ở mức 1-shot. Khi tăng lên 10-shot, mô hình này vẫn có Macro-F1 và Balanced Acc cao nhất, còn LoRA-BiomedCLIP dẫn đầu Acc và Macro AUROC. Ở mức tối đa 20 mẫu mỗi lớp, LoRA-BiomedCLIP đạt ba độ đo phân loại theo quyết định cao nhất, trong khi XBone-Net giữ Macro AUROC cao nhất. Hai lớp hiếm của CTCH chỉ có lần lượt 19 và 16 mẫu huấn luyện, nhưng ba mô hình nhận cùng tập con nên phép đối sánh trong mức shot vẫn nhất quán.

4.5.3 Đánh giá thành phần

Kết quả của ba biến thể tiền xử lý ảnh trên ba lần chạy được trình bày trong Bảng 4.11.

Mô hình	Acc $\uparrow$	Balanced Acc $\uparrow$	Macro-F1 $\uparrow$	Macro AUROC $\uparrow$
XBone-Net (sparse-focal)	0.5830 ± 0.0065	0.6049 ± 0.0296	0.5646 ± 0.0084	0.9568 ± 0.0086
XBone-Net (letterbox)	0.5954 ± 0.0116	0.6028 ± 0.0488	0.5781 ± 0.0279	0.9581 ± 0.0064
XBone-Net (direct resize)	0.5914 ± 0.0587	0.5783 ± 0.0485	0.5547 ± 0.0118	0.9500 ± 0.0142

Bảng 4.11: Kết quả đánh giá thành phần tiền xử lý ảnh trên CTCH

Letterbox đạt trung bình cao nhất về Acc, Macro-F1 và Macro AUROC, còn sparse-focal đạt Balanced Acc cao nhất. Chênh lệch giữa letterbox và sparse-focal nhỏ so với độ lệch chuẩn ở Macro-F1 và Balanced Acc. Vì vậy, kết quả hiện tại chưa cho thấy một phương án dẫn đầu ổn định trên mọi độ đo. Direct resize có Macro-F1, Balanced Acc và Macro AUROC thấp nhất trong ba biến thể, nhưng độ biến thiên Acc của biến thể này cũng lớn hơn đáng kể. Các kết quả này chưa hỗ trợ kết luận rằng sparse-focal là lựa chọn tốt nhất trên toàn bộ tiêu chí; lợi ích của phương pháp này cần được cân nhắc cùng chi phí tính toán.

4.5.4 OOD hậu xử lý

Bảng 4.12 tổng hợp các phương pháp chính trong ba kịch bản OOD trên mô hình XBone-Net đã huấn luyện. Với domain OOD, bảng chỉ đưa vào Mahalanobis và kNN theo giao thức đánh giá chính.

Kịch bản	Phương pháp	AUROC-OOD $\uparrow$	FPR@95% $\downarrow$
Semantic OOD	Mahalanobis	0.6070 ± 0.0123	0.8939 ± 0.0572
	kNN	0.6046 ± 0.0199	0.9015 ± 0.0262
	MSP	0.5672 ± 0.0040	0.9242 ± 0.0131
	Entropy	0.5719 ± 0.0072	0.9394 ± 0.0347
	Energy	0.5962 ± 0.0232	0.9242 ± 0.0131
	Max-logit	0.5968 ± 0.0235	0.9242 ± 0.0131
Domain OOD	Mahalanobis	0.7389 ± 0.0127	0.7107 ± 0.0374
	kNN	0.6812 ± 0.0134	0.7966 ± 0.0393
Bệnh sử không tương hợp khác lớp	Mahalanobis	0.7106 ± 0.0091	0.8032 ± 0.0238
	kNN	0.7412 ± 0.0119	0.7519 ± 0.0312
	MSP	0.6350 ± 0.0059	0.8974 ± 0.0195
	Entropy	0.6575 ± 0.0129	0.8640 ± 0.0220
	Energy	0.7293 ± 0.0101	0.8191 ± 0.0113
	Max-logit	0.7253 ± 0.0122	0.8231 ± 0.0242

Bảng 4.12: Kết quả OOD hậu xử lý của XBone-Net trên CTCH; chữ đậm biểu thị kết quả tốt nhất trong từng kịch bản chính

Mahalanobis có kết quả cao nhất trong semantic OOD, nhưng AUROC-
 OOD chỉ đạt 0.6070 và FPR@95% vẫn ở mức 0.8939. Đối với domain OOD,
 Mahalanobis đạt AUROC-ODD 0.7389 và FPR@95% 0.7107, tốt hơn kNN
 trong hai phương pháp chính nhưng tỷ lệ chấp nhận nhầm OOD còn cao.
 Trong trường hợp bệnh sử không tương hợp khác lớp, kNN đạt kết quả tốt
 nhất với AUROC-ODD 0.7412 và FPR@95% 0.7519. Đối chứng ghép bệnh
 sử cùng lớp khó phân biệt hơn; kNN chỉ đạt AUROC-ODD 0.5580 ± 0.0111
 và FPR@95% 0.9292 ± 0.0121 .

Nhìn chung, các điểm hậu xử lý có tín hiệu xếp hạng nhất định đối
 với domain OOD và bệnh sử không tương hợp khác lớp, nhưng chưa tạo
 được điểm vận hành có tỷ lệ chấp nhận nhầm thấp. Do đó, kết quả hiện
 tại chưa đủ để xem các detector này như một cơ chế từ chối đáng tin cậy
 trong triển khai; chúng phù hợp hơn với vai trò phân tích ban đầu và cần
 được đánh giá thêm trên tập OOD đa dạng hơn.

4.5.5 Giải thích và biểu diễn

Các kết quả định lượng của XBone-Net trên 44 mẫu ở mỗi lần chạy
 được tóm tắt trong Bảng 4.13. Giá trị độ giảm dương cho biết đầu ra của
 lớp mục tiêu giảm khi nhánh tương ứng bị loại bỏ.

Kết quả của XBone-Net	Trung bình $\pm$ độ lệch chuẩn
Độ giảm logit khi bỏ nhánh image-from-text	4.2750 ± 0.1492
Độ giảm logit khi bỏ nhánh text-from-image	1.8471 ± 0.0877
Độ giảm xác suất khi bỏ nhánh image-from-text	0.3670 ± 0.0833
Độ giảm xác suất khi bỏ nhánh text-from-image	0.2082 ± 0.0180
Integrated Gradients completeness error	0.000092 ± 0.000012
Integrated Gradients relative completeness error	0.000669 ± 0.000055
Lợi thế deletion logit-AUC của token ảnh so với thứ tự ngẫu nhiên	0.0382 ± 0.0062
Lợi thế deletion logit-AUC của token bệnh sử so với thứ tự ngẫu nhiên	0.0116 ± 0.0042
Tương quan Spearman dưới nhiều nhỏ	0.8906 ± 0.0203
Tương quan Spearman sau khi ngẫu nhiên hóa classifier	0.3741 ± 0.2199
Tương quan Spearman giữa Integrated Gradients và gradient	0.0053 ± 0.0257

Bảng 4.13: Kết quả phân bổ mức đóng góp của XBone-Net trên CTCH

Hai nhánh cross-attention đều ảnh hưởng đến đầu ra; việc loại bỏ nhánh
 image-from-text tạo độ giảm logit và xác suất trung bình lớn hơn. Inte-
 grated Gradients có sai số completeness nhỏ và thứ hạng mức đóng góp
 tương đối ổn định dưới nhiễu. Tuy nhiên, lợi thế của thứ tự token được
 xếp hạng so với thứ tự ngẫu nhiên còn nhỏ, tương quan giữa Integrated

Gradients và gradient gần 0, và tương quan sau khi ngẫu nhiên hóa đầu phân loại vẫn là 0.3741 ± 0.2199 . Các kết quả này chỉ hỗ trợ một kết luận hạn chế về tính ổn định số học; chưa đủ để khẳng định mức đóng góp có độ trung thực hoặc tính đặc hiệu mô hình cao.

Không gian biểu diễn	Silhouette $\uparrow$	Davies–Bouldin $\downarrow$	NMI $\uparrow$	Tâm lớp Balanced Acc $\uparrow$
Dung hợp (fused)	-0.0301 ± 0.0068	2.6078 ± 0.0514	0.5371 ± 0.0041	0.6049 ± 0.0296
Ảnh toàn cục	-0.0977 ± 0.0070	4.1172 ± 0.0685	0.4617 ± 0.0147	0.5057 ± 0.0165
Tóm tắt ảnh cục bộ	-0.1444 ± 0.0059	4.5634 ± 0.2262	0.3886 ± 0.0117	0.4264 ± 0.0139
Văn bản toàn cục	-0.0978 ± 0.0143	3.5501 ± 0.0443	0.4952 ± 0.0018	0.5631 ± 0.0115
Image-from-text	-0.1006 ± 0.0069	3.7604 ± 0.0783	0.4703 ± 0.0067	0.5228 ± 0.0294
Text-from-image	-0.0981 ± 0.0173	3.4334 ± 0.0358	0.4963 ± 0.0080	0.5729 ± 0.0171

Bảng 4.14: Kết quả hình học biểu diễn của XBone-Net trên CTCH; chữ đậm biểu thị giá trị tốt nhất theo từng cột

Không gian dung hợp đạt giá trị tốt nhất trong sáu không gian ở bốn chỉ báo trong Bảng 4.14. Không gian này cũng đạt ARI 0.1842 ± 0.0177 và kNN Balanced Acc 0.5586 ± 0.0260 , cao nhất trong các không gian được khảo sát. Dù vậy, Silhouette vẫn âm, cho thấy các lớp còn chồng lấn trong không gian nhúng. Vì thế, kết quả chỉ cho thấy cấu trúc lớp của biểu diễn dung hợp tốt hơn tương đối so với các biểu diễn thành phần; chưa thể diễn giải thành sự phân tách cụm rõ ràng hoặc khả năng định vị tổn thương.

Chương 5

Kết luận và hướng phát triển

5.1 Kết luận

Khóa luận đã nghiên cứu và đề xuất một hệ thống phân loại ảnh X-quang xương đa phương thức kết hợp khả năng phát hiện dữ liệu ngoài phân phối nhằm hỗ trợ chẩn đoán các bệnh lý cơ xương khớp. Hệ thống khai thác đồng thời hai nguồn thông tin gồm ảnh X-quang và thông tin lâm sàng, từ đó tận dụng được tính bổ sung giữa hai phương thức dữ liệu để nâng cao hiệu quả phân loại.

Trên cơ sở mô hình nền BioMedCLIP, nghiên cứu áp dụng kỹ thuật tinh chỉnh tham số hiệu quả LoRA để thích nghi với miền dữ liệu X-quang xương mà không làm thay đổi toàn bộ trọng số của mô hình. Đặc trưng hình ảnh và văn bản được kết hợp thông qua cơ chế chú ý hai chiều, sau đó được huấn luyện bằng sự kết hợp giữa hàm mất mát Cross-Entropy và Prototypical Loss. Trong đó, Cross-Entropy đảm nhiệm nhiệm vụ tối ưu phân loại, còn Prototypical Loss giúp xây dựng không gian đặc trưng có tính phân biệt cao, tạo tiền đề cho giai đoạn phát hiện dữ liệu ngoài phân phối.

Đối với bài toán phát hiện dữ liệu ngoài phân phối, luận văn lựa chọn phương pháp Mahalanobis Distance theo cơ chế hậu xử lý (post-hoc), với không gian đặc trưng đã được học dựa vào mạng nguyên mẫu. Cách tiếp

cận này tận dụng trực tiếp không gian đặc trưng đã được học trong quá trình huấn luyện để đánh giá mức độ bất thường của mẫu kiểm thử mà không cần thay đổi kiến trúc hoặc huấn luyện lại mô hình. Điều này giúp nâng cao độ tin cậy của hệ thống khi triển khai trong các tình huống lâm sàng thực tế, nơi có thể xuất hiện các bệnh lý hoặc trường hợp chưa từng xuất hiện trong dữ liệu huấn luyện.

Các thực nghiệm được thực hiện trên bộ dữ liệu BTXRD kết hợp với bộ dữ liệu nội bộ CTCH đã cho thấy phương pháp đề xuất đạt hiệu quả tốt trong nhiệm vụ phân loại, đồng thời xây dựng được không gian đặc trưng phù hợp để hỗ trợ phát hiện dữ liệu ngoài phân phối. Kết quả cũng cho thấy việc kết hợp thông tin lâm sàng với ảnh X-quang giúp cải thiện khả năng nhận diện bệnh lý so với việc chỉ sử dụng một nguồn dữ liệu.

Nhìn chung, luận văn đã hoàn thành các mục tiêu nghiên cứu đã đề ra, bao gồm xây dựng mô hình phân loại đa phương thức dựa trên BioMed-CLIP, tối ưu biểu diễn đặc trưng bằng Prototypical Loss và tích hợp cơ chế phát hiện dữ liệu ngoài phân phối dựa trên khoảng cách Mahalanobis. Các kết quả đạt được là cơ sở cho việc phát triển các hệ thống hỗ trợ chẩn đoán có độ tin cậy cao hơn trong lĩnh vực chẩn đoán hình ảnh y khoa.

5.2 Hướng phát triển

Mặc dù đạt được những kết quả khả quan, phương pháp đề xuất vẫn còn một số hạn chế và có thể được mở rộng trong các nghiên cứu tiếp theo.

Thứ nhất, phương pháp phát hiện dữ liệu ngoài phân phối hiện được xây dựng theo hướng hậu xử lý bằng khoảng cách Mahalanobis. Các nghiên cứu tiếp theo có thể khảo sát những phương pháp OOD hiện đại hơn hoặc tích hợp trực tiếp mục tiêu phát hiện OOD vào quá trình huấn luyện để nâng cao khả năng phát hiện các trường hợp Near-OOD.

Thứ hai, phạm vi thực nghiệm của luận văn mới được đánh giá trên bộ dữ liệu BTXRD và bộ dữ liệu CTCH. Trong tương lai, cần mở rộng thực nghiệm trên nhiều bộ dữ liệu X-quang xương có quy mô lớn hơn cũng như đánh giá khả năng tổng quát hóa giữa các bệnh viện, thiết bị chụp và điều kiện thu nhận ảnh khác nhau.

Cuối cùng, hệ thống hiện tập trung vào hai nhiệm vụ chính là phân loại và phát hiện dữ liệu ngoài phân phối. Trong tương lai, có thể tích hợp thêm các phương pháp giải thích mô hình (Explainable AI) hoặc các mô hình ngôn ngữ lớn y khoa nhằm hỗ trợ sinh báo cáo chẩn đoán, giải thích kết quả dự đoán và tăng cường khả năng tương tác với bác sĩ trong quá trình hỗ trợ ra quyết định lâm sàng.

Tài liệu tham khảo

Tiếng Anh

- [1] Samira Abnar and Willem Zuidema. “Quantifying Attention Flow in Transformers”. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2020, pp. 4190–4197. DOI: 10.18653/v1/2020.acl-main.385. URL: <https://aclanthology.org/2020.acl-main.385/>.
- [2] Jean-Baptiste Alayrac et al. “Flamingo: a Visual Language Model for Few-Shot Learning”. In: *Advances in Neural Information Processing Systems*. Vol. 35. 2022, pp. 23716–23736. URL: https://papers.nips.cc/paper_files/paper/2022/hash/960a172bc7fbf0177ccccbb411a7c Abstract-Conference.html.
- [3] Shruthi Bannur et al. “Learning to exploit temporal structure for biomedical vision-language processing”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2023, pp. 15016–15027.
- [4] Lynn S. Bickley, Peter G. Szilagyi, and Richard M. Hoffman. *Bates’ Guide to Physical Examination and History Taking*. 13th. Lippincott Williams & Wilkins, 2020.
- [5] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing”. In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5.

- [7] Yin Cui et al. “Class-Balanced Loss Based on Effective Number of Samples”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, pp. 9268–9277. URL: https://openaccess.thecvf.com/content_CVPR_2019/html/Cui_Class-Balanced_Loss_Based_on_Effective_Number_of_Samples_CVPR_2019_paper.html.
- [8] Yin Dai and Yifan Gao. “TransMed: Transformers Advance Multi-modal Medical Image Classification”. In: *CoRR* abs/2103.05940 (2021). arXiv: 2103.05940. URL: <https://arxiv.org/abs/2103.05940>.
- [9] Ye Du, Nanxi Yu, and Shujun Wang. “Medical Knowledge Intervention Prompt Tuning for Medical Image Classification”. In: *IEEE Transactions on Medical Imaging* 44.12 (2025), pp. 4945–4959. DOI: 10.1109/TMI.2025.3584841.
- [10] Xiao Fang et al. “Aligning Medical Images with General Knowledge from Large Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15010. Springer Nature Switzerland, 2024.
- [11] Kaiming He et al. “Deep Residual Learning for Image Recognition”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016.
- [12] Dan Hendrycks and Kevin Gimpel. “A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks”. In: *International Conference on Learning Representations*. 2017. URL: <https://arxiv.org/abs/1610.02136>.
- [13] Dan Hendrycks et al. “Scaling Out-of-Distribution Detection for Real-World Settings”. In: *Proceedings of the 39th International Conference on Machine Learning*. Vol. 162. Proceedings of Machine Learning Research. PMLR, 2022, pp. 8759–8773. URL: <https://proceedings.mlr.press/v162/hendrycks22a.html>.
- [14] Edward J. Hu et al. “LoRA: Low-Rank Adaptation of Large Language Models”. In: *International Conference on Learning Representations*. 2022. URL: <https://openreview.net/forum?id=nZeVKeeFYf9>.

- [15] Gao Huang et al. “Densely Connected Convolutional Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017.
- [16] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [17] Yijin Huang et al. “Fine-grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-resolution Medical Image Classification”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15012. Springer Nature Switzerland, 2024, pp. 120–130. DOI: 10.1007/978-3-031-72390-2_12.
- [18] Andrew Jaegle et al. “Perceiver: General Perception with Iterative Attention”. In: *Proceedings of the 38th International Conference on Machine Learning*. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 4651–4664. URL: <https://proceedings.mlr.press/v139/jaegle21a.html>.
- [19] Sarthak Jain and Byron C. Wallace. “Attention is not Explanation”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, 2019, pp. 3543–3556. DOI: 10.18653/v1/N19-1357. URL: <https://aclanthology.org/N19-1357/>.
- [20] Taha Koleilat et al. “BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models”. In: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*. 2025, pp. 14766–14776.
- [21] Zhengfeng Lai et al. “CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts”. In: *Proceedings of the IEEE/CVF International*

- Conference on Computer Vision (ICCV) Workshops*. 2023, pp. 2374–2380.
- [22] Olivier Ledoit and Michael Wolf. “A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices”. In: *Journal of Multivariate Analysis* 88.2 (2004), pp. 365–411. DOI: 10.1016/S0047-259X(03)00096-4.
 - [23] Kimin Lee et al. “A Simple Unified Framework for Detecting Out-of-Distribution Samples and Adversarial Attacks”. In: *Advances in Neural Information Processing Systems*. Vol. 31. 2018, pp. 7167–7177. URL: <https://proceedings.neurips.cc/paper/2018/hash/abdeb6f575ac5c6676b747bca8d09cc2-Abstract.html>.
 - [24] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: <https://arxiv.org/abs/2306.00890>.
 - [25] Zihan Li et al. “LViT: Language Meets Vision Transformer in Medical Image Segmentation”. In: *IEEE Transactions on Medical Imaging* 43.1 (2024), pp. 96–107. DOI: 10.1109/TMI.2023.3291719.
 - [26] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: <https://arxiv.org/abs/2401.12215>.
 - [27] Mingyuan Liu et al. “Sparsity- and Hybridity-Inspired Visual Parameter-Efficient Fine-Tuning for Medical Diagnosis”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15005. Springer Nature Switzerland, 2024.
 - [28] Weitang Liu et al. “Energy-based Out-of-distribution Detection”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 21464–21475. URL: <https://proceedings.neurips.cc/paper/2020/hash/f5496252609c43eb8a3d147ab9b9c006-Abstract.html>.
 - [29] Xueyan Mei et al. “Artificial intelligence-enabled rapid diagnosis of patients with COVID-19”. In: *Nature Medicine* 26 (Aug. 2020),

- 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: <https://www.nature.com/articles/s41591-020-0931-3>.
- [30] Yifei Ming et al. “Delving into Out-of-Distribution Detection with Vision-Language Representations”. In: *Advances in Neural Information Processing Systems*. Vol. 35. 2022, pp. 35087–35102. URL: https://papers.nips.cc/paper_files/paper/2022/hash/e43a33994a28f746dcfc Abstract-Conference.html.
 - [31] Jong Hak Moon et al. “Multi-Modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training”. In: *IEEE Journal of Biomedical and Health Informatics* 26.12 (2022), pp. 6070–6080. DOI: 10.1109/JBHI.2022.3207502.
 - [32] Michael Moor et al. *Med-Flamingo: a Multimodal Medical Few-shot Learner*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.15189. URL: <https://arxiv.org/abs/2307.15189>.
 - [33] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.
 - [34] Umair Rahman et al. “Can language-guided unsupervised adaptation improve medical image classification using unpaired images and texts?” In: *2025 IEEE 22nd International Symposium on Biomedical Imaging (ISBI)*. IEEE. 2025, pp. 1–5.
 - [35] Bryan C Russell et al. “LabelMe: a database and web-based tool for image annotation”. In: *International journal of computer vision* 77.1-3 (2008), pp. 157–173.
 - [36] Ramprasaath R. Selvaraju et al. “Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization”. In: *Proceedings of the IEEE International Conference on Computer Vision*. 2017, pp. 618–626. URL: https://openaccess.thecvf.com/content_iccv_2017/html/Selvaraju_Grad-CAM_Visual_Explanations_ICCV_2017_paper.html.

- [37] Jake Snell, Kevin Swersky, and Richard S. Zemel. “Prototypical Networks for Few-shot Learning”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017, pp. 4077–4087. URL: https://papers.nips.cc/paper_files/paper/2017/hash/cb8da6767461f2812ae429Abstract.html.
- [38] Yiyu Sun et al. “Out-of-Distribution Detection with Deep Nearest Neighbors”. In: *Proceedings of the 39th International Conference on Machine Learning*. Vol. 162. Proceedings of Machine Learning Research. PMLR, 2022, pp. 20827–20840. URL: <https://proceedings.mlr.press/v162/sun22d.html>.
- [39] Nikhil Kumar Tomar et al. “TGANet: Text-Guided Attention for Improved Polyp Segmentation”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2022*. Cham, Switzerland: Springer Nature Switzerland, 2022, pp. 151–160. ISBN: 978-3-031-16437-8. DOI: 10.1007/978-3-031-16437-8_15.
- [40] Tao Tu et al. *Towards Generalist Biomedical AI*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.14334. URL: <https://arxiv.org/abs/2307.14334>.
- [41] Xiaosong Wang et al. “TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018.
- [42] Yan Wang et al. *SimpleShot: Revisiting Nearest-Neighbor Classification for Few-Shot Learning*. 2019. arXiv: 1911.04623 [cs.CV]. URL: <https://arxiv.org/abs/1911.04623>.
- [43] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, Dec. 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: <https://aclanthology.org/2022.emnlp-main.256/>.

- [44] W.B. Saunders. *Dorland's Illustrated Medical Dictionary*. 32nd. Elsevier Health Sciences, 2011.
- [45] Chaoyi Wu et al. “MedKLIP: Medical Knowledge Enhanced Language-Image Pre-Training for X-ray Diagnosis”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023, pp. 21372–21383.
- [46] Bin Yan and Mingtao Pei. “Clinical-BERT: Vision-Language Pre-training for Radiograph Diagnosis and Reports Generation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 36. 3. 2022, pp. 2982–2990. DOI: 10.1609/aaai.v36i3.20204. URL: <https://doi.org/10.1609/aaai.v36i3.20204>.
- [47] Shunhan Yao et al. “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors”. In: *Scientific Data* 12.1 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y. URL: <https://doi.org/10.1038/s41597-024-04311-y>.
- [48] Chenlu Zhan et al. “UniDCP: Unifying Multiple Medical Vision-Language Tasks via Dynamic Cross-Modal Learnable Prompts”. In: *IEEE Transactions on Multimedia* 26 (2024), pp. 9736–9748. DOI: 10.1109/TMM.2024.3397191.
- [49] Jiajin Zhang et al. “Disease-informed Adaptation of Vision-Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15011. Springer Nature Switzerland, 2024.
- [50] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoA2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoA2400640>.
- [51] Xiaoman Zhang et al. “Knowledge-enhanced visual-language pre-training on chest radiology images”. In: *Nature Communications* 14 (July 2023). DOI: 10.1038/s41467-023-40260-7. URL: <https://arxiv.org/pdf/2302.14042.pdf>.

- [52] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 7th Machine Learning for Healthcare Conference*. Ed. by Zachary Lipton et al. Vol. 182. Proceedings of Machine Learning Research. PMLR, 2022, pp. 2–25. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
- [53] Yunkun Zhang et al. “Text-Guided Foundation Model Adaptation for Pathological Image Classification”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*. Ed. by Hayit Greenspan et al. Cham: Springer Nature Switzerland, 2023, pp. 272–282. ISBN: 978-3-031-43904-9.
- [54] Fudan Zheng et al. “Exploring low-resource medical image classification with weakly supervised prompt learning”. In: *Pattern Recognition* 149 (2024), p. 110250. ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2024.110250>. URL: <https://www.sciencedirect.com/science/article/pii/S0031320324000013>.
- [55] Kaipeng Zheng, Weiran Huang, and Lichao Sun. “TransMed: Large Language Models Enhance Vision Transformer for Biomedical Image Classification”. In: *arXiv preprint arXiv:2312.07125* (2023).
- [56] Hong-Yu Zhou et al. “A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics”. In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).
- [57] Hong-Yu Zhou et al. “Advancing Radiograph Representation Learning with Masked Record Modeling”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=w-x7U26GM7j>.
- [58] Juexiao Zhou et al. “Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4”. In: *Nature Communications* 15 (July 2024). DOI: 10.1038/s41467-024-50043-3. URL: <https://doi.org/10.1038/s41467-024-50043-3>.