

«««< HEAD

===== »»»> e5f1bbbc7193aec1b097f7d9ebe4238ebef0293

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - Nguyễn Gia Kiệt

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

TP. HỒ CHÍ MINH, THÁNG 08/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - 22127390

Nguyễn Gia Kiệt - 22127221

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

GIÁO VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

TP. HỒ CHÍ MINH, THÁNG 08/2026

Lời cam đoan

Nhóm xin cam đoan đây là công trình nghiên cứu của riêng nhóm. Dữ liệu và kết quả nghiên cứu trong luận văn này là trung thực và không trùng lặp với bất kỳ chủ đề nào khác. Nhóm cam đoan toàn bộ nội dung luận văn này không đạo văn hoặc sao chép từ các công trình nghiên cứu khác. Ngoài ra, trong quá trình nghiên cứu và viết luận văn, nhóm tuân thủ nghiêm ngặt các quy định về bảo mật do các tập dữ liệu nhóm sử dụng trong nghiên cứu của mình cung cấp. Hơn nữa, nhóm luôn tuân thủ mọi nguyên tắc đạo đức trong suốt quá trình nghiên cứu. Nhóm đảm bảo rằng tất cả các nguồn và tài liệu tham khảo đều được trích dẫn đúng cách và nhóm duy trì tính chính trực học thuật trong mọi khía cạnh công việc của mình.

Lời cảm ơn

Nhóm xin chân thành cảm ơn PGS.TS Lý Quốc Ngọc và ThS. Đỗ Thị Thanh Hà đã dành rất nhiều thời gian, tâm huyết để định hướng, tận tình hướng dẫn và đưa ra những lời khuyên quý báu cho nhóm trong suốt quá trình nghiên cứu và thực hiện khóa luận tốt nghiệp với đề tài "Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức".

Xin trân trọng gửi lời cảm ơn sâu sắc đến Ban Chủ nhiệm cùng toàn thể quý thầy cô Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG-HCM. Những kiến thức nền tảng vững chắc mà các thầy cô đã truyền đạt trong bốn năm học vừa qua và môi trường thí nghiệm tuyệt vời chính là hành trang quan trọng nhất giúp nhóm có thể hoàn thành tốt hướng nghiên cứu này.

Nhóm cũng xin gửi lời cảm ơn đến các y bác sĩ tại Bệnh viện Chấn thương Chỉnh hình TP.HCM, thầy Đỗ Phúc Thịnh và thầy Võ Thế Hào đã hỗ trợ chia sẻ nguồn dữ liệu ảnh X-quang cũng như tư vấn các kiến thức chuyên môn về y khoa, giúp mô hình nghiên cứu bám sát với quy trình chẩn đoán thực tế.

Mặc dù đã có nhiều cố gắng trong quá trình thực hiện, nhưng do hạn chế về mặt thời gian và kinh nghiệm nghiên cứu, khóa luận chắc chắn không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô và hội đồng đánh giá để đề tài được hoàn thiện hơn.

Xin chân thành cảm ơn!



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO HỌC SÂU ĐA PHƯƠNG THỨC

*(Developing a bone X-ray image classification
system based on multimodal deep learning)*

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm Sinh viên thực hiện:

1. Nguyễn Văn Lê Bá Thành (MSSV: 22127390)
2. Nguyễn Gia Kiệt (MSSV: 22127221)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 02/2026 đến 08/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn đầu. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, các nghiên cứu hiện nay đã ứng dụng các mô hình học sâu vào để giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ để đưa vào ứng dụng thực tế. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để bổ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác. Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống.

Khác với các mô hình đơn phương thức chỉ xử lý trên một phương thức như ảnh hay văn bản duy nhất, các mô hình đa phương thức có thể sử dụng nhiều phương thức và tìm ra sự tương quan giữa các phương thức nhằm tạo nên biểu diễn có ý nghĩa hơn từ đó nâng cao hiệu năng của hệ thống. Với thực tế lâm sàng hiện nay, các mô hình nghiên cứu tập trung

vào kết hợp ngôn ngữ và hình ảnh hay còn được gọi là mô hình ngôn ngữ trực quan đang là các mô hình đang nhận được nhiều sự chú ý.

2.2 Định nghĩa các khái niệm

Thông tin lâm sàng

Thông tin lâm sàng là những dữ liệu thu thập trực tiếp qua quá trình bác sĩ thăm khám người bệnh, bao gồm việc khai thác bệnh sử và khám thực thể (nhìn, sờ, gõ, nghe) [Dorland2011]. Dữ liệu này mang tính chất định hướng ban đầu, giúp bác sĩ khoanh vùng tổn thương và đưa ra các quyết định chỉ định thăm khám chuyên sâu tiếp theo [Bickley2020_Bates].

Thông tin cận lâm sàng

Thông tin cận lâm sàng là các dữ liệu khách quan thu được từ việc áp dụng các trang thiết bị và kỹ thuật y khoa hiện đại (như hình ảnh X-quang, cắt lớp, hay xét nghiệm sinh hóa) [Dorland2011]. Nếu lâm sàng dùng để định hướng, thì cận lâm sàng cung cấp bằng chứng xác thực từ bên trong cơ thể để chẩn đoán chính xác bệnh lý.

2.3 Phát biểu bài toán

Đầu vào (Input)

Hệ thống nhận vào các nguồn dữ liệu sau:

- Thông tin lâm sàng bao gồm báo cáo cận lâm sàng, khám xét toàn thân, lý do vào viện của bệnh nhân.
- Ảnh X-quang xương của bệnh nhân tương ứng.
- Tập nhãn được định nghĩa trước.


Đầu ra (Output)

Hệ thống sẽ sinh ra các nhãn sau:

- Tỷ lệ mà ảnh và thông tin lâm sàng tương ứng thuộc vào các lớp được định nghĩa trước.
- Ảnh trực quan hóa giải thích cho kết quả.

Kiến trúc tổng quan

Với bài toán này, kiến trúc tổng quan của một mô hình học sâu đa phương thức được sử dụng bao gồm bốn thành phần chính: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại như được thể hiện ở Hình ??.



Hình 1: Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức

Trong đó, bộ mã hóa ảnh có chức năng rút trích đặc trưng từ ảnh đầu vào, bộ mã hóa văn bản có chức năng rút trích đặc trưng từ văn bản đầu vào, bộ dung hợp dữ liệu có chức năng dung hợp hay căn chỉnh các đặc trưng được rút trích từ hai phương thức dữ liệu trên để tạo ra một biểu diễn có ý nghĩa và có đầy đủ tính chất của phương thức đầu vào, đây cũng là mô-đun quan trọng nhất đối với một mô hình học sâu đa phương thức, cuối cùng là bộ phân loại, nhận biểu diễn đặc trưng chung của các phương thức đầu vào để phân loại và đưa ra kết quả cuối cùng.

2.4 Mục tiêu đề tài

Trong bối cảnh già hóa dân số và các tác nhân gây bệnh từ ô nhiễm và lối sống thiếu lành mạnh trong đời sống hiện đại, các bệnh lý về xương và chấn thương có thể ảnh hưởng trực tiếp đến đời sống và tính mạng dẫn đến việc chẩn đoán và tiên lượng để đưa ra hướng điều trị phù hợp đang trở thành gánh nặng cho các y bác sĩ, các hệ thống học sâu đa phương

thức tuy đã phát triển nhưng lại thiếu khả năng giải thích. Đề tài hướng đến phát triển một hệ thống phân loại ảnh X-quang có khả năng:

- Đạt được độ chính xác cao trên các bộ dữ liệu nội bộ và quốc tế.
- Có khả năng giải thích được kết quả.
- Tích hợp kết quả để trợ giúp y bác sĩ trong quá trình chẩn đoán.

2.5 Phạm vi của đề tài

Nội dung nghiên cứu của đề tài tập trung vào việc khảo sát các mô hình nền tảng và thiết kế, huấn luyện, tinh chỉnh, đánh giá kiến trúc được đề xuất trên ảnh X-quang xương và các bộ dữ liệu quốc tế để so sánh, đánh giá với các kiến trúc trước.

Đối tượng nghiên cứu xoay quanh các thành phần bên trong một mạng học sâu đa phương thức bao gồm: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại, tập trung vào các phương pháp dung hợp dữ liệu hình ảnh và văn bản cùng với các phương pháp tinh chỉnh tham số cho các bộ mã hóa đã được huấn luyện trước nhằm tận dụng lại các tri thức đã có và nâng cao hiệu năng trên các tác vụ đích.

Đề tài chủ yếu sử dụng các bộ dữ liệu cặp ảnh - văn bản, không có trường hợp thiếu đã được công bố và bộ dữ liệu nội bộ được thu thập và cung cấp bởi giảng viên có hợp tác với bệnh viện ở khu vực Thành phố Hồ Chí Minh, một số thông tin cơ bản về các bộ dữ liệu được thể hiện ở Bảng ???. Nhóm sử dụng các bộ dữ liệu này nhằm đánh giá hiệu năng của kiến trúc đề xuất thông qua các độ đo phổ biến và tiến hành so sánh với các phương pháp trước đó nhằm chứng minh sự hiệu quả của phương pháp đề xuất.

2.6 Cách tiếp cận dự kiến

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ cung cấp tổng quan tình hình nghiên cứu

Bộ dữ liệu	Nguồn	Loại dữ liệu	Số lượng mẫu	Số lượng lớp
RSNA Pneumonia (2018)	Radiological Society of North America	Ảnh X-quang ngực metadata/tags	30,000	3
CheXpert (2019)	Stanford ML Group - Stanford Hospital	Ảnh X-quang ngực Báo cáo đọc ảnh	224,316	14
MIMIC-CXR v2 (2019)	Beth Israel Deaconess Medical Center	Ảnh X-quang ngực Báo cáo đọc ảnh	227,835	14
SARCOMA-CTCH (2025)	Bệnh viện Chấn Thương Chỉnh Hình - TPHCM	Ảnh X-quang xương Báo cáo đọc ảnh Báo cáo lâm sàng	Đang cập nhật	Đang cập nhật

Bảng 1: Tổng hợp các bộ dữ liệu dự kiến được sử dụng để thí nghiệm

từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

Các mô hình xây dựng từ đầu là các mô hình đơn giản, khởi điểm trong bài toán học sâu đa phương thức, thiết kế và huấn luyện một hệ thống mới từ đầu, điểm chung của các phương pháp này là chúng tập trung vào việc thiết kế các cơ chế để "trộn" (fusion) đặc trưng từ các bộ mã hóa (encoder) chuyên biệt ở các cấp độ khác nhau để tối ưu hóa hiệu suất cho các tác vụ cụ thể, sử dụng những bộ mã hóa hình ảnh đơn giản như CNN.

Khởi điểm vào 2020, X. Mei [**XMei**] và đồng nghiệp đã đề xuất lấy đặc trưng được tạo ra từ các lớp cuối của mô hình CNN (véc-tơ 512 chiều) và các đặc trưng từ dữ liệu lâm sàng rồi nối lại. Véc-tơ kết hợp này được đưa vào một mạng MLP cuối cùng để đưa ra dự đoán.

Clinical-BERT [**yan_2022_clinicalbert**] và TGANet [**nikhilkumartomar_2022_tganet**] tìm cách học biểu diễn đa phương thức bằng cách thúc đẩy mô hình hiểu và liên kết (align) các đặc trưng giữa các vùng trong ảnh và các từ khóa trong văn bản báo cáo thông qua các nhiệm vụ tự giám sát (self-supervised objectives), cho phép mô hình học được các biểu diễn ngữ nghĩa chung. Hay LViT [**li_2024_lvit**] đề xuất một kiến trúc hybrid CNN-Transformer "Double-U", cấu trúc CNN-Transformer kết hợp mô-đun Pixel-Level Attention Module để giữ lại các đặc trưng cục bộ của ảnh giúp mô hình giữ được khả năng trích xuất đặc trưng cục bộ mạnh mẽ của CNN, đồng thời tận dụng khả năng mô hình hóa ngữ cảnh toàn cục của Transformer.

Việc chỉ nối các đặc trưng có điểm yếu về sự khác biệt về giá trị hoặc sự ngữ nghĩa lớn giữa các phương thức dữ liệu, IRENE [**IRENE**] đã đưa

tất cả dữ liệu gốc về dạng token chung và học biểu diễn tổng thể (holistic representation) ngay từ đầu, sử dụng một mô hình Transformer duy nhất học các biểu diễn toàn diện cho cả hai phương thức. IRENE còn sử dụng cơ chế chú ý hai chiều ở cấp độ token để nắm bắt "các kết nối cục bộ".

Nghiên cứu của Dai và cộng sự [TransMed21] đề xuất mô hình TransMed, giải quyết bài toán kết hợp đa phương thức bằng cách tích hợp CNN và Transformer. Bằng việc chuyển đổi đặc trưng ảnh từ CNN thành dạng chuỗi để Transformer xử lý, mô hình này tối ưu hóa việc nắm bắt các đặc điểm toàn cục của hình ảnh y khoa. Cách tiếp cận này mang lại hiệu quả cao hơn các kỹ thuật fusion thông thường nhờ khả năng biểu diễn dữ liệu đa phương thức một cách toàn diện và chính xác.

Những nghiên cứu này đã khai phá và chứng minh về tác động tích cực của các phương thức dữ liệu khác như văn bản đến kết quả của việc chẩn đoán hình ảnh, tuy nhiên độ chính xác của các phương thức này còn chưa quá cao bởi các bộ mã hóa và phương pháp dung hợp dữ liệu còn đơn giản.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Kiến trúc mô hình			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	X. Mei [XMei]	Full Fine-Tuning	Pretrain với Cross-Entropy loss	Inception-ResNet-v2	ResNet-18	Decision-level	N/a
2	Clinical-BERT [yan_2022_clinicalbert]	Full Fine-Tuning	Cross-modal Repr. Learning	DenseNet121	Uncased BERT-base	Early fusion	N/a
3	LViT [li_2024_lvit]	Full Fine-Tuning	Semi-supervised (Pseudo-label)	Hybrid U-shape (CNN + ViT)	BERT_12_768_12	Intermediate	N/a
4	TGANet [nikhilkumartomar_2022_tganet]	Train from scratch	Exponential Pseudo-label Iteration	ResNet50	Không có	Intermediate	N/a
5	IRENE [IRENE]	Train from scratch	BCE Loss & AdamW optimizer	Convolution layer	Pretrained BERT	Simultaneous	Upsampling, FEM, CBAM Attention
6	TransMed [TransMed21]	Full Fine-Tuning	Supervised (SGD, 100 epochs)	2D CNN (ResNet18 đến 152)	N/a	Attention fusion	Lớp kết nối đầy đủ (FC Layer)

Bảng 2: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tinh chỉnh của các mô hình kết hợp ngôn ngữ - ảnh

Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu (thường cố gắng dung hợp dữ liệu thô thành một khối thống nhất), Med-VLMs chú trọng vào việc đối chiếu và liên kết chặt chẽ ngữ nghĩa giữa hình ảnh và ngôn ngữ tự nhiên. Cụ thể, kiến trúc của chúng thường kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này khớp với nhau. Lúc này, bộ phân loại không gán nhãn theo cách truyền thống mà

đóng vai trò là một cơ chế đo lường mức độ tương đồng. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Để đạt được khả năng trên, các nghiên cứu tiền huấn luyện Med-VLMs hiện nay đang phát triển chủ yếu theo ba hướng: học tương phản, học có che giấu và tích hợp tri thức y khoa (chi tiết tổng hợp được trình bày tại các Bảng ??, ??, ??).

Thứ nhất, **học tương phản (Contrastive Learning)** là chiến lược được ứng dụng rộng rãi nhất, tiêu biểu với các mô hình như ConVIRT [ConVIRT], GLoRIA [GLoRIA], MedCLIP [MedCLIP] và BiomedCLIP [BiomedCLIP]. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau ở mức độ cục bộ lẫn toàn cục. Phương pháp này đem lại hiệu năng ấn tượng; ví dụ, BiomedCLIP [BiomedCLIP] (huấn luyện trên 15 triệu cặp dữ liệu) đạt độ chính xác phân loại 83%, trong khi ConVIRT [ConVIRT] đạt 90,3% trên bộ dữ liệu COVIDx. Mặc dù có ưu điểm vượt trội là khả năng học biểu diễn không cần gán nhãn thủ công, học tương phản vẫn bộc lộ hạn chế về việc tiêu tốn tài nguyên tính toán lớn và rủi ro xảy ra hiện tượng âm tính giả (đẩy xa các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý).

Thứ hai, **học có che giấu (Masked Learning)** là hướng đi tập trung vào mục tiêu tái tạo dữ liệu, với các đại diện nổi bật như MRM [MRM] và MedViLL [MedViLL]. Bằng cách ẩn ngẫu nhiên các vùng ảnh hoặc từ ngữ trong báo cáo y khoa, kiến trúc này buộc mô hình phải dự đoán và khôi phục phần thông tin bị khuyết. Hướng tiếp cận này thể hiện ưu thế rõ rệt trong các môi trường khan hiếm dữ liệu; điển hình là MRM [MRM] đạt mức 92,7% AUC chỉ với 10% dữ liệu từ tập RSNA. Tuy nhiên, rào cản chính của phương pháp này nằm ở việc phụ thuộc vào nguồn dữ liệu đã được ghép cặp sẵn từ trước, cộng với độ phức tạp tính toán cao của quá trình khôi phục điểm ảnh/token.

Thứ ba, **tích hợp tri thức y khoa (Knowledge Integration)** ra đời nhằm giải quyết những đặc thù phức tạp của ngôn ngữ lâm sàng.

Các mô hình như MedKLIP [MedKLIP], BioViL [BioViL], BioViL-T [BioViL-T] và KAD [KAD] tận dụng đồ thị tri thức (như RadGraph) hoặc dữ liệu chuỗi thời gian để cung cấp tín hiệu giám sát chi tiết về cả loại và vị trí bệnh lý. Cách tiếp cận này giúp giải quyết triệt để sự mơ hồ của các từ vựng diễn tả tiến triển bệnh (ví dụ: "cải thiện", "xấu đi"). Về mặt hiệu năng, KAD [KAD] đạt 0.966 AUC trên tập PadChest ở thiết lập không mẫu (zero-shot), còn BioViL-T [BioViL-T] đạt độ chính xác 67,4% trong bài toán phân loại tiến triển bệnh. Dù vậy, các phương pháp này chưa loại bỏ hoàn toàn được hiện tượng âm tính giả và rất dễ gặp sai số nếu nhân chẩn đoán thực tế nằm ngoài cơ sở tri thức đồ thị gốc.

Dựa trên sự phân tích các ưu và nhược điểm từ những khảo sát trên, hướng tiếp cận đề xuất trong nghiên cứu này được thiết kế có chọn lọc nhằm tối ưu hóa hiệu năng và chi phí:

- **Kế thừa BiomedCLIP [BiomedCLIP]:** Tận dụng sức mạnh của các bộ mã hóa đã được huấn luyện với chất lượng cao.
- **Không áp dụng học tương phản & học có che giấu:** Khó khắc phục rào cản về tài nguyên tính toán lớn và giảm thiểu rủi ro gặp phải hiện tượng âm tính giả.
- **Tích hợp tri thức từ UMLS (tương tự MedKLIP [MedKLIP]):** Sử dụng để làm giàu thêm tri thức trong các báo cáo lâm sàng.

Mặc dù các phương pháp tiền huấn luyện Med-VLMs giúp xây dựng nền tảng tri thức đa phương thức khổng lồ, việc áp dụng trực tiếp vào lâm sàng lại vấp phải rào cản lớn về chi phí tính toán và sự khan hiếm dữ liệu y tế ghép cặp. Để giải quyết vấn đề này, các nghiên cứu thường chuyển hướng sang tinh chỉnh mô hình. Tuy nhiên, nếu tinh chỉnh toàn phần trên một tập dữ liệu nhỏ, sự chênh lệch phân phối sẽ dễ dẫn đến hiện tượng chuyển giao tiêu cực hoặc "quên thảm khốc", làm đánh mất tri thức gốc. Do đó, giới nghiên cứu đang tập trung vào các chiến lược tinh chỉnh hiệu quả tham số (PEFT) nhằm đảm bảo tính linh hoạt, tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các nghiên cứu gần đây được chia thành ba hướng tiếp cận chính:

STT	Tên phương pháp	Phân loại	Nguyên lý
1	ConVIRT (2020)	Học tương phản	Tối ưu bộ mã hoá ảnh và văn bản bằng cách kéo các cặp đặc trưng ảnh-văn bản giống nhau lại gần nhau và đẩy các cặp đặc trưng ảnh-văn bản khác nhau ra xa
2	GLoRIA (2021)	Học tương phản	Dùng hai hàm mất mát global contrastive để kéo các cặp đặc trưng ảnh-văn bản, trong khi đó hàm mất mát local contrastive học cách căn chỉnh chi tiết của các vùng trong ảnh và các từ trong câu
3	MedCLIP (2022)	Học tương phản	Đề xuất cơ chế tách cặp và trích xuất tri thức, và đề xuất hàm mất mát Semantic Matching nhằm giải quyết vấn đề false negative
4	BiomedCLIP (2023)	Học tương phản	Có cơ chế tương tự như CLIP nhưng được tiền huấn luyện với bộ dữ liệu PMC-15M
5	MRM (2023)	Học có che giấu	Ẩn ngẫu nhiên các thông tin trong văn bản và các vùng trong ảnh để cho mô hình dự đoán lại ảnh và văn bản hoàn chỉnh.
6	MedViLL (2022)	Học có che giấu	Đề xuất một kiến trúc dựa trên BERT kết hợp với một mặt nạ chú ý mới được đề xuất (BAR) cho phép ảnh tương tác tự do với văn bản trong các tác vụ hiểu, đồng thời đảm bảo tính tự hồi quy cho các token trong văn bản trong các tác vụ sinh
7	BioViL (2022)	Tích hợp kiến thức y khoa	Đề xuất một bộ mã hoá văn bản CXR-BERT được tối ưu cho ảnh X-quang, duy trì hàm mất mát MLM để giúp mô hình giữ lại được các kiến thức văn bản trong quá trình căn chỉnh với ảnh
8	BioViL-T (2023)	Tích hợp kiến thức y khoa	Sử dụng các ảnh X-quang từ trước kết hợp với ảnh hiện tại để học được các đặc trưng không gian, thời gian từ đó giải thích cho các từ vụng như "cải thiện" giúp giảm đi sự mơ hồ trong báo cáo
9	MedKLIP (2023)	Tích hợp kiến thức y khoa	Đề xuất một mô-đun trích xuất bộ ba và cơ chế mã hoá tăng cường tri thức, từ đó tạo ra biểu diễn tốt hơn cho văn bản
10	KAD (2023)	Tích hợp kiến thức y khoa	Tích hợp kiến thức y khoa vào quá trình tiền huấn luyện để giúp mô hình học các biểu diễn có ý nghĩa hơn

Bảng 3: Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Mục tiêu tiền huấn luyện	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	CL	GCL	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	CL	LCL, GCL	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	CL	GCL	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	CL	GCL	ViT-Base	PubMedBERT	Contrastive Alignment	N/a
5	MRM (2023)	MP	MIM, MLM	Kiến trúc giống ViT	WordPiece	Global Context Injection	Văn bản: Transformer; Hình ảnh: Fully Connected
6	MedViLL (2022)	HA	MLM, ITM	ResNet50	BERT	Cross-modal Self-Attention	Multi-Layer Perceptron
7	BioViL (2022)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
8	BioViL-T (2023)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
9	MedKLIP (2023)	CL	LCL	ResNet50	ClinicalBERT	Knowledge-enhanced Alignment	Contrastive head, Cross-Entropy head
10	KAD (2023)	HA	CL, Disease Diagnosis Prediction	ResNet50, ViT-Base	PubMedBERT	Contrastive Alignment	Disease Query Network

Bảng 4: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;

STT	Tên phương pháp	Bộ dữ liệu tiền huấn luyện	Hiệu năng			
			Tác vụ	Bộ dữ liệu đánh giá	Độ đo	Kết quả
1	ConVIRT (2020)	MIMIC-CXR, Private Bone image	- Phân loại ảnh - Phân loại ít mẫu	RSNA Pneumonia, CheXpert, COVIDx, MURA	AUC, Accuracy	- Phân loại ít mẫu: RSNA (1%): 88.8% AUC, (10%): 91.5% AUC; CheXpert (1%): 87.0% AUC, (10%): 88.1% AUC; MURA (1%): 81.3% AUC, (10%): 86.5% AUC - Phân loại ảnh: RSNA: 92.7% AUC, CheXpert: 88.1% AUC, MURA: 89.0% AUC; COVIDx 90.3% ACC
2	GLoRIA (2021)	CheXpert	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	CheXpert, RSNA Pneumonia	AUROC	- Phân loại không mẫu: CheXpert 5x200: 0.61 ACC, 0.67 F1; RSNA: 0.70 ACC, 0.58 F1; - Phân loại ít mẫu: CheXpert (1%): 86.6 AUC, (10%): 87.8 AUC, RSNA (1%): 86.1 AUC, (10%): 88.0 AUC - Phân loại ảnh: CheXpert: 88.1 AUC, RSNA: 88.6 AUC
3	MedCLIP (2022)	MIMIC-CXR, CheXpert	- Phân loại ảnh - Phân loại không mẫu	MIMIC-5x200, COVID, RSNA Pneumonia	Mean Accuracy	- Phân loại không mẫu: CheXpert-5x200: 0.5942 ACC; MIMIC-5x200: 0.5430 ACC; COVID: 0.8472 ACC; RSNA: 0.7682 ACC - Phân loại ảnh: CheXpert-5x200: 0.5960 ACC; MIMIC-5x200: 0.5650 ACC; COVID: 0.7890 ACC; RSNA: 0.8075 ACC
4	BiomedCLIP (2023)	PMC-15M	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PCam, LC25000 (Lung, Colon), TCGA-TIL, RSNA Pneumonia	AUC, Accuracy	- Phân loại không mẫu: PCam: 73.41% ACC; LC25000 Lung 65.23% ACC; LC25000 Colon 92.98%; RSNA 78.95%; TCGA-TIL: 67.04% - Phân loại ít mẫu: PCam (1%): 82% ACC, (10%): 83%; RSNA (1%): 77% ACC, (10%): 82% ACC - Phân loại ảnh: PCam: 83% ACC, RSNA: 83% ACC
5	MRM (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu	CheXpert, NIH ChestX-ray, RSNA Pneumonia, COVID-19 Image Data Collection	AUC, Accuracy	- Phân loại ít mẫu: CheXpert (1%): 88.5 AUC, (10%): 88.5 AUC; RSNA (1%): 91.3 AUC, (10%): 92.7 AUC; NIH ChestX-ray (1%): 79.4 AUC, (10%): 84.0 AUC - Phân loại ảnh: CheXpert: 88.7 AUC, RSNA 93.3, NIH ChestX-ray: 85.9, COVID-19: 85.8
6	MedViLL (2022)	MIMIC-CXR	- Phân loại chẩn đoán	MIMIC-CXR, Open-I	Micro-averaged AUROC, Micro-averaged F1 score	- Phân loại ảnh: MIMIC-CXR: 0.980 avg AUROC, 0.839 F1; Open-I: 0.892 avg AUROC, 0.407 F1
7	BioViL (2022)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	RSNA Pneumonia	Accuracy, F1-score, AUROC, Sensitivity Specificity.	- Phân loại không mẫu: RSNA: 0.732 ACC, 0.831 AUC; ChestX-ray14: 0.6912 AUC - Phân loại ít mẫu: RSNA (1%): 0.805 ACC, 0.881 AUC; (10%): 0.812 ACC, 0.884 AUC - Phân loại ảnh: RSNA: 0.822 ACC, 0.891 AUC
8	BioViL-T (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu - Phân loại ảnh tiến triển	MS-CXR-T, RSNA Penumonia, Chest ImaGenome	Macro-Accuracy, Accuracy, F1, AUROC.	- Phân loại Tiến triển: MS-CXR-T: 67.4% Acc - Phân loại không mẫu: RSNA: 0.805 ACC, 0.871 AUC - Phân loại ít mẫu: RSNA (1%): 0.814 ACC, 0.890 AUC
9	MedKLIP (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại không mẫu	ChestX-ray14, RSNA Pneumonia, SIIM-ACR Pneumothorax, COVIDx CXR-2, COVID Rural, Edema Severity	AUC, F1-score, Accuracy.	- Phân loại không mẫu: RSNA: 0.8694 AUC, 0.6342 F1; SIIM-ACR: 0.8924 AUC, 0.6833 F1; ChestX-ray14: 0.7676 AUC, 0.2525 F1; COVID-19: 0.7396 AUC, 0.7670 F1 - Phân loại ít mẫu: ChestX-ray14 (1%): 0.7721 AUC, (10%): 0.7894; RSNA (1%): 0.8731 AUC, (10%): 0.8799 AUC - Phân loại mẫu: ChestX-ray14: 0.8323 AUC, RSNA 0.8931
10	KAD (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PadChest, NIH ChestXray14, CheXpert, ChestX-Det	AUC, F1-Score, MCC	- Phân loại không mẫu: PadChest: 0.966 AUC; CheXpert: 0.905 AUC, 0.647 F1, 0.589 MCC - Phân loại ít mẫu: ChestXray-14 (1%): 0.78 AUC, 0.31 F1; (10%): 0.80 AUC, 0.33 F1 - Phân loại ảnh: ChestXray-14: 0.82 AUC, 0.34 F1

Bảng 5: Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

Tinh chỉnh sử dụng câu nhắc (Prompt Tuning): Hướng này chèn thêm các tham số có thể học được vào không gian đầu vào của mô hình. Các phương pháp như CITE [**CITE**], FPT [**FPT**] hay PLIP [**PLIP**] khai thác đặc trưng thị giác kết hợp với tri thức lâm sàng, cho thấy hiệu quả vượt trội ngay cả khi thiếu hụt dữ liệu (ví dụ: PLIP đạt 0.896 AUC chỉ với 5% dữ liệu PanNuke). Nhằm giải quyết khó khăn khi thiết kế thủ công, MedPrompt [**MedPrompt**] và UniDCP [**UniDCP**] tự động sinh câu nhắc động dựa trên ngữ cảnh ảnh để xử lý đa tác vụ. Gần đây hơn, việc tích hợp Mô hình ngôn ngữ Lớn (LLM) qua ViP [**ViP**], CILMP [**CLIMP**] và BiomedCoOp [**BiomedCoOp**] giúp tạo sinh các câu nhắc ngữ nghĩa sâu sắc, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản, mang lại hiệu năng cao trong các kịch bản ít mẫu hoặc không mẫu.

Tinh chỉnh bộ điều hợp (Adapter Tuning): Thay vì can thiệp ở đầu vào, phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ giữa các lớp của kiến trúc gốc. Điển hình, CLIPath [**CLIPath**] sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu nhỏ; FTB [**FTB**] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức. Ở hướng bán giám sát, mô hình MedUnA [**MedUnA**] dùng LLM tạo nhãn giả và tinh chỉnh không giám sát bộ điều hợp trên ảnh chưa gán nhãn, giúp mô hình thích ứng tốt mà không thay đổi trọng số.

Tinh chỉnh chọn lọc (Selective Tuning): Hướng đi này tối ưu hóa kiến trúc bằng cách chỉ cập nhật một lượng nhỏ các trọng số quyết định hiệu năng. TransMed [**TransMed**] kết hợp LLM để chuyển đổi nhãn bệnh thành mô tả chi tiết, trong khi SH-PEFT [**SH-PEFT**] chỉ tìm và cập nhật các trọng số quan trọng nhất trên bộ mã hóa thị giác nhằm khai thác tính thừa thớt của mạng. Tương tự, LCBB [**LCBB**] áp dụng kỹ thuật LoRA để tinh chỉnh tham số hiệu quả cho Med-VLMs, giúp bám sát hiệu năng của tinh chỉnh toàn phần (đạt 93.1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn) nhưng giảm thiểu tối đa chi phí tính toán.

Tóm lại, các phương pháp tinh chỉnh hiệu quả tham số (PEFT) thể hiện ưu điểm vượt trội trong việc tiết kiệm tài nguyên tính toán, ngăn chặn hiện tượng quên tri thức và giúp mô hình thích ứng tốt ngay cả khi đối mặt với các bộ dữ liệu y tế khan hiếm. Tuy nhiên, hướng tiếp cận này vẫn tồn tại một số hạn chế nhất định. Hiệu năng cuối cùng của hệ thống

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	CITE (2023)	Parameter-efficient fine tuning	Visual prompt tuning	CLIP ViT-Base, ImageNet-21k ViT-Base, INTERN ViT-Base	BioLinkBERT-large, BioBERT-large , Kế thừa CLIP	Contrastive Alignment	N/a
2	UniDCP (2023)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	CLIP ViT	RoBERTa	Cross Attention, Contrastive Alignment	N/a
3	ViP (2024)	Parameter-efficient fine tuning	Textual prompt tuning	ViT-Base	Kế thừa CLIP	Cross Attention, Contrastive Alignment	N/a
4	PLIP (2024)	Parameter-efficient fine tuning	Visual prompt tuning, Efficient Selective tuning	ViT-Base	Kế thừa CLIP	Concatnate	N/a
5	FPT (2024)	Parameter-efficient fine tuning	Visual prompt tuning	ViT-Base	N/a	Cross Attention	N/a
6	MedPrompt (2024)	Parameter-efficient fine tuning	Textual prompt tuning	Swin Transformer, ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
7	CILMP (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	ViT-Base	Kế thừa CLIP	Hadamard Product, Concatnate	N/a
8	BiomedCoOp (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	Kế thừa BiomedCLIP	Kế thừa BiomedCLIP	Contrastive Alignment	N/a
9	CLIPath (2023)	Parameter-efficient fine tuning	Adapter tuning	ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
10	FTB (2024)	Parameter-efficient fine tuning	Adapter tuning	ResNet autoencoder, DINOv2-small, DINOv2-base	BERT, BioBERT, ClinicalBERT, CXR-BERT, PubMedBERT	Cross Attention	N/a
11	MedUnA (2024)	Parameter-efficient fine tuning	Adapter tuning	ViT-Base, MedCLIP-Swin	Kế thừa CLIP, MedCLIP	No Fusion	N/a
12	TransMed (2023)	Parameter-efficient fine tuning	Direct Selective tuning	Swin Transformer, ViT-Base	BERT, LLM/GPT-4	Contrastive Alignment	N/a
13	SH-PEFT (2024)	Parameter-efficient fine tuning	Direct Selective tuning	ViT-Base	Kế thừa CLIP	No Fusion	N/a
14	LCBB (2024)	Parameter-efficient fine tuning	Efficient Selective tuning	Kế thừa MAE, MRM	Kế thừa MAE, MRM	Kế thừa MAE, MRM	N/a

Bảng 6: Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan

phụ thuộc rất lớn vào chất lượng của mô hình tiền huấn luyện gốc. Đồng thời, quá trình thiết kế câu nhắc mang đậm tính chuyên môn hay xác định vị trí tối ưu để chèn bộ điều hợp thường phức tạp và đòi hỏi nhiều thử nghiệm. Ngoài ra, việc bổ sung các thành phần này ít nhiều làm tăng tính "hộp đen" của mô hình, gây ra những thách thức về tính minh bạch khi cần giải thích các quyết định dự đoán cho bác sĩ trên thực tế lâm sàng.

Các mô hình ngôn ngữ lớn y khoa đa phương thức

Trong thời gian gần đây, với sự phát triển của các mô hình ngôn ngữ lớn được huấn luyện trên những tập dữ liệu rất lớn phục vụ cho rất nhiều tác vụ khác nhau, các mô hình này đang thể hiện sự ảnh hưởng và đa dụng trong lĩnh vực y tế với độ chính xác rất tốt khi chỉ học ít mẫu hoặc không mẫu.

Med-Flamingo [**moor_2023_medflamingo**] là mô hình đầu tiên có khả năng học ít mẫu chuyên dụng cho y tế, thông qua hội thoại tự nhiên để hỗ trợ chẩn đoán. Theo sau đó, LLaVA-Med [**li_2023_llavamed**] là mô hình chuyển đổi khả năng thực hiện theo chỉ dẫn (instruction-following) từ miền tổng quát sang lĩnh vực y sinh bằng cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn với 600.000 cặp, với dữ liệu hội thoại tạo ra từ chú thích ảnh y khoa được tạo ra bằng cách sử dụng GPT-4. Phương pháp này đã đề xuất quy trình huấn luyện 2 bước: (1) Căn chỉnh khái niệm; (2) Tinh chỉnh chỉ dẫn đầy đủ; 2 bước này tương ứng với giai đoạn học và suy luận. Kết quả thể hiện khả năng suy luận vượt trội trên dữ liệu chưa từng thấy.

Med-Palm M [**MED-PALM-M**] là mô hình của Google, đánh dấu bước tiến từ các mô hình đơn nhiệm sang đa nhiệm quy mô lớn, có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì sử dụng các mô hình chuyên biệt cho từng tác vụ. Gần đây hơn, SkinGPT-4 [**SkinGPT-4**] là hệ thống chẩn đoán da liễu tương tác đầu tiên sử dụng LLM quy mô lớn với độ chính xác cao, đã kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM), tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Dù đưa đến các phương pháp có độ chính xác cao đến rất cao trong nhiều tác vụ cùng việc hỗ trợ trong việc giao tiếp với mô hình, kích cỡ và chi phí huấn luyện (Med-Flamingo có đến 9 tỷ thông số) để vận hành các

mô hình ngôn ngữ lớn đa phương thức là một vấn đề lớn, đi kèm với vấn đề ảo giác có thể gặp phải khi đối mặt với dữ liệu mới hoặc những câu hỏi phức tạp. Ngoài ra nếu yêu cầu một độ chính xác cao - một yêu cầu quan trọng trong lĩnh vực y tế trong một tác vụ cụ thể thì đây không phải một cách tiếp cận tốt cho bài toán này.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Cấu trúc phương pháp			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	Med-Flamingo [moor_2023_medflamingo]	PEFT	Parameter-efficient + Domain adaptation	Frozen CLIP ViT	LLaMA-7B	Intermediate fusion	LLaMA Decoder
2	LLaVA-Med [li_2023_llavamed]	Full FT	Visual Instruction Tuning (GPT-4 data)	CLIP ViT-L/14	LLaMA	Projection Matrix	LLM (Vicuna)
3	Med-PaLM M [MED-PALM-M]	Full FT	Instruction Fine-tuning	ViT (4B - 22B)	PaLM	Multimodal embedding	PaLM
4	SkinGPT-4 [SkinGPT-4]	PEFT	LoRA	Vision Transformer	GPT-4	Linear alignment	LLaMA-2-13B


Bảng 7: Tổng hợp chiến lược và cấu trúc các mô hình ngôn ngữ lớn đa phương thức

Phương pháp đề xuất: Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế theo hướng tích hợp tri thức y khoa nhằm nâng cao khả năng giải thích của mô hình được minh họa ở Hình ???. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Bộ mã hóa ảnh:** Kế thừa lại mô hình ViT-Base của phương pháp BiomedCLIP [**BiomedCLIP**]
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [**BiomedCLIP**]
- **Bộ dung hợp dữ liệu:** Nhóm hướng đến sử dụng cơ chế *Knowledge-guided Cross-Attention* - Các khái niệm y học được trích xuất và liên kết từ văn bản lâm sàng thông qua sẽ được sử dụng để tạo thiên lệch (bias) trong quá trình tính toán cross attention. Cơ chế này giúp điều hướng mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Nhờ đó, mô hình không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.

- **Bộ phân loại:** Sử dụng một mạng phân loại (Multi-Layer Perceptron) để dự đoán nhãn bệnh lý.

Đồng thời, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán.



Hình 2: Kiến trúc tổng thể của hệ thống đề xuất

2.7 Kết quả dự kiến của đề tài

- **Số liệu định lượng:** Độ chính xác, điểm F1, AUC-ROC đạt kết quả cạnh tranh trên các bộ dữ liệu đã nêu.
- **Sản phẩm đầu ra:**
 - Hệ thống demo phân loại ảnh X-quang xương với khả năng nhận ảnh và văn bản và trả ra các lớp thuộc bộ dữ liệu Sarcoma-CTCH.
 - Giao diện đơn giản để hiển thị kết quả phân loại.
 - Cho phép trực quan hóa sau khi hiện kết quả phân loại.
- **Báo cáo khoa học:** hoàn thiện phương pháp và hệ thống để hướng tới công bố trên các hội nghị và tạp chí uy tín trong lĩnh vực Trí tuệ nhân tạo và Y sinh, như MICCAI, CVPR hoặc các tạp chí được công nhận.
- **Hướng phát triển:**
 - Mở rộng ra cho các bệnh lý khác.
 - Cải thiện độ chính xác và hiệu suất của hệ thống.

2.8 Kế hoạch thực hiện

Mục tiêu	Thời gian	Phân công	Nội dung
Khoá luận tốt nghiệp	01 tháng	Giai đoạn 1	
		Bá Thành	Khảo sát tổng quan về bài toán phân loại ảnh X-quang về xương
		Gia Kiệt	Khảo sát các mô hình tiền huấn luyện trên dữ liệu y khoa
		Bá Thành	Khảo sát các phương pháp học chuyển giao và các mô hình liên quan
	02 tháng	Giai đoạn 2	
		Cả nhóm	Phát triển mô hình học sâu đa phương thức áp dụng phương pháp học chuyển giao
		Gia Kiệt	Cài đặt môi trường, thu thập các bộ dữ liệu liên quan
		Bá Thành	Thực hiện thí nghiệm trên mô hình đề xuất
	02 tháng	Giai đoạn 3	
		Bá Thành	Phân tích so sánh kết quả thực nghiệm.
		Gia Kiệt	Xây dựng nguyên mẫu cho hệ thống phân loại
	0.5 tháng	Giai đoạn 4	
		Cả nhóm	Viết 01 bài báo khoa học cho hội nghị - tạp chí chuyên ngành trong nước hoặc ngoài nước
	0.5 tháng	Giai đoạn 5	
		Bá Thành	Viết báo cáo khoá luận tốt nghiệp.
		Gia Kiệt	Thiết kế slide cho lễ bảo vệ đề tài tốt nghiệp

Bảng 8: Kế hoạch bố trí thời gian nghiên cứu

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 05 tháng 04 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

Mục lục

Danh sách hình

Danh sách bảng

Tóm tắt

Các bệnh lý và chấn thương xương ngày càng phổ biến, làm gia tăng nhu cầu ứng dụng trí tuệ nhân tạo trong phân tích ảnh X-quang. Tuy nhiên, dữ liệu y khoa thường hạn chế về số lượng mẫu gán nhãn, mất cân bằng lớp và tồn tại bệnh ngoài phân phối, giảm khả năng tổng quát của mô hình khi triển khai. Đề tài nhằm xây dựng hệ thống phân loại đa lớp ảnh X-quang xương theo hướng đa phương thức, khai thác đồng thời hình ảnh và văn bản lâm sàng để nâng cao hiệu quả dự đoán. Hệ thống được phát triển trên nền tảng BioMedCLIP với hai giai đoạn huấn luyện: thích nghi miền bằng LoRA kết hợp hàm mất mát khớp ngữ nghĩa để cải thiện biểu diễn đặc trưng, sau đó hợp nhất đặc trưng ảnh và văn bản bằng cơ chế chú ý hai chiều. Mạng nguyên mẫu kết hợp Cross-Entropy có trọng số lớp được sử dụng nhằm giảm ảnh hưởng mất cân bằng lớp, hỗ trợ các lớp ít mẫu và phát hiện dữ liệu ngoài phân phối dựa trên khoảng cách mahalanobis. Phương pháp được đánh giá thông qua thí nghiệm thành phần, so sánh với mô hình nền và kiểm thử trên bộ dữ liệu tại Bệnh viện Chấn thương Chỉnh hình. Kết quả cho thấy phương pháp đề xuất cải thiện hiệu quả phân loại đa lớp và khả năng tổng quát, đồng thời hỗ trợ nhận diện mẫu ngoài phân phối.

Chương 1

Giới thiệu

Chương này trình bày bối cảnh, vấn đề nghiên cứu và phạm vi của bài toán phân loại ảnh X-quang xương bằng học sâu đa phương thức. Trọng tâm của luận văn là khai thác đồng thời ảnh X-quang và bệnh sử lâm sàng được thu nhận trước khi đọc ảnh, qua đó đánh giá giá trị bổ sung của thông tin lâm sàng đối với mô hình chỉ sử dụng hình ảnh. Chương cũng xác định các thách thức liên quan đến độ phân giải ảnh, dữ liệu hạn chế, mất cân bằng lớp, dữ liệu ngoài phân phối và khả năng giải thích; từ đó xây dựng mục tiêu, câu hỏi nghiên cứu và các đóng góp của luận văn.

1.1 Bối cảnh và lý do chọn đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ khảo sát cấu trúc xương, phát hiện tổn thương, bất thường và hỗ trợ định hướng điều trị. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay có thể gặp khó khăn khi tổn thương nhỏ, ảnh có tương phản thấp hoặc khi số lượng ca cần đọc lớn, lúc đó kết quả phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ.


Để giải quyết các thách thức này, nhiều nghiên cứu đã ứng dụng các mô hình học sâu vào việc hỗ trợ phân tích và phân loại ảnh X-quang và đưa ra quyết định dựa trên thông tin trên ảnh như các kiến trúc mạng nơ-ron tích chập ResNet [0] và DenseNet [0]. Tuy nhiên, các mô hình chỉ sử dụng hình ảnh không khai thác được các thông tin lâm sàng có sẵn trước khi đọc ảnh, chẳng hạn triệu chứng, tiền sử bệnh hoặc cơ chế chấn thương. Trong khi đó, quá trình ra quyết định lâm sàng thực tế của bác sĩ thường dựa trên sự kết hợp giữa bằng chứng hình ảnh và bối cảnh bệnh hoặc chấn thương của người bệnh.

Dựa vào thực tế đó, các mô hình ngôn ngữ trực quan y khoa như MedCLIP [0], BiomedCLIP [0] và BioViL [0] cung cấp một hướng tiếp cận phù hợp để học biểu diễn chung giữa ảnh và văn bản. Nhờ được tiền huấn luyện trên các tập dữ liệu ảnh–văn bản quy mô lớn, các mô hình này có thể được chuyển giao sang những bài toán y khoa chuyên biệt với lượng dữ liệu gán nhãn hạn chế.

Tuy nhiên, việc chuyển giao các mô hình ngôn ngữ trực quan y khoa sang bài toán phân loại ảnh X-quang xương vẫn gặp nhiều trở ngại. Những trở ngại này xuất phát từ sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu đầu vào thực tế, số lượng dữ liệu gán nhãn hạn chế và mất cân bằng, nguy cơ xuất hiện dữ liệu ngoài phân phối, yêu cầu bảo toàn các tổn thương nhỏ trên ảnh có độ phân giải cao, cũng như nhu cầu giải thích quyết định của mô hình. Các thách thức cụ thể của bài toán được trình bày tại Mục ??.

1.2 Động lực nghiên cứu

1.2.1 Kịch bản thực tế




Hình 1.1: Sơ đồ quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam).

Trong thực hành lâm sàng với các ca bệnh có chỉ định chụp X-quang, quy trình chẩn đoán bệnh lý xương thường tuân theo Hình ?? bao gồm các bước: bác sĩ chính khai thác bệnh sử, khám lâm sàng, chỉ định chụp X-quang. Sau đó, bác sĩ đọc ảnh sẽ phân tích ảnh X-quang và kết hợp với các ngữ cảnh lâm sàng để đưa ra nhận định cận lâm sàng. Cuối cùng, bác sĩ chính sử dụng tất cả các thông tin kể trên để làm căn cứ cho quyết định chẩn đoán cuối cùng và hướng xử trí.

Hệ thống được đề xuất trong luận văn được thiết kế nhằm hỗ trợ quá trình phân tích ảnh X-quang bằng cách khai thác đồng thời ảnh X-quang và dữ liệu văn bản chứa bệnh sử để dự đoán lớp bệnh lý của bệnh nhân như thể hiện ở Hình ?. Việc kết hợp hai nguồn dữ liệu giúp mô hình tận dụng các thông tin bổ sung, từ đó nâng cao khả năng học biểu diễn và cải thiện hiệu quả phân loại so với việc chỉ sử dụng một phương thức dữ liệu.

Cần lưu ý rằng hệ thống được nghiên cứu như một công cụ hỗ trợ phân tích và không thay thế kết luận của bác sĩ. Các đầu ra của mô hình chỉ mang tính hỗ trợ, hiệu quả lâm sàng thực tế cần được đánh giá thêm thông qua nghiên cứu độc lập với sự tham gia của chuyên gia y tế. Về ý tưởng, hệ thống được kỳ vọng sẽ giúp rút ngắn thời gian đọc phim, giảm nguy cơ bỏ sót tổn thương và nâng cao hiệu quả chẩn đoán, đặc biệt tại các cơ sở y tế có khối lượng bệnh nhân lớn hoặc nguồn nhân lực chuyên khoa còn hạn chế.



Hình 1.2: Sơ đồ tích hợp hệ thống hỗ trợ phân tích (các khối tím) vào quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam).

1.2.2 Ý nghĩa khoa học của đề tài

Đề tài cung cấp đánh giá thực nghiệm về giá trị bổ sung của bệnh sử lâm sàng được thu nhận trước khi đọc ảnh đối với bài toán phân loại ảnh X-quang xương. Qua đó, nghiên cứu góp phần làm rõ mức độ mà thông tin lâm sàng có thể cải thiện biểu diễn và hiệu quả phân loại so với phương pháp chỉ sử dụng hình ảnh.

Nghiên cứu đồng thời khảo sát khả năng thích nghi của mô hình ngôn ngữ-thị giác y khoa được tiền huấn luyện trên dữ liệu quy mô lớn đối với

dữ liệu X-quang xương có quy mô hạn chế và phân bố mất cân bằng. Kết quả nghiên cứu cung cấp thêm cơ sở thực nghiệm cho việc ứng dụng các mô hình nền tảng đa phương thức vào những miền y khoa chuyên biệt.

Bên cạnh hiệu quả phân loại, đề tài xem xét khả năng nhận diện dữ liệu ngoài phân phối và phân tích vùng ảnh hưởng đến dự đoán. Việc đánh giá đồng thời các khía cạnh này góp phần mở rộng tiêu chí nghiên cứu từ độ chính xác đơn thuần sang khả năng tổng quát hóa, độ tin cậy và tính minh bạch của hệ thống.

1.2.3 Ý nghĩa thực tiễn của đề tài

Hệ thống được đề xuất hướng đến hỗ trợ bác sĩ trong quá trình phân tích ảnh X-quang bằng cách kết hợp thông tin từ ảnh X-quang và dữ liệu lâm sàng ban đầu để đưa ra kết quả phân loại. Quá trình huấn luyện tận dụng bệnh sử lâm sàng nhằm học mối quan hệ giữa ảnh X-quang và biểu hiện của bệnh lý. Cách tiếp cận này phù hợp với quy trình khám chữa bệnh thực tế tại các cơ sở y tế, góp phần nâng cao khả năng ứng dụng của hệ thống trong thực tiễn.

Ngoài ra, quá trình nghiên cứu góp phần xây dựng và chuẩn hóa một bộ dữ liệu đa phương thức gồm ảnh X-quang và bệnh sử lâm sàng từ dữ liệu thực tế tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh. Bộ dữ liệu và quy trình xử lý có thể tạo nền tảng cho các nghiên cứu tiếp theo về phân loại bệnh lý xương và mô hình ngôn ngữ-thị giác y khoa tại Việt Nam.

Đồng thời, mô hình cung cấp các bản đồ nhiệt trực quan hóa vùng ảnh trong ảnh X-quang ảnh hưởng đến kết quả dự đoán và cơ chế cảnh báo đối với các mẫu dữ liệu ngoài phân phối, góp phần nâng cao tính minh bạch, độ tin cậy và tính an toàn khi hỗ trợ bác sĩ trong quá trình phân tích và đưa ra chẩn đoán xác định.

1.3 Giới thiệu bài toán

Bài toán được nghiên cứu trong đề tài là bài toán phân loại đa lớp ảnh X-quang sử dụng học sâu đa phương thức. Mục tiêu của hệ thống là dự đoán các loại bệnh hoặc tổn thương dựa trên đồng thời dữ liệu hình ảnh X-quang và thông tin lâm sàng liên quan.

- **Đầu vào:** Hệ thống nhận vào các nguồn dữ liệu sau:

- Ảnh X-quang của bệnh nhân:

$$x^{img} \in \mathbb{R}^{H \times W \times C}$$

trong đó:

- * H, W : chiều cao và chiều rộng ảnh,
- * C : số kênh màu của ảnh.
- Thông tin lâm sàng (lời khai bệnh nhân, triệu chứng, tiền sử bệnh).

$$x^{txt} = (w_1, w_2, \dots, w_T)$$

trong đó:

- * w_t : token tại vị trí thứ t trong văn bản,
- * T : số lượng token trong văn bản.
- Tập nhãn được định nghĩa trước:

$$\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$$

với K là số lớp bệnh cần phân loại.

- **Đầu ra:** Hệ thống sinh ra hai đầu ra chính:

- Nhãn dự đoán cuối cùng hoặc cảnh báo dữ liệu ngoài phân phối:

$$\hat{y} = \begin{cases} \text{OOD}, & \text{nếu } s_{\text{OOD}}(x^{img}, x^{txt}) > \tau, \\ \arg \max_{y_k \in \mathcal{Y}} p(y_k | x^{img}, x^{txt}), & \text{ngược lại.} \end{cases}$$

trong đó:

- * $s_{\text{OOD}}(x^{\text{img}}, x^{\text{txt}})$ là điểm ngoài phân phối của mẫu đầu vào;
 - * τ là ngưỡng từ chối được xác định trên tập dữ liệu;
 - * $p(y_k | x^{\text{img}}, x^{\text{txt}})$ là điểm dự đoán của lớp y_k ;
 - * $\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$ là tập các lớp nội phân phối đã biết.
- **Bản đồ nhiệt trực quan hóa:** Hệ thống sinh ra bản đồ nhiệt trên ảnh nhằm thể hiện các vùng có ảnh hưởng đến quyết định dự đoán của mô hình.

1.3.1 Các thách thức trong bài toán

Mặc dù các mô hình học sâu đa phương thức đã đạt được nhiều kết quả tích cực, bài toán vẫn tồn tại nhiều thách thức cần được giải quyết:

- **Sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu đầu vào thực tế:** Tồn tại sự chênh lệch lớn giữa các bộ dữ liệu đa phương thức hiện có (thường là cặp ảnh X-quang và báo cáo đọc ảnh X-quang) so với luồng công việc thực tế lâm sàng (bao gồm ảnh chụp X-quang kết hợp với báo cáo tổng quát), làm hạn chế khả năng ứng dụng trực tiếp của các mô hình.
- **Sự khác biệt về không gian và ngữ nghĩa giữa dữ liệu hình ảnh và dữ liệu văn bản:** Sự khác biệt này gây khó khăn cho quá trình học biểu diễn chung, yêu cầu một cơ chế dung hợp hiệu quả.
- **Bảo toàn tổn thương nhỏ trên ảnh độ phân giải cao:** Việc co toàn bộ ảnh X-quang về kích thước cố định ở độ phân giải thấp của các mô hình hiện nay (224x224) có thể làm mất đi các chi tiết cục bộ quan trọng, đặc biệt là các tổn thương nhỏ, dẫn đến hiệu quả phân loại bị hạn chế.
- **Hạn chế của dữ liệu thực tế:** Dữ liệu y tế thường có số lượng hạn chế và mất cân bằng giữa các loại bệnh, đặt ra yêu cầu đặc biệt về thiết kế mô hình để tận dụng tối đa thông tin có sẵn.

- **Dữ liệu ngoài phân phối:** Các bộ phân loại đóng phổ biến hiện tại chưa được thiết kế để xử lý các trường hợp dữ liệu ngoài phân phối, dẫn đến nguy cơ đưa ra dự đoán không chính xác với độ tin cậy cao đối với những ca bệnh mới chưa từng xuất hiện trong dữ liệu huấn luyện, đặt ra yêu cầu về khả năng tổng quát hóa và thích ứng của mô hình.
- **Khả năng giải thích của mô hình:** Khả năng giải thích của các mô hình vẫn còn hạn chế khiến độ tin cậy của người dùng vào các dự đoán của hệ thống là không cao, gây khó khăn cho việc triển khai trong thực tế lâm sàng.

1.4 Mục tiêu nghiên cứu

Đề tài hướng đến việc nghiên cứu và xây dựng một hệ thống học sâu đa phương thức phục vụ phân loại bệnh lý trên ảnh X-quang xương, hỗ trợ phân tích ảnh, khai thác đồng thời dữ liệu hình ảnh và bệnh sử lâm sàng nhằm đảm bảo hiệu quả phân loại so với các phương pháp hiện có và có khả năng thích ứng với các tình huống thực tế như dữ liệu ngoài phân phối và mất cân bằng lớp.

Các mục tiêu cụ thể của đề tài bao gồm:

1. Đánh giá vai trò của bệnh sử lâm sàng trong việc nâng cao hiệu quả phân loại bệnh lý xương khi kết hợp với ảnh X-quang, so với các phương pháp chỉ sử dụng dữ liệu hình ảnh.
2. Nghiên cứu chiến lược dung hợp đặc trưng đa phương thức, cụ thể là cơ chế chú ý chéo và so sánh với các phương pháp khác, nhằm xác định phương pháp kết hợp hiệu quả giữa đặc trưng hình ảnh và văn bản.
3. Khảo sát các phương pháp tinh chỉnh hiệu quả tham số, nhằm giảm chi phí tính toán trong khi duy trì hoặc cải thiện hiệu quả phân loại so với việc tinh chỉnh toàn bộ tham số.

4. Nghiên cứu cơ chế phát hiện dữ liệu ngoài phân phối nhằm tăng khả năng nhận diện các mẫu bệnh lý chưa từng xuất hiện trong dữ liệu huấn luyện, nâng cao độ tin cậy của hệ thống trong môi trường thực tế.
5. Xây dựng cơ chế giải thích dựa trên bản đồ chú ý giúp trực quan hóa các vùng ảnh mà mô hình tập trung khi đưa ra quyết định phân loại, hỗ trợ bác sĩ trong việc đánh giá và kiểm chứng kết quả dự đoán.
6. Xây dựng và đánh giá hệ thống XBone-Net trên bộ dữ liệu phân loại bệnh lý xương có phân bố mất cân bằng, so sánh với các mô hình nền tảng y khoa hiện có.

1.5 Đối tượng và phạm vi nghiên cứu

1.5.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học sâu đa phương thức sử dụng đồng thời dữ liệu hình ảnh và văn bản trong bài toán phân loại ảnh X-quang xương. Cụ thể, nghiên cứu tập trung vào các thành phần chính sau:

- Các mô hình ngôn ngữ trực quan tiền huấn luyện trên dữ liệu y khoa và dữ liệu tổng quát, được sử dụng làm bộ mã hóa đặc trưng đa phương thức.
- Các chiến lược dung hợp đặc trưng đa phương thức, bao gồm cơ chế chú ý chéo và phép nối đặc trưng, nhằm kết hợp thông tin từ ảnh X-quang và bệnh sử lâm sàng.
- Các phương pháp tinh chỉnh tham số hiệu quả cho các mô hình tiền huấn luyện quy mô lớn nhằm giảm chi phí tính toán.
- Các kiến trúc bộ phân loại, phục vụ bài toán phân loại đa lớp trên dữ liệu mất cân bằng và phát hiện dữ liệu ngoài phân phối.

1.5.2 Phạm vi nghiên cứu

Đề tài tập trung vào bài toán phân loại đa lớp bệnh lý xương trên ảnh X-quang, kết hợp với bệnh sử lâm sàng dạng văn bản. Phạm vi cụ thể bao gồm:

- **Dữ liệu:** Nghiên cứu sử dụng bộ dữ liệu BTXRD gồm 10 lớp bệnh lý xương, và bộ dữ liệu CTCH được thu thập từ Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.
- **Dữ liệu văn bản:** Trong quá trình huấn luyện và suy luận, hệ thống sử dụng bệnh sử lâm sàng được thu nhận trước khi đọc ảnh (chứa thông tin triệu chứng và tiền sử bệnh) thay vì báo cáo đọc ảnh X-quang, nhằm hạn chế rò rỉ nhãn và phù hợp hơn với thời điểm áp dụng hệ thống.
- **Vai trò hệ thống:** Hệ thống được thiết kế làm công cụ hỗ trợ phân tích ảnh, không thay thế vai trò của bác sĩ trong quá trình ra quyết định.
- **Giới hạn:** Đề tài không tập trung vào các bài toán phát hiện đối tượng, phân đoạn ảnh hay sinh báo cáo y khoa tự động.

1.6 Các câu hỏi nghiên cứu và giả thuyết

Trong các giả thuyết dưới đây, Macro F1-Score được sử dụng làm chỉ số chính cho bài toán phân loại do dữ liệu có phân bố mất cân bằng; Accuracy, Macro AUROC và Specificity được sử dụng làm các chỉ số bổ sung. Hiệu quả tính toán được đánh giá thông qua số tham số có thể huấn luyện, mức sử dụng bộ nhớ và thời gian suy luận. Đối với phát hiện dữ liệu ngoài phân phối, các chỉ số chính gồm AUROC, AUPR-Out và FPR@95TPR.

- **Câu hỏi nghiên cứu 1:** Việc kết hợp bệnh sử lâm sàng được thu

nhận trước khi ghi chụp ảnh với ảnh X-quang có cải thiện hiệu quả phân loại so với mô hình chỉ sử dụng ảnh không?

Giả thuyết 1: Mô hình sử dụng đồng thời ảnh X-quang và bệnh sử lâm sàng đạt Macro F1-Score cao hơn mô hình chỉ sử dụng ảnh hoặc chỉ sử dụng văn bản bệnh sử lâm sàng trên cùng tập dữ liệu và quy trình đánh giá.

- **Câu hỏi nghiên cứu 2:** Cơ chế chú ý chéo hai chiều có khai thác tương tác giữa ảnh và văn bản hiệu quả hơn phép nối đặc trưng và các biến thể chú ý chéo một chiều không?

Giả thuyết 2: Cơ chế chú ý chéo hai chiều đạt Macro F1-Score cao hơn các cấu hình dùng phép nối đặc trưng hoặc chỉ thực hiện chú ý theo một chiều khi các thành phần còn lại được giữ nguyên.

- **Câu hỏi nghiên cứu 3:** Chiến lược tinh chỉnh LoRA có đạt hiệu quả phân loại cạnh tranh trong khi giảm chi phí tính toán so với tinh chỉnh toàn bộ tham số trong trường hợp ít mẫu không?

Giả thuyết 3: LoRA đạt Macro F1-Score tương đương hoặc cao hơn tinh chỉnh toàn bộ tham số, đồng thời sử dụng ít tham số có thể huấn luyện và sử dụng ít bộ nhớ hơn.

- **Câu hỏi nghiên cứu 4:** Nhánh xử lý ảnh độ phân giải cao dựa trên lưới ảnh cục bộ và bộ tái lấy mẫu có tọa độ có cải thiện khả năng phân loại so với các phương pháp chỉ sử dụng ảnh toàn cục không?

Giả thuyết 4: Nhánh xử lý ảnh độ phân giải cao đạt Macro F1-Score cao hơn cấu hình chỉ sử dụng ảnh toàn cục khi sử dụng cùng mô hình xương sống và chiến lược huấn luyện.

- **Câu hỏi nghiên cứu 5:** Hệ thống đề xuất XBone-Net có đạt hiệu quả phân loại tốt hơn so với các mô hình nền tảng được tinh chỉnh theo cùng cách thức đánh giá không?

Giả thuyết 5: XBone-Net đạt Macro F1-Score cao hơn mô hình đối chứng tốt nhất; các chỉ số còn lại được báo cáo như tiêu chí bổ sung thay vì giả định XBone-Net phải vượt trội trên mọi độ đo.

- **Câu hỏi nghiên cứu 6:** Không gian biểu diễn của XBone-Net có hỗ trợ phân biệt dữ liệu nội phân phối với các bộ dữ liệu ngoài phân phối được xác định trước không?

Giả thuyết 6: Ít nhất một phương pháp hậu xử lý được khảo sát, gồm khoảng cách Mahalanobis, Cosine-kNN, Energy Score và khoảng cách đến mốc văn bản, đạt AUROC lớn hơn mức ngẫu nhiên trong việc phân biệt dữ liệu nội phân phối và ngoài phân phối; phương pháp được lựa chọn dựa trên tập hiệu chỉnh thay vì tập kiểm thử.

- **Câu hỏi nghiên cứu 7:** Bản đồ chú ý của mô hình có tập trung vào các vùng tổn thương được chú thích trên ảnh X-quang không?

Giả thuyết 7: Trên các mẫu có chú thích tổn thương, tỷ lệ khối lượng chú ý nằm trong vùng tổn thương lớn hơn tỷ lệ diện tích của vùng này trên ảnh, tương ứng với tỷ số tập trung chú ý lớn hơn 1.

1.7 Đóng góp chính của đề tài

Các đóng góp chính của đề tài bao gồm:

1. **Quy trình sử dụng dữ liệu đa phương thức hạn chế rò rỉ nhãn:** Xây dựng quy trình sử dụng ảnh X-quang cùng bệnh sử lâm sàng được thu nhận trước khi đọc ảnh trong cả hai giai đoạn huấn luyện và khi suy luận. Báo cáo đọc ảnh, vốn có thể chứa trực tiếp kết luận chẩn đoán, được loại khỏi pipeline chính và chỉ được sử dụng trong các thí nghiệm loại bỏ thành phần nhằm đánh giá rò rỉ nhãn.
2. **Kiến trúc XBone-Net xử lý ảnh độ phân giải cao:** Phát triển nhánh thị giác bao phủ toàn bộ ảnh X-quang bằng lưới ảnh cục bộ xác định, tổng hợp các token cục bộ và nén chúng bằng bộ tái lấy mẫu có sử dụng thông tin tọa độ. Biểu diễn thị giác sau đó được kết hợp với biểu diễn bệnh sử lâm sàng bằng cơ chế chú ý chéo hai chiều.
3. **Quy trình huấn luyện hai giai đoạn với LoRA:** Thiết kế Giai đoạn 1 sử dụng Semantic Matching Loss để căn chỉnh biểu diễn ảnh và bệnh sử lâm sàng, sau đó tiếp tục tối ưu các adapter LoRA cùng mô-đun dung hợp trong Giai đoạn 2. Cách thiết kế này cho phép thích nghi mô hình BioMedCLIP với dữ liệu X-quang xương trong khi chỉ cập nhật một phần nhỏ tổng số tham số.

4. **Bộ phân loại dựa trên tâm lớp thực nghiệm:** Xây dựng bộ phân loại phi tham số sử dụng độ tương đồng cosine đến các tâm lớp được ước lượng lại từ biểu diễn của tập huấn luyện. Trong Giai đoạn 2, mô hình được tối ưu bằng Cross-Entropy có trọng số theo số mẫu hiệu dụng nhằm giảm ảnh hưởng của phân bố lớp mất cân bằng.
5. **Khung phát hiện dữ liệu ngoài phân phối:** Tích hợp quy trình phát hiện ngoài phân phối theo hướng hậu xử lý trên không gian biểu diễn đã học, hỗ trợ khoảng cách Mahalanobis, Cosine-kNN, Energy Score và khoảng cách đến mốc văn bản. Ngưỡng từ chối được hiệu chỉnh trên dữ liệu nội phân phối tách biệt trước khi đánh giá trên các bộ dữ liệu ngoài phân phối được xác định trước.
6. **Cung cấp khả năng giải thích kết quả:** Xây dựng công cụ trích xuất bản đồ chú ý đặc thù theo lớp từ mô-đun chú ý chéo hai chiều, chiếu trọng số chú ý ngược về các vùng ảnh gốc thông qua bộ tái lấy mẫu không gian và định lượng mức độ tập trung trên vùng tổn thương được chú thích. Công cụ này hỗ trợ phân tích quyết định của mô hình, tuy nhiên không được xem là bằng chứng thay thế cho đánh giá lâm sàng của bác sĩ.

1.8 Bố cục luận văn

Chương 1: Giới thiệu. Chương này cung cấp cái nhìn tổng quan về bối cảnh nghiên cứu, xác định rõ vấn đề cần giải quyết, mục tiêu, phương pháp tiếp cận và những đóng góp chính của đề tài. Đây là phần nền tảng định hướng cho toàn bộ nội dung khóa luận.

Chương 2: Các công trình nghiên cứu liên quan. Chương này tập trung hệ thống hóa các hướng tiếp cận đã được mô tả ở trên, làm tiền đề cho việc xây dựng giải pháp của khóa luận. Trọng tâm của chương là việc phân tích các kiến trúc mô hình ngôn ngữ trực quan cùng các chiến lược dung hợp đặc trưng đa phương thức. Bên cạnh đó, các kỹ thuật tinh chỉnh tối ưu và phương pháp nhận diện dữ liệu ngoài phân phối cũng được xem xét toàn diện, từ đó thiết lập cơ sở lý thuyết vững chắc và định vị rõ

ràng hướng giải quyết của đề tài so với các công trình đi trước.

Chương 3: Phương pháp đề xuất. Đây là chương trọng tâm mô tả chi tiết quy trình xây dựng hệ thống. Tại đây, nhóm sẽ trình bày cụ thể về kiến trúc mô hình được kế thừa, quy trình xử lý dữ liệu đầu vào (cả ảnh và văn bản), thiết kế các hàm mất mát, và chiến lược huấn luyện mô hình. Các sơ đồ khối và thuật toán sẽ được mô tả chi tiết để minh họa cho giải pháp.

Chương 4: Thực nghiệm và Kết quả. Chương này trình bày về bộ dữ liệu được sử dụng, thiết lập môi trường thực nghiệm và các chỉ số đánh giá. Kết quả thực nghiệm sẽ được phân tích, so sánh đối chiếu với các phương pháp khác để làm rõ ưu nhược điểm của mô hình đề xuất.

Chương 5: Kết luận và Hướng phát triển. Chương cuối cùng tổng kết lại những kết quả đạt được so với mục tiêu ban đầu, nhìn nhận những hạn chế còn tồn tại của hệ thống và đề xuất các hướng nghiên cứu tiếp theo để hoàn thiện và mở rộng ứng dụng trong tương lai.

Chương 2

Các công trình nghiên cứu liên quan

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Nhằm xác lập cơ sở cho việc thiết kế hệ thống phân loại, phần này sẽ mô tả tổng quan các nghiên cứu về các mô hình nền tảng của các cách tiếp cận khác nhau cho bài toán phân loại ảnh y khoa, các chiến lược bảo toàn thông tin trên ảnh độ phân giải cao, đặc biệt là cách kết hợp ngữ cảnh toàn cục với đặc trưng cục bộ, các kỹ thuật tinh chỉnh hiệu quả tham số và phương pháp phát hiện dữ liệu ngoài phân phối. Trên cơ sở đó, đối chiếu ưu điểm, hạn chế và mức độ phù hợp của các hướng tiếp cận hiện có đối với dữ liệu thực tế, chương xác định khoảng trống nghiên cứu và làm rõ cơ sở lựa chọn các thành phần trong phương pháp được đề xuất ở Chương 3.

2.1 Các hướng tiếp cận chính và các mô hình nền tảng

2.1.1 Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu

Sự kết hợp giữa dữ liệu cận lâm sàng và báo cáo lâm sàng, lịch sử bệnh lý đã tạo ra những bước tiến lớn trong việc cải thiện độ chính xác của các mô hình chẩn đoán, đặc biệt là thông qua việc sử dụng văn bản để bù đắp những thiếu sót thông tin mà hình ảnh đơn thuần không thể cung cấp, hoặc giúp mô hình tập trung vào những vùng trên ảnh được xác định bởi thông tin từ nguồn văn bản. Nghiên cứu của X. Mei [0] trong việc chẩn đoán COVID-19 là một minh chứng rõ nét: khi ảnh chụp CT ngực ở giai đoạn sớm có thể chưa biểu hiện bất thường, việc tích hợp thông tin lâm sàng thông qua mạng MLP với đặc trưng ảnh từ CNN đã giúp mô hình nhận diện chính xác 68% số bệnh nhân dương tính mà các bác sĩ X-quang đã bỏ sót. Mô hình TieNet [0] đã mã hóa các báo cáo y tế và tích hợp các cơ chế chú ý đa cấp để giống hàng các từ mang ý nghĩa quan trọng với các vùng ảnh tương ứng, cải thiện trung bình 6% chỉ số AUC so với các mô hình chỉ dùng ảnh. Gần đây, IRENE [0] đưa tất cả dữ liệu về một dạng token chung và sử dụng một mô hình Transformer duy nhất, cho phép văn bản trực tiếp tương tác và giải thích các token của ảnh ở cấp độ cục bộ.

Nhìn chung, những nghiên cứu này minh chứng rằng sự đóng góp của nhiều nguồn dữ liệu, đặc biệt là văn bản đã đi từ việc chỉ là một véc-tơ thông tin ghép nối thêm, trở thành một thành phần cốt lõi có khả năng giống hàng ngữ nghĩa và định hướng trong cơ chế chú ý. Tuy nhiên, các mô hình xây dựng từ đầu thường đòi hỏi dữ liệu ghép cặp quy mô lớn và chi phí huấn luyện cao, tạo tiền đề cho sự xuất hiện của các mô hình ngôn ngữ trực quan y khoa.

2.1.2 Mô hình ngôn ngữ trực quan y khoa (Med-VLMs)

Các mô hình ngôn ngữ trực quan đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu, VLMs nói chung và Med-VLMs nói riêng tập trung vào hai nguồn dữ liệu đầu vào chính là ảnh và văn bản, Med-VLMs kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Chiến lược **học tương phản (Contrastive Learning)** là hướng tiếp cận được ứng dụng rộng rãi nhất và có liên quan trực tiếp đến phương pháp đề xuất trong luận văn. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau.

ConVIRT [0] là nghiên cứu tiên phong áp dụng học tương phản cho dữ liệu y khoa, sử dụng ResNet50 và BERT để tối ưu bộ mã hóa ảnh và văn bản, đạt 90,3% accuracy trên bộ dữ liệu COVIDx. GLoRIA [0] mở rộng hướng tiếp cận này bằng cách kết hợp hai hàm mất mát toàn cục (global contrastive) và cục bộ (local contrastive), cho phép căn chỉnh chi tiết giữa các vùng trong ảnh và các từ trong câu. MedCLIP [0] đề xuất cơ chế tách cặp và trích xuất tri thức cùng hàm mất mát Semantic Matching nhằm giải quyết vấn đề âm tính giả (false negative) — khi các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý. BiomedCLIP [0] kế thừa kiến trúc CLIP với bộ mã hóa ViT-Base và PubMedBERT, được tiền huấn luyện trên 15 triệu cặp dữ liệu từ tập PMC-15M, đạt độ chính xác phân loại 83%, giúp mô hình có độ phủ và khả năng tổng quát tốt với nhiều nguồn dữ liệu và tác vụ y khoa.

Ngoài học tương phản, các hướng tiếp cận khác bao gồm **học có che giấu (Masked Learning)** và **tích hợp tri thức y khoa (Knowledge Integration)**. Tuy nhiên, các phương pháp này thường phụ thuộc vào nguồn dữ liệu ghép cặp sẵn hoặc đồ thị tri thức chuyên biệt, hạn chế khả năng ứng dụng trên các bài toán không có sẵn nguồn tri thức ngoài.

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Phương pháp			
			Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	Học tương phản	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	Học tương phản	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	Học tương phản	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	Học tương phản	ViT-Base	PubMedBERT	Contrastive Alignment	N/a

Bảng 2.1: Bảng tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản.

Song song với các Med-VLMs, sự phát triển của các mô hình ngôn ngữ lớn (LLMs) đa phương thức như Med-Flamingo [0], LLaVA-Med [0] hay Med-PaLM M [0] đã cho thấy tiềm năng trong các tác vụ hội thoại và hỗ trợ ra quyết định y khoa. Tuy nhiên, các mô hình này thường có quy mô rất lớn, chi phí huấn luyện và suy luận cao, đồng thời vẫn tồn tại nguy cơ tạo ra thông tin không chính xác (hallucination). Do đó, đối với các bài toán phân loại chuyên biệt như phân loại ảnh X-quang xương, việc sử dụng các mô hình ngôn ngữ - thị giác chuyên dụng kết hợp tinh chỉnh hiệu quả tham số thường phù hợp và hiệu quả hơn.

2.2 Biểu diễn ảnh độ phân giải cao và thông tin không gian

Ảnh y khoa thường có độ phân giải cao để ghi nhận được các dấu hiệu bệnh lý nhỏ, trong khi các bộ mã hóa thị giác tiền huấn luyện thường yêu cầu kích thước đầu vào cố định ở kích thước nhỏ. Việc co toàn bộ ảnh về kích thước nhỏ giúp giảm chi phí tính toán nhưng có thể làm mất các

chi tiết cục bộ. Ngược lại, xử lý trực tiếp ảnh độ phân giải cao làm tăng bộ nhớ cần sử dụng và chi phí tính toán cao của cơ chế chú ý. FPT [0] giải quyết sự đánh đổi này bằng cách lựa chọn một phần token kết hợp với mạng nhánh, cho thấy việc thích nghi mô hình nền tảng cho ảnh y khoa cần đồng thời bảo toàn chi tiết và kiểm soát bộ nhớ.

Trong các mô hình ngôn ngữ-thị giác tổng quát, LLaVA-NeXT [0] đề xuất AnyRes, trong đó ảnh được biểu diễn bởi một ảnh toàn cục và nhiều ô ảnh cục bộ theo lưới thích nghi. Phiên bản Higher-AnyRes mở rộng số ô ảnh để hỗ trợ đầu vào có độ phân giải lớn hơn, đồng thời giới hạn tổng số token bằng phép nội suy đặc trưng. Các thí nghiệm cho thấy tăng độ phân giải quan sát thường cải thiện các tác vụ phụ thuộc vào chi tiết, trong khi tăng mạnh số token hoặc phóng lớn ảnh một cách cưỡng bức làm tăng chi phí nhưng không luôn đem lại hiệu quả tương ứng. Kết quả này nhấn mạnh rằng mục tiêu chính là giữ lại thông tin cục bộ hữu ích trong một ngân sách token phù hợp.

Đối với ảnh y khoa, MedBridge [0] áp dụng chiến lược đa góc nhìn gồm một ảnh toàn cục và nhiều vùng cục bộ được lấy từ ảnh X-quang độ phân giải cao. Cách biểu diễn này duy trì ngữ cảnh giải phẫu của toàn ảnh, đồng thời giúp các dấu hiệu bệnh lý khu trú được quan sát ở độ phân giải phù hợp với bộ mã hóa. Kết quả loại bỏ thành phần cho thấy việc không sử dụng lấy mẫu đa góc nhìn làm hiệu năng giảm, qua đó cung cấp bằng chứng thực nghiệm cho lợi ích của biểu diễn global-local trên ảnh X-quang. Tuy nhiên, nghiên cứu được thực hiện chủ yếu trên X-quang ngực và kết hợp thêm các mô-đun thích nghi khác, nên hiệu quả trên X-quang xương vẫn cần được kiểm chứng riêng.

Ngoài phương pháp chia vùng, Perceiver [0] và Flamingo [0] sử dụng tập truy vấn hoặc latent có kích thước cố định để nén số lượng lớn đặc trưng thị giác. Hướng tiếp cận này giúp kiểm soát độ dài chuỗi, nhưng việc nén quá mạnh có thể làm mất các tín hiệu nhỏ. Nhìn chung, các nghiên cứu hiện nay cho thấy biểu diễn ảnh độ phân giải cao cần cân bằng ba yếu tố: ngữ cảnh toàn cục, chi tiết cục bộ và chi phí tính toán. Đây là cơ sở cho việc nghiên cứu chiến lược global-local với ngân sách token cố định trong bài toán phân loại ảnh X-quang xương.

Chiến lược	Đặc điểm	Khả năng đáp ứng	Hạn chế cần xem xét
Co giãn ảnh toàn cục	Một ảnh được đưa về kích thước cố định	Chi phí thấp và duy trì bố cục tổng thể	Có thể làm mất các dấu hiệu nhỏ hoặc khu trú.
Xử lý trực tiếp ảnh độ phân giải cao	Tăng kích thước ảnh hoặc số lượng patch	Giữ lại nhiều chi tiết hơn; FPT [0] xem xét sự đánh đổi giữa khả năng bảo toàn chi tiết và chi phí bộ nhớ trong ảnh y khoa	Số lượng token và chi phí của cơ chế attention tăng nhanh.
AnyRes và Higher-AnyRes	Kết hợp ảnh toàn cục với các vùng ảnh theo lưới thích nghi và giới hạn số token bằng phép nội suy	Tăng độ phủ không gian và cải thiện các tác vụ phụ thuộc vào chi tiết [0]	Lưới đều có thể xử lý nhiều vùng không liên quan; bằng chứng thực nghiệm chủ yếu đến từ dữ liệu phi y khoa.
Latent resampling	Nén tập token đầu vào thành một số lượng latent cố định	Kiểm soát độ dài chuỗi và chi phí kết nối đa phương thức	Có nguy cơ làm mất các tín hiệu nhỏ và phụ thuộc vào khả năng tối ưu các truy vấn học được [0, 0].
Global-local đa góc nhìn	Kết hợp ảnh toàn cục với nhiều vùng cục bộ được trích xuất từ ảnh gốc	Phù hợp với các dấu hiệu bệnh lý nhỏ và khu trú; MedBridge cho thấy hiệu quả trên ảnh X-quang ngược [0]	Làm tăng số lần thực thi backbone; hiệu quả phụ thuộc vào cách lựa chọn vùng và chưa được kiểm chứng trực tiếp trên ảnh X-quang xương.

Bảng 2.2: Các chiến lược xử lý ảnh độ phân giải cao và sự đánh đổi chính.

2.3 Các kỹ thuật tinh chỉnh hiệu quả tham số

Sự xuất hiện của các Mô hình Nền tảng nói chung và Mô hình Ngôn ngữ - Thị giác Y sinh (Med-VLMs) nói riêng đã mang lại một nền tảng tri thức đa phương thức khổng lồ. Tuy nhiên, để triển khai hiệu quả các mô hình này vào các bài toán lâm sàng đặc thù, quá trình chuyển giao tri thức là bắt buộc.

Hướng đến yêu cầu cụ thể hơn cho bài toán sử dụng hai nguồn ảnh và văn bản lâm sàng, luận văn tập trung vào các kỹ thuật tinh chỉnh để khai thác tối đa từ hai nguồn dữ liệu này với đặc điểm dữ liệu thực tế còn hạn chế.

Trước đây, hai chiến lược phổ biến nhất là tinh chỉnh toàn phần (Full Fine-tuning) và dò tuyến tính (Linear Probing). Tinh chỉnh toàn phần cập nhật lại toàn bộ tham số của mô hình gốc, mang lại khả năng thích ứng cao nhưng đòi hỏi chi phí tính toán, bộ nhớ khổng lồ, yêu cầu dữ liệu huấn luyện lớn đến rất lớn, dẫn đến hiện tượng “quên thảm khốc” (catastrophic forgetting) trên các tập dữ liệu y tế nhỏ. Ngược lại, dò tuyến tính đóng băng toàn bộ mạng nơ-ron gốc và chỉ huấn luyện một lớp phân loại duy nhất ở cuối, tiết kiệm tài nguyên nhưng hạn chế khả năng thích ứng khi sự chênh lệch phân phối (domain shift) giữa dữ liệu gốc và dữ liệu y tế là quá lớn.

Để giải quyết bài toán đánh đổi giữa hiệu năng và chi phí tính toán, Tinh chỉnh Hiệu quả Tham số (Parameter-Efficient Fine-Tuning - PEFT) đã nổi lên như một giải pháp thay thế. Kỹ thuật này chỉ cập nhật hoặc thêm mới một lượng rất nhỏ tham số, giúp tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các phương pháp PEFT được chia thành ba hướng tiếp cận chính:

2.3.1 Tinh chỉnh sử dụng câu nhắc

Hướng tiếp cận này chèn thêm các tham số (vector) có thể học được vào không gian đầu vào của mô hình mà không thay đổi cấu trúc mạng

bên trong.

- **Điểm mạnh:** Tiết kiệm tham số tối đa, bảo toàn nguyên vẹn tri thức của mô hình gốc, đặc biệt hiệu quả trong các kịch bản học ít mẫu (few-shot) hoặc không mẫu (zero-shot).
- **Điểm yếu:** Tối ưu hóa khó khăn do không gian biểu diễn bị giới hạn ở đầu vào, nhạy cảm với cách khởi tạo, và chiếm dụng một phần độ dài của chuỗi đầu vào.

Trong lĩnh vực y tế, PLIP [0] kết hợp đặc trưng thị giác với câu nhắc hiệu quả, đạt 0,896 AUC chỉ với 5% dữ liệu PanNuke. BiomedCoOp [0] tích hợp mô hình ngôn ngữ lớn để tự động sinh các câu nhắc ngữ nghĩa, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản.

2.3.2 Tinh chỉnh bộ điều hợp

Phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ (adapters) vào giữa các lớp kiến trúc của mạng học sâu.

- **Điểm mạnh:** Tính mô-đun hóa cao, dễ dàng thêm/bớt các adapter cho các tác vụ khác nhau mà không can thiệp vào tham số gốc.
- **Điểm yếu:** Việc chèn thêm các lớp mạng vật lý làm tăng độ trễ suy luận (inference latency), hạn chế khả năng triển khai trên các hệ thống đòi hỏi thời gian thực.

Diễn hình, CLIPath [0] sử dụng kết nối thặng dư để giảm khoảng cách miền trên dữ liệu nhỏ. FTB [0] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức.

2.3.3 Tinh chỉnh chọn lọc

Hướng đi này không thêm bất kỳ tham số mới nào, mà chỉ chọn lọc ra một lượng nhỏ các tham số quan trọng nhất của mô hình gốc để cập nhật.

- **Điểm mạnh:** Không làm thay đổi kiến trúc mô hình, hoàn toàn không gây tăng độ trễ (zero inference latency) do tham số cập nhật được hợp nhất trực tiếp vào trọng số gốc.
- **Điểm yếu:** Đòi hỏi phương pháp heuristic phức tạp để xác định chính xác các tham số nào ảnh hưởng lớn nhất đến hiệu năng của tác vụ mục tiêu.

Nổi bật nhất trong nhóm này là cơ chế thích ứng hạng thấp LoRA (Low-Rank Adaptation). LoRA đóng băng toàn bộ trọng số của mô hình tiền huấn luyện, đồng thời tiêm các ma trận phân rã hạng thấp vào các khối Attention. LCBB [0] áp dụng LoRA và đạt 93,1% AUROC trên tập RSNA với chỉ 10% dữ liệu gán nhãn, bám sát hiệu năng của tinh chỉnh toàn phần nhưng giảm thiểu tối đa chi phí.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Nguyên lý	Kết quả nổi bật
1	PLIP (2024)	Prompt Tuning	Kết hợp câu nhắc thị giác với selective tuning, tận dụng đặc trưng hình ảnh để tinh chỉnh hiệu quả	0,896 AUC (5% PanNuke)
2	CLIPath (2023)	Adapter Tuning	Sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu mô bệnh học	Cải thiện so với CLIP trên dữ liệu nhỏ
3	LCBB (2024)	Selective Tuning (LoRA)	Áp dụng LoRA vào bộ mã hóa thị giác, giữ nguyên hiệu năng tinh chỉnh toàn phần	93,1% AUROC (RSNA, 10%)
4	FTB (2024)	Adapter Tuning	Mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản, chất lọc thông tin đa phương thức	Cải thiện trên CheXpert, RSNA

Bảng 2.3: Bảng tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện cho các mô hình ngôn ngữ trực quan y khoa.

2.4 Các phương pháp phát hiện dữ liệu ngoài phân phối

Phát hiện dữ liệu ngoài phân phối (Out-of-Distribution Detection - OOD Detection) là bài toán xác định các mẫu dữ liệu không thuộc phân phối của tập huấn luyện nhằm nâng cao độ tin cậy và tính an toàn của các hệ thống học sâu. Trong lĩnh vực chẩn đoán hình ảnh y khoa, khả năng phát hiện các trường hợp chưa từng xuất hiện hoặc khác biệt đáng kể so với dữ liệu huấn luyện có ý nghĩa quan trọng nhằm giảm nguy cơ đưa ra các dự đoán sai với độ tin cậy cao. Các phương pháp OOD hiện nay có thể được chia thành các nhóm chính sau đây.

2.4.1 Các phương pháp hậu xử lý dựa trên đầu ra mô hình

Nhóm phương pháp này tận dụng trực tiếp đầu ra của một mô hình đã được huấn luyện mà không cần thay đổi kiến trúc hoặc huấn luyện lại mô hình.

- **Maximum Softmax Probability (MSP)[0]:** Sử dụng xác suất Softmax lớn nhất làm độ tin cậy của dự đoán. Các mẫu có xác suất cực đại thấp được xem là ứng viên OOD. Tuy nhiên, các mạng nơ-ron sâu thường có xu hướng dự đoán quá tự tin (overconfidence), làm giảm hiệu quả của phương pháp.
- **ODIN (Out-of-Distribution detector for Neural Networks)[0]:** Mở rộng MSP bằng cách kết hợp hiệu chỉnh nhiệt độ và nhiễu đầu vào nhằm gia tăng khoảng cách logit giữa dữ liệu trong phân phối (In-Distribution - ID) và dữ liệu OOD.
- **Energy-based Score[0]:** Thay vì sử dụng xác suất Softmax, phương pháp này sử dụng giá trị năng lượng được tính từ vector logit thay vì sử dụng xác suất lớn nhất:

$$E(x) = -T \log \sum_i \exp \left(\frac{f_i(x)}{T} \right),$$

trong đó $f_i(x)$ là logit của lớp thứ i và T là hệ số nhiệt độ.

Các cải tiến của ODIN và Energy-based Score khắc phục một phần hạn chế của MSP, nhưng vẫn phụ thuộc chủ yếu vào đầu ra của bộ phân loại và chưa mô hình hóa trực tiếp phân phối của embedding.

2.5 Các phương pháp phát hiện dữ liệu ngoài phân phối

Phát hiện dữ liệu ngoài phân phối (Out-of-Distribution - OOD detection) là bài toán cốt lõi nhằm xác định các mẫu dữ liệu không thuộc phân phối của tập huấn luyện (In-Distribution - ID). Đặc biệt trong lĩnh vực phân tích ảnh y khoa, khả năng từ chối dự đoán đối với các mẫu dữ liệu lạ giúp ngăn chặn các chẩn đoán sai lệch với độ tự tin cao, từ đó đảm bảo tính an toàn của hệ thống. Dựa trên cách tiếp cận, các phương pháp OOD hiện nay được chia thành các nhóm chính sau.

2.5.1 Các phương pháp hậu xử lý dựa trên đầu ra (Post-hoc Output-based Methods)

Nhóm phương pháp này không can thiệp vào quá trình huấn luyện mà tận dụng trực tiếp đầu ra (thường là các logit hoặc xác suất) của một bộ phân loại đã được huấn luyện.

- **Maximum Softmax Probability (MSP) [0]:** Sử dụng giá trị cực đại của hàm Softmax làm độ tin cậy. Dữ liệu có xác suất cực đại thấp sẽ bị đánh dấu là OOD. Tuy nhiên, điểm yếu chí mạng của MSP là các mạng nơ-ron sâu thường mắc lỗi "tự tin thái quá" (overconfidence), dẫn đến việc gán xác suất rất cao cho cả những mẫu OOD hoàn toàn không liên quan.
- **ODIN (Out-of-Distribution detector for Neural Networks) [0]:** Cải thiện MSP bằng cách sử dụng hiệu chỉnh nhiệt độ (Temperature Scaling) và thêm nhiễu đầu vào (Input Perturbation) để gia tăng sự chênh lệch logit giữa dữ liệu trong phân phối (ID - In-Distribution) và dữ liệu ngoài phân phối (OOD - Out-of-Distribution).
- **Energy-based Score [0]:** Chuyển đổi vector logit thành hàm năng

lượng thay vì xác suất Softmax:

$$E(x) = -T \log \sum_i \exp \left(\frac{f_i(x)}{T} \right)$$

trong đó $f_i(x)$ là logit của lớp thứ i và T là hệ số nhiệt độ. Dữ liệu ID sẽ có mức năng lượng thấp hơn so với dữ liệu OOD. Mặc dù khắc phục được một phần lỗi overconfidence, các phương pháp này vẫn bị giới hạn bởi không gian quyết định (decision boundary) mở vô tận của hàm Softmax ở lớp cuối cùng.

2.5.2 Các phương pháp dựa trên độ không chắc chắn và tái tạo (Uncertainty & Reconstruction)

Để tránh phụ thuộc vào đầu ra Softmax, một số nghiên cứu tiếp cận bài toán bằng cách đánh giá khả năng sinh hoặc sự bất định của mô hình.

- **Reconstruction Error:** Sử dụng các mô hình sinh như Autoencoder (AE) được huấn luyện chỉ trên dữ liệu ID. Khi gặp dữ liệu OOD, sai số tái tạo (reconstruction error) sẽ tăng đột biến. Dù hiệu quả, phương pháp này gặp khó khăn khi tái tạo các ảnh y khoa có độ phân giải cao và chi tiết phức tạp.
- **Monte Carlo Dropout (MC Dropout):** Kích hoạt Dropout trong quá trình kiểm thử (inference) và thực hiện dự đoán nhiều lần để tính phương sai. Tuy nhiên, việc phải suy luận nhiều lần làm tăng chi phí tính toán, không phù hợp cho các hệ thống đòi hỏi thời gian thực.

2.5.3 Các phương pháp dựa trên khoảng cách trong không gian đặc trưng (Distance-based Methods)

Nhận thấy những hạn chế của không gian logit, các nghiên cứu gần đây chuyển hướng sang thực hiện phát hiện OOD trực tiếp trên không gian đặc trưng (embedding space). Việc đánh giá bằng khoảng cách giúp giới hạn không gian rủi ro mở (open-space risk).

- **Khoảng cách Euclidean và Cosine:** Khoảng cách Euclidean đo khoảng cách hình học tuyệt đối $d_E(z, c_k) = \|z - c_k\|_2$, trong khi Cosine chỉ xét góc giữa các vector. Điểm yếu của chúng là giả định phân phối của các cụm dữ liệu có dạng hình cầu hoàn hảo và phương sai đồng đều ở mọi chiều, điều hiếm khi xảy ra trong thực tế dữ liệu phức tạp.
- **Khoảng cách Mahalanobis [0]:** Khắc phục điểm yếu của Euclidean bằng cách xét đến ma trận hiệp phương sai (covariance matrix), giúp đo lường khoảng cách dựa trên cả hình dáng và hướng của phân phối dữ liệu:

$$d_M(z, \mu_k) = (z - \mu_k)^\top (\Sigma + \lambda I)^{-1} (z - \mu_k)$$

Trong đó, z là embedding của mẫu kiểm thử, μ_k là tâm cụm lớp k , và Σ là ma trận hiệp phương sai. Mahalanobis mô tả ranh giới phân phối dữ liệu chính xác và mềm dẻo hơn.

2.5.4 Học biểu diễn phục vụ phát hiện dữ liệu ngoài phân phối

Sự thành công của các phương pháp dựa trên khoảng cách phụ thuộc rất lớn vào chất lượng của không gian đặc trưng. Nếu mô hình được huấn luyện bằng hàm Cross-Entropy thông thường, dữ liệu của các lớp không được tối ưu để co cụm lại, làm giảm hiệu quả của các phép đo khoảng

cách. Để giải quyết vấn đề này, các kỹ thuật học biểu diễn (Representation Learning) được áp dụng.

- **Contrastive Learning:** Học biểu diễn bằng cách kéo gần các mẫu tương đồng và đẩy xa các mẫu khác lớp trong không gian đặc trưng.
- **Center Loss [0]:** Giảm phương sai nội lớp bằng cách học một tâm biểu diễn cho mỗi lớp và ép các embedding tiến gần tâm tương ứng.
- **Prototypical Networks (ProtoNet) [0]:** Là một kiến trúc mạng học theo hệ đo (Metric Learning), ProtoNet định nghĩa trực tiếp mỗi lớp bằng một nguyên mẫu (prototype) c_k :

$$c_k = \frac{1}{|S_k|} \sum_{x_i \in S_k} f_{\theta}(x_i)$$

Trong quá trình huấn luyện, mạng được tối ưu hóa để cực tiểu hóa khoảng cách giữa đặc trưng của dữ liệu và prototype tương ứng của nó.

2.6 Bàn luận

2.6.1 Hạn chế của các nghiên cứu hiện nay

Mặc dù đạt được nhiều kết quả tích cực, các nghiên cứu hiện có vẫn chưa giải quyết đồng thời các yêu cầu của bài toán phân loại ảnh X-quang xương đa phương thức.

Thứ nhất, phần lớn mô hình y khoa đa phương thức được phát triển trên X-quang ngực hoặc các bộ dữ liệu lớn. Ảnh X-quang xương có phạm vi giải phẫu, tư thế chụp và kiểu tổn thương đa dạng, trong khi số lượng mẫu giữa các lớp thường mất cân bằng đáng kể. Vì vậy, hiệu quả trên các miền dữ liệu khác chưa thể được chuyển trực tiếp sang bài toán này.

Thứ hai, việc co toàn bộ ảnh về kích thước cố định có thể làm mất các đường gãy hoặc bất thường khu trú. Ngược lại, xử lý toàn bộ ảnh ở độ phân giải cao hoặc chia thành quá nhiều vùng làm số token và chi phí tính

toán tăng nhanh. Do đó, cần kết hợp ngữ cảnh toàn cục với các vùng cục bộ có ích trong một ngân sách token được kiểm soát.

Thứ ba, nhiều nghiên cứu sử dụng báo cáo đọc ảnh hoặc kết luận chẩn đoán làm đầu vào văn bản. Tuy nhiên, các báo cáo này thường được hình thành sau khi bác sĩ hoặc bác sĩ chẩn đoán hình ảnh đã quan sát phim và có thể mô tả trực tiếp vị trí, hình thái hoặc mức độ tổn thương, chẳng hạn đường gãy, di lệch hay bất thường xương. Việc sử dụng các nguồn văn bản này trong giai đoạn suy luận có thể gây rò rỉ nhãn, khiến mô hình chủ yếu học cách ánh xạ một mô tả gần với kết luận chẩn đoán sang nhãn tương ứng. Trong bối cảnh triển khai thực tế, để tạo được báo cáo chi tiết, bác sĩ đã phải nhận diện tổn thương trước, do đó mô hình không còn đóng vai trò hỗ trợ phát hiện mà chủ yếu lặp lại thông tin đã được xác định. Ngược lại, các thông tin lâm sàng có sẵn trước chẩn đoán cuối cùng, như triệu chứng, tiền sử bệnh, vị trí đau hoặc cơ chế chấn thương, vẫn chưa được khai thác đầy đủ, mặc dù đây là những nguồn thông tin quan trọng giúp định hướng quá trình chẩn đoán. Bên cạnh đó, nhiều phương pháp chỉ nổi hai vector đặc trưng toàn cục, nên chưa mô hình hóa được quan hệ cụ thể giữa các vùng ảnh và nội dung lâm sàng liên quan.

Thứ ba, mặc dù các mô hình nền tảng đạt hiệu quả cao, nhiều nghiên cứu vẫn lựa chọn tính chỉnh toàn bộ tham số của mô hình. Cách tiếp cận này đòi hỏi chi phí tính toán lớn, đồng thời làm tăng nguy cơ quên tri thức đã được học trong giai đoạn tiền huấn luyện.

Cuối cùng, hầu hết các nghiên cứu chỉ tập trung tối ưu hiệu năng phân loại mà chưa quan tâm đầy đủ đến khả năng phát hiện dữ liệu ngoài phân phối. Trong môi trường lâm sàng, mô hình có thể gặp các trường hợp bệnh lý hiếm, dữ liệu có chất lượng thấp hoặc các bất thường chưa xuất hiện trong tập huấn luyện. Nếu không có cơ chế phát hiện OOD, mô hình vẫn có thể đưa ra dự đoán với độ tin cậy cao mặc dù kết quả không chính xác.

2.6.2 Cơ sở lựa chọn và định hướng phương pháp đề xuất

Từ những hạn chế trên, luận văn lựa chọn xây dựng hệ thống dựa trên việc kế thừa mô hình BiomedCLIP [0] kết hợp với thông tin lâm sàng để khai thác đồng thời đặc trưng hình ảnh và văn bản. Các lựa chọn thiết kế cụ thể được đưa ra dựa trên phân tích sau:

Về kỹ thuật tinh chỉnh: Kỹ thuật LoRA được lựa chọn thay vì tinh chỉnh toàn phần hoặc các phương pháp tinh chỉnh hiệu quả tham số khác, vì ba lý do chính:

- LoRA giảm số lượng tham số cần huấn luyện xuống đáng kể bằng cách tiêm các ma trận phân rã hạng thấp vào mạng nơ-ron, cho phép tinh chỉnh các mô hình VLM ngay cả khi nguồn lực tính toán bị hạn chế.
- Khác với Adapter Tuning chèn thêm các lớp ẩn vật lý làm chậm tốc độ xử lý, các ma trận trọng số của LoRA có thể được cộng gộp trực tiếp vào trọng số gốc, giúp không tăng độ trễ trong lúc suy luận.
- LoRA cho phép mô hình bám sát dữ liệu y tế đặc thù trong khi không phá vỡ các cấu trúc tri thức đa phương thức tổng quát đã được tiền huấn luyện.

Về xử lý ảnh độ phân giải cao: Luận văn lựa chọn chiến lược global-local nhằm đồng thời duy trì bố cục giải phẫu toàn cục và bảo toàn các dấu hiệu bệnh lý nhỏ trên ảnh gốc. Thay vì chia ảnh thành lưới dày làm tăng chi phí tính toán, hệ thống chỉ sử dụng bốn vùng cục bộ được lựa chọn theo chiến lược sparse-focal và nén thành số token cố định. Thông tin tọa độ của từng vùng được bổ sung để duy trì quan hệ không gian, trong khi cơ chế chú ý cho phép mô hình ưu tiên các vùng phù hợp với ngữ cảnh toàn ảnh. Thiết kế này cân bằng giữa khả năng giữ lại chi tiết, độ phủ không gian và chi phí xử lý.

Về phương pháp phát hiện OOD: Nghiên cứu đề xuất sự kết hợp tương hỗ giữa Mạng nguyên mẫu (Prototypical Networks) và khoảng cách

Mahalanobis theo hai giai đoạn. Trong giai đoạn huấn luyện, hàm mất mát Entropy chéo có trọng số được kết hợp cùng Mạng nguyên mẫu để tối ưu hóa việc phân loại. Cơ chế này chủ động định hình không gian đặc trưng, ép các dữ liệu chuẩn thuộc phân phối tạo thành các cụm xung quanh các nguyên mẫu, khắc phục nhược điểm mở rộng không gian quyết định vô hạn của hàm Softmax.

Trong giai đoạn suy luận, khoảng cách Mahalanobis được áp dụng ở khâu hậu kỳ (post-hoc) để phát hiện dữ liệu bất thường, thay thế cho khoảng cách Euclidean mặc định. Việc này cho phép tận dụng thông tin từ ma trận hiệp phương sai của các cụm đặc trưng đã được định hình trước đó. Nhờ vậy, hệ thống đánh giá chính xác mức độ bất thường của mẫu và nhận diện các ranh giới phân phối tinh tế hơn. Từ đó, mô hình từ chối hiệu quả các mẫu dữ liệu lạ, đặc biệt là các trường hợp có đặc trưng rất gần với dữ liệu gốc (Near-OOD) phổ biến trong ảnh y khoa, đồng thời vẫn duy trì độ chính xác cao trên tập dữ liệu chuẩn.

Về kiến trúc pipeline: Hệ thống được thiết kế theo kiến trúc hai giai đoạn :

- **Giai đoạn 1 - Căn chỉnh tương phản:** Chỉ huấn luyện backbone BiomedCLIP thông qua LoRA bằng hàm mất mát tương phản, giúp backbone thích ứng với miền dữ liệu y khoa chuyên biệt. Mô-đun dung hợp và bộ phân loại được đóng băng trong giai đoạn này.
- **Giai đoạn 2 - Huấn luyện dung hợp và phân loại:** Tiếp tục huấn luyện backbone thông qua LoRA phục vụ cho nhiệm vụ phân loại, ngoài ra spatial resampler và mô-đun dung hợp cross-attention tiếp tục được tối ưu. Bộ phân loại empirical-centroid không học prototype tự do mà cập nhật centroid từ trung bình embedding của tập huấn luyện, qua đó hạn chế nguy cơ quá khớp.

Kiến trúc chi tiết của hệ thống cùng quy trình huấn luyện và đánh giá sẽ được trình bày trong Chương 3.

Chương 3

Phương pháp đề xuất

3.1 Tổng quan phương pháp đề xuất

Nhóm nghiên cứu đề xuất XBone-Net như một pipeline học sâu đa phương thức dành cho phân loại ảnh X-quang xương, trong đó ảnh cung cấp bằng chứng hình thái và bệnh sử lâm sàng cung cấp ngữ cảnh liên quan đến tình trạng của người bệnh trước khi ảnh được diễn giải. Pipeline kế thừa bộ mã hóa thị giác và bộ mã hóa văn bản của BiomedCLIP [0], thích nghi miền dữ liệu cho hai bộ mã hóa bằng LoRA, sử dụng đồng thời thông tin toàn cục và chi tiết cục bộ của ảnh, trao đổi thông tin giữa hai phương thức bằng chú ý chéo hai chiều, sau đó đưa biểu diễn dung hợp vào bộ phân loại dựa trên tâm lớp thực nghiệm. Báo cáo kết quả X-quang không được sử dụng làm đầu vào của pipeline chính nhằm hạn chế nguy cơ mô hình dựa vào từ khóa chẩn đoán thay vì học mối liên hệ giữa hình ảnh và bệnh sử.

Quy trình được chia thành quá trình huấn luyện ngoại tuyến và quá trình suy luận trực tuyến. Cách phân chia này làm rõ thành phần nào được cập nhật từ dữ liệu huấn luyện và thành phần nào chỉ thực hiện truyền thuận khi hệ thống tiếp nhận một ca mới. Trong cả hai quá trình, ảnh và văn bản đi qua cùng một quy tắc tiền xử lý và cùng một kiến trúc mã hóa; khác biệt chủ yếu nằm ở việc tính gradient, cập nhật tham số và ước lượng tâm lớp.

3.1.1 Huấn luyện hai giai đoạn trong quá trình ngoại tuyến (Offline)

Trong giai đoạn thứ nhất, ảnh X-quang và bệnh sử lâm sàng tương ứng được đưa qua hai bộ mã hóa để tạo biểu diễn trong một không gian chung. Mục tiêu khớp ngữ nghĩa được sử dụng để tăng mức tương hợp của cặp ảnh-văn bản tương ứng và ghi nhận quan hệ giữa các mẫu cùng lớp, qua đó giảm việc xem mọi cặp không trùng chỉ số là cặp âm. Mini-batch được lấy mẫu có nhận biết lớp để tăng khả năng mỗi lớp đóng góp nhiều hơn một mẫu vào cùng một batch, nhờ đó quan hệ đồng lớp trong mục tiêu mềm có thể được quan sát trực tiếp. Ở giai đoạn này, trọng số nền của BiomedCLIP được giữ cố định; các adapter LoRA và các thành phần tổng hợp đặc trưng ảnh cục bộ được cập nhật. Bộ dung hợp chú ý chéo và bộ phân loại chưa tham gia vào mục tiêu tối ưu của giai đoạn thứ nhất.

Trong giai đoạn thứ hai, các adapter LoRA được giữ ở dạng tách rời và tiếp tục được cập nhật thay vì hợp nhất vào trọng số nền. Biểu diễn ảnh và văn bản được đưa qua chú ý chéo hai chiều để hình thành biểu diễn dung hợp, sau đó các tâm lớp được ước lượng từ toàn bộ biểu diễn của tập huấn luyện. Hàm mất mát phân loại cập nhật adapter LoRA, thành phần biểu diễn ảnh cục bộ, mô-đun dung hợp và độ lệch riêng của từng lớp; các tâm lớp là thống kê thực nghiệm nên không nhận gradient. Việc tách hai giai đoạn giúp quá trình thích nghi không gian ảnh-văn bản được thực hiện trước khi tối ưu trực tiếp ranh giới quyết định của bài toán phân loại.

Sau mỗi epoch của giai đoạn thứ hai, tâm lớp được ước lượng lại bằng trạng thái hiện tại của bộ mã hóa trước khi đánh giá trên tập validation. Checkpoint được lựa chọn theo độ đo đã xác định trước trên tập validation, sau đó tâm lớp được tính lại một lần cuối từ tập huấn luyện bằng checkpoint được chọn. Tập kiểm thử không tham gia vào quá trình cập nhật tham số, lựa chọn checkpoint hoặc ước lượng tâm lớp.

3.1.2 Suy luận trong quá trình trực tuyến (Online)

Trong quá trình trực tuyến, một ảnh X-quang và bệnh sử lâm sàng của ca cần phân tích được xử lý bằng đúng pipeline đã sử dụng trong giai đoạn thứ hai. Các tham số của bộ mã hóa, adapter LoRA, mô-đun dung hợp, tâm lớp và độ lệch lớp đều được cố định; hệ thống chỉ thực hiện truyền thuận để tạo biểu diễn dung hợp, tính điểm của từng lớp và trả về lớp có điểm lớn nhất. Quá trình này không yêu cầu cập nhật gradient, không ước lượng lại tâm lớp từ mẫu mới và không sử dụng thông tin từ tập kiểm thử để điều chỉnh quyết định.

Biểu diễn dung hợp và đầu ra phân loại có thể được chuyển sang mô-đun OOD hậu xử lý đã hiệu chỉnh bằng dữ liệu huấn luyện và validation. Mô-đun OOD không làm thay đổi dự đoán phân loại bên trong XBone-Net mà bổ sung một tín hiệu về mức độ phù hợp của mẫu với phân phối đã quan sát. Vì vậy, kết quả phân loại và cảnh báo OOD được xem là hai đầu ra có mục đích khác nhau: đầu ra thứ nhất lựa chọn lớp gần nhất trong tập lớp đã biết, còn đầu ra thứ hai xem xét liệu mẫu có đủ tương đồng với dữ liệu trong phân phối hay không.

3.2 Các thành phần của pipeline

3.2.1 Đầu vào và tiền xử lý (Input and Pre-processing)

Mỗi mẫu huấn luyện gồm một ảnh X-quang, một bệnh sử lâm sàng và một nhãn lớp duy nhất. Tập dữ liệu huấn luyện được ký hiệu như sau.

$$\mathcal{D}_{\text{train}} = \{(X_i, R_i, y_i)\}_{i=1}^N. \quad (3.1)$$

Trong Công thức ??, N là số mẫu huấn luyện, X_i là ảnh X-quang gốc của mẫu thứ i , R_i là bệnh sử lâm sàng tương ứng và $y_i \in \{1, \dots, K\}$ là nhãn của một trong K lớp. Ký hiệu $\mathcal{D}_{\text{train}}$ chỉ tập huấn luyện và không

bao gồm tập validation hoặc tập kiểm thử.

Ảnh X-quang thường có độ phân giải và tỷ lệ khung hình khác nhau, trong khi bộ mã hóa thị giác kế thừa nhận đầu vào có kích thước cố định. Pipeline vì vậy tạo một ảnh toàn cục để giữ bố cục giải phẫu và bốn ảnh cục bộ để giữ lại chi tiết tại các vùng giàu thông tin. Ảnh toàn cục được tạo bằng phép biến đổi giữ tỷ lệ và thêm biên khi cần thiết, sau đó được chuẩn hóa theo quy tắc đầu vào của bộ mã hóa thị giác.

$$X_i^g = \mathcal{T}_g(X_i) \in \mathbb{R}^{3 \times H \times W}. \quad (3.2)$$

Trong Công thức ??, $\mathcal{T}_g$ là phép tiền xử lý ảnh toàn cục, X_i^g là ảnh toàn cục của mẫu thứ i , ba kênh đầu vào được tạo theo định dạng mà backbone yêu cầu, còn $H = W = 224$ là chiều cao và chiều rộng đưa vào bộ mã hóa. Phép biến đổi này không sử dụng nhân hoặc vị trí tổn thương.

Đối với nhánh cục bộ, ảnh nguồn trước hết được xác định vùng nội dung nhằm hạn chế các biên đen và vùng đệm của thiết bị chụp. Bốn cửa sổ được chọn theo chiến lược sparse-focal: hai cửa sổ hỗ trợ bao phủ dọc theo trục chính của vùng giải phẫu và hai cửa sổ ưu tiên vùng có năng lượng kết cấu cao, đồng thời hạn chế chồng lấp quá mức với các vùng đã chọn. Mỗi cửa sổ được ánh xạ về ảnh nguồn và biến đổi thành một local view có cùng kích thước đầu vào với ảnh toàn cục.

$$\mathcal{X}_i^\ell = \{X_{i,m}^\ell = \mathcal{T}_\ell(X_i; b_{i,m})\}_{m=1}^M. \quad (3.3)$$

Trong Công thức ??, $\mathcal{X}_i^\ell$ là tập local view của mẫu thứ i , $M = 4$ là số vùng cục bộ cố định, $b_{i,m}$ là hộp tọa độ của vùng thứ m trên ảnh nguồn, $\mathcal{T}_\ell$ là phép cắt, đổi kích thước và chuẩn hóa vùng ảnh, còn $X_{i,m}^\ell \in \mathbb{R}^{3 \times 224 \times 224}$ là local view thứ m . Các hộp $b_{i,m}$ chỉ được xác định từ tín hiệu ảnh, không sử dụng nhân, bounding box tổn thương hoặc một mô hình phát hiện được huấn luyện riêng.

Bệnh sử lâm sàng được chuẩn hóa về mã hóa ký tự, khoảng trắng và các ký hiệu không mang nội dung trước khi token hóa. Chuỗi được cắt hoặc đệm đến độ dài tối đa, đồng thời một attention mask được tạo để phân biệt token nội dung với token đệm.

$$(\mathbf{u}_i, \mathbf{m}_i) = \mathcal{T}_t(R_i). \quad (3.4)$$

Trong Công thức ??, $\mathcal{T}_t$ là bộ tiền xử lý và token hóa văn bản, $\mathbf{u}_i \in \mathbb{N}^L$ là chuỗi chỉ số token, $\mathbf{m}_i \in \{0, 1\}^L$ là attention mask và L là độ dài chuỗi sau khi cắt hoặc đệm. Giá trị một trong $\mathbf{m}_i$ biểu thị token hợp lệ, còn giá trị không biểu thị vị trí đệm không được tham gia vào phép chú ý.

3.2.2 Bộ mã hóa (Encoders)

Hai bộ mã hóa được kế thừa từ BiomedCLIP để tận dụng không gian biểu diễn ảnh-văn bản đã được tiền huấn luyện trên dữ liệu y sinh. Bộ mã hóa thị giác xử lý ảnh toàn cục và các local view bằng cùng một tập trọng số, trong khi bộ mã hóa văn bản xử lý chuỗi token của bệnh sử. Đầu ra của hai nhánh được chiếu về cùng chiều $D = 512$, nhờ đó có thể được căn chỉnh ở giai đoạn thứ nhất và trao đổi thông tin trong mô-đun dung hợp ở giai đoạn thứ hai.

Bộ mã hóa thị giác (Visual Encoder)

Bộ mã hóa thị giác sử dụng Vision Transformer của BiomedCLIP. Ảnh toàn cục được chia thành các patch, kết hợp với token đại diện và embedding vị trí, sau đó đi qua các lớp Transformer. Token đại diện ở đầu ra được chiếu về không gian chung để tạo đặc trưng toàn cục.

$$\mathbf{g}_i^I = \mathcal{P}_I(\mathcal{E}_I(X_i^g)_{\text{CLS}}) \in \mathbb{R}^D. \quad (3.5)$$

Trong Công thức ??, $\mathcal{E}_I$ là bộ mã hóa thị giác, chỉ số CLS chỉ token đại diện của ảnh, $\mathcal{P}_I$ là phép chiếu thị giác sang không gian biểu diễn chung, $\mathbf{g}_i^I$ là embedding ảnh toàn cục và $D = 512$ là số chiều đặc trưng.

Mỗi local view đi qua cùng bộ mã hóa thị giác. Đối với từng vùng, pipeline giữ lại token CLS và một lưới 2×2 thu được bằng pooling thích nghi trên các patch token. Cách tổng hợp này tạo năm token cho mỗi vùng, gồm một token mang nội dung tổng quát của vùng và bốn token giữ phân bố không gian thô bên trong vùng.

$$\mathbf{L}_{i,m}^I = \mathcal{P}_I \left(\text{Concat} \left[\mathcal{E}_I (X_{i,m}^\ell)_{\text{CLS}}, \text{Pool}_{2 \times 2} \left(\mathcal{E}_I (X_{i,m}^\ell)_{\text{patch}} \right) \right] \right) \in \mathbb{R}^{5 \times D}. \quad (3.6)$$

Trong Công thức ??, $\mathbf{L}_{i,m}^I$ là tập token của local view thứ m , ký hiệu patch chỉ chuỗi patch token ở đầu ra của bộ mã hóa, $\text{Pool}_{2 \times 2}$ là phép pooling thích nghi tạo bốn vùng không gian, Concat là phép ghép theo chiều token và $\mathcal{P}_I$ là phép chiếu được áp dụng theo từng token. Số chiều của mỗi token sau phép chiếu được ký hiệu là D .

Token của bốn local view được ghép thành một chuỗi có ngân sách cố định. Cấu trúc cố định này giúp mô-đun dung hợp nhận cùng số token ảnh đối với mọi mẫu, không phụ thuộc kích thước ban đầu của ảnh X-quang.

$$\mathbf{L}_i^I = \text{Concat}_{m=1}^M (\mathbf{L}_{i,m}^I) \in \mathbb{R}^{P \times D}. \quad (3.7)$$

Trong Công thức ??, $\mathbf{L}_i^I$ là toàn bộ chuỗi token cục bộ, $M = 4$ là số local view và $P = 5M = 20$ là tổng số token cục bộ. Phép ghép giữ nguyên thứ tự vùng và thứ tự token bên trong từng vùng.

Do các vùng cục bộ được lấy từ những vị trí khác nhau trên ảnh nguồn, tọa độ chuẩn hóa của mỗi vùng được ánh xạ thành embedding không gian và cộng vào token tương ứng. Một hệ số có thể học kiểm soát cường độ của tín hiệu tọa độ để thông tin vị trí bổ sung cho nội dung thị giác mà không thay thế nội dung đó.

$$\tilde{\mathbf{L}}_i^I = \mathbf{L}_i^I + \gamma \mathcal{P}_s (\mathbf{B}_i). \quad (3.8)$$

Trong Công thức ??, $\mathbf{B}_i$ chứa tọa độ đã chuẩn hóa của bốn hộp cục bộ, $\mathcal{P}_s$ là phép chiếu tọa độ sang không gian D chiều, γ là hệ số vô hướng có thể học và $\tilde{\mathbf{L}}_i^I$ là chuỗi token cục bộ đã bổ sung vị trí. Embedding của một hộp được lặp cho năm token xuất phát từ hộp đó.

Trong giai đoạn thứ nhất, chuỗi token cục bộ được tổng hợp bằng attention pooling có điều kiện theo embedding toàn cục. Cơ chế này cho phép mức đóng góp của các vùng thay đổi theo từng ảnh thay vì sử dụng trung bình không trọng số.

$$e_{i,p} = \mathbf{w}_a^\top \tanh \left(\mathbf{W}_g \mathbf{g}_i^I + \mathbf{W}_\ell \tilde{\mathbf{L}}_{i,p}^I \right). \quad (3.9)$$

Trong Công thức ??, $e_{i,p}$ là điểm chú ý chưa chuẩn hóa của token cục bộ thứ p , $\tilde{\mathbf{L}}_{i,p}^I$ là token cục bộ tương ứng, $\mathbf{W}_g$ và $\mathbf{W}_\ell$ là các ma trận chiếu có thể học, $\mathbf{w}_a$ là vector tham số của attention pooling và $\tanh$ là hàm kích hoạt.

$$a_{i,p} = \frac{\exp(e_{i,p})}{\sum_{q=1}^P \exp(e_{i,q})}. \quad (3.10)$$

Trong Công thức ??, $a_{i,p}$ là trọng số đã chuẩn hóa của token thứ p , $P = 20$ là tổng số token cục bộ và chỉ số q duyệt qua toàn bộ token cục bộ của cùng một ảnh. Các trọng số không âm và có tổng bằng một.

$$\mathbf{z}_i^I = \text{Norm}_2 \left(\mathbf{g}_i^I + \lambda_\ell \sum_{p=1}^P a_{i,p} \tilde{\mathbf{L}}_{i,p}^I \right). \quad (3.11)$$

Trong Công thức ??, $\mathbf{z}_i^I$ là embedding thị giác dùng cho mục tiêu căn chỉnh ở giai đoạn thứ nhất, Norm_2 là phép chuẩn hóa theo chuẩn Euclid, $\lambda_\ell = 0,25$ là hệ số điều tiết đóng góp của nhánh cục bộ và tổng có trọng số biểu diễn thông tin cục bộ liên quan đến ngữ cảnh toàn cục.

Bộ mã hóa văn bản (Text Encoder)

Bộ mã hóa văn bản kế thừa PubMedBERT của BiomedCLIP và nhận chuỗi token cùng attention mask của bệnh sử. Chuỗi đặc trưng đầu ra giữ lại thông tin ở mức token để phục vụ chú ý chéo, trong khi token đại diện được chiếu sang không gian chung để phục vụ căn chỉnh và tạo query toàn cục.

$$\mathbf{H}_i^T = \mathcal{P}_T(\mathcal{E}_T(\mathbf{u}_i, \mathbf{m}_i)) \in \mathbb{R}^{L \times D}. \quad (3.12)$$

Trong Công thức ??, $\mathcal{E}_T$ là bộ mã hóa văn bản, $\mathcal{P}_T$ là phép chiếu được áp dụng theo từng token, $\mathbf{u}_i$ là chuỗi chỉ số token, $\mathbf{m}_i$ là attention mask, L là chiều dài chuỗi và $\mathbf{H}_i^T$ là ma trận biểu diễn theo token sau phép chiếu về D chiều. Các vị trí đệm được loại khỏi phép chú ý bằng attention mask.

$$\mathbf{z}_i^T = \text{Norm}_2(\mathbf{H}_{i,0}^T) \in \mathbb{R}^D. \quad (3.13)$$

Trong Công thức ??, $\mathbf{H}_{i,0}^T$ là token đại diện ở vị trí đầu chuỗi sau phép chiếu, Norm_2 là phép chuẩn hóa L_2 và $\mathbf{z}_i^T$ là embedding văn bản toàn cục.

Nhóm nghiên cứu sử dụng LoRA [0] để thích nghi các phép chiếu được lựa chọn trong cả hai bộ mã hóa. Trọng số tiền huấn luyện không bị thay thế; phần cập nhật được biểu diễn bằng tích của hai ma trận hạng thấp.

$$\mathbf{W}' = \mathbf{W} + \frac{\alpha_L}{r} \mathbf{B} \mathbf{A}. \quad (3.14)$$

Trong Công thức ??, $\mathbf{W} \in \mathbb{R}^{d \times k}$ là ma trận trọng số tiền huấn luyện được giữ cố định, $\mathbf{W}'$ là trọng số hiệu dụng khi truyền thuận, $\mathbf{A} \in \mathbb{R}^{r \times k}$ và $\mathbf{B} \in \mathbb{R}^{d \times r}$ là hai ma trận được huấn luyện, r là hạng LoRA và α_L là hệ số tỷ lệ. Điều kiện $r \ll \min(d, k)$ làm cho số tham số cần cập nhật nhỏ hơn đáng kể so với tinh chỉnh toàn bộ ma trận $\mathbf{W}$.

Trong giai đoạn thứ nhất, độ tương đồng giữa embedding ảnh và embedding văn bản được tính bằng cosine. Do hai embedding đã được chuẩn hóa, tích vô hướng tương ứng với độ tương đồng cosine; công thức tổng quát vẫn được trình bày để làm rõ đại lượng được tối ưu.

$$s_{ij} = \frac{(\mathbf{z}_i^I)^T \mathbf{z}_j^T}{\|\mathbf{z}_i^I\|_2 \|\mathbf{z}_j^T\|_2}. \quad (3.15)$$

Trong Công thức ??, s_{ij} là mức tương đồng giữa ảnh thứ i và bệnh sử thứ j , $\mathbf{z}_i^I$ là embedding thị giác, $\mathbf{z}_j^T$ là embedding văn bản, ký hiệu T biểu thị chuyển vị và $\|\cdot\|_2$ là chuẩn Euclid.

Mục tiêu mềm phân bổ trọng số lớn cho cặp tương ứng và một phần trọng số cho các cặp khác thuộc cùng lớp. Phân phối mục tiêu theo hàng được xây dựng như sau.

$$q_{ij} = \frac{\rho \mathbb{K}[i = j] + (1 - \rho) \mathbb{K}[y_i = y_j]}{\sum_{n=1}^B (\rho \mathbb{K}[i = n] + (1 - \rho) \mathbb{K}[y_i = y_n])}. \quad (3.16)$$

Trong Công thức ??, q_{ij} là xác suất mục tiêu của cặp ảnh i và văn bản j , B là kích thước mini-batch, $\rho \in [0, 1]$ là hệ số ưu tiên cặp tương ứng, $\mathbb{K}[\cdot]$ là hàm chỉ thị và y_i, y_j là nhãn lớp. Mẫu số chuẩn hóa tổng trọng số

mục tiêu của mỗi ảnh bằng một; khi trong mini-batch có nhiều mẫu cùng lớp, các mẫu này nhận trọng số mềm thay vì bị xem hoàn toàn là cặp âm.

Xác suất dự đoán theo hướng ảnh sang văn bản được tính từ toàn bộ văn bản trong cùng mini-batch.

$$p_{ij}^{I \rightarrow T} = \frac{\exp(s_{ij}/\tau)}{\sum_{n=1}^B \exp(s_{in}/\tau)}. \quad (3.17)$$

Trong Công thức ??, $p_{ij}^{I \rightarrow T}$ là xác suất văn bản j tương ứng với ảnh i , s_{ij} là độ tương đồng ảnh-văn bản, $\tau > 0$ là nhiệt độ và B là kích thước mini-batch. Nhiệt độ nhỏ tạo phân phối sắc hơn, còn nhiệt độ lớn tạo phân phối phẳng hơn.

Xác suất theo hướng văn bản sang ảnh được tính đối xứng trên toàn bộ ảnh trong mini-batch.

$$p_{ji}^{T \rightarrow I} = \frac{\exp(s_{ij}/\tau)}{\sum_{n=1}^B \exp(s_{nj}/\tau)}. \quad (3.18)$$

Trong Công thức ??, $p_{ji}^{T \rightarrow I}$ là xác suất ảnh i tương ứng với văn bản j , mẫu số duyệt qua các ảnh có chỉ số n trong mini-batch, còn s_{ij} , τ và B có ý nghĩa như trong Công thức ??.

Hàm mất mát khớp ngữ nghĩa lấy trung bình hai hướng để tránh ưu tiên riêng nhánh ảnh hoặc nhánh văn bản.

$$\mathcal{L}_{\text{SM}} = -\frac{1}{2B} \sum_{i=1}^B \sum_{j=1}^B q_{ij} (\log p_{ij}^{I \rightarrow T} + \log p_{ji}^{T \rightarrow I}). \quad (3.19)$$

Trong Công thức ??, $\mathcal{L}_{\text{SM}}$ là hàm mất mát của giai đoạn thứ nhất, q_{ij} là mục tiêu mềm, $p_{ij}^{I \rightarrow T}$ và $p_{ji}^{T \rightarrow I}$ là hai phân phối dự đoán, còn B là kích thước mini-batch. Gradient của hàm mất mát này cập nhật adapter LoRA và thành phần tổng hợp token ảnh cục bộ nhưng không cập nhật mô-đun dung hợp hoặc bộ phân loại.

3.2.3 Bộ dung hợp (Cross-Attention)

Bộ dung hợp chỉ được tối ưu và sử dụng từ giai đoạn thứ hai. Đầu vào thị giác gồm token toàn cục cùng 20 token cục bộ đã bổ sung tọa độ,

trong khi đầu vào văn bản gồm embedding toàn cục và chuỗi token bệnh sử. Hai hướng chú ý có vai trò bổ sung: hướng ảnh sang văn bản dùng ngữ cảnh lâm sàng để làm giàu token ảnh toàn cục, còn hướng văn bản sang ảnh dùng bằng chứng thị giác toàn cục và cục bộ để làm giàu token văn bản toàn cục.

$$\mathbf{V}_i = \text{Concat} \left[\mathbf{g}_i^I, \tilde{\mathbf{L}}_i^I \right] \in \mathbb{R}^{(P+1) \times D}. \quad (3.20)$$

Trong Công thức ??, $\mathbf{V}_i$ là chuỗi token thị giác dùng cho dung hợp, $\mathbf{g}_i^I$ là token ảnh toàn cục, $\tilde{\mathbf{L}}_i^I$ là $P = 20$ token cục bộ đã bổ sung tọa độ và $D = 512$ là chiều đặc trưng. Vì vậy, chuỗi thị giác có tổng cộng $P + 1 = 21$ token.

Ở hướng ảnh sang văn bản, token ảnh toàn cục đóng vai trò query, còn chuỗi token văn bản đóng vai trò key và value. Attention mask của văn bản được áp dụng trước Softmax để token đệm không nhận trọng số.

$$\mathbf{A}_i^{I \leftarrow T} = \text{Softmax} \left(\frac{(\mathbf{g}_i^I \mathbf{W}_Q^I) (\mathbf{H}_i^T \mathbf{W}_K^T)^T}{\sqrt{d_h}} + \mathbf{M}_i^T \right). \quad (3.21)$$

Trong Công thức ??, $\mathbf{A}_i^{I \leftarrow T}$ là phân bố chú ý từ token ảnh đến các token văn bản, $\mathbf{W}_Q^I$ và $\mathbf{W}_K^T$ là ma trận chiếu query và key, d_h là chiều của mỗi attention head, $\mathbf{M}_i^T$ là mặt nạ cộng có giá trị không tại token hợp lệ và giá trị âm lớn tại token đệm, còn Softmax chuẩn hóa trọng số theo chiều token văn bản.

$$\mathbf{h}_i^I = \text{LN} \left(\mathbf{g}_i^I + \mathbf{A}_i^{I \leftarrow T} (\mathbf{H}_i^T \mathbf{W}_V^T) \right). \quad (3.22)$$

Trong Công thức ??, $\mathbf{h}_i^I$ là biểu diễn ảnh đã được bổ sung ngữ cảnh văn bản, $\mathbf{W}_V^T$ là ma trận chiếu value của nhánh văn bản, LN là Layer Normalization và phép cộng với $\mathbf{g}_i^I$ tạo kết nối residual giúp giữ thông tin ảnh ban đầu.

Ở hướng văn bản sang ảnh, embedding văn bản toàn cục đóng vai trò query, còn chuỗi 21 token thị giác đóng vai trò key và value. Hướng này cho phép một biểu diễn văn bản tổng quát lựa chọn thông tin từ bố cục toàn cục và các vùng ảnh cục bộ.

$$\mathbf{A}_i^{T \leftarrow I} = \text{Softmax} \left(\frac{(\mathbf{z}_i^T \mathbf{W}_Q^T) (\mathbf{V}_i \mathbf{W}_K^I)^T}{\sqrt{d_h}} \right). \quad (3.23)$$

Trong Công thức ??, $\mathbf{A}_i^{T \leftarrow I}$ là phân bố chú ý từ embedding văn bản đến chuỗi token thị giác, $\mathbf{W}_Q^T$ và $\mathbf{W}_K^I$ là các ma trận chiều query và key, $\mathbf{V}_i$ là chuỗi thị giác và d_h là chiều của mỗi attention head.

$$\mathbf{h}_i^T = \text{LN} (\mathbf{z}_i^T + \mathbf{A}_i^{T \leftarrow I} (\mathbf{V}_i \mathbf{W}_V^I)). \quad (3.24)$$

Trong Công thức ??, $\mathbf{h}_i^T$ là biểu diễn văn bản đã được bổ sung thông tin thị giác, $\mathbf{W}_V^I$ là ma trận chiều value của nhánh ảnh, LN là Layer Normalization và kết nối residual giữ lại nội dung của embedding văn bản toàn cục.

Hai biểu diễn tăng cường được ghép và đưa qua MLP để tạo embedding dung hợp dùng chung cho bộ phân loại. MLP giảm vector ghép từ $2D = 1024$ chiều về $D = 512$ chiều, sau đó tiếp tục chiếu trong không gian D chiều và chuẩn hóa đầu ra. Các embedding toàn cục thô không được ghép lại thêm một lần nữa sau bước này.

$$\mathbf{z}_i^F = \text{LN} (\mathbf{W}_2 \phi (\mathbf{W}_1 \text{Concat} [\mathbf{h}_i^I, \mathbf{h}_i^T] + \mathbf{b}_1) + \mathbf{b}_2) \in \mathbb{R}^D. \quad (3.25)$$

Trong Công thức ??, $\mathbf{z}_i^F$ là embedding dung hợp, $\mathbf{W}_1$ và $\mathbf{W}_2$ là hai ma trận trọng số của MLP, $\mathbf{b}_1$ và $\mathbf{b}_2$ là các vector độ lệch, ϕ là hàm kích hoạt phi tuyến, Concat là phép ghép theo chiều đặc trưng và $D = 512$ là chiều đầu ra.

3.2.4 Bộ phân loại dựa trên tâm lớp thực nghiệm (Classifier)

Bộ phân loại biểu diễn mỗi lớp bằng trung bình embedding dung hợp của các mẫu huấn luyện thuộc lớp đó. Tâm lớp không phải là tham số tự do và không được optimizer cập nhật; khi bộ mã hóa hoặc bộ dung hợp thay đổi, các tâm được ước lượng lại từ tập huấn luyện. Thiết kế này giữ

cho đại diện lớp gắn trực tiếp với hình học của không gian biểu diễn hiện tại.

$$\mathbf{c}_k = \frac{1}{N_k} \sum_{i:y_i=k} \mathbf{z}_i^F. \quad (3.26)$$

Trong Công thức ??, $\mathbf{c}_k \in \mathbb{R}^D$ là tâm thực nghiệm của lớp k , N_k là số mẫu huấn luyện thuộc lớp đó, $\mathbf{z}_i^F$ là embedding dung hợp của mẫu thứ i và điều kiện $y_i = k$ giới hạn phép tổng trên các mẫu có nhãn k . Mỗi lớp trong cấu hình phải có ít nhất một mẫu huấn luyện để tâm lớp được xác định.

Độ tương đồng giữa một mẫu và từng tâm lớp được tính bằng cosine, nhờ đó quyết định phụ thuộc chủ yếu vào hướng của embedding thay vì độ lớn tuyệt đối của vector.

$$r_{ik} = \frac{(\mathbf{z}_i^F)^\top \mathbf{c}_k}{\|\mathbf{z}_i^F\|_2 \|\mathbf{c}_k\|_2}. \quad (3.27)$$

Trong Công thức ??, r_{ik} là độ tương đồng cosine giữa mẫu i và lớp k , $\mathbf{z}_i^F$ là embedding dung hợp, $\mathbf{c}_k$ là tâm lớp, ký hiệu $\top$ biểu thị chuyển vị và $\|\cdot\|_2$ là chuẩn Euclid.

Điểm phân loại kết hợp độ tương đồng với một hệ số tỷ lệ cố định và một độ lệch riêng cho từng lớp. Độ lệch lớp được khởi tạo bằng không và được học trong giai đoạn thứ hai, qua đó cho phép điều chỉnh ranh giới quyết định mà không biến tâm thực nghiệm thành prototype tham số.

$$\ell_{ik} = \alpha_c r_{ik} + b_k. \quad (3.28)$$

Trong Công thức ??, ℓ_{ik} là logit của mẫu i đối với lớp k , r_{ik} là độ tương đồng với tâm lớp, $\alpha_c = 15$ là hệ số tỷ lệ cố định và b_k là class-specific bias có thể học của lớp k .

Logit của tất cả các lớp được chuẩn hóa bằng Softmax để tạo phân phối xác suất dự đoán.

$$p_{ik} = \frac{\exp(\ell_{ik})}{\sum_{j=1}^K \exp(\ell_{ij})}. \quad (3.29)$$

Trong Công thức ??, p_{ik} là xác suất dự đoán lớp k cho mẫu i , ℓ_{ik} là logit tương ứng, K là tổng số lớp và chỉ số j duyệt qua toàn bộ lớp trong bài toán.

Để hạn chế việc các lớp có nhiều mẫu chi phối hàm mục tiêu, trọng số lớp được xây dựng từ số mẫu hiệu dụng [0]. Đại lượng số mẫu hiệu dụng của lớp k được xác định như sau.

$$E_k = \frac{1 - \beta^{N_k}}{1 - \beta}. \quad (3.30)$$

Trong Công thức ??, E_k là số mẫu hiệu dụng của lớp k , N_k là số mẫu thực tế của lớp và $\beta \in [0, 1)$ là hệ số kiểm soát mức bão hòa. Khi số mẫu tăng, đóng góp bổ sung của các mẫu mới giảm dần thay vì tăng tuyến tính không giới hạn.

Nghịch đảo số mẫu hiệu dụng được chuẩn hóa để trọng số trung bình của các lớp bằng một, đồng thời có thể được chặn trên nhằm hạn chế gradient quá lớn ở lớp rất hiếm.

$$w_k = \frac{K E_k^{-1}}{\sum_{j=1}^K E_j^{-1}}. \quad (3.31)$$

Trong Công thức ??, w_k là trọng số của lớp k , E_k^{-1} là nghịch đảo số mẫu hiệu dụng và K là tổng số lớp. Việc chuẩn hóa không làm các lớp có tần suất bằng nhau, mà chỉ thay đổi mức đóng góp tương đối của chúng vào hàm mất mát.

Label smoothing được áp dụng để tránh mục tiêu one-hot tuyệt đối và giảm mức quá tự tin của đầu phân loại. Phân phối mục tiêu sau làm tròn được xác định như sau.

$$\tilde{y}_{ik} = (1 - \varepsilon) \mathbb{I}[y_i = k] + \frac{\varepsilon}{K}. \quad (3.32)$$

Trong Công thức ??, $\tilde{y}_{ik}$ là xác suất mục tiêu của lớp k đối với mẫu i , $\varepsilon = 0,05$ là hệ số label smoothing, $\mathbb{I}[y_i = k]$ là hàm chỉ thị của nhãn đúng và K là tổng số lớp.

Hàm mất mát của giai đoạn thứ hai là Cross-Entropy có trọng số lớp trên phân phối mục tiêu đã làm tròn. Pipeline không bổ sung Prototypical

Loss dạng pull-push vì các tâm lớp được xác định bằng thống kê của tập huấn luyện thay vì được học như tham số tự do.

$$\mathcal{L}_{P2} = -\frac{1}{B} \sum_{i=1}^B \sum_{k=1}^K w_k \tilde{y}_{ik} \log p_{ik}. \quad (3.33)$$

Trong Công thức ??, $\mathcal{L}_{P2}$ là hàm mất mát của giai đoạn thứ hai, B là kích thước mini-batch, w_k là trọng số của lớp k , $\tilde{y}_{ik}$ là mục tiêu đã làm trơn và p_{ik} là xác suất dự đoán. Gradient của hàm mất mát cập nhật các tham số có thể học của pipeline nhưng không cập nhật trực tiếp các tâm $\mathbf{c}_k$.

Trong quá trình trực tuyến, lớp dự đoán là lớp có logit lớn nhất. Quy tắc này tương đương lựa chọn tâm lớp có điểm cosine đã hiệu chỉnh lớn nhất.

$$\hat{y}_i = \arg \max_{k \in \{1, \dots, K\}} \ell_{ik}. \quad (3.34)$$

Trong Công thức ??, $\hat{y}_i$ là nhãn dự đoán của mẫu i , k là chỉ số lớp, K là tổng số lớp và ℓ_{ik} là logit đã kết hợp độ tương đồng tâm lớp với class-specific bias. Quy tắc dự đoán sử dụng các tâm và độ lệch lớp đã được cố định sau quá trình huấn luyện ngoại tuyến.

3.3 Tóm tắt chương

Chương này trình bày XBone-Net theo một luồng thống nhất từ đầu vào đến quyết định phân loại. Trong quá trình ngoại tuyến, giai đoạn thứ nhất thích nghi hai bộ mã hóa và nhánh ảnh cục bộ bằng mục tiêu khớp ngữ nghĩa, còn giai đoạn thứ hai tiếp tục thích nghi biểu diễn đồng thời học chú ý chéo, MLP dung hợp và độ lệch lớp dưới mục tiêu Cross-Entropy có trọng số. Trong quá trình trực tuyến, cùng pipeline tiền xử lý, mã hóa và dung hợp được sử dụng với toàn bộ tham số đã cố định; nhãn được xác định bằng khoảng cách tới các tâm lớp thực nghiệm. Cấu trúc này cho phép tách rõ vai trò của bảo toàn chi tiết ảnh, mã hóa bệnh sử, tương tác liên phương thức và ra quyết định dựa trên hình học của tập huấn luyện.

Chương 4

Thực nghiệm

Chương này trình bày các thực nghiệm được thực hiện để kiểm tra hiệu năng của mô hình đề xuất. Các nội dung được trình bày bao gồm các bộ dữ liệu được sử dụng, các độ đo được sử dụng, các thiết lập siêu tham số và môi trường thí nghiệm, các nội dung thí nghiệm và cuối cùng là trình bày kết quả và bàn luận về kết quả.

4.1 Chuẩn bị dữ liệu

Nghiên cứu sử dụng bộ dữ liệu BTXRD được công bố [0] và bộ dữ liệu CTCH được thu thập tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh do giảng viên cung cấp. Các phần dưới đây mô tả nguồn gốc, cách thức thu thập, các bước tiền xử lý và những số liệu thống kê liên quan đến từng bộ dữ liệu.

4.1.1 Bộ dữ liệu BTXRD


BTXRD [0] là bộ dữ liệu ảnh X-quang được xây dựng cho các bài toán phân loại, định vị và phân vùng u xương nguyên phát. Phiên bản lưu trữ được sử dụng trong nghiên cứu gồm 3.746 ảnh, siêu dữ liệu về tuổi, giới tính, vị trí giải phẫu và tư thế chụp, cùng các chỉ báo về sự hiện diện, tính lành tính hoặc ác tính và phân nhóm tổn thương. Đối với 1.867 ảnh có u, bộ dữ liệu còn cung cấp tệp chú thích chứa thông tin vùng tổn thương.

Theo mô tả của bộ dữ liệu công bố, dữ liệu được tổng hợp từ ba bệnh viện tại Trung Quốc, Radiopaedia và MedPix. Dữ liệu bệnh viện được thu thập trong giai đoạn từ tháng 7 năm 2013 đến tháng 7 năm 2023; chẩn đoán được xác nhận bằng mô bệnh học hoặc được hai bác sĩ X-quang thống nhất. Đối với hai nguồn trực tuyến, các ảnh liên quan đến u xương được hai chuyên gia tuyển chọn, đồng thời yêu cầu có thông tin tuổi và giới tính. Những vùng giải phẫu có ít mẫu hoặc nhiều nhiễu như đầu, cổ, ngực và bụng được loại bỏ, do đó phạm vi còn lại tập trung vào chi trên, chi dưới và xương chậu.

Quy trình chú thích được thực hiện bằng Labelme [0]: một bác sĩ chuyên khoa u xương có 10 năm kinh nghiệm xác định vùng tổn thương, sau đó kết quả được một chuyên gia có 20 năm kinh nghiệm kiểm tra.

Đặc điểm dữ liệu và bài toán phân loại

Trong 3.746 mẫu, có 1.879 ảnh bình thường, 1.525 ảnh thuộc nhóm u lành tính và 342 ảnh thuộc nhóm u ác tính. Tuổi dao động từ 1 đến 88, trung bình $35,29 \pm 20,90$ tuổi; dữ liệu gồm 2.098 mẫu nam và 1.648 mẫu nữ như được thể hiện trong Hình ??.



Hình 4.1: Phân bố độ tuổi và giới tính của các bệnh nhân được quan sát trong bộ dữ liệu BTXRD

Bài toán thực nghiệm được thiết lập dưới dạng phân loại đơn nhãn với 10 lớp. Nhãn bình thường được suy ra khi cờ chỉ báo u bằng 0, chín lớp còn lại được lấy từ các chỉ báo bệnh lý trong metadata.

Bảng ?? trình bày số lượng mẫu theo tập chia, trong khi Bảng ?? trình bày phân bố lớp sau khi chuẩn hóa và tạm dịch các tên bệnh.

Tập dữ liệu	Số lượng hình ảnh	Tỷ lệ (%)
Huấn luyện	2.621	70
Xác thực	375	10
Kiểm thử	750	20
Tổng cộng	3.746	100,00

Bảng 4.1: Phân bố hình ảnh theo các tập dữ liệu trong BTXRD

Nhân bệnh lý	Train	Validation	Test	Tổng	Tỷ lệ
Bình thường	1.322	191	366	1.879	50,16%
U xương sụn	538	70	145	753	20,10%
Sarcoma xương	200	32	65	297	7,93%
Đa u xương sụn	189	29	45	263	7,02%
Nang xương đơn thuần	149	17	40	206	5,50%
U lành tính khác	83	8	24	115	3,07%
U tế bào khổng lồ	54	8	31	93	2,48%
U sụn màng hoạt dịch	35	7	9	51	1,36%
U ác tính khác	27	5	13	45	1,20%
U xơ xương	24	8	12	44	1,17%
Tổng	2.621	375	750	3.746	100,00%

Bảng 4.2: Phân bố các lớp đơn nhân sau chuẩn hóa trong bộ dữ liệu BTXRD

Bộ dữ liệu được chia ngẫu nhiên ở mức ảnh được thực hiện với hạt giống 42 với tỷ lệ 70/10/20 cho huấn luyện, đánh giá, kiểm tra. Các tập được tạo với phân bố lớp được hình thành ngẫu nhiên.

Nguồn văn bản đa phương thức

bộ dữ liệu BTXRD không cung cấp báo cáo bệnh sử tương ứng với từng ảnh. Vì vậy, văn bản được sinh ngoại tuyến từ các siêu dữ liệu được cung cấp và mức liên quan khớp và các nhãn với bộ sinh giả ngẫu nhiên cố định với hạt giống 42. Mỗi báo cáo gồm thông tin người bệnh, lý do vào viện, quá trình bệnh lý, tiền sử và thông tin tư thế chụp. Thiết lập chính của BTXRD dùng nguồn này cho cả hai giai đoạn huấn luyện thông.

Tuy nhiên, nguồn văn bản này vẫn phụ thuộc vào cờ có u và cờ ác tính, vì vậy nguồn văn bản này chỉ giảm rò rỉ tên lớp trực tiếp chứ không độc lập hoàn toàn với nhãn đích. Kết quả đa phương thức trên BTXRD do đó không được xem là bằng chứng tương đương với việc sử dụng bệnh sử lâm sàng tự nhiên.

Các mô tả X-quang tổng hợp trực tiếp từ nhãn và có thể nêu tên chẩn đoán; nguồn này không được sử dụng trong thiết lập huấn luyện và phân loại chính. Cấu trúc tệp, thuật toán chuẩn hóa nhãn, quy trình sinh văn bản, thống kê định dạng ảnh, kiểm tra tính toàn vẹn, ví dụ trước và sau xử lý được trình bày chi tiết trong Phụ lục ??.

4.1.2 Bộ dữ liệu CTCH

CTCH là bộ dữ liệu X-quang xương được thu thập tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh và được giảng viên cung cấp cho nghiên cứu. Dữ liệu nguồn gồm ảnh được lựa chọn từ từng ca khám cùng các trường bệnh án tiếng Việt liên quan đến lý do vào viện, diễn tiến bệnh, tiền sử, tóm tắt khám và cận lâm sàng, kết quả khảo sát hình ảnh và chẩn đoán chuyên môn. Phạm vi thực nghiệm chỉ sử dụng ảnh X-quang đã được lựa chọn; những phương thức tạo ảnh khác và những ảnh không đại diện cho vị trí bệnh lý không được đưa vào tập phân loại.

Sàng lọc và xác định quần thể nghiên cứu

Quá trình kiểm tra bắt đầu từ 3.641 hồ sơ. Có 348 hồ sơ mang dụng cụ y tế như nẹp hoặc phương tiện kết hợp xương được loại bỏ nhằm hạn chế hiện tượng mô hình dựa vào dấu hiệu can thiệp thay vì đặc điểm tổn thương; không ghi nhận hồ sơ bị đánh dấu xóa hoặc thiếu ảnh đã lựa chọn trong phiên bản dữ liệu hiện tại. Sau sàng lọc còn 3.293 hồ sơ, gồm 3.249 mẫu thuộc không gian 22 lớp phân loại và 44 mẫu được tách riêng làm dữ liệu ngoài phân phối về ngữ nghĩa.

Mỗi hồ sơ được liên kết với một ảnh X-quang đại diện và một mã nhóm người bệnh. Trong quần thể phân loại hiện tại, 3.249 ảnh tương ứng với 3.249 mã người bệnh; quần thể ngoài phân phối gồm 44 ảnh từ 44 mã khác

và không giao với quần thể phân loại. Mã nhóm chỉ được sử dụng để kiểm soát rò rỉ giữa các tập và không được trình bày trong báo cáo.

Các mẫu ngoài phân phối không tham gia huấn luyện, xác thực hoặc kiểm thử bộ phân loại 22 lớp. Trong 44 mẫu này, 34 mẫu thuộc nhóm chấn thương và 10 mẫu thuộc nhóm viêm nhiễm nhưng biểu hiện bệnh lý nằm ngoài không gian nhãn đích; chúng chỉ được sử dụng trong kịch bản đánh giá Semantic OOD được trình bày ở phần thực nghiệm hậu xử lý.

Nhãn và phân chia dữ liệu

Sau khi chuẩn hóa Unicode, loại khoảng trắng thừa và đối chiếu tên lớp theo một thứ tự cố định, mỗi mẫu trong phân phối được ánh xạ vào đúng một trong 22 lớp. Kiểm tra toàn vẹn cho thấy toàn bộ 3.249 mẫu đều có đúng một nhãn hoạt động và không có nhãn nằm ngoài miền hợp lệ. Phân bố lớp thể hiện mức mất cân bằng đáng kể: lớp bình thường chiếm 1.086 mẫu, tương đương 33,43%, trong khi gãy xương vùng chậu chỉ có 24 mẫu, tương đương 0,74%.

Việc chia dữ liệu được thực hiện theo người bệnh với hạt giống ngẫu nhiên 42 và tỷ lệ mục tiêu 70/10/20. Người bệnh được nhóm theo lớp chính trước khi phân bổ để duy trì sự hiện diện của các lớp ít mẫu ở cả ba tập khi số lượng cho phép. Kết quả gồm 2.265 mẫu huấn luyện, 315 mẫu xác thực và 669 mẫu kiểm thử; kiểm tra sau phân chia không phát hiện người bệnh xuất hiện đồng thời ở hai tập.

Tập dữ liệu	Số lượng ảnh	Tỷ lệ (%)
Huấn luyện	2.265	69,71
Xác thực	315	9,70
Kiểm thử	669	20,59
Tổng cộng	3.249	100,00

Bảng 4.3: Phân bố mẫu trong phân phối của CTCH theo tập dữ liệu

Lớp	Huấn luyện	Xác thực	Kiểm thử	Tổng	Tỷ lệ (%)
Bình thường	760	108	218	1.086	33,43
Gãy xương quay	209	29	61	299	9,20
Gãy xương cánh tay	147	21	42	210	6,46
Gãy xương đùi	106	15	31	152	4,68
Gãy xương ngón tay	102	14	31	147	4,52
Gãy xương chày	99	14	29	142	4,37
Gãy xương cẳng tay	99	14	29	142	4,37
Gãy xương cổ chân	87	12	26	125	3,85
Gãy xương cẳng chân	85	12	25	122	3,76
Gãy xương vùng vai	70	10	21	101	3,11
Gãy xương bàn chân	68	9	21	98	3,02
Gãy cột sống thắt lưng	53	7	16	76	2,34
Gãy xương bàn tay	53	7	16	76	2,34
Gãy xương ngón chân	52	7	16	75	2,31
Viêm khớp	47	6	15	68	2,09
Gãy xương trụ	46	6	14	66	2,03
Cắt cụt ngón tay	42	6	13	61	1,88
Gãy xương bánh chè	41	5	13	59	1,82
Gãy xương gót	36	5	11	52	1,60
Gãy cột sống ngực	28	4	8	40	1,23
Gãy xương thuyền	19	2	7	28	0,86
Gãy xương vùng chậu	16	2	6	24	0,74
Tổng cộng	2.265	315	669	3.249	100,00

Bảng 4.4: Phân bố 22 lớp của CTCH trong ba tập dữ liệu

Xây dựng dữ liệu văn bản

Hai nguồn văn bản được xây dựng từ bệnh án gốc. Bệnh sử lâm sàng kết hợp lý do vào viện, diễn tiến bệnh và tiền sử bản thân; mô tả X-quang kết hợp phần tóm tắt khám, cận lâm sàng và kết quả khảo sát. Tên trường được thống nhất, nội dung được chuẩn hóa Unicode, loại khoảng trắng thừa và giữ nguyên thứ tự ngữ nghĩa trước khi dịch từ tiếng Việt sang tiếng Anh.

Chẩn đoán xác định và nhãn phân loại không được nối trực tiếp vào văn bản đầu vào. Tuy nhiên, phần tóm tắt khám hoặc kết quả khảo sát do bác sĩ viết vẫn có thể chứa tên tổn thương, vị trí gãy hoặc nhận định chẩn đoán; vì vậy, việc không sử dụng cột nhãn không đồng nghĩa với loại bỏ toàn bộ tín hiệu liên quan đến nhãn. Kết quả đa phương thức cần được diễn giải như khả năng kết hợp ảnh với thông tin bệnh án thực tế, trong đó văn bản có thể chứa bằng chứng lâm sàng hỗ trợ quyết định.

Bản dịch tiếng Anh được sử dụng để tương thích với bộ mã hóa văn bản tiền huấn luyện. Quy trình dịch theo từng trường và tái sử dụng những đoạn đã dịch trước đó nhằm bảo đảm tính nhất quán; nếu dịch không thành công trong quá trình chuẩn bị thông thường, nội dung tiếng Việt được giữ lại thay vì tạo một câu không có căn cứ. Sai khác thuật ngữ, viết tắt và cấu trúc câu giữa bản gốc với bản dịch vẫn là một nguồn nhiễu tiềm tàng.

Kiểm tra cuối cùng xác nhận toàn bộ 3.249 mẫu phân loại và 44 mẫu ngoài phân phối đều có ảnh cùng hai nguồn văn bản ở cả tiếng Việt và tiếng Anh, không có báo cáo lỗi trong quần thể được sử dụng. Kiểm tra nội dung ảnh bằng SHA-256 không phát hiện tệp trùng tuyệt đối và không ghi nhận giao nhau giữa quần thể trong phân phối với ngoài phân phối. Quy trình sàng lọc, chuẩn hóa, tạo văn bản và kiểm tra dữ liệu được trình bày chi tiết hơn trong Phụ lục ??.

4.2 Độ đo đánh giá

Hai bộ dữ liệu BTXRD [0] và CTCH được thiết lập dưới dạng bài toán phân loại đa lớp, với BTXRD có 10 lớp và 22 lớp đối với CTCH. Các độ đo được chia thành ba nhóm nhằm tách biệt hiệu năng phân loại, khả năng nhận diện dữ liệu ngoài phân phối và hiệu quả suy luận.

4.2.1 Độ đo phân loại

Accuracy

Accuracy, hay độ chính xác tổng thể, biểu thị tỷ lệ mẫu có nhãn dự đoán trùng với nhãn thật trên toàn bộ tập đánh giá.

$$\text{Accuracy} = \frac{\sum_{c=1}^C TP_c}{N}. \quad (4.1)$$

Trong đó:

- N là tổng số mẫu.
- C là tổng số lớp.
- TP_c là số mẫu thuộc lớp c được phân loại đúng.

Accuracy được sử dụng vì có cách diễn giải trực tiếp và được báo cáo phổ biến trong phân loại ảnh y khoa. Tuy nhiên, độ đo này có thể bị chi phối bởi các lớp có nhiều mẫu, do đó không được sử dụng riêng lẻ mà được đọc cùng Balanced Accuracy và Macro-F1. Giá trị cao hơn biểu thị tỷ lệ dự đoán đúng lớn hơn.

Balanced Accuracy

Balanced Accuracy [**Brodersen2010BalancedAcc**] tính trung bình độ nhạy của từng lớp, nhờ đó mỗi lớp đóng góp như nhau vào kết quả bất kể tần suất xuất hiện trong tập đánh giá.

$$\text{Balanced Accuracy} = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FN_c}. \quad (4.2)$$

Trong đó:

- C là tổng số lớp.
- TP_c là số mẫu thuộc lớp c được dự đoán đúng.
- FN_c là số mẫu thuộc lớp c nhưng bị dự đoán thành lớp khác.

Balanced Accuracy được sử dụng để giảm ảnh hưởng của mất cân bằng lớp trên hai bộ dữ liệu BTXRD và CTCH. Độ đo này cho biết liệu khả năng nhận diện có được duy trì trên các lớp ít mẫu thay vì chủ yếu phản ánh lớp phổ biến. Giá trị cao hơn biểu thị recall trung bình giữa các lớp tốt hơn.

Macro-F1

Macro-F1 tổng hợp đồng thời precision và recall của từng lớp, sau đó lấy trung bình không trọng số trên toàn bộ lớp.

$$\text{Macro-F1} = \frac{1}{C} \sum_{c=1}^C \frac{2TP_c}{2TP_c + FP_c + FN_c}. \quad (4.3)$$

Trong đó:

- C là tổng số lớp.
- TP_c là số mẫu thuộc lớp c được dự đoán đúng.
- FP_c là số mẫu lớp khác bị dự đoán nhầm thành lớp c .
- FN_c là số mẫu thuộc lớp c nhưng bị dự đoán thành lớp khác.

Macro-F1 được sử dụng làm độ đo chính vì một lớp chỉ đạt F1 cao khi precision và recall đều được duy trì. Phép trung bình hạn chế việc kết quả của lớp phổ biến che khuất sai số tại lớp hiếm. Giá trị cao hơn biểu thị sự cân bằng tốt hơn giữa hai loại sai số.

Macro-AUROC

Macro-AUROC [Fawcett2006ROC] đánh giá khả năng xếp hạng xác suất của từng lớp theo chiến lược một đối với tất cả trên toàn bộ ngưỡng, sau đó lấy trung bình không trọng số trên các lớp hợp lệ.

$$\text{TPR}_c = \frac{TP_c}{TP_c + FN_c}. \quad (4.4)$$

$$\text{FPR}_c = \frac{FP_c}{FP_c + TN_c}. \quad (4.5)$$

$$\text{AUROC}_c = \int_0^1 \text{TPR}_c(\text{FPR}_c) d\text{FPR}_c. \quad (4.6)$$

$$\text{Macro-AUROC} = \frac{1}{|\mathcal{C}_v|} \sum_{c \in \mathcal{C}_v} \text{AUROC}_c \quad (4.7)$$

Trong đó:

- $\mathcal{C}_v$ là tập lớp có cả mẫu dương và mẫu âm, $|\mathcal{C}_v|$ là số lớp hợp lệ.
- TP_c là số mẫu thuộc lớp c được dự đoán đúng.
- FP_c là số mẫu lớp khác bị dự đoán nhầm thành lớp c .
- TN_c là số mẫu lớp khác được xác nhận đúng không thuộc lớp c .
- FN_c là số mẫu thuộc lớp c nhưng bị dự đoán thành lớp khác.
- TPR_c là tỷ lệ mô hình phát hiện đúng các mẫu thuộc lớp c .
- FPR_c là tỷ lệ mô hình báo động nhầm các mẫu không thuộc lớp c .
- AUROC_c là diện tích dưới đường cong ROC riêng của lớp c .

Macro-AUROC được sử dụng vì không phụ thuộc vào một ngưỡng quyết định duy nhất và phản ánh chất lượng xếp hạng xác suất. Độ đo này bổ sung cho Macro-F1 nhưng ít nhạy hơn với mất cân bằng mẫu dương/âm, vì vậy cần được đọc cùng Macro-AUPRC. Giá trị cao hơn biểu thị khả năng xếp hạng tốt hơn.

Macro-AUPRC

Macro-AUPRC [Davis2006PR] đánh giá sự đánh đổi giữa độ chính xác và độ phủ cho từng lớp theo chiến lược một đối với toàn bộ trên toàn bộ dải ngưỡng, sau đó lấy trung bình không trọng số trên các lớp hợp lệ.

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c}. \quad (4.8)$$

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c}. \quad (4.9)$$

$$\text{AP}_c = \sum_{k=1}^{K_c} (R_{c,k} - R_{c,k-1}) P_{c,k}. \quad (4.10)$$

$$\text{Macro-AUPRC} = \frac{1}{|\mathcal{C}_v|} \sum_{c \in \mathcal{C}_v} \text{AP}_c. \quad (4.11)$$

Trong đó:

- $\mathcal{C}_v$ là tập lớp có cả mẫu dương và mẫu âm, $|\mathcal{C}_v|$ là số lớp hợp lệ.
- TP_c là số mẫu thuộc lớp c được dự đoán đúng.
- FP_c là số mẫu lớp khác bị dự đoán nhầm thành lớp c .
- FN_c là số mẫu thuộc lớp c nhưng bị dự đoán thành lớp khác.
- $\text{Recall}_c, \text{Precision}_c$: Độ phủ và độ chính xác của lớp c .
- $P_{c,k}, R_{c,k}$: Giá trị Precision và Recall tại điểm ngưỡng thứ k .
- K_c : Số lượng điểm ngưỡng phân loại trên tập dữ liệu đối với lớp c .
- AUPRC_c : Diện tích dưới đường cong Precision-Recall của lớp c .

Macro-AUPRC được sử dụng vì nhạy với chất lượng nhận diện lớp dương khi số mẫu dương ít hơn đáng kể số mẫu âm. Độ đo này giúp phát hiện trường hợp AUROC tương đối cao nhưng precision của lớp hiếm vẫn thấp. Giá trị cao hơn biểu thị sự đánh đổi precision–recall tốt hơn.

Expected Calibration Error

Expected Calibration Error (ECE) [Guo2017Calibration] đánh giá mức phù hợp giữa độ tin cậy dự đoán và tần suất dự đoán đúng quan sát được. Các mẫu được chia vào M khoảng theo xác suất lớn nhất của mô hình trước khi so sánh độ tin cậy trung bình với độ chính xác thực nghiệm trong từng khoảng.

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{N} |\text{Acc}(B_m) - \text{Conf}(B_m)|. \quad (4.12)$$

Trong đó:

- M là số khoảng độ tin cậy, báo cáo sử dụng $M = 15$.
- $|B_m|$ là số mẫu trong khoảng.
- N là tổng số mẫu.
- $\text{Acc}(B_m)$ là tỷ lệ dự đoán đúng.
- $\text{Conf}(B_m)$ là trung bình xác suất lớn nhất trong khoảng.

ECE được sử dụng vì một mô hình có Accuracy cao vẫn có thể đưa ra xác suất quá tự tin hoặc thiếu tự tin. Trong bài toán hỗ trợ phân tích ảnh y khoa, mức tin cậy cần được diễn giải thận trọng, đặc biệt khi được dùng để sắp xếp ca hoặc hỗ trợ cơ chế từ chối. Giá trị ECE thấp hơn biểu thị độ hiệu chuẩn tốt hơn, nhưng độ đo vẫn phụ thuộc vào cách chia khoảng.

4.2.2 Độ đo phát hiện dữ liệu ngoài phân phối

Để đánh giá khả năng phát hiện dữ liệu ngoài phân phối (Out-of-Distribution - OOD), gọi $\mathcal{D}_{\text{ID}}$ là tập dữ liệu trong phân phối (có N_{ID} mẫu) và $\mathcal{D}_{\text{OOD}}$ là tập dữ liệu ngoài phân phối (có N_{OOD} mẫu). Mọi bộ phát hiện đều được quy đổi nhất quán về hàm tính điểm bất thường $s(x)$: mẫu x có giá trị $s(x)$ càng lớn thì khả năng là mẫu OOD càng cao.

AUROC-OOD

AUROC-OOD [0] (Area Under the Receiver Operating Characteristic Curve) đo lường khả năng phân tách tổng quát giữa mẫu ID và mẫu OOD trên toàn bộ các ngưỡng phát hiện. Về mặt ý nghĩa xác suất, AUROC-OOD chính là xác suất để điểm bất thường của một mẫu OOD ngẫu nhiên lớn hơn điểm bất thường của một mẫu ID ngẫu nhiên:

$$\text{AUROC}_{\text{OOD}} = \Pr(s(x_{\text{OOD}}) > s(x_{\text{ID}})) + \frac{1}{2} \Pr(s(x_{\text{OOD}}) = s(x_{\text{ID}})). \quad (4.13)$$

Trong đó:

- $x_{\text{ID}}, x_{\text{OOD}}$ lần lượt là các mẫu ngẫu nhiên được rút từ tập $\mathcal{D}_{\text{ID}}$ và $\mathcal{D}_{\text{OOD}}$.
- $s(x)$ là điểm bất thường của mẫu x .
- $\Pr(\cdot)$ là hàm xác suất biểu thị thứ tự xếp hạng điểm giữa hai mẫu.

AUROC-OOD nhận giá trị từ 0 đến 1 (hoặc 0% đến 100%), giá trị càng cao biểu thị khả năng phân biệt ID và OOD càng tốt (mức ngẫu nhiên là 0.5).

AUPR-Out

AUPR-Out [0, 0] đo lường diện tích bên dưới đường cong Precision-Recall khi coi các mẫu OOD là lớp tích cực cần phát hiện.

$$\text{Recall}_{\text{OOD}} = \frac{\text{Số mẫu OOD phát hiện đúng}}{\text{Tổng số mẫu OOD}}. \quad (4.14)$$

$$\text{Precision}_{\text{OOD}} = \frac{\text{Số mẫu OOD phát hiện đúng}}{\text{Tổng số mẫu bị cảnh báo OOD}}. \quad (4.15)$$

Chỉ số AUPR-Out được tính bằng tổng tích phân của Precision theo Recall:

$$\text{AUPR-Out} = \int_0^1 \text{Precision}_{\text{OOD}} \, d \text{Recall}_{\text{OOD}}. \quad (4.16)$$

Trong đó:

- $N_{\text{ID}}, N_{\text{OOD}}$ là tổng số mẫu trong tập ID và OOD.
- τ là ngưỡng điểm bất thường để đưa ra quyết định phân loại OOD.
- $\text{Precision}_{\text{OOD}}, \text{Recall}_{\text{OOD}}$ là độ chính xác và độ nhạy phát hiện OOD tại ngưỡng τ .

AUPR-Out rất quan trọng trong kịch bản dữ liệu mất cân bằng (khi số mẫu OOD ít hơn nhiều so với ID). Giá trị AUPR-Out càng cao biểu thị mô hình ít bị cảnh báo nhầm (báo động giả) trên tập ID.

FPR@95%TPR

FPR@95%TPR [0, 0] (False Positive Rate at 95% True Positive Rate) được tính theo quy ước xem mẫu ID được chấp nhận là lớp dương tại điểm vận hành này. Ngưỡng được chọn để giữ lại ít nhất 95% mẫu ID; FPR khi đó là tỷ lệ mẫu OOD bị chấp nhận nhầm như ID.

$$\text{FPR@95\%TPR} = \frac{|\{x \in \mathcal{D}_{\text{OOD}} \mid s(x) \leq \tau_{95}\}|}{N_{\text{OOD}}}. \quad (4.17)$$

Trong đó:

- τ_{95} là ngưỡng điểm bất thường được chọn sao cho tỷ lệ mẫu ID được chấp nhận đạt ít nhất 95%, tức $\Pr_{x \sim \mathcal{D}_{\text{ID}}}[s(x) \leq \tau_{95}] \geq 0.95$.
- N_{OOD} là tổng số mẫu trong tập ngoài phân phối $\mathcal{D}_{\text{OOD}}$.
- $s(x) \leq \tau_{95}$ là điều kiện một mẫu OOD có điểm bất thường không vượt ngưỡng và bị chấp nhận nhầm như ID.

FPR@95%TPR phản ánh mức đánh đổi tại điểm vận hành ưu tiên giữ lại phần lớn dữ liệu ID: sau khi hệ thống duy trì tỷ lệ chấp nhận ID ít nhất 95%, độ đo cho biết bao nhiêu phần trăm mẫu OOD vẫn lọt qua cơ chế từ chối. Giá trị FPR@95%TPR càng nhỏ càng tốt.

4.2.3 Độ đo hiệu quả suy luận

Đánh giá mô hình học sâu trong điều kiện triển khai cần xem xét đồng thời chất lượng dự đoán và chi phí tính toán. Canziani và cộng sự [Canziani2017PracticalDNN] phân tích các mô hình thị giác theo số tham số, số phép toán, bộ nhớ và thời gian suy luận, trong khi MLPerf Inference [Reddi2020MLPerfInference] nhấn mạnh việc cố định giao thức phần cứng và phần mềm để kết quả hiệu năng có khả năng đối sánh. Trên cơ sở đó, nghiên cứu báo cáo năm nhóm đại lượng gồm số tham số, GFLOPs trên mỗi mẫu, thông lượng, độ trễ suy luận và bộ nhớ GPU cực đại.

Số tham số

Số tham số biểu thị quy mô của mô hình. Nghiên cứu báo cáo đồng thời tổng số tham số và số tham số có thể huấn luyện. Tổng số tham số bao gồm mọi tham số thuộc backbone, bộ dung hợp và bộ phân loại, trong khi số tham số có thể huấn luyện chỉ bao gồm các tham số được thuật toán tối ưu cập nhật.

$$\text{Tổng tham số} = \text{Số lượng toàn bộ tham số của mô hình.} \quad (4.18)$$

$$\text{Tham số huấn luyện} = \text{Số tham số được cập nhật.} \quad (4.19)$$

Tổng tham số hỗ trợ đối sánh quy mô mô hình, còn tham số huấn luyện cho biết số lượng tham số thực sự tham gia huấn luyện. Tỷ lệ tham số huấn luyện nhỏ hơn cho thấy phương pháp tinh chỉnh cần cập nhật ít tham số hơn. Tuy nhiên, số tham số không thay thế cho phép đo tốc độ suy luận vì mô hình có ít tham số hơn chưa chắc thực thi nhanh hơn trên cùng phần cứng.

GFLOPs trên mỗi mẫu

GFLOPs trên mỗi mẫu biểu thị khối lượng phép toán dấu phẩy động mà mô hình thực hiện để xử lý một đầu vào. Theo quy ước của phép đo, một phép nhân và phép cộng được tính là hai FLOPs và một GFLOP tương ứng với 10^9 FLOPs.

$$\text{GFLOPs} = \frac{\text{FLOPs của một lượt lan truyền tiến}}{10^9}. \quad (4.20)$$

Trong đó:

- FLOPs: là tổng số phép toán được ghi nhận cho một lần lan truyền tiến.
- Hằng số 10^9 : là hệ số đổi từ FLOPs sang GFLOPs.

Giá trị thấp hơn cho biết mô hình cần ít phép toán hơn cho một mẫu. GFLOPs chỉ phản ánh khối lượng tính toán lý thuyết và không phải thời gian thực thi. Vì vậy, đại lượng này được đọc cùng thông lượng và độ trễ.

Thông lượng

Thông lượng biểu thị số mẫu mà mô hình có thể xử lý trong một giây. Đại lượng này được tính trực tiếp từ số mẫu đã xử lý và tổng thời gian lan truyền tiến tương ứng.

$$\text{Thông lượng} = \frac{\text{Số mẫu được xử lý}}{\text{Thời gian suy luận (giây)}}. \quad (4.21)$$

Kết quả được báo cáo bằng thông lượng trung bình qua các lượt đo sau giai đoạn khởi động và có đơn vị là mẫu/giây. Giá trị cao hơn cho biết mô hình xử lý được nhiều mẫu hơn trong cùng một khoảng thời gian. Việc so sánh chỉ có ý nghĩa khi các mô hình sử dụng cùng GPU, kích thước lô và độ chính xác số học.

Độ trễ suy luận

Độ trễ suy luận phản ánh thời gian mô hình cần để xử lý một mẫu sau khi đầu vào đã nằm trên GPU. Khi phép đo sử dụng một lô gồm nhiều mẫu, thời gian của cả lô được chia cho số mẫu trong lô.

$$\text{Độ trễ mỗi mẫu} = \frac{\text{Thời gian truyền thuận của cả lô (ms)}}{\text{Số mẫu trong lô}}. \quad (4.22)$$

Độ trễ được báo cáo bằng ba giá trị. Giá trị trung bình là thời gian trung bình của toàn bộ lượt đo. P50 là mức mà một nửa số lượt đo có độ trễ thấp hơn hoặc bằng. P95 là mức mà 95% số lượt đo có độ trễ thấp hơn hoặc bằng. Giá trị trung bình và P50 mô tả thời gian xử lý điển hình, trong khi P95 phản ánh những lượt xử lý chậm ở phần đuôi của phân phối [Reddi2020MLPerfInference]. Các giá trị càng thấp cho thấy mô hình suy luận càng nhanh và ổn định hơn.

Bộ nhớ GPU cực đại

Bộ nhớ GPU cực đại là lượng bộ nhớ CUDA được cấp phát lớn nhất tại một thời điểm bất kỳ trong lượt truyền thuận. Giá trị tính theo byte được chuyển sang MiB để thuận tiện cho việc báo cáo.

$$\text{Bộ nhớ GPU cực đại (MiB)} = \frac{\text{Bộ nhớ cấp phát cực đại (byte)}}{2^{20}}. \quad (4.23)$$

Trong đó, 2^{20} là số byte tương ứng với một MiB. Độ đo bao gồm bộ nhớ dành cho mô hình, đầu vào và các tensor trung gian trong quá trình suy luận. Giá trị thấp hơn cho thấy mô hình cần ít tài nguyên GPU hơn. Giá trị được báo cáo là bộ nhớ thực sự được cấp phát, không phải toàn bộ vùng nhớ mà bộ quản lý CUDA giữ lại để tái sử dụng.

4.3 Thiết lập thực nghiệm

Phần này trình bày các thiết lập thực nghiệm, bao gồm môi trường phần cứng và phần mềm, cũng như các siêu tham số được sử dụng trong quá trình huấn luyện mô hình. Các thiết lập này nhằm đảm bảo tính nhất quán và khả năng tái tạo của các thí nghiệm.

4.3.1 Môi trường thực nghiệm

Mô hình đề xuất và các mô hình nền tảng được chạy ba lần với hạt giống lần lượt là 42, 123, 456 trong các điều kiện và siêu tham số giống nhau. Môi trường phần cứng và phần mềm được trình bày trong Bảng ?? và Bảng ??.

Thành phần	Cấu hình
GPU	1 × RTX 5060 Ti 16 GB VRAM
CPU	Intel Core Ultra 7 265KF
Bộ nhớ hệ thống	32 GB RAM
Độ chính xác số học	BF16 trong cả hai pha huấn luyện

Bảng 4.5: Môi trường phần cứng được sử dụng trong quá trình huấn luyện

Thành phần	Phiên bản
Python	3.11.15
Torch	2.11.0+cu128
CUDA runtime	12.8

Bảng 4.6: Phiên bản của các thư viện chính trong môi trường thí nghiệm

4.3.2 Tham số thực nghiệm

Các Bảng ?? và ?? dưới đây mô tả cấu hình siêu tham số của mô hình đề xuất. Các siêu tham số được lựa chọn dựa trên các nghiên cứu trước và thử nghiệm sơ bộ để tối ưu hóa hiệu suất mô hình trên cả hai bộ dữ liệu BTXRD và CTCH.

Siêu tham số	Pha 1
Độ phân giải ảnh đầu vào	1 ảnh global 224×224 và 4 tile cùng kích thước
Bộ tối ưu hóa	AdamW
Tốc độ học	5×10^{-5}
Suy giảm trọng số	1×10^{-4}
Bộ điều chỉnh tốc độ học	Cosine
Tỷ lệ khởi động	0.1
Kích thước lô	16
Số epoch tối đa	30
Số epoch dừng sớm	3 epochs
Nhiệt độ tương phản (τ)	0.07
Trạng thái tham số Backbone	Tinh chỉnh qua LoRA
Hạng LoRA (r)	16
Hệ số LoRA (α)	32
Tỷ lệ bỏ học LoRA	0.1

Bảng 4.7: Bảng tổng hợp siêu tham số ở pha 1 và thiết lập của chúng

Siêu tham số	Pha 2
Độ phân giải ảnh đầu vào	Giống pha 1
Bộ tối ưu hóa	AdamW
Tốc độ học	1×10^{-4}
Suy giảm trọng số	1×10^{-4}
Bộ điều chỉnh tốc độ học	Cosine
Tỷ lệ khởi động	0.1
Kích thước lô	16
Số epoch tối đa	50
Số epoch dừng sớm	5 epochs
Nhiệt độ tương phản (τ)	Không áp dụng
Trạng thái tham số Backbone	Tinh chỉnh qua LoRA
Hạng LoRA (r)	16
Hệ số LoRA (α)	32
Tỷ lệ bỏ học LoRA	0.1

Bảng 4.8: Bảng tổng hợp siêu tham số ở pha 2 và thiết lập của chúng

4.4 Nội dung thực nghiệm

Phần này trình bày các nhóm thí nghiệm được thực hiện trên hai bộ dữ liệu BTXRD và CTCH, bao gồm nội dung, mục đích và các mô hình sử dụng.

4.4.1 Đánh giá mô hình nền tảng

Thiết kế mô hình: Nhóm thí nghiệm này sử dụng bốn mô hình ngôn ngữ trực quan gồm CLIP, MedCLIP, PubMedCLIP và BiomedCLIP ở chế độ zero-shot. Toàn bộ tham số của backbone được giữ cố định. Với mỗi lớp c , tên lớp tiếng Anh được đưa vào một cặp câu nhắc cố định gồm câu nhắc khẳng định và câu nhắc phủ định:

```
this is an image of a bone x-ray; [class] presented in image,  
this is an image of a bone x-ray; no [class] presented in image.
```

Chẳng hạn, đối với lớp osteosarcoma, hai câu nhắc lần lượt là

```
this is an image of a bone x-ray; osteosarcoma presented in image,  
this is an image of a bone x-ray; no osteosarcoma presented in image.
```

Hai câu nhắc được mã hóa thành biểu diễn văn bản và so sánh với biểu diễn ảnh. Độ tương đồng của cặp khẳng định phủ định được chuyển thành xác suất bằng softmax với nhiệt độ τ , xác suất của câu nhắc khẳng định được dùng làm điểm cho lớp c . Nhân dự đoán là lớp có điểm khẳng định lớn nhất trong toàn bộ tập lớp.

Mục đích thực nghiệm: Thí nghiệm khảo sát khả năng chuyển trực tiếp tri thức đã tiền huấn luyện sang bài toán phân loại X-quang xương. Thiết lập này cung cấp một mốc tham chiếu không sử dụng mẫu huấn luyện của bộ dữ liệu đích, qua đó cho phép xem xét mức độ phù hợp ban đầu của các mô hình ngôn ngữ trực quan

Dữ liệu và độ đo: Bốn mô hình được đánh giá độc lập trên tập kiểm thử của BTXRD và CTCH, các tập huấn luyện và validation không được sử dụng để cập nhật mô hình. Các độ đo báo cáo gồm Accuracy, Balanced Accuracy, Macro-F1, Macro-AUROC, và Macro-AUPRC theo định nghĩa tại Mục ??.

4.4.2 So sánh với các mô hình nền tảng

Thiết kế mô hình: Nhóm đối sánh có ba thiết lập bổ sung cho nhau:

1. **Mẫu hạn chế:** LoRA-BiomedCLIP và LoRA-PubMedCLIP được huấn luyện với 1, 10 hoặc 20 mẫu cho mỗi lớp ở tập huấn luyện, tập đánh giá và kiểm thử được giữ nguyên. Các mô hình áp dụng kỹ thuật LoRA sử dụng quy trình hai pha, phép nối đặc trưng và đầu phân loại tuyến tính.
2. **Toàn bộ dữ liệu:** ResNet-50 và DenseNet-121 được tinh chỉnh toàn bộ với đầu tuyến tính và chỉ nhận ảnh. Các mô hình ngôn ngữ trực quan y khoa gồm CLIP, MedCLIP, PubMedCLIP và BiomedCLIP được tinh chỉnh toàn bộ, sử dụng ảnh cùng báo cáo lâm sàng, phép nối đặc trưng và đầu tuyến tính.
3. **Tinh chỉnh hiệu quả tham số:** Hai mô hình BiomedCLIP và PubMedCLIP được áp dụng kỹ thuật LoRA. Hai mô hình này giữ phép nối đặc trưng và đầu tuyến tính.

Mục đích thực nghiệm: Thiết lập mẫu hạn chế đánh giá khả năng học khi số mẫu gán nhãn bị giới hạn và mức suy giảm so với khi huấn luyện trên toàn bộ dữ liệu khi áp dụng kỹ thuật LoRA. Thiết lập toàn bộ dữ liệu cung cấp đối sánh tổng thể giữa mô hình ảnh đơn phương thức, các mô hình ngôn ngữ trực quan y khoa được tinh chỉnh và pipeline đề xuất. So sánh tinh chỉnh hiệu quả tham số được dùng để xem xét liệu các mô hình ngôn ngữ trực quan y khoa có thể đạt được hiệu suất tương tự như mô hình tinh chỉnh toàn bộ khi chỉ được huấn luyện với một số lượng nhỏ tham số.

Dữ liệu và độ đo: Tất cả ba thiết lập được thực hiện trên BTXRD và CTCH với các tập huấn luyện, validation và kiểm thử cố định. Kết quả được tổng hợp trên ba hạt giống 42, 123 và 456 bằng Accuracy, Balanced Accuracy, Macro-F1, Macro-AUROC, Macro-AUPRC và ECE. Nhằm mô tả đánh đổi giữa hiệu năng dự đoán và chi phí suy luận, tổng số và số tham số có thể huấn luyện, GFLOPs, thông lượng, độ trễ suy luận và bộ nhớ GPU cực đại cũng được báo cáo.

4.4.3 OOD hậu xử lý

Thiết kế phương pháp. Phân tích OOD không huấn luyện lại mô hình phân loại mà sử dụng trọng số của CTCH ở ba hạt giống. Bốn score hậu xử lý gồm khoảng cách cosine tới tâm lớp gần nhất, khoảng cách Mahalanobis tới tâm lớp với hiệp phương sai, khoảng cách cosine kNN với $k = 5$ và entropy dự đoán. Ba score hình học chỉ sử dụng fused embedding đã được huấn luyện, trong đó token ảnh toàn cục, các token ảnh cục bộ độ phân giải cao và token bệnh sử được kết hợp bằng cross-attention hai chiều trước khi chiếu qua fusion MLP; entropy được tính từ phân phối xác suất của cùng checkpoint. Thống kê detector được ước lượng từ CTCH train. Ngưỡng vận hành được hiệu chỉnh chỉ trên CTCH validation-ID, sau đó được khóa trước khi đánh giá.

Mục đích thực nghiệm. Nhóm thí nghiệm đánh giá liệu các score hậu xử lý có thể tách mẫu ngoài phân phối khỏi mẫu thuộc phân phối huấn luyện mà không thay đổi bộ phân loại hay không. Hai dạng sai lệch được xem xét gồm khác biệt ngữ nghĩa bệnh trong cùng nguồn CTCH và dịch chuyển khác bộ dữ liệu trên FracAtlas hoặc BTXRD. Việc tách ba kịch bản giúp phân biệt bất thường ngữ nghĩa với sự thay đổi đồng thời về miền thu nhận, không gian nhãn và lược đồ bệnh sử.

Dữ liệu và độ đo. Tập ID gồm CTCH train để khớp bộ phát hiện, CTCH validation để hiệu chỉnh ngưỡng và CTCH test để đánh giá. Semantic OOD sử dụng 44 mẫu trong manifest `ctch-ood.csv`; domain OOD sử dụng riêng 613 mẫu thuộc tập kiểm thử FracAtlas và 750 mẫu thuộc tập kiểm thử BTXRD. Cả bốn score được áp dụng nhất quán trên ba kịch bản, trong đó ba score hình học chỉ sử dụng biểu diễn fused ảnh-bệnh sử. BTXRD được xem như một nguồn OOD khác bộ dữ liệu, kết hợp dịch chuyển miền thu nhận với thay đổi không gian nhãn theo các bệnh lý u xương; riêng lớp bình thường có ngữ nghĩa giao một phần với CTCH. Vì bệnh sử `clinical_v2` của BTXRD là văn bản tổng hợp, kết quả trên nguồn này được diễn giải như khả năng phát hiện OOD đa phương thức, không được dùng làm bằng chứng riêng cho dịch chuyển miền ảnh. Ba độ đo chính là AUROC-OD, AUPR-Out và FPR@95%TPR; khoảng tin cậy bootstrap 95% được tính với $B = 2.000$ lần lấy mẫu lại. AUROC-OD

và AUPR-Out cao hơn biểu thị khả năng phân tách hoặc chất lượng cảnh báo tốt hơn, trong khi $FPR@95\%TPR$ thấp hơn biểu thị ít mẫu OOD bị chấp nhận nhầm hơn tại mức giữ lại 95% ID.

4.4.4 Đánh giá thành phần

Thiết kế biến thể. Các biến thể kế thừa cấu hình của mô hình đề xuất ngoài thành phần đang khảo sát; dữ liệu, hạt giống và quy trình chọn checkpoint được giữ cố định. Bốn nhóm biến thể gồm:

1. **Đầu vào và phương thức:** cấu hình đầy đủ được so sánh với biến thể chỉ dùng ảnh, chỉ dùng bệnh sử và xáo trộn bệnh sử giữa các mẫu. Nhóm tiền xử lý khảo sát thêm việc loại nhánh ảnh độ phân giải cao, letterbox, mean pooling và giảm số token ảnh cục bộ.
2. **Tinh chỉnh và chiến lược huấn luyện:** mô hình đề xuất cập nhật adapter LoRA trong quy trình hai pha. Các đối chứng gồm đóng băng backbone, tinh chỉnh toàn bộ backbone, huấn luyện gộp hai pha, chỉ huấn luyện pha 2 và chỉ bổ sung bệnh sử từ pha 2.
3. **Dung hợp:** cross-attention hai chiều của mô hình đề xuất được so sánh với phép nối đặc trưng và hai biến thể attention **một chiều ảnh sang văn bản, văn bản sang ảnh**.
4. **Đầu phân loại và cân bằng lớp:** đầu tính tâm cụm với trọng số lớp và bias theo lớp được so sánh với đầu tuyến tính, biến thể không dùng trọng số lớp và biến thể không dùng bias theo lớp.

Mục đích thực nghiệm. Nhóm thí nghiệm lần lượt xem xét vai trò của việc bảo toàn chi tiết ảnh độ phân giải cao, chiến lược cập nhật mô hình kế thừa, hướng trao đổi thông tin giữa hai phương thức và lựa chọn đầu phân loại trong điều kiện mất cân bằng lớp. Thiết kế kế thừa cùng cấu hình giúp giới hạn thay đổi trong từng phép so sánh, từ đó hỗ trợ diễn giải chênh lệch theo thành phần.

Dữ liệu và độ đo. Toàn bộ đánh giá thành phần được thực hiện trên CTCH với ba hạt giống 42, 123 và 456. Hiệu năng phân loại được

đánh giá bằng Accuracy, Balanced Accuracy, Macro-F1, Macro-AUROC, Macro-AUPRC và ECE, kèm Confusion Matrix cho các biến thể cần phân tích sai số theo lớp và khoảng tin cậy bootstrap 95% với $B = 10.000$. Với nhóm tinh chỉnh và tiền xử lý ảnh, tổng số và số tham số có thể huấn luyện, GFLOPs trên mỗi mẫu, thông lượng, độ trễ suy luận và bộ nhớ GPU cực đại được ghi nhận bổ sung để mô tả đánh đổi về tài nguyên. Chỉ các cấu hình có đủ ba hạt giống và vượt qua kiểm tra tính hợp lệ của checkpoint, kích thước representation và giao thức đánh giá mới được đưa vào bảng kết quả chính.

4.5 Kết quả thực nghiệm và thảo luận

Phần này trình bày kết quả thực nghiệm; đối với các thiết lập có huấn luyện, giá trị trong bảng là trung bình $\pm$ độ lệch chuẩn mẫu trên ba hạt giống ngẫu nhiên 42, 123 và 456. Kết quả phân loại không mẫu được báo cáo bằng ước lượng điểm do quá trình suy luận có tính xác định. Giá trị tốt nhất theo từng cột và trong cùng một thiết lập được in đậm, khoảng tin cậy bootstrap 95% được lưu cho từng lần chạy.

4.5.1 Đánh giá mô hình nền tảng

Thí nghiệm zero-shot được sử dụng như một mốc về hiệu năng thuần túy của các mô hình ngôn ngữ-thị giác trước khi có bất kỳ cập nhật tham số nào trên dữ liệu đích. Thiết lập này không nhằm thay thế giai đoạn thích ứng, mà hỗ trợ lựa chọn backbone có biểu diễn ban đầu phù hợp hơn để kế thừa trong pipeline đề xuất; vì dữ liệu mất cân bằng, Macro-F1, Balanced Accuracy, Macro-AUROC và Macro-AUPRC được xem xét đồng thời với Accuracy.

Dữ liệu	Mô hình	Acc $\uparrow$	Balanced Acc $\uparrow$	Macro-F1 $\uparrow$	Macro AUROC $\uparrow$	Macro AUPRC $\uparrow$
BTXRD	CLIP	0.0640	0.1297	0.0631	0.4997	0.1214
	MedCLIP	0.0387	0.0935	0.0075	0.4628	0.1041
	PubMedCLIP	0.0893	0.1334	0.0690	0.5531	0.1277
	BiomedCLIP	0.3427	0.1493	0.1289	0.5786	0.1416
CTCH	CLIP	0.1540	0.2367	0.1307	0.8003	0.1906
	MedCLIP	0.0179	0.0224	0.0043	0.4707	0.0480
	PubMedCLIP	0.1016	0.1294	0.0698	0.7920	0.1966
	BiomedCLIP	0.2556	0.2109	0.1659	0.8191	0.2334

Bảng 4.9: Kết quả zero-shot trên BTXRD và CTCH, chữ đậm biểu thị giá trị tốt nhất theo từng bộ dữ liệu

Trên BTXRD, BiomedCLIP có giá trị cao hơn ba mô hình còn lại ở cả năm độ đo, với Accuracy 0.3427, Balanced Accuracy 0.1493, Macro-F1 0.1289, Macro-AUROC 0.5786 và Macro-AUPRC 0.1416; khoảng tin cậy bootstrap 95% của bốn độ đo đầu lần lượt là [0.3093; 0.3760], [0.1116; 0.1927], [0.0945; 0.1661] và [0.5443; 0.6118]. Khoảng cách Accuracy tương đối lớn so với PubMedCLIP (0.0893), nhưng Balanced Accuracy và Macro-F1 vẫn thấp, gợi ý rằng dự đoán zero-shot còn nghiêng về các lớp phổ biến và chưa bao phủ đồng đều mười lớp.

Trên CTCH, BiomedCLIP có Accuracy 0.2556, Macro-F1 0.1659, Macro-AUROC 0.8191 và Macro-AUPRC 0.2334, trong khi CLIP có Balanced Accuracy cao hơn ở mức 0.2367 so với 0.2109 của BiomedCLIP. Macro-F1 của BiomedCLIP có khoảng tin cậy [0.1263; 0.1966], còn Balanced Accuracy của CLIP có khoảng tin cậy [0.2055; 0.2648]; sự thay đổi thứ hạng theo độ đo cho thấy chất lượng xếp hạng lớp và quyết định argmax chưa hoàn toàn đồng nhất trong thiết lập 22 lớp.

Xét đồng thời hai bộ dữ liệu, BiomedCLIP đứng đầu bốn trong năm độ đo trên CTCH và toàn bộ năm độ đo trên BTXRD, do đó được chọn làm backbone kế thừa cho XBone-Net. Lựa chọn này chủ yếu dựa trên khả năng phân biệt ban đầu và mức phù hợp với miền y khoa, không hàm ý rằng đầu ra zero-shot đã đủ cho sử dụng trực tiếp; các giá trị Macro-F1 thấp hơn 0.17 trên cả hai bộ dữ liệu vẫn cho thấy nhu cầu thích ứng với dữ liệu đích, cơ chế xử lý mất cân bằng và khai thác thông tin lâm sàng.

4.5.2 So sánh với các mô hình nền tảng

Kết quả khi sử dụng toàn bộ dữ liệu huấn luyện


Thiết lập đánh giá trên toàn bộ dữ liệu (Full-shot) tiến hành so sánh đối chứng giữa hai mô hình mạng thần kinh cuộn đơn phương thức (ResNet-50, DenseNet-121), bốn mô hình ngôn ngữ - thị giác nền tảng y khoa và tự nhiên được tinh chỉnh toàn bộ (BioMedCLIP, PubMedCLIP, MedCLIP, CLIP), hai biến thể tinh chỉnh hiệu quả tham số (LoRA-BiomedCLIP, LoRA-PubMedCLIP) và mô hình đề xuất XBone-Net. Các kết quả đánh giá phân loại quyết định được tổng hợp tại Bảng ??, các độ đo xếp hạng xác suất được trình bày tại Bảng ??, các chỉ số hiệu quả tính toán tài nguyên được báo cáo tại Bảng ?? và Bảng ??, trong khi các đồ thị đường cong ROC, đường cong Precision-Recall và Reliability Diagram được trực quan hóa lần lượt tại Hình ?? và Hình ??.

Dữ liệu	Mô hình	Acc $\uparrow$	Balanced Acc $\uparrow$	Macro-F1 $\uparrow$
BTXRD	BioMedCLIP	0.8311 ± 0.0028	0.6062 ± 0.0254	0.5994 ± 0.0124
	CLIP	0.8036 ± 0.0273	0.5957 ± 0.0160	0.5787 ± 0.0252
	DenseNet-121	0.6320 ± 0.0013	0.3694 ± 0.0150	0.3718 ± 0.0173
	MedCLIP	0.8204 ± 0.0144	0.6125 ± 0.0235	0.6054 ± 0.0147
	PubMedCLIP	0.7884 ± 0.0285	0.6089 ± 0.0342	0.5723 ± 0.0577
	ResNet-50	0.6071 ± 0.0140	0.3188 ± 0.0136	0.3291 ± 0.0102
	LoRA-BiomedCLIP	0.8133 ± 0.0035	0.6552 ± 0.0244	0.6225 ± 0.0088
	LoRA-PubMedCLIP	0.8347 ± 0.0058	0.6369 ± 0.0197	0.6327 ± 0.0211
	XBone-Net	0.8258 ± 0.0034	0.5916 ± 0.0116	0.6010 ± 0.0034
CTCH	BioMedCLIP	0.5969 ± 0.0253	0.6023 ± 0.0234	0.5540 ± 0.0080
	CLIP	0.5874 ± 0.0209	0.6217 ± 0.0359	0.5633 ± 0.0090
	DenseNet-121	0.4818 ± 0.0052	0.4927 ± 0.0461	0.4367 ± 0.0238
	MedCLIP	0.5590 ± 0.0389	0.5717 ± 0.0186	0.5151 ± 0.0216
	PubMedCLIP	0.5521 ± 0.0234	0.5589 ± 0.0614	0.5203 ± 0.0264
	ResNet-50	0.4928 ± 0.0017	0.4126 ± 0.0106	0.4078 ± 0.0051
	LoRA-BiomedCLIP	0.5959 ± 0.0212	0.6092 ± 0.0243	0.5599 ± 0.0220
	LoRA-PubMedCLIP	0.6009 ± 0.0305	0.5699 ± 0.0081	0.5538 ± 0.0196
	XBone-Net	0.5655 ± 0.0353	0.5899 ± 0.0490	0.5574 ± 0.0049

Bảng 4.10: Các độ đo dựa trên quyết định phân loại khi sử dụng toàn bộ dữ liệu

Dữ liệu	Mô hình	AUROC $\uparrow$	AUPRC $\uparrow$
BTXRD	BioMedCLIP	0.8865 ± 0.0165	0.6511 ± 0.0104
	CLIP	0.8973 ± 0.0231	0.6251 ± 0.0080
	DenseNet-121	0.7717 ± 0.0173	0.3831 ± 0.0036
	MedCLIP	0.8599 ± 0.0330	0.6228 ± 0.0253
	PubMedCLIP	0.9048 ± 0.0240	0.6149 ± 0.0245
	ResNet-50	0.7236 ± 0.0259	0.3338 ± 0.0061
	LoRA-BiomedCLIP	0.9102 ± 0.0319	0.6343 ± 0.0209
	LoRA-PubMedCLIP	0.9039 ± 0.0063	0.6592 ± 0.0341
	XBone-Net	0.9243 ± 0.0298	0.6301 ± 0.0211
CTCH	BioMedCLIP	0.9390 ± 0.0289	0.6169 ± 0.0090
	CLIP	0.9290 ± 0.0387	0.6002 ± 0.0400
	DenseNet-121	0.9350 ± 0.0046	0.4762 ± 0.0136
	MedCLIP	0.9215 ± 0.0333	0.5839 ± 0.0185
	PubMedCLIP	0.9279 ± 0.0214	0.5888 ± 0.0196
	ResNet-50	0.9145 ± 0.0037	0.4492 ± 0.0042
	LoRA-BiomedCLIP	0.9334 ± 0.0216	0.6045 ± 0.0204
	LoRA-PubMedCLIP	0.9366 ± 0.0202	0.6087 ± 0.0072
	XBone-Net	0.9474 ± 0.0246	0.6146 ± 0.0132

Bảng 4.11: Các độ đo xếp hạng xác suất khi sử dụng toàn bộ dữ liệu



Hình 4.2: Trực quan hóa đường cong ROC và Precision-Recall khi sử dụng toàn bộ dữ liệu huấn luyện

Phân tích kết quả thực nghiệm từ Bảng ?? và Bảng ?? phản ánh sự đối sánh đa chiều giữa mô hình đề xuất XBone-Net với các nhóm mô hình đối chứng. Xét về điểm mạnh, XBone-Net vượt trội hoàn toàn về khả năng phân tách và xếp hạng xác suất tổng quát, khi đạt chỉ số Macro-AUROC cao nhất trên cả hai tập dữ liệu: 0.9243 ± 0.0298 trên tập X-quang xương

tổng quát BTXRD và đạt vị trí dẫn đầu toàn bảng 0.9474 ± 0.0246 trên tập bệnh lý chấn thương chỉnh hình CTCH (22 lớp mất cân bằng). Ngoài ra, XBone-Net cùng các mô hình đa phương thức VLM thể hiện sự áp đảo tuyệt đối so với các mạng cuộn đơn phương thức truyền thống (ResNet-50, DenseNet-121) với mức chênh lệch từ 15% đến 30% trên mọi độ đo. Ngược lại, xét về các điểm hạn chế, trên bộ dữ liệu BTXRD, điểm Macro-F1 (0.6010 ± 0.0034) và Balanced Accuracy (0.5916 ± 0.0116) của XBone-Net thấp hơn một chút so với các mô hình baseline tinh chỉnh hiệu quả tham số như LoRA-PubMedCLIP (0.6327 Macro-F1) hay LoRA-BiomedCLIP (0.6552 Balanced Acc). Bên cạnh đó, về mặt chi phí tính toán (Bảng ??), việc tích hợp mô-đun chú ý chéo bổ sung khiến chi phí FLOPs (229.02 GFLOPs) và độ trễ suy luận (64.92 ms) của XBone-Net cao hơn so với các mô hình LoRA thuần túy.


Đi sâu vào phân tích bản chất phương pháp luận và đặc tính dữ liệu, những kết quả trên giải thích rõ lý do tạo nên sự khác biệt về hiệu năng của XBone-Net. Mô hình thể hiện sức mạnh vượt trội trên tập CTCH nhờ sự kết hợp giữa cơ chế chú ý chéo hai chiều (Bidirectional Cross-Attention) và đầu phân loại tâm điểm thực nghiệm (Empirical Centroid Classifier). Với CTCH — một tập dữ liệu y tế chuyên sâu chứa 22 lớp bệnh lý có độ chênh lệch số lượng mẫu cực kỳ nghiêm trọng, việc đo khoảng cách không gian đến các tâm điểm lớp (centroids) thay vì dùng lớp tuyến tính Softmax truyền thống đã ngăn chặn hiệu quả hiện tượng ranh giới quyết định bị lệch về phía các lớp đa số. Đồng thời, văn bản bệnh sử lâm sàng chi tiết trong CTCH giúp cơ chế Cross-Attention định hướng mô hình tập trung vào các vùng tổn thương đặc trưng trên ảnh. Tuy nhiên, trên tập BTXRD — một tập dữ liệu X-quang tổng quát với cấu trúc 10 lớp cân bằng hơn và phần mô tả văn bản ngắn, các mô hình LoRA thuần túy tận dụng tốt tri thức tiền huấn luyện của bộ mã hóa ngôn ngữ-thị giác để tối ưu hóa quyết định phân lớp tại một ngưỡng cố định, dẫn đến Macro-F1 tốt hơn. Việc XBone-Net đạt Macro-AUROC đỉnh nhưng Macro-F1 ở mức trung bình trên BTXRD cho thấy mô hình ưu tiên tối ưu hóa thứ tự xếp hạng xác suất không gian toàn cục thay vì cưỡng ép ngưỡng phân loại cứng cho các tập dữ liệu ít mất cân bằng.

Từ những phân tích trên, thực nghiệm rút ra ba insight khoa học quan

trọng về kiến trúc XBone-Net: Thứ nhất, mô hình đạt giá trị ứng dụng cao nhất trong các bài toán y tế chuyên sâu có phân phối lớp mất cân bằng phức tạp (như CTCH), nơi tri thức lâm sàng đa phương thức và phân loại hình học centroid phát huy tối đa lợi thế. Thứ hai, tồn tại một sự đánh đổi (Trade-off) tự nhiên giữa khả năng phân tách xác suất toàn cục (được phản ánh qua Macro-AUROC hàng đầu) và việc tối ưu hóa ngưỡng phân loại cứng tại chỗ (Macro-F1). Thứ ba, mặc dù gia tăng nhẹ chi phí tính toán suy luận, XBone-Net chỉ cần huấn luyện 4.22% tham số (8.63M tham số trainable) và đạt độ hiệu chuẩn xác suất ECE đáng tin cậy (0.0966 trên BTXRD - Bảng ??), giúp hạn chế rủi ro dự đoán quá tự tin (Overconfidence). Tóm lại, các kết quả trên khẳng định XBone-Net là một giải pháp học sâu đa phương thức mạnh mẽ, có căn cứ khoa học vững chắc và cân bằng giữa hiệu năng chẩn đoán, độ tin cậy xác suất và chi phí huấn luyện cho bài toán phân loại ảnh X-quang y học.

Dữ liệu	ECE ↓
BTXRD	0.0966 ± 0.0265
CTCH	0.1482 ± 0.0682

Bảng 4.12: ECE của XBone-Net trên ba hạt giống



Hình 4.3: Reliability diagram thể hiện độ hiệu chuẩn xác suất ECE của XBone-Net trên bộ dữ liệu BTXRD và CTCH

Về chất lượng hiệu chuẩn xác suất (Calibration), Bảng ?? và Hình ??

báo cáo chỉ số ECE của XBone-Net trên hai tập dữ liệu. Trên BTXRD, XBone-Net đạt độ hiệu chuẩn ECE ấn tượng 0.0966 ± 0.0265 , chứng minh các xác suất dự đoán của mô hình phản ánh sát sao tần suất xuất hiện bệnh lý thực tế. Trên CTCH, chỉ số ECE đạt 0.1482 ± 0.0682 ; quan sát Reliability Diagram ở Hình ?? cho thấy phân bố xác suất của mô hình có xu hướng thận trọng hơn ở các khoảng độ tin cậy trung bình, giúp giảm thiểu rủi ro đưa ra dự đoán quá tự tin (Overconfidence) trong hỗ trợ chẩn đoán y khoa.

Dữ liệu	Mô hình	Tổng tham số	Tham số huấn luyện	Tỷ lệ (%)
BTXRD	LoRA-BiomedCLIP	201,447,179	5,544,458	2.75%
	LoRA-PubMedCLIP	155,052,299	3,774,986	2.43%
	XBone-Net	204,535,308	8,632,587	4.22%
CTCH	LoRA-BiomedCLIP	201,453,335	5,550,614	2.76%
	LoRA-PubMedCLIP	155,058,455	3,781,142	2.44%
	XBone-Net	204,535,320	8,632,599	4.22%

Bảng 4.13: Đánh giá số lượng tham số của các mô hình khi sử dụng toàn bộ dữ liệu

Dữ liệu	Mô hình	GFLOPs	Độ trễ (ms)	Thông lượng (mẫu/s)
BTXRD	LoRA-BiomedCLIP	83.321	36.25	30.6
	LoRA-PubMedCLIP	15.198	43.87	33.3
	XBone-Net	229.020	64.92	17.7
CTCH	LoRA-BiomedCLIP	83.321	30.16	38.3
	LoRA-PubMedCLIP	15.198	34.56	37.7
	XBone-Net	229.020	87.15	13.4

Bảng 4.14: Đánh giá chi phí tính toán và tốc độ suy luận của các mô hình khi sử dụng toàn bộ dữ liệu

Bảng ?? và Bảng ?? tổng hợp đánh giá hiệu quả tính toán tài nguyên của các mô hình. XBone-Net tối ưu hóa chi phí huấn luyện khi chỉ cần cập nhật 4.22% tổng số tham số (8.63M tham số trainable), giữ nguyên các đại lượng biểu diễn gốc từ BiomedCLIP. Mặc dù bổ sung cơ chế Cross-Attention khiến số phép tính GFLOPs tăng lên 229.02 GFLOPs và độ trễ suy luận là 64.92 ms (BTXRD) / 87.15 ms (CTCH), tốc độ xử lý 13.4–17.7 mẫu/giây hoàn toàn đáp ứng tốt thời gian thực trong môi trường triển khai lâm sàng tại bệnh viện.

Kết quả trong trường hợp mẫu học hạn chế


Thiết lập kịch bản mẫu hạn chế (Few-shot Learning) tiến hành so sánh đối chứng giữa hai mô hình LoRA baseline và XBone-Net ở các mức 1-shot, 10-shot và 20-shot trên mỗi lớp. Các kết quả đánh giá phân loại được trình bày tại Bảng ??, các độ đo xếp hạng được báo cáo tại Bảng ??, đồ thị so sánh Macro-F1 được thể hiện ở Hình ??, và chi tiết hiệu quả tính toán được tổng hợp tại Bảng ?? và Bảng ??.

Dữ liệu	Kịch bản	Mô hình	Accuracy $\uparrow$	Balanced Acc $\uparrow$	Macro-F1 $\uparrow$
BTXRD	1-shot	LoRA-BiomedCLIP	0.2782 ± 0.0553	0.2132 ± 0.0468	0.1699 ± 0.0356
		LoRA-PubMedCLIP	0.3164 ± 0.1723	0.2507 ± 0.0431	0.1818 ± 0.0619
		XBone-Net	0.2480 ± 0.0370	0.2116 ± 0.0503	0.1620 ± 0.0259
	10-shot	LoRA-BiomedCLIP	0.6769 ± 0.0381	0.4671 ± 0.0159	0.4211 ± 0.0123
		LoRA-PubMedCLIP	0.6640 ± 0.0615	0.4441 ± 0.0105	0.4164 ± 0.0157
		XBone-Net	0.6889 ± 0.0296	0.4771 ± 0.0300	0.4302 ± 0.0263
	20-shot	LoRA-BiomedCLIP	0.7311 ± 0.0073	0.5492 ± 0.0244	0.4876 ± 0.0044
		LoRA-PubMedCLIP	0.7369 ± 0.0109	0.5785 ± 0.0158	0.5132 ± 0.0112
		XBone-Net	0.7449 ± 0.0166	0.5949 ± 0.0258	0.5202 ± 0.0300
CTCH	1-shot	LoRA-BiomedCLIP	0.2128 ± 0.0116	0.2830 ± 0.0164	0.2074 ± 0.0034
		LoRA-PubMedCLIP	0.1908 ± 0.0496	0.2850 ± 0.0749	0.1876 ± 0.0434
		XBone-Net	0.2342 ± 0.0175	0.3351 ± 0.0659	0.2236 ± 0.0206
	10-shot	LoRA-BiomedCLIP	0.4036 ± 0.0334	0.5558 ± 0.0275	0.4291 ± 0.0165
		LoRA-PubMedCLIP	0.3812 ± 0.0158	0.5629 ± 0.0136	0.4186 ± 0.0117
		XBone-Net	0.3926 ± 0.0511	0.5590 ± 0.0419	0.4329 ± 0.0357
	20-shot	LoRA-BiomedCLIP	0.4395 ± 0.0269	0.6136 ± 0.0263	0.4803 ± 0.0219
		LoRA-PubMedCLIP	0.4509 ± 0.0195	0.5878 ± 0.0230	0.4649 ± 0.0236
		XBone-Net	0.4360 ± 0.0183	0.5856 ± 0.0173	0.4684 ± 0.0063


Bảng 4.15: Hiệu năng phân loại tổng hợp trong kịch bản mẫu hạn chế (Few-shot)

Dữ liệu	Kịch bản	Mô hình	Macro-AUROC $\uparrow$	Macro-AUPRC $\uparrow$
BTXRD	1-shot	LoRA-BiomedCLIP	0.6319 ± 0.0404	0.2085 ± 0.0342
		LoRA-PubMedCLIP	0.6511 ± 0.0259	0.2501 ± 0.0364
		XBone-Net	0.6274 ± 0.0274	0.2035 ± 0.0383
	10-shot	LoRA-BiomedCLIP	0.8598 ± 0.0144	0.4467 ± 0.0173
		LoRA-PubMedCLIP	0.8529 ± 0.0190	0.4606 ± 0.0183
		XBone-Net	0.8577 ± 0.0050	0.4552 ± 0.0330
	20-shot	LoRA-BiomedCLIP	0.9271 ± 0.0092	0.5420 ± 0.0061
		LoRA-PubMedCLIP	0.9205 ± 0.0132	0.5561 ± 0.0067
		XBone-Net	0.9163 ± 0.0160	0.5635 ± 0.0395
CTCH	1-shot	LoRA-BiomedCLIP	0.8231 ± 0.0212	0.2357 ± 0.0130
		LoRA-PubMedCLIP	0.7904 ± 0.0188	0.2040 ± 0.0257
		XBone-Net	0.8645 ± 0.0082	0.2882 ± 0.0140
	10-shot	LoRA-BiomedCLIP	0.9353 ± 0.0070	0.4647 ± 0.0268
		LoRA-PubMedCLIP	0.9393 ± 0.0065	0.4785 ± 0.0053
		XBone-Net	0.9368 ± 0.0108	0.4540 ± 0.0235
	20-shot	LoRA-BiomedCLIP	0.9416 ± 0.0143	0.5088 ± 0.0308
		LoRA-PubMedCLIP	0.9501 ± 0.0011	0.5263 ± 0.0191
		XBone-Net	0.9457 ± 0.0072	0.5217 ± 0.0147

Bảng 4.16: Các độ đo xếp hạng xác suất trong kịch bản mẫu hạn chế (Few-shot)



(a) Tập dữ liệu BTXRD



(b) Tập dữ liệu CTCH

Hình 4.4: So sánh chỉ số Macro-F1 giữa các kịch bản mẫu hạn chế (1-shot, 10-shot, 20-shot) trên BTXRD và CTCH

Phân tích kết quả từ Bảng ??, Bảng ?? và Hình ?? chỉ ra sự vượt trội ấn tượng của XBone-Net so với các mô hình LoRA baselines đối chứng trong các kịch bản mẫu hạn chế (Few-shot). Tại kịch bản 1-shot khắt khe nhất trên bộ dữ liệu CTCH, XBone-Net dẫn đầu tuyệt đối trên toàn bộ năm chỉ số đánh giá (Accuracy 0.2342 ± 0.0175 , Balanced Acc 0.3351 ± 0.0659 , Macro-F1 0.2236 ± 0.0206 , Macro-AUROC 0.8645 ± 0.0082

và Macro-AUPRC 0.2882 ± 0.0140). Khi quy mô dữ liệu huấn luyện mở rộng từ $1 \rightarrow 10 \rightarrow 20$ -shot, điểm Macro-F1 của các mô hình đều tăng trưởng vượt bậc, trong đó XBone-Net liên tục giữ vững vị thế dẫn đầu trên BTXRD ở cả kịch bản 10-shot (0.4302 ± 0.0263) và 20-shot (0.5202 ± 0.0300).

Phân tích sâu vào các thành phần kiến trúc giải thích vì sao XBone-Net lại đạt được hiệu năng ấn tượng này: Trong kịch bản 1-shot cực kỳ thiếu hụt dữ liệu gán nhãn, cơ chế chú ý chéo hai chiều (Bidirectional Cross-Attention) đóng vai trò định hướng ngữ cảnh quan trọng, khai thác thông tin mô tả lâm sàng trong bệnh sử để làm mờ neo không gian đặc trưng cho ảnh X-quang. Đồng thời, đầu phân loại tâm điểm thực nghiệm (Empirical Centroids Classifier) thay vì tối ưu hóa một ma trận trọng số tuyến tính dễ bị nhiễu do 1 mẫu duy nhất gây ra, đã khởi tạo và điều chỉnh trực tiếp vị trí tâm điểm của từng lớp, giúp xây dựng ranh giới phân tách lớp cân bằng hơn khi lượng mẫu gia tăng dần qua các kịch bản 10-shot và 20-shot.

Những kết quả thực nghiệm kịch bản mẫu hạn chế này giúp chứng minh rằng XBone-Net có khả năng học và tổng quát hóa cực kỳ mạnh mẽ trong điều kiện khan hiếm dữ liệu gán nhãn y khoa - một đặc thù phổ biến trong thực tế khi việc thu thập nhãn bệnh lý từ bác sĩ chuyên khoa xương khớp rất tốn kém và mất thời gian. Khả năng thích ứng vượt trội ở kịch bản 1-shot khẳng định tính khả thi cao khi triển khai mô hình vào các hệ thống y tế thực tế, giúp duy trì hiệu suất chẩn đoán ổn định ngay cả với các bệnh lý hiếm gặp hoặc khi cơ sở y tế chỉ sở hữu một số lượng mẫu huấn luyện cực kỳ hạn chế.

Dữ liệu	Kịch bản	Mô hình	Tổng tham số	Tham số huấn luyện	Tỷ lệ (%)
BTXRD	1-shot	LoRA-BiomedCLIP	201,447,179	5,544,458	2.75%
		LoRA-PubMedCLIP	155,052,299	3,774,986	2.43%
		XBone-Net	204,535,308	8,632,587	4.22%
	10-shot	LoRA-BiomedCLIP	201,447,179	5,544,458	2.75%
		LoRA-PubMedCLIP	155,052,299	3,774,986	2.43%
		XBone-Net	204,535,308	8,632,587	4.22%
	20-shot	LoRA-BiomedCLIP	201,447,179	5,544,458	2.75%
		LoRA-PubMedCLIP	155,052,299	3,774,986	2.43%
		XBone-Net	204,535,308	8,632,587	4.22%
CTCH	1-shot	LoRA-BiomedCLIP	201,453,335	5,550,614	2.76%
		LoRA-PubMedCLIP	155,058,455	3,781,142	2.44%
		XBone-Net	204,535,320	8,632,599	4.22%
	10-shot	LoRA-BiomedCLIP	201,453,335	5,550,614	2.76%
		LoRA-PubMedCLIP	155,058,455	3,781,142	2.44%
		XBone-Net	204,535,320	8,632,599	4.22%
	20-shot	LoRA-BiomedCLIP	201,453,335	5,550,614	2.76%
		LoRA-PubMedCLIP	155,058,455	3,781,142	2.44%
		XBone-Net	204,535,320	8,632,599	4.22%

Bảng 4.17: Đánh giá số lượng tham số của các mô hình trong kịch bản mẫu hạn chế (Few-shot)

Dữ liệu	Kịch bản	Mô hình	GFLOPs	Độ trễ (ms)	Thông lượng (mẫu/s)
BTXRD	1-shot	LoRA-BiomedCLIP	83.321	37.32	28.8
		LoRA-PubMedCLIP	15.198	43.74	33.1
		XBone-Net	229.020	82.53	14.3
	10-shot	LoRA-BiomedCLIP	83.321	35.18	30.9
		LoRA-PubMedCLIP	15.198	38.77	35.2
		XBone-Net	229.020	84.25	14.2
	20-shot	LoRA-BiomedCLIP	83.321	37.94	28.5
		LoRA-PubMedCLIP	15.198	41.50	33.1
		XBone-Net	229.020	77.28	15.4
CTCH	1-shot	LoRA-BiomedCLIP	83.321	33.56	32.2
		LoRA-PubMedCLIP	15.198	39.98	34.6
		XBone-Net	229.020	73.73	16.6
	10-shot	LoRA-BiomedCLIP	83.321	35.61	30.7
		LoRA-PubMedCLIP	15.198	38.31	35.9
		XBone-Net	229.020	66.27	16.8
	20-shot	LoRA-BiomedCLIP	83.321	37.91	28.2
		LoRA-PubMedCLIP	15.198	43.91	31.9
		XBone-Net	229.020	80.92	14.5

Bảng 4.18: Đánh giá chi phí tính toán và tốc độ suy luận của các mô hình trong kịch bản mẫu hạn chế (Few-shot)

Cuối cùng, Bảng ?? và Bảng ?? minh chứng tính ổn định tuyệt đối về hiệu quả tính toán của XBone-Net qua các kịch bản Few-shot. Số lượng phép tính GFLOPs (229.020) và số tham số có thể huấn luyện (4.22%) duy trì cố định bất kể số lượng mẫu shot được cung cấp. Độ trễ suy luận trung bình duy trì trong khoảng 66.27 – 84.25 ms, đảm bảo hiệu năng tính toán

đáng tin cậy và không phụ thuộc vào quy mô dữ liệu gán nhãn sẵn có.


4.5.3 Đánh giá thành phần

Thành phần hoặc độ đo	XBone-Net	Không high-res	Mean pooling	Chỉ pha 2	Concat	Linear head
Nhánh ảnh độ phân giải cao	✓		✓	✓	✓	✓
Attention pooling cục bộ	✓	–		✓	✓	✓
Huấn luyện pha 1	✓	✓	✓		✓	✓
Cross-attention hai chiều	✓	✓	✓	✓		✓
Empirical centroid	✓	✓	✓	✓	✓	
Accuracy ↑	0.5725 ± 0.0286	0.6074 ± 0.0204	0.5790 ± 0.0139	0.6173 ± 0.0119	0.5924 ± 0.0085	0.6263 ± 0.0060
Balanced Accuracy ↑	0.5844 ± 0.0454	0.5571 ± 0.0104	0.6049 ± 0.0459	0.5572 ± 0.0239	0.5668 ± 0.0276	0.5779 ± 0.0396
Macro-F1 ↑	0.5558 ± 0.0072	0.5553 ± 0.0136	0.5736 ± 0.0251	0.5753 ± 0.0175	0.5425 ± 0.0130	0.5889 ± 0.0251
Macro-AUROC ↑	0.9473 ± 0.0246	0.9148 ± 0.0223	0.9577 ± 0.0082	0.9144 ± 0.0198	0.9566 ± 0.0046	0.9080 ± 0.0099
Macro-AUPRC ↑	0.6189 ± 0.0145	0.5990 ± 0.0073	0.6312 ± 0.0277	0.6268 ± 0.0170	0.6019 ± 0.0139	0.6076 ± 0.0218
ECE ↓	0.1032 ± 0.0303	0.1743 ± 0.0634	0.1506 ± 0.0564	0.1868 ± 0.0724	0.0789 ± 0.0148	0.0882 ± 0.0153

Bảng 4.19: Nghiên cứu loại bỏ từng thành phần của XBone-Net trên CTCH. Mỗi cột chỉ loại bỏ hoặc thay thế thành phần được khảo sát so với cấu hình đầy đủ: direct resize thay cho nhánh high-resolution, mean pooling thay cho attention pooling, chỉ huấn luyện pha 2, concat thay cho cross-attention hai chiều và linear head thay cho empirical centroid. Kết quả được trình bày dưới dạng trung bình ± độ lệch chuẩn trên 3 hạt giống; chữ đậm biểu thị kết quả tốt nhất theo từng độ đo. Ký hiệu “–” chỉ trường hợp attention pooling không còn áp dụng khi nhánh high-resolution bị loại bỏ.

Biến thể	BAcc ↑	Macro-F1 ↑	Macro-AUROC ↑	Macro-AUPRC ↑
XBone-Net	0.5844 ± 0.0454	0.5558 ± 0.0072	0.9473 ± 0.0246	0.6189 ± 0.0145
Chỉ ảnh	0.4405 ± 0.0082	0.3984 ± 0.0176	0.9275 ± 0.0041	0.4177 ± 0.0075
Chỉ bệnh sử	0.5401 ± 0.0149	0.4770 ± 0.0133	0.9393 ± 0.0020	0.5165 ± 0.0036
Bệnh sử xáo trộn	0.3120 ± 0.0172	0.3039 ± 0.0048	0.8494 ± 0.0537	0.3098 ± 0.0264
Nổi đặc trưng	0.5668 ± 0.0276	0.5425 ± 0.0130	0.9566 ± 0.0046	0.6019 ± 0.0139
Ảnh truy vấn văn bản	0.5674 ± 0.0433	0.5559 ± 0.0159	0.9449 ± 0.0268	0.6174 ± 0.0292
Văn bản truy vấn ảnh	0.5680 ± 0.0480	0.5632 ± 0.0217	0.9410 ± 0.0216	0.6211 ± 0.0137
Đầu tuyến tính	0.5779 ± 0.0396	0.5889 ± 0.0251	0.9080 ± 0.0099	0.6076 ± 0.0218
Không trọng số lớp	0.5582 ± 0.0064	0.5641 ± 0.0093	0.9528 ± 0.0056	0.6133 ± 0.0114
Không bias theo lớp	0.5749 ± 0.0317	0.5740 ± 0.0126	0.9355 ± 0.0188	0.6125 ± 0.0116
Đóng băng backbone	0.5833 ± 0.0149	0.5405 ± 0.0061	0.9502 ± 0.0105	0.5641 ± 0.0091
Chỉ huấn luyện pha 2	0.5572 ± 0.0239	0.5753 ± 0.0175	0.9144 ± 0.0198	0.6268 ± 0.0170

Bảng 4.20: Đánh giá bổ sung các biến thể đa phương thức, dung hợp, bộ phân loại và chiến lược huấn luyện có đủ ba hạt giống trên CTCH.



Hình 4.5: Chênh lệch Macro-F1 của từng biến thể so với cấu hình XBone-Net chuẩn trên CTCH

Kết quả tại Bảng ??, Bảng ?? và Hình ?? cho thấy XBone-Net chuẩn không dẫn đầu trên mọi độ đo. Cấu hình mean pooling đạt Balanced Accuracy, Macro-AUROC và Macro-AUPRC cao nhất trong nhóm loại bỏ thành phần, lần lượt là 0.6049 ± 0.0459 , 0.9577 ± 0.0082 và 0.6312 ± 0.0277 . Đầu tuyến tính đạt Accuracy và Macro-F1 cao nhất, lần lượt là 0.6263 ± 0.0060 và 0.5889 ± 0.0251 , nhưng Macro-AUROC giảm xuống 0.9080 ± 0.0099 . Trong khi đó, XBone-Net đạt Balanced Accuracy 0.5844 ± 0.0454 , Macro-F1 0.5558 ± 0.0072 và Macro-AUROC 0.9473 ± 0.0246 . Các suy giảm lớn nhất xuất hiện khi chỉ dùng ảnh, chỉ dùng bệnh sử và đặc biệt khi xáo trộn bệnh sử, với Macro-F1 lần lượt là 0.3984, 0.4770 và 0.3039. Vì vậy, điểm mạnh rõ nhất của cấu hình chuẩn không nằm ở việc tối ưu một độ đo phân loại đơn lẻ mà ở việc cung cấp cấu hình tham chiếu đầy đủ để khảo sát vai trò của từng thành phần; điểm yếu là các thành phần được kết hợp hiện chưa tạo ra cải thiện đồng thời trên toàn bộ các độ đo phân loại.

Sự suy giảm của các biến thể đơn phương thức cho thấy ảnh và bệnh

sử cung cấp thông tin bổ sung, còn kết quả thấp của bệnh sử xáo trộn xác nhận rằng lợi ích không chỉ đến từ sự hiện diện của văn bản mà còn phụ thuộc vào quan hệ ghép cặp đúng giữa hai phương thức. Tuy nhiên, hai hướng cross-attention một chiều có Macro-F1 gần cấu hình hai chiều, còn phép nổi đặc trưng đạt Macro-AUROC cao hơn; điều này cho thấy cross-attention hai chiều hiện chưa tạo ưu thế ổn định trên mọi độ đo. Đầu tuyến tính cải thiện quyết định argmax nhưng làm giảm Macro-AUROC, phù hợp với sự khác biệt giữa ranh giới tuyến tính tối ưu cho phân lớp và hình học theo tâm lớp dùng cho xếp hạng. Tương tự, việc loại trọng số lớp hoặc bias theo lớp làm thay đổi Macro-F1, Balanced Accuracy và Macro-AUROC theo các hướng khác nhau, cho thấy hai cơ chế cân bằng lớp tạo ra đánh đổi thay vì cải thiện đồng thời. Biến thể chỉ huấn luyện pha 2 cũng đạt Macro-F1 và Macro-AUPRC cao hơn nhưng Macro-AUROC thấp hơn cấu hình chuẩn, gợi ý rằng pha 1 có lợi hơn cho cấu trúc biểu diễn toàn cục so với quyết định cứng.

Insight chính của nghiên cứu thành phần là đóng góp được hỗ trợ rõ nhất hiện tại nằm ở thiết kế đa phương thức và tính nhất quán ảnh-bệnh sử. Lợi ích riêng của attention pooling, cross-attention hai chiều, empirical centroid, trọng số lớp và bias theo lớp phụ thuộc vào tiêu chí đánh giá, do đó không nên được trình bày như các cải tiến đồng đều. Nếu mục tiêu vận hành chỉ ưu tiên Macro-F1, đầu tuyến tính phù hợp hơn; nếu ưu tiên Balanced Accuracy, Macro-AUROC và Macro-AUPRC, mean pooling là biến thể đáng chú ý hơn trong các kết quả hiện có. XBone-Net vì vậy được giữ làm cấu hình tham chiếu đầy đủ để phân tích sự đánh đổi giữa các thành phần và khả năng sử dụng fused embedding cho OOD, thay vì được diễn giải là cấu hình phân loại tối ưu tuyệt đối.

4.5.4 OOD hậu xử lý

Bảng ?? tổng hợp bốn score hậu xử lý trên ba kịch bản OOD của XBone-Net. Tất cả score hình học được tính trên fused embedding của cùng checkpoint; entropy được tính từ phân phối xác suất đầu ra. Các kết quả là trung bình và độ lệch chuẩn trên ba hạt giống, trong đó thống kê detector được ước lượng từ CTCH train và ngưỡng vận hành chỉ được hiệu

chỉnh trên CTCH validation-ID trước khi đánh giá.

Kịch bản	Phương pháp	AUROC-ODD $\uparrow$	AUPR-Out $\uparrow$	FPR@95%TPR
Semantic OOD	Cosine-centroid	0.6006 ± 0.0132	0.0965 ± 0.0066	0.4725 ± 0.1857
	Mahalanobis-centroid	0.6285 ± 0.0177	0.1033 ± 0.0092	0.4725 ± 0.1857
	kNN	0.6269 ± 0.0175	0.1083 ± 0.0112	0.4725 ± 0.1857
	Entropy	0.5705 ± 0.0230	0.1052 ± 0.0162	0.4725 ± 0.1857
Domain OOD–FracAtlas	Cosine-centroid	0.8143 ± 0.0934	0.7868 ± 0.0951	0.4725 ± 0.1857
	Mahalanobis-centroid	0.8878 ± 0.0793	0.8734 ± 0.0791	0.4725 ± 0.1857
	kNN	0.8575 ± 0.0900	0.8340 ± 0.0924	0.4725 ± 0.1857
	Entropy	0.7768 ± 0.0575	0.7543 ± 0.0636	0.4725 ± 0.1857
Cross-dataset OOD–BTXRD	Cosine-centroid	0.7301 ± 0.0850	0.7268 ± 0.0633	0.4725 ± 0.1857
	Mahalanobis-centroid	0.8040 ± 0.0937	0.8007 ± 0.0609	0.4725 ± 0.1857
	kNN	0.7725 ± 0.0970	0.7641 ± 0.0703	0.4725 ± 0.1857
	Entropy	0.6918 ± 0.0859	0.7033 ± 0.0731	0.4725 ± 0.1857

Bảng 4.21: Kết quả OOD hậu xử lý từ fused embedding của XBone-Net; chữ đậm biểu thị kết quả tốt nhất theo từng độ đo trong mỗi kịch bản

Phân tích Bảng ?? cho thấy các score hình học nhìn chung phù hợp với fused embedding hơn entropy đầu ra. Mahalanobis-centroid đạt kết quả cao nhất trên cả ba độ đo đối với FracAtlas, với AUROC-ODD 0.8878 ± 0.0793 , AUPR-Out 0.8734 ± 0.0791 và FPR@95%TPR 0.4725 ± 0.1857 ; xu hướng tương tự xuất hiện trên BTXRD với các giá trị lần lượt là 0.8040 ± 0.0937 , 0.8007 ± 0.0609 và 0.7071 ± 0.0678 . Ngược lại, Semantic OOD là kịch bản khó hơn: AUROC-ODD tốt nhất chỉ đạt 0.6285 ± 0.0177 với Mahalanobis-centroid, trong khi kNN đạt AUPR-Out cao nhất 0.1083 ± 0.0112 . FPR@95%TPR của mọi phương pháp trong kịch bản này đều xấp xỉ 0.88, cho thấy ưu thế về xếp hạng chưa chuyển thành một điểm vận hành có tỷ lệ chấp nhận nhầm OOD thấp.

Sự khác biệt giữa các kịch bản có thể được giải thích từ hình học của không gian dung hợp và bản chất dịch chuyển dữ liệu. Mahalanobis-centroid sử dụng phương sai và tương quan giữa các chiều fused embedding nên phù hợp hơn khi FracAtlas và BTXRD tạo ra dịch chuyển miền có cấu trúc; kNN chỉ mô hình hóa lân cận cục bộ nên cho kết quả gần Mahalanobis nhưng biến thiên giữa các hạt giống lớn hơn. Trong Semantic OOD, các mẫu ngoài phân phối vẫn có thể chia sẻ đặc trưng giải phẫu hoặc biểu hiện hình ảnh với các lớp CTCH, trong khi fused embedding được huấn luyện chủ yếu cho phân loại lớp thay vì tách riêng ID và OOD. AUPR-Out thấp còn chịu ảnh hưởng của số mẫu OOD nhỏ so với tập CTCH-ID. Đối với

BTXRD, sự giao nhau của lớp bình thường, các lớp u xương ngoài không gian nhãn CTCH và lược đồ bệnh sử tổng hợp cũng khiến kết quả phản ánh đồng thời dịch chuyển ảnh, nhãn và văn bản, thay vì chỉ một nguồn dịch chuyển miền.

Insight chính của thí nghiệm là fused embedding chứa tín hiệu hữu ích cho phát hiện domain OOD mà không cần huấn luyện thêm, nhưng chất lượng này phụ thuộc vào loại dịch chuyển và score hậu xử lý. Mahalanobis-centroid là lựa chọn phù hợp hơn cho hai bộ dữ liệu ngoài miền, còn kNN cung cấp đối chứng cục bộ có kết quả gần nhất; entropy đơn lẻ chưa khai thác đầy đủ cấu trúc của representation. Tuy nhiên, FPR@95%TPR còn cao và độ lệch chuẩn giữa các hạt giống đáng kể, do đó các score hiện tại chỉ phù hợp như tín hiệu cảnh báo hỗ trợ, chưa đủ cơ sở để xem là cơ chế từ chối tự động trong triển khai. Kết quả này định hướng việc cải thiện hiệu chỉnh ngưỡng và học không gian biểu diễn chuyên biệt hơn cho OOD.

Chương 5

Kết luận và hướng phát triển

5.1 Kết luận

Khóa luận đã nghiên cứu và đề xuất một hệ thống phân loại ảnh X-quang xương đa phương thức kết hợp khả năng phát hiện dữ liệu ngoài phân phối nhằm hỗ trợ chẩn đoán các bệnh lý cơ xương khớp. Hệ thống khai thác đồng thời hai nguồn thông tin gồm ảnh X-quang và thông tin lâm sàng, từ đó tận dụng được tính bổ sung giữa hai phương thức dữ liệu để nâng cao hiệu quả phân loại.

Trên cơ sở mô hình nền BioMedCLIP, nghiên cứu áp dụng kỹ thuật tinh chỉnh tham số hiệu quả LoRA để thích nghi với miền dữ liệu X-quang xương mà không làm thay đổi toàn bộ trọng số của mô hình. Đặc trưng hình ảnh và văn bản được kết hợp thông qua cơ chế chú ý hai chiều, sau đó được huấn luyện bằng sự kết hợp giữa hàm mất mát Cross-Entropy và Prototypical Loss. Trong đó, Cross-Entropy đảm nhiệm nhiệm vụ tối ưu phân loại, còn Prototypical Loss giúp xây dựng không gian đặc trưng có tính phân biệt cao, tạo tiền đề cho giai đoạn phát hiện dữ liệu ngoài phân phối.

Đối với bài toán phát hiện dữ liệu ngoài phân phối, luận văn lựa chọn phương pháp Mahalanobis Distance theo cơ chế hậu xử lý (post-hoc), với không gian đặc trưng đã được học dựa vào mạng nguyên mẫu. Cách tiếp

cận này tận dụng trực tiếp không gian đặc trưng đã được học trong quá trình huấn luyện để đánh giá mức độ bất thường của mẫu kiểm thử mà không cần thay đổi kiến trúc hoặc huấn luyện lại mô hình. Điều này giúp nâng cao độ tin cậy của hệ thống khi triển khai trong các tình huống lâm sàng thực tế, nơi có thể xuất hiện các bệnh lý hoặc trường hợp chưa từng xuất hiện trong dữ liệu huấn luyện.

Các thực nghiệm được thực hiện trên bộ dữ liệu BTXRD kết hợp với bộ dữ liệu nội bộ CTCH đã cho thấy phương pháp đề xuất đạt hiệu quả tốt trong nhiệm vụ phân loại, đồng thời xây dựng được không gian đặc trưng phù hợp để hỗ trợ phát hiện dữ liệu ngoài phân phối. Kết quả cũng cho thấy việc kết hợp thông tin lâm sàng với ảnh X-quang giúp cải thiện khả năng nhận diện bệnh lý so với việc chỉ sử dụng một nguồn dữ liệu.

Nhìn chung, luận văn đã hoàn thành các mục tiêu nghiên cứu đã đề ra, bao gồm xây dựng mô hình phân loại đa phương thức dựa trên BioMed-CLIP, tối ưu biểu diễn đặc trưng bằng Prototypical Loss và tích hợp cơ chế phát hiện dữ liệu ngoài phân phối dựa trên khoảng cách Mahalanobis. Các kết quả đạt được là cơ sở cho việc phát triển các hệ thống hỗ trợ chẩn đoán có độ tin cậy cao hơn trong lĩnh vực chẩn đoán hình ảnh y khoa.

5.2 Hướng phát triển

Mặc dù đạt được những kết quả khả quan, phương pháp đề xuất vẫn còn một số hạn chế và có thể được mở rộng trong các nghiên cứu tiếp theo.

Thứ nhất, phương pháp phát hiện dữ liệu ngoài phân phối hiện được xây dựng theo hướng hậu xử lý bằng khoảng cách Mahalanobis. Các nghiên cứu tiếp theo có thể khảo sát những phương pháp OOD hiện đại hơn hoặc tích hợp trực tiếp mục tiêu phát hiện OOD vào quá trình huấn luyện để nâng cao khả năng phát hiện các trường hợp Near-OOD.

Thứ hai, phạm vi thực nghiệm của luận văn mới được đánh giá trên bộ dữ liệu BTXRD và bộ dữ liệu CTCH. Trong tương lai, cần mở rộng thực nghiệm trên nhiều bộ dữ liệu X-quang xương có quy mô lớn hơn cũng như đánh giá khả năng tổng quát hóa giữa các bệnh viện, thiết bị chụp và điều kiện thu nhận ảnh khác nhau.

Cuối cùng, hệ thống hiện tập trung vào hai nhiệm vụ chính là phân loại và phát hiện dữ liệu ngoài phân phối. Trong tương lai, có thể tích hợp thêm các phương pháp giải thích mô hình (Explainable AI) hoặc các mô hình ngôn ngữ lớn y khoa nhằm hỗ trợ sinh báo cáo chẩn đoán, giải thích kết quả dự đoán và tăng cường khả năng tương tác với bác sĩ trong quá trình hỗ trợ ra quyết định lâm sàng.

Tài liệu tham khảo

Tiếng Anh

- [0] Jean-Baptiste Alayrac et al. “Flamingo: a Visual Language Model for Few-Shot Learning”. In: *Advances in Neural Information Processing Systems*. Vol. 35. 2022, pp. 23716–23736. URL: https://papers.nips.cc/paper_files/paper/2022/hash/960a172bc7fbf0177ccccbb411a7d Abstract-Conference.html.
- [0] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing”. In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5.
- [0] Yin Cui et al. “Class-Balanced Loss Based on Effective Number of Samples”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, pp. 9268–9277. URL: https://openaccess.thecvf.com/content_CVPR_2019/html/Cui_Class-Balanced_Loss_Based_on_Effective_Number_of_Samples_CVPR_2019_paper.html.
- [0] Kaiming He et al. “Deep Residual Learning for Image Recognition”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016.
- [0] Dan Hendrycks and Kevin Gimpel. “A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks”. In: *International Conference on Learning Representations*. 2017. URL: <https://arxiv.org/abs/1610.02136>.

- [0] Edward J. Hu et al. “LoRA: Low-Rank Adaptation of Large Language Models”. In: *International Conference on Learning Representations*. 2022. URL: <https://openreview.net/forum?id=nZeVKeeFYf9>.
- [0] Gao Huang et al. “Densely Connected Convolutional Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017.
- [0] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [0] Yijin Huang et al. “Fine-grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-resolution Medical Image Classification”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15012. Springer Nature Switzerland, 2024, pp. 120–130. DOI: 10.1007/978-3-031-72390-2_12.
- [0] Andrew Jaegle et al. “Perceiver: General Perception with Iterative Attention”. In: *Proceedings of the 38th International Conference on Machine Learning*. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 4651–4664. URL: <https://proceedings.mlr.press/v139/jaegle21a.html>.
- [0] Taha Koleilat et al. “BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models”. In: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*. 2025, pp. 14766–14776.
- [0] Zhengfeng Lai et al. “CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*. 2023, pp. 2374–2380.
- [0] Kimin Lee et al. “A Simple Unified Framework for Detecting Out-of-Distribution Samples and Adversarial Attacks”. In: *Advances in Neural Information Processing Systems*. Vol. 31. 2018, pp. 7167–7177.

URL: <https://proceedings.neurips.cc/paper/2018/hash/abdeb6f575ac5c6676b747bca8d09cc2-Abstract.html>.

- [0] Bo Li et al. *LLaVA-NeXT: What Else Influences Visual Instruction Tuning Beyond Data?* May 25, 2024. URL: <https://llava-vl.github.io/blog/2024-05-25-llava-next-ablations/> (visited on 07/25/2026).
- [0] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: <https://arxiv.org/abs/2306.00890>.
- [0] Yitong Li, Morteza Ghahremani, and Christian Wachinger. “Adapting Foundation Vision-Language Models to Medical Diagnosis via Query-Driven Expert Bridging”. In: (May 15, 2026). Version 3. arXiv: 2505.21698 [cs.CV].
- [0] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: <https://arxiv.org/abs/2401.12215>.
- [0] Shiyu Liang, Yixuan Li, and R. Srikant. “Enhancing the Reliability of Out-of-Distribution Image Detection in Neural Networks”. In: *International Conference on Learning Representations*. 2018.
- [0] Weitang Liu et al. “Energy-based Out-of-distribution Detection”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 21464–21475. URL: <https://proceedings.neurips.cc/paper/2020/hash/f5496252609c43eb8a3d147ab9b9c006-Abstract.html>.
- [0] Xueyan Mei et al. “Artificial intelligence-enabled rapid diagnosis of patients with COVID-19”. In: *Nature Medicine* 26 (Aug. 2020), 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: <https://www.nature.com/articles/s41591-020-0931-3>.
- [0] Michael Moor et al. *Med-Flamingo: a Multimodal Medical Few-shot Learner*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.15189. URL: <https://arxiv.org/abs/2307.15189>.

- [0] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.
- [0] Bryan C Russell et al. “LabelMe: a database and web-based tool for image annotation”. In: *International journal of computer vision* 77.1-3 (2008), pp. 157–173.
- [0] Jake Snell, Kevin Swersky, and Richard S. Zemel. “Prototypical Networks for Few-shot Learning”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017, pp. 4077–4087. URL: https://papers.nips.cc/paper_files/paper/2017/hash/cb8da6767461f2812ae4290Abstract.html.
- [0] Tao Tu et al. *Towards Generalist Biomedical AI*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.14334. URL: <https://arxiv.org/abs/2307.14334>.
- [0] Xiaosong Wang et al. “TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018.
- [0] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, Dec. 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: <https://aclanthology.org/2022.emnlp-main.256/>.
- [0] Yandong Wen et al. “A discriminative feature learning approach for deep face recognition”. In: *Lecture Notes in Computer Science* (2016), 499–515. DOI: 10.1007/978-3-319-46478-7_31.

- [0] Shunhan Yao et al. “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors”. In: *Scientific Data* 12.1 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y. URL: <https://doi.org/10.1038/s41597-024-04311-y>.
- [0] Jiajin Zhang et al. “Disease-informed Adaptation of Vision-Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15011. Springer Nature Switzerland, 2024.
- [0] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoa2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoa2400640>.
- [0] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 7th Machine Learning for Healthcare Conference*. Ed. by Zachary Lipton et al. Vol. 182. Proceedings of Machine Learning Research. PMLR, 2022, pp. 2–25. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
- [0] Hong-Yu Zhou et al. “A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics”. In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).

Phụ lục A

Chi tiết chuẩn bị và kiểm tra bộ dữ liệu BTXRD

Phụ lục này bổ sung các thông tin kỹ thuật cần thiết để tái lập phần chuẩn bị dữ liệu BTXRD, bao gồm cấu trúc lưu trữ, kiểm tra tính toàn vẹn, chuẩn hóa nhãn, phân chia dữ liệu, xây dựng văn bản tổng hợp và tạo đầu vào ảnh. Các thống kê được tính trực tiếp từ phiên bản dữ liệu trong thư mục `data/BTXRD`; vì vậy, chúng phản ánh chính xác dữ liệu được mã nguồn hiện tại sử dụng thay vì chỉ lặp lại mô tả của bài báo công bố.

A.1 Cấu trúc lưu trữ và lược đồ dữ liệu

Bảng ?? mô tả vai trò của từng thành phần trên đĩa. Tên tệp ảnh trong `image_id` được sử dụng làm khóa liên kết giữa metadata, nhãn, tập chia, ảnh và các báo cáo văn bản; tên không có phần mở rộng được sử dụng để truy cập các tệp JSON và TXT tương ứng.

Thành phần	Số tệp/hàng	Vai trò
<code>images/</code>	3.746	Lưu ảnh X-quang đầu vào.
<code>Annotations/</code>	1.867	Lưu chú thích JSON cho các ảnh có u; không được sử dụng trong huấn luyện phân loại.
<code>reports/</code> <code>clinical/</code>	3.746	Phiên bản bệnh sử tổng hợp cũ, chỉ được giữ để truy vết.
<code>reports/</code> <code>clinical_v2/</code>	3.746	Nguồn văn bản tổng hợp chuẩn được cấu hình cho các thí nghiệm chính.
<code>reports/</code> <code>xray/</code>	3.746	Mô tả X-quang tổng hợp từ nhân; không được sử dụng trong thiết lập phân loại chính.
<code>dataset.csv</code>	3.746	Metadata gốc, gồm định danh ảnh, mã nguồn, tuổi, giới tính, vị trí giải phẫu, tư thế chụp và các cờ bệnh lý.
<code>btxrd-labels.csv</code>	3.746	Manifest chứa định danh ảnh và 10 cột chỉ báo lớp.
<code>btxrd-split.csv</code>	3.746	Manifest ánh xạ mỗi ảnh vào <code>train</code> , <code>validate</code> hoặc <code>test</code> .

Bảng A.1: Cấu trúc lưu trữ của bộ dữ liệu BTXRD trong nghiên cứu

Các cột trong `dataset.csv` có thể được chia thành năm nhóm: định danh và nguồn gồm `image_id`, `center`; nhân khẩu học gồm `age`, `gender`; vị trí giải phẫu gồm các chỉ báo xương, khớp và ba vùng `upper limb`, `lower limb`, `pelvis`; trạng thái bệnh gồm `tumor`, `benign`, `malignant` và chín phân nhóm tổn thương; tư thế chụp gồm `frontal`, `lateral`, `oblique`. Không phát hiện giá trị thiếu ở ba trường `center`, `age`, `gender`; mỗi mẫu có ít nhất một chỉ báo vị trí giải phẫu và ít nhất một chỉ báo tư thế chụp.

A.2 Kiểm tra tính toàn vẹn và đặc điểm tệp ảnh

Kiểm tra định danh cho thấy ba tệp CSV đều có 3.746 định danh duy nhất và không có hàng lặp theo `image_id`. Tập định danh của các tệp ảnh và của ba thư mục báo cáo khớp hoàn toàn với `dataset.csv`; không phát hiện ảnh, nhân, split hoặc báo cáo bị thiếu hay không có metadata tương ứng. Số tệp JSON bằng đúng số mẫu có `tumor=1`, vì vậy 1.879 ảnh bình thường không có chú thích vùng tổn thương là phù hợp với tổ chức dữ liệu nguồn.

Thành phần	Tổng	Định danh lặp	Thiếu	Dư
<code>dataset.csv</code>	3.746	0	0	0
<code>btxrd-labels.csv</code>	3.746	0	0	0
<code>btxrd-split.csv</code>	3.746	0	0	0
Ảnh	3.746	0	0	0
<code>clinical_v2</code>	3.746	0	0	0
<code>xray</code>	3.746	0	0	0

Bảng A.2: Kết quả kiểm tra tính toàn vẹn của các thành phần BTXRD

Bảng ?? cho thấy dữ liệu ảnh có định dạng không hoàn toàn đồng nhất. Mặc dù tất cả tệp đều mang phần mở rộng JPEG, kiểm tra bằng Pillow xác định 3.744 tệp được mã hóa JPEG, một tệp được mã hóa BMP và một tệp được nhận diện là MPO; toàn bộ 3.746 tệp vẫn giải mã thành công. Loader chuyển mọi ảnh sang RGB trước khi tạo tensor, do đó sự khác biệt giữa ảnh một kênh và ba kênh không làm thay đổi số kênh đầu vào của mô hình.

Thuộc tính	Kết quả kiểm tra
Phần mở rộng	3.719 tệp <code>.jpeg</code> và 27 tệp <code>.jpg</code> .
Chế độ màu khi giải mã	2.895 ảnh thang xám L và 851 ảnh RGB.
Định dạng mã hóa	3.744 JPEG, 1 BMP và 1 MPO.
Chiều rộng	Nhỏ nhất 153 px, trung vị 1.612 px, lớn nhất 3.594 px.
Chiều cao	Nhỏ nhất 311 px, trung vị 2.256 px, lớn nhất 4.881 px.
Khả năng giải mã	3.746/3.746 tệp được đọc thành công.

Bảng A.3: Đặc điểm kỹ thuật của các tệp ảnh BTXRD

A.3 Chuẩn hóa nhãn và phân chia dữ liệu

Từ `dataset.csv`, nhãn `normal` được tạo theo quy tắc $\mathbb{I}(\text{tumor} = 0)$, sau đó được ghép với chín chỉ báo bệnh lý để tạo `btxrd-labels.csv`. Dữ liệu gốc có 3.745 hàng mang một chỉ báo lớp và một hàng mang đồng thời hai chỉ báo do quan hệ phân cấp. Khi loader đọc dữ liệu, nhãn cha `osteochondroma` được đặt về 0 nếu `multiple osteochondromas` hoặc

synovial osteochondroma hoạt động; sau bước này, toàn bộ 3.746 hàng đều thỏa điều kiện đơn nhãn.

Algorithm 1 Chuẩn hóa nhãn và tạo tập chia BTXRD

Require: Bảng metadata D , danh sách lớp có thứ tự C và seed $s = 42$

Ensure: Manifest nhãn L và manifest phân chia S

```

1: Tạo  $D[normal] \leftarrow \mathbb{I}(D[tumor] = 0)$ 
2: Tạo  $L \leftarrow D[image\_id \cup C]$ 
3:  $(L_{tv}, L_{te}) \leftarrow \text{RANDOMSPLIT}(L, 0, 20, s)$ 
4:  $(L_{tr}, L_{va}) \leftarrow \text{RANDOMSPLIT}(L_{tv}, 0, 125, s)$ 
5: Gán các giá trị train, validate và test để tạo  $S$ 
6: for all mẫu  $i$  khi loader đọc  $L$  do
7:   if  $L_{i,multiple} = 1$  hoặc  $L_{i,synovial} = 1$  then
8:     Đặt  $L_{i,osteochondroma} \leftarrow 0$ 
9:   Kiểm tra  $\sum_{c \in C} L_{ic} = 1$ 
10:  Gán  $class\_id_i \leftarrow \arg \max_{c \in C} L_{ic}$ 
11: return  $L, S$ 

```

Hai lời gọi `train_test_split` không truyền tham số `stratify`; vì vậy, tỷ lệ xấp xỉ 70/10/20 chỉ được kiểm soát theo tổng số ảnh, không được bảo đảm riêng cho từng lớp. Phép chia cũng không thể kiểm soát theo bệnh nhân vì metadata không cung cấp khóa bệnh nhân. Đây là giới hạn của manifest hiện tại và cần được phân biệt với phép chia theo bệnh nhân của những bộ dữ liệu có định danh người bệnh.

Ngoài kiểm tra định danh, nội dung ảnh được băm bằng SHA-256 để phát hiện tệp trùng tuyệt đối. Kết quả có 21 nhóm, mỗi nhóm gồm hai tệp có cùng nội dung byte; 16 nhóm nằm hoàn toàn trong một tập và 5 nhóm đi qua ranh giới train–validate hoặc train–test. Bảng ?? liệt kê đầy đủ năm cặp liên tập; bốn cặp có cùng nhãn, trong khi cặp `IMG000707.jpeg–IMG003346.jpeg` lần lượt mang nhãn *osteochondroma* và *normal*.

Ảnh thứ nhất	Tập	Ảnh thứ hai	Tập	Quan hệ nhãn
IMG000245.jpeg	Train	IMG000683.jpeg	Test	Cùng lớp <i>simple bone cyst</i> .
IMG000415.jpeg	Test	IMG000497.jpeg	Train	Cùng lớp <i>giant cell tumor</i> .
IMG000707.jpeg	Train	IMG003346.jpeg	Validate	Khác lớp: <i>osteochondroma/normal</i> .
IMG001721.jpeg	Validate	IMG001799.jpeg	Train	Cùng lớp <i>osteochondroma</i> .
IMG001950.jpeg	Train	IMG002173.jpeg	Test	Cùng lớp <i>normal</i> .

Bảng A.4: Các cặp ảnh BTXRD trùng nội dung tuyệt đối nhưng nằm ở các tập khác nhau

Các split đã được dùng để huấn luyện toàn bộ mô hình nên được giữ nguyên trong báo cáo kết quả nhằm bảo đảm khả năng đối chiếu giữa các thí nghiệm. Tuy nhiên, năm cặp ảnh liên tập tạo nguy cơ rò rỉ ở mức ảnh và một cặp còn cho thấy bất nhất nhãn; vì vậy, kết quả trên split hiện tại không nên được diễn giải như ước lượng hoàn toàn độc lập ở mức người bệnh. Một đánh giá tiếp theo nên loại trùng trước khi chia lại theo nhóm ảnh hoặc bệnh nhân, nếu định danh bệnh nhân có thể được bổ sung.

A.4 Văn bản BTXRD

BTXRD không có báo cáo bệnh sử tự do đi kèm từng ảnh. Ba thư mục văn bản hiện có đều được sinh ngoại tuyến từ metadata với seed 42, trong đó `clinical` là phiên bản cũ, `clinical_v2` là nguồn chuẩn của thiết lập hiện tại và `xray` là mô tả được tạo trực tiếp từ nhãn. Việc tách ba nguồn giúp tránh sử dụng nhầm văn bản chứa tên lớp trong các thí nghiệm phân loại chính.

`clinical_v2` sử dụng tuổi, giới tính, vị trí xương hoặc khớp, vùng giải phẫu, tư thế chụp, số xương được đánh dấu, mức liên quan khớp và nhóm trạng thái bình thường–lành tính–ác tính. Các trường đầu ra gồm *Patient*, *Reason for admission*, *Disease history*, *Physical examination*, *Personal medical history* và *Radiographic evaluation*. Quy trình không chèn tên của 10 lớp đích, nhưng việc lựa chọn mẫu câu vẫn phụ thuộc vào `tumor` và `malignant`; vì vậy, văn bản giảm rò rỉ từ khóa trực tiếp nhưng vẫn chứa tín hiệu có điều kiện liên quan đến nhãn.

`xray` sử dụng trực tiếp phân nhóm bệnh và các mô tả X-quang điển hình, do đó có thể nêu tên lớp hoặc mô tả đặc hiệu của lớp. Nguồn này được giữ để kiểm tra dữ liệu và minh họa, không được lựa chọn bởi `p1_report_type` hoặc `p2_report_type` trong cấu hình proposed chính của BTXRD.

Algorithm 2 Sinh và nạp văn bản BTXRD

Require: Hàng metadata r , định danh ảnh u và seed $s = 42$

Ensure: Chuỗi token lâm sàng $t_{clinical}$

- 1: Đọc tuổi, giới tính, vị trí, tư thế chụp, số xương và khớp liên quan từ r
 - 2: Xác định nhóm mẫu câu từ `tumor` và `malignant`
 - 3: Chọn các mẫu câu bằng bộ sinh giả ngẫu nhiên có seed s
 - 4: Ghép các trường thành báo cáo `clinical_v2` mà không chèn tên lớp cụ thể
 - 5: Lưu báo cáo tại `reports/clinical_v2/{stem(u)}.txt`
 - 6: Đọc báo cáo theo stem của u và thay bằng câu mặc định nếu tệp thiếu hoặc rỗng
 - 7: Chuẩn hóa $h \leftarrow \text{lower}(\text{strip}(h))$
 - 8: Mã hóa $t_{clinical} \leftarrow \text{TOKENIZER}(h)$
 - 9: **return** $t_{clinical}$
-

Bảng ?? tổng hợp kiểm tra các báo cáo thực tế trên đĩa. Không có tệp rỗng trong cả ba nguồn. `clinical_v2` có 3.745 nội dung duy nhất trên 3.746 tệp, trong khi `xray` chỉ có 1.555 nội dung duy nhất do sử dụng tập mẫu câu phụ thuộc mạnh vào lớp. Phép tìm kiếm không phân biệt hoa-thường đối với tên các lớp cụ thể không ghi nhận lần xuất hiện nào trong `clinical_v2`, nhưng phát hiện các tên bệnh tương ứng trong `xray`; kiểm tra này chỉ xác nhận việc không chèn tên lớp trực tiếp và không loại trừ tín hiệu nhãn gián tiếp.

Nguồn	Tệp	Rỗng	Duy nhất	Từ nhỏ nhất	Trung vị	Từ lớn nhất
<code>clinical</code>	3.746	0	3.684	40	51	89
<code>clinical_v2</code>	3.746	0	3.745	44	56	91
<code>xray</code>	3.746	0	1.555	19	25	42

Bảng A.5: Thống kê các nguồn văn bản BTXRD trên đĩa

A.5 Tạo đầu vào ảnh tại thời điểm nạp dữ liệu

Thiết lập chính sử dụng chiến lược `sparse_focal`. Mỗi tệp ảnh được giải mã và chuyển sang RGB, sau đó thuật toán ước lượng vùng tiền cảnh

từ cường độ pixel mà không truy cập nhãn, văn bản hoặc chú thích JSON. Một ảnh toàn cục được tạo bằng letterbox về 224×224 ; đồng thời, ảnh nguồn được dùng để chọn bốn vùng cục bộ có kích thước 224×224 , tạo thành tensor có ngân sách cố định cho bộ mã hóa ảnh.

Điểm của cửa sổ cục bộ thứ j kết hợp năng lượng biên Laplacian đã chuẩn hóa $\tilde{E}_j^{lap}$, entropy mức xám đã chuẩn hóa $\tilde{H}_j$ và tỷ lệ tiền cảnh R_j^{fg} theo Công thức ??.

$$s_j = 0,55 \tilde{E}_j^{lap} + 0,35 \tilde{H}_j + 0,10 R_j^{fg}. \quad (\text{A.1})$$

Trong Công thức ??, s_j là điểm thông tin của cửa sổ j ; $\tilde{E}_j^{lap}$ phản ánh mức biến thiên cục bộ và biên; $\tilde{H}_j$ phản ánh độ đa dạng cường độ; R_j^{fg} biểu thị tỷ lệ pixel thuộc vùng tiền cảnh. Hai vùng đầu được ưu tiên để tăng độ phủ giải phẫu, các vùng còn lại được chọn theo điểm thông tin kết hợp độ đa dạng không gian và NMS, sau đó tọa độ được chuẩn hóa về khoảng $[0, 1]$.

Algorithm 3 Tạo đầu vào ảnh `sparse_focal` cho một mẫu BTXRD

Require: Ảnh X , số vùng $K = 4$, kích thước vùng $p = 224$ và stride $d = 168$

Ensure: Ảnh toàn cục G , tập vùng cục bộ T và tọa độ chuẩn hóa B

- 1: Chuyển X sang RGB và ước lượng vùng tiền cảnh từ dải biên ảnh
 - 2: Tạo $G \leftarrow \text{LETTERBOX}(X, 224)$
 - 3: Tạo canvas có cạnh dài tối đa 896 mà không phóng lớn ảnh nhỏ
 - 4: Sinh các cửa sổ 224×224 với stride 168
 - 5: **for all** cửa sổ ứng viên w_j **do**
 - 6: Tính $\tilde{E}_j^{lap}$, $\tilde{H}_j$, R_j^{fg} và s_j
 - 7: Chọn các vùng theo độ phủ, s_j , độ đa dạng không gian và NMS
 - 8: Bổ sung theo thứ tự xác định nếu chưa đủ K vùng
 - 9: Letterbox từng vùng về 224×224 và chuẩn hóa tọa độ về $[0, 1]$
 - 10: **return** G, T, B
-

A.6 Ví dụ truy vết dữ liệu trước và sau xử lý

Bảng ?? sử dụng trực tiếp mẫu `IMG000001.jpeg` trong thư mục dữ liệu để minh họa quan hệ giữa ảnh, metadata và hai nguồn văn bản. Vì BTXRD không cung cấp bệnh sử tự do, cột nguồn ban đầu là các trường metadata có cấu trúc; cả hai đoạn văn bản bên phải đều là dữ liệu dẫn xuất chứ không phải báo cáo nguyên bản của bác sĩ.

Ảnh	Metadata nguồn	Văn bản sau xử lý ngoại tuyến
	<pre>age=48; gender=F; hip bone=1; pelvis=1; frontal=1; tumor=1; malignant=1; other mt=1.</pre>	clinical_v2: Patient: 48-year-old female. Reason for admission: Pain and swelling of the hip bone. Disease history: Pain in the hip bone for 1 month; associated with decreased appetite. Physical examination: Palpable mass; tenderness on palpation; mild swelling. Personal medical history: No prior bone disease or fracture. No relevant surgical or medical history. Radiographic evaluation: AP view of the hip bone was obtained. Nhân đơn sau chuẩn hóa là <i>other mt</i>. xray: A musculoskeletal radiograph of the bone in standard projection with evidence of other mt: a destructive bone lesion with ill-defined borders suggestive of malignancy. In a high-resolution diagnostic acquisition. The imaging features raise concern for malignancy.

Bảng A.6: Ví dụ ảnh, metadata và văn bản dẫn xuất của BTXRD

Ví dụ cho thấy báo cáo X-quang tổng hợp nêu trực tiếp nhãn **other mt**, trong khi bệnh sử tổng hợp không chứa tên lớp nhưng mô tả triệu chứng được lựa chọn từ nhóm mẫu câu ác tính. Khi loader nạp mẫu, bệnh sử được loại khoảng trắng ở hai đầu, chuyển về chữ thường và mã hóa bằng tokenizer của backbone; ảnh được chuyển thành một tensor toàn cục cùng bốn tensor vùng cục bộ. Cách truy vết này làm rõ nguồn gốc của từng phương thức và giới hạn của việc xem văn bản tổng hợp như bệnh sử độc lập.

Phụ lục B

Chi tiết chuẩn bị và kiểm tra bộ dữ liệu CTCH

Phụ lục này mô tả quy trình chuẩn bị CTCH ở mức phương pháp luận nhằm hỗ trợ tái lập và đánh giá tính hợp lệ của dữ liệu. Tên tệp, cấu trúc thư mục và định danh nội bộ của mã nguồn được lược bỏ vì không đóng góp trực tiếp cho việc hiểu thiết kế thực nghiệm; thay vào đó, nội dung tập trung vào tiêu chí lựa chọn mẫu, cách hình thành nhãn, nguyên tắc chia tập, nguồn gốc văn bản và các phép kiểm tra toàn vẹn.

B.1 Sàng lọc và hình thành các quần thể

Dữ liệu nguồn gồm 3.641 hồ sơ đã được lựa chọn sơ bộ từ các ca khám tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh. Mỗi hồ sơ liên kết thông tin bệnh án với một ảnh đại diện cho vị trí cần khảo sát. Quá trình sàng lọc tiếp tục loại những ca có nếp, dính hoặc phương tiện kết hợp xương vì các cấu trúc này có thể che khuất tổn thương và tạo dấu hiệu thị giác ngoài mục tiêu phân loại.

Trong phiên bản hiện tại, 348 hồ sơ có dụng cụ y tế bị loại; không có hồ sơ bị đánh dấu xóa và không có hồ sơ thiếu ảnh đã lựa chọn. Phần còn lại gồm 3.293 mẫu, được tách thành 3.249 mẫu trong phân phối phục vụ

phân loại và 44 mẫu ngoài phân phối về ngữ nghĩa. Hai quần thể không giao nhau theo ảnh hoặc theo mã nhóm người bệnh.

Giai đoạn	Số hồ sơ
Hồ sơ nguồn	3.641
Loại do có dụng cụ y tế	348
Còn lại sau sàng lọc	3.293
Quần thể trong phân phối	3.249
Quần thể ngoài phân phối	44

Bảng B.1: Dòng dữ liệu qua các bước sàng lọc CTCH

Quần thể ngoài phân phối gồm 34 mẫu thuộc nhóm chấn thương và 10 mẫu thuộc nhóm viêm nhiễm, nhưng biểu hiện cụ thể không thuộc 22 lớp đích. Cách tổ chức này tạo một kịch bản Semantic OOD trong cùng nguồn bệnh viện, qua đó giảm mức trộn lẫn giữa sai lệch ngữ nghĩa với thay đổi thiết bị hoặc cơ sở thu nhận. Tuy nhiên, số lượng 44 mẫu còn nhỏ nên khoảng bất định của các độ đo OOD cần được trình bày và kết quả không nên được khái quát thành mọi dạng bất thường lâm sàng.

B.2 Chuẩn hóa nhãn và phân chia theo người bệnh

Tên lớp được chuẩn hóa về cùng biểu diễn Unicode, loại khoảng trắng không cần thiết và đối chiếu không phân biệt chữ hoa với chữ thường. Mỗi mẫu trong phân phối được ánh xạ vào một lớp duy nhất trong danh sách 22 lớp có thứ tự cố định, sau đó được kiểm tra để bảo đảm không có mẫu thiếu nhãn, đa nhãn hoặc nằm ngoài miền lớp hợp lệ.

Phép chia được thực hiện trên mã nhóm người bệnh thay vì trên ảnh riêng lẻ. Đối với mỗi người bệnh, lớp xuất hiện nhiều nhất được xem là lớp chính để hỗ trợ phân bổ; danh sách người bệnh trong từng lớp được xáo trộn bằng hạt giống 42 và phân chia theo tỷ lệ mục tiêu 70/10/20. Với những lớp có ít nhất ba người bệnh, quy trình cố gắng dành tối thiểu một người cho mỗi tập.

Algorithm 4 Chuẩn hóa và phân chia dữ liệu CTCH

Require: Bảng bệnh án đã mã hóa định danh, ảnh đã lựa chọn và danh sách 22 lớp đích

Ensure: Ba tập trong phân phối và một quần thể ngoài phân phối độc lập

- 1: Loại hồ sơ bị đánh dấu xóa, hồ sơ có dụng cụ y tế và hồ sơ không có ảnh đại diện
 - 2: Tách các mẫu được xác định nằm ngoài không gian 22 lớp khỏi quần thể phân loại
 - 3: Chuẩn hóa tên lớp và ánh xạ mỗi mẫu trong phân phối vào đúng một lớp
 - 4: Tạo mã nhóm từ mã người bệnh; sử dụng mã ca khám khi mã người bệnh không có
 - 5: Xác định lớp chính của từng người bệnh theo tần suất xuất hiện
 - 6: Xáo trộn người bệnh trong từng lớp bằng hạt giống 42
 - 7: Phân bổ người bệnh vào tập huấn luyện, xác thực và kiểm thử theo tỷ lệ mục tiêu 70/10/20
 - 8: Kiểm tra ba tập không giao nhau theo người bệnh và không giao với quần thể ngoài phân phối
-

Kết quả phân chia có 2.265 người bệnh trong tập huấn luyện, 315 người bệnh trong tập xác thực và 669 người bệnh trong tập kiểm thử. Mỗi người bệnh trong phiên bản dữ liệu hiện tại đóng góp một ảnh đã lựa chọn, do đó số người bệnh bằng số ảnh ở từng tập. Kiểm tra giao tập cho kết quả bằng 0 đối với cả ba cặp huấn luyện–xác thực, huấn luyện–kiểm thử và xác thực–kiểm thử.

B.3 Xây dựng và dịch dữ liệu văn bản

Bệnh sử lâm sàng được ghép từ ba nhóm thông tin: lý do vào viện, diễn tiến bệnh và tiền sử bản thân. Mô tả X-quang được ghép từ tóm tắt khám và cận lâm sàng cùng phần tổng hợp kết quả khảo sát. Mỗi trường không rỗng được đặt sau một tiền tố ngữ nghĩa thống nhất; nếu toàn bộ nguồn của một loại báo cáo không có nội dung, một thông báo trung tính

được sử dụng để tránh suy diễn thông tin không tồn tại.

Nguồn văn bản	Thông tin được sử dụng	Thông tin không nổi trực tiếp
Bệnh sử lâm sàng	Lý do vào viện, diễn tiến bệnh và tiền sử bản thân.	Nhân phân loại và chẩn đoán xác định.
Mô tả X-quang	Tóm tắt khám, cận lâm sàng và tổng hợp kết quả khảo sát.	Nhân phân loại và trường chẩn đoán xác định riêng biệt.

Bảng B.2: Nguồn nội dung dùng để hình thành hai phương thức văn bản CTCH

Nội dung tiếng Việt được chuẩn hóa Unicode, loại khoảng trắng thừa và dịch sang tiếng Anh theo từng trường để giữ cấu trúc báo cáo. Những đoạn đã dịch được tái sử dụng nhằm giảm sai khác giữa các lần xử lý. Khi dịch vụ không trả về kết quả hợp lệ trong chế độ chuẩn bị thông thường, đoạn tiếng Việt gốc được giữ lại; đối với quy trình khôi phục quần thể ngoài phân phối, lỗi dịch được báo cáo thay vì tự động tạo nội dung thay thế.

Việc không nổi trực tiếp nhân và chẩn đoán xác định làm giảm nguy cơ rò rỉ từ trường đích, nhưng không bảo đảm văn bản độc lập hoàn toàn với lớp. Các mô tả do bác sĩ ghi trong phần khám hoặc khảo sát vẫn có thể nêu vị trí gãy, loại tổn thương hoặc nhận định chuyên môn. Vì vậy, văn bản CTCH được xem là bằng chứng lâm sàng đồng hành với ảnh, không phải một phương thức đã loại bỏ mọi thông tin chẩn đoán.

Bảng ?? thống kê 3.293 báo cáo thuộc hai quần thể được sử dụng. Không có báo cáo rỗng hoặc thiếu ở bốn phiên bản. Số nội dung duy nhất thấp hơn số mẫu vì một số hồ sơ có cùng cách diễn đạt, đặc biệt ở mô tả X-quang; điều này phản ánh tính lặp lại của thuật ngữ lâm sàng và cần được cân nhắc khi phân tích mức đóng góp của văn bản.

Nguồn	Số báo cáo	Rỗng	Duy nhất	Từ nhỏ nhất	Trung vị	Từ lớn nhất
Bệnh sử tiếng Việt	3.293	0	3.154	7	42	113
Bệnh sử tiếng Anh	3.293	0	3.151	7	41	119
Mô tả X-quang tiếng Việt	3.293	0	2.696	10	23	116
Mô tả X-quang tiếng Anh	3.293	0	2.609	8	24	116

Bảng B.3: Thống kê văn bản CTCH thuộc quần thể được sử dụng

B.4 Chuẩn bị ảnh và kiểm tra toàn vẹn

Toàn bộ ảnh được sử dụng có định dạng JPEG và được giải mã thành ba kênh màu. Chiều rộng dao động từ 1.186 đến 2.836 pixel với trung vị 1.213 pixel; chiều cao dao động từ 1.213 đến 2.880 pixel với trung vị 1.713 pixel. Trước khi đưa vào mô hình, ảnh được chuyển về cùng không gian màu và xử lý bằng chiến lược ảnh toàn cục kết hợp bốn vùng cục bộ có ngân sách cố định như mô tả ở Phụ lục BTRD.

Kiểm tra SHA-256 trên toàn bộ 3.464 ảnh đang lưu trữ không phát hiện hai tệp có nội dung byte giống nhau. Trong số này, 3.293 ảnh thuộc hai quần thể được sử dụng và 171 ảnh là phần dư từ các lần chuẩn bị trước, không được tham chiếu bởi bảng phân chia hiện hành. Tương tự, mỗi nguồn báo cáo trên đĩa có 5.212 tệp, trong đó 3.293 tệp được sử dụng và 1.919 tệp cũ được loại khỏi thực nghiệm thông qua bảng ánh xạ mẫu.

Nội dung kiểm tra	Kết quả	Diễn giải
Mẫu trong phân phối có đủ ảnh và bốn phiên bản văn bản	3.249/3.249	Không phát hiện thành phần bất buộc bị thiếu.
Mẫu ngoài phân phối có đủ ảnh và bốn phiên bản văn bản	44/44	Quần thể OOD có đủ hai phương thức cho suy luận.
Giao người bệnh giữa ba tập phân loại	0	Không phát hiện rò rỉ người bệnh giữa các tập.
Giao người bệnh giữa hai quần thể	0	Quần thể trong và ngoài phân phối độc lập theo người bệnh.
Nhóm ảnh trùng nội dung tuyệt đối	0	Không phát hiện ảnh trùng theo SHA-256.
Ảnh lưu trữ không thuộc quần thể hiện hành	171	Không được truy cập trong thực nghiệm.
Báo cáo cũ không thuộc quần thể hiện hành ở mỗi nguồn	1.919	Không được truy cập trong thực nghiệm.

Bảng B.4: Tóm tắt kiểm tra toàn vẹn CTCH

Các kiểm tra trên xác nhận tập dữ liệu được dùng trong thí nghiệm có độ phủ đầy đủ và không có giao nhau theo người bệnh. Tuy nhiên, CTCH vẫn là dữ liệu đơn trung tâm, có phân bố lớp mất cân bằng, phụ thuộc vào quá trình lựa chọn một ảnh đại diện và sử dụng bản dịch tự động cho bộ

mã hóa tiếng Anh. Đây là các giới hạn cần được giữ trong phần diễn giải kết quả và trong đánh giá khả năng khái quát sang bệnh viện khác.