

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - Nguyễn Gia Kiệt

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

TP. HỒ CHÍ MINH, THÁNG 08/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - 22127390

Nguyễn Gia Kiệt - 22127221

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

GIÁO VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

TP. HỒ CHÍ MINH, THÁNG 08/2026

Lời cam đoan

Nhóm xin cam đoan đây là công trình nghiên cứu của riêng nhóm. Dữ liệu và kết quả nghiên cứu trong luận văn này là trung thực và không trùng lặp với bất kỳ chủ đề nào khác. Nhóm cam đoan toàn bộ nội dung luận văn này không đạo văn hoặc sao chép từ các công trình nghiên cứu khác. Ngoài ra, trong quá trình nghiên cứu và viết luận văn, nhóm tuân thủ nghiêm ngặt các quy định về bảo mật do các tập dữ liệu nhóm sử dụng trong nghiên cứu của mình cung cấp. Hơn nữa, nhóm luôn tuân thủ mọi nguyên tắc đạo đức trong suốt quá trình nghiên cứu. Nhóm đảm bảo rằng tất cả các nguồn và tài liệu tham khảo đều được trích dẫn đúng cách và nhóm duy trì tính chính trực học thuật trong mọi khía cạnh công việc của mình.

Lời cảm ơn

Nhóm xin chân thành cảm ơn PGS.TS Lý Quốc Ngọc và ThS. Đỗ Thị Thanh Hà đã dành rất nhiều thời gian, tâm huyết để định hướng, tận tình hướng dẫn và đưa ra những lời khuyên quý báu cho nhóm trong suốt quá trình nghiên cứu và thực hiện khóa luận tốt nghiệp với đề tài "Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức".

Xin trân trọng gửi lời cảm ơn sâu sắc đến Ban Chủ nhiệm cùng toàn thể quý thầy cô Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG-HCM. Những kiến thức nền tảng vững chắc mà các thầy cô đã truyền đạt trong bốn năm học vừa qua và môi trường thí nghiệm tuyệt vời chính là hành trang quan trọng nhất giúp nhóm có thể hoàn thành tốt hướng nghiên cứu này.

Nhóm cũng xin gửi lời cảm ơn đến các y bác sĩ tại Bệnh viện Chấn thương Chỉnh hình TP.HCM, thầy Đỗ Phúc Thịnh và thầy Võ Thế Hào đã hỗ trợ chia sẻ nguồn dữ liệu ảnh X-quang cũng như tư vấn các kiến thức chuyên môn về y khoa, giúp mô hình nghiên cứu bám sát với quy trình chẩn đoán thực tế.

Mặc dù đã có nhiều cố gắng trong quá trình thực hiện, nhưng do hạn chế về mặt thời gian và kinh nghiệm nghiên cứu, khóa luận chắc chắn không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô và hội đồng đánh giá để đề tài được hoàn thiện hơn.

Xin chân thành cảm ơn!



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO HỌC SÂU ĐA PHƯƠNG THỨC

*(Developing a bone X-ray image classification
system based on multimodal deep learning)*

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm Sinh viên thực hiện:

1. Nguyễn Văn Lê Bá Thành (MSSV: 22127390)
2. Nguyễn Gia Kiệt (MSSV: 22127221)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 02/2026 đến 08/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn đầu. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, các nghiên cứu hiện nay đã ứng dụng các mô hình học sâu vào để giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ để đưa vào ứng dụng thực tế. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để bổ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác. Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống.

Khác với các mô hình đơn phương thức chỉ xử lý trên một phương thức như ảnh hay văn bản duy nhất, các mô hình đa phương thức có thể sử dụng nhiều phương thức và tìm ra sự tương quan giữa các phương thức nhằm tạo nên biểu diễn có ý nghĩa hơn từ đó nâng cao hiệu năng của hệ thống. Với thực tế lâm sàng hiện nay, các mô hình nghiên cứu tập trung

vào kết hợp ngôn ngữ và hình ảnh hay còn được gọi là mô hình ngôn ngữ trực quan đang là các mô hình đang nhận được nhiều sự chú ý.

2.2 Định nghĩa các khái niệm

Thông tin lâm sàng

Thông tin lâm sàng là những dữ liệu thu thập trực tiếp qua quá trình bác sĩ thăm khám người bệnh, bao gồm việc khai thác bệnh sử và khám thực thể (nhìn, sờ, gõ, nghe) [23]. Dữ liệu này mang tính chất định hướng ban đầu, giúp bác sĩ khoanh vùng tổn thương và đưa ra các quyết định chỉ định thăm khám chuyên sâu tiếp theo [2].

Thông tin cận lâm sàng

Thông tin cận lâm sàng là các dữ liệu khách quan thu được từ việc áp dụng các trang thiết bị và kỹ thuật y khoa hiện đại (như hình ảnh X-quang, cắt lớp, hay xét nghiệm sinh hóa) [23]. Nếu lâm sàng dùng để định hướng, thì cận lâm sàng cung cấp bằng chứng xác thực từ bên trong cơ thể để chẩn đoán chính xác bệnh lý.

2.3 Phát biểu bài toán

Đầu vào (Input)

Hệ thống nhận vào các nguồn dữ liệu sau:

- Thông tin lâm sàng bao gồm báo cáo cận lâm sàng, khám xét toàn thân, lý do vào viện của bệnh nhân.
- Ảnh X-quang xương của bệnh nhân tương ứng.
- Tập nhãn được định nghĩa trước.


Đầu ra (Output)

Hệ thống sẽ sinh ra các nhãn sau:

- Tỷ lệ mà ảnh và thông tin lâm sàng tương ứng thuộc vào các lớp được định nghĩa trước.
- Ảnh trực quan hóa giải thích cho kết quả.

Kiến trúc tổng quan

Với bài toán này, kiến trúc tổng quan của một mô hình học sâu đa phương thức được sử dụng bao gồm bốn thành phần chính: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại như được thể hiện ở Hình 1.



Hình 1: Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức

Trong đó, bộ mã hóa ảnh có chức năng rút trích đặc trưng từ ảnh đầu vào, bộ mã hóa văn bản có chức năng rút trích đặc trưng từ văn bản đầu vào, bộ dung hợp dữ liệu có chức năng dung hợp hay căn chỉnh các đặc trưng được rút trích từ hai phương thức dữ liệu trên để tạo ra một biểu diễn có ý nghĩa và có đầy đủ tính chất của phương thức đầu vào, đây cũng là mô-đun quan trọng nhất đối với một mô hình học sâu đa phương thức, cuối cùng là bộ phân loại, nhận biểu diễn đặc trưng chung của các phương thức đầu vào để phân loại và đưa ra kết quả cuối cùng.

2.4 Mục tiêu đề tài

Trong bối cảnh già hóa dân số và các tác nhân gây bệnh từ ô nhiễm và lối sống thiếu lành mạnh trong đời sống hiện đại, các bệnh lý về xương và chấn thương có thể ảnh hưởng trực tiếp đến đời sống và tính mạng dẫn đến việc chẩn đoán và tiên lượng để đưa ra hướng điều trị phù hợp đang trở thành gánh nặng cho các y bác sĩ, các hệ thống học sâu đa phương

thức tuy đã phát triển nhưng lại thiếu khả năng giải thích. Đề tài hướng đến phát triển một hệ thống phân loại ảnh X-quang có khả năng:

- Đạt được độ chính xác cao trên các bộ dữ liệu nội bộ và quốc tế.
- Có khả năng giải thích được kết quả.
- Tích hợp kết quả để trợ giúp y bác sĩ trong quá trình chẩn đoán.

2.5 Phạm vi của đề tài

Nội dung nghiên cứu của đề tài tập trung vào việc khảo sát các mô hình nền tảng và thiết kế, huấn luyện, tinh chỉnh, đánh giá kiến trúc được đề xuất trên ảnh X-quang xương và các bộ dữ liệu quốc tế để so sánh, đánh giá với các kiến trúc trước.

Đối tượng nghiên cứu xoay quanh các thành phần bên trong một mạng học sâu đa phương thức bao gồm: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại, tập trung vào các phương pháp dung hợp dữ liệu hình ảnh và văn bản cùng với các phương pháp tinh chỉnh tham số cho các bộ mã hóa đã được huấn luyện trước nhằm tận dụng lại các tri thức đã có và nâng cao hiệu năng trên các tác vụ đích.

Đề tài chủ yếu sử dụng các bộ dữ liệu cặp ảnh - văn bản, không có trường hợp thiếu đã được công bố và bộ dữ liệu nội bộ được thu thập và cung cấp bởi giảng viên có hợp tác với bệnh viện ở khu vực Thành phố Hồ Chí Minh, một số thông tin cơ bản về các bộ dữ liệu được thể hiện ở Bảng 1. Nhóm sử dụng các bộ dữ liệu này nhằm đánh giá hiệu năng của kiến trúc đề xuất thông qua các độ đo phổ biến và tiến hành so sánh với các phương pháp trước đó nhằm chứng minh sự hiệu quả của phương pháp đề xuất.

2.6 Cách tiếp cận dự kiến

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ cung cấp tổng quan tình hình nghiên cứu

Bộ dữ liệu	Nguồn	Loại dữ liệu	Số lượng mẫu	Số lượng lớp
RSNA Pneumonia (2018)	Radiological Society of North America	Ảnh X-quang ngực metadata/tags	30,000	3
CheXpert (2019)	Stanford ML Group - Stanford Hospital	Ảnh X-quang ngực Báo cáo đọc ảnh	224,316	14
MIMIC-CXR v2 (2019)	Beth Israel Deaconess Medical Center	Ảnh X-quang ngực Báo cáo đọc ảnh	227,835	14
SARCOMA-CTCH (2025)	Bệnh viện Chấn Thương Chỉnh Hình - TPHCM	Ảnh X-quang xương Báo cáo đọc ảnh Báo cáo lâm sàng	Đang cập nhật	Đang cập nhật

Bảng 1: Tổng hợp các bộ dữ liệu dự kiến được sử dụng để thí nghiệm

từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

Các mô hình xây dựng từ đầu là các mô hình đơn giản, khởi điểm trong bài toán học sâu đa phương thức, thiết kế và huấn luyện một hệ thống mới từ đầu, điểm chung của các phương pháp này là chúng tập trung vào việc thiết kế các cơ chế để "trộn" (fusion) đặc trưng từ các bộ mã hóa (encoder) chuyên biệt ở các cấp độ khác nhau để tối ưu hóa hiệu suất cho các tác vụ cụ thể, sử dụng những bộ mã hóa hình ảnh đơn giản như CNN.

Khởi điểm vào 2020, X. Mei [15] và đồng nghiệp đã đề xuất lấy đặc trưng được tạo ra từ các lớp cuối của mô hình CNN (véc-tơ 512 chiều) và các đặc trưng từ dữ liệu lâm sàng rồi nối lại. Véc-tơ kết hợp này được đưa vào một mạng MLP cuối cùng để đưa ra dự đoán.

Clinical-BERT [25] và TGANet [20] tìm cách học biểu diễn đa phương thức bằng cách thúc đẩy mô hình hiểu và liên kết (align) các đặc trưng giữa các vùng trong ảnh và các từ khóa trong văn bản báo cáo thông qua các nhiệm vụ tự giám sát (self-supervised objectives), cho phép mô hình học được các biểu diễn ngữ nghĩa chung. Hay LViT [12] đề xuất một kiến trúc hybrid CNN-Transformer "Double-U", cấu trúc CNN-Transformer kết hợp mô-đun Pixel-Level Attention Module để giữ lại các đặc trưng cục bộ của ảnh giúp mô hình giữ được khả năng trích xuất đặc trưng cục bộ mạnh mẽ của CNN, đồng thời tận dụng khả năng mô hình hóa ngữ cảnh toàn cục của Transformer.

Việc chỉ nối các đặc trưng có điểm yếu về sự khác biệt về giá trị hoặc sự ngữ nghĩa lớn giữa các phương thức dữ liệu, IRENE [34] đã đưa tất

cả dữ liệu gốc về dạng token chung và học biểu diễn tổng thể (holistic representation) ngay từ đầu, sử dụng một mô hình Transformer duy nhất học các biểu diễn toàn diện cho cả hai phương thức. IRENE còn sử dụng cơ chế chú ý hai chiều ở cấp độ token để nắm bắt "các kết nối cục bộ".

Nghiên cứu của Dai và cộng sự [4] đề xuất mô hình TransMed, giải quyết bài toán kết hợp đa phương thức bằng cách tích hợp CNN và Transformer. Bằng việc chuyển đổi đặc trưng ảnh từ CNN thành dạng chuỗi để Transformer xử lý, mô hình này tối ưu hóa việc nắm bắt các đặc điểm toàn cục của hình ảnh y khoa. Cách tiếp cận này mang lại hiệu quả cao hơn các kỹ thuật fusion thông thường nhờ khả năng biểu diễn dữ liệu đa phương thức một cách toàn diện và chính xác.

Những nghiên cứu này đã khai phá và chứng minh về tác động tích cực của các phương thức dữ liệu khác như văn bản đến kết quả của việc chẩn đoán hình ảnh, tuy nhiên độ chính xác của các phương thức này còn chưa quá cao bởi các bộ mã hóa và phương pháp dung hợp dữ liệu còn đơn giản.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Kiến trúc mô hình			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	X. Mei [15]	Full Fine-Tuning	Pretrain với Cross-Entropy loss	Inception-ResNet-v2	ResNet-18	Decision-level	N/a
2	Clinical-BERT [25]	Full Fine-Tuning	Cross-modal Repr. Learning	DenseNet121	Uncased BERT-base	Early fusion	N/a
3	LViT [12]	Full Fine-Tuning	Semi-supervised (Pseudo-label)	Hybrid U-shape (CNN + ViT)	BERT_12_768_12	Intermediate	N/a
4	TGANet [20]	Train from scratch	Exponential Pseudo-label Iteration	ResNet50	Không có	Intermediate	N/a
5	IRENE [34]	Train from scratch	BCE Loss & AdamW optimizer	Convolution layer	Pretrained BERT	Simultaneous	Upsampling, FEM, CBAM Attention
6	TransMed [4]	Full Fine-Tuning	Supervised (SGD, 100 epochs)	2D CNN (ResNet18 đến 152)	N/a	Attention fusion	Lớp kết nối đầy đủ (FC Layer)

Bảng 2: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tinh chỉnh của các mô hình kết hợp ngôn ngữ - ảnh

Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu (thường cố gắng dung hợp dữ liệu thô thành một khối thống nhất), Med-VLMs chú trọng vào việc đối chiếu và liên kết chặt chẽ ngữ nghĩa giữa hình ảnh và ngôn ngữ tự nhiên. Cụ thể, kiến trúc của chúng thường kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này khớp với

nhau. Lúc này, bộ phân loại không gán nhãn theo cách truyền thống mà đóng vai trò là một cơ chế đo lường mức độ tương đồng. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Để đạt được khả năng trên, các nghiên cứu tiền huấn luyện Med-VLMs hiện nay đang phát triển chủ yếu theo ba hướng: học tương phản, học có che giấu và tích hợp tri thức y khoa (chi tiết tổng hợp được trình bày tại các Bảng 3, 4, 5).

Thứ nhất, **học tương phản (Contrastive Learning)** là chiến lược được ứng dụng rộng rãi nhất, tiêu biểu với các mô hình như ConVIRT [30], GLoRIA [7], MedCLIP [22] và BiomedCLIP [28]. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau ở mức độ cục bộ lẫn toàn cục. Phương pháp này đem lại hiệu năng ấn tượng; ví dụ, BiomedCLIP [28] (huấn luyện trên 15 triệu cặp dữ liệu) đạt độ chính xác phân loại 83%, trong khi ConVIRT [30] đạt 90,3% trên bộ dữ liệu COVIDx. Mặc dù có ưu điểm vượt trội là khả năng học biểu diễn không cần gán nhãn thủ công, học tương phản vẫn bộc lộ hạn chế về việc tiêu tốn tài nguyên tính toán lớn và rủi ro xảy ra hiện tượng âm tính giả (đẩy xa các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý).

Thứ hai, **học có che giấu (Masked Learning)** là hướng đi tập trung vào mục tiêu tái tạo dữ liệu, với các đại diện nổi bật như MRM [35] và MedViLL [16]. Bằng cách ẩn ngẫu nhiên các vùng ảnh hoặc từ ngữ trong báo cáo y khoa, kiến trúc này buộc mô hình phải dự đoán và khôi phục phần thông tin bị khuyết. Hướng tiếp cận này thể hiện ưu thế rõ rệt trong các môi trường khan hiếm dữ liệu; điển hình là MRM [35] đạt mức 92,7% AUC chỉ với 10% dữ liệu từ tập RSNA. Tuy nhiên, rào cản chính của phương pháp này nằm ở việc phụ thuộc vào nguồn dữ liệu đã được ghép cặp sẵn từ trước, cộng với độ phức tạp tính toán cao của quá trình khôi phục điểm ảnh/token.

Thứ ba, **tích hợp tri thức y khoa (Knowledge Integration)** ra đời nhằm giải quyết những đặc thù phức tạp của ngôn ngữ lâm sàng. Các

mô hình như MedKLIP [24], BioViL [3], BioViL-T [1] và KAD [29] tận dụng đồ thị tri thức (như RadGraph) hoặc dữ liệu chuỗi thời gian để cung cấp tín hiệu giám sát chi tiết về cả loại và vị trí bệnh lý. Cách tiếp cận này giúp giải quyết triệt để sự mơ hồ của các từ vựng diễn tả tiến triển bệnh (ví dụ: "cải thiện", "xấu đi"). Về mặt hiệu năng, KAD [29] đạt 0.966 AUC trên tập PadChest ở thiết lập không mẫu (zero-shot), còn BioViL-T [1] đạt độ chính xác 67,4% trong bài toán phân loại tiến triển bệnh. Dù vậy, các phương pháp này chưa loại bỏ hoàn toàn được hiện tượng âm tính giả và rất dễ gặp sai số nếu nhãn chẩn đoán thực tế nằm ngoài cơ sở tri thức đồ thị gốc.

Dựa trên sự phân tích các ưu và nhược điểm từ những khảo sát trên, hướng tiếp cận đề xuất trong nghiên cứu này được thiết kế có chọn lọc nhằm tối ưu hóa hiệu năng và chi phí:

- **Kế thừa BiomedCLIP [28]:** Tận dụng sức mạnh của các bộ mã hóa đã được huấn luyện với chất lượng cao.
- **Không áp dụng học tương phản & học có che giấu:** Khó khắc phục rào cản về tài nguyên tính toán lớn và giảm thiểu rủi ro gặp phải hiện tượng âm tính giả.
- **Tích hợp tri thức từ UMLS (tương tự MedKLIP [24]):** Sử dụng để làm giàu thêm tri thức trong các báo cáo lâm sàng.

Mặc dù các phương pháp tiền huấn luyện Med-VLMs giúp xây dựng nền tảng tri thức đa phương thức khổng lồ, việc áp dụng trực tiếp vào lâm sàng lại vấp phải rào cản lớn về chi phí tính toán và sự khan hiếm dữ liệu y tế ghép cặp. Để giải quyết vấn đề này, các nghiên cứu thường chuyển hướng sang tinh chỉnh mô hình. Tuy nhiên, nếu tinh chỉnh toàn phần trên một tập dữ liệu nhỏ, sự chênh lệch phân phối sẽ dễ dẫn đến hiện tượng chuyển giao tiêu cực hoặc "quên thảm khốc", làm đánh mất tri thức gốc. Do đó, giới nghiên cứu đang tập trung vào các chiến lược tinh chỉnh hiệu quả tham số (PEFT) nhằm đảm bảo tính linh hoạt, tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các nghiên cứu gần đây được chia thành ba hướng tiếp cận chính:

STT	Tên phương pháp	Phân loại	Nguyên lý
1	ConVIRT (2020)	Học tương phản	Tối ưu bộ mã hoá ảnh và văn bản bằng cách kéo các cặp đặc trưng ảnh-văn bản giống nhau lại gần nhau và đẩy các cặp đặc trưng ảnh-văn bản khác nhau ra xa
2	GLoRIA (2021)	Học tương phản	Dùng hai hàm mất mát global contrastive để kéo các cặp đặc trưng ảnh-văn bản, trong khi đó hàm mất mát local contrastive học cách căn chỉnh chi tiết của các vùng trong ảnh và các từ trong câu
3	MedCLIP (2022)	Học tương phản	Đề xuất cơ chế tách cặp và trích xuất tri thức, và đề xuất hàm mất mát Semantic Matching nhằm giải quyết vấn đề false negative
4	BiomedCLIP (2023)	Học tương phản	Có cơ chế tương tự như CLIP nhưng được tiền huấn luyện với bộ dữ liệu PMC-15M
5	MRM (2023)	Học có che giấu	Ẩn ngẫu nhiên các thông tin trong văn bản và các vùng trong ảnh để cho mô hình dự đoán lại ảnh và văn bản hoàn chỉnh.
6	MedViLL (2022)	Học có che giấu	Đề xuất một kiến trúc dựa trên BERT kết hợp với một mặt nạ chú ý mới được đề xuất (BAR) cho phép ảnh tương tác tự do với văn bản trong các tác vụ hiểu, đồng thời đảm bảo tính tự hồi quy cho các token trong văn bản trong các tác vụ sinh
7	BioViL (2022)	Tích hợp kiến thức y khoa	Đề xuất một bộ mã hoá văn bản CXR-BERT được tối ưu cho ảnh X-quang, duy trì hàm mất mát MLM để giúp mô hình giữ lại được các kiến thức văn bản trong quá trình căn chỉnh với ảnh
8	BioViL-T (2023)	Tích hợp kiến thức y khoa	Sử dụng các ảnh X-quang từ trước kết hợp với ảnh hiện tại để học được các đặc trưng không gian, thời gian từ đó giải thích cho các từ vụng như "cải thiện" giúp giảm đi sự mơ hồ trong báo cáo
9	MedKLIP (2023)	Tích hợp kiến thức y khoa	Đề xuất một mô-đun trích xuất bộ ba và cơ chế mã hoá tăng cường tri thức, từ đó tạo ra biểu diễn tốt hơn cho văn bản
10	KAD (2023)	Tích hợp kiến thức y khoa	Tích hợp kiến thức y khoa vào quá trình tiền huấn luyện để giúp mô hình học các biểu diễn có ý nghĩa hơn

Bảng 3: Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Mục tiêu tiền huấn luyện	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	CL	GCL	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	CL	LCL, GCL	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	CL	GCL	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	CL	GCL	ViT-Base	PubMedBERT	Contrastive Alignment	N/a
5	MRM (2023)	MP	MIM, MLM	Kiến trúc giống ViT	WordPiece	Global Context Injection	Văn bản: Transformer; Hình ảnh: Fully Connected
6	MedViLL (2022)	HA	MLM, ITM	ResNet50	BERT	Cross-modal Self-Attention	Multi-Layer Perceptron
7	BioViL (2022)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
8	BioViL-T (2023)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
9	MedKLIP (2023)	CL	LCL	ResNet50	ClinicalBERT	Knowledge-enhanced Alignment	Contrastive head, Cross-Entropy head
10	KAD (2023)	HA	CL, Disease Diagnosis Prediction	ResNet50, ViT-Base	PubMedBERT	Contrastive Alignment	Disease Query Network

Bảng 4: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;

STT	Tên phương pháp	Bộ dữ liệu tiền huấn luyện	Hiệu năng			
			Tác vụ	Bộ dữ liệu đánh giá	Độ đo	Kết quả
1	ConVIRT (2020)	MIMIC-CXR, Private Bone image	- Phân loại ảnh - Phân loại ít mẫu	RSNA Pneumonia, CheXpert, COVIDx, MURA	AUC, Accuracy	- Phân loại ít mẫu: RSNA (1%): 88.8% AUC, (10%): 91.5% AUC; CheXpert (1%): 87.0% AUC, (10%): 88.1% AUC; MURA (1%): 81.3% AUC, (10%): 86.5% AUC - Phân loại ảnh: RSNA: 92.7% AUC, CheXpert: 88.1% AUC, MURA: 89.0% AUC; COVIDx 90.3% ACC
2	GLoRIA (2021)	CheXpert	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	CheXpert, RSNA Pneumonia	AUROC	- Phân loại không mẫu: CheXpert 5x200: 0.61 ACC, 0.67 F1; RSNA: 0.70 ACC, 0.58 F1; - Phân loại ít mẫu: CheXpert (1%): 86.6 AUC, (10%): 87.8 AUC, RSNA (1%): 86.1 AUC, (10%): 88.0 AUC - Phân loại ảnh: CheXpert: 88.1 AUC, RSNA: 88.6 AUC
3	MedCLIP (2022)	MIMIC-CXR, CheXpert	- Phân loại ảnh - Phân loại không mẫu	MIMIC-5x200, COVID, RSNA Pneumonia	Mean Accuracy	- Phân loại không mẫu: CheXpert-5x200: 0.5942 ACC; MIMIC-5x200: 0.5430 ACC; COVID: 0.8472 ACC; RSNA: 0.7682 ACC - Phân loại ảnh: CheXpert-5x200: 0.5960 ACC; MIMIC-5x200: 0.5650 ACC; COVID: 0.7890 ACC; RSNA: 0.8075 ACC
4	BiomedCLIP (2023)	PMC-15M	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PCam, LC25000 (Lung, Colon), TCGA-TIL, RSNA Pneumonia	AUC, Accuracy	- Phân loại không mẫu: PCam: 73.41% ACC; LC25000 Lung 65.23% ACC; LC25000 Colon 92.98%; RSNA 78.95%; TCGA-TIL: 67.04% - Phân loại ít mẫu: PCam (1%): 82% ACC, (10%): 83%; RSNA (1%): 77% ACC, (10%): 82% ACC - Phân loại ảnh: PCam: 83% ACC, RSNA: 83% ACC
5	MRM (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu	CheXpert, NIH ChestX-ray, RSNA Pneumonia, COVID-19 Image Data Collection	AUC, Accuracy	- Phân loại ít mẫu: CheXpert (1%): 88.5 AUC, (10%): 88.5 AUC; RSNA (1%): 91.3 AUC, (10%): 92.7 AUC; NIH ChestX-ray (1%): 79.4 AUC, (10%): 84.0 AUC - Phân loại ảnh: CheXpert: 88.7 AUC, RSNA 93.3, NIH ChestX-ray: 85.9, COVID-19: 85.8
6	MedViLL (2022)	MIMIC-CXR	- Phân loại chẩn đoán	MIMIC-CXR, Open-I	Micro-averaged AUROC, Micro-averaged F1 score	- Phân loại ảnh: MIMIC-CXR: 0.980 avg AUROC, 0.839 F1; Open-I: 0.892 avg AUROC, 0.407 F1
7	BioViL (2022)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	RSNA Pneumonia	Accuracy, F1-score, AUROC, Sensitivity Specificity.	- Phân loại không mẫu: RSNA: 0.732 ACC, 0.831 AUC; ChestX-ray14: 0.6912 AUC - Phân loại ít mẫu: RSNA (1%): 0.805 ACC, 0.881 AUC; (10%): 0.812 ACC, 0.884 AUC - Phân loại ảnh: RSNA: 0.822 ACC, 0.891 AUC
8	BioViL-T (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu - Phân loại ảnh tiến triển	MS-CXR-T, RSNA Penumonia, Chest ImaGenome	Macro-Accuracy, Accuracy, F1, AUROC.	- Phân loại Tiến triển: MS-CXR-T: 67.4% Acc - Phân loại không mẫu: RSNA: 0.805 ACC, 0.871 AUC - Phân loại ít mẫu: RSNA (1%): 0.814 ACC, 0.890 AUC
9	MedKLIP (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại không mẫu	ChestX-ray14, RSNA Pneumonia, SIIM-ACR Pneumothorax, COVIDx CXR-2, COVID Rural, Edema Severity	AUC, F1-score, Accuracy.	- Phân loại không mẫu: RSNA: 0.8694 AUC, 0.6342 F1; SIIM-ACR: 0.8924 AUC, 0.6833 F1; ChestX-ray14: 0.7676 AUC, 0.2525 F1; COVID-19: 0.7396 AUC, 0.7670 F1 - Phân loại ít mẫu: ChestX-ray14 (1%): 0.7721 AUC, (10%): 0.7894; RSNA (1%): 0.8731 AUC, (10%): 0.8799 AUC - Phân loại mẫu: ChestX-ray14: 0.8323 AUC, RSNA 0.8931
10	KAD (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PadChest, NIH ChestXray14, CheXpert, ChestX-Det	AUC, F1-Score, MCC	- Phân loại không mẫu: PadChest: 0.966 AUC; CheXpert: 0.905 AUC, 0.647 F1, 0.589 MCC - Phân loại ít mẫu: ChestXray-14 (1%): 0.78 AUC, 0.31 F1; (10%): 0.80 AUC, 0.33 F1 - Phân loại ảnh: ChestXray-14: 0.82 AUC, 0.34 F1

Bảng 5: Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

Tinh chỉnh sử dụng câu nhắc (Prompt Tuning): Hướng này chèn thêm các tham số có thể học được vào không gian đầu vào của mô hình. Các phương pháp như CITE [31], FPT [8] hay PLIP [27] khai thác đặc trưng thị giác kết hợp với tri thức lâm sàng, cho thấy hiệu quả vượt trội ngay cả khi thiếu hụt dữ liệu (ví dụ: PLIP đạt 0.896 AUC chỉ với 5% dữ liệu PanNuke). Nhằm giải quyết khó khăn khi thiết kế thủ công, MedPrompt [32] và UniDCP [26] tự động sinh câu nhắc động dựa trên ngữ cảnh ảnh để xử lý đa tác vụ. Gần đây hơn, việc tích hợp Mô hình ngôn ngữ Lớn (LLM) qua ViP [6], CILMP [5] và BiomedCoOp [9] giúp tạo sinh các câu nhắc ngữ nghĩa sâu sắc, đồng bộ hóa qua cơ chế chú ý chéo và cân chỉnh tương phản, mang lại hiệu năng cao trong các kịch bản ít mẫu hoặc không mẫu.

Tinh chỉnh bộ điều hợp (Adapter Tuning): Thay vì can thiệp ở đầu vào, phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ giữa các lớp của kiến trúc gốc. Điển hình, CLIPath [10] sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu nhỏ; FTB [18] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức. Ở hướng bán giám sát, mô hình MedUnA [19] dùng LLM tạo nhãn giả và tinh chỉnh không giám sát bộ điều hợp trên ảnh chưa gán nhãn, giúp mô hình thích ứng tốt mà không thay đổi trọng số.

Tinh chỉnh chọn lọc (Selective Tuning): Hướng đi này tối ưu hóa kiến trúc bằng cách chỉ cập nhật một lượng nhỏ các trọng số quyết định hiệu năng. TransMed [33] kết hợp LLM để chuyển đổi nhãn bệnh thành mô tả chi tiết, trong khi SH-PEFT [14] chỉ tìm và cập nhật các trọng số quan trọng nhất trên bộ mã hóa thị giác nhằm khai thác tính thừa thớt của mạng. Tương tự, LCBP [13] áp dụng kỹ thuật LoRA để tinh chỉnh tham số hiệu quả cho Med-VLMs, giúp bám sát hiệu năng của tinh chỉnh toàn phần (đạt 93.1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn) nhưng giảm thiểu tối đa chi phí tính toán.

Tóm lại, các phương pháp tinh chỉnh hiệu quả tham số (PEFT) thể hiện ưu điểm vượt trội trong việc tiết kiệm tài nguyên tính toán, ngăn chặn hiện tượng quên tri thức và giúp mô hình thích ứng tốt ngay cả khi đối mặt với các bộ dữ liệu y tế khan hiếm. Tuy nhiên, hướng tiếp cận này vẫn tồn tại một số hạn chế nhất định. Hiệu năng cuối cùng của hệ thống

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	CITE (2023)	Parameter-efficient fine tuning	Visual prompt tuning	CLIP ViT-Base, ImageNet-21k ViT-Base, INTERN ViT-Base	BioLinkBERT-large, BioBERT-large , Kế thừa CLIP	Contrastive Alignment	N/a
2	UniDCP (2023)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	CLIP ViT	RoBERTa	Cross Attention, Contrastive Alignment	N/a
3	ViP (2024)	Parameter-efficient fine tuning	Textual prompt tuning	ViT-Base	Kế thừa CLIP	Cross Attention, Contrastive Alignment	N/a
4	PLIP (2024)	Parameter-efficient fine tuning	Visual prompt tuning, Efficient Selective tuning	ViT-Base	Kế thừa CLIP	Concatnate	N/a
5	FPT (2024)	Parameter-efficient fine tuning	Visual prompt tuning	ViT-Base	N/a	Cross Attention	N/a
6	MedPrompt (2024)	Parameter-efficient fine tuning	Textual prompt tuning	Swin Transformer, ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
7	CILMP (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	ViT-Base	Kế thừa CLIP	Hadamard Product, Concatnate	N/a
8	BiomedCoOp (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	Kế thừa BiomedCLIP	Kế thừa BiomedCLIP	Contrastive Alignment	N/a
9	CLIPath (2023)	Parameter-efficient fine tuning	Adapter tuning	ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
10	FTB (2024)	Parameter-efficient fine tuning	Adapter tuning	ResNet autoencoder, DINOv2-small, DINOv2-base	BERT, BioBERT, ClinicalBERT, CXR-BERT, PubMedBERT	Cross Attention	N/a
11	MedUnA (2024)	Parameter-efficient fine tuning	Adapter tuning	ViT-Base, MedCLIP-Swin	Kế thừa CLIP, MedCLIP	No Fusion	N/a
12	TransMed (2023)	Parameter-efficient fine tuning	Direct Selective tuning	Swin Transformer, ViT-Base	BERT, LLM/GPT-4	Contrastive Alignment	N/a
13	SH-PEFT (2024)	Parameter-efficient fine tuning	Direct Selective tuning	ViT-Base	Kế thừa CLIP	No Fusion	N/a
14	LCBB (2024)	Parameter-efficient fine tuning	Efficient Selective tuning	Kế thừa MAE, MRM	Kế thừa MAE, MRM	Kế thừa MAE, MRM	N/a

Bảng 6: Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan

phụ thuộc rất lớn vào chất lượng của mô hình tiền huấn luyện gốc. Đồng thời, quá trình thiết kế câu nhắc mang đậm tính chuyên môn hay xác định vị trí tối ưu để chèn bộ điều hợp thường phức tạp và đòi hỏi nhiều thử nghiệm. Ngoài ra, việc bổ sung các thành phần này ít nhiều làm tăng tính "hộp đen" của mô hình, gây ra những thách thức về tính minh bạch khi cần giải thích các quyết định dự đoán cho bác sĩ trên thực tế lâm sàng.

Các mô hình ngôn ngữ lớn y khoa đa phương thức

Trong thời gian gần đây, với sự phát triển của các mô hình ngôn ngữ lớn được huấn luyện trên những tập dữ liệu rất lớn phục vụ cho rất nhiều tác vụ khác nhau, các mô hình này đang thể hiện sự ảnh hưởng và đa dụng trong lĩnh vực y tế với độ chính xác rất tốt khi chỉ học ít mẫu hoặc không mẫu.

Med-Flamingo [17] là mô hình đầu tiên có khả năng học ít mẫu chuyên dụng cho y tế, thông qua hội thoại tự nhiên để hỗ trợ chẩn đoán. Theo sau đó, LLaVA-Med [11] là mô hình chuyển đổi khả năng thực hiện theo chỉ dẫn (instruction-following) từ miền tổng quát sang lĩnh vực y sinh bằng cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn với 600.000 cặp, với dữ liệu hội thoại tạo ra từ chú thích ảnh y khoa được tạo ra bằng cách sử dụng GPT-4. Phương pháp này đã đề xuất quy trình huấn luyện 2 bước: (1) Căn chỉnh khái niệm; (2) Tinh chỉnh chỉ dẫn đầy đủ; 2 bước này tương ứng với giai đoạn học và suy luận. Kết quả thể hiện khả năng suy luận vượt trội trên dữ liệu chưa từng thấy.

Med-Palm M [21] là mô hình của Google, đánh dấu bước tiến từ các mô hình đơn nhiệm sang đa nhiệm quy mô lớn, có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì sử dụng các mô hình chuyên biệt cho từng tác vụ. Gần đây hơn, SkinGPT-4 [36] là hệ thống chẩn đoán da liễu tương tác đầu tiên sử dụng LLM quy mô lớn với độ chính xác cao, đã kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM), tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Dù đưa đến các phương pháp có độ chính xác cao đến rất cao trong nhiều tác vụ cùng việc hỗ trợ trong việc giao tiếp với mô hình, kích cỡ và chi phí huấn luyện (Med-Flamingo có đến 9 tỷ thông số) để vận hành các

mô hình ngôn ngữ lớn đa phương thức là một vấn đề lớn, đi kèm với vấn đề ảo giác có thể gặp phải khi đối mặt với dữ liệu mới hoặc những câu hỏi phức tạp. Ngoài ra nếu yêu cầu một độ chính xác cao - một yêu cầu quan trọng trong lĩnh vực y tế trong một tác vụ cụ thể thì đây không phải một cách tiếp cận tốt cho bài toán này.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Cấu trúc phương pháp			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	Med-Flamingo [17]	PEFT	Parameter-efficient + Domain adaptation	Frozen CLIP ViT	LLaMA-7B	Intermediate fusion	LLaMA Decoder
2	LLaVA-Med [11]	Full FT	Visual Instruction Tuning (GPT-4 data)	CLIP ViT-L/14	LLaMA	Projection Matrix	LLM (Vicuna)
3	Med-PaLM M [21]	Full FT	Instruction Fine-tuning	ViT (4B - 22B)	PaLM	Multimodal embedding	PaLM
4	SkinGPT-4 [36]	PEFT	LoRA	Vision Transformer	GPT-4	Linear alignment	LLaMA-2-13B


Bảng 7: Tổng hợp chiến lược và cấu trúc các mô hình ngôn ngữ lớn đa phương thức

Phương pháp đề xuất: Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế theo hướng tích hợp tri thức y khoa nhằm nâng cao khả năng giải thích của mô hình được minh họa ở Hình 2. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Bộ mã hóa ảnh:** Kế thừa lại mô hình ViT-Base của phương pháp BiomedCLIP [28]
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [28]
- **Bộ dung hợp dữ liệu:** Nhóm hướng đến sử dụng cơ chế *Knowledge-guided Cross-Attention* - Các khái niệm y học được trích xuất và liên kết từ văn bản lâm sàng thông qua sẽ được sử dụng để tạo thiên lệch (bias) trong quá trình tính toán cross attention. Cơ chế này giúp điều hướng mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Nhờ đó, mô hình không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.

- **Bộ phân loại:** Sử dụng một mạng phân loại (Multi-Layer Perceptron) để dự đoán nhãn bệnh lý.

Đồng thời, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán.



Hình 2: Kiến trúc tổng thể của hệ thống đề xuất

2.7 Kết quả dự kiến của đề tài

- **Số liệu định lượng:** Độ chính xác, điểm F1, AUC-ROC đạt kết quả cạnh tranh trên các bộ dữ liệu đã nêu.
- **Sản phẩm đầu ra:**
 - Hệ thống demo phân loại ảnh X-quang xương với khả năng nhận ảnh và văn bản và trả ra các lớp thuộc bộ dữ liệu Sarcoma-CTCH.
 - Giao diện đơn giản để hiển thị kết quả phân loại.
 - Cho phép trực quan hóa sau khi hiện kết quả phân loại.
- **Báo cáo khoa học:** hoàn thiện phương pháp và hệ thống để hướng tới công bố trên các hội nghị và tạp chí uy tín trong lĩnh vực Trí tuệ nhân tạo và Y sinh, như MICCAI, CVPR hoặc các tạp chí được công nhận.
- **Hướng phát triển:**
 - Mở rộng ra cho các bệnh lý khác.
 - Cải thiện độ chính xác và hiệu suất của hệ thống.

2.8 Kế hoạch thực hiện

Mục tiêu	Thời gian	Phân công	Nội dung
Khoá luận tốt nghiệp	01 tháng	Giai đoạn 1	
		Bá Thành	Khảo sát tổng quan về bài toán phân loại ảnh X-quang về xương
		Gia Kiệt	Khảo sát các mô hình tiền huấn luyện trên dữ liệu y khoa
		Bá Thành	Khảo sát các phương pháp học chuyển giao và các mô hình liên quan
	02 tháng	Giai đoạn 2	
		Cả nhóm	Phát triển mô hình học sâu đa phương thức áp dụng phương pháp học chuyển giao
		Gia Kiệt	Cài đặt môi trường, thu thập các bộ dữ liệu liên quan
		Bá Thành	Thực hiện thí nghiệm trên mô hình đề xuất
	02 tháng	Giai đoạn 3	
		Bá Thành	Phân tích so sánh kết quả thực nghiệm.
		Gia Kiệt	Xây dựng nguyên mẫu cho hệ thống phân loại
	0.5 tháng	Giai đoạn 4	
		Cả nhóm	Viết 01 bài báo khoa học cho hội nghị - tạp chí chuyên ngành trong nước hoặc ngoài nước
	0.5 tháng	Giai đoạn 5	
		Bá Thành	Viết báo cáo khoá luận tốt nghiệp.
		Gia Kiệt	Thiết kế slide cho lễ bảo vệ đề tài tốt nghiệp

Bảng 8: Kế hoạch bố trí thời gian nghiên cứu

Tài liệu tham khảo

- [1] Shruthi Bannur et al. “Learning to exploit temporal structure for biomedical vision-language processing”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2023, pp. 15016–15027.
- [2] Lynn S. Bickley, Peter G. Szilagyi, and Richard M. Hoffman. *Bates’ Guide to Physical Examination and History Taking*. 13th. Lippincott Williams & Wilkins, 2020.
- [3] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing”. In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5.
- [4] Yin Dai and Yifan Gao. “TransMed: Transformers Advance Multi-modal Medical Image Classification”. In: *CoRR* abs/2103.05940 (2021). arXiv: 2103.05940. URL: <https://arxiv.org/abs/2103.05940>.
- [5] Ye Du, Nanxi Yu, and Shujun Wang. “Medical Knowledge Intervention Prompt Tuning for Medical Image Classification”. In: *IEEE Transactions on Medical Imaging* 44.12 (2025), pp. 4945–4959. DOI: 10.1109/TMI.2025.3584841.
- [6] Xiao Fang et al. “Aligning Medical Images with General Knowledge from Large Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15010. Springer Nature Switzerland, 2024.
- [7] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [8] Yijin Huang et al. “Fine-grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-resolution Medical Image Classification”. In: *proceedings of Medical Image Comput-*

ing and Computer Assisted Intervention – MICCAI 2024. Vol. LNCS 15012. Springer Nature Switzerland, 2024.

- [9] Taha Koleilat et al. “BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models”. In: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*. 2025, pp. 14766–14776.
- [10] Zhengfeng Lai et al. “CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*. 2023, pp. 2374–2380.
- [11] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: <https://arxiv.org/abs/2306.00890>.
- [12] Zihan Li et al. “LViT: Language Meets Vision Transformer in Medical Image Segmentation”. In: *IEEE Transactions on Medical Imaging* 43 (Jan. 2024), pp. 96–107. DOI: 10.1109/tmi.2023.3291719. (Visited on 02/19/2024).
- [13] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: <https://arxiv.org/abs/2401.12215>.
- [14] Mingyuan Liu et al. “Sparsity- and Hybridity-Inspired Visual Parameter-Efficient Fine-Tuning for Medical Diagnosis”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15005. Springer Nature Switzerland, 2024.
- [15] Xueyan Mei et al. “Artificial intelligence-enabled rapid diagnosis of patients with COVID-19”. In: *Nature Medicine* 26 (Aug. 2020), 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: <https://www.nature.com/articles/s41591-020-0931-3>.

- [16] Jong Hak Moon et al. “Multi-Modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training”. In: *IEEE Journal of Biomedical and Health Informatics* 26.12 (2022), pp. 6070–6080. DOI: 10.1109/JBHI.2022.3207502.
- [17] Michael Moor et al. *Med-Flamingo: a Multimodal Medical Few-shot Learner*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.15189. URL: <https://arxiv.org/abs/2307.15189>.
- [18] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.
- [19] Umaima Rahman et al. “Can language-guided unsupervised adaptation improve medical image classification using unpaired images and texts?” In: *2025 IEEE 22nd International Symposium on Biomedical Imaging (ISBI)*. IEEE. 2025, pp. 1–5.
- [20] Nikhil Kumar Tomar et al. “TGANet: Text-Guided Attention for Improved Polyp Segmentation”. In: *Lecture notes in computer science* (Jan. 2022), pp. 151–160. DOI: 10.1007/978-3-031-16437-8_15. (Visited on 09/04/2024).
- [21] Tao Tu et al. *Towards Generalist Biomedical AI*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.14334. URL: <https://arxiv.org/abs/2307.14334>.
- [22] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, Dec. 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: <https://aclanthology.org/2022.emnlp-main.256/>.
- [23] W.B. Saunders. *Dorland’s Illustrated Medical Dictionary*. 32nd. Elsevier Health Sciences, 2011.

- [24] Chaoyi Wu et al. “MedKLIP: Medical Knowledge Enhanced Language-Image Pre-Training for X-ray Diagnosis”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023, pp. 21372–21383.
- [25] Bin Yan and Mingtao Pei. “Clinical-BERT: Vision-Language Pre-training for Radiograph Diagnosis and Reports Generation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence* 36 (June 2022), pp. 2982–2990. DOI: 10.1609/aaai.v36i3.20204. (Visited on 07/08/2022).
- [26] Chenlu Zhan et al. “UniDCP: Unifying Multiple Medical Vision-Language Tasks via Dynamic Cross-Modal Learnable Prompts”. In: *IEEE Transactions on Multimedia* 26 (2024), pp. 9736–9748. DOI: 10.1109/TMM.2024.3397191.
- [27] Jiajin Zhang et al. “Disease-informed Adaptation of Vision-Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15011. Springer Nature Switzerland, 2024.
- [28] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoa2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoa2400640>.
- [29] Xiaoman Zhang et al. “Knowledge-enhanced visual-language pre-training on chest radiology images”. In: *Nature Communications* 14 (July 2023). DOI: 10.1038/s41467-023-40260-7. URL: <https://arxiv.org/pdf/2302.14042.pdf>.
- [30] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 7th Machine Learning for Healthcare Conference*. Ed. by Zachary Lipton et al. Vol. 182. Proceedings of Machine Learning Research. PMLR, 2022, pp. 2–25. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.

- [31] Yunkun Zhang et al. “Text-Guided Foundation Model Adaptation for Pathological Image Classification”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*. Ed. by Hayit Greenspan et al. Cham: Springer Nature Switzerland, 2023, pp. 272–282. ISBN: 978-3-031-43904-9.
- [32] Fudan Zheng et al. “Exploring low-resource medical image classification with weakly supervised prompt learning”. In: *Pattern Recognition* 149 (2024), p. 110250. ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2024.110250>. URL: <https://www.sciencedirect.com/science/article/pii/S0031320324000013>.
- [33] Kaipeng Zheng, Weiran Huang, and Lichao Sun. “TransMed: Large Language Models Enhance Vision Transformer for Biomedical Image Classification”. In: *arXiv preprint arXiv:2312.07125* (2023).
- [34] Hong-Yu Zhou et al. “A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics”. In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).
- [35] Hong-Yu Zhou et al. “Advancing Radiograph Representation Learning with Masked Record Modeling”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=w-x7U26GM7j>.
- [36] Juexiao Zhou et al. “Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4”. In: *Nature Communications* 15 (July 2024). DOI: 10.1038/s41467-024-50043-3. URL: <https://doi.org/10.1038/s41467-024-50043-3>.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
 (Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 05 tháng 04 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
 (Ký và ghi rõ họ tên)

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Đề cương chi tiết	iii
Mục lục	iii
Danh sách hình	vii
Danh sách bảng	ix
Danh mục ký hiệu	xii
Tóm tắt	xiv
1 Giới thiệu	1
1.1 Bối cảnh và lý do chọn đề tài	1
1.2 Động lực nghiên cứu	3
1.2.1 Kịch bản thực tế	3
1.2.2 Ý nghĩa khoa học của đề tài	4
1.2.3 Ý nghĩa thực tiễn của đề tài	5
1.3 Giới thiệu bài toán	6
1.3.1 Các thách thức trong bài toán	7
1.4 Mục tiêu nghiên cứu	8
1.5 Đối tượng nghiên cứu	9
1.6 Phạm vi nghiên cứu	10
1.7 Câu hỏi nghiên cứu	11

1.8	Dóng góp chính của đề tài	12
1.9	Bố cục khóa luận	13
2	Các công trình nghiên cứu liên quan	14
2.1	Các hướng tiếp cận chính và các mô hình nền tảng	15
2.1.1	Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu	15
2.1.2	Mô hình ngôn ngữ trực quan y khoa - Med-VLMs .	16
2.2	Biểu diễn ảnh độ phân giải cao và thông tin không gian . .	19
2.3	Các kỹ thuật tinh chỉnh hiệu quả tham số	20
2.3.1	Tinh chỉnh sử dụng câu nhắc	22
2.3.2	Tinh chỉnh bộ điều hợp	23
2.3.3	Tinh chỉnh chọn lọc	23
2.4	Các phương pháp phát hiện dữ liệu ngoài phân phối	24
2.4.1	Các phương pháp hậu xử lý dựa trên đầu ra của mô hình	24
2.4.2	Các phương pháp dựa trên độ không chắc chắn và tái tạo	25
2.4.3	Các phương pháp dựa trên khoảng cách trong không gian đặc trưng	26
2.4.4	Học biểu diễn phục vụ phát hiện dữ liệu ngoài phân phối	26
2.5	Bàn luận	27
2.5.1	Hạn chế của các nghiên cứu hiện nay	27
2.5.2	Cơ sở lựa chọn và định hướng phương pháp đề xuất	29
3	Phương pháp đề xuất	32
3.1	Tổng quan phương pháp đề xuất	32
3.2	Nhánh biểu diễn ảnh	33
3.2.1	Tiền xử lý ảnh X-quang và xử lý độ phân giải cao .	33
3.2.2	Bộ mã hóa thị giác BiomedCLIP	36
3.3	Nhánh biểu diễn văn bản	38
3.3.1	Tiền xử lý và mã hóa đầu vào	38
3.3.2	Bộ mã hóa văn bản BiomedCLIP	38
3.4	Thích nghi tham số bằng LoRA	39

3.5	Dung hợp đa phương thức bằng chú ý chéo	40
3.6	Bộ phân lớp bằng mạng nguyên mẫu	43
3.7	Huấn luyện hai giai đoạn trong quá trình ngoại tuyến . . .	45
3.7.1	Giai đoạn 1: thích nghi miền bằng khớp ngữ nghĩa	45
3.7.2	Giai đoạn 2: học dung hợp và phân lớp	48
3.8	Suy luận trong quá trình trực tuyến	50
3.9	Kết luận chương	51
4	Thực nghiệm và kết quả	53
4.1	Thiết kế thực nghiệm	53
4.1.1	Chuẩn bị dữ liệu	53
4.1.2	Nội dung thực nghiệm	59
4.1.3	Độ đo đánh giá	61
4.1.4	Cấu hình thực nghiệm	68
4.2	Khả năng chuyển giao trực tiếp của các mô hình nền tảng	69
4.2.1	Kết quả không mẫu	69
4.2.2	Phân tích khả năng chuyển giao của BiomedCLIP .	70
4.3	Vai trò của ảnh và văn bản	70
4.3.1	Kết quả trên CTCH và BTXRD	70
4.3.2	Phân tích tính nhất quán ảnh-văn bản	71
4.3.3	Kết luận	71
4.4	Hiệu năng theo dữ liệu và chi phí	72
4.4.1	Kết quả khi sử dụng toàn bộ dữ liệu	72
4.4.2	Kết quả trong trường hợp ít mẫu	76
4.4.3	Hiệu quả tham số và chi phí suy luận	78
4.4.4	Kết luận	81
4.5	Đánh giá thành phần	81
4.5.1	Kết quả loại bỏ thành phần	81
4.5.2	Kết luận	83
4.6	Biểu diễn và dữ liệu ngoài phân phối	84
4.6.1	Hình học biểu diễn	84
4.6.2	Phát hiện dữ liệu ngoài phân phối	85
4.6.3	Kết luận	86
4.7	Phân tích nguồn thông tin của dự đoán	87

4.7.1	Can thiệp ở cấp phương thức	87
4.7.2	Độ trung thực và ổn định của tích phân gradient	87
4.7.3	Phân tích định tính	88
4.7.4	Kết luận	91
5	Kết luận và hướng phát triển	93
5.1	Tổng kết	93
5.2	Trả lời các câu hỏi nghiên cứu	94
5.2.1	RQ1: Vai trò của ảnh và văn bản	94
5.2.2	RQ2: Đóng góp của các thành phần XBone-Net	95
5.2.3	RQ3: Đánh đổi dữ liệu, tham số và chi phí tính toán	96
5.2.4	RQ4: Phân biệt dữ liệu ngoài phân phối	96
5.2.5	RQ5: Vai trò của các nguồn thông tin trong lời giải thích	97
5.3	Hướng phát triển	98
	Tài liệu tham khảo	100
A	Chi tiết về bộ dữ liệu	107
A.1	Bộ dữ liệu BTXRD	107
A.1.1	Cấu trúc lưu trữ và đặc điểm kỹ thuật	107
A.1.2	Phương pháp tạo dữ liệu giả lâm sàng	108
A.2	Bộ dữ liệu CTCH	111
A.2.1	Cấu trúc dữ liệu và đặc điểm kỹ thuật	112
B	Kết quả chi tiết theo từng hạt giống	116
B.1	Phạm vi trình bày	116
B.2	Phân loại khi sử dụng toàn bộ dữ liệu huấn luyện	117
B.3	Phân loại trong trường hợp mẫu học hạn chế	119
B.4	Nghiên cứu loại bỏ từng thành phần	121
B.5	Kết quả đánh giá dữ liệu ngoài phân phối	122

Danh sách hình

1.1	Sơ đồ quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam).	3
1.2	Sơ đồ tích hợp hệ thống hỗ trợ phân tích (các khối tím) vào quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam). . . .	4
3.1	Sơ đồ tổng quan phương pháp XBone-Net đề xuất	32
3.2	Quy trình tạo ảnh toàn cục và bốn ảnh cục bộ từ ảnh X-quang	34
3.3	Mô-đun dung hợp bằng chú ý chéo hai chiều	41
3.4	phân lớp vectơ đặc trưng tổng hợp trong không gian nguyên mẫu	44
3.5	Giai đoạn thích nghi miền bằng khớp ngữ nghĩa ảnh-văn bản	46
3.6	Giai đoạn học dung hợp và phân lớp bằng mạng nguyên mẫu	48
3.7	Quy trình suy luận trực tuyến và phát hiện mẫu ngoài phân phối	50
4.1	Phân bố độ tuổi và giới tính của các bệnh nhân được quan sát trong bộ dữ liệu BTXRD	55
4.2	Khoảng tin cậy ghép cặp 95% của chênh lệch điểm F1 trung bình theo lớp giữa XBone-Net và các mô hình cơ sở	74
4.3	Ma trận nhầm lẫn chuẩn hóa theo lớp thực của XBone-Net trên CTCH, tổng hợp trên ba hạt giống	74
4.4	Đường cong độ chính xác-độ nhạy trung bình theo lớp của XBone-Net trên CTCH	75
4.5	Đường cong đặc trưng hoạt động trung bình theo lớp của XBone-Net trên CTCH	75

4.6	Đường cong hiệu chỉnh trung bình của XBone-Net trên CTCH qua ba hạt giống	76
4.7	Chênh lệch độ chính xác giữa các biến thể loại bỏ thành phần và XBone-Net trên CTCH	82
4.8	Chênh lệch Macro-F1 giữa các biến thể và XBone-Net trên CTCH	83
4.9	Chênh lệch Macro-AUROC giữa các biến thể và XBone-Net trên CTCH	83
4.10	Kết quả phát hiện dữ liệu ngoài phân phối bằng khoảng cách Mahalanobis theo tâm lớp trong hai kịch bản	86
4.11	Phân tích tích phân gradient của một trường hợp dự đoán đúng gây xương chày trên CTCH	89
4.12	Phân tích tích phân gradient của một trường hợp nhằm cắt cụt ngón tay thành gãy xương ngón tay trên CTCH	90
4.13	Trường hợp dự đoán đúng có đường loại bỏ-khôi phục gần như phẳng ở mức xác suất cao	91
A.1	Quá trình tạo văn bản minh họa cho mẫu IMG000001.jpeg	111
B.1	Macro-F1 khi sử dụng toàn bộ dữ liệu của XBone-Net và hai mô hình cơ sở PEFT tại từng hạt giống trên BTXRD và CTCH	119
B.2	Khoảng tin cậy 95% của chênh lệch Accuracy giữa từng biến thể loại bỏ thành phần và XBone-Net trên CTCH	123
B.3	Khoảng tin cậy 95% của chênh lệch Balanced Accuracy giữa từng biến thể loại bỏ thành phần và XBone-Net trên CTCH	123
B.4	Khoảng tin cậy 95% của chênh lệch Macro-F1 giữa từng biến thể loại bỏ thành phần và XBone-Net trên CTCH	124
B.5	Khoảng tin cậy 95% của chênh lệch Macro-AUROC giữa từng biến thể loại bỏ thành phần và XBone-Net trên CTCH	124
B.7	Các độ đo OOD của phương pháp Mahalanobis theo tâm lớp tại từng hạt giống trên kịch bản OOD ngữ nghĩa và BTXRD	126
B.6	Khoảng tin cậy 95% của chênh lệch Macro-AUPRC giữa từng biến thể loại bỏ thành phần và XBone-Net trên CTCH	127

Danh sách bảng

2.1	Bảng tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản.	17
2.2	Các chiến lược xử lý ảnh độ phân giải cao và sự đánh đổi chính.	21
2.3	Bảng tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện cho các mô hình ngôn ngữ trực quan y khoa. .	24
4.1	Phân bố mẫu theo các tập chia trong BTXRD	55
4.2	Phân bố các lớp đơn nhãn sau chuẩn hóa trong bộ dữ liệu BTXRD	55
4.3	Ví dụ ảnh, nhãn và văn bản giả lâm sàng được sinh của bộ dữ liệu BTXRD	56
4.4	Phân bố mẫu trong phân phối của CTCH theo tập dữ liệu	58
4.5	Phân bố 22 lớp của CTCH trong ba tập dữ liệu	58
4.6	Các ví dụ ảnh, nhãn và bệnh sử lâm sàng của bộ dữ liệu CTCH	59
4.7	Ánh xạ câu hỏi nghiên cứu với giả thuyết, thực nghiệm và độ đo chính	60
4.8	Môi trường thực nghiệm	68
4.9	Cấu hình chính của các thực nghiệm	68
4.10	Kết quả phân loại không mẫu của các mô hình nền tảng trên BTXRD và CTCH	69
4.11	So sánh giữa các phương thức đầu vào trên hai bộ dữ liệu BTXRD và CTCH	71
4.12	Kết quả phân loại khi sử dụng toàn bộ tập huấn luyện . .	72

4.13	Kết quả xếp hạng xác suất khi sử dụng toàn bộ tập huấn luyện	73
4.14	Kết quả phân loại trong các thiết lập mẫu học hạn chế . .	77
4.15	Kết quả xếp hạng xác suất trong thiết lập mẫu học hạn chế	77
4.16	So sánh các mức thích nghi trên bộ dữ liệu CTCH	78
4.17	Đánh giá số lượng tham số của các mô hình khi sử dụng toàn bộ dữ liệu	78
4.18	Đánh giá chi phí tính toán và tốc độ suy luận của các mô hình khi sử dụng toàn bộ dữ liệu	79
4.19	Đánh giá số lượng tham số của các mô hình trong thiết lập mẫu học hạn chế	80
4.20	Đánh giá chi phí tính toán và tốc độ suy luận của các mô hình trong thiết lập mẫu học hạn chế	80
4.21	Nghiên cứu loại bỏ từng thành phần của XBone-Net trên CTCH	81
4.22	Hình học của các không gian biểu diễn trên 669 mẫu kiểm thử CTCH theo Silhouette và Davies–Bouldin; giá trị là trung bình $\pm$ độ lệch chuẩn giữa ba hạt giống. Chữ đậm biểu thị kết quả tốt nhất trong từng cột.	84
4.23	Kết quả phát hiện OOD hậu xử lý của XBone-Net trên các kịch bản được xét; các giá trị được trình bày dưới dạng trung bình $\pm$ độ lệch chuẩn trên ba hạt giống.	85
4.24	So sánh biểu diễn RQ4 bằng cùng điểm Mahalanobis theo tâm lớp	85
4.25	Can thiệp từng nguồn thông tin trên 669 mẫu kiểm thử CTCH tại mỗi hạt giống. Giá trị được trình bày dưới dạng trung bình $\pm$ độ lệch chuẩn giữa ba hạt giống. Δp là mức giảm xác suất của lớp được mô hình dự đoán trước can thiệp; cột cuối ghi tỷ lệ mẫu mà nguồn tương ứng có Δp lớn nhất.	87

4.26	Độ trung thực của thứ tự đơn vị biểu diễn theo IG và trọng số chú ý chéo trên CTCH. AUC loại bỏ thấp hơn cho biết xác suất lớp đích giảm nhanh hơn khi loại bỏ trước các đơn vị được xếp hạng quan trọng. Hai hàng trọng số chú ý chỉ được tính trên sáu ca trực quan hóa ở mỗi hạt giống. . . .	88
A.1	Cấu trúc lưu trữ của bộ dữ liệu BTXRD trong nghiên cứu	108
A.2	Đặc điểm kỹ thuật của các tệp ảnh BTXRD	108
A.3	Các mẫu câu đại diện trong ngân hàng văn bản giả lâm sàng BTXRD	110
A.4	Cấu trúc lưu trữ của bộ dữ liệu CTCH trong nghiên cứu .	112
A.5	Đặc điểm kỹ thuật của các tệp ảnh CTCH	112
A.6	Dòng dữ liệu qua các bước sàng lọc CTCH	113
A.7	Số lượng hồ sơ còn lại qua các bước sàng lọc bộ dữ liệu CTCH	114
B.1	Kết quả khi sử dụng toàn bộ dữ liệu huấn luyện của từng hạt giống trên BTXRD; hàng XBone-Net được tô xám để dễ đối chiếu.	117
B.2	Kết quả khi sử dụng toàn bộ dữ liệu huấn luyện của từng hạt giống trên CTCH; hàng XBone-Net được tô xám để dễ đối chiếu.	118
B.3	Kết quả mẫu học hạn chế của từng hạt giống trên BTXRD; hàng XBone-Net được tô xám để dễ đối chiếu.	120
B.4	Kết quả mẫu học hạn chế của từng hạt giống trên CTCH; hàng XBone-Net được tô xám để dễ đối chiếu.	120
B.5	Kết quả của từng hạt giống trong nghiên cứu loại bỏ từng thành phần trên CTCH; cấu hình đầy đủ được tô xám. . .	122
B.6	Kết quả OOD hậu xử lý của từng hạt giống; các hàng Mahalanobis theo tâm lớp được tô xám.	125

Danh mục ký hiệu

Ký hiệu	Mô tả	Trang
x^{img}	Ảnh X-quang đầu vào của hệ thống.	6
H, W, C	Chiều cao, chiều rộng và số kênh của ảnh (hoặc số lớp).	6
x^{txt}	Chuỗi văn bản lâm sàng đầu vào.	6
w_t, T	Token tại vị trí t và tổng số token (hoặc nhiệt độ).	6
$\mathcal{Y}, y_k, K$	Tập nhãn nội phân phối, lớp thứ k và tổng số lớp.	6
$\hat{y}$	Nhãn dự đoán cuối cùng hoặc cảnh báo OOD.	6
$s_{\text{OOD}}(\cdot)$	Điểm ngoài phân phối của mẫu đầu vào.	6
$p(y_k x^{img}, x^{txt})$	Xác suất dự đoán lớp y_k .	6
$E(x)$	Energy score của mẫu x .	25
$f_i(x)$	Logit phân loại của lớp i .	25
$d_E(z, c_k)$	Khoảng cách Euclid giữa embedding z và tâm lớp c_k .	26
$d_M(z, \mu_k)$	Khoảng cách Mahalanobis giữa embedding z và trung bình μ_k .	26
Σ, λ, I	Ma trận hiệp phương sai, hệ số điều chuẩn và ma trận đơn vị.	26
S_k, f_θ, c_k	Tập hỗ trợ, hàm embedding và prototype của lớp k .	27
$\mathcal{D}_{\text{train}}, N$	Tập dữ liệu và tổng số mẫu huấn luyện.	33
X_i, R_i, y_i	Ảnh X-quang, bệnh sử và nhãn của mẫu thứ i .	33
$X_i^g, \mathcal{T}_g$	Ảnh toàn cục và phép tiền xử lý tương ứng.	33
$\mathcal{X}_i^\ell, X_{i,m}^\ell$	Tập ảnh cục bộ và ảnh cục bộ thứ m .	33
$b_{i,m}, \mathcal{T}_\ell, M$	Hộp vùng thứ m , phép xử lý cục bộ và tổng số vùng.	33
$E_i(b), H_i(b)$	Năng lượng Laplacian và entropy mức xám của cửa sổ b .	35
$\hat{E}_i, \hat{H}_i, r_i$	Giá trị Laplacian, entropy chuẩn hóa và tỷ lệ tiền cảnh.	35
$q_i(b)$	Điểm tổng hợp của cửa sổ ứng viên b .	35
$\mathbf{u}_i, \mathbf{m}_i$	Chuỗi chỉ số token và attention mask của mẫu i .	38
$\mathcal{T}_t, L$	Phép xử lý văn bản và chiều dài chuỗi.	38
$\mathcal{E}_I, \mathcal{P}_I$	Bộ mã hóa thị giác và phép chiếu đặc trưng.	37
$\mathbf{g}_i^I, D$	Embedding ảnh toàn cục và số chiều không gian chung.	37
$\mathbf{L}_{i,m}^I$	Các token thị giác sinh từ vùng cục bộ m .	37
$\mathbf{L}_i^I, P$	Chuỗi token cục bộ và tổng số token cục bộ.	37
$\mathbf{B}_i, \mathcal{P}_s$	Tọa độ chuẩn hóa hộp cục bộ và phép chiếu tọa độ.	37
$\gamma, \tilde{\mathbf{L}}_i^I$	Hệ số vị trí học được và chuỗi token đã nhúng tọa độ.	37
$e_{i,p}, a_{i,p}$	Điểm chú ý và trọng số pooling của token thứ p .	46

Còn tiếp ở trang sau

Ký hiệu	Mô tả	Trang
$\mathbf{W}_g, \mathbf{W}_\ell, \mathbf{w}_a$	Trọng số học được của mô-đun attention pooling.	46
$\mathbf{z}_i^I, \lambda_\ell$	Embedding thị giác pha 1 và hệ số đóng góp cục bộ.	46
$\mathcal{E}_T, \mathcal{P}_T$	Bộ mã hóa văn bản và phép chiếu tương ứng.	39
$\mathbf{H}_i^T, \mathbf{z}_i^T$	Chuỗi embedding token và embedding văn bản toàn cục.	39
$\mathbf{W}, \mathbf{W}'$	Trọng số tiền huấn luyện và trọng số sau cập nhật LoRA.	39
$\mathbf{A}, \mathbf{B}, r$	Các ma trận hạng thấp và hạng của LoRA.	39
s_{ij}	Độ tương đồng cosine giữa ảnh i và văn bản j .	46
q_{ij}, ρ	Xác suất mục tiêu mềm và hệ số ưu tiên cặp.	47
B	Kích thước mini-batch (hoặc số lần lấy mẫu lặp).	47
$p_{ij}^{I \rightarrow T}, p_{ji}^{T \rightarrow I}$	Xác suất dự đoán ghép cặp ảnh-văn bản và văn bản-ảnh.	47
τ	Nhiệt độ phân phối tương đồng (hoặc ngưỡng OOD).	47
$\mathcal{L}_{\text{SM}}$	Hàm mất mát khớp ngữ nghĩa hai chiều (pha 1).	47
$\mathbf{V}_i$	Chuỗi đặc trưng thị giác kết hợp.	37
$\mathbf{A}_i^{I \leftarrow T}, \mathbf{A}_i^{T \leftarrow I}$	Phân bố chú ý chéo giữa hai phương thức.	42
$\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$	Ma trận query, key, value trong mô-đun chú ý chéo.	42
$\mathbf{h}_i^I, \mathbf{h}_i^T$	Biểu diễn đặc trưng sau dung hợp.	42
$\mathbf{z}_i^F$	Embedding tổng hợp cuối cùng cho bộ phân loại.	43
$\mathbf{c}_k, N_k$	Tâm đặc trưng thực nghiệm và số mẫu huấn luyện lớp k .	44
r_{ik}	Độ tương đồng cosine giữa mẫu i và tâm lớp k .	44
ℓ_{ik}, α_c, b_k	Logit, hệ số tỷ lệ cố định và độ lệch riêng lớp k .	44
E_k, β	Số mẫu hiệu dụng của lớp k và hệ số bão hòa.	48
w_k	Trọng số phạt tổn thất của lớp k .	48
$\tilde{y}_{ik}, \varepsilon$	Mục tiêu huấn luyện sau label smoothing và hệ số làm trơn.	49
$\mathcal{L}_{\text{P2}}$	Hàm mất mát phân loại có trọng số (pha 2).	49
TP_c, FP_c, TN_c, FN_c	Các trường hợp dương/âm tính thật/giả của lớp c .	62
$\text{TPR}_c, \text{FPR}_c$	Tỷ lệ dương tính thật và dương tính giả.	61
AUROC_c	Diện tích dưới đường cong ROC của lớp c .	63
$\text{Precision}_c, \text{Recall}_c$	Độ chính xác và độ thu hồi của lớp c .	62
AP_c	Average Precision (AP) của lớp c .	63
M, B_m	Số khoảng hiệu chuẩn và tập mẫu thuộc khoảng m .	64
$\text{Acc}(B_m), \text{Conf}(B_m)$	Độ chính xác và độ tin cậy trung bình trong khoảng B_m .	64
$\mathcal{D}_{\text{ID}}, \mathcal{D}_{\text{OOD}}$	Tập dữ liệu trong phân phối và ngoài phân phối.	61
τ_{95}	Ngưỡng OOD giữ lại 95% mẫu ID.	65
$\text{Precision}_{\text{OOD}}, \text{Recall}_{\text{OOD}}$	Precision và recall khi xem OOD là lớp dương.	65

Tóm tắt

Các bệnh lý và chấn thương xương ngày càng phổ biến, làm gia tăng nhu cầu ứng dụng trí tuệ nhân tạo trong phân tích ảnh X-quang. Tuy nhiên, dữ liệu y khoa thường hạn chế về số lượng mẫu gán nhãn, mất cân bằng lớp và tồn tại bệnh ngoài phân phối, giảm khả năng tổng quát của mô hình khi triển khai. Đề tài nhằm xây dựng hệ thống phân loại đa lớp ảnh X-quang xương theo hướng đa phương thức, khai thác đồng thời hình ảnh và văn bản lâm sàng để nâng cao hiệu quả dự đoán. Hệ thống được phát triển trên nền tảng BioMedCLIP với hai giai đoạn huấn luyện: thích nghi miền bằng LoRA kết hợp hàm mất mát khớp ngữ nghĩa để cải thiện biểu diễn đặc trưng, sau đó hợp nhất đặc trưng ảnh và văn bản bằng cơ chế chú ý hai chiều. Mạng nguyên mẫu kết hợp Cross-Entropy có trọng số lớp được sử dụng nhằm giảm ảnh hưởng mất cân bằng lớp, hỗ trợ các lớp ít mẫu và phát hiện dữ liệu ngoài phân phối dựa trên khoảng cách mahalanobis. Phương pháp được đánh giá thông qua thí nghiệm thành phần, so sánh với mô hình nền và kiểm thử trên bộ dữ liệu tại Bệnh viện Chấn thương Chỉnh hình. Kết quả cho thấy phương pháp đề xuất cải thiện hiệu quả phân loại đa lớp và khả năng tổng quát, đồng thời hỗ trợ nhận diện mẫu ngoài phân phối.

Chương 1

Giới thiệu

Chương này trình bày bối cảnh, vấn đề nghiên cứu và phạm vi của bài toán phân lớp ảnh X-quang xương bằng học sâu đa phương thức. Trọng tâm của khóa luận là khai thác đồng thời ảnh X-quang và nguồn văn bản đi kèm. Khóa luận áp dụng hai kịch bản dữ liệu gồm nguồn văn bản chính là bệnh sử lâm sàng có sẵn trong bệnh án và văn bản lâm sàng được sinh ngoại tuyến từ siêu dữ liệu do bộ dữ liệu không cung cấp bệnh sử tương ứng với từng ảnh. Hai nguồn này được phân tích riêng vì không có mức độ xác thực lâm sàng và quan hệ với nhãn giống nhau. Chương cũng xác định các thách thức liên quan đến độ phân giải ảnh, dữ liệu hạn chế, mất cân bằng lớp, dữ liệu ngoài phân phối và khả năng giải thích để từ đó xây dựng mục tiêu, câu hỏi nghiên cứu và các đóng góp của khóa luận.

1.1 Bối cảnh và lý do chọn đề tài

Hệ xương đóng vai trò quan trọng trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ khảo sát cấu trúc xương, phát hiện tổn thương, bất thường và hỗ trợ định hướng điều trị.

Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay có thể gặp khó khăn khi tổn thương nhỏ, ảnh có tương phản thấp hoặc khi số lượng ca cần đọc lớn, lúc đó kết quả phụ thuộc đáng kể vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ.

Để giải quyết các thách thức này, nhiều nghiên cứu đã ứng dụng các mô hình học sâu vào việc hỗ trợ phân tích và phân lớp ảnh X-quang và đưa ra quyết định dựa trên thông tin trên ảnh như các kiến trúc mạng nơ-ron tích chập ResNet [11] và DenseNet [14]. Tuy nhiên, các mô hình chỉ sử dụng hình ảnh không khai thác được các thông tin lâm sàng có sẵn trước khi đọc ảnh, chẳng hạn triệu chứng, tiền sử bệnh hoặc cơ chế chấn thương. Trong khi đó, quá trình ra quyết định lâm sàng thực tế của bác sĩ thường dựa trên sự kết hợp giữa bằng chứng hình ảnh và bối cảnh bệnh hoặc chấn thương của người bệnh.


Dựa vào thực tế đó, các mô hình ngôn ngữ trực quan y khoa như MedCLIP [43], BiomedCLIP [47] và BioViL [2] cung cấp một hướng tiếp cận phù hợp để học biểu diễn chung giữa ảnh và văn bản. Nhờ được tiền huấn luyện trên các tập dữ liệu ảnh–văn bản y khoa quy mô lớn, các mô hình này có thể được chuyển giao sang những bài toán y khoa ở tác vụ đích.

Tuy nhiên, việc chuyển giao các mô hình ngôn ngữ trực quan y khoa sang bài toán phân lớp ảnh X-quang xương vẫn gặp nhiều trở ngại. Những trở ngại này xuất phát từ sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu đầu vào thực tế, số lượng dữ liệu gán nhãn hạn chế và mất cân bằng, nguy cơ xuất hiện dữ liệu ngoài phân phối, yêu cầu bảo toàn các tổn thương nhỏ trên ảnh có độ phân giải cao, cũng như nhu cầu giải thích quyết định của mô hình.

1.2 Động lực nghiên cứu

1.2.1 Kịch bản thực tế


Trong thực hành lâm sàng với các ca bệnh có chỉ định chụp X-quang, quy trình chẩn đoán bệnh lý xương thường tuân theo Hình 1.1 bao gồm các bước: bác sĩ chính khai thác bệnh sử, khám lâm sàng, chỉ định chụp X-quang. Sau đó, bác sĩ đọc ảnh sẽ phân tích ảnh X-quang và kết hợp với các ngữ cảnh lâm sàng để đưa ra nhận định cận lâm sàng. Cuối cùng, bác sĩ chính sử dụng tất cả các thông tin kể trên để làm căn cứ cho quyết định chẩn đoán cuối cùng và đưa ra hướng xử trí.



Hình 1.1: Sơ đồ quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam).

Hệ thống được đề xuất trong khóa luận được thiết kế nhằm hỗ trợ quá trình phân tích ảnh X-quang bằng cách khai thác đồng thời ảnh X-quang và dữ liệu văn bản đi kèm để dự đoán lớp bệnh lý của bệnh nhân như thể hiện ở Hình 1.2. Hai kịch bản văn bản là bệnh sử có sẵn trong bệnh án và văn bản lâm sàng được chuẩn bị trước do dữ liệu nguồn không có bệnh sử tự do. Việc kết hợp hai nguồn dữ liệu cho phép khảo sát khả năng học

biểu diễn đa phương thức, nhưng kết quả có được từ bệnh sử được tổng hợp không được diễn giải tương đương với việc sử dụng bệnh sử tự nhiên.



Hình 1.2: Sơ đồ tích hợp hệ thống hỗ trợ phân tích (các khối tím) vào quy trình khám chữa bệnh lý xương thực tế (các khối xanh) và các kết quả thu được ở từng bước (các khối cam).

Cần lưu ý rằng hệ thống được nghiên cứu như một công cụ hỗ trợ phân tích và không thay thế phân tích của bác sĩ đọc ảnh. Các đầu ra của mô hình chỉ mang tính hỗ trợ, hiệu quả lâm sàng thực tế với kỳ vọng có thể rút ngắn thời gian đọc phim, giảm nguy cơ bỏ sót tổn thương và nâng cao hiệu quả chẩn đoán cần được đánh giá thêm thông qua nghiên cứu độc lập với sự tham gia của các chuyên gia y tế.

1.2.2 Ý nghĩa khoa học của đề tài

Đề tài cung cấp đánh giá thực nghiệm về việc kết hợp ảnh X-quang với văn bản trong hai điều kiện dữ liệu lâm sàng khác nhau. Một kịch bản cho phép khảo sát bệnh sử lâm sàng có sẵn trong bệnh án, trong khi kịch bản còn lại được sử dụng để khảo sát quy trình đa phương thức với văn bản tổng hợp từ siêu dữ liệu. Sự phân biệt này giúp tránh quy kết giá trị lâm sàng của văn bản tổng hợp cho bệnh sử tự nhiên.

Nghiên cứu đồng thời khảo sát khả năng thích nghi của mô hình ngôn ngữ trực quan y khoa được tiền huấn luyện trên dữ liệu quy mô lớn đối với dữ liệu X-quang xương có quy mô hạn chế và phân bố mất cân bằng. Kết quả nghiên cứu cung cấp thêm cơ sở thực nghiệm cho việc ứng dụng các mô hình nền tảng đa phương thức vào những miền y khoa chuyên biệt.

Bên cạnh hiệu quả phân lớp, đề tài xem xét khả năng nhận diện dữ liệu ngoài phân phối và phân tích các vùng ảnh có ảnh hưởng đến dự đoán. Việc đánh giá đồng thời các khía cạnh này góp phần mở rộng tiêu chí nghiên cứu từ độ chính xác đơn thuần sang khả năng tổng quát hóa, độ tin cậy và tính minh bạch của hệ thống.

1.2.3 Ý nghĩa thực tiễn của đề tài

Hệ thống được đề xuất hướng đến hỗ trợ bác sĩ trong quá trình phân tích ảnh X-quang bằng cách kết hợp thông tin từ ảnh và dữ liệu lâm sàng ban đầu để đưa ra kết quả phân lớp. Khả năng phù hợp với quy trình khám chữa bệnh thực tế được xem xét chủ yếu trên kịch bản bệnh sử có sẵn trong bệnh án. Kịch bản còn lại đóng vai trò bổ sung để đánh giá thuật toán với văn bản tổng hợp và không được dùng làm bằng chứng trực tiếp về hiệu quả triển khai với bệnh sử thực.

Ngoài ra, quá trình nghiên cứu góp phần xây dựng và chuẩn hóa một bộ dữ liệu đa phương thức gồm ảnh X-quang và bệnh sử lâm sàng từ dữ liệu thực tế tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh. Bộ dữ liệu và quy trình xử lý có thể tạo nền tảng cho các nghiên cứu tiếp theo về phân lớp bệnh lý xương và mô hình ngôn ngữ trực quan y khoa tại Việt Nam.

Đồng thời, mô hình cung cấp bản đồ nhiệt đóng góp để khảo sát những vùng ảnh và đơn vị từ ngữ có liên hệ với dự đoán, cùng các điểm bất thường hậu xử lý cho dữ liệu ngoài phân phối. Các đầu ra này phục vụ phân tích mô hình, chưa phải bằng chứng định vị tổn thương hoặc cơ chế bảo đảm an toàn lâm sàng.

1.3 Giới thiệu bài toán

Bài toán được nghiên cứu trong đề tài là bài toán phân lớp đa lớp ảnh X-quang sử dụng học sâu đa phương thức. Mục tiêu của hệ thống là dự đoán các loại bệnh hoặc tổn thương dựa đồng thời vào ảnh X-quang và văn bản đi kèm.

Đầu vào

Hệ thống nhận vào các nguồn dữ liệu sau:

- **Ảnh X-quang của bệnh nhân:**

$$x^{\text{img}} \in \mathbb{R}^{H \times W \times C}$$

Với H, W là chiều cao và chiều rộng ảnh, C là số kênh màu của ảnh.

- **Văn bản đi kèm:** bệnh sử lâm sàng hoặc văn bản lâm sàng được sinh từ siêu dữ liệu.

$$x^{\text{txt}} = (w_1, w_2, \dots, w_T)$$

Với w_t là đơn vị từ ngữ tại vị trí thứ t trong văn bản, T là số lượng đơn vị từ ngữ trong văn bản.

- **Tập nhãn được định nghĩa trước:**

$$\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$$

với K là số lớp bệnh cần phân lớp.

Đầu ra

Hệ thống sinh ra ba đầu ra chính:

- **Nhân dự đoán cuối cùng:**

$$\hat{y} = \arg \max_{y_k \in \mathcal{Y}} p(y_k | x^{\text{img}}, x^{\text{txt}}),$$

Với $p(y_k | x^{\text{img}}, x^{\text{txt}})$ là xác suất dự đoán của lớp y_k .

- **Cảnh báo dữ liệu ngoài phân phối:**

$$\omega_{\text{OOD}} = \begin{cases} 1, & \text{nếu } s_{\text{OOD}}(x^{\text{img}}, x^{\text{txt}}) > \delta_{\text{OOD}}, \\ 0, & \text{ngược lại,} \end{cases}$$

Với $s_{\text{OOD}}(x^{\text{img}}, x^{\text{txt}})$ là điểm ngoài phân phối của mẫu đầu vào, δ_{OOD} là ngưỡng cảnh báo được xác định trước và $\omega_{\text{OOD}} = 1$ biểu thị rằng mẫu được phát hiện là dữ liệu ngoài phân phối.

- **Thông tin hỗ trợ giải thích:** Hệ thống sinh ra các bản đồ nhiệt đóng góp cho ảnh toàn cục, các vùng ảnh cục bộ và văn bản đi kèm nhằm khảo sát mức độ liên hệ của từng nguồn thông tin với dự đoán của mô hình.

1.3.1 Các thách thức trong bài toán

Mặc dù các mô hình học sâu đa phương thức đã đạt được nhiều kết quả tích cực, bài toán vẫn tồn tại nhiều thách thức cần được giải quyết:

- **Sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu đầu vào thực tế:** Tồn tại sự chênh lệch giữa các bộ dữ liệu đa phương thức hiện có, thường là cặp ảnh X-quang và báo cáo đọc ảnh, so với dữ liệu đầu vào được khảo sát trong khóa luận gồm ảnh X-quang kết hợp với bệnh sử hoặc thông tin lâm sàng ban đầu. Sự khác biệt này có thể hạn chế khả năng chuyển giao trực tiếp của mô hình.
- **Sự khác biệt về không gian và ngữ nghĩa giữa dữ liệu hình ảnh và dữ liệu văn bản:** Sự khác biệt này gây khó khăn cho quá trình học biểu diễn chung, yêu cầu một cơ chế dung hợp hiệu quả.

- **Bảo toàn tổn thương nhỏ trên ảnh độ phân giải cao:** Việc co toàn bộ ảnh X-quang về kích thước cố định ở độ phân giải thấp của các mô hình hiện nay có thể làm mất đi các chi tiết cục bộ quan trọng, đặc biệt là các tổn thương nhỏ, dẫn đến hiệu quả phân lớp bị hạn chế.
- **Hạn chế của dữ liệu thực tế:** Dữ liệu y tế thường có số lượng hạn chế và mất cân bằng giữa các loại bệnh, đặt ra yêu cầu đặc biệt về thiết kế mô hình để tận dụng tối đa thông tin có sẵn.
- **Dữ liệu ngoài phân phối:** Các bộ phân lớp theo giả định tập đóng chưa được thiết kế để xử lý các trường hợp dữ liệu ngoài phân phối, dẫn đến nguy cơ đưa ra dự đoán không chính xác với độ tin cậy cao đối với những ca bệnh mới chưa từng xuất hiện trong dữ liệu huấn luyện, đặt ra yêu cầu về khả năng tổng quát hóa và thích ứng của mô hình.
- **Khả năng giải thích của mô hình:** Khả năng giải thích của các mô hình vẫn còn hạn chế khiến độ tin cậy của người dùng vào các dự đoán của hệ thống là không cao, gây khó khăn cho việc triển khai trong thực tế lâm sàng.

1.4 Mục tiêu nghiên cứu

Đề tài hướng đến xây dựng và đánh giá một hệ thống học sâu đa phương thức phục vụ phân lớp bệnh lý trên ảnh X-quang xương bằng cách khai thác đồng thời thông tin hình ảnh và bệnh sử lâm sàng. Hệ thống được nghiên cứu trong điều kiện dữ liệu gán nhãn hạn chế và mất cân bằng lớp, đồng thời được đánh giá về hiệu năng phân lớp, khả năng phát hiện dữ liệu ngoài phân phối, tính giải thích và chi phí tính toán.

Các mục tiêu cụ thể của đề tài bao gồm:

1. Đánh giá mức độ đóng góp của bệnh sử lâm sàng đối với hiệu năng phân lớp khi kết hợp với ảnh X-quang, so với thiết lập chỉ sử dụng hình ảnh.

2. Nghiên cứu phương pháp xử lý ảnh X-quang độ phân giải cao nhằm bảo toàn các đặc trưng cục bộ liên quan đến tổn thương xương.
3. Nghiên cứu và đánh giá các chiến lược dung hợp đặc trưng hình ảnh-văn bản, trong đó tập trung vào cơ chế chú ý chéo hai chiều và so sánh với các phương pháp dung hợp cơ sở.
4. Khảo sát các phương pháp tinh chỉnh hiệu quả tham số nhằm giảm số lượng tham số cần cập nhật và chi phí huấn luyện, đồng thời duy trì hiệu năng cạnh tranh so với tinh chỉnh toàn bộ.
5. Nghiên cứu cơ chế phát hiện dữ liệu ngoài phân phối nhằm nhận diện các mẫu khác biệt so với dữ liệu huấn luyện và hỗ trợ đánh giá độ tin cậy của dự đoán.
6. Xây dựng cơ chế giải thích dựa trên phương pháp tích phân gradient và can thiệp nguồn thông tin để khảo sát vai trò của ảnh toàn cục, các vùng ảnh cục bộ và bệnh sử đối với quyết định của mô hình.
7. Xây dựng và đánh giá XBone-Net trên các bộ dữ liệu X-quang xương mất cân bằng; đồng thời so sánh với các mô hình ảnh đơn phương thức và mô hình ngôn ngữ trực quan y khoa trong các thiết lập không mẫu, mẫu hạn chế và toàn bộ mẫu.

1.5 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học sâu đa phương thức trong bài toán phân lớp bệnh lý trên ảnh X-quang xương, sử dụng đồng thời thông tin hình ảnh và bệnh sử lâm sàng. Nghiên cứu tập trung vào các nhóm mô hình và thành phần kỹ thuật sau:

- Các mô hình ngôn ngữ trực quan được tiền huấn luyện trên dữ liệu tổng quát hoặc dữ liệu y khoa, đóng vai trò bộ mã hóa đặc trưng hình ảnh và văn bản.

- Các phương pháp xử lý ảnh X-quang độ phân giải cao nhằm khai thác đồng thời đặc trưng toàn cục và đặc trưng cục bộ của vùng tổn thương.
- Các chiến lược dung hợp đa phương thức, bao gồm phép nối đặc trưng và cơ chế chú ý chéo, để kết hợp biểu diễn hình ảnh với thông tin bệnh sử lâm sàng.
- Các phương pháp tinh chỉnh hiệu quả tham số cho mô hình tiền huấn luyện quy mô lớn, tập trung vào việc giới hạn số tham số cần cập nhật trong quá trình huấn luyện.
- Các kiến trúc đầu phân lớp đa lớp trên dữ liệu mất cân bằng, bao gồm bộ phân lớp tuyến tính và bộ phân lớp dựa trên tâm lớp.
- Các phương pháp phát hiện dữ liệu ngoài phân phối và trực quan hóa bản đồ tích phân gradient nhằm hỗ trợ đánh giá độ tin cậy và khả năng giải thích của mô hình.

1.6 Phạm vi nghiên cứu

Đề tài tập trung vào bài toán phân lớp đa lớp bệnh lý xương trên ảnh X-quang, kết hợp với bệnh sử lâm sàng. Phạm vi cụ thể bao gồm:

- **Dữ liệu:** Nghiên cứu sử dụng bộ dữ liệu BTXRD [45] gồm 10 lớp bệnh lý xương, và bộ dữ liệu CTCH được thu thập từ Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.
- **Dữ liệu văn bản:** Bộ dữ liệu CTCH sử dụng bệnh sử có sẵn trong bệnh án, gồm lý do vào viện, diễn tiến bệnh và tiền sử. Bộ dữ liệu BTXRD không có bệnh sử tự do nên sử dụng văn bản lâm sàng được sinh ngoại tuyến từ siêu dữ liệu. Vì mẫu câu tổng hợp có phụ thuộc vào các cờ nhóm bệnh, kết quả BTXRD chỉ phản ánh thiết lập văn bản tổng hợp và không được xem là bằng chứng tương đương với bệnh sử lâm sàng tự nhiên.

- **Vai trò hệ thống:** Hệ thống được thiết kế làm công cụ hỗ trợ phân tích ảnh, không thay thế vai trò của bác sĩ trong quá trình ra quyết định.
- **Giới hạn:** Đề tài không tập trung vào các bài toán phát hiện đối tượng, phân đoạn ảnh hay sinh báo cáo y khoa tự động.

1.7 Câu hỏi nghiên cứu

Để đạt được các mục tiêu đã đề ra, nghiên cứu tập trung trả lời các câu hỏi sau:

- **Câu hỏi nghiên cứu 1:** Việc kết hợp ảnh X-quang với bệnh sử lâm sàng đi kèm ảnh hưởng như thế nào đến hiệu năng phân lớp so với các mô hình chỉ sử dụng hình ảnh? Ảnh hưởng này khác nhau ra sao giữa hai kịch bản bệnh sử thực và văn bản tổng hợp từ siêu dữ liệu?
- **Câu hỏi nghiên cứu 2:** Các thành phần của XBone-Net, bao gồm nhánh xử lý ảnh độ phân giải cao, quá trình huấn luyện hai pha, cơ chế dung hợp hai chiều và đầu phân lớp dựa trên tâm lớp, đóng góp như thế nào vào hiệu năng phân lớp, khả năng xếp hạng và hiệu chuẩn của mô hình?
- **Câu hỏi nghiên cứu 3:** XBone-Net và chiến lược tinh chỉnh LoRA đạt sự đánh đổi như thế nào giữa hiệu năng phân lớp, số lượng dữ liệu gán nhãn, số tham số cần cập nhật và chi phí tính toán trong các thiết lập ít mẫu và toàn bộ dữ liệu?
- **Câu hỏi nghiên cứu 4:** Không gian biểu diễn của XBone-Net có hỗ trợ phân biệt dữ liệu trong phân phối với các dạng dữ liệu ngoài phân phối được xác định trước hay không?
- **Câu hỏi nghiên cứu 5:** Phương pháp tích phân gradient phản ánh vai trò của ảnh toàn cục, các vùng ảnh cục bộ và thông tin văn bản đối với quyết định phân lớp của XBone-Net như thế nào?

1.8 Đóng góp chính của đề tài

Các đóng góp chính của đề tài bao gồm:

1. **Quy trình khai thác dữ liệu đa phương thức:** Sử dụng ảnh X-quang kết hợp với bệnh sử thực trên CTCH và văn bản lâm sàng tổng hợp từ siêu dữ liệu trên BTXRD.
2. **Kiến trúc XBone-Net cho ảnh độ phân giải cao:** Xây dựng nhánh thị giác khai thác đồng thời ảnh toàn cục và các vùng ảnh cục bộ, sử dụng thông tin tọa độ để tổng hợp các đơn vị biểu diễn trước khi dung hợp với biểu diễn văn bản bằng cơ chế chú ý chéo hai chiều.
3. **Quy trình huấn luyện hai giai đoạn với LoRA:** Giai đoạn đầu căn chỉnh biểu diễn ảnh-văn bản, sau đó tối ưu các bộ điều hợp của LoRA và mô-đun dung hợp cho tác vụ phân lớp ở giai đoạn sau. Quy trình này giúp thích nghi BiomedCLIP với ảnh X-quang xương trong khi chỉ cập nhật một phần tham số.
4. **Bộ phân lớp dựa trên tâm lớp:** Xây dựng bộ phân lớp sử dụng độ tương đồng cosine với các tâm lớp được ước lượng từ tập huấn luyện, kết hợp với hàm mất mát entropy chéo có trọng số nhằm hạn chế ảnh hưởng của mất cân bằng lớp.
5. **Khung phát hiện dữ liệu ngoài phân phối:** Đánh giá các điểm ngoài phân phối dựa trên khoảng cách đến tâm lớp, Mahalanobis, kNN và entropy dự đoán đối với các mẫu cùng bộ dữ liệu và các mẫu khác bộ dữ liệu.
6. **Cơ chế giải thích ở cấp độ trường hợp:** Áp dụng tích phân gradient và can thiệp thông tin đầu vào để phân tích đóng góp của ảnh toàn cục, ảnh cục bộ và văn bản đối với các dự đoán của mô hình. Phân tích này hỗ trợ truy vết quyết định, không thay thế đánh giá định vị tổn thương hoặc đánh giá lâm sàng.

1.9 Bố cục khóa luận

Khóa luận được tổ chức thành năm chương như sau:

Chương 1: Giới thiệu. Chương này trình bày bối cảnh nghiên cứu, vấn đề đặt ra, mục tiêu, đối tượng, câu hỏi nghiên cứu và các đóng góp chính của đề tài. Nội dung chương đóng vai trò định hướng cho toàn bộ khóa luận.

Chương 2: Các công trình nghiên cứu liên quan. Chương này tổng quan các nghiên cứu về mô hình ngôn ngữ trực quan, phân lớp ảnh X-quang xương, xử lý ảnh độ phân giải cao, dung hợp đa phương thức, tinh chỉnh hiệu quả tham số, phát hiện dữ liệu ngoài phân phối và khả năng giải thích mô hình. Trên cơ sở đó, chương xác định khoảng trống nghiên cứu và định vị phương pháp đề xuất so với các công trình trước.

Chương 3: Phương pháp đề xuất. Chương này mô tả kiến trúc XBone-Net, quy trình xử lý ảnh và văn bản, cơ chế dung hợp hai chiều, bộ phân lớp dựa trên tâm lớp, các hàm mất mát và chiến lược huấn luyện hai giai đoạn với LoRA. Quy trình phát hiện dữ liệu ngoài phân phối và giải thích dự đoán cũng được trình bày trong chương này.

Chương 4: Thực nghiệm và kết quả. Chương này giới thiệu các bộ dữ liệu, thiết lập thực nghiệm, mô hình đối sánh và các độ đo đánh giá. Các kết quả không mẫu, mẫu hạn chế, toàn bộ mẫu, nghiên cứu loại bỏ thành phần, đánh giá hiệu quả tính toán, phát hiện dữ liệu ngoài phân phối và giải thích mô hình được phân tích nhằm làm rõ ưu điểm, hạn chế và sự đánh đổi của phương pháp đề xuất.

Chương 5: Kết luận và hướng phát triển. Chương cuối tổng kết các kết quả đạt được, trả lời các câu hỏi nghiên cứu, chỉ ra những hạn chế còn tồn tại và đề xuất các hướng cải tiến, mở rộng trong tương lai.

Chương 2

Các công trình nghiên cứu liên quan

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Nhằm xác lập cơ sở cho việc thiết kế hệ thống phân lớp, phần này sẽ mô tả tổng quan các nghiên cứu về các mô hình nền tảng của các cách tiếp cận khác nhau cho bài toán phân lớp ảnh y khoa, các chiến lược bảo toàn thông tin trên ảnh độ phân giải cao, đặc biệt là cách kết hợp ngữ cảnh toàn cục với đặc trưng cục bộ, các kỹ thuật tinh chỉnh hiệu quả tham số và phương pháp phát hiện dữ liệu ngoài phân phối. Trên cơ sở đó, đối chiếu ưu điểm, hạn chế và mức độ phù hợp của các hướng tiếp cận hiện có đối với dữ liệu thực tế, chương xác định khoảng trống nghiên cứu và làm rõ cơ sở lựa chọn các thành phần trong phương pháp được đề xuất ở Chương 3.

2.1 Các hướng tiếp cận chính và các mô hình nền tảng

2.1.1 Các mô hình kết hợp ngôn ngữ - ảnh xây dựng từ đầu

Sự kết hợp giữa dữ liệu cận lâm sàng và báo cáo lâm sàng, lịch sử bệnh lý đã tạo ra những bước tiến lớn trong việc cải thiện độ chính xác của các mô hình chẩn đoán, đặc biệt là thông qua việc sử dụng văn bản để bù đắp những thiếu sót thông tin mà hình ảnh đơn thuần không thể cung cấp, hoặc giúp mô hình tập trung vào những vùng trên ảnh được xác định bởi thông tin từ nguồn văn bản. Nghiên cứu của X. Mei [29] trong việc chẩn đoán COVID-19 là một minh chứng rõ nét: khi ảnh chụp CT ngực ở giai đoạn sớm có thể chưa biểu hiện bất thường, việc tích hợp thông tin lâm sàng thông qua mạng MLP với đặc trưng ảnh từ CNN đã giúp mô hình nhận diện chính xác 68% số bệnh nhân dương tính mà các bác sĩ X-quang đã bỏ sót. Mô hình TieNet [42] đã mã hóa các báo cáo y tế và tích hợp các cơ chế chú ý đa cấp để giống hàng các từ mang ý nghĩa quan trọng với các vùng ảnh tương ứng, cải thiện trung bình 6% chỉ số AUC so với các mô hình chỉ dùng ảnh. Gần đây, IRENE [49] đưa tất cả dữ liệu về một dạng token chung và sử dụng một mô hình Transformer duy nhất, cho phép văn bản trực tiếp tương tác và giải thích các token của ảnh ở cấp độ cục bộ.

Nhìn chung, những nghiên cứu này minh chứng rằng sự đóng góp của nhiều nguồn dữ liệu, đặc biệt là văn bản đã đi từ việc chỉ là một véc-tơ thông tin ghép nối thêm, trở thành một thành phần cốt lõi có khả năng giống hàng ngữ nghĩa và định hướng trong cơ chế chú ý. Tuy nhiên, các mô hình xây dựng từ đầu thường đòi hỏi dữ liệu ghép cặp quy mô lớn và chi phí huấn luyện cao, tạo tiền đề cho sự xuất hiện của các mô hình ngôn ngữ trực quan y khoa.

2.1.2 Mô hình ngôn ngữ trực quan y khoa - Med-VLMs

Các mô hình ngôn ngữ trực quan đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu, VLMs nói chung và Med-VLMs nói riêng tập trung vào hai nguồn dữ liệu đầu vào chính là ảnh và văn bản, Med-VLMs kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Chiến lược **học tương phản** là hướng tiếp cận được ứng dụng rộng rãi nhất. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau.

ConVIRT [48] là nghiên cứu tiên phong áp dụng học tương phản cho dữ liệu y khoa, sử dụng ResNet50 và BERT để tối ưu bộ mã hóa ảnh và văn bản, đạt độ chính xác 90,3% trên bộ dữ liệu COVIDx. GLORIA [15] mở rộng hướng tiếp cận này bằng cách kết hợp hai hàm mất mát toàn cục và cục bộ, cho phép căn chỉnh chi tiết giữa các vùng trong ảnh và các từ trong câu. MedCLIP [43] đề xuất cơ chế tách cặp và trích xuất tri thức cùng hàm mất mát khớp ngữ nghĩa nhằm giải quyết vấn đề âm tính giả — khi các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý. BiomedCLIP [47] kế thừa kiến trúc CLIP với bộ mã hóa ViT-Base và PubMedBERT, được tiền huấn luyện trên 15 triệu cặp dữ liệu từ tập PMC-15M, đạt độ chính xác phân lớp 83%, giúp mô hình có độ phủ và khả năng tổng quát tốt với nhiều nguồn dữ liệu và tác vụ y khoa.

Ngoài học tương phản, các hướng tiếp cận khác bao gồm **học có che giấu** và **tích hợp tri thức y khoa**. Tuy nhiên, các phương pháp này

thường phụ thuộc vào nguồn dữ liệu ghép cặp sẵn hoặc đồ thị tri thức chuyên biệt, hạn chế khả năng ứng dụng trên các bài toán không có sẵn nguồn tri thức ngoài.

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Phương pháp			
			Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	Học tương phản	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	Học tương phản	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	Học tương phản	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	Học tương phản	ViT-Base	PubMedBERT	Contrastive Alignment	N/a

Bảng 2.1: Bảng tổng hợp các mô hình ngôn ngữ trực quan y khoa sử dụng học tương phản.

Song song với các Med-VLMs, sự phát triển của các mô hình ngôn ngữ lớn (LLMs) đa phương thức như Med-Flamingo [30], LLaVA-Med [23] hay Med-PaLM M [41] đã cho thấy tiềm năng trong các tác vụ hội thoại và hỗ trợ ra quyết định y khoa. Tuy nhiên, các mô hình này thường có quy mô rất lớn, chi phí huấn luyện và suy luận cao, đồng thời vẫn tồn tại nguy cơ tạo ra thông tin không chính xác. Do đó, đối với các bài toán phân lớp chuyên biệt như phân lớp ảnh X-quang xương, việc sử dụng các mô hình ngôn ngữ - thị giác chuyên dụng kết hợp tinh chỉnh hiệu quả tham số thường phù hợp và hiệu quả hơn.

Lựa chọn BiomedCLIP làm mô hình nền tảng

Trong số các mô hình ngôn ngữ-thị giác y khoa được khảo sát, luận văn lựa chọn BiomedCLIP [47] làm mô hình nền tảng dựa trên mức độ phù hợp với bài toán, thay vì chỉ dựa trên kết quả của một bộ dữ liệu riêng lẻ. Thứ nhất, BiomedCLIP được tiền huấn luyện trên PMC-15M, gồm khoảng 15 triệu cặp ảnh-văn bản thu thập từ nhiều loại dữ liệu y sinh, trong khi một số mô hình trước đó chủ yếu được xây dựng và đánh giá trên ảnh X-quang ngực. Phạm vi tiền huấn luyện rộng hơn tạo cơ sở phù hợp cho việc chuyển giao sang ảnh X-quang xương, vốn có sự đa dạng lớn về vùng giải phẫu, tư thế chụp và loại tổn thương. Thứ hai, mô hình sử

dụng kiến trúc hai bộ mã hóa độc lập gồm Vision Transformer cho ảnh và PubMedBERT cho văn bản, phù hợp với thiết kế hai nhánh của hệ thống và cho phép kế thừa trực tiếp biểu diễn của cả hai phương thức. Thứ ba, kiến trúc CLIP của mô hình hỗ trợ đánh giá zero-shot thông qua độ tương đồng ảnh-văn bản, đồng thời có thể được mở rộng bằng các kỹ thuật tinh chỉnh hiệu quả tham số và mô-đun dung hợp cho bài toán đích. Vì vậy, BiomedCLIP được sử dụng làm backbone khởi tạo, trong khi các ý tưởng phù hợp từ những nghiên cứu khác, chẳng hạn hàm mất mát khớp ngữ nghĩa của MedCLIP, được kế thừa để cải thiện quá trình thích nghi trên dữ liệu X-quang xương. Kết quả phân lớp không mẫu của BiomedCLIP và các mô hình nền tảng khác được trình bày trong Phần 4.2.1.

Cơ chế phân lớp không mẫu của BiomedCLIP

BiomedCLIP có thể thực hiện phân lớp trong thiết lập *không mẫu* mà không cần huấn luyện một đầu phân lớp riêng trên dữ liệu đích. Thay vào đó, mô hình biểu diễn ảnh đầu vào và các câu nhắc mô tả lớp trong cùng một không gian đặc trưng, sau đó xác định lớp dựa trên mức độ tương đồng giữa hai phương thức.

Ảnh đầu vào x trước hết được tiền xử lý theo cấu hình của BiomedCLIP, bao gồm thay đổi kích thước, cắt vùng trung tâm và chuẩn hóa, để thu được tensor ảnh có kích thước 224×224 . Ảnh sau đó được chia thành các patch kích thước 16×16 và đưa qua bộ mã hóa thị giác ViT-B/16 để tạo biểu diễn ảnh.

Với mỗi lớp k , tên lớp được đưa vào một mẫu câu nhắc thống nhất, chẳng hạn **A radiograph showing [tên lớp]**. Câu nhắc được mã hóa bởi bộ mã hóa văn bản PubMedBERT để thu được biểu diễn văn bản t_k . Điểm số của lớp k được tính bằng độ tương đồng cosin:

$$s_k = \frac{v^\top t_k}{\|v\|_2 \|t_k\|_2}. \quad (2.1)$$

Các điểm tương đồng được chuẩn hóa bằng hàm Softmax để tạo phân phối xác suất trên tập lớp:

$$p(y = k | x) = \frac{\exp(s_k/\tau)}{\sum_{j=1}^K \exp(s_j/\tau)}, \quad (2.2)$$

trong đó τ là hệ số nhiệt độ. Lớp có xác suất lớn nhất được chọn làm kết quả dự đoán. Cơ chế này cho phép BiomedCLIP chuyển giao tri thức đã học sang các tập nhãn mới mà không cần cập nhật tham số. Tuy nhiên, hiệu quả phụ thuộc đáng kể vào mức độ tương đồng giữa dữ liệu tiền huấn luyện và dữ liệu đích, cách xây dựng câu nhắc, cũng như khả năng biểu diễn các dấu hiệu bệnh lý chuyên biệt của bộ mã hóa.

2.2 Biểu diễn ảnh độ phân giải cao và thông tin không gian

Ảnh y khoa thường có độ phân giải cao để ghi nhận được các dấu hiệu bệnh lý nhỏ, trong khi các bộ mã hóa thị giác tiền huấn luyện thường yêu cầu kích thước đầu vào cố định ở kích thước nhỏ. Việc co toàn bộ ảnh về kích thước nhỏ giúp giảm chi phí tính toán nhưng có thể làm mất các chi tiết cục bộ. Ngược lại, xử lý trực tiếp ảnh độ phân giải cao làm tăng bộ nhớ cần sử dụng và chi phí tính toán cao của cơ chế chú ý. FPT [16] giải quyết sự đánh đổi này bằng cách lựa chọn một phần token kết hợp với mạng nhánh, cho thấy việc thích nghi mô hình nền tảng cho ảnh y khoa cần đồng thời bảo toàn chi tiết và kiểm soát bộ nhớ.

Trong các mô hình ngôn ngữ-thị giác tổng quát, LLaVA-NeXT [22] đề xuất AnyRes, trong đó ảnh được biểu diễn bởi một ảnh toàn cục và nhiều ô ảnh cục bộ theo lưới thích nghi. Phiên bản Higher-AnyRes mở rộng số ô ảnh để hỗ trợ đầu vào có độ phân giải lớn hơn, đồng thời giới hạn tổng số token bằng phép nội suy đặc trưng. Các thí nghiệm cho thấy tăng độ phân giải quan sát thường cải thiện các tác vụ phụ thuộc vào chi tiết, trong khi tăng mạnh số token hoặc phóng lớn ảnh một cách cưỡng bức làm tăng chi phí nhưng không luôn đem lại hiệu quả tương ứng. Kết quả này nhấn mạnh rằng mục tiêu chính là giữ lại thông tin cục bộ hữu ích trong một ngân sách token phù hợp.

Đối với ảnh y khoa, MedBridge [24] áp dụng chiến lược đa góc nhìn gồm một ảnh toàn cục và nhiều vùng cục bộ được lấy từ ảnh X-quang độ phân giải cao. Cách biểu diễn này duy trì ngữ cảnh giải phẫu của toàn ảnh, đồng thời giúp các dấu hiệu bệnh lý khu trú được quan sát ở độ phân giải phù hợp với bộ mã hóa. Kết quả loại bỏ thành phần cho thấy việc không sử dụng lấy mẫu đa góc nhìn làm hiệu năng giảm, qua đó cung cấp bằng chứng thực nghiệm cho lợi ích của biểu diễn toàn cục-cục bộ trên ảnh X-quang. Tuy nhiên, nghiên cứu được thực hiện chủ yếu trên X-quang ngực và kết hợp thêm các mô-đun thích nghi khác, nên hiệu quả trên X-quang xương vẫn cần được kiểm chứng riêng.

Ngoài phương pháp chia vùng, Perceiver [17] và Flamingo [1] sử dụng tập truy vấn hoặc latent có kích thước cố định để nén số lượng lớn đặc trưng thị giác. Hướng tiếp cận này giúp kiểm soát độ dài chuỗi, nhưng việc nén quá mạnh có thể làm mất các tín hiệu nhỏ. Nhìn chung, các nghiên cứu hiện nay cho thấy biểu diễn ảnh độ phân giải cao cần cân bằng ba yếu tố: ngữ cảnh toàn cục, chi tiết cục bộ và chi phí tính toán. Đây là cơ sở cho việc nghiên cứu chiến lược toàn cục-cục bộ với ngân sách token cố định trong bài toán phân lớp ảnh X-quang xương.

Bảng tổng hợp về các chiến lược xử lý ảnh độ phân giải cao và sự đánh đổi chính được trình bày trong Bảng 2.2.

2.3 Các kỹ thuật tinh chỉnh hiệu quả tham số

Sự xuất hiện của các Mô hình Nền tảng nói chung và Mô hình Ngôn ngữ - Thị giác Y sinh nói riêng đã mang lại một nền tảng tri thức đa phương thức khổng lồ. Tuy nhiên, để triển khai hiệu quả các mô hình này vào các bài toán lâm sàng đặc thù, quá trình chuyển giao tri thức là bắt buộc.

Hướng đến yêu cầu cụ thể hơn cho bài toán sử dụng hai nguồn ảnh và văn bản lâm sàng, luận văn tập trung vào các kỹ thuật tinh chỉnh để khai thác tối đa từ hai nguồn dữ liệu này với đặc điểm dữ liệu thực tế còn hạn chế.

Chiến lược	Đặc điểm	Khả năng đáp ứng	Hạn chế cần xem xét
Co giãn ảnh toàn cục	Một ảnh được đưa về kích thước cố định	Chi phí thấp và duy trì bố cục tổng thể	Có thể làm mất các dấu hiệu nhỏ hoặc khu trú.
Xử lý trực tiếp ảnh độ phân giải cao	Tăng kích thước ảnh hoặc số lượng patch	Giữ lại nhiều chi tiết hơn; FPT [16] xem xét sự đánh đổi giữa khả năng bảo toàn chi tiết và chi phí bộ nhớ trong ảnh y khoa	Số lượng token và chi phí của cơ chế chú ý tăng nhanh.
AnyRes và Higher-AnyRes	Kết hợp ảnh toàn cục với các vùng ảnh theo lưới thích nghi và giới hạn số token bằng phép nội suy	Tăng độ phủ không gian và cải thiện các tác vụ phụ thuộc vào chi tiết [22]	Lưới đều có thể xử lý nhiều vùng không liên quan; bằng chứng thực nghiệm chủ yếu đến từ dữ liệu phi y khoa.
Latent resampling	Nén tập token đầu vào thành một số lượng latent cố định	Kiểm soát độ dài chuỗi và chi phí kết nối đa phương thức	Có nguy cơ làm mất các tín hiệu nhỏ và phụ thuộc vào khả năng tối ưu các truy vấn học được [17, 1].
Toàn cục-cục bộ đa góc nhìn	Kết hợp ảnh toàn cục với nhiều vùng cục bộ được trích xuất từ ảnh gốc	Phù hợp với các dấu hiệu bệnh lý nhỏ và khu trú; MedBridge cho thấy hiệu quả trên ảnh X-quang ngược [24]	Làm tăng số lần thực thi backbone; hiệu quả phụ thuộc vào cách lựa chọn vùng và chưa được kiểm chứng trực tiếp trên ảnh X-quang xương.

Bảng 2.2: Các chiến lược xử lý ảnh độ phân giải cao và sự đánh đổi chính.

Trước đây, hai chiến lược phổ biến nhất là tinh chỉnh toàn phần và dò tuyến tính. Tinh chỉnh toàn phần cập nhật lại toàn bộ tham số của mô hình gốc, mang lại khả năng thích ứng cao nhưng đòi hỏi chi phí tính toán, bộ nhớ khổng lồ, yêu cầu dữ liệu huấn luyện lớn đến rất lớn, dẫn đến hiện tượng "quên thăm khốc" trên các tập dữ liệu y tế nhỏ. Ngược lại, dò tuyến tính đóng băng toàn bộ mạng nơ-ron gốc và chỉ huấn luyện một lớp phân lớp duy nhất ở cuối, tiết kiệm tài nguyên nhưng hạn chế khả năng thích ứng khi sự chênh lệch phân phối giữa dữ liệu gốc và dữ liệu y tế là quá lớn.

Để giải quyết bài toán đánh đổi giữa hiệu năng và chi phí tính toán, Tinh chỉnh Hiệu quả Tham số - PEFT đã nổi lên như một giải pháp thay thế. Kỹ thuật này chỉ cập nhật hoặc thêm mới một lượng rất nhỏ tham số, giúp tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các phương pháp PEFT được chia thành ba hướng tiếp cận chính:

2.3.1 Tinh chỉnh sử dụng câu nhắc

Hướng tiếp cận này chèn thêm các tham số (vector) có thể học được vào không gian đầu vào của mô hình mà không thay đổi cấu trúc mạng bên trong.

- **Điểm mạnh:** Tiết kiệm tham số tối đa, bảo toàn nguyên vẹn tri thức của mô hình gốc, đặc biệt hiệu quả trong các kịch bản học ít mẫu hoặc không mẫu.
- **Điểm yếu:** Tối ưu hóa khó khăn do không gian biểu diễn bị giới hạn ở đầu vào, nhạy cảm với cách khởi tạo, và chiếm dụng một phần độ dài của chuỗi đầu vào.

Trong lĩnh vực y tế, PLIP [46] kết hợp đặc trưng thị giác với câu nhắc hiệu quả, đạt 0,896 AUC chỉ với 5% dữ liệu PanNuke. BiomedCoOp [18] tích hợp mô hình ngôn ngữ lớn để tự động sinh các câu nhắc ngữ nghĩa, đồng bộ hóa qua cơ chế chú ý chéo và cân chỉnh tương phản.

2.3.2 Tinh chỉnh bộ điều hợp

Phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ, còn được gọi là bộ điều hợp vào giữa các lớp kiến trúc của mạng học sâu.

- **Điểm mạnh:** Tính mô-đun hóa cao, dễ dàng thêm/bớt các bộ điều hợp cho các tác vụ khác nhau mà không can thiệp vào tham số gốc.
- **Điểm yếu:** Việc chèn thêm các lớp mạng vật lý làm tăng độ trễ suy luận, hạn chế khả năng triển khai trên các hệ thống đòi hỏi thời gian thực.

Diễn hình, CLIPath [19] sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu nhỏ. FTB [33] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức.

2.3.3 Tinh chỉnh chọn lọc

Hướng đi này không thêm bất kỳ tham số mới nào, mà chỉ chọn lọc ra một lượng nhỏ các tham số quan trọng nhất của mô hình gốc để cập nhật.

- **Điểm mạnh:** Không làm thay đổi kiến trúc mô hình, hoàn toàn không gây tăng độ trễ (zero inference latency) do tham số cập nhật được hợp nhất trực tiếp vào trọng số gốc.
- **Điểm yếu:** Đòi hỏi phương pháp heuristic phức tạp để xác định chính xác các tham số nào ảnh hưởng lớn nhất đến hiệu năng của tác vụ mục tiêu.

Nổi bật nhất trong nhóm này là cơ chế thích ứng hạng thấp LoRA. LoRA đóng băng toàn bộ trọng số của mô hình tiền huấn luyện, đồng thời thêm các ma trận phân rã hạng thấp vào các khối chú ý. LCBB [25] áp dụng LoRA và đạt 93,1% AUROC trên tập RSNA với chỉ 10% dữ liệu gán nhãn, bám sát hiệu năng của tinh chỉnh toàn phần nhưng giảm thiểu tối đa chi phí.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Nguyên lý	Kết quả nổi bật
1	PLIP (2024)	Tinh chỉnh sử dụng câu nhắc	Kết hợp câu nhắc thị giác với tinh chỉnh chọn lọc, tận dụng đặc trưng hình ảnh để tinh chỉnh hiệu quả	0,896 AUC (5% PanNuke)
2	CLIPath (2023)	Tinh chỉnh sử dụng bộ điều hợp	Sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu mô bệnh học	Cải thiện so với CLIP trên dữ liệu nhỏ
3	LCBB (2024)	Tinh chỉnh chọn lọc (LoRA)	Áp dụng LoRA vào bộ mã hóa thị giác, giữ nguyên hiệu năng tinh chỉnh toàn phần	93,1% AUROC (RSNA, 10%)
4	FTB (2024)	Tinh chỉnh sử dụng bộ điều hợp	Mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản, chất lọc thông tin đa phương thức	Cải thiện trên CheXpert, RSNA

Bảng 2.3: Bảng tổng hợp các phương pháp tinh chỉnh hiệu quả tham số đại diện cho các mô hình ngôn ngữ trực quan y khoa.

2.4 Các phương pháp phát hiện dữ liệu ngoài phân phối

Phát hiện dữ liệu ngoài phân phối (Out-of-Distribution - OOD) là bài toán cốt lõi nhằm xác định các mẫu dữ liệu không thuộc phân phối của tập huấn luyện (In-Distribution - ID). Đặc biệt trong lĩnh vực phân tích ảnh y khoa, khả năng từ chối dự đoán đối với các mẫu dữ liệu lạ giúp ngăn chặn các chẩn đoán sai lệch với độ tự tin cao, từ đó đảm bảo tính an toàn của hệ thống. Dựa trên cách tiếp cận, các phương pháp OOD hiện nay được chia thành các nhóm chính sau.

2.4.1 Các phương pháp hậu xử lý dựa trên đầu ra của mô hình

Nhóm phương pháp này không can thiệp vào quá trình huấn luyện mà tận dụng trực tiếp đầu ra (thường là các logit hoặc xác suất) của một bộ phân lớp đã được huấn luyện.

- Maximum Softmax Probability (MSP) [12]:** Sử dụng giá trị cực đại của hàm Softmax làm độ tin cậy. Dữ liệu có xác suất cực đại thấp sẽ bị đánh dấu là OOD. Tuy nhiên, điểm yếu chí mạng của MSP là các mạng nơ-ron sâu thường mắc lỗi "tự tin thái quá", dẫn đến việc gán xác suất rất cao cho cả những mẫu OOD hoàn toàn không liên quan.

- **ODIN (Out-of-Distribution detector for Neural Networks)** [26]: Cải thiện MSP bằng cách sử dụng hiệu chỉnh nhiệt độ và thêm nhiễu đầu vào để gia tăng sự chênh lệch logit giữa dữ liệu trong phân phối và dữ liệu ngoài phân phối.
- **Điểm năng lượng [27]:** Chuyển đổi vector logit thành hàm năng lượng thay vì xác suất Softmax:

$$E(x) = -T \log \sum_i \exp \left(\frac{f_i(x)}{T} \right)$$

trong đó $f_i(x)$ là logit của lớp thứ i và T là hệ số nhiệt độ. Mặc dù điểm năng lượng khai thác độ lớn tuyệt đối của các logit và thường khắc phục một phần hiện tượng quá tự tin của Softmax, các phương pháp hậu xử lý dựa trên đầu ra vẫn phụ thuộc mạnh vào biểu diễn và biên quyết định của bộ phân lớp đã huấn luyện. Do mô hình phân lớp đóng buộc mọi đầu vào vào một trong các lớp đã biết, các mẫu OOD nằm xa dữ liệu huấn luyện vẫn có thể nhận điểm tin cậy cao.

2.4.2 Các phương pháp dựa trên độ không chắc chắn và tái tạo

Để tránh phụ thuộc vào đầu ra Softmax, một số nghiên cứu tiếp cận bài toán bằng cách đánh giá khả năng sinh hoặc sự bất định của mô hình.

- **Sai số tái tạo:** Sử dụng các mô hình sinh như bộ tự mã hóa (AE) được huấn luyện chỉ trên dữ liệu ID. Khi gặp dữ liệu OOD, sai số tái tạo sẽ tăng đột biến. Dù hiệu quả, phương pháp này gặp khó khăn khi tái tạo các ảnh y khoa có độ phân giải cao và chi tiết phức tạp.
- **Monte Carlo Dropout (MC Dropout):** Kích hoạt Dropout trong quá trình suy luận và thực hiện dự đoán nhiều lần để tính phương sai. Tuy nhiên, việc phải suy luận nhiều lần làm tăng chi phí tính toán, không phù hợp cho các hệ thống đòi hỏi thời gian thực.

2.4.3 Các phương pháp dựa trên khoảng cách trong không gian đặc trưng

Nhận thấy những hạn chế của không gian logit, các nghiên cứu gần đây chuyển hướng sang thực hiện phát hiện OOD trực tiếp trên không gian đặc trưng. Việc đánh giá bằng khoảng cách giúp giới hạn không gian rủi ro mở.

- **Khoảng cách Euclidean và Cosine:** Khoảng cách Euclidean đo khoảng cách hình học tuyệt đối $d_E(z, c_k) = \|z - c_k\|_2$, trong khi Cosine chỉ xét góc giữa các vector. Điểm yếu của chúng là giả định phân phối của các cụm dữ liệu có dạng hình cầu hoàn hảo và phương sai đồng đều ở mọi chiều, điều hiếm khi xảy ra trong thực tế dữ liệu phức tạp.
- **Khoảng cách Mahalanobis [21]:** Khắc phục điểm yếu của Euclidean bằng cách xét đến ma trận hiệp phương sai (covariance matrix), giúp đo lường khoảng cách dựa trên cả hình dáng và hướng của phân phối dữ liệu:

$$d_M(z, \mu_k) = (z - \mu_k)^\top (\Sigma + \lambda I)^{-1} (z - \mu_k)$$

Trong đó, z là embedding của mẫu kiểm thử, μ_k là tâm cụm lớp k , và Σ là ma trận hiệp phương sai. Mahalanobis mô tả ranh giới phân phối dữ liệu chính xác và mềm dẻo hơn.

2.4.4 Học biểu diễn phục vụ phát hiện dữ liệu ngoài phân phối

Sự thành công của các phương pháp dựa trên khoảng cách phụ thuộc rất lớn vào chất lượng của không gian đặc trưng. Nếu mô hình được huấn luyện bằng hàm Cross-Entropy thông thường, dữ liệu của các lớp không được tối ưu để co cụm lại, làm giảm hiệu quả của các phép đo khoảng cách. Để giải quyết vấn đề này, các kỹ thuật học biểu diễn (Representation

Learning) được áp dụng.

- **Contrastive Learning:** Học biểu diễn bằng cách kéo gần các mẫu tương đồng và đẩy xa các mẫu khác lớp trong không gian đặc trưng.
- **Center Loss [44]:** Giảm phương sai nội lớp bằng cách học một tâm biểu diễn cho mỗi lớp và ép các embedding tiến gần tâm tương ứng.
- **Prototypical Networks (ProtoNet) [39]:** Là một kiến trúc mạng học theo hệ đo (Metric Learning), ProtoNet định nghĩa trực tiếp mỗi lớp bằng một nguyên mẫu (prototype) c_k :

$$c_k = \frac{1}{|S_k|} \sum_{x_i \in S_k} f_{\theta}(x_i)$$

Trong quá trình huấn luyện, mạng được tối ưu hóa để cực tiểu hóa khoảng cách giữa đặc trưng của dữ liệu và prototype tương ứng của nó.

2.5 Bàn luận

2.5.1 Hạn chế của các nghiên cứu hiện nay

Mặc dù đạt được nhiều kết quả tích cực, các nghiên cứu hiện có vẫn chưa giải quyết đồng thời các yêu cầu của bài toán phân lớp ảnh X-quang xương đa phương thức. Cùng với những hạn chế của mô hình BiomedCLIP khi phân lớp trực tiếp đã được trình bày trong Phần 2.1.2, các vấn đề chính được tổng hợp như sau:

Thứ nhất, phần lớn mô hình y khoa đa phương thức được phát triển trên X-quang ngực hoặc các bộ dữ liệu lớn. Ảnh X-quang xương có phạm vi giải phẫu, tư thế chụp và kiểu tổn thương đa dạng, trong khi số lượng mẫu giữa các lớp thường mất cân bằng đáng kể. Vì vậy, hiệu quả trên các miền dữ liệu khác chưa thể được chuyển trực tiếp sang bài toán này.

Thứ hai, việc co toàn bộ ảnh về kích thước cố định có thể làm mất các đường gãy hoặc bất thường khu trú. Ngược lại, xử lý toàn bộ ảnh ở độ

phân giải cao hoặc chia thành quá nhiều vùng làm số token và chi phí tính toán tăng nhanh. Do đó, cần kết hợp ngữ cảnh toàn cục với các vùng cục bộ có ích trong một ngân sách token được kiểm soát.

Thứ ba, nhiều nghiên cứu sử dụng báo cáo đọc ảnh hoặc kết luận chẩn đoán làm đầu vào văn bản. Tuy nhiên, các báo cáo này thường được hình thành sau khi bác sĩ hoặc bác sĩ chẩn đoán hình ảnh đã quan sát phim và có thể mô tả trực tiếp vị trí, hình thái hoặc mức độ tổn thương, chẳng hạn đường gãy, di lệch hay bất thường xương. Việc sử dụng các nguồn văn bản này trong giai đoạn suy luận có thể gây rò rỉ nhãn, khiến mô hình chủ yếu học cách ánh xạ một mô tả gần với kết luận chẩn đoán sang nhãn tương ứng. Trong bối cảnh triển khai thực tế, để tạo được báo cáo chi tiết, bác sĩ đã phải nhận diện tổn thương trước, do đó mô hình không còn đóng vai trò hỗ trợ phát hiện mà chủ yếu lặp lại thông tin đã được xác định. Ngược lại, các thông tin lâm sàng có sẵn trước chẩn đoán cuối cùng, như triệu chứng, tiền sử bệnh, vị trí đau hoặc cơ chế chấn thương, vẫn chưa được khai thác đầy đủ, mặc dù đây là những nguồn thông tin quan trọng giúp định hướng quá trình chẩn đoán. Bên cạnh đó, nhiều phương pháp chỉ nối hai vector đặc trưng toàn cục, nên chưa mô hình hóa được quan hệ cụ thể giữa các vùng ảnh và nội dung lâm sàng liên quan.

Thứ tư, mặc dù các mô hình nền tảng đạt hiệu quả cao, nhiều nghiên cứu vẫn lựa chọn tính chỉnh toàn bộ tham số của mô hình. Cách tiếp cận này đòi hỏi chi phí tính toán lớn, đồng thời làm tăng nguy cơ quên tri thức đã được học trong giai đoạn tiền huấn luyện.

Cuối cùng, hầu hết các nghiên cứu chỉ tập trung tối ưu hiệu năng phân lớp mà chưa quan tâm đầy đủ đến khả năng phát hiện dữ liệu ngoài phân phối. Trong môi trường lâm sàng, mô hình có thể gặp các trường hợp bệnh lý hiếm, dữ liệu có chất lượng thấp hoặc các bất thường chưa xuất hiện trong tập huấn luyện. Nếu không có cơ chế phát hiện OOD, mô hình vẫn có thể đưa ra dự đoán với độ tin cậy cao mặc dù kết quả không chính xác.

2.5.2 Cơ sở lựa chọn và định hướng phương pháp đề xuất

Từ những hạn chế trên, luận văn lựa chọn xây dựng hệ thống dựa trên việc kế thừa mô hình BiomedCLIP [47] kết hợp với thông tin lâm sàng để khai thác đồng thời đặc trưng hình ảnh và văn bản. Các lựa chọn thiết kế cụ thể được đưa ra dựa trên phân tích sau:

Về xử lý ảnh độ phân giải cao: Việc co toàn bộ ảnh X-quang về kích thước đầu vào cố định có thể làm suy giảm các dấu hiệu tổn thương nhỏ, trong khi xử lý toàn bộ ảnh ở độ phân giải cao làm tăng đáng kể chi phí tính toán. Vì vậy, luận văn lựa chọn chiến lược toàn cục-cục bộ, trong đó ảnh toàn cục duy trì bố cục giải phẫu chung, còn bốn vùng cục bộ được lựa chọn theo chiến lược sparse-focal nhằm bảo toàn các vùng giàu thông tin. Các đặc trưng cục bộ được bổ sung thông tin vị trí và nén về số lượng token cố định để cân bằng giữa khả năng giữ lại chi tiết và chi phí xử lý.

Về thích nghi mô hình nền tảng: LoRA [13] được sử dụng để thích nghi hai bộ mã hóa của BiomedCLIP với miền ảnh X-quang xương mà không cần cập nhật toàn bộ tham số nền. Lựa chọn này giúp giảm chi phí huấn luyện, hạn chế nguy cơ quá khớp trên các lớp có ít mẫu và bảo toàn phần lớn tri thức y sinh đã được học trong giai đoạn tiền huấn luyện.

Bên cạnh đó, hàm mất mát tương phản InfoNCE nguyên bản xem các mẫu khác nhau trong cùng lô là các cặp âm, kể cả khi chúng thuộc cùng một lớp hoặc có nội dung lâm sàng tương đồng. Do đó, luận văn sử dụng hàm mất mát khớp ngữ nghĩa với phân phối đích mềm theo nhãn lớp. Mục tiêu này vẫn ưu tiên sự tương hợp của cặp ảnh-văn bản tương ứng, đồng thời giảm ảnh hưởng của các cặp âm tính giả giữa những mẫu có quan hệ ngữ nghĩa gần nhau.

Về khai thác và dung hợp thông tin lâm sàng: Thiết lập phân lớp không mẫu của BiomedCLIP chỉ đối sánh ảnh với các câu nhắc đại diện cho lớp và không sử dụng thông tin riêng của từng người bệnh. Phương pháp đề xuất bổ sung nhánh văn bản để mã hóa những thông tin lâm sàng có sẵn trước kết luận chẩn đoán, chẳng hạn lý do vào viện, triệu chứng và bệnh sử. Báo cáo đọc ảnh, chẩn đoán xác định và nhãn phân lớp không

được đưa trực tiếp vào đầu vào nhằm hạn chế rò rỉ nhãn.

Thay vì chỉ ghép nối hai biểu diễn toàn cục, luận văn lựa chọn cơ chế chú ý chéo hai chiều để đặc trưng ảnh lựa chọn các thông tin lâm sàng liên quan, đồng thời đặc trưng văn bản định hướng mô hình đến các vùng ảnh phù hợp. Thiết kế này cho phép mô hình hóa quan hệ cụ thể giữa dấu hiệu X-quang và ngữ cảnh lâm sàng.

Về phân lớp đa lớp và mất cân bằng dữ liệu: Phương pháp sử dụng đầu phân lớp dựa trên tâm lớp thực nghiệm, trong đó mỗi lớp được đại diện bằng trung bình các embedding thuộc lớp đó thay vì một prototype được học tự do. Mẫu mới được phân lớp dựa trên độ tương đồng với các tâm lớp. Hàm mất mát entropy chéo có trọng số được sử dụng trong quá trình huấn luyện nhằm giảm ảnh hưởng của sự chênh lệch số lượng mẫu giữa các lớp.

Về phát hiện dữ liệu ngoài phân phối: Ngoài nhiệm vụ phân lớp, luận văn bổ sung cơ chế phát hiện OOD ở giai đoạn hậu xử lý mà không yêu cầu mẫu OOD trong quá trình huấn luyện. Khoảng cách Mahalanobis được tính giữa biểu diễn của mẫu mới và các tâm lớp thực nghiệm, có xét đến cấu trúc hiệp phương sai của không gian đặc trưng. Mẫu có khoảng cách nhỏ nhất vượt quá ngưỡng xác định trên tập kiểm định sẽ được đánh dấu là dữ liệu ngoài phân phối thay vì buộc phải gán vào một lớp đã biết.

Về quy trình huấn luyện: Từ các lựa chọn trên, hệ thống được tổ chức thành hai giai đoạn ngoại tuyến:

- **Giai đoạn 1 - Thích nghi và căn chỉnh biểu diễn:** hai bộ mã hóa của BiomedCLIP được thích nghi thông qua LoRA bằng hàm mất mát khớp ngữ nghĩa. Mô-đun dung hợp và đầu phân lớp chưa được tối ưu trong giai đoạn này.
- **Giai đoạn 2 - Dung hợp và phân lớp:** các bộ mã hóa tiếp tục được thích nghi thông qua LoRA, đồng thời mô-đun xử lý đặc trưng cục bộ và cơ chế chú ý chéo hai chiều được tối ưu cho nhiệm vụ phân lớp. Các tâm lớp thực nghiệm được cập nhật từ embedding của tập huấn luyện và được sử dụng cho cả phân lớp lẫn phát hiện OOD.

Các định hướng trên được hiện thực hóa trong phương pháp XBone-


Net. Kiến trúc chi tiết, quy trình huấn luyện và cơ chế suy luận được trình bày trong Chương 3.

Chương 3

Phương pháp đề xuất

3.1 Tổng quan phương pháp đề xuất

Nhóm nghiên cứu đề xuất XBone-Net cho bài toán phân lớp đa lớp ảnh X-quang xương có kết hợp thông tin lâm sàng. Hệ thống được xây dựng theo kiến trúc hai nhánh. Nhánh ảnh khai thác đồng thời cấu trúc giải phẫu toàn cục và các vùng cục bộ giàu chi tiết, trong khi nhánh văn bản biểu diễn bệnh sử và lý do vào viện. Hai nguồn thông tin được ánh xạ vào cùng một không gian đặc trưng, trao đổi ngữ cảnh bằng cơ chế chú ý chéo hai chiều, sau đó được phân lớp bằng mạng nguyên mẫu.



Hình 3.1: Sơ đồ tổng quan phương pháp XBone-Net đề xuất

Như minh họa trong Hình 3.1, XBone-Net kế thừa bộ mã hóa thị giác và bộ mã hóa văn bản của BiomedCLIP [47]. Các tham số nền được giữ cố định để bảo toàn tri thức y sinh đã học trước, trong khi các ma trận thích nghi hạng thấp LoRA [13] được huấn luyện trên dữ liệu đích. Sau bước

mã hóa, mô-đun dung hợp kết hợp đặc trưng toàn cục và cục bộ của hai phương thức. Biểu diễn tổng hợp cuối cùng được so sánh với các nguyên mẫu lớp để đưa ra dự đoán.

Mỗi mẫu dữ liệu được ký hiệu bởi bộ ba gồm ảnh X-quang, thông tin lâm sàng và nhãn lớp. Tập huấn luyện có dạng:

$$\mathcal{D}_{\text{train}} = \left\{ \left(x_i^{\text{img}}, x_i^{\text{txt}}, y_i \right) \right\}_{i=1}^N, \quad y_i \in \mathcal{Y}. \quad (3.1)$$

Trong đó, $x_i^{\text{img}} \in \mathbb{R}^{H_i \times W_i \times C_{\text{in}}}$ là ảnh X-quang của mẫu thứ i ; H_i , W_i và C_{in} lần lượt là chiều cao, chiều rộng và số kênh ảnh. Thông tin lâm sàng được ký hiệu $x_i^{\text{txt}} = (w_{i,1}, \dots, w_{i,L_i})$, với L_i là số token trước khi cắt hoặc đệm. Nhãn y_i thuộc tập chỉ số lớp $\mathcal{Y} = \{1, \dots, K\}$, còn N là số mẫu huấn luyện.

Quá trình xây dựng mô hình được chia thành hai giai đoạn ngoại tuyến. Giai đoạn thứ nhất thích nghi hai nhánh mã hóa và căn chỉnh không gian ảnh-văn bản bằng hàm mất mát khớp ngữ nghĩa. Giai đoạn thứ hai học cơ chế dung hợp và ranh giới phân lớp trong không gian nguyên mẫu. Khi suy luận trực tuyến, toàn bộ tham số và các nguyên mẫu lớp được cố định, mô hình chỉ thực hiện tính toán truyền thuận cho một ca mới.


Để làm rõ cách hệ thống chuyển đổi từng nguồn dữ liệu thành biểu diễn có thể sử dụng cho quá trình dung hợp, các phần tiếp theo lần lượt trình bày nhánh biểu diễn ảnh, nhánh biểu diễn văn bản và cơ chế thích nghi hai bộ mã hóa trước khi đi đến mô-đun dung hợp và phân lớp.

3.2 Nhánh biểu diễn ảnh

3.2.1 Tiền xử lý ảnh X-quang và xử lý độ phân giải cao

Ảnh X-quang đầu vào x_i^{img} có kích thước và tỷ lệ khung hình khác nhau, trong khi bộ mã hóa thị giác của BiomedCLIP nhận ảnh vuông 224×224 . Để giữ đồng thời bố cục chung và chi tiết cục bộ, mỗi ảnh được chuyển thành một ảnh toàn cục $x_i^{\text{img},g}$ và bốn ảnh cục bộ $\{x_{i,m}^{\text{img},\ell}\}_{m=1}^4$. Việc chọn

vùng chỉ sử dụng giá trị điểm ảnh, không sử dụng nhãn, bệnh sử hoặc chú thích tổn thương.



Hình 3.2: Quy trình tạo ảnh toàn cục và bốn ảnh cục bộ từ ảnh X-quang

Xác định vùng nội dung và tạo ảnh toàn cục

Ảnh được chuyển sang thang xám, chuẩn hóa cường độ về $[0, 1]$ và thu nhỏ tạm thời sao cho cạnh dài không vượt quá 512 điểm ảnh. Mức nền được ước lượng bằng trung vị của dải biên, còn độ phân tán được ước lượng bằng độ lệch tuyệt đối trung vị với hệ số hiệu chỉnh 1,4826. Điểm ảnh có độ lệch so với nền không nhỏ hơn giá trị lớn hơn giữa 0,035 và bốn lần độ phân tán được xem là tiền cảnh.

Hộp nội dung được xác định từ các hàng và cột có ít nhất 1% điểm ảnh tiền cảnh. Các đoạn liên tục ngắn hơn 3% chiều tương ứng bị loại và hộp được mở rộng thêm 4%. Nếu chiều rộng hoặc chiều cao của hộp dưới 35% kích thước ảnh, diện tích dưới 20% hoặc năng lượng tương phản được giữ lại dưới 95%, toàn bộ ảnh được sử dụng để hạn chế cắt mất cấu trúc giải phẫu. Vùng nội dung sau đó được đổi kích thước đồng nhất trên hai trục bằng nội suy hai chiều bậc ba, đệm bằng trung vị màu biên thành ảnh vuông 224×224 và chuẩn hóa theo đầu vào của BiomedCLIP để tạo ảnh toàn cục $x_i^{img,g}$.

Sinh và lựa chọn vùng cục bộ

Vùng nội dung được thu nhỏ sao cho cạnh dài không vượt quá 896 điểm ảnh mà không phóng lớn ảnh nhỏ. Trên ảnh trung gian, các cửa sổ 224×224 được sinh với bước dịch chuyển 168 điểm ảnh; vị trí cuối mỗi trục được bổ sung để phủ phần biên. Các cửa sổ có tỷ lệ tiền cảnh từ 60% trở lên được ưu tiên xem xét. Mặt nạ tại bước này được tính lại với mức nền là khoảng cường độ xuất hiện nhiều nhất tại biên.

Mỗi cửa sổ b được đánh giá bằng lượng biến thiên cục bộ, entropy mức xám và tỷ lệ tiền cảnh. Đáp ứng Laplacian làm nổi bật biến thiên cường độ và biên ảnh [28]; các độ đo dựa trên Laplacian cũng thường được sử dụng để đánh giá lượng chi tiết hoặc độ sắc nét cục bộ [32]. Với lân cận bốn hướng, năng lượng Laplacian của cửa sổ được tính bởi:

$$\begin{aligned}\Delta x_i^{gray}(u, v) &= 4x_i^{gray}(u, v) - x_i^{gray}(u-1, v) - x_i^{gray}(u+1, v) \\ &\quad - x_i^{gray}(u, v-1) - x_i^{gray}(u, v+1), \\ E_i(b) &= \frac{1}{|b|} \sum_{(u,v) \in b} |\Delta x_i^{gray}(u, v)|.\end{aligned}\tag{3.2}$$

Entropy Shannon mô tả mức độ đa dạng của phân bố cường độ [38]. Với histogram gồm 32 khoảng mức xám và $\pi_{i,k}(b)$ là tỷ lệ điểm ảnh của cửa sổ b thuộc khoảng thứ k , entropy chuẩn hóa được xác định bởi:

$$H_i(b) = -\frac{1}{\log_2 32} \sum_{k: \pi_{i,k}(b) > 0} \pi_{i,k}(b) \log_2 \pi_{i,k}(b).\tag{3.3}$$

Hai đại lượng trên được chuẩn hóa min-max trong phạm vi các cửa sổ của cùng ảnh; nếu mọi giá trị bằng nhau thì kết quả chuẩn hóa được đặt bằng 0. Điểm tổng hợp của mỗi cửa sổ được xác định bởi:

$$q_i(b) = 0,55 \hat{E}_i(b) + 0,35 \hat{H}_i(b) + 0,10 r_i(b),\tag{3.4}$$

trong đó $\hat{E}_i$ và $\hat{H}_i$ lần lượt là năng lượng Laplacian và entropy đã chuẩn hóa, r_i là tỷ lệ tiền cảnh. Bộ trọng số phản ánh mức ưu tiên giảm dần theo tính trực tiếp của tín hiệu đối với tổn thương xương: năng lượng Laplacian

nhận trọng số cao nhất vì phản ánh trực tiếp biến thiên cường độ tại đường gãy và bờ u; entropy bổ sung thông tin về độ phức tạp kết cấu nhưng cũng nhạy với nhiễu nền nên nhận trọng số trung bình; tỷ lệ tiền cảnh chỉ đóng vai trò phạt nhẹ vùng nền vì hai thành phần kia đã ngầm ưu tiên vùng có cấu trúc. Tổng bộ ba trọng số bằng 1,00 để điểm nằm trong khoảng $[0, 1]$.

Bốn cửa sổ được chia thành hai vai trò. Hai cửa sổ bao phủ được chọn gần các vị trí phân bố trên trục dài của vùng nội dung và ưu tiên vùng chứa nhiều tiền cảnh. Hai cửa sổ tiêu điểm ưu tiên điểm tổng hợp q_i cao, đồng thời được khuyến khích cách xa các vùng đã chọn với trọng số đa dạng 0,35. Các ứng viên có mức giao trên hợp lớn hơn 0,30 bị loại; ngưỡng này nằm trong khoảng $[0,30; 0,50]$ thường dùng trong loại bỏ trùng lặp để khuyến khích các vùng phân tán không gian, phù hợp với đặc thù ảnh X-quang xương có vùng quan tâm trải dài hơn là tập trung. Nếu số ứng viên hợp lệ không đủ, quy trình lần lượt mở rộng sang toàn bộ lưới, bỏ ràng buộc chồng lấp và lặp vùng theo thứ tự xác định để luôn tạo bốn đầu vào cục bộ.

Toàn bộ các giá trị trọng số và ngưỡng trên được chọn theo nguyên tắc thiết kế và giữ cố định cho mọi thí nghiệm; chúng không được tối ưu trên tập xác thực và việc khảo sát có hệ thống được xác định là hướng phát triển tương lai.

Các cửa sổ được ánh xạ ngược về ảnh gốc trước khi cắt để không lấy chi tiết từ ảnh trung gian đã thu nhỏ. Mỗi vùng được giữ tỷ lệ, đệm bằng màu biên, chuyển thành ảnh vuông 224×224 và chuẩn hóa giống ảnh toàn cục. Kết quả tiền xử lý gồm ảnh toàn cục $x_i^{img,g}$, bốn ảnh cục bộ $\{x_{i,m}^{img,\ell}\}_{m=1}^4$ và tọa độ hộp tương ứng được chuẩn hóa theo kích thước ảnh gốc.

3.2.2 Bộ mã hóa thị giác BiomedCLIP

Mô hình kế thừa bộ mã hóa của BiomedCLIP [47], được xây dựng theo kiến trúc Vision Transformer [8]. Mỗi ảnh 224×224 được chia thành lưới 14×14 mảnh ảnh kích thước 16×16 . Sau khi thêm một đơn vị đại diện, bộ mã hóa và lớp chiếu tạo chuỗi gồm 197 vectơ có chiều $D = 512$:

$$\mathbf{H}_{i,m}^I = \mathcal{F}_I(x_{i,m}) = [\mathbf{h}_{i,m,0}; \mathbf{h}_{i,m,1}; \dots; \mathbf{h}_{i,m,196}] \in \mathbb{R}^{197 \times D}. \quad (3.5)$$

$\mathcal{F}_I$ gồm bộ mã hóa thị giác và lớp chiếu của BiomedCLIP. Chỉ số $m = g$ biểu thị ảnh toàn cục, còn $m = 1, \dots, 4$ biểu thị bốn ảnh cục bộ. Chỉ số 0 chỉ đơn vị đại diện, còn các chỉ số 1 đến 196 tương ứng với lưới mảnh ảnh. Ảnh toàn cục được biểu diễn bằng vectơ đại diện đã chuẩn hóa:

$$\mathbf{g}_i = \text{Norm}(\mathbf{h}_{i,g,0}) \in \mathbb{R}^D. \quad (3.6)$$

Ảnh toàn cục và bốn ảnh cục bộ dùng chung $\mathcal{F}_I$, do đó không hình thành một bộ mã hóa riêng cho nhánh cục bộ. Đối với mỗi ảnh cục bộ, lưới 14×14 được gộp trung bình thích nghi thành lưới 2×2 ; đơn vị đại diện của vùng được giữ lại. Vì vậy, mỗi vùng tạo năm đơn vị biểu diễn:

$$\mathbf{L}_{i,m} = \text{Norm}([\mathbf{h}_{i,m,0}; \text{Pool}_{2 \times 2}(\mathbf{h}_{i,m,1:196})]) \in \mathbb{R}^{5 \times D}. \quad (3.7)$$

Phép Norm chuẩn hóa từng vectơ theo chuẩn ℓ_2 . Ghép kết quả của bốn vùng thu được $P = 4 \times 5 = 20$ đơn vị cục bộ. Hộp của đơn vị đại diện bằng hộp của toàn vùng; bốn đơn vị còn lại nhận tọa độ của bốn ô con trong lưới 2×2 .

Gọi $\ell_{i,n}$ và $\mathbf{b}_{i,n} \in [0, 1]^4$ lần lượt là đơn vị cục bộ thứ n và hộp tọa độ tương ứng. Tọa độ được chiếu qua một mạng hai lớp, cộng có kiểm soát vào nội dung và chuẩn hóa lại, tạo ra token ảnh có thông tin vị trí:

$$\tilde{\ell}_{i,n} = \text{Norm}(\text{Norm}(\ell_{i,n}) + \tanh(\gamma) \text{Norm}(\mathcal{P}_s(\mathbf{b}_{i,n}))), \quad n = 1, \dots, P. \quad (3.8)$$

$\mathcal{P}_s : \mathbb{R}^4 \rightarrow \mathbb{R}^D$ là phép chiếu tọa độ và γ là hệ số học được, khởi tạo bằng 0,1. Cấu hình chính truyền nguyên 20 đơn vị sau khi bổ sung tọa độ, không gộp chúng bằng các truy vấn học được. Chuỗi thị giác dùng cho dung hợp vì vậy là:

$$\mathbf{V}_i = [\mathbf{g}_i; \tilde{\ell}_{i,1}; \dots; \tilde{\ell}_{i,20}] \in \mathbb{R}^{21 \times 512}. \quad (3.9)$$

Trong giai đoạn khớp ngữ nghĩa, chuỗi $\mathbf{V}_i$ được rút thành một vectơ ảnh bằng phép gộp có điều kiện theo đặc trưng toàn cục, như trình bày trong Công thức 3.25. Ở giai đoạn dung hợp, mô hình sử dụng trực tiếp

toàn bộ chuỗi V_i để giữ lại thông tin theo từng vùng.

3.3 Nhánh biểu diễn văn bản

Bổ sung cho các bằng chứng hình thái được trích xuất từ ảnh X-quang, nhánh biểu diễn văn bản có nhiệm vụ mã hóa thông tin lâm sàng x_i^{txt} thành các đặc trưng ngữ cảnh theo từng token và một vectơ đại diện cho toàn bộ chuỗi. Trong khóa luận, nhánh này được kế thừa từ bộ mã hóa văn bản của BiomedCLIP [47], với thành phần chính là PubMedBERT. Khác với các mô hình ngôn ngữ được tiền huấn luyện trên văn bản tổng quát, PubMedBERT được tiền huấn luyện từ đầu trên kho ngữ liệu y sinh và sử dụng bộ từ vựng được xây dựng trực tiếp từ miền dữ liệu này. Nhờ đó, mô hình phù hợp hơn với các thuật ngữ chuyên ngành xuất hiện trong thông tin lâm sàng.

3.3.1 Tiền xử lý và mã hóa đầu vào

Trước khi đưa vào PubMedBERT, chuỗi văn bản x_i^{txt} được phân tách thành các đơn vị từ con bằng bộ mã hóa WordPiece tương ứng với mô hình. Hai token đặc biệt [CLS] và [SEP] lần lượt được thêm vào đầu và cuối chuỗi. Chuỗi sau khi mã hóa được cắt hoặc đệm đến độ dài tối đa T_T :

$$(\mathbf{u}_i, \mathbf{m}_i) = \text{Tokenizer}_T(x_i^{\text{txt}}), \quad (3.10)$$

trong đó $\mathbf{u}_i \in \mathbb{N}^{T_T}$ là chuỗi chỉ số token và $\mathbf{m}_i \in \{0, 1\}^{T_T}$ là mặt nạ chú ý. Giá trị bằng 1 trong $\mathbf{m}_i$ biểu thị một token hợp lệ, trong khi giá trị bằng 0 biểu thị vị trí được thêm vào để đệm chuỗi.

3.3.2 Bộ mã hóa văn bản BiomedCLIP

Mô hình kế thừa bộ mã hóa văn bản PubMedBERT của BiomedCLIP [47]. Chuỗi chỉ số token $\mathbf{u}_i$ cùng mặt nạ chú ý $\mathbf{m}_i$ được đưa qua bộ mã hóa và lớp chiếu để tạo chuỗi đặc trưng có cùng chiều $D = 512$ với nhánh ảnh:

$$\mathbf{H}_i^T = \mathcal{F}_T(\mathbf{u}_i, \mathbf{m}_i) = [\mathbf{h}_{i,0}^T; \mathbf{h}_{i,1}^T; \dots; \mathbf{h}_{i,T_T-1}^T] \in \mathbb{R}^{T_T \times D}. \quad (3.11)$$

$\mathcal{F}_T$ gồm bộ mã hóa văn bản và lớp chiếu của BiomedCLIP, còn T_T là độ dài chuỗi sau khi cắt hoặc đệm. Mặt nạ $\mathbf{m}_i$ loại bỏ ảnh hưởng của các vị trí đệm. Chỉ số 0 biểu thị token $[\text{CLS}]$, được dùng để tạo vectơ văn bản toàn cục đã chuẩn hóa:

$$\mathbf{t}_i = \text{Norm}(\mathbf{h}_{i,0}^T) \in \mathbb{R}^D. \quad (3.12)$$

Chuỗi $\mathbf{H}_i^T$ được giữ lại cho bước dung hợp bằng chú ý chéo, trong khi $\mathbf{t}_i$ được sử dụng làm biểu diễn toàn cục của văn bản.

Kết thúc hai nhánh mã hóa, mỗi mẫu được biểu diễn bởi chuỗi đặc trưng ảnh $\mathbf{V}_i$, ma trận đặc trưng văn bản $\mathbf{H}_i^T$ và các vectơ toàn cục tương ứng. Mặc dù các biểu diễn này kế thừa tri thức y sinh từ BiomedCLIP, sự khác biệt giữa dữ liệu tiền huấn luyện và dữ liệu X-quang xương đích vẫn đòi hỏi hai bộ mã hóa được thích nghi trước khi thực hiện dung hợp.

3.4 Thích nghi tham số bằng LoRA

Hai bộ mã hóa đã được tiền huấn luyện trên dữ liệu y sinh quy mô lớn, nhưng dữ liệu X-quang xương đích vẫn có khác biệt về phân bố ảnh, cách ghi bệnh sử và hệ thống nhãn. Việc tinh chỉnh toàn bộ tham số có chi phí lớn và dễ quá khớp khi dữ liệu gán nhãn hạn chế. XBone-Net vì vậy sử dụng LoRA để học phần cập nhật hạng thấp cho các phép biến đổi tuyến tính quan trọng.

Với ma trận trọng số nền $\mathbf{W} \in \mathbb{R}^{d_o \times d_i}$, LoRA biểu diễn ma trận sau thích nghi theo công thức chuẩn:

$$\mathbf{W}' = \mathbf{W} + \frac{\alpha}{r} \mathbf{B} \mathbf{A}, \quad \mathbf{A} \in \mathbb{R}^{r \times d_i}, \quad \mathbf{B} \in \mathbb{R}^{d_o \times r}, \quad r \ll \min(d_i, d_o). \quad (3.13)$$

Trong Công thức 3.13, $\mathbf{W}$ được giữ cố định, $\mathbf{A}$ và $\mathbf{B}$ là hai ma trận

được cập nhật, r là hạng thích nghi và α là hệ số tỷ lệ. Nhờ đó, mô hình chỉ học một phần nhỏ tham số bổ sung nhưng vẫn có thể điều chỉnh cả biểu diễn ảnh lẫn biểu diễn văn bản cho miền dữ liệu mới. Khi triển khai, phần cập nhật có thể được giữ riêng hoặc gộp tương đương vào trọng số nền mà không làm thay đổi kết quả tính toán.

LoRA chỉ điều chỉnh cách từng bộ mã hóa biểu diễn dữ liệu trong miền đích; bản thân kỹ thuật này chưa thực hiện trao đổi thông tin giữa ảnh và văn bản. Sau khi hai nhánh đã tạo ra các đặc trưng thích nghi, các biểu diễn này được chuyển đến mô-đun dung hợp để mô hình hóa quan hệ giữa dấu hiệu thị giác và ngữ cảnh lâm sàng.

3.5 Dung hợp đa phương thức bằng chú ý chéo


Từ hai nhánh mã hóa, hệ thống thu được chuỗi đặc trưng ảnh $\mathbf{V}_i$, ma trận đặc trưng văn bản $\mathbf{H}_i^T$ và hai biểu diễn toàn cục $\mathbf{g}_i, \mathbf{t}_i$. Nếu chỉ ghép nối trực tiếp các vectơ toàn cục, mô hình chưa thể hiện rõ nội dung lâm sàng nào liên quan đến từng dấu hiệu trên ảnh. Vì vậy, XBone-Net sử dụng cơ chế chú ý chéo hai chiều để mỗi phương thức chủ động truy vấn thông tin cần thiết từ phương thức còn lại trước khi hình thành biểu diễn chung, được thể hiện trong Hình 3.3.

Trước khi chú ý, mỗi chuỗi được chuẩn hóa lớp và chiếu riêng về cùng không gian D chiều:

$$\widehat{\mathbf{V}}_i = \text{Linear}_I(\text{LN}(\mathbf{V}_i)), \quad \widehat{\mathbf{H}}_i^T = \text{Linear}_T(\text{LN}(\mathbf{H}_i^T)). \quad (3.14)$$

Trong đó, Linear_I và Linear_T là hai lớp tuyến tính $D \rightarrow D$ có tham số độc lập, lần lượt biến đổi đặc trưng ảnh và đặc trưng văn bản trước khi thực hiện chú ý chéo.

XBone-Net sử dụng cơ chế chú ý đa đầu chia không gian đặc trưng thành H_a không gian con. Mỗi đầu thực hiện một phép chú ý độc lập, sau đó các kết quả được ghép và chiếu để tạo đầu ra chung:



Hình 3.3: Mô-đun dung hợp bằng chú ý chéo hai chiều

$$\text{head}_h = \text{Attn}_h(\mathbf{X}, \mathbf{Y}; \mathbf{M}), \quad h = 1, \dots, H_a. \quad (3.15)$$

Sau đó, đầu ra của các đầu được ghép và chiếu bởi ma trận $\mathbf{W}_O$:

$$\text{MHA}(\mathbf{X}, \mathbf{Y}; \mathbf{M}) = [\text{head}_1; \dots; \text{head}_{H_a}] \mathbf{W}_O. \quad (3.16)$$

Với đầu chú ý thứ h có truy vấn $\mathbf{X}$, ngữ cảnh $\mathbf{Y}$ và mặt nạ cộng $\mathbf{M}$, phép tính chú ý một đầu là:

$$\text{Attn}_h(\mathbf{X}, \mathbf{Y}; \mathbf{M}) = \text{softmax}\left(\frac{(\mathbf{X}\mathbf{W}_Q^{(h)})(\mathbf{Y}\mathbf{W}_K^{(h)})^\top}{\sqrt{d_h}} + \mathbf{M}\right)(\mathbf{Y}\mathbf{W}_V^{(h)}). \quad (3.17)$$

Trong đó, $d_h = D/H_a$ là số chiều của một trong H_a đầu chú ý. Mỗi đầu trong mỗi hướng có các ma trận $\mathbf{W}_Q^{(h)}, \mathbf{W}_K^{(h)}, \mathbf{W}_V^{(h)}$ riêng, còn $\mathbf{W}_O$ chiếu kết quả sau khi ghép các đầu. Mặt nạ $\mathbf{M}$ nhận giá trị $-\infty$ tại token đệm và 0 tại token hợp lệ.

Việc sử dụng nhiều đầu cho phép mô hình đồng thời khảo sát các quan hệ ảnh-văn bản trong những không gian biểu diễn khác nhau, cung cấp cho mô hình các phép chiếu truy vấn, khóa và giá trị khác nhau, qua đó tạo khả năng học đồng thời nhiều kiểu quan hệ giữa ảnh và văn bản. Do đó, các đầu có thể chú ý đến những khía cạnh bổ sung nhau.

XBone-Net sử dụng token toàn cục chỉ làm truy vấn, còn khóa và giá trị loại bỏ token toàn cục ở vị trí đầu. Ở chiều ảnh truy vấn văn bản:

$$\mathbf{h}_i^{I \leftarrow T} = \text{LN}\left(\widehat{\mathbf{V}}_{i,0} + \text{MHA}_{I \leftarrow T}\left(\widehat{\mathbf{V}}_{i,0:1}, \widehat{\mathbf{H}}_{i,1:}^T; \mathbf{M}_i^T\right)_0\right) \in \mathbb{R}^D. \quad (3.18)$$

Ở chiều văn bản truy vấn ảnh, một mô-đun chú ý độc lập sử dụng P token ảnh cục bộ:

$$\mathbf{h}_i^{T \leftarrow I} = \text{LN}\left(\widehat{\mathbf{H}}_{i,0}^T + \text{MHA}_{T \leftarrow I}\left(\widehat{\mathbf{H}}_{i,0:1}^T, \widehat{\mathbf{V}}_{i,1:}; \mathbf{M}_i^I\right)_0\right) \in \mathbb{R}^D. \quad (3.19)$$

Hai biểu diễn sau chú ý được ghép và đưa qua một perceptron đa tầng

để tạo vectơ đặc trưng tổng hợp:


$$\mathbf{z}_i = \text{LN} \left(\text{MLP} \left([\mathbf{h}_i^{I \leftarrow T}; \mathbf{h}_i^{T \leftarrow I}] \right) \right) \in \mathbb{R}^D. \quad (3.20)$$

Hình 3.3 cho thấy hai hướng chú ý được thực hiện song song. Hai mô-đun không chia sẻ tham số vì vai trò truy vấn-ngữ cảnh đảo ngược nhau. Kết nối phần dư giữ lại token toàn cục, còn MLP học cách tổng hợp hai biểu diễn đã được bổ sung ngữ cảnh.

Kết quả của quá trình trên là vectơ đa phương thức $\mathbf{z}_i$, trong đó thông tin ảnh và văn bản đã được tổng hợp trong cùng một biểu diễn. Vectơ này là đầu vào trực tiếp của bộ phân lớp, do đó quyết định cuối cùng không còn dựa trên từng phương thức riêng lẻ mà dựa trên quan hệ đã học giữa chúng.

3.6 Bộ phân lớp bằng mạng nguyên mẫu

Trên không gian đặc trưng đa phương thức được tạo bởi mô-đun dung hợp, XBone-Net thực hiện phân lớp theo nguyên lý của mạng nguyên mẫu [39]. Thay vì sử dụng một lớp tuyến tính với trọng số lớp được học trực tiếp, mỗi lớp được biểu diễn bằng tâm của các vectơ $\mathbf{z}_i$ thuộc lớp tương ứng. Cách xây dựng này cho phép diễn giải dự đoán thông qua mức độ gần giữa mẫu và từng tâm lớp, đồng thời tạo ra một không gian khoảng cách có thể tiếp tục được khai thác trong bước phát hiện OOD.



Hình 3.4: phân lớp vectơ đặc trưng tổng hợp trong không gian nguyên mẫu

Với $\mathcal{I}_k = \{i \mid y_i = k\}$ là tập chỉ số các mẫu huấn luyện thuộc lớp k , tâm thực nghiệm được ước lượng bằng trung bình đặc trưng:

$$\mathbf{c}_k = \frac{1}{|\mathcal{I}_k|} \sum_{i \in \mathcal{I}_k} \mathbf{z}_i. \quad (3.21)$$

Điểm tương đồng giữa mẫu và tâm lớp được xác định bằng cosin:

$$r_{ik} = \frac{\mathbf{z}_i^\top \mathbf{c}_k}{\|\mathbf{z}_i\|_2 \|\mathbf{c}_k\|_2}. \quad (3.22)$$

Đầu phân lớp chuyển điểm tương đồng thành logit sử dụng hệ số tỷ lệ α_c và một độ lệch học được riêng cho từng lớp:

$$\ell_{ik} = \alpha_c r_{ik} + b_k, \quad \alpha_c > 0. \quad (3.23)$$

Xác suất dự đoán được tính bằng Softmax trên các logit:

$$p_{ik} = p(y = k \mid \mathbf{z}_i) = \frac{\exp(\ell_{ik})}{\sum_{j=1}^K \exp(\ell_{ij})}, \quad (3.24)$$

trong đó α_c điều chỉnh độ sắc của phân phối xác suất, còn b_k được tối

ưu trong pha 2. Khi các độ lệch bằng nhau, nhãn dự đoán tương đương với tâm có cosin lớn nhất; khi b_k được học, ranh giới còn được hiệu chỉnh theo lớp. Các tâm $\mathbf{c}_k$ là thống kê của tập huấn luyện, không phải tham số nhận đạo hàm.

Các phần trên xác định luồng truyền thuận của XBone-Net từ dữ liệu đầu vào đến xác suất phân lớp. Tuy nhiên, các thành phần không được tối ưu đồng thời ngay từ đầu, bởi việc thích nghi không gian ảnh-văn bản và việc học nhiệm vụ phân lớp có mục tiêu khác nhau. Vì vậy, quá trình huấn luyện được tách thành hai giai đoạn ngoại tuyến.

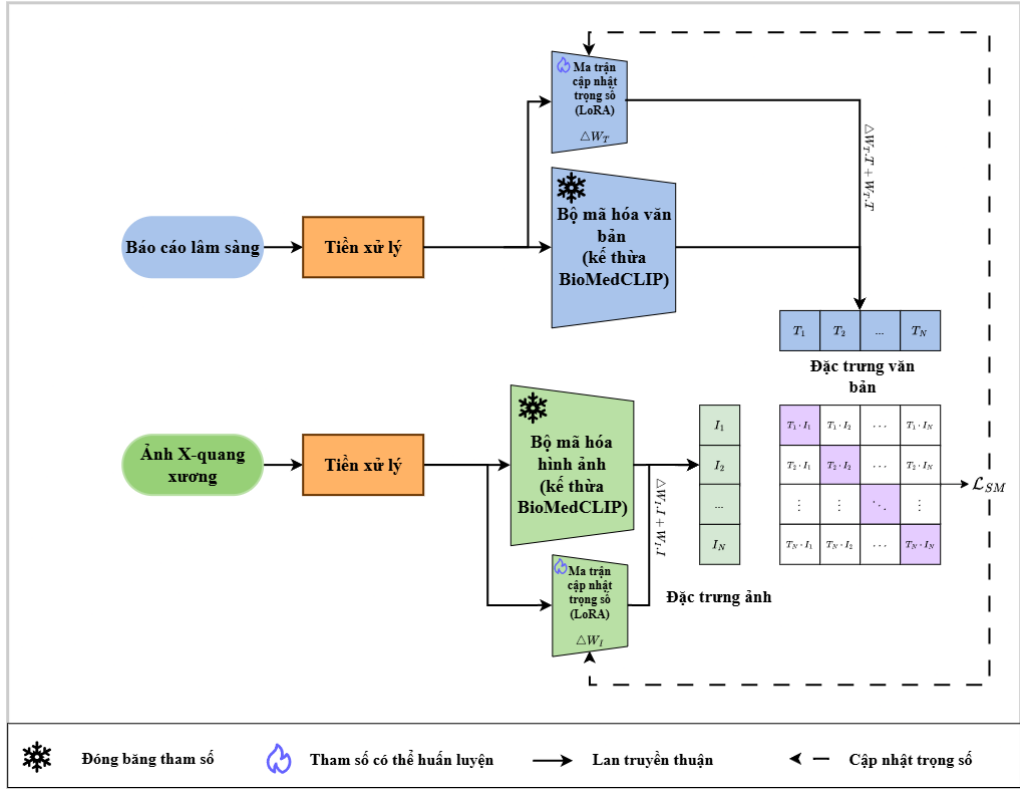
3.7 Huấn luyện hai giai đoạn trong quá trình ngoại tuyến

Quy trình ngoại tuyến lần lượt giải quyết hai yêu cầu của hệ thống. Giai đoạn thứ nhất điều chỉnh các bộ mã hóa để ảnh X-quang và thông tin lâm sàng tương ứng được biểu diễn phù hợp hơn trong miền dữ liệu đích. Trên nền không gian đã thích nghi, giai đoạn thứ hai học tương tác liên phương thức và tối ưu quyết định phân lớp có xét đến sự mất cân bằng giữa các lớp.

3.7.1 Giai đoạn 1: thích nghi miền bằng khớp ngữ nghĩa

Giai đoạn thứ nhất được minh họa trong Hình 3.5. Ảnh X-quang và thông tin lâm sàng tương ứng được đưa qua hai bộ mã hóa để tạo các vectơ trong cùng một không gian. Các trọng số nền của BiomedCLIP được đóng băng, còn các ma trận LoRA và thành phần tổng hợp đặc trưng ảnh cục bộ được cập nhật. Mô-đun dung hợp và mạng nguyên mẫu chưa tham gia vào mục tiêu tối ưu ở giai đoạn này.

Giai đoạn này sử dụng hàm mất mát khớp ngữ nghĩa với phân phối đích mềm theo nhãn lớp. Trước hết, các token ảnh cục bộ được tóm tắt bằng tổng có trọng số rồi bổ sung vào đặc trưng toàn cục:



Hình 3.5: Giai đoạn thích nghi miền bằng khớp ngữ nghĩa ảnh-văn bản

$$\mathbf{v}_i^{\text{local}} = \sum_{n \in \mathcal{P}_i} \alpha_{i,n} \tilde{\ell}_{i,n}, \quad (3.25)$$

$$\bar{\mathbf{v}}_i = \text{Norm}_2(\mathbf{g}_i + 0,25 \text{Norm}_2(\mathbf{v}_i^{\text{local}})).$$

Trong đó, $\mathcal{P}_i$ là tập chỉ số token cục bộ hợp lệ, còn $\alpha_{i,n}$ biểu thị mức đóng góp tương đối của token cục bộ thứ n vào biểu diễn của ảnh i . Trọng số này không phải là một tham số được học trực tiếp mà được tính riêng cho từng ảnh bằng Softmax trên các điểm số sinh từ token cục bộ $\tilde{\ell}_{i,n}$ và đặc trưng toàn cục $\mathbf{g}_i$ thông qua một hàm chấm điểm có tham số học được. Do đó, $\alpha_{i,n} \geq 0$, $\sum_{n \in \mathcal{P}_i} \alpha_{i,n} = 1$; giá trị càng lớn thì token tương ứng đóng góp càng nhiều. Vectơ $\mathbf{v}_i^{\text{local}}$ tóm tắt thông tin cục bộ, còn $\bar{\mathbf{v}}_i$ giữ đặc trưng toàn cục làm thành phần chính và bổ sung 0,25 lần bản tóm tắt này.

Độ tương đồng giữa ảnh i và văn bản j được tính trong không gian đã chuẩn hóa:

$$s_{ij} = \frac{\bar{\mathbf{v}}_i^\top \mathbf{t}_j}{\tau_{\text{SM}}}. \quad (3.26)$$

Trong đó, τ_{SM} là nhiệt độ tương ứng với hệ số tỷ lệ logit được kế thừa

từ BiomedCLIP. Với một lô gồm B ảnh và B văn bản, đặt $\tilde{\mathbf{Q}} = [\tilde{q}_{ij}]$ là ma trận đích mềm chưa chuẩn hóa. Phần tử $\tilde{q}_{ij}$ nhận giá trị 1 đối với cặp ảnh–văn bản của cùng một mẫu, nhận giá trị ρ đối với hai mẫu khác nhau nhưng cùng lớp, và nhận giá trị 0 đối với hai mẫu khác lớp. Cấu hình chính sử dụng $\rho = 0,50$. Các phân phối đích theo hai hướng được chuẩn hóa từ ma trận này:

$$q_{ij}^{I \rightarrow T} = \frac{\tilde{q}_{ij}}{\sum_{n=1}^B \tilde{q}_{in}}, \quad q_{ij}^{T \rightarrow I} = \frac{\tilde{q}_{ji}}{\sum_{n=1}^B \tilde{q}_{ni}}. \quad (3.27)$$

Trong đó, $q_{ij}^{I \rightarrow T}$ là xác suất đích của văn bản j khi ảnh i làm truy vấn, còn $q_{ij}^{T \rightarrow I}$ là xác suất đích của ảnh j khi văn bản i làm truy vấn.


Đặt $\mathbf{S} = [s_{ij}]$, còn $p_{ij}^{I \rightarrow T}$ và $p_{ij}^{T \rightarrow I}$ lần lượt là các phần tử của hai phân phối dự đoán. Hàm mất mát khớp ngữ nghĩa được viết gọn như sau:

$$\begin{aligned} \mathbf{P}^{I \rightarrow T} &= \text{softmax}_{\text{row}}(\mathbf{S}), & \mathbf{P}^{T \rightarrow I} &= \text{softmax}_{\text{row}}(\mathbf{S}^T), \\ \mathcal{L}_{\text{SM}} &= -\frac{1}{2B} \sum_{i=1}^B \sum_{j=1}^B [q_{ij}^{I \rightarrow T} \log p_{ij}^{I \rightarrow T} + q_{ij}^{T \rightarrow I} \log p_{ij}^{T \rightarrow I}]. \end{aligned} \quad (3.28)$$

Dạng mất mát trong Công thức 3.28 kế thừa nguyên lý khớp ngữ nghĩa hai chiều của các mô hình ảnh–văn bản y khoa [43]. So với nhãn khớp cứng, phân phối đích mềm tránh xem mọi cặp khác mẫu là âm hoàn toàn khi chúng cùng mô tả một lớp bệnh. Việc lấy mẫu theo lớp làm tăng khả năng một lô có nhiều cặp cùng lớp để cung cấp tín hiệu ngữ nghĩa cho mục tiêu này.

Sau giai đoạn này, hai bộ mã hóa đã được điều chỉnh để tạo ra không gian ảnh–văn bản phù hợp hơn với dữ liệu X-quang xương. Tuy nhiên, các đặc trưng của cặp ảnh–văn bản mới chỉ được căn chỉnh gần nhau hơn ở mức biểu diễn trong không gian nhúng và chưa được tối ưu trực tiếp cho quyết định phân lớp đa lớp. Vì vậy, giai đoạn thứ hai tiếp tục sử dụng các bộ mã hóa đã thích nghi, đồng thời đưa mô-đun dung hợp và mạng nguyên mẫu vào quá trình huấn luyện có giám sát.

3.7.2 Giai đoạn 2: học dung hợp và phân lớp



Hình 3.6: Giai đoạn học dung hợp và phân lớp bằng mạng nguyên mẫu

Trong giai đoạn thứ hai, hai nhánh mã hóa tạo chuỗi đặc trưng toàn cục và cục bộ. Các chuỗi này được đưa qua mô-đun chú ý chéo để tạo vectơ tổng hợp z_i . Mạng nguyên mẫu sử dụng các vectơ của tập huấn luyện để ước lượng tâm lớp và tính xác suất dự đoán. Trọng số nền của BiomedCLIP tiếp tục được giữ cố định, trong khi LoRA, thành phần biểu diễn ảnh cục bộ và mô-đun dung hợp tiếp tục được cập nhật, với mục tiêu giúp biểu diễn đa phương thức có tính phân biệt giữa các lớp.

Do số mẫu của các lớp có thể chênh lệch lớn, hàm mất mát sử dụng trọng số lớp dựa trên số lượng mẫu hiệu dụng [5]. Với n_k là số mẫu của lớp k , trọng số sau khi chuẩn hóa và giới hạn trên được tính trực tiếp bởi:

$$w_k = \min \left(w_{\max}, \frac{K (1 - \beta^{n_k})^{-1}}{\sum_{j=1}^K (1 - \beta^{n_j})^{-1}} \right). \quad (3.29)$$

Trong đó, β điều khiển mức hiệu chỉnh theo tần suất lớp và $w_{\max}$ giới hạn trọng số lớn nhất. Cấu hình chính sử dụng $\beta = 0,999$ và $w_{\max} = 5,0$. Nhân được làm tròn với hệ số $\varepsilon = 0,05$. Ký hiệu $\tilde{y}_{ik}$ biểu thị xác suất mục tiêu của lớp k đối với mẫu i .

Với $Z_{\mathcal{B}}$ là hệ số chuẩn hóa, mục tiêu pha 2 là hàm mất mát entropy chéo có trọng số theo lớp, kết hợp làm tròn nhân:

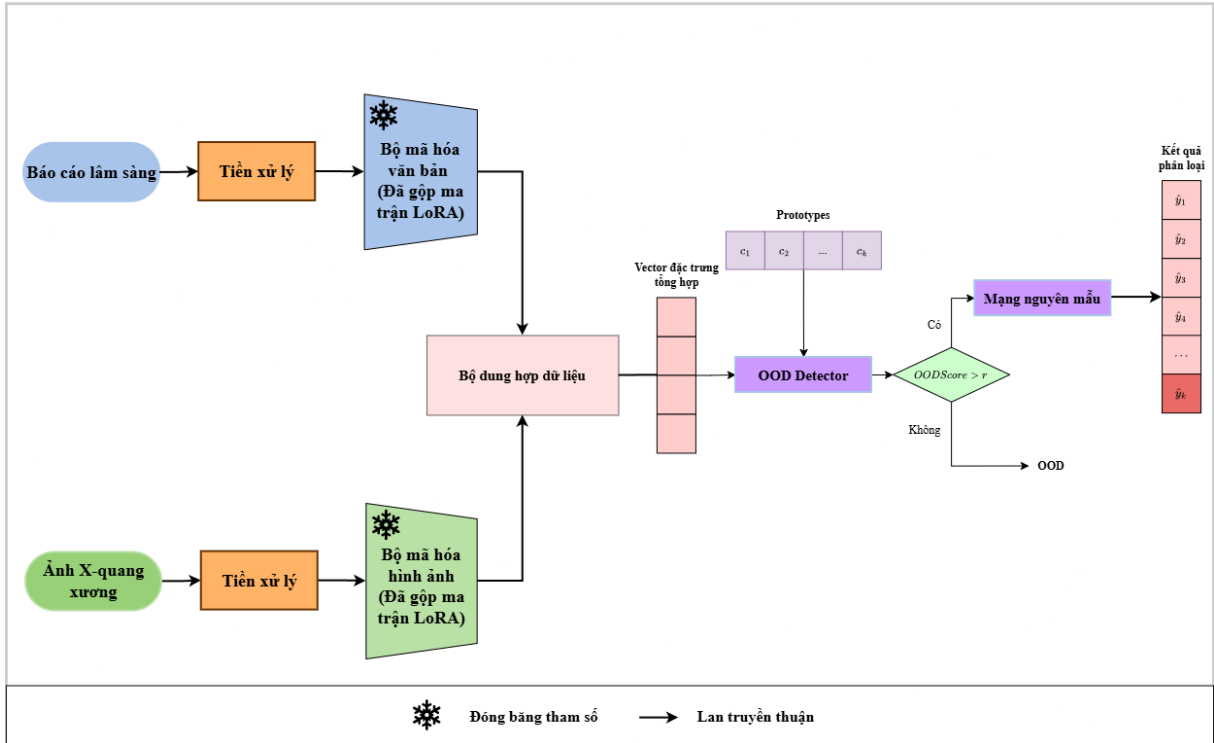
$$\mathcal{L}_{\text{WCE}} = -\frac{1}{Z_{\mathcal{B}}} \sum_{i=1}^B \sum_{k=1}^K w_k \tilde{y}_{ik} \log p_{ik}. \quad (3.30)$$

Trong Công thức 3.30, các lớp hiếm nhận trọng số lớn hơn, còn làm tròn nhân hạn chế việc phân phối dự đoán tập trung tuyệt đối vào một lớp.

Các tâm lớp được khởi tạo từ toàn bộ tập huấn luyện trước epoch đầu tiên. Trong mỗi epoch, chúng được giữ cố định như buffer và không nhận gradient. Ngay sau epoch, mô hình chuyển sang chế độ đánh giá, tính lại embedding của tập huấn luyện bằng trạng thái tham số mới nhất, cập nhật các tâm theo Công thức 3.21, rồi mới đánh giá trên tập kiểm định. Trạng thái tốt nhất được lựa chọn theo độ đo đã định trước; cuối cùng, các tâm được tính lại từ tập huấn luyện bằng trạng thái này. Tập kiểm thử không tham gia cập nhật tham số, ước lượng tâm hoặc lựa chọn mô hình.

Kết quả của quá trình ngoại tuyến là tập tham số LoRA, mô-đun dung hợp, trạng thái bộ mã hóa và các tâm lớp đã được xác định từ dữ liệu huấn luyện. Các thành phần này được cố định và chuyển sang quy trình trực tuyến để xử lý từng ca mới mà không thực hiện thêm bất kỳ bước cập nhật nào.

3.8 Suy luận trong quá trình trực tuyến



Hình 3.7: Quy trình suy luận trực tuyến và phát hiện mẫu ngoài phân phối

Khi tiếp nhận một ca mới, ảnh X-quang và thông tin lâm sàng được xử lý bằng đúng các phép biến đổi đã sử dụng trong huấn luyện. Hai bộ mã hóa tạo đặc trưng ảnh và văn bản, mô-đun chú ý chéo tạo vectơ tổng hợp, sau đó mạng nguyên mẫu tính xác suất cho từng lớp. Toàn bộ tham số LoRA, mô-đun dung hợp và các nguyên mẫu lớp đều được cố định. Quá trình này không tính đạo hàm và không cập nhật tâm lớp từ mẫu mới. Kết quả trên cho biết lớp nào gần mẫu nhất trong số các lớp đã biết, nhưng chưa cho biết mẫu có thực sự phù hợp với phân bố huấn luyện hay không.

Vì vậy, ngoài kết quả phân lớp, hệ thống sử dụng khoảng cách Mahalanobis đến lớp gần nhất làm điểm phát hiện ngoài phân phối [21]. Gọi μ_k là trung bình đặc trưng của lớp k và Σ là ma trận hiệp phương sai chung được ước lượng từ tập huấn luyện ID. Ma trận hiệp phương sai được điều chuẩn bằng phương pháp Ledoit–Wolf để tăng tính ổn định trong không

gian nhiều chiều [20]. Khoảng cách Mahalanobis và điểm OOD được xác định bởi:

$$\begin{aligned} d_M(\mathbf{z}, \boldsymbol{\mu}_k) &= \sqrt{(\mathbf{z} - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}^{-1} (\mathbf{z} - \boldsymbol{\mu}_k)}, \\ s_{\text{OOD}}(\mathbf{z}) &= \min_{k \in \mathcal{Y}} d_M(\mathbf{z}, \boldsymbol{\mu}_k). \end{aligned} \quad (3.31)$$

Điểm $s_{\text{OOD}}(\mathbf{z})$ là khoảng cách nhỏ nhất từ biểu diễn của mẫu mới đến các lớp đã biết. Giá trị càng lớn cho thấy mẫu càng xa toàn bộ phân bố lớp ID. Ngưỡng δ_{OOD} được hiệu chỉnh chỉ bằng dữ liệu ID huấn luyện và kiểm định. Quy tắc đầu ra là:

$$\hat{y} = \begin{cases} \text{OOD}, & \text{nếu } s_{\text{OOD}}(\mathbf{z}) > \delta_{\text{OOD}}, \\ \arg \max_{k \in \mathcal{Y}} p(y = k | \mathbf{z}), & \text{ngược lại.} \end{cases} \quad (3.32)$$

Mô-đun phát hiện ngoài phân phối không thay đổi dự đoán nội tại của XBone-Net. Nó cung cấp thêm một tín hiệu cảnh báo về mức độ phù hợp của mẫu với phân bố đã quan sát. Vì vậy, đầu ra phân lớp và cảnh báo ngoài phân phối có hai vai trò khác nhau: đầu ra thứ nhất chọn lớp gần nhất trong tập lớp đã biết, còn đầu ra thứ hai đánh giá liệu quyết định đó có được thực hiện trên một mẫu đủ quen thuộc hay không.

3.9 Kết luận chương

Chương này trình bày kiến trúc, quá trình huấn luyện và cơ chế suy luận của XBone-Net cho bài toán phân lớp ảnh X-quang xương kết hợp thông tin lâm sàng. Các nội dung chính gồm:

1. **Kết hợp ngữ cảnh lâm sàng:** Thông tin bệnh sử và triệu chứng được sử dụng để bổ sung ngữ cảnh cho các dấu hiệu trên ảnh X-quang.
2. **Biểu diễn ảnh toàn cục-cục bộ:** Một ảnh toàn cục và bốn vùng cục bộ có thông tin tọa độ được sử dụng để giữ cả cấu trúc giải phẫu và chi tiết khu trú.

3. **Thích nghi BiomedCLIP bằng LoRA:** Hai bộ mã hóa tiền huấn luyện được thích nghi với miền X-quang xương bằng LoRA trong khi các tham số nền được giữ cố định.
4. **Dung hợp bằng chú ý chéo hai chiều:** Đặc trưng ảnh và văn bản truy vấn lẫn nhau trước khi được tổng hợp thành một biểu diễn đa phương thức chung.
5. **Huấn luyện hai giai đoạn và phân lớp nguyên mẫu:** Giai đoạn đầu khớp ngữ nghĩa ảnh-văn bản bằng đích mềm; giai đoạn sau học dung hợp và phân lớp theo nguyên mẫu với mất mát có trọng số lớp.
6. **Suy luận và phát hiện ngoài phân phối:** Mô hình cố định tham số khi suy luận, dự đoán theo các nguyên mẫu lớp và dùng khoảng cách Mahalanobis đến các nguyên mẫu để cảnh báo mẫu ngoài phân phối.

Chương 4

Thực nghiệm và kết quả

Chương này trình bày thiết kế thực nghiệm và các kết quả dùng để trả lời năm câu hỏi nghiên cứu của khóa luận. Cách tổ chức được xây dựng theo một chuỗi lập luận gồm khả năng chuyển giao trực tiếp của mô hình nền tảng, vai trò của hai phương thức đầu vào, hiệu năng theo điều kiện dữ liệu và chi phí, ảnh hưởng của từng thành phần, chất lượng biểu diễn đối với dữ liệu ngoài phân phối và mức phụ thuộc của dự đoán vào các nguồn thông tin. Các cấu hình có huấn luyện được đánh giá trên ba hạt giống 42, 123 và 456 với giá trị tổng hợp được báo cáo dưới dạng trung bình $\pm$ độ lệch chuẩn mẫu. Kết quả theo từng hạt giống và các phân tích bổ sung được trình bày tại Phụ lục B.

4.1 Thiết kế thực nghiệm

4.1.1 Chuẩn bị dữ liệu

Nghiên cứu sử dụng bộ dữ liệu BTXRD [45] được công bố và bộ dữ liệu CTCH được thu thập tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh do giảng viên cung cấp. Các phần dưới đây mô tả nguồn gốc, cách thức thu thập và những số liệu thống kê liên quan đến từng bộ dữ liệu. Ngoài ra, cấu trúc thư mục và các bước tiền xử lý sẽ được mô tả ở Phụ lục A

Bộ dữ liệu BTXRD


BTXRD là bộ dữ liệu ảnh X-quang được xây dựng cho các bài toán phân lớp, định vị và phân vùng u xương nguyên phát. Phiên bản được sử dụng trong nghiên cứu gồm 3,746 ảnh, siêu dữ liệu về tuổi, giới tính, vị trí giải phẫu và tư thế chụp, cùng các chỉ báo về sự hiện diện, tính lành tính hoặc ác tính và phân nhóm tổn thương. Đối với 1,867 ảnh có u, bộ dữ liệu còn cung cấp tệp chú thích chứa thông tin vùng tổn thương.

Theo mô tả của bộ dữ liệu công bố, dữ liệu được tổng hợp từ ba bệnh viện tại Trung Quốc, Radiopaedia và MedPix. Dữ liệu bệnh viện được thu thập trong giai đoạn từ tháng 7 năm 2013 đến tháng 7 năm 2023, các chẩn đoán được xác nhận bằng mô bệnh học hoặc được hai bác sĩ X-quang thống nhất. Đối với hai nguồn trực tuyến, các ảnh liên quan đến u xương được hai chuyên gia tuyển chọn, đồng thời yêu cầu có thông tin tuổi và giới tính. Những vùng giải phẫu có ít mẫu hoặc nhiều nhiễu như đầu, cổ, ngực và bụng được loại bỏ, do đó phạm vi còn lại tập trung vào chi trên, chi dưới và xương chậu.

Quy trình chú thích được thực hiện bằng Labelme [37]: một bác sĩ chuyên khoa u xương có 10 năm kinh nghiệm xác định vùng tổn thương, sau đó kết quả được một chuyên gia có 20 năm kinh nghiệm kiểm tra.

Đặc điểm dữ liệu và bài toán phân lớp Trong 3,746 mẫu, có 1,879 ảnh bình thường, 1,525 ảnh thuộc nhóm u lành tính và 342 ảnh thuộc nhóm u ác tính. Tuổi dao động từ 1 đến 88, gồm 2,098 mẫu nam và 1,648 mẫu nữ như được thể hiện trong Hình 4.1.

Nhân được thiết lập dưới dạng phân lớp đơn nhãn với 10 lớp. Nhân bình thường được suy ra khi cờ chỉ báo u bằng 0, chín lớp còn lại được lấy từ các chỉ báo bệnh lý trong siêu dữ liệu. Bảng 4.1 trình bày số lượng mẫu theo tập chia, trong khi Bảng 4.2 trình bày phân bố lớp ở các tập chia.



Hình 4.1: Phân bố độ tuổi và giới tính của các bệnh nhân được quan sát trong bộ dữ liệu BTXRD

Tập chia	Số lượng hình ảnh	Tỷ lệ (%)
Huấn luyện	2,621	70
Đánh giá	375	10
Kiểm thử	750	20
Tổng cộng	3,746	100,00

Bảng 4.1: Phân bố mẫu theo các tập chia trong BTXRD

Nhân bệnh lý	Huấn luyện	Đánh giá	Kiểm thử	Tổng	Tỷ lệ
Bình thường	1,322	191	366	1,879	50,16%
U xương sụn	538	70	145	753	20,10%
Sarcoma xương	200	32	65	297	7,93%
Đa u xương sụn	189	29	45	263	7,02%
Nang xương đơn thuần	149	17	40	206	5,50%
U lành tính khác	83	8	24	115	3,07%
U tế bào khổng lồ	54	8	31	93	2,48%
U sụn màng hoạt dịch	35	7	9	51	1,36%
U ác tính khác	27	5	13	45	1,20%
U xơ xương	24	8	12	44	1,17%
Tổng	2,621	375	750	3,746	100,00%

Bảng 4.2: Phân bố các lớp đơn nhãn sau chuẩn hóa trong bộ dữ liệu BTXRD

Bộ dữ liệu được chia ngẫu nhiên ở mức ảnh với hạt giống 42 và tỷ lệ 70/10/20 cho các tập huấn luyện, đánh giá và kiểm thử. Tập siêu dữ liệu không cung cấp mã người bệnh ổn định để nhóm các ảnh của cùng một ca trước khi chia do đó, kết quả BTXRD vì vậy chỉ được diễn giải trong phạm vi phép chia ở mức ảnh.

Bộ dữ liệu BTXRD không cung cấp bệnh sử lâm sàng tương ứng với từng bệnh nhân. Do đó, để bổ sung nguồn văn bản đi kèm, nghiên cứu sử dụng quy trình sinh văn bản lâm sàng bằng siêu dữ liệu có sẵn được mô tả ở Phụ lục A.1 và kết quả được minh họa như Bảng 4.3.

Ảnh	Nhãn	Văn bản giả lâm sàng được sinh
	<i>other mt</i>	Patient: 48-year-old female. Reason for admission: Pain and swelling of the hip bone. Disease history: Pain in the hip bone for 1 month; associated with decreased appetite. Physical examination: Palpable mass; tenderness on palpation; mild swelling. Personal medical history: No prior bone disease or fracture. No relevant surgical or medical history. Radiographic evaluation: AP view of the hip bone was obtained.
	<i>multiple osteo-chondro-mas</i>	Patient: 64-year-old male. Reason for admission: Progressive pain in the humerus. Disease history: The patient reports worsening pain in the humerus for 1 month. Physical examination: Palpable mass with local tenderness; no lymphadenopathy detected. Personal medical history: No prior bone disease or fracture. History of age-related degenerative changes; no prior bone lesions. Radiographic evaluation: AP view of the humerus was obtained.

Bảng 4.3: Ví dụ ảnh, nhãn và văn bản giả lâm sàng được sinh của bộ dữ liệu BTXRD

Trong thiết kế thực nghiệm, BTXRD được sử dụng để khảo sát khả năng chuyển giao sang bài toán u xương, ảnh hưởng của mất cân bằng lớp và hành vi của mô hình trong thiết lập văn bản tổng hợp. Do văn bản lâm sàng được sinh từ siêu dữ liệu và chịu ảnh hưởng của các cờ nhóm bệnh, kết quả trên bộ dữ liệu này không được diễn giải tương đương với kết quả thu được từ bệnh sử lâm sàng thực tế.

Bộ dữ liệu CTCH

CTCH là bộ dữ liệu X-quang xương được thu thập tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh và được giảng viên Võ Thế Hào cùng giảng viên Đỗ Phúc Thịnh cung cấp cho nghiên cứu. Dữ liệu nguồn gồm ảnh được lựa chọn từ từng ca khám và các trường bệnh án tiếng Việt liên quan đến lý do vào viện, diễn tiến bệnh, tiền sử, kết quả khảo sát hình ảnh và chẩn đoán chuyên môn. Phạm vi thực nghiệm chỉ sử dụng ảnh X-quang đại diện cho vị trí bệnh lý các ảnh từ phương thức tạo ảnh khác hoặc không đại diện cho vị trí bệnh lý không được đưa vào tập phân lớp.

Đạo đức nghiên cứu, quyền riêng tư và tính sẵn có của dữ liệu

Bộ dữ liệu được sử dụng theo thỏa thuận bảo mật đã ký kết và chỉ phục vụ mục đích nghiên cứu. Trước khi xử lý, các thông tin có khả năng định danh trực tiếp người bệnh đã được loại bỏ và các mã hồ sơ chỉ được dùng để liên kết dữ liệu, kiểm soát việc phân chia tập và không được công bố trong kết quả nghiên cứu.

Do chứa thông tin y tế nhạy cảm, bộ dữ liệu gốc không được công khai và khóa luận chỉ trình bày số liệu thống kê cùng kết quả tổng hợp. Mọi hoạt động kiểm định hoặc triển khai trong môi trường lâm sàng về sau cần tuân thủ quy định bảo vệ dữ liệu và được cơ quan có thẩm quyền phê duyệt.

Đặc điểm dữ liệu và bài toán phân lớp

Việc chia dữ liệu được thực hiện theo người bệnh với hạt giống ngẫu nhiên 42 và tỷ lệ mục tiêu 70/10/20. Người bệnh được nhóm theo lớp chính trước khi phân bổ để duy trì sự hiện diện của các lớp ít mẫu ở cả ba tập khi số lượng cho phép. Kết quả như được thể hiện ở Bảng 4.4 gồm 2.265 mẫu huấn luyện, 315 mẫu Đánh giá và 669 mẫu kiểm thử và Bảng 4.5 thể hiện chi tiết số lượng mẫu trong từng lớp trong các tập chia.

Tập dữ liệu	Số lượng ảnh	Tỷ lệ
Huấn luyện	2,265	69,71%
Đánh giá	315	9,70%
Kiểm thử	669	20,59%
Tổng cộng	3,249	100,00%

Bảng 4.4: Phân bố mẫu trong phân phối của CTCH theo tập dữ liệu

Lớp	Huấn luyện	Đánh giá	Kiểm thử	Tổng	Tỷ lệ
Bình thường	760	108	218	1.086	33,43%
Gãy xương quay	209	29	61	299	9,20%
Gãy xương cánh tay	147	21	42	210	6,46%
Gãy xương đùi	106	15	31	152	4,68%
Gãy xương ngón tay	102	14	31	147	4,52%
Gãy xương chày	99	14	29	142	4,37%
Gãy xương cẳng tay	99	14	29	142	4,37%
Gãy xương cổ chân	87	12	26	125	3,85%
Gãy xương cẳng chân	85	12	25	122	3,76%
Gãy xương vùng vai	70	10	21	101	3,11%
Gãy xương bàn chân	68	9	21	98	3,02%
Gãy cột sống thắt lưng	53	7	16	76	2,34%
Gãy xương bàn tay	53	7	16	76	2,34%
Gãy xương ngón chân	52	7	16	75	2,31%
Viêm khớp	47	6	15	68	2,09%
Gãy xương trụ	46	6	14	66	2,03%
Cắt cụt ngón tay	42	6	13	61	1,88%
Gãy xương bánh chè	41	5	13	59	1,82%
Gãy xương gót	36	5	11	52	1,60%
Gãy cột sống ngực	28	4	8	40	1,23%
Gãy xương thuyền	19	2	7	28	0,86%
Gãy xương vùng chậu	16	2	6	24	0,74%
Tổng cộng	2,265	315	669	3,249	100,00%

Bảng 4.5: Phân bố 22 lớp của CTCH trong ba tập dữ liệu

Mỗi hồ sơ được liên kết với một ảnh X-quang duy nhất. Trong quần thể phân lớp hiện tại, 3,249 ảnh tương ứng với 3,249 mã bệnh nhân và quần thể ngoài phân phối gồm 44 ảnh từ 44 mã khác và không giao với quần thể phân lớp. Bảng 4.6 minh họa kết quả sau khi tiền xử lý và phương pháp sàng lọc và tiền xử lý được mô tả ở Phụ lục A.2.

Các mẫu ngoài phân phối không được đưa vào huấn luyện, Đánh giá hoặc kiểm thử bộ phân lớp 22 lớp. Trong 44 mẫu này, 34 mẫu thuộc nhóm chấn thương và 10 mẫu thuộc nhóm viêm nhiễm nhưng biểu hiện bệnh lý

nằm ngoài không gian nhãn đích. Do đó, chúng chỉ được sử dụng trong kịch bản đánh giá dữ liệu ngoài phân phối được trình bày ở phần thực nghiệm.

Ảnh	Nhãn	Bệnh sử lâm sàng
	<i>Shoulder girdle fracture</i>	Reason for admission: Left shoulder pain. Disease history: 16:00, April 4, 2023, patient riding a motorbike fell by himself in Long An, after the accident, right shoulder pain, first aid at Tan Tru Hospital, examined at Orthopedics Hospital. Personal medical history: No abnormalities were detected.
	<i>Finger phalanx fracture</i>	Reason for admission: Right hand wound. Disease history: The patient had his right hand cut by a saw at 2:00 p.m. on October 17, 2024 in Dong Nai; Go to the local medical station for first aid. to the Orthopedic Trauma Hospital. Personal medical history: Right hand third metatarsal fusion surgery 9 years ago

Bảng 4.6: Các ví dụ ảnh, nhãn và bệnh sử lâm sàng của bộ dữ liệu CTCH

CTCH được xem là nguồn bằng chứng chính cho câu hỏi về giá trị của học đa phương thức, vì mỗi ảnh được liên kết với bệnh sử lâm sàng có sẵn và phép chia được thực hiện theo người bệnh. Bộ dữ liệu này đồng thời cung cấp quần thể ngoài không gian nhãn để khảo sát cảnh báo dữ liệu ngoài phân phối và toàn bộ 669 mẫu kiểm thử được dùng cho phân tích nguồn thông tin của dự đoán.

4.1.2 Nội dung thực nghiệm

Các thực nghiệm được tổ chức theo năm câu hỏi nghiên cứu như đã trình bày ở chương 1. Bảng 4.7 trình bày giả thuyết cần kiểm tra, thực nghiệm chính và độ đo được ưu tiên trong quá trình diễn giải. Điểm F1 trung bình theo lớp là độ đo phân lớp chính vì hai bộ dữ liệu đều mất cân bằng các độ đo xếp hạng, hiệu chỉnh, cảnh báo dữ liệu ngoài phân phối và chi phí được dùng để làm rõ những đánh đổi mà một độ đo đơn lẻ không phản ánh đầy đủ.

Câu hỏi nghiên cứu	Giả thuyết kiểm tra	Thực nghiệm chính	Độ đo chính
Vai trò của ảnh và văn bản	Ảnh X-quang và văn bản đi kèm cung cấp thông tin bổ sung; làm sai quan hệ ghép cặp sẽ làm suy giảm dự đoán.	So sánh ảnh-văn bản, chỉ ảnh, chỉ văn bản và văn bản ghép khác lớp trên CTCH và BTXRD.	Điểm F1 trung bình theo lớp; độ chính xác cân bằng.
Đóng góp của các thành phần	Nhánh ảnh cục bộ, huấn luyện hai pha, dung hợp và đầu tâm lớp tác động khác nhau đến quyết định lớp, chất lượng xếp hạng và hiệu chỉnh.	Loại bỏ từng thành phần và đối chứng theo nhóm mã hóa ảnh, huấn luyện, dung hợp, đầu phân lớp và mức thích nghi bộ mã hóa.	Điểm F1 trung bình theo lớp; diện tích dưới hai đường cong xếp hạng; sai số hiệu chỉnh kỳ vọng.
Đánh đổi dữ liệu, tham số và chi phí	XBone-Net và chiến lược LoRA duy trì hiệu năng cạnh tranh khi dữ liệu hạn chế và giảm số tham số cần cập nhật, nhưng không nhất thiết giảm chi phí suy luận.	So sánh không mẫu, 1, 10, 20 mẫu mỗi lớp và toàn bộ dữ liệu; đo tham số, thời gian, thông lượng, độ trễ và số phép toán.	Điểm F1 trung bình theo lớp; số tham số cập nhật; thông lượng và độ trễ.
Phân biệt dữ liệu ngoài phân phối	Không gian biểu diễn chứa tín hiệu giúp tách mẫu trong phân phối khỏi mẫu ngoài không gian nhân và mẫu khác bộ dữ liệu.	So sánh điểm cosin theo tâm lớp, Mahalanobis, láng giềng gần nhất và entropy trên hai kịch bản dịch chuyển.	Diện tích dưới đường cong phân biệt; FPR@95%TPR.
Nguồn thông tin của dự đoán	Ảnh toàn cục, các đơn vị ảnh cục bộ và bệnh sử có mức ảnh hưởng khác nhau; thứ tự quy đóng cần làm xác suất lớp đích giảm nhanh hơn đối chứng ngẫu nhiên.	Can thiệp từng nguồn, tích phân gradient, kiểm tra loại bỏ-khôi phục và phân tích trường hợp đúng, sai.	Mức giảm xác suất lớp đích; diện tích dưới đường cong loại bỏ; độ ổn định thứ hạng.

Bảng 4.7: Ánh xạ câu hỏi nghiên cứu với giả thuyết, thực nghiệm và độ đo chính

Ở thiết lập không mẫu, CLIP, MedCLIP, PubMedCLIP và BiomedCLIP được giữ cố định; tên lớp tiếng Anh được thay vào câu nhắc [34]:

A photo of a [class].

Biểu diễn ảnh và câu nhắc được chuẩn hóa rồi so sánh bằng độ tương đồng cosin. Thiết lập này chỉ đóng vai trò mốc chuyển giao trực tiếp. Trong trường hợp mẫu học hạn chế, tối đa 1, 10 hoặc 20 mẫu mỗi lớp được lấy không hoàn lại theo từng hạt giống, trong khi tập Đánh giá và tập kiểm thử được giữ nguyên. CTCH chỉ có 19 mẫu gãy xương thuyền và 16 mẫu gãy xương vùng chậu ở mức 20 mẫu, do đó ngân sách thực tế của hai lớp này không đạt đủ 20 mẫu. Trong thiết lập toàn bộ dữ liệu, các đối chứng gồm ResNet-50, DenseNet-121, bốn mô hình ngôn ngữ trực quan được tinh chỉnh toàn bộ và hai mô hình cơ sở dùng LoRA với phép nổi đặc trưng và đầu tuyến tính.

XBone-Net đầy đủ là cấu hình tham chiếu cho năm phép loại bỏ: bỏ nhánh ảnh độ phân giải cao, thay gộp có trọng số chú ý bằng gộp trung bình, bỏ pha khớp ngữ nghĩa, thay chú ý chéo hai chiều bằng nổi đặc trưng và thay đầu tâm lớp bằng đầu tuyến tính. Các đối chứng bổ sung khảo sát hướng chú ý một chiều, xử lý mất cân bằng, số đơn vị ảnh cục bộ, cách

đệm ảnh và mức cập nhật bộ mã hóa. Dữ liệu, hạt giống và tiêu chí chọn điểm kiểm tra được giữ nguyên trong từng nhóm; các chênh lệch được diễn giải như liên hệ với cấu hình thay đổi, không phải quan hệ nhân quả độc lập.

Đánh giá biểu diễn được thực hiện trên 669 mẫu kiểm thử CTCH bằng chỉ số Silhouette và Davies-Bouldin. Phát hiện dữ liệu ngoài phân phối dùng khoảng cách cosin đến tâm lớp, khoảng cách Mahalanobis, năm láng giềng gần nhất theo khoảng cách cosin và entropy dự đoán. Tâm lớp, láng giềng và hiệp phương sai Ledoit-Wolf chỉ được ước lượng từ tập huấn luyện CTCH; tập Đánh giá được dùng để hiệu chỉnh ngưỡng giữ lại ít nhất 95% mẫu trong phân phối. Hai kịch bản đánh giá gồm 44 mẫu ngoài không gian nhãn nhưng cùng nguồn CTCH và 750 mẫu BTXRD, nơi nguồn ảnh, nguồn văn bản và không gian nhãn cùng thay đổi.

Phân tích nguồn thông tin được thực hiện bằng cách thay lần lượt ảnh toàn cục, các đơn vị ảnh cục bộ hoặc bệnh sử rồi đo thay đổi xác suất lớp đích. Tích phân gradient dùng 24 bước nội suy và được so sánh với 16 thứ tự loại bỏ ngẫu nhiên. Kiểm tra ổn định dùng hai lần gây nhiễu ở tỷ lệ 0,01; kiểm tra ngẫu nhiên hóa đầu phân lớp dùng năm mẫu; phân tích trực tiếp trọng số chú ý dùng sáu mẫu tại mỗi hạt giống. Các phép đo chỉ truy vết mức phụ thuộc của đầu ra vào đầu vào và không xác lập quan hệ nhân quả, khả năng định vị tổn thương hoặc độ đúng lâm sàng.

4.1.3 Độ đo đánh giá

Hai bộ dữ liệu BTXRD và CTCH được thiết lập dưới dạng bài toán phân lớp đa lớp, với BTXRD có 10 lớp và CTCH có 22 lớp. Các độ đo được chia theo bốn mục tiêu: phân lớp, phát hiện dữ liệu ngoài phân phối, đánh giá biểu diễn và đánh giá tích phân gradient. Hiệu quả suy luận được báo cáo bổ sung để phản ánh chi phí triển khai.

Độ đo phân lớp

Gọi N là số mẫu, C là số lớp và TP_c , FP_c , FN_c lần lượt là số dương đúng, dương sai và âm sai khi xem lớp c là lớp dương. Ký hiệu $\mathcal{C}_v$ chỉ các

lớp có cả mẫu dương và mẫu âm trong phép đánh giá một đối với tất cả.

Độ chính xác Độ chính xác là tỷ lệ mẫu được dự đoán đúng trên toàn bộ tập đánh giá:

$$\text{Accuracy} = \frac{\sum_{c=1}^C TP_c}{N}. \quad (4.1)$$

Độ đo này được dùng để mô tả hiệu năng tổng thể, nhưng có thể bị chi phối bởi các lớp có nhiều mẫu.

Độ chính xác cân bằng Độ chính xác cân bằng [3] là trung bình độ nhạy của các lớp:

$$\text{Balanced Accuracy} = \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FN_c}. \quad (4.2)$$

Mỗi lớp đóng góp như nhau, vì vậy độ đo được dùng để hạn chế ảnh hưởng của mất cân bằng lớp.

Độ chính xác dự đoán theo lớp Độ chính xác dự đoán của lớp c là tỷ lệ dự đoán lớp c thực sự thuộc lớp đó:

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c}. \quad (4.3)$$

Độ đo được dùng khi cần xem xét mức dự đoán dương sai của từng lớp và là thành phần của đường cong độ chính xác-độ nhạy.

Độ nhạy theo lớp Độ nhạy của lớp c là tỷ lệ mẫu thuộc lớp c được nhận diện:

$$\text{Recall}_c = \frac{TP_c}{TP_c + FN_c}. \quad (4.4)$$

Độ đo phản ánh mức bỏ sót của từng lớp và tạo trực còn lại của đường cong độ chính xác-độ nhạy.

Macro-F1 Điểm F1 trung bình theo lớp lấy trung bình điểm F1 của từng lớp:

$$\text{Macro-F1} = \frac{1}{C} \sum_{c=1}^C \frac{2TP_c}{2TP_c + FP_c + FN_c}. \quad (4.5)$$

Độ đo cân bằng giữa dự đoán dương đúng và mức bỏ sót ở từng lớp, đồng thời được dùng làm độ đo phân lớp chính của nghiên cứu.

Macro-AUROC Diện tích dưới đường cong đặc trưng hoạt động trung bình theo lớp [9] lấy trung bình diện tích dưới đường cong ROC của từng lớp theo chiến lược một đối với tất cả:

$$\text{Macro-AUROC} = \frac{1}{|\mathcal{C}_v|} \sum_{c \in \mathcal{C}_v} \text{AUROC}_c. \quad (4.6)$$

Trong đó, AUROC_c là xác suất một mẫu lớp c được xếp hạng cao hơn một mẫu không thuộc lớp c . Độ đo được dùng để đánh giá chất lượng xếp hạng trên toàn bộ ngưỡng quyết định các giá trị cao hơn thường biểu thị khả năng phân biệt tốt hơn.

Độ chính xác trung bình theo lớp Độ chính xác trung bình của lớp c tóm tắt đường cong độ chính xác-độ nhạy tại các ngưỡng xếp hạng:

$$\text{AP}_c = \sum_{k=1}^{K_c} (R_{c,k} - R_{c,k-1}) P_{c,k}. \quad (4.7)$$

Trong đó, $P_{c,k}$ và $R_{c,k}$ là độ chính xác dự đoán và độ nhạy tại ngưỡng thứ k , còn K_c là số ngưỡng được xét. Độ đo được dùng để tổng hợp chất lượng xếp hạng của riêng lớp c .

Macro-AUPRC Diện tích dưới đường cong độ chính xác-độ nhạy trung bình theo lớp [7] lấy trung bình độ chính xác trung bình trên các lớp hợp lệ:

$$\text{Macro-AUPRC} = \frac{1}{|\mathcal{C}_v|} \sum_{c \in \mathcal{C}_v} \text{AP}_c. \quad (4.8)$$

Độ đo được dùng để đánh giá khả năng xếp hạng khi các lớp mất cân bằng các giá trị cao hơn thường biểu thị kết quả thuận lợi hơn.

Sai số hiệu chỉnh kỳ vọng Sai số hiệu chỉnh kỳ vọng [10] đo chênh lệch giữa độ tin cậy và tỷ lệ dự đoán đúng trên $M = 15$ khoảng xác suất:

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{N} |\text{Acc}(B_m) - \text{Conf}(B_m)|. \quad (4.9)$$

Trong đó, B_m là tập mẫu ở khoảng xác suất thứ m , còn $\text{Acc}(B_m)$ và $\text{Conf}(B_m)$ là tỷ lệ đúng và độ tin cậy trung bình trong khoảng. Sai số hiệu chỉnh kỳ vọng được dùng để xem xét mức phù hợp của xác suất dự đoán; các giá trị thấp hơn thường cho thấy hiệu chỉnh tốt hơn.

Độ đo phát hiện dữ liệu ngoài phân phối

Gọi $\mathcal{D}_{\text{ID}}$ và $\mathcal{D}_{\text{OOD}}$ lần lượt là tập trong và ngoài phân phối, $N_{\text{OOD}} = |\mathcal{D}_{\text{OOD}}|$, còn $s(x)$ là điểm bất thường với giá trị lớn hơn biểu thị khả năng ngoài phân phối cao hơn.

AUROC-OOD Diện tích dưới đường cong phân biệt dữ liệu ngoài phân phối [12] là xác suất điểm của một mẫu ngoài phân phối cao hơn điểm của một mẫu trong phân phối, với trường hợp bằng điểm được tính một nửa:

$$\text{AUROC}_{\text{OOD}} = \Pr(s(x_{\text{OOD}}) > s(x_{\text{ID}})) + \frac{1}{2} \Pr(s(x_{\text{OOD}}) = s(x_{\text{ID}})). \quad (4.10)$$

Độ đo được dùng để đánh giá khả năng xếp hạng hai phân phối trên mọi ngưỡng các giá trị cao hơn thường biểu thị mức phân biệt tốt hơn.

AUPR-Out Diện tích dưới đường cong độ chính xác-độ nhạy khi dữ liệu ngoài phân phối là lớp dương [12, 26] là diện tích dưới đường cong độ chính xác-độ nhạy khi mẫu ngoài phân phối được xem là lớp dương:

$$\text{AUPR-Out} = \int_0^1 \text{Precision}_{\text{OOD}} \, d \text{Recall}_{\text{OOD}}. \quad (4.11)$$

Độ đo được dùng để bổ sung diện tích dưới đường cong phân biệt khi tỷ lệ mẫu ngoài phân phối thay đổi giữa các kịch bản; các giá trị cao hơn thường thuận lợi hơn.

FPR@95%TPR Tỷ lệ chấp nhận nhầm tại mức giữ lại 95% mẫu trong phân phối [26, 27] được báo cáo tại ngưỡng τ_{95} giữ lại ít nhất 95% mẫu trong phân phối:

$$\text{FPR@95\%TPR} = \frac{|\{x \in \mathcal{D}_{\text{OOD}} : s(x) \leq \tau_{95}\}|}{N_{\text{OOD}}}, \quad \Pr_{x \sim \mathcal{D}_{\text{ID}}} [s(x) \leq \tau_{95}] \geq 0.95. \quad (4.12)$$

Ngưỡng τ_{95} được hiệu chỉnh trên tập Đánh giá. Độ đo được dùng để ước lượng tỷ lệ mẫu ngoài phân phối bị chấp nhận nhầm tại một mức giữ lại mẫu trong phân phối cố định; giá trị thấp hơn thường thuận lợi hơn.

Độ đo đánh giá biểu diễn

Gọi $\mathbf{z}_i$ là biểu diễn đã chuẩn hóa của mẫu i , y_i là nhãn lớp và C là số lớp. Ký hiệu $\mathcal{I}_c = \{i : y_i = c\}$ và $N_c = |\mathcal{I}_c|$. Các độ đo được tính trong không gian biểu diễn gốc, không dựa trên hình chiếu hai chiều.

Silhouette Silhouette [36] so sánh khoảng cách của mỗi mẫu đến các mẫu cùng lớp với khoảng cách đến lớp lân cận gần nhất:

$$\begin{aligned}
a_i &= \frac{1}{N_{y_i} - 1} \sum_{j \in \mathcal{I}_{y_i}, j \neq i} d_{\cos}(\mathbf{z}_i, \mathbf{z}_j), \\
b_i &= \min_{c \neq y_i} \frac{1}{N_c} \sum_{j \in \mathcal{I}_c} d_{\cos}(\mathbf{z}_i, \mathbf{z}_j), \\
\text{Silhouette} &= \frac{1}{N} \sum_{i=1}^N \frac{b_i - a_i}{\max(a_i, b_i)}.
\end{aligned} \tag{4.13}$$

Trong đó, $d_{\cos}$ là khoảng cách cosin. Độ đo được dùng để xem xét đồng thời độ chặt trong lớp và độ tách giữa các lớp; giá trị gần 1 thuận lợi hơn, còn giá trị âm gợi ý sự chồng lấn.

Davies-Bouldin Chỉ số Davies-Bouldin [6] so sánh độ phân tán trong lớp với khoảng cách giữa các tâm lớp:

$$\begin{aligned}
\bar{\mathbf{z}}_c &= \frac{1}{N_c} \sum_{i \in \mathcal{I}_c} \mathbf{z}_i, \quad S_c = \frac{1}{N_c} \sum_{i \in \mathcal{I}_c} \|\mathbf{z}_i - \bar{\mathbf{z}}_c\|_2, \\
\text{DB} &= \frac{1}{C} \sum_{c=1}^C \max_{c' \neq c} \frac{S_c + S_{c'}}{\|\bar{\mathbf{z}}_c - \bar{\mathbf{z}}_{c'}\|_2}.
\end{aligned} \tag{4.14}$$

Trong đó, $\bar{\mathbf{z}}_c$ và S_c là tâm và độ phân tán của lớp c . Chỉ số đánh giá mức tách cụm theo nhãn; giá trị thấp hơn thường thuận lợi hơn.

Độ đo đánh giá tích phân gradient

Gọi $F_t(\mathbf{u})$ là điểm số của lớp đích t tại đầu vào hoặc dãy đơn vị biểu diễn $\mathbf{u}$, $\mathbf{u}'$ là mốc tham chiếu và L là số thành phần được quy đóng. Các độ đo dưới đây chỉ xem xét tính đầy đủ số học, độ trung thực theo phép loại bỏ và độ ổn định thứ hạng.

Mức quy đóng bằng tích phân gradient Tích phân gradient [40] gán mức quy đóng cho thành phần j dọc theo đoạn thẳng từ mốc tham chiếu đến đầu vào:

$$\text{IG}_j(\mathbf{u}) = (u_j - u'_j) \int_0^1 \frac{\partial F_t(\mathbf{u}' + \alpha(\mathbf{u} - \mathbf{u}'))}{\partial u_j} d\alpha. \quad (4.15)$$

Trong đó, α là hệ số nội suy. Tích phân được xấp xỉ bằng quy tắc hình thang với 24 điểm và độ lớn quy đóng được dùng để sắp thứ tự các đơn vị cho phép kiểm tra loại bỏ.

Diện tích dưới đường cong loại bỏ Gọi $p_t(\mathbf{u}^{\text{del}}(q))$ là xác suất lớp đích sau khi thay tỷ lệ q đơn vị có mức quy đóng cao nhất bằng mốc tham chiếu. Diện tích dưới đường cong loại bỏ được xác định bởi:

$$\text{AUC}_{\text{del}} = \int_0^1 p_t(\mathbf{u}^{\text{del}}(q)) dq. \quad (4.16)$$

Tích phân được xấp xỉ bằng quy tắc hình thang tại sáu tỷ lệ loại bỏ. Độ đo được dùng để kiểm tra liệu các đơn vị được tích phân gradient xếp hạng cao có làm xác suất lớp đích giảm nhanh hay không; giá trị thấp hơn thường cung cấp bằng chứng thuận lợi hơn về độ trung thực.

Chênh lệch diện tích dưới đường cong so với thứ tự ngẫu nhiên Đối chứng ngẫu nhiên lấy trung bình đường cong của 16 thứ tự loại bỏ. Chênh lệch giữa đối chứng này và thứ tự do tích phân gradient xác định được tính bởi:

$$\Delta_{\text{del}} = \text{AUC}_{\text{del}}^{\text{random}} - \text{AUC}_{\text{del}}^{\text{IG}}. \quad (4.17)$$

Độ đo được dùng để tách ảnh hưởng của thứ tự quy đóng khỏi ảnh hưởng của việc loại bỏ nói chung. Giá trị dương lớn hơn cho thấy thứ tự do tích phân gradient xác định làm xác suất giảm nhanh hơn đối chứng; giá trị gần 0 cho thấy bằng chứng còn hạn chế.

Độ đo hiệu quả suy luận

Nghiên cứu báo cáo tổng tham số, số tham số được cập nhật, số tỷ phép toán dấu phẩy động trên mỗi mẫu, thông lượng, độ trễ trung bình và bộ nhớ đồ họa cực đại [4, 35]. Số tỷ phép toán dấu phẩy động mô tả khối lượng tính toán lý thuyết, các đại lượng còn lại được đo trên cùng phần cứng và độ chính xác số học. Thông lượng và độ trễ sử dụng kích thước lô 1 trên 20 lô kiểm thử, mỗi lô gồm 10 lượt khởi động và 10 lượt ghi thời gian. Thời gian chỉ bao gồm lan truyền tiến sau khi dữ liệu đã nằm trong bộ nhớ đồ họa.

4.1.4 Cấu hình thực nghiệm

Mỗi cấu hình có huấn luyện được chạy với ba hạt giống 42, 123 và 456 trên cùng phân chia dữ liệu và môi trường ở Bảng 4.8. Bảng 4.9 trình bày các siêu tham số chính dùng trong thực nghiệm

Thành phần	Cấu hình
Phần cứng	RTX 5060 Ti 16 GB; Intel Core Ultra 7 265KF; 32 GB RAM
Phần mềm	Python 3.11.15; Torch 2.11.0+cu128; CUDA 12.8
Độ chính xác số học	bfloat16 trong cả hai pha huấn luyện

Bảng 4.8: Môi trường thực nghiệm

Thành phần	Cấu hình
Đầu vào ảnh	1 ảnh toàn cục và 4 vùng ảnh 224×224
Bộ tối ưu; kích thước lô	AdamW; 16
Hệ số suy giảm trọng số	10^{-4}
Lịch tốc độ học	cosine
Tỷ lệ khởi động	0,1
Độ chính xác số học	bfloat16
Cấu hình LoRA	Hạng 16; hệ số 32; tỷ lệ bỏ học 0,1
Huấn luyện pha 1	Tốc độ học 5×10^{-5} ; tối đa 30 vòng lặp; dừng sớm sau 3 vòng
Huấn luyện pha 2	Tốc độ học 10^{-4} ; tối đa 50 vòng lặp; dừng sớm sau 5 vòng
Xử lý mất cân bằng lớp	Hệ số số lượng hiệu dụng 0.999; giới hạn trọng số lớp 5,0

Bảng 4.9: Cấu hình chính của các thực nghiệm

4.2 Khả năng chuyển giao trực tiếp của các mô hình nền tảng

4.2.1 Kết quả không mẫu

Kết quả trong Bảng 4.10 cho thấy BiomedCLIP đạt độ chính xác 0.1453, độ chính xác cân bằng 0.1261, điểm F1 trung bình theo lớp 0.0837 và Macro-AUPRC 0.1656 trên BTXRD, cao nhất trong bốn mô hình ở các độ đo này còn Macro-AUROC cao nhất với 0.6051 thuộc về mô hình CLIP. Trên CTCH, BiomedCLIP đạt giá trị cao nhất ở cả năm độ đo, gồm độ chính xác 0.2720, độ chính xác cân bằng 0.3898, điểm F1 trung bình theo lớp 0.2698, Macro-AUROC 0.8976 và Macro-AUPRC 0.3244.

Dữ liệu	Mô hình	Acc $\uparrow$	BAcc $\uparrow$	Macro-F1 $\uparrow$	Macro-AUROC $\uparrow$	Macro-AUPRC $\uparrow$
BTXRD	BioMedCLIP	0.1453	0.1261	0.0837	0.5912	0.1656
	CLIP	0.0560	0.1033	0.0189	0.6051	0.1532
	MedCLIP	0.0440	0.0991	0.0217	0.4594	0.1109
	PubMedCLIP	0.0733	0.1196	0.0613	0.5745	0.1303
CTCH	BioMedCLIP	0.2720	0.3898	0.2698	0.8976	0.3244
	CLIP	0.1868	0.2915	0.1532	0.8308	0.2220
	MedCLIP	0.0239	0.0455	0.0021	0.5074	0.0570
	PubMedCLIP	0.1943	0.2737	0.1607	0.8357	0.2297

Bảng 4.10: Kết quả phân loại không mẫu của các mô hình nền tảng trên BTXRD và CTCH

Trên BTXRD, độ chính xác cân bằng của các mô hình dao động từ 0.0991 đến 0.1261 và điểm F1 trung bình theo lớp không vượt quá 0.0837. Kết quả này cho thấy một câu nhắc chung chưa phân tách tốt các nhóm u xương có biểu hiện hình ảnh và tên gọi chuyên biệt. CLIP đạt chất lượng xếp hạng cao hơn BiomedCLIP theo đường cong đặc trưng hoạt động nhưng có điểm F1 thấp hơn, cho thấy khả năng sắp thứ tự điểm chưa chuyển thành quyết định đa lớp ổn định. Trên CTCH, BiomedCLIP có chất lượng xếp hạng tốt hơn rõ rệt, nhưng khoảng cách giữa 0.8976 ở độ đo xếp hạng và 0.2698 ở điểm F1 vẫn cho thấy giới hạn của quyết định lớp trực tiếp.

4.2.2 Phân tích khả năng chuyển giao của BiomedCLIP

Các kết quả trên cho thấy rằng BiomedCLIP có biểu diễn y sinh tiền huấn luyện phù hợp hơn với các khái niệm giải phẫu và bệnh lý xương tạo một điểm khởi đầu hợp lý cho XBone-Net. Tuy nhiên, kết quả không mẫu không chứng minh khả năng sử dụng trực tiếp trong bài toán đích: hiệu năng quyết định lớp còn thấp, đặc biệt trên BTXRD, và không mô hình nào duy trì ưu thế tuyệt đối trên cả hai bộ dữ liệu. Vì vậy, các phần tiếp theo khảo sát sự cần thiết của thích nghi miền, khai thác văn bản đi kèm, xử lý mất cân bằng và duy trì thông tin ảnh cục bộ.

4.3 Vai trò của ảnh và văn bản

4.3.1 Kết quả trên CTCH và BTXRD

Kết quả trong Bảng 4.11 cho thấy trên CTCH, XBone-Net dùng đồng thời ảnh và bệnh sử đạt độ chính xác cân bằng 0.5844 ± 0.0454 và điểm F1 trung bình theo lớp 0.5558 ± 0.0072 . Khi chỉ dùng ảnh, hai giá trị giảm còn 0.4405 ± 0.0082 và 0.3984 ± 0.0176 và 0.5401 ± 0.0149 và 0.4770 ± 0.0133 khi chỉ dùng bệnh sử. Như vậy, cấu hình đa phương thức tăng điểm F1 lần lượt 0.1574 và 0.0788 điểm so với hai cấu hình đơn phương thức.

Trên BTXRD, cấu hình ảnh kết hợp văn bản tổng hợp đạt điểm F1 trung bình theo lớp 0.6010 ± 0.0034 , cao hơn cấu hình chỉ ảnh 0.2845 điểm và cao hơn cấu hình chỉ văn bản 0.0695 điểm. Kết quả cho thấy mô hình có thể khai thác quan hệ giữa ảnh và văn bản trong thiết lập này. Tuy nhiên, văn bản BTXRD được sinh từ siêu dữ liệu và chịu ảnh hưởng của cờ có u và cờ ác tính do đó, mức cải thiện không được diễn giải như bằng chứng tương đương với bệnh sử lâm sàng tự nhiên.

Kết quả này hỗ trợ giả thuyết rằng ảnh X-quang và bệnh sử thực chứa thông tin bổ sung. Ảnh cung cấp hình thái tổn thương và vị trí giải phẫu, trong khi bệnh sử cung cấp cơ chế chấn thương, diễn tiến và tiền sử.

Bộ dữ liệu	Phương thức đầu vào	B _{Acc} ↑	Macro-F1 ↑	Macro-AUROC ↑	Macro-AUPRC ↑
BTXRD	Ảnh và văn bản tổng hợp	0.5916 ± 0.0116	0.6010 ± 0.0034	0.9243 ± 0.0298	0.6301 ± 0.0211
	Chỉ ảnh	0.3167 ± 0.0191	0.3165 ± 0.0081	0.7756 ± 0.0179	0.3358 ± 0.0074
	Chỉ văn bản	0.5393 ± 0.0160	0.5315 ± 0.0121	0.9279 ± 0.0172	0.5721 ± 0.0096
	Ảnh và văn bản xáo trộn khác lớp	0.0078 ± 0.0016	0.0068 ± 0.0014	0.4124 ± 0.0644	0.0800 ± 0.0059
CTCH	Ảnh và bệnh sử lâm sàng	0.5844 ± 0.0454	0.5558 ± 0.0072	0.9473 ± 0.0246	0.6189 ± 0.0145
	Chỉ ảnh	0.4405 ± 0.0082	0.3984 ± 0.0176	0.9275 ± 0.0041	0.4177 ± 0.0075
	Chỉ văn bản	0.5401 ± 0.0149	0.4770 ± 0.0133	0.9393 ± 0.0020	0.5165 ± 0.0036
	Ảnh và bệnh sử xáo trộn khác lớp	0.3120 ± 0.0172	0.3039 ± 0.0048	0.8494 ± 0.0537	0.3098 ± 0.0264

Bảng 4.11: So sánh giữa các phương thức đầu vào trên hai bộ dữ liệu BTXRD và CTCH

4.3.2 Phân tích tính nhất quán ảnh-văn bản

Khi thay văn bản của mỗi mẫu bằng văn bản thuộc lớp khác, điểm F1 trung bình theo lớp giảm từ 0.5558 ± 0.0072 xuống 0.3039 ± 0.0048 trên CTCH. Trên BTXRD, điểm F1 giảm từ 0.6010 ± 0.0034 xuống 0.0068 ± 0.0014 , đồng thời Macro-AUROC giảm từ 0.9243 ± 0.0298 xuống 0.4124 ± 0.0644 . Phép can thiệp cho thấy mô hình nhạy với tính nhất quán của cặp ảnh-văn bản thay vì chỉ với sự hiện diện độc lập của hai đầu vào.

Mức giảm trên BTXRD lớn hơn nhiều so với CTCH vì phép ghép bất buộc chọn mẫu khác lớp và nguồn văn bản tổng hợp mang tín hiệu liên hệ mạnh với nhãn. Do đó, kết quả BTXRD xác nhận độ nhạy với phép ghép nhưng không mô tả mức chịu nhiễu của bệnh sử tự nhiên. Trên CTCH, mức suy giảm vừa phải hơn phản ánh một kịch bản thực tế hơn, trong đó văn bản có thể hữu ích nhưng không hoàn toàn quyết định nhãn.

4.3.3 Kết luận

Kết hợp ảnh và văn bản cải thiện điểm F1 trung bình theo lớp so với chỉ ảnh hoặc chỉ văn bản trên cả hai bộ dữ liệu. Phép ghép sai làm hiệu năng giảm rõ rệt, qua đó xác nhận mô hình sử dụng quan hệ liên phương thức. Bằng chứng chính đến từ CTCH vì sử dụng bệnh sử thực và chia dữ liệu theo người bệnh các kết quả BTXRD chỉ phản ánh thiết lập văn bản

tổng hợp có điều kiện.

4.4 Hiệu năng theo dữ liệu và chi phí

4.4.1 Kết quả khi sử dụng toàn bộ dữ liệu

Kết quả trong Bảng 4.12 và Bảng 4.13 cho thấy XBone-Net không dẫn đầu trên các độ đo quyết định lớp. Trên BTXRD, mô hình đạt điểm F1 trung bình theo lớp 0.6010 ± 0.0034 , thấp hơn LoRA-PubMedCLIP 0.0317 điểm còn độ chính xác và độ chính xác cân bằng cũng thấp hơn mức cao nhất lần lượt là 0.0089 và 0.0636 điểm. Trên CTCH, điểm F1 của XBone-Net đạt 0.5558 ± 0.0072 , thấp hơn kết quả cao nhất 0.0075 điểm.

Ngược lại, XBone-Net đạt Macro-AUROC cao nhất trên BTXRD và CTCH với các giá trị lần lượt là 0.9243 ± 0.0298 và 0.9473 ± 0.0246 , đồng thời đạt Macro-AUPRC cao nhất trên CTCH (0.6189 ± 0.0145).

Dữ liệu	Mô hình	Accuracy $\uparrow$	Balanced Accuracy $\uparrow$	Macro-F1 $\uparrow$
BTXRD	BioMedCLIP	0.8311 ± 0.0028	0.6062 ± 0.0254	0.5994 ± 0.0124
	CLIP	0.8036 ± 0.0273	0.5957 ± 0.0160	0.5787 ± 0.0252
	DenseNet-121	0.6320 ± 0.0013	0.3694 ± 0.0150	0.3718 ± 0.0173
	MedCLIP	0.8204 ± 0.0144	0.6125 ± 0.0235	0.6054 ± 0.0147
	PubMedCLIP	0.7884 ± 0.0285	0.6089 ± 0.0342	0.5723 ± 0.0577
	ResNet-50	0.6071 ± 0.0140	0.3188 ± 0.0136	0.3291 ± 0.0102
	LoRA-BiomedCLIP	0.8133 ± 0.0035	0.6552 ± 0.0244	0.6225 ± 0.0088
	LoRA-PubMedCLIP	0.8347 ± 0.0058	0.6369 ± 0.0197	0.6327 ± 0.0211
	XBone-Net	0.8258 ± 0.0034	0.5916 ± 0.0116	0.6010 ± 0.0034
CTCH	BioMedCLIP	0.5969 ± 0.0253	0.6023 ± 0.0234	0.5540 ± 0.0080
	CLIP	0.5874 ± 0.0209	0.6217 ± 0.0359	0.5633 ± 0.0090
	DenseNet-121	0.4818 ± 0.0052	0.4927 ± 0.0461	0.4367 ± 0.0238
	MedCLIP	0.5590 ± 0.0389	0.5717 ± 0.0186	0.5151 ± 0.0216
	PubMedCLIP	0.5521 ± 0.0234	0.5589 ± 0.0614	0.5203 ± 0.0264
	ResNet-50	0.4928 ± 0.0017	0.4126 ± 0.0106	0.4078 ± 0.0051
	LoRA-BiomedCLIP	0.5959 ± 0.0212	0.6092 ± 0.0243	0.5599 ± 0.0220
	LoRA-PubMedCLIP	0.6009 ± 0.0305	0.5699 ± 0.0081	0.5538 ± 0.0196
	XBone-Net	0.5725 ± 0.0286	0.5844 ± 0.0454	0.5558 ± 0.0072


Bảng 4.12: Kết quả phân loại khi sử dụng toàn bộ tập huấn luyện

Dữ liệu	Mô hình	Macro-AUROC $\uparrow$	Macro-AUPRC $\uparrow$
BTXRD	BioMedCLIP	0.8865 ± 0.0165	0.6511 ± 0.0104
	CLIP	0.8973 ± 0.0231	0.6251 ± 0.0080
	DenseNet-121	0.7717 ± 0.0173	0.3831 ± 0.0036
	MedCLIP	0.8599 ± 0.0330	0.6228 ± 0.0253
	PubMedCLIP	0.9048 ± 0.0240	0.6149 ± 0.0245
	ResNet-50	0.7236 ± 0.0259	0.3338 ± 0.0061
	LoRA-BiomedCLIP	0.9102 ± 0.0319	0.6343 ± 0.0209
	LoRA-PubMedCLIP	0.9039 ± 0.0063	0.6592 ± 0.0341
	XBone-Net	0.9243 ± 0.0298	0.6301 ± 0.0211
CTCH	BioMedCLIP	0.9390 ± 0.0289	0.6169 ± 0.0090
	CLIP	0.9290 ± 0.0387	0.6002 ± 0.0400
	DenseNet-121	0.9350 ± 0.0046	0.4762 ± 0.0136
	MedCLIP	0.9215 ± 0.0333	0.5839 ± 0.0185
	PubMedCLIP	0.9279 ± 0.0214	0.5888 ± 0.0196
	ResNet-50	0.9145 ± 0.0037	0.4492 ± 0.0042
	LoRA-BiomedCLIP	0.9334 ± 0.0216	0.6045 ± 0.0204
	LoRA-PubMedCLIP	0.9366 ± 0.0202	0.6087 ± 0.0072
	XBone-Net	0.9473 ± 0.0246	0.6189 ± 0.0145


Bảng 4.13: Kết quả xếp hạng xác suất khi sử dụng toàn bộ tập huấn luyện

Khoảng tin cậy ghép cặp của chênh lệch điểm F1 trong Hình 4.2 cho thấy XBone-Net cao hơn rõ rệt so với ResNet-50 và DenseNet-121 trên cả hai bộ dữ liệu, nhưng phần lớn khoảng so sánh với các mô hình ngôn ngữ trực quan cắt mốc 0. Trên BTXRD, khoảng so sánh với LoRA-BiomedCLIP nằm phía mô hình cơ sở. Vì chỉ có ba cặp hạt giống, các khoảng này chủ yếu mô tả độ biến thiên của các lần huấn luyện hiện có và không được dùng để suy rộng thành phân phối hiệu năng rộng hơn.

Trên CTCH, ma trận nhầm lẫn tổng hợp ở Hình 4.3 cho thấy độ nhạy cao ở gãy xương đùi, gãy xương gót, gãy cột sống thắt lưng, gãy xương ngón tay và gãy xương cổ chân. Các lớp yếu gồm cắt cụt ngón tay, gãy cột sống ngực, gãy xương trụ và gãy xương thuyền. Cắt cụt ngón tay thường bị nhầm với gãy xương ngón tay, còn gãy cột sống ngực thường bị nhầm với gãy cột sống thắt lưng; đây là các cặp có vị trí giải phẫu hoặc biểu hiện văn bản gần nhau. Lớp bình thường chỉ đạt độ nhạy trung bình 0.43, cho thấy mô hình vẫn gán một phần đáng kể ảnh không tổn thương vào các lớp bệnh lý.




Hình 4.2: Khoảng tin cậy ghép cặp 95% của chênh lệch điểm F1 trung bình theo lớp giữa XBone-Net và các mô hình cơ sở




Hình 4.3: Ma trận nhầm lẫn chuẩn hóa theo lớp thực của XBone-Net trên CTCH, tổng hợp trên ba hạt giống

Hai đường cong xếp hạng ở Hình 4.4 và Hình 4.5 làm rõ khoảng cách giữa chất lượng xếp hạng và quyết định lớp. Macro-AUROC đạt 0.947 ± 0.025 , trong khi Macro-AUPRC đạt 0.619 ± 0.014 . Đường cong độ chính xác-độ nhạy vẫn cao hơn rõ rệt mức phổ biến trung bình 0.045, nhưng giảm nhanh khi độ nhạy tiến gần 1, phản ánh khó khăn trong việc duy trì độ chính xác cao cho toàn bộ các lớp hiếm.




Hình 4.4: Đường cong độ chính xác-độ nhạy trung bình theo lớp của XBone-Net trên CTCH



Hình 4.5: Đường cong đặc trưng hoạt động trung bình theo lớp của XBone-Net trên CTCH

Đường cong hiệu chỉnh trong Hình 4.6 cho thấy sai số hiệu chỉnh kỳ vọng đạt $10.32\% \pm 3.03\%$. Ở phần lớn các khoảng có độ tin cậy từ khoảng 0.6 trở lên, độ chính xác quan sát thấp hơn độ tin cậy trung bình, cho thấy xu hướng quá tự tin. Độ biến thiên giữa ba hạt giống tăng ở các khoảng tin cậy cao, vì vậy xác suất dự đoán cần được hiệu chỉnh thêm trước khi được dùng làm tín hiệu quyết định độc lập.



Hình 4.6: Đường cong hiệu chỉnh trung bình của XBone-Net trên CTCH qua ba hạt giống

4.4.2 Kết quả trong trường hợp ít mẫu

Kết quả trong Bảng 4.14 và Bảng 4.15 cho thấy hiệu năng tăng theo ngân sách mẫu nhưng thứ hạng thay đổi giữa bộ dữ liệu. Trên BTXRD, XBone-Net đạt điểm F1 0.1620 ± 0.0259 ở mức một mẫu, thấp hơn hai mô hình cơ sở tại 10 và 20 mẫu, mô hình dẫn đầu với 0.4302 ± 0.0263 và 0.5202 ± 0.0300 . Trên CTCH, XBone-Net dẫn đầu ở mức một mẫu với 0.2236 ± 0.0206 và đạt điểm F1 cao nhất ở mức 10 mẫu với 0.4329 ± 0.0357 , nhưng thấp hơn LoRA-BiomedCLIP tại 20 mẫu.

Dữ liệu	Thiết lập	Mô hình	Accuracy $\uparrow$	Balanced Accuracy $\uparrow$	Macro-F1 $\uparrow$
BTXRD	1 mẫu	LoRA-BiomedCLIP	0.2782 ± 0.0553	0.2132 ± 0.0468	0.1699 ± 0.0356
		LoRA-PubMedCLIP	0.3164 ± 0.1723	0.2507 ± 0.0431	0.1818 ± 0.0619
		XBone-Net	0.2480 ± 0.0370	0.2116 ± 0.0503	0.1620 ± 0.0259
	10 mẫu	LoRA-BiomedCLIP	0.6769 ± 0.0381	0.4671 ± 0.0159	0.4211 ± 0.0123
		LoRA-PubMedCLIP	0.6640 ± 0.0615	0.4441 ± 0.0105	0.4164 ± 0.0157
		XBone-Net	0.6889 ± 0.0296	0.4771 ± 0.0300	0.4302 ± 0.0263
	20 mẫu	LoRA-BiomedCLIP	0.7311 ± 0.0073	0.5492 ± 0.0244	0.4876 ± 0.0044
		LoRA-PubMedCLIP	0.7369 ± 0.0109	0.5785 ± 0.0158	0.5132 ± 0.0112
		XBone-Net	0.7449 ± 0.0166	0.5949 ± 0.0258	0.5202 ± 0.0300
CTCH	1 mẫu	LoRA-BiomedCLIP	0.2128 ± 0.0116	0.2830 ± 0.0164	0.2074 ± 0.0034
		LoRA-PubMedCLIP	0.1908 ± 0.0496	0.2850 ± 0.0749	0.1876 ± 0.0434
		XBone-Net	0.2342 ± 0.0175	0.3351 ± 0.0659	0.2236 ± 0.0206
	10 mẫu	LoRA-BiomedCLIP	0.4036 ± 0.0334	0.5558 ± 0.0275	0.4291 ± 0.0165
		LoRA-PubMedCLIP	0.3812 ± 0.0158	0.5629 ± 0.0136	0.4186 ± 0.0117
		XBone-Net	0.3926 ± 0.0511	0.5590 ± 0.0419	0.4329 ± 0.0357
	20 mẫu	LoRA-BiomedCLIP	0.4395 ± 0.0269	0.6136 ± 0.0263	0.4803 ± 0.0219
		LoRA-PubMedCLIP	0.4509 ± 0.0195	0.5878 ± 0.0230	0.4649 ± 0.0236
		XBone-Net	0.4360 ± 0.0183	0.5856 ± 0.0173	0.4684 ± 0.0063

Bảng 4.14: Kết quả phân loại trong các thiết lập mẫu học hạn chế

Dữ liệu	Thiết lập	Mô hình	Macro-AUROC $\uparrow$	Macro-AUPRC $\uparrow$
BTXRD	1 mẫu	LoRA-BiomedCLIP	0.6319 ± 0.0404	0.2085 ± 0.0342
		LoRA-PubMedCLIP	0.6511 ± 0.0259	0.2501 ± 0.0364
		XBone-Net	0.6274 ± 0.0274	0.2035 ± 0.0383
	10 mẫu	LoRA-BiomedCLIP	0.8598 ± 0.0144	0.4467 ± 0.0173
		LoRA-PubMedCLIP	0.8529 ± 0.0190	0.4606 ± 0.0183
		XBone-Net	0.8577 ± 0.0050	0.4552 ± 0.0330
	20 mẫu	LoRA-BiomedCLIP	0.9271 ± 0.0092	0.5420 ± 0.0061
		LoRA-PubMedCLIP	0.9205 ± 0.0132	0.5561 ± 0.0067
		XBone-Net	0.9163 ± 0.0160	0.5635 ± 0.0395
CTCH	1 mẫu	LoRA-BiomedCLIP	0.8231 ± 0.0212	0.2357 ± 0.0130
		LoRA-PubMedCLIP	0.7904 ± 0.0188	0.2040 ± 0.0257
		XBone-Net	0.8645 ± 0.0082	0.2882 ± 0.0140
	10 mẫu	LoRA-BiomedCLIP	0.9353 ± 0.0070	0.4647 ± 0.0268
		LoRA-PubMedCLIP	0.9393 ± 0.0065	0.4785 ± 0.0053
		XBone-Net	0.9368 ± 0.0108	0.4540 ± 0.0235
	20 mẫu	LoRA-BiomedCLIP	0.9416 ± 0.0143	0.5088 ± 0.0308
		LoRA-PubMedCLIP	0.9501 ± 0.0011	0.5263 ± 0.0191
		XBone-Net	0.9457 ± 0.0072	0.5217 ± 0.0147

Bảng 4.15: Kết quả xếp hạng xác suất trong thiết lập mẫu học hạn chế

Khi tăng từ một lên 10 mẫu, điểm F1 của XBone-Net tăng 0.2682 điểm trên BTXRD và 0.2093 điểm trên CTCH. Mức tăng từ 10 lên 20 mẫu giảm còn 0.0900 và 0.0355 điểm. Xu hướng gợi ý lợi ích biên giảm khi bổ sung mẫu, nhưng ba mức ngân sách chưa đủ để mô tả đầy đủ đường học. Độ lệch chuẩn của XBone-Net tương đối lớn ở một số ngân sách, đặc biệt tại 10 và 20 mẫu trên BTXRD và 10 mẫu trên CTCH, cho thấy kết quả còn nhạy với lựa chọn tập mẫu theo hạt giống.

4.4.3 Hiệu quả tham số và chi phí suy luận

Trước hết, Bảng 4.16 đối chiếu ba mức thích nghi bộ mã hóa nền tảng trên CTCH. XBone-Net sử dụng thích nghi hạng thấp và cập nhật 8.63 triệu tham số, tương đương 4.22% tổng số tham số, trong khi tinh chỉnh toàn bộ cập nhật 199.43 triệu tham số. Cấu hình thích nghi hạng thấp đạt điểm F1 trung bình theo lớp 0.5558 ± 0.0072 và diện tích dưới đường cong độ chính xác-độ nhạy trung bình theo lớp 0.6189 ± 0.0145 , cao hơn tinh chỉnh toàn bộ lần lượt 0.0146 và 0.0357 điểm. Diện tích dưới đường cong đặc trưng hoạt động của hai cấu hình gần tương đương. Kết quả xác nhận rằng việc giới hạn phạm vi cập nhật vẫn duy trì hiệu năng cạnh tranh trên dữ liệu hiện có.

Phương pháp	Tham số cập nhật	Macro-F1 $\uparrow$	Macro-AUROC $\uparrow$	Macro-AUPRC $\uparrow$
Đóng băng bộ mã hóa	3.49M (1.75%)	0.5405 ± 0.0061	0.9502 ± 0.0105	0.5641 ± 0.0091
LoRA (XBone-Net)	8.63M (4.22%)	0.5558 ± 0.0072	0.9473 ± 0.0246	0.6189 ± 0.0145
Tinh chỉnh toàn bộ	199.43M (100%)	0.5412 ± 0.0089	0.9507 ± 0.0091	0.5832 ± 0.0192

Bảng 4.16: So sánh các mức thích nghi trên bộ dữ liệu CTCH

Số tham số của ba mô hình dùng thích nghi hạng thấp trong thiết lập toàn bộ dữ liệu được trình bày tại Bảng 4.17. XBone-Net có khoảng 204.54 triệu tham số và cập nhật 8.63 triệu tham số. Mức này cao hơn LoRA-BiomedCLIP và LoRA-PubMedCLIP do XBone-Net bổ sung mô-đun tổng hợp ảnh cục bộ, cơ chế dung hợp và đầu phân lớp theo tâm lớp. Tuy vậy, tỷ lệ tham số được cập nhật vẫn chỉ bằng 4.22%, thấp hơn đáng kể so với tinh chỉnh toàn bộ. Số tham số gần như không thay đổi giữa BTXRD và CTCH; phần chênh lệch nhỏ chỉ đến từ số lớp đầu ra.

Dữ liệu	Mô hình	Tổng tham số	Tham số huấn luyện	Tỷ lệ (%)
BTXRD	LoRA-BiomedCLIP	201,447,179	5,544,458	2.75%
	LoRA-PubMedCLIP	155,052,299	3,774,986	2.43%
	XBone-Net	204,535,308	8,632,587	4.22%
CTCH	LoRA-BiomedCLIP	201,453,335	5,550,614	2.76%
	LoRA-PubMedCLIP	155,058,455	3,781,142	2.44%
	XBone-Net	204,535,320	8,632,599	4.22%

Bảng 4.17: Đánh giá số lượng tham số của các mô hình khi sử dụng toàn bộ dữ liệu

Dữ liệu	Mô hình	GFLOPs (GFLOP/mẫu)	Thông lượng (mẫu/s)	Độ trễ trung bình (ms/mẫu)	Bộ nhớ GPU cực đại (MiB)
BTXRD	LoRA-BiomedCLIP	83.321	30.6	36.25	792.6
	LoRA-PubMedCLIP	15.198	33.3	43.87	603.6
	XBone-Net	229.020	17.7	64.92	835.5
CTCH	LoRA-BiomedCLIP	83.321	38.3	30.16	792.6
	LoRA-PubMedCLIP	15.198	37.7	34.56	603.6
	XBone-Net	229.020	13.4	87.15	835.6

Bảng 4.18: Đánh giá chi phí tính toán và tốc độ suy luận của các mô hình khi sử dụng toàn bộ dữ liệu

Bảng 4.18 cho thấy hiệu quả tham số khi huấn luyện không đồng nghĩa với chi phí suy luận thấp. XBone-Net cần 229.020 tỷ phép toán dấu phẩy động trên mỗi mẫu, cao gấp khoảng 2.75 lần LoRA-BiomedCLIP và 15.07 lần LoRA-PubMedCLIP. Nguyên nhân chính là mỗi mẫu được mã hóa bằng một ảnh toàn cục cùng bốn vùng ảnh cục bộ trước khi các biểu diễn được tổng hợp và dung hợp với văn bản.

Trên BTXRD, XBone-Net đạt thông lượng 17.7 mẫu mỗi giây và độ trễ trung bình 64.92 mili giây mỗi mẫu, trong khi hai mô hình cơ sở đạt từ 30.6 đến 33.3 mẫu mỗi giây. Trên CTCH, thông lượng của XBone-Net giảm còn 13.4 mẫu mỗi giây và độ trễ tăng lên 87.15 mili giây mỗi mẫu, so với thông lượng từ 37.7 đến 38.3 mẫu mỗi giây của hai mô hình cơ sở. Bộ nhớ đồ họa cực đại của XBone-Net đạt khoảng 835.5 MiB, cao hơn LoRA-BiomedCLIP khoảng 5% và LoRA-PubMedCLIP khoảng 38%. Vì các phép đo chỉ bao gồm lan truyền tiến sau khi dữ liệu đã được đưa lên bộ nhớ đồ họa, các giá trị này phản ánh chi phí của kiến trúc mô hình hơn là thời gian tiền xử lý hoặc đọc dữ liệu.

Các kết quả trong thiết lập mẫu học hạn chế được trình bày tại Bảng 4.19 và Bảng 4.20. Số tham số và số phép toán trên mỗi mẫu không thay đổi theo ngân sách một, 10 hoặc 20 mẫu mỗi lớp vì kiến trúc suy luận được giữ nguyên. XBone-Net duy trì 8.63 triệu tham số huấn luyện và 229.020 tỷ phép toán dấu phẩy động trên mỗi mẫu ở mọi ngân sách. Thông lượng quan sát được dao động từ 14.2 đến 15.4 mẫu mỗi giây trên BTXRD và từ 14.5 đến 16.8 mẫu mỗi giây trên CTCH; độ trễ tương ứng dao động từ 77.28 đến 84.25 mili giây và từ 66.27 đến 80.92 mili giây. Những chênh lệch nhỏ giữa các ngân sách không được diễn giải như ảnh hưởng của số mẫu huấn luyện, vì độ phức tạp suy luận là như nhau và sai khác chủ yếu phản ánh biến thiên của phép đo thời gian.

Dữ liệu	Kịch bản	Mô hình	Tổng tham số	Tham số huấn luyện	Tỷ lệ (%)
BTXRD	1 mẫu	LoRA-BiomedCLIP	201,447,179	5,544,458	2.75%
		LoRA-PubMedCLIP	155,052,299	3,774,986	2.43%
		XBone-Net	204,535,308	8,632,587	4.22%
	10 mẫu	LoRA-BiomedCLIP	201,447,179	5,544,458	2.75%
		LoRA-PubMedCLIP	155,052,299	3,774,986	2.43%
		XBone-Net	204,535,308	8,632,587	4.22%
	20 mẫu	LoRA-BiomedCLIP	201,447,179	5,544,458	2.75%
		LoRA-PubMedCLIP	155,052,299	3,774,986	2.43%
		XBone-Net	204,535,308	8,632,587	4.22%
CTCH	1 mẫu	LoRA-BiomedCLIP	201,453,335	5,550,614	2.76%
		LoRA-PubMedCLIP	155,058,455	3,781,142	2.44%
		XBone-Net	204,535,320	8,632,599	4.22%
	10 mẫu	LoRA-BiomedCLIP	201,453,335	5,550,614	2.76%
		LoRA-PubMedCLIP	155,058,455	3,781,142	2.44%
		XBone-Net	204,535,320	8,632,599	4.22%
	20 mẫu	LoRA-BiomedCLIP	201,453,335	5,550,614	2.76%
		LoRA-PubMedCLIP	155,058,455	3,781,142	2.44%
		XBone-Net	204,535,320	8,632,599	4.22%

Bảng 4.19: Đánh giá số lượng tham số của các mô hình trong thiết lập mẫu học hạn chế

Dữ liệu	Kịch bản	Mô hình	GFLOPs (GFLOP/mẫu)	Thông lượng (mẫu/s)	Độ trễ trung bình (ms/mẫu)	Bộ nhớ GPU cực đại (MiB)
BTXRD	1 mẫu	LoRA-BiomedCLIP	83.321	28.8	37.32	792.6
		LoRA-PubMedCLIP	15.198	33.1	43.74	603.6
		XBone-Net	229.020	14.3	82.53	835.5
	10 mẫu	LoRA-BiomedCLIP	83.321	30.9	35.18	792.6
		LoRA-PubMedCLIP	15.198	35.2	38.77	603.6
		XBone-Net	229.020	14.2	84.25	835.5
	20 mẫu	LoRA-BiomedCLIP	83.321	28.5	37.94	792.6
		LoRA-PubMedCLIP	15.198	33.1	41.50	611.0
		XBone-Net	229.020	15.4	77.28	835.5
CTCH	1 mẫu	LoRA-BiomedCLIP	83.321	32.2	33.56	792.6
		LoRA-PubMedCLIP	15.198	34.6	39.98	603.6
		XBone-Net	229.020	16.6	73.73	835.6
	10 mẫu	LoRA-BiomedCLIP	83.321	30.7	35.61	792.6
		LoRA-PubMedCLIP	15.198	35.9	38.31	603.6
		XBone-Net	229.020	16.8	66.27	835.6
	20 mẫu	LoRA-BiomedCLIP	83.321	28.2	37.91	792.6
		LoRA-PubMedCLIP	15.198	31.9	43.91	603.6
		XBone-Net	229.020	14.5	80.92	835.6

Bảng 4.20: Đánh giá chi phí tính toán và tốc độ suy luận của các mô hình trong thiết lập mẫu học hạn chế

Về thời gian huấn luyện thực, XBone-Net cần 2.61 ± 0.44 giờ trên ba hạt giống, trong khi cấu hình tinh chỉnh toàn bộ có một phép đo 1.94 giờ. Quy trình hai pha cùng nhánh ảnh toàn cục-cục bộ làm tăng số lượt mã hóa, vì vậy mức giảm tham số cập nhật không chuyển trực tiếp thành thời gian huấn luyện ngắn hơn. Do đối chứng tinh chỉnh toàn bộ mới được đo một lần, kết quả hiện tại chỉ xác nhận lợi thế về phạm vi tham số cần cập nhật và chưa xác nhận lợi thế về thời gian huấn luyện.

Xét tổng thể, XBone-Net đạt hiệu quả tham số so với tinh chỉnh toàn bộ và duy trì hiệu năng cạnh tranh trong một số thiết lập ít mẫu. Đổi lại, mô hình có số phép toán, độ trễ và mức sử dụng bộ nhớ cao hơn hai

mô hình cơ sở dùng thích nghi hạng thấp. Do đó, lợi ích của phương pháp nằm ở khả năng thích nghi với số tham số cập nhật hạn chế và khai thác ảnh độ phân giải cao, không phải ở chi phí suy luận thấp.

4.4.4 Kết luận

Trong thiết lập toàn bộ dữ liệu, XBone-Net không dẫn đầu điểm F1 nhưng đạt chất lượng xếp hạng cao nhất trên cả hai bộ dữ liệu và có hiệu năng gần các mô hình mạnh nhất trên CTCH. Lợi thế xuất hiện rõ hơn ở một số ngân sách ít mẫu, song không ổn định ở mọi mức. LoRA giảm mạnh số tham số cần cập nhật, nhưng kiến trúc ảnh toàn cục-cục bộ và quy trình hai pha làm cho tiết kiệm tham số không đồng nghĩa với giảm thời gian hoặc chi phí suy luận.

4.5 Đánh giá thành phần

4.5.1 Kết quả loại bỏ thành phần

Bảng 4.21 cho thấy không biến thể nào giảm đồng thời cả sáu độ đo. So với XBone-Net, gộp trung bình tăng độ chính xác cân bằng 0.0205, điểm F1 0.0178, hai độ đo xếp hạng lần lượt 0.0104 và 0.0123 điểm, nhưng sai số hiệu chỉnh kỳ vọng tăng từ 0.1032 lên 0.1506. Đầu tuyến tính tăng độ chính xác 0.0538 và điểm F1 0.0331 điểm, đồng thời làm Macro-AUROC giảm 0.0393 điểm. Nối đặc trưng đạt sai số hiệu chỉnh thấp nhất (0.0789 ± 0.0148) nhưng điểm F1 giảm 0.0133 điểm.


Thành phần/ độ đo	XBone-Net	Không tiền xử lý	Gộp trung bình	Chỉ pha 2	Nối đặc trưng	Đầu tuyến tính
Tiền xử lý ảnh	✓		✓	✓	✓	✓
Gộp chú ý cục bộ	✓	–		✓	✓	✓
Huấn luyện pha 1	✓	✓	✓		✓	✓
Chú ý chéo hai chiều	✓	✓	✓	✓		✓
Tầm lớp thực nghiệm	✓	✓	✓	✓	✓	
Accuracy ↑	0.5725 ± 0.0286	0.6074 ± 0.0204	0.5790 ± 0.0139	0.6173 ± 0.0119	0.5924 ± 0.0085	0.6263 ± 0.0060
Balanced Accuracy ↑	0.5844 ± 0.0454	0.5571 ± 0.0104	0.6049 ± 0.0459	0.5572 ± 0.0239	0.5668 ± 0.0276	0.5779 ± 0.0396
Macro-F1 ↑	0.5558 ± 0.0072	0.5553 ± 0.0136	0.5736 ± 0.0251	0.5753 ± 0.0175	0.5425 ± 0.0130	0.5889 ± 0.0251
Macro-AUROC ↑	0.9473 ± 0.0246	0.9148 ± 0.0223	0.9577 ± 0.0082	0.9144 ± 0.0198	0.9566 ± 0.0046	0.9080 ± 0.0099
Macro-AUPRC ↑	0.6189 ± 0.0145	0.5990 ± 0.0073	0.6312 ± 0.0277	0.6268 ± 0.0170	0.6019 ± 0.0139	0.6076 ± 0.0218
ECE ↓	0.1032 ± 0.0303	0.1743 ± 0.0634	0.1506 ± 0.0564	0.1868 ± 0.0724	0.0789 ± 0.0148	0.0882 ± 0.0153

Bảng 4.21: Nghiên cứu loại bỏ từng thành phần của XBone-Net trên CTCH


Bỏ xử lý ảnh độ phân giải cao gần như giữ nguyên điểm F1 (0.5553 ± 0.0136) nhưng làm hai độ đo xếp hạng giảm và sai số hiệu chỉnh tăng lên 0.1743 ± 0.0634 . Kết quả hỗ trợ vai trò của việc duy trì thông tin cục bộ đối với chất lượng xếp hạng và hiệu chỉnh, nhưng gộp trung bình lại tốt hơn gộp có trọng số chú ý ở nhiều độ đo. Do đó, lợi ích quan sát được gắn với nhánh ảnh cục bộ nhiều hơn với cơ chế gộp hiện tại.

Chỉ huấn luyện pha 2 tăng điểm F1 lên 0.5753 ± 0.0175 , nhưng Macro-AUROC giảm xuống 0.9144 ± 0.0198 và sai số hiệu chỉnh tăng lên 0.1868 ± 0.0724 . Pha khớp ngữ nghĩa vì vậy chưa cải thiện quyết định lớp một cách nhất quán, nhưng có liên hệ với chất lượng xếp hạng và xác suất dự đoán.


Các khoảng tái lấy mẫu bắt cặp trong Hình 4.7, Hình 4.8 và Hình 4.9 cho thấy sau hiệu chỉnh Holm, chỉ pha 2 và đầu tuyến tính có độ chính xác cao hơn XBone-Net trong phép so sánh hiện tại; không biến thể nào khác biệt rõ theo điểm F1, độ chính xác cân bằng hoặc diện tích dưới đường cong độ chính xác-độ nhạy; còn XBone-Net có Macro-AUROC cao hơn đầu tuyến tính. Các phép so sánh được tính trên các dự đoán của ba lần huấn luyện hiện có và không thay thế việc lặp lại trên số hạt giống lớn hơn.



Hình 4.7: Chênh lệch độ chính xác giữa các biến thể loại bỏ thành phần và XBone-Net trên CTCH



Hình 4.8: Chênh lệch Macro-F1 giữa các biến thể và XBone-Net trên CTCH



Hình 4.9: Chênh lệch Macro-AUROC giữa các biến thể và XBone-Net trên CTCH

4.5.2 Kết luận

Nhánh ảnh cục bộ, huấn luyện hai pha, dung hợp và đầu tâm lớp đều làm thay đổi quyết định lớp, chất lượng xếp hạng hoặc hiệu chỉnh, nhưng không thành phần nào cải thiện nhất quán mọi tiêu chí. Cấu hình đầy đủ là một điểm đánh đổi: nhánh cục bộ và pha khớp ngữ nghĩa liên hệ với xếp

hạng và hiệu chỉnh, trong khi gộp trung bình, đầu tuyến tính hoặc một số biến thể đơn giản có thể đạt điểm F1 hoặc độ chính xác cao hơn. Gộp có trọng số chú ý và chú ý chéo hai chiều là hai lựa chọn cần được đơn giản hóa hoặc kiểm chứng thêm.

4.6 Biểu diễn và dữ liệu ngoài phân phối

4.6.1 Hình học biểu diễn

Bảng 4.22 cho thấy biểu diễn dung hợp đạt Silhouette -0.0075 ± 0.0325 và Davies-Bouldin 2.8672 ± 0.0719 , thuận lợi nhất trong sáu không gian được khảo sát. Biểu diễn ảnh sau khi nhận ngữ cảnh văn bản đứng thứ hai về Silhouette (-0.0880 ± 0.0124), còn biểu diễn văn bản sau khi nhận ngữ cảnh ảnh đứng thứ hai về Davies-Bouldin (3.5628 ± 0.1281).

Không gian biểu diễn	Silhouette $\uparrow$	Davies-Bouldin $\downarrow$
Dung hợp	-0.0075 ± 0.0325	2.8672 ± 0.0719
Ảnh toàn cục	-0.0974 ± 0.0197	4.1912 ± 0.0453
Tóm tắt ảnh cục bộ	-0.1595 ± 0.0284	4.3243 ± 0.2035
Văn bản toàn cục	-0.1205 ± 0.0104	3.6686 ± 0.0914
Ảnh nhận ngữ cảnh văn bản	-0.0880 ± 0.0124	3.7898 ± 0.0989
Văn bản nhận ngữ cảnh ảnh	-0.1179 ± 0.0115	3.5628 ± 0.1281

Bảng 4.22: Hình học của các không gian biểu diễn trên 669 mẫu kiểm thử CTCH theo Silhouette và Davies-Bouldin; giá trị là trung bình $\pm$ độ lệch chuẩn giữa ba hạt giống. Chữ đậm biểu thị kết quả tốt nhất trong từng cột.

Mọi giá trị Silhouette đều âm. Tóm tắt ảnh cục bộ có Silhouette thấp nhất (-0.1595 ± 0.0284) và Davies-Bouldin cao nhất (4.3243 ± 0.2035). Hai độ đo cùng cho thấy dung hợp làm giảm mức chồng lấn tương đối giữa các lớp trên CTCH, nhưng giá trị gần 0 chưa xác nhận các cụm tách biệt ổn định. Hình học thuận lợi hơn trong dữ liệu kiểm thử CTCH cũng không bảo đảm khả năng phát hiện mọi dạng dịch chuyển, vì mục tiêu phân tách lớp trong phân phối khác với mục tiêu tách một phân phối mới.

4.6.2 Phát hiện dữ liệu ngoài phân phối

Bảng 4.23 sử dụng 669 mẫu CTCH trong phân phối, 44 mẫu ngoài không gian nhãn của CTCH và 750 mẫu BTXRD. Khoảng cách Mahalanobis đạt diện tích dưới đường cong phân biệt cao nhất trong bốn phương pháp trên BTXRD (0.8042 ± 0.0938) và trên nhóm ngoài không gian nhãn (0.6286 ± 0.0177). Năm láng giềng gần nhất đạt diện tích dưới đường cong độ chính xác-độ nhạy cao nhất trên nhóm ngoài không gian nhãn.


Kịch bản	Phương pháp	AUROC-ODD $\uparrow$	AUPR-Out $\uparrow$	FPR@95%TPR $\downarrow$
OOD ngữ nghĩa	Cosine	0.6006 ± 0.0132	0.0965 ± 0.0066	0.8864 ± 0.0000
	Mahalanobis	0.6286 ± 0.0177	0.1034 ± 0.0092	0.8864 ± 0.0394
	kNN	0.6269 ± 0.0175	0.1083 ± 0.0112	0.8788 ± 0.0131
	Entropy	0.5705 ± 0.0230	0.1052 ± 0.0162	0.8788 ± 0.0347
BTXRD	Cosine	0.7301 ± 0.0850	0.7268 ± 0.0633	0.7956 ± 0.0575
	Mahalanobis	0.8042 ± 0.0938	0.8009 ± 0.0609	0.7071 ± 0.0678
	kNN	0.7725 ± 0.0970	0.7641 ± 0.0703	0.7671 ± 0.0963
	Entropy	0.6918 ± 0.0859	0.7033 ± 0.0731	0.8258 ± 0.0697

Bảng 4.23: Kết quả phát hiện OOD hậu xử lý của XBone-Net trên các kịch bản được xét; các giá trị được trình bày dưới dạng trung bình $\pm$ độ lệch chuẩn trên ba hạt giống.

Kịch bản	Biểu diễn	AUROC-ODD $\uparrow$	AUPR-Out $\uparrow$	FPR@95%TPR $\downarrow$
OOD ngữ nghĩa	XBone-Net	0.6286 ± 0.0177	0.1034 ± 0.0092	0.8864 ± 0.0394
	Chỉ pha 2	0.5921 ± 0.0535	0.0870 ± 0.0190	0.9242 ± 0.0262
	Nổi đặc trưng	0.5795 ± 0.0151	0.0980 ± 0.0151	0.9015 ± 0.0131
	Đầu tuyến tính	0.5464 ± 0.0336	0.0746 ± 0.0079	0.9545 ± 0.0394
BTXRD	XBone-Net	0.8042 ± 0.0938	0.8009 ± 0.0609	0.7071 ± 0.0678
	Chỉ pha 2	0.6723 ± 0.0332	0.7015 ± 0.0382	0.8133 ± 0.0501
	Nổi đặc trưng	0.8966 ± 0.0478	0.8713 ± 0.0555	0.5978 ± 0.1744
	Đầu tuyến tính	0.6517 ± 0.0651	0.6719 ± 0.0623	0.8382 ± 0.0584

Bảng 4.24: So sánh biểu diễn RQ4 bằng cùng điểm Mahalanobis theo tâm lớp

Hình 4.10 cho thấy tín hiệu phân biệt rõ hơn khi dùng BTXRD làm dữ liệu dịch chuyển: diện tích dưới đường cong phân biệt và diện tích dưới đường cong độ chính xác-độ nhạy lần lượt đạt 0.804 và 0.801. Với 44 mẫu ngoài không gian nhãn nhưng còn gần miền CTCH, hai giá trị chỉ đạt 0.629 và 0.103. Tuy nhiên, FPR@95%TPR vẫn là 0.886 trên nhóm ngoài không gian nhãn và 0.707 trên BTXRD. Vì vậy, phần lớn mẫu ngoài phân phối vẫn không bị từ chối tại ngưỡng vận hành này.



Hình 4.10: Kết quả phát hiện dữ liệu ngoài phân phối bằng khoảng cách Mahalanobis theo tâm lớp trong hai kịch bản

Khi giữ cố định điểm Mahalanobis để so sánh không gian biểu diễn, BiomedCLIP không mẫu đạt diện tích dưới đường cong phân biệt 0.6362 trên nhóm ngoài không gian nhãn trong một lần đánh giá, cao hơn nhẹ XBone-Net. XBone-Net đạt diện tích dưới đường cong độ chính xác-độ nhạy cao nhất trong nhóm các biểu diễn được huấn luyện trên kịch bản này. Trên BTXRD, nổi đặc trưng dẫn đầu cả ba độ đo với diện tích dưới đường cong phân biệt 0.8966 ± 0.0478 và tỷ lệ chấp nhận nhầm 0.5978 ± 0.1744 . Kiến trúc dung hợp phức tạp vì vậy không mặc nhiên tạo không gian tốt nhất cho mọi dạng dịch chuyển.

4.6.3 Kết luận

Biểu diễn dung hợp có cấu trúc lớp thuận lợi hơn tương đối trên CTCH và chứa tín hiệu phân biệt dữ liệu ngoài phân phối. Tín hiệu rõ hơn khi nguồn ảnh, văn bản và không gian nhãn cùng thay đổi như kịch bản BTXRD, nhưng yếu đối với các bệnh ngoài không gian nhãn còn gần miền CTCH. Tỷ lệ chấp nhận nhầm còn cao ở cả hai kịch bản; mô-đun hiện tại chỉ phù hợp làm cảnh báo hỗ trợ và chưa đủ cho cơ chế từ chối tự động.

4.7 Phân tích nguồn thông tin của dự đoán

4.7.1 Can thiệp ở cấp phương thức

Bảng 4.25 ghi nhận mức giảm xác suất lớp đích trung bình lớn nhất khi thay ảnh toàn cục (0.3740 ± 0.0278), tiếp theo là bệnh sử (0.2614 ± 0.0621). Ảnh toàn cục và bệnh sử là nguồn có mức giảm lớn nhất lần lượt trong 63.48% và 35.87% số mẫu. Mức giảm trung bình của ảnh cục bộ là -0.0036 ± 0.0028 và chỉ chi phối 0.65% mẫu.

Nguồn thông tin	Mức giảm xác suất Δp	Tỷ lệ làm giảm xác suất	Tỷ lệ có mức giảm lớn nhất
Ảnh toàn cục	0.3740 ± 0.0278	$87.69\% \pm 9.67\%$	$63.48\% \pm 4.34\%$
Ảnh cục bộ	-0.0036 ± 0.0028	$42.85\% \pm 1.67\%$	$0.65\% \pm 1.00\%$
Bệnh sử lâm sàng	0.2614 ± 0.0621	$88.34\% \pm 3.34\%$	$35.87\% \pm 4.56\%$

Bảng 4.25: Can thiệp từng nguồn thông tin trên 669 mẫu kiểm thử CTCH tại mỗi hạt giống. Giá trị được trình bày dưới dạng trung bình $\pm$ độ lệch chuẩn giữa ba hạt giống. Δp là mức giảm xác suất của lớp được mô hình dự đoán trước can thiệp; cột cuối ghi tỷ lệ mẫu mà nguồn tương ứng có Δp lớn nhất.

Ảnh toàn cục được thay bằng đầu vào không, ảnh cục bộ được thay bằng biểu diễn toàn cục lặp lại và bệnh sử được thay bằng phần đệm. Mốc thay thế ảnh cục bộ vẫn giữ thông tin thị giác, vì vậy kết quả gần 0 không chứng minh các vùng cục bộ không có giá trị. Các chênh lệch chỉ mô tả độ nhạy đối với mốc tham chiếu hiện tại và không phải đóng góp nhân quả độc lập của từng nguồn.

4.7.2 Độ trung thực và ổn định của tích phân gradient

Bảng 4.26 cho thấy diện tích dưới đường cong loại bỏ theo tích phân gradient thấp hơn đối chứng ngẫu nhiên 0.0062 đối với đơn vị ảnh cục bộ và 0.0036 đối với đơn vị từ ngữ. Trọng số chú ý trên sáu trường hợp tại mỗi hạt giống cho kết quả gần thứ tự ngẫu nhiên. Chênh lệch nhỏ cho thấy

thứ tự quy đóng hiện tại chỉ cung cấp bằng chứng hạn chế về độ trung thực.


Thứ tự loại bỏ	AUC loại bỏ theo độ quan trọng	AUC loại bỏ ngẫu nhiên	Số mẫu/hạt giống
IG trên đơn vị biểu diễn ảnh cục bộ	0.6322 ± 0.0594	0.6384 ± 0.0619	669
IG trên đơn vị biểu diễn bệnh sử	0.6314 ± 0.0594	0.6350 ± 0.0614	669
Trọng số chú ý trên đơn vị biểu diễn ảnh	0.7339 ± 0.0509	0.7335 ± 0.0514	6
Trọng số chú ý trên đơn vị biểu diễn bệnh sử	0.7289 ± 0.0567	0.7309 ± 0.0580	6

Bảng 4.26: Độ trung thực của thứ tự đơn vị biểu diễn theo IG và trọng số chú ý chéo trên CTCH. AUC loại bỏ thấp hơn cho biết xác suất lớp đích giảm nhanh hơn khi loại bỏ trước các đơn vị được xếp hạng quan trọng. Hai hàng trọng số chú ý chỉ được tính trên sáu ca trực quan hóa ở mỗi hạt giống.

Kiểm tra ổn định cho thấy thứ hạng có thể thay đổi khi đầu vào bị gây nhiễu nhẹ, còn kiểm tra ngẫu nhiên hóa đầu phân lớp chưa tạo mức phân tách đủ mạnh để xem bản đồ quy đóng là bằng chứng độc lập. Vì vậy, tích phân gradient được dùng để truy vết nguồn thông tin có liên hệ với đầu ra, không được diễn giải như bằng chứng định vị tổn thương. Trọng số chú ý càng không nên được dùng riêng như lời giải thích.

4.7.3 Phân tích định tính


Hình 4.11 trình bày một trường hợp dự đoán đúng gãy xương chày với xác suất 50.8%. Bản đồ trên ảnh toàn cục tập trung quanh khớp gối và đầu gần xương chày; các vùng cục bộ bao phủ phần lớn vùng gối. Trong bệnh sử, các từ liên quan đến đau gối phải, té ngã và khó đi lại nhận mức quy đóng ủng hộ. Khi thay từng nguồn bằng mốc tham chiếu, xác suất lớp dự đoán giảm 0.249 đối với ảnh toàn cục, 0.071 đối với ảnh cục bộ và 0.053 đối với bệnh sử. Trường hợp này cho thấy dự đoán chủ yếu dựa vào ảnh toàn cục, còn hai nguồn còn lại cung cấp tín hiệu bổ sung.



Hình 4.11: Phân tích tích phân gradient của một trường hợp dự đoán đúng gãy xương chày trên CTCH


Hình 4.12 trình bày trường hợp nhãn đúng là cắt cụt ngón tay nhưng mô hình dự đoán gãy xương ngón tay với xác suất 71.7%. Bản đồ ảnh tập trung đúng vùng bàn tay và các ngón; bệnh sử chứa các cụm mô tả vết thương gần đứt ngón thứ ba và tai nạn do máy. Tuy nhiên, mô hình vẫn chọn lớp gãy xương ngón tay. Khi thay bệnh sử và ảnh toàn cục, xác suất lớp dự đoán giảm lần lượt 0.622 và 0.573, trong khi thay ảnh cục bộ chỉ làm giảm 0.009. Đây là trường hợp mô hình dựa mạnh vào hai nguồn có liên quan giải phẫu nhưng không phân biệt được bản chất tổn thương, cho

thấy lời giải thích có thể chỉ ra nguồn phụ thuộc mà không xác nhận tính đúng của dự đoán.



Hình 4.12: Phân tích tích phân gradient của một trường hợp nhaim cắt cụt ngón tay thành gãy xương ngón tay trên CTCH

Một trường hợp bổ sung trong Hình 4.13 được dự đoán đúng gãy xương vùng vai với xác suất 97.8%. Các vùng cục bộ và bản đồ tích phân gradient tập trung quanh vùng vai và xương đòn, nhưng các đường loại bỏ-khôi phục của cả đơn vị ảnh cục bộ và từ ngữ gần như phẳng quanh xác suất ban đầu. Trường hợp này cho thấy dự đoán có thể bị bão hòa ở mức xác suất cao hoặc mốc can thiệp chưa đủ làm thay đổi biểu diễn, khiến phép kiểm tra độ trung thực không phân biệt được thứ tự quan trọng.



Hình 4.13: Trường hợp dự đoán đúng có đường loại bỏ-khôi phục gần như phẳng ở mức xác suất cao

Ba trường hợp cho thấy giá trị của phân tích định tính nằm ở việc đối chiếu bản đồ quy đóng, bệnh sử và hành vi sau can thiệp. Một bản đồ tập trung đúng vùng giải phẫu không bảo đảm nhãn dự đoán đúng; ngược lại, đường cong loại bỏ gần phẳng có thể phản ánh bão hòa xác suất, mốc thay thế chưa phù hợp hoặc quy đóng chưa trung thực. Vì vậy, phân tích ca cần luôn được đọc cùng nhãn thật, xác suất, mức giảm theo phương thức và đối chứng loại bỏ ngẫu nhiên.

4.7.4 Kết luận

Trong phép can thiệp hiện tại, ảnh toàn cục và bệnh sử là hai nguồn chi phối dự đoán, còn vai trò biên của ảnh cục bộ phụ thuộc mạnh vào mốc thay thế. Tích phân gradient giúp truy vết vùng ảnh và từ ngữ có liên hệ với đầu ra, nhưng chênh lệch nhỏ so với thứ tự ngẫu nhiên cho thấy độ

trung thực còn hạn chế. Phân tích định tính xác nhận rằng lời giải thích có thể làm rõ nguồn phụ thuộc của cả dự đoán đúng và dự đoán sai, nhưng không xác lập quan hệ nhân quả, khả năng định vị tổn thương hoặc độ đúng lâm sàng.

Chương 5

Kết luận và hướng phát triển

5.1 Tổng kết

Khóa luận xây dựng và đánh giá XBone-Net, một quy trình phân lớp ảnh X-quang xương đa phương thức dựa trên BiomedCLIP. Quy trình kết hợp ảnh toàn cục, các vùng ảnh cục bộ độ phân giải cao và văn bản đi kèm; biểu diễn được dung hợp bằng chú ý chéo và phân lớp theo độ tương đồng với tâm lớp thực nghiệm. Bộ mã hóa nền tảng được thích nghi bằng LoRA trong quy trình hai pha. Trên biểu diễn sau dung hợp, khóa luận còn đánh giá bốn điểm OOD hậu xử lý gồm cosine theo tâm lớp, Mahalanobis theo tâm lớp, kNN và entropy.

Các thí nghiệm sử dụng ba hạt giống trên BTXRD và CTCH, bao gồm đối chứng phương thức, loại bỏ từng thành phần, các mức thích nghi bộ mã hóa, thiết lập ít mẫu và hai kịch bản OOD. Trên CTCH, khóa luận còn đánh giá tích phân gradient và can thiệp nguồn thông tin trên toàn bộ 669 mẫu kiểm thử ở mỗi hạt giống. Kết quả không cho thấy một cấu hình duy nhất dẫn đầu trên mọi độ đo. XBone-Net có ưu thế ở một số độ đo xếp hạng, một số ngân sách ít mẫu và mức sử dụng tham số huấn luyện; ngược lại, gộp trung bình, đầu tuyến tính hoặc nổi đặc trưng có thể phù hợp hơn với những mục tiêu cụ thể.

Theo phạm vi cập nhật kết quả của khóa luận, chương này trả lời RQ1–

RQ5. Đối với RQ5, kết luận định lượng được giới hạn ở độ phụ thuộc theo mốc tham chiếu, độ trung thực và độ ổn định của mức quy đóng; khóa luận không suy rộng các kết quả này thành độ đúng lâm sàng hoặc khả năng định vị tổn thương.

5.2 Trả lời các câu hỏi nghiên cứu

5.2.1 RQ1: Vai trò của ảnh và văn bản

Kết hợp ảnh với văn bản cải thiện Macro-F1 so với chỉ ảnh trên cả hai bộ dữ liệu. Trên BTXRD, Macro-F1 tăng từ 0.3165 ± 0.0081 lên 0.6010 ± 0.0034 ; trên CTCH, chỉ số này tăng từ 0.3984 ± 0.0176 lên 0.5558 ± 0.0072 . So với chỉ văn bản, mô hình đầy đủ cũng tăng Macro-F1 0.0695 điểm trên BTXRD và 0.0788 điểm trên CTCH.

Hai bộ dữ liệu không có ý nghĩa bằng chứng giống nhau. CTCH có bệnh sử lâm sàng sẵn có; khi cả bệnh sử và mô tả X-quang được xáo trộn khác lớp, Macro-F1 giảm từ 0.5558 ± 0.0072 xuống 0.3039 ± 0.0048 , cho thấy mô hình phụ thuộc vào quan hệ ghép cặp ảnh–văn bản. Trên BTXRD, khi cả văn bản lâm sàng tổng hợp và mô tả X-quang được thay bằng văn bản của một mẫu khác lớp, Macro-F1 giảm từ 0.6010 ± 0.0034 xuống 0.0068 ± 0.0014 và Macro-AUROC giảm từ 0.9243 ± 0.0298 xuống 0.4124 ± 0.0644 . Mức giảm cực lớn phù hợp với việc phép can thiệp bắt buộc chọn mẫu cho khác lớp và văn bản tổng hợp BTXRD mang tín hiệu mạnh liên hệ với nhãn. Do đó, kết quả này xác nhận độ nhạy với ghép cặp trên BTXRD, nhưng không chứng minh giá trị tương đương của bệnh sử tự nhiên.

Trả lời RQ1: kết hợp ảnh và văn bản cải thiện Macro-F1 so với chỉ ảnh hoặc chỉ văn bản trên cả hai tập dữ liệu, và phép ghép sai khác lớp làm hiệu năng giảm rõ rệt, xác nhận mô hình sử dụng quan hệ liên phương thức thay vì chỉ sự hiện diện độc lập của từng đầu vào. Tuy nhiên, ý nghĩa lâm sàng phụ thuộc nguồn văn bản: CTCH có bệnh sử sẵn có, trong khi độ nhạy rất lớn trên BTXRD chịu ảnh hưởng của văn bản tổng hợp liên hệ mạnh với nhãn. Vì các cấu hình đơn phương thức đồng thời bỏ pha

1 và đối chứng xáo trộn thay cả hai nguồn văn bản, các chênh lệch chưa phải ước lượng đóng góp biên thuần túy của từng phương thức văn bản.

5.2.2 RQ2: Đóng góp của các thành phần XBone-Net

Các thành phần ảnh hưởng đến những mục tiêu khác nhau. Bỏ nhánh ảnh độ phân giải cao gần như không đổi Macro-F1 nhưng làm Macro-AUROC giảm từ 0.9473 xuống 0.9148, Macro-AUPRC giảm từ 0.6189 xuống 0.5990 và ECE tăng từ 0.1032 lên 0.1743. Tuy nhiên, gộp trung bình tốt hơn gộp có trọng số chú ý ở ba độ đo này, nên lợi ích quan sát được gắn với việc duy trì thông tin cục bộ nhiều hơn là cơ chế gộp hiện tại.

Chỉ huấn luyện pha 2 làm Macro-F1 tăng lên 0.5753 nhưng Macro-AUROC giảm xuống 0.9144 và ECE tăng lên 0.1868. Nổi đặc trưng đạt Macro-AUROC 0.9566 và ECE 0.0789, trong khi Macro-F1 giảm còn 0.5425. Hai hướng chú ý một chiều đạt kết quả gần cấu hình hai chiều, vì vậy chưa có bằng chứng chú ý chéo hai chiều vượt trội riêng trên tác vụ phân lớp. Đầu tuyến tính đạt Macro-F1 0.5889, cao hơn đầu tâm lớp, nhưng Macro-AUROC chỉ 0.9080. Bỏ trọng số lớp hoặc độ chệch theo lớp cũng cải thiện một số độ đo và làm giảm những độ đo khác.

Phân tích hình học bổ sung cho thấy biểu diễn dung hợp tốt nhất tương đối trong sáu không gian được khảo sát, với NMI 0.5447 ± 0.0065 và Balanced Accuracy theo tâm lớp 0.5847 ± 0.0456 . Tuy nhiên, Silhouette vẫn hơi âm (-0.0075 ± 0.0325), cho thấy các lớp còn chồng lấn. Kết quả này hỗ trợ vai trò tổ chức biểu diễn của phép dung hợp, nhưng không mâu thuẫn với việc nổi đặc trưng hoặc chú ý một chiều tốt hơn trên một số độ đo đầu ra.

Trả lời RQ2: nhánh ảnh cục bộ, chiến lược hai pha, dung hợp và đầu tâm lớp đều thay đổi hình học biểu diễn, quyết định lớp hoặc hiệu chuẩn, nhưng không thành phần nào tạo cải thiện nhất quán trên mọi tiêu chí. Cấu hình đầy đủ là một điểm đánh đổi giữa Macro-F1, khả năng xếp hạng và hiệu chuẩn; gộp có trọng số chú ý và chú ý chéo hai chiều là hai lựa

chọn cần được đơn giản hóa hoặc kiểm chứng thêm.

5.2.3 RQ3: Đánh đổi dữ liệu, tham số và chi phí tính toán

Trong thiết lập toàn bộ dữ liệu CTCH, LoRA cập nhật 8.63 triệu tham số (4.22%), thấp hơn nhiều so với 199.43 triệu tham số của tinh chỉnh toàn bộ. LoRA đạt Macro-F1 0.5558 ± 0.0072 và Macro-AUPRC 0.6189 ± 0.0145 , cao hơn tinh chỉnh toàn bộ lần lượt 0.0146 và 0.0357 điểm; Macro-AUROC của hai thiết lập gần nhau. So với đóng băng bộ mã hóa nền tảng, LoRA cũng cải thiện Macro-F1 và Macro-AUPRC.

Trong thiết lập ít mẫu, XBone-Net nổi bật nhất ở CTCH với một mẫu mỗi lớp và đạt Macro-F1 cao nhất trên BTXRD ở mức 10 và 20 mẫu. Lợi thế giảm khi ngân sách dữ liệu tăng và không nhất quán trên Macro-AUROC hoặc Macro-AUPRC. Về chi phí, XBone-Net cần 229.020 GFLOP/mẫu và có thông lượng thấp hơn các mô hình LoRA cơ sở. Thời gian huấn luyện thực là 2.61 ± 0.44 giờ trên ba hạt giống, trong khi tinh chỉnh toàn bộ có một phép đo 1.94 giờ; quy trình hai pha và nhánh ảnh độ phân giải cao làm cho tiết kiệm tham số không đồng nghĩa với tiết kiệm thời gian.

Trả lời RQ3: LoRA đạt hiệu quả tham số rõ ràng và duy trì hiệu năng cạnh tranh, đồng thời XBone-Net có lợi thế trong một số thiết lập cực ít nhãn. Tuy nhiên, kết quả không chứng minh lợi thế về thời gian huấn luyện hoặc suy luận. So sánh thời gian với tinh chỉnh toàn bộ còn hạn chế vì mới có một phép đo.

5.2.4 RQ4: Phân biệt dữ liệu ngoài phân phối

Với XBone-Net, Mahalanobis theo tâm lớp đạt AUROC-OOD 0.8042 ± 0.0938 trên BTXRD và 0.6286 ± 0.0177 trên đủ 44 mẫu OOD ngữ nghĩa. Điều này cho thấy biểu diễn dễ phân biệt dịch chuyển liên bộ dữ liệu hơn các trường hợp ngoài không gian nhãn nhưng còn gần phân phối CTCH. Tuy

nhiên, tại ngưỡng giữ ít nhất 95% mẫu trong phân phối, FPR@95%TPR vẫn là 0.7071 trên BTXRD và 0.8864 trên OOD ngữ nghĩa, tức phần lớn mẫu OOD chưa bị từ chối.

Đổi sánh cùng Mahalanobis cho thấy nổi đặc trưng đạt kết quả BTXRD tốt hơn XBone-Net, với AUROC-OOD 0.8966 ± 0.0478 và FPR@95%TPR 0.5978 ± 0.1744 .

Trong một lần đánh giá OOD ngữ nghĩa, BiomedCLIP không mẫu đạt AUROC-OOD 0.6362, cao hơn nhẹ XBone-Net. Với Mahalanobis, XBone-Net đạt AUPR-Out cao nhất, ở mức 0.1034 ± 0.0092 , đồng thời có FPR@95%TPR thấp nhất, ở mức 0.8864 ± 0.0394 . Vì vậy, chú ý chéo và đầu tâm lớp tạo biểu diễn cạnh tranh trên OOD ngữ nghĩa nhưng không bảo đảm không gian tốt nhất cho mọi dạng dịch chuyển.

Trả lời RQ4: các biểu diễn được đánh giá có chứa tín hiệu OOD, rõ hơn với dịch chuyển BTXRD; XBone-Net cạnh tranh trên OOD ngữ nghĩa nhưng không vượt trội đồng thời các mô hình cơ sở và kịch bản. FPR@95%TPR còn cao ở cả hai dạng dịch chuyển, nên mô-đun OOD chỉ phù hợp làm cảnh báo hỗ trợ và chưa đủ cho cơ chế từ chối tự động.

5.2.5 RQ5: Vai trò của các nguồn thông tin trong lời giải thích

Can thiệp trên toàn bộ 669 mẫu kiểm thử CTCH ở mỗi hạt giống cho thấy ảnh toàn cục tạo mức giảm xác suất lớp đích trung bình 0.3740 ± 0.0278 và là nguồn chi phối trong $63.48\% \pm 4.34\%$ số mẫu. Bệnh sử làm xác suất giảm 0.2614 ± 0.0621 và chi phối $35.87\% \pm 4.56\%$ số mẫu. Ảnh cục bộ chỉ chi phối $0.65\% \pm 1.00\%$ số mẫu và mức thay đổi trung bình gần không. Kết quả này cho thấy quyết định thường phụ thuộc đồng thời vào ảnh toàn cục và bệnh sử, còn vai trò biên của đơn vị biểu diễn cục bộ theo mốc tham chiếu hiện tại nhỏ hơn nhiều.

Mức quy đóng bằng tích phân gradient đạt tương quan Spearman 0.9158 ± 0.0085 dưới nhiễu nhỏ. Khi ngẫu nhiên hóa đầu phân lớp, tương quan giảm còn 0.1988 ± 0.3101 trên năm mẫu mỗi hạt giống, cho thấy lời giải thích phụ thuộc vào tham số đã học nhưng phép kiểm tra còn ít mẫu.

Deletion AUC theo thứ tự tích phân gradient chỉ thấp hơn thứ tự ngẫu nhiên 0.0062 đối với ảnh cục bộ và 0.0036 đối với bệnh sử. Trọng số chú ý chéo có entropy chuẩn hóa cao và Deletion AUC gần như không khác ngẫu nhiên trên sáu ca mỗi hạt giống, nên không được xem là lời giải thích độc lập.

Trả lời RQ5: tích phân gradient kết hợp can thiệp đầu vào cho phép truy vết nguồn thông tin ở cấp độ trường hợp và chỉ ra vai trò nổi trội của ảnh toàn cục cùng ảnh hưởng đáng kể của bệnh sử. Lời giải thích có độ ổn định tốt, nhưng chênh lệch về độ trung thực so với xếp hạng ngẫu nhiên còn nhỏ; do thiếu chú thích vùng tổn thương và đánh giá chuyên gia, kết quả chưa chứng minh độ đúng lâm sàng hoặc khả năng định vị tổn thương.

5.3 Hướng phát triển

Thiết kế hiện tại tạo cơ sở cho các nghiên cứu tiếp theo nhờ sử dụng ba hạt giống, báo cáo đồng thời độ đo quyết định lớp, xếp hạng, hiệu chuẩn và chi phí, đồng thời duy trì các đối chứng về phương thức, thành phần, mức thích nghi bộ mã hóa, biểu diễn và lời giải thích. Tuy nhiên, kết quả cũng cho thấy chưa có cấu hình dẫn đầu nhất quán, nên hướng phát triển cần ưu tiên kiểm chứng các đánh đổi thay vì chỉ mở rộng độ phức tạp của kiến trúc.

Về dữ liệu đa phương thức, văn bản BTXRD được tổng hợp từ siêu dữ liệu và cờ nhóm bệnh nên không tương đương bệnh sử tự nhiên, trong khi các đối chứng hiện tại thay đồng thời hai nguồn văn bản và bắt buộc ghép khác lớp. Nghiên cứu tiếp theo cần xáo trộn riêng bệnh sử và mô tả X-quang, ghép sai cùng lớp, gây nhiễu từng phần và đánh giá trường hợp thiếu hoặc lỗi thời văn bản. Với BTXRD, cần tách văn bản tạo từ thông tin không chứa nhãn khỏi văn bản dùng cờ nhóm bệnh; với CTCH, cần kiểm tra bệnh sử từ cơ sở khác và định lượng ảnh hưởng của sai lệch dịch thuật.

Về kiến trúc và hiệu quả tính toán, gộp trung bình, đầu tuyến tính và nổi đặc trưng lần lượt tốt hơn cấu hình đầy đủ trên một số độ đo, còn LoRA giảm số tham số cập nhật nhưng chưa giảm chi phí suy luận của

nhánh ảnh độ phân giải cao. Do đó, nên khảo sát phiên bản XBone-Net gọn hơn với ít đơn vị biểu diễn cục bộ, gộp trung bình, nổi đặc trưng hoặc chú ý một chiều. Việc lựa chọn cần dựa trên tối ưu đa mục tiêu giữa Macro-F1, Macro-AUROC, Macro-AUPRC, ECE, GFLOPs và độ trễ; thời gian của tinh chỉnh toàn bộ và đóng băng bộ mã hóa cũng cần được thu thập trên đủ ba hạt giống để bảo đảm phép so sánh cân bằng.

Về biểu diễn và OOD, việc giữ cùng tập trong phân phối, hai kịch bản và điểm Mahalanobis giúp so sánh các biểu diễn nhất quán, nhưng tập OOD ngữ nghĩa mới có 44 mẫu và chưa bao phủ đầy đủ các dạng dịch chuyển. Nghiên cứu tiếp theo cần bổ sung OOD gần phân phối có kiểm soát, nhiều nhóm bệnh ngoài không gian nhãn, dịch chuyển thiết bị và dịch chuyển bệnh viện; ngưỡng cần được hiệu chỉnh trên tập xác thực độc lập. Các mục tiêu huấn luyện trực tiếp cho OOD hoặc dự đoán có chọn lọc chỉ nên được xem xét sau khi đánh giá đồng thời tỷ lệ từ chối và chi phí lỗi lâm sàng.

Về khả năng giải thích, tích phân gradient và can thiệp nguồn thông tin đã được đánh giá trên toàn bộ tập kiểm thử CTCH, nhưng chưa có chú thích vùng tổn thương hoặc đánh giá của bác sĩ; chênh lệch Deletion AUC so với thứ tự ngẫu nhiên còn nhỏ, còn phép ngẫu nhiên hóa đầu phân lớp và phân tích trọng số chú ý sử dụng ít mẫu. Cần bổ sung chú thích tổn thương, mốc thay thế đầu vào đa dạng, đánh giá chuyên gia và kiểm tra ngẫu nhiên hóa trên cỡ mẫu lớn hơn để phân biệt khả năng truy vết tín hiệu với độ đúng lâm sàng.

Cuối cùng, dữ liệu CTCH hiện đến từ một cơ sở và chưa có đánh giá tiền cứu hoặc kiểm định đa trung tâm. Hướng phát triển dài hạn là thực hiện kiểm định ngoài và nghiên cứu tiền cứu với bác sĩ đọc phim; chỉ sau khi xác nhận độ ổn định theo cơ sở, thiết bị, quần thể và chất lượng văn bản, hệ thống mới có thể được xem xét như công cụ hỗ trợ quyết định thay vì mô hình thử nghiệm.

Tài liệu tham khảo

Tiếng Anh

- [1] Jean-Baptiste Alayrac et al. “Flamingo: a Visual Language Model for Few-Shot Learning”. In: *Advances in Neural Information Processing Systems*. Vol. 35. 2022, pp. 23716–23736. URL: https://papers.nips.cc/paper_files/paper/2022/hash/960a172bc7fbf0177ccccbb411a7c Abstract-Conference.html.
- [2] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing”. In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5.
- [3] Kay H. Brodersen et al. “The Balanced Accuracy and Its Posterior Distribution”. In: *2010 20th International Conference on Pattern Recognition*. 2010, pp. 3121–3124. DOI: 10.1109/ICPR.2010.764. URL: <https://doi.org/10.1109/ICPR.2010.764>.
- [4] Alfredo Canziani, Adam Paszke, and Eugenio Culurciello. “An Analysis of Deep Neural Network Models for Practical Applications”. In: *arXiv preprint arXiv:1605.07678* (2016). eprint: 1605.07678. URL: <https://arxiv.org/abs/1605.07678>.
- [5] Yin Cui et al. “Class-Balanced Loss Based on Effective Number of Samples”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019, pp. 9268–9277. URL: https://openaccess.thecvf.com/content_CVPR_2019/html/Cui_Class-Balanced_Loss_Based_on_Effective_Number_of_Samples_CVPR_2019_paper.html.

- [6] David L. Davies and Donald W. Bouldin. “A Cluster Separation Measure”. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* PAMI-1.2 (1979), pp. 224–227. DOI: 10.1109/TPAMI.1979.4766909. URL: <https://doi.org/10.1109/TPAMI.1979.4766909>.
- [7] Jesse Davis and Mark H. Goadrich. “The Relationship Between Precision–Recall and ROC Curves”. In: *Proceedings of the 23rd International Conference on Machine Learning*. Association for Computing Machinery, 2006, pp. 233–240. DOI: 10.1145/1143844.1143874. URL: <https://doi.org/10.1145/1143844.1143874>.
- [8] Alexey Dosovitskiy et al. “An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale”. In: *International Conference on Learning Representations*. 2021. URL: <https://openreview.net/forum?id=YicbFdNTTy>.
- [9] Tom Fawcett. “An Introduction to ROC Analysis”. In: *Pattern Recognition Letters* 27.8 (2006), pp. 861–874. DOI: 10.1016/j.patrec.2005.10.010. URL: <https://doi.org/10.1016/j.patrec.2005.10.010>.
- [10] Chuan Guo et al. “On Calibration of Modern Neural Networks”. In: *Proceedings of the 34th International Conference on Machine Learning*. Vol. 70. Proceedings of Machine Learning Research. PMLR, 2017, pp. 1321–1330. URL: <https://proceedings.mlr.press/v70/guo17a.html>.
- [11] Kaiming He et al. “Deep Residual Learning for Image Recognition”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016.
- [12] Dan Hendrycks and Kevin Gimpel. “A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks”. In: *International Conference on Learning Representations*. 2017. URL: <https://arxiv.org/abs/1610.02136>.
- [13] Edward J. Hu et al. “LoRA: Low-Rank Adaptation of Large Language Models”. In: *International Conference on Learning Representations*. 2022. URL: <https://openreview.net/forum?id=nZeVKeeFYf9>.

- [14] Gao Huang et al. “Densely Connected Convolutional Networks”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017.
- [15] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.
- [16] Yijin Huang et al. “Fine-grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-resolution Medical Image Classification”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15012. Springer Nature Switzerland, 2024, pp. 120–130. DOI: 10.1007/978-3-031-72390-2_12.
- [17] Andrew Jaegle et al. “Perceiver: General Perception with Iterative Attention”. In: *Proceedings of the 38th International Conference on Machine Learning*. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 4651–4664. URL: <https://proceedings.mlr.press/v139/jaegle21a.html>.
- [18] Taha Koleilat et al. “BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models”. In: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*. 2025, pp. 14766–14776.
- [19] Zhengfeng Lai et al. “CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*. 2023, pp. 2374–2380.
- [20] Olivier Ledoit and Michael Wolf. “A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices”. In: *Journal of Multivariate Analysis* 88.2 (2004), pp. 365–411. DOI: 10.1016/S0047-259X(03)00096-4.

- [21] Kimin Lee et al. “A Simple Unified Framework for Detecting Out-of-Distribution Samples and Adversarial Attacks”. In: *Advances in Neural Information Processing Systems*. Vol. 31. 2018, pp. 7167–7177. URL: <https://proceedings.neurips.cc/paper/2018/hash/abdeb6f575ac5c6676b747bca8d09cc2-Abstract.html>.
- [22] Bo Li et al. *LLaVA-NeXT: What Else Influences Visual Instruction Tuning Beyond Data?* May 25, 2024. URL: <https://llava-vl.github.io/blog/2024-05-25-llava-next-ablations/> (visited on 07/25/2026).
- [23] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: <https://arxiv.org/abs/2306.00890>.
- [24] Yitong Li, Morteza Ghahremani, and Christian Wachinger. “Adapting Foundation Vision-Language Models to Medical Diagnosis via Query-Driven Expert Bridging”. In: (May 15, 2026). Version 3. arXiv: 2505.21698 [cs.CV].
- [25] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: <https://arxiv.org/abs/2401.12215>.
- [26] Shiyu Liang, Yixuan Li, and R. Srikant. “Enhancing the Reliability of Out-of-Distribution Image Detection in Neural Networks”. In: *International Conference on Learning Representations*. 2018.
- [27] Weitang Liu et al. “Energy-based Out-of-distribution Detection”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 21464–21475. URL: <https://proceedings.neurips.cc/paper/2020/hash/f5496252609c43eb8a3d147ab9b9c006-Abstract.html>.
- [28] David Marr and Ellen Hildreth. “Theory of Edge Detection”. In: *Proceedings of the Royal Society of London. Series B. Biological Sciences* 207.1167 (1980), pp. 187–217. DOI: 10.1098/rspb.1980.0020. URL: <https://doi.org/10.1098/rspb.1980.0020>.

- [29] Xueyan Mei et al. “Artificial intelligence-enabled rapid diagnosis of patients with COVID-19”. In: *Nature Medicine* 26 (Aug. 2020), 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: <https://www.nature.com/articles/s41591-020-0931-3>.
- [30] Michael Moor et al. *Med-Flamingo: a Multimodal Medical Few-shot Learner*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.15189. URL: <https://arxiv.org/abs/2307.15189>.
- [31] OpenAI. *GPT-4o System Card*. Aug. 8, 2024. URL: <https://openai.com/index/gpt-4o-system-card/> (visited on 08/01/2026).
- [32] Said Pertuz, Domenec Puig, and Miguel Angel Garcia. “Analysis of Focus Measure Operators for Shape-from-Focus”. In: *Pattern Recognition* 46.5 (2013), pp. 1415–1432. DOI: 10.1016/j.patcog.2012.11.011. URL: <https://doi.org/10.1016/j.patcog.2012.11.011>.
- [33] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.
- [34] Alec Radford et al. “Learning Transferable Visual Models From Natural Language Supervision”. In: *Proceedings of the 38th International Conference on Machine Learning*. Vol. 139. Proceedings of Machine Learning Research. PMLR, 2021, pp. 8748–8763. URL: <https://proceedings.mlr.press/v139/radford21a.html>.
- [35] Vijay Janapa Reddi et al. “MLPerf Inference Benchmark”. In: *2020 ACM/IEEE 47th Annual International Symposium on Computer Architecture*. 2020, pp. 446–459. DOI: 10.1109/ISCA45697.2020.00045. URL: <https://doi.org/10.1109/ISCA45697.2020.00045>.
- [36] Peter J. Rousseeuw. “Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis”. In: *Journal of Computational and Applied Mathematics* 20 (1987), pp. 53–65. DOI: 10.1016/0377-0427(87)90125-7. URL: [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7).

- [37] Bryan C Russell et al. “LabelMe: a database and web-based tool for image annotation”. In: *International journal of computer vision* 77.1-3 (2008), pp. 157–173.
- [38] Claude E. Shannon. “A Mathematical Theory of Communication”. In: *The Bell System Technical Journal* 27.3 (1948), pp. 379–423. DOI: 10.1002/j.1538-7305.1948.tb01338.x. URL: <https://doi.org/10.1002/j.1538-7305.1948.tb01338.x>.
- [39] Jake Snell, Kevin Swersky, and Richard S. Zemel. “Prototypical Networks for Few-shot Learning”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017, pp. 4077–4087. URL: https://papers.nips.cc/paper_files/paper/2017/hash/cb8da6767461f2812ae429Abstract.html.
- [40] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. “Axiomatic Attribution for Deep Networks”. In: *Proceedings of the 34th International Conference on Machine Learning*. Vol. 70. Proceedings of Machine Learning Research. PMLR, 2017, pp. 3319–3328. URL: <https://proceedings.mlr.press/v70/sundararajan17a.html>.
- [41] Tao Tu et al. *Towards Generalist Biomedical AI*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.14334. URL: <https://arxiv.org/abs/2307.14334>.
- [42] Xiaosong Wang et al. “TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018.
- [43] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, Dec. 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: <https://aclanthology.org/2022.emnlp-main.256/>.

- [44] Yandong Wen et al. “A discriminative feature learning approach for deep face recognition”. In: *Lecture Notes in Computer Science* (2016), 499–515. DOI: 10.1007/978-3-319-46478-7_31.
- [45] Shunhan Yao et al. “A Radiograph Dataset for the Classification, Localization, and Segmentation of Primary Bone Tumors”. In: *Scientific Data* 12.1 (2025), p. 88. DOI: 10.1038/s41597-024-04311-y. URL: <https://doi.org/10.1038/s41597-024-04311-y>.
- [46] Jiajin Zhang et al. “Disease-informed Adaptation of Vision-Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15011. Springer Nature Switzerland, 2024.
- [47] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoa2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoa2400640>.
- [48] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 7th Machine Learning for Healthcare Conference*. Ed. by Zachary Lipton et al. Vol. 182. Proceedings of Machine Learning Research. PMLR, 2022, pp. 2–25. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
- [49] Hong-Yu Zhou et al. “A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics”. In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).

Phụ lục A

Chi tiết về bộ dữ liệu

Phụ lục này bổ sung các thông tin kỹ thuật cần thiết để tái lập quá trình chuẩn bị hai bộ dữ liệu BTXRD và CTCH. Nội dung của mỗi bộ dữ liệu được tổ chức theo cấu trúc dữ liệu, cách xây dựng nguồn văn bản sử dụng trong thực nghiệm đối với bộ dữ liệu BTXRD và cách sàng lọc dữ liệu đối với bộ dữ liệu CTCH. Các thống kê được tính trực tiếp từ phiên bản dữ liệu mà mã nguồn hiện tại sử dụng.

A.1 Bộ dữ liệu BTXRD

Phần này trình bày cấu trúc dữ liệu, đặc điểm kỹ thuật của ảnh và phương pháp xây dựng văn bản dạng lâm sàng tổng hợp cho BTXRD. Ảnh và siêu dữ liệu thuộc phiên bản BTXRD được sử dụng trong nghiên cứu riêng văn bản tổng hợp được sinh ngoại tuyến và cố định trước khi huấn luyện. Nội dung này tập trung vào cách sinh nguồn dữ liệu giả lâm sàng.

A.1.1 Cấu trúc lưu trữ và đặc điểm kỹ thuật

Bảng A.1 mô tả các thành phần liên quan đến phạm vi phân loại của nghiên cứu. Định danh ảnh là khóa liên kết một-một giữa siêu dữ liệu, nhãn, tập chia, ảnh và văn bản tổng hợp.

Thành phần	Số tệp	Vai trò
images/	3,746	Lưu ảnh X-quang đầu vào.
Annotations/	1,867	Lưu chú thích JSON cho các ảnh có u; không được sử dụng trong huấn luyện phân loại.
reports/	3,746	Mỗi ảnh có một văn bản dạng lâm sàng được sinh ngoại tuyến từ siêu dữ liệu.
dataset.csv	3,746	Siêu dữ liệu gốc, gồm định danh ảnh, nguồn thu thập, tuổi, giới tính, vị trí giải phẫu, tư thế chụp và các cờ nhóm bệnh.
btxrd-labels.csv	3,746	Chứa định danh ảnh và 10 cột chỉ báo lớp.
btxrd-split.csv	3,746	Ánh xạ mỗi ảnh vào <code>train</code> , <code>validate</code> hoặc <code>test</code> .

Bảng A.1: Cấu trúc lưu trữ của bộ dữ liệu BTXRD trong nghiên cứu

Bảng A.2 cho thấy dữ liệu ảnh có định dạng không hoàn toàn đồng nhất. Mặc dù tất cả tên tệp đều mang định dạng JPEG, kiểm tra nội dung tệp xác định 3,744 ảnh được mã hóa JPEG, một ảnh được mã hóa BMP và một ảnh được nhận diện là MPO; toàn bộ 3,746 ảnh vẫn giải mã thành công. Khi nạp dữ liệu, mỗi ảnh được chuyển sang RGB trước khi tạo tensor, do đó ảnh thang xám và ảnh ba kênh đều tạo đầu vào ba kênh cho mô hình.

Thuộc tính	Kết quả kiểm tra
Phần mở rộng	3,719 tệp .jpeg và 27 tệp .jpg.
Chế độ màu khi giải mã	2,895 ảnh thang xám L và 851 ảnh RGB.
Định dạng mã hóa	3,744 JPEG, 1 BMP và 1 MPO.
Chiều rộng	Nhỏ nhất 153 px, trung vị 1,612 px, lớn nhất 3,594 px.
Chiều cao	Nhỏ nhất 311 px, trung vị 2,256 px, lớn nhất 4,881 px.
Khả năng giải mã	3,746/3,746 tệp được đọc thành công.

Bảng A.2: Đặc điểm kỹ thuật của các tệp ảnh BTXRD

A.1.2 Phương pháp tạo dữ liệu giả lâm sàng

BTXRD không cung cấp bệnh sử tự do tương ứng với từng ảnh. Để mô phỏng đầu vào văn bản của một hệ thống đa phương thức, nghiên cứu xây dựng một văn bản dạng lâm sàng cho mỗi mẫu bằng quy trình dựa trên luật và ngân hàng mẫu câu. Mục tiêu của quy trình là tạo một cấu trúc đầu vào thống nhất, không phải khôi phục bệnh sử thật của người bệnh.

Thông tin đầu vào và luật điều kiện

Các trường được lấy trực tiếp từ siêu dữ liệu gồm tuổi, giới tính, vị trí xương, vị trí khớp, vùng giải phẫu và tư thế chụp. Vị trí chính được chọn theo thứ tự ưu tiên xương, khớp, vùng giải phẫu nếu không có trường vị trí cụ thể, một mô tả tổng quát về xương sẽ được sử dụng. Tuổi được chia thành bốn nhóm gồm dưới 20 tuổi, 20-34 tuổi, 35-49 tuổi và từ 50 tuổi trở lên để lựa chọn ngữ cảnh tiền sử phù hợp.

Ngân hàng mẫu câu được chia thành ba nhóm hành vi. Mẫu không có cờ u được gán nhóm "không u" còn mẫu có cờ u và cờ ác tính được gán nhóm "ác tính" và các mẫu có u còn lại được gán nhóm "lành tính". Theo luật này, dữ liệu gồm 1.879 mẫu không u, 1.525 mẫu có u nhưng không mang cờ ác tính và 342 mẫu ác tính. Nhóm này quyết định tập mẫu câu dùng cho lý do vào viện, diễn tiến bệnh và khám thực thể. Ngoài ra, 182 mẫu có nhiều hơn một xương được đánh dấu và 61 mẫu có khớp liên quan thì được nối thêm một câu mô tả bối cảnh nhiều vị trí hoặc hạn chế vận động quanh khớp.

Ghép văn bản và cố định dữ liệu

Các lựa chọn ngẫu nhiên sử dụng phân phối đều trên từng ngân hàng câu và hạt giống 42. Ngân hàng mẫu câu ban đầu được sinh từ tên bệnh bằng ChatGPT-4o [31], tham chiếu cấu trúc các trường bệnh sử của CTCH để mô phỏng cách trình bày. Danh sách khoảng thời gian có 10 lựa chọn; số mẫu câu lý do vào viện của ba nhóm không u/lành tính/ác tính lần lượt là 6/7/6, số mẫu diễn tiến bệnh là 6/8/8 và số mẫu khám thực thể là 4/7/7. Ngân hàng tiền sử chung có 9 câu, mỗi nhóm tuổi có 3 câu ngữ cảnh, còn hai ngân hàng bổ sung nhiều xương và quanh khớp đều có 5 câu. Sau bước biên soạn ngân hàng, quy trình chọn và ghép văn bản không gọi mô hình ngôn ngữ và không có bước xác nhận nội dung bởi bác sĩ.

Với thứ tự hàng siêu dữ liệu được giữ cố định, mỗi lần chạy quy trình tạo ra cùng một lựa chọn mẫu câu. Văn bản được ghép theo thứ tự: thông tin người bệnh, lý do vào viện, diễn tiến bệnh, khám thực thể, tiền sử bản thân và thông tin thu nhận ảnh.

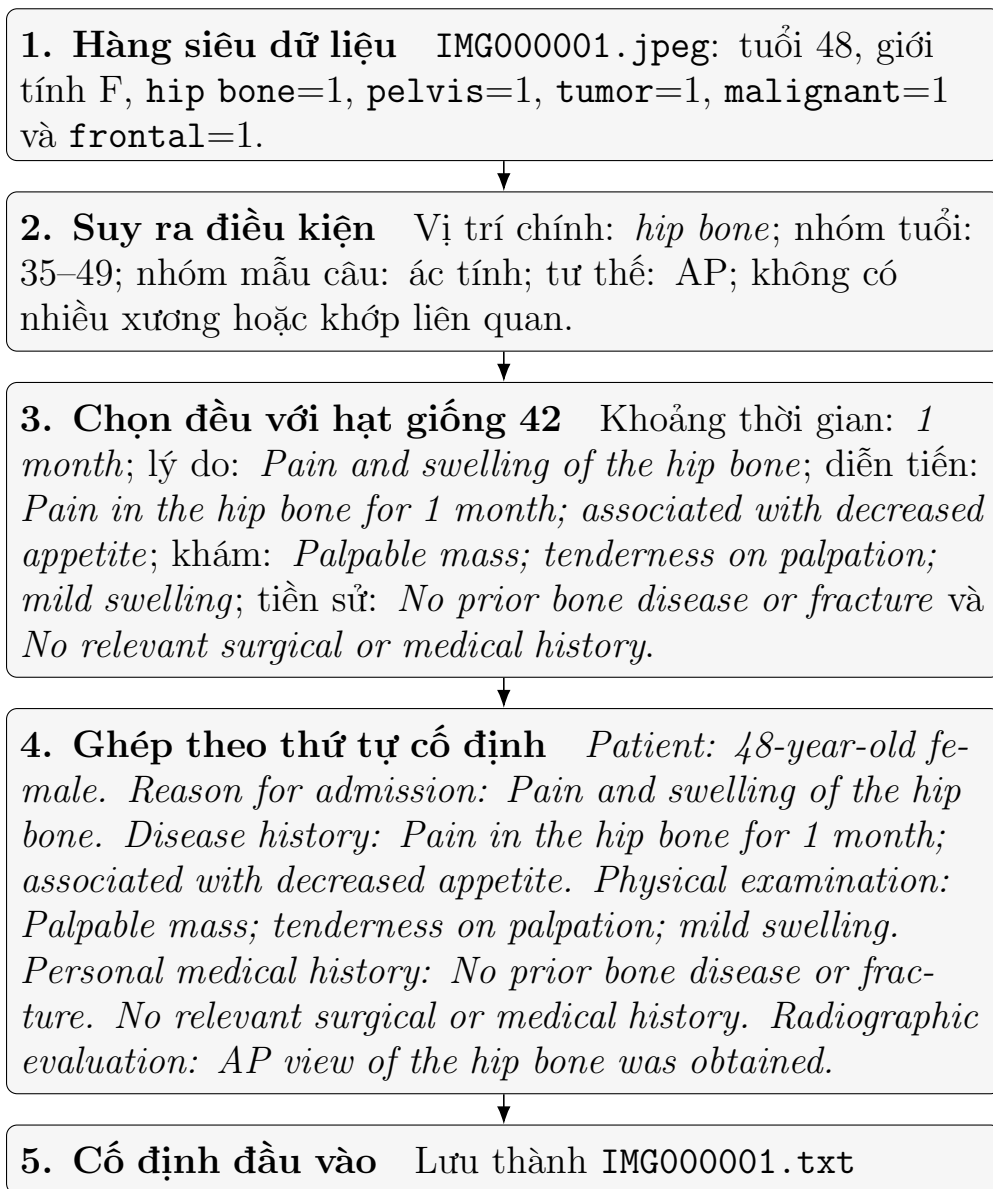
Bảng A.3 liệt kê các mẫu câu đại diện cho từng ngân hàng. Các mẫu được giữ nguyên bằng tiếng Anh vì đây là ngôn ngữ của đầu vào văn bản BTXRD trong thí nghiệm với các ký hiệu "location", "duration" và "joint" lần lượt được thay bằng vị trí chính, khoảng thời gian được chọn và khớp liên quan

Ngân hàng	Mẫu câu đại diện
Khoảng thời gian	<i>2 weeks; 1 month; 3 months; 6 months; several weeks; a few months; 2 months; 4 weeks; several months; 1 year.</i>
Lý do vào viện	Không u: <i>Pain in the {location}.</i> Lành tính: <i>Swelling of the {location}.</i> Ác tính: <i>Persistent pain in the {location}.</i>
Diễn tiến bệnh	Không u: <i>Onset {duration} ago; mild symptoms.</i> Lành tính: <i>The patient noticed swelling in the {location} {duration} ago.</i> Ác tính: <i>Pain and swelling in the {location} for {duration}; progressively worsening.</i>
Khám thực thể	Không u: <i>No tenderness or swelling on palpation.</i> Lành tính: <i>Palpable firm mass; non-tender; no skin changes.</i> Ác tính: <i>Firm, tender mass on the {location}; local warmth noted.</i>
Bổ sung nhiều xương	<i>Multiple bony prominences palpated at several sites; Multiple hard masses involving several bones on examination.</i>
Bổ sung quanh khớp	<i>Joint involvement noted; restricted range of motion at the {joint}; Soft tissue swelling observed around the {joint}.</i>
Tiền sử chung	<i>No significant medical history; No prior bone disease or fracture; No relevant prior medical or surgical history.</i>
Ngữ cảnh theo tuổi	Dưới 20 tuổi: <i>Growth and development appropriate for age.</i> Từ 20–34 tuổi: <i>No prior bone lesions.</i> Từ 35–49 tuổi: <i>No relevant surgical or medical history.</i> Từ 50 tuổi trở lên: <i>History of age-related degenerative changes; no prior bone lesions.</i>

Bảng A.3: Các mẫu câu đại diện trong ngân hàng văn bản giả lâm sàng BTXRD

Quy trình không chèn trực tiếp tên của 10 lớp đích vào văn bản. Tuy nhiên, cờ có u và cờ ác tính tham gia trực tiếp vào việc chọn ngân hàng mẫu câu; vì vậy, nội dung tổng hợp vẫn mang tín hiệu liên hệ mạnh với nhân. Các triệu chứng, thời gian mắc bệnh, dấu hiệu khám và tiền sử được chọn từ mẫu câu là dữ liệu giả lập, không phải lời khai của người bệnh hoặc ghi nhận của nhân viên y tế. Do đó, kết quả liên quan đến văn bản BTXRD chỉ phản ánh thiết lập giả lâm sàng có điều kiện này và không được diễn giải tương đương với bệnh sử tự nhiên của CTCH.

Hình A.1 minh họa toàn bộ quá trình đối với mẫu IMG000001.jpeg. Do đây là hàng đầu tiên của siêu dữ liệu, trạng thái bộ sinh giả ngẫu nhiên bắt đầu trực tiếp từ hạt giống 42.



Hình A.1: Quá trình tạo văn bản minh họa cho mẫu IMG000001.jpeg

A.2 Bộ dữ liệu CTCH

Phụ lục này mô tả quy trình chuẩn bị CTCH nhằm hỗ trợ tái lập và đánh giá tính hợp lệ của dữ liệu. Tên tệp, cấu trúc thư mục và định danh nội bộ của mã nguồn được lược bỏ vì không đóng góp trực tiếp cho việc hiểu thiết kế thực nghiệm; thay vào đó, nội dung tập trung vào tiêu chí lựa chọn mẫu, cách hình thành nhãn, nguyên tắc chia tập, nguồn gốc văn bản và các phép kiểm tra toàn vẹn.

A.2.1 Cấu trúc dữ liệu và đặc điểm kỹ thuật

Bảng A.4 mô tả các thành phần liên quan đến phạm vi phân loại của nghiên cứu. Định danh ảnh là khóa liên kết một-một giữa siêu dữ liệu, nhãn, tập chia, ảnh và văn bản tổng hợp.

Thành phần	Số lượng	Vai trò
images/	3,293	Lưu ảnh X-quang đầu vào.
reports/	3,293	Mỗi ảnh có một bệnh sử lâm sàng tương ứng của bệnh nhân.
ctch-labels.csv	3,249	Chứa định danh ảnh và 22 cột chỉ báo lớp.
ctch-ood.csv	44	Chứa định danh và thông tin các mẫu ngoài phân phối.
ctch-split.csv	3,249	Ảnh xạ mỗi ảnh vào <code>train</code> , <code>validate</code> hoặc <code>test</code> .

Bảng A.4: Cấu trúc lưu trữ của bộ dữ liệu CTCH trong nghiên cứu

Bảng A.5 cho thấy dữ liệu ảnh có định dạng đồng nhất. Toàn bộ 3,293 tệp lưu trữ đều có phần mở rộng JPEG và được mã hóa chuẩn JPEG với toàn bộ 3,293 ảnh giải mã thành công. Khi nạp dữ liệu, mỗi ảnh được chuyển sang RGB trước khi tạo tensor, bảo đảm đầu vào ba kênh cho mô hình.

Thuộc tính	Kết quả kiểm tra
Phần mở rộng	3,293 tệp .jpg.
Chế độ màu khi giải mã	3,293 ảnh RGB.
Định dạng mã hóa	3,293 JPEG.
Chiều rộng	Nhỏ nhất 1,186 px, trung vị 1,213 px, lớn nhất 2,836 px.
Chiều cao	Nhỏ nhất 1,213 px, trung vị 1,713 px, lớn nhất 2,880 px.
Khả năng giải mã	3,293/3,293 tệp được đọc thành công.

Bảng A.5: Đặc điểm kỹ thuật của các tệp ảnh CTCH

Dữ liệu nguồn gồm 3,641 hồ sơ đã được lựa chọn sơ bộ từ các ca khám tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh. Mỗi hồ sơ liên kết thông tin bệnh án với một ảnh đại diện cho vị trí cần khảo sát. Quá trình sàng lọc tiếp tục loại những ca có nếp, dính hoặc phương tiện kết hợp xương vì các cấu trúc này có thể che khuất tổn thương và tạo dấu hiệu thị giác ngoài mục tiêu phân loại.

Hiện tại 348 hồ sơ có dụng cụ y tế bị loại nhằm đảm bảo phạm vi nghiên cứu, đồng thời giúp đảm bảo chất lượng dữ liệu đầu vào là đồng nhất. Phần còn lại gồm 3,293 mẫu, được tách thành 3,249 mẫu trong phân phối phục vụ phân loại và 44 mẫu ngoài phân phối về ngữ nghĩa. Hai quần thể không giao nhau theo ảnh hoặc theo mã nhóm người bệnh.

Giai đoạn	Số hồ sơ
Hồ sơ nguồn	3,641
Loại do có dụng cụ y tế	348
Còn lại sau sàng lọc	3,293
Quần thể trong phân phối	3,249
Quần thể ngoài phân phối	44

Bảng A.6: Dòng dữ liệu qua các bước sàng lọc CTCH

Quần thể ngoài phân phối gồm 34 mẫu thuộc nhóm chấn thương và 10 mẫu thuộc nhóm viêm nhiễm, nhưng biểu hiện cụ thể không thuộc 22 lớp đích. Cách tổ chức này tạo một kịch bản ngoài dữ liệu trong cùng nguồn bệnh viện, qua đó giảm mức trộn lẫn giữa sai lệch ngữ nghĩa với thay đổi thiết bị hoặc cơ sở thu nhận. Tuy nhiên, số lượng 44 mẫu còn nhỏ nên khoảng bất định của các độ đo ngoài phân phối cần được trình bày và kết quả không nên được khái quát thành mọi dạng bất thường lâm sàng.

Sàng lọc và xác định quần thể nghiên cứu

Quần thể đích của bộ dữ liệu CTCH gồm các bệnh nhân được chụp X-quang xương khớp nhằm hỗ trợ chẩn đoán bệnh lý hoặc chấn thương xương. Quần thể tiếp cận bao gồm các bệnh nhân có bệnh án và dữ liệu hình ảnh được thu thập tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.

Dữ liệu ban đầu gồm 12.949 bệnh án. Tuy nhiên, các hồ sơ này chưa thể được sử dụng trực tiếp vì có sự khác biệt về loại dữ liệu cận lâm sàng, thời điểm thăm khám, tình trạng điều trị và mức độ phù hợp của nhãn. Quy trình sàng lọc được thực hiện tuần tự nhằm hình thành quần thể có ảnh X-quang, bệnh sử và nhãn phù hợp với phạm vi phân loại của nghiên cứu. Số lượng hồ sơ còn lại sau từng bước được trình bày trong Bảng A.7.

Giai đoạn sàng lọc	Số hồ sơ còn lại
Dữ liệu bệnh án ban đầu	12,949
Sau khi lọc nội dung cận lâm sàng không phù hợp	9,142
Sau khi loại các trường hợp đã mổ	7,900
Sau khi loại các ca tái khám	7,070
Sau khi chỉ giữ lần khám đầu tiên	6,575
Sau khi hoàn tất chuẩn hóa nhãn và lập tập ứng viên	4,132
Sau khi loại các hồ sơ không đáp ứng yêu cầu	3,641
Sau khi loại các hồ sơ có dụng cụ y tế	3,293

Bảng A.7: Số lượng hồ sơ còn lại qua các bước sàng lọc bộ dữ liệu CTCH

Trước hết, các bệnh án có nội dung cận lâm sàng không phù hợp với phạm vi nghiên cứu được loại bỏ, làm số lượng hồ sơ giảm từ 12.949 xuống còn 9.142. Các trường hợp đã trải qua phẫu thuật tiếp tục được loại nhằm hạn chế ảnh hưởng của quá trình điều trị lên biểu hiện hình ảnh và thông tin lâm sàng, còn lại 7.900 hồ sơ.

Đối với các bệnh nhân có nhiều lần thăm khám, các ca được xác định là tái khám được loại trước, làm số lượng giảm xuống 7.070. Sau đó, với những bệnh nhân vẫn còn nhiều lần khám hợp lệ, nghiên cứu chỉ giữ lần khám đầu tiên để giảm sự phụ thuộc giữa các mẫu và hạn chế việc cùng một bệnh nhân xuất hiện nhiều lần trong dữ liệu. Sau bước này, quần thể còn 6.575 hồ sơ.

Các trường chẩn đoán được chuẩn hóa và ánh xạ vào không gian nhãn của bài toán. Những hồ sơ không đáp ứng yêu cầu về nhãn hoặc không thuộc tập ứng viên được loại bỏ, tạo thành tập gồm 4.132 hồ sơ. Tiếp theo, 491 hồ sơ có cờ **Deleted** bị loại, còn lại 3.641 hồ sơ đã được lựa chọn sơ bộ.

Bước sàng lọc cuối cùng loại 348 hồ sơ có nẹp, đinh hoặc các dụng cụ y tế khác. Những cấu trúc này có thể che khuất tổn thương, làm thay đổi đặc điểm thị giác của ảnh và tạo ra dấu hiệu không thuộc mục tiêu phân loại. Quần thể cuối cùng do đó gồm 3.293 mẫu, tương ứng khoảng 25,4% số bệnh án ban đầu.

Trong số 3.293 mẫu được giữ lại, 3.249 mẫu thuộc 22 lớp đích và được sử dụng làm quần thể trong phân phối cho tác vụ phân loại. Bốn mươi bốn mẫu còn lại có biểu hiện không thuộc không gian nhãn đích và được

tách thành quần thể ngoài phân phối về ngữ nghĩa. Hai quần thể không giao nhau theo ảnh hoặc theo mã nhóm người bệnh.

Phụ lục B

Kết quả chi tiết theo từng hạt giống

B.1 Phạm vi trình bày

Phụ lục này công bố các kết quả riêng của ba hạt giống ngẫu nhiên 42, 123 và 456 nhằm hỗ trợ cho các giá trị trung bình và độ lệch chuẩn được trình bày trong Chương 4. Sự thay đổi giữa các hạt giống được sử dụng chủ yếu để đánh giá độ nhạy của quy trình huấn luyện và hỗ trợ việc diễn giải khoảng tin cậy, thay vì khẳng định phân phối hiệu năng của mô hình.

Các kết quả gồm phân loại khi sử dụng toàn bộ dữ liệu, phân loại trong trường hợp mẫu học hạn chế, nghiên cứu loại bỏ từng thành phần và đánh giá dữ liệu ngoài phân phối bằng hậu xử lý. Đây là các nội dung trong Chương 4 có đủ kết quả cho cả ba hạt giống và có thể đối chiếu trực tiếp với các bảng tổng hợp. Kết quả không mẫu, phép đo hiệu quả suy luận và hai trường hợp minh họa bằng phương pháp tích phân gradient không được lặp lại dưới dạng bảng ba hạt giống vì các nội dung này hiện chỉ được thực hiện một lần hoặc được dùng như minh họa định tính.

B.2 Phân loại khi sử dụng toàn bộ dữ liệu huấn luyện

Bảng B.1 và Bảng B.2 trình bày năm độ đo phân loại của từng mô hình tại từng hạt giống. Việc giữ đồng thời Accuracy, Balanced Accuracy, Macro-F1, Macro-AUROC và Macro-AUPRC cho phép kiểm tra liệu thứ hạng trung bình trong Chương 4 có xuất hiện nhất quán hay phụ thuộc vào một lần khởi tạo cụ thể.


Bảng B.1: Kết quả khi sử dụng toàn bộ dữ liệu huấn luyện của từng hạt giống trên BTXRD; hàng XBone-Net được tô xám để dễ đối chiếu.

Mô hình	Hạt giống	Accuracy	BAcc	Macro-F1	Macro-AUROC	Macro-AUPRC
BioMedCLIP	42	0,8320	0,5769	0,5870	0,8679	0,6395
BioMedCLIP	123	0,8280	0,6197	0,5993	0,8918	0,6542
BioMedCLIP	456	0,8333	0,6219	0,6118	0,8996	0,6595
CLIP	42	0,8200	0,5949	0,5722	0,9114	0,6342
CLIP	123	0,7720	0,5802	0,5574	0,8706	0,6192
CLIP	456	0,8187	0,6121	0,6064	0,9099	0,6219
DenseNet-121	42	0,6320	0,3644	0,3688	0,7916	0,3852
DenseNet-121	123	0,6333	0,3862	0,3904	0,7596	0,3790
DenseNet-121	456	0,6307	0,3575	0,3562	0,7639	0,3851
MedCLIP	42	0,8307	0,5860	0,5931	0,8221	0,6089
MedCLIP	123	0,8040	0,6204	0,6014	0,8736	0,6074
MedCLIP	456	0,8267	0,6310	0,6217	0,8838	0,6520
PubMedCLIP	42	0,7573	0,5716	0,5067	0,8856	0,5874
PubMedCLIP	123	0,7947	0,6163	0,5946	0,8970	0,6233
PubMedCLIP	456	0,8133	0,6388	0,6155	0,9317	0,6341
ResNet-50	42	0,6067	0,3031	0,3174	0,6947	0,3279
ResNet-50	123	0,6213	0,3253	0,3364	0,7447	0,3401
ResNet-50	456	0,5933	0,3278	0,3333	0,7313	0,3333
LoRA-BiomedCLIP	42	0,8173	0,6402	0,6226	0,8859	0,6545
LoRA-BiomedCLIP	123	0,8107	0,6421	0,6136	0,8984	0,6127
LoRA-BiomedCLIP	456	0,8120	0,6834	0,6312	0,9463	0,6357
LoRA-PubMedCLIP	42	0,8280	0,6227	0,6177	0,8975	0,6337
LoRA-PubMedCLIP	123	0,8373	0,6594	0,6569	0,9100	0,6979
LoRA-PubMedCLIP	456	0,8387	0,6287	0,6237	0,9043	0,6460
XBone-Net	42	0,8227	0,6029	0,6037	0,9391	0,6520
XBone-Net	123	0,8253	0,5797	0,5972	0,8899	0,6099
XBone-Net	456	0,8293	0,5922	0,6023	0,9438	0,6285

Bảng B.2: Kết quả khi sử dụng toàn bộ dữ liệu huấn luyện của từng hạt giống trên CTCH; hàng XBone-Net được tô xám để dễ đối chiếu.

Mô hình	Hạt giống	Accuracy	BAcc	Macro-F1	Macro-AUROC	Macro-AUPRC
BioMedCLIP	42	0,5904	0,6203	0,5520	0,9559	0,6248
BioMedCLIP	123	0,5755	0,6107	0,5472	0,9555	0,6188
BioMedCLIP	456	0,6248	0,5758	0,5628	0,9057	0,6071
CLIP	42	0,5725	0,6579	0,5727	0,9547	0,6270
CLIP	123	0,5785	0,6209	0,5547	0,9478	0,6196
CLIP	456	0,6114	0,5862	0,5624	0,8845	0,5542
DenseNet-121	42	0,4813	0,5348	0,4610	0,9404	0,4917
DenseNet-121	123	0,4873	0,4435	0,4134	0,9323	0,4667
DenseNet-121	456	0,4768	0,4999	0,4356	0,9325	0,4703
MedCLIP	42	0,5590	0,5811	0,5265	0,9354	0,5973
MedCLIP	123	0,5979	0,5503	0,5285	0,8835	0,5628
MedCLIP	456	0,5202	0,5838	0,4902	0,9456	0,5916
PubMedCLIP	42	0,5306	0,6108	0,5313	0,9350	0,6073
PubMedCLIP	123	0,5486	0,4912	0,4902	0,9038	0,5683
PubMedCLIP	456	0,5770	0,5747	0,5395	0,9448	0,5907
ResNet-50	42	0,4918	0,4238	0,4131	0,9130	0,4489
ResNet-50	123	0,4948	0,4027	0,4029	0,9118	0,4452
ResNet-50	456	0,4918	0,4114	0,4076	0,9188	0,4536
LoRA-BiomedCLIP	42	0,6203	0,6113	0,5762	0,9095	0,5829
LoRA-BiomedCLIP	123	0,5830	0,6324	0,5685	0,9516	0,6235
LoRA-BiomedCLIP	456	0,5845	0,5839	0,5349	0,9389	0,6071
LoRA-PubMedCLIP	42	0,5665	0,5718	0,5314	0,9600	0,6031
LoRA-PubMedCLIP	123	0,6114	0,5769	0,5631	0,9253	0,6167
LoRA-PubMedCLIP	456	0,6248	0,5610	0,5671	0,9246	0,6062
XBone-Net	42	0,5590	0,5995	0,5485	0,9601	0,6260
XBone-Net	123	0,6054	0,5334	0,5629	0,9190	0,6022
XBone-Net	456	0,5531	0,6203	0,5559	0,9628	0,6284

Hình B.1 tập trung vào XBone-Net và hai mô hình cơ sở PEFT gần nhất để minh họa biến thiên Macro-F1 mà không lặp lại toàn bộ thông tin trong hai bảng. Trên BTXRD, đường của XBone-Net thay đổi ít hơn hai mô hình cơ sở nhưng nằm ở mức thấp hơn; trên CTCH, ba đường giao nhau giữa các hạt giống, phù hợp với nhận định rằng chênh lệch Macro-F1 giữa các mô hình ngôn ngữ trực quan chưa ổn định trong phạm vi ba lần huấn luyện.



Hình B.1: Macro-F1 khi sử dụng toàn bộ dữ liệu của XBone-Net và hai mô hình cơ sở PEFT tại từng hạt giống trên BTXRD và CTCH

Hình 4.2 trình bày trung bình chênh lệch Macro-F1 giữa XBone-Net và từng mô hình đối sánh tại cùng hạt giống; khoảng tin cậy được tính theo phân phối t hai phía với hai bậc tự do. Trên BTXRD, khoảng ước lượng khi so với LoRA-BioMedCLIP nằm dưới mốc 0, còn khoảng khi so với các mô hình chỉ dùng ảnh nằm trên mốc 0. Trên CTCH, các khoảng khi so với hai mô hình chỉ dùng ảnh nằm trên mốc 0, trong khi các khoảng của nhóm mô hình ngôn ngữ trực quan và nhóm tinh chỉnh hiệu quả tham số cắt mốc 0. Vì chỉ có ba cặp hạt giống, các khoảng này chủ yếu mô tả độ biến thiên giữa các lần huấn luyện hiện có.

B.3 Phân loại trong trường hợp mẫu học hạn chế

Bảng B.3 và Bảng B.4 báo cáo kết quả tại từng hạt giống cho các mức ngân sách tối đa 1, 10 và 20 mẫu trên mỗi lớp. Khi số mẫu huấn luyện của một lớp thấp hơn ngân sách, toàn bộ mẫu hiện có được giữ lại và không lấy lặp; vì vậy mức 20 mẫu của CTCH sử dụng 19 mẫu cho lớp gãy xương thuyền và 16 mẫu cho lớp gãy xương vùng chậu. Các giá trị này bổ sung cho biểu đồ trung bình trong Chương 4, đồng thời cho phép nhận diện trường hợp chênh lệch trung bình nhỏ hơn mức dao động giữa các lần huấn luyện.

Bảng B.3: Kết quả mẫu học hạn chế của từng hạt giống trên BTXRD; hàng XBone-Net được tô xám để dễ đối chiếu.

Thiết lập	Mô hình	Hạt giống	Accuracy	BAcc	Macro-F1	Macro-AUROC	Macro-AUPRC
1 mẫu	LoRA-BiomedCLIP	42	0,2880	0,1666	0,1413	0,6239	0,1747
1 mẫu	LoRA-BiomedCLIP	123	0,3280	0,2601	0,2098	0,6756	0,2430
1 mẫu	LoRA-BiomedCLIP	456	0,2187	0,2130	0,1587	0,5960	0,2077
1 mẫu	LoRA-PubMedCLIP	42	0,5027	0,2905	0,2506	0,6672	0,2610
1 mẫu	LoRA-PubMedCLIP	123	0,2840	0,2566	0,1643	0,6649	0,2799
1 mẫu	LoRA-PubMedCLIP	456	0,1627	0,2050	0,1304	0,6213	0,2095
1 mẫu	XBone-Net	42	0,2053	0,1547	0,1345	0,5958	0,1608
1 mẫu	XBone-Net	123	0,2720	0,2499	0,1859	0,6450	0,2347
1 mẫu	XBone-Net	456	0,2667	0,2302	0,1655	0,6413	0,2150
10 mẫu	LoRA-BiomedCLIP	42	0,6373	0,4487	0,4074	0,8503	0,4289
10 mẫu	LoRA-BiomedCLIP	123	0,7133	0,4759	0,4308	0,8764	0,4634
10 mẫu	LoRA-BiomedCLIP	456	0,6800	0,4766	0,4251	0,8528	0,4480
10 mẫu	LoRA-PubMedCLIP	42	0,6160	0,4535	0,4010	0,8366	0,4533
10 mẫu	LoRA-PubMedCLIP	123	0,7333	0,4460	0,4159	0,8738	0,4814
10 mẫu	LoRA-PubMedCLIP	456	0,6427	0,4328	0,4324	0,8483	0,4471
10 mẫu	XBone-Net	42	0,6547	0,4894	0,4255	0,8599	0,4463
10 mẫu	XBone-Net	123	0,7067	0,4429	0,4066	0,8520	0,4276
10 mẫu	XBone-Net	456	0,7053	0,4989	0,4585	0,8612	0,4918
20 mẫu	LoRA-BiomedCLIP	42	0,7347	0,5774	0,4866	0,9268	0,5491
20 mẫu	LoRA-BiomedCLIP	123	0,7360	0,5353	0,4838	0,9365	0,5383
20 mẫu	LoRA-BiomedCLIP	456	0,7227	0,5350	0,4925	0,9181	0,5388
20 mẫu	LoRA-PubMedCLIP	42	0,7293	0,5608	0,5062	0,9119	0,5608
20 mẫu	LoRA-PubMedCLIP	123	0,7320	0,5837	0,5073	0,9357	0,5592
20 mẫu	LoRA-PubMedCLIP	456	0,7493	0,5911	0,5261	0,9139	0,5484
20 mẫu	XBone-Net	42	0,7347	0,5794	0,5076	0,8991	0,5410
20 mẫu	XBone-Net	123	0,7360	0,5806	0,4987	0,9192	0,5403
20 mẫu	XBone-Net	456	0,7640	0,6246	0,5545	0,9307	0,6091

Bảng B.4: Kết quả mẫu học hạn chế của từng hạt giống trên CTCH; hàng XBone-Net được tô xám để dễ đối chiếu.

Thiết lập	Mô hình	Hạt giống	Accuracy	BAcc	Macro-F1	Macro-AUROC	Macro-AUPRC
1 mẫu	LoRA-BiomedCLIP	42	0,2093	0,2674	0,2110	0,8286	0,2244
1 mẫu	LoRA-BiomedCLIP	123	0,2257	0,3002	0,2067	0,8411	0,2328
1 mẫu	LoRA-BiomedCLIP	456	0,2033	0,2814	0,2044	0,7997	0,2500

Còn tiếp ở trang sau

Bảng B.4 (tiếp theo)

Thiết lập	Mô hình	Hạt giống	Accuracy	BAcc	Macro-F1	Macro-AUROC	Macro-AUPRC
1 mẫu	LoRA-PubMedCLIP	42	0,1480	0,2108	0,1435	0,7689	0,1781
1 mẫu	LoRA-PubMedCLIP	123	0,2451	0,3605	0,2303	0,8032	0,2294
1 mẫu	LoRA-PubMedCLIP	456	0,1794	0,2839	0,1890	0,7991	0,2044
1 mẫu	XBone-Net	42	0,2272	0,2825	0,2075	0,8662	0,2781
1 mẫu	XBone-Net	123	0,2541	0,4090	0,2467	0,8718	0,3041
1 mẫu	XBone-Net	456	0,2212	0,3137	0,2165	0,8556	0,2823
10 mẫu	LoRA-BiomedCLIP	42	0,4141	0,5817	0,4384	0,9399	0,4741
10 mẫu	LoRA-BiomedCLIP	123	0,3662	0,5270	0,4101	0,9272	0,4345
10 mẫu	LoRA-BiomedCLIP	456	0,4305	0,5588	0,4389	0,9387	0,4855
10 mẫu	LoRA-PubMedCLIP	42	0,3871	0,5763	0,4281	0,9452	0,4784
10 mẫu	LoRA-PubMedCLIP	123	0,3632	0,5491	0,4055	0,9323	0,4732
10 mẫu	LoRA-PubMedCLIP	456	0,3931	0,5633	0,4220	0,9404	0,4837
10 mẫu	XBone-Net	42	0,4111	0,5928	0,4528	0,9414	0,4627
10 mẫu	XBone-Net	123	0,3348	0,5122	0,3917	0,9245	0,4274
10 mẫu	XBone-Net	456	0,4320	0,5721	0,4542	0,9445	0,4720
20 mẫu	LoRA-BiomedCLIP	42	0,4694	0,6409	0,5033	0,9527	0,5364
20 mẫu	LoRA-BiomedCLIP	123	0,4170	0,5883	0,4597	0,9255	0,4756
20 mẫu	LoRA-BiomedCLIP	456	0,4320	0,6117	0,4777	0,9466	0,5142
20 mẫu	LoRA-PubMedCLIP	42	0,4694	0,6076	0,4899	0,9495	0,5319
20 mẫu	LoRA-PubMedCLIP	123	0,4305	0,5932	0,4430	0,9493	0,5050
20 mẫu	LoRA-PubMedCLIP	456	0,4529	0,5626	0,4618	0,9513	0,5420
20 mẫu	XBone-Net	42	0,4559	0,5725	0,4756	0,9374	0,5223
20 mẫu	XBone-Net	123	0,4200	0,6052	0,4659	0,9494	0,5067
20 mẫu	XBone-Net	456	0,4320	0,5789	0,4637	0,9503	0,5362

B.4 Nghiên cứu loại bỏ từng thành phần

Bảng B.5 trình bày kết quả của XBone-Net và năm biến thể loại bỏ từng thành phần tại từng hạt giống trên CTCH. Một biến thể có giá trị trung bình cao hơn nhưng thay đổi dấu chênh lệch giữa các hạt giống không được xem là bằng chứng về ưu thế ổn định.


Bảng B.5: Kết quả của từng hạt giống trong nghiên cứu loại bỏ từng thành phần trên CTCH; cấu hình đầy đủ được tô xám.

Cấu hình	Hạt giống	Accuracy	BAcc	Macro-F1	Macro-AUROC	Macro-AUPRC	ECE
XBone-Net	42	0,5590	0,5995	0,5485	0,9601	0,6260	0,0857
XBone-Net	123	0,6054	0,5334	0,5629	0,9190	0,6022	0,0856
XBone-Net	456	0,5531	0,6203	0,5559	0,9628	0,6284	0,1382
Không dùng ảnh độ phân giải cao	42	0,6293	0,5454	0,5512	0,8943	0,6022	0,1502
Không dùng ảnh độ phân giải cao	123	0,6039	0,5608	0,5704	0,9116	0,5907	0,2462
Không dùng ảnh độ phân giải cao	456	0,5889	0,5651	0,5442	0,9385	0,6041	0,1265
Gộp trung bình	42	0,5635	0,6339	0,5732	0,9613	0,6065	0,2042
Gộp trung bình	123	0,5904	0,5520	0,5487	0,9484	0,6259	0,0918
Gộp trung bình	456	0,5830	0,6288	0,5989	0,9636	0,6612	0,1559
Chỉ pha 2	42	0,6263	0,5833	0,5950	0,9188	0,6388	0,1276
Chỉ pha 2	123	0,6218	0,5365	0,5615	0,9317	0,6341	0,1653
Chỉ pha 2	456	0,6039	0,5516	0,5696	0,8928	0,6073	0,2675
Nổi đặc trưng	42	0,5994	0,5439	0,5357	0,9520	0,6070	0,0629
Nổi đặc trưng	123	0,5949	0,5974	0,5576	0,9612	0,6124	0,0922
Nổi đặc trưng	456	0,5830	0,5590	0,5344	0,9567	0,5862	0,0815
Đầu tuyến tính	42	0,6203	0,5590	0,5741	0,8984	0,5919	0,1039
Đầu tuyến tính	123	0,6323	0,5513	0,5747	0,9075	0,5985	0,0873
Đầu tuyến tính	456	0,6263	0,6234	0,6179	0,9181	0,6325	0,0733


Các khoảng trong Hình B.2–B.6 được tính bằng 10.000 lần tái lấy mẫu bắt cặp; hai cận là phân vị 2,5% và 97,5% của phân bố chênh lệch. Trong mỗi lần, người bệnh được tái lấy mẫu theo cụm và phân tầng theo lớp, đồng thời ba hạt giống huấn luyện được tái lấy mẫu có hoàn lại. Cùng một mẫu tái lập được áp dụng cho cấu hình tham chiếu và biến thể. Thành phần biến thiên theo hạt giống chỉ dựa trên ba giá trị quan sát, vì vậy các khoảng được diễn giải theo hướng mô tả và thăm dò.

B.5 Kết quả đánh giá dữ liệu ngoài phân phối


Bảng B.6 công bố kết quả theo từng hạt giống cho bốn phương pháp chấm điểm OOD trên kịch bản OOD ngữ nghĩa và BTXRD. Số mẫu trong phân phối và ngoài phân phối được ghi trực tiếp trong bảng vì AUPR-Out và $FPR@95\%TPR$ chịu ảnh hưởng bởi số lượng và tỷ lệ mẫu của từng kịch




Hình B.2: Khoảng tin cậy 95% của chênh lệch Accuracy giữa từng biến thể loại bỏ thành phần và XBone-Net trên CTCH



Hình B.3: Khoảng tin cậy 95% của chênh lệch Balanced Accuracy giữa từng biến thể loại bỏ thành phần và XBone-Net trên CTCH



Hình B.4: Khoảng tin cậy 95% của chênh lệch Macro-F1 giữa từng biến thể loại bỏ thành phần và XBone-Net trên CTCH



Hình B.5: Khoảng tin cậy 95% của chênh lệch Macro-AUROC giữa từng biến thể loại bỏ thành phần và XBone-Net trên CTCH

bản.

Mỗi lần đánh giá sử dụng 669 mẫu CTCH trong phân phối. Kịch bản OOD ngữ nghĩa sử dụng đủ 44 mẫu trong danh sách đánh giá và kịch bản BTXRD sử dụng đủ 750 mẫu ngoài phân phối; không mẫu nào bị bỏ qua trong các tập kết quả được tổng hợp. Tuy nhiên, AUPR-Out và FPR@95%TPR vẫn chịu ảnh hưởng của chênh lệch quy mô và tỷ lệ mẫu trong-ngoài phân phối giữa hai kịch bản, vì vậy cần được đọc cùng AUROC-ODD và cỡ mẫu ghi trong bảng.

Bảng B.6: Kết quả OOD hậu xử lý của từng hạt giống; các hàng Mahalanobis theo tâm lớp được tô xám.


Kịch bản	Phương pháp	Hạt giống	N_{ID}	N_{OOD}	AUROC-ODD	AUPR-Out	FPR@95%TPR
OOD ngữ nghĩa	Cosine theo tâm lớp	42	669	44	0,5856	0,1040	0,8864
OOD ngữ nghĩa	Mahalanobis theo tâm lớp	42	669	44	0,6112	0,1134	0,8409
OOD ngữ nghĩa	kNN	42	669	44	0,6094	0,1212	0,8636
OOD ngữ nghĩa	Entropy	42	669	44	0,5969	0,1237	0,8409
OOD ngữ nghĩa	Cosine theo tâm lớp	123	669	44	0,6061	0,0941	0,8864
OOD ngữ nghĩa	Mahalanobis theo tâm lớp	123	669	44	0,6278	0,0953	0,9091
OOD ngữ nghĩa	kNN	123	669	44	0,6267	0,1014	0,8864
OOD ngữ nghĩa	Entropy	123	669	44	0,5595	0,0983	0,8864
OOD ngữ nghĩa	Cosine theo tâm lớp	456	669	44	0,6102	0,0916	0,8864
OOD ngữ nghĩa	Mahalanobis theo tâm lớp	456	669	44	0,6467	0,1014	0,9091
OOD ngữ nghĩa	kNN	456	669	44	0,6445	0,1023	0,8864
OOD ngữ nghĩa	Entropy	456	669	44	0,5550	0,0936	0,9091
BTXRD	Cosine theo tâm lớp	42	669	750	0,8052	0,7974	0,7307
BTXRD	Mahalanobis theo tâm lớp	42	669	750	0,8762	0,8591	0,6307
BTXRD	kNN	42	669	750	0,8544	0,8379	0,6573
BTXRD	Entropy	42	669	750	0,7325	0,7583	0,7453
BTXRD	Cosine theo tâm lớp	123	669	750	0,6379	0,6751	0,8160
BTXRD	Mahalanobis theo tâm lớp	123	669	750	0,6982	0,7377	0,7600
BTXRD	kNN	123	669	750	0,6654	0,6979	0,8067
BTXRD	Entropy	123	669	750	0,5931	0,6203	0,8680
BTXRD	Cosine theo tâm lớp	456	669	750	0,7471	0,7079	0,8400

Còn tiếp ở trang sau


Bảng B.6 (tiếp theo)

Kịch bản	Phương pháp	Hạt giống	N_{ID}	N_{OOD}	AUROC-OOD	AUPR-Out	FPR@95%TPR
BTXRD	Mahalanobis theo tâm lớp	456	669	750	0,8381	0,8058	0,7307
BTXRD	kNN	456	669	750	0,7977	0,7564	0,8373
BTXRD	Entropy	456	669	750	0,7498	0,7313	0,8640

Hình B.7 biểu diễn riêng phương pháp Mahalanobis theo tâm lớp vì đây là phương pháp được nhấn mạnh trong phần kết quả chính. Khoảng biến thiên lớn hơn trên BTXRD, đặc biệt ở AUROC-OOD, cho thấy kết quả liên bộ dữ liệu nhạy với trạng thái biểu diễn được học ở từng hạt giống. Kịch bản OOD ngẫu nhiên có AUROC-OOD ổn định hơn nhưng FPR@95%TPR vẫn cao ở cả ba lần chạy.



Hình B.7: Các độ đo OOD của phương pháp Mahalanobis theo tâm lớp tại từng hạt giống trên kịch bản OOD ngẫu nhiên và BTXRD



Hình B.6: Khoảng tin cậy 95% của chênh lệch Macro-AUPRC giữa từng biến thể loại bỏ thành phần và XBone-Net trên CTCH