

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - Nguyễn Gia
Kiệt

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

Tp. Hồ Chí Minh, tháng 07/2026

**TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN**

Nguyễn Văn Lê Bá Thành - 22127390

Nguyễn Gia Kiệt - 22127221

**PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC**

**KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO**

GIÁO VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

Tp. Hồ Chí Minh, tháng 07/2026

Lời cam đoan

Nhóm xin cam đoan đây là công trình nghiên cứu của riêng chúng tôi. Dữ liệu và kết quả nghiên cứu trong luận văn này là trung thực và không trùng lặp với bất kỳ chủ đề nào khác. Nhóm cam đoan toàn bộ nội dung luận văn này không đạo văn hoặc sao chép từ các công trình nghiên cứu khác. Ngoài ra, trong quá trình nghiên cứu và viết luận văn, chúng tôi tuân thủ nghiêm ngặt các quy định về bảo mật do các tập dữ liệu chúng tôi sử dụng trong nghiên cứu của mình cung cấp. Hơn nữa, chúng tôi luôn tuân thủ mọi nguyên tắc đạo đức trong suốt quá trình nghiên cứu. Nhóm đảm bảo rằng tất cả các nguồn và tài liệu tham khảo đều được trích dẫn đúng cách và chúng tôi duy trì tính chính trực học thuật trong mọi khía cạnh công việc của mình.

Lời cảm ơn

Nhóm xin chân thành cảm ơn PGS.TS Lý Quốc Ngọc và ThS. Đỗ Thị Thanh Hà đã dành rất nhiều thời gian, tâm huyết để định hướng, tận tình hướng dẫn và đưa ra những lời khuyên quý báu cho nhóm trong suốt quá trình nghiên cứu và thực hiện khóa luận tốt nghiệp với đề tài "Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức".

Xin trân trọng gửi lời cảm ơn sâu sắc đến Ban Chủ nhiệm cùng toàn thể quý thầy cô Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG-HCM. Những kiến thức nền tảng vững chắc mà các thầy cô đã truyền đạt trong bốn năm học vừa qua và môi trường thí nghiệm tuyệt vời chính là hành trang quan trọng nhất giúp nhóm có thể hoàn thành tốt hướng nghiên cứu này.

Nhóm cũng xin gửi lời cảm ơn đến các y bác sĩ tại Bệnh viện Chấn thương Chỉnh hình TP.HCM, thầy Đỗ Phúc Thịnh và thầy Võ Thế Hào đã hỗ trợ chia sẻ nguồn dữ liệu ảnh X-quang cũng như tư vấn các kiến thức chuyên môn về y khoa, giúp mô hình nghiên cứu bám sát với quy trình chẩn đoán thực tế.

Mặc dù đã có nhiều cố gắng trong quá trình thực hiện, nhưng do hạn chế về mặt thời gian và kinh nghiệm nghiên cứu, khóa luận chắc chắn không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô và hội đồng đánh giá để đề tài được hoàn thiện hơn.

Xin chân thành cảm ơn!



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO HỌC SÂU ĐA PHƯƠNG THỨC

*(Developing a bone X-ray image classification
system based on multimodal deep learning)*

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS Lý Quốc Ngọc (Khoa Công nghệ Thông tin)
- ThS Đỗ Thị Thanh Hà (Khoa Công nghệ Thông tin)

Nhóm Sinh viên thực hiện:

1. Nguyễn Văn Lê Bá Thành (MSSV: 22127390)
2. Nguyễn Gia Kiệt (MSSV: 22127221)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 02/2026 đến 08/2026

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn đầu. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, các nghiên cứu hiện nay đã ứng dụng các mô hình học sâu vào để giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ để đưa vào ứng dụng thực tế. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để bổ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác. Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống.

Khác với các mô hình đơn phương thức chỉ xử lý trên một phương thức như ảnh hay văn bản duy nhất, các mô hình đa phương thức có thể sử dụng nhiều phương thức và tìm ra sự tương quan giữa các phương thức nhằm tạo nên biểu diễn có ý nghĩa hơn từ đó nâng cao hiệu năng của hệ thống. Với thực tế lâm sàng hiện nay, các mô hình nghiên cứu tập trung

vào kết hợp ngôn ngữ và hình ảnh hay còn được gọi là mô hình ngôn ngữ trực quan đang là các mô hình đang nhận được nhiều sự chú ý.

2.2 Định nghĩa các khái niệm

Thông tin lâm sàng

Thông tin lâm sàng là những dữ liệu thu thập trực tiếp qua quá trình bác sĩ thăm khám người bệnh, bao gồm việc khai thác bệnh sử và khám thực thể (nhìn, sờ, gõ, nghe) [Dorland2011]. Dữ liệu này mang tính chất định hướng ban đầu, giúp bác sĩ khoanh vùng tổn thương và đưa ra các quyết định chỉ định thăm khám chuyên sâu tiếp theo [Bickley2020_Bates].

Thông tin cận lâm sàng

Thông tin cận lâm sàng là các dữ liệu khách quan thu được từ việc áp dụng các trang thiết bị và kỹ thuật y khoa hiện đại (như hình ảnh X-quang, cắt lớp, hay xét nghiệm sinh hóa) [Dorland2011]. Nếu lâm sàng dùng để định hướng, thì cận lâm sàng cung cấp bằng chứng xác thực từ bên trong cơ thể để chẩn đoán chính xác bệnh lý.

2.3 Phát biểu bài toán

Đầu vào (Input)

Hệ thống nhận vào các nguồn dữ liệu sau:

- Thông tin lâm sàng bao gồm báo cáo cận lâm sàng, khám xét toàn thân, lý do vào viện của bệnh nhân.
- Ảnh X-quang xương của bệnh nhân tương ứng.
- Tập nhãn được định nghĩa trước.


Đầu ra (Output)

Hệ thống sẽ sinh ra các nhãn sau:

- Tỷ lệ mà ảnh và thông tin lâm sàng tương ứng thuộc vào các lớp được định nghĩa trước.
- Ảnh trực quan hóa giải thích cho kết quả.

Kiến trúc tổng quan

Với bài toán này, kiến trúc tổng quan của một mô hình học sâu đa phương thức được sử dụng bao gồm bốn thành phần chính: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại như được thể hiện ở Hình 1.4.



Hình 1: Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức

Trong đó, bộ mã hóa ảnh có chức năng rút trích đặc trưng từ ảnh đầu vào, bộ mã hóa văn bản có chức năng rút trích đặc trưng từ văn bản đầu vào, bộ dung hợp dữ liệu có chức năng dung hợp hay căn chỉnh các đặc trưng được rút trích từ hai phương thức dữ liệu trên để tạo ra một biểu diễn có ý nghĩa và có đầy đủ tính chất của phương thức đầu vào, đây cũng là mô-đun quan trọng nhất đối với một mô hình học sâu đa phương thức, cuối cùng là bộ phân loại, nhận biểu diễn đặc trưng chung của các phương thức đầu vào để phân loại và đưa ra kết quả cuối cùng.

2.4 Mục tiêu đề tài

Trong bối cảnh già hóa dân số và các tác nhân gây bệnh từ ô nhiễm và lối sống thiếu lành mạnh trong đời sống hiện đại, các bệnh lý về xương và chấn thương có thể ảnh hưởng trực tiếp đến đời sống và tính mạng dẫn đến việc chẩn đoán và tiên lượng để đưa ra hướng điều trị phù hợp đang trở thành gánh nặng cho các y bác sĩ, các hệ thống học sâu đa phương

thức tuy đã phát triển nhưng lại thiếu khả năng giải thích. Đề tài hướng đến phát triển một hệ thống phân loại ảnh X-quang có khả năng:

- Đạt được độ chính xác cao trên các bộ dữ liệu nội bộ và quốc tế.
- Có khả năng giải thích được kết quả.
- Tích hợp kết quả để trợ giúp y bác sĩ trong quá trình chẩn đoán.

2.5 Phạm vi của đề tài

Nội dung nghiên cứu của đề tài tập trung vào việc khảo sát các mô hình nền tảng và thiết kế, huấn luyện, tinh chỉnh, đánh giá kiến trúc được đề xuất trên ảnh X-quang xương và các bộ dữ liệu quốc tế để so sánh, đánh giá với các kiến trúc trước.

Đối tượng nghiên cứu xoay quanh các thành phần bên trong một mạng học sâu đa phương thức bao gồm: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại, tập trung vào các phương pháp dung hợp dữ liệu hình ảnh và văn bản cùng với các phương pháp tinh chỉnh tham số cho các bộ mã hóa đã được huấn luyện trước nhằm tận dụng lại các tri thức đã có và nâng cao hiệu năng trên các tác vụ đích.

Đề tài chủ yếu sử dụng các bộ dữ liệu cặp ảnh - văn bản, không có trường hợp thiếu đã được công bố và bộ dữ liệu nội bộ được thu thập và cung cấp bởi giảng viên có hợp tác với bệnh viện ở khu vực Thành phố Hồ Chí Minh, một số thông tin cơ bản về các bộ dữ liệu được thể hiện ở Bảng 1. Nhóm sử dụng các bộ dữ liệu này nhằm đánh giá hiệu năng của kiến trúc đề xuất thông qua các độ đo phổ biến và tiến hành so sánh với các phương pháp trước đó nhằm chứng minh sự hiệu quả của phương pháp đề xuất.

2.6 Cách tiếp cận dự kiến

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ cung cấp tổng quan tình hình nghiên cứu

Bộ dữ liệu	Nguồn	Loại dữ liệu	Số lượng mẫu	Số lượng lớp
RSNA Pneumonia (2018)	Radiological Society of North America	Ảnh X-quang ngực metadata/tags	30,000	3
CheXpert (2019)	Stanford ML Group - Stanford Hospital	Ảnh X-quang ngực Báo cáo đọc ảnh	224,316	14
MIMIC-CXR v2 (2019)	Beth Israel Deaconess Medical Center	Ảnh X-quang ngực Báo cáo đọc ảnh	227,835	14
SARCOMA-CTCH (2025)	Bệnh viện Chấn Thương Chỉnh Hình - TPHCM	Ảnh X-quang xương Báo cáo đọc ảnh Báo cáo lâm sàng	Đang cập nhật	Đang cập nhật

Bảng 1: Tổng hợp các bộ dữ liệu dự kiến được sử dụng để thí nghiệm

từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

Các mô hình xây dựng từ đầu là các mô hình đơn giản, khởi điểm trong bài toán học sâu đa phương thức, thiết kế và huấn luyện một hệ thống mới từ đầu, điểm chung của các phương pháp này là chúng tập trung vào việc thiết kế các cơ chế để "trộn" (fusion) đặc trưng từ các bộ mã hóa (encoder) chuyên biệt ở các cấp độ khác nhau để tối ưu hóa hiệu suất cho các tác vụ cụ thể, sử dụng những bộ mã hóa hình ảnh đơn giản như CNN.

Khởi điểm vào 2020, X. Mei [**XMei**] và đồng nghiệp đã đề xuất lấy đặc trưng được tạo ra từ các lớp cuối của mô hình CNN (véc-tơ 512 chiều) và các đặc trưng từ dữ liệu lâm sàng rồi nối lại. Véc-tơ kết hợp này được đưa vào một mạng MLP cuối cùng để đưa ra dự đoán.

Clinical-BERT [**yan_2022_clinicalbert**] và TGANet [**nikhilkumartomar_2022_tganet**] tìm cách học biểu diễn đa phương thức bằng cách thúc đẩy mô hình hiểu và liên kết (align) các đặc trưng giữa các vùng trong ảnh và các từ khóa trong văn bản báo cáo thông qua các nhiệm vụ tự giám sát (self-supervised objectives), cho phép mô hình học được các biểu diễn ngữ nghĩa chung. Hay LViT [**li_2024_lvit**] đề xuất một kiến trúc hybrid CNN-Transformer "Double-U", cấu trúc CNN-Transformer kết hợp mô-đun Pixel-Level Attention Module để giữ lại các đặc trưng cục bộ của ảnh giúp mô hình giữ được khả năng trích xuất đặc trưng cục bộ mạnh mẽ của CNN, đồng thời tận dụng khả năng mô hình hóa ngữ cảnh toàn cục của Transformer.

Việc chỉ nối các đặc trưng có điểm yếu về sự khác biệt về giá trị hoặc sự ngữ nghĩa lớn giữa các phương thức dữ liệu, IRENE [**IRENE**] đã đưa

tất cả dữ liệu gốc về dạng token chung và học biểu diễn tổng thể (holistic representation) ngay từ đầu, sử dụng một mô hình Transformer duy nhất học các biểu diễn toàn diện cho cả hai phương thức. IRENE còn sử dụng cơ chế chú ý hai chiều ở cấp độ token để nắm bắt "các kết nối cục bộ".

Nghiên cứu của Dai và cộng sự [TransMed21] đề xuất mô hình TransMed, giải quyết bài toán kết hợp đa phương thức bằng cách tích hợp CNN và Transformer. Bằng việc chuyển đổi đặc trưng ảnh từ CNN thành dạng chuỗi để Transformer xử lý, mô hình này tối ưu hóa việc nắm bắt các đặc điểm toàn cục của hình ảnh y khoa. Cách tiếp cận này mang lại hiệu quả cao hơn các kỹ thuật fusion thông thường nhờ khả năng biểu diễn dữ liệu đa phương thức một cách toàn diện và chính xác.

Những nghiên cứu này đã khai phá và chứng minh về tác động tích cực của các phương thức dữ liệu khác như văn bản đến kết quả của việc chẩn đoán hình ảnh, tuy nhiên độ chính xác của các phương thức này còn chưa quá cao bởi các bộ mã hóa và phương pháp dung hợp dữ liệu còn đơn giản.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Kiến trúc mô hình			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	X. Mei [XMei]	Full Fine-Tuning	Pretrain với Cross-Entropy loss	Inception-ResNet-v2	ResNet-18	Decision-level	N/a
2	Clinical-BERT [yan_2022_clinicalbert]	Full Fine-Tuning	Cross-modal Repr. Learning	DenseNet121	Uncased BERT-base	Early fusion	N/a
3	LViT [li_2024_lvit]	Full Fine-Tuning	Semi-supervised (Pseudo-label)	Hybrid U-shape (CNN + ViT)	BERT_12_768_12	Intermediate	N/a
4	TGANet [nikhilkumartomar_2022_tganet]	Train from scratch	Exponential Pseudo-label Iteration	ResNet50	Không có	Intermediate	N/a
5	IRENE [IRENE]	Train from scratch	BCE Loss & AdamW optimizer	Convolution layer	Pretrained BERT	Simultaneous	Upsampling, FEM, CBAM Attention
6	TransMed [TransMed21]	Full Fine-Tuning	Supervised (SGD, 100 epochs)	2D CNN (ResNet18 đến 152)	N/a	Attention fusion	Lớp kết nối đầy đủ (FC Layer)

Bảng 2: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tinh chỉnh của các mô hình kết hợp ngôn ngữ - ảnh

Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu (thường cố gắng dung hợp dữ liệu thô thành một khối thống nhất), Med-VLMs chú trọng vào việc đối chiếu và liên kết chặt chẽ ngữ nghĩa giữa hình ảnh và ngôn ngữ tự nhiên. Cụ thể, kiến trúc của chúng thường kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này khớp với nhau. Lúc này, bộ phân loại không gán nhãn theo cách truyền thống mà

đóng vai trò là một cơ chế đo lường mức độ tương đồng. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Để đạt được khả năng trên, các nghiên cứu tiền huấn luyện Med-VLMs hiện nay đang phát triển chủ yếu theo ba hướng: học tương phản, học có che giấu và tích hợp tri thức y khoa (chi tiết tổng hợp được trình bày tại các Bảng 2.3, 2.4, 2.5).

Thứ nhất, **học tương phản (Contrastive Learning)** là chiến lược được ứng dụng rộng rãi nhất, tiêu biểu với các mô hình như ConVIRT [ConVIRT], GLoRIA [GLoRIA], MedCLIP [MedCLIP] và BiomedCLIP [BiomedCLIP]. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau ở mức độ cục bộ lẫn toàn cục. Phương pháp này đem lại hiệu năng ấn tượng; ví dụ, BiomedCLIP [BiomedCLIP] (huấn luyện trên 15 triệu cặp dữ liệu) đạt độ chính xác phân loại 83%, trong khi ConVIRT [ConVIRT] đạt 90,3% trên bộ dữ liệu COVIDx. Mặc dù có ưu điểm vượt trội là khả năng học biểu diễn không cần gán nhãn thủ công, học tương phản vẫn bộc lộ hạn chế về việc tiêu tốn tài nguyên tính toán lớn và rủi ro xảy ra hiện tượng âm tính giả (đẩy xa các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý).

Thứ hai, **học có che giấu (Masked Learning)** là hướng đi tập trung vào mục tiêu tái tạo dữ liệu, với các đại diện nổi bật như MRM [MRM] và MedViLL [MedViLL]. Bằng cách ẩn ngẫu nhiên các vùng ảnh hoặc từ ngữ trong báo cáo y khoa, kiến trúc này buộc mô hình phải dự đoán và khôi phục phần thông tin bị khuyết. Hướng tiếp cận này thể hiện ưu thế rõ rệt trong các môi trường khan hiếm dữ liệu; điển hình là MRM [MRM] đạt mức 92,7% AUC chỉ với 10% dữ liệu từ tập RSNA. Tuy nhiên, rào cản chính của phương pháp này nằm ở việc phụ thuộc vào nguồn dữ liệu đã được ghép cặp sẵn từ trước, cộng với độ phức tạp tính toán cao của quá trình khôi phục điểm ảnh/token.

Thứ ba, **tích hợp tri thức y khoa (Knowledge Integration)** ra đời nhằm giải quyết những đặc thù phức tạp của ngôn ngữ lâm sàng.

Các mô hình như MedKLIP [MedKLIP], BioViL [BioViL], BioViL-T [BioViL-T] và KAD [KAD] tận dụng đồ thị tri thức (như RadGraph) hoặc dữ liệu chuỗi thời gian để cung cấp tín hiệu giám sát chi tiết về cả loại và vị trí bệnh lý. Cách tiếp cận này giúp giải quyết triệt để sự mơ hồ của các từ vựng diễn tả tiến triển bệnh (ví dụ: "cải thiện", "xấu đi"). Về mặt hiệu năng, KAD [KAD] đạt 0.966 AUC trên tập PadChest ở thiết lập không mẫu (zero-shot), còn BioViL-T [BioViL-T] đạt độ chính xác 67,4% trong bài toán phân loại tiến triển bệnh. Dù vậy, các phương pháp này chưa loại bỏ hoàn toàn được hiện tượng âm tính giả và rất dễ gặp sai số nếu nhân chẩn đoán thực tế nằm ngoài cơ sở tri thức đồ thị gốc.

Dựa trên sự phân tích các ưu và nhược điểm từ những khảo sát trên, hướng tiếp cận đề xuất trong nghiên cứu này được thiết kế có chọn lọc nhằm tối ưu hóa hiệu năng và chi phí:

- **Kế thừa BiomedCLIP [BiomedCLIP]:** Tận dụng sức mạnh của các bộ mã hóa đã được huấn luyện với chất lượng cao.
- **Không áp dụng học tương phản & học có che giấu:** Khó khắc phục rào cản về tài nguyên tính toán lớn và giảm thiểu rủi ro gặp phải hiện tượng âm tính giả.
- **Tích hợp tri thức từ UMLS (tương tự MedKLIP [MedKLIP]):** Sử dụng để làm giàu thêm tri thức trong các báo cáo lâm sàng.

Mặc dù các phương pháp tiền huấn luyện Med-VLMs giúp xây dựng nền tảng tri thức đa phương thức khổng lồ, việc áp dụng trực tiếp vào lâm sàng lại vấp phải rào cản lớn về chi phí tính toán và sự khan hiếm dữ liệu y tế ghép cặp. Để giải quyết vấn đề này, các nghiên cứu thường chuyển hướng sang tinh chỉnh mô hình. Tuy nhiên, nếu tinh chỉnh toàn phần trên một tập dữ liệu nhỏ, sự chênh lệch phân phối sẽ dễ dẫn đến hiện tượng chuyển giao tiêu cực hoặc "quên thảm khốc", làm đánh mất tri thức gốc. Do đó, giới nghiên cứu đang tập trung vào các chiến lược tinh chỉnh hiệu quả tham số (PEFT) nhằm đảm bảo tính linh hoạt, tiết kiệm tài nguyên và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các nghiên cứu gần đây được chia thành ba hướng tiếp cận chính:

STT	Tên phương pháp	Phân loại	Nguyên lý
1	ConVIRT (2020)	Học tương phản	Tối ưu bộ mã hoá ảnh và văn bản bằng cách kéo các cặp đặc trưng ảnh-văn bản giống nhau lại gần nhau và đẩy các cặp đặc trưng ảnh-văn bản khác nhau ra xa
2	GLoRIA (2021)	Học tương phản	Dùng hai hàm mất mát global contrastive để kéo các cặp đặc trưng ảnh-văn bản, trong khi đó hàm mất mát local contrastive học cách căn chỉnh chi tiết của các vùng trong ảnh và các từ trong câu
3	MedCLIP (2022)	Học tương phản	Đề xuất cơ chế tách cặp và trích xuất tri thức, và đề xuất hàm mất mát Semantic Matching nhằm giải quyết vấn đề false negative
4	BiomedCLIP (2023)	Học tương phản	Có cơ chế tương tự như CLIP nhưng được tiền huấn luyện với bộ dữ liệu PMC-15M
5	MRM (2023)	Học có che giấu	Ẩn ngẫu nhiên các thông tin trong văn bản và các vùng trong ảnh để cho mô hình dự đoán lại ảnh và văn bản hoàn chỉnh.
6	MedViLL (2022)	Học có che giấu	Đề xuất một kiến trúc dựa trên BERT kết hợp với một mặt nạ chú ý mới được đề xuất (BAR) cho phép ảnh tương tác tự do với văn bản trong các tác vụ hiểu, đồng thời đảm bảo tính tự hồi quy cho các token trong văn bản trong các tác vụ sinh
7	BioViL (2022)	Tích hợp kiến thức y khoa	Đề xuất một bộ mã hoá văn bản CXR-BERT được tối ưu cho ảnh X-quang, duy trì hàm mất mát MLM để giúp mô hình giữ lại được các kiến thức văn bản trong quá trình căn chỉnh với ảnh
8	BioViL-T (2023)	Tích hợp kiến thức y khoa	Sử dụng các ảnh X-quang từ trước kết hợp với ảnh hiện tại để học được các đặc trưng không gian, thời gian từ đó giải thích cho các từ vựng như "cải thiện" giúp giảm đi sự mơ hồ trong báo cáo
9	MedKLIP (2023)	Tích hợp kiến thức y khoa	Đề xuất một mô-đun trích xuất bộ ba và cơ chế mã hoá tăng cường tri thức, từ đó tạo ra biểu diễn tốt hơn cho văn bản
10	KAD (2023)	Tích hợp kiến thức y khoa	Tích hợp kiến thức y khoa vào quá trình tiền huấn luyện để giúp mô hình học các biểu diễn có ý nghĩa hơn

Bảng 3: Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Mục tiêu tiền huấn luyện	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	CL	GCL	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	CL	LCL, GCL	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	CL	GCL	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	CL	GCL	ViT-Base	PubMedBERT	Contrastive Alignment	N/a
5	MRM (2023)	MP	MIM, MLM	Kiến trúc giống ViT	WordPiece	Global Context Injection	Văn bản: Transformer; Hình ảnh: Fully Connected
6	MedViLL (2022)	HA	MLM, ITM	ResNet50	BERT	Cross-modal Self-Attention	Multi-Layer Perceptron
7	BioViL (2022)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
8	BioViL-T (2023)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
9	MedKLIP (2023)	CL	LCL	ResNet50	ClinicalBERT	Knowledge-enhanced Alignment	Contrastive head, Cross-Entropy head
10	KAD (2023)	HA	CL, Disease Diagnosis Prediction	ResNet50, ViT-Base	PubMedBERT	Contrastive Alignment	Disease Query Network

Bảng 4: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;

STT	Tên phương pháp	Bộ dữ liệu tiền huấn luyện	Hiệu năng			
			Tác vụ	Bộ dữ liệu đánh giá	Độ đo	Kết quả
1	ConVIRT (2020)	MIMIC-CXR, Private Bone image	- Phân loại ảnh - Phân loại ít mẫu	RSNA Pneumonia, CheXpert, COVIDx, MURA	AUC, Accuracy	- Phân loại ít mẫu: RSNA (1%): 88.8% AUC, (10%): 91.5% AUC; CheXpert (1%): 87.0% AUC, (10%): 88.1% AUC; MURA (1%): 81.3% AUC, (10%): 86.5% AUC - Phân loại ảnh: RSNA: 92.7% AUC, CheXpert: 88.1% AUC, MURA: 89.0% AUC; COVIDx 90.3% ACC
2	GLoRIA (2021)	CheXpert	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	CheXpert, RSNA Pneumonia	AUROC	- Phân loại không mẫu: CheXpert 5x200: 0.61 ACC, 0.67 F1; RSNA: 0.70 ACC, 0.58 F1; - Phân loại ít mẫu: CheXpert (1%): 86.6 AUC, (10%): 87.8 AUC, RSNA (1%): 86.1 AUC, (10%) 88.0 AUC - Phân loại ảnh: CheXpert: 88.1 AUC, RSNA: 88.6 AUC
3	MedCLIP (2022)	MIMIC-CXR, CheXpert	- Phân loại ảnh - Phân loại không mẫu	MIMIC-5x200, COVID, RSNA Pneumonia	Mean Accuracy	- Phân loại không mẫu: CheXpert-5x200: 0.5942 ACC; MIMIC-5x200: 0.5430 ACC; COVID: 0.8472 ACC; RSNA: 0.7682 ACC - Phân loại ảnh: CheXpert-5x200: 0.5960 ACC; MIMIC-5x200: 0.5650 ACC; COVID: 0.7890 ACC; RSNA: 0.8075 ACC
4	BiomedCLIP (2023)	PMC-15M	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PCam, LC25000 (Lung, Colon), TCGA-TIL, RSNA Pneumonia	AUC, Accuracy	- Phân loại không mẫu: PCam: 73.41% ACC; LC25000 Lung 65.23% ACC; LC25000 Colon 92.98%; RSNA 78.95%; TCGA-TIL: 67.04% - Phân loại ít mẫu: PCam (1%): 82% ACC, (10%): 83%; RSNA (1%): 77% ACC, (10%): 82% ACC - Phân loại ảnh: PCam: 83% ACC, RSNA: 83% ACC
5	MRM (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu	CheXpert, NIH ChestX-ray, RSNA Pneumonia, COVID-19 Image Data Collection	AUC, Accuracy	- Phân loại ít mẫu: CheXpert (1%): 88.5 AUC, (10%): 88.5 AUC; RSNA (1%): 91.3 AUC, (10%): 92.7 AUC; NIH ChestX-ray (1%): 79.4 AUC, (10%): 84.0 AUC - Phân loại ảnh: CheXpert: 88.7 AUC, RSNA 93.3, NIH ChestX-ray: 85.9, COVID-19: 85.8
6	MedViLL (2022)	MIMIC-CXR	- Phân loại chẩn đoán	MIMIC-CXR, Open-I	Micro-averaged AUROC, Micro-averaged F1 score	- Phân loại ảnh: MIMIC-CXR: 0.980 avg AUROC, 0.839 F1; Open-I: 0.892 avg AUROC, 0.407 F1
7	BioViL (2022)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	RSNA Pneumonia	Accuracy, F1-score, AUROC, Sensitivity Specificity.	- Phân loại không mẫu: RSNA: 0.732 ACC, 0.831 AUC; ChestX-ray14: 0.6912 AUC - Phân loại ít mẫu: RSNA (1%): 0.805 ACC, 0.881 AUC; (10%): 0.812 ACC, 0.884 AUC - Phân loại ảnh: RSNA: 0.822 ACC, 0.891 AUC
8	BioViL-T (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu - Phân loại ảnh tiến triển	MS-CXR-T, RSNA Penumonia, Chest ImaGenome	Macro-Accuracy, Accuracy, F1, AUROC.	- Phân loại Tiến triển: MS-CXR-T: 67.4% Acc - Phân loại không mẫu: RSNA: 0.805 ACC, 0.871 AUC - Phân loại ít mẫu: RSNA (1%): 0.814 ACC, 0.890 AUC
9	MedKLIP (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại không mẫu	ChestX-ray14, RSNA Pneumonia, SIIM-ACR Pneumothorax, COVIDx CXR-2, COVID Rural, Edema Severity	AUC, F1-score, Accuracy.	- Phân loại không mẫu: RSNA: 0.8694 AUC, 0.6342 F1; SIIM-ACR: 0.8924 AUC, 0.6833 F1; ChestX-ray14: 0.7676 AUC, 0.2525 F1; COVID-19: 0.7396 AUC, 0.7670 F1 - Phân loại ít mẫu: ChestX-ray14 (1%): 0.7721 AUC, (10%): 0.7894; RSNA (1%): 0.8731 AUC, (10%): 0.8799 AUC - Phân loại mẫu: ChestX-ray14: 0.8323 AUC, RSNA 0.8931
10	KAD (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PadChest, NIH ChestXray14, CheXpert, ChestX-Det	AUC, F1-Score, MCC	- Phân loại không mẫu: PadChest: 0.966 AUC; CheXpert: 0.905 AUC, 0.647 F1, 0.589 MCC - Phân loại ít mẫu: ChestXray-14 (1%): 0.78 AUC, 0.31 F1; (10%): 0.80 AUC, 0.33 F1 - Phân loại ảnh: ChestXray-14: 0.82 AUC, 0.34 F1

Bảng 5: Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

Tinh chỉnh sử dụng câu nhắc (Prompt Tuning): Hướng này chèn thêm các tham số có thể học được vào không gian đầu vào của mô hình. Các phương pháp như CITE [CITE], FPT [FPT] hay PLIP [PLIP] khai thác đặc trưng thị giác kết hợp với tri thức lâm sàng, cho thấy hiệu quả vượt trội ngay cả khi thiếu hụt dữ liệu (ví dụ: PLIP đạt 0.896 AUC chỉ với 5% dữ liệu PanNuke). Nhằm giải quyết khó khăn khi thiết kế thủ công, MedPrompt [MedPrompt] và UniDCP [UniDCP] tự động sinh câu nhắc động dựa trên ngữ cảnh ảnh để xử lý đa tác vụ. Gần đây hơn, việc tích hợp Mô hình ngôn ngữ Lớn (LLM) qua ViP [ViP], CILMP [CLIMP] và BiomedCoOp [BiomedCoOp] giúp tạo sinh các câu nhắc ngữ nghĩa sâu sắc, đồng bộ hóa qua cơ chế chú ý chéo và cân chỉnh tương phản, mang lại hiệu năng cao trong các kịch bản ít mẫu hoặc không mẫu.

Tinh chỉnh bộ điều hợp (Adapter Tuning): Thay vì can thiệp ở đầu vào, phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ giữa các lớp của kiến trúc gốc. Điển hình, CLIPath [CLIPath] sử dụng kết nối thẳng dư để giảm khoảng cách miền trên dữ liệu nhỏ; FTB [FTB] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức. Ở hướng bán giám sát, mô hình MedUnA [MedUnA] dùng LLM tạo nhãn giả và tinh chỉnh không giám sát bộ điều hợp trên ảnh chưa gán nhãn, giúp mô hình thích ứng tốt mà không thay đổi trọng số.

Tinh chỉnh chọn lọc (Selective Tuning): Hướng đi này tối ưu hóa kiến trúc bằng cách chỉ cập nhật một lượng nhỏ các trọng số quyết định hiệu năng. TransMed [TransMed] kết hợp LLM để chuyển đổi nhãn bệnh thành mô tả chi tiết, trong khi SH-PEFT [SH-PEFT] chỉ tìm và cập nhật các trọng số quan trọng nhất trên bộ mã hóa thị giác nhằm khai thác tính thừa thớt của mạng. Tương tự, LCBB [LCBB] áp dụng kỹ thuật LoRA để tinh chỉnh tham số hiệu quả cho Med-VLMs, giúp bám sát hiệu năng của tinh chỉnh toàn phần (đạt 93.1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn) nhưng giảm thiểu tối đa chi phí tính toán.

Tóm lại, các phương pháp tinh chỉnh hiệu quả tham số (PEFT) thể hiện ưu điểm vượt trội trong việc tiết kiệm tài nguyên tính toán, ngăn chặn hiện tượng quên tri thức và giúp mô hình thích ứng tốt ngay cả khi đối mặt với các bộ dữ liệu y tế khan hiếm. Tuy nhiên, hướng tiếp cận này vẫn tồn tại một số hạn chế nhất định. Hiệu năng cuối cùng của hệ thống

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	CITE (2023)	Parameter-efficient fine tuning	Visual prompt tuning	CLIP ViT-Base, ImageNet-21k ViT-Base, INTERN ViT-Base	BioLinkBERT-large, BioBERT-large, Kế thừa CLIP	Contrastive Alignment	N/a
2	UniDCP (2023)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	CLIP ViT	RoBERTa	Cross Attention, Contrastive Alignment	N/a
3	ViP (2024)	Parameter-efficient fine tuning	Textual prompt tuning	ViT-Base	Kế thừa CLIP	Cross Attention, Contrastive Alignment	N/a
4	PLIP (2024)	Parameter-efficient fine tuning	Visual prompt tuning, Efficient Selective tuning	ViT-Base	Kế thừa CLIP	Concatnate	N/a
5	FPT (2024)	Parameter-efficient fine tuning	Visual prompt tuning	ViT-Base	N/a	Cross Attention	N/a
6	MedPrompt (2024)	Parameter-efficient fine tuning	Textual prompt tuning	Swin Transformer, ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
7	CILMP (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	ViT-Base	Kế thừa CLIP	Hadamard Product, Concatnate	N/a
8	BiomedCoOp (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	Kế thừa BiomedCLIP	Kế thừa BiomedCLIP	Contrastive Alignment	N/a
9	CLIPath (2023)	Parameter-efficient fine tuning	Adapter tuning	ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
10	FTB (2024)	Parameter-efficient fine tuning	Adapter tuning	ResNet autoencoder, DINOv2-small, DINOv2-base	BERT, BioBERT, ClinicalBERT, CXR-BERT, PubMedBERT	Cross Attention	N/a
11	MedUnA (2024)	Parameter-efficient fine tuning	Adapter tuning	ViT-Base, MedCLIP-Swin	Kế thừa CLIP, MedCLIP	No Fusion	N/a
12	TransMed (2023)	Parameter-efficient fine tuning	Direct Selective tuning	Swin Transformer, ViT-Base	BERT, LLM/GPT-4	Contrastive Alignment	N/a
13	SH-PEFT (2024)	Parameter-efficient fine tuning	Direct Selective tuning	ViT-Base	Kế thừa CLIP	No Fusion	N/a
14	LCBB (2024)	Parameter-efficient fine tuning	Efficient Selective tuning	Kế thừa MAE, MRM	Kế thừa MAE, MRM	Kế thừa MAE, MRM	N/a

Bảng 6: Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan

phụ thuộc rất lớn vào chất lượng của mô hình tiền huấn luyện gốc. Đồng thời, quá trình thiết kế câu nhắc mang đậm tính chuyên môn hay xác định vị trí tối ưu để chèn bộ điều hợp thường phức tạp và đòi hỏi nhiều thử nghiệm. Ngoài ra, việc bổ sung các thành phần này ít nhiều làm tăng tính "hộp đen" của mô hình, gây ra những thách thức về tính minh bạch khi cần giải thích các quyết định dự đoán cho bác sĩ trên thực tế lâm sàng.

Các mô hình ngôn ngữ lớn y khoa đa phương thức

Trong thời gian gần đây, với sự phát triển của các mô hình ngôn ngữ lớn được huấn luyện trên những tập dữ liệu rất lớn phục vụ cho rất nhiều tác vụ khác nhau, các mô hình này đang thể hiện sự ảnh hưởng và đa dụng trong lĩnh vực y tế với độ chính xác rất tốt khi chỉ học ít mẫu hoặc không mẫu.

Med-Flamingo [moor_2023_medflamingo] là mô hình đầu tiên có khả năng học ít mẫu chuyên dụng cho y tế, thông qua hội thoại tự nhiên để hỗ trợ chẩn đoán. Theo sau đó, LLaVA-Med [li_2023_llavamed] là mô hình chuyển đổi khả năng thực hiện theo chỉ dẫn (instruction-following) từ

miền tổng quát sang lĩnh vực y sinh bằng cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn với 600.000 cặp, với dữ liệu hội thoại tạo ra từ chú thích ảnh y khoa được tạo ra bằng cách sử dụng GPT-4. Phương pháp này đã đề xuất quy trình huấn luyện 2 bước: (1) Căn chỉnh khái niệm; (2) Tinh chỉnh chỉ dẫn đầy đủ; 2 bước này tương ứng với giai đoạn học và suy luận. Kết quả thể hiện khả năng suy luận vượt trội trên dữ liệu chưa từng thấy.

Med-Palm M [**MED-PALM-M**] là mô hình của Google, đánh dấu bước tiến từ các mô hình đơn nhiệm sang đa nhiệm quy mô lớn, có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì sử dụng các mô hình chuyên biệt cho từng tác vụ. Gần đây hơn, SkinGPT-4 [**SkinGPT-4**] là hệ thống chẩn đoán da liễu tương tác đầu tiên sử dụng LLM quy mô lớn với độ chính xác cao, đã kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM), tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Dù đưa đến các phương pháp có độ chính xác cao đến rất cao trong nhiều tác vụ cùng việc hỗ trợ trong việc giao tiếp với mô hình, kích cỡ và chi phí huấn luyện (Med-Flamingo có đến 9 tỷ thông số) để vận hành các mô hình ngôn ngữ lớn đa phương thức là một vấn đề lớn, đi kèm với vấn đề ảo giác có thể gặp phải khi đối mặt mới dữ liệu mới hoặc những câu hỏi phức tạp. Ngoài ra nếu yêu cầu một độ chính xác cao - một yêu cầu quan trọng trong lĩnh vực y tế trong một tác vụ cụ thể thì đây không phải một cách tiếp cận tốt cho bài toán này.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Cấu trúc phương pháp			
				Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	Med-Flamingo [moor_2023_medflamingo]	PEFT	Parameter-efficient + Domain adaptation	Frozen CLIP ViT	LLaMA-7B	Intermediate fusion	LLaMA Decoder
2	LLaVA-Med [li_2023_llavamed]	Full FT	Visual Instruction Tuning (GPT-4 data)	CLIP ViT-L/14	LLaMA	Projection Matrix	LLM (Vicuna)
3	Med-PaLM M [MED-PALM-M]	Full FT	Instruction Fine-tuning	ViT (4B - 22B)	PaLM	Multimodal embedding	PaLM
4	SkinGPT-4 [SkinGPT-4]	PEFT	LoRA	Vision Transformer	GPT-4	Linear alignment	LLaMA-2-13B


Bảng 7: Tổng hợp chiến lược và cấu trúc các mô hình ngôn ngữ lớn đa phương thức

Phương pháp đề xuất: Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế theo hướng tích hợp tri thức y khoa nhằm nâng cao

khả năng giải thích của mô hình được minh họa ở Hình 2. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Bộ mã hóa ảnh:** Kế thừa lại mô hình ViT-Base của phương pháp BiomedCLIP [BiomedCLIP]
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [BiomedCLIP]
- **Bộ dung hợp dữ liệu:** Nhóm hướng đến sử dụng cơ chế *Knowledge-guided Cross-Attention* - Các khái niệm y học được trích xuất và liên kết từ văn bản lâm sàng thông qua sẽ được sử dụng để tạo thiên lệch (bias) trong quá trình tính toán cross attention. Cơ chế này giúp điều hướng mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Nhờ đó, mô hình không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.
- **Bộ phân loại:** Sử dụng một mạng phân loại (Multi-Layer Perceptron) để dự đoán nhãn bệnh lý.

Đồng thời, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán.



Hình 2: Kiến trúc tổng thể của hệ thống đề xuất

2.7 Kết quả dự kiến của đề tài

- **Số liệu định lượng:** Độ chính xác, điểm F1, AUC-ROC đạt kết quả cạnh tranh trên các bộ dữ liệu đã nêu.
- **Sản phẩm đầu ra:**

- Hệ thống demo phân loại ảnh X-quang xương với khả năng nhận ảnh và văn bản và trả ra các lớp thuộc bộ dữ liệu Sarcoma-CTCH.
 - Giao diện đơn giản để hiển thị kết quả phân loại.
 - Cho phép trực quan hóa sau khi hiển kết quả phân loại.
- **Báo cáo khoa học:** hoàn thiện phương pháp và hệ thống để hướng tới công bố trên các hội nghị và tạp chí uy tín trong lĩnh vực Trí tuệ nhân tạo và Y sinh, như MICCAI, CVPR hoặc các tạp chí được công nhận.
 - **Hướng phát triển:**
 - Mở rộng ra cho các bệnh lý khác.
 - Cải thiện độ chính xác và hiệu suất của hệ thống.

2.8 Kế hoạch thực hiện

Mục tiêu	Thời gian	Phân công	Nội dung
Khoá luận tốt nghiệp	01 tháng	Giai đoạn 1	
		Bá Thành	Khảo sát tổng quan về bài toán phân loại ảnh X-quang về xương
		Gia Kiệt	Khảo sát các mô hình tiền huấn luyện trên dữ liệu y khoa
		Bá Thành	Khảo sát các phương pháp học chuyển giao và các mô hình liên quan
	02 tháng	Giai đoạn 2	
		Cả nhóm	Phát triển mô hình học sâu đa phương thức áp dụng phương pháp học chuyển giao
		Gia Kiệt	Cài đặt môi trường, thu thập các bộ dữ liệu liên quan
		Bá Thành	Thực hiện thí nghiệm trên mô hình đề xuất
	02 tháng	Giai đoạn 3	
		Bá Thành	Phân tích so sánh kết quả thực nghiệm.
		Gia Kiệt	Xây dựng nguyên mẫu cho hệ thống phân loại
	0.5 tháng	Giai đoạn 4	
		Cả nhóm	Viết 01 bài báo khoa học cho hội nghị - tạp chí chuyên ngành trong nước hoặc ngoài nước
	0.5 tháng	Giai đoạn 5	
		Bá Thành	Viết báo cáo khoá luận tốt nghiệp.
		Gia Kiệt	Thiết kế slide cho lễ bảo vệ đề tài tốt nghiệp

Bảng 8: Kế hoạch bố trí thời gian nghiên cứu

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 05 tháng 04 năm 2026
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)

Mục lục

Lời cam đoan	i
Lời cảm ơn	ii
Đề cương chi tiết	iii
Mục lục	xxiii
Danh sách hình	xxvii
Danh sách bảng	xxviii
Tóm tắt	xxix
1 Giới thiệu	1
1.1 Bối cảnh và lý do chọn đề tài	2
1.2 Động lực nghiên cứu	3
1.2.1 Vị trí của hệ thống phân loại khi áp dụng trong quy trình chẩn đoán thực tế	3
1.2.2 Ý nghĩa khoa học của đề tài	4
1.2.3 Ý nghĩa thực tiễn của đề tài	6
1.3 Định nghĩa các khái niệm	7
1.3.1 Thông tin lâm sàng	7
1.3.2 Thông tin cận lâm sàng	7
1.4 Giới thiệu bài toán	8
1.4.1 Các thách thức trong bài toán	9
1.4.2 Các hướng tiếp cận hiện có	10
1.5 Đối tượng và phạm vi nghiên cứu	11

1.5.1	Đối tượng nghiên cứu	11
1.5.2	Phạm vi nghiên cứu	11
1.6	Bố cục luận văn	12
2	Các công trình nghiên cứu liên quan	14
2.1	Các mô hình nền tảng	14
2.1.1	Các mô hình xây dựng từ đầu	14
2.1.2	Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) .	16
2.1.3	Các mô hình ngôn ngữ lớn y khoa đa phương thức .	21
2.2	Các kỹ thuật tinh chỉnh mô hình	23
2.2.1	Tinh chỉnh sử dụng câu nhắc (Prompt Tuning) . .	24
2.2.2	Tinh chỉnh bộ điều hợp (Adapter Tuning)	24
2.2.3	Tinh chỉnh chọn lọc (Selective Tuning)	25
2.2.4	Cơ sở lựa chọn kỹ thuật LoRA cho hệ thống phân loại y khoa đa phương thức	26
2.3	Các phương pháp phát hiện dữ liệu ngoài phân phối	27
2.3.1	Phương pháp dựa trên đầu ra của mô hình (Post-hoc Methods)	28
2.3.2	Không gian đặc trưng và Mạng nguyên mẫu	28
2.3.3	Mô hình sinh và Định lượng độ không chắc chắn (Generative Models & Uncertainty Quantification)	30
2.3.4	Học sâu Đa phương thức trong phát hiện OOD Y khoa (Multimodal Deep Learning)	30
2.3.5	Hạn chế của các phương pháp hiện tại và Cơ sở lựa chọn	31
3	Phương pháp đề xuất	33
3.1	Phân loại với mô hình BioMedCLIP và đề xuất cải tiến . .	33
3.1.1	Quá trình phân loại của mô hình BiomedCLIP . . .	33
3.1.2	Kết quả phân loại	34
3.1.3	Kết luận	36
3.1.4	Đề xuất cải tiến	37
3.2	Ý tưởng ban đầu	38
3.3	Giai đoạn off-line	39

3.3.1	Domain-Adaption với kỹ thuật LoRA	40
3.3.2	Fusion-learning	43
3.4	Giai đoạn online	46
3.5	Đóng góp của phương pháp	47
4	Thực nghiệm	49
4.1	Mục đích thực nghiệm	49
4.1.1	Đánh giá so sánh hiệu năng chẩn đoán với các mô hình đối sánh	50
4.1.2	Đánh giá khả năng phát hiện dữ liệu ngoài phân phối	50
4.1.3	Đánh giá vai trò của các nguồn thông tin văn bản lâm sàng	51
4.1.4	Đánh giá ảnh hưởng của chiến thuật tinh chỉnh backbone	51
4.1.5	Đánh giá hiệu quả của đầu phân loại nguyên mẫu so với đầu phân loại tuyến tính	52
4.1.6	Trực quan hóa bản đồ chú ý chéo và khả năng giải thích y khoa	53
4.2	Chuẩn bị dữ liệu	53
4.2.1	Bộ dữ liệu BTXRD	54
4.2.2	Bộ dữ liệu CTCH	58
4.3	Độ đo đánh giá	63
4.3.1	Định nghĩa toán học và ý nghĩa của các độ đo . . .	63
4.4	Thiết lập thực nghiệm	67
4.4.1	Môi trường thực nghiệm	67
4.4.2	Tham số thực nghiệm	69
4.5	Kết quả thực nghiệm và Thảo luận	69
4.5.1	Đánh giá so sánh hiệu năng chẩn đoán với các mô hình đối sánh	69
4.5.2	Đánh giá khả năng phát hiện dữ liệu ngoài phân phối	71
4.5.3	Các thí nghiệm rời rạc	71
4.5.4	Trực quan hóa bản đồ chú ý chéo và khả năng giải thích y khoa	74

5 Kết luận và hướng phát triển	77
Tài liệu tham khảo	78

Danh sách hình

1.1	Nguồn thông tin lâm sàng bao gồm khai thác bệnh sử và khám thực thể	7
1.2	Nguồn thông tin cận lâm sàng từ hình ảnh X-quang	7
1.3	Nguồn thông tin từ báo cáo đọc ảnh X-quang	8
1.4	Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức	11
3.1	Sơ đồ chung của hệ thống trong công đoạn Domain-Adaption.	40
3.2	Sơ đồ chung của hệ thống trong công đoạn Fusion-learning.	43
3.3	Sơ đồ mạng prototypical.	44
3.4	Sơ đồ chung của hệ thống trong giai đoạn online.	46
4.1	Sơ đồ phân cấp cấu trúc dữ liệu BTXRD	55
4.2	Sơ đồ phân cấp cấu trúc dữ liệu CTCH	61
4.3	Trực quan hóa bản đồ chú ý chéo (Cross-Attention Map) của mô hình đề xuất XBone-Net trên các nhóm bệnh lý điển hình (mỗi cặp gồm ảnh chụp X-quang gốc bên trái đã vẽ đường nét đứt màu xanh lá thể hiện phân vùng tổn thương thực tế - Ground Truth và ảnh chồng bản đồ chú ý chéo ở bên phải).	75

Danh sách bảng

2.1	Bảng tổng hợp nguyên lý của các mô hình kết hợp ngôn ngữ - ảnh nổi bật	16
2.2	Bảng tổng hợp phương pháp của các mô hình kết hợp ngôn ngữ - ảnh nổi bật	16
2.3	Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan	18
2.4	Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;	19
2.5	Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan	20
2.6	Bảng tổng hợp nguyên lý của các mô hình ngôn ngữ lớn đa phương thức	22
2.7	Bảng tổng hợp phương pháp của các mô hình ngôn ngữ lớn đa phương thức	22
2.8	Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan	26
3.1	Các chỉ số đánh giá tổng quan (Aggregated/Macro)	35
3.2	Chỉ số F1 (F1-score) chi tiết theo từng lớp	36

4.1	Ví dụ các mẫu dữ liệu đa phương thức trong bộ dữ liệu BTXRD	59
4.2	Phân bố hình ảnh theo các tập dữ liệu trong BTXRD . . .	60
4.3	Phân bố các lớp bệnh lý u xương trong bộ dữ liệu BTXRD	60
4.4	Bảng tổng hợp siêu tham số ở pha 1 và thiết lập của chúng	68
4.5	Bảng tổng hợp siêu tham số ở pha 2 và thiết lập của chúng	68
4.6	Bảng so sánh kết quả thực nghiệm giữa mô hình đề xuất và các baselines	69
4.7	Bảng kết quả ablation về nguồn văn bản đầu vào	71
4.8	Bảng kết quả ablation về chiến thuật tinh chỉnh backbone	72
4.9	Bảng kết quả ablation về bộ phân loại Classifier Head . . .	73

Tóm tắt

Các bệnh lý và chấn thương xương ngày càng phổ biến, làm gia tăng nhu cầu ứng dụng trí tuệ nhân tạo nhằm hỗ trợ bác sĩ trong quá trình phân tích ảnh X-quang. Tuy nhiên, dữ liệu X-quang y khoa thường có số lượng mẫu gán nhãn hạn chế, mất cân bằng giữa các lớp bệnh và tồn tại nhiều trường hợp ngoài phân phối (Out-of-Distribution - OOD), khiến hiệu quả của các mô hình học sâu suy giảm khi triển khai trong thực tế.

Đề tài hướng đến xây dựng một hệ thống phân loại đa nhãn ảnh X-quang xương theo hướng đa phương thức, khai thác đồng thời thông tin từ ảnh X-quang và văn bản lâm sàng nhằm nâng cao hiệu quả dự đoán.

Hệ thống được xây dựng trên nền tảng BioMedCLIP với hai giai đoạn huấn luyện. Giai đoạn thứ nhất thực hiện thích nghi miền bằng kỹ thuật LoRA sử dụng Semantic Matching Loss nhằm cải thiện khả năng biểu diễn đặc trưng đối với dữ liệu X-quang xương. Giai đoạn thứ hai sử dụng cơ chế chú ý hai chiều để hợp nhất đặc trưng ảnh và văn bản, kết hợp Asymmetric Loss nhằm xử lý mất cân bằng dữ liệu và Prototypical Network để tăng cường khả năng phân biệt giữa các lớp, hỗ trợ các lớp có ít mẫu và làm cơ sở cho phát hiện dữ liệu ngoài phân phối. Hệ thống được đánh giá thông qua các thực nghiệm thành phần, so sánh với các mô hình nền tảng và đánh giá trên bộ dữ liệu X-quang xương được xây dựng từ dữ liệu thực tế tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh.

Kết quả thực nghiệm cho thấy phương pháp đề xuất cải thiện hiệu quả phân loại đa nhãn so với mô hình nền, đồng thời nâng cao khả năng tổng quát và hỗ trợ phát hiện dữ liệu ngoài phân phối. Ngoài ra, đề tài còn đóng góp một bộ dữ liệu X-quang xương đã được tinh lọc và chuẩn hóa, tạo nền tảng cho các nghiên cứu tiếp theo về học đa phương thức và ứng dụng mô hình thị giác-ngôn ngữ trong phân tích ảnh y khoa.

Chương 1

Giới thiệu

Chương này trình bày tổng quan về bài toán hỗ trợ chẩn đoán bệnh lý trên ảnh X-quang bằng học sâu đa phương thức, đặc biệt trong bối cảnh dữ liệu y tế thường có tính phức tạp cao và phụ thuộc vào kinh nghiệm của bác sĩ trong quá trình phân tích. Bên cạnh thông tin hình ảnh, quá trình chẩn đoán thực tế còn yêu cầu kết hợp thêm các thông tin lâm sàng và báo cáo y khoa nhằm đưa ra đánh giá toàn diện về tình trạng bệnh nhân. Tuy nhiên, việc khai thác hiệu quả đồng thời nhiều nguồn dữ liệu khác nhau vẫn còn là một thách thức lớn đối với các hệ thống học sâu hiện nay.

Xuất phát từ thực tế đó, khóa luận hướng đến nghiên cứu và xây dựng một hệ thống học sâu đa phương thức kết hợp dữ liệu hình ảnh X-quang, thông tin văn bản lâm sàng và báo cáo y khoa nhằm nâng cao hiệu năng phân loại và hỗ trợ chẩn đoán. Đồng thời, đề tài cũng khảo sát các phương pháp tinh chỉnh mô hình tiền huấn luyện, cơ chế dung hợp dữ liệu nhằm tăng khả năng tận dụng tri thức nền cũng như cải thiện tính minh bạch trong quá trình suy luận của mô hình. Kết quả nghiên cứu được kỳ vọng góp phần xây dựng một hệ thống hỗ trợ chẩn đoán có độ chính xác cao, khả năng giải thích tốt và tạo tiền đề cho việc ứng dụng các mô hình trí tuệ nhân tạo đa phương thức trong lĩnh vực y tế tại Việt Nam.

1.1 Bối cảnh và lý do chọn đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Trong những năm gần đây, các bệnh lý và chấn thương xương ngày càng gia tăng do tai nạn giao thông, tai nạn lao động, hoạt động thể thao và quá trình già hóa dân số. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế cần được quan tâm đặc biệt nhất, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực tế lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn sớm. Tuy nhiên, việc đọc và phân tích ảnh X-quang hiện nay phụ thuộc rất lớn vào kinh nghiệm và của các bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, nhiều nghiên cứu đã ứng dụng các mô hình học sâu vào việc giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ tốt để đưa vào ứng dụng thực tế như DenseNet và Resnet. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để hỗ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác. Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống.

Khác với các mô hình đơn phương thức chỉ xử lý trên một phương thức như ảnh hay văn bản duy nhất, các mô hình đa phương thức có thể sử dụng nhiều phương thức và tìm ra sự tương quan giữa các phương thức nhằm tạo nên biểu diễn có ý nghĩa hơn từ đó nâng cao hiệu năng của hệ thống. Với thực tế lâm sàng hiện nay, các mô hình nghiên cứu tập trung

vào kết hợp ngôn ngữ và hình ảnh hay còn được gọi là mô hình ngôn ngữ trực quan đang là các mô hình đang nhận được nhiều sự chú ý, tiêu biểu có thể nhắc đến là MedCLIP [MedCLIP], BioMedCLIP [BiomedCLIP] hay BioViL [BioViL]. Tuy nhiên, các mô hình này vẫn còn tồn tại nhiều hạn chế khi áp dụng vào thực tế lâm sàng, như sự khác biệt về đặc trưng giữa dữ liệu hình ảnh và dữ liệu văn bản, dữ liệu y tế thực tế thu thập được thường có số lượng hạn chế và mất cân bằng giữa các lớp bệnh, yêu cầu đặc biệt về thiết kế mô hình để tận dụng tối đa thông tin có sẵn và phải có khả năng.

Xuất phát từ những vấn đề trên, đề tài lựa chọn nghiên cứu xây dựng một hệ thống phân loại ảnh X-quang xương đa phương thức kết hợp đồng thời thông tin từ ảnh và văn bản nhằm khai thác ưu điểm của cả hai nguồn dữ liệu, và mở rộng hơn là bài toán phân loại đa lớp nhằm phản ánh thực tế lâm sàng, khi một bệnh nhân có thể đồng thời mắc nhiều tổn thương hoặc nhiều bệnh lý xương. Đồng thời, đề tài nghiên cứu các kỹ thuật thích nghi miền, học biểu diễn đa phương thức và học phân loại dựa trên mạng nguyên mẫu (prototypical network) nhằm nâng cao khả năng tổng quát của mô hình trong điều kiện dữ liệu y tế hạn chế, dữ liệu mất cân bằng và hướng tới khả năng nhận biết các trường hợp nằm ngoài phân phối dữ liệu huấn luyện. Kết quả nghiên cứu kỳ vọng sẽ góp phần nâng cao hiệu quả của các hệ thống hỗ trợ chẩn đoán bệnh lý xương và tạo tiền đề cho việc ứng dụng các mô hình thị giác-ngôn ngữ trong phân tích ảnh y khoa.

1.2 Động lực nghiên cứu

1.2.1 Vị trí của hệ thống phân loại khi áp dụng trong quy trình chẩn đoán thực tế

Trong thực hành lâm sàng, quá trình chẩn đoán bệnh lý xương thường bao gồm nhiều bước, từ khám lâm sàng, chỉ định chụp X-quang, phân tích hình ảnh, kết hợp với các thông tin bệnh án và đưa ra chẩn đoán xác định.

Sau khi ảnh X-quang được ghi nhận, bác sĩ chẩn đoán hình ảnh sẽ đánh giá các đặc điểm bất thường như vị trí tổn thương, hình thái gãy xương, dấu hiệu khối u hoặc các biến đổi bệnh lý khác. Đồng thời, bác sĩ cũng tham khảo các thông tin lâm sàng như triệu chứng, tiền sử bệnh, ngữ cảnh diễn biến chấn thương và các kết quả xét nghiệm để đưa ra kết quả đọc ảnh trước khi bác sĩ chính đưa ra chẩn đoán cuối cùng.

Hệ thống được đề xuất trong luận văn được thiết kế nhằm hỗ trợ bác sĩ chính ở giai đoạn phân tích ảnh X-quang. Cụ thể, hệ thống sử dụng đồng thời ảnh X-quang và dữ liệu văn bản (bao gồm các thông tin lâm sàng) để dự đoán một nhiều nhãn bệnh lý có thể xuất hiện trên cùng một bệnh nhân. Việc khai thác đồng thời hai nguồn dữ liệu giúp mô hình tận dụng các thông tin bổ sung mà chỉ riêng ảnh hoặc văn bản khó có thể biểu diễn đầy đủ.

Khác với các hệ thống chỉ thực hiện phân loại đơn nhãn, hệ thống trong luận văn được xây dựng cho bài toán phân loại đa lớp nhằm phản ánh tốt hơn thực tế lâm sàng, khi một bệnh nhân có thể đồng thời mắc nhiều tổn thương hoặc nhiều bệnh lý xương. Bên cạnh đó, hệ thống còn được định hướng tích hợp cơ chế phát hiện dữ liệu ngoài phân phối (Out-of-Distribution - OOD) nhằm cảnh báo khi gặp các trường hợp nằm ngoài phạm vi dữ liệu đã được huấn luyện. Trong các tình huống này, hệ thống sẽ không đưa ra dự đoán với độ tin cậy cao mà chuyển quyền quyết định cho bác sĩ chuyên môn, góp phần nâng cao tính an toàn khi ứng dụng trong thực tế.

Cần lưu ý rằng hệ thống được đề xuất không thay thế vai trò của bác sĩ mà đóng vai trò là công cụ hỗ trợ ra quyết định. Các kết quả dự đoán của mô hình cung cấp thông tin tham khảo giúp bác sĩ rút ngắn thời gian đọc phim, giảm nguy cơ bỏ sót tổn thương và nâng cao hiệu quả chẩn đoán, đặc biệt trong các cơ sở y tế có khối lượng bệnh nhân lớn hoặc thiếu bác sĩ chuyên khoa.

1.2.2 Ý nghĩa khoa học của đề tài

Một trong những đóng góp học thuật quan trọng và mang tính thực tiễn lâm sàng cao nhất của nghiên cứu này là việc phát hiện, phân tích

và đề xuất giải pháp triệt tiêu hoàn toàn hiện tượng rò rỉ nhãn trong các hệ thống ngôn ngữ trực quan y tế (Med-VLMs). Hầu hết các nghiên cứu VLM y học trước đây thường dựa trên một giả định phi thực tế rằng báo cáo kết quả X-quang hoàn chỉnh đã có sẵn để làm đầu vào cho mô hình AI đưa ra chẩn đoán. Tuy nhiên, trong quy trình lâm sàng thực tế, báo cáo X-quang này chỉ được bác sĩ chẩn đoán hình ảnh soạn thảo sau khi đã phân tích hình ảnh phim chụp; do đó, việc đưa nó vào quá trình suy luận của AI sẽ trực tiếp làm rò rỉ nhãn bệnh lý thông qua các từ khóa văn bản chuyên môn, làm mất đi hoàn toàn giá trị chẩn đoán thực tế của hệ thống hỗ trợ. Để giải quyết rào cản này, nghiên cứu đề xuất một quy trình huấn luyện hai pha bất đối xứng: khai thác báo cáo X-quang chuyên sâu để tối ưu hóa không gian căn chỉnh biểu diễn ở giai đoạn offline, nhưng sử dụng thông tin bệnh sử lâm sàng ban đầu (như triệu chứng sơ bộ, độ tuổi, giới tính, vị trí đau) ở giai đoạn suy luận online. Giải pháp này không chỉ ngăn chặn hiện tượng rò rỉ nhãn mà còn mô phỏng chính xác luồng công việc của bác sĩ trong thực tế, mở ra một hướng đi thực tiễn, tin cậy cao cho việc triển khai các hệ thống trí tuệ nhân tạo hỗ trợ chẩn đoán tại các cơ sở y tế.

Trọng tâm của nghiên cứu là khám phá và ứng dụng các kiến trúc mạng ngôn ngữ trực quan, cụ thể là BiomedCLIP [**BiomedCLIP**], nhằm tận dụng tri thức đã học từ các mô hình tiền huấn luyện trên dữ liệu y tế đa phương thức. Cách tiếp cận này góp phần mở rộng khả năng ứng dụng của các mô hình ngôn ngữ trực quan trong các bài toán y khoa có dữ liệu chuyên biệt.

Đồng thời, đề tài đi sâu vào việc phát triển hệ thống có khả năng phân loại dưới điều kiện dữ liệu hạn chế, mất cân bằng và có sự xuất hiện của các trường hợp ngoài phân phối, khi dữ liệu huấn luyện được đánh nhãn đầy đủ không khả dụng nhiều, việc bảo toàn tri thức gốc là một thách thức lớn và cũng như đảm bảo mô hình không phân nhãn cho một ca bệnh mới chưa từng xuất hiện trong dữ liệu của bệnh viện.

Đề tài góp phần giải thích kết quả phân loại bằng cách trực quan hóa các vùng ảnh X-quang mà mô hình tập trung khi đưa ra dự đoán, giúp bác sĩ hiểu được cơ sở ra quyết định của mô hình.

1.2.3 Ý nghĩa thực tiễn của đề tài

Đề tài xây dựng bộ dữ liệu ảnh X-quang xương được thu thập từ dữ liệu thực tế tại Bệnh viện Chấn thương Chỉnh hình Thành phố Hồ Chí Minh, đồng thời tiến hành chuẩn hóa, tinh lọc và xây dựng hệ thống nhân phục vụ cho bài toán phân loại đa lớp. Bộ dữ liệu này có giá trị tham khảo cho các nghiên cứu tiếp theo về phân tích ảnh X-quang xương và phát triển các mô hình trí tuệ nhân tạo trong lĩnh vực chẩn đoán hình ảnh ở thực tế.

Bên cạnh việc đưa ra một kết quả phân tích ảnh mang tính chất hỗ trợ chẩn đoán, mô hình còn được thiết kế để cung cấp các bản đồ nhiệt trực quan hóa trên ảnh X-quang, giúp bác sĩ hiểu được cơ sở ra quyết định của mô hình, từ đó nâng cao tính minh bạch và độ tin cậy khi triển khai trong thực tế lâm sàng.

Hệ thống được đề xuất hướng đến giải quyết các thách thức thường gặp trong dữ liệu thực tế ở lĩnh vực y tế nước nhà như số lượng mẫu gán nhãn hạn chế, mất cân bằng giữa các lớp bệnh khi một ca bệnh có tỉ trọng cao hơn và sự xuất hiện của các trường hợp ngoài phân phối khi gặp một căn bệnh mới. Việc xây dựng hệ thống đối phó được với các thách thức này giúp nâng cao khả năng tổng quát của mô hình, tăng độ tin cậy khi triển khai trong môi trường lâm sàng nước ta với dữ liệu y tế phục vụ huấn luyện còn hạn chế, cũng như giúp phát hiện một ca bệnh chưa từng xuất hiện trong dữ liệu của bệnh viện.

Bên cạnh với đối phó về thiếu hụt dữ liệu để đáp ứng thực tế, đề tài phát triển hệ thống hỗ trợ phân loại bệnh lý xương từ ảnh X-quang theo quy trình gần với thực tế lâm sàng. Trong quá trình huấn luyện, mô hình được khai thác thông tin từ báo cáo phân tích ảnh nhằm học được mối liên hệ giữa hình ảnh và tri thức chuyên môn. Khi đưa vào sử dụng, hệ thống chỉ yêu cầu ảnh X-quang kết hợp với các thông tin lâm sàng ban đầu như triệu chứng, cơ chế chấn thương hoặc chẩn đoán sơ bộ của bác sĩ để đưa ra dự đoán. Cách tiếp cận này mô phỏng quy trình ra quyết định của bác sĩ trong thực tế, góp phần nâng cao khả năng ứng dụng của hệ thống trong hỗ trợ chẩn đoán và giảm phụ thuộc vào các báo cáo chẩn đoán chuyên sâu vốn chưa có tại thời điểm tiếp nhận bệnh nhân.

1.3 Định nghĩa các khái niệm

Nhằm đảm bảo sự thống nhất trong quá trình nghiên cứu và trình bày, một số khái niệm cơ bản được định nghĩa như sau:

1.3.1 Thông tin lâm sàng


Thông tin lâm sàng là những dữ liệu thu thập trực tiếp qua quá trình bác sĩ thăm khám người bệnh, bao gồm việc khai thác bệnh sử và khám thực thể (nhìn, sờ, gõ, nghe) [Dorland2011]. Dữ liệu này mang tính chất định hướng ban đầu, giúp bác sĩ khoanh vùng tổn thương và đưa ra các quyết định chỉ định thăm khám chuyên sâu tiếp theo [Bickley2020_Bates].



Hình 1.1: Nguồn thông tin lâm sàng bao gồm khai thác bệnh sử và khám thực thể


1.3.2 Thông tin cận lâm sàng

Thông tin cận lâm sàng là các dữ liệu khách quan thu được từ việc áp dụng các trang thiết bị và kỹ thuật y khoa hiện đại (như hình ảnh X-quang, cắt lớp, hay xét nghiệm sinh hóa) [Dorland2011]. Nếu lâm sàng dùng để định hướng, thì cận lâm sàng cung cấp bằng chứng xác thực từ bên trong cơ thể để chẩn đoán chính xác bệnh lý.



Hình 1.2: Nguồn thông tin cận lâm sàng từ hình ảnh X-quang

Ngoài ra, thông tin cận lâm sàng còn bao gồm các báo cáo đọc ảnh của bác sĩ đọc ảnh, đây là những dữ liệu văn bản được trích xuất từ quá trình phân tích hình ảnh y tế, cung cấp các nhận định chuyên môn về tình trạng bệnh nhân dựa trên hình ảnh thu được [Bickley2020_Bates].



Hình 1.3: Nguồn thông tin từ báo cáo đọc ảnh X-quang

1.4 Giới thiệu bài toán

Bài toán được nghiên cứu trong đề tài là bài toán phân loại đa lớp ảnh X-quang sử dụng học sâu đa phương thức. Mục tiêu của hệ thống là dự đoán các loại bệnh hoặc tổn thương dựa trên đồng thời dữ liệu hình ảnh X-quang và thông tin văn bản lâm sàng liên quan.

- **Đầu vào (Input):** Hệ thống nhận vào các nguồn dữ liệu sau:

- Ảnh X-quang của bệnh nhân:

$$x^{img} \in \mathbb{R}^{H \times W \times C}$$

trong đó:

- * H, W : chiều cao và chiều rộng ảnh,
 - * C : số kênh màu của ảnh.
- Thông tin văn bản đầu vào được phân định theo hai giai đoạn:
 - (1) Báo cáo chẩn đoán hình ảnh chuyên sâu của bác sĩ được sử dụng ở giai đoạn huấn luyện offline để căn chỉnh không gian biểu diễn;
 - (2) Thông tin bệnh sử lâm sàng ban đầu (lời khai bệnh nhân, triệu chứng) được sử dụng ở giai đoạn suy luận online để

hỗ trợ chẩn đoán thực tế mà không gây rò rỉ nhãn.

$$x^{txt} = \{w_1, w_2, \dots, w_T\}$$

trong đó:

- * w_t : token thứ t ,
 - * T : số lượng token trong văn bản.
- Tập nhãn được định nghĩa trước:

$$\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$$

với K là số lớp bệnh cần phân loại.

- **Đầu ra (Output):** Hệ thống sinh ra:

- Các nhãn dự đoán cuối cùng, được sắp xếp theo thứ tự:

$$y^* = \arg \max_{k \in \{1, \dots, K\}} \hat{y}_k$$

- Bản đồ nhiệt trực quan hóa trên ảnh nhằm giải thích dự đoán của mô hình

1.4.1 Các thách thức trong bài toán

Mặc dù các mô hình học sâu đa phương thức đã đạt được nhiều kết quả tích cực, bài toán vẫn tồn tại nhiều thách thức cần được giải quyết:

- Tồn tại sự chênh lệch lớn giữa các bộ dữ liệu đa phương thức hiện có (thường là cặp ảnh X-quang và báo cáo đọc ảnh X-quang) so với luồng công việc thực tế lâm sàng (bao gồm ảnh chụp X-quang kết hợp với báo cáo tổng quát), làm hạn chế khả năng ứng dụng trực tiếp của các mô hình.
- Sự khác biệt về đặc trưng giữa dữ liệu hình ảnh và dữ liệu văn bản gây khó khăn cho quá trình học biểu diễn chung, yêu cầu một cơ chế dung hợp hiệu quả.

- Dữ liệu y tế thường có số lượng hạn chế và mất cân bằng giữa các lớp bệnh, đặt ra yêu cầu đặc biệt về thiết kế mô hình để tận dụng tối đa thông tin có sẵn.
- Trong thực tế lâm sàng, luôn có tỉ lệ xuất hiện những loại bệnh mới nằm ngoài dữ liệu huấn luyện, đặt ra yêu cầu về khả năng tổng quát hóa và thích ứng của mô hình.
- Khả năng giải thích của mô hình vẫn còn hạn chế, gây khó khăn cho việc triển khai trong thực tế lâm sàng.

1.4.2 Các hướng tiếp cận hiện có

Các nghiên cứu hiện nay chủ yếu tiếp cận bài toán theo ba hướng chính:

- Các phương pháp đa phương thức kết hợp dữ liệu hình ảnh và văn bản thông qua các chiến lược dung hợp đặc trưng nhằm khai thác mối tương quan giữa các phương thức dữ liệu.
- Các mô hình ngôn ngữ thị giác quy mô lớn được huấn luyện trước trên dữ liệu đa phương thức nhằm học biểu diễn chung giữa ảnh và văn bản.
- Các mô hình ngôn ngữ lớn đa phương thức được huấn luyện trên nhiều tác vụ khác nhau nhằm tăng khả năng suy luận, hiểu ngữ cảnh và hỗ trợ ra quyết định trong các bài toán y tế phức tạp.

Tuy đã đạt được nhiều kết quả khả quan, các nghiên cứu hiện nay phần lớn vẫn tiếp cận vấn đề một cách rời rạc. Chúng thường chỉ tập trung giải quyết riêng lẻ từng thách thức như tiền huấn luyện trên dữ liệu y khoa, học với ít mẫu (few-shot learning) hay phát hiện dữ liệu ngoài phân phối (out-of-distribution detection), mà thiếu đi một khuôn khổ thống nhất. Đáng chú ý nhất, các phương pháp này tồn tại một khoảng trống lớn so với thực tiễn: chúng gần như chỉ phụ thuộc vào cặp dữ liệu ảnh X-quang và báo cáo đọc ảnh X-quang. Việc bỏ qua các báo cáo lâm sàng tổng quát (nguồn thông tin bối cảnh mang tính quyết định) làm giảm đáng kể tính


ứng dụng của mô hình. Hơn nữa, việc khai thác mối tương quan ngữ nghĩa đa phương thức giữa hình ảnh và văn bản vẫn chưa đạt hiệu quả tối ưu, kéo theo những hạn chế về khả năng giải thích quá trình suy luận và ra quyết định.

1.5 Đối tượng và phạm vi nghiên cứu

1.5.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học sâu đa phương thức sử dụng đồng thời dữ liệu hình ảnh và văn bản trong bài toán phân loại ảnh X-quang. Nghiên cứu tập trung vào các thành phần chính của một hệ thống đa phương thức bao gồm bộ mã hóa ảnh, bộ mã hóa văn bản, mô-đun dung hợp dữ liệu và bộ phân loại.

Ngoài ra, đề tài cũng khảo sát các phương pháp tinh chỉnh tham số hiệu quả cho các mô hình đã được huấn luyện trước nhằm tận dụng tri thức nền và cải thiện hiệu năng trên tác vụ đích.



Hình 1.4: Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức

1.5.2 Phạm vi nghiên cứu

Đề tài tập trung nghiên cứu các bài toán phân loại trên ảnh X-quang kết hợp với thông tin văn bản lâm sàng. Dữ liệu văn bản được sử dụng bao gồm báo cáo đọc ảnh, thông tin lâm sàng.

Hệ thống được sử dụng với vai trò là một công cụ hỗ trợ chẩn đoán, không thay thế vai trò của bác sĩ trong quá trình ra quyết định.

Nghiên cứu chủ yếu sử dụng các bộ dữ liệu cặp ảnh – văn bản đã được công bố công khai cùng với bộ dữ liệu nội bộ được cung cấp thông qua hợp tác với bệnh viện tại Thành phố Hồ Chí Minh. Các bộ dữ liệu này được sử dụng nhằm đánh giá hiệu năng, khả năng tổng quát hóa và tính hiệu quả của mô hình đề xuất thông qua các độ đo phổ biến trong bài toán phân loại.

Đề tài không tập trung vào các bài toán khác như phát hiện đối tượng, phân đoạn ảnh hay sinh báo cáo y khoa tự động.

1.6 Bố cục luận văn

Khóa luận được trình bày một cách hệ thống và logic qua 5 chương, dẫn dắt người đọc từ tổng quan lý thuyết đến thực nghiệm chi tiết và kết luận:

Chương 1: Giới thiệu. Chương này cung cấp cái nhìn tổng quan về bối cảnh nghiên cứu, xác định rõ vấn đề cần giải quyết, mục tiêu, phương pháp tiếp cận và những đóng góp chính của đề tài. Đây là phần nền tảng định hướng cho toàn bộ nội dung khóa luận.

Chương 2: Các công trình nghiên cứu liên quan. Chương này tập trung hệ thống hóa các hướng tiếp cận đã được mô tả ở trên, làm tiền đề cho việc xây dựng giải pháp của khóa luận. Trọng tâm của chương là việc phân tích các kiến trúc mô hình thị giác - ngôn ngữ tiên tiến cùng các chiến lược dung hợp đặc trưng đa phương thức. Bên cạnh đó, các kỹ thuật tinh chỉnh tối ưu và phương pháp nhận diện dữ liệu ngoài phân phối cũng được xem xét toàn diện, từ đó thiết lập cơ sở lý thuyết vững chắc và định vị rõ ràng hướng giải quyết của đề tài so với các công trình đi trước.

Chương 3: Phương pháp đề xuất. Đây là chương trọng tâm mô tả chi tiết quy trình xây dựng hệ thống. Tại đây, nhóm sẽ trình bày cụ thể về kiến trúc mô hình Med-VLM được lựa chọn, quy trình xử lý dữ liệu đầu vào (cả ảnh và văn bản), thiết kế các hàm mất mát (loss functions), và chiến lược huấn luyện mô hình (training strategy). Các sơ đồ khối và thuật toán sẽ được mô tả chi tiết để minh họa cho giải pháp.

Chương 4: Thực nghiệm và Kết quả. Chương này trình bày về bộ

dữ liệu được sử dụng, thiết lập môi trường thực nghiệm và các chỉ số đánh giá (metrics) như Accuracy, F1-Score, AUC-ROC. Kết quả thực nghiệm sẽ được phân tích sâu, so sánh đối chiếu với các phương pháp khác để làm rõ ưu nhược điểm của mô hình đề xuất. Các phân tích sai số (error analysis) cũng được thực hiện để hiểu rõ hành vi của mô hình.

Chương 5: Kết luận và Hướng phát triển. Chương cuối cùng tổng kết lại những kết quả đạt được so với mục tiêu ban đầu, nhìn nhận thẳng thắn những hạn chế còn tồn tại của hệ thống và đề xuất các hướng nghiên cứu tiếp theo để hoàn thiện và mở rộng ứng dụng trong tương lai.

Chương 2

Các công trình nghiên cứu liên quan

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ mô tả tổng quan các nghiên cứu về các mô hình nền tảng, các kỹ thuật để tinh chỉnh mô hình và phương pháp phát hiện dữ liệu ngoài phân phối từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

2.1 Các mô hình nền tảng

2.1.1 Các mô hình xây dựng từ đầu

Sự kết hợp giữa dữ liệu cận lâm sàng và báo cáo lâm sàng, lịch sử bệnh lý đã tạo ra những bước tiến lớn trong việc cải thiện độ chính xác của các mô hình chẩn đoán chẩn đoán, đặc biệt là thông qua việc sử dụng văn bản để bù đắp những thiếu sót thông tin mà hình ảnh đơn thuần không thể cung cấp. Khởi điểm với các phương pháp sử dụng văn bản để cung cấp bối cảnh lâm sàng thiết yếu. Nghiên cứu của X. Mei [XMei] trong việc chẩn đoán COVID-19 là một minh chứng rõ nét: khi ảnh chụp CT ngực ở giai đoạn sớm có thể chưa biểu hiện bất thường, việc tích hợp thông tin lâm sàng thông qua mạng MLP với đặc trưng ảnh từ CNN đã giúp mô

hình nhận diện chính xác 68% số bệnh nhân dương tính mà các bác sĩ X-quang đã bỏ sót. Điều này khẳng định văn bản có khả năng định hướng chẩn đoán ngay cả khi tín hiệu hình ảnh còn mờ nhạt.

Không chỉ là dữ liệu bổ sung, văn bản còn được khai thác như một "tri thức tiên nghiệm" để hướng dẫn mô hình tập trung vào các vùng ảnh quan trọng. Mô hình TieNet [**TieNet**] đã mã hóa các báo cáo y tế và tích hợp các cơ chế chú ý đa cấp độ để làm nổi bật các từ mang ý nghĩa quan trọng, từ đó giống hàng chúng với các vùng ảnh tương ứng. Việc sử dụng văn bản làm tri thức dẫn đường này đã giúp TieNet cải thiện đáng kể kết quả phân loại bệnh lý, tăng trung bình 6% chỉ số AUC so với các mô hình chỉ dùng ảnh.

Mặc dù các mô hình như TransMed [**TransMed**] đã chứng minh sức mạnh của kiến trúc lai CNN-Transformer trong việc thiết lập sự phụ thuộc ở khoảng cách xa đối với dữ liệu đa phương thức, các phương pháp nổi đặc trưng truyền thống vẫn gặp hạn chế lớn do sự khác biệt về không gian véc-tơ và khoảng cách ngữ nghĩa giữa ảnh và văn bản.

Để giải quyết triệt để vấn đề này, IRENE [**IRENE**] đã loại bỏ cách tiếp cận trích xuất đặc trưng riêng lẻ. Thay vào đó, IRENE đưa tất cả dữ liệu (hình ảnh, báo cáo lâm sàng không cấu trúc, và dữ liệu cấu trúc) về một dạng token chung và sử dụng một mô hình Transformer duy nhất để học biểu diễn tổng thể. Việc sử dụng cơ chế chú ý đa phương thức hai chiều cho phép văn bản trực tiếp tương tác và giải thích các token của ảnh ở cấp độ cục bộ. Đóng góp của văn bản trong cấu trúc này mang tính quyết định: các thử nghiệm loại bỏ (ablation study) của IRENE chỉ ra rằng, việc thiếu vắng văn bản báo cáo bệnh lý (chief complaints) làm giảm 6% hiệu suất mô hình, và việc bỏ qua các kết quả xét nghiệm làm giảm thêm 4%.

Nhìn chung, những nghiên cứu này minh chứng rằng sự đóng góp của văn bản đã tiến hóa từ việc chỉ là một véc-tơ thông tin ghép nối thêm, trở thành một thành phần cốt lõi có khả năng giống hàng ngữ nghĩa và định hướng sự chú ý, giúp các mô hình học sâu đưa ra chẩn đoán hình ảnh y khoa toàn diện và chính xác hơn.

STT	Tên phương pháp	Nguyên lý
1	TieNet (2018)	Sử dụng các báo cáo y tế như một tri thức tiên nghiệm kết hợp với hình ảnh X-quang để phân loại bệnh lý lồng ngực và tạo báo cáo y khoa tự động. Mô hình tích hợp các cơ chế chú ý đa cấp để làm nổi bật các từ mang ý nghĩa quan trọng và các vùng ảnh tương ứng
2	X. Mei (2020)	Tích hợp các phát hiện trên ảnh chụp CT ngực với các thông tin lâm sàng nhằm chẩn đoán nhanh bệnh nhân nhiễm COVID-19 ở giai đoạn sớm, khi mà ảnh CT có thể chưa có biểu hiện bất thường
3	TransMed (2021)	Kết hợp sức mạnh của CNN trong việc trích xuất đặc trưng cục bộ và của Transformer trong việc thiết lập sự phụ thuộc ở khoảng cách xa để tận dụng mối quan hệ giữa các phương thức/chuỗi trên ảnh y khoa.
4	IRENE (2023)	Thay vì dùng các mô hình riêng biệt cho từng loại dữ liệu, chỉ sử dụng một Transformer duy nhất xử lý đồng thời dữ liệu hình ảnh, văn bản. Nguyên lý mấu chốt là trực tiếp khai thác mối liên kết nội bộ của từng phương thức và giữa các phương thức khác nhau.

Bảng 2.1: Bảng tổng hợp nguyên lý của các mô hình kết hợp ngôn ngữ - ảnh nổi bật

STT	Tên phương pháp	Kiến trúc mô hình			
		Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	TieNet (2018)	ResNet50	word2vec	Feature-level fusion	Fully Connected
2	X. Mei (2020)	Inception-ResNet-v2	MLP	Feature-level fusion	MLP
3	TransMed (2021)	2D CNN (ResNet18 đến 152)	N/a	Feature-level fusion	Fully Connected
4	IRENE (2023)	Convolution layer	Pretrained BERT	Feature-level fusion	MLP

Bảng 2.2: Bảng tổng hợp phương pháp của các mô hình kết hợp ngôn ngữ - ảnh nổi bật

2.1.2 Mô hình ngôn ngữ trực quan y khoa (Med-VLMs)

Các mô hình ngôn ngữ trực quan đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu (thường cố gắng dung hợp dữ liệu thô thành một khối thống nhất), Med-VLMs chú trọng vào việc đối chiếu và liên kết chặt chẽ ngữ nghĩa giữa hình ảnh và ngôn ngữ tự nhiên. Cụ thể, kiến trúc của chúng thường kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp

phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này khớp với nhau. Lúc này, bộ phân loại không gán nhãn theo cách truyền thống mà đóng vai trò là một cơ chế đo lường mức độ tương đồng. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Để đạt được khả năng trên, các nghiên cứu tiền huấn luyện Med-VLMs hiện nay đang phát triển chủ yếu theo ba hướng: học tương phản, học có che giấu và tích hợp tri thức y khoa (chi tiết tổng hợp được trình bày tại các Bảng 2.3, 2.4, 2.5).

Thứ nhất, **học tương phản (Contrastive Learning)** là chiến lược được ứng dụng rộng rãi nhất, tiêu biểu với các mô hình như ConVIRT [ConVIRT], GLoRIA [GLoRIA], MedCLIP [MedCLIP] và BiomedCLIP [BiomedCLIP]. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau ở mức độ cục bộ lẫn toàn cục. Phương pháp này đem lại hiệu năng ấn tượng; ví dụ, BiomedCLIP [BiomedCLIP] (huấn luyện trên 15 triệu cặp dữ liệu) đạt độ chính xác phân loại 83%, trong khi ConVIRT [ConVIRT] đạt 90,3% trên bộ dữ liệu COVIDx. Mặc dù có ưu điểm vượt trội là khả năng học biểu diễn không cần gán nhãn thủ công, học tương phản vẫn bộc lộ hạn chế về việc tiêu tốn tài nguyên tính toán lớn và rủi ro xảy ra hiện tượng âm tính giả (đẩy xa các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý).

Thứ hai, **học có che giấu (Masked Learning)** là hướng đi tập trung vào mục tiêu tái tạo dữ liệu, với các đại diện nổi bật như MRM [MRM] và MedViLL [MedViLL]. Bằng cách ẩn ngẫu nhiên các vùng ảnh hoặc từ ngữ trong báo cáo y khoa, kiến trúc này buộc mô hình phải dự đoán và khôi phục phần thông tin bị khuyết. Hướng tiếp cận này thể hiện ưu thế rõ rệt trong các môi trường khan hiếm dữ liệu; điển hình là MRM [MRM] đạt mức 92,7% AUC chỉ với 10% dữ liệu từ tập RSNA. Tuy nhiên, rào cản chính của phương pháp này nằm ở việc phụ thuộc vào nguồn dữ liệu đã được ghép cặp sẵn từ trước, cộng với độ phức tạp tính toán cao của quá

trình khôi phục điểm ảnh/token.

Thứ ba, **tích hợp tri thức y khoa (Knowledge Integration)** ra đời nhằm giải quyết những đặc thù phức tạp của ngôn ngữ lâm sàng. Các mô hình như MedKLIP [MedKLIP], BioViL [BioViL], BioViL-T [BioViL-T] và KAD [KAD] tận dụng đồ thị tri thức (như RadGraph) hoặc dữ liệu chuỗi thời gian để cung cấp tín hiệu giám sát chi tiết về cả loại và vị trí bệnh lý. Cách tiếp cận này giúp giải quyết triệt để sự mơ hồ của các từ vựng diễn tả tiến triển bệnh (ví dụ: "cải thiện", "xấu đi"). Về mặt hiệu năng, KAD [KAD] đạt 0.966 AUC trên tập PadChest ở thiết lập không mẫu (zero-shot), còn BioViL-T [BioViL-T] đạt độ chính xác 67,4% trong bài toán phân loại tiến triển bệnh. Dù vậy, các phương pháp này chưa loại bỏ hoàn toàn được hiện tượng âm tính giả và rất dễ gặp sai số nếu nhân chẩn đoán thực tế nằm ngoài cơ sở tri thức đồ thị gốc.

STT	Tên phương pháp	Phân loại	Nguyên lý
1	ConVIRT (2020)	Học tương phản	Tối ưu bộ mã hoá ảnh và văn bản bằng cách kéo các cặp đặc trưng ảnh-văn bản giống nhau lại gần nhau và đẩy các cặp đặc trưng ảnh-văn bản khác nhau ra xa
2	GLoRIA (2021)	Học tương phản	Dùng hai hàm mất mát global contrastive để kéo các cặp đặc trưng ảnh-văn bản, trong khi đó hàm mất mát local contrastive học cách căn chỉnh chi tiết của các vùng trong ảnh và các từ trong câu
3	MedCLIP (2022)	Học tương phản	Đề xuất cơ chế tách cặp và trích xuất tri thức, và đề xuất hàm mất mát Semantic Matching nhằm giải quyết vấn đề false negative
4	BiomedCLIP (2023)	Học tương phản	Có cơ chế tương tự như CLIP nhưng được tiền huấn luyện với bộ dữ liệu PMC-15M
5	MRM (2023)	Học có che giấu	Ẩn ngẫu nhiên các thông tin trong văn bản và các vùng trong ảnh để cho mô hình dự đoán lại ảnh và văn bản hoàn chỉnh.
6	MedViLL (2022)	Học có che giấu	Đề xuất một kiến trúc dựa trên BERT kết hợp với một mặt nạ chú ý mới được đề xuất (BAR) cho phép ảnh tương tác tự do với văn bản trong các tác vụ hiểu, đồng thời đảm bảo tính tự hồi quy cho các token trong văn bản trong các tác vụ sinh
7	BioViL (2022)	Tích hợp kiến thức y khoa	Đề xuất một bộ mã hoá văn bản CXR-BERT được tối ưu cho ảnh X-quang, duy trì hàm mất mát MLM để giúp mô hình giữ lại được các kiến thức văn bản trong quá trình căn chỉnh với ảnh
8	BioViL-T (2023)	Tích hợp kiến thức y khoa	Sử dụng các ảnh X-quang từ trước kết hợp với ảnh hiện tại để học được các đặc trưng không gian, thời gian từ đó giải thích cho các từ vựng như "cải thiện" giúp giảm đi sự mơ hồ trong báo cáo
9	MedKLIP (2023)	Tích hợp kiến thức y khoa	Đề xuất một mô-đun trích xuất bộ ba và cơ chế mã hoá tăng cường tri thức, từ đó tạo ra biểu diễn tốt hơn cho văn bản
10	KAD (2023)	Tích hợp kiến thức y khoa	Tích hợp kiến thức y khoa vào quá trình tiền huấn luyện để giúp mô hình học các biểu diễn có ý nghĩa hơn

Bảng 2.3: Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Mục tiêu tiền huấn luyện	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	CL	GCL	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	CL	LCL, GCL	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	CL	GCL	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	CL	GCL	ViT-Base	PubMedBERT	Contrastive Alignment	N/a
5	MRM (2023)	MP	MIM, MLM	Kiến trúc giống ViT	WordPiece	Global Context Injection	Văn bản: Transformer; Hình ảnh: Fully Connected
6	MedViLL (2022)	HA	MLM, ITM	ResNet50	BERT	Cross-modal Self-Attention	Multi-Layer Perceptron
7	BioViL (2022)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
8	BioViL-T (2023)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
9	MedKLIP (2023)	CL	LCL	ResNet50	ClinicalBERT	Knowledge-enhanced Alignment	Contrastive head, Cross-Entropy head
10	KAD (2023)	HA	CL, Disease Diagnosis Prediction	ResNet50, ViT-Base	PubMedBERT	Contrastive Alignment	Disease Query Network

Bảng 2.4: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;

STT	Tên phương pháp	Bộ dữ liệu tiền huấn luyện	Hiệu năng			
			Tác vụ	Bộ dữ liệu đánh giá	Độ đo	Kết quả
1	ConVIRT (2020)	MIMIC-CXR, Private Bone image	- Phân loại ảnh - Phân loại ít mẫu	RSNA Pneumonia, CheXpert, COVIDx, MURA	AUC, Accuracy	- Phân loại ít mẫu: RSNA (1%): 88.8% AUC, (10%): 91.5% AUC; CheXpert (1%): 87.0% AUC, (10%): 88.1% AUC; MURA (1%): 81.3% AUC, (10%): 86.5% AUC - Phân loại ảnh: RSNA: 92.7% AUC, CheXpert: 88.1% AUC, MURA: 89.0% AUC; COVIDx 90.3% ACC
2	GLoRIA (2021)	CheXpert	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	CheXpert, RSNA Pneumonia	AUROC	- Phân loại không mẫu: CheXpert 5x200: 0.61 ACC, 0.67 F1; RSNA: 0.70 ACC, 0.58 F1; - Phân loại ít mẫu: CheXpert (1%): 86.6 AUC, (10%): 87.8 AUC, RSNA (1%): 86.1 AUC, (10%): 88.0 AUC - Phân loại ảnh: CheXpert: 88.1 AUC, RSNA: 88.6 AUC
3	MedCLIP (2022)	MIMIC-CXR, CheXpert	- Phân loại ảnh - Phân loại không mẫu	MIMIC-5x200, COVID, RSNA Pneumonia	Mean Accuracy	- Phân loại không mẫu: CheXpert-5x200: 0.5942 ACC; MIMIC-5x200: 0.5430 ACC; COVID: 0.8472 ACC; RSNA: 0.7682 ACC - Phân loại ảnh: CheXpert-5x200: 0.5960 ACC; MIMIC-5x200: 0.5650 ACC; COVID: 0.7890 ACC; RSNA: 0.8075 ACC
4	BiomedCLIP (2023)	PMC-15M	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PCam, LC25000 (Lung, Colon), TCGA-TIL, RSNA Pneumonia	AUC, Accuracy	- Phân loại không mẫu: PCam: 73.41% ACC; LC25000 Lung 65.23% ACC; LC25000 Colon 92.98%; RSNA 78.95%; TCGA-TIL: 67.04% - Phân loại ít mẫu: PCam (1%): 82% ACC, (10%): 83%; RSNA (1%): 77% ACC, (10%): 82% ACC - Phân loại ảnh: PCam: 83% ACC, RSNA: 83% ACC
5	MRM (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu	CheXpert, NIH ChestX-ray, RSNA Pneumonia, COVID-19 Image Data Collection	AUC, Accuracy	- Phân loại ít mẫu: CheXpert (1%): 88.5 AUC, (10%): 88.5 AUC; RSNA (1%): 91.3 AUC, (10%): 92.7 AUC; NIH ChestX-ray (1%): 79.4 AUC, (10%): 84.0 AUC - Phân loại ảnh: CheXpert: 88.7 AUC, RSNA 93.3, NIH ChestX-ray: 85.9, COVID-19: 85.8
6	MedViLL (2022)	MIMIC-CXR	- Phân loại chẩn đoán	MIMIC-CXR, Open-I	Micro-averaged AUROC, Micro-averaged F1 score	- Phân loại ảnh: MIMIC-CXR: 0.980 avg AUROC, 0.839 F1; Open-I: 0.892 avg AUROC, 0.407 F1
7	BioViL (2022)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	RSNA Pneumonia	Accuracy, F1-score, AUROC, Sensitivity Specificity.	- Phân loại không mẫu: RSNA: 0.732 ACC, 0.831 AUC; ChestX-ray14: 0.6912 AUC - Phân loại ít mẫu: RSNA (1%): 0.805 ACC, 0.881 AUC; (10%): 0.812 ACC, 0.884 AUC - Phân loại ảnh: RSNA: 0.822 ACC, 0.891 AUC
8	BioViL-T (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu - Phân loại ảnh tiến triển	MS-CXR-T, RSNA Penumonia, Chest ImaGenome	Macro-Accuracy, Accuracy, F1, AUROC.	- Phân loại Tiến triển: MS-CXR-T: 67.4% Acc - Phân loại không mẫu: RSNA: 0.805 ACC, 0.871 AUC - Phân loại ít mẫu: RSNA (1%): 0.814 ACC, 0.890 AUC
9	MedKLIP (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại không mẫu	ChestX-ray14, RSNA Pneumonia, SIIM-ACR Pneumothorax, COVIDx CXR-2, COVID Rural, Edema Severity	AUC, F1-score, Accuracy.	- Phân loại không mẫu: RSNA: 0.8694 AUC, 0.6342 F1; SIIM-ACR: 0.8924 AUC, 0.6833 F1; ChestX-ray14: 0.7676 AUC, 0.2525 F1; COVID-19: 0.7396 AUC, 0.7670 F1 - Phân loại ít mẫu: ChestX-ray14 (1%): 0.7721 AUC, (10%): 0.7894; RSNA (1%): 0.8731 AUC, (10%): 0.8799 AUC - Phân loại mẫu: ChestX-ray14: 0.8323 AUC, RSNA 0.8931
10	KAD (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PadChest, NIH ChestXray14, CheXpert, ChestX-Det	AUC, F1-Score, MCC	- Phân loại không mẫu: PadChest: 0.966 AUC; CheXpert: 0.905 AUC, 0.647 F1, 0.589 MCC - Phân loại ít mẫu: ChestXray-14 (1%): 0.78 AUC, 0.31 F1; (10%): 0.80 AUC, 0.33 F1 - Phân loại ảnh: ChestXray-14: 0.82 AUC, 0.34 F1

Bảng 2.5: Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

2.1.3 Các mô hình ngôn ngữ lớn y khoa đa phương thức

Trong thời gian gần đây, với sự phát triển của các mô hình ngôn ngữ lớn được huấn luyện trên những tập dữ liệu rất lớn phục vụ cho rất nhiều tác vụ khác nhau, các mô hình này đang thể hiện sự ảnh hưởng và đa dụng trong lĩnh vực y tế với độ chính xác rất tốt khi chỉ học ít mẫu hoặc không mẫu.

Med-Flamingo [**moor_2023_medflamingo**] là mô hình đầu tiên có khả năng học ít mẫu chuyên dụng cho y tế, thông qua hội thoại tự nhiên để hỗ trợ chẩn đoán. Theo sau đó, LLaVA-Med [**li_2023_llavamed**] là mô hình chuyển đổi khả năng thực hiện theo chỉ dẫn (instruction-following) từ miền tổng quát sang lĩnh vực y sinh bằng cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn với 600.000 cặp, với dữ liệu hội thoại tạo ra từ chú thích ảnh y khoa được tạo ra bằng cách sử dụng GPT-4. Phương pháp này đã đề xuất quy trình huấn luyện 2 bước: (1) Căn chỉnh khái niệm; (2) Tinh chỉnh chỉ dẫn đầy đủ; 2 bước này tương ứng với giai đoạn học và suy luận. Kết quả thể hiện khả năng suy luận vượt trội trên dữ liệu chưa từng thấy.

Med-Palm M [**MED-PALM-M**] là mô hình của Google, đánh dấu bước tiến từ các mô hình đơn nhiệm sang đa nhiệm quy mô lớn, có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì sử dụng các mô hình chuyên biệt cho từng tác vụ. Gần đây hơn, SkinGPT-4 [**SkinGPT-4**] là hệ thống chẩn đoán da liễu tương tác đầu tiên sử dụng LLM quy mô lớn với độ chính xác cao, đã kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM), tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Dù đưa đến các phương pháp có độ chính xác cao đến rất cao trong nhiều tác vụ cùng việc hỗ trợ trong việc giao tiếp với mô hình, kích cỡ và chi phí huấn luyện (Med-Flamingo có đến 9 tỷ thông số) để vận hành các mô hình ngôn ngữ lớn đa phương thức là một vấn đề lớn, đi kèm với vấn đề ảo giác có thể gặp phải khi đối mặt với dữ liệu mới hoặc những câu hỏi phức tạp. Ngoài ra nếu yêu cầu một độ chính xác cao - một yêu cầu quan

trọng trong lĩnh vực y tế trong một tác vụ cụ thể thì đây không phải một cách tiếp cận tốt cho bài toán này.

STT	Tên phương pháp	Nguyên lý
1	Med-Flamingo (2023)	Huấn luyện (từ nền tảng OpenFlamingo-9B) trên các dữ liệu văn bản và hình ảnh y tế. Mô hình có khả năng học theo ngữ cảnh để sinh ra văn bản tạo các báo cáo, giải thích y khoa hoặc trả lời câu hỏi mở.
2	LLaVA-Med (2023)	Chuyển đổi khả năng theo sát chỉ dẫn (instruction-following) từ miền tổng quát sang miền y sinh bằng cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn.
3	Med-PaLM M (2023)	Xây dựng một hệ thống AI y sinh tổng quát (Generalist Biomedical AI) có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì các mô hình chuyên biệt cho từng tác vụ
4	SkinGPT-4 (2024)	Kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM). Mục tiêu là tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Bảng 2.6: Bảng tổng hợp nguyên lý của các mô hình ngôn ngữ lớn đa phương thức

STT	Tên phương pháp	Phương pháp			
		Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	Med-Flamingo (2023)	Frozen CLIP ViT	LLaMA-7B	Intermediate fusion	LLaMA Decoder
2	LLaVA-Med (2023)	CLIP ViT-L/14	LLaMA	Projection Matrix	LLM (Vicuna)
3	Med-PaLM M (2023)	ViT (4B - 22B)	PaLM	Multimodal embedding	PaLM
4	SkinGPT-4 (2024)	Vision Transformer	GPT-4	Linear alignment	LLaMA-2-13B

Bảng 2.7: Bảng tổng hợp phương pháp của các mô hình ngôn ngữ lớn đa phương thức

Dựa trên sự phân tích các ưu và nhược điểm từ những khảo sát trên, hướng tiếp cận đề xuất trong nghiên cứu này được thiết kế có chọn lọc nhằm tối ưu hóa hiệu năng và chi phí:

- **Kế thừa BiomedCLIP [BiomedCLIP]:** Tận dụng sức mạnh của các bộ mã hóa đã được huấn luyện với chất lượng cao.
- **Không áp dụng học tương phản & học có che giấu:** Khó khắc phục rào cản về tài nguyên tính toán lớn và giảm thiểu rủi ro gặp phải hiện tượng âm tính giả.

- **Tích hợp tri thức từ UMLS (tương tự MedKLIP [MedKLIP]):**
Sử dụng để làm giàu thêm tri thức trong các báo cáo lâm sàng.

2.2 Các kỹ thuật tinh chỉnh mô hình

Sự xuất hiện của các Mô hình Nền tảng (Foundation Models) nói chung và Mô hình Ngôn ngữ - Thị giác Y sinh (Med-VLMs) nói riêng đã mang lại một nền tảng tri thức đa phương thức khổng lồ. Tuy nhiên, để triển khai hiệu quả các mô hình này vào các bài toán lâm sàng đặc thù — chẳng hạn như phát triển hệ thống phân loại ảnh y khoa chỉnh hình kết hợp dữ liệu lâm sàng — quá trình chuyển giao tri thức là bắt buộc.

Trước đây, hai chiến lược phổ biến nhất là tinh chỉnh toàn phần (Full Fine-tuning) và dò tuyến tính (Linear Probing). Tinh chỉnh toàn phần cập nhật lại toàn bộ tham số của mô hình gốc, mang lại khả năng thích ứng cao với miền dữ liệu mới nhưng đòi hỏi chi phí tính toán, bộ nhớ khổng lồ. Hơn nữa, trên các tập dữ liệu y tế ghép cặp thường khan hiếm, phương pháp này rất dễ dẫn đến hiện tượng "quên thảm khốc" (catastrophic forgetting), làm mất đi tri thức tổng quát đã được tiền huấn luyện. Ngược lại, dò tuyến tính đóng băng toàn bộ mạng nơ-ron gốc và chỉ huấn luyện một lớp phân loại duy nhất ở cuối. Dù tiết kiệm tài nguyên đáng kể, dò tuyến tính lại hạn chế khả năng tinh chỉnh các biểu diễn sâu của mô hình, dẫn đến hiệu suất thường dưới mức tối ưu khi sự chênh lệch phân phối (domain shift) giữa dữ liệu gốc và dữ liệu y tế là quá lớn.

Để giải quyết bài toán đánh đổi giữa hiệu năng và chi phí tính toán, Tinh chỉnh Hiệu quả Tham số (Parameter-Efficient Fine-Tuning - PEFT) đã nổi lên như một giải pháp thay thế lý tưởng. Kỹ thuật này chỉ cập nhật hoặc thêm mới một lượng rất nhỏ tham số, giúp tiết kiệm tài nguyên, rút ngắn thời gian huấn luyện và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các phương pháp PEFT được chia thành ba hướng tiếp cận chính:

2.2.1 Tinh chỉnh sử dụng câu nhắc (Prompt Tuning)

Hướng tiếp cận này chèn thêm các tham số (vector) có thể học được vào không gian đầu vào của mô hình (thị giác hoặc văn bản) mà không thay đổi cấu trúc mạng bên trong.

- **Điểm mạnh:** Tiết kiệm tham số tối đa, bảo toàn nguyên vẹn tri thức của mô hình gốc, đặc biệt hiệu quả trong các kịch bản học ít mẫu (few-shot) hoặc không mẫu (zero-shot).
- **Điểm yếu:** Việc tối ưu hóa khó khăn do không gian biểu diễn bị giới hạn ở đầu vào, nhạy cảm với cách khởi tạo, và chiếm dụng một phần độ dài của chuỗi đầu vào (sequence length context).

Trong lĩnh vực y tế, các phương pháp như CITE [**CITE**], FPT [**FPT**] hay PLIP [**PLIP**] khai thác đặc trưng thị giác kết hợp với tri thức lâm sàng, cho thấy hiệu quả vượt trội ngay cả khi thiếu hụt dữ liệu (ví dụ: PLIP đạt 0.896 AUC chỉ với 5% dữ liệu PanNuke). Nhằm giải quyết khó khăn khi thiết kế thủ công, MedPrompt [**MedPrompt**] và UniDCP [**UniDCP**] tự động sinh câu nhắc động dựa trên ngữ cảnh ảnh để xử lý đa tác vụ. Gần đây, việc tích hợp Mô hình ngôn ngữ Lớn (LLM) qua ViP [**ViP**], CILMP [**CLIMP**] và BiomedCoOp [**BiomedCoOp**] giúp tạo sinh các câu nhắc ngữ nghĩa sâu sắc, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản.

2.2.2 Tinh chỉnh bộ điều hợp (Adapter Tuning)

Thay vì can thiệp ở không gian đầu vào, phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ (adapters) vào giữa các lớp kiến trúc của mạng học sâu (ví dụ: giữa các lớp Transformer).

- **Điểm mạnh:** Tính mô-đun hóa cao, dễ dàng thêm/bớt các adapter cho các tác vụ khác nhau mà không can thiệp vào tham số gốc, dễ hội tụ hơn so với Prompt Tuning.

- **Điểm yếu:** Việc chèn thêm các lớp mạng vật lý làm tăng độ trễ suy luận (inference latency), hạn chế khả năng triển khai trên các hệ thống đòi hỏi thời gian thực.

Diễn hình cho hướng đi này, CLIPath [**CLIPath**] sử dụng kết nối thặng dư để giảm khoảng cách miền trên dữ liệu nhỏ. FTB [**FTB**] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức. Ở hướng bán giám sát, mô hình MedUnA [**MedUnA**] dùng LLM tạo nhãn giả và tinh chỉnh không giám sát bộ điều hợp trên ảnh chưa gán nhãn, giúp mô hình thích ứng tốt mà không thay đổi trọng số.

2.2.3 Tinh chỉnh chọn lọc (Selective Tuning)

Hướng đi này tối ưu hóa kiến trúc bằng cách không thêm bất kỳ tham số mới nào, mà chỉ chọn lọc ra một lượng nhỏ các tham số (hoặc ma trận trọng số) quan trọng nhất của mô hình gốc để cập nhật.

- **Điểm mạnh:** Không làm thay đổi kiến trúc mô hình, hoàn toàn không gây tăng độ trễ (zero inference latency) do tham số cập nhật được hợp nhất trực tiếp vào trọng số gốc.
- **Điểm yếu:** Đòi hỏi phương pháp heuristic phức tạp để xác định chính xác các tham số nào ảnh hưởng lớn nhất đến hiệu năng của tác vụ mục tiêu.

Về ứng dụng thực tiễn, TransMed [**TransMed**] kết hợp LLM để chuyển đổi nhãn bệnh thành mô tả chi tiết, trong khi SH-PEFT [**SH-PEFT**] chỉ tìm và cập nhật các trọng số quan trọng nhất trên bộ mã hóa thị giác. Nổi bật nhất trong nhóm hiệu quả là sự xuất hiện của các cơ chế thích ứng hạng thấp như LoRA (được LCBB [**LCBB**] áp dụng), giúp bám sát hiệu năng của tinh chỉnh toàn phần (đạt 93.1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn) nhưng giảm thiểu tối đa chi phí.

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	CITE (2023)	Parameter-efficient fine tuning	Visual prompt tuning	CLIP ViT-Base, ImageNet-21k ViT-Base, INTERN ViT-Base	BioLinkBERT-large, BioBERT-large, Kế thừa CLIP	Contrastive Alignment	N/a
2	UniDCP (2023)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	CLIP ViT	RoBERTa	Cross Attention, Contrastive Alignment	N/a
3	ViP (2024)	Parameter-efficient fine tuning	Textual prompt tuning	ViT-Base	Kế thừa CLIP	Cross Attention, Contrastive Alignment	N/a
4	PLIP (2024)	Parameter-efficient fine tuning	Visual prompt tuning, Efficient Selective tuning	ViT-Base	Kế thừa CLIP	Concatenate	N/a
5	FPT (2024)	Parameter-efficient fine tuning	Visual prompt tuning	ViT-Base	N/a	Cross Attention	N/a
6	MedPrompt (2024)	Parameter-efficient fine tuning	Textual prompt tuning	Swin Transformer, ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
7	CILMP (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	ViT-Base	Kế thừa CLIP	Hadamard Product, Concatenate	N/a
8	BiomedCoOp (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	Kế thừa BiomedCLIP	Kế thừa BiomedCLIP	Contrastive Alignment	N/a
9	CLIPath (2023)	Parameter-efficient fine tuning	Adapter tuning	ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
10	FTB (2024)	Parameter-efficient fine tuning	Adapter tuning	ResNet autoencoder, DINOv2-small, DINOv2-base	BERT, BioBERT, ClinicalBERT, CXR-BERT, PubMedBERT	Cross Attention	N/a
11	MedUnA (2024)	Parameter-efficient fine tuning	Adapter tuning	ViT-Base, MedCLIP-Swin	Kế thừa CLIP, MedCLIP	No Fusion	N/a
12	TransMed (2023)	Parameter-efficient fine tuning	Direct Selective tuning	Swin Transformer, ViT-Base	BERT, LLM/GPT-4	Contrastive Alignment	N/a
13	SH-PEFT (2024)	Parameter-efficient fine tuning	Direct Selective tuning	ViT-Base	Kế thừa CLIP	No Fusion	N/a
14	LCBB (2024)	Parameter-efficient fine tuning	Efficient Selective tuning	Kế thừa MAE, MRM	Kế thừa MAE, MRM	Kế thừa MAE, MRM	N/a

Bảng 2.8: Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan

2.2.4 Cơ sở lựa chọn kỹ thuật LoRA cho hệ thống phân loại y khoa đa phương thức

Trong định hướng xây dựng một hệ thống phân loại ảnh y khoa hiệu năng cao kết hợp với dữ liệu lâm sàng, bài toán đặt ra không chỉ là tính chính xác trên các vùng tổn thương đặc thù (như xương khớp), mà còn là tính khả thi khi triển khai các kiến trúc khổng lồ của VLMs. Việc sử dụng toàn bộ mô hình gốc vừa bất khả thi về mặt phần cứng, vừa đối mặt với rủi ro mất đi biểu diễn đặc trưng ngôn ngữ - hình ảnh vốn có. Do đó, kỹ thuật LoRA (Low-Rank Adaptation) được lựa chọn như một phương pháp PEFT cốt lõi với các lý do sau:

1. **Hiệu quả tham số và tài nguyên:** LoRA đóng băng toàn bộ trọng số của mô hình tiền huấn luyện, đồng thời tiêm các ma trận phân rã hạng thấp (low-rank decomposition matrices) vào mạng nơ-ron (chủ

yếu là các khối Attention). Điều này giúp giảm số lượng tham số cần huấn luyện xuống hàng vạn lần và tối ưu hóa VRAM yêu cầu, cho phép tinh chỉnh các mô hình VLM kích thước lớn ngay cả khi nguồn lực máy tính bị hạn chế.

2. Loại bỏ hoàn toàn độ trễ suy luận (Zero Inference Latency):

Khác với Adapter Tuning chèn thêm các lớp ẩn vật lý làm chậm tốc độ xử lý, các ma trận trọng số học được của LoRA có thể được cộng gộp (merge) trực tiếp vào các ma trận trọng số gốc của VLM khi hoàn tất huấn luyện. Đặc tính này mang lại độ trễ tương đương với mô hình gốc, cực kỳ quan trọng đối với các hệ thống hỗ trợ chẩn đoán thời gian thực.

3. Cân bằng giữa thích ứng và bảo toàn tri thức: Ảnh y khoa đòi hỏi mô hình phải nhận diện các đặc trưng họa tiết tinh tế mà mô hình miền tự nhiên có thể bỏ qua. LoRA cho phép mô hình bám sát dữ liệu thị giác y tế đặc thù trong khi không phá vỡ các cấu trúc tri thức đa phương thức tổng quát, tránh hiện tượng quá khớp (overfitting) thường thấy khi full fine-tuning trên các tập dữ liệu nhỏ.

Tóm lại, thông qua việc áp dụng LoRA, hệ thống được đảm bảo tính linh hoạt, tốc độ đáp ứng cao và khả năng khai thác toàn diện sự kết hợp phức tạp giữa mô tả y khoa và hình ảnh X-quang, đáp ứng trọn vẹn yêu cầu của một bài toán y tế chuyên sâu.

2.3 Các phương pháp phát hiện dữ liệu ngoài phân phối

Bài toán phát hiện dữ liệu ngoài phân phối (OOD detection) đóng vai trò then chốt trong việc đảm bảo tính an toàn và độ tin cậy của các hệ thống trí tuệ nhân tạo, đặc biệt trong các ứng dụng rủi ro cao như chẩn đoán hình ảnh y khoa. Dựa trên cơ chế hoạt động và cách biểu diễn dữ liệu, các phương pháp OOD hiện nay có thể được phân loại thành các nhóm chính sau đây.

2.3.1 Phương pháp dựa trên đầu ra của mô hình (Post-hoc Methods)

Nhóm phương pháp này tận dụng trực tiếp đầu ra (logits hoặc probabilities) của một mạng nơ-ron đã được huấn luyện mà không cần thay đổi kiến trúc hay huấn luyện lại mô hình.

- **Maximum Softmax Probability (MSP):** Đây là phương pháp nền tảng, dựa trên giả định rằng mô hình sẽ đưa ra xác suất dự đoán thấp hơn đối với các mẫu OOD. Tuy nhiên, các mạng nơ-ron sâu thường gặp hiện tượng "tự tin thái quá" (overconfidence), khiến MSP kém hiệu quả trên thực tế.
- **ODIN (Out-of-Distribution detector for Neural networks):** Khắc phục nhược điểm của MSP bằng cách sử dụng kỹ thuật Temperature Scaling và thêm nhiễu (perturbation) vào đầu vào. Cơ chế này giúp khuếch đại sự khác biệt về logit giữa mẫu In-Distribution (ID) và OOD.
- **Energy-based Scores:** Thay vì sử dụng xác suất phân bố, phương pháp này chuyển đổi các giá trị logit thành mức năng lượng. Các mẫu ID sẽ có mức năng lượng thấp, trong khi các mẫu OOD có năng lượng cao. Hàm năng lượng được định nghĩa như sau:

$$E(x; f) = -T \log \sum_i \exp(f_i(x)/T)$$

Trong đó, $f_i(x)$ là logit của lớp i và T là tham số nhiệt độ (temperature).

2.3.2 Không gian đặc trưng và Mạng nguyên mẫu

Thay vì chỉ sử dụng lớp đầu ra, các phương pháp này khai thác không gian ẩn (latent space) để tính toán khoảng cách từ mẫu kiểm thử đến phân

phối dữ liệu huấn luyện. Tiêu biểu trong nhóm này là kiến trúc **Mạng nguyên mẫu (Prototypical Networks)**. Trong không gian nhúng, các mẫu của cùng một lớp được gom cụm xung quanh một "nguyên mẫu" (prototype) c_k , được tính bằng trung bình các vector đặc trưng của tập dữ liệu hỗ trợ S_k :

$$c_k = \frac{1}{|S_k|} \sum_{x_i \in S_k} f_\theta(x_i)$$

Khả năng phát hiện OOD của phương pháp này phụ thuộc chặt chẽ vào độ đo khoảng cách được sử dụng:

- **Khoảng cách Euclidean (L_2 Norm):** Tính toán bằng công thức $d_E(z, c_k) = \|z - c_k\|_2$. Phương pháp này giả định các cụm dữ liệu có dạng hình cầu và đẳng hướng (isotropic). Dù dễ tính toán, nó thường kém hiệu quả do bỏ qua sự tương quan và độ phương sai khác biệt giữa các chiều đặc trưng.
- **Khoảng cách Cosine:** Định lượng góc giữa hai vector ($d_C(z, c_k) = 1 - \frac{z \cdot c_k}{\|z\|_2 \|c_k\|_2}$). Khoảng cách này loại bỏ ảnh hưởng của độ lớn vector (magnitude), rất hiệu quả khi kết hợp với các hàm mất mát đối chiếu (Contrastive Loss), nhưng có thể làm mất đi tín hiệu nhận diện quan trọng khi các mẫu OOD thường có norm thấp hơn ID.
- **Khoảng cách Mahalanobis:** Là độ đo mạnh mẽ nhất cho Near-OOD, được biểu diễn qua công thức $d_M(z, c_k) = \sqrt{(z - c_k)^T \Sigma_k^{-1} (z - c_k)}$ (với Σ_k là ma trận hiệp phương sai). Bằng cách cho phép các cụm dữ liệu có dạng ellipsoid linh hoạt (anisotropic), Mahalanobis đánh giá được mức độ bất thường dựa trên chính sự phân bố nội bộ của lớp, dù chi phí tính toán nghịch đảo ma trận là một rào cản lớn khi tập dữ liệu hỗ trợ nhỏ.

2.3.3 Mô hình sinh và Định lượng độ không chắc chắn (Generative Models & Uncertainty Quantification)

Nhóm phương pháp này tiếp cận bài toán OOD thông qua khả năng tái tạo dữ liệu và ước lượng độ tin cậy của mô hình.

- **Lỗi tái tạo (Reconstruction Error):** Sử dụng các mô hình Autoencoders hoặc Variational Autoencoders (VAEs) được huấn luyện chỉ trên dữ liệu ID (ví dụ: các cấu trúc giải phẫu bình thường). Khi gặp dữ liệu OOD, mô hình sẽ không thể khôi phục chính xác, dẫn đến lỗi tái tạo pixel-level cao, từ đó không chỉ phát hiện mà còn khoanh vùng được vùng bất thường.
- **Monte Carlo Dropout (MC Dropout):** Để định lượng "độ không chắc chắn nhận thức" (epistemic uncertainty), kỹ thuật này thực hiện quá trình truyền xuôi (forward pass) nhiều lần với dropout được kích hoạt trong pha kiểm thử. Phương sai lớn giữa các lần dự đoán là tín hiệu mạnh mẽ chỉ ra rằng mô hình đang đối mặt với dữ liệu chưa từng quan sát.

2.3.4 Học sâu Đa phương thức trong phát hiện OOD Y khoa (Multimodal Deep Learning)

Trong bối cảnh phân loại ảnh y khoa phức tạp, ranh giới giữa ID và OOD thường rất mỏng manh (Near-OOD) do sự đa dạng của các bệnh lý hiếm gặp hoặc hiện tượng dịch chuyển phân phối (Covariate shift). Các phương pháp OOD hiện đại đang dịch chuyển mạnh mẽ sang kiến trúc Học sâu đa phương thức (Multimodal Deep Learning - MDL).

- **Supervised Contrastive Learning:** Nhằm giải quyết Covariate shift giữa các hệ thống thu nhận hình ảnh (ví dụ: các máy chụp X-quang khác nhau), kỹ thuật đối chiếu có giám sát ép mô hình học

các biểu diễn hình thái cốt lõi của tổn thương thay vì ghi nhớ nhiễu (noise/texture). Điều này giúp tối ưu hóa ranh giới khoảng cách trong không gian ẩn.

- **Zero-shot OOD với Vision-Language Models:** Sự xuất hiện của các mô hình nền tảng y khoa như BiomedCLIP cho phép phát hiện OOD thông qua độ lệch pha (misalignment) giữa đặc trưng hình ảnh và văn bản. Cụ thể, thông qua cơ chế Knowledge-guided Cross-Attention, hệ thống có thể đối chiếu chéo (cross-reference) các vùng hình ảnh với kho tri thức y khoa. Ví dụ, trong bài toán phân loại khối u xương (bone tumor) đa phương thức, nếu mô hình đối mặt với một ảnh X-quang chứa mảnh ghép kim loại chỉnh hình hoặc một dạng Sarcoma chưa từng có trong tập huấn luyện, điểm tương đồng (Alignment Score) giữa đặc trưng ảnh và các báo cáo u xương tiêu chuẩn sẽ suy giảm đột ngột. Sự sụt giảm độ chú ý tại các vùng bất thường này cung cấp cơ chế "cấm cờ" (flag) OOD mạnh mẽ và có khả năng giải thích cao (interpretable).

2.3.5 Hạn chế của các phương pháp hiện tại và Cơ sở lựa chọn

Các phương pháp OOD hiện hành vẫn tồn tại nhiều điểm yếu khi áp dụng vào phân loại ảnh y khoa: nhóm Post-hoc (MSP, ODIN) dễ mắc lỗi "tự tin thái quá" và kém hiệu quả với ranh giới Near-OOD; nhóm Generative tốn kém tài nguyên tính toán và dễ tổng quát hóa sai (over-generalization); trong khi Contrastive Learning lại phụ thuộc quá mức vào lượng dữ liệu lớn, khó xử lý các tập dữ liệu y tế mất cân bằng nghiêm trọng.

Do đó, Mạng nguyên mẫu (Prototypical Networks) được lựa chọn làm giải pháp cốt lõi nhờ ba ưu thế chiến lược:

1. **Tối ưu cho dữ liệu khan hiếm (Few-shot):** Hoạt động ổn định ngay cả với tập dữ liệu hỗ trợ rất nhỏ, đặc biệt phù hợp để xử lý các biến thể bệnh lý hiếm gặp như khối u xương mà không bị chệch (bias).

2. **Cơ sở suy luận minh bạch:** Định lượng trực tiếp sự bất thường thông qua khoảng cách hình học tới các nguyên mẫu bệnh lý, đáp ứng yêu cầu khắt khe về khả năng giải thích (interpretability) trong lâm sàng.
3. **Nhạy bén với Near-OOD:** Khả năng tích hợp linh hoạt với các độ đo (như Mahalanobis) giúp mô hình đánh giá chính xác độ phân tán của dữ liệu, từ đó bóp nghẹt dung sai và phát hiện sự chênh lệch mỏng manh nhất trong không gian đặc trưng đa phương thức.

Chương 3

Phương pháp đề xuất

3.1 Phân loại với mô hình BioMed-CLIP và đề xuất cải tiến

Với việc được tiền huấn luyện trên bộ dữ liệu PMC-15M, đã bao gồm ảnh X-quang, nhóm quyết định sử dụng mô hình BioMedCLIP làm mô hình cơ sở để phát triển hệ thống phân loại. Trước tiên, nhóm thực hiện đánh giá khả năng phân loại ảnh X-quang xương của mô hình BiomedCLIP [**BiomedCLIP**] thuần túy để đánh giá khả năng phân loại với một tác vụ riêng biệt ở miền ảnh X-Quang xương, yêu cầu một độ chính xác cao với độ nhầm lẫn thấp để đáp ứng với yêu cầu thực tế, đặc biệt là trong lĩnh vực y khoa.

Bộ dữ liệu được sử dụng để đánh giá là BTXRD, gồm tổng cộng 3.746 hình ảnh, trong đó phân bổ thành 1.879 ảnh xương bình thường, 1.525 ảnh u xương lành tính và 342 ảnh u xương ác tính.

3.1.1 Quá trình phân loại của mô hình Biomed-CLIP

Mô hình BiomedCLIP gốc trong thiết lập *zero-shot* thực hiện quá trình phân loại dựa trên cơ chế đối sánh Hình ảnh - Văn bản (Vision-Language Matching) thay vì sử dụng các lớp phân loại (classification head) truyền

thống. Quy trình này bao gồm 5 bước cốt lõi sau:

1. **Xây dựng bộ mô tả văn bản (Text Prompting):** Các nhãn phân loại rời rạc được chuyển đổi thành các câu lệnh mang ngữ nghĩa lâm sàng phong phú nhằm cung cấp thông tin ngữ cảnh cho mô hình (Ví dụ: "A radiograph showing tên_bệnh_lý").
2. **Trích xuất đặc trưng văn bản (Text Encoding):** Các câu mô tả được đưa qua nhánh *Text Encoder* (kiến trúc PubMedBERT) để chuyển đổi thành các vector đặc trưng văn bản (*text embeddings*) trong không gian biểu diễn chung.
3. **Trích xuất đặc trưng hình ảnh (Image Encoding):** Ảnh X-quang đầu vào được xử lý qua nhánh *Vision Encoder* (kiến trúc Vision Transformer - ViT) để trích xuất vector đặc trưng hình ảnh (*image embedding*) đại diện cho các thông tin thị giác.
4. **Tính toán độ tương đồng (Cosine Similarity):** Mô hình tiến hành đo lường khoảng cách giữa vector hình ảnh với tất cả các vector văn bản thông qua phép toán độ tương đồng Cosine. Cặp ảnh - văn bản có sự tương hợp cao nhất về mặt ngữ nghĩa y khoa sẽ đạt điểm số lớn nhất.
5. **Đưa ra dự đoán cuối cùng:** Các điểm số tương đồng được chuẩn hóa thông qua hàm Softmax để chuyển thành phân phối xác suất. Lớp tương ứng với câu mô tả có xác suất cao nhất sẽ được lựa chọn làm kết quả dự đoán của mô hình.

3.1.2 Kết quả phân loại

- **Độ đặc hiệu cao (Specificity = 0.9064):** Mô hình làm rất tốt việc *loại trừ*. Nghĩa là khi nó dự đoán một ca là "không mắc bệnh" (âm tính), thì khả năng cao là bệnh nhân thực sự không mắc bệnh.
- **Độ nhạy cực thấp (Sensitivity = 0.1499):** Đây là "báo động đỏ" trong y tế. Độ nhạy chỉ đạt $\sim 15\%$ có nghĩa là mô hình **bỏ sót**

Chỉ số (Metric)	Giá trị
Độ chính xác (Accuracy)	0.3381
F1 Macro	0.1056
AUROC Macro	0.5773
Độ nhạy (Sensitivity Macro)	0.1499
Độ đặc hiệu (Specificity Macro)	0.9064
Độ chuẩn xác (Precision Macro)	0.1123

Bảng 3.1: Các chỉ số đánh giá tổng quan (Aggregated/Macro)

tới 85% các ca thực sự có khối u (Âm tính giả - False Negative cao). Mô hình đang có xu hướng an toàn là dự đoán mọi thứ thành lớp Bình thường (Normal).

- **Độ chuẩn xác (Precision = 0.1123) và F1 Macro (0.1056) rất thấp:** Khi mô hình quyết định cảnh báo một ca là khối u, thì phần lớn các cảnh báo đó là sai (Dương tính giả - False Positive cao). F1 Macro thấp (~10.5%) cho thấy mô hình xử lý cực kỳ kém trên toàn bộ các lớp.
- **Độ chính xác tổng (Accuracy = 0.3381):** Chỉ có khoảng 33.8% tổng số mẫu được dự đoán đúng. Tuy nhiên, trong y tế, Accuracy là một chỉ số "đánh lừa" nếu dữ liệu bị mất cân bằng.
- **AUROC Macro (0.5773):** Chỉ số này nhỉnh hơn mức độ đoán mò (0.5) một chút. Nó chứng tỏ mô hình BiomedCLIP gốc chưa có đủ khả năng phân biệt (discrimination) rõ ràng giữa các ranh giới của các loại u xương.

Bảng F1-Score 3.2 từng lớp chính là minh chứng rõ ràng nhất cho tình trạng **mất cân bằng dữ liệu (data imbalance)**:

- **Lớp Normal (0.5790):** Là lớp có kết quả cao nhất. Điều này dễ hiểu vì dữ liệu y tế luôn có số lượng ảnh bình thường áp đảo. Mô hình đã học được "thiên kiến" (bias), dẫn đến việc dự đoán ưu tiên lớp này để tối ưu Accuracy tổng.
- **Các lớp có số liệu thấp (Osteosarcoma, Giant cell tumor, Simple bone cyst):** Chỉ đạt mức F1 từ 0.12 đến 0.19. Dù Sarcoma

Lớp chẩn đoán (Class)	F1-Score
Normal (Bình thường)	0.5790
Simple bone cyst (Nang xương đơn giản)	0.1935
Osteosarcoma (Sarcoma xương)	0.1250
Giant cell tumor (U tế bào khổng lồ)	0.1212
Osteofibroma (U xơ xương)	0.0375
Osteochondroma (U sụn xương)	0.0000
Multiple osteochondromas (Đa u sụn xương)	0.0000
Other bt (U lành tính khác)	0.0000
Synovial osteochondroma (U sụn màng hoạt dịch)	0.0000
Other mt (U ác tính khác)	0.0000

Bảng 3.2: Chỉ số F1 (F1-score) chi tiết theo từng lớp

xương (Osteosarcoma) là một bệnh lý có đặc điểm hình ảnh khá đặc trưng, mô hình zero-shot vẫn gặp khó khăn trong việc nhận diện chính xác.

- **Các lớp bị điểm 0 tuyệt đối (Osteochondroma, Synovial osteochondroma, ...):** Mô hình hoàn toàn "mù" trước các lớp này (không đoán trúng được ca nào). Điều này xảy ra khi đặc trưng hình ảnh của các khối u này quá hiếm hoặc quá phức tạp để mô hình gốc có thể nội suy ra được mà không qua quá trình huấn luyện (fine-tuning).

3.1.3 Kết luận

Các kết quả này chỉ ra ba hạn chế chính của mô hình:

1. Khoảng cách miền giữa dữ liệu tiền huấn luyện và ảnh X-quang xương;
2. Thiếu thông tin ngữ cảnh lâm sàng khi mô hình gốc gần như chỉ sử dụng ảnh;
3. Chưa xử lý được đặc tính đa nhãn, mất cân bằng dữ liệu của bài toán.

Do đó, việc tinh chỉnh lại mô hình để cải thiện hiệu năng, giảm khoảng cách miền và đáp ứng bài toán thiếu hụt dữ liệu là cần thiết, nghiên cứu đề xuất một kiến trúc đa phương thức gồm hai giai đoạn huấn luyện:

1. Thích nghi miền dựa trên LoRA để các vector đặc trưng mang tính khả tách.
2. Hợp nhất ảnh–văn bản bằng cơ chế chú ý chéo hai chiều và học phân loại đa nhãn dựa trên mạng nguyên mẫu.

Các cải tiến cụ thể hơn sẽ được trình bày trong phần tiếp theo.

3.1.4 Đề xuất cải tiến

Dựa trên những hạn chế của mô hình gốc, nghiên cứu đề xuất các thay đổi quan trọng sau:

Lựa chọn cách finetuning với đặc thù ít dữ liệu: LoRA được lựa chọn vì đây là phương pháp tinh chỉnh hiệu quả về tham số, cho phép thích nghi BioMedCLIP với miền ảnh X-quang xương mà vẫn bảo toàn tri thức tiền huấn luyện. So với tinh chỉnh toàn bộ tham số, LoRA giảm nguy cơ quá khớp dữ liệu và quên thảm khốc trong bối cảnh dữ liệu y khoa có quy mô hạn chế và phân phối mất cân bằng. Mặc dù nghiên cứu sử dụng toàn bộ dữ liệu hiện có, nhiều lớp vẫn chỉ chứa số lượng mẫu rất ít. Do đó, bài toán ở cấp độ từng lớp mang đặc tính học ít mẫu, và LoRA giúp hệ thống duy trì khả năng thích nghi tốt trong các trường hợp này.

Lựa chọn mục tiêu huấn luyện cho học biểu diễn: Loss tương phản gốc của BioMedCLIP (InfoNCE) giả định quan hệ một-một giữa ảnh và văn bản, do đó chưa phù hợp với dữ liệu X-quang xương, nơi một ảnh có thể tương ứng với nhiều mô tả ngữ nghĩa và nhiều nhãn đồng thời. Vì vậy, nghiên cứu thay thế hàm mất mát tương phản bằng hàm mất mát tương ứng ngữ nghĩa (Semantic Matching Loss) nhằm khai thác mức độ tương đồng ngữ nghĩa giữa ảnh và văn bản, giảm ảnh hưởng của các cặp âm tính giả và hỗ trợ tốt hơn cho bài toán đa nhãn. Tuy nhiên, Semantic Matching Loss không trực tiếp xử lý mất cân bằng dữ liệu. Do đó, ở giai đoạn phân loại đa nhãn, nghiên cứu kết hợp thêm các hàm mất mát chuyên biệt như

hàm mất mát không đối xứng (Asymmetric Loss) để tăng khả năng nhận diện các lớp hiếm.

Xử lý đa nhãn và mất cân bằng dữ liệu trong học phân loại: Do bài toán được xây dựng theo hướng phân loại đa nhãn với dữ liệu mất cân bằng nghiêm trọng, hàm mất mát Cross-Entropy không còn phù hợp vì giả định các lớp loại trừ lẫn nhau. Nghiên cứu sử dụng kiến trúc mạng nguyên mẫu (Prototypical Network) dạng tham số (Parametric Prototypical Network) kết hợp với hàm mất mát không đối xứng nhằm tối ưu hiệu suất trên các lớp hiếm.

Phát hiện OOD (Out-of-Distribution): Việc phát hiện dữ liệu ngoài phân phối (OOD) được thực hiện dựa trên khoảng cách Cosine giữa các đặc trưng và các nguyên mẫu (prototypes) trong không gian biểu diễn chung, thay vì xác suất Softmax. Mô hình có thể được huấn luyện chỉ với dữ liệu trong phân phối, và sau đó nếu có dữ liệu OOD, có thể mở rộng bằng cách bổ sung hàm mất mát OOD Margin Loss để ép các mẫu ngoài phân phối nằm xa tất cả các nguyên mẫu, tăng khả năng phân biệt dữ liệu bất thường.

3.2 Ý tưởng ban đầu

Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế theo hướng tích hợp tri thức y khoa nhằm nâng cao khả năng học ít mẫu và phát hiện dữ liệu ngoài phân phối. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Bộ mã hóa ảnh:** Kế thừa lại mô hình ViT-Base của phương pháp BiomedCLIP [BiomedCLIP]
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [BiomedCLIP]
- **Bộ dung hợp dữ liệu:** Kỹ thuật Bidirectional Cross-Attention được xây dựng dựa trên cơ chế cross-attention nhằm học mối quan hệ ngữ

nghĩa giữa đặc trưng hình ảnh và đặc trưng văn bản y khoa.

- **Bộ phân loại:** Dùng phương pháp metric-based few-shot learning với một prototypical network, nhận được quyết định bởi khoảng cách đến các prototype trong không gian biểu diễn chung, thay vì lớp phân loại truyền thống làm ràng buộc mô hình phân loại vào các nhãn đã biết, giúp phát hiện dữ liệu ngoài phân phối khi khoảng cách đó vượt quá ngưỡng xác định.


Đồng thời, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán.

3.3 Giai đoạn off-line

Giai đoạn off-line nhằm xây dựng bộ tham số cho mô hình, thiết lập không gian biểu diễn chung và học cách dung hợp giữa đặc trưng hình ảnh X-quang và ngữ nghĩa y khoa.

Giai đoạn off-line gồm 2 công đoạn: Domain-Adaption và Fine-tuning. Trong đó, công đoạn Domain-Adaption nhằm mục đích giúp mô hình thích nghi từ miền dữ liệu tiền huấn luyện lớn sang miền dữ liệu y khoa đích của bài toán, trong khi công đoạn Fine-tuning tập trung vào việc tối ưu hóa khả năng dung hợp dữ liệu và phân loại trên tập dữ liệu mục tiêu.

3.3.1 Domain-Adaption với kỹ thuật LoRA



Hình 3.1: Sơ đồ chung của hệ thống trong công đoạn Domain-Adaption.

Trong công đoạn này, mục tiêu chính giúp mô hình học cách biểu diễn sao cho các cặp ảnh và báo cáo ảnh X-Quang nằm gần nhau hơn trong không gian biểu diễn bằng cách tối ưu hàm mất mát khớp ngữ nghĩa (Semantic Matching Loss), mô hình tuân theo framework contrastive learning để căn chỉnh bộ mã hóa BiomedCLIP về miền dữ liệu X-Quang xương được sử dụng, với đầu vào là các cặp ảnh X-quang và phân tích ảnh tương ứng của bác sĩ. Dữ liệu được đưa vào bộ mã hóa tương ứng để trích xuất đặc trưng, sau đó được chiếu vào không gian chung và chuẩn hóa để so sánh và thực hiện điều chỉnh. Kết quả là các cặp hình ảnh và văn bản giống nhau hoặc chung lớp nằm gần nhau hơn gọi là các semantic clusters, trong khi các cặp văn bản khác lớp sẽ nằm xa nhau hơn.

Nhóm thực hiện tinh chỉnh (fine-tuning) đồng thời Vision Encoder và Text Encoder bằng kỹ thuật LoRA (Low-Rank Adaptation). LoRA được lựa chọn vì đây là phương pháp tinh chỉnh hiệu quả về tham số, cho phép

thích nghi BioMedCLIP với miền ảnh X-quang xương mà vẫn bảo toàn tri thức tiền huấn luyện.

Mặc dù nghiên cứu sử dụng toàn bộ dữ liệu hiện có, nhiều lớp vẫn chỉ chứa số lượng mẫu rất ít. Do đó, bài toán ở cấp độ từng lớp mang đặc tính few-shot, và LoRA giúp hệ thống duy trì khả năng thích nghi tốt trong các trường hợp này. Nghiên cứu lựa chọn LoRA thay vì QLoRA vì mục tiêu chính là thích nghi miền hiệu quả trong điều kiện dữ liệu hạn chế, thay vì tối ưu bộ nhớ cho các mô hình siêu lớn. BioMedCLIP có quy mô tham số vừa phải, cho phép huấn luyện hiệu quả với LoRA trên phần cứng hiện có mà không cần lượng tử hóa. Ngoài ra, việc giữ nguyên trọng số ở độ chính xác đầy đủ giúp bảo toàn các đặc trưng hình ảnh tinh vi của ảnh X-quang xương, vốn rất quan trọng đối với việc nhận diện các tổn thương nhỏ và các lớp hiếm.

Để cập nhật trọng số của ma trận LoRA, nhóm sử dụng **Hàm mất mát Khớp ngữ nghĩa (Semantic Matching Loss - $\mathcal{L}_{SM}$)** nhằm đồng bộ hóa không gian biểu diễn đa phương thức. Loss tương phản gốc của BioMedCLIP (InfoNCE) giả định quan hệ một-một giữa ảnh và văn bản, do đó chưa phù hợp với dữ liệu X-quang xương, nơi một ảnh có thể tương ứng với nhiều mô tả ngữ nghĩa và nhiều nhãn đồng thời.

Vì vậy, nghiên cứu thay thế contrastive loss bằng Semantic Matching Loss nhằm khai thác mức độ tương đồng ngữ nghĩa giữa ảnh và văn bản, giảm ảnh hưởng của các cặp âm tính giả và hỗ trợ tốt hơn cho bài toán đa nhãn. Tuy nhiên, Semantic Matching Loss không trực tiếp xử lý mất cân bằng dữ liệu. Do đó, ở giai đoạn phân loại đa nhãn, nghiên cứu kết hợp thêm các hàm mất mát chuyên biệt như Asymmetric Loss để tăng khả năng nhận diện các lớp hiếm.

Mức độ tương đồng Cosine giữa đặc trưng ảnh z_i^I và đặc trưng văn bản z_j^T :

$$\text{sim}(z_i^I, z_j^T) = \frac{z_i^I \cdot z_j^T}{\|z_i^I\| \|z_j^T\|} \quad (3.1)$$

Hàm mất mát được sử dụng là Semantic Matching Loss $\mathcal{L}_{SM}$ được định


nghĩa dựa trên ma trận mục tiêu mềm s_{ij} :

$$\mathcal{L}_{SM} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N s_{ij} \log \frac{\exp(\text{sim}(z_i^I, z_j^T)/\tau)}{\sum_{k=1}^N \exp(\text{sim}(z_i^I, z_k^T)/\tau)} \quad (3.2)$$

trong đó, N là kích thước mini-batch, s_{ij} là ma trận mục tiêu xác định các mẫu chung lớp, và τ là siêu tham số nhiệt độ (temperature) giúp điều chỉnh độ nhạy của hàm phạt đối với các mẫu âm tính (negative samples). Bằng cách tối ưu $\mathcal{L}_{SM}$, mô hình đẩy các đặc trưng giải phẫu X-quang cục bộ hội tụ chặt chẽ về đúng định nghĩa y khoa của chúng trong không gian chung.

Công đoạn Domain-Adaption giúp mô hình học cách biểu diễn sao cho các cặp ảnh và báo cáo khám tổng quát chung lớp nằm gần nhau hơn trong không gian biểu diễn, Semantic Matching Loss giúp các dữ liệu chung lớp nằm gần nhau thay vì ràng buộc như contrastive learning truyền thống rằng các cặp ảnh và báo cáo chung lớp dù không tương ứng dù nằm chung lớp vẫn phải nằm cách xa nhau ra. Điều này cực quan trọng với bài toán dữ liệu còn hạn chế, giúp tránh trường hợp dữ liệu nằm chung nhóm không hội tụ. Trong quá trình huấn luyện, đạo hàm từ hàm mất mát $\mathcal{L}_{SM}$ chỉ chảy qua và cập nhật ma trận $A \in \mathbb{R}^{r \times k}$ và $B \in \mathbb{R}^{d \times r}$ (với hạng $r \ll \min(d, k)$) của LoRA. Tổng số tham số cần học (learnable parameters) chiếm dưới 5% toàn mạng.

3.3.2 Fusion-learning




Hình 3.2: Sơ đồ chung của hệ thống trong công đoạn Fusion-learning.

Trong công đoạn này, nhóm tối ưu khả năng khai thác và dung hợp dữ liệu bằng cách sử dụng kỹ thuật Bidirectional Cross-Attention để học các mối liên hệ giữa đặc trưng đặc trưng toàn cục của ảnh X-Quang với đặc trưng cục bộ của báo cáo khám tổng quát và ngược lại.

Để mô phỏng sát với quá trình học phân tích ảnh thực tế của bác sĩ, dữ liệu đầu vào của công đoạn này là các cặp ảnh X-quang và báo cáo khám tổng quát. Các dữ liệu này được đưa vào bộ mã hóa tương ứng để trích xuất đặc trưng. Kỹ thuật cross-attention được sử dụng để học các mối liên hệ giữa các đặc trưng này. Đặc trưng toàn cục của ảnh X-quang được sử dụng để tìm các đặc trưng cục bộ của báo cáo khám tổng quát có liên quan và ngược lại, đặc trưng toàn cục của văn bản được sử dụng để tìm các đặc trưng cục bộ của ảnh X-quang có liên quan. Sau đó, các đặc trưng có liên quan được đưa vào một khối Transformer, nơi chúng được kết hợp một lần nữa thông qua cơ chế attention để học sự phụ thuộc giữa các đặc trưng, tương quan ngữ nghĩa ở mức độ sâu hơn trước khi được đưa

vào bộ phân loại cuối cùng để dự đoán nhãn bệnh lý. Sự khác biệt của dự đoán với nhãn thực tế sẽ được tính toán và sử dụng để cập nhật tham số của các khối Cross-Attention, Linear Projection và Transformer cũng như Classifier.

Do bài toán được xây dựng theo hướng phân loại đa nhãn với dữ liệu mất cân bằng nghiêm trọng, hàm mất mát Cross-Entropy không còn phù hợp vì giả định các lớp loại trừ lẫn nhau. Nghiên cứu sử dụng kiến trúc Prototypical Network dạng tham số (Parametric Prototypical Network) kết hợp với hàm mất mát Asymmetric Loss nhằm tối ưu hiệu suất trên các lớp hiếm.



Hình 3.3: Sơ đồ mạng prototypical.

Thay vì tính toán giá trị prototype cố định bằng trung bình cộng của các mẫu hỗ trợ, các prototype lớp c_k được định nghĩa là các vector trọng số có thể học được (learnable parameters) và được cập nhật trực tiếp qua quá trình lan truyền ngược (backpropagation). Khoảng cách giữa embedding hợp nhất z_i và các prototype c_k được sử dụng để đưa ra dự đoán đa nhãn, đồng thời hỗ trợ phát hiện dữ liệu ngoài phân phối thông qua ngưỡng khoảng cách đến prototype gần nhất. Nghiên cứu sử dụng khoảng cách

Cosine (Cosine Distance) giữa đặc trưng đã chuẩn hóa L2 để đảm bảo sự ổn định trong không gian nhúng của mô hình đa phương thức:

$$d(z_i, c_k) = 1 - \frac{z_i \cdot c_k}{\|z_i\|_2 \|c_k\|_2} \quad (3.3)$$

Mức độ tương đồng Cosine có trọng số tỷ lệ τ được tính để xác định xác suất dự đoán của mẫu i đối với lớp k bằng hàm Sigmoid:

$$p_{ik} = \sigma(\tau(1 - d(z_i, c_k))) \quad (3.4)$$

Hàm mất mát chính trong giai đoạn này là Asymmetric Loss (ASL) nhằm xử lý đa nhãn và mất cân bằng dữ liệu bằng cách điều chỉnh hệ số suy giảm γ khác nhau cho nhãn dương và nhãn âm:

$$\mathcal{L}_{\text{ASL}} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K \left[y_{ik}(1 - p_{ik})^{\gamma^+} \log(p_{ik}) + (1 - y_{ik})p_{m,ik}^{\gamma^-} \log(1 - p_{m,ik}) \right] \quad (3.5)$$

với $p_{m,ik} = \max(0, p_{ik} - \text{clip})$ là xác suất đã dịch chuyển nhằm loại bỏ các mẫu âm tính có độ tin cậy cao.

Ngoài ra, hàm Prototype Loss $\mathcal{L}_{\text{proto}}$ được áp dụng để kéo đặc trưng gần với prototype lớp tương ứng và đẩy ra xa khỏi các prototype lớp khác:

$$\mathcal{L}_{\text{proto}} = \frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K [y_{ik}d(z_i, c_k) + (1 - y_{ik}) \max(0, \delta - d(z_i, c_k))] \quad (3.6)$$

Việc phát hiện dữ liệu ngoài phân phối (OOD) được thực hiện dựa trên khoảng cách Cosine giữa embedding và các prototype. Do đặc thù dữ liệu y khoa khó thu thập mẫu OOD đại diện, mô hình có thể được huấn luyện chỉ với dữ liệu trong phân phối. Nếu có dữ liệu OOD, có thể mở rộng mô hình bằng cách bổ sung hàm mất mát OOD Margin Loss $\mathcal{L}_{\text{OOD}}$ để ép các mẫu ngoài phân phối nằm xa tất cả các prototype:


$$\mathcal{L}_{\text{OOD}} = \frac{1}{N_{\text{OOD}}} \sum_{i=1}^{N_{\text{OOD}}} \max \left(0, m_{\text{OOD}} - \min_k d(z_i^{\text{OOD}}, c_k) \right) \quad (3.7)$$

Tổng hợp lại, hàm mất mát cho giai đoạn học phân loại được định nghĩa như sau:

$$\mathcal{L} = \mathcal{L}_{\text{ASL}} + \lambda_1 \mathcal{L}_{\text{proto}} + \lambda_2 \mathcal{L}_{\text{OOD}} \quad (3.8)$$

Bằng cách tối ưu tổ hợp hàm mất mát này, mô hình học được cách phân loại chính xác các bệnh lý xương khớp dưới dạng đa nhãn, cải thiện năng lực dự đoán trên các lớp hiếm và cung cấp khả năng phát hiện mẫu bệnh lý bất thường (OOD).

3.4 Giai đoạn online



Hình 3.4: Sơ đồ chung của hệ thống trong giai đoạn online.

Sơ đồ của hệ thống trong giai đoạn online được trình bày trong Hình 3.4. Gần tương ứng với công đoạn Fine-tuning, ảnh X-Quang cùng báo cáo tổng quát gồm lời khai của bệnh nhân và tiền sử bệnh lý sau tiền xử lý được đưa vào bộ mã hóa tương ứng để trích xuất đặc trưng. Các đặc trưng này được đưa vào khối Cross-Attention để học các mối liên hệ tương tác giữa đặc trưng toàn cục với các đặc trưng cục bộ, sau đó được đưa vào

khối Transformer để hợp nhất đặc trưng đa phương thức ở mức độ sâu hơn trước khi được đưa vào mạng prototypical để dự đoán nhãn bệnh lý, ở đây, nhãn được lựa chọn dựa trên khoảng cách đến các prototype, nếu khoảng cách đến prototype gần nhất vượt quá ngưỡng nhất định, mô hình sẽ đánh dấu là không chắc chắn. Ngoài ra, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán. Cụ thể, mô hình có thể tạo ra các bản đồ nhiệt trực quan hóa trên ảnh X-quang dựa trên các trọng số attention để giải thích dự đoán của mô hình.

3.5 Đóng góp của phương pháp

- **Tích hợp tri thức y khoa với biểu diễn đa phương thức:** Không chỉ sử dụng kết hợp cả hai phương thức dữ liệu, phương pháp đã thực hiện trích xuất các thông tin cần thiết từ văn bản y khoa theo khuôn mẫu, giúp giảm nhiễu ngôn ngữ tự nhiên, tăng tính nhất quán ngữ nghĩa; đồng thời việc làm giàu tri thức qua UMLS giúp làm giàu ngữ nghĩa văn bản theo chuẩn y khoa mà không gặp vấn đề hallucination so với việc tạo ra mô tả bằng LLM.
- **Cơ chế Cross-Attention có hướng dẫn tri thức:** Việc sử dụng cơ chế Cross-Attention có hướng dẫn tri thức giúp mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Điều này không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.
- **Cơ chế fusion ở nhiều cấp độ:** Việc kết hợp đặc trưng toàn cục và cục bộ thông qua Cross-Attention và khối Transformer giúp mô hình khai thác tối đa dữ liệu và học được các mối liên hệ phức tạp giữa hai nguồn dữ liệu, từ đó cải thiện hiệu suất phân loại và khả năng giải thích của mô hình.
- **Giảm nguy cơ suy giảm không gian ngữ nghĩa trong bối cảnh dữ liệu hạn chế:** Cơ chế cập nhật tham số bằng LoRA giúp các bộ

mã hóa thích nghi với dữ liệu y khoa đích mà không làm mất mát các tri thức đã học. Điều này giúp hạn chế hiện tượng overfitting và giảm độ phức tạp tính toán.

- **Cơ chế phát hiện dữ liệu ngoài phân phối:** Mô hình có khả năng phát hiện dữ liệu ngoài phân phối với mạng prototypical.

Chương 4

Thực nghiệm

Trong quá trình thực nghiệm, nhóm tập trung vào việc đánh giá hiệu quả của mô hình đề xuất so với các backbone khác (ResNet-50, CLIP, MedCLIP, BiomedCLIP, PubMedCLIP) trên nhiệm vụ phân loại ảnh x-quang. Nhóm đã thiết lập một loạt các thí nghiệm để so sánh hiệu suất của các mô hình này, đồng thời thực hiện các thí nghiệm rời rạc để kiểm tra ảnh hưởng của việc sử dụng thông tin văn bản, các đóng góp của các thành phần đề xuất trong quá trình huấn luyện và đánh giá.

4.1 Mục đích thực nghiệm

Nhằm chứng minh cho các luận điểm mà nhóm đưa ra, đóng góp lý thuyết cũng như thực tiễn của mô hình đề xuất XBone-Net trên bài toán hỗ trợ chẩn đoán và phân loại đa lớp ảnh x-quang xương, nhóm nghiên cứu đã thiết lập một hệ thống các thí nghiệm thực nghiệm. Mỗi thí nghiệm được xây dựng nhằm xác thực một luận điểm cụ thể, giải quyết các thách thức của bài toán phân loại ảnh x-quang xương đa phương thức và kiểm chứng các cải tiến về mặt kiến trúc cũng như phương pháp huấn luyện hai pha.

4.1.1 Đánh giá so sánh hiệu năng chẩn đoán với các mô hình đối sánh

Mục đích chính của nhóm thí nghiệm này là đặt mô hình đề xuất XBone-Net vào mối tương quan so sánh trực tiếp với các mô hình học sâu đa phương thức y khoa hiện nay. Các mô hình đối sánh được lựa chọn bao gồm cả kiến trúc đơn phương thức truyền thống như ResNet-50 và các mô hình ngôn ngữ trực quan mạnh mẽ như CLIP, MedCLIP, BiomedCLIP và PubMedCLIP. Thí nghiệm này nhằm chứng minh các luận điểm sau:

- Sự vượt trội của việc kết hợp thông tin đa phương thức (ảnh chụp X-quang và văn bản bệnh sử lâm sàng) so với các phương pháp chỉ sử dụng thông tin hình ảnh thị giác đơn thuần trong việc phân biệt các lớp bệnh lý u xương có hình thái tương đồng trên ảnh x-quang.
- Hiệu quả vượt trội của việc sử dụng các mô hình ngôn ngữ trực quan y khoa tiền huấn luyện làm bộ trích xuất đặc trưng so với các mô hình ngôn ngữ trực quan tiền huấn luyện trên dữ liệu ảnh tự nhiên nói chung, do sự thu hẹp khoảng cách miền dữ liệu.
- Khả năng tối ưu hóa vượt trội của mô hình đề xuất XBone-Net trong việc duy trì độ chính xác cao trên toàn cục đồng thời bảo toàn độ nhạy chẩn đoán đối với các lớp bệnh lý hiếm gặp trong bối cảnh mất cân bằng dữ liệu.

4.1.2 Đánh giá khả năng phát hiện dữ liệu ngoài phân phối

Trong môi trường lâm sàng thực tế, mô hình phân loại có thể phải đối mặt với các hình ảnh X-quang không chứa khối u xương mà chứa các loại bệnh lý xương khớp khác (như gãy xương, viêm khớp, loãng xương) hoặc ảnh chụp từ các vùng giải phẫu không liên quan. Mục đích của thí nghiệm này là đánh giá độ tin cậy và an toàn y khoa của mô hình thông qua khả năng phát hiện dữ liệu ngoài phân phối thay vì đưa ra các chẩn đoán sai lệch. Thí nghiệm hướng đến việc kiểm chứng giả thuyết:

- Việc sử dụng đầu phân loại nguyên mẫu kết hợp học khoảng cách ở Pha 2 giúp tạo lập một không gian đặc trưng có cấu trúc cụm chặt chẽ hơn.
- Độ tương đồng cosine giữa vector đặc trưng của mẫu kiểm thử với các nguyên mẫu của lớp đã biết cung cấp một thước đo khoảng cách đáng tin cậy để xác định ranh giới từ chối chẩn đoán, giúp phát hiện các mẫu ngoài phân phối.

4.1.3 Đánh giá vai trò của các nguồn thông tin văn bản lâm sàng

Thông tin văn bản y khoa có thể đến từ nhiều nguồn khác nhau trong quy trình chẩn đoán lâm sàng. Thí nghiệm này được thiết lập nhằm bóc tách đóng góp cụ thể của từng nguồn văn bản (báo cáo mô tả hình ảnh X-quang và báo cáo lâm sàng) đến kết quả phân loại cuối cùng. Mục đích cốt lõi của thí nghiệm này bao gồm:

- Phát hiện và ngăn chặn hiện tượng rò rỉ nhãn trong học máy đa phương thức y tế. Các báo cáo chẩn đoán X-quang cận lâm sàng thường chứa trực tiếp tên của bệnh lý (ví dụ: "osteosarcoma"). Nếu đưa báo cáo này vào huấn luyện, mô hình sẽ học cách đọc trực tiếp từ khóa này thay vì phân tích các dấu hiệu thị giác trên ảnh, dẫn đến việc mất đi giá trị chẩn đoán thực tế khi ứng dụng.
- Khẳng định giá trị lâm sàng thực tế của báo cáo tổng quát như tuổi tác, giới tính, vị trí sưng đau, tiền sử bệnh án. Đây là nguồn thông tin an toàn, không gây rò rỉ nhãn và đóng vai trò hỗ trợ đắc lực cho hình ảnh X-quang để đưa ra kết luận chẩn đoán chính xác nhất.

4.1.4 Đánh giá ảnh hưởng của chiến thuật tinh chỉnh backbone

Mục đích của nhóm thí nghiệm này là nghiên cứu và so sánh các chiến thuật cập nhật trọng số cho các bộ trích xuất đặc trưng bao gồm: đóng

bằng hoàn toàn, tinh chỉnh hiệu quả tham số và tinh chỉnh toàn bộ. Nhóm thí nghiệm hướng tới chứng minh hai luận điểm quan trọng:

- **Hiện tượng quên biểu diễn:** Xảy ra khi có sự không đồng nhất về mặt ngữ nghĩa giữa nguồn thông tin văn bản được sử dụng trong Pha 1 học biểu diễn và Pha 2 học phân loại. Thí nghiệm nhằm chứng minh việc đồng bộ hóa nguồn văn bản lâm sàng ở cả hai pha sẽ bảo toàn không gian biểu diễn chung, tránh trôi lệch đặc trưng và nâng cao đáng kể hiệu năng chẩn đoán.
- **Quên tri thức gốc và Quá khớp:** Thí nghiệm kiểm chứng giả thuyết rằng việc áp dụng PEFT (QLoRA) kết hợp với quy trình huấn luyện hai pha sẽ giúp giữ lại các tri thức y khoa nền tảng mạnh mẽ đã học được ở giai đoạn tiền huấn luyện trên bộ dữ liệu quy mô lớn, ngăn chặn hiện tượng quên đặc trưng khi tinh chỉnh trên tập dữ liệu y sinh nhỏ so với Full Fine-Tuning.

4.1.5 Đánh giá hiệu quả của đầu phân loại nguyên mẫu so với đầu phân loại tuyến tính

Thí nghiệm này tập trung vào việc đánh giá so sánh hiệu năng của đầu phân loại nguyên mẫu, sử dụng khoảng cách để phân lớp, so với đầu phân loại tuyến tính truyền thống. Mục đích thực nghiệm là xác minh:

- Khả năng xây dựng ranh giới quyết định của phân loại nguyên mẫu trong không gian đặc trưng.
- Sự ổn định và khả năng chống chịu của đầu phân loại nguyên mẫu khi đối mặt với hiện tượng trôi lệch biểu diễn hoặc nhiễu dữ liệu. Bằng cách định hướng quá trình tối ưu kéo gần các đặc trưng cùng lớp về phía nguyên mẫu đại diện và đẩy xa các lớp khác thông qua hàm loss khoảng cách có khoảng lề, phân loại nguyên mẫu giúp ổn định ranh giới quyết định tốt hơn đầu tuyến tính.

4.1.6 Trực quan hóa bản đồ chú ý chéo và khả năng giải thích y khoa

Thí nghiệm này nhằm trực quan hóa các vùng chú ý của mô hình khi đưa ra quyết định phân loại, từ đó cung cấp khả năng giải thích lâm sàng và tính minh bạch cho các dự đoán của mô hình đề xuất XBone-Net. Mục đích thực nghiệm cụ thể bao gồm:

- **Đánh giá khả năng định vị tổn thương giải phẫu:** Xác minh xem vùng tập trung chú ý cao nhất của bản đồ chú ý chéo trích xuất từ mô-đun Cross-Attention Fusion có thực sự trùng khớp với phân vùng tổn thương thực tế được chú thích bởi các chuyên gia y tế trên ảnh X-quang hay không.
- **Kiểm chứng tương tác đa phương thức:** Chứng minh rằng thông tin từ bệnh sử lâm sàng dạng văn bản đóng vai trò dẫn đường hiệu quả, giúp mô hình tập trung vào các vùng giải phẫu đặc trưng của từng bệnh cảnh cụ thể trên ảnh X-quang, thay vì dựa vào các chi tiết nền không liên quan.
- **Củng cố độ tin cậy trong hỗ trợ chẩn đoán:** Chứng minh tính hợp lý về mặt y học của ranh giới quyết định, giúp các bác sĩ hiểu rõ cơ sở logic của mô hình khi đưa ra dự đoán chẩn đoán, từ đó tăng cường độ tin cậy trong các ứng dụng thực tế.

4.2 Chuẩn bị dữ liệu

Để minh chứng hiệu quả của mô hình đề xuất, nhóm đã sử dụng hai tập dữ liệu xương được thu thập từ bệnh viện chấn thương chỉnh hình và bộ dữ liệu BTXRD được công bố [Yao2025]. Các tập dữ liệu này bao gồm các hình ảnh xương cùng với các nhãn và mô tả bệnh lý tương ứng. Nhóm đã thực hiện các bước tiền xử lý dữ liệu, bao gồm chuẩn hóa hình ảnh và mã hóa nhãn, để đảm bảo tính nhất quán và chất lượng của dữ liệu trước khi đưa vào quá trình huấn luyện và đánh giá mô hình.

4.2.1 Bộ dữ liệu BTXRD

Bộ dữ liệu hình ảnh X-quang U xương (Bone Tumor X-ray Radiograph dataset - BTXRD) được xây dựng nhằm hỗ trợ cho các nghiên cứu về phân loại, định vị và phân vùng tự động các khối u xương nguyên phát trên ảnh X-quang. Bộ dữ liệu này bao gồm tổng cộng 3.746 hình ảnh, mỗi hình ảnh trong BTXRD đều được gắn nhãn với các thông tin lâm sàng bao gồm giới tính, độ tuổi, bộ phận cơ thể được chụp và góc chụp. Đặc biệt, mỗi hình ảnh chứa khối u còn được bổ sung thêm các nhãn phân loại lành tính hoặc ác tính, nhãn phân loại phụ, nhãn vị trí giải phẫu, cùng với mặt nạ phân vùng và hộp giới hạn được chú thích thủ công.

Hình ảnh của bộ dữ liệu BTXRD được thu thập từ ba trung tâm lưu trữ hình ảnh y tế khác nhau. Trung tâm 1 bao gồm ba bệnh viện tại Trung Quốc: Bệnh viện trực thuộc số 1 của Đại học Y khoa Quảng Tây, Bệnh viện trực thuộc của Đại học Y khoa Dân tộc Hữu Giang và Bệnh viện Nhân dân Bách Sắc. Trung tâm 2 là nền tảng giáo dục X-quang trực tuyến Radiopaedia.org. Trung tâm 3 là cơ sở dữ liệu công cộng MedPix.


Tại Trung tâm 1, các hình ảnh X-quang của những bệnh nhân mắc u xương nguyên phát (đã được xác nhận qua mô bệnh học hoặc bởi hai chuyên gia X-quang) được thu thập trong khoảng thời gian từ tháng 7 năm 2013 đến tháng 7 năm 2023. Đối với Trung tâm 2 và 3, hai chuyên gia X-quang đã thu thập hình ảnh bằng cách tìm kiếm các từ khóa cụ thể liên quan đến u xương (như 'bone tumor', 'osteosarcoma', v.v.) và tải trực tiếp hình ảnh từ các trang web chính thức. Tiêu chí đưa vào bộ dữ liệu bắt buộc mỗi hình ảnh phải có thông tin tương ứng về giới tính và độ tuổi. Trong quá trình làm sạch dữ liệu, các mẫu u xương nguyên phát ở vùng đầu, cổ, ngực và bụng đã bị loại bỏ do số lượng ít và có nhiều nhiễu ảnh. Do đó, BTXRD chỉ bao gồm các hình ảnh khối u xương và xương bình thường thuộc các vị trí chi trên, chi dưới và xương chậu.

Trong giai đoạn gán nhãn, một bác sĩ chuyên khoa u xương với 10 năm kinh nghiệm chẩn đoán đã sử dụng công cụ gán nhãn hình ảnh Labelme [russell2008labelme] để phân vùng các khối u và vẽ hộp giới hạn xung quanh chúng. Các chú thích ban đầu này sau đó được đánh giá và xem xét lại bởi một chuyên gia khác có 20 năm kinh nghiệm nhằm đảm bảo tính

chính xác. Sau khi hoàn tất, toàn bộ thông tin về mặt nạ phân vùng và hộp giới hạn được lưu dưới định dạng JSON. Các thông tin nhãn lâm sàng khác của mỗi hình ảnh như giới tính, tuổi tác, vị trí giải phẫu và góc chụp được ghi lại trong các tệp định dạng CSV.

Cấu trúc bộ dữ liệu

Bộ dữ liệu này bao gồm tổng cộng 3.746 hình ảnh, trong đó phân bổ thành 1.879 ảnh xương bình thường, 1.525 ảnh u xương lành tính và 342 ảnh u xương ác tính. Dữ liệu hình ảnh được lưu dưới định dạng JPEG thang độ xám 8-bit, các dữ liệu về nhãn lâm sàng được lưu dưới định dạng CSV, và các thông tin về mặt nạ phân vùng cũng như hộp giới hạn được lưu dưới định dạng JSON. Cấu trúc thư mục của bộ dữ liệu được tổ chức như sau:



Hình 4.1: Sơ đồ phân cấp cấu trúc dữ liệu BTXRD

Trong đó:

- **images/**: Thư mục chứa toàn bộ hình ảnh chụp X-quang gốc của bệnh nhân dưới định dạng ảnh JPEG thang độ xám.
- **Annotations/**: Chứa các tệp nhãn dạng JSON lưu trữ tọa độ đỉnh đa giác phân vùng của khối u và hộp giới hạn tương ứng được xuất ra từ công cụ LabelMe.
- **reports/**: Thư mục lưu trữ hai nguồn văn bản phục vụ cho học máy đa phương thức:
 - **clinical/**: Chứa các báo cáo mô tả bệnh sử lâm sàng của từng bệnh nhân.
 - **xray/**: Chứa các văn bản mô tả phát hiện chẩn đoán hình ảnh trên phim X-quang.
- **dataset.csv**: Tệp bảng chứa siêu dữ liệu thô ban đầu (tuổi, giới tính, vùng xương chụp, góc chụp).
- **btxrd-labels.csv**: Tệp lưu trữ ánh xạ các lớp bệnh lý của từng ảnh phục vụ cho huấn luyện phân loại (bao gồm cả lớp phân loại đa lớp `class_id`).
- **btxrd-split.csv**: Tệp tin chỉ định phân tách phân bổ tập dữ liệu (huấn luyện, đánh giá, kiểm thử).

Phương pháp xây dựng dữ liệu báo cáo y khoa đa phương thức

Do tập dữ liệu gốc BTXRD công bố chỉ bao gồm hình ảnh X-quang, nhãn phân loại và tọa độ vùng khoanh u xương mà không đi kèm các báo cáo văn bản chẩn đoán y khoa, nhóm nghiên cứu đã thiết kế một quy trình xây dựng văn bản báo cáo y khoa đa phương thức bán tự động dựa trên khuôn mẫu và thuộc tính. Phương pháp này giúp giả lập hai nguồn dữ liệu văn bản quan trọng tương tự như trong thực tế chẩn đoán:

1. **Báo cáo lâm sàng**: Báo cáo này được tạo lập bằng cách kết hợp thông tin nhân khẩu học (độ tuổi, giới tính) và vị trí giải phẫu xương

của bệnh nhân với các bệnh lý tương ứng. Nhóm đã xây dựng các ngân hàng khuôn mẫu câu mô tả:

- Lý do khám bệnh (ví dụ: xuất hiện khối u sưng nề hoặc đau nhức ở vùng xương tương ứng).
- Thời gian khởi phát triệu chứng (được chọn ngẫu nhiên trong khoảng từ vài tuần đến vài tháng).
- Tiền sử bệnh và ghi nhận khám thực thể.

Đặc biệt, để mô phỏng chính xác bệnh cảnh lâm sàng, quy trình sinh văn bản sẽ phân nhánh dựa trên tính chất u xương. Đối với u lành tính, bệnh sử mô tả các khối u tăng trưởng chậm, không sốt, không sụt cân, không đau đêm. Ngược lại, đối với u ác tính, văn bản được thêm vào các triệu chứng nguy cấp của ung thư như đau xương tăng dữ dội về đêm, sụt cân không rõ nguyên nhân, sốt nhẹ hoặc đổ mồ hôi trộm. Các thuộc tính cá nhân của bệnh nhân sau đó được thay thế vào các chỗ trống để tạo ra văn bản lâm sàng tự nhiên và đa dạng.

2. **Báo cáo mô tả ảnh X-quang:** Báo cáo cận lâm sàng chẩn đoán hình ảnh được sinh ra dựa trên góc chụp X-quang và các dấu hiệu hình ảnh đặc trưng lâm sàng của từng phân nhóm u xương đã được chuyên gia chẩn đoán:

- Đối với u xương sụn (*osteochondroma*): văn bản sinh ra các mô tả đặc trưng như chồi xương có nắp sụn liên tục với vỏ xương và tủy xương ("*cartilage-capped bony outgrowth*", "*continuity of cortex*").
- Đối với nang xương đơn thuần (*simple bone cyst*): văn bản mô tả tổn thương tiêu xương giới hạn rõ ở vùng hành xương ("*well-defined lucent lesion in the metaphysis*").
- Đối với u tế bào khổng lồ (*giant cell tumor*): văn bản chứa mô tả tổn thương tiêu xương dạng bong bóng xà phòng ("*soap-bubble appearance*").

Các mô tả hình thái học thuật này giúp mô hình học sâu có thể liên kết giữa các đặc trưng thị giác trên phim X-quang gốc với các thuật ngữ y học chuyên ngành tương ứng trong báo cáo cận lâm sàng.

Bảng 4.1 trình bày một số mẫu ví dụ cụ thể về hình ảnh X-quang gốc cùng với hai nguồn văn bản báo cáo y khoa lâm sàng và cận lâm sàng tương ứng được xây dựng trong bộ dữ liệu BTXRD.

Thông kê số liệu

Nhằm cung cấp cái nhìn chi tiết và khách quan về cấu trúc dữ liệu, các bảng thống kê dưới đây trình bày phân bố số lượng mẫu hình ảnh theo các tập chia dữ liệu (Bảng 4.2) và phân bố theo các lớp u xương bệnh lý (Bảng 4.3).

Về mặt gán nhãn u xương, bộ dữ liệu BTXRD được tổ chức chủ yếu dưới dạng đơn nhãn, trong đó có 1.879 ảnh bình thường (không có khối u) và 1.866 ảnh có đúng 1 nhãn bệnh lý. Chỉ có duy nhất 1 hình ảnh chứa đồng thời 2 nhãn bệnh lý (u xương sụn và đa u xương sụn). Số lượng nhãn trung bình trên mỗi ảnh là 0,50 và tối đa là 2 nhãn.

Đối với phần báo cáo ảnh x-quang, có tổng cộng 3.746 tệp tương ứng với 3.746 hình ảnh. Trong đó, có 1.576 văn bản báo cáo là độc nhất (tỷ lệ độc nhất đạt 42,1%). Sự trùng lặp văn bản là do quy trình tự động sinh dựa trên các tập thuộc tính và mẫu câu cố định. Tuy nhiên, tính độc nhất này phân bố cao hơn trên các tập chia nhỏ: tập huấn luyện có 1.333/2.622 báo cáo độc nhất (50,8%), tập đánh giá có 475/562 báo cáo độc nhất (84,5%), và tập kiểm thử có 451/562 báo cáo độc nhất (80,2%). Độ dài trung bình của các báo cáo cận lâm sàng là khoảng 24,6 từ (tối thiểu là 19 từ, tối đa là 36 từ), tương đương trung bình khoảng 172 ký tự (từ 120 đến 266 ký tự).

4.2.2 Bộ dữ liệu CTCH

Bộ dữ liệu hình ảnh X-quang xương CTCH được thu thập từ bệnh viện Chấn thương Chỉnh hình, bao gồm tổng cộng 400 hình ảnh X-quang từ

Hình ảnh X-quang	Thông tin lâm sàng (Clinical)	Thông tin cận lâm sàng (X-ray)
	Patient: 58-year-old male. Chief complaint: swelling and discomfort in the tibia (shin bone) region. The patient noticed the lump 2 months ago. It has been painless and gradually increasing in size. No night pain reported. Physical examination reveals a hard, non-tender bony protuberance. No history of prior bone disease, fracture, or malignancy. Radiographic evaluation: AP view of the tibia (shin bone) was obtained.	A musculoskeletal radiograph of the bone in standard projection with evidence of osteochondroma: a pedunculated or sessile bony projection with cartilage cap. Captured at standard radiographic technique. The overall appearance favors a benign process.
	Patient: 6-year-old male. The patient reports a progressively growing swelling over the humerus (upper arm). Rapidly enlarging mass in the humerus (upper arm) over the past a few months. Associated with night pain and unintentional weight loss. Large, firm, tender mass with overlying skin warmth. Regional lymphadenopathy absent. No significant past medical history. Radiographic evaluation: AP view of the humerus (upper arm) was obtained.	A musculoskeletal radiograph of the bone in conventional radiographic view with evidence of osteosarcoma: an aggressive osteoblastic lesion with irregular periosteal new bone formation. In a routine clinical radiographic study. The imaging features raise concern for malignancy.
	Patient: 48-year-old female. The patient presents with a palpable mass on the hip bone (pelvis). The patient presents with a painful mass that has been growing rapidly. Significant weight loss of 5 kg over 1 month. Night pain disturbs sleep. Painful, rapidly growing mass with constitutional symptoms. No known chronic diseases. No prior surgeries. Radiographic evaluation: AP view of the hip bone (pelvis) was obtained.	A musculoskeletal radiograph of the bone in standard projection with evidence of other mt: a destructive bone lesion with ill-defined borders suggestive of malignancy. In a high-resolution diagnostic acquisition. The imaging features raise concern for malignancy.

Bảng 4.1: Ví dụ các mẫu dữ liệu đa phương thức trong bộ dữ liệu BTXRD

Tập dữ liệu (Split)	Số lượng hình ảnh	Tỷ lệ (%)
Huấn luyện (Train)	2.622	70,0%
Đánh giá (Validation)	562	15,0%
Kiểm thử (Test)	562	15,0%
Tổng cộng	3.746	100,0%

Bảng 4.2: Phân bố hình ảnh theo các tập dữ liệu trong BTXRD

Nhân bệnh lý (Pathology)	Số lượng	Tỷ lệ (%)
Bình thường (Normal)	1.879	50,2%
U xương sụn (<i>osteochondroma</i>)	754	20,1%
U xương ác tính (<i>osteosarcoma</i>)	297	7,9%
Đa u xương sụn (<i>multiple</i>)	263	7,0%
Nang xương đơn thuần (<i>cyst</i>)	206	5,5%
U xương lành tính khác (<i>other benign</i>)	115	3,1%
U tế bào khổng lồ (<i>giant cell</i>)	93	2,5%
U màng hoạt dịch (<i>synovial</i>)	51	1,4%
U xương ác tính khác (<i>other malignant</i>)	45	1,2%
U xơ không tạo xương (<i>osteofibroma</i>)	44	1,2%

Bảng 4.3: Phân bố các lớp bệnh lý u xương trong bộ dữ liệu BTXRD

400 bệnh nhân khác nhau. Mỗi hình ảnh được gán nhãn với các thông tin lâm sàng bao gồm lý do vào viện, quá trình bệnh lý, tiền sử bệnh lý.

Cấu trúc bộ dữ liệu

Trong đó:

- **images/**: Thư mục chứa toàn bộ hình ảnh chụp X-quang gốc của bệnh nhân dưới định dạng ảnh JPEG thang độ xám.
- **reports/**: Thư mục lưu trữ hai nguồn văn bản phục vụ cho học máy đa phương thức:
 - **clinical/**: Chứa các báo cáo mô tả bệnh sử lâm sàng của từng bệnh nhân.
 - **clinical_vi/**: Chứa các báo cáo mô tả bệnh sử lâm sàng của từng bệnh nhân bằng tiếng Việt.
 - **xray/**: Chứa các văn bản mô tả phát hiện chẩn đoán hình ảnh trên phim X-quang.


```
data/BTXRD/  
├── images/  
│   └── IMG000001.jpeg  
├── reports/  
│   ├── clinical_vi/  
│   │   └── IMG000001.txt  
│   ├── clinical/  
│   │   └── IMG000001.txt  
│   ├── xray_vi/  
│   │   └── IMG000001.txt  
│   └── xray/  
│       └── IMG000001.txt  
├── data_labeled.csv  
├── ctch-labels.csv  
└── ctch-split.csv
```

Hình 4.2: Sơ đồ phân cấp cấu trúc dữ liệu CTCH

- **xray_vi/**: Chứa các văn bản mô tả phát hiện chẩn đoán hình ảnh trên phim X-quang bằng tiếng Việt.
- **data_labeled.csv**: Tập bảng chứa siêu dữ liệu thô ban đầu.
- **ctch-labels.csv**: Tập lưu trữ ánh xạ các lớp bệnh lý của từng ảnh phục vụ cho huấn luyện phân loại.
- **ctch-split.csv**: Tập tin chỉ định phân tách phân bố tập dữ liệu (huấn luyện, đánh giá, kiểm thử).

Tiền xử lý dữ liệu

Dữ liệu gốc được thu thập từ bệnh viện Chấn thương Chỉnh hình có nhiều vấn đề như sau:

- Dữ liệu gốc được thu thập từ bệnh viện Chấn thương Chỉnh hình có nhiều loại ảnh khác nhau, bao gồm ảnh chụp X-quang, ảnh CT, ảnh MRI và các loại ảnh khác.
- Một ca khám có thể có nhiều ảnh chụp từ các vị trí giải phẫu khác nhau, từ 2 đến vài trăm ảnh, nhưng chỉ một trong số đó là đúng vị trí và có sự thể hiện rõ về bệnh lý ở mắt thị giác.
- Một bệnh nhân có thể tái khám nhiều lần, dẫn đến việc có nhiều mẫu dữ liệu tương tự.
- Nhiều ca khám thiếu hụt các trường thông tin quan trọng đến huấn luyện như không có chẩn đoán xác định, không có phân tích ảnh X-quang,...
- Đôi khi chẩn đoán xác định của bác sĩ là những căn bệnh về phần mềm (sụn, dây chằng, gân, cơ) không thể hiện được trên ảnh X-quang.

Nhóm nghiên cứu đã thực hiện các bước tiền xử lý dữ liệu để chuẩn hóa và làm sạch dữ liệu trước khi đưa vào huấn luyện mô hình. Các bước tiền xử lý bao gồm:

- Loại bỏ các ảnh không liên quan hoặc không có giá trị chẩn đoán, có các dụng cụ y tế (nẹp, đinh) che vùng tổn thương.
- Đánh dấu và phân loại các mẫu dữ liệu theo lớp bệnh lý của ảnh X-quang (nếu bệnh là gãy dây chằng thuộc về phần mềm thì nhãn vẫn là "bình thường" nếu ảnh không ghi nhận tổn thương về xương).
- Loại bỏ các ca khám trùng lặp, tái khám nhiều lần.
- Chuẩn hóa và biên dịch các báo cáo y khoa từ tiếng Việt sang tiếng Anh.
- Lọc các ca hiếm gặp, không đủ số lượng mẫu để làm dữ liệu ngoài phân phối.

4.3 Độ đo đánh giá

Để đánh giá hiệu quả của mô hình đề xuất và các mô hình đối sánh trên bài toán phân loại đa lớp u xương, nhóm nghiên cứu đã sử dụng các độ đo tiêu chuẩn trong học máy y sinh. Do tập dữ liệu BTXRD có sự mất cân bằng lớp nghiêm trọng (lớp Bình thường chiếm hơn 50% số lượng mẫu, trong khi một số lớp u hiếm như u xơ xương chỉ chiếm khoảng 1,2%), các chỉ số tính toán được áp dụng cơ chế Macro-averaging. Phương pháp này giúp phản ánh chính xác hiệu năng dự đoán trên từng lớp bệnh lý độc lập, ngăn chặn việc kết quả của lớp đa số chi phối các lớp hiếm gặp.

4.3.1 Định nghĩa toán học và ý nghĩa của các độ đo

Các chỉ số đánh giá được tính toán dựa trên các khái niệm cơ bản cho từng lớp $c \in \{1, 2, \dots, C\}$ (với $C = 10$ là số lớp):

- **True Positive (TP_c):** Số lượng mẫu thuộc lớp c được dự đoán chính xác vào lớp c .

- **False Positive (FP_c):** Số lượng mẫu thuộc lớp khác nhưng bị mô hình dự đoán nhầm vào lớp c .
- **True Negative (TN_c):** Số lượng mẫu không thuộc lớp c được dự đoán chính xác không thuộc lớp c .
- **False Negative (FN_c):** Số lượng mẫu thuộc lớp c nhưng bị mô hình dự đoán nhầm vào lớp khác.

Dưới đây là định nghĩa toán học và ý nghĩa chi tiết của từng độ đo được áp dụng:

Độ chính xác

- **Công thức:**

$$\text{Accuracy} = \frac{\sum_{c=1}^C TP_c}{N} \quad (4.1)$$

Trong đó N là tổng số lượng mẫu trong tập kiểm thử.

- **Ý nghĩa:** Chỉ số này thể hiện tỷ lệ phần trăm mẫu được chẩn đoán hoàn toàn chính xác trên toàn bộ tập dữ liệu. Độ đo này hữu ích khi cấu trúc dữ liệu cân bằng, nhưng đối với BTXRD, nó chỉ đóng vai trò tham khảo phụ vì dễ bị chi phối bởi lớp Bình thường chiếm đa số.

Độ chính xác dương tính

- **Công thức:**

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c} \quad (4.2)$$

$$\text{Macro Precision} = \frac{1}{C} \sum_{c=1}^C \text{Precision}_c \quad (4.3)$$

- **Ý nghĩa:** Precision đo lường độ tin cậy trong các dự đoán dương tính của mô hình. Ví dụ, nếu mô hình chẩn đoán 10 ca là u ác tính và Precision đạt 90%, nghĩa là có 9 ca thực sự là ác tính và chỉ có 1 ca bị chẩn đoán nhầm (dương tính giả). Trong lâm sàng, Precision

cao giúp giảm tỷ lệ chỉ định sinh thiết nhầm và giảm gánh nặng chi phí cũng như tâm lý cho bệnh nhân.

Độ phủ

- **Công thức:**

$$\text{Sensitivity}_c = \text{Recall}_c = \frac{TP_c}{TP_c + FN_c} \quad (4.4)$$

$$\text{Macro Sensitivity} = \frac{1}{C} \sum_{c=1}^C \text{Sensitivity}_c \quad (4.5)$$

- **Ý nghĩa:** Độ nhạy phản ánh khả năng phát hiện bệnh của mô hình, tức là tỷ lệ bệnh nhân thực sự có u được mô hình nhận diện chính xác. Nếu một mô hình có độ nhạy 95% đối với u ác tính osteosarcoma, điều đó nghĩa là cứ 100 bệnh nhân mắc bệnh thì mô hình phát hiện được 95 người, chỉ bỏ sót 5 người (âm tính giả). Chỉ số này bắt buộc phải duy trì ở mức cao trong chẩn đoán y sinh để đảm bảo an toàn tính mạng cho người bệnh.

Độ đặc hiệu

- **Công thức:**

$$\text{Specificity}_c = \frac{TN_c}{TN_c + FP_c} \quad (4.6)$$

$$\text{Macro Specificity} = \frac{1}{C} \sum_{c=1}^C \text{Specificity}_c \quad (4.7)$$

- **Ý nghĩa:** Độ đặc hiệu đo lường khả năng nhận diện các ca âm tính (không mắc bệnh c). Đối với lớp Bình thường, Specificity cao đồng nghĩa với việc mô hình ít khi chẩn đoán nhầm một người khỏe mạnh là có khối u. Chỉ số này giúp bảo vệ bệnh nhân khỏi các quy trình điều trị nhầm lẫn có hại cho sức khỏe.

Chỉ số F1-Score

- **Công thức:**

$$F1_c = 2 \times \frac{\text{Precision}_c \times \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \quad (4.8)$$

$$\text{Macro F1-Score} = \frac{1}{C} \sum_{c=1}^C F1_c \quad (4.9)$$

- **Ý nghĩa:** F1-Score là trung bình điều hòa của Precision và Recall, đóng vai trò là thước đo trung thực nhất cho sức khỏe tổng thể của mô hình. F1-Score chỉ cao khi cả Precision và Recall đều cao. Nếu mô hình có xu hướng dự đoán bừa để tăng Recall hoặc chỉ dự đoán các ca cực kỳ dễ để tăng Precision, chỉ số F1-Score sẽ bị kéo tụt xuống. Chỉ số trung bình vĩ mô (Macro F1-Score) là độ đo chính được sử dụng để xếp hạng các mô hình đối sánh trong nghiên cứu này.

Diện tích dưới đường cong ROC

- **Công thức:**

$$\text{Macro AUROC} = \frac{1}{C} \sum_{c=1}^C \text{AUC}_c \quad (4.10)$$

Trong đó AUC_c là diện tích dưới đường cong ROC của lớp c được tính toán theo phương pháp một đối tất cả (One-vs-Rest).

- **Ý nghĩa:** ROC AUC thể hiện xác suất mô hình xếp hạng một mẫu dương tính thực sự cao hơn một mẫu âm tính thực sự. Giá trị AUROC bằng 0,5 tương đương đoán ngẫu nhiên, trong khi bằng 1,0 thể hiện khả năng phân tách hoàn hảo giữa các lớp bệnh lý. Chỉ số này đại diện cho năng lực trích xuất đặc trưng thuần túy của mô hình, độc lập với ngưỡng quyết định phân lớp được lựa chọn.

Ma trận nhầm lẫn

- **Ý nghĩa:** Trong y học, ma trận nhầm lẫn không chỉ cung cấp các con số mà còn mang ý nghĩa định hướng chẩn đoán sai lệch. Nó giúp các bác sĩ hiểu rõ mô hình đang phân loại nhầm giữa các lớp nào với nhau (ví dụ: mô hình có xu hướng nhầm u ác tính osteosarcoma sang u lành tính osteochondroma hay không). Sự nhầm lẫn giữa hai lớp lành tính ít gây hậu quả nghiêm trọng hơn so với việc chẩn đoán nhầm từ một u ác tính sang một u lành tính hoặc bình thường. Do đó, ma trận nhầm lẫn là công cụ đặc lực để chẩn đoán lâm sàng lỗi hệ thống của mô hình.

4.4 Thiết lập thực nghiệm

Phần này trình bày các thiết lập thực nghiệm, bao gồm môi trường phần cứng và phần mềm, cũng như các siêu tham số được sử dụng trong quá trình huấn luyện mô hình. Các thiết lập này nhằm đảm bảo tính nhất quán và khả năng tái tạo của các thí nghiệm.

4.4.1 Môi trường thực nghiệm

- **Phần cứng:** NVIDIA RTX 5060ti 16GB, CPU Ultra 7 265KF, RAM 32GB
- **Phần mềm:** Python 3.11.15, PyTorch 2.11.0, CUDA 12.8, HuggingFace Transformers

Siêu tham số	Pha 1 (Tương phản)
Độ phân giải ảnh đầu vào	224×224 pixels
Bộ tối ưu hóa	AdamW
Tốc độ học	2×10^{-4}
Suy giảm trọng số	1×10^{-2}
Bộ điều chỉnh tốc độ học	Cosine Annealing
Tỷ lệ khởi động	0.1
Kích thước lô	32
Số epoch tối đa	50
Số epoch dừng sớm	5 epochs
Nhiệt độ tương phản (τ)	0.07
Trạng thái tham số Backbone	Tinh chỉnh qua PEFT
Hạng QLoRA (r)	16
Hệ số QLoRA (α)	32
Tỷ lệ bỏ học QLoRA	0.1

Bảng 4.4: Bảng tổng hợp siêu tham số ở pha 1 và thiết lập của chúng

Siêu tham số	Pha 2 (Phân loại)
Độ phân giải ảnh đầu vào	224×224 pixels
Bộ tối ưu hóa	AdamW
Tốc độ học	1×10^{-3}
Suy giảm trọng số	1×10^{-4}
Bộ điều chỉnh tốc độ học	Cosine Annealing
Tỷ lệ khởi động	0.1
Kích thước lô	32
Số epoch tối đa	50 / 100
Số epoch dừng sớm	5 epochs
Nhiệt độ tương phản (τ)	Không áp dụng
Trạng thái tham số Backbone	Đông bằng
Hạng QLoRA (r)	Không áp dụng
Hệ số QLoRA (α)	Không áp dụng
Tỷ lệ bỏ học QLoRA	Không áp dụng

Bảng 4.5: Bảng tổng hợp siêu tham số ở pha 2 và thiết lập của chúng

4.4.2 Tham số thực nghiệm

4.5 Kết quả thực nghiệm và Thảo luận

4.5.1 Đánh giá so sánh hiệu năng chẩn đoán với các mô hình đối sánh

Kết quả đối sánh trên bộ dữ liệu BTXRD

Bảng 4.6 trình bày kết quả thực nghiệm chi tiết của các mô hình trên tập kiểm thử (Test Set) của bộ dữ liệu BTXRD.

Mô hình	Backbone	F1-Macro $\uparrow$	Accuracy $\uparrow$	Macro AUROC $\uparrow$	Specificity $\uparrow$
ResNet-50	ResNet-50	0,3099	0,6441	0,8006	0,9438
OpenAI CLIP	ViT-B/16	0,1733	0,6014	0,6160	0,9303
MedCLIP	Swin-Tiny	0,7784	0,9609	0,9984	0,9959
BiomedCLIP	ViT-B/16	0,8105	0,9448	0,9940	0,9937
PubMedCLIP	ViT-B/32	0,8434	0,9466	0,9886	0,9942
XBone-Net	BiomedCLIP	0,8583	0,9626	0,9869	0,9945

Bảng 4.6: Bảng so sánh kết quả thực nghiệm giữa mô hình đề xuất và các baselines

Dựa trên bảng kết quả, nhóm đưa ra các phân tích và thảo luận sau:

- **BiomedCLIP Zero-shot (B6):** Đạt F1-Macro chỉ 0,1056, Accuracy đạt 33,81% và Specificity đạt 90,64%. Kết quả thấp này phản ánh thách thức cực kỳ lớn của việc áp dụng trực tiếp mô hình VLM y học gốc mà không qua bất kỳ giai đoạn tinh chỉnh hay thích ứng miền nào. Khoảng cách miền kết hợp với các ranh giới bệnh lý u xương tinh tế trên ảnh chụp X-quang làm cho các phép đo cosine zero-shot đơn thuần không thể phân biệt chính xác. Điều này chứng minh quy trình huấn luyện hai pha đề xuất và đầu phân loại Prototypical Head là bắt buộc để đạt hiệu năng lâm sàng hữu ích.
- **Mô hình đề xuất XBone-Net:** Đạt đỉnh hiệu năng vượt trội với F1-Macro là **0,8583**, độ chính xác chẩn đoán toàn cục đạt **96,26%**

và Specificity đạt **99,45%**. Kết quả này chứng minh rằng việc kết hợp đồng bộ quy trình huấn luyện hai pha (căn chỉnh tương đối ảnh-văn bản y khoa ở pha 1 và phân loại ở pha 2) cùng với đầu phân loại Prototypical Head đã giúp tối ưu hóa tốt nhất ranh giới quyết định giữa các lớp u xương.

- **Baselines y khoa (PubMedCLIP và BiomedCLIP):** Cả hai mô hình đều đạt kết quả rất cao (F1-Macro lần lượt là 0,8434 và 0,8105) khi được tích hợp thêm QLoRA và Cross-Attention. PubMedCLIP và BiomedCLIP sở hữu các bộ trích xuất đặc trưng được pre-train trên hàng triệu cặp ảnh-văn bản y sinh y học chuyên sâu (PMC-15M và ROCO), giúp chúng có lợi thế tự nhiên cực kỳ lớn trong việc biểu diễn ảnh X-quang xương.
- **MedCLIP:** Đạt F1-Macro là 0,7784, Accuracy đạt 96,09% và Specificity đạt 99,59%. MedCLIP đạt kết quả phân loại rất khả quan do được thiết kế chuyên biệt cho ảnh y tế và huấn luyện tinh chỉnh toàn bộ (Full FT). Tuy nhiên, vì kích thước của backbone Swin-Tiny tương đối nhỏ và kiến trúc học sâu đơn giản hơn so với ViT-B, MedCLIP vẫn có phần lép vế về mặt F1-Macro so với BiomedCLIP hay mô hình đề xuất XBone-Net.
- **ResNet-50:** Đạt F1-Macro 0,3099 và Accuracy 64,41%. Do chỉ sử dụng dữ liệu đơn phương thức (Image-only), ResNet-50 gặp khó khăn lớn khi đối mặt với các bệnh lý u xương có hình thái tổn thương tương đối giống nhau trên ảnh nhưng lại có bệnh cảnh lâm sàng khác nhau. Tuy nhiên, tính ổn định của mạng tích chập (CNN) giúp nó vượt qua OpenAI CLIP trên tập dữ liệu nhỏ.
- **OpenAI CLIP:** Đạt kết quả thấp nhất với F1-Macro chỉ 0,1733. Nguyên nhân đến từ khoảng cách miền dữ liệu. OpenAI CLIP được pre-train trên ảnh internet tự nhiên (chó, mèo, phong cảnh), khiến bộ trích xuất đặc trưng của nó hầu như không thể biểu diễn tốt ảnh X-quang y khoa thang độ xám.

Kết quả đối sánh trên bộ dữ liệu nội bộ CTCH

Nhằm đánh giá khả năng tổng quát hóa của mô hình đề xuất trên dữ liệu thực tế tại Việt Nam, nhóm nghiên cứu thực hiện đánh giá đối sánh trên bộ dữ liệu nội bộ CTCH được thu thập tại Bệnh viện Chấn thương Chỉnh hình TP.HCM.

4.5.2 Đánh giá khả năng phát hiện dữ liệu ngoài phân phối

4.5.3 Các thí nghiệm rời rạc

Nhóm đã thực hiện các thí nghiệm loại bỏ thành phần để bóc tách đóng góp cụ thể của các mô-đun đề xuất trong kiến trúc XBone-Net.

Đánh giá vai trò của các nguồn thông tin văn bản lâm sàng

Mục đích thí nghiệm này là đánh giá tác động của việc tích hợp văn bản lâm sàng và cận lâm sàng đến kết quả chẩn đoán, đồng thời xác định xem có xảy ra hiện tượng rò rỉ nhãn hay không. Nhóm so sánh 4 kịch bản văn bản tại Bảng 4.7.

Kịch bản văn bản	Văn bản sử dụng	F1-Macro	Accuracy	Macro AUROC
Image only	Không sử dụng	0,2052	0,6050	0,7857
Clinical only	Bệnh sử lâm sàng	0,8583	0,9626	0,9869
X-ray only	Mô tả kết quả X-quang	1,0000	1,0000	1,0000
Both texts	Lâm sàng + X-quang	1,0000	1,0000	1,0000

Bảng 4.7: Bảng kết quả ablation về nguồn văn bản đầu vào

Thảo luận kết quả:

- **Hiện tượng rò rỉ nhãn (Label Leakage):** Các kịch bản có sử dụng văn bản phát hiện X-quang (*xray*) đạt F1-Macro tuyệt đối là 1,0000. Phân tích văn bản cho thấy báo cáo X-quang của bác sĩ chẩn đoán hình ảnh chứa trực tiếp tên lớp bệnh lý (ví dụ: "osteosarcoma",

"osteochondroma"). Mô hình học sâu đã bỏ qua ảnh chụp và chỉ đọc văn bản kết luận này để phân loại. Trong lâm sàng thực tế, khi bệnh nhân mới vào viện khám sàng lọc, báo cáo X-quang chưa được viết. Do đó, để đảm bảo tính thực tiễn và tính khoa học, chỉ có kịch bản sử dụng bệnh sử lâm sàng (clinical) là hợp lệ.

- **Đóng góp của Bệnh sử lâm sàng:** Khi chuyển từ chỉ dùng ảnh (T2_imgonly) sang dùng ảnh kèm bệnh sử lâm sàng, F1-Macro tăng vọt từ **0,2052** lên **0,8583** (tăng gấp 4 lần). Điều này chứng minh thông tin y khoa lâm sàng (như độ tuổi, vị trí đau đùi, các triệu chứng sốt/sụt cân) là "la bàn" vô cùng đặc lực giúp bộ phân loại định hướng chính xác lớp bệnh lý u xương.

Đánh giá ảnh hưởng của chiến thuật tinh chỉnh backbone

Mục đích thí nghiệm này là đánh giá hiệu năng khi đóng băng backbone so với tinh chỉnh (Full FT hoặc QLoRA PEFT) trong quy trình huấn luyện.

Chiến thuật	Pha 1	F1-Macro	Accuracy	Macro AUROC
Đóng băng backbone	Không	0,8095	0,9431	0,9907
Tinh chỉnh LoRA	Có (Clinical)	0,6140	0,8808	0,9665
Tinh chỉnh toàn bộ	Có (Clinical)	0,5951	0,8559	0,9632
Tinh chỉnh QLoRA (Gốc)	Có (Xray)	0,6464	0,8754	0,9741
Tinh chỉnh QLoRA (Cải tiến)	Có (Clinical)	0,8583	0,9626	0,9869

Bảng 4.8: Bảng kết quả ablation về chiến thuật tinh chỉnh backbone

Thảo luận kết quả:

- **Hiện tượng trôi lệch biểu diễn (Representation Drift):** Bản gốc `full_proposed` chỉ đạt F1-Macro 0,6464 (kém hơn so với đóng băng hoàn toàn backbone `T3_no_ft` đạt 0,8095). Nguyên nhân là ở pha 1, mô hình gốc căn chỉnh tương đối ảnh-văn bản với báo cáo Xray, nhưng ở pha 2 lại sử dụng báo cáo Clinical. Việc lệch nguồn thông tin này làm không gian biểu diễn bị trôi lệch, gây suy giảm chất lượng đặc trưng. Khi đồng bộ hóa dùng Clinical ở cả hai pha (`T2_clinical`), hiệu năng vượt lên đạt ****0,8583****.

- **Quên lãng thảm họa (Catastrophic Forgetting) trên tập dữ liệu nhỏ:** Thí nghiệm tinh chỉnh toàn bộ hệ thống (T3_full_ft) đạt kết quả thấp nhất (F1-Macro 0,5951). Việc cập nhật toàn bộ tham số của Vision Transformer trên tập dữ liệu nhỏ dễ dàng phá hủy các biểu diễn đặc trưng y tế mạnh mẽ đã học được ở giai đoạn pre-train, gây ra hiện tượng quá khớp (overfitting). Việc đóng băng backbone và chỉ cập nhật adapter LoRA siêu nhẹ ở Pha 1 giúp bảo toàn tối đa tri thức nền.

Đánh giá hiệu quả của đầu phân loại nguyên mẫu so với đầu phân loại tuyến tính

Nhóm thí nghiệm này nhằm kiểm tra hiệu quả của đầu phân loại nguyên mẫu (Prototypical Head) so với đầu phân loại tuyến tính (Linear Head) truyền thống trong bài toán phân loại đa lớp u xương.

Backbone	Bộ phân loại	F1-Macro	Accuracy	Macro AUROC
BiomedCLIP (Frozen)	Linear Head (B4)	0,8105	0,9448	0,9940
BiomedCLIP (Frozen)	Prototypical Head	0,8095	0,9431	0,9907
BiomedCLIP (QLoRA)	Linear Head	0,6261	0,8737	0,9693
BiomedCLIP (QLoRA)	Prototypical Head	0,6464	0,8754	0,9741

Bảng 4.9: Bảng kết quả ablation về bộ phân loại Classifier Head

Thảo luận kết quả:

- Khi backbone được đóng băng hoàn toàn (các đặc trưng có độ phân tách cao), cả hai bộ phân loại đều đạt hiệu năng xuất sắc ngang nhau (0,81 F1-Macro).
- Tuy nhiên, khi backbone bị trôi lệch biểu diễn (đặc trưng bị nhiễu do lệch pha thông tin), bộ phân loại nguyên mẫu Prototypical Head (full_proposed đạt 0,6464) vượt trội hơn so với Linear Head (T4_crossattn_1 đạt 0,6261). Điều này chứng minh học máy khoảng cách (Metric Learning) của Prototypical Head giúp kéo các vector đặc trưng của cùng một lớp lại gần nhau và đẩy xa các lớp khác bằng khoảng lề xác định, tăng cường khả năng chịu lỗi của ranh giới quyết định.


4.5.4 Trực quan hóa bản đồ chú ý chéo và khả năng giải thích y khoa

Để chứng minh khả năng giải thích lâm sàng (clinical explainability) và tính hợp lý về mặt y khoa của mô hình đề xuất XBone-Net, nhóm nghiên cứu tiến hành trích xuất bản đồ chú ý chéo (Cross-Attention Map) từ khối Transformer của mô-đun Cross-Attention Fusion cuối cùng trước đầu phân loại. Bản đồ này được thu nhận bằng cách tính toán trọng số tự chú ý (self-attention) của token đại diện lớp hình ảnh (CLS token) đối với các token vị trí hình ảnh (196 token patch), thể hiện mức độ tập trung của mô hình vào các vùng không gian trên ảnh chụp X-quang khi tổng hợp với thông tin bệnh sử lâm sàng.

Các kết quả trực quan hóa attention map chồng lên ảnh chụp X-quang gốc đối với một số nhóm bệnh lý điển hình từ tập kiểm thử được trình bày trong Hình 4.3.

Phân tích định tính y khoa và kết quả định lượng:

- **Trường hợp Bình thường (Hình 4.3a):** Đối với ca chẩn đoán bình thường không có khối u xương (Normal), mô hình đề xuất dự đoán chính xác nhãn NORMAL với độ tự tin đạt **46,8%**. Bản đồ chú ý chéo cho thấy trọng số chú ý không tập trung vào bất kỳ vùng khu trú bất thường nào, mà phân bố rộng rãi, đồng đều và mờ nhạt trên toàn bộ vùng giải phẫu của đầu dưới xương đùi và khớp gối. Điều này phản ánh sự tương khớp hoàn toàn với thực tế lâm sàng khi không có bất kỳ tổn thương hay cấu trúc khối u cục bộ nào cần phải khoanh vùng.
- **Trường hợp U xương sụn (Hình 4.3b):** Đối với bệnh lý u xương sụn (Osteochondroma), mô hình dự đoán chính xác lớp OSTEOCHONDROMA với độ tự tin rất cao đạt **89,5%**. Bản đồ chú ý của mô hình tập trung cực kỳ chính xác vào phần chồi xương nhô ra từ bề mặt hành xương đùi (exostosis) - đây chính là vùng tổn thương giải phẫu bệnh lý đặc trưng nhất của loại u này, hoàn toàn trùng khớp với phân vùng tổn thương thực tế (Ground Truth) được khoanh bằng đường nét đứt màu xanh lá.



Hình 4.3: Trực quan hóa bản đồ chú ý chéo (Cross-Attention Map) của mô hình đề xuất XBone-Net trên các nhóm bệnh lý điển hình (mỗi cặp gồm ảnh chụp X-quang gốc bên trái đã vẽ đường nét đứt màu xanh lá thể hiện phân vùng tổn thương thực tế - Ground Truth và ảnh chồng bản đồ chú ý chéo ở bên phải).

- **Trường hợp Sarcoma xương (Hình 4.3c):** Sarcoma xương (Osteosarcoma) là một khối u ác tính có tính chất hủy xương và xâm lấn mạnh. Mô hình XBone-Net đã nhận diện chính xác bệnh lý này với độ tự tin rất cao đạt **90,7%**. Bản đồ trực quan hóa cho thấy mô hình tập trung mạnh mẽ và chính xác vào vùng hủy xương ở đầu dưới xương đùi kèm theo phản ứng màng xương dạng thớ (Sunburst/Codman triangle), chứng minh mô hình có khả năng định vị rất tốt các dấu hiệu nguy kịch của bệnh lý ác tính này.
- **Trường hợp U tế bào khổng lồ (Hình 4.3d):** Ở trường hợp u tế bào khổng lồ (Giant cell tumor), mô hình chẩn đoán chính xác lớp GIANT CELL TUMOR với độ tự tin đạt **27,7%**. Mặc dù đây là lớp bệnh lý hiếm gặp dẫn đến độ tự tin thấp hơn, bản đồ chú ý chéo vẫn tập trung rất rõ rệt vào vùng đầu xương (epiphysis) giáp khớp gối - vị trí tổn thương đặc hữu dạng "bong bóng xà phòng" (soap bubble appearance) của loại u này, trùng khớp với vùng chú thích Ground Truth.

Các kết quả định tính trên chứng minh rằng mô hình XBone-Net không chỉ đưa ra các dự đoán phân loại dựa trên các tương quan thống kê thuần túy, mà đã thực sự học được cách liên kết chặt chẽ thông tin gợi ý từ bệnh sử lâm sàng để định vị đúng các vùng tổn thương giải phẫu bệnh lý thực tế trên ảnh X-quang, mang lại giá trị giải thích cao và củng cố niềm tin cho các y bác sĩ trong quá trình hỗ trợ chẩn đoán.

Chương 5

Kết luận và hướng phát triển

Tài liệu tham khảo