

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - Nguyễn Gia
Kiệt

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - 22127390

Nguyễn Gia Kiệt - 22127221

**PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

GIÁO VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

Tp. Hồ Chí Minh, tháng 07/2026

Lời cảm ơn

Nhóm xin chân thành cảm ơn PGS.TS Lý Quốc Ngọc và ThS. Đỗ Thị Thanh Hà đã dành rất nhiều thời gian, tâm huyết để định hướng, tận tình hướng dẫn và đưa ra những lời khuyên khoa học quý báu cho nhóm trong suốt quá trình nghiên cứu và thực hiện khóa luận tốt nghiệp với đề tài "Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức".

Xin trân trọng gửi lời cảm ơn sâu sắc đến Ban Chủ nhiệm cùng toàn thể quý thầy cô Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG-HCM. Những kiến thức nền tảng vững chắc mà các thầy cô đã truyền đạt trong bốn năm học vừa qua và môi trường thí nghiệm tuyệt vời chính là hành trang quan trọng nhất giúp nhóm có thể hoàn thành tốt hướng nghiên cứu này.

Nhóm cũng xin gửi lời cảm ơn đến các y bác sĩ tại Bệnh viện Chấn thương Chỉnh hình TP.HCM và thầy Võ Thế Hào đã hỗ trợ chia sẻ nguồn dữ liệu ảnh X-quang cũng như tư vấn các kiến thức chuyên môn về y khoa, giúp mô hình nghiên cứu bám sát với quy trình chẩn đoán lâm sàng thực tế.

Cuối cùng, nhóm xin dành lời tri ân đến gia đình, người thân và những người bạn đồng hành đã luôn là chỗ dựa tinh thần vững chắc, động viên và tạo mọi điều kiện tốt nhất để nhóm có thể tập trung học tập và hoàn thành chương trình đại học.

Mặc dù đã có nhiều cố gắng trong quá trình thực hiện, nhưng do hạn chế về mặt thời gian và kinh nghiệm nghiên cứu, khóa luận chắc chắn không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô và hội đồng đánh giá để đề tài được hoàn thiện hơn.

Xin chân thành cảm ơn!

Mục lục

Lời cảm ơn	i
Mục lục	ii
1 Giới thiệu	1
1.1 Giới thiệu bài toán	2
1.2 Sơ đồ chung của hệ thống	3
2 Phương pháp đề xuất	4
2.1 Ý tưởng ban đầu	4
2.2 Tiền xử lý văn bản với UMLS	5
2.3 Giai đoạn off-line	5
2.3.1 Domain-Adaption với kỹ thuật LoRA	6
2.3.2 Fusion-learning	8
2.4 Giai đoạn online	12
2.5 Đóng góp của phương pháp	13
Tài liệu tham khảo	14

Danh sách hình

1.1	Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức	3
2.1	Công đoạn Tiền xử lý văn bản với UMLS.	5
2.2	Sơ đồ chung của hệ thống trong công đoạn Domain-Adaption.	6
2.3	Sơ đồ chung của hệ thống trong công đoạn Fusion-learning.	8
2.4	Sơ đồ mạng prototypical.	10
2.5	Sơ đồ chung của hệ thống trong giai đoạn online.	12

Danh sách bảng

Chương 1

Giới thiệu

Chương này trình bày tổng quan về bài toán hỗ trợ chẩn đoán bệnh lý trên ảnh X-quang bằng học sâu đa phương thức, đặc biệt trong bối cảnh dữ liệu y tế thường có tính phức tạp cao và phụ thuộc mạnh vào kinh nghiệm của bác sĩ trong quá trình phân tích. Bên cạnh thông tin hình ảnh, quá trình chẩn đoán thực tế còn yêu cầu kết hợp thêm các thông tin lâm sàng và báo cáo y khoa nhằm đưa ra đánh giá toàn diện về tình trạng bệnh nhân. Tuy nhiên, việc khai thác đồng thời nhiều nguồn dữ liệu khác nhau vẫn còn là một thách thức lớn đối với các hệ thống học sâu hiện nay.

Xuất phát từ thực tế đó, khóa luận hướng đến nghiên cứu và xây dựng một hệ thống học sâu đa phương thức kết hợp dữ liệu hình ảnh X-quang và thông tin văn bản lâm sàng nhằm nâng cao hiệu năng phân loại và hỗ trợ chẩn đoán. Đồng thời, đề tài cũng khảo sát các phương pháp tinh chỉnh mô hình tiền huấn luyện, cơ chế dung hợp dữ liệu và cơ chế giải thích nhằm tăng khả năng tận dụng tri thức nền cũng như cải thiện tính minh bạch trong quá trình suy luận của mô hình. Kết quả nghiên cứu được kỳ vọng góp phần xây dựng một hệ thống hỗ trợ chẩn đoán có độ chính xác cao, khả năng giải thích tốt và tạo tiền đề cho việc ứng dụng các mô hình trí tuệ nhân tạo đa phương thức trong lĩnh vực y tế tại Việt Nam.

1.1 Giới thiệu bài toán

Bài toán được nghiên cứu trong đề tài là bài toán phân loại đa nhãn ảnh X-quang sử dụng học sâu đa phương thức (multimodal deep learning). Mục tiêu của hệ thống là dự đoán các loại bệnh hoặc tổn thương dựa trên đồng thời dữ liệu hình ảnh X-quang và thông tin văn bản lâm sàng liên quan.

- **Đầu vào (Input):** Hệ thống nhận vào các nguồn dữ liệu sau:

- Ảnh X-quang của bệnh nhân:

$$x^{img} \in \mathbb{R}^{H \times W \times C}$$

trong đó:

- * H, W : chiều cao và chiều rộng ảnh,
 - * C : số kênh màu của ảnh.
- Thông tin văn bản lâm sàng gồm các báo cáo đọc ảnh của bác sĩ đọc ảnh, lời khai bệnh nhân và lịch sử bệnh lý được biểu diễn dưới dạng chuỗi token:

$$x^{txt} = \{w_1, w_2, \dots, w_T\}$$

trong đó:

- * w_t : token thứ t ,
 - * T : số lượng token trong văn bản.
- Tập nhãn được định nghĩa trước:

$$\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$$

với K là số lớp bệnh cần phân loại.

- **Đầu ra (Output):** Hệ thống sinh ra:


- Các nhãn dự đoán cuối cùng, được sắp xếp theo thứ tự:

$$y^* = \arg \max_{k \in \{1, \dots, K\}} \hat{y}_k$$

- Bản đồ nhiệt trực quan hóa trên ảnh nhằm giải thích dự đoán của mô hình

1.2 Sơ đồ chung của hệ thống

Hệ thống học sâu đa phương thức được đề xuất bao gồm bốn thành phần chính: bộ mã hóa ảnh, bộ mã hóa văn bản, bộ dung hợp dữ liệu và bộ phân loại. Sơ đồ tổng quan của hệ thống được thể hiện ở Hình 1.1.



Hình 1.1: Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức

Chương 2

Phương pháp đề xuất

2.1 Ý tưởng ban đầu


Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế theo hướng tích hợp tri thức y khoa nhằm nâng cao khả năng học ít mẫu và phát hiện dữ liệu ngoài phân phối. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Tiền xử lý văn bản với UMLS:** Phương pháp sử dụng GLiNER để trích xuất các tình trạng y khoa cùng với mức độ và vị trí từ báo cáo chẩn đoán ảnh X-quang, sau đó ánh xạ chúng vào hệ thống phân loại UMLS (Unified Medical Language System) để chuẩn hóa và liên kết tri thức từ đó xây dựng được các câu mô tả nhằm làm giàu ngữ nghĩa.
- **Bộ mã hóa ảnh:** Kế thừa lại mô hình ViT-Base của phương pháp BiomedCLIP [1]
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [1]
- **Bộ dung hợp dữ liệu:** Kỹ thuật Bidirectional Cross-Attention được xây dựng dựa trên cơ chế cross-attention nhằm học mối quan hệ ngữ nghĩa giữa đặc trưng hình ảnh và đặc trưng văn bản y khoa.
- **Bộ phân loại:** Dùng phương pháp metric-based few-shot learning với một prototypical network, nhận được quyết định bởi khoảng cách đến các prototype trong không gian biểu diễn chung, thay vì lớp phân

loại truyền thống làm ràng buộc mô hình phân loại vào các nhãn đã biết, giúp phát hiện dữ liệu ngoài phân phối khi khoảng cách đó vượt quá ngưỡng xác định.

Đồng thời, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán.

2.2 Tiền xử lý văn bản với UMLS



Hình 2.1: Công đoạn Tiền xử lý văn bản với UMLS.


Công đoạn tiền xử lý được thực hiện ở toàn bộ 2 giai đoạn offline và online của phương pháp, sử dụng GLiNER để trích xuất các tình trạng y khoa cùng với mức độ và vị trí từ báo cáo chẩn đoán ảnh X-quang, sau đó ánh xạ chúng vào hệ thống phân loại UMLS (Unified Medical Language System) để chuẩn hóa và liên kết tri thức từ đó xây dựng được các câu mô tả nhằm làm giàu ngữ nghĩa.

2.3 Giai đoạn off-line

Giai đoạn off-line nhằm xây dựng bộ tham số cho mô hình, thiết lập không gian biểu diễn chung và học cách dung hợp giữa đặc trưng hình ảnh X-quang và ngữ nghĩa y khoa.

Giai đoạn off-line gồm 2 công đoạn: Domain-Adaption và Fine-tuning. Trong đó, công đoạn Domain-Adaption nhằm mục đích giúp mô hình thích nghi từ miền dữ liệu tiền huấn luyện lớn sang miền dữ liệu y khoa đích của bài toán, trong khi công đoạn Fine-tuning tập trung vào việc tối ưu hóa khả năng dung hợp dữ liệu và phân loại trên tập dữ liệu mục tiêu.

2.3.1 Domain-Adaption với kỹ thuật LoRA



Hình 2.2: Sơ đồ chung của hệ thống trong công đoạn Domain-Adaption.

Trong công đoạn này, mục tiêu chính giúp mô hình học cách biểu diễn sao cho các cặp ảnh và báo cáo khám tổng quát chung lớp nằm gần nhau hơn trong không gian biểu diễn bằng cách tối ưu hàm mất mát khớp ngữ nghĩa (Semantic Matching Loss), mô hình tuân theo framework contrastive learning để căn chỉnh bộ mã hóa BiomedCLIP về miền dữ liệu X-Quang xương được sử dụng, với đầu vào là các cặp ảnh X-quang và phân tích ảnh tương ứng của bác sĩ. Dữ liệu được đưa vào bộ mã hóa tương ứng để trích xuất đặc trưng, sau đó được chiếu vào không gian chung và chuẩn hóa để so sánh và thực hiện điều chỉnh. Kết quả là các cặp hình ảnh và văn bản giống nhau hoặc chung lớp nằm gần nhau hơn gọi là các semantic clusters, trong khi các cặp văn bản khác lớp sẽ nằm xa nhau hơn.

Nhóm thực hiện tinh chỉnh (fine-tuning) đồng thời Vision Encoder và Text Encoder bằng kỹ thuật LoRA (Low-Rank Adaptation): Thay vì tinh

chỉnh toàn bộ trọng số của Vision Encoder và Text Encoder, kỹ thuật này đóng băng hai Encoder, sau đó chỉ tạo và cập nhật một ma trận nhỏ các tham số hạng thấp (low-rank) được chèn vào các khối Attention của các bộ mã hóa. Điều này giúp giảm thiểu rủi ro quá khớp (overfitting) và bảo tồn tri thức nền tảng của các mô hình mã hóa với trường hợp ít mẫu học.

Để cập nhật trọng số của ma trận LoRA, nhóm sử dụng **Hàm mất mát Khớp ngữ nghĩa (Semantic Matching Loss - $\mathcal{L}_{SM}$)** nhằm đồng bộ hóa không gian biểu diễn đa phương thức. Thay vì tính toán trên các véc-tơ tổng, mô hình thiết lập ma trận tương đồng $s(I_i, T_j)$ dựa trên sự căn chỉnh giữa các vùng ảnh (patches) của ảnh I_i và các từ vựng (tokens) của câu lệnh T_j .

Hàm mất mát được sử dụng là Semantic Matching Loss $\mathcal{L}_{SM}$ được định nghĩa là trung bình cộng của hai hàm mất mát tương phản hai chiều (Bi-directional Contrastive Loss), bao gồm chiều từ ảnh sang chữ ($\mathcal{L}_{I2T}$) và từ chữ sang ảnh ($\mathcal{L}_{T2I}$):

$$\mathcal{L}_{I2T} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s(I_i, T_i)/\tau)}{\sum_{j=1}^N \exp(s(I_i, T_j)/\tau)} \quad (2.1)$$

$$\mathcal{L}_{T2I} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s(I_i, T_i)/\tau)}{\sum_{j=1}^N \exp(s(I_j, T_i)/\tau)} \quad (2.2)$$


$$\mathcal{L}_{SM} = \frac{1}{2}(\mathcal{L}_{I2T} + \mathcal{L}_{T2I}) \quad (2.3)$$

trong đó, N là kích thước mini-batch, $s(I_i, T_j)$ là điểm tương đồng ngữ nghĩa tổng hợp giữa ảnh i và văn bản j , và τ là siêu tham số nhiệt độ (temperature) giúp điều chỉnh độ nhạy của hàm phạt đối với các mẫu âm tính (negative samples). Bằng cách tối ưu $\mathcal{L}_{SM}$, mô hình đẩy các đặc trưng giải phẫu X-quang cục bộ hội tụ chặt chẽ về đúng định nghĩa y khoa của chúng trong không gian chung.

Công đoạn Domain-Adaption giúp mô hình học cách biểu diễn sao cho các cặp ảnh và báo cáo khám tổng quát chung lớp nằm gần nhau hơn trong không gian biểu diễn, Semantic Matching Loss giúp các dữ liệu chung lớp nằm gần nhau thay vì ràng buộc như contrastive learning truyền thống

rằng các cặp ảnh và báo cáo chung lớp dù không tương ứng dù nằm chung lớp vẫn phải nằm cách xa nhau ra. Điều này cực quan trọng với bài toán dữ liệu còn hạn chế, giúp tránh trường hợp dữ liệu nằm chung nhóm không hội tụ. Trong quá trình huấn luyện, đạo hàm từ hàm mất mát $\mathcal{L}_{SM}$ chỉ chảy qua và cập nhật ma trận $A \in \mathbb{R}^{r \times k}$ và $B \in \mathbb{R}^{d \times r}$ (với hạng $r \ll \min(d, k)$) của LoRA. Tổng số tham số cần học (learnable parameters) chiếm dưới 5% toàn mạng.

2.3.2 Fusion-learning



Hình 2.3: Sơ đồ chung của hệ thống trong công đoạn Fusion-learning.

Trong công đoạn này, nhóm tối ưu khả năng khai thác và dung hợp dữ liệu bằng cách sử dụng kỹ thuật Bidirectional Cross-Attention để học các mối liên hệ giữa đặc trưng đặc trưng toàn cục của ảnh X-Quang với đặc trưng cục bộ của báo cáo khám tổng quát và ngược lại.

Để mô phỏng sát với quá trình học phân tích ảnh thực tế của bác sĩ, dữ liệu đầu vào của công đoạn này là các cặp ảnh X-quang và báo cáo khám tổng quát. Các dữ liệu này được đưa vào bộ mã hóa tương ứng để


trích xuất đặc trưng. Kỹ thuật cross-attention được sử dụng để học các mối liên hệ giữa các đặc trưng này. Đặc trưng toàn cục của ảnh X-quang được sử dụng để tìm các đặc trưng cục bộ của báo cáo khám tổng quát có liên quan và ngược lại, đặc trưng toàn cục của văn bản được sử dụng để tìm các đặc trưng cục bộ của ảnh X-quang có liên quan. Sau đó, các đặc trưng có liên quan được đưa vào một khối Transformer, nơi chúng được kết hợp một lần nữa thông qua cơ chế attention để học sự phụ thuộc giữa các đặc trưng, tương quan ngữ nghĩa ở mức độ sâu hơn trước khi được đưa vào bộ phân loại cuối cùng để dự đoán nhãn bệnh lý. Sự khác biệt của dự đoán với nhãn thực tế sẽ được tính toán và sử dụng để cập nhật tham số của các khối Cross-Attention, Linear Projection và Transformer cũng như Classifier.

Hàm mất mát được sử dụng là Cross-Entropy Loss $\mathcal{L}_{CE}$, được định nghĩa như sau:

$$\mathcal{L}_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log(\hat{y}_{ik}) \quad (2.4)$$

trong đó, N là kích thước mini-batch, K là số lượng lớp bệnh lý, y_{ik} là nhãn thực tế (one-hot encoded) của mẫu i cho lớp k , và $\hat{y}_{ik}$ là xác suất dự đoán của mô hình cho lớp k của mẫu i . Bằng cách tối ưu $\mathcal{L}_{CE}$, mô hình học được cách phân loại chính xác các bệnh lý dựa trên sự kết hợp của thông tin hình ảnh và văn bản, đồng thời cơ chế cross-attention và khối Transformer giúp mô hình học được các mối liên hệ phức tạp giữa hai nguồn dữ liệu này, từ đó cải thiện hiệu suất phân loại và khả năng giải thích của mô hình.

Nhóm đồng thời sử dụng phương pháp phân loại metric-based few-shot learning với một prototypical network, nhãn được quyết định bởi khoảng cách đến các prototype trong không gian biểu diễn chung, thay vì lớp phân loại truyền thống làm ràng buộc mô hình phân loại vào các nhãn đã biết, giúp phát hiện dữ liệu ngoài phân phối khi khoảng cách đó vượt quá ngưỡng xác định.



Hình 2.4: Sơ đồ mạng prototypical.

Mỗi prototype của một lớp bệnh lý được tính bằng cách lấy trung bình của các đặc trưng của các mẫu hỗ trợ (support samples) thuộc lớp đó trong không gian biểu diễn chung.

$$c_k = \frac{1}{|S_k|} \sum_{(x_i, y_i) \in S_k} f(x_i) \quad (2.5)$$

Trong đó, c_k là prototype của lớp k , S_k là tập các mẫu hỗ trợ thuộc lớp k , và $f(x_i)$ là đặc trưng của mẫu x_i được trích xuất bởi mô hình.

Khoảng cách giữa embedding của mẫu cần phân loại và prototype của lớp được tính bằng khoảng cách Euclidean:

$$d(z, c_k) = \|z - c_k\|^2 \quad (2.6)$$

Xác suất dự đoán của mẫu x thuộc lớp k được tính bằng hàm softmax

trên các khoảng cách đến các prototype:

$$p(y = k|x) = \frac{\exp(-d(z, c_k))}{\sum_{j=1}^K \exp(-d(z, c_j))} \quad (2.7)$$


Trong đó, z là embedding của mẫu x được trích xuất bởi mô hình. Bằng cách sử dụng phương pháp phân loại này, mô hình có thể dự đoán nhãn cho các mẫu mới dựa trên khoảng cách đến các prototype, đồng thời có khả năng phát hiện dữ liệu ngoài phân phối khi khoảng cách đó vượt quá ngưỡng xác định.

Hàm mất mát được sử dụng để tối ưu là Cross-Entropy Loss $\mathcal{L}_{CE}$, được định nghĩa như sau:

$$\mathcal{L}_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log(p(y = k|x_i)) \quad (2.8)$$

trong đó, N là kích thước mini-batch, K là số lượng lớp bệnh lý, y_{ik} là nhãn thực tế (one-hot encoded) của mẫu i cho lớp k , và $p(y = k|x_i)$ là xác suất dự đoán của mô hình cho lớp k của mẫu i được tính bằng hàm softmax trên các khoảng cách đến các prototype. Bằng cách tối ưu $\mathcal{L}_{CE}$, mô hình học được cách phân loại chính xác các bệnh lý dựa trên sự kết hợp của thông tin hình ảnh và văn bản, đồng thời cơ chế cross-attention và khối Transformer giúp mô hình học được các mối liên hệ phức tạp giữa hai nguồn dữ liệu này, từ đó cải thiện hiệu suất phân loại và khả năng giải thích của mô hình.

2.4 Giai đoạn online



Hình 2.5: Sơ đồ chung của hệ thống trong giai đoạn online.

Sơ đồ của hệ thống trong giai đoạn online được trình bày trong Hình 2.5. Gần tương ứng với công đoạn Fine-tuning, ảnh X-Quang cùng báo cáo tổng quát gồm lời khai của bệnh nhân và tiền sử bệnh lý sau tiền xử lý được đưa vào bộ mã hóa tương ứng để trích xuất đặc trưng. Các đặc trưng này được đưa vào khối Cross-Attention để học các mối liên hệ tương tác giữa đặc trưng toàn cục với các đặc trưng cục bộ, sau đó được đưa vào khối Transformer để hợp nhất đặc trưng đa phương thức ở mức độ sâu hơn trước khi được đưa vào mạng prototypical để dự đoán nhãn bệnh lý, ở đây, nhãn được lựa chọn dựa trên khoảng cách đến các prototype, nếu khoảng cách đến prototype gần nhất vượt quá ngưỡng nhất định, mô hình sẽ đánh dấu là không chắc chắn. Ngoài ra, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán. Cụ thể, mô hình có thể tạo ra các bản đồ nhiệt trực quan hóa trên ảnh X-quang dựa trên các trọng số attention để giải thích dự đoán của mô

hình.

2.5 Đóng góp của phương pháp

- **Tích hợp tri thức y khoa với biểu diễn đa phương thức:** Không chỉ sử dụng kết hợp cả hai phương thức dữ liệu, phương pháp đã thực hiện trích xuất các thông tin cần thiết từ văn bản y khoa theo khuôn mẫu, giúp giảm nhiễu ngôn ngữ tự nhiên, tăng tính nhất quán ngữ nghĩa; đồng thời việc làm giàu tri thức qua UMLS giúp làm giàu ngữ nghĩa văn bản theo chuẩn y khoa mà không gặp vấn đề hallucination so với việc tạo ra mô tả bằng LLM.
- **Cơ chế Cross-Attention có hướng dẫn tri thức:** Việc sử dụng cơ chế Cross-Attention có hướng dẫn tri thức giúp mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Điều này không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.
- **Cơ chế fusion ở nhiều cấp độ:** Việc kết hợp đặc trưng toàn cục và cục bộ thông qua Cross-Attention và khối Transformer giúp mô hình khai thác tối đa dữ liệu và học được các mối liên hệ phức tạp giữa hai nguồn dữ liệu, từ đó cải thiện hiệu suất phân loại và khả năng giải thích của mô hình.
- **Giảm nguy cơ suy giảm không gian ngữ nghĩa trong bối cảnh dữ liệu hạn chế:** Cơ chế cập nhật tham số bằng LoRA giúp các bộ mã hóa thích nghi với dữ liệu y khoa đích mà không làm mất mát các tri thức đã học. Điều này giúp hạn chế hiện tượng overfitting và giảm độ phức tạp tính toán.
- **Cơ chế phát hiện dữ liệu ngoài phân phối:** Mô hình có khả năng phát hiện dữ liệu ngoài phân phối với mạng prototypical.

Tài liệu tham khảo

Tiếng Anh

- [1] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image–Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoa2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoa2400640>.