

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - Nguyễn Gia
Kiệt

PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Văn Lê Bá Thành - 22127390

Nguyễn Gia Kiệt - 22127221

**PHÁT TRIỂN HỆ THỐNG PHÂN LỚP
ẢNH X-QUANG VỀ XƯƠNG DỰA VÀO
HỌC SÂU ĐA PHƯƠNG THỨC**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN
CHƯƠNG TRÌNH CHẤT LƯỢNG CAO

GIÁO VIÊN HƯỚNG DẪN

PGS.TS. Lý Quốc Ngọc

ThS. Đỗ Thị Thanh Hà

Tp. Hồ Chí Minh, tháng 07/2026

Lời cảm ơn

Nhóm xin chân thành cảm ơn PGS.TS Lý Quốc Ngọc và ThS. Đỗ Thị Thanh Hà đã dành rất nhiều thời gian, tâm huyết để định hướng, tận tình hướng dẫn và đưa ra những lời khuyên quý báu cho nhóm trong suốt quá trình nghiên cứu và thực hiện khóa luận tốt nghiệp với đề tài "Phát triển hệ thống phân lớp ảnh X-quang về xương dựa vào học sâu đa phương thức".

Xin trân trọng gửi lời cảm ơn sâu sắc đến Ban Chủ nhiệm cùng toàn thể quý thầy cô Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên - ĐHQG-HCM. Những kiến thức nền tảng vững chắc mà các thầy cô đã truyền đạt trong bốn năm học vừa qua và môi trường thí nghiệm tuyệt vời chính là hành trang quan trọng nhất giúp nhóm có thể hoàn thành tốt hướng nghiên cứu này.

Nhóm cũng xin gửi lời cảm ơn đến các y bác sĩ tại Bệnh viện Chấn thương Chỉnh hình TP.HCM và thầy Võ Thế Hào đã hỗ trợ chia sẻ nguồn dữ liệu ảnh X-quang cũng như tư vấn các kiến thức chuyên môn về y khoa, giúp mô hình nghiên cứu bám sát với quy trình chẩn đoán lâm sàng thực tế. NEED FIX

Cuối cùng, nhóm xin dành lời tri ân đến gia đình, người thân và những người bạn đồng hành đã luôn là chỗ dựa tinh thần vững chắc, động viên và tạo mọi điều kiện tốt nhất để nhóm có thể tập trung học tập và hoàn thành khóa luận.

Mặc dù đã có nhiều cố gắng trong quá trình thực hiện, nhưng do hạn chế về mặt thời gian và kinh nghiệm nghiên cứu, khóa luận chắc chắn không tránh khỏi những thiếu sót. Nhóm rất mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô và hội đồng đánh giá để đề tài được hoàn thiện hơn.

Xin chân thành cảm ơn!

Mục lục

Lời cảm ơn	i
Mục lục	ii
1 Giới thiệu	1
1.1 Lý do chọn đề tài	2
1.2 Định nghĩa các khái niệm	3
1.2.1 Thông tin lâm sàng	3
1.2.2 Thông tin cận lâm sàng	3
1.3 Giới thiệu bài toán	4
1.3.1 Ý nghĩa và tính cần thiết của bài toán	5
1.3.2 Các thách thức trong bài toán	6
1.3.3 Các hướng tiếp cận hiện có	6
1.4 Mục tiêu nghiên cứu	7
1.5 Đối tượng và phạm vi nghiên cứu	8
1.5.1 Đối tượng nghiên cứu	8
1.5.2 Phạm vi nghiên cứu	8
1.6 Các câu hỏi nghiên cứu	9
1.7 Đóng góp của luận văn	9
1.8 Bố cục luận văn	9
2 Các công trình nghiên cứu liên quan	11
2.1 Các mô hình nền tảng	11
2.1.1 Các mô hình xây dựng từ đầu	11
2.1.2 Mô hình ngôn ngữ trực quan y khoa (Med-VLMs) .	13
2.1.3 Các mô hình ngôn ngữ lớn y khoa đa phương thức .	15
2.2 Các kỹ thuật tinh chỉnh mô hình	20
2.2.1 Tinh chỉnh sử dụng câu nhắc (Prompt Tuning) . .	20
2.2.2 Tinh chỉnh bộ điều hợp (Adapter Tuning)	21

2.2.3	Tinh chỉnh chọn lọc (Selective Tuning)	22
2.2.4	Cơ sở lựa chọn kỹ thuật LoRA cho hệ thống phân loại y khoa đa phương thức	22
2.3	Các phương pháp nhận diện dữ liệu ngoài phân phối . . .	24
3	Phương pháp đề xuất	25
3.1	Ý tưởng ban đầu	25
3.2	Tiền xử lý văn bản với UMLS	26
3.3	Giai đoạn off-line	26
3.3.1	Domain-Adaption với kỹ thuật LoRA	27
3.3.2	Fusion-learning	29
3.4	Giai đoạn online	33
3.5	Đóng góp của phương pháp	34
	Tài liệu tham khảo	35

Danh sách hình

1.1	Nguồn thông tin lâm sàng bao gồm khai thác bệnh sử và khám thực thể	3
1.2	Nguồn thông tin cận lâm sàng từ hình ảnh X-quang	3
1.3	Nguồn thông tin từ báo cáo đọc ảnh X-quang	4
1.4	Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức	8
3.1	Công đoạn Tiền xử lý văn bản với UMLS.	26
3.2	Sơ đồ chung của hệ thống trong công đoạn Domain-Adaption.	27
3.3	Sơ đồ chung của hệ thống trong công đoạn Fusion-learning.	29
3.4	Sơ đồ mạng prototypical.	31
3.5	Sơ đồ chung của hệ thống trong giai đoạn online.	33

Danh sách bảng

2.1	Bảng tổng hợp nguyên lý của các mô hình kết hợp ngôn ngữ - ảnh nổi bật	13
2.2	Bảng tổng hợp phương pháp của các mô hình kết hợp ngôn ngữ - ảnh nổi bật	13
2.3	Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan	15
2.4	Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;	16
2.5	Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan	17
2.6	Bảng tổng hợp nguyên lý của các mô hình ngôn ngữ lớn đa phương thức	19
2.7	Bảng tổng hợp phương pháp của các mô hình ngôn ngữ lớn đa phương thức	19
2.8	Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan	23

Chương 1

Giới thiệu

Chương này trình bày tổng quan về bài toán hỗ trợ chẩn đoán bệnh lý trên ảnh X-quang bằng học sâu đa phương thức, đặc biệt trong bối cảnh dữ liệu y tế thường có tính phức tạp cao và phụ thuộc mạnh vào kinh nghiệm của bác sĩ trong quá trình phân tích. Bên cạnh thông tin hình ảnh, quá trình chẩn đoán thực tế còn yêu cầu kết hợp thêm các thông tin lâm sàng và báo cáo y khoa nhằm đưa ra đánh giá toàn diện về tình trạng bệnh nhân. Tuy nhiên, việc khai thác đồng thời nhiều nguồn dữ liệu khác nhau vẫn còn là một thách thức lớn đối với các hệ thống học sâu hiện nay.

Xuất phát từ thực tế đó, khóa luận hướng đến nghiên cứu và xây dựng một hệ thống học sâu đa phương thức kết hợp dữ liệu hình ảnh X-quang và thông tin văn bản lâm sàng nhằm nâng cao hiệu năng phân loại và hỗ trợ chẩn đoán. Đồng thời, đề tài cũng khảo sát các phương pháp tinh chỉnh mô hình tiền huấn luyện, cơ chế dung hợp dữ liệu và cơ chế giải thích nhằm tăng khả năng tận dụng tri thức nền cũng như cải thiện tính minh bạch trong quá trình suy luận của mô hình. Kết quả nghiên cứu được kỳ vọng góp phần xây dựng một hệ thống hỗ trợ chẩn đoán có độ chính xác cao, khả năng giải thích tốt và tạo tiền đề cho việc ứng dụng các mô hình trí tuệ nhân tạo đa phương thức trong lĩnh vực y tế tại Việt Nam.

1.1 Lý do chọn đề tài

Hệ xương đóng vai trò rất lớn trong việc nâng đỡ cơ thể, bảo vệ các cơ quan trọng yếu và đảm bảo khả năng vận động của con người. Do đó, chấn thương xương khớp và các bệnh lý về xương là một trong những vấn đề y tế phổ biến, đòi hỏi việc chẩn đoán phải được thực hiện nhanh chóng và chính xác. Trong thực hành lâm sàng, ảnh X-quang xương là phương tiện chẩn đoán hình ảnh cơ bản, phổ biến và có chi phí thấp, cho phép bác sĩ quan sát cấu trúc xương, phát hiện tổn thương và định hướng điều trị ngay từ giai đoạn đầu. Tuy nhiên, việc đọc và phân tích ảnh X-quang truyền thống hiện nay phụ thuộc rất lớn vào kinh nghiệm thực tiễn và sự tập trung của bác sĩ. Điều này dễ dẫn đến những sai sót không đáng có khi lượng bệnh nhân quá lớn gây quá tải cho các y bác sĩ.

Để giải quyết các thách thức này, các nghiên cứu hiện nay đã ứng dụng các mô hình học sâu vào để giải quyết vấn đề đọc ảnh và đưa ra quyết định dựa trên thông tin trên ảnh. Tuy nhiên, các mô hình này vẫn chưa đạt được hiệu quả đủ để đưa vào ứng dụng thực tế. Một trong các lý do chính đó là các mô hình chỉ mới tiếp cận được các thông tin trong ảnh, các y bác sĩ không chỉ dựa vào thông tin thông qua việc đọc ảnh mà còn dựa vào các thông tin từ nhiều nguồn bao gồm: thông tin từ bệnh nhân thông qua lời khai và khám lâm sàng sau đó các xét nghiệm cận lâm sàng như X-quang kèm với thông tin từ bác sĩ đọc ảnh để bổ trợ, từ đó giúp bác sĩ đưa ra chẩn đoán sơ khởi hay chẩn đoán chính xác. Dựa vào thực tế đó, các nghiên cứu hiện nay đang dần chuyển dịch sang hướng tiếp cận đa phương thức nhằm mô phỏng lại quá trình chẩn đoán của bác sĩ nhằm nâng cao hiệu năng của hệ thống.

Khác với các mô hình đơn phương thức chỉ xử lý trên một phương thức như ảnh hay văn bản duy nhất, các mô hình đa phương thức có thể sử dụng nhiều phương thức và tìm ra sự tương quan giữa các phương thức nhằm tạo nên biểu diễn có ý nghĩa hơn từ đó nâng cao hiệu năng của hệ thống. Với thực tế lâm sàng hiện nay, các mô hình nghiên cứu tập trung vào kết hợp ngôn ngữ và hình ảnh hay còn được gọi là mô hình ngôn ngữ trực quan đang là các mô hình đang nhận được nhiều sự chú ý.

1.2 Định nghĩa các khái niệm

Nhằm đảm bảo sự thống nhất trong quá trình nghiên cứu và trình bày, một số khái niệm cơ bản được định nghĩa như sau:

1.2.1 Thông tin lâm sàng

Thông tin lâm sàng là những dữ liệu thu thập trực tiếp qua quá trình bác sĩ thăm khám người bệnh, bao gồm việc khai thác bệnh sử và khám thực thể (nhìn, sờ, gõ, nghe) [20]. Dữ liệu này mang tính chất định hướng ban đầu, giúp bác sĩ khoanh vùng tổn thương và đưa ra các quyết định chỉ định thăm khám chuyên sâu tiếp theo [2].



Hình 1.1: Nguồn thông tin lâm sàng bao gồm khai thác bệnh sử và khám thực thể


1.2.2 Thông tin cận lâm sàng

Thông tin cận lâm sàng là các dữ liệu khách quan thu được từ việc áp dụng các trang thiết bị và kỹ thuật y khoa hiện đại (như hình ảnh X-quang, cắt lớp, hay xét nghiệm sinh hóa) [20]. Nếu lâm sàng dùng để định hướng, thì cận lâm sàng cung cấp bằng chứng xác thực từ bên trong cơ thể để chẩn đoán chính xác bệnh lý.



Hình 1.2: Nguồn thông tin cận lâm sàng từ hình ảnh X-quang

Ngoài ra, thông tin cận lâm sàng còn bao gồm các báo cáo đọc ảnh của bác sĩ đọc ảnh, đây là những dữ liệu văn bản được trích xuất từ quá trình phân tích hình ảnh y tế, cung cấp các nhận định chuyên môn về tình trạng bệnh nhân dựa trên hình ảnh thu được [2].



Hình 1.3: Nguồn thông tin từ báo cáo đọc ảnh X-quang

1.3 Giới thiệu bài toán

Bài toán được nghiên cứu trong đề tài là bài toán phân loại đa nhãn ảnh X-quang sử dụng học sâu đa phương thức. Mục tiêu của hệ thống là dự đoán các loại bệnh hoặc tổn thương dựa trên đồng thời dữ liệu hình ảnh X-quang và thông tin văn bản lâm sàng liên quan.

- **Đầu vào (Input):** Hệ thống nhận vào các nguồn dữ liệu sau:

- Ảnh X-quang của bệnh nhân:

$$x^{img} \in \mathbb{R}^{H \times W \times C}$$

trong đó:

- * H, W : chiều cao và chiều rộng ảnh,
- * C : số kênh màu của ảnh.

- Thông tin văn bản lâm sàng gồm các báo cáo đọc ảnh của bác sĩ đọc ảnh, lời khai bệnh nhân và lịch sử bệnh lý được biểu diễn dưới dạng chuỗi token:

$$x^{txt} = \{w_1, w_2, \dots, w_T\}$$

trong đó:

- * w_t : token thứ t ,
 - * T : số lượng token trong văn bản.
- Tập nhãn được định nghĩa trước:

$$\mathcal{Y} = \{y_1, y_2, \dots, y_K\}$$

với K là số lớp bệnh cần phân loại.

- **Đầu ra (Output):** Hệ thống sinh ra:

- Các nhãn dự đoán cuối cùng, được sắp xếp theo thứ tự:

$$y^* = \arg \max_{k \in \{1, \dots, K\}} \hat{y}_k$$

- Bản đồ nhiệt trực quan hóa trên ảnh nhằm giải thích dự đoán của mô hình

1.3.1 Ý nghĩa và tính cần thiết của bài toán

Trong thực tế lâm sàng, việc chẩn đoán bệnh không chỉ phụ thuộc vào thông tin hình ảnh mà còn yêu cầu kết hợp với các dữ liệu lâm sàng khác nhằm đưa ra đánh giá toàn diện về tình trạng bệnh nhân. Việc nghiên cứu các mô hình đa phương thức có khả năng khai thác đồng thời dữ liệu hình ảnh và văn bản có ý nghĩa quan trọng trong việc hỗ trợ bác sĩ nâng cao độ chính xác chẩn đoán, giảm thời gian phân tích và tăng khả năng phát hiện bệnh ở giai đoạn sớm.

1.3.2 Các thách thức trong bài toán

Mặc dù các mô hình học sâu đa phương thức đã đạt được nhiều kết quả tích cực, bài toán vẫn tồn tại nhiều thách thức cần được giải quyết:

- Tồn tại sự chênh lệch lớn giữa các bộ dữ liệu đa phương thức hiện có (thường là cặp ảnh X-quang và báo cáo đọc ảnh X-quang) so với luồng công việc thực tế lâm sàng (bao gồm ảnh chụp X-quang kết hợp với báo cáo tổng quát), làm hạn chế khả năng ứng dụng trực tiếp của các mô hình.
- Sự khác biệt về đặc trưng giữa dữ liệu hình ảnh và dữ liệu văn bản gây khó khăn cho quá trình học biểu diễn chung, yêu cầu một cơ chế dung hợp hiệu quả.
- Dữ liệu y tế thường có số lượng hạn chế và mất cân bằng giữa các lớp bệnh, đặt ra yêu cầu đặc biệt về thiết kế mô hình để tận dụng tối đa thông tin có sẵn.
- Trong thực tế lâm sàng, luôn có tỉ lệ xuất hiện những loại bệnh mới nằm ngoài dữ liệu huấn luyện, đặt ra yêu cầu về khả năng tổng quát hóa và thích ứng của mô hình.
- Khả năng giải thích của mô hình vẫn còn hạn chế, gây khó khăn cho việc triển khai trong thực tế lâm sàng.

1.3.3 Các hướng tiếp cận hiện có

Các nghiên cứu hiện nay chủ yếu tiếp cận bài toán theo ba hướng chính:

- Các phương pháp đa phương thức kết hợp dữ liệu hình ảnh và văn bản thông qua các chiến lược dung hợp đặc trưng nhằm khai thác mối tương quan giữa các phương thức dữ liệu.
- Các mô hình ngôn ngữ thị giác quy mô lớn được huấn luyện trước trên dữ liệu đa phương thức nhằm học biểu diễn chung giữa ảnh và văn bản.

- Các mô hình ngôn ngữ lớn đa phương thức được huấn luyện trên nhiều tác vụ khác nhau nhằm tăng khả năng suy luận, hiểu ngữ cảnh và hỗ trợ ra quyết định trong các bài toán y tế phức tạp.

Tuy đã đạt được nhiều kết quả khả quan, các nghiên cứu hiện nay phần lớn vẫn tiếp cận vấn đề một cách rời rạc. Chúng thường chỉ tập trung giải quyết riêng lẻ từng thách thức như tiền huấn luyện trên dữ liệu y khoa, học với ít mẫu (few-shot learning) hay phát hiện dữ liệu ngoài phân phối (out-of-distribution detection), mà thiếu đi một khuôn khổ thống nhất. Đáng chú ý nhất, các phương pháp này tồn tại một khoảng trống lớn so với thực tiễn: chúng gần như chỉ phụ thuộc vào cặp dữ liệu ảnh X-quang và báo cáo đọc ảnh X-quang. Việc bỏ qua các báo cáo lâm sàng tổng quát (nguồn thông tin bối cảnh mang tính quyết định) làm giảm đáng kể tính ứng dụng của mô hình. Hơn nữa, việc khai thác mối tương quan ngữ nghĩa đa phương thức giữa hình ảnh và văn bản vẫn chưa đạt hiệu quả tối ưu, kéo theo những hạn chế về khả năng giải thích quá trình suy luận và ra quyết định.

1.4 Mục tiêu nghiên cứu

Đề tài hướng đến việc nghiên cứu và xây dựng một hệ thống học sâu đa phương thức phục vụ hỗ trợ phân loại ảnh X-quang kết hợp với thông tin lâm sàng. Hệ thống được kỳ vọng có khả năng khai thác hiệu quả mối tương quan giữa dữ liệu hình ảnh và báo cáo lâm sàng nhằm nâng cao hiệu năng chẩn đoán so với các mô hình đơn phương thức truyền thống.

Các mục tiêu cụ thể của đề tài bao gồm:

- Khảo sát và phân tích các phương pháp học sâu đa phương thức trong bài toán phân loại ảnh y tế.
- Nghiên cứu các chiến lược dung hợp dữ liệu hình ảnh và văn bản nhằm khai thác tối đa thông tin đa nguồn.
- Nghiên cứu các cơ chế phát hiện dữ liệu ngoài phân phối (out-of-distribution detection) nhằm tăng khả năng tổng quát hóa và độ tin cậy của mô hình trong môi trường lâm sàng thực tế.


- Khảo sát các phương pháp tinh chỉnh tham số hiệu quả cho các mô hình tiền huấn luyện nhằm giảm chi phí huấn luyện và tận dụng tri thức đã có.
- Xây dựng cơ chế giải thích giúp trực quan hóa cơ sở đưa ra quyết định của mô hình.
- Đánh giá hiệu năng và khả năng tổng quát hóa của mô hình trên các bộ dữ liệu công khai và dữ liệu nội bộ.

1.5 Đối tượng và phạm vi nghiên cứu

1.5.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các mô hình học sâu đa phương thức sử dụng đồng thời dữ liệu hình ảnh và văn bản trong bài toán phân loại ảnh X-quang. Nghiên cứu tập trung vào các thành phần chính của một hệ thống đa phương thức bao gồm bộ mã hóa ảnh, bộ mã hóa văn bản, mô-đun dung hợp dữ liệu và bộ phân loại.

Ngoài ra, đề tài cũng khảo sát các phương pháp tinh chỉnh tham số hiệu quả cho các mô hình đã được huấn luyện trước nhằm tận dụng tri thức nền và cải thiện hiệu năng trên tác vụ đích.



Hình 1.4: Khung chương trình tổng quát cho một hệ thống phân loại ảnh sử dụng học sâu đa phương thức

1.5.2 Phạm vi nghiên cứu

Đề tài tập trung nghiên cứu các bài toán phân loại trên ảnh X-quang kết hợp với thông tin văn bản lâm sàng. Dữ liệu văn bản được sử dụng bao gồm báo cáo đọc ảnh, thông tin lâm sàng.

Nghiên cứu chủ yếu sử dụng các bộ dữ liệu cặp ảnh – văn bản đã được công bố công khai cùng với bộ dữ liệu nội bộ được cung cấp thông qua hợp tác với bệnh viện tại Thành phố Hồ Chí Minh. Các bộ dữ liệu này được sử dụng nhằm đánh giá hiệu năng, khả năng tổng quát hóa và tính hiệu quả của mô hình đề xuất thông qua các độ đo phổ biến trong bài toán phân loại.

Đề tài không tập trung vào các bài toán khác như phát hiện đối tượng, phân đoạn ảnh hay sinh báo cáo y khoa tự động.

1.6 Các câu hỏi nghiên cứu

1.7 Đóng góp của luận văn

1.8 Bố cục luận văn

Khóa luận được trình bày một cách hệ thống và logic qua 5 chương, dẫn dắt người đọc từ tổng quan lý thuyết đến thực nghiệm chi tiết và kết luận:

Chương 1: Giới thiệu. Chương này cung cấp cái nhìn tổng quan về bối cảnh nghiên cứu, xác định rõ vấn đề cần giải quyết, mục tiêu, phương pháp tiếp cận và những đóng góp chính của đề tài. Đây là phần nền tảng định hướng cho toàn bộ nội dung khóa luận.

Chương 2: Các công trình nghiên cứu liên quan. Chương này tập trung hệ thống hóa các hướng tiếp cận đã được mô tả ở trên, làm tiền đề cho việc xây dựng giải pháp của khóa luận. Trọng tâm của chương là việc phân tích các kiến trúc mô hình thị giác - ngôn ngữ tiên tiến cùng các chiến lược dung hợp đặc trưng đa phương thức. Bên cạnh đó, các kỹ thuật tinh chỉnh tối ưu và phương pháp nhận diện dữ liệu ngoài phân phối cũng được xem xét toàn diện, từ đó thiết lập cơ sở lý thuyết vững chắc và định vị rõ ràng hướng giải quyết của đề tài so với các công trình đi trước.

Chương 3: Phương pháp đề xuất. Đây là chương trọng tâm mô tả chi tiết quy trình xây dựng hệ thống. Tại đây, nhóm sẽ trình bày cụ thể về kiến trúc mô hình Med-VLM được lựa chọn, quy trình xử lý dữ liệu đầu vào (cả ảnh và văn bản), thiết kế các hàm mất mát (loss functions), và

chiến lược huấn luyện mô hình (training strategy). Các sơ đồ khối và thuật toán sẽ được mô tả chi tiết để minh họa cho giải pháp.

Chương 4: Thực nghiệm và Kết quả. Chương này trình bày về bộ dữ liệu được sử dụng, thiết lập môi trường thực nghiệm và các chỉ số đánh giá (metrics) như Accuracy, F1-Score, AUC-ROC. Kết quả thực nghiệm sẽ được phân tích sâu, so sánh đối chiếu với các phương pháp khác để làm rõ ưu nhược điểm của mô hình đề xuất. Các phân tích sai số (error analysis) cũng được thực hiện để hiểu rõ hành vi của mô hình.

Chương 5: Kết luận và Hướng phát triển. Chương cuối cùng tổng kết lại những kết quả đạt được so với mục tiêu ban đầu, nhìn nhận thẳng thắn những hạn chế còn tồn tại của hệ thống và đề xuất các hướng nghiên cứu tiếp theo để hoàn thiện và mở rộng ứng dụng trong tương lai.

Chương 2

Các công trình nghiên cứu liên quan

Trong giai đoạn hiện nay, rất nhiều nghiên cứu về ứng dụng học sâu đa phương thức vào lĩnh vực y tế đã phát triển rất nhanh và đạt được nhiều thành tựu nổi bật. Phần này sẽ mô tả tổng quan các nghiên cứu về các mô hình nền tảng, các kỹ thuật để tinh chỉnh mô hình và phương pháp phát hiện dữ liệu ngoài phân phối từ đó đưa ra các nhận xét về các phương pháp hiện có làm tiền đề cho phương pháp đề xuất.

2.1 Các mô hình nền tảng

2.1.1 Các mô hình xây dựng từ đầu

Sự kết hợp giữa dữ liệu cận lâm sàng và báo cáo lâm sàng, lịch sử bệnh lý đã tạo ra những bước tiến lớn trong việc cải thiện độ chính xác của các mô hình chẩn đoán chẩn đoán, đặc biệt là thông qua việc sử dụng văn bản để bù đắp những thiếu sót thông tin mà hình ảnh đơn thuần không thể cung cấp. Khởi điểm với các phương pháp sử dụng văn bản để cung cấp bối cảnh lâm sàng thiết yếu. Nghiên cứu của X. Mei [13] trong việc chẩn đoán COVID-19 là một minh chứng rõ nét: khi ảnh chụp CT ngực ở giai đoạn sớm có thể chưa biểu hiện bất thường, việc tích hợp thông tin lâm sàng thông qua mạng MLP với đặc trưng ảnh từ CNN đã giúp mô hình nhận diện chính xác 68% số bệnh nhân dương tính mà các bác sĩ X-quang đã bỏ sót. Điều này khẳng định văn bản có khả năng định hướng chẩn đoán ngay cả khi tín hiệu hình ảnh còn mờ nhạt.

Không chỉ là dữ liệu bổ sung, văn bản còn được khai thác như một "trình thức tiên nghiệm" để hướng dẫn mô hình tập trung vào các vùng ảnh quan

trọng. Mô hình TieNet [0] đã mã hóa các báo cáo y tế và tích hợp các cơ chế chú ý đa cấp độ để làm nổi bật các từ mang ý nghĩa quan trọng, từ đó giống hàng chúng với các vùng ảnh tương ứng. Việc sử dụng văn bản làm tri thức dẫn đường này đã giúp TieNet cải thiện đáng kể kết quả phân loại bệnh lý, tăng trung bình 6% chỉ số AUC so với các mô hình chỉ dùng ảnh.

Mặc dù các mô hình như TransMed [29] đã chứng minh sức mạnh của kiến trúc lai CNN-Transformer trong việc thiết lập sự phụ thuộc ở khoảng cách xa đối với dữ liệu đa phương thức, các phương pháp nổi đặc trưng truyền thống vẫn gặp hạn chế lớn do sự khác biệt về không gian véc-tơ và khoảng cách ngữ nghĩa giữa ảnh và văn bản.

Để giải quyết triệt để vấn đề này, IRENE [0] đã loại bỏ cách tiếp cận trích xuất đặc trưng riêng lẻ. Thay vào đó, IRENE đưa tất cả dữ liệu (hình ảnh, báo cáo lâm sàng không cấu trúc, và dữ liệu cấu trúc) về một dạng token chung và sử dụng một mô hình Transformer duy nhất để học biểu diễn tổng thể. Việc sử dụng cơ chế chú ý đa phương thức hai chiều cho phép văn bản trực tiếp tương tác và giải thích các token của ảnh ở cấp độ cục bộ. Đóng góp của văn bản trong cấu trúc này mang tính quyết định: các thử nghiệm loại bỏ (ablation study) của IRENE chỉ ra rằng, việc thiếu vắng văn bản báo cáo bệnh lý (chief complaints) làm giảm 6% hiệu suất mô hình, và việc bỏ qua các kết quả xét nghiệm làm giảm thêm 4%.

Nhìn chung, những nghiên cứu này minh chứng rằng sự đóng góp của văn bản đã tiến hóa từ việc chỉ là một véc-tơ thông tin ghép nối thêm, trở thành một thành phần cốt lõi có khả năng giống hàng ngữ nghĩa và định hướng sự chú ý, giúp các mô hình học sâu đưa ra chẩn đoán hình ảnh y khoa toàn diện và chính xác hơn.

STT	Tên phương pháp	Nguyên lý
1	TieNet (2018)	Sử dụng các báo cáo y tế như một tri thức tiên nghiệm kết hợp với hình ảnh X-quang để phân loại bệnh lý lồng ngực và tạo báo cáo y khoa tự động. Mô hình tích hợp các cơ chế chú ý đa cấp để làm nổi bật các từ mang ý nghĩa quan trọng và các vùng ảnh tương ứng
2	X. Mei (2020)	Tích hợp các phát hiện trên ảnh chụp CT ngực với các thông tin lâm sàng nhằm chẩn đoán nhanh bệnh nhân nhiễm COVID-19 ở giai đoạn sớm, khi mà ảnh CT có thể chưa có biểu hiện bất thường
3	TransMed (2021)	Kết hợp sức mạnh của CNN trong việc trích xuất đặc trưng cục bộ và của Transformer trong việc thiết lập sự phụ thuộc ở khoảng cách xa để tận dụng mối quan hệ giữa các phương thức/chuỗi trên ảnh y khoa.
4	IRENE (2023)	Thay vì dùng các mô hình riêng biệt cho từng loại dữ liệu, chỉ sử dụng một Transformer duy nhất xử lý đồng thời dữ liệu hình ảnh, văn bản. Nguyên lý mấu chốt là trực tiếp khai thác mối liên kết nội bộ của từng phương thức và giữa các phương thức khác nhau.

Bảng 2.1: Bảng tổng hợp nguyên lý của các mô hình kết hợp ngôn ngữ - ảnh nổi bật

STT	Tên phương pháp	Kiến trúc mô hình			
		Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	TieNet (2018)	ResNet50	word2vec	Feature-level fusion	Fully Connected
2	X. Mei (2020)	Inception-ResNet-v2	MLP	Feature-level fusion	MLP
3	TransMed (2021)	2D CNN (ResNet18 đến 152)	N/a	Feature-level fusion	Fully Connected
4	IRENE (2023)	Convolution layer	Pretrained BERT	Feature-level fusion	MLP

Bảng 2.2: Bảng tổng hợp phương pháp của các mô hình kết hợp ngôn ngữ - ảnh nổi bật

2.1.2 Mô hình ngôn ngữ trực quan y khoa (Med-VLMs)

đánh dấu một bước tiến quan trọng trong việc ứng dụng học sâu đa phương thức vào lĩnh vực y tế. Khác với các mô hình được xây dựng từ đầu (thường cố gắng dung hợp dữ liệu thô thành một khối thống nhất), Med-VLMs chú trọng vào việc đối chiếu và liên kết chặt chẽ ngữ nghĩa giữa hình ảnh và ngôn ngữ tự nhiên. Cụ thể, kiến trúc của chúng thường kế thừa các bộ mã hóa đặc trưng độc lập cho từng phương thức, điển hình như ResNet hoặc ViT cho hình ảnh và các mô hình ngôn ngữ cho văn bản. Thay vì sử dụng các mô-đun dung hợp phức tạp, Med-VLMs tối ưu hóa các hàm mất mát để căn chỉnh không gian đặc trưng của hai phương thức này khớp với nhau. Lúc này, bộ phân loại không gán nhãn theo cách truyền

thống mà đóng vai trò là một cơ chế đo lường mức độ tương đồng. Nhờ biểu diễn đa phương thức mở rộng này, mô hình có khả năng thấu hiểu sâu sắc ngữ nghĩa giữa ảnh X-quang và báo cáo lâm sàng, từ đó cải thiện đáng kể hiệu năng trên nhiều tác vụ y khoa khác nhau.

Để đạt được khả năng trên, các nghiên cứu tiền huấn luyện Med-VLMs hiện nay đang phát triển chủ yếu theo ba hướng: học tương phản, học có che giấu và tích hợp tri thức y khoa (chi tiết tổng hợp được trình bày tại các Bảng 2.3, 2.4, 2.5).

Thứ nhất, **học tương phản (Contrastive Learning)** là chiến lược được ứng dụng rộng rãi nhất, tiêu biểu với các mô hình như ConVIRT [26], GLoRIA [6], MedCLIP [19] và BiomedCLIP [24]. Nguyên lý của chiến lược này là tối ưu hóa không gian biểu diễn bằng cách thu hẹp khoảng cách giữa các cặp đặc trưng ảnh - văn bản tương đồng, đồng thời đẩy các cặp khác biệt ra xa nhau ở mức độ cục bộ lẫn toàn cục. Phương pháp này đem lại hiệu năng ấn tượng; ví dụ, BiomedCLIP [24] (huấn luyện trên 15 triệu cặp dữ liệu) đạt độ chính xác phân loại 83%, trong khi ConVIRT [26] đạt 90,3% trên bộ dữ liệu COVIDx. Mặc dù có ưu điểm vượt trội là khả năng học biểu diễn không cần gán nhãn thủ công, học tương phản vẫn bộc lộ hạn chế về việc tiêu tốn tài nguyên tính toán lớn và rủi ro xảy ra hiện tượng âm tính giả (đẩy xa các cặp dữ liệu bị ghép nhầm dù chúng có chung đặc điểm bệnh lý).

Thứ hai, **học có che giấu (Masked Learning)** là hướng đi tập trung vào mục tiêu tái tạo dữ liệu, với các đại diện nổi bật như MRM [30] và MedViLL [14]. Bằng cách ẩn ngẫu nhiên các vùng ảnh hoặc từ ngữ trong báo cáo y khoa, kiến trúc này buộc mô hình phải dự đoán và khôi phục phần thông tin bị khuyết. Hướng tiếp cận này thể hiện ưu thế rõ rệt trong các môi trường khan hiếm dữ liệu; điển hình là MRM [30] đạt mức 92,7% AUC chỉ với 10% dữ liệu từ tập RSNA. Tuy nhiên, rào cản chính của phương pháp này nằm ở việc phụ thuộc vào nguồn dữ liệu đã được ghép cặp sẵn từ trước, cộng với độ phức tạp tính toán cao của quá trình khôi phục điểm ảnh/token.

Thứ ba, **tích hợp tri thức y khoa (Knowledge Integration)** ra đời nhằm giải quyết những đặc thù phức tạp của ngôn ngữ lâm sàng. Các mô hình như MedKLIP [21], BioViL [3], BioViL-T [1] và KAD [25] tận

dụng đồ thị tri thức (như RadGraph) hoặc dữ liệu chuỗi thời gian để cung cấp tín hiệu giám sát chi tiết về cả loại và vị trí bệnh lý. Cách tiếp cận này giúp giải quyết triệt để sự mơ hồ của các từ vựng diễn tả tiến triển bệnh (ví dụ: "cải thiện", "xấu đi"). Về mặt hiệu năng, KAD [25] đạt 0.966 AUC trên tập PadChest ở thiết lập không mẫu (zero-shot), còn BioViL-T [1] đạt độ chính xác 67,4% trong bài toán phân loại tiến triển bệnh. Dù vậy, các phương pháp này chưa loại bỏ hoàn toàn được hiện tượng âm tính giả và rất dễ gặp sai số nếu nhãn chẩn đoán thực tế nằm ngoài cơ sở tri thức đồ thị gốc.

STT	Tên phương pháp	Phân loại	Nguyên lý
1	ConVIRT (2020)	Học tương phản	Tối ưu bộ mã hoá ảnh và văn bản bằng cách kéo các cặp đặc trưng ảnh-văn bản giống nhau lại gần nhau và đẩy các cặp đặc trưng ảnh-văn bản khác nhau ra xa
2	GLoRIA (2021)	Học tương phản	Dùng hai hàm mất mát global contrastive để kéo các cặp đặc trưng ảnh-văn bản, trong khi đó hàm mất mát local contrastive học cách căn chỉnh chi tiết của các vùng trong ảnh và các từ trong câu
3	MedCLIP (2022)	Học tương phản	Đề xuất cơ chế tách cặp và trích xuất tri thức, và đề xuất hàm mất mát Semantic Matching nhằm giải quyết vấn đề false negative
4	BiomedCLIP (2023)	Học tương phản	Có cơ chế tương tự như CLIP nhưng được tiền huấn luyện với bộ dữ liệu PMC-15M
5	MRM (2023)	Học có che giấu	Ẩn ngẫu nhiên các thông tin trong văn bản và các vùng trong ảnh để cho mô hình dự đoán lại ảnh và văn bản hoàn chỉnh.
6	MedViLL (2022)	Học có che giấu	Đề xuất một kiến trúc dựa trên BERT kết hợp với một mặt nạ chú ý mới được đề xuất (BAR) cho phép ảnh tương tác tự do với văn bản trong các tác vụ hiểu, đồng thời đảm bảo tính tự hồi quy cho các token trong văn bản trong các tác vụ sinh
7	BioViL (2022)	Tích hợp kiến thức y khoa	Đề xuất một bộ mã hoá văn bản CXR-BERT được tối ưu cho ảnh X-quang, duy trì hàm mất mát MLM để giúp mô hình giữ lại được các kiến thức văn bản trong quá trình căn chỉnh với ảnh
8	BioViL-T (2023)	Tích hợp kiến thức y khoa	Sử dụng các ảnh X-quang từ trước kết hợp với ảnh hiện tại để học được các đặc trưng không gian, thời gian từ đó giải thích cho các từ vựng như "cải thiện" giúp giảm đi sự mơ hồ trong báo cáo
9	MedKLIP (2023)	Tích hợp kiến thức y khoa	Đề xuất một mô-đun trích xuất bộ ba và cơ chế mã hoá tăng cường tri thức, từ đó tạo ra biểu diễn tốt hơn cho văn bản
10	KAD (2023)	Tích hợp kiến thức y khoa	Tích hợp kiến thức y khoa vào quá trình tiền huấn luyện để giúp mô hình học các biểu diễn có ý nghĩa hơn

Bảng 2.3: Bảng tổng hợp nguyên lý của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

2.1.3 Các mô hình ngôn ngữ lớn y khoa đa phương thức

Trong thời gian gần đây, với sự phát triển của các mô hình ngôn ngữ lớn được huấn luyện trên những tập dữ liệu rất lớn phục vụ cho rất nhiều

STT	Tên phương pháp	Chiến lược tiền huấn luyện	Mục tiêu tiền huấn luyện	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	ConVIRT (2020)	CL	GCL	ResNet50	BERT	Contrastive Alignment	N/a
2	GLoRIA (2021)	CL	LCL, GCL	ResNet50	BioClinicalBERT	Global-Local Contrastive Alignment	N/a
3	MedCLIP (2022)	CL	GCL	Swin Transformer, ResNet50	BioClinicalBERT	Knowledge-enhanced Alignment	N/a
4	BiomedCLIP (2023)	CL	GCL	ViT-Base	PubMedBERT	Contrastive Alignment	N/a
5	MRM (2023)	MP	MIM, MLM	Kiến trúc giống ViT	WordPiece	Global Context Injection	Văn bản: Transformer; Hình ảnh: Fully Connected
6	MedViLL (2022)	HA	MLM, ITM	ResNet50	BERT	Cross-modal Self-Attention	Multi-Layer Perceptron
7	BioViL (2022)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
8	BioViL-T (2023)	HA	CL, MLM	ResNet50	CXR-BERT	Global-Local Contrastive Alignment	N/A
9	MedKLIP (2023)	CL	LCL	ResNet50	ClinicalBERT	Knowledge-enhanced Alignment	Contrastive head, Cross-Entropy head
10	KAD (2023)	HA	CL, Disease Diagnosis Prediction	ResNet50, ViT-Base	PubMedBERT	Contrastive Alignment	Disease Query Network

Bảng 2.4: Bảng tổng hợp chiến lược, mục tiêu và phương pháp tiền huấn luyện của các mô hình ngôn ngữ trực quan. Trong đó, CL (Contrastive Learning): Học tương phản; GCL (Global Contrastive Learning): Học tương phản toàn cục; LCL (Local Contrastive Learning): Học tương phản cục bộ; MIM (Masked Image Modeling): Mô hình hóa hình ảnh có che giấu; MLM (Masked Language Modeling): Mô hình hóa ngôn ngữ có che giấu; ITM (Image-Text Matching): Ghép nối ảnh - văn bản;

STT	Tên phương pháp	Bộ dữ liệu tiền huấn luyện	Hiệu năng			
			Tác vụ	Bộ dữ liệu đánh giá	Độ đo	Kết quả
1	ConVIRT (2020)	MIMIC-CXR, Private Bone image	- Phân loại ảnh - Phân loại ít mẫu	RSNA Pneumonia, CheXpert, COVIDx, MURA	AUC, Accuracy	- Phân loại ít mẫu: RSNA (1%): 88.8% AUC, (10%): 91.5% AUC; CheXpert (1%): 87.0% AUC, (10%): 88.1% AUC; MURA (1%): 81.3% AUC, (10%): 86.5% AUC - Phân loại ảnh: RSNA: 92.7% AUC, CheXpert: 88.1% AUC, MURA: 89.0% AUC; COVIDx 90.3% ACC
2	GLoRIA (2021)	CheXpert	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	CheXpert, RSNA Pneumonia	AUROC	- Phân loại không mẫu: CheXpert 5x200: 0.61 ACC, 0.67 F1; RSNA: 0.70 ACC, 0.58 F1; - Phân loại ít mẫu: CheXpert (1%): 86.6 AUC, (10%): 87.8 AUC, RSNA (1%): 86.1 AUC, (10%): 88.0 AUC - Phân loại ảnh: CheXpert: 88.1 AUC, RSNA: 88.6 AUC
3	MedCLIP (2022)	MIMIC-CXR, CheXpert	- Phân loại ảnh - Phân loại không mẫu	MIMIC-5x200, COVID, RSNA Pneumonia	Mean Accuracy	- Phân loại không mẫu: CheXpert-5x200: 0.5942 ACC; MIMIC-5x200: 0.5430 ACC; COVID: 0.8472 ACC; RSNA: 0.7682 ACC - Phân loại ảnh: CheXpert-5x200: 0.5960 ACC; MIMIC-5x200: 0.5650 ACC; COVID: 0.7890 ACC; RSNA: 0.8075 ACC
4	BiomedCLIP (2023)	PMC-15M	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PCam, LC25000 (Lung, Colon), TCGA-TIL, RSNA Pneumonia	AUC, Accuracy	- Phân loại không mẫu: PCam: 73.41% ACC; LC25000 Lung 65.23% ACC; LC25000 Colon 92.98%; RSNA 78.95%; TCGA-TIL: 67.04% - Phân loại ít mẫu: PCam (1%): 82% ACC, (10%): 83%; RSNA (1%): 77% ACC, (10%): 82% ACC - Phân loại ảnh: PCam: 83% ACC, RSNA: 83% ACC
5	MRM (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu	CheXpert, NIH ChestX-ray, RSNA Pneumonia, COVID-19 Image Data Collection	AUC, Accuracy	- Phân loại ít mẫu: CheXpert (1%): 88.5 AUC, (10%): 88.5 AUC; RSNA (1%): 91.3 AUC, (10%): 92.7 AUC; NIH ChestX-ray (1%): 79.4 AUC, (10%): 84.0 AUC - Phân loại ảnh: CheXpert: 88.7 AUC, RSNA 93.3, NIH ChestX-ray: 85.9, COVID-19: 85.8
6	MedViLL (2022)	MIMIC-CXR	- Phân loại chẩn đoán	MIMIC-CXR, Open-I	Micro-averaged AUROC, Micro-averaged F1 score	- Phân loại ảnh: MIMIC-CXR: 0.980 avg AUROC, 0.839 F1; Open-I: 0.892 avg AUROC, 0.407 F1
7	BioViL (2022)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	RSNA Pneumonia	Accuracy, F1-score, AUROC, Sensitivity Specificity.	- Phân loại không mẫu: RSNA: 0.732 ACC, 0.831 AUC; ChestX-ray14: 0.6912 AUC - Phân loại ít mẫu: RSNA (1%): 0.805 ACC, 0.881 AUC; (10%): 0.812 ACC, 0.884 AUC - Phân loại ảnh: RSNA: 0.822 ACC, 0.891 AUC
8	BioViL-T (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu - Phân loại ảnh tiến triển	MS-CXR-T, RSNA Penumonia, Chest ImaGenome	Macro-Accuracy, Accuracy, F1, AUROC.	- Phân loại Tiến triển: MS-CXR-T: 67.4% Acc - Phân loại không mẫu: RSNA: 0.805 ACC, 0.871 AUC - Phân loại ít mẫu: RSNA (1%): 0.814 ACC, 0.890 AUC
9	MedKLIP (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại không mẫu	ChestX-ray14, RSNA Pneumonia, SIIM-ACR Pneumothorax, COVIDx CXR-2, COVID Rural, Edema Severity	AUC, F1-score, Accuracy.	- Phân loại không mẫu: RSNA: 0.8694 AUC, 0.6342 F1; SIIM-ACR: 0.8924 AUC, 0.6833 F1; ChestX-ray14: 0.7676 AUC, 0.2525 F1; COVID-19: 0.7396 AUC, 0.7670 F1 - Phân loại ít mẫu: ChestX-ray14 (1%): 0.7721 AUC, (10%): 0.7894; RSNA (1%): 0.8731 AUC, (10%): 0.8799 AUC - Phân loại mẫu: ChestX-ray14: 0.8323 AUC, RSNA 0.8931
10	KAD (2023)	MIMIC-CXR	- Phân loại ảnh - Phân loại ít mẫu - Phân loại không mẫu	PadChest, NIH ChestXray14, CheXpert, ChestX-Det	AUC, F1-Score, MCC	- Phân loại không mẫu: PadChest: 0.966 AUC; CheXpert: 0.905 AUC, 0.647 F1, 0.589 MCC - Phân loại ít mẫu: ChestXray-14 (1%): 0.78 AUC, 0.31 F1; (10%): 0.80 AUC, 0.33 F1 - Phân loại ảnh: ChestXray-14: 0.82 AUC, 0.34 F1

Bảng 2.5: Bảng tổng hợp kết quả của các phương pháp tiền huấn luyện mô hình ngôn ngữ trực quan

tác vụ khác nhau, các mô hình này đang thể hiện sự ảnh hưởng và đa dụng trong lĩnh vực y tế với độ chính xác rất tốt khi chỉ học ít mẫu hoặc không mẫu.

Med-Flamingo [15] là mô hình đầu tiên có khả năng học ít mẫu chuyên dụng cho y tế, thông qua hội thoại tự nhiên để hỗ trợ chẩn đoán. Theo sau đó, LLaVA-Med [10] là mô hình chuyển đổi khả năng thực hiện theo chỉ dẫn (instruction-following) từ miền tổng quát sang lĩnh vực y sinh bằng cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn với 600.000 cặp, với dữ liệu hội thoại tạo ra từ chú thích ảnh y khoa được tạo ra bằng cách sử dụng GPT-4. Phương pháp này đã đề xuất quy trình huấn luyện 2 bước: (1) Căn chỉnh khái niệm; (2) Tinh chỉnh chỉ dẫn đầy đủ; 2 bước này tương ứng với giai đoạn học và suy luận. Kết quả thể hiện khả năng suy luận vượt trội trên dữ liệu chưa từng thấy.

Med-Palm M [18] là mô hình của Google, đánh dấu bước tiến từ các mô hình đơn nhiệm sang đa nhiệm quy mô lớn, có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì sử dụng các mô hình chuyên biệt cho từng tác vụ. Gần đây hơn, SkinGPT-4 [31] là hệ thống chẩn đoán da liễu tương tác đầu tiên sử dụng LLM quy mô lớn với độ chính xác cao, đã kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM), tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Dù đưa đến các phương pháp có độ chính xác cao đến rất cao trong nhiều tác vụ cùng việc hỗ trợ trong việc giao tiếp với mô hình, kích cỡ và chi phí huấn luyện (Med-Flamingo có đến 9 tỷ thông số) để vận hành các mô hình ngôn ngữ lớn đa phương thức là một vấn đề lớn, đi kèm với vấn đề ảo giác có thể gặp phải khi đối mặt với dữ liệu mới hoặc những câu hỏi phức tạp. Ngoài ra nếu yêu cầu một độ chính xác cao - một yêu cầu quan trọng trong lĩnh vực y tế trong một tác vụ cụ thể thì đây không phải một cách tiếp cận tốt cho bài toán này.

STT	Tên phương pháp	Nguyên lý
1	Med-Flamingo (2023)	Huấn luyện (từ nền tảng OpenFlamingo-9B) trên các dữ liệu văn bản và hình ảnh y tế. Mô hình có khả năng học theo ngữ cảnh để sinh ra văn bản tạo các báo cáo, giải thích y khoa hoặc trả lời câu hỏi mở.
2	LLaVA-Med (2023)	Chuyển đổi khả năng theo sát chỉ dẫn (instruction-following) từ miền tổng quát sang miền y sinh bằng cách sử dụng dữ liệu cặp ảnh-văn bản quy mô lớn.
3	Med-PaLM M (2023)	Xây dựng một hệ thống AI y sinh tổng quát (Generalist Biomedical AI) có khả năng xử lý đa nhiệm và đa phương thức bằng một bộ tham số duy nhất, thay vì các mô hình chuyên biệt cho từng tác vụ
4	SkinGPT-4 (2024)	Kết hợp khả năng hiểu hình ảnh y tế chuyên sâu với khả năng suy luận và giao tiếp của các mô hình ngôn ngữ lớn (LLM). Mục tiêu là tạo ra một hệ thống chẩn đoán da liễu có thể tương tác, giải thích lý do và đưa ra lời khuyên hữu ích cho người dùng.

Bảng 2.6: Bảng tổng hợp nguyên lý của các mô hình ngôn ngữ lớn đa phương thức

STT	Tên phương pháp	Phương pháp			
		Bộ mã hoá ảnh	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	Med-Flamingo (2023)	Frozen CLIP ViT	LLaMA-7B	Intermediate fusion	LLaMA Decoder
2	LLaVA-Med (2023)	CLIP ViT-L/14	LLaMA	Projection Matrix	LLM (Vicuna)
3	Med-PaLM M (2023)	ViT (4B - 22B)	PaLM	Multimodal embedding	PaLM
4	SkinGPT-4 (2024)	Vision Transformer	GPT-4	Linear alignment	LLaMA-2-13B

Bảng 2.7: Bảng tổng hợp phương pháp của các mô hình ngôn ngữ lớn đa phương thức

Dựa trên sự phân tích các ưu và nhược điểm từ những khảo sát trên, hướng tiếp cận đề xuất trong nghiên cứu này được thiết kế có chọn lọc nhằm tối ưu hóa hiệu năng và chi phí:

- **Kế thừa BiomedCLIP [24]:** Tận dụng sức mạnh của các bộ mã hóa đã được huấn luyện với chất lượng cao.
- **Không áp dụng học tương phản & học có che giấu:** Khó khắc phục rào cản về tài nguyên tính toán lớn và giảm thiểu rủi ro gặp phải hiện tượng âm tính giả.
- **Tích hợp tri thức từ UMLS (tương tự MedKLIP [21]):** Sử dụng để làm giàu thêm tri thức trong các báo cáo lâm sàng.

2.2 Các kỹ thuật tinh chỉnh mô hình

Sự xuất hiện của các Mô hình Nền tảng (Foundation Models) nói chung và Mô hình Ngôn ngữ - Thị giác Y sinh (Med-VLMs) nói riêng đã mang lại một nền tảng tri thức đa phương thức khổng lồ. Tuy nhiên, để triển khai hiệu quả các mô hình này vào các bài toán lâm sàng đặc thù — chẳng hạn như phát triển hệ thống phân loại ảnh y khoa chỉnh hình kết hợp dữ liệu lâm sàng — quá trình chuyển giao tri thức là bắt buộc.

Trước đây, hai chiến lược phổ biến nhất là tinh chỉnh toàn phần (Full Fine-tuning) và dò tuyến tính (Linear Probing). Tinh chỉnh toàn phần cập nhật lại toàn bộ tham số của mô hình gốc, mang lại khả năng thích ứng cao với miền dữ liệu mới nhưng đòi hỏi chi phí tính toán, bộ nhớ khổng lồ. Hơn nữa, trên các tập dữ liệu y tế ghép cặp thường khan hiếm, phương pháp này rất dễ dẫn đến hiện tượng "quên thảm khốc" (catastrophic forgetting), làm mất đi tri thức tổng quát đã được tiền huấn luyện. Ngược lại, dò tuyến tính đóng băng toàn bộ mạng nơ-ron gốc và chỉ huấn luyện một lớp phân loại duy nhất ở cuối. Dù tiết kiệm tài nguyên đáng kể, dò tuyến tính lại hạn chế khả năng tinh chỉnh các biểu diễn sâu của mô hình, dẫn đến hiệu suất thường dưới mức tối ưu khi sự chênh lệch phân phối (domain shift) giữa dữ liệu gốc và dữ liệu y tế là quá lớn.

Để giải quyết bài toán đánh đổi giữa hiệu năng và chi phí tính toán, Tinh chỉnh Hiệu quả Tham số (Parameter-Efficient Fine-Tuning - PEFT) đã nổi lên như một giải pháp thay thế lý tưởng. Kỹ thuật này chỉ cập nhật hoặc thêm mới một lượng rất nhỏ tham số, giúp tiết kiệm tài nguyên, rút ngắn thời gian huấn luyện và giữ vững khả năng tổng quát hóa. Dựa trên cơ chế can thiệp, các phương pháp PEFT được chia thành ba hướng tiếp cận chính:

2.2.1 Tinh chỉnh sử dụng câu nhắc (Prompt Tuning)

Hướng tiếp cận này chèn thêm các tham số (vector) có thể học được vào không gian đầu vào của mô hình (thị giác hoặc văn bản) mà không thay đổi cấu trúc mạng bên trong.

- **Điểm mạnh:** Tiết kiệm tham số tối đa, bảo toàn nguyên vẹn tri

thức của mô hình gốc, đặc biệt hiệu quả trong các kịch bản học ít mẫu (few-shot) hoặc không mẫu (zero-shot).

- **Điểm yếu:** Việc tối ưu hóa khó khăn do không gian biểu diễn bị giới hạn ở đầu vào, nhạy cảm với cách khởi tạo, và chiếm dụng một phần độ dài của chuỗi đầu vào (sequence length context).

Trong lĩnh vực y tế, các phương pháp như CITE [27], FPT [7] hay PLIP [23] khai thác đặc trưng thị giác kết hợp với tri thức lâm sàng, cho thấy hiệu quả vượt trội ngay cả khi thiếu hụt dữ liệu (ví dụ: PLIP đạt 0.896 AUC chỉ với 5% dữ liệu PanNuke). Nhằm giải quyết khó khăn khi thiết kế thủ công, MedPrompt [28] và UniDCP [22] tự động sinh câu nhắc động dựa trên ngữ cảnh ảnh để xử lý đa tác vụ. Gần đây, việc tích hợp Mô hình ngôn ngữ Lớn (LLM) qua ViP [5], CILMP [4] và BiomedCoOp [8] giúp tạo sinh các câu nhắc ngữ nghĩa sâu sắc, đồng bộ hóa qua cơ chế chú ý chéo và căn chỉnh tương phản.

2.2.2 Tinh chỉnh bộ điều hợp (Adapter Tuning)

Thay vì can thiệp ở không gian đầu vào, phương pháp này chèn các mô-đun mạng nơ-ron siêu nhẹ (adapters) vào giữa các lớp kiến trúc của mạng học sâu (ví dụ: giữa các lớp Transformer).

- **Điểm mạnh:** Tính mô-đun hóa cao, dễ dàng thêm/bớt các adapter cho các tác vụ khác nhau mà không can thiệp vào tham số gốc, dễ hội tụ hơn so với Prompt Tuning.
- **Điểm yếu:** Việc chèn thêm các lớp mạng vật lý làm tăng độ trễ suy luận (inference latency), hạn chế khả năng triển khai trên các hệ thống đòi hỏi thời gian thực.

Diễn hình cho hướng đi này, CLIPath [9] sử dụng kết nối thặng dư để giảm khoảng cách miền trên dữ liệu nhỏ. FTB [16] đặt mô-đun dung hợp giữa bộ mã hóa ảnh và văn bản để chất lọc thông tin đa phương thức. Ở hướng bán giám sát, mô hình MedUnA [17] dùng LLM tạo nhãn giả và tinh chỉnh không giám sát bộ điều hợp trên ảnh chưa gán nhãn, giúp mô hình thích ứng tốt mà không thay đổi trọng số.

2.2.3 Tinh chỉnh chọn lọc (Selective Tuning)

Hướng đi này tối ưu hóa kiến trúc bằng cách không thêm bất kỳ tham số mới nào, mà chỉ chọn lọc ra một lượng nhỏ các tham số (hoặc ma trận trọng số) quan trọng nhất của mô hình gốc để cập nhật.

- **Điểm mạnh:** Không làm thay đổi kiến trúc mô hình, hoàn toàn không gây tăng độ trễ (zero inference latency) do tham số cập nhật được hợp nhất trực tiếp vào trọng số gốc.
- **Điểm yếu:** Đòi hỏi phương pháp heuristic phức tạp để xác định chính xác các tham số nào ảnh hưởng lớn nhất đến hiệu năng của tác vụ mục tiêu.

Về ứng dụng thực tiễn, TransMed [29] kết hợp LLM để chuyển đổi nhãn bệnh thành mô tả chi tiết, trong khi SH-PEFT [12] chỉ tìm và cập nhật các trọng số quan trọng nhất trên bộ mã hóa thị giác. Nổi bật nhất trong nhóm hiệu quả là sự xuất hiện của các cơ chế thích ứng hạng thấp như LoRA (được LCB [11] áp dụng), giúp bám sát hiệu năng của tinh chỉnh toàn phần (đạt 93.1% AUROC trên tập RSNA với 10% dữ liệu gán nhãn) nhưng giảm thiểu tối đa chi phí.

2.2.4 Cơ sở lựa chọn kỹ thuật LoRA cho hệ thống phân loại y khoa đa phương thức

Trong định hướng xây dựng một hệ thống phân loại ảnh y khoa hiệu năng cao kết hợp với dữ liệu lâm sàng, bài toán đặt ra không chỉ là tính chính xác trên các vùng tổn thương đặc thù (như xương khớp), mà còn là tính khả thi khi triển khai các kiến trúc khổng lồ của VLMs. Việc sử dụng toàn bộ mô hình gốc vừa bất khả thi về mặt phần cứng, vừa đối mặt với rủi ro mất đi biểu diễn đặc trưng ngôn ngữ - hình ảnh vốn có. Do đó, kỹ thuật LoRA (Low-Rank Adaptation) được lựa chọn như một phương pháp PEFT cốt lõi với các lý do sau:

1. **Hiệu quả tham số và tài nguyên:** LoRA đóng băng toàn bộ trọng số của mô hình tiền huấn luyện, đồng thời tiêm các ma trận phân rã hạng thấp (low-rank decomposition matrices) vào mạng nơ-ron (chủ

STT	Tên phương pháp	Chiến lược tinh chỉnh	Phương pháp tinh chỉnh	Phương pháp			
				Bộ mã hoá thị giác	Bộ mã hoá văn bản	Chiến lược kết hợp	Bộ giải mã
1	CITE (2023)	Parameter-efficient fine tuning	Visual prompt tuning	CLIP ViT-Base, ImageNet-21k ViT-Base, INTERN ViT-Base	BioLinkBERT-large, BioBERT-large, Kế thừa CLIP	Contrastive Alignment	N/a
2	UniDCP (2023)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	CLIP ViT	RoBERTa	Cross Attention, Contrastive Alignment	N/a
3	ViP (2024)	Parameter-efficient fine tuning	Textual prompt tuning	ViT-Base	Kế thừa CLIP	Cross Attention, Contrastive Alignment	N/a
4	PLIP (2024)	Parameter-efficient fine tuning	Visual prompt tuning, Efficient Selective tuning	ViT-Base	Kế thừa CLIP	Concatnate	N/a
5	FPT (2024)	Parameter-efficient fine tuning	Visual prompt tuning	ViT-Base	N/a	Cross Attention	N/a
6	MedPrompt (2024)	Parameter-efficient fine tuning	Textual prompt tuning	Swin Transformer, ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
7	CILMP (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	ViT-Base	Kế thừa CLIP	Hadamard Product, Concatnate	N/a
8	BiomedCoOp (2025)	Parameter-efficient fine tuning	Visual-Textual prompt tuning	Kế thừa BiomedCLIP	Kế thừa BiomedCLIP	Contrastive Alignment	N/a
9	CLIPath (2023)	Parameter-efficient fine tuning	Adapter tuning	ResNet50	Kế thừa CLIP	Contrastive Alignment	N/a
10	FTB (2024)	Parameter-efficient fine tuning	Adapter tuning	ResNet autoencoder, DINOv2-small, DINOv2-base	BERT, BioBERT, ClinicalBERT, CXR-BERT, PubMedBERT	Cross Attention	N/a
11	MedUnA (2024)	Parameter-efficient fine tuning	Adapter tuning	ViT-Base, MedCLIP-Swin	Kế thừa CLIP, MedCLIP	No Fusion	N/a
12	TransMed (2023)	Parameter-efficient fine tuning	Direct Selective tuning	Swin Transformer, ViT-Base	BERT, LLM/GPT-4	Contrastive Alignment	N/a
13	SH-PEFT (2024)	Parameter-efficient fine tuning	Direct Selective tuning	ViT-Base	Kế thừa CLIP	No Fusion	N/a
14	LCBB (2024)	Parameter-efficient fine tuning	Efficient Selective tuning	Kế thừa MAE, MRM	Kế thừa MAE, MRM	Kế thừa MAE, MRM	N/a

Bảng 2.8: Bảng tổng hợp chiến lược, mục tiêu và phương pháp học chuyển giao của các mô hình ngôn ngữ trực quan

yếu là các khối Attention). Điều này giúp giảm số lượng tham số cần huấn luyện xuống hàng vạn lần và tối ưu hóa VRAM yêu cầu, cho phép tinh chỉnh các mô hình VLM kích thước lớn ngay cả khi nguồn lực máy tính bị hạn chế.

2. Loại bỏ hoàn toàn độ trễ suy luận (Zero Inference Latency):

Khác với Adapter Tuning chèn thêm các lớp ẩn vật lý làm chậm tốc độ xử lý, các ma trận trọng số học được của LoRA có thể được cộng gộp (merge) trực tiếp vào các ma trận trọng số gốc của VLM khi hoàn tất huấn luyện. Đặc tính này mang lại độ trễ tương đương với mô hình gốc, cực kỳ quan trọng đối với các hệ thống hỗ trợ chẩn đoán thời gian thực.

3. Cân bằng giữa thích ứng và bảo toàn tri thức: Ảnh y khoa đòi hỏi mô hình phải nhận diện các đặc trưng họa tiết tinh tế mà mô hình miền tự nhiên có thể bỏ qua. LoRA cho phép mô hình bám sát dữ liệu thị giác y tế đặc thù trong khi không phá vỡ các cấu trúc tri thức đa phương thức tổng quát, tránh hiện tượng quá khớp (overfitting) thường thấy khi full fine-tuning trên các tập dữ liệu nhỏ.

Tóm lại, thông qua việc áp dụng LoRA, hệ thống được đảm bảo tính linh hoạt, tốc độ đáp ứng cao và khả năng khai thác toàn diện sự kết hợp phức tạp giữa mô tả y khoa và hình ảnh X-quang, đáp ứng trọn vẹn yêu cầu của một bài toán y tế chuyên sâu.

2.3 Các phương pháp nhận diện dữ liệu ngoài phân phối

Chương 3

Phương pháp đề xuất

3.1 Ý tưởng ban đầu


Dựa trên các nghiên cứu liên quan, nhóm đề xuất xây dựng một hệ thống học sâu đa phương thức nhằm khai thác đồng thời thông tin từ ảnh X-quang và dữ liệu lâm sàng văn bản. Đặc biệt, hệ thống được thiết kế theo hướng tích hợp tri thức y khoa nhằm nâng cao khả năng học ít mẫu và phát hiện dữ liệu ngoài phân phối. Cụ thể, kiến trúc bao gồm các thành phần chính như sau:

- **Tiền xử lý văn bản với UMLS:** Phương pháp sử dụng GLiNER để trích xuất các tình trạng y khoa cùng với mức độ và vị trí từ báo cáo chẩn đoán ảnh X-quang, sau đó ánh xạ chúng vào hệ thống phân loại UMLS (Unified Medical Language System) để chuẩn hóa và liên kết tri thức từ đó xây dựng được các câu mô tả nhằm làm giàu ngữ nghĩa.
- **Bộ mã hóa ảnh:** Kế thừa lại mô hình ViT-Base của phương pháp BiomedCLIP [24]
- **Bộ mã hóa văn bản:** Kế thừa lại mô hình PubMedBERT của phương pháp BiomedCLIP [24]
- **Bộ dung hợp dữ liệu:** Kỹ thuật Bidirectional Cross-Attention được xây dựng dựa trên cơ chế cross-attention nhằm học mối quan hệ ngữ nghĩa giữa đặc trưng hình ảnh và đặc trưng văn bản y khoa.
- **Bộ phân loại:** Dùng phương pháp metric-based few-shot learning với một prototypical network, nhận được quyết định bởi khoảng cách đến các prototype trong không gian biểu diễn chung, thay vì lớp phân

loại truyền thống làm ràng buộc mô hình phân loại vào các nhãn đã biết, giúp phát hiện dữ liệu ngoài phân phối khi khoảng cách đó vượt quá ngưỡng xác định.

Đồng thời, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán.

3.2 Tiền xử lý văn bản với UMLS



Hình 3.1: Công đoạn Tiền xử lý văn bản với UMLS.


Công đoạn tiền xử lý được thực hiện ở toàn bộ 2 giai đoạn offline và online của phương pháp, sử dụng GLiNER để trích xuất các tình trạng y khoa cùng với mức độ và vị trí từ báo cáo chẩn đoán ảnh X-quang, sau đó ánh xạ chúng vào hệ thống phân loại UMLS (Unified Medical Language System) để chuẩn hóa và liên kết tri thức từ đó xây dựng được các câu mô tả nhằm làm giàu ngữ nghĩa.

3.3 Giai đoạn off-line

Giai đoạn off-line nhằm xây dựng bộ tham số cho mô hình, thiết lập không gian biểu diễn chung và học cách dung hợp giữa đặc trưng hình ảnh X-quang và ngữ nghĩa y khoa.

Giai đoạn off-line gồm 2 công đoạn: Domain-Adaption và Fine-tuning. Trong đó, công đoạn Domain-Adaption nhằm mục đích giúp mô hình thích nghi từ miền dữ liệu tiền huấn luyện lớn sang miền dữ liệu y khoa đích của bài toán, trong khi công đoạn Fine-tuning tập trung vào việc tối ưu hóa khả năng dung hợp dữ liệu và phân loại trên tập dữ liệu mục tiêu.

3.3.1 Domain-Adaption với kỹ thuật LoRA



Hình 3.2: Sơ đồ chung của hệ thống trong công đoạn Domain-Adaption.

Trong công đoạn này, mục tiêu chính giúp mô hình học cách biểu diễn sao cho các cặp ảnh và báo cáo khám tổng quát chung lớp nằm gần nhau hơn trong không gian biểu diễn bằng cách tối ưu hàm mất mát khớp ngữ nghĩa (Semantic Matching Loss), mô hình tuân theo framework contrastive learning để căn chỉnh bộ mã hóa BiomedCLIP về miền dữ liệu X-Quang xương được sử dụng, với đầu vào là các cặp ảnh X-quang và phân tích ảnh tương ứng của bác sĩ. Dữ liệu được đưa vào bộ mã hóa tương ứng để trích xuất đặc trưng, sau đó được chiếu vào không gian chung và chuẩn hóa để so sánh và thực hiện điều chỉnh. Kết quả là các cặp hình ảnh và văn bản giống nhau hoặc chung lớp nằm gần nhau hơn gọi là các semantic clusters, trong khi các cặp văn bản khác lớp sẽ nằm xa nhau hơn.

Nhóm thực hiện tinh chỉnh (fine-tuning) đồng thời Vision Encoder và Text Encoder bằng kỹ thuật LoRA (Low-Rank Adaptation): Thay vì tinh

chỉnh toàn bộ trọng số của Vision Encoder và Text Encoder, kỹ thuật này đóng băng hai Encoder, sau đó chỉ tạo và cập nhật một ma trận nhỏ các tham số hạng thấp (low-rank) được chèn vào các khối Attention của các bộ mã hóa. Điều này giúp giảm thiểu rủi ro quá khớp (overfitting) và bảo tồn tri thức nền tảng của các mô hình mã hóa với trường hợp ít mẫu học.

Để cập nhật trọng số của ma trận LoRA, nhóm sử dụng **Hàm mất mát Khớp ngữ nghĩa (Semantic Matching Loss - $\mathcal{L}_{SM}$)** nhằm đồng bộ hóa không gian biểu diễn đa phương thức. Thay vì tính toán trên các véc-tơ tổng, mô hình thiết lập ma trận tương đồng $s(I_i, T_j)$ dựa trên sự căn chỉnh giữa các vùng ảnh (patches) của ảnh I_i và các từ vựng (tokens) của câu lệnh T_j .

Hàm mất mát được sử dụng là Semantic Matching Loss $\mathcal{L}_{SM}$ được định nghĩa là trung bình cộng của hai hàm mất mát tương phản hai chiều (Bi-directional Contrastive Loss), bao gồm chiều từ ảnh sang chữ ($\mathcal{L}_{I2T}$) và từ chữ sang ảnh ($\mathcal{L}_{T2I}$):

$$\mathcal{L}_{I2T} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s(I_i, T_i)/\tau)}{\sum_{j=1}^N \exp(s(I_i, T_j)/\tau)} \quad (3.1)$$

$$\mathcal{L}_{T2I} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(s(I_i, T_i)/\tau)}{\sum_{j=1}^N \exp(s(I_j, T_i)/\tau)} \quad (3.2)$$


$$\mathcal{L}_{SM} = \frac{1}{2}(\mathcal{L}_{I2T} + \mathcal{L}_{T2I}) \quad (3.3)$$

trong đó, N là kích thước mini-batch, $s(I_i, T_j)$ là điểm tương đồng ngữ nghĩa tổng hợp giữa ảnh i và văn bản j , và τ là siêu tham số nhiệt độ (temperature) giúp điều chỉnh độ nhạy của hàm phạt đối với các mẫu âm tính (negative samples). Bằng cách tối ưu $\mathcal{L}_{SM}$, mô hình đẩy các đặc trưng giải phẫu X-quang cục bộ hội tụ chặt chẽ về đúng định nghĩa y khoa của chúng trong không gian chung.

Công đoạn Domain-Adaption giúp mô hình học cách biểu diễn sao cho các cặp ảnh và báo cáo khám tổng quát chung lớp nằm gần nhau hơn trong không gian biểu diễn, Semantic Matching Loss giúp các dữ liệu chung lớp nằm gần nhau thay vì ràng buộc như contrastive learning truyền thống

rằng các cặp ảnh và báo cáo chung lớp dù không tương ứng dù nằm chung lớp vẫn phải nằm cách xa nhau ra. Điều này cực quan trọng với bài toán dữ liệu còn hạn chế, giúp tránh trường hợp dữ liệu nằm chung nhóm không hội tụ. Trong quá trình huấn luyện, đạo hàm từ hàm mất mát $\mathcal{L}_{SM}$ chỉ chảy qua và cập nhật ma trận $A \in \mathbb{R}^{r \times k}$ và $B \in \mathbb{R}^{d \times r}$ (với hạng $r \ll \min(d, k)$) của LoRA. Tổng số tham số cần học (learnable parameters) chiếm dưới 5% toàn mạng.

3.3.2 Fusion-learning



Hình 3.3: Sơ đồ chung của hệ thống trong công đoạn Fusion-learning.

Trong công đoạn này, nhóm tối ưu khả năng khai thác và dung hợp dữ liệu bằng cách sử dụng kỹ thuật Bidirectional Cross-Attention để học các mối liên hệ giữa đặc trưng đặc trưng toàn cục của ảnh X-Quang với đặc trưng cục bộ của báo cáo khám tổng quát và ngược lại.

Để mô phỏng sát với quá trình học phân tích ảnh thực tế của bác sĩ, dữ liệu đầu vào của công đoạn này là các cặp ảnh X-quang và báo cáo khám tổng quát. Các dữ liệu này được đưa vào bộ mã hóa tương ứng để


trích xuất đặc trưng. Kỹ thuật cross-attention được sử dụng để học các mối liên hệ giữa các đặc trưng này. Đặc trưng toàn cục của ảnh X-quang được sử dụng để tìm các đặc trưng cục bộ của báo cáo khám tổng quát có liên quan và ngược lại, đặc trưng toàn cục của văn bản được sử dụng để tìm các đặc trưng cục bộ của ảnh X-quang có liên quan. Sau đó, các đặc trưng có liên quan được đưa vào một khối Transformer, nơi chúng được kết hợp một lần nữa thông qua cơ chế attention để học sự phụ thuộc giữa các đặc trưng, tương quan ngữ nghĩa ở mức độ sâu hơn trước khi được đưa vào bộ phân loại cuối cùng để dự đoán nhãn bệnh lý. Sự khác biệt của dự đoán với nhãn thực tế sẽ được tính toán và sử dụng để cập nhật tham số của các khối Cross-Attention, Linear Projection và Transformer cũng như Classifier.

Hàm mất mát được sử dụng là Cross-Entropy Loss $\mathcal{L}_{CE}$, được định nghĩa như sau:

$$\mathcal{L}_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log(\hat{y}_{ik}) \quad (3.4)$$

trong đó, N là kích thước mini-batch, K là số lượng lớp bệnh lý, y_{ik} là nhãn thực tế (one-hot encoded) của mẫu i cho lớp k , và $\hat{y}_{ik}$ là xác suất dự đoán của mô hình cho lớp k của mẫu i . Bằng cách tối ưu $\mathcal{L}_{CE}$, mô hình học được cách phân loại chính xác các bệnh lý dựa trên sự kết hợp của thông tin hình ảnh và văn bản, đồng thời cơ chế cross-attention và khối Transformer giúp mô hình học được các mối liên hệ phức tạp giữa hai nguồn dữ liệu này, từ đó cải thiện hiệu suất phân loại và khả năng giải thích của mô hình.

Nhóm đồng thời sử dụng phương pháp phân loại metric-based few-shot learning với một prototypical network, nhận được quyết định bởi khoảng cách đến các prototype trong không gian biểu diễn chung, thay vì lớp phân loại truyền thống làm ràng buộc mô hình phân loại vào các nhãn đã biết, giúp phát hiện dữ liệu ngoài phân phối khi khoảng cách đó vượt quá ngưỡng xác định.



Hình 3.4: Sơ đồ mạng prototypical.

Mỗi prototype của một lớp bệnh lý được tính bằng cách lấy trung bình của các đặc trưng của các mẫu hỗ trợ (support samples) thuộc lớp đó trong không gian biểu diễn chung.

$$c_k = \frac{1}{|S_k|} \sum_{(x_i, y_i) \in S_k} f(x_i) \quad (3.5)$$

Trong đó, c_k là prototype của lớp k , S_k là tập các mẫu hỗ trợ thuộc lớp k , và $f(x_i)$ là đặc trưng của mẫu x_i được trích xuất bởi mô hình.

Khoảng cách giữa embedding của mẫu cần phân loại và prototype của lớp được tính bằng khoảng cách Euclidean:

$$d(z, c_k) = \|z - c_k\|^2 \quad (3.6)$$

Xác suất dự đoán của mẫu x thuộc lớp k được tính bằng hàm softmax

trên các khoảng cách đến các prototype:

$$p(y = k|x) = \frac{\exp(-d(z, c_k))}{\sum_{j=1}^K \exp(-d(z, c_j))} \quad (3.7)$$


Trong đó, z là embedding của mẫu x được trích xuất bởi mô hình. Bằng cách sử dụng phương pháp phân loại này, mô hình có thể dự đoán nhãn cho các mẫu mới dựa trên khoảng cách đến các prototype, đồng thời có khả năng phát hiện dữ liệu ngoài phân phối khi khoảng cách đó vượt quá ngưỡng xác định.

Hàm mất mát được sử dụng để tối ưu là Cross-Entropy Loss $\mathcal{L}_{CE}$, được định nghĩa như sau:

$$\mathcal{L}_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log(p(y = k|x_i)) \quad (3.8)$$

trong đó, N là kích thước mini-batch, K là số lượng lớp bệnh lý, y_{ik} là nhãn thực tế (one-hot encoded) của mẫu i cho lớp k , và $p(y = k|x_i)$ là xác suất dự đoán của mô hình cho lớp k của mẫu i được tính bằng hàm softmax trên các khoảng cách đến các prototype. Bằng cách tối ưu $\mathcal{L}_{CE}$, mô hình học được cách phân loại chính xác các bệnh lý dựa trên sự kết hợp của thông tin hình ảnh và văn bản, đồng thời cơ chế cross-attention và khối Transformer giúp mô hình học được các mối liên hệ phức tạp giữa hai nguồn dữ liệu này, từ đó cải thiện hiệu suất phân loại và khả năng giải thích của mô hình.

3.4 Giai đoạn online



Hình 3.5: Sơ đồ chung của hệ thống trong giai đoạn online.

Sơ đồ của hệ thống trong giai đoạn online được trình bày trong Hình 3.5. Gần tương ứng với công đoạn Fine-tuning, ảnh X-Quang cùng báo cáo tổng quát gồm lời khai của bệnh nhân và tiền sử bệnh lý sau tiền xử lý được đưa vào bộ mã hóa tương ứng để trích xuất đặc trưng. Các đặc trưng này được đưa vào khối Cross-Attention để học các mối liên hệ tương tác giữa đặc trưng toàn cục với các đặc trưng cục bộ, sau đó được đưa vào khối Transformer để hợp nhất đặc trưng đa phương thức ở mức độ sâu hơn trước khi được đưa vào mạng prototypical để dự đoán nhãn bệnh lý, ở đây, nhãn được lựa chọn dựa trên khoảng cách đến các prototype, nếu khoảng cách đến prototype gần nhất vượt quá ngưỡng nhất định, mô hình sẽ đánh dấu là không chắc chắn. Ngoài ra, các trọng số attention và thông tin từ tri thức y khoa được khai thác để trực quan hóa và giải thích kết quả dự đoán. Cụ thể, mô hình có thể tạo ra các bản đồ nhiệt trực quan hóa trên ảnh X-quang dựa trên các trọng số attention để giải thích dự đoán của mô

hình.

3.5 Đóng góp của phương pháp

- **Tích hợp tri thức y khoa với biểu diễn đa phương thức:** Không chỉ sử dụng kết hợp cả hai phương thức dữ liệu, phương pháp đã thực hiện trích xuất các thông tin cần thiết từ văn bản y khoa theo khuôn mẫu, giúp giảm nhiễu ngôn ngữ tự nhiên, tăng tính nhất quán ngữ nghĩa; đồng thời việc làm giàu tri thức qua UMLS giúp làm giàu ngữ nghĩa văn bản theo chuẩn y khoa mà không gặp vấn đề hallucination so với việc tạo ra mô tả bằng LLM.
- **Cơ chế Cross-Attention có hướng dẫn tri thức:** Việc sử dụng cơ chế Cross-Attention có hướng dẫn tri thức giúp mô hình tập trung vào các vùng ảnh có liên quan đến bệnh lý, thay vì các vùng nền không liên quan. Điều này không chỉ cải thiện hiệu năng mà còn cung cấp khả năng giải thích thông qua việc truy vết mối liên hệ giữa khái niệm y khoa và vùng ảnh được chú ý.
- **Cơ chế fusion ở nhiều cấp độ:** Việc kết hợp đặc trưng toàn cục và cục bộ thông qua Cross-Attention và khối Transformer giúp mô hình khai thác tối đa dữ liệu và học được các mối liên hệ phức tạp giữa hai nguồn dữ liệu, từ đó cải thiện hiệu suất phân loại và khả năng giải thích của mô hình.
- **Giảm nguy cơ suy giảm không gian ngữ nghĩa trong bối cảnh dữ liệu hạn chế:** Cơ chế cập nhật tham số bằng LoRA giúp các bộ mã hóa thích nghi với dữ liệu y khoa đích mà không làm mất mát các tri thức đã học. Điều này giúp hạn chế hiện tượng overfitting và giảm độ phức tạp tính toán.
- **Cơ chế phát hiện dữ liệu ngoài phân phối:** Mô hình có khả năng phát hiện dữ liệu ngoài phân phối với mạng prototypical.

Tài liệu tham khảo

Tiếng Anh

- [1] Shruthi Bannur et al. “Learning to exploit temporal structure for biomedical vision-language processing”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2023, pp. 15016–15027.
- [2] Lynn S. Bickley, Peter G. Szilagyi, and Richard M. Hoffman. *Bates’ Guide to Physical Examination and History Taking*. 13th. Lippincott Williams & Wilkins, 2020.
- [3] Benedikt Boecking et al. “Making the Most of Text Semantics to Improve Biomedical Vision–Language Processing”. In: *Computer Vision – ECCV 2022*. Cham: Springer Nature Switzerland, 2022, pp. 1–21. ISBN: 978-3-031-20059-5.
- [4] Ye Du, Nanxi Yu, and Shujun Wang. “Medical Knowledge Intervention Prompt Tuning for Medical Image Classification”. In: *IEEE Transactions on Medical Imaging* 44.12 (2025), pp. 4945–4959. DOI: 10.1109/TMI.2025.3584841.
- [5] Xiao Fang et al. “Aligning Medical Images with General Knowledge from Large Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15010. Springer Nature Switzerland, 2024.
- [6] Shih-Cheng Huang et al. “GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition”. In: *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 3922–3931. DOI: 10.1109/ICCV48922.2021.00391.

- [7] Yijin Huang et al. “Fine-grained Prompt Tuning: A Parameter and Memory Efficient Transfer Learning Method for High-resolution Medical Image Classification”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15012. Springer Nature Switzerland, 2024.
- [8] Taha Koleilat et al. “BiomedCoOp: Learning to Prompt for Biomedical Vision-Language Models”. In: *Proceedings of the Computer Vision and Pattern Recognition Conference (CVPR)*. 2025, pp. 14766–14776.
- [9] Zhengfeng Lai et al. “CLIPath: Fine-Tune CLIP with Visual Feature Fusion for Pathology Image Analysis Towards Minimizing Data Collection Efforts”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*. 2023, pp. 2374–2380.
- [10] Chunyuan Li et al. *LLaVA-Med: Training a Large Language-and-Vision Assistant for Biomedicine in One Day*. arXiv.org, June 2023. DOI: 10.48550/arXiv.2306.00890. URL: <https://arxiv.org/abs/2306.00890>.
- [11] Chenyu Lian et al. *Less Could Be Better: Parameter-efficient Fine-tuning Advances Medical Vision Foundation Models*. 2024. arXiv: 2401.12215 [cs.CV]. URL: <https://arxiv.org/abs/2401.12215>.
- [12] Mingyuan Liu et al. “Sparsity- and Hybridity-Inspired Visual Parameter-Efficient Fine-Tuning for Medical Diagnosis”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15005. Springer Nature Switzerland, 2024.
- [13] Xueyan Mei et al. “Artificial intelligence-enabled rapid diagnosis of patients with COVID-19”. In: *Nature Medicine* 26 (Aug. 2020), 1224–1228. DOI: 10.1038/s41591-020-0931-3. URL: <https://www.nature.com/articles/s41591-020-0931-3>.
- [14] Jong Hak Moon et al. “Multi-Modal Understanding and Generation for Medical Images and Text via Vision-Language Pre-Training”. In:

- IEEE Journal of Biomedical and Health Informatics* 26.12 (2022), pp. 6070–6080. DOI: 10.1109/JBHI.2022.3207502.
- [15] Michael Moor et al. *Med-Flamingo: a Multimodal Medical Few-shot Learner*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.15189. URL: <https://arxiv.org/abs/2307.15189>.
 - [16] Jiuming Qin et al. “Freeze the Backbones: a Parameter-Efficient Contrastive Approach to Robust Medical Vision-Language Pre-Training”. In: *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2024, pp. 1686–1690. DOI: 10.1109/ICASSP48485.2024.10447326.
 - [17] Umaima Rahman et al. “Can language-guided unsupervised adaptation improve medical image classification using unpaired images and texts?” In: *2025 IEEE 22nd International Symposium on Biomedical Imaging (ISBI)*. IEEE. 2025, pp. 1–5.
 - [18] Tao Tu et al. *Towards Generalist Biomedical AI*. arXiv.org, July 2023. DOI: 10.48550/arXiv.2307.14334. URL: <https://arxiv.org/abs/2307.14334>.
 - [0] Xiaosong Wang et al. “TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018.
 - [19] Zifeng Wang et al. “MedCLIP: Contrastive Learning from Unpaired Medical Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yoav Goldberg, Zornitsa Kozareva, and Yue Zhang. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, Dec. 2022, pp. 3876–3887. DOI: 10.18653/v1/2022.emnlp-main.256. URL: <https://aclanthology.org/2022.emnlp-main.256/>.
 - [20] W.B. Saunders. *Dorland’s Illustrated Medical Dictionary*. 32nd. Elsevier Health Sciences, 2011.

- [21] Chaoyi Wu et al. “MedKLIP: Medical Knowledge Enhanced Language-Image Pre-Training for X-ray Diagnosis”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023, pp. 21372–21383.
- [22] Chenlu Zhan et al. “UniDCP: Unifying Multiple Medical Vision-Language Tasks via Dynamic Cross-Modal Learnable Prompts”. In: *IEEE Transactions on Multimedia* 26 (2024), pp. 9736–9748. DOI: 10.1109/TMM.2024.3397191.
- [23] Jiajin Zhang et al. “Disease-informed Adaptation of Vision-Language Models”. In: *proceedings of Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*. Vol. LNCS 15011. Springer Nature Switzerland, 2024.
- [24] Sheng Zhang et al. “A Multimodal Biomedical Foundation Model Trained from Fifteen Million Image-Text Pairs”. In: *NEJM AI* 2.1 (2024). DOI: 10.1056/AIoa2400640. URL: <https://ai.nejm.org/doi/full/10.1056/AIoa2400640>.
- [25] Xiaoman Zhang et al. “Knowledge-enhanced visual-language pre-training on chest radiology images”. In: *Nature Communications* 14 (July 2023). DOI: 10.1038/s41467-023-40260-7. URL: <https://arxiv.org/pdf/2302.14042.pdf>.
- [26] Yuhao Zhang et al. “Contrastive Learning of Medical Visual Representations from Paired Images and Text”. In: *Proceedings of the 7th Machine Learning for Healthcare Conference*. Ed. by Zachary Lipton et al. Vol. 182. Proceedings of Machine Learning Research. PMLR, 2022, pp. 2–25. URL: <https://proceedings.mlr.press/v182/zhang22a.html>.
- [27] Yunkun Zhang et al. “Text-Guided Foundation Model Adaptation for Pathological Image Classification”. In: *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*. Ed. by Hayit Greenspan et al. Cham: Springer Nature Switzerland, 2023, pp. 272–282. ISBN: 978-3-031-43904-9.

- [28] Fudan Zheng et al. “Exploring low-resource medical image classification with weakly supervised prompt learning”. In: *Pattern Recognition* 149 (2024), p. 110250. ISSN: 0031-3203. DOI: <https://doi.org/10.1016/j.patcog.2024.110250>. URL: <https://www.sciencedirect.com/science/article/pii/S0031320324000013>.
- [29] Kaipeng Zheng, Weiran Huang, and Lichao Sun. “TransMed: Large Language Models Enhance Vision Transformer for Biomedical Image Classification”. In: *arXiv preprint arXiv:2312.07125* (2023).
- [0] Hong-Yu Zhou et al. “A transformer-based representation-learning model with unified processing of multimodal input for clinical diagnostics”. In: *Nature Biomedical Engineering* 7 (June 2023), pp. 743–755. DOI: 10.1038/s41551-023-01045-x. (Visited on 11/05/2023).
- [30] Hong-Yu Zhou et al. “Advancing Radiograph Representation Learning with Masked Record Modeling”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: <https://openreview.net/forum?id=w-x7U26GM7j>.
- [31] Juexiao Zhou et al. “Pre-trained multimodal large language model enhances dermatological diagnosis using SkinGPT-4”. In: *Nature Communications* 15 (July 2024). DOI: 10.1038/s41467-024-50043-3. URL: <https://doi.org/10.1038/s41467-024-50043-3>.